



统计学习方法初学者讲义

合并总册

数学基础、监督学习、序列模型、无监督学习与采样方法

v2.7.0 · 完整解析版

2026 年 8 月

面向第一次系统学习统计学习方法的读者

基于知识依赖重新组织，保留原书知识覆盖并展开必要推导

合订本导读

本合订本把五个分册的 37 章统一组织为一条从数学基础到统计学习方法、从监督学习到无监督学习、再到采样方法、主题模型与图排序的完整学习路线。正文复用五个分册的同一套章节内容，并采用全书连续编号，使合订环境中的公式、图表、算法、定理与超链接锚点保持一致。

关键结论

建议先按目录顺序完成第 1 册的数学与统计学习基础，再进入第 2—3 册的监督学习和序列模型；第 4 册建立无监督学习与矩阵分解框架，第 5 册进一步连接随机模拟、主题模型和图排序。每章的学习目标、前置检查、推导、算法、例题、练习、完整解析和自检均可独立闭环。

目录

合订本导读	ii
符号索引	ix
阅读图例与使用说明	xiii
第 1 册：数学基础与统计学习基本理论	1
第 1 章 数学语言、符号约定与学习路线	2
1.1 学习路线与使用说明	5
1.2 集合、映射与函数	6
1.3 标量、向量与矩阵记号	6
1.4 求和、连乘与指示函数	6
1.5 参数、变量、样本、特征与标签	6
1.6 数学逻辑与前置自检	6
第 2 章 线性代数基础	14
2.1 向量、矩阵与分量运算	20
2.2 内积、范数、距离与夹角	20
2.3 线性组合、相关性、基与维数	21
2.4 秩、线性方程组与基本子空间	21
2.5 正交与投影	21
2.6 特征值、对称矩阵、正定性与二次型	23
2.7 谱分解、奇异值预备与幂法	23
第 3 章 多元微积分与矩阵微分	32
3.1 多元函数与偏导数	38
3.2 梯度与方向导数	38
3.3 Hessian 矩阵、泰勒展开与极值	39
3.4 多元链式法则	40
3.5 标量对向量求导	40
3.6 矩阵微分的分量解释与常用公式	40
第 4 章 概率论基础	48
4.1 样本空间、事件与概率	48
4.2 条件概率、全概率与贝叶斯公式	49
4.3 期望、方差、协方差与大数定律	51
4.4 随机变量与概率分布	55
4.5 联合、边缘与条件分布	56
4.6 独立与条件独立	57
第 5 章 常用分布与统计推断	64
5.1 伯努利、二项与多项分布	65
5.2 高斯分布与多元高斯分布	65
5.3 Gamma 与狄利克雷分布	66
5.4 总体、样本、参数与统计量	67
5.5 似然、对数似然与极大似然	67
5.6 先验、后验、共轭与最大后验	69
5.7 边缘似然、隐变量与指数族	71
第 6 章 信息论基础	81
6.1 信息量与熵	82
6.2 条件熵与联合熵	83
6.3 KL 散度与交叉熵	85

6.4	互信息	87
6.5	信息增益与信息增益比	88
6.6	基尼指数	89
第 7 章	凸优化与拉格朗日对偶	98
7.1	优化问题、目标函数与约束	98
7.2	可行域与局部/全局最优	99
7.3	凸集与凸函数	100
7.4	KKT 条件与互补松弛	100
7.5	一阶与二阶凸性条件	104
7.6	Jensen 不等式	104
7.7	拉格朗日乘子与拉格朗日函数	105
7.8	原问题、对偶函数与对偶问题	105
7.9	弱对偶、强对偶与 Slater 条件	106
第 8 章	数值优化方法	117
8.1	梯度下降与步长	117
8.2	线搜索、停止条件与收敛判据	118
8.3	拟牛顿法、DFP 与 BFGS	121
8.4	坐标下降	123
8.5	专项算法章节边界：改进迭代尺度法预告	124
8.6	牛顿法	128
第 9 章	统计学习的基本框架	135
9.1	统计学习与机器学习	142
9.2	监督学习、无监督学习与强化学习	142
9.3	输入、特征与输出空间	143
9.4	假设空间与概率模型	143
9.5	模型、策略与算法	144
第 10 章	模型评估、选择与泛化	151
10.1	损失函数与风险函数	152
10.2	经验风险与期望风险	153
10.3	训练误差与测试误差	154
10.4	过拟合、正则化与模型选择	155
10.5	交叉验证	158
10.6	泛化能力与泛化界	160
10.7	生成方法与判别方法	162
第 11 章	监督学习任务与应用	170
11.1	分类问题	171
11.2	标注问题	173
11.3	回归问题	174
11.4	监督学习应用与方法选择	175
第 2 册：基础监督学习方法		184
第 12 章	感知机	185
12.1	二分类与线性分离	186
12.2	感知机模型	186
12.3	误分类驱动的学习策略	188
12.4	原始形式学习算法	190
12.5	收敛性证明	193
12.6	对偶形式与 Gram 矩阵	194
12.7	例题、判别计算与练习	197
第 13 章	k 近邻法	206
13.1	距离度量、 k 值与分类决策	207
13.2	k 近邻模型与三要素	211

13.3 多类分类与回归扩展	212
13.4 kd 树的构造	213
13.5 kd 树的搜索	216
13.6 例题、复杂度与练习	217
第 14 章 朴素贝叶斯法	226
14.1 生成式分类与条件独立	227
14.2 朴素贝叶斯学习与分类	228
14.3 极大似然参数估计	230
14.4 贝叶斯估计与平滑	231
14.5 参数估计、例题与练习	232
第 15 章 决策树	243
15.1 树模型与条件概率分布	244
15.2 特征选择问题	245
15.3 熵、信息增益与信息增益比	246
15.4 ID3 与 C4.5 生成算法	250
15.5 决策树剪枝	253
15.6 CART 分类与回归树	254
15.7 例题、树模型计算与练习	259
第 16 章 逻辑斯谛回归	268
16.1 二项逻辑斯谛模型	269
16.2 几率、对数几率与概率解释	271
16.3 极大似然与梯度推导	273
16.4 多项逻辑斯谛回归	277
16.5 数值优化、例题与练习	278
第 3 册：优化模型与序列模型	286
第 17 章 最大熵模型	287
17.1 最大熵原理	288
17.2 对偶目标与参数估计	290
17.3 最大熵模型的定义	292
17.4 约束与指数族形式	292
17.5 改进的迭代尺度法	295
17.6 例题、优化计算与练习	298
第 18 章 支持向量机	309
18.1 线性可分支持向量机	310
18.2 超平面、函数间隔与几何间隔	311
18.3 硬间隔最大化与原始问题	312
18.4 拉格朗日对偶、KKT 与支持向量	314
18.5 线性支持向量机与软间隔	316
18.6 松弛变量与合页损失	317
18.7 核技巧与正定核	318
18.8 非线性支持向量机	320
18.9 序列最小最优化算法	321
18.10 证明、例题与练习	325
第 19 章 提升方法	336
19.1 弱学习与强学习	337
19.2 AdaBoost 算法	338
19.3 训练误差与泛化解释	341
19.4 加法模型与前向分步算法	342
19.5 提升树	344
19.6 梯度提升	346
19.7 例题、迭代计算与练习	349

第 20 章 EM 算法及其推广	359
20.1 隐变量、不完全数据与边缘似然	360
20.2 Jensen 不等式与下界构造	361
20.3 E 步与 M 步	364
20.4 单调性与收敛性质	366
20.5 高斯混合模型	367
20.6 EM 算法推广与 GEM	370
20.7 例题、EM 计算与练习	376
第 21 章 隐马尔可夫模型	386
21.1 马尔可夫性质与概率图结构	387
21.2 HMM 定义与三个基本问题	389
21.3 前向与后向算法	391
21.4 Baum-Welch 学习算法	397
21.5 Viterbi 预测算法	400
21.6 条件独立、复杂度与实现	402
21.7 例题与练习	403
第 22 章 条件随机场	412
22.1 概率图、因子与势函数	413
22.2 线性链条件随机场	417
22.3 改进迭代尺度与拟牛顿学习	420
22.4 条件随机场的概率计算	422
22.5 Viterbi 预测	424
22.6 序列标注例题与练习	425
第 23 章 监督学习方法总结	434
23.1 监督学习方法的共同框架	435
23.2 生成方法与判别方法比较	437
23.3 概率模型与非概率模型	438
23.4 线性模型、核方法与集成方法	438
23.5 模型选择与适用条件	439
23.6 综合自检与学习路线	440
第 4 册：无监督学习与矩阵分解	449
第 24 章 无监督学习概论	450
24.1 无监督学习问题	451
24.2 基本方法与任务分类	452
24.3 生成式与表示学习视角	453
24.4 评价、选择与应用	456
第 25 章 聚类方法	465
25.1 聚类问题与相似度	466
25.2 距离与相似度度量	467
25.3 层次聚类	470
25.4 k 均值模型与目标函数	471
25.5 k 均值算法与收敛	474
25.6 例题、聚类计算与练习	479
第 26 章 奇异值分解	486
26.1 SVD 定义与存在性	487
26.2 奇异值和左右奇异向量	490
26.3 紧致与截断 SVD	491
26.4 SVD 的计算	493
26.5 低秩矩阵近似	495
26.6 代数推导与几何解释	498
26.7 例题与练习	499

第 27 章 主成分分析	509
27.1 总体主成分	510
27.2 协方差矩阵与方差最大化	512
27.3 样本主成分	515
27.4 重构误差最小化	517
27.5 PCA 与 SVD 的联系	518
27.6 主成分算法、例题与练习	519
第 28 章 潜在语义分析与非负矩阵分解	530
28.1 文档 – 单词矩阵与潜在语义	531
28.2 LSA 模型	533
28.3 截断 SVD 模型、坐标与最优性	533
28.4 非负矩阵分解模型	535
28.5 数值实现：截断 SVD 与平方损失 NMF	540
28.6 例题、矩阵分解计算与练习	544
第 29 章 概率潜在语义分析	552
29.1 潜在主题与混合表示	553
29.2 PLSA 生成过程与模型	556
29.3 似然函数与隐变量	557
29.4 EM 参数估计	558
29.5 与 LSA、NMF 及 LDA 的联系	564
29.6 例题、参数估计与练习	566
第 5 册：采样方法、主题模型与图排序	576
第 30 章 马尔可夫链基础	577
30.1 随机过程与马尔可夫性质	578
30.2 状态转移矩阵	580
30.3 平稳分布	582
30.4 不可约、非周期与正常返	584
30.5 遍历定理与可逆性	586
30.6 随机游走	592
第 31 章 蒙特卡罗方法与直接采样	605
31.1 蒙特卡罗估计	606
31.2 逆变换抽样	611
31.3 接受 – 拒绝抽样	612
31.4 重要性抽样	616
31.5 估计误差与诊断	618
第 32 章 马尔可夫链蒙特卡罗法	634
32.1 MCMC 基本思想	636
32.2 平稳分布与细致平衡	638
32.3 Metropolis-Hastings 算法	639
32.4 接受率推导	641
32.5 收敛与样本诊断	645
32.6 例题、马尔可夫链计算与练习	654
第 33 章 Gibbs 抽样	666
33.1 完整条件分布	668
33.2 逐变量 Gibbs 抽样	672
33.3 与 Metropolis-Hastings 的关系	674
33.4 收敛、抽样计算与练习	678
第 34 章 狄利克雷分布与共轭先验	690
34.1 多项分布	691
34.2 Gamma 函数与 Beta 分布	693
34.3 狄利克雷分布	695

34.4 一般矩、条件分布与期望对数	698
34.5 Dirichlet- 多项共轭	699
34.6 后验预测与例题	702
第 35 章 潜在狄利克雷分配	715
35.1 文档—主题—单词关系	717
35.2 LDA 生成过程与概率图	718
35.3 折叠 Gibbs 推断	723
35.4 变分 EM 推断	725
35.5 超参数、实现与评估	730
35.6 例题与练习	738
第 36 章 PageRank 算法	749
36.1 网页图与随机游走	751
36.2 基本 PageRank	753
36.3 一般 PageRank 与阻尼	756
36.4 平稳分布与主特征向量	757
36.5 幂法计算	760
36.6 例题、排序计算与练习	764
第 37 章 无监督学习方法总结	773
37.1 聚类、降维、主题模型与采样的联系	775
37.2 矩阵分解与概率模型比较	778
37.3 模型选择与评价	783
37.4 方法选择地图	785
37.5 全书综合自检	789
主题索引	799

符号索引

如何使用符号索引

符号索引按符号定位定义与主要用法；同一符号在不同章节含义不同时，先按页码回到相应章节核对作用域。电子阅读时可点击页码跳转，并用[目录](#)返回学习主线。

A : 邻接矩阵, $A_{ij} > 0$ 表示 $j \rightarrow i$; 角色: 边权存储, 750

A : 本章待分解的任意实矩阵, 不表示图的邻接矩阵, 486

a : 单个实数, 2

A, B : 对象的无序汇集, 2

A, B : 随机事件, 48

$A = (a_{ij})$: $a_{ij} = P(X_{t+1} = j | X_t = i)$, 577

$A = (a_{ij})$: 状态 i 到状态 j 的转移概率, 387

$A = [\alpha_1, \dots, \alpha_m]$: 正交主轴矩阵, $A^T A = I$, 510

a, h : kd 树切分轴与节点深度, 206

$A_j = \{a_{j1}, \dots, a_{js_j}\}$: 第 j 个特征的可能取值, 226

A_k : 保留前 k 项的截断近似, 486

$A \in \mathbb{R}^{m \times n}$: 从 $\mathbb{R}^n$ 到 $\mathbb{R}^m$ 的线性映射表示, 14

$B(a, b)$ 、 $B(\alpha)$: 二元与多元 Beta 函数, 691

$B, C_{in}, C_{out}, T_{max}$: 候选数、内/外层折数、迭代上限; 角色: 复杂度规模, 774

$B = (b_j(k))$: 状态 j 产生观测 v_k 的概率, 387

$B = [\alpha_1, \dots, \alpha_q]$: 前 q 个主轴, $B^T B = I_q$, 510

B_k, G_k : Hessian 与逆 Hessian 近似, 117

$b(x; \gamma)$: 参数为 γ 的基模型, 337

C : 软间隔违约惩罚系数, 310

c : 接受 - 拒绝包络 $p \leq cq$, 606

$C(a, y)$: 采取动作 a 而真实标签为 y 的代价, 435

$C(i)$: 样本 i 的硬类别编号, 466

$c_i(x), h_j(x)$: 不等式约束与等式约束函数, 98

c_j : 结点 j 的加权出度; 角色: 列归一化分母, 750

c_j, C : $c_j = n(d_j) = \sum_i n_{ij}$, $C = \sum_j c_j$ 为总词元数, 553

C_k : 属于第 k 类的样本集合, 243

$C\alpha(T)$: 拟合损失与叶结点复杂度惩罚之和, 243

C, Y_C : 团及团中随机变量, 413

D : 悬挂结点集合; 角色: 需要先修复的零列, 750

D : 本章 Newton 推导中对角元为 $p_i(1 - p_i)$ 的权重矩阵, 269

d : 阻尼因子; 角色: 沿链转移概率, 750

$D = \{(x_i, y_i)\}_{i=1}^N$: 当前结点上的训练数据集, 243

$D(G_p, G_q)$: 两类之间的连接距离, 466

D_i : 特征 A 取第 i 个值时的样本集合, 243

$d(i)$: 状态 i 所有可能正回返时长的最大公约数; 无正回返时约定为 0, 577

$D_m(i)$: 第 m 轮第 i 个训练样本的权重, 337

$D_u f(x)$: 单位方向 u 上的方向导数, 32

d, δ : 有限假设数与失败概率上限, 151

$D_{KL}(P||Q)$: 相对熵, 81

$d(x_i, x_j)$: 样本距离, 466

$D(X||WH)$: 广义 KL 散度型损失, 531

E_i : SMO 误差 $g(x_i) - y_i$, 310

e_m : G_m 在 D_m 下的加权错误率, 337

$E_P(f_i)$: 特征在 $\hat{P}(x)P(y|x)$ 下的期望, 287

f, h : f 用于期望, h 用于积分或被积函数, 606

$f_i(x, y)$: 第 i 个特征函数, $i = 1, \dots, n$, 287

f_{ij}, df_i : 词频与包含 w_i 的文本数, 531

$f_k(y_{i-1}, y_i, x, i)$: 第 k 个局部特征函数, 413

$F_k(y, x)$: 第 k 个全局特征总和, 413

F_m : 前 m 轮的实值加法模型, 337

$f, \hat{y}$: 预测函数与 $\hat{y} = f(x)$, 170

f_θ : 参数为 θ 的模型, 435

f_θ 或 $P_\theta(Y|X)$: 决策函数或条件概率分布, 135

F, Q : $Q(u) = \inf\{x : F(x) \geq u\}$, 606

$F(q, \theta)$: 期望完全数据对数似然与熵之和, 360

$f^\#(x, y)$: IIS 中的特征总量 $\sum_i f_i(x, y)$, 287

$f: \mathbb{R}^d \rightarrow \mathbb{R}$: 输入向量、输出标量, 32

$f: X \rightarrow Y$: 把定义域中的每个元素指定到陪域中的唯一元素, 2

$f(x)$: 目标函数, 98

G : 本章对偶感知机的 Gram 矩阵, $G_{ij} = x_i^T x_j$, 185

G : 一般 PageRank 转移矩阵; 角色: 列随机压缩算子; $v > 0$ 时严格正, 750

$g(D, A), g_R(D, A)$: 信息增益与信息增益比, 243

$G = (V, E)$: 随机变量之间的依赖结构, 413

$G = (V, E)$: 随机游走的状态和允许移动关系, 577

G_m : 第 m 轮基分类器, 337

G_ℓ : 第 ℓ 个类或簇, 466

g_θ : 确定性表示或分配函数, 451

$g(x)$: 判别得分 $w^T x + b$ 或其核展开, 310

$g(x), f(x)$: 判别分数 $g(x) = w^T x + b$ 与类别 $f(x) = \text{sign } g(x)$, 185

$g(x, y)$: 有向提议流 $\tilde{\pi}(x)q(x, y)$, 635

$H(D), H(D|A)$: 经验熵与按特征 A 分组的经验条件熵, 243

$H = [H_{\ell j}]$: NMF 的非负文本系数矩阵, 531

$H_f(x)$: 二阶偏导组成的 Hessian 矩阵, 32

$H(P, Q)$: 用 Q 编码来自 P 的数据的交叉熵, 81

$H(X), H(X|Y)$: 熵与条件熵, 81

$I = (i_1, \dots, i_T)$: 隐状态序列, 387

$I(x)$: 事件结果 x 的自信息 $-\log p(x)$, 81

$I(X; Y)$: 互信息, 81

$J_F(W, H)$: 平方 Frobenius 损失 $\frac{1}{2}\|X - WH\|_F^2$, 531
 $J_g(x)$: $[J_g]_{ij} = \partial g_i / \partial x_j$, 32
 $J_{\text{fit}}, Q_{\text{val}}$: 训练目标、验证指标; 角色: 拟合与选择, 774

K : 本章多项逻辑斯谛模型的类别数, 269
 K : 本章按具体方法限定的候选阶数; 在聚类中为类别数, 在表示学习中为维数, 不混作同一对象, 451
 K : 类别数; 非退化单纯形通常取 $K \geq 2$, 691
 k : 用于预测的近邻个数, 206
 K_j : 只重抽第 j 个坐标的 Gibbs 更新, 667
 K, M : 交叉验证折数与候选配置数, 151
 K_{rs} : 固定权重随机扫描 $\sum_j w_j K_j$, 667
 K_{sys} : 一轮系统扫描 $K_1 K_2 \cdots K_d$, 667
 $K(x, B)$: 从 x 一步进入可测集合 B 的概率, 577
 $K(x, dy)$: 从当前状态 x 到下一状态的转移规则, 635
 $K(x, z)$: 核函数, 等于特征空间内积, 310

$L(\theta)$: 训练策略定义的目标函数, 451
 $L(\theta), \ell(\theta)$: 似然与对数似然, 64
 L, R : 损失与条件风险, 170
 $L(x, \alpha, \beta)$: 拉格朗日函数, 98
 $L(y, f(x))$: 预测 $f(x)$ 相对真实输出 y 的损失, 151
 $L(y, f(x))$: 单次预测的损失, 135
 $L(y, f(x))$: 单样本损失, 435
 $\mathcal{Y}, m$: 真实标签集合及其大小, 413

M : 本章感知机训练中当前被误分类的样本下标集合, 185

M : 未修复的沿链矩阵; 角色: 非悬挂列转移, 750
 M : 本章无监督数据中每个样本的属性维数 (正整数标量), 451

$M_i(x)$: 含边界状态的非负局部因子矩阵, 413
 m, n : 燃烧期转移数与保留状态数, 635
 m, n, k : 词数、文本数和潜在话题数, 531
 M, N, K : 单词数、文档数与预设主题数, 553
 m, n, T : 燃烧轮数、保留轮数及 $T = m + n$, 667
 M, V, K : 文档数、词表大小、主题数; 角色: 三个基本规模参数, 716

α_0 : 总浓度 $\sum_i \alpha_i$, 691
 α_i : 本章对偶感知机中第 i 个样本触发更新的累计强度, 185
 α_i : 本章 SVM 约束的对偶变量; 硬间隔时上界为 $+\infty$, 310

α_i, β_i : 前向与后向非规范化权重, 413

α_i, β_j : 拉格朗日乘子, 98

α_i, λ_i : 第 i 个标准正交方向及其方差, 510

α_k : 第 k 个混合成分的权重, 360

α_m : 第 m 个基分类器的组合系数, 337

α, α, α_0 : 标量形状参数、Dirichlet 参数向量及总浓度, 64

$\alpha_t(i), \beta_t(i)$: 前向概率与后向概率, 387

$\alpha(x, y)$: 从 x 到提议 y 的接受概率, 635

$g: \mathbb{R}^d \rightarrow \mathbb{R}^m$: m 个标量分量函数, 32

α : 文档主题先验; 角色: Dirichlet 超参数, 716

$\alpha = (\alpha_1, \dots, \alpha_K)$: 狄利克雷形状参数, 691

β : 主题词先验; 角色: Dirichlet 超参数, 716

η_{mn} : $q(z_{mn})$ 参数; 角色: 主题责任度, 716

γ_m : $q(\theta_m)$ 参数; 角色: 局部变分参数, 716

$\theta = (\theta_1, \dots, \theta_K)$: 类别概率向量, $\sum_i \theta_i = 1$, 691

θ_m : 文档 - 主题概率向量; 角色: 文档级隐变量, 716
 ϕ_k : 主题 - 词概率向量; 角色: 主题级参数或隐变量, 716

$x, y \in \mathbb{R}^n$: n 个有序分量, 14

$x \in \mathbb{R}^d$: 默认按列书写的向量, 2

m : 均值参数 α/α_0 , 691

$n = (n_1, \dots, n_K)$: 类别计数, $N = \sum_i n_i$, 691

$r^{(t)}$: 第 t 步排名向量; 角色: 幂迭代状态, 750

U_K, Σ_K, V_K : 截断 SVD 因子; 角色: 正交低秩坐标, 774

v : 个性化跳转分布; 角色: 悬挂修复与随机跳转, 750

W, H : 左因子、右因子; 角色: 低秩表示, 774

$X = [x_{ij}]$: 词 - 文档或特征 - 样本矩阵; 角色: 观测数据; 计数、NMF 与话题场景另要求非负, 774

δ_i : IIS 对参数 w_i 的一次增量, 287

Δ_{K-1} : $\theta_i \geq 0$ 且分量和为 1 的集合, 691

$\delta_t(i), \psi_t(i)$: Viterbi 最优前缀值与回溯指针, 387

$\ell(\theta)$: 观测数据对数似然 $\log P(Y | \theta)$, 360

ℓ, Q' : 观测对数似然与去除常数后的 EM 辅助函数, 553

η : 本章感知机更新的学习率, 185

η : 本章 SMO 二变量子问题的曲率

$K_{11} + K_{22} - 2K_{12}$, 不是学习率, 310

η_i : 第 i 主成分方差贡献率, 510

$\Gamma(a)$: Gamma 函数, 691

γ_i : 样本几何间隔 $\hat{\gamma}_i / \|w\|_2$, 310

γ_{ijk} : $\gamma_{ijk} = P(z_k | w_i, d_j)$, E 步责任度, 553

γ_{jk} : 样本 j 属于成分 k 的后验责任度, 360

γ_k, ρ_k : 平稳轨迹的滞后 k 自协方差与自相关, 635

γ, r_t, G_t : 折扣因子、即时奖励与累计回报, 其中 $0 \leq \gamma \leq 1$, 135

$\gamma_t(i)$: 给定完整观测时, 时刻 t 处于状态 i 的后验, 387

$\mathbb{I}(\cdot)$: 条件成立取 1, 否则取 0 的指示函数, 206

$\mathbb{I}\{P\}$: 命题 P 成立取 1, 否则取 0, 2

$\langle x, y \rangle$: $x^T y$, 14

λ : 本章朴素贝叶斯计数的对称平滑强度, 226

λ : 监督学习模型选择中的正则化强度, 435

λ : L_2 正则化强度, 269

$\lambda = (A, B, \pi)$: 离散 HMM 模型参数, 387

$\lambda, J(f)$: 正则化强度与复杂度函数, 151

λ, q : 特征值与对应特征向量, 14

$\mathbb{E}, \text{Var}, \text{Cov}$: 期望、方差、协方差, 48

N_{cnt} : $[N_{\text{cnt}}]_{ij} = n_{ij}$, 稀疏单词 - 文档计数矩阵, 553

$\mathcal{A}$: 本章学习框架中把训练数据和设定变为所选模型的学习算法; 其他章可另作事件族或算子, 135

$\mathcal{A}$: 当前仍可用于划分的特征, 243

$\mathcal{F}$: 学习算法允许选择的假设空间, 135

$\mathcal{F}$: 候选模型或假设空间, 151, 435

$\mathcal{G} = (\mathcal{V}, \mathcal{E})$: 有向图; 角色: 图排序输入, 774

$\mathcal{M}$: 待比较的方法与超参数配置, 435

$\mathcal{M}, \lambda$: 候选方法集合、超参数配置; 角色: 选择空间, 774

$\mathcal{S}$: 状态空间, 577

$\mathcal{V}, \mathcal{E}$: 结点集、有向边集; 角色: 网页图, 750

$\mathcal{X} = \prod_{j=1}^d \mathcal{X}_j$: d 个坐标或变量块的联合取值空间, 667

$(\mathcal{X}, \mathcal{B})$: 马尔可夫链状态空间, 635

$\mathcal{X}, \mathcal{Y}$: 输入空间与输出空间, 170, 435

$\mathcal{X}, \mathcal{Z}, \mathcal{Y}$: 输入空间、特征空间与输出空间, 135

- $\mathcal{Y} = \{c_1, \dots, c_C\}$: 分类标签空间, 206
 TP, FP, FN, TN: 二分类混淆矩阵四项计数, 170
 df : 函数的一阶微分, 32
 μ : 目标期望 $E_p[f(X)]$ 或目标积分, 606
 μ_k, σ_k^2 : 一维高斯成分的均值和方差, 360
 μ_ℓ : 第 ℓ 类中心, 466
 μ, σ^2, Σ : 均值、方差和协方差, 64
 $\nabla f(\mathbf{x})$: 各偏导组成的列梯度, 32
 $\|\mathbf{x}\|_2$: 欧氏范数, 14
 ν : 收缩率或学习率, 337
 $\Omega(f)$: 复杂度或正则项, 435
 $\Omega, \mathcal{F}, P$: 概率空间, 48
 $\text{Gini}(D, A)$: 经特征测试后子集不纯度的加权值, 243
 $\bar{\mathcal{Y}}$: 加入起点和终点后的计算状态集, 413
 ϕ_{ik} : $\phi_{ik} = P(w_i | z_k)$, 主题 k 的单词分布, 553
 Φ, Θ : 分别以 ϕ_{ik} 和 θ_{kj} 为元素的列随机矩阵, 553
 π : 目标分布; 满足 $\int \pi d\mu = 1$, 635
 $\pi = (\pi_i)$: 初始状态分布, 387
 π_j : $\pi_j = P(d_j)$, 本文取经验值 c_j/C , 553
 $\pi_j(t | x_{-j})$: 给定其余坐标时第 j 个坐标的满条件分布, 667
 π_k, θ_{jkl} : 类别先验与类条件概率, 226
 $\pi_{-j}(x_{-j})$: 对 x_j 积分或求和得到的边缘, 667
 $\pi(x)$: Gibbs 链的目标联合分布, 667
 $\psi(a)$: digamma 函数 $d \log \Gamma(a)/da$, 691
 $\psi_C(Y_C)$: 团上的势函数, 413
 ψ, ψ' : digamma、trigamma; 角色: Dirichlet 对数矩与 Newton 步, 716
 $\text{rank}(A)$: 行空间与列空间的共同维数, 14
 ρ : 标准二元正态的相关系数, 667
 $\rho(B), \|B\|_1$: 谱半径、诱导 1 范数; 角色: 收敛与复杂度分析, 750
 ρ_k, ψ_{jk} : 共现参数 $P(z_k)$ 与 $P(d_j | z_k)$, 553
 Σ : 本章 SVD 中的 $m \times n$ 矩形奇异值矩阵, 不表示协方差矩阵, 486
 Σ : 本章 PCA 总体协方差矩阵 $E(\mathbf{z}\mathbf{z}^T)$, 不是 SVD 的矩形奇异值矩阵, 510
 σ_j : 第 j 个奇异值, 按非增次序排列, 486
 $\sigma(z)$: 逻辑斯谛函数 $1/(1 + e^{-z})$, 269
 τ_i : 首次到达状态 i 的时间, 577
 τ_i^+ : 从 i 出发的首次正回返时间, 577
 τ_{int} : 积分自相关时间; ESS 仅在其严格为正时定义, 635
 θ : 由学习过程确定并用于描述模型的量, 2
 θ_{kj} : $\theta_{kj} = P(z_k | d_j)$, 文档 j 的主题混合, 553
 $\theta \in \Theta$: 具体模型的索引及其允许取值范围, 135
 θ, Θ : 未知但固定的模型参数及其可行集合, 64
 $\theta, \theta(t)$: 模型参数及第 t 次迭代值, 360
 ε, c, ρ : 容差、充分下降常数与步长缩减因子, 117
 ε_{jt} : 二元正态 Gibbs 第 t 轮第 j 步的创新, 667
 ε, δ : 停止容差与数值退化阈值, 531
 $\varepsilon, T_{\text{max}}$: 目标 1 范数误差、迭代上限; 角色: 停止与失败保护, 750
 $\hat{y}_i$: 样本函数间隔 $y_i(w^T x_i + b)$, 310
 $\hat{\mu}_N$: N 个样本的蒙特卡罗均值, 606
 $\hat{R}_{\text{test}}$: 锁定测试集平均损失; 角色: 最终性能估计, 774
 $\hat{R}_N(f)$: 经验风险, 435
 $\hat{x}_i, \hat{w}$: 增广向量 $(x_i^T, 1)^T$ 与 $(w^T, b)^T$, 185
 $\tilde{\pi}$: 未归一化目标, $\tilde{\pi} = Z\pi$, $0 < Z < \infty$, 635
 $\bar{E}(f_i)$: 特征在联合经验分布下的期望, 287
 $\bar{P}(x)$: 输入的边缘经验分布, 287
 $\bar{P}(x, y)$: 训练样本联合经验分布, 287
 ξ_i : 第 i 个样本的松弛变量, 310
 $\xi_t(i, j)$: 给定完整观测时, 相邻状态为 i, j 的后验, 387
 N : 样本数, 451
 $N(A)$: $A\mathbf{x} = \mathbf{0}$ 的全部解, 14
 N, B : 目标样本数与最多允许的提议次数, 606
 $n_C(x)$: 邻域中类别 c 的样本数, 206
 n_{ij} : $n_{ij} = n(w_i, d_j)$, 单词 - 文档对的共现次数, 553
 N_{jkl} : 类别 c_k 且第 j 个特征取 a_{jl} 的样本数, 226
 N_k : 训练集中类别 c_k 的样本数, 226
 $N_k(x)$: 查询 x 的 k 个最近训练样本, 206
 N_m, I : 第 m 篇长度、总词元数; 角色: 计算复杂度的样本规模, 716
 n, m, k : 样本数、属性维数、类别数, 466
 n_ℓ : 第 ℓ 类样本数, 466
 N_{eff} : 相对独立样本方差的有效样本量, 635
 n_{mk}, n_{kv} : 文档 - 主题、主题 - 词计数; 角色: 折叠推断充分统计量, 716
 $O = (o_1, \dots, o_T)$: 观测序列, 387
 p : 本章矩阵尺寸给出的奇异值槽位数 $\min(m, n)$, 不是距离阶数, 486
 p : 本章 L_p 距离的阶数, 不表示概率, 206
 p_i : $P(Y = 1 | x_i)$ 的简记, 269
 p_k, α_k : 搜索方向与步长, 117
 $p_\theta(x | z)$: 潜在结构生成观测的条件模型, 451
 $p_\theta(z | x)$: 给定样本后的潜在变量条件分布, 451
 p, q : 目标分布与提议分布, 606
 p^*, d^* : 原问题与对偶问题最优值, 98
 p_X, f_X, F_X : 概率质量、密度、分布函数, 48
 $P(X, Y)$: 产生监督样本的总体统计规律, 135
 $P(y | x)$: 待学习的条件概率, 且对每个 x 按 y 归一化, 287
 $p(y | x)$: 给定输入时输出的条件概率, 170
 α_0^{post} : 后验总浓度 $\alpha_0 + N$, 691
 α^{post} : 后验参数 $\alpha + n$, 691
 $Q(\theta, \theta(t))$: q_t 下完全数据对数似然的期望, 360
 $q_t(z)$: 当前后验 $P(z | Y, \theta(t))$, 360
 $q(x, y)$: 给定 x 时提议 y 的条件密度, $\int q(x, y)\mu(dy) = 1$, 635
 R : 标准化变量的样本相关系数矩阵, 510
 r : 本章近邻搜索的当前最优距离或候选半径, 206
 r : 本章矩阵 A 的秩及正奇异值个数, 不表示搜索半径, 486
 $R(A)$: A 的列空间, 也就是 A 的值域, 14
 $R(f), \hat{R}_N(f)$: 期望风险与训练样本上的经验风险, 151
 $R(f), \hat{R}_T(f)$: 期望风险与经验风险, 135
 R_m, c_m : 回归树的第 m 个区域与区域输出, 243
 r_{mi} : 梯度提升第 m 轮伪残差, 337
 $R_{\text{start}}, R_{\text{chain}}, R_{\text{bootstrap}}$: 多启动、独立链、重采样次数; 角色: 完整实验预算, 774

R, T, T_* : 非零共现对数、训练迭代数与新文档折入迭代数, 553

$r(x)$: 拒绝提议后留在 x 的自环质量, 635

$\rho_{\star}^{\text{row}}$ (正文简称 $\rho_{\star}$): 满足 $\rho_{\star} = \rho_{\star} A$ 的平稳概率行向量, 577

ρ_t^{row} (正文简称 ρ_t): 时刻 t 的边缘概率行向量, 577

S : 悬挂修复后的沿链矩阵; 角色: 基础转移算子, 750

S : 本章 PCA 样本协方差 $X_C X_C^T / (n-1)$, 不是转移算子, 510

$s^2, \widehat{\text{SE}}$: 样本方差与估计标准误, 606

$s_k(x)$: 类别 c_k 的对数后验未归一化得分, 226

s_k, y_k : $x_{k+1} - x_k$ 与 $g_{k+1} - g_k$, 117

s, T_S, T_N : $s = \text{nnz}(X)$ 及 SVD、NMF 迭代轮数, 531

$T = \{(x_i, y_i)\}_{i=1}^N$: 二分类训练集, 185

$T = \{(x_i, y_i)\}_{i=1}^N$: 含 N 个样本的训练集, 206

$T = \{(x_i, y_i)\}_{i=1}^N$: 含 N 个输入-输出对的监督训练集, 135

$T = \{(x_i, y_i)\}_{i=1}^N$: 含 N 个标注样本的训练数据, 170

$T = \{(x_i, y_i)\}_{i=1}^N$: 监督训练数据, 435

$T = (z_1, \dots, z_N)$: 独立同分布训练样本, 151

$T, |T|$: 决策树及其叶结点数, 243

T, V : 类内平均距离阈值与最大距离阈值, 466

$T(x; \Theta_m)$: 第 m 轮树及其区域、叶值参数, 337

T, Y : 一般 LSA 中的单词-话题矩阵与话题-文本矩阵, 531

U : 左正交矩阵, 列为左奇异向量, 486

U_k, Σ_k, V_k : X 的前 k 个奇异三元组, 531

U, Γ, V : $X_C = U \Gamma V^T$ 的紧致 SVD, 510

U_r, Σ_r, V_r : 紧 SVD 的三个因子, 486

$\|\cdot\|_2, \|\cdot\|_F$: 谱范数与 Frobenius 范数, 486

V : 右正交矩阵, 列为右奇异向量, 486

w : 拉格朗日乘子组成的参数向量, 287

w, b : 权重向量与截距, 269

w, b : 超平面法向量与截距, 310

w, b : 超平面的法向量与截距, 185

$W(C, \mu)$: 类内平方和目标, 466

W, D, Z : $W = \{w_i\}_{i=1}^M, D = \{d_j\}_{j=1}^N,$

$Z = \{z_k\}_{k=1}^K$, 553

w, d, z : 取值分别位于 W, D, Z ; z 为隐变量, 553

$W = [W_{i\ell}]$: NMF 的非负话题基矩阵, 531

w_i, d_j : 第 i 个单词与第 j 篇文本, 531

w_j : 随机扫描选择坐标 j 的概率, 667

$w \in \mathbb{R}^K$: 全部特征权重, 413

w_{mn} : 第 m 篇第 n 个词元; 角色: 观测变量, 716

$w(x)$: 重要性权重 $p(x)/q(x)$ 或未归一化权重, 606

X : 以样本为行的数据矩阵, 451

X : 以样本向量为行的设计矩阵, 269

$x_{1:n}$: $x_1, \dots, x_n$ 的简写, 64

$X_{1:n}, Y_{1:n}$: 长度 n 的观测序列与标记序列, 170

$X_{C,\text{row}}, X_C$: 行样本中心化矩阵及其显式转置工作矩阵, 510

$x = (x_1, \dots, x_d)$: 一个完整链状态, 667

$X = (X^{(1)}, \dots, X^{(n)})$: 含 n 个特征的随机输入, 226

$X = [x_{ij}]$: 单词-文本矩阵, $x_j = X[:, j]$ 表示文本 d_j , 531

x_i : 第 i 个可观测样本, 451

x_i : 第 i 个样本, 466

x_i, X_{ij} : 向量第 i 分量与矩阵第 i 行第 j 列分量, 2

X_i, Y_i : 目标样本与提议样本; 下标 i 是样本编号, 606

x_k, g_k, H_k : 第 k 次迭代点、梯度与 Hessian, 117

$x \in \mathbb{R}^d$: 待优化变量, 98

$X \in \mathbb{R}^{n \times d}$: 行对应样本、列对应特征的数据矩阵, 2

x_{-j} : 删除第 j 个坐标后的其余状态, 667

$x, \mu, z = x - \mu$: 随机向量、总体均值与中心化随机向量, 510

$x, \phi(x), y$: 一个实例、特征表示与输出值, 135

X_t : 第 t 次转移后的链状态, 635

$\{X_t\}_{t \geq 0}$: 随机过程; X_t 是时刻 t 的状态, 577

X' : $X'_{ij} = P(w_i, d_j)$ 的联合概率矩阵, 553

x, x_i : 输入特征向量与第 i 个样本的输入, 269

X, Y : 观测序列与标记序列, 413

X, Y : 随机变量, 48

X, Y, Z : 输入、监督输出与潜在表示, 135

Y : 类别随机变量, 226

$Y = (y_1, \dots, y_N)$: 已观测数据; 连续情形把对 Z 的和改为积分, 360

y_i : 本章第 i 个总体主成分得分 $\alpha_i^T z$, 不是监督标签, 510

y_i : 本章逻辑斯蒂模型中的二分类或多分类标签, 269

Y_t : 第 t 次类别观测, 691

$Y_t = f(X_t)$: 目标函数沿轨迹的取值, 635

Z : 未直接观测的完整数据分量, 360

$z = w^T x + b$: 二项模型的线性预测量, 269

$Z = (X, Y)$: 输入输出对, 服从未知分布 P , 151

z_i : 与 x_i 对应的潜在结构, 可为类别、低维向量或图结构, 451

Z_m : 第 m 轮权重更新的规范化因子, 337

z, θ_j, ϕ_k : 主题指标、文档主题分布、主题词分布; 角色: 概率话题表示, 774

z_{mn} : 词元的主题指派; 角色: 离散隐变量, 716

$Z_w(x)$: 对输入 x 的配分函数, 287

$Z_w(x)$: 给定 x 的规范化因子, 413

阅读图例与使用说明

先理解数学对象，再检查稳健实现

正文中的核心算法只回答五件事：数学输入与输出是什么、怎样初始化、核心量怎样更新、何时满足数学停止条件、最终返回什么；主线控制在 10 个数学步骤以内。超过 10 行的故障处理框一律视为稳健实现说明，不属于第一次阅读路径。第一次阅读先沿相邻灰色条带手算一轮；实现时再点击算法标题，查看定义域检查、失败分支、预算和状态语义。

易混淆概念对比

标记	第一次阅读关注	复习或实现时关注
定义／定理	对象、条件与结论	边界、反例与证明细节
例题	读题翻译、第一步与关键变形	核验、迁移与常见误区
算法	初始化、核心更新与数学停止	数值检查、失败状态与资源预算
扩展讨论	暂不阻断当前依赖链	需要严格推广时再进入

怎样使用练习解析。常规题给出 3–6 个必要数学动作；关键题保留完整推导、边界与反例；只有结果不能直接回代时才增加一次独立核验。读题后应先自行列出条件和第一步，再逐步对照解析；同一题不堆叠重复核验。

看到新公式时，先说出对象类型和成立条件；看到算法时，先用最小数值例完成一轮更新。若两者任一做不到，就回到该节的定义或概念桥，而不是先记工程状态码。

第 1 册：数学基础与统计学习基本理论

本册建立后续各类模型共同使用的符号、线性代数、微积分、概率统计、信息论和优化语言，并在此基础上形成统计学习的任务、评估和泛化框架。

1. 数学语言、符号约定与学习路线；
2. 线性代数基础；
3. 多元微积分与矩阵微分；
4. 概率论基础；
5. 常用分布与统计推断；
6. 信息论基础；
7. 凸优化与拉格朗日对偶；
8. 数值优化方法；
9. 统计学习的基本框架；
10. 模型评估、选择与泛化；
11. 监督学习任务与应用。

学习路径

前 8 章负责建立“表达—计算—概率—优化”工具链，第 9—11 章把这些工具放入经验风险、模型评估和监督学习任务中。遇到后续模型的矩阵、梯度、概率或对偶推导时，可沿章节标签回到相应基础章复习。

入册准备与完成标准

学习前应能进行基本代数运算并理解函数与集合。完成本册后，应能独立辨认对象的维数与作用域，复算常见梯度和概率公式，解释经验风险与泛化误差的区别，并为监督学习问题选择合适的评价指标。

第1章 数学语言、符号约定与学习路线

本章地图

核心问题：如何把含糊任务改写成类型、条件和结论都可核对的陈述

可检验学习目标：

- 能把自然语言陈述改写为集合、映射、量词和维数明确的数学陈述；
- 能区分标量、向量、矩阵、参数、样本与标签，并核对上标、下标和转置；
- 能执行“先读定义、再查条件、继而计算、最后解释”的学习流程，并据自检结果选择回看位置。

最短先修：本章只要求整数和实数的四则运算，以及按条件判断一个对象是否属于某个集合。若对负数乘法、分数或括号运算仍不熟练，应先补齐这些运算；其余符号均在本章定义。

依赖路线：本章的依赖顺序是

集合与映射 $\longrightarrow$ 对象类型与索引 $\longrightarrow$ 求和、连乘与指示函数 $\longrightarrow$ 数据角色与逻辑陈述。

这条链也是后续学习路线的最短入口：线性代数依赖对象类型，概率论依赖集合与求和，优化依赖映射、变量和量词。

完成标准与返回：若不能区分对象类型或量词，回看本章对应小节并重新完成章末自检

本章符号表

符号	类型或维数	含义
A, B	集合	对象的无序汇集
$f : X \rightarrow Y$	映射	把定义域中的每个元素指定到陪域中的唯一元素
a	标量	单个实数
$\mathbf{x} \in \mathbb{R}^d$	$d \times 1$	默认按列书写的向量
$X \in \mathbb{R}^{n \times d}$	$n \times d$	行对应样本、列对应特征的数据矩阵
x_i, X_{ij}	标量	向量第 i 分量与矩阵第 i 行第 j 列分量
$\mathbb{I}\{P\}$	$\{0, 1\}$	命题 P 成立取 1，否则取 0
θ	参数	由学习过程确定并用于描述模型的量

问题提出

统计学习把数据、模型和评价准则放在同一套数学语言中。若不声明对象属于什么集合、下标表示什么、等式在什么条件下成立，同一串符号可能产生互相冲突的解释。本章要解决的问题是：怎样把一个含糊任务转写为类型可核对、运算可执行、结论可验证的陈述。

本讲义的工作性检查表。 阅读一个数学陈述时，依次核对四项：涉及哪些对象；每个对象属于什么取值空间；对象之间断言了什么关系；该关系在哪些条件下成立。这是一份帮助读者检查类型、

定义域和前提的阅读约定，并非通行教材中的编号定义，也不把数学陈述限定为某种新的“四元组”对象。后文若引用本段，只表示应执行这四项检查。

核心推导：指示函数把逻辑条件变成计数

阅读目标：把“命题成立/不成立”转换为可求和的数值，并得到样本计数公式。

对象：命题 $P_1, \dots, P_n$ 及其指示量 $\mathbb{I}\{P_i\} \in \{0, 1\}$ 。

合法条件： $n < \infty$ ；每个 P_i 的真假确定；求和项均为标量。

第一步：先逐项写出： P_i 成立时 $\mathbb{I}\{P_i\} = 1$ ，否则为 0。

推导目标

给定命题 $P_1, \dots, P_n$ ，推导满足条件的命题个数，并说明该式如何用于统计分类正确的样本数。

推导准备

已知 $\mathbb{I}\{P_i\} \in \{0, 1\}$ ；有限和允许逐项相加；所有求和项都是标量，因此维数一致。

推导第 1 步：单项编码。按指示函数定义， P_i 成立时第 i 项贡献 1，不成立时贡献 0。

推导第 2 步：有限累加。将 n 个互不要求独立的逻辑判断相加，得到

$$C = \sum_{i=1}^n \mathbb{I}\{P_i\}.$$

每个成立命题恰贡献一个单位，不成立命题不改变总和。

推导第 3 步：对应学习任务。令 P_i 为“预测 $\hat{y}_i$ 等于标签 y_i ”，则正确数与正确率分别为

$$C = \sum_{i=1}^n \mathbb{I}\{\hat{y}_i = y_i\}, \quad \hat{p} = \frac{1}{n} \sum_{i=1}^n \mathbb{I}\{\hat{y}_i = y_i\}.$$

除以 $n > 0$ 只改变尺度，不改变每个样本是否被计入的逻辑。

定理 1.1 (有限指示和的计数性质) 设 $I = \{1, \dots, n\}$ 且 $n \in \mathbb{N}$ 、 $n > 0$ ， $S = \{i \in I : P_i \text{ 成立}\}$ 。则 $\sum_{i=1}^n \mathbb{I}\{P_i\} = |S|$ ，其中 $|S|$ 表示有限集合 S 的元素个数。

证明。证明目标是说明求和的每一个单位与 S 中的一个元素一一对应。对任意 $i \in I$ ，若 $i \in S$ ，则 P_i 成立，定义给出 $\mathbb{I}\{P_i\} = 1$ ；若 $i \notin S$ ，则 $\mathbb{I}\{P_i\} = 0$ 。因此求和时只有属于 S 的下标贡献 1。有限集合 S 中的每个下标被求和范围访问一次，既不重复也不遗漏，所以总和等于 S 的元素个数，结论成立。□

几何理解

几何解释。向量 $\mathbf{x} \in \mathbb{R}^d$ 可视作 d 维空间中的点，也可视为从原点指向该点的箭头；矩阵 X 把 n 个样本按行排列。维数核对相当于检查几何变换的输入空间与输出空间能否衔接。

概率解释

事件是样本空间的子集，事件指示函数是取值为 0 或 1 的随机变量。其平均值记录事件在样本中的发生比例，并为后续“期望等于概率”的关系准备统一语言。

优化解释

优化解释。参数 θ 是搜索对象，允许取值的集合是可行域，评价参数优劣的函数是目标函数。先声明变量与条件，才能判断一次更新是否仍在可行域内。



图 1.1 数学语言从对象声明到任务陈述的依赖关系。每一条箭头都表示右侧内容使用左侧定义。

使用图 1.1 时应从任务端逆向核对：对象、取值域、映射和目标只要有一项未定义，就先补全声明再计算；箭头记录使用关系，不是可逆蕴含。

例题 1.1 (三样本数据的类型核对). 设 $X = \begin{bmatrix} 1 & 0 \\ 2 & 1 \\ 0 & 1 \end{bmatrix} \in \mathbb{R}^{3 \times 2}$, $\boldsymbol{w} = (2, -1)^T \in \mathbb{R}^2$, 标签 $\boldsymbol{y} = (1, 1, -1)^T$. 求 $X\boldsymbol{w}$, 并核对结果维数。

例题 1.1 解答

读题翻译 把三个样本的两维特征矩阵乘以给定权重，既要算出三个线性得分，也要确认结果能与三维标签逐样本对应。

已知与合法条件 $X \in \mathbb{R}^{3 \times 2}$ 、 $\boldsymbol{w} \in \mathbb{R}^2$ 、 $\boldsymbol{y} \in \mathbb{R}^3$ 均按列向量约定；矩阵乘法要求 X 的列数等于 $\boldsymbol{w}$ 的行数。

为什么想到这个方法 先用形状规则确定输出维数，再逐行作内积；最后按矩阵两列的线性组合独立复算。

方法选择 核对 $(3 \times 2)(2 \times 1)$ 的内侧维数，计算三个行内积，并把结果与 $2X_{:1} - X_{:2}$ 及标签长度相互核验。

推导/计算 先核对矩阵乘法的内侧维数：

$$X \in \mathbb{R}^{3 \times 2}, \quad \boldsymbol{w} \in \mathbb{R}^{2 \times 1} \implies X\boldsymbol{w} \in \mathbb{R}^{3 \times 1}.$$

逐行计算得到

$$\begin{aligned} Xw &= \begin{bmatrix} 1 & 0 \\ 2 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 2 \\ -1 \end{bmatrix} \\ &= \begin{bmatrix} 1 \cdot 2 + 0 \cdot (-1) \\ 2 \cdot 2 + 1 \cdot (-1) \\ 0 \cdot 2 + 1 \cdot (-1) \end{bmatrix} \\ &= \begin{bmatrix} 2 \\ 3 \\ -1 \end{bmatrix} \in \mathbb{R}^{3 \times 1}. \end{aligned}$$

独立核验 按列复算得 $2X_{:1} - X_{:2} = (2, 4, 0)^\top - (0, 1, 1)^\top = (2, 3, -1)^\top$ ，与逐行计算一致；结果有三行，恰与三个样本及 $y \in \mathbb{R}^3$ 对应。

结论 $Xw = (2, 3, -1)^\top \in \mathbb{R}^3$ 。

读前自检：常见错误与误用边界：核心推导：指示函数把逻辑条件变成计数。 核心推导：指示函数把逻辑条件变成计数以“边界框首项禁止把 $\in$ 写成 $\subseteq$ ”为约束；请把固定错误“把 $\in$ 写成 $\subseteq$ ”中的对象、操作与结论按本节定义拆开，指出第一个不满足的定义条件，再把该处改为本节允许的写法，并确认改写后的运算或判断有定义，且不再触发“把 $\in$ 写成 $\subseteq$ ”。

常见错误

典型误用包括把 $\in$ 写成 $\subseteq$ 、把向量上标当作幂、忽视矩阵乘法顺序、把参数当作已观测数据，以及否定全称命题时忘记把“所有”改为“至少一个不”。

易混淆概念对比

概念	正确含义	识别问题
$x \in A$ 与 $A \subseteq B$	前者是元素关系，后者是集合关系	左端是对象还是集合？
映射与函数值	f 是规则， $f(x)$ 是规则在 x 处的结果	当前谈的是规则还是输出？
下标与上标	下标常标分量或样本，上标须由上下文声明	上标是样本编号、迭代编号还是幂？
参数与变量	参数在一次模型确定后固定，变量可在定义域内变化	哪个量由学习过程选择？

1.1 学习路线与使用说明

第一册的必学顺序是数学语言、线性代数、多元微分、概率统计、信息论、优化基础、统计学习基本理论。定义后的直观说明可以在复习时跳读；首次出现的分量推导、概率归一化、对偶

条件和算法更新不可跳过。每章结束都要完成自检；未通过时，应返回自检项指定的最早依赖节，而不是继续堆叠新概念。

1.2 集合、映射与函数

集合由互不重复的元素确定。 $x \in A$ 表示 x 属于 A ， $A \subseteq B$ 表示 A 的每个元素都属于 B 。并集 $A \cup B$ 保留至少属于一个集合的元素，交集 $A \cap B$ 保留同时属于两者的元素，差集 $A \setminus B$ 保留属于 A 而不属于 B 的元素。

映射 $f: X \rightarrow Y$ 要求每个 $x \in X$ 恰有一个 $f(x) \in Y$ 。 X 称定义域， Y 称陪域，实际取得的值构成像 $f(X) \subseteq Y$ 。若 $x_1 \neq x_2$ 总能推出 $f(x_1) \neq f(x_2)$ ，则 f 为**单射** (injective)；若 $f(X) = Y$ ，则 f 为**满射** (surjective)；同时为单射和满射的映射称为**双射** (bijective)，此时才存在从 Y 到 X 的逆映射。函数是映射在数值语境中的常用名称。

1.3 标量、向量与矩阵记号

标量 $a \in \mathbb{R}$ 是单个数；向量 $\mathbf{x} \in \mathbb{R}^d$ 默认是 $d \times 1$ 列向量；矩阵 $A \in \mathbb{R}^{m \times n}$ 有 m 行 n 列。粗体小写字母表示向量，大写字母表示矩阵，普通小写字母表示标量。运算前应先写维数，再核对内侧维数。

x_i 表示第 i 个分量， $\mathbf{x}^{(r)}$ 常表示第 r 个样本或第 r 次迭代，具体含义必须就地声明。转置 A^T 交换行列，满足 $(A^T)_{ij} = A_{ji}$ 。上标若表示幂，应使用标量语境并避免与样本编号混用。

1.4 求和、连乘与指示函数

$\sum_{i=1}^n a_i = a_1 + \cdots + a_n$ ， $\prod_{i=1}^n a_i = a_1 \cdots a_n$ 。索引 i 是局部记号，可改名而不改变值；范围和被运算项决定表达式。有限和满足线性性，有限连乘在出现零因子时等于零。

读前自检：指示函数。 先锁定数学语言、符号约定与学习路线中的指示函数的条件“指示函数定义为 $\mathbb{I}\{P\} = 1$ 当且仅当命题 P 成立，否则为 0 ”：检查 $\mathbb{I}\{P\} = 1$ 中每项的类型后完成等式变形，所得结果应满足两端运算均有定义、类型一致且化为同一结果。

指示函数定义为 $\mathbb{I}\{P\} = 1$ 当且仅当命题 P 成立，否则为 0 。它把分类、集合成员关系和事件发生转换为可求和的数值，前述定理给出了其计数意义。

1.5 参数、变量、样本、特征与标签

一个监督学习数据集可写为 $\mathcal{D} = \{(\mathbf{x}^{(i)}, y_i)\}_{i=1}^n$ 。 $\mathbf{x}^{(i)} \in \mathbb{R}^d$ 是第 i 个样本的特征向量， $x_j^{(i)}$ 是其第 j 个特征， y_i 是标签。模型 f_θ 以变量 $\mathbf{x}$ 为输入，以参数 θ 控制其具体形状；训练数据被观测，参数由学习策略和算法确定。

1.6 数学逻辑与前置自检

命题是可判断真假的陈述。 $\forall x \in X, P(x)$ 表示定义域中每个 x 都满足 P ； $\exists x \in X, P(x)$ 表示至少存在一个满足者。全称命题的否定是 $\exists x \in X, \neg P(x)$ ，存在命题的否定是 $\forall x \in X, \neg P(x)$ 。蕴含 $P \Rightarrow Q$ 只在 P 真而 Q 假时为假；充要条件写作 $P \Leftrightarrow Q$ 。

本章共 19 道练习。每道题干后立即给出同号解析；长解析可自然跨页，续页标题保留题号。

练习 1.1 (路线依赖). 说明为什么应在矩阵微分之前学习矩阵乘法的维数规则，并给出一个不合法乘积的例子。

练习 1.1 解析

矩阵乘法的合法性判据为

$$A \in \mathbb{R}^{m \times n}, \quad B \in \mathbb{R}^{p \times q} \implies AB \text{ 有定义} \iff n = p,$$

并且在 $n = p$ 时有 $AB \in \mathbb{R}^{m \times q}$ 。矩阵微分中的 Jacobian、Hessian 与链式法则都要复用这一内侧维数判据。例如

$$A \in \mathbb{R}^{2 \times 3}, \quad B \in \mathbb{R}^{4 \times 2}, \quad 3 \neq 4 \implies AB \text{ 无定义}.$$

因此应先掌握矩阵乘法的维数规则，再进入矩阵微分。

练习 1.2 (回看决策). 一名读者会计算导数，却无法解释 $\mathbf{x} \in \mathbb{R}^d$ 。他应先回看哪一节，为什么？

练习 1.2 解析

已知与合法条件 读者会做标量求导，但尚不能解释 $\mathbf{x} \in \mathbb{R}^d$ 所声明的对象类型与维数。

方法选择 先补齐向量、矩阵及其维数规则，再把标量导数推广到梯度。

推导/计算 应回看节 1.3。该节说明 $\mathbf{x} \in \mathbb{R}^d$ 通常表示 $d \times 1$ 列向量，并给出转置和矩阵乘法的形状规则。于是对 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ ，才能判断

$$\nabla f(\mathbf{x}) = [\partial f / \partial x_1 \quad \cdots \quad \partial f / \partial x_d]^\top \in \mathbb{R}^d.$$

独立核验 若把 $\mathbf{x}$ 误作行向量，则 $\mathbf{w}^\top \mathbf{x}$ 等常用表达式会立刻出现维数冲突。

结论 应先回看“对象、维数与基本记号”，因为矩阵微分不仅要求会求导，还要求导数对象的类型和维数合法。

练习 1.3 (可跳读与不可跳过). 把“定义后的生活类比”和“二次型梯度的首次分量推导”分别归入可跳读或不可跳过，并说明标准。

练习 1.3 解析

方法选择 用“后文是否依赖其中的新定义、推导或合法条件”作为判断标准，而不以段落长短或阅读难度为标准。

推导/计算 定义后的生活类比只帮助形成直觉，不承担后续公式的逻辑前提；已理解定义时可以跳读。二次型梯度的首次分量推导出偏导项、转置位置及 $\mathbf{A} + \mathbf{A}^\top$ 的对称化来源，后文会直接调用这些结论，因此不可跳过。

独立核验 去掉类比不影响任何符号的含义；去掉首次推导却无法独立判断 $\nabla_{\mathbf{x}}(\mathbf{x}^\top \mathbf{A} \mathbf{x})$ 的维数和系数。

练习 1.3 解析 (续)

结论 生活类比可跳读, 首次分量推导不可跳过; 标准是知识依赖而非篇幅。

练习 1.4 (集合运算). 设 $A = \{1, 2, 3\}$, $B = \{2, 4\}$, 求 $A \cup B$, $A \cap B$ 和 $A \setminus B$ 。

练习 1.4 解析

已知与合法条件 $A = \{1, 2, 3\}$, $B = \{2, 4\}$ 。

方法选择 分别按“至少属于一个集合”“同时属于两个集合”“属于 A 但不属于 B ”逐个筛选元素。

推导/计算 合并并去重得到 $A \cup B = \{1, 2, 3, 4\}$; 共同元素只有 2, 故 $A \cap B = \{2\}$; 从 A 中删去同时属于 B 的 2, 得到 $A \setminus B = \{1, 3\}$ 。

独立核验 $|A \cup B| = |A| + |B| - |A \cap B| = 3 + 2 - 1 = 4$, 与结果一致。

结论

$$A \cup B = \{1, 2, 3, 4\}, \quad A \cap B = \{2\}, \quad A \setminus B = \{1, 3\}.$$

练习 1.5 (函数判定). 关系 $R = \{(1, a), (1, b), (2, a)\}$ 是否定义了从 $\{1, 2\}$ 到 $\{a, b\}$ 的函数?

练习 1.5 解析

令 $D = \{1, 2\}$, $C = \{a, b\}$ 。关系 $R \subseteq D \times C$ 定义函数的充要条件是

$$\forall x \in D, \quad |\{y \in C : (x, y) \in R\}| = 1.$$

对当前关系, 两个输入的像纤维分别为

$$\{y : (1, y) \in R\} = \{a, b\}, \quad \{y : (2, y) \in R\} = \{a\}.$$

第一集合的基数为 $2 \neq 1$, 故唯一性条件失败, R 不是从 D 到 C 的函数。删除 $(1, a)$ 与 $(1, b)$ 中的任意一个、同时保留 $(2, a)$, 才可得到满足判据的函数关系。

练习 1.6 (像与陪域). 令 $f : \mathbb{R} \rightarrow \mathbb{R}$, $f(x) = x^2$ 。写出其像, 并判断是否为满射。

练习 1.6 解析

已知与合法条件 $f : \mathbb{R} \rightarrow \mathbb{R}$, $f(x) = x^2$; 满射要求每个 $y \in \mathbb{R}$ 都能写成 $f(x)$ 。

推导/计算 对任意 $x \in \mathbb{R}$ 都有 $x^2 \geq 0$, 故 $f(\mathbb{R}) \subseteq [0, +\infty)$ 。反之, 对任意 $y \geq 0$ 取 $x = \sqrt{y} \in \mathbb{R}$, 便有 $f(x) = y$, 所以 $[0, +\infty) \subseteq f(\mathbb{R})$ 。

独立核验 负数 (例如 -1) 属于陪域 $\mathbb{R}$, 却不存在实数 x 使 $x^2 = -1$ 。

结论 $f(\mathbb{R}) = [0, +\infty) \neq \mathbb{R}$, 因此 f 不是从 $\mathbb{R}$ 到 $\mathbb{R}$ 的满射。

练习 1.7 (维数核对). 设 $A \in \mathbb{R}^{3 \times 2}$ 、 $\mathbf{x} \in \mathbb{R}^2$ ，写出 $A\mathbf{x}$ 的维数和第 i 个分量。

练习 1.7 解析

已知与合法条件 A 有 3 行 2 列， $\mathbf{x}$ 是 2×1 列向量。

方法选择 先核对矩阵乘法的内侧维数，再按“第 i 行乘以列向量”写出分量。

推导/计算

$$(3 \times 2)(2 \times 1) = (3 \times 1), \quad (A\mathbf{x})_i = \sum_{j=1}^2 A_{ij}x_j = A_{i1}x_1 + A_{i2}x_2.$$

这里 $i \in \{1, 2, 3\}$ 标记输出行， $j \in \{1, 2\}$ 遍历输入分量。

独立核验 乘积的两个内侧维数均为 2，而结果保留外侧维数 3×1 。

结论 $A\mathbf{x} \in \mathbb{R}^3$ ，其第 i 个分量如上式。

练习 1.8 (转置). 令 $A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}$ ，求 A^T 并说明维数变化。

练习 1.8 解析

已知与合法条件 $A \in \mathbb{R}^{2 \times 3}$ ，且转置满足 $(A^T)_{ij} = A_{ji}$ 。

推导/计算 把 A 的三列依次写成 A^T 的三行，得到

$$A^T = \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix} \in \mathbb{R}^{3 \times 2}.$$

独立核验 再转置一次可恢复原矩阵： $(A^T)^T = A$ 。

结论 转置交换行列，因此维数由 2×3 变为 3×2 。

练习 1.9 (上标辨析). 解释 x^2 、 $\mathbf{x}^{(2)}$ 和 A^T 三个上标为什么不能采用同一含义。

练习 1.9 解析

先按对象类型与运算结果区分：

记号	含义	结果类型
a^2	$a \cdot a$ ($a \in \mathbb{R}$)	$\mathbb{R}$
$\mathbf{x}^{(2)}$	第 2 个样本或第 2 次迭代向量	$\mathbb{R}^d$
A^T	矩阵转置	$\mathbb{R}^{n \times m}$ ($A \in \mathbb{R}^{m \times n}$)

相应地，

$$a^2 \neq \mathbf{x}^{(2)}, \quad (A^T)_{ij} = A_{ji}.$$

标量平方也可与向量平方范数对照： $\|\mathbf{x}\|_2^2 = \mathbf{x}^T \mathbf{x}$ ，但不把 $\mathbf{x}^2$ 当作默认记法。三种上标分别表示幂、编号与运算符；字体、括号和就地声明共同确定其含义。

练习 1.10 (求和展开). 计算 $\sum_{i=1}^4 (2i - 1)$, 并写出每一项。

练习 1.10 解析

方法选择 让索引 i 依次取 $1, 2, 3, 4$, 逐项代入被加数 $2i - 1$ 。

推导/计算

$$\sum_{i=1}^4 (2i - 1) = (2 \cdot 1 - 1) + (2 \cdot 2 - 1) + (2 \cdot 3 - 1) + (2 \cdot 4 - 1) = 1 + 3 + 5 + 7 = 16.$$

独立核验 也可用 $\sum_{i=1}^4 (2i - 1) = 2(1 + 2 + 3 + 4) - 4 = 20 - 4 = 16$ 核验。

结论 该和共有四项, 结果为 16。

练习 1.11 (连乘与零因子). 计算 $\prod_{i=1}^5 (i - 3)$, 并指出决定结果的关键因子。

练习 1.11 解析

方法选择 展开索引范围并先查找零因子; 有限连乘中只要有一个因子为零, 整个乘积即为零。

推导/计算

$$\prod_{i=1}^5 (i - 3) = (-2)(-1)(0)(1)(2) = 0.$$

独立核验 索引集合 $\{1, 2, 3, 4, 5\}$ 确实包含 $i = 3$, 对应关键因子 $i - 3 = 0$ 。

结论 结果为 0, 决定结果的关键因子是 $i = 3$ 时的零因子。

练习 1.12 (指示计数). 标签为 $(1, -1, 1, 1)$, 预测为 $(1, 1, 1, -1)$ 。用指示函数求正确数和正确率。

练习 1.12 解析

令 $n = 4$, 并逐项编码预测是否等于标签:

$$\begin{aligned} (\mathbb{I}\{\hat{y}_i = y_i\})_{i=1}^4 &= (1, 0, 1, 0), \\ C &= \sum_{i=1}^4 \mathbb{I}\{\hat{y}_i = y_i\} \\ &= 1 + 0 + 1 + 0 = 2. \end{aligned}$$

因为 $n = 4 > 0$, 正确率有定义, 且

$$\hat{p} = \frac{C}{n} = \frac{2}{4} = \frac{1}{2}.$$

这里只对四个逻辑值计数, 不需要假设样本相互独立。

练习 1.13 (角色识别). 在线性模型 $f_{\mathbf{w},b}(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$ 中, 指出变量与参数。

练习 1.13 解析

已知与合法条件 $f_{\mathbf{w},b}(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$, 其中 $\mathbf{x}, \mathbf{w} \in \mathbb{R}^d$, $b \in \mathbb{R}$ 。

方法选择 根据“调用模型时输入什么”和“训练阶段调节什么”区分变量与参数。

推导/计算 对固定的 $(\mathbf{w}, b)$, 改变 $\mathbf{x}$ 会改变函数输入, 因此 $\mathbf{x}$ 是输入变量; 训练通过数据选择 $\mathbf{w}$ 与 b , 所以它们是模型参数。

独立核验 $\mathbf{w}^T \mathbf{x}$ 是标量, 和 b 相加后仍属于 $\mathbb{R}$, 与 $f_{\mathbf{w},b} : \mathbb{R}^d \rightarrow \mathbb{R}$ 一致。

结论 $\mathbf{x}$ 是变量, $(\mathbf{w}, b) \in \mathbb{R}^d \times \mathbb{R}$ 是参数; 参数在训练中更新不改变其对象角色。

练习 1.14 (数据矩阵). 有 $n = 5$ 个样本、每个样本 $d = 3$ 个特征。按行放样本时, 写出 X 与 $\mathbf{y}$ 的维数。

练习 1.14 解析

由 $n = 5$ 、 $d = 3$ 且样本按行排列,

$$\mathbf{x}^{(i)} \in \mathbb{R}^{3 \times 1}, \quad X = \begin{bmatrix} (\mathbf{x}^{(1)})^T \\ \vdots \\ (\mathbf{x}^{(5)})^T \end{bmatrix} \in \mathbb{R}^{5 \times 3}.$$

每个样本对应一个标量标签, 因此

$$\mathbf{y} = [y_1 \quad \cdots \quad y_5]^T \in \mathbb{R}^{5 \times 1} = \mathbb{R}^5.$$

若 $\mathbf{w} \in \mathbb{R}^{3 \times 1}$, 则

$$(5 \times 3)(3 \times 1) = (5 \times 1), \quad X\mathbf{w} \in \mathbb{R}^5,$$

其第 i 个分量与 y_i 逐行对应。

练习 1.15 (双重下标). 解释 $x_j^{(i)}$ 中 i 与 j 的不同角色, 并给出允许的取值范围。

练习 1.15 解析

已知与合法条件 数据集含 n 个样本, 每个样本含 d 个特征, 并按样本逐行组成 X 。

推导/计算 对第 i 个样本 $\mathbf{x}^{(i)}$, 下标 j 选取其第 j 个特征, 故

$$x_j^{(i)} = X_{ij}, \quad i \in \{1, \dots, n\}, \text{quad } j \in \{1, \dots, d\}.$$

于是 $X = (x_j^{(i)}) \in \mathbb{R}^{n \times d}$ 。

独立核验 固定 i 并让 j 变化会得到第 i 个样本的全部特征; 固定 j 并让 i 变化会得到第 j 个特征在全部样本上的取值。

结论 上标括号中的 i 标样本行, 下标 j 标特征列, 二者不能互换。

练习 1.16 (量词否定). 写出“所有训练样本都被正确分类”的否定。

练习 1.16 解析

已知与合法条件 令命题 $P(i)$ 表示“第 i 个训练样本被正确分类”，即 $\hat{y}_i = y_i$ 。

方法选择 使用量词否定规则 $\neg(\forall i P(i)) \Leftrightarrow \exists i \neg P(i)$ 。

推导/计算 若训练索引集为 $\{1, \dots, n\}$, 则

$$\neg(\forall i \in \{1, \dots, n\}, \hat{y}_i = y_i) \Leftrightarrow \exists i \in \{1, \dots, n\}, \hat{y}_i \neq y_i.$$

独立核验 否定“全部正确”只要求找到一个反例，不要求所有样本都分类错误。

结论 否定为“至少存在一个训练样本被错误分类”。

练习 1.17 (逆命题). 已知命题“若 $x > 2$, 则 $x^2 > 4$ ”。写出逆命题，并判断其在实数域是否成立。

练习 1.17 解析

在实数域中定义

$$P(x) : x > 2, \quad Q(x) : x^2 > 4.$$

原命题与逆命题分别是

$$\forall x \in \mathbb{R}, P(x) \Rightarrow Q(x), \quad \forall x \in \mathbb{R}, Q(x) \Rightarrow P(x).$$

取反例 $x = -3$, 则

$$Q(-3) : (-3)^2 = 9 > 4 \text{ 为真}, \quad P(-3) : -3 > 2 \text{ 为假}.$$

故逆命题为假。与原命题等价的是逆否命题

$$\forall x \in \mathbb{R}, x^2 \leq 4 \Rightarrow x \leq 2.$$

因此，反例已经否定逆命题，而最后一式给出了原命题真正等价的逆否命题。

练习 1.18 (条件核对). 判断陈述“对所有 $x \in \mathbb{R}$, $\log x$ 有定义”并给出修正后的量词范围。

练习 1.18 解析

已知与合法条件 在实数范围内，对数函数的定义域是 $(0, +\infty)$ 。

方法选择 用定义域中的反例检验全称命题，再把量词范围缩到合法定义域。

推导/计算 原命题把 $x = 0$ 和所有负数也纳入 $\mathbb{R}$, 但 $\log 0$ 与 $\log(-1)$ 在实数范围内均无定义，因此全称命题为假。

独立核验 对任意 $x > 0$, 存在唯一实数 y 使 $e^y = x$, 所以 $\log x = y$ 确有定义。

结论 修正为：“对所有 $x \in (0, +\infty)$, $\log x$ 在实数范围内有定义。”

练习 1.19 (章末综合). 综合任务：把“选择参数，使分类错误尽量少”改写为含参数空间、样本索引、指示函数和最小化符号的数学问题；随后逐项标出对象、关系与成立条件。

练习 1.19 解析

先声明对象与合法条件：

$$n \in \mathbb{N}, \quad n > 0, \quad \Theta \neq \emptyset, \quad f_{\theta}(\mathbf{x}^{(i)}) \text{ 对所有 } (\theta, i) \in \Theta \times \{1, \dots, n\} \text{ 有定义.}$$

定义经验错误数

$$C(\theta) = \sum_{i=1}^n \mathbb{I}\{f_{\theta}(\mathbf{x}^{(i)}) \neq y_i\}, \quad \theta \in \Theta.$$

每一项只取 0 或 1，因此

$$C(\Theta) = \{C(\theta) : \theta \in \Theta\} \subseteq \{0, 1, \dots, n\}.$$

又因 $\Theta \neq \emptyset$ ，集合 $C(\Theta)$ 是有限集合 $\{0, 1, \dots, n\}$ 的非空子集，故最小值存在。于是

$$\Theta^* = \arg \min_{\theta \in \Theta} C(\theta) \neq \emptyset, \quad \hat{\theta} \in \Theta^*.$$

对象是参数、样本与标签；关系是预测值是否等于标签；可行域是非空参数空间 Θ 。若 Θ^* 含多个参数，则需要额外的确定性并列规则才能使 $\hat{\theta}$ 唯一。

本章结论与下一步

核心结论： 集合、映射、对象类型、索引与数据角色

关键依据： 先核对定义域和维数，再执行求和、连乘与逻辑推演

可执行自检： 用对象 – 空间 – 关系 – 条件检查表逐句验算

适用边界： 阅读任何新定义、公式或算法之前

下一步： 进入章 2；自检失败则回到最早缺失的定义

1. 我能区分 $\in$ 与 $\subseteq$ ，并说明定义域、陪域和像；否则回看节 1.2。
2. 我能在矩阵运算前写出每个对象的维数；否则回看节 1.3。
3. 我能用指示函数计数并解释上下标；否则回看节 1.4、1.5。
4. 我能否定含量词的命题并给出反例；否则回看节 1.6。
5. 四项全部通过后，再进入线性代数；任一项未通过时，按所列位置复习并重新作答。

第 2 章 线性代数基础

本章地图

核心问题：矩阵运算如何对应线性映射及其保留和丢失的方向

可检验学习目标：

- 能用分量形式核对向量、矩阵、内积、投影和矩阵乘法；
- 能联系秩、零空间、行空间、列空间及其正交补，并完成投影定理的证明；
- 能判断对称矩阵的正定性，解释谱分解与奇异值，并手工执行幂法。

最短先修：需要掌握集合、映射、列向量约定、求和记号和实数方程，相关内容见章 1。本章所有向量都取实数分量；复数矩阵所需的共轭转置不在本章范围内。

依赖路线：

分量运算 → 内积与范数 → 线性组合与基 → 秩和基本子空间 → 正交投影 → 谱与奇异值。

每一箭头表示后者在定义或证明中使用前者；幂法还使用向量归一化和特征向量定义。

完成标准与返回：矩阵乘法或二次型诊断未通过时返回相应复习节

读前自检：本章符号表。 线性代数符号表规定 $A \in \mathbb{R}^{m \times n}$ 把 $\mathbb{R}^n$ 映到 $\mathbb{R}^m$ ，且 $N(A) \subseteq \mathbb{R}^n$ 、 $R(A) \subseteq \mathbb{R}^m$ ；请逐项核对 Ax 、 $\text{rank}(A)$ 的类型与维数是否闭合。

本章符号表		
符号	类型	含义
$x, y \in \mathbb{R}^n$	列向量	n 个有序分量
$A \in \mathbb{R}^{m \times n}$	矩阵	从 $\mathbb{R}^n$ 到 $\mathbb{R}^m$ 的线性映射表示
$\langle x, y \rangle$	标量	$x^T y$
$\ x\ _2$	非负标量	欧氏范数
$\text{rank}(A)$	整数	行空间与列空间的共同维数
$N(A)$	$\mathbb{R}^n$ 的子空间	$Ax = 0$ 的全部解
$R(A)$	$\mathbb{R}^m$ 的子空间	A 的列空间，也就是 A 的值域
λ, q	标量、非零向量	特征值与对应特征向量

问题提出

数据表、线性预测、最小二乘、协方差和降维都依赖矩阵。核心问题不是记住运算表，而是判断：线性映射保留了哪些方向，丢失了哪些方向；一个向量如何分解为子空间内分量和正交残差；迭代为何会突出主特征方向。

定义 2.1 (线性映射). 设 $T : \mathbb{R}^n \rightarrow \mathbb{R}^m$ 。若对任意 $x, y \in \mathbb{R}^n$ 和 $a, b \in \mathbb{R}$ 都有 $T(ax + by) = aT(x) + bT(y)$ ，则称 T 为线性映射。给定标准基后，存在唯一 $A \in \mathbb{R}^{m \times n}$ 使 $T(x) = Ax$ 。

模型、策略与算法

本章把矩阵 A 视为线性模型：输入 $\mathbf{x} \in \mathbb{R}^n$ ，输出 $A\mathbf{x} \in \mathbb{R}^m$ ；列空间描述可达到的输出，零空间描述映射为零的输入。

学习策略是先按分量核对运算，再用子空间解释结构，最后用正交性或谱性质寻找最简表示。对近似问题，选择使欧氏残差最小的投影；对实对称矩阵，Rayleigh 商最大化给出最大代数特征值的方向。只有协方差等半正定矩阵中，这一方向才同时是最大方差方向。

本章学习算法采用归一化幂法：反复施加矩阵并归一化，使初始向量中占优的特征方向相对放大。算法的完整输入、更新与终止规则见算法 2.1。

核心推导：一维正交投影系数

阅读目标：把“到直线最近”化为一个标量二次函数的极小化。

对象： $\mathbf{x}, \mathbf{u} \in \mathbb{R}^n$ 与候选投影点 $a\mathbf{u}$ 。

合法条件： $\mathbf{u} \neq \mathbf{0}$ ，故 $\mathbf{u}^\top \mathbf{u} > 0$ ； $a \in \mathbb{R}$ 。

第一步：先展开 $g(a) = \|\mathbf{x} - a\mathbf{u}\|_2^2$ ，再对标量 a 求导。

推导目标

给定非零 $\mathbf{u} \in \mathbb{R}^n$ 和 $\mathbf{x} \in \mathbb{R}^n$ ，求 $\mathbf{x}$ 在 $\text{span}(\mathbf{u})$ 上的最近点 $a\mathbf{u}$ ，并得到系数 a 。

推导准备

目标函数为 $g(a) = \|\mathbf{x} - a\mathbf{u}\|_2^2$ ，定义域为 $a \in \mathbb{R}$ 。因为 $\mathbf{u} \neq \mathbf{0}$ ，有 $\mathbf{u}^\top \mathbf{u} > 0$ 。

推导第 1 步：展开平方。使用内积的双线性与对称性，

$$g(a) = \mathbf{x}^\top \mathbf{x} - 2a\mathbf{u}^\top \mathbf{x} + a^2\mathbf{u}^\top \mathbf{u}.$$

每一项都是标量，维数相容。

推导第 2 步：求驻点。对标量 a 求导，

$$g'(a) = -2\mathbf{u}^\top \mathbf{x} + 2a\mathbf{u}^\top \mathbf{u}.$$

令 $g'(a) = 0$ 的依据是最小点位于无约束实数域内部且 g 可微。

推导第 3 步：验证最小性。解得

$$a^\star = \frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}}, \quad g''(a) = 2\mathbf{u}^\top \mathbf{u} > 0.$$

二阶导数为正，所以 $a^\star \mathbf{u}$ 是唯一最近点；残差与 $\mathbf{u}$ 的内积为零。

定理 2.1(子空间正交投影的最佳逼近) 设 S 是 $\mathbb{R}^n$ 的子空间， $\mathbf{x} = \mathbf{p} + \mathbf{r}$ ，其中 $\mathbf{p} \in S$ 且 $\mathbf{r} \in S^\perp$ 。则对任意 $\mathbf{s} \in S$ ， $\|\mathbf{x} - \mathbf{p}\|_2 \leq \|\mathbf{x} - \mathbf{s}\|_2$ ，等号成立当且仅当 $\mathbf{s} = \mathbf{p}$ 。

读前自检：证明：子空间正交投影的最佳逼近。 子空间最佳逼近证明给出 $\mathbf{x} = \mathbf{p} + \mathbf{r}$ ，其中 $\mathbf{p}, \mathbf{s} \in S$ 且 $\mathbf{r} \in S^\perp$ ；请展开 $\|\mathbf{x} - \mathbf{s}\|_2^2$ ，消去交叉项并核对等号仅在 $\mathbf{s} = \mathbf{p}$ 时成立。

证明。 证明目标是比较任意候选 $\mathbf{s}$ 与 $\mathbf{p}$ 的误差。由分解条件， $\mathbf{x} - \mathbf{s} = \mathbf{r} + (\mathbf{p} - \mathbf{s})$ 。因为 $\mathbf{p} - \mathbf{s} \in S$ 且 $\mathbf{r} \in S^\perp$ ，两项内积为零。展开平方范数得到

$$\|\mathbf{x} - \mathbf{s}\|_2^2 = \|\mathbf{r}\|_2^2 + \|\mathbf{p} - \mathbf{s}\|_2^2 \geq \|\mathbf{r}\|_2^2 = \|\mathbf{x} - \mathbf{p}\|_2^2.$$

平方根在非负实数上保持次序。等号成立恰要求 $\|\mathbf{p} - \mathbf{s}\|_2^2 = 0$ ，也就是 $\mathbf{s} = \mathbf{p}$ ，结论成立。 $\square$

几何理解

几何解释。 投影把向量分成子空间内分量与垂直残差；特征向量是在线性变换下方向不变的轴，特征值给出该轴上的伸缩。秩是输出空间中独立方向的个数。

概率解释

随机向量中心化后的二阶矩形成协方差矩阵。任意方向 $\mathbf{q}$ 上的方差写成二次型 $\mathbf{q}^\top \Sigma \mathbf{q}$ ，所以最大方差方向与对称矩阵的主特征向量相连。

优化解释

优化解释。 最小二乘是在列空间中寻找离观测向量最近的点；正规方程表达残差与列空间正交。对实对称矩阵，Rayleigh 商最大化得到最大代数特征值的单位特征向量；它与“最大模特征值”不是同一概念。




图 2.1 向量的正交分解。投影向量属于子空间，残差属于其正交补，虚线残差给出到子空间的最短距离。

由图 2.1 中的正交证书，对任意 $\mathbf{s} \in S$ 都有 $\|\mathbf{x} - \mathbf{s}\|_2^2 = \|(I - P_S)\mathbf{x}\|_2^2 + \|P_S \mathbf{x} - \mathbf{s}\|_2^2$ ；第二项只在 $\mathbf{s} = P_S \mathbf{x}$ 时为零，这就给出最短距离而非仅凭图形判断。

例题 2.1 (二维投影与残差). 令 $\mathbf{x} = (3, 1)^\top$ ， $\mathbf{u} = (1, 1)^\top$ 。求 $\mathbf{x}$ 到 $\text{span}(\mathbf{u})$ 的投影与距离。

例题 2.1 解答

读题翻译 把 $\mathbf{x}$ 正交投影到 $\mathbf{u}$ 张成的直线上, 求投影点、残差及点到直线的欧氏距离。

已知与合法条件 $\mathbf{x}, \mathbf{u} \in \mathbb{R}^2$ 且 $\mathbf{u} \neq \mathbf{0}$, 故 $\mathbf{u}^\top \mathbf{u} > 0$, 投影系数有定义。

为什么想到这个方法 用一维子空间的正交投影公式求系数和投影, 再由残差范数求距离; 以正交性和勾股恒等式核验。

方法选择 计算 $a = (\mathbf{u}^\top \mathbf{x})/(\mathbf{u}^\top \mathbf{u})$, 令 $\mathbf{p} = a\mathbf{u}$ 、 $\mathbf{r} = \mathbf{x} - \mathbf{p}$, 最后求 $\|\mathbf{r}\|_2$ 。

推导/计算 对象与条件为 $\mathbf{x}, \mathbf{u} \in \mathbb{R}^2$ 且 $\mathbf{u} \neq \mathbf{0}$, 因此投影系数的分母严格为正。逐步计算

$$\begin{aligned} \mathbf{u}^\top \mathbf{x} &= 1 \cdot 3 + 1 \cdot 1 = 4, & \mathbf{u}^\top \mathbf{u} &= 1^2 + 1^2 = 2, \\ a^\star &= \frac{\mathbf{u}^\top \mathbf{x}}{\mathbf{u}^\top \mathbf{u}} = 2, & \mathbf{p} &= a^\star \mathbf{u} = (2, 2)^\top, \\ \mathbf{r} &= \mathbf{x} - \mathbf{p} = (1, -1)^\top, & \mathbf{u}^\top \mathbf{r} &= 1 - 1 = 0, \\ \text{dist}(\mathbf{x}, \text{span}(\mathbf{u})) &= \|\mathbf{r}\|_2 = \sqrt{1^2 + (-1)^2} = \sqrt{2}. \end{aligned}$$

独立核验 $\mathbf{u}^\top \mathbf{r} = 0$ 说明残差与子空间正交; 另有 $\|\mathbf{x}\|_2^2 = 10 = 8 + 2 = \|\mathbf{p}\|_2^2 + \|\mathbf{r}\|_2^2$, 两项证书一致。

结论 投影系数 $a = 2$, 投影 $\mathbf{p} = (2, 2)^\top$, 残差 $\mathbf{r} = (1, -1)^\top$, 距离为 $\sqrt{2}$ 。

主特征方向的严格伪代码

输入为方阵 $A \in \mathbb{R}^{n \times n}$ 与非零初始向量, 输出为最大模特征值及其单位特征向量的近似与残差; 若最大模特征值为负, 它不等于 Rayleigh 商最大值。方向收敛还要求最大模特征值唯一且初始向量在该特征方向上的分量非零。参数 T 是最大迭代次数, $\varepsilon > 0$ 是残差容差; 符号 $\mathbf{q}_t$ 表示第 t 次单位向量。初始化使用 $\mathbf{q}_0 = \mathbf{v}_0 / \|\mathbf{v}_0\|_2$, 要求 $\mathbf{v}_0 \neq \mathbf{0}$ 。更新依次计算 $\mathbf{z}_t = A\mathbf{q}_{t-1}$ 、 $\mathbf{q}_t = \mathbf{z}_t / \|\mathbf{z}_t\|_2$ 和 $\lambda_t = \mathbf{q}_t^\top A\mathbf{q}_t$ 。停止条件为特征残差 $\|A\mathbf{q}_t - \lambda_t \mathbf{q}_t\|_2 \leq \varepsilon$ 或 $t = T$ 。本章只在实对称矩阵上给出无条件数遗漏的速率结论。设 $A = A^\top$ 有标准正交特征向量 $\mathbf{q}_1, \dots, \mathbf{q}_n$, 特征值按 $|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|$ 排列, 并写 $\mathbf{q}_0 = \sum_i c_i \mathbf{q}_i$ 且 $c_1 \neq 0$ 。若迭代未遇到 $A\mathbf{q}_{t-1} = \mathbf{0}$, 则归一化不改变方向, 并且

$$\tan \angle(\mathbf{q}_t, \text{span}(\mathbf{q}_1)) = \frac{(\sum_{i=2}^n c_i^2 |\lambda_i / \lambda_1|^{2t})^{1/2}}{|c_1|} \leq \frac{(\sum_{i=2}^n c_i^2)^{1/2}}{|c_1|} \left| \frac{\lambda_2}{\lambda_1} \right|^t.$$

一般可对角化但非正规矩阵还会出现特征向量基的条件数, 复特征值与 Jordan 块也需另行处理, 不能直接套用上述常数为1的方向界。

读前自检: 归一化幂法: 执行契约。 归一化幂法以方阵 A 、非零 $\mathbf{v}_0$ 、 $\varepsilon > 0$ 和 $T \in \mathbb{N}_0$ 为输入; 请从合法 $\hat{\mathbf{q}}$ 计算 $\mathbf{z} = A\hat{\mathbf{q}}$ 、 $\mathbf{q}^+ = \mathbf{z} / \|\mathbf{z}\|_2$ 、 λ^+ 与 $\mathbf{r}^+$, 只在候选均有时提交, 并核对 $\mathbf{r}^+ \leq \varepsilon$ 触发 converged, 否则到 T 轮触发 budget_stop。

归一化幂法：五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 2.1: 归一化幂法

输入: $A \in \mathbb{R}^{n \times n}$, $v_0 \neq 0$, $\varepsilon > 0$, $T \in \mathbb{N}_0$

输出: 最后合法 $(\hat{\lambda}, \hat{q}, \hat{r})$; $t_{\text{done}}, m_{\text{done}}$; **status** 与诊断

- 1 若维数、有限性、 $v_0 \neq 0$ 、容差或预算非法，返回空结果、计数 0、**invalid_input** 及字段诊断
- 2 置 $\hat{q} \leftarrow v_0 / \|v_0\|_2$, $t_{\text{done}} \leftarrow 0$, $m_{\text{done}} \leftarrow 0$; 计算 $y \leftarrow A\hat{q}$ 并增加 m_{done}
- 3 若 y 非有限，则返回 $\hat{q}$ 、**numerical_failure** 及初始化乘法诊断；否则置 $\hat{\lambda} \leftarrow \hat{q}^T y$, $\hat{r} \leftarrow \|y - \hat{\lambda}\hat{q}\|_2$
- 4 若 $\hat{\lambda}$ 或 $\hat{r}$ 非有限，返回最后合法方向、**numerical_failure** 及初始残差诊断；若 $\hat{r} \leq \varepsilon$ ，返回当前结果、**converged** 及零轮残差证书
- 5 当 $t_{\text{done}} < T$ 执行
 - 6 计算 $z \leftarrow A\hat{q}$ 并增加 m_{done} ；若 z 非有限或 $\|z\|_2 = 0$ ，返回上一合法结果、**numerical_failure** 及失败轮诊断
 - 7 形成 $q^+ \leftarrow z / \|z\|_2$ ，计算 $y^+ \leftarrow Aq^+$ 并增加 m_{done} ，再形成 $\lambda^+ = (q^+)^T y^+$ 与 $r^+ = \|y^+ - \lambda^+ q^+\|_2$
 - 8 若候选任一量非有限，则返回上一合法结果、**numerical_failure** 及候选阶段诊断
 - 9 原子提交 $(\hat{q}, \hat{\lambda}, \hat{r}) \leftarrow (q^+, \lambda^+, r^+)$ 并增加 t_{done}
 - 10 若 $\hat{r} \leq \varepsilon$ ，返回最后合法结果、**converged** 及残差证书
- 11 结束
- 12 返回最后合法结果、**budget_stop** 及“预算耗尽、残差未达标”最终诊断

算法实现说明：首次阅读只跟踪“乘矩阵—归一化—算 Rayleigh 商—查残差”；实现时再核对零范数、非有限值、预算和最后合法状态 完整 C1–C14 契约

读前自检：复杂度分析：主特征方向的严格伪代码。 主特征方向的严格伪代码所用的明确前提是“稠密矩阵按全部 n^2 个元素访问，稀疏矩阵允许按非零元顺序完成矩阵向量乘法，并把实际迭代轮数记为 T ”；完成由 n^2 的总成本剥离一次迭代或一次样本因子后，核对幂法输出特征对，不定义对新样本的预测函数。

复杂度分析

复杂度假设。以下界采用单位成本实数运算；稠密矩阵按全部 n^2 个元素访问，稀疏矩阵允许按非零元顺序完成矩阵向量乘法，并把实际迭代轮数记为 T 。构造或读取输入矩阵的外部成本不并入幂法本身。**训练复杂度。**这里的“训练”指求解主特征对。对 $n \times n$ 矩阵，稠密矩阵向量乘法每轮为 $O(n^2)$ ，故 T 轮为 $O(Tn^2)$ ；稀疏情形为 $O(T \text{nnz}(A))$ 。**预测复杂度。**幂法输出特征对，不定义对新样本的预测函数。**存储复杂度。**除输入矩阵外只保存若干 n 维向量，额外空间为 $O(n)$ ；计入矩阵后稠密情形为 $O(n^2)$ ，稀疏情形为 $O(\text{nnz}(A) + n)$ 。

适用条件与局限性

适用条件。幂法适合矩阵向量乘法便宜且只需要模最大的特征方向的任务，对大规模稀疏矩阵尤其有用。

方法局限。主特征值模相同会导致方向不唯一，谱间隙小时收敛缓慢，初始向量与主方向正交时也无法恢复该方向。

读前自检：常见错误与误用边界：主特征方向的严格伪代码。 围绕主特征方向的严格伪代码，先采用条件“边界框首项禁止把 AB 与 BA 互换”，再把固定错误“把 AB 与 BA 互换”中的对象、操作与结论按本节定义拆开，指出第一个不满足的定义条件，再把该处改为本节允许的写法；最后验证改写后的运算或判断有定义，且不再触发“把 AB 与 BA 互换”。

常见错误

典型误用有把 AB 与 BA 互换、把 $\mathbf{x}^\top \mathbf{y}$ 当作向量、认为秩等于非零元素个数、把 A 的零空间放入 $\mathbb{R}^m$ 、忽视特征向量必须非零，以及将半正定误写为所有二次型严格为正。

易混淆概念对比		
概念	定义核心	区别
行空间与列空间	分别由行、列张成	所在空间通常为 $\mathbb{R}^n$ 与 $\mathbb{R}^m$
零空间与左零空间	$N(A)$ 、 $N(A^\top)$	维数分别为 $n - r$ 与 $m - r$
特征分解与奇异值分解	特征分解要求方阵可对角化；实对称方阵总可正交对角化；SVD 对任意实矩阵存在	奇异值非负且来自 $A^\top A$
正定与半正定	二次型对非零向量严格正或非负	半正定允许零方向

读前自检：向量及其分量。 向量及其分量中的“向量 $\mathbf{x} = (x_1, \dots, x_n)^\top$ 属于 $\mathbb{R}^n$ ”决定可执行范围；请标出 $\mathbf{x}$ 两侧的 shape 并完成一次乘法或正交检查，结果须满足乘法内侧维数相等且结果落入声明空间。

读前自检：矩阵及其分量。 把矩阵及其分量放在“相等矩阵必须维数相同且对应分量相等”下考察：标出 $A = (A_{ij}) \in \mathbb{R}^{m \times n}$ 两侧的 shape 并完成一次乘法或正交检查，并检查乘法内侧维数相等且结果落入声明空间。

读前自检：矩阵乘法的分量形式。 矩阵乘法的分量形式要求先确认“若 $A \in \mathbb{R}^{m \times n}$ 、 $B \in \mathbb{R}^{n \times p}$ ”；请随后标出 $(AB)_{ij} = \sum_{k=1}^n A_{ik} B_{kj}$ 两侧的 shape 并完成一次乘法或正交检查，用 $AB \in \mathbb{R}^{m \times p}$ 且 $(AB)_{ij} = \sum_{k=1}^n A_{ik} B_{kj}$ 验收。

读前自检：行列式。 对 $A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$, 请按二阶行列式定义计算 $\det(A) = ad - bc$, 并核对 $\det(A) \neq 0$ 恰好对应 A 可逆。

2.1 向量、矩阵与分量运算

向量 $\mathbf{x} = (x_1, \dots, x_n)^T$ 属于 $\mathbb{R}^n$, 加法和标量乘法逐分量进行。矩阵 $A = (A_{ij}) \in \mathbb{R}^{m \times n}$ 有 m 个行向量和 n 个列向量; 相等矩阵必须维数相同且对应分量相等。若 $A \in \mathbb{R}^{m \times n}$ 、 $B \in \mathbb{R}^{n \times p}$, 则 $AB \in \mathbb{R}^{m \times p}$ 且 $(AB)_{ij} = \sum_{k=1}^n A_{ik}B_{kj}$ 。方阵 A 的行列式 $\det(A)$ 是有符号体积缩放因子; $\det(A) \neq 0$ 等价于 A 可逆。二阶情形 $\det \begin{bmatrix} a & b \\ c & d \end{bmatrix} = ad - bc$ 。

读前自检：距离与度量。 距离与度量依赖“由范数诱导的距离 $d(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|$ 满足非负、同一性、对称和三角不等式”; 请据此把 $d(\mathbf{x}, \mathbf{y})$ 展开一次并检查其类型或边界, 并直接核对展开后的量满足定义中的域、维数或符号限制。

2.2 内积、范数、距离与夹角

$\langle \mathbf{x}, \mathbf{y} \rangle = \sum_i x_i y_i$ 是标量, 满足对称性、双线性和正定性

$$\langle \mathbf{x}, \mathbf{x} \rangle \geq 0, \quad \langle \mathbf{x}, \mathbf{x} \rangle = 0 \iff \mathbf{x} = \mathbf{0}.$$

最后一个“当且仅当”把内积与仅半正定的双线性型区分开; 也正因为它, $\|\mathbf{x}\|_2 = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle}$ 满足 $\|\mathbf{x}\|_2 = 0 \iff \mathbf{x} = \mathbf{0}$ 。范数满足非负性、齐次性和三角不等式; 常用 $\|\mathbf{x}\|_1 = \sum_i |x_i|$ 、 $\|\mathbf{x}\|_2 = (\sum_i x_i^2)^{1/2}$ 和 $\|\mathbf{x}\|_\infty = \max_i |x_i|$ 。由范数诱导的距离 $d(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|$ 满足非负、同一性、对称和三角不等式。

读前自检：向量夹角。 线性代数基础中的向量夹角以“非零向量夹角 $\theta \in [0, \pi]$ 由 $\cos \theta = \mathbf{x}^T \mathbf{y} / (\|\mathbf{x}\|_2 \|\mathbf{y}\|_2)$ 定义”为约束; 请标出 $\cos \theta$ 两侧的形状并完成一次乘法或正交检查, 并确认乘法内侧维数相等且结果落入声明空间。

非零向量夹角 $\theta \in [0, \pi]$ 由 $\cos \theta = \mathbf{x}^T \mathbf{y} / (\|\mathbf{x}\|_2 \|\mathbf{y}\|_2)$ 定义。

读前自检：线性组合与张成。 先锁定线性组合与张成的条件“ $a_1 \mathbf{v}_1 + \dots + a_k \mathbf{v}_k$ 是向量组的线性组合”: 把 $a_1 \mathbf{v}_1 + \dots + a_k \mathbf{v}_k$ 展开一次并检查其类型或边界, 所得结果应满足展开后的量满足定义中的域、维数或符号限制。

读前自检：线性相关与线性无关。 对线性相关与线性无关, 条件“若 $\sum_i a_i \mathbf{v}_i = \mathbf{0}$ 只有全零系数解”不可省; 请将 $\sum_i a_i \mathbf{v}_i = \mathbf{0}$ 左端按正文定义展开一层, 再逐项对齐右端, 再用存在非全零解时线性相关作检查。

读前自检：基、坐标与维数。 基、坐标与维数把问题限定在“向量在给定基下的坐标唯一, 基向量个数是空间维数”; 请把“向量在给定基下的坐标唯一, 基向量个数是空间维数”中的已声明对

象代回基、坐标与维数的定义，检查是否得到对象、条件与结论逐项闭合，且每项都可直接判为成立或失败。

2.3 线性组合、相关性、基与维数

$a_1\mathbf{v}_1 + \cdots + a_k\mathbf{v}_k$ 是向量组的线性组合，所有线性组合构成其张成空间。若 $\sum_i a_i\mathbf{v}_i = \mathbf{0}$ 只有全零系数解，则向量组线性无关；存在非全零解时线性相关。子空间的一组基既线性无关又张成该空间；向量在给定基下的坐标唯一，基向量个数是空间维数。

读前自检：矩阵的秩。 给定 $A \in \mathbb{R}^{m \times n}$ 且 $\text{rank}(A) = r$ ；请核对 $r = \dim R(A) = \dim R(A^T) \leq \min(m, n)$ ，再用 $r = n$ 验证满列秩时 $N(A) = \{\mathbf{0}\}$ 。

读前自检：线性方程组与解空间。 线性方程组与解空间所用的明确前提是“ $A\mathbf{x} = \mathbf{b}$ 有解当且仅当 $\mathbf{b} \in R(A)$ ”；完成标出 $A\mathbf{x} = \mathbf{b}$ 两侧的形状并完成一次乘法或正交检查后，核对若 $\mathbf{x}_p$ 是一组特解，则全部解为 $\mathbf{x}_p + N(A)$ 。

2.4 秩、线性方程组与基本子空间

矩阵的秩 r 是列空间维数，也等于行空间维数。秩不超过 $\min(m, n)$ ，满列秩意味着零空间只有零向量。 $A\mathbf{x} = \mathbf{b}$ 有解当且仅当 $\mathbf{b} \in R(A)$ ；若 $\mathbf{x}_p$ 是一组特解，则全部解为 $\mathbf{x}_p + N(A)$ 。非零 $\mathbf{w} \in \mathbb{R}^n$ 与 $\mathbf{b} \in \mathbb{R}$ 定义超平面 $H = \{\mathbf{x} : \mathbf{w}^T \mathbf{x} + b = 0\}$ ， $\mathbf{w}$ 是法向量。

对 $A \in \mathbb{R}^{m \times n}$ ，四个基本子空间分别是 $R(A) \subseteq \mathbb{R}^m$ 、 $R(A^T) \subseteq \mathbb{R}^n$ 、 $N(A) \subseteq \mathbb{R}^n$ 和 $N(A^T) \subseteq \mathbb{R}^m$ 。秩—零度关系为 $\text{rank}(A) + \dim N(A) = n$ ，转置后还有 $\text{rank}(A) + \dim N(A^T) = m$ 。

读前自检：正交与标准正交组。 标准正交组要求 $\langle \mathbf{v}_i, \mathbf{v}_j \rangle = 0$ ($i \neq j$) 且 $\|\mathbf{v}_i\|_2 = 1$ ；请写出其 Gram 矩阵，逐项核对对角元为 1、非对角元为 0，从而得到单位矩阵。

2.5 正交与投影

向量内积为零称为正交；一组两两正交且范数为 1 的向量称标准正交组。

读前自检：矩阵的基本子空间。 对 $A \in \mathbb{R}^{m \times n}$ ，请把四个基本子空间固定归位： $R(A^T), N(A) \subseteq \mathbb{R}^n$ ， $R(A), N(A^T) \subseteq \mathbb{R}^m$ ；逐项核对定义域与输出域。

读前自检：向量空间的子空间。 把向量空间的子空间放在“非空集合 $S \subseteq V$ 若对向量加法和实数乘法封闭”下考察：用 $S \subseteq V$ 做一次维数或封闭性核对，并检查封闭性保证任意有限线性组合仍在 S 中。

读前自检：向量空间的基和维数。 设 $B = (\mathbf{v}_1, \dots, \mathbf{v}_r)$ 是向量空间 V 的线性无关生成组；请把任意 $\mathbf{v} \in V$ 唯一写成 $\sum_{i=1}^r a_i \mathbf{v}_i$ ，并核对 $\dim V = r$ 。

读前自检：矩阵的行空间和列空间。 从矩阵的行空间和列空间的条件“ $R(A^T)$ 由 A 的行向量张成”出发，请标出 $R(A^T)$ 两侧的 shape 并完成一次乘法或正交检查；所得量应符合乘法内侧维数相等且结果落入声明空间。

读前自检：矩阵的零空间。 矩阵的零空间依赖“ $N(A) = \{x \in \mathbb{R}^n : Ax = 0\}$ ”；请据此标出 $N(A)$ 两侧的 shape 并完成一次乘法或正交检查，并直接核对乘法内侧维数相等且结果落入声明空间。

读前自检：秩 - 零度定理。 秩 - 零度定理针对 $A \in \mathbb{R}^{m \times n}$ ；请取 $N(A)$ 的一组基扩充为 $\mathbb{R}^n$ 的基，比较经 A 映射后保留下来的基向量数，核对 $\text{rank}(A) + \dim N(A) = n$ 。

矩阵结构由行空间、列空间、零空间与左零空间共同描述。非空集合 $S \subseteq V$ 若对向量加法和实数乘法封闭，则为 V 的子空间；封闭性保证任意有限线性组合仍在 S 中。基是线性无关的生成组，基中向量数定义空间维数。 $R(A^T)$ 由 A 的行向量张成， $R(A)$ 由 A 的列向量张成，二者维数同为 $\text{rank}(A)$ 。

$$N(A) = \{x \in \mathbb{R}^n : Ax = 0\}$$

是 $\mathbb{R}^n$ 的子空间，其维数称零度。对 $A \in \mathbb{R}^{m \times n}$ ， $\text{rank}(A) + \dim N(A) = n$ ；这等于主元变量数与自由变量数之和。

读前自检：子空间的正交补。 先锁定子空间的正交补的条件“ $S^\perp = \{x : x^T s = 0, \forall s \in S\}$ 也是子空间”：用 $S^\perp$ 做一次维数或封闭性核对，所得结果应满足所得维数与定义域、值域的空间一致。

$S^\perp = \{x : x^T s = 0, \forall s \in S\}$ 也是子空间。

读前自检：矩阵的基本子空间。 对 $A \in \mathbb{R}^{m \times n}$ ，请核对定义域中的 $R(A^T) \perp N(A)$ 与输出域中的 $R(A) \perp N(A^T)$ ，再用两条秩 - 零度等式验证两对正交补维数闭合。

四个空间成两对正交补：定义域中是行空间与零空间，输出空间中是列空间与左零空间。

读前自检：定理 D 1。 定理 D.1 断言 $N(A) = R(A^T)^\perp$ 且 $N(A^T) = R(A)^\perp$ ；请把“ x 与 A 的每一行正交”改写成 $Ax = 0$ ，再对 A^T 重复同一步，并核对 $N(A) = R(A^T)^\perp$ 及其转置版本同时成立。

具体关系为

$$N(A) = R(A^T)^\perp, \quad N(A^T) = R(A)^\perp.$$

证明第一式时， x 与 A 每一行正交等价于 $Ax = 0$ ；第二式对 A^T 应用同一论证。

读前自检：正交投影。 在“若 Q 的列标准正交”成立时处理线性代数基础中的正交投影：请独立化简 $P = QQ^T$ 的两端，并以到 $R(Q)$ 的投影矩阵为 $P = QQ^T$ 判定结果。

读前自检：点到超平面的距离。 点 x_0 到超平面 $w^T x + b = 0$ 的距离要求 $w \neq 0$ ；请把 x_0 沿单位法向量投影，核对距离为 $|w^T x_0 + b| / \|w\|_2$ 。

若 Q 的列标准正交，则到 $R(Q)$ 的投影矩阵为 $P = QQ^T$ ，满足 $P^T = P$ 和 $P^2 = P$ 。点 x_0 到 $w^T x + b = 0$ 的距离为 $|w^T x_0 + b| / \|w\|_2$ ，前提是 $w \neq 0$ 。

读前自检：特征值与特征向量。 围绕特征值与特征向量，先采用条件“若 $Aq = \lambda q$ 且 $q \neq 0$ ”，再标出 $Aq = \lambda q$ 两侧的 shape 并完成一次乘法或正交检查；最后验证 λ 是特征值、 q 是特征向量。

读前自检：对称矩阵。 线性代数基础中的对称矩阵中的“实矩阵满足 $A = A^T$ 称对称矩阵”决定可执行范围；请标出 $A = A^T$ 两侧的 shape 并完成一次乘法或正交检查，结果须满足其特征值为实数，不同特征值的特征向量正交。

读前自检：正定矩阵与半正定矩阵。 把正定矩阵与半正定矩阵放在“对称矩阵 A 若对所有非零 x 有 $x^T A x > 0$ 则正定”下考察：标出 $x^T A x > 0$ 两侧的 shape 并完成一次乘法或正交检查，并检查若对所有 x 非负则半正定。

读前自检：二次型。 线性代数基础中的二次型要求先确认“ $q(x) = x^T A x$ 是二次型”；请随后把 $q(x)$ 展开一次并检查其类型或边界，用展开后的量满足定义中的域、维数或符号限制验收。

读前自检：矩阵的迹。 从线性代数基础中的矩阵的迹的条件“ $\text{tr}(A) = \sum_i A_{ii}$ ”出发，请标出 $\text{tr}(A) = \sum_i A_{ii}$ 两侧的 shape 并完成一次乘法或正交检查；所得量应符合乘法内侧维数相等且结果落入声明空间。

2.6 特征值、对称矩阵、正定性与二次型

若 $Aq = \lambda q$ 且 $q \neq 0$ ，则 λ 是特征值、 q 是特征向量。实矩阵满足 $A = A^T$ 称对称矩阵；其特征值为实数，不同特征值的特征向量正交。对称矩阵 A 若对所有非零 x 有 $x^T A x > 0$ 则正定；若对所有 x 非负则半正定。 $q(x) = x^T A x$ 是二次型，只有 A 的对称部分 $(A + A^T)/2$ 影响其值。 $\text{tr}(A) = \sum_i A_{ii}$ ；对维数相容矩阵有 $\text{tr}(AB) = \text{tr}(BA)$ ，并且迹等于特征值按代数重数之和。

读前自检：对称矩阵的谱分解。 对称矩阵的谱分解依赖“实对称矩阵可写为 $A = Q\Lambda Q^T$ ”；请据此标出 $A = Q\Lambda Q^T$ 两侧的 shape 并完成一次乘法或正交检查，并直接核对乘法内侧维数相等且结果落入声明空间。

读前自检：奇异值与奇异值分解的预备知识。 奇异值与奇异值分解的预备知识以“任意 $A \in \mathbb{R}^{m \times n}$ 的 $A^T A$ 半正定”为约束；请沿 $A \in \mathbb{R}^{m \times n}$ 标出输入域、输出域和一次运算结果的 shape，并确认左右奇异向量分别位于输入空间与输出空间。

2.7 谱分解、奇异值预备与幂法

实对称矩阵可写为 $A = Q\Lambda Q^T$ ，其中 Q 正交， Λ 为实对角矩阵；二次型因此分解为各特征方向坐标平方的加权和。任意 $A \in \mathbb{R}^{m \times n}$ 的 $A^T A$ 半正定，其非负特征值平方根称奇异值。左右奇异向量分别位于输入空间与输出空间。幂法利用 $A^t q_0 = \sum_i c_i \lambda_i^t q_i$ 中最大模特征值的幂次占优，通过每轮归一化避免数值尺度失控。唯一最大模特征值与非零初始分量是方向收敛的关键条件。

本章共 22 道练习。每道题干后立即给出同号解析；长解析可自然跨页，续页标题保留题号。

练习 2.1 (矩阵乘法). 计算 $\begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 3 \\ 4 \end{bmatrix}$ 。

练习 2.1 解析

对象为 $A \in \mathbb{R}^{2 \times 2}$ 与 $v \in \mathbb{R}^{2 \times 1}$ ；内侧维数相等，故 $Av \in \mathbb{R}^{2 \times 1}$ 。按行复算

$$\begin{aligned} Av &= \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 3 \\ 4 \end{bmatrix} \\ &= \begin{bmatrix} 1 \cdot 3 + 2 \cdot 4 \\ 0 \cdot 3 + 1 \cdot 4 \end{bmatrix} = \begin{bmatrix} 11 \\ 4 \end{bmatrix}. \end{aligned}$$

因此矩阵—向量乘积为 $(11, 4)^T$ ，其维数也与 $Av \in \mathbb{R}^2$ 一致。

练习 2.2 (乘法次序). 给出两个二阶矩阵，使 $AB \neq BA$ ，并完成计算。

练习 2.2 解析

取 $A, B \in \mathbb{R}^{2 \times 2}$ 如下；两个方向的乘积都有定义，但复合次序不同：

$$\begin{aligned} A &= \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}, & B &= \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}, \\ AB &= \begin{bmatrix} 1 \cdot 1 + 1 \cdot 1 & 1 \cdot 0 + 1 \cdot 1 \\ 0 \cdot 1 + 1 \cdot 1 & 0 \cdot 0 + 1 \cdot 1 \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix}, \\ BA &= \begin{bmatrix} 1 & 1 \\ 1 & 2 \end{bmatrix}, & AB - BA &= \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \neq 0. \end{aligned}$$

因此该例直接说明一般矩阵乘法不满足交换律。

练习 2.3 (行列式与可逆性). 判断 $A = \begin{bmatrix} 2 & 4 \\ 1 & 2 \end{bmatrix}$ 是否可逆。

练习 2.3 解析

对象是方阵 $A \in \mathbb{R}^{2 \times 2}$ ；可逆性的判据为 $\det(A) \neq 0$ 。本题有

$$\begin{aligned} \det(A) &= 2 \cdot 2 - 4 \cdot 1 = 0, \\ A \begin{bmatrix} -2 \\ 1 \end{bmatrix} &= \begin{bmatrix} -4 + 4 \\ -2 + 2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, & \begin{bmatrix} -2 \\ 1 \end{bmatrix} &\neq \mathbf{0}. \end{aligned}$$

因此 $N(A)$ 非平凡，等价地两列线性相关，故 A 不可逆。

练习 2.4 (三种范数). 对 $\mathbf{x} = (-1, 2, -2)^T$ 计算 ℓ_1 、 ℓ_2 和 ℓ_∞ 范数。

练习 2.4 解析

对象为 $\mathbf{x} = (-1, 2, -2)^T \in \mathbb{R}^3$ 。三种范数按各自定义计算为

$$\|\mathbf{x}\|_1 = |-1| + |2| + |-2| = 1 + 2 + 2 = 5,$$

$$\|\mathbf{x}\|_2 = \sqrt{(-1)^2 + 2^2 + (-2)^2} = \sqrt{9} = 3,$$

$$\|\mathbf{x}\|_\infty = \max\{|-1|, |2|, |-2|\} = 2.$$

所以三种范数依次为 5, 3, 2, 并满足 $\|\mathbf{x}\|_\infty \leq \|\mathbf{x}\|_2 \leq \|\mathbf{x}\|_1$ 。

练习 2.5 (距离). 求 $(1, 2)^T$ 与 $(4, -2)^T$ 的欧氏距离。

练习 2.5 解析

两点 $\mathbf{x}, \mathbf{y} \in \mathbb{R}^2$ 使用同一欧氏坐标系, 距离定义为差向量的二范数:

$$\mathbf{x} - \mathbf{y} = \begin{bmatrix} 1 \\ 2 \end{bmatrix} - \begin{bmatrix} 4 \\ -2 \end{bmatrix} = \begin{bmatrix} -3 \\ 4 \end{bmatrix},$$

$$d(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_2 = \sqrt{(-3)^2 + 4^2} = \sqrt{25} = 5.$$

交换两点只使差向量变号, 范数不变。

练习 2.6 (夹角与正交). 判断 $(1, 2)^T$ 与 $(2, -1)^T$ 是否正交, 并给出夹角。

练习 2.6 解析

令 $\mathbf{x} = (1, 2)^T$ 、 $\mathbf{y} = (2, -1)^T$; 二者非零, 故夹角公式的分母为正。于是

$$\mathbf{x}^T \mathbf{y} = 1 \cdot 2 + 2 \cdot (-1) = 0,$$

$$\cos \theta = \frac{\mathbf{x}^T \mathbf{y}}{\|\mathbf{x}\|_2 \|\mathbf{y}\|_2} = 0,$$

$$\theta = \frac{\pi}{2} \in [0, \pi].$$

故两向量正交。

练习 2.7 (张成判断). 判断 $(3, 1)^T$ 是否属于 $\text{span}\{(1, 1)^T, (1, -1)^T\}$ 。

练习 2.7 解析

对象均在 $\mathbb{R}^2$ 中。属于张成空间等价于存在 $a, b \in \mathbb{R}$ 满足线性方程：

$$\begin{aligned} a \begin{bmatrix} 1 \\ 1 \end{bmatrix} + b \begin{bmatrix} 1 \\ -1 \end{bmatrix} &= \begin{bmatrix} 3 \\ 1 \end{bmatrix} \Leftrightarrow \begin{cases} a + b = 3, \\ a - b = 1, \end{cases} \\ 2a &= 4 \Rightarrow a = 2, \quad b = 3 - a = 1, \\ 2 \begin{bmatrix} 1 \\ 1 \end{bmatrix} + \begin{bmatrix} 1 \\ -1 \end{bmatrix} &= \begin{bmatrix} 3 \\ 1 \end{bmatrix}. \end{aligned}$$

存在所需系数，故结论为属于；生成向量无关又保证表示唯一。

练习 2.8 (线性相关). 判断 $(1, 0, 1)^T$ 、 $(0, 1, 1)^T$ 、 $(1, 1, 2)^T$ 是否线性无关。

练习 2.8 解析

记三个给定向量为 $\boldsymbol{v}_1, \boldsymbol{v}_2, \boldsymbol{v}_3 \in \mathbb{R}^3$ 。线性相关只需构造一组非全零系数：

$$\begin{aligned} \boldsymbol{v}_1 + \boldsymbol{v}_2 &= \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} + \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ 2 \end{bmatrix} = \boldsymbol{v}_3, \\ 1\boldsymbol{v}_1 + 1\boldsymbol{v}_2 - 1\boldsymbol{v}_3 &= \mathbf{0}, \quad (1, 1, -1) \neq (0, 0, 0). \end{aligned}$$

因此该向量组线性相关。

练习 2.9 (换基坐标). 在基 $\mathcal{B} = ((1, 1)^T, (1, -1)^T)$ 下求 $(4, 2)^T$ 的坐标。

练习 2.9 解析

基矩阵 $B = [\boldsymbol{b}_1 \ \boldsymbol{b}_2] \in \mathbb{R}^{2 \times 2}$ 满足 $\det(B) = -2 \neq 0$ ，故坐标存在且唯一。求解

$$\begin{aligned} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} &= \begin{bmatrix} 4 \\ 2 \end{bmatrix} \Leftrightarrow \begin{cases} a + b = 4, \\ a - b = 2, \end{cases} \\ a &= 3, \quad b = 1, \\ [(4, 2)^T]_{\mathcal{B}} &= \begin{bmatrix} 3 \\ 1 \end{bmatrix}. \end{aligned}$$

因此 $(4, 2)^T = 3(1, 1)^T + (1, -1)^T$ ，坐标为 $(3, 1)^T$ 。

练习 2.10 (方程组全部解). 求 $x_1 + x_2 = 2$ 的全部实数解，并写成特解加零空间。

练习 2.10 解析

令 $A = [1 \ 1] \in \mathbb{R}^{1 \times 2}$ 、 $\mathbf{x} \in \mathbb{R}^2$ 。取特解 $\mathbf{x}_p = (2, 0)^T$ ，齐次解与全部解依次为

$$\begin{aligned} A\mathbf{x} = 0 &\iff x_1 = -x_2, \\ N(A) &= \left\{ t \begin{bmatrix} -1 \\ 1 \end{bmatrix} : t \in \mathbb{R} \right\}, \\ \{\mathbf{x} : A\mathbf{x} = 2\} &= \left\{ \begin{bmatrix} 2 \\ 0 \end{bmatrix} + t \begin{bmatrix} -1 \\ 1 \end{bmatrix} : t \in \mathbb{R} \right\}, \\ A \left(\begin{bmatrix} 2 \\ 0 \end{bmatrix} + t \begin{bmatrix} -1 \\ 1 \end{bmatrix} \right) &= 2 - t + t = 2. \end{aligned}$$

因此齐次解空间是一条过原点的直线，非齐次解集是它经过 $(2, 0)^T$ 的平移。

练习 2.11 (秩与零度). 已知 $A \in \mathbb{R}^{4 \times 6}$ 且 $\text{rank}(A) = 3$ ，求 $N(A)$ 和 $N(A^T)$ 的维数。

练习 2.11 解析

对象为 $A : \mathbb{R}^6 \rightarrow \mathbb{R}^4$ ，而 $A^T : \mathbb{R}^4 \rightarrow \mathbb{R}^6$ ；两者秩均为 3。分别在各自定义域应用秩—零度定理：

$$\begin{aligned} \dim N(A) &= 6 - \text{rank}(A) = 6 - 3 = 3, \quad N(A) \subseteq \mathbb{R}^6, \\ \dim N(A^T) &= 4 - \text{rank}(A^T) = 4 - 3 = 1, \quad N(A^T) \subseteq \mathbb{R}^4. \end{aligned}$$

所以两个零空间的维数分别为 3 与 1，其所属环境空间也已对应核对。

练习 2.12 (超平面). 写出经过点 $(1, 0)^T$ 、法向量为 $(2, -1)^T$ 的直线方程。

练习 2.12 解析

令 $\mathbf{x}_0 = (1, 0)^T \in \mathbb{R}^2$ ，非零法向量 $\mathbf{w} = (2, -1)^T$ 。所求仿射超平面为

$$\begin{aligned} H &= \{\mathbf{x} \in \mathbb{R}^2 : \mathbf{w}^T(\mathbf{x} - \mathbf{x}_0) = 0\} \\ &= \{(x_1, x_2)^T : 2(x_1 - 1) - (x_2 - 0) = 0\} \\ &= \{(x_1, x_2)^T : 2x_1 - x_2 - 2 = 0\}. \end{aligned}$$

代入 $\mathbf{x}_0$ 所得左端为零，故经过指定点。

练习 2.13 (基本子空间). 对 $A = \begin{bmatrix} 1 & 1 \\ 2 & 2 \end{bmatrix}$ 求列空间与零空间的一组基。

练习 2.13 解析

对象为 $A: \mathbb{R}^2 \rightarrow \mathbb{R}^2$ 。第二列与第一列相同且非零，因此

$$\begin{aligned} R(A) &= \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \end{bmatrix} \right\}, \\ A \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \mathbf{0} &\Leftrightarrow x_1 + x_2 = 0 \Leftrightarrow \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = t \begin{bmatrix} -1 \\ 1 \end{bmatrix}, \\ N(A) &= \text{span} \left\{ \begin{bmatrix} -1 \\ 1 \end{bmatrix} \right\}, \quad \text{rank}(A) + \dim N(A) = 1 + 1 = 2. \end{aligned}$$

因此 $R(A)$ 与 $N(A)$ 均为一维，且秩—零度恒等式得到验证。

练习 2.14 (投影矩阵). 设 $\mathbf{q} = (1, 0)^\top$ ，求到其张成空间的投影矩阵，并投影 $(2, 3)^\top$ 。

练习 2.14 解析

给定 $\mathbf{q} = (1, 0)^\top \in \mathbb{R}^2$ 且 $\mathbf{q}^\top \mathbf{q} = 1$ ，故一维投影矩阵无需额外归一化：

$$\begin{aligned} P &= \mathbf{q}\mathbf{q}^\top = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} \in \mathbb{R}^{2 \times 2}, \\ P \begin{bmatrix} 2 \\ 3 \end{bmatrix} &= \begin{bmatrix} 2 \\ 0 \end{bmatrix}, & \mathbf{r} &= \begin{bmatrix} 2 \\ 3 \end{bmatrix} - \begin{bmatrix} 2 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 3 \end{bmatrix}, \\ \mathbf{q}^\top \mathbf{r} &= 0, & P^2 &= P. \end{aligned}$$

因此 P 确为到 x 轴的正交投影，向量 $(2, 3)^\top$ 的投影为 $(2, 0)^\top$ 。

练习 2.15 (点到直线距离). 求点 $(0, 0)^\top$ 到直线 $3x_1 + 4x_2 - 10 = 0$ 的距离。

练习 2.15 解析

直线法向量 $\mathbf{w} = (3, 4)^\top \neq \mathbf{0}$ ，故点到超平面的距离公式分母非零。对 $\mathbf{x}_0 = (0, 0)^\top$ ，

$$\begin{aligned} \|\mathbf{w}\|_2 &= \sqrt{3^2 + 4^2} = 5, \\ |\mathbf{w}^\top \mathbf{x}_0 - 10| &= |3 \cdot 0 + 4 \cdot 0 - 10| = 10, \\ \text{dist}(\mathbf{x}_0, H) &= \frac{10}{5} = 2 \geq 0. \end{aligned}$$

所以原点到该直线的距离为 2。

练习 2.16 (特征对). 验证 $(1, 1)^\top$ 是 $A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$ 的特征向量并求特征值。

练习 2.16 解析

对象为 $A \in \mathbb{R}^{2 \times 2}$ 和非零候选 $\mathbf{q} = (1, 1)^\top$ 。按特征对定义核对

$$\begin{aligned} A\mathbf{q} &= \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 3 \\ 3 \end{bmatrix} \\ &= 3 \begin{bmatrix} 1 \\ 1 \end{bmatrix} = 3\mathbf{q}. \end{aligned}$$

因此 $\mathbf{q}$ 是特征向量，对应特征值 $\lambda = 3$ 。

练习 2.17 (正定判断). 判断 $A = \text{diag}(2, 0)$ 是正定还是半正定。

练习 2.17 解析

矩阵 $A = \text{diag}(2, 0)$ 实对称。对任意 $\mathbf{x} = (x_1, x_2)^\top \in \mathbb{R}^2$,

$$\begin{aligned} \mathbf{x}^\top A \mathbf{x} &= \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2x_1 \\ 0 \end{bmatrix} = 2x_1^2 \geq 0, \\ \mathbf{e}_2^\top A \mathbf{e}_2 &= 0, \quad \mathbf{e}_2 = (0, 1)^\top \neq \mathbf{0}. \end{aligned}$$

故 A 半正定，但因存在非零零方向而不正定。

练习 2.18 (迹与特征值). 已知二阶矩阵特征值为 5 和 -1 ，求其迹，并判断它能否为正定对称矩阵。

练习 2.18 解析

对象是实二阶矩阵，给定特征值按代数重数为 $\lambda_1 = 5$ 、 $\lambda_2 = -1$ 。于是

$$\begin{aligned} \text{tr}(A) &= \lambda_1 + \lambda_2 = 5 - 1 = 4, \\ A &= A^\top, A > 0 \implies \lambda_1 > 0 \text{ 且 } \lambda_2 > 0, \\ \lambda_2 &= -1 < 0 \implies A \text{ 不可能是正定对称矩阵.} \end{aligned}$$

迹为正只约束特征值之和，不能排除负特征值。

练习 2.19 (谱重构). 设 $Q = I_2$ 、 $\Lambda = \text{diag}(3, 1)$ ，写出 $Q\Lambda Q^\top$ 并解释两个主轴。

练习 2.19 解析

对象为 $Q = I_2 \in \mathbb{R}^{2 \times 2}$ 与 $\Lambda = \text{diag}(3, 1)$ 。谱重构及主轴作用为

$$\begin{aligned} Q\Lambda Q^\top &= I_2 \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix} I_2 = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}, \\ A\mathbf{e}_1 &= 3\mathbf{e}_1, & A\mathbf{e}_2 &= 1\mathbf{e}_2. \end{aligned}$$

故两条主轴就是标准坐标轴，第一轴伸缩三倍，第二轴保持不变。

练习 2.20 (奇异值). 求 $A = \text{diag}(4, 2)$ 的奇异值。

练习 2.20 解析

对象为 $A = \text{diag}(4, 2) \in \mathbb{R}^{2 \times 2}$; 奇异值是 $A^T A$ 特征值的非负平方根:

$$\begin{aligned} A^T A &= \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}^T \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix} = \begin{bmatrix} 16 & 0 \\ 0 & 4 \end{bmatrix}, \\ \lambda(A^T A) &\in \{16, 4\}, \\ (\sigma_1, \sigma_2) &= (\sqrt{16}, \sqrt{4}) = (4, 2). \end{aligned}$$

因此按非增次序排列的奇异值为 4 和 2。

练习 2.21 (幂法一步). 对 $A = \text{diag}(3, 1)$ 和 $q_0 = (1, 1)^T / \sqrt{2}$ 执行一次归一化幂法。

练习 2.21 解析

输入满足 $A \in \mathbb{R}^{2 \times 2}$ 、 $\|q_0\|_2 = 1$, 且 $z_1 = Aq_0 \neq 0$, 所以本轮归一化合法。一次完整更新为

$$\begin{aligned} z_1 &= Aq_0 = \frac{1}{\sqrt{2}} \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} 3 \\ 1 \end{bmatrix}, \\ \|z_1\|_2 &= \sqrt{\frac{9+1}{2}} = \sqrt{5}, & q_1 &= \frac{z_1}{\|z_1\|_2} = \frac{1}{\sqrt{10}} \begin{bmatrix} 3 \\ 1 \end{bmatrix}, \\ \lambda_1 &= q_1^T Aq_1 = \frac{27+1}{10} = \frac{14}{5}, & \|Aq_1 - \lambda_1 q_1\|_2 &= \frac{3}{5}. \end{aligned}$$

方向系数比由 1 : 1 变为 3 : 1, 主特征方向的相对权重增大。

练习 2.22 (章末综合). 综合题: 设 $A = \begin{bmatrix} 1 & 1 \\ 1 & 1 \\ 0 & 0 \end{bmatrix}$ 。求秩、零空间一组基、列空间一组基, 并验证 $N(A) = R(A^T)^\perp$ 。

练习 2.22 解析

对象为 $A: \mathbb{R}^2 \rightarrow \mathbb{R}^3$ 。两列相同且非零，故依次得到

$$\begin{aligned}\operatorname{rank}(A) &= 1, \\ R(A) &= \operatorname{span} \left\{ \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} \right\} \subseteq \mathbb{R}^3, \\ A \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} &= \mathbf{0} \iff x_1 + x_2 = 0, \\ N(A) &= \operatorname{span} \left\{ \begin{bmatrix} -1 \\ 1 \end{bmatrix} \right\} \subseteq \mathbb{R}^2, \\ R(A^\top) &= \operatorname{span} \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\}, \\ R(A^\top)^\perp &= \left\{ \begin{bmatrix} z_1 \\ z_2 \end{bmatrix} : z_1 + z_2 = 0 \right\} \\ &= \operatorname{span} \left\{ \begin{bmatrix} -1 \\ 1 \end{bmatrix} \right\} = N(A).\end{aligned}$$

因此 $N(A) = R(A^\top)^\perp$ 在本例中成立，同时 $\operatorname{rank}(A) = 1$ 与各空间维数相符。

读前自检：本章结论与下一步。 线性代数基础章末由“向量、矩阵、子空间与谱”落到“先验维数检查、再求解或迭代并记录停止条件”；请把前者产出和后者输入逐项对齐，固定核对前者末项的输出类型能否作为后者首项的输入类型。

本章结论与下一步

核心结论： 向量、矩阵、子空间与谱

关键依据： 由分量运算推出投影、正定性和谱分解

可执行自检： 先验维数检查、再求解或迭代并记录停止条件

适用边界： 线性模型、二次优化与降维的代数准备

下一步： 进入章 3 并保留列向量约定

1. 我能按分量写出矩阵乘法并核对维数；未通过时回看节 2.1。
2. 我能区分范数、距离、内积和夹角；未通过时回看节 2.2。
3. 我能由方程组求秩、基和四个基本子空间；未通过时回看节 2.3—2.5。
4. 我能判断正定性并解释谱分解、奇异值与幂法条件；未通过时回看节 2.6、2.7。

第3章 多元微积分与矩阵微分

本章地图

核心问题：多元函数的局部变化怎样转化为可计算的导数对象

可检验学习目标：

- 能从偏导数构造梯度、Jacobian 矩阵和 Hessian 矩阵，并核对其维数；
- 能按分量推导线性函数、二次型和对数函数的梯度，正确使用多元链式法则；
- 能以一阶、二阶泰勒模型解释方向变化和极值条件，并执行带停止规则的梯度下降伪代码。

最短先修：需要掌握一元函数的极限、导数、乘法法则以及章2中的内积、矩阵乘法、对称矩阵与正定性。全部梯度按列向量书写，输入向量默认属于 $\mathbb{R}^d$ 。

依赖路线：

偏导数 → 梯度与方向导数 → Hessian 与泰勒模型 → 链式法则 → 向量、矩阵微分。

梯度下降依赖梯度，极值判定依赖 Hessian，复合模型的参数导数依赖 Jacobian 矩阵的乘法顺序。

完成标准与返回：定义域或维数不闭合时回看偏导与矩阵分量节

读前自检：本章符号表。 多元微积分与矩阵微分符号表规定 $d \times 1$ 、 $\mathbf{u}$ 的类型或范围；请把 $d \times 1$ 代入紧随其后的定义关系，逐项核对输入形状、输出形状与取值域。

本章符号表

符号	维数或类型	含义
$f : \mathbb{R}^d \rightarrow \mathbb{R}$	标量函数	输入向量、输出标量
$\nabla f(\mathbf{x})$	$d \times 1$	各偏导组成的列梯度
$D_{\mathbf{u}}f(\mathbf{x})$	标量	单位方向 $\mathbf{u}$ 上的方向导数
$H_f(\mathbf{x})$	$d \times d$	二阶偏导组成的 Hessian 矩阵
$\mathbf{g} : \mathbb{R}^d \rightarrow \mathbb{R}^m$	向量函数	m 个标量分量函数
$J_{\mathbf{g}}(\mathbf{x})$	$m \times d$	$[J_{\mathbf{g}}]_{ij} = \partial g_i / \partial x_j$
df	标量线性形式	函数的一阶微分

问题提出

统计学习的目标函数通常同时依赖许多参数。只会逐个套用一元公式，容易把梯度方向、转置位置和链式法则的矩阵顺序写错。本章要回答：多元函数在一个点附近怎样变化，哪个方向上升最快，驻点在什么条件下可能是极小点，以及常用矩阵公式怎样由分量定义推出。

读前自检：可微与梯度。 可微定义要求 $U \subseteq \mathbb{R}^d$ 为开集且 $f : U \rightarrow \mathbb{R}$ ；请把增量写成 $f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}) = \mathbf{g}^T \mathbf{h} + o(\|\mathbf{h}\|)$ ，再核对线性主部 $\mathbf{g}$ 就是 $\nabla f(\mathbf{x})$ 。

定义 3.1 (可微与梯度). 设 $U \subseteq \mathbb{R}^d$ 为开集, $f: U \rightarrow \mathbb{R}$. 若存在向量 $\mathbf{g} \in \mathbb{R}^d$, 使得当 $\mathbf{h} \rightarrow \mathbf{0}$ 时

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \mathbf{g}^\top \mathbf{h} + o(\|\mathbf{h}\|_2),$$

则 f 在 $\mathbf{x}$ 可微, $\mathbf{g}$ 称梯度, 记作 $\nabla f(\mathbf{x})$. 小量条件要求余项除以 $\|\mathbf{h}\|_2$ 后趋于零。

局部模型、求解策略与算法

一阶局部模型为 $m_1(\mathbf{h}) = f(\mathbf{x}) + \nabla f(\mathbf{x})^\top \mathbf{h}$; 二阶局部模型再加入 $\frac{1}{2} \mathbf{h}^\top H_f(\mathbf{x}) \mathbf{h}$. 模型只承诺在足够小邻域内近似原函数。

学习策略是先写变量空间与输出类型, 再按分量确定导数, 随后用链式法则组合, 最后用方向导数或数值代入核对。优化时选择负梯度方向, 因为它使一阶模型在给定步长下下降最多。

学习算法采用固定步长梯度下降: 每轮计算梯度, 沿其反方向更新, 并以梯度范数作为一阶停止判据。该算法的收敛条件必须与步长和函数曲率共同声明。

核心推导: 二次型的梯度

阅读目标: 看清变量在二次型的左右两侧各贡献一次导数。

对象: $A \in \mathbb{R}^{d \times d}$ 、 $\mathbf{x} \in \mathbb{R}^d$ 与标量函数 $f(\mathbf{x}) = \mathbf{x}^\top A \mathbf{x}$ 。

合法条件: A 在求导时固定; 梯度采用 $d \times 1$ 列向量约定。

第一步: 先写成 $f = \sum_{i,j} x_i A_{ij} x_j$, 再对任意分量 x_k 求偏导。

推导目标

对 $A \in \mathbb{R}^{d \times d}$ 与 $f(\mathbf{x}) = \mathbf{x}^\top A \mathbf{x}$, 由分量定义推导 $\nabla f(\mathbf{x})$, 并解释对称情形。

推导准备

$\mathbf{x} \in \mathbb{R}^d$ 是列向量, f 是标量; 分量形式为 $f = \sum_{i=1}^d \sum_{j=1}^d x_i A_{ij} x_j$. 矩阵 A 在求导时固定。

推导第 1 步: 对第 k 个分量求偏导。 使用乘法法则, x_k 可能出现在左因子或右因子, 因而

$$\frac{\partial f}{\partial x_k} = \sum_{j=1}^d A_{kj} x_j + \sum_{i=1}^d x_i A_{ik}.$$

推导第 2 步: 识别矩阵分量。 第一项是 $(A\mathbf{x})_k$, 第二项是 $(A^\top \mathbf{x})_k$. 对每个 k 组合这些分量, 得到

$$\nabla f(\mathbf{x}) = (A + A^\top) \mathbf{x}.$$

右侧维数为 $d \times 1$, 与列梯度约定一致。

推导第 3 步: 代入对称条件。 若 $A = A^\top$, 则两个贡献相等, 所以

$$\nabla f(\mathbf{x}) = 2A\mathbf{x}, \quad H_f(\mathbf{x}) = 2A.$$

系数 2 来自变量在二次项的两个位置，不能在非对称矩阵情形中只保留 $2A\mathbf{x}$ 。

定理 3.1 (方向导数与梯度) 若 $U \subseteq \mathbb{R}^d$ 为开集, $f: U \rightarrow \mathbb{R}$ 在 $\mathbf{x} \in U$ 可微, $\mathbf{u} \in \mathbb{R}^d$ 且 $\|\mathbf{u}\|_2 = 1$, 则方向导数存在并满足 $D_{\mathbf{u}}f(\mathbf{x}) = \nabla f(\mathbf{x})^T \mathbf{u}$ 。当梯度非零时, 其最大值为 $\|\nabla f(\mathbf{x})\|_2$, 在 $\mathbf{u} = \nabla f / \|\nabla f\|_2$ 处取得。

读前自检：证明：方向导数与梯度。 方向导数证明要求 U 开、 $\mathbf{x} \in U$ 且 $\|\mathbf{u}\|_2 = 1$ ；请把可微增量式代入 $\mathbf{h} = t\mathbf{u}$ 并除以 t 取极限，核对 $D_{\mathbf{u}}f(\mathbf{x}) = \nabla f(\mathbf{x})^T \mathbf{u}$ 。

证明。 因为 U 为开集且 $\mathbf{x} \in U$, 存在 $r > 0$ 使 $B(\mathbf{x}, r) \subset U$ 。于是当 $|t| < r$ 时, $\mathbf{x} + t\mathbf{u} \in U$, 双侧差商均有定义。由可微定义取 $\mathbf{h} = t\mathbf{u}$, 则

$$\frac{f(\mathbf{x} + t\mathbf{u}) - f(\mathbf{x})}{t} = \nabla f(\mathbf{x})^T \mathbf{u} + \frac{o(|t|\|\mathbf{u}\|_2)}{t}.$$

余项可写为 $|t|\varepsilon(t)$, 其中 $\varepsilon(t) \rightarrow 0$; 故其除以 t 为 $\text{sgn}(t)\varepsilon(t) \rightarrow 0$, 所以双侧极限等于梯度与方向的内积。再由 Cauchy-Schwarz 不等式, $\nabla f^T \mathbf{u} \leq \|\nabla f\|_2 \|\mathbf{u}\|_2 = \|\nabla f\|_2$ 。取与梯度同向的单位向量时等号成立; 梯度为零时所有方向导数均为零。两部分结论均成立。□

读前自检：几何解释：梯度垂直于等值线并指向局部上升最快方向。 梯度几何解释以单位方向 $\mathbf{u}$ 为对象; 请由方向导数 $D_{\mathbf{u}}f = \nabla f^T \mathbf{u}$ 应用 Cauchy-Schwarz, 核对最大值 $\|\nabla f\|_2$ 在 $\mathbf{u}$ 与梯度同向时取得。

几何理解

几何解释。 梯度垂直于等值线并指向局部上升最快方向。对 $\mathbf{u} \in \mathbb{R}^d$, Hessian 作为线性映射先给出向量 $H\mathbf{u} \in \mathbb{R}^d$; 标量 $\mathbf{u}^T H\mathbf{u} \in \mathbb{R}$ 才是沿 $\mathbf{u}$ 的二阶方向导数 (局部曲率)。正定 Hessian 对应每个非零方向上的曲率都为正。

概率解释

当随机输入在均值附近有小扰动 δ 时, 一阶近似 $f(\mu + \delta) \approx f(\mu) + \nabla f(\mu)^T \delta$ 把输出不确定性转化为梯度加权的输入扰动; 该解释要求扰动足够小并且函数在均值附近可微。

优化解释

优化解释。 负梯度最小化一阶模型; Hessian 半正定是内部局部极小点的必要二阶条件。若 Hessian 正定且邻域内连续, 则驻点为严格局部极小点。




图 3.1 梯度与等值线。箭头在该点垂直于局部切线，并指向函数值增加的方向。

在图 3.1 中，等值线切向量 $\mathbf{v}_{\text{tan}}$ 满足 $\nabla f^T \mathbf{v}_{\text{tan}} = 0$ ；梯度非零时，最速上升单位方向另记为 $\mathbf{u}_{\text{max}} = \nabla f / \|\nabla f\|_2$ 。两者正交，不能复用同一符号。

例题 3.1 (二元二次函数). 设 $f(x_1, x_2) = x_1^2 + 2x_1x_2 + 3x_2^2$ 。求梯度、Hessian，并判断原点的性质。

例题 3.1 解答

读题翻译 对给定二元二次函数逐项求一、二阶导数，并据 Hessian 曲率判断原点是何种驻点及其全局性质。

已知与合法条件 $f: \mathbb{R}^2 \rightarrow \mathbb{R}$ 在整个定义域二次可微，原点没有边界约束；常 Hessian 可用 Sylvester 判据检验正定性。

为什么想到这个方法 先逐分量求梯度和 Hessian，再检查两个顺序主子式；最后用配方独立确认全局最小值与唯一性。

方法选择 计算 ∇f 和 H_f ，验证 $\nabla f(0,0) = 0$ 及 Hessian 正定，再把 f 写成平方和作全局核验。

推导/计算 对象为 $f: \mathbb{R}^2 \rightarrow \mathbb{R}$ ；其定义域没有边界限制。逐项求导并用 Sylvester 判据核对：

$$\begin{aligned}\nabla f(x_1, x_2) &= \begin{bmatrix} 2x_1 + 2x_2 \\ 2x_1 + 6x_2 \end{bmatrix}, & \nabla f(0,0) &= \mathbf{0}, \\ H_f &= \begin{bmatrix} 2 & 2 \\ 2 & 6 \end{bmatrix}, & \Delta_1 &= 2 > 0, \quad \Delta_2 = 12 - 4 = 8 > 0, \\ \mathbf{x}^T H_f \mathbf{x} &> 0 & & \text{对所有 } \mathbf{x} \neq \mathbf{0}.\end{aligned}$$

两个顺序主子式均为正，故 Hessian 正定；原点是严格局部极小点。由于 $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T H_f \mathbf{x}$ ，该结论也适用于全局。

独立核验 独立配方得

$$f(x_1, x_2) = (x_1 + x_2)^2 + 2x_2^2 \geq 0,$$

且等号迫使 $x_2 = 0, x_1 = 0$ ，再次证明极小点唯一并核对最小值为 0。

结论

$$\nabla f = \begin{bmatrix} 2x_1 + 2x_2 \\ 2x_1 + 6x_2 \end{bmatrix}, \quad H_f = \begin{bmatrix} 2 & 2 \\ 2 & 6 \end{bmatrix};$$

原点是唯一全局极小点, 最小值为 0。

梯度下降伪代码

输入为可微函数 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 、确定性的梯度规则和一个已核验合法的初始向量; 输出统一为最终返回点、在该点重新计算的函数值与梯度范数、已经完成的更新次数和状态。数值失败还要给出失败位置与诊断, 不能把候选失败点覆盖成返回点。参数 $\eta > 0$ 是步长, $\varepsilon > 0$ 是梯度容差, $T \in \mathbb{N}_0$ 是更新预算; 三者必须分别为有限正数、有限正数和非负整数, 否则状态为 `invalid_input`。初始化令 $\mathbf{x} \leftarrow \mathbf{x}_0$, $t \leftarrow 0$ 。只有在点、函数值与梯度都通过有限性和定义域检查后, 当前点才是可返回的“最后合法点”。更新规则是 $\mathbf{x}^+ = \mathbf{x} - \eta \nabla f(\mathbf{x})$ 。先核验候选点的 $f(\mathbf{x}^+)$ 与 $\nabla f(\mathbf{x}^+)$, 全部合法后才提交 $\mathbf{x} \leftarrow \mathbf{x}^+$ 并增加 t ; 越域、异常或非有限值均保留旧的最后合法点。每个出口都在最终返回点重新计算 $f_{\text{final}} = f(\mathbf{x})$ 和 $\mathbf{g}_{\text{final}} = \nabla f(\mathbf{x})$ 。若 $\|\mathbf{g}_{\text{final}}\|_2 \leq \varepsilon$ 则状态为 `converged`; 若 $t = T$ 仍未满足容差则为 `budget_stop`; 输入不合法与数值求值失败分别为 `invalid_input` 和 `numerical_failure`。旧点梯度不得冒充最终点梯度。**扩展讨论(严格速率, 主线可先跳过)**。以下结论所需的凸性与光滑性概念在章 7、8 中系统建立。若 f 为 μ 强凸且梯度为 L -Lipschitz 连续, 并取 $0 < \eta \leq 1/L$, 令 $\mathbf{x}^*$ 为唯一极小点, 则

$$\begin{aligned} f(\mathbf{x}_t) - f(\mathbf{x}^*) &\leq (1 - \mu\eta)^t (f(\mathbf{x}_0) - f(\mathbf{x}^*)), \\ \|\mathbf{x}_t - \mathbf{x}^*\|_2^2 &\leq \frac{2}{\mu} (1 - \mu\eta)^t (f(\mathbf{x}_0) - f(\mathbf{x}^*)), \\ \|\nabla f(\mathbf{x}_t)\|_2^2 &\leq 2L(1 - \mu\eta)^t (f(\mathbf{x}_0) - f(\mathbf{x}^*)). \end{aligned}$$

第一行是函数值线性收敛, 后两行分别由强凸性和 L -光滑性推出点误差与梯度范数界。一般非凸但下有界且 L -光滑时, 若仍取 $0 < \eta \leq 1/L$, 则只保证

$$\min_{0 \leq k < T} \|\nabla f(\mathbf{x}_k)\|_2^2 \leq \frac{2(f(\mathbf{x}_0) - \inf f)}{\eta T},$$

即一阶驻点指标趋零, 不保证迭代点或函数值以线性速率收敛。

读前自检: 固定步长梯度下降: 执行契约。 固定步长梯度下降输入“确定性目标、梯度、初始点、步长、容差与最大更新数”, 条件“初始点处目标与梯度有限, 函数与梯度的维数匹配”; 请执行“候选点及其目标与梯度均合法后才提交当前点并增加更新数”, 以“最终点梯度范数不超过容差时返回 `converged`”判停。

读前自检: 固定步长梯度下降。 固定步长梯度下降输入“确定性目标、梯度、初始点、步长、容差与最大更新数”, 条件“初始点处目标与梯度有限, 函数与梯度的维数匹配”; 请做一轮“候选点及其目标与梯度均合法后才提交当前点并增加更新数”, 以“最终点梯度范数不超过容差时返回 `converged`”核对停止证书。

算法 3.1: 固定步长梯度下降

输入: $f, \nabla f$, 初始点 $\mathbf{x}_0$, 步长 $\eta > 0$, 容差 $\varepsilon > 0$, 更新上限 T

输出: 最后合法点 $\mathbf{x}$ 、梯度范数、实际更新数 t 与停止状态

1 核验输入, 在 $\mathbf{x} \leftarrow \mathbf{x}_0$ 处计算 $\mathbf{g} \leftarrow \nabla f(\mathbf{x})$ 并置 $t \leftarrow 0$

2 当 $\|\mathbf{g}\|_2 > \varepsilon$ 且 $t < T$ 执行

3 形成候选 $\mathbf{x}^+ \leftarrow \mathbf{x} - \eta \mathbf{g}$, 并只在 $f(\mathbf{x}^+)$ 与 $\nabla f(\mathbf{x}^+)$ 均合法有限时提交

4 令 $\mathbf{x} \leftarrow \mathbf{x}^+$ 、 $\mathbf{g} \leftarrow \nabla f(\mathbf{x})$ 、 $t \leftarrow t + 1$

5 结束

6 若 $\|\mathbf{g}\|_2 \leq \varepsilon$ 返回 converged, 否则返回 budget_stop; 非法候选保留上一合法点并返回失败诊断

算法实现说明: 主体只有初始化、梯度更新与 $\|\nabla f\|_2$ 停止三层; 非法输入、越域或非有限候选均由完整契约处理并保留上一合法点 完整 C1–C14 契约

读前自检: 复杂度分析: 梯度下降伪代码。把梯度下降伪代码放在“若参数维数为 d , 一次函数与梯度计算成本为 $C_f + C_g$ ”下考察: 由 C_f, C_g 的总成本剥离一次迭代或一次样本因子, 并检查显式保存 Hessian 时增至 $O(d^2)$ 。

复杂度分析

复杂度假设。以下界把一次目标值和梯度求值的实际成本分别记为 C_f, C_g , 把执行的更新轮数记为 T ; 向量运算采用单位成本实数模型, 稠密二次型按完整矩阵访问。线搜索的额外函数求值应另行计入 C_f 的实际调用次数。训练复杂度。若参数维数为 d , 一次函数与梯度计算成本为 $C_f + C_g$, T 轮固定步长梯度下降为 $O(T(C_f + C_g))$; 稠密二次型的一次梯度计算通常为 $O(d^2)$ 。预测复杂度。通用微分与优化过程本身不定义预测映射; 拟合后模型的预测成本取决于所优化的具体模型。存储复杂度。除模型数据外保存当前点、梯度和候选点, 额外空间为 $O(d)$; 显式保存 Hessian 时增至 $O(d^2)$ 。

适用条件与局限性

适用条件。梯度方法适用于目标可微且梯度可计算的连续参数问题; 矩阵微分适合把大量分量关系压缩为维数清楚的式子。

方法局限。不可微点没有普通梯度, 固定步长对尺度敏感, 鞍点也满足梯度为零, 泰勒近似离展开点过远时误差还可能很大。

读前自检: 常见错误与误用边界: 梯度下降伪代码。梯度下降伪代码要求先确认“边界框首项禁止把列梯度写成行向量”; 请随后把固定错误“把列梯度写成行向量”中的对象、操作与结论按本节定义拆开, 指出第一个不满足的定义条件, 再把该处改为本节允许的写法, 用改写后的运算或判断有定义, 且不再触发“把列梯度写成行向量”验收。

常见错误

典型误用包括把列梯度写成行向量、链式法则中颠倒 Jacobian 矩阵次序、对 $\log x$ 忽视 $x > 0$ 、把偏导存在误当作必然可微、在非对称二次型中写 $2\mathbf{A}\mathbf{x}$, 以及用梯度为零单独断言局部极小。

阅读目标：把多元二阶展开化为一元 Taylor 定理，并核对每一项都是标量。

对象： $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 、展开点 $\mathbf{x}$ 与增量 $\mathbf{h} \in \mathbb{R}^d$ 。

合法条件： f 在连接 $\mathbf{x}$ 与 $\mathbf{x} + \mathbf{h}$ 的线段邻域内二次连续可微。

第一步：先定义一元函数 $\phi(t) = f(\mathbf{x} + t\mathbf{h})$, $t \in [0, 1]$ 。

易混淆概念对比

概念	输出	关键区别
偏导数与方向导数	标量	前者沿坐标轴，后者沿任意给定方向
梯度与 Jacobian 矩阵	$d \times 1$ 与 $m \times d$	标量输出采用梯度，向量输出采用 Jacobian 矩阵
梯度与 Hessian 矩阵	一阶向量与二阶矩阵	前者给斜率，后者给曲率
驻点与极小点	条件与性质	驻点还可能是极大点或鞍点

读前自检：多元函数。从多元微积分与矩阵微分中的多元函数的条件“定义域可能是全空间，也可能受对数、平方根或分母条件限制”出发，请沿 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 标出输入域、输出域和一次运算结果的形状；所得量应符合运算闭合且结果落入声明的空间或集合。

3.1 多元函数与偏导数

多元标量函数 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 把一个 d 维输入映射为标量。定义域可能是全空间，也可能受对数、平方根或分母条件限制。第 j 个偏导固定其余分量，只让 x_j 变化：

$$\frac{\partial f}{\partial x_j}(\mathbf{x}) = \lim_{t \rightarrow 0} \frac{f(\mathbf{x} + t\mathbf{e}_j) - f(\mathbf{x})}{t},$$

前提是极限存在且附近点留在定义域内。

读前自检：梯度。多元微积分与矩阵微分中的梯度依赖“ $\nabla f = (\partial f / \partial x_1, \dots, \partial f / \partial x_d)^\top$ 是列向量”；请据此对 ∇f 完成一项求导、代入或边界比较，并直接核对结果的形状、符号和取等条件与定义一致。

读前自检：方向导数。多元微积分与矩阵微分中的方向导数以“单位方向 $\mathbf{u}$ 上的方向导数是沿直线 $\mathbf{x} + t\mathbf{u}$ 的一元导数”为约束；请对 $\mathbf{u}$ 完成一项求导、代入或边界比较，并确认函数可微时等于梯度内积。

3.2 梯度与方向导数

$\nabla f = (\partial f / \partial x_1, \dots, \partial f / \partial x_d)^\top$ 是列向量，其分量与输入坐标一一对应。单位方向 $\mathbf{u}$ 上的方向导数是沿直线 $\mathbf{x} + t\mathbf{u}$ 的一元导数；函数可微时等于梯度内积。

读前自检：Hessian 矩阵。 先锁定 Hessian 矩阵的条件“二次连续可微函数的 Hessian 为 $[H_f]_{ij} = \partial^2 f / (\partial x_i \partial x_j)$ ”：标出 $[H_f]_{ij}$ 两侧的形狀并完成一次乘法或正交检查，所得结果应满足乘法内侧维数相等且结果落入声明空间。

读前自检：多元函数极值的必要条件。 对多元函数极值的必要条件，条件“若可微函数在开集内部点取得局部极值”不可省；请把 $\phi''(t)$ 展开一次并检查其类型或边界，再用展开后的量满足定义中的域、维数或符号限制作检查。

3.3 Hessian 矩阵、泰勒展开与极值

二次连续可微函数的 Hessian 为 $[H_f]_{ij} = \partial^2 f / (\partial x_i \partial x_j)$ ，此时混合偏导相等，矩阵对称。若可微函数在开集内部点取得局部极值，则梯度为零；若还二次可微且为局部极小，则 Hessian 半正定。梯度为零与 Hessian 半正定一般不是充分条件。

推导目标

推导 $f(\mathbf{x} + \mathbf{h})$ 在展开点 $\mathbf{x}$ 附近的二阶 Taylor 式，并核对线性项与二次项均为标量。

推导准备

设 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 在连接 $\mathbf{x}$ 与 $\mathbf{x} + \mathbf{h}$ 的线段邻域内二次连续可微； $\mathbf{h} \in \mathbb{R}^d$ ，梯度为 $d \times 1$ 列向量，Hessian 为 $d \times d$ 矩阵。

推导第 1 步：化为单变量函数。 令 $\phi(t) = f(\mathbf{x} + t\mathbf{h})$ ， $t \in [0, 1]$ 。链式法则给出

$$\phi'(t) = \nabla f(\mathbf{x} + t\mathbf{h})^\top \mathbf{h},$$

右侧是 $1 \times d$ 与 $d \times 1$ 的乘积，因而为标量。

推导第 2 步：再求一次导数。 对 $\phi'(t)$ 应用链式法则，得到

$$\phi''(t) = \mathbf{h}^\top H_f(\mathbf{x} + t\mathbf{h}) \mathbf{h},$$

其中矩阵乘法维数依次为 $(1 \times d)(d \times d)(d \times 1)$ 。

推导第 3 步：应用一元 Taylor 公式。 在 $t = 0$ 处展开并取 $t = 1$ ，二阶连续性使余项为 $o(\|\mathbf{h}\|_2^2)$ ，于是

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \nabla f(\mathbf{x})^\top \mathbf{h} + \frac{1}{2} \mathbf{h}^\top H_f(\mathbf{x}) \mathbf{h} + o(\|\mathbf{h}\|_2^2).$$

读前自检：多元链式法则。 多元链式法则把问题限定在“若 $\mathbf{g}: \mathbb{R}^d \rightarrow \mathbb{R}^m$ 、 $f: \mathbb{R}^m \rightarrow \mathbb{R}$ 均可微”；请把 $\nabla h(\mathbf{x})$ 展开一次并检查其类型或边界，检查是否得到在列梯度约定下 $\nabla h(\mathbf{x}) = J_g(\mathbf{x})^\top \nabla f(g(\mathbf{x}))$ 。

读前自检：多元泰勒展开。 在“使用时必须声明展开点、增量和余项阶数”成立时处理多元泰勒展开：请把“使用时必须声明展开点、增量和余项阶数”中的已声明对象代回多元泰勒展开的定义，并以对象、条件与结论逐项闭合，且每项都可直接判为成立或失败判定结果。

读前自检：指数函数与对数函数的微分。 指数函数与对数函数的微分所用的明确前提是“ $d(\log u) = du/u$ 要求 $u > 0$ ”；完成检查 $d(e^u) = e^u du$ 中每项的类型后完成等式变形后，核对 $d(e^u) = e^u du$ 对所有实 u 成立。

3.4 多元链式法则

若 $g: \mathbb{R}^d \rightarrow \mathbb{R}^m, f: \mathbb{R}^m \rightarrow \mathbb{R}$ 均可微, $h = f \circ g$, 则在列梯度约定下 $\nabla h(\mathbf{x}) = J_g(\mathbf{x})^\top \nabla f(g(\mathbf{x}))$ 。泰勒展开用梯度给一阶项、Hessian 给二阶项；使用时必须声明展开点、增量和余项阶数。 $d(e^u) = e^u du$ 对所有实 u 成立； $d(\log u) = du/u$ 要求 $u > 0$ 。复合函数还要乘内部函数的微分。

3.5 标量对向量求导

标量函数 $f(\mathbf{x})$ 对列向量的导数采用列梯度。微分写成 $df = \nabla f(\mathbf{x})^\top d\mathbf{x}$, 右侧是 $1 \times d$ 与 $d \times 1$ 的乘积, 结果为标量。

微分法的操作顺序是：先把 df 写成关于 $d\mathbf{x}$ 的线性式, 再通过迹的循环性质或转置把它整理成 $\mathbf{g}^\top d\mathbf{x}$, 最后读出 $\nabla f = \mathbf{g}$ 。每次整理都要维持标量类型。

读前自检：线性函数的梯度。 线性函数 $f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x} + b$ 把 $\mathbf{x} \in \mathbb{R}^d$ 映为标量；请逐分量求偏导，核对 $\nabla f(\mathbf{x}) = \mathbf{a} \in \mathbb{R}^d$ 且与 $\mathbf{x}$ 无关。

读前自检：二次型的梯度。 二次型的梯度中的“分量推导出 $\nabla(\mathbf{x}^\top A \mathbf{x}) = (A + A^\top)\mathbf{x}$ ”决定可执行范围；请对 $\nabla(\mathbf{x}^\top A \mathbf{x})$ 完成一项求导、代入或边界比较，结果须满足 A 对称时化为 $2A\mathbf{x}$ 。

读前自检：对数函数的梯度。 把对数函数的梯度放在“对正分量向量”下考察：对 $f(\mathbf{x}) = \sum_{i=1}^d \log x_i$ 完成一项求导、代入或边界比较，并检查结果的形状、符号和取等条件与定义一致。

读前自检：Jacobian 矩阵。 Jacobian 矩阵要求先确认“对 $\mathbf{g}: \mathbb{R}^d \rightarrow \mathbb{R}^m$ ”；请随后标出 $\mathbf{g}(\mathbf{x})$ 两侧的 shape 并完成一次乘法或正交检查，用线性函数 $\mathbf{g}(\mathbf{x}) = A\mathbf{x} + \mathbf{b}$ 的 Jacobian 矩阵为 A 验收。

3.6 矩阵微分的分量解释与常用公式

若 $f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x} + b$, 则 $\partial f / \partial x_k = a_k$, 故 $\nabla f = \mathbf{a}$ 。分量推导出 $\nabla(\mathbf{x}^\top A \mathbf{x}) = (A + A^\top)\mathbf{x}$; A 对称时化为 $2A\mathbf{x}$ 。对正分量向量, $f(\mathbf{x}) = \sum_{i=1}^d \log x_i$ 有 $\nabla f = (1/x_1, \dots, 1/x_d)^\top$ 。对 $\mathbf{g}: \mathbb{R}^d \rightarrow \mathbb{R}^m$, $J_g \in \mathbb{R}^{m \times d}$ 的第 i 行是 $\mathbf{g}_i$ 梯度的转置；线性函数 $\mathbf{g}(\mathbf{x}) = A\mathbf{x} + \mathbf{b}$ 的 Jacobian 矩阵为 A 。常用公式还包括

$$d(A\mathbf{x}) = A d\mathbf{x}, \quad d(\mathbf{x}^\top A \mathbf{x}) = \mathbf{x}^\top (A + A^\top) d\mathbf{x},$$

以及 $\nabla_{\mathbf{x}} \frac{1}{2} \|\mathbf{Ax} - \mathbf{b}\|_2^2 = \mathbf{A}^T(\mathbf{Ax} - \mathbf{b})$ 。这些式子的首次依据分别是分量线性、乘法法则和链式法则，不是仅供记忆的表格。

本章共 19 道练习。每道题干后立即给出同号解析；长解析可自然跨页，续页标题保留题号。

练习 3.1 (偏导计算). 对 $f(x, y) = x^2y + 3y$ 求两个一阶偏导。

练习 3.1 解析

对象为 $f: \mathbb{R}^2 \rightarrow \mathbb{R}$ ，在整个 $\mathbb{R}^2$ 上可微。固定另一个变量逐项求导：

$$\begin{aligned}\frac{\partial f}{\partial x} &= \frac{\partial}{\partial x}(x^2y) + \frac{\partial}{\partial x}(3y) = 2xy + 0 = 2xy, \\ \frac{\partial f}{\partial y} &= \frac{\partial}{\partial y}(x^2y) + \frac{\partial}{\partial y}(3y) = x^2 + 3, \\ \nabla f(x, y) &= \begin{bmatrix} 2xy \\ x^2 + 3 \end{bmatrix} \in \mathbb{R}^2.\end{aligned}$$

因此两个偏导分别为 $2xy$ 与 $x^2 + 3$ ，梯度维数与二维输入一致。

练习 3.2 (定义域). 写出 $f(x, y) = \log(x - y)$ 的定义域，并求偏导。

练习 3.2 解析

实对数要求真数严格为正，故对象及定义域为 $f: D \rightarrow \mathbb{R}$ ，其中 $D = \{(x, y) \in \mathbb{R}^2 : x - y > 0\}$ 。在 D 内令 $u = x - y$ ，则

$$\begin{aligned}\frac{\partial f}{\partial x} &= \frac{1}{u} \frac{\partial u}{\partial x} = \frac{1}{x - y}, \\ \frac{\partial f}{\partial y} &= \frac{1}{u} \frac{\partial u}{\partial y} = -\frac{1}{x - y}, \\ \nabla f(x, y) &= \frac{1}{x - y} \begin{bmatrix} 1 \\ -1 \end{bmatrix}, \quad (x, y) \in D.\end{aligned}$$

边界 $x = y$ 使分母为零且对数无定义，不能纳入答案。

练习 3.3 (偏导存在与可微). 说明仅知道一个点处各偏导存在，为什么还不能断言函数在该点可微。

练习 3.3 解析

可微性的判据要求存在同一个线性映射控制所有二维增量。以下函数给出反例：

$$f(x, y) = \begin{cases} \frac{xy}{\sqrt{x^2 + y^2}}, & (x, y) \neq (0, 0), \\ 0, & (x, y) = (0, 0). \end{cases}$$

练习 3.3 解析 (续)

沿坐标轴与沿对角线分别计算得

$$\begin{aligned} f(h, 0) = f(0, h) = 0 &\implies f_x(0, 0) = f_y(0, 0) = 0, \\ f(t, t) &= \frac{t^2}{\sqrt{2t^2}} = \frac{|t|}{\sqrt{2}}, \\ \frac{|f(t, t) - f(0, 0) - \mathbf{0}^T(t, t)|}{\|(t, t)\|_2} &= \frac{1}{2} \not\rightarrow 0. \end{aligned}$$

所以两个偏导虽存在, 函数仍不可微; 邻域内一阶偏导连续是一项常用的充分条件。

练习 3.4 (梯度). 求 $f(x, y) = x^2 + xy + y^2$ 在 $(1, 2)$ 处的梯度。

练习 3.4 解析

对象为 $f: \mathbb{R}^2 \rightarrow \mathbb{R}$, 梯度按输入坐标次序组成列向量:

$$\begin{aligned} f_x(x, y) &= 2x + y, & f_y(x, y) &= x + 2y, \\ \nabla f(x, y) &= \begin{bmatrix} 2x + y \\ x + 2y \end{bmatrix}, & \nabla f(1, 2) &= \begin{bmatrix} 4 \\ 5 \end{bmatrix} \in \mathbb{R}^2. \end{aligned}$$

所以点 $(1, 2)$ 处的梯度为 $(4, 5)^T$ 。

练习 3.5 (方向导数). 沿单位方向 $(3, 4)^T/5$ 求上一题函数在 $(1, 2)$ 处的方向导数。

练习 3.5 解析

点为 $\mathbf{x}_0 = (1, 2)^T$, 方向 $\mathbf{u} = (3, 4)^T/5$ 必须先核对为单位向量:

$$\begin{aligned} \|\mathbf{u}\|_2 &= \frac{\sqrt{3^2 + 4^2}}{5} = 1, \\ \nabla f(\mathbf{x}_0) &= \begin{bmatrix} 4 \\ 5 \end{bmatrix}, \\ D_{\mathbf{u}}f(\mathbf{x}_0) &= \nabla f(\mathbf{x}_0)^T \mathbf{u} = 4 \frac{3}{5} + 5 \frac{4}{5} = \frac{32}{5}. \end{aligned}$$

因此沿给定单位方向的方向导数为 $32/5$ 。

练习 3.6 (最速下降方向). 若某点梯度为 $(6, -8)^T$, 求单位最速下降方向及最小方向导数。

练习 3.6 解析

设该点梯度 $\mathbf{g} = (6, -8)^\top \neq \mathbf{0}$ 。在约束 $\|\mathbf{u}\|_2 = 1$ 下, Cauchy-Schwarz 给出可达下界:

$$\begin{aligned}\|\mathbf{g}\|_2 &= \sqrt{6^2 + (-8)^2} = 10, \\ \mathbf{g}^\top \mathbf{u} &\geq -\|\mathbf{g}\|_2 = -10, \\ \mathbf{u}_\star &= -\frac{\mathbf{g}}{\|\mathbf{g}\|_2} = \begin{bmatrix} -3/5 \\ 4/5 \end{bmatrix}, \\ \mathbf{g}^\top \mathbf{u}_\star &= -10.\end{aligned}$$

因此 $\mathbf{u}_\star$ 是单位最速下降方向, 最小方向导数为 -10 。

练习 3.7 (Hessian). 求 $f(x, y) = x^2 + 4xy + 5y^2$ 的 Hessian 并判断正定性。

练习 3.7 解析

对象为二次函数 $f: \mathbb{R}^2 \rightarrow \mathbb{R}$, Hessian 在整个定义域恒定。逐次求导并用顺序主子式判断:

$$\begin{aligned}\nabla f(x, y) &= \begin{bmatrix} 2x + 4y \\ 4x + 10y \end{bmatrix}, \\ H_f &= \begin{bmatrix} 2 & 4 \\ 4 & 10 \end{bmatrix} = H_f^\top, \\ \Delta_1 &= 2 > 0, \quad \Delta_2 = \det(H_f) = 20 - 16 = 4 > 0.\end{aligned}$$

故 $H_f > 0$, 函数沿每个非零方向均有正曲率。

练习 3.8 (驻点分类). 分类 $f(x, y) = x^2 - y^2$ 在原点的驻点。

练习 3.8 解析

对象为 $f: \mathbb{R}^2 \rightarrow \mathbb{R}$, 原点是定义域内部点。先核对驻点, 再比较两条可行路径:

$$\begin{aligned}\nabla f(x, y) &= \begin{bmatrix} 2x \\ -2y \end{bmatrix}, & \nabla f(0, 0) &= \mathbf{0}, \\ H_f &= \text{diag}(2, -2), & \lambda(H_f) &= \{2, -2\}, \\ f(t, 0) - f(0, 0) &= t^2 > 0, & f(0, t) - f(0, 0) &= -t^2 < 0 \quad (t \neq 0).\end{aligned}$$

任意小邻域内同时出现更大与更小的函数值, 故原点为鞍点。

练习 3.9 (二阶近似). 用二阶泰勒式近似 e^x 在 $x = 0.1$ 处的值, 并写出所用展开点。

练习 3.9 解析

对象为 $f(x) = e^x$, 展开点明确取 $x_0 = 0$ 。二阶 Taylor 式及代入过程为

$$T_2(x; 0) = f(0) + f'(0)x + \frac{f''(0)}{2}x^2 = 1 + x + \frac{x^2}{2},$$

$$e^{0.1} \approx T_2(0.1; 0) = 1 + 0.1 + \frac{0.1^2}{2} = 1.105,$$

$$R_2(0.1) = \frac{e^\xi}{6}(0.1)^3, \quad \xi \in (0, 0.1).$$

最后一式说明近似误差来自三阶余项并给出其适用区间。

练习 3.10 (标量复合). 求 $h(x, y) = \exp(x^2 + y)$ 的梯度。

练习 3.10 解析

对象为 $h: \mathbb{R}^2 \rightarrow (0, \infty)$; 指数函数不增加定义域限制。令 $u(x, y) = x^2 + y$, 链式法则给出

$$\nabla u(x, y) = \begin{bmatrix} 2x \\ 1 \end{bmatrix},$$

$$\frac{d}{du} e^u = e^u,$$

$$\nabla h(x, y) = e^{u(x, y)} \nabla u(x, y) = e^{x^2 + y} \begin{bmatrix} 2x \\ 1 \end{bmatrix}.$$

所以链式法则给出的梯度为 $e^{x^2 + y}(2x, 1)^\top$ 。

练习 3.11 (对数复合). 求 $h(\mathbf{x}) = \log(1 + \mathbf{x}^\top \mathbf{x})$ 的梯度。

练习 3.11 解析

对象为 $h: \mathbb{R}^d \rightarrow \mathbb{R}$ 。内部量对所有 $\mathbf{x} \in \mathbb{R}^d$ 满足严格正的定义域条件:

$$u(\mathbf{x}) = 1 + \mathbf{x}^\top \mathbf{x} = 1 + \|\mathbf{x}\|_2^2 \geq 1 > 0,$$

$$\nabla u(\mathbf{x}) = 2\mathbf{x} \in \mathbb{R}^d,$$

$$\nabla h(\mathbf{x}) = \frac{1}{u(\mathbf{x})} \nabla u(\mathbf{x}) = \frac{2\mathbf{x}}{1 + \mathbf{x}^\top \mathbf{x}} \in \mathbb{R}^d.$$

因此该函数在整个 $\mathbb{R}^d$ 上有定义, 梯度为上述 d 维向量。

练习 3.12 (Jacobian 链式法则). 设 $\mathbf{g}(x, y) = (x + y, xy)^\top$, $f(u, v) = u^2 + v$, 求 $\nabla(f \circ \mathbf{g})$ 。

练习 3.12 解析

映射为 $g: \mathbb{R}^2 \rightarrow \mathbb{R}^2$ 、 $f: \mathbb{R}^2 \rightarrow \mathbb{R}$ ，故 $J_g \in \mathbb{R}^{2 \times 2}$ 且最终梯度属于 $\mathbb{R}^2$ 。计算

$$\begin{aligned} J_g(x, y) &= \begin{bmatrix} 1 & 1 \\ y & x \end{bmatrix}, & \nabla f(u, v) &= \begin{bmatrix} 2u \\ 1 \end{bmatrix}, \\ \nabla(f \circ g) &= J_g^\top \nabla f(g(x, y)) \\ &= \begin{bmatrix} 1 & y \\ 1 & x \end{bmatrix} \begin{bmatrix} 2(x+y) \\ 1 \end{bmatrix} = \begin{bmatrix} 2x+3y \\ 3x+2y \end{bmatrix}. \end{aligned}$$

直接展开 $(x+y)^2 + xy$ 求导得到同一结果。

练习 3.13 (线性函数微分). 用微分求 $f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x} + b$ 的梯度。

练习 3.13 解析

声明 $\mathbf{x}, \mathbf{a} \in \mathbb{R}^d$ 、 $b \in \mathbb{R}$ ，并在对 $\mathbf{x}$ 求导时固定参数 $\mathbf{a}, b$ 。由微分定义

$$\begin{aligned} df &= d(\mathbf{a}^\top \mathbf{x} + b) = \mathbf{a}^\top d\mathbf{x} + 0, \\ df &= (\nabla_{\mathbf{x}} f)^\top d\mathbf{x}, \\ \nabla_{\mathbf{x}} f &= \mathbf{a} \in \mathbb{R}^d. \end{aligned}$$

所以仿射函数对 $\mathbf{x}$ 的梯度恒为系数向量 $\mathbf{a}$ 。

练习 3.14 (平方损失). 求 $f(\mathbf{x}) = \frac{1}{2} \|\mathbf{A}\mathbf{x} - \mathbf{b}\|_2^2$ 的梯度。

练习 3.14 解析

声明 $\mathbf{A} \in \mathbb{R}^{m \times d}$ 、 $\mathbf{x} \in \mathbb{R}^d$ 、 $\mathbf{b} \in \mathbb{R}^m$ ，故残差 $\mathbf{r} = \mathbf{A}\mathbf{x} - \mathbf{b} \in \mathbb{R}^m$ 。微分链为

$$\begin{aligned} f &= \frac{1}{2} \mathbf{r}^\top \mathbf{r}, & d\mathbf{r} &= \mathbf{A} d\mathbf{x}, \\ df &= \mathbf{r}^\top d\mathbf{r} = \mathbf{r}^\top \mathbf{A} d\mathbf{x} \\ &= (\mathbf{A}^\top \mathbf{r})^\top d\mathbf{x}, \\ \nabla_{\mathbf{x}} f &= \mathbf{A}^\top (\mathbf{A}\mathbf{x} - \mathbf{b}) \in \mathbb{R}^d. \end{aligned}$$

因此最小二乘目标的梯度为 $\mathbf{A}^\top (\mathbf{A}\mathbf{x} - \mathbf{b})$ ，输出维数为 d 。

练习 3.15 (仿射对数). 对 $f(\mathbf{x}) = \log(\mathbf{a}^\top \mathbf{x} + c)$ 求梯度并写出定义域。

练习 3.15 解析

声明 $\mathbf{a}, \mathbf{x} \in \mathbb{R}^d$ 、 $c \in \mathbb{R}$ ，定义域为 $D = \{\mathbf{x} : \mathbf{a}^\top \mathbf{x} + c > 0\}$ ；若 D 为空则不存在可求导点。在 D 内

$$\begin{aligned} u &= \mathbf{a}^\top \mathbf{x} + c > 0, & du &= \mathbf{a}^\top d\mathbf{x}, \\ df &= \frac{du}{u} = \left(\frac{\mathbf{a}}{u}\right)^\top d\mathbf{x}, \\ \nabla f(\mathbf{x}) &= \frac{\mathbf{a}}{\mathbf{a}^\top \mathbf{x} + c} \in \mathbb{R}^d. \end{aligned}$$

边界 $u = 0$ 和负半空间均不在实对数定义域内。

练习 3.16 (非对称二次型). 令 $A = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}$ ，求 $\nabla(\mathbf{x}^\top A \mathbf{x})$ 并用展开式核对。

练习 3.16 解析

对象为 $A \in \mathbb{R}^{2 \times 2}$ 、 $\mathbf{x} = (x_1, x_2)^\top \in \mathbb{R}^2$ ； $A \neq A^\top$ ，不能使用仅适用于对称矩阵的 $2A\mathbf{x}$ 。两种合法推导为

$$\begin{aligned} \mathbf{x}^\top A \mathbf{x} &= \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} x_2 \\ 0 \end{bmatrix} = x_1 x_2, \\ \nabla(x_1 x_2) &= \begin{bmatrix} x_2 \\ x_1 \end{bmatrix}, \\ (A + A^\top)\mathbf{x} &= \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} x_2 \\ x_1 \end{bmatrix}. \end{aligned}$$

因此直接求导与一般公式 $(A + A^\top)\mathbf{x}$ 完全一致。

练习 3.17 (Jacobian 矩阵). 对 $\mathbf{g}(\mathbf{x}, \mathbf{y}) = (x^2 y, x + y^2)^\top$ 求 Jacobian 矩阵并写出维数。

练习 3.17 解析

映射 $\mathbf{g} : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ 有两个输出和两个输入，因此 $J_{\mathbf{g}} \in \mathbb{R}^{2 \times 2}$ 。按“输出分量为行、输入坐标为列”排列：

$$\begin{aligned} \nabla g_1(\mathbf{x}, \mathbf{y})^\top &= [2xy \quad x^2], \\ \nabla g_2(\mathbf{x}, \mathbf{y})^\top &= [1 \quad 2y], \\ J_{\mathbf{g}}(\mathbf{x}, \mathbf{y}) &= \begin{bmatrix} \partial g_1 / \partial x & \partial g_1 / \partial y \\ \partial g_2 / \partial x & \partial g_2 / \partial y \end{bmatrix} = \begin{bmatrix} 2xy & x^2 \\ 1 & 2y \end{bmatrix}. \end{aligned}$$

所以 $J_{\mathbf{g}}(\mathbf{x}, \mathbf{y})$ 为上述 2×2 矩阵，行对应输出分量、列对应输入坐标。

练习 3.18 (对数和梯度). 对 $f(\mathbf{x}) = -\sum_{i=1}^d \log x_i$ 求梯度和 Hessian，并判断 Hessian 正定性。

练习 3.18 解析

定义域是开凸集 $D = (0, \infty)^d$ ；只有在每个 $x_i > 0$ 时实对数和下列分母才有定义。逐分量计算

$$\begin{aligned}\nabla f(\mathbf{x}) &= [-1/x_1 \quad \cdots \quad -1/x_d]^\top, \\ H_f(\mathbf{x}) &= \text{diag}\left(\frac{1}{x_1^2}, \dots, \frac{1}{x_d^2}\right), \\ \mathbf{v}^\top H_f(\mathbf{x}) \mathbf{v} &= \sum_{i=1}^d \frac{v_i^2}{x_i^2} > 0 \quad (\mathbf{v} \neq \mathbf{0}, \mathbf{x} \in D).\end{aligned}$$

故 Hessian 在定义域内正定， f 在 D 上严格凸。

练习 3.19 (章末综合). 综合题：设 $F(\mathbf{x}) = \frac{1}{2}\|\mathbf{A}\mathbf{x} - \mathbf{b}\|_2^2 + \frac{\lambda}{2}\|\mathbf{x}\|_2^2$ ，其中 $\mathbf{A} \in \mathbb{R}^{m \times d}$ 、 $\mathbf{b} \in \mathbb{R}^m$ 、 $\lambda > 0$ 。求梯度和 Hessian，并说明驻点为何唯一。

练习 3.19 解析

对象与条件为 $\mathbf{A} \in \mathbb{R}^{m \times d}$ 、 $\mathbf{b} \in \mathbb{R}^m$ 、 $\mathbf{x} \in \mathbb{R}^d$ 、 $\lambda > 0$ ，定义域为整个 $\mathbb{R}^d$ 。微分与二阶导数给出

$$\begin{aligned}\nabla F(\mathbf{x}) &= \mathbf{A}^\top(\mathbf{A}\mathbf{x} - \mathbf{b}) + \lambda\mathbf{x} \\ &= (\mathbf{A}^\top\mathbf{A} + \lambda\mathbf{I}_d)\mathbf{x} - \mathbf{A}^\top\mathbf{b}, \\ H_F &= \mathbf{A}^\top\mathbf{A} + \lambda\mathbf{I}_d \in \mathbb{R}^{d \times d}, \\ \mathbf{v}^\top H_F \mathbf{v} &= \|\mathbf{A}\mathbf{v}\|_2^2 + \lambda\|\mathbf{v}\|_2^2 > 0 \quad (\mathbf{v} \neq \mathbf{0}).\end{aligned}$$

因此 H_F 正定且可逆，驻点不仅唯一而且确实存在：

$$\mathbf{x}^\star = (\mathbf{A}^\top\mathbf{A} + \lambda\mathbf{I}_d)^{-1}\mathbf{A}^\top\mathbf{b}.$$

严格凸性使该驻点成为唯一全局极小点。

读前自检：本章结论与下一步。 多元微积分与矩阵微分章末由“梯度、方向导数、Jacobian 与 Hessian”落到“声明开集与维数，按链式法则组合并用方向导数核对”；请把前者产出和后者输入逐项对齐，固定核对前者末项的输出类型能否作为后者首项的输入类型。

本章结论与下一步

核心结论： 梯度、方向导数、Jacobian 与 Hessian

关键依据： 沿直线积分和分量求导连接一阶、二阶局部模型

可执行自检： 声明开集与维数，按链式法则组合并用方向导数核对

适用边界： 目标函数求导、极值判断与优化更新之前

下一步： 进入第 4 章：概率论基础；本章工具将在第 7 章与第 8 章复用

1. 我能写出多元函数定义域并逐分量求偏导；未通过时回看节 3.1。
2. 我能由梯度计算方向导数，并解释最速方向；未通过时回看节 3.2。
3. 我能用 Hessian 与泰勒模型判断驻点，而不把必要条件当充分条件；未通过时回看节 3.3。
4. 我能按正确矩阵次序使用链式法则，并从分量推导二次型梯度；未通过时回看节 3.4—3.6。

第4章 概率论基础

读前自检：先修自检。 概率论先修自检给出 $A \cap B = \emptyset$ ；请把 $A \cup B$ 拆成两个不交事件，核对 $P(A \cup B) = P(A) + P(B)$ ，并据此判断该项是否通过。

本章地图

核心问题：不确定性怎样在条件化、边缘化和重复抽样中保持一致

可检验学习目标：

- 从样本空间和概率公理出发，严格建立条件概率、独立性与分布的语言；
- 能够逐行推出全概率公式、贝叶斯公式、方差分解与样本均值收敛的条件；
- 能够把联合分布转化为边缘量、条件量和可执行的概率推断流程。

最短先修：需要集合的并、交、补与划分，有限或可数求和，函数及其逆像，以及极限的基本概念。连续型部分还使用积分；向量随机变量的协方差矩阵需要内积与矩阵转置。

依赖路线：样本空间与事件 $\rightarrow$ 概率公理 $\rightarrow$ 条件概率 $\rightarrow$ 全概率与贝叶斯公式；随机变量 $\rightarrow$ 联合分布 $\rightarrow$ 边缘、条件与独立 $\rightarrow$ 期望、协方差和大数定律。

完成标准与返回：分母或支持条件不清楚时返回条件概率与联合分布节

本章符号表

符号	取值空间	含义
$\Omega, \mathcal{F}, P$	集合、事件族、 $[0, 1]$ 值函数	概率空间
A, B	$\mathcal{F}$	随机事件
X, Y	$\mathbb{R}$ 或有限集合	实值随机变量或有限集值随机元素
p_X, f_X, F_X	非负函数、 $[0, 1]$ 值函数	概率质量、密度、分布函数
$\mathbb{E}, \text{Var}, \text{Cov}$	标量或矩阵	期望、方差、协方差

4.1 样本空间、事件与概率

一次随机试验所有可能结果构成样本空间 Ω ；事件是可被判断是否发生的结果集合。统计学习中的“随机抽取一个训练样本”可把 Ω 取为特征与标签的所有可能配对，而事件 $\{Y = 1\}$ 表示标签为正类。

读前自检：概率空间。 概率空间 $(\Omega, \mathcal{F}, P)$ 要求 $\mathcal{F}$ 含 Ω 、对补集和可数并封闭；请对任意已声明的 $A \in \mathcal{F}$ 证明 $A^c \in \mathcal{F}$ ，再核对 $P(\Omega) = 1$ 与可列可加性。

定义 4.1 (概率空间). 设非空事件族 $\mathcal{F} \subseteq 2^\Omega$ 满足 $\Omega \in \mathcal{F}$ ，并且对补集与可数并封闭；这样的 $\mathcal{F}$ 称为 σ -代数。映射 $P: \mathcal{F} \rightarrow [0, 1]$ 满足 $P(\Omega) = 1$ ，且对两两不交事件 $A_1, A_2, \dots$ 有

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i),$$

则 $(\Omega, \mathcal{F}, P)$ 称为概率空间。

由公理可推出 $P(\emptyset) = 0$ 、 $P(A^c) = 1 - P(A)$ ，以及

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

这些式子依赖集合关系；不能在 A, B 有交叠时把两项概率机械相加。

例题 4.1 (骰子事件并集的两种核验). 掷一枚均匀六面骰子，令 $A = \{2, 4, 6\}$ 、 $B = \{4, 5, 6\}$ 。则 $P(A \cup B) = 3/6 + 3/6 - 2/6 = 2/3$ 。

例题 4.1 解答

读题翻译 在六个等可能骰面上求事件 $A \cup B$ 的概率，并用容斥公式与直接枚举两条路线相互核验。

已知与合法条件 样本空间 $\Omega = \{1, 2, 3, 4, 5, 6\}$ 中各结果等概率； A 与 B 有交叠，不能直接相加概率。

为什么想到这个方法 先显式求交集与并集，再用二事件容斥公式；最后直接数并集元素个数。

方法选择 计算 $A \cap B$ 和 $A \cup B$ ，代入 $P(A \cup B) = P(A) + P(B) - P(A \cap B)$ ，再以 $|A \cup B|/6$ 复算。

推导/计算 样本空间为 $\Omega = \{1, 2, 3, 4, 5, 6\}$ ，六个结果等概率。集合运算与概率链为

$$\begin{aligned} A \cap B &= \{4, 6\}, & A \cup B &= \{2, 4, 5, 6\}, \\ P(A \cup B) &= P(A) + P(B) - P(A \cap B) \\ &= \frac{3}{6} + \frac{3}{6} - \frac{2}{6} = \frac{4}{6} = \frac{2}{3}. \end{aligned}$$

独立核验 直接计数 $A \cup B = \{2, 4, 5, 6\}$ 得 $|A \cup B|/6 = 4/6 = 2/3$ ，与容斥结果一致，也确认交集 $\{4, 6\}$ 只扣除一次。

结论 $P(A \cup B) = 2/3$ 。

4.2 条件概率、全概率与贝叶斯公式

当 $P(B) > 0$ 时，已知 B 发生后的概率定义为

$$P(A | B) = \frac{P(A \cap B)}{P(B)}, \quad P(A \cap B) = P(A | B)P(B).$$

条件化把样本空间缩小到 B ，同时重新归一化概率质量。

读前自检：全概率公式。 先锁定全概率公式的条件“若 $B_1, \dots, B_m$ 两两不交、并为 Ω 且概率均为正”：把 $P(A) = \sum_{i=1}^m P(A | B_i)P(B_i)$ 在其支持上求和或积分一次，所得结果应满足各项非负且总和或积分满足归一化条件。

读前自检：贝叶斯公式。 贝叶斯公式以正概率事件 A 和划分 $B_1, \dots, B_m$ 为条件；请将 $P(A \cap B_j) = P(A | B_j)P(B_j)$ 代入条件概率，并核对分母 $\sum_i P(A | B_i)P(B_i)$ 完成归一化。

若 $B_1, \dots, B_m$ 两两不交、并为 Ω 且概率均为正，则

$$P(A) = \sum_{i=1}^m P(A | B_i)P(B_i).$$

对 $P(A) > 0$ ，后验概率为

$$P(B_j | A) = \frac{P(A | B_j)P(B_j)}{\sum_{i=1}^m P(A | B_i)P(B_i)}.$$

阅读目标：分清联合概率、证据概率与归一化后的后验概率。

对象：观察事件 A 与互斥完备划分 $B_1, \dots, B_m$ 。

合法条件： $P(B_i) > 0$ 且 $P(A) > 0$ ； $\{B_i\}$ 覆盖整个样本空间。

第一步：先用全概率公式写 $P(A) = \sum_i P(A | B_i)P(B_i)$ 。

推导目标

从事件划分推导贝叶斯公式，并明确分子与归一化分母各自的来源。

推导准备

准备条件： $B_1, \dots, B_m$ 构成划分， $P(B_i) > 0$ ，且观察事件 A 的概率为正。

推导第1步：由乘法公式， $P(A \cap B_j) = P(A | B_j)P(B_j)$ 。

推导第2步：因 $A = \bigcup_i (A \cap B_i)$ 且各项不交，可数可加性给出 $P(A) = \sum_i P(A \cap B_i)$ 。

推导第3步：把前两步代入 $P(B_j | A) = P(A \cap B_j)/P(A)$ ，得到贝叶斯公式。分母汇总所有能够产生观察 A 的互斥来源，因而使后验概率之和为 1。

模型。诊断模型由先验 $P(B_i)$ 与观测模型 $P(A | B_i)$ 构成；二者相乘得到未归一化后验。**策略。**先列出完备且互斥的原因，再计算每个原因生成证据的概率，最后统一归一化，可避免漏项和把 $P(A | B)$ 误当作 $P(B | A)$ 。

几何理解

几何解释。联合密度的等高线若由两个一维因子的乘积生成，其轴向变化可分别控制；但“等高线像矩形”只是一种直观，独立性的判据仍是整个支持集上的精确因子分解。

概率解释

条件独立表达“固定背景信息后，一个变量不再为另一个提供额外概率信息”。朴素贝叶斯正是把各特征在类别给定时视为条件独立，而不要求特征在总体上独立。

优化解释

优化解释。独立分解把联合对数似然转化为因子对数之和，使参数估计可分块计算；这是概率假设改变优化结构的典型例子，但分解错误会带来模型偏差。

读前自检：数学期望。 概率论基础中的数学期望把问题限定在“只要相应绝对期望有限，线性性不要求变量独立”；请把 $\mathbb{E}[g(X)] = \sum_x g(x)p_X(x)$ 按定义展开一层，检查是否得到展开结果为标量或声明形状且满足相应线性恒等式。

读前自检：方差。 在“ $\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}X)^2] = \mathbb{E}[X^2] - (\mathbb{E}X)^2$ 。”成立时处理概率论基础中的方差：请把 $\text{Var}(X)$ 展开一次并检查其类型或边界，并以展开后的量满足定义中的域、维数或符号限制判定结果。

读前自检：协方差与协方差矩阵。 协方差矩阵 $\Sigma = \mathbb{E}[(X - \mathbb{E}X)(X - \mathbb{E}X)^T]$ 针对 $X \in \mathbb{R}^d$ ；请核对 $\Sigma \in \mathbb{R}^{d \times d}$ 、对角元为方差，并对任意 a 验证 $a^T \Sigma a \geq 0$ 。

读前自检：条件期望。 围绕概率论基础中的条件期望，先采用条件“先在每个条件分布中平均，再对 Y 平均”，再把 $\mathbb{E}[\mathbb{E}[X | Y]]$ 按定义展开一层；最后验证展开结果为标量或声明形状且满足相应线性恒等式。

4.3 期望、方差、协方差与大数定律

期望是按概率加权的平均：离散情形 $\mathbb{E}[g(X)] = \sum_x g(x)p_X(x)$ ，连续情形把求和换成积分。只要相应绝对期望有限，线性性不要求变量独立。

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}X)^2] = \mathbb{E}[X^2] - (\mathbb{E}X)^2.$$

$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)]$ 。随机向量的协方差矩阵 $\Sigma = \mathbb{E}[(X - \mu)(X - \mu)^T]$ 对称半正定。 $\mathbb{E}[X | Y]$ 是 Y 的函数；先在每个条件分布中平均，再对 Y 平均，得到塔式法则 $\mathbb{E}\{\mathbb{E}[X | Y]\} = \mathbb{E}X$ 。若 $X_1, \dots, X_n$ 独立同分布且均值、方差有限，则 $\bar{X}_n = n^{-1} \sum_i X_i$ 满足 $\mathbb{E}\bar{X}_n = \mu$ 、 $\text{Var}(\bar{X}_n) = \sigma^2/n$ ，从而依概率收敛到 μ 。

读前自检：切比雪夫界下的样本均值收敛。 样本均值满足 $\mathbb{E}\bar{X}_n = \mu$ 、 $\text{Var}(\bar{X}_n) = \sigma^2/n$ ；请代入 Chebyshev 不等式，核对 $P(|\bar{X}_n - \mu| \geq \varepsilon) \leq \sigma^2/(n\varepsilon^2) \rightarrow 0$ 。

推论 4.1 (切比雪夫界下的样本均值收敛) 对任意 $\varepsilon > 0$,

$$P(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2} \rightarrow 0.$$

读前自检：证明：切比雪夫界下的样本均值收敛。 把切比雪夫界下的样本均值收敛放在“ $\text{Var}(\bar{X}_n) = n\sigma^2/n^2$ ”下考察：把 $\text{Var}(\bar{X}_n)$ 用到的关键定义展开并完成下一步变形，并检查当 n 增大时分母线性增大，故上界趋于零。

证明. 独立性使和的方差等于各方差之和，所以 $\text{Var}(\bar{X}_n) = n\sigma^2/n^2$ 。对 $\bar{X}_n$ 应用切比雪夫不等式即得上界；当 n 增大时分母线性增大，故上界趋于零。□

例题 4.2 (方差分解). 若 $Y \in \{0, 1\}$, $P(Y = 1) = 1/2$, 且 $X | Y = y$ 的均值为 $2y$ 、方差为 1, 求 $\text{Var}(X)$ 并解释两项来源。

例题 4.2 解答

读题翻译 把 X 的总方差分解为给定组内方差与条件均值造成的组间方差，并解释两项各自的贡献。

已知与合法条件 $Y \in \{0, 1\}$ 且 $P(Y = 1) = P(Y = 0) = 1/2$; $\mathbb{E}[X | Y] = 2Y$ 、 $\text{Var}(X | Y) = 1$ 。

为什么想到这个方法 应用全方差公式分别计算组内项和组间项，再用一、二阶矩直接复算总方差。

方法选择 求 $\mathbb{E}[\text{Var}(X | Y)]$ 与 $\text{Var}(\mathbb{E}[X | Y])$ 并相加；随后独立计算 $\mathbb{E}[X]$ 和 $\mathbb{E}[X^2]$ 。

推导/计算 对象满足 $P(Y = 0) = P(Y = 1) = 1/2$ 、 $\mathbb{E}[X | Y] = 2Y$ 及 $\text{Var}(X | Y) = 1$ 。全方差公式逐项给出

$$\begin{aligned}\mathbb{E}[\text{Var}(X | Y)] &= \mathbb{E}[1] = 1, \\ \text{Var}(\mathbb{E}[X | Y]) &= \text{Var}(2Y) = 4 \text{Var}(Y) \\ &= 4 \left(\frac{1}{2}\right) \left(1 - \frac{1}{2}\right) = 1, \\ \text{Var}(X) &= 1 + 1 = 2.\end{aligned}$$

第一项是组内变动，第二项是组间均值变动。

独立核验 独立地用 $\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2$ 核验：

$$\mathbb{E}[X] = \mathbb{E}[2Y] = 1, \quad \mathbb{E}[X^2] = \mathbb{E}[1 + (2Y)^2] = 3,$$

故 $\text{Var}(X) = 3 - 1^2 = 2$ ，与分解结果一致。

结论 $\text{Var}(X) = 2$ ；组内变动与组间均值变动各贡献 1。

读前自检：复杂度分析：期望、方差、协方差与大数定律。 期望、方差、协方差与大数定律要求先确认“预测复杂度：若用后验权重对 m 个假设的单样本预测作模型平均”；请随后由 m, u, v 的总成本剥离一次迭代或一次样本因子，用只求证据归一化常数可流式降为 $O(1)$ 额外空间，完整联合表为 $O(uv)$ 验收。

复杂度分析

复杂度假设。以下界假设 m, u, v 均为有限且状态可显式枚举，单个先验、似然或联合表项可在单位时间读取； C_{pred} 包含一个候选假设对单样本的完整预测成本。连续积分或隐式状态表示不适用这些枚举界。设 m 为有限假设数， u, v 为两个离散变量的状态数。**训练复杂度：**一次贝叶斯更新或边缘化为 $O(m)$ ；遍历完整联合表为 $O(uv)$ 。**预测复杂度：**若用后验权重对 m 个假设的单样本预测作模型平均，成本为 $O(mC_{\text{pred}})$ ，其中 C_{pred} 是一个假设的预测成本；只选择最大后验假设则扫描权重为 $O(m)$ 。**存储复杂度：**保存全部先验、似然和后验权重为 $O(m)$ ；只求证据归一化常数可流式降为 $O(1)$ 额外空间，完整联合表为 $O(uv)$ 。

适用条件与局限性

适用条件：上述有限求和适用于离散且状态可枚举的模型；连续变量需改用积分并检查密度可积性。**局限性：**大数定律结论依赖独立同分布和有限方差这一组充分条件，数据存在强依赖、分布漂移或重尾时，应重新核实相应收敛定理。概率模型能量化不确定性，但不能自动修正错误的样本空间或条件独立假设。

读前自检：常见错误与误用边界：期望、方差、协方差与大数定律。从期望、方差、协方差与大数定律的条件“边界框首项禁止把密度值当点概率”出发，请把固定错误“把密度值当点概率”中的对象、操作与结论按本节定义拆开，指出第一个不满足的定义条件，再把该处改为本节允许写法；所得量应符合改写后的运算或判断有定义，且不再触发“把密度值当点概率”。

常见错误

典型误用包括：把密度值当点概率；把 $P(A | B)$ 与 $P(B | A)$ 互换；未验证划分完备就使用全概率公式；由零协方差推断一般分布下的独立；对连续变量在条件概率分母中使用零概率单点而不引入条件密度。

易混淆概念对比

概念对比：互斥描述事件不能同时发生，独立描述一个事件发生不改变另一个事件的概率；两个正概率互斥事件不可能独立。边缘独立忽略背景变量，条件独立固定背景变量，两者回答的问题不同。概率质量是点概率，概率密度必须经过积分才能得到概率。

读前自检：有限假设空间上的贝叶斯更新：执行契约。有限假设空间上的贝叶斯更新输入“有限假设数 m 、先验向量 π 与事件似然向量 ℓ ”，条件“ $m \geq 1$ ， $\pi_i \geq 0$ 且和为 1， $0 \leq \ell_i \leq 1$ ，全部输入有限”；请执行“每个有限权重原子追加到合法前缀”，以“两次有限扫描完成或首次失败时停止”判停。

有限假设空间上的贝叶斯更新：五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 4.1：有限假设空间上的贝叶斯更新

输入：先验 $\pi_i = P(B_i)$ ，似然 $\ell_i = P(A | B_i)$ ， $i = 1, \dots, m$
输出：最后合法 w 前缀、 Z, q ； $h_{\text{done}}, n_{\text{done}}$ ；**status** 与诊断

- 1 若 m 、维数、有限性或概率约束非法，返回空后验、计数 0、**invalid_input** 及字段诊断
- 2 初始化 $Z \leftarrow 0, w \leftarrow 0, q \leftarrow \text{未定义}, h_{\text{done}} \leftarrow 0, n_{\text{done}} \leftarrow 0$ ；对 $i \leftarrow 1$ 至 m 执行
- 3 | 形成 $w_i^+ \leftarrow \pi_i \ell_i, Z^+ \leftarrow Z + w_i^+$ ；若候选非有限，返回旧前缀、**numerical_failure** 及 i 诊断
- 4 | 原子提交 $(w_i, Z) \leftarrow (w_i^+, Z^+)$ 并增加 h_{done}
- 5 结束
- 6 若 $Z = 0$ ，返回完整权重、未定义 q 、**invalid_input** 及零证据诊断
- 7 对 $i \leftarrow 1$ 至 m 执行
- 8 | 形成 $q_i^+ \leftarrow w_i / Z$ ；若非有限则返回未定义 q 、**numerical_failure** 及 i 诊断；否则增加 n_{done}
- 9 结束
- 10 若 q^+ 非负性或和为 1 的核验失败，返回未定义 q 、**numerical_failure** 及归一化诊断
- 11 原子提交 $q \leftarrow q^+$ ；返回完整结果、**completed** 及证据/归一化最终诊断

算法实现说明：首次阅读只做“权重—证据—归一化”三步；实现时检查零证据、概率约束、有限性与返回状态 完整 C1-C14 契约

终止与定义域说明。该过程只执行两次有限求和和一次归一化，不产生趋于极限的迭代序列，因此无需渐近收敛判据。若 $Z = 0$ ，则 $P(B_i | A)$ 因分母为零而未定义；若先验或似然不满足概率约束，则输入不属于算法声明的定义域。这两种情形都不是“迭代未收敛”。

例题 4.3 (医学筛查的基率效应). 患病率为 0.01，灵敏度为 0.95，假阳性率为 0.05。求一次阳性后的患病概率。

例题 4.3 解答

读题翻译 由患病率、灵敏度和假阳性率计算一次阳性后的患病后验，重点体现低基率对结果的影响。

已知与合法条件 $P(D) = 0.01$ 、 $P(+ | D) = 0.95$ 、 $P(+ | D^c) = 0.05$ ，且 D, D^c 构成互斥完备划分。

为什么想到这个方法 先用全概率公式求阳性证据概率，再归一化联合概率；最后用先验赔率乘似然比复核后验。

方法选择 计算 $P(+)$ 和 $P(D \cap +)$ ，由 Bayes 公式得到 $P(D | +)$ ，再用赔率形式独立核验。

推导/计算 令 D 表示患病、 $+$ 表示阳性。条件为 $P(D) = 0.01$ 、 $P(+ | D) = 0.95$ 、 $P(+ | D^c) = 0.05$ ，且证据概率严格为正。于是

$$\begin{aligned} P(+) &= 0.95 \times 0.01 + 0.05 \times 0.99 = 0.059, \\ P(D \cap +) &= 0.95 \times 0.01 = 0.0095, \\ P(D | +) &= \frac{P(D \cap +)}{P(+)} = \frac{0.0095}{0.059} \approx 0.161. \end{aligned}$$

独立核验 先验赔率为 $1 : 99$ ，阳性似然比为 $0.95/0.05 = 19$ ，故后验赔率为 $19 : 99$ ，对应 $19/(19 + 99) = 19/118$ ，与 Bayes 公式一致。

结论 $P(D | +) = 19/118 \approx 0.1610$ ，即约 16.1%；阳性不等于“有 95% 概率患病”，后验还受低基率影响。

4.4 随机变量与概率分布

更一般地，**随机元素**是从概率空间到可测空间 $(S, \mathcal{S})$ 的可测映射 $X : \Omega \rightarrow S$ ；当 $S = \mathbb{R}$ 时称为**实值随机变量**。本讲义遇到类别标签等有限集值对象时，为保持统计学习中的通行说法，有时简称“离散随机变量”，其严格含义是取值于带离散 σ 代数的有限集值随机元素。离散对象由概率质量函数 $p_X(x) = P(X = x)$ 描述；实值连续变量若具有密度，则以 $f_X(x)$ 描述区间概率。分布函数

$$F_X(t) = P(X \leq t)$$

单调不减、右连续，并满足两端极限为 0 和 1。若密度存在，则 $F_X(t) = \int_{-\infty}^t f_X(x) dx$ ；不能把连续变量的 $f_X(t)$ 当作点概率。

定理 4.1 (分布函数唯一确定分布) 若随机变量 X, Y 的分布函数在每个实数点相同，则二者具有相同分布。

扩展讨论 (严格测度论证明，主线可先使用定理结论)。

读前自检：证明：分布函数唯一确定分布。 分布函数相同给出 $\mu_X((-\infty, b]) = \mu_Y((-\infty, b])$ 对每个 b 成立；请核对左半直线族连同 $\emptyset, \mathbb{R}$ 构成 π 系统且生成 $\mathcal{B}(\mathbb{R})$ ，再用 π - λ 唯一性推出 $\mu_X = \mu_Y$ 。

证明. 令 μ_X, μ_Y 为 X, Y 在 $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ 上的分布测度。对每个 $b \in \mathbb{R}$,

$$\mu_X((-\infty, b]) = F_X(b) = F_Y(b) = \mu_Y((-\infty, b]).$$

取

$$\mathcal{P} = \{\emptyset, \mathbb{R}\} \cup \{(-\infty, b] : b \in \mathbb{R}\}.$$

它确为 π 系统：两个左半直线的交仍是以较小端点为界的左半直线，且与 $\emptyset, \mathbb{R}$ 作有限交仍留在 $\mathcal{P}$ 中。又有 $\sigma(\mathcal{P}) = \mathcal{B}(\mathbb{R})$ ，并且两概率测度在 $\mathcal{P}$ 上一致。由概率测度的 π - λ 唯一性定理， μ_X 与 μ_Y 在全部 Borel 集上一致，故 X, Y 同分布。□




图 4.1 离散随机变量的分布函数: 跳跃高度等于对应点的概率质量

可用图 4.1 做双向核对: 由各跳跃量恢复概率质量, 或把概率质量累加为分布函数; 右连续约定决定跳点取上端值, 而单调性与终值 1 是合法性检查。

读前自检: 联合分布。 先锁定概率论基础中的联合分布的条件“离散变量的联合质量 $p_{XY}(x, y) = P(X = x, Y = y)$ 完整描述成对结果”: 把 $p_{XY}(x, y) = P(X = x, Y = y)$ 在其支持上求和或积分一次, 所得结果应满足连续变量则用联合密度, 使矩形区域概率等于密度在区域上的二重积分。

读前自检: 边缘分布。 对概率论基础中的边缘分布, 条件“ $p_X(x) = \sum_y p_{XY}(x, y)$, $f_X(x) = \int f_{XY}(x, y) dy$.”不可省; 请把 $p_X(x)$ 在其支持上求和或积分一次, 再用各项非负且总和或积分满足归一化条件作检查。

4.5 联合、边缘与条件分布

离散变量的联合质量 $p_{XY}(x, y) = P(X = x, Y = y)$ 完整描述成对结果。连续变量则用联合密度, 使矩形区域概率等于密度在区域上的二重积分。消去不关心的变量得到边缘分布:

$$p_X(x) = \sum_y p_{XY}(x, y), \quad f_X(x) = \int f_{XY}(x, y) dy.$$

在 $p_Y(y) > 0$ 时, $p_{X|Y}(x | y) = p_{XY}(x, y)/p_Y(y)$ 。联合分布可按 $p_{XY} = p_{X|Y}p_Y$ 分解, 这正是概率图模型局部因子化的基础。

读前自检: 条件分布归一化。 条件分布归一化把问题限定在“对任意满足 $p_Y(y) > 0$ 的 y ”; 请把 $\sum_x p_{X|Y}(x | y) = 1$ 在其支持上求和或积分一次, 检查是否得到各项非负且总和或积分满足归一化条件。

引理 4.1 (条件分布归一化) 对任意满足 $p_Y(y) > 0$ 的 y , 有 $\sum_x p_{X|Y}(x | y) = 1$ 。

读前自检: 证明: 条件分布归一化。 条件分布归一化要求 $p_Y(y) > 0$; 请把 $p_{X|Y}(x | y) = p_{XY}(x, y)/p_Y(y)$ 对 x 求和, 用 $\sum_x p_{XY}(x, y) = p_Y(y)$ 约去分母并核对结果为 1。

证明. 把条件分布定义代入求和, 分子之和为 $\sum_x p_{XY}(x, y) = p_Y(y)$; 再除以同一个正数 $p_Y(y)$, 结果为 1。□

读前自检：随机变量的独立性。 随机变量的独立性所用的明确前提是“ X, Y 独立是指对所有适当集合 A, B ”；完成检查 $P(X \in A, Y \in B) = P(X \in A)P(Y \in B)$ 中每项的类型后完成等式变形后，核对在质量或密度存在时可检验联合分布是否处处分解为边缘乘积。

4.6 独立与条件独立

X, Y 独立是指对所有适当集合 A, B , $P(X \in A, Y \in B) = P(X \in A)P(Y \in B)$ 。在质量或密度存在时可检验联合分布是否处处分解为边缘乘积。给定 Z 后条件独立记为 $X \perp Y | Z$ 。当 Z 离散时，对每个满足 $p_Z(z) > 0$ 的取值，点条件质量函数应满足

$$p(x, y | z) = p(x | z)p(y | z)$$

(对所有 x, y)。以上离散版本足以支撑本书主线例题与练习。

扩展讨论（一般条件分布）。 设 X, Y, Z 取值于标准 Borel 空间，并取其正则条件分布； $X \perp Y | Z$ 是指对所有可测集 A, B ,

$$P_{(X,Y)|Z=z}(A \times B) = P_{X|Z=z}(A)P_{Y|Z=z}(B) \quad \text{对 } P_Z \text{ 几乎处处的 } z \text{ 成立。}$$

正则条件分布的版本只需在 P_Z 零测集之外一致，因此连续 Z 不能用 $P(Z = z) > 0$ 的点事件商式作为定义。

离散例。 令 $Z \sim \text{Bernoulli}(1/2)$ ；给定 $Z = z$ 后，独立生成 $X \sim \text{Bernoulli}(p_z)$ 与 $Y \sim \text{Bernoulli}(q_z)$ 。两个 z 都具有正概率，故可逐点用质量函数验证分解。**连续例。** 令 $Z \sim \text{Uniform}(0, 1)$ ，且 $\varepsilon_1, \varepsilon_2 \sim \mathcal{N}(0, 1)$ 彼此独立并与 Z 独立；取 $X = Z + \varepsilon_1$ 、 $Y = Z + \varepsilon_2$ 。给定 $Z = z$ 时，两者的正则条件分布为 $\mathcal{N}(z, 1)$ 的乘积分布，所以 $X \perp Y | Z$ ，尽管每个 $z \in [0, 1]$ 都满足 $P(Z = z) = 0$ 。边缘独立与条件独立互不蕴含；共同原因可能造成边缘相关，而条件化共同原因后相关消失。

本章共 18 道练习。每道题干后立即给出同号解析；长解析可自然跨页，续页标题保留题号。

练习 4.1. 设 $P(A) = 0.55, P(B) = 0.40, P(A \cap B) = 0.25$ ，求 $P(A \cup B)$ 、 $P(A^c \cap B)$ 。

练习 4.1 解析

对象 $A, B \in \mathcal{F}$ 是同一概率空间中的事件；未给独立性，只能使用并集公式和不交分解。于是

$$\begin{aligned} P(A \cup B) &= P(A) + P(B) - P(A \cap B) \\ &= 0.55 + 0.40 - 0.25 = 0.70, \\ B &= (A \cap B) \dot{\cup} (A^c \cap B), \\ P(A^c \cap B) &= P(B) - P(A \cap B) = 0.40 - 0.25 = 0.15. \end{aligned}$$

因此 $P(A \cup B) = 0.70$ ，且 $P(A^c \cap B) = 0.15$ 。

练习 4.2. 证明对任意事件 A, B 有 $P(A \cap B) \geq P(A) + P(B) - 1$ 。

练习 4.2 解析

对同一概率空间中的任意事件 $A, B \in \mathcal{F}$ ，概率上界与加法公式给出

$$\begin{aligned} P(A \cup B) &\leq P(\Omega) = 1, \\ P(A) + P(B) - P(A \cap B) &\leq 1, \\ P(A \cap B) &\geq P(A) + P(B) - 1. \end{aligned}$$

当 $A \cup B = \Omega$ 时第一步取等号，故该下界可以达到。

练习 4.3. 从一副 52 张标准扑克牌中均匀抽一张。求“是红牌或是 A”的概率，并说明重复计数发生在哪里。

练习 4.3 解析

样本空间含 52 张等可能的牌。令 R 为红牌事件、 E 为 A 事件，则 $|R| = 26$ 、 $|E| = 4$ 、 $|R \cap E| = 2$ 。容斥计算为

$$\begin{aligned} |R \cup E| &= |R| + |E| - |R \cap E| = 26 + 4 - 2 = 28, \\ P(R \cup E) &= \frac{|R \cup E|}{52} = \frac{28}{52} = \frac{7}{13}. \end{aligned}$$

重复计数发生在两张红色 A 上，它们同时属于 R 和 E 。

练习 4.4. 三台机器产量占比为 0.2, 0.3, 0.5，次品率为 0.01, 0.02, 0.04。随机抽到次品时，求其来自第三台机器的概率。

练习 4.4 解析

令 M_1, M_2, M_3 为互斥完备的机器来源， D 为次品。给定先验和条件次品率均合法，且下式证据概率为正：

$$\begin{aligned} P(D) &= \sum_{i=1}^3 P(D | M_i)P(M_i) \\ &= 0.01(0.2) + 0.02(0.3) + 0.04(0.5) = 0.028, \\ P(D \cap M_3) &= 0.04(0.5) = 0.020, \\ P(M_3 | D) &= \frac{0.020}{0.028} = \frac{5}{7}. \end{aligned}$$

所以抽到的次品来自第三台机器的后验概率为 $5/7$ 。

练习 4.5. 设 $P(A) > 0$ 、 $P(B_1) > 0$ 、 $P(B_2) > 0$ 且 $P(A \cap B_2) > 0$ 。证明后验比满足 $P(B_1 | A)/P(B_2 | A) = \{P(A | B_1)/P(A | B_2)\}\{P(B_1)/P(B_2)\}$ 。

练习 4.5 解析

对象是事件 A, B_1, B_2 ; 题设保证 $P(A) > 0$, 且 $P(A \cap B_2) > 0$ 进一步保证待除的 $P(A | B_2)$ 和 $P(B_2 | A)$ 均为正。贝叶斯公式与比值化简为

$$P(B_j | A) = \frac{P(A | B_j)P(B_j)}{P(A)}, \quad j = 1, 2,$$

$$\frac{P(B_1 | A)}{P(B_2 | A)} = \frac{P(A | B_1)P(B_1)}{P(A | B_2)P(B_2)}$$

$$= \frac{P(A | B_1) P(B_1)}{P(A | B_2) P(B_2)}.$$

若缺少上述正分母条件, 比值可能没有定义, 不能沿用该式。

练习 4.6. 若 $P(A | B) = 0.8, P(A | B^c) = 0.2, P(B) = 0.4$, 求 $P(B | A)$ 与 $P(B | A^c)$ 。

练习 4.6 解析

B, B^c 构成划分, 且 $P(B^c) = 0.6$ 。先对证据 A , 再对其补事件分别归一化:

$$P(A) = 0.8(0.4) + 0.2(0.6) = 0.44,$$

$$P(B | A) = \frac{0.8(0.4)}{0.44} = \frac{8}{11},$$

$$P(A^c) = 0.2(0.4) + 0.8(0.6) = 0.56,$$

$$P(B | A^c) = \frac{0.2(0.4)}{0.56} = \frac{1}{7}.$$

两个分母均严格为正, 故条件概率都有定义。

练习 4.7. 给定 $P(X = -1) = 0.2, P(X = 0) = 0.5, P(X = 2) = 0.3$, 写出 $F_X(t)$ 的分段形式并求 $P(-1 < X \leq 2)$ 。

练习 4.7 解析

离散随机变量的支持集为 $\{-1, 0, 2\}$, 三点质量和为 $0.2 + 0.5 + 0.3 = 1$ 。右连续分布函数为

$$F_X(t) = \begin{cases} 0, & t < -1, \\ 0.2, & -1 \leq t < 0, \\ 0.7, & 0 \leq t < 2, \\ 1, & t \geq 2. \end{cases}$$

区间端点按 $-1 < X \leq 2$ 处理:

$$P(-1 < X \leq 2) = P(X = 0) + P(X = 2) = 0.5 + 0.3 = 0.8.$$

因此所求区间概率为 0.8; 这也与 $F_X(2) - F_X(-1)$ 一致。

练习 4.8. 设 $f(x) = cx$ ($0 \leq x \leq 2$) 且区间外为 0。求 c 、分布函数及 $P(X > 1)$ 。

练习 4.8 解析

密度支持集是 $[0, 2]$ ；归一化且非负要求 $c \geq 0$ 并满足

$$1 = \int_{-\infty}^{\infty} f(x) dx = \int_0^2 cx dx = 2c \implies c = \frac{1}{2}.$$

因此

$$F_X(t) = \begin{cases} 0, & t < 0, \\ \int_0^t \frac{x}{2} dx = \frac{t^2}{4}, & 0 \leq t \leq 2, \\ 1, & t > 2, \end{cases} \quad P(X > 1) = 1 - F_X(1) = \frac{3}{4}.$$

所以归一化常数为 $1/2$ ，相应分布函数如上，且 $P(X > 1) = 3/4$ 。

练习 4.9. 设 $Y = 2X + 1$ ，已知 X 的分布函数为 F_X 。分别写出系数 2 为正与一般负系数 $a < 0$ 时 $aX + b$ 的分布函数。

练习 4.9 解析

令 $Y = aX + b$ ，其定义域由 X 给定。单调方向决定不等号是否反转。对 $a = 2 > 0$ ，

$$\begin{aligned} F_Y(y) &= P(2X + 1 \leq y) = P\left(X \leq \frac{y-1}{2}\right) \\ &= F_X\left(\frac{y-1}{2}\right). \end{aligned}$$

对一般 $a < 0$ ，令 $c = (y - b)/a$ ，则

$$\begin{aligned} F_{aX+b}(y) &= P(aX + b \leq y) = P(X \geq c) \\ &= 1 - P(X < c) = 1 - F_X(c^-). \end{aligned}$$

若 X 连续， $F_X(c^-) = F_X(c)$ ；一般情形必须保留左极限以计入阈值处点质量。

练习 4.10. 联合质量表为 $p(0,0) = 0.2, p(0,1) = 0.3, p(1,0) = 0.1, p(1,1) = 0.4$ 。求两边缘分布与 $P(X = 1 | Y = 1)$ 。

练习 4.10 解析

联合支持集为 $\{0,1\}^2$ ，四项质量非负且和为 1。沿另一个变量求和得到

$$\begin{aligned} p_X(0) &= 0.2 + 0.3 = 0.5, & p_X(1) &= 0.1 + 0.4 = 0.5, \\ p_Y(0) &= 0.2 + 0.1 = 0.3, & p_Y(1) &= 0.3 + 0.4 = 0.7, \\ P(X = 1 | Y = 1) &= \frac{p(1,1)}{p_Y(1)} = \frac{0.4}{0.7} = \frac{4}{7}. \end{aligned}$$

条件分母 $0.7 > 0$ ，所以后一步合法。

练习 4.11. 设联合密度 $f(x, y) = 2$ 定义在 $0 < y < x < 1$ 上, 其余为 0。求 $f_X(x)$ 、 $f_Y(y)$ 。

练习 4.11 解析

联合支持集为 $S = \{(x, y) : 0 < y < x < 1\}$; 其面积为 $1/2$, 故常数密度 2 已归一化。按切片确定积分边界:

$$f_X(x) = \int_0^x 2 \, dy = 2x, \quad 0 < x < 1,$$

$$f_Y(y) = \int_y^1 2 \, dx = 2(1 - y), \quad 0 < y < 1.$$

支持集外两者均为零, 并且

$$\int_0^1 2x \, dx = \int_0^1 2(1 - y) \, dy = 1.$$

因此边缘密度分别为 $f_X(x) = 2x$ 与 $f_Y(y) = 2(1 - y)$ ($0 < x, y < 1$), 且均已归一化。

练习 4.12. 对上题求 $f_{X|Y}(x | y)$, 并计算 $E[X | Y = y]$ 。

练习 4.12 解析

只对 $0 < y < 1$ 有 $f_Y(y) = 2(1 - y) > 0$, 因此普通条件密度在此条件值域内定义; 给定 y 后的支持为 $y < x < 1$ 。于是

$$f_{X|Y}(x | y) = \frac{f(x, y)}{f_Y(y)} = \frac{2}{2(1 - y)} = \frac{1}{1 - y}, \quad y < x < 1,$$

$$E[X | Y = y] = \int_y^1 x \frac{1}{1 - y} \, dx$$

$$= \frac{1 - y^2}{2(1 - y)} = \frac{1 + y}{2}.$$

条件支持之外密度为零; $y = 1$ 处边缘密度为零, 不能套用该比值。

练习 4.13. 用练习 4.10 的四格联合质量表判断 X, Y 是否独立, 并给出一个足以否定独立性的格子。

练习 4.13 解析

离散独立要求在整个支持集 $\{0, 1\}^2$ 上满足 $p(x, y) = p_X(x)p_Y(y)$ 。找一个失败格子即可否定:

$$p_X(0) = 0.2 + 0.3 = 0.5,$$

$$p_Y(0) = 0.2 + 0.1 = 0.3,$$

$$p_X(0)p_Y(0) = 0.5 \times 0.3 = 0.15 \neq 0.20 = p(0, 0).$$

故 X, Y 不独立。

练习 4.14. 设两次抛公平硬币的结果为 $X_1, X_2 \in \{0, 1\}$, 令 $S = X_1 + X_2$ 。说明 X_1, X_2 独立, 但给定 $S = 1$ 后不独立。

练习 4.14 解析

样本空间为 $\{0, 1\}^2$ 且四个序对等概率。未条件化时, 对任意 $i, j \in \{0, 1\}$,

$$P(X_1 = i, X_2 = j) = \frac{1}{4} = \frac{1}{2} \cdot \frac{1}{2} = P(X_1 = i)P(X_2 = j),$$

故 $X_1 \perp X_2$ 。事件 $S = 1$ 的条件支持仅含 $(0, 1), (1, 0)$, 于是

$$P(X_1 = 1 | S = 1) = P(X_2 = 1 | S = 1) = \frac{1}{2},$$

$$P(X_1 = 1, X_2 = 1 | S = 1) = 0 \neq \frac{1}{2} \cdot \frac{1}{2}.$$

故给定 $S = 1$ 后不独立。

练习 4.15. 设 $Z \sim \text{Bernoulli}(1/2)$, 给定 Z 后 X, Y 独立且都以概率 0.9 等于 Z 。解释为什么 X, Y 边缘上正相关。

练习 4.15 解析

对象 $X, Y, Z \in \{0, 1\}$; 题设给出 $X \perp Y | Z$ 。由对称性边缘化共同原因:

$$P(X = 1) = \frac{1}{2}(0.9) + \frac{1}{2}(0.1) = 0.5, \quad P(Y = 1) = 0.5,$$

$$P(X = 1, Y = 1) = \frac{1}{2}(0.9^2) + \frac{1}{2}(0.1^2) = 0.41,$$

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = 0.41 - 0.25 = 0.16 > 0.$$

共同原因被边缘化后产生正相关, 因此条件独立不推出边缘独立。

练习 4.16. 设 $\mathbb{E}[X] = 2, \mathbb{E}[Y] = -1, \text{Var}(X) = 4, \text{Var}(Y) = 9, \text{Cov}(X, Y) = 3$, 求 $\mathbb{E}[2X - Y]$ 与 $\text{Var}(2X - Y)$ 。

练习 4.16 解析

对象 X, Y 具有题设给出的有限二阶矩, 因此期望、方差与协方差展开均有定义。令 $a = 2, b = -1$, 则

$$\mathbb{E}[2X - Y] = 2\mathbb{E}[X] - \mathbb{E}[Y] = 2(2) - (-1) = 5,$$

$$\begin{aligned} \text{Var}(2X - Y) &= a^2 \text{Var}(X) + b^2 \text{Var}(Y) + 2ab \text{Cov}(X, Y) \\ &= 4(4) + 1(9) + 2(2)(-1)(3) = 16 + 9 - 12 = 13. \end{aligned}$$

所以 $\mathbb{E}[2X - Y] = 5, \text{Var}(2X - Y) = 13$ 。

练习 4.17. 证明协方差矩阵半正定, 并解释任意向量 $\mathbf{a}$ 下二次型的概率意义。

练习 4.17 解析

设随机向量 $\mathbf{X} \in \mathbb{R}^d$ 具有有限二阶矩, $\boldsymbol{\mu} = \mathbb{E}\mathbf{X}$, $\boldsymbol{\Sigma} = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top]$ 。对任意确定的 $\mathbf{a} \in \mathbb{R}^d$,

$$\begin{aligned}\mathbf{a}^\top \boldsymbol{\Sigma} \mathbf{a} &= \mathbb{E}[\mathbf{a}^\top (\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top \mathbf{a}] \\ &= \mathbb{E}[(\mathbf{a}^\top (\mathbf{X} - \boldsymbol{\mu}))^2] \\ &= \text{Var}(\mathbf{a}^\top \mathbf{X}) \geq 0.\end{aligned}$$

故 $\boldsymbol{\Sigma} \succeq 0$; 二次型正是随机向量沿 $\mathbf{a}$ 方向投影的方差。

练习 4.18. 独立同分布变量方差为 16。要使 $P(|\bar{X}_n - \mu| \geq 0.5) \leq 0.04$, 用切比雪夫界至少需要多大样本量?

练习 4.18 解析

对象 $X_1, \dots, X_n$ 独立同分布, 方差 $\sigma^2 = 16 < \infty$, 阈值 $\varepsilon = 0.5 > 0$ 。切比雪夫界给出

$$\begin{aligned}P(|\bar{X}_n - \mu| \geq 0.5) &\leq \frac{\text{Var}(\bar{X}_n)}{0.5^2} = \frac{16/n}{0.25} = \frac{64}{n}, \\ \frac{64}{n} \leq 0.04 &\iff n \geq \frac{64}{0.04} = 1600.\end{aligned}$$

样本量必须为正整数, 因此最小可取 $n = 1600$; 这是只使用二阶矩所得的保守保证。

本章结论与下一步

核心结论: 事件、随机变量、联合与条件分布

关键依据: 由划分和归一化推出全概率、贝叶斯与边缘化

可执行自检: 先声明支持与正分母, 再计算并检查归一化

适用边界: 概率建模、条件推断与经验平均的理论准备

下一步: 进入章 5、6 的统计推断与信息量

1. 能否先写出互斥完备的事件划分, 再推导而不是背诵贝叶斯公式?
2. 能否从联合表或联合密度正确确定边缘化的求和范围或积分限?
3. 能否分别给出独立、条件独立、互斥和零协方差的反例关系?
4. 能否把协方差矩阵二次型解释成一维投影方差, 并说明其非负性? 未通过第 1 项回看节 4.2, 未通过第 2 项回看节 4.5, 未通过第 3 项回看节 4.6, 未通过第 4 项回看节 4.3。

第5章 常用分布与统计推断

读前自检：先修自检。 常用分布与统计推断先修自检固定核验“能否说明概率质量函数对随机结果归一化，而似然函数把观测固定后比较参数”；请说明概率质量函数对随机结果归一化，而似然函数把观测固定后比较参数并写出中间结果，再按“中间结果直接回答首项“能否说明概率质量函数对随机结果归一化，而似然函数把观测固定后比较参数”并给出通过或失败”明确判为通过或失败。

本章地图

核心问题：样本怎样通过概率模型约束未知参数

可检验学习目标：

- 掌握离散计数分布、高斯分布、Gamma 分布与狄利克雷分布的参数和支持集；
- 从抽样模型完整推导极大似然、最大后验与共轭更新，不混淆概率和似然；
- 能够处理边缘似然、隐变量与指数族表示，并判断估计方法的适用条件。

最短先修：本章依赖第四章的条件概率、期望、方差与独立同分布抽样，还使用求和、积分、对数、偏导数和正定矩阵。多元高斯的二次型可回看第二章。

依赖路线：概率公理 → 常用分布 → 独立抽样 → 似然与极大似然；先验 + 似然 → 后验与 MAP → 共轭更新；联合模型 → 边缘似然 → 隐变量推断与指数族统一表示。

完成标准与返回：支持或参数化不清楚时返回分布定义与似然节

读前自检：本章符号表。 常用分布与统计推断符号表规定 $\theta, \Theta, x_{1:n}$ 的类型或范围；请把 θ, Θ 代入紧随其后的定义关系，逐项核对输入形状、输出形状与取值域。

本章符号表

符号	取值空间	含义
θ, Θ	参数、参数空间	未知但固定的模型参数及其可行集合
$x_{1:n}$	观测样本	$x_1, \dots, x_n$ 的简写
$L(\theta), \ell(\theta)$	非负函数、实函数	似然与对数似然
μ, σ^2, Σ	实数、正数、对称半正定矩阵	均值、方差和协方差；高斯密度式另要求 $\Sigma > 0$
$\mathbf{N}, \mathbf{n}$	$\mathbb{Z}_{\geq 0}^K$ 中的随机向量、实现值	K 类计数向量及其一次实现
n	正整数	多项分布的总试验数，满足 $\sum_{k=1}^K n_k = n$
$\alpha; \boldsymbol{\alpha}; \alpha_0$	正数； $\mathbb{R}_{>0}^K$ ；正数	标量形状参数；Dirichlet 参数向量；总浓度 $\alpha_0 = \sum_k \alpha_k$

读前自检：伯努利分布。 把伯努利分布放在“ $X \in \{0, 1\}$ 且 $P(X = x) = p^x(1-p)^{1-x}$ ”下考察：把 $P(X = x) = p^x(1-p)^{1-x}$ 在其支持上求和或积分一次，并检查其期望为 p ，方差为 $p(1-p)$ 。

5.1 伯努利、二项与多项分布

定义 5.1 (伯努利分布). $X \in \{0, 1\}$ 且 $P(X = x) = p^x(1-p)^{1-x}$, 其中 $0 \leq p \leq 1$. 其期望为 p , 方差为 $p(1-p)$.

若 $X_1, \dots, X_n$ 独立且同服从 $\text{Bernoulli}(p)$, 成功次数 $S = \sum_i X_i$ 的质量函数为

$$P(S = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, \dots, n.$$

把每次试验推广到 K 个类别, 记随机计数向量与其实现值分别为 $\mathbf{N} = (N_1, \dots, N_K)$ 和 $\mathbf{n} = (n_1, \dots, n_K)$; 标量 n 专指总试验数, 故 $\sum_{k=1}^K N_k = n$ 且可行实现满足 $\sum_{k=1}^K n_k = n$. 此时

$$P(\mathbf{N} = \mathbf{n}) = \frac{n!}{\prod_{k=1}^K n_k!} \prod_{k=1}^K p_k^{n_k}, \quad p_k \geq 0, \quad \sum_{k=1}^K p_k = 1.$$

定理 5.1 (二项分布的均值与方差) 若 $S \sim \text{Binomial}(n, p)$, 则 $\mathbb{E}S = np$, $\text{Var}(S) = np(1-p)$.

读前自检：证明：二项分布的均值与方差。 二项分布的均值与方差要求先确认 “ $\sum_i p(1-p) = np(1-p)$ ”; 请随后执行 $\sum_i p(1-p) = np(1-p)$ 中最内层的一次求和、积分或期望, 用独立性使协方差项为零, 故和的方差为 $\sum_i p(1-p) = np(1-p)$ 验收。

读前自检：一元高斯分布。 已知 $\sigma^2 > 0$. 请说明高斯密度为何非负, 并核对其在 $\mathbb{R}$ 上的积分为 1。

证明. 把 S 写成独立伯努利变量之和。期望线性性给出 $\sum_i p = np$; 独立性使协方差项为零, 故和的方差为 $\sum_i p(1-p) = np(1-p)$. $\square$

5.2 高斯分布与多元高斯分布

一元高斯密度为

$$f(x | \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right], \quad \sigma^2 > 0.$$

对 $x \in \mathbb{R}^d$, 当 $\Sigma \succ 0$ 时, 多元高斯是非退化分布, 并具有相对于 d 维 Lebesgue 测度的密度

$$f(x) = \frac{\exp[-\frac{1}{2}(x-\mu)^\top \Sigma^{-1}(x-\mu)]}{(2\pi)^{d/2} |\Sigma|^{1/2}}.$$

二次型给出马氏距离, 行列式控制等密度椭球的体积尺度。

扩展讨论：非退化密度与退化高斯测度

若只要求 $\Sigma \geq 0$ ，仍可通过 $X = \mu + LZ$ 、 $LL^T = \Sigma$ 定义高斯测度；当 $\text{rank}(\Sigma) < d$ 时，它集中在低维仿射子空间 $\mu + \text{col}(L)$ 上，相对于 d 维 Lebesgue 测度没有密度，因而不能把 $|\Sigma| = 0$ 或不存在的 Σ^{-1} 代入上式。

一个秩亏二维反例是：令 $Z \sim \mathcal{N}(0, 1)$ 并取 $X = (Z, Z)^T$ ，则

$$\Sigma = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \geq 0, \quad \text{rank}(\Sigma) = 1.$$

这是一个退化二维高斯向量，其全部质量集中在直线 $x_1 = x_2$ 上；它是高斯测度，却不是可由上述二维密度公式表示的非退化高斯密度。

引理 5.1 (标准化) 若 $X \sim \mathcal{N}(\mu, \sigma^2)$ ，则 $Z = (X - \mu)/\sigma \sim \mathcal{N}(0, 1)$ 。

读前自检：证明：标准化。 常用分布与统计推断中的标准化依赖“把原密度与雅可比相乘后， σ 与归一化常数中的 $1/\sigma$ 抵消”；请据此把 $x = \mu + \sigma z$ 用到的关键定义展开并完成下一步变形，并直接核对得到标准高斯密度。

证明。 使用变量代换 $x = \mu + \sigma z$ ，雅可比绝对值为 σ 。把原密度与雅可比相乘后， σ 与归一化常数中的 $1/\sigma$ 抵消，指数项化为 $-z^2/2$ ，因此得到标准高斯密度。□




图 5.1 方差增大使高斯密度变宽、峰值降低，但曲线下面积保持为 1

比较图 5.1 中的曲线时要同时检查位置、尺度和面积：改变 μ 只平移中心，改变 σ 会展宽并降低峰值；若只横向拉伸而不调整 $1/(\sqrt{2\pi}\sigma)$ ，所得曲线便不再是概率密度。

5.3 Gamma 与狄利克雷分布

Gamma 函数定义为 $\Gamma(a) = \int_0^\infty t^{a-1} e^{-t} dt$ ($a > 0$)，分部积分给出 $\Gamma(a+1) = a\Gamma(a)$ 。采用形状-速率参数化时，

$$f(x | a, b) = \frac{b^a}{\Gamma(a)} x^{a-1} e^{-bx}, \quad x > 0,$$

其均值为 a/b ，方差为 a/b^2 。狄利克雷分布定义在概率单纯形上，后续作为多项分布的共轭先验。

读前自检：Gamma 递推。 Gamma 递推以“特别地，正整数 n 满足 $\Gamma(n) = (n-1)!$ ”为约束；请独立化简 $\Gamma(a+1) = a\Gamma(a)$ 的两端，并确认两端运算均有定义、类型一致且化为同一结果。

引理 5.2 (Gamma 递推) 对 $a > 0$, $\Gamma(a+1) = a\Gamma(a)$; 特别地，正整数 n 满足 $\Gamma(n) = (n-1)!$ 。

证明。 对 $\int_0^\infty t^a e^{-t} dt$ 分部积分，取 $u = t^a$ 、 $dv = e^{-t} dt$ 。边界项在零与无穷处均为零，剩余积分为 $a \int_0^\infty t^{a-1} e^{-t} dt$ 。再从 $\Gamma(1) = 1$ 递推到整数即可。□

5.4 总体、样本、参数与统计量

总体分布 P_θ 是数据生成机制， θ 是描述该机制的未知参数；样本 $X_{1:n}$ 是从总体抽取的随机变量组，观察后得到固定数值 $x_{1:n}$ 。统计量 $T(X_{1:n})$ 只能依赖样本，不能依赖未知参数。估计量是用于估计参数的统计量，其抽样分布描述重复抽样时的波动。

读前自检：似然函数。 似然函数在观测 $x_{1:n}$ 固定后把 θ 视为变量；请在条件独立假设下写出 $L(\theta; x_{1:n}) = \prod_{i=1}^n p(x_i | \theta)$ ，并核对它无需对 θ 积分为 1 但必须尊重参数域。

读前自检：对数似然。 对常用分布与统计推断中的对数似然，条件“严格单调的对数把乘积化为和： $\ell(\theta) = \sum_i \log p(x_i | \theta)$ ”不可省；请把观测对应因子代入 $\ell(\theta) = \sum_i \log p(x_i | \theta)$ 并合并一次，再用所得目标保留参数定义域且无需对参数归一化作检查。

5.5 似然、对数似然与极大似然

给定观测 $x_{1:n}$ 后， $L(\theta; x) = p(x_{1:n} | \theta)$ 被视为参数 θ 的函数。独立抽样时它是单点概率或密度的乘积。严格单调的对数把乘积化为和： $\ell(\theta) = \sum_i \log p(x_i | \theta)$ ，且不改变最大点。

$$\hat{\theta}_{\text{MLE}} \in \arg \max_{\theta \in \Theta} \ell(\theta).$$

模型。 伯努利抽样模型假定给定 p 后样本条件独立，数据只通过成功次数进入似然。**学习策略。** 选择使已观测数据密度最大的可行参数，并用边界、二阶条件或凸性核实该驻点是否为全局最大点。

阅读目标： 同时处理内部驻点与全为 0、全为 1 的边界样本。

对象： 独立样本 $x_i \in \{0, 1\}$ 、成功次数 $s = \sum_i x_i$ 与参数 $\theta \in [0, 1]$ 。

合法条件： 参数空间是闭区间；当 $s = 0$ 或 $s = n$ 时不能只依赖内部一阶条件。

第一步： 先写对数似然 $\ell(\theta) = s \log \theta + (n-s) \log(1-\theta)$ 。

推导目标

推导伯努利参数的极大似然估计，并说明边界样本的处理。

推导准备

数据 $x_i \in \{0, 1\}$ 独立同分布，令 $s = \sum_i x_i$ ，参数空间为闭区间 $[0, 1]$ 。

推导第1步：写出 $L(p) = p^s(1-p)^{n-s}$, 在 $0 < p < 1$ 上有 $\ell(p) = s \log p + (n-s) \log(1-p)$ 。

推导第2步：求导得到 $\ell'(p) = s/p - (n-s)/(1-p)$, 令其为零并通分, 得到 $s(1-p) = (n-s)p$ 。

推导第3步：解得 $\hat{p} = s/n = \bar{x}$ 。当 $0 < s < n$ 时二阶导数为负; 当 $s = 0$ 或 $s = n$ 时, 比较闭区间边界分别得到 0 或 1, 仍与 s/n 一致。

读前自检: Corollary: 伯努利样本中, 样本均值同时是成功概率 p 的极大似然估计与无偏估计。伯努利样本令 $s = \sum_i x_i$; 请对 $\ell(p) = s \log p + (n-s) \log(1-p)$ 求导并解驻点, 核对 $\hat{p} = s/n = \bar{x}$ 且 $\mathbb{E}[\bar{X}] = p$ 。

推论 5.1 伯努利样本中, 样本均值同时是成功概率 p 的极大似然估计与无偏估计。

例题 5.1 (十次伯努利试验的极大似然). 观察到 10 次试验中 7 次成功。求伯努利成功概率的 MLE, 并比较候选参数 0.5 与 0.7 的对数似然。

例题 5.1 解答

读题翻译 由十次伯努利试验中的七次成功估计成功概率, 并比较 $p = 0.7$ 与 $p = 0.5$ 的对数似然。

已知与合法条件 成功数 $s = 7$ 、失败数 $n - s = 3$ 且 $0 < s < n = 10$; 参数域为 $p \in [0, 1]$, 内部对数似然可微。

为什么想到这个方法 写出二项对数似然并解得分方程, 以严格凹性和端点行为认证极大值, 再直接比较两个候选。

方法选择 在 $(0, 1)$ 上求解 $\ell'(p) = 0$, 用 $\ell''(p) < 0$ 及边界似然排除其他极大点, 并计算 $\ell(0.7) - \ell(0.5)$ 。

推导/计算 参数域为 $p \in [0, 1]$, 成功数 $s = 7$ 满足 $0 < s < n = 10$, 故极大点位于内部。省略与 p 无关的组合常数,

$$\begin{aligned}\ell(p) &= 7 \log p + 3 \log(1-p), \\ \ell'(p) &= \frac{7}{p} - \frac{3}{1-p} = 0 \iff 7(1-p) = 3p \iff \hat{p} = 0.7, \\ \ell''(p) &= -\frac{7}{p^2} - \frac{3}{(1-p)^2} < 0, \\ \ell(0.7) - \ell(0.5) &= 7 \log \frac{0.7}{0.5} + 3 \log \frac{0.3}{0.5} > 0.\end{aligned}$$

独立核验 严格凹性使内部驻点唯一; 成功与失败次数均为正, 故 $p = 0, 1$ 处似然为 0 而 $p = 0.7$ 处为正。另有 $\ell(0.7) - \ell(0.5) \approx 0.82283 > 0$ 。

结论 唯一的极大似然估计为 $\hat{p} = 0.7 = 7/10$; 候选 0.7 的对数似然比 0.5 大约 0.82283。

读前自检: 先验、似然与后验。 在“贝叶斯公式写成 $p(\theta | x) \propto p(x | \theta)p(\theta)$ ”成立时处理先验、似然与后验: 请把观测对应因子代入 $p(\theta | x) \propto p(x | \theta)p(\theta)$ 并合并一次, 并以先验表达观测数据之前的不确定性, 后验同时吸收先验与样本信息判定结果。

读前自检：最大后验估计。 最大后验估计在先验 $p(\theta) > 0$ 的参数域上最大化 $\log p(x | \theta) + \log p(\theta)$ ；请对一个候选代入两项，核对均匀先验时排序退化为极大似然。

读前自检：共轭先验。 围绕常用分布与统计推断中的共轭先验，先采用条件“若先验与后验属于同一分布族”，再把“若先验与后验属于同一分布族”中的已声明对象代回常用分布与统计推断中的共轭先验的定义；最后验证共轭性使更新只需改变有限维超参数。

5.6 先验、后验、共轭与最大后验

贝叶斯公式写成 $p(\theta | x) \propto p(x | \theta)p(\theta)$ 。先验表达观测数据之前的不确定性，后验同时吸收先验与样本信息。 $\hat{\theta}_{\text{MAP}} \in \arg \max_{\theta} \{\log p(x | \theta) + \log p(\theta)\}$ ，可视为带先验正则项的优化。若先验与后验属于同一分布族，则称先验对该似然共轭。共轭性使更新只需改变有限维超参数。令

$$\Delta_{K-1}^{\alpha} = \{p \in (0, 1)^K : \sum_{k=1}^K p_k = 1\}, \quad \alpha_k > 0, \quad \alpha_0 = \sum_{k=1}^K \alpha_k.$$

相对于坐标 $(p_1, \dots, p_{K-1})$ 上的 $(K-1)$ 维 Lebesgue 参考测度，狄利克雷分布在单纯形相对内部的密度为

$$f(p | \alpha) = \frac{\Gamma(\alpha_0)}{\prod_{k=1}^K \Gamma(\alpha_k)} \prod_{k=1}^K p_k^{\alpha_k-1}, \quad p_K = 1 - \sum_{k=1}^{K-1} p_k.$$

它不是相对于 $\mathbb{R}^K$ 中 K 维 Lebesgue 测度的密度。靠近面 $p_k = 0$ 时， $\alpha_k < 1$ 、 $= 1$ 、 > 1 分别对应密度沿该坐标趋于无穷、保持有限非零因子、趋于零；边界本身的参考测度为零，密度极限不等于边界上的点概率。该分布是多项分布参数的共轭先验，完整构造见章 34。

几何理解

几何解释。 指数族的自然参数位于凸参数域，对数配分函数的 Hessian 半正定；因此自然参数到期望参数的映射由凸函数梯度给出。高斯等密度面则是马氏距离相同的椭球。

概率解释

边缘似然把每个参数值对数据的解释能力按先验加权，自动体现“拟合好但只在狭小参数区域有效”的模型会受到体积惩罚。隐变量模型则先描述完整数据，再对未观察部分求和。

优化解释

优化解释。 MLE 优化数据项，MAP 在其上加对数先验；隐变量似然的对数套求和造成变量耦合，后续 EM 算法通过下界与交替优化处理。共轭模型把函数优化简化为超参数加法更新。

读前自检：复杂度分析：先验、后验、共轭与最大后验。 先验、后验、共轭与最大后验中的“类别标签若以整数索引给出”决定可执行范围；请由 K 的总成本剥离一次迭代或一次样本因子，结果须满足预测复杂度：输出一个 K 类后验预测分布需 $O(K)$ 。

复杂度分析

复杂度假设。类别标签若以整数索引给出，则一次计数更新为单位成本；若以 K 维稠密向量给出，则必须读取全部 K 个分量。高斯界假设使用稠密完整协方差并采用 Cholesky 分解；稀疏、对角或低秩协方差应按相应数据结构重新计数。设 n 为样本数、 K 为类别数、 d 为连续变量维数。**训练复杂度：**Dirichlet-多项更新在类别标签稀疏表示下累计计数为 $O(n+K)$ ，若每条样本以 K 维稠密向量给出则为 $O(nK)$ ；完整协方差高斯的 Cholesky 分解为 $O(d^3)$ 。**预测复杂度：**输出一个 K 类后验预测分布需 $O(K)$ ；已分解的高斯对一个样本计算密度通常需 $O(d^2)$ 。**存储复杂度：**类别计数与参数为 $O(K)$ ，完整协方差及其分解为 $O(d^2)$ 。应复用分解而不是反复求逆。

适用条件与局限性

适用条件：MLE 适合抽样模型可信且样本量足以识别参数的情形；MAP 适合存在可辩护先验或正则化需求的情形；共轭更新适合需要快速顺序推断的标准模型。**局限性：**高斯对重尾和离群点敏感，MAP 忽略后验宽度，边缘似然依赖先验尺度，隐变量模型还可能不存在不可辨识与多个局部最优。

常见错误

典型误用包括：把似然当作关于参数的归一化概率；忘记参数决定支持集；混用 Gamma 的速率与尺度参数化；把协方差矩阵的行列式写成负数或零却仍使用密度公式；只解一阶方程而不检查边界与最大性；把 MAP 点估计当作完整贝叶斯预测。

易混淆概念对比

概念对比：概率固定参数后衡量可能数据，似然固定数据后比较参数；MLE 只使用似然，MAP 再加入先验众数偏好，后验均值则平均全部参数不确定性。边缘似然积分掉参数，剖面似然最大化掉干扰参数，两种消元方式不同。参数是总体机制的未知量，统计量是样本的已知函数。

读前自检：狄利克雷 – 多项分布的顺序共轭更新：执行契约。 狄利克雷 – 多项分布的顺序共轭更新输入“类别数 K 、严格正 Dirichlet 先验 α 与有限类别观测流 $y_{1:n}$ ”，条件“ $K \geq 1$, $n \in \mathbb{N}_0$, $\alpha_k > 0$ 且有限，每个 $y_i \in \{1, \dots, K\}$ ”；请执行“每次有限正参数加一后原子提交 $\hat{\alpha}$ ”，以“恰好处理 n 个观测并归一化 K 项，或首次失败时停止”判停。

狄利克雷 – 多项分布的顺序共轭更新：五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 5.1: 狄利克雷 – 多项分布的顺序共轭更新**输入:** 先验参数向量 $\alpha = (\alpha_1, \dots, \alpha_K)^T \in \mathbb{R}_{>0}^K$; 类别观测流 $y_1, \dots, y_n$ **输出:** 最后合法 $\hat{\alpha}, \hat{p}$; $i_{\text{done}}, p_{\text{done}}$; **status** 与诊断

- 1 若 K, n 、维数、先验有限正性或任一类别编码非法, 返回空结果、计数 0、**invalid_input** 及位置诊断
- 2 初始化 $\hat{\alpha} \leftarrow \alpha, i_{\text{done}} \leftarrow 0, p_{\text{done}} \leftarrow 0$
- 3 对 $i \leftarrow 1$ 至 n 执行
 - 4 复制 $\alpha^+ \leftarrow \hat{\alpha}$ 并令 $\alpha_{y_i}^+ \leftarrow \alpha_{y_i}^+ + 1$; 若非有限则返回 $\hat{\alpha}$ 、**numerical_failure** 及 i 诊断
 - 5 原子提交 $\hat{\alpha} \leftarrow \alpha^+$ 并增加 i_{done}
- 6 结束
- 7 计算 $\hat{\alpha}_0 \leftarrow \sum_k \hat{\alpha}_k$; 若 $\hat{\alpha}_0$ 非有限或不正, 返回 $\hat{\alpha}$ 、**numerical_failure** 及总浓度诊断
- 8 对 $k \leftarrow 1$ 至 K 执行
 - 9 形成 $p_k^+ \leftarrow \hat{\alpha}_k / \hat{\alpha}_0$; 若非有限则返回 $\hat{\alpha}$ 、**numerical_failure** 及 k 诊断; 否则增加 p_{done}
- 10 结束
- 11 若 p^+ 非负性或和为 1 核验失败, 返回最后合法 $\hat{\alpha}$ 、**numerical_failure** 及概率和诊断
- 12 原子提交 $\hat{p} \leftarrow p^+$; 返回完整结果、**completed** 及总浓度/零观测最终诊断

算法实现说明: 首次阅读只跟踪 $\hat{\alpha} = \alpha + n$ 与按 $\hat{\alpha}_0$ 归一化; 实现时再检查类别编码、有限性和状态 完整 C1–C14 契约

终止与定义域说明。 顺序共轭更新对每个观测恰执行一次计数加法, n 有限时必在有限步终止; 它不是数值迭代, 因此无需渐近收敛判据。参数非正或类别编码越界时, 相应概率模型未定义, 必须停止而不能继续归一化。

读前自检: 边缘似然。 常用分布与统计推断中的边缘似然要求先确认“边缘似然又称模型证据: $p(x) = \int p(x | \theta) p(\theta) d\theta$ ”; 请随后把观测对应因子代入 $p(x)$ 并合并一次, 用它平均参数不确定性, 而不是把参数替换为一个点估计验收。

读前自检: 隐变量与不完全数据。 联合模型 $p(x, z | \theta)$ 中 z 未观测; 请对 z 求和得到 $p(x | \theta) = \sum_z p(x, z | \theta)$, 再核对观测对数似然为 $\log \sum_z p(x, z | \theta)$ 而不是 $\sum_z \log p(x, z | \theta)$ 。

读前自检: 指数族分布。 指数族分布依赖“并假设存在 η 的开邻域 N 及可积函数 g_1, g_2 ”; 请据此把 $\frac{\partial^2 A}{\partial \eta_i \partial \eta_j}$ 在其支持上求和或积分一次, 并直接核对对期望的第 i 个分量关于 η_j 求导。

5.7 边缘似然、隐变量与指数族

边缘似然又称模型证据: $p(x) = \int p(x | \theta) p(\theta) d\theta$ 。它平均参数不确定性, 而不是把参数替换为一个点估计。若联合模型为 $p(x, z | \theta)$ 而 z 未观测, 则观测似然是 $p(x | \theta) = \sum_z p(x, z | \theta)$ 或相应积分。隐变量的边缘化常使对数似然出现“对数套求和”。指数族统一写作

$$p(x | \eta) = h(x) \exp\{\eta^T T(x) - A(\eta)\},$$

其中 $T(x)$ 是充分统计量, $A(\eta)$ 是对数配分函数。

阅读目标：由对数配分函数导数得到充分统计量的均值、协方差与凸性。

对象： $A(\eta) = \log Z(\eta)$ 、充分统计量 $T(X)$ 与自然参数 η 。

合法条件： $\eta \in \text{int } \mathcal{H}$ ；支配条件允许两次交换求导与积分。

第一步：先对 $Z(\eta) = \int h(x)e^{\eta^\top T(x)} dx$ 逐分量求导。

推导目标

推导 $\nabla A(\eta)$ 与 $\nabla^2 A(\eta)$ ，解释自然参数、期望参数和凸性之间的关系。

推导准备

设自然参数空间 $\mathcal{H} = \{\eta : Z(\eta) < \infty\}$ ，取 $\eta \in \text{int } \mathcal{H}$ ， $A(\eta) = \log Z(\eta)$ 。并假设存在 η 的开邻域 N 及可积函数 g_1, g_2 ，使所有 $\xi \in N$ 与几乎处处的 x 满足 $|T_j(x)|h(x)e^{\xi^\top T(x)} \leq g_1(x)$ 、 $|T_i(x)T_j(x)|h(x)e^{\xi^\top T(x)} \leq g_2(x)$ 。这些支配条件允许两次交换求导与积分；边界参数须另行处理。

推导第1步：对归一化常数求导。第 j 个分量满足

$$\frac{\partial Z}{\partial \eta_j} = \int T_j(x)h(x)e^{\eta^\top T(x)} dx.$$

推导第2步：识别期望。由 $A = \log Z$ 和 $p_\eta(x) = h(x)e^{\eta^\top T(x)}/Z(\eta)$,

$$\frac{\partial A}{\partial \eta_j} = \frac{1}{Z} \frac{\partial Z}{\partial \eta_j} = \mathbb{E}_\eta[T_j(X)], \quad \nabla A(\eta) = \mathbb{E}_\eta[T(X)].$$

推导第3步：再求导并中心化。对期望的第 i 个分量关于 η_j 求导，商法则给出

$$\frac{\partial^2 A}{\partial \eta_i \partial \eta_j} = \mathbb{E}_\eta[T_i T_j] - \mathbb{E}_\eta[T_i] \mathbb{E}_\eta[T_j].$$

因此 $\nabla^2 A(\eta) = \text{Cov}_\eta[T(X)] \geq 0$ ；协方差矩阵半正定说明 A 为凸函数。

本章共 21 道练习。每道题干后立即给出同号解析；长解析可自然跨页，续页标题保留题号。

练习 5.1. 某分类器对单个独立样本预测正确的概率为 0.8。测试 10 个样本时，恰好正确 8 个及至少正确 1 个的概率各是多少？

练习 5.1 解析

令 S 为 10 个独立样本中的正确数, 则 $S \sim \text{Binomial}(10, 0.8)$, 支持集为 $\{0, \dots, 10\}$, 所有概率均有限。于是

$$P(S = 8) = \binom{10}{8} (0.8)^8 (0.2)^2 = 0.301989888,$$

$$P(S \geq 1) = 1 - P(S = 0) = 1 - (0.2)^{10} = 0.9999998976.$$

第二式使用支持集中的唯一补事件 $S = 0$, 避免逐项累加。

练习 5.2. 证明多项分布中 $E[N_k] = np_k$, 并求 $\text{Cov}(N_j, N_k)$ ($j \neq k$)。

练习 5.2 解析

设 $n \in \mathbb{N}$, 类别概率 $p_k \geq 0$ 且 $\sum_k p_k = 1$ 。令 $I_{ik} = \mathbf{1}\{Z_i = k\}$, 则 I_{ik} 有界, 所需期望均存在, 且

$$N_k = \sum_{i=1}^n I_{ik}, \quad \mathbb{E}[N_k] = \sum_{i=1}^n \mathbb{E}[I_{ik}] = np_k,$$

$$\text{Cov}(I_{ij}, I_{ik}) = \mathbb{E}[I_{ij}I_{ik}] - p_j p_k = -p_j p_k, \quad j \neq k,$$

$$\text{Cov}(N_j, N_k) = \sum_{i=1}^n \text{Cov}(I_{ij}, I_{ik}) = -np_j p_k.$$

最后一步使用不同试验间独立, 使跨试验协方差为零。

练习 5.3. 若 $S \sim \text{Binomial}(n, p)$, 用指示变量证明 $E[S(S-1)] = n(n-1)p^2$ 。

练习 5.3 解析

令 $X_i \stackrel{\text{iid}}{\sim} \text{Bernoulli}(p)$, $0 \leq p \leq 1$, 且 $S = \sum_{i=1}^n X_i$ 。因变量有界, 二阶矩存在。利用 $X_i^2 = X_i$,

$$\begin{aligned} S(S-1) &= \left(\sum_i X_i \right)^2 - \sum_i X_i \\ &= \sum_i (X_i^2 - X_i) + \sum_{i \neq j} X_i X_j = \sum_{i \neq j} X_i X_j, \\ \mathbb{E}[S(S-1)] &= \sum_{i \neq j} \mathbb{E}[X_i] \mathbb{E}[X_j] = n(n-1)p^2. \end{aligned}$$

因此二项变量的二阶阶乘矩为 $n(n-1)p^2$, 边界 $p = 0, 1$ 也包含在内。

练习 5.4. 若 $X \sim \mathcal{N}(2, 9)$, 求 $Y = 3X - 1$ 的分布, 并把 $P(X \leq 5)$ 写成标准高斯分布函数 Φ 。

练习 5.4 解析

$X \sim \mathcal{N}(2, 9)$ 的支持集为 $\mathbb{R}$ 且二阶矩有限。对 $Y = 3X - 1$,

$$\begin{aligned}\mathbb{E}[Y] &= 3\mathbb{E}[X] - 1 = 3 \cdot 2 - 1 = 5, \\ \text{Var}(Y) &= 3^2 \text{Var}(X) = 9 \cdot 9 = 81, \\ Y &\sim \mathcal{N}(5, 81), \\ P(X \leq 5) &= P\left(\frac{X-2}{3} \leq \frac{5-2}{3}\right) = \Phi(1).\end{aligned}$$

所以 $Y \sim \mathcal{N}(5, 81)$, 且 $P(X \leq 5) = \Phi(1)$ 。

练习 5.5. 设 $X \sim \mathcal{N}(\mu, \Sigma)$, 求标量 $a^\top X + b$ 的均值与方差。

练习 5.5 解析

声明 $X \in \mathbb{R}^d$ 、 $\mu, a \in \mathbb{R}^d$ 、 $\Sigma \in \mathbb{R}^{d \times d}$ 对称半正定、 $b \in \mathbb{R}$ 。高斯二阶矩存在, 故

$$\begin{aligned}\mathbb{E}[a^\top X + b] &= a^\top \mu + b, \\ \text{Var}(a^\top X + b) &= \mathbb{E}[a^\top (X - \mu)(X - \mu)^\top a] \\ &= a^\top \Sigma a \geq 0, \\ a^\top X + b &\sim \mathcal{N}(a^\top \mu + b, a^\top \Sigma a).\end{aligned}$$

若 $a^\top \Sigma a = 0$, 最后一项表示退化在其均值处的点质量。

练习 5.6. 二维高斯协方差为 $\Sigma = \begin{pmatrix} 4 & 2 \\ 2 & 9 \end{pmatrix}$ 。求两分量相关系数, 并检验矩阵正定。

练习 5.6 解析

协方差矩阵 $\Sigma \in \mathbb{R}^{2 \times 2}$ 对称, 边缘方差 4, 9 均为正, 因此相关系数有定义。计算

$$\begin{aligned}\sigma_1 &= \sqrt{4} = 2, & \sigma_2 &= \sqrt{9} = 3, \\ \rho_{12} &= \frac{\Sigma_{12}}{\sigma_1 \sigma_2} = \frac{2}{2 \cdot 3} = \frac{1}{3}, \\ \Delta_1 &= 4 > 0, & \Delta_2 &= \det(\Sigma) = 4 \cdot 9 - 2^2 = 32 > 0.\end{aligned}$$

由 Sylvester 判据 $\Sigma > 0$, 故该协方差合法且非退化。

练习 5.7. 用 Gamma 递推计算 $\Gamma(5)$, 并说明它与 $5!$ 的区别。

练习 5.7 解析

Gamma 函数在 $a > 0$ 时由正半轴上的有限积分定义, 并满足 $\Gamma(a+1) = a\Gamma(a)$ 、 $\Gamma(1) = 1$ 。因此

$$\begin{aligned}\Gamma(5) &= 4\Gamma(4) = 4 \cdot 3\Gamma(3) = 4 \cdot 3 \cdot 2\Gamma(2) \\ &= 4 \cdot 3 \cdot 2 \cdot 1\Gamma(1) = 4! = 24, \\ 5! &= 5 \cdot 4! = 120.\end{aligned}$$

练习 5.7 解析 (续)

整数 $n \geq 1$ 时 $\Gamma(n) = (n-1)!$, 故同一自变量下不能直接写成 $n!$ 。

练习 5.8. 若 $X \sim \text{Gamma}(a, b)$ 采用形状-速率参数化, 求 $Y = cX$ ($c > 0$) 的 Gamma 参数。

练习 5.8 解析

采用形状-速率参数化, 要求 $a, b, c > 0$; X 与 $Y = cX$ 的支持集均为 $(0, \infty)$ 。对 $y > 0$ 作变量代换 $x = y/c$,

$$\begin{aligned} f_Y(y) &= f_X(y/c) \left| \frac{d(y/c)}{dy} \right| \\ &= \frac{b^a}{\Gamma(a)} \left(\frac{y}{c} \right)^{a-1} e^{-by/c} \frac{1}{c} \\ &= \frac{(b/c)^a}{\Gamma(a)} y^{a-1} e^{-(b/c)y}. \end{aligned}$$

故 $Y \sim \text{Gamma}(a, b/c)$, 并有 $\mathbb{E}[Y] = c(a/b) = a/(b/c)$ 。

练习 5.9. 设 $p = (p_1, p_2, p_3)$ 服从参数 $(2, 3, 5)$ 的狄利克雷分布, 求各分量期望, 并解释它们为何相加为 1。

练习 5.9 解析

参数 $(2, 3, 5)$ 均为正, 支持集是概率单纯形 $\Delta_2 = \{p_k \geq 0 : \sum_{k=1}^3 p_k = 1\}$, 分量有界因而期望有限。令 $\alpha_0 = 2 + 3 + 5 = 10$, 则

$$\begin{aligned} \mathbb{E}[p_1] &= \frac{2}{10} = 0.2, & \mathbb{E}[p_2] &= \frac{3}{10} = 0.3, \\ \mathbb{E}[p_3] &= \frac{5}{10} = 0.5, \\ \sum_{k=1}^3 \mathbb{E}[p_k] &= \mathbb{E}\left[\sum_{k=1}^3 p_k\right] = \mathbb{E}[1] = 1. \end{aligned}$$

因此三个分量的期望为 $(0.2, 0.3, 0.5)$, 并保持单纯形上的和为 1。

练习 5.10. 判断 $\bar{X}$ 、 $\sum_i (X_i - \mu)^2$ 、 $\max_i X_i$ 中哪些在未知 μ 时是统计量。

练习 5.10 解析

统计量必须是仅依赖样本 $X_{1:n}$ 、不含未知参数的可测函数。按该判据,

$$\begin{aligned} T_1(X_{1:n}) &= \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad \text{是统计量,} \\ T_2(X_{1:n}; \mu) &= \sum_{i=1}^n (X_i - \mu)^2 \quad \text{在未知 } \mu \text{ 时不是统计量,} \\ T_3(X_{1:n}) &= \max_{1 \leq i \leq n} X_i \quad \text{是统计量.} \end{aligned}$$

若将 μ 换为样本函数 $\bar{X}$, 则 $\sum_i (X_i - \bar{X})^2$ 重新成为统计量。

练习 5.11. 设 $X_1, \dots, X_n$ 独立同分布, 均值为 μ 、方差为 σ^2 。证明 $\bar{X}$ 无偏并给出标准误。

练习 5.11 解析

设 $n \geq 1$, X_i 独立同分布且 $\mathbb{E}[X_i] = \mu$ 、 $\text{Var}(X_i) = \sigma^2 < \infty$, 故样本均值的一、二阶矩存在。于是

$$\begin{aligned}\mathbb{E}[\bar{X}] &= \frac{1}{n} \sum_{i=1}^n \mathbb{E}[X_i] = \frac{n\mu}{n} = \mu, \\ \text{Var}(\bar{X}) &= \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{\sigma^2}{n}, \\ \text{SE}(\bar{X}) &= \sqrt{\text{Var}(\bar{X})} = \frac{\sigma}{\sqrt{n}}.\end{aligned}$$

第一式证明无偏, 独立性只在第二式消去交叉协方差时使用。

练习 5.12. 解释为什么观测到数据后样本值是固定的, 但频率学派仍把估计量称为随机变量。

练习 5.12 解析

对象分为抽样前的随机样本 $X_{1:n}$ 与观测后的实现 $x_{1:n}$ 。同一估计规则 T 在两层分别写成

$$\begin{aligned}\hat{\theta} &= T(X_{1:n}) && \text{是随机变量,} \\ \hat{\theta}_{\text{obs}} &= T(x_{1:n}) && \text{是固定数值,} \\ \text{Bias}_{\theta}(T) &= \mathbb{E}_{\theta}[T(X_{1:n})] - \theta, && \text{Var}_{\theta}(T) = \mathbb{E}_{\theta}[(T - \mathbb{E}_{\theta}T)^2].\end{aligned}$$

只要相应期望存在, 偏差和方差描述重复抽样分布, 而不表示已经记录的数据仍在变化。

练习 5.13. 独立高斯样本方差 σ^2 已知, 推导均值 μ 的极大似然估计。

练习 5.13 解析

设 $n \geq 1$ 、 $x_i \in \mathbb{R}$ 、已知 $\sigma^2 > 0$, 参数域为 $\mu \in \mathbb{R}$; 高斯密度在全支持上严格为正。忽略与 μ 无关的常数,

$$\begin{aligned}\ell(\mu) &= -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 + C, \\ \ell'(\mu) &= \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \iff \hat{\mu} = \bar{x}, \\ \ell''(\mu) &= -\frac{n}{\sigma^2} < 0.\end{aligned}$$

对数似然严格凹且参数域无边界, 故 $\hat{\mu} = \bar{x}$ 是唯一全局 MLE。

练习 5.14. 说明对数似然为何比原似然更适合数值计算, 并指出它何时不能定义。

练习 5.14 解析

对独立样本定义 $L(\theta) = \prod_{i=1}^n p_{\theta}(x_i)$ 及正似然域 $\Theta_+ = \{\theta : L(\theta) > 0\}$ 。在 Θ_+ 上,

$$\begin{aligned}\ell(\theta) &= \log L(\theta) = \sum_{i=1}^n \log p_{\theta}(x_i), \\ \arg \max_{\theta \in \Theta_+} L(\theta) &= \arg \max_{\theta \in \Theta_+} \ell(\theta), \\ L(\theta) = 0 &\implies \log L(\theta) \text{ 在普通实数中无定义, } \ell(\theta) := -\infty \text{ 按扩展实数约定.}\end{aligned}$$

求和避免大量小数连乘下溢; 零概率边界表示观测在该模型下不可能, 不能用数值常数随意改写。

练习 5.15. 均匀分布 $X_i \sim \text{Unif}(0, \theta)$, $\theta > 0$ 。求 MLE 并解释为何不能只令普通导数为零。

练习 5.15 解析

参数域为 $\Theta = (0, \infty)$, 单样本支持为 $[0, \theta]$ 。令 $x_{(1)} = \min_i x_i$ 、 $x_{(n)} = \max_i x_i$, 完整似然为

$$L(\theta; x_{1:n}) = \theta^{-n} \mathbf{1}_{\{x_{(1)} \geq 0\}} \mathbf{1}_{\{\theta \geq x_{(n)}\}}, \quad \theta > 0.$$

若样本与模型相容且 $x_{(n)} > 0$, 可行参数集为 $[x_{(n)}, \infty)$, 并且

$$\begin{aligned}\frac{d}{d\theta} \theta^{-n} &= -n\theta^{-n-1} < 0, \quad \theta \geq x_{(n)}, \\ L(\theta) \text{ 严格递减} &\implies \hat{\theta} = x_{(n)}.\end{aligned}$$

若 $x_{(1)} < 0$, 则 $L \equiv 0$, 原始似然的 $\arg \max$ 退化为整个 Θ 而对数似然处处为 $-\infty$; 若所有 $x_i = 0$, 则 $L(\theta) = \theta^{-n} \rightarrow \infty$ 当 $\theta \downarrow 0$, 只有上确界而无 MLE。参数改变支持集, 因此内部驻点法不适用。

练习 5.16. 伯努利参数先验为 $\text{Beta}(2, 3)$, 观察 8 次成功、2 次失败。求后验参数与后验均值。

练习 5.16 解析

参数 p 的支持为 $(0, 1)$, 先验 $\text{Beta}(2, 3)$ 正规且 10 次观测含 8 次成功、2 次失败。后验核为

$$\begin{aligned}\pi(p | x) &\propto p^{2-1}(1-p)^{3-1} p^8(1-p)^2 \\ &= p^{10-1}(1-p)^{5-1}, \\ p | x &\sim \text{Beta}(10, 5), \\ \mathbb{E}[p | x] &= \frac{10}{10+5} = \frac{2}{3}.\end{aligned}$$

后验形状参数均为正, 故归一化常数与均值都有限。

练习 5.17. 对上题求 MAP, 并说明形状参数不大于 1 时为何要检查边界。

练习 5.17 解析

后验为 $\text{Beta}(a, b)$ 且本题 $(a, b) = (10, 5)$, 两者均大于 1, 故密度在 $(0, 1)$ 有限且边界趋零。内部对数密度满足

$$\begin{aligned}\ell(p) &= (a-1)\log p + (b-1)\log(1-p) + C, \\ \ell'(p) &= \frac{a-1}{p} - \frac{b-1}{1-p} = 0, \\ p_{\text{MAP}} &= \frac{a-1}{a+b-2} = \frac{9}{13}, \\ \ell''(p) &= -\frac{a-1}{p^2} - \frac{b-1}{(1-p)^2} < 0.\end{aligned}$$

若 $a \leq 1$ 或 $b \leq 1$, 端点可能取到最大、出现平台或使密度发散, 内部公式不再给出全局 MAP, 必须按支持边界另行比较。

练习 5.18. 三类先验为 $\text{Dirichlet}(1, 1, 1)$, 观测计数为 $(4, 2, 0)$ 。求后验与后验预测概率。

练习 5.18 解析

类别概率 p 位于三类单纯形, 先验参数均为正, 计数为 $n = (4, 2, 0)$ 且样本数 $n = 6$ 。共轭更新为

$$\begin{aligned}\alpha' &= (1, 1, 1) + (4, 2, 0) = (5, 3, 1), \\ p | x &\sim \text{Dirichlet}(5, 3, 1), \\ P(X_{\text{new}} = k | x) &= \mathbb{E}[p_k | x] = \frac{\alpha'_k}{\sum_j \alpha'_j}, \\ P_{\text{pred}} &= \left(\frac{5}{9}, \frac{3}{9}, \frac{1}{9}\right).\end{aligned}$$

三个预测概率非负且和为 1; 第三类因正先验伪计数而未被赋零概率。

练习 5.19. 模型有两个参数值, 先验各为 $1/2$, 数据似然分别为 0.1 和 0.4。求边缘似然与两个参数的后验概率。

练习 5.19 解析

参数支持集为 $\{\theta_1, \theta_2\}$, 先验质量各为 $1/2$; 两个似然有限且证据概率将严格为正。由全概率与 Bayes 公式,

$$\begin{aligned}p(x) &= \sum_{j=1}^2 p(x | \theta_j) \pi_j = 0.5(0.1) + 0.5(0.4) = 0.25, \\ P(\theta_1 | x) &= \frac{0.05}{0.25} = 0.2, \\ P(\theta_2 | x) &= \frac{0.20}{0.25} = 0.8, \\ P(\theta_1 | x) + P(\theta_2 | x) &= 1.\end{aligned}$$

所以后验分布为 $(0.2, 0.8)$, 归一化检查通过。

练习 5.20. 混合模型 $p(x) = \sum_{k=1}^K \pi_k p(x | z = k)$ 中, 写出给定 x 后隐类别的后验责任度。

练习 5.20 解析

类别支持为 $\{1, \dots, K\}$, 权重 $\pi_k \geq 0$ 且 $\sum_k \pi_k = 1$ 。对给定 x 定义有限证据 $Z(x) = \sum_{j=1}^K \pi_j p(x | z = j)$; 仅当 $0 < Z(x) < \infty$ 时责任度有定义:

$$\begin{aligned}\gamma_k(x) &= P(z = k | x) = \frac{\pi_k p(x | z = k)}{Z(x)}, \\ \gamma_k(x) &\geq 0, \quad \sum_{k=1}^K \gamma_k(x) = \frac{Z(x)}{Z(x)} = 1, \\ \gamma_k(x) &= \mathbb{E}[\mathbf{1}\{z = k\} | x].\end{aligned}$$

若 $Z(x) = 0$, 观测落在混合分布支持之外, 后验责任度未定义。

练习 5.21. 证明指数族中 $\nabla^2 A(\eta) = \text{Cov}_\eta[T(X)]$, 并说明 A 的凸性。

练习 5.21 解析

设自然参数 η 位于开凸集 $\mathcal{H}$, 配分积分 $Z(\eta) = \int h(x) e^{\eta^\top T(x)} dx$ 有限且正, 并存在可积支配函数允许对 η 作两次积分号下求导; 同时 $\mathbb{E}_\eta \|T(X)\|_2^2 < \infty$ 。令 $A(\eta) = \log Z(\eta)$, 则

$$\begin{aligned}\nabla A(\eta) &= \frac{\int T(x) h(x) e^{\eta^\top T(x)} dx}{Z(\eta)} = \mathbb{E}_\eta[T(X)], \\ \nabla^2 A(\eta) &= \mathbb{E}_\eta[T(X)T(X)^\top] - \mathbb{E}_\eta[T(X)]\mathbb{E}_\eta[T(X)]^\top \\ &= \text{Cov}_\eta[T(X)].\end{aligned}$$

对任意 v , $v^\top \nabla^2 A(\eta) v = \text{Var}_\eta(v^\top T(X)) \geq 0$, 故 A 在 $\mathcal{H}$ 上凸。若缺少换导与二阶矩条件, 上述形式推导不能直接作为证明。

读前自检：本章结论与下一步。 常用分布与统计推断章末由“常用分布、参数、统计量与充分统计量”落到“先核对支持边界与换导条件, 再求驻点并比较边界”; 请把前者产出和后者输入逐项对齐, 固定核对前者末项的输出类型能否作为后者首项的输入类型。

本章结论与下一步

核心结论: 常用分布、参数、统计量与充分统计量

关键依据: 似然/MAP 优化、共轭更新及配分函数求导

可执行自检: 先核对支持边界与换导条件, 再求驻点并比较边界

适用边界: 参数估计、隐变量建模和概率预测

下一步: 进入章 6, 用 KL 与交叉熵比较分布

1. 能否在写密度前先声明支持集与参数化, 并检查归一化?
2. 能否从独立抽样模型逐步写出似然、对数似然、一阶条件及边界检查?
3. 能否说明共轭先验的超参数如何随充分统计量更新?

4. 能否区分边缘似然、后验、MAP 与后验预测各自积分或优化的对象？未通过时依次回看节 5.1—5.3、5.5—5.7。

第 6 章 信息论基础

读前自检：先修自检。 信息论基础先修自检固定核验“能否验证一组非负数是否构成归一化概率分布”；请验证一组非负数实际构成归一化概率分布并写出中间结果，再按“中间结果直接回答首项“能否验证一组非负数是否构成归一化概率分布”并给出通过或失败”明确判为通过或失败。

本章地图

核心问题：如何量化不确定性、分布差异与条件信息

可检验学习目标：

- 从事件信息量建立熵、条件熵、联合熵与互信息，并掌握各自的取值条件；
- 完整证明 KL 散度非负，理解交叉熵与最大似然之间的等价关系；
- 能够计算信息增益、信息增益比和基尼指数，并用于分类划分评价。

最短先修：需要离散概率分布、条件概率、联合与边缘分布、期望和对数函数。Jensen 不等式在下文首次使用前给出有限加权版本。约定 $0 \log 0 = 0$ ，对数底为 2 时单位为比特，底为 e 时单位为奈特。

依赖路线：信息量 $\rightarrow$ 熵 $\rightarrow$ 联合熵与条件熵 $\rightarrow$ 互信息；交叉熵 $\rightarrow$ 熵 $\rightarrow$ KL 散度；条件熵下降 $\rightarrow$ 信息增益 $\rightarrow$ 信息增益比；类别不纯度 $\rightarrow$ 基尼指数。

完成标准与返回：支撑或归一化不闭合时返回 KL 定义和条件熵节

前置知识：有限加权 Jensen 不等式

设 D 为凸集， $x_1, \dots, x_m \in D$ ，权重 $\lambda_i \geq 0$ 且 $\sum_{i=1}^m \lambda_i = 1$ 。若 $f : D \rightarrow \mathbb{R}$ 为凸函数，则

$$f\left(\sum_{i=1}^m \lambda_i x_i\right) \leq \sum_{i=1}^m \lambda_i f(x_i);$$

若 f 为凹函数，不等号反向。严格凸（或严格凹）时，在所有正权重属于定义域的条件下，等号要求这些点相同。

本章反复使用凹函数 $\log$ 。例如取 $x_1 = 1, x_2 = 4$ 及 $\lambda_1 = \lambda_2 = 1/2$ ，有

$$\log \frac{1+4}{2} = \log 2.5 \geq \frac{1}{2} \log 1 + \frac{1}{2} \log 4 = \log 2,$$

方向与数值大小一致。使用时必须同时核对：点位于定义域内、权重非负、权重和为 1。节 7.6 将在凸函数体系中给出归纳证明和概率形式。

本章主线约定。除“扩展讨论”明确另述外， X, Y 均取值于有限字母表，所有边缘熵、联合熵与条件熵因而是有限实数，有限求和也可直接换序。若允许可数无限支持或一般测度空间，互信息以 KL 散度定义；只有相关熵均有限时才把它改写为熵的差，绝不进行未定义的 $+\infty - \infty$ 运算。

本章符号表

符号	取值	含义
$I(x)$	$[0, \infty]$	事件结果 x 的自信息 $-\log p(x)$
$H(X), H(X Y)$	$[0, \infty)$	主线有限字母表上的熵与条件熵
$D_{\text{KL}}(P\ Q)$	$[0, +\infty]$	相对熵
$H(P, Q)$	$[0, +\infty]$	用 Q 编码来自 P 的数据的交叉熵
$I(X; Y)$	$[0, \infty)$	主线有限字母表上的互信息

6.1 信息量与熵

结果 x 的自信息在扩展实数中定义为

$$I(x) = \begin{cases} -\log p(x), & p(x) > 0, \\ +\infty, & p(x) = 0. \end{cases}$$

零概率点不会在该模型下以正概率被观察到，但将其自信息记为 $+\infty$ 可准确记录支持失败。独立事件同时发生时概率相乘，而有限自信息相加，这解释了对数形式；概率 1 的确定事件信息量为 0。

读前自检：熵。 对信息论基础中的熵，条件“若 X 有 K 个可能值”不可省；请在共同支持上代入 $H(X)$ 并合并一项，再用上界当且仅当分布均匀时取得作检查。

定义 6.1 (离散熵). 对质量函数 p ，随机变量 X 的熵为

$$H(X) = -\sum_x p(x) \log p(x) = \mathbb{E}[-\log p(X)].$$

熵是观察之前的平均不确定性，而单个结果的信息量是观察之后针对该结果的量。

定理 6.1 (有限均匀分布最大熵) 若 X 有 K 个可能值，则 $0 \leq H(X) \leq \log K$ ；上界当且仅当分布均匀时取得。

读前自检：证明：有限均匀分布最大熵。 设 P 支撑于至多 K 个点。请用 Jensen 不等式推出 $H(P) \leq \log K$ ，并核对等号仅在 K 点均匀时成立。

证明。 记正概率支持为 $S = \{x : p(x) > 0\}$ 。由 $\log$ 的凹性直接应用 Jensen 不等式，

$$H(P) = \sum_{x \in S} p(x) \log \frac{1}{p(x)} \leq \log \left(\sum_{x \in S} p(x) \frac{1}{p(x)} \right) = \log |S| \leq \log K.$$

第一处等号要求 $1/p(x)$ 在 S 上为常数，第二处等号要求 $|S| = K$ ，故上界等号当且仅当 P 在全部 K 点上均匀。另一方面， $0 < p(x) \leq 1$ 使每个 $-p(x) \log p(x)$ 非负，故 $H(P) \geq 0$ 。此证明不依赖后文才定义的 KL 散度。□




图 6.1 二元熵在 $p = 1/2$ 处达到 1 比特，在确定分布两端趋于 0

对称性给出 $H_b(p) = H_b(1-p)$ ；二阶导数为负说明图 6.1 中的曲线严格凹，驻点 $p = 1/2$ 因此是唯一最大点。

6.2 条件熵与联合熵

在本章有限字母表约定下，

$$H(X | Y) = - \sum_{x,y} p(x,y) \log p(x | y) = \sum_y p(y) H(X | Y = y).$$

它先在每个条件分布中计算不确定性，再按条件变量的概率平均。联合熵定义为

$$H(X, Y) = - \sum_{x,y} p(x,y) \log p(x,y).$$

利用 $p(x,y) = p(y)p(x | y)$ ，得到链式法则

$$H(X, Y) = H(Y) + H(X | Y) = H(X) + H(Y | X).$$

引理 6.1 (条件化不增加离散熵) 若 X, Y 取值于有限字母表，则 $H(X | Y) \leq H(X)$ ，等号当且仅当 X, Y 独立（忽略零概率点）。

读前自检：证明：条件化不增加离散熵。 条件化不增加离散熵可写成 $H(X) - H(X | Y) = I(X; Y)$ ；请把互信息展开为 $D_{\text{KL}}(P_{XY} \| P_X P_Y)$ ，由非负性核对 $H(X | Y) \leq H(X)$ ，并指出等号对应 X, Y 独立。

证明. 有限字母表保证 $H(X)$ 与 $H(X|Y)$ 均有限, 所以下面的差不是 $+\infty - \infty$ 。令 $S = \{(x, y) : p(x, y) > 0\}$ 并记 $\Delta = H(X) - H(X|Y)$ 。直接展开后,

$$\Delta = \sum_{(x,y) \in S} p(x,y) \log \frac{p(x,y)}{p_X(x)p_Y(y)}.$$

不引用后文的互信息或 KL 结论, 而对 $-\Delta$ 直接使用 $\log$ 的凹性:

$$-\Delta \leq \log \sum_{(x,y) \in S} p_X(x)p_Y(y) \leq \log 1 = 0.$$

因此 $H(X|Y) \leq H(X)$ 。等号要求 $p(x, y) = p_X(x)p_Y(y)$ 并且边缘乘积分布在 S 外没有质量, 恰好等价于 X, Y 独立 (零概率点按通常约定忽略)。□

读前自检: 常见错误与误用边界: 条件熵与联合熵。 令 $P(Z = n) = C/[n(\log n)^2]$ ($n \geq 2$), $B \sim \text{Bernoulli}(1/2)$ 且与 Z 独立, 并取 $X = (B, Z), Y = B$; 请核对 $H(X) = H(X|Y) = +\infty$ 使熵差未定义, 而 $D_{\text{KL}}(P_{XY} \| P_X \otimes P_Y) = \log 2$ 。

常见错误

扩展讨论: 无限熵反例不能用“ $\infty = \infty$ ”判断独立。 令 Z 取值 $n \geq 2$ 且 $P(Z = n) = C/[n(\log n)^2]$, 其中 C 为归一化常数, 则 $H(Z) = +\infty$ 。再令 $B \sim \text{Bernoulli}(1/2)$ 与 Z 独立, 并取 $X = (B, Z), Y = B$ 。此时 Y 由 X 决定, 二者显然相关, 却有

$$H(X) = +\infty, \quad H(X|Y) = +\infty.$$

差 $H(X) - H(X|Y)$ 没有定义; 按 KL 定义计算才得到良定义的 $I(X; Y) = H(B) = \log 2$ 。因此一般版本必须以 $I(X; Y) = D_{\text{KL}}(P_{XY} \| P_X \otimes P_Y)$ 为定义。

阅读目标: 用 Jensen 不等式建立非负性, 并准确识别等号成立条件。

对象: 概率分布 P, Q , 且 P 的支持包含在 Q 的支持中。

合法条件: P, Q 均归一化; 在 $P(x) > 0$ 处有 $Q(x) > 0$ 。

第一步: 先在 P 下对 $\log \frac{Q(X)}{P(X)}$ 应用凹函数 $\log$ 的 Jensen 不等式。

读前自检: KL 散度 (相对熵)。 围绕 KL 散度 (相对熵), 先采用条件 “若 $P(x) > 0, Q(x) = 0$ ”, 再在共同支持上代入 $D_{\text{KL}}(P \| Q)$ 并合并一项; 最后验证交换两分布通常会改变数值, 且可能把有限值变为无穷。

读前自检: KL 散度的定义和狄利克雷分布的性质。 KL 散度的定义和狄利克雷分布的性质中的 “若 $P(x) > 0, Q(x) = 0$ ” 决定可执行范围; 请在共同支持上代入 $D_{\text{KL}}(P \| Q)$ 并合并一项, 结果须满足交换两分布通常会改变数值, 且可能把有限值变为无穷。

6.3 KL 散度与交叉熵

对有限离散分布 P, Q , 约定 $0 \log(0/q) = 0$; 若 $P(x) > 0, Q(x) = 0$, 则该项为 $+\infty$ 。定义

$$D_{\text{KL}}(P\|Q) = \sum_x P(x) \log \frac{P(x)}{Q(x)}. \quad (6.1)$$

若 P, Q 在 $\mathbb{R}^d$ 上相对于 Lebesgue 测度有密度 p, q , 主线直接应用

$$D_{\text{KL}}(P\|Q) = \int_{\mathbb{R}^d} p(x) \log(p(x)/q(x)) dx,$$

并约定 $p > 0, q = 0$ 处散度为 $+\infty$ 。**扩展讨论 (一般测度空间)**。若 $P \ll Q$ (P 对 Q 绝对连续), 用 Radon-Nikodym 导数定义

$$D_{\text{KL}}(P\|Q) = \int \log\left(\frac{dP}{dQ}\right) dP.$$

当 P, Q 相对于同一支配测度分别有密度 p, q 时, 这才化为 $\int p \log(p/q)$ 。若 $P \not\ll Q$, 即存在事件 A 满足 $P(A) > 0, Q(A) = 0$, 则定义散度为 $+\infty$; 这比只比较单点密度更准确。交换两分布通常会改变数值, 且可能把有限值变为无穷。

在主线有限字母表上, $H(P) < \infty$ 。交叉熵 $H(P, Q) = -\sum_x P(x) \log Q(x)$ 因而在扩展实数中满足

$$H(P, Q) = H(P) + D_{\text{KL}}(P\|Q).$$

若 Q 在 P 的正支持上取零, 则等式两边均为 $+\infty$; 这里从不把它倒写成两个无穷量之差。当数据分布 P 固定时, 最小化交叉熵等价于最小化 KL 散度, 也等价于最大化模型 Q 的期望对数似然。

推导目标

逐步证明 KL 散度非负, 并确定等号条件。

推导准备

先处理 P 的支持包含于 Q 支持且两者归一化的情形; 使用凹函数 $\log$ 的 Jensen 不等式。

推导第 1 步: 记 $S = \{x : P(x) > 0\}$ 。在 S 上把负散度写成

$$-D_{\text{KL}}(P\|Q) = \sum_{x \in S} P(x) \log \frac{Q(x)}{P(x)}.$$

推导第 2 步: 由 $\log$ 的凹性,

$$-D_{\text{KL}}(P\|Q) \leq \log \sum_{x \in S} Q(x) \leq \log 1 = 0.$$

第二个不等式不能擅自把 S 外的 Q 质量计入求和; 这正是支持集边界需要单独写出的原因。

推导第 3 步: 两边乘以 -1 得到

阅读目标：把联合分布相对独立分布的 KL 散度拆成熵差。

对象：有限字母表上的联合分布 $p(x, y)$ 及边缘分布 p_X, p_Y 。

合法条件：分布已归一化，并采用 $0 \log 0 = 0$ ；有限求和可重新分组。

第一步：先展开 $\log \frac{p(x, y)}{p_X(x)p_Y(y)} = \log p(x, y) - \log p_X(x) - \log p_Y(y)$ 。

$$D_{\text{KL}}(P\|Q) \geq 0. \quad (6.2)$$

若取等，则既要有 $Q(x)/P(x)$ 在 S 上为常数，又要有 $\sum_{x \in S} Q(x) = 1$ 。归一化迫使该常数为 1 且 S 外的 Q 质量为 0，故 $Q = P$ 。反过来，若 $Q = P$ ，则每个 $P(x) > 0$ 的项都有 $\log(P(x)/Q(x)) = \log 1 = 0$ ，而 $P(x) = 0$ 的项按 $0 \log 0 = 0$ 约定贡献为零，故总和为零。若某点满足 $P(x) > 0, Q(x) = 0$ ，则散度为 $+\infty$ ，非负性仍成立。

读前自检：Corollary：真实类别分布固定时，交叉熵的最小值是其自身熵，并且只有预测分布等于真实分布时.....。 真实类别分布 P 固定时，交叉熵满足 $H(P, Q) = H(P) + D_{\text{KL}}(P\|Q)$ ；请减去 $H(P)$ 并用 KL 非负性核对最小值为 $H(P)$ ，等号仅在 $Q = P$ 时取得。

推论 6.1 真实类别分布固定时，交叉熵的最小值是其自身熵，并且只有预测分布等于真实分布时达到。

例题 6.1 (二元分布的双向 KL 比较). 真实二元分布为 $P = (0.8, 0.2)$ ，模型为 $Q = (0.6, 0.4)$ 。分别计算两个方向的 KL 散度并比较。

例题 6.1 解答

读题翻译 在同一二元支持上分别按 $P\|Q$ 与 $Q\|P$ 的次序计算 KL 散度，并用数值结果判断其是否对称。

已知与合法条件 $P = (0.8, 0.2)$ 与 $Q = (0.6, 0.4)$ 均归一化且在共同支持上严格为正，所以两个方向的 KL 都有限。

为什么想到这个方法 保持分子分母次序分别展开两个 KL 和式，再用方向无关的总变差与 Pinsker 下界检查数值量级。

方法选择 计算 $\sum_i P_i \log(P_i/Q_i)$ 和 $\sum_i Q_i \log(Q_i/P_i)$ ，比较两值，并核验它们都不小于 $2\|P - Q\|_{\text{TV}}^2$ 。

推导/计算 两个分布在有限支持 $\{1, 2\}$ 上均严格为正，所以两个方向的 KL 都有限。以自然对数计，

$$\begin{aligned} D_{\text{KL}}(P\|Q) &= 0.8 \log \frac{0.8}{0.6} + 0.2 \log \frac{0.2}{0.4} \\ &= 0.8 \log \frac{4}{3} + 0.2 \log \frac{1}{2} \approx 0.09152, \\ D_{\text{KL}}(Q\|P) &= 0.6 \log \frac{0.6}{0.8} + 0.4 \log \frac{0.4}{0.2} \\ &= 0.6 \log \frac{3}{4} + 0.4 \log 2 \approx 0.10465. \end{aligned}$$

独立核验 总变差距离为 $\|P - Q\|_{TV} = 0.2$; Pinsker 不等式对两个方向都给出下界 $2(0.2)^2 = 0.08$, 而 0.09152 与 0.10465 均满足该界。

结论 $D_{KL}(P\|Q) \approx 0.09152$, $D_{KL}(Q\|P) \approx 0.10465$; 两值不同, 故 KL 散度不对称, 也不是度量距离。

读前自检：互信息。 信息论基础中的互信息要求先确认“设 X, Y 取值于有限字母表, 联合分布 $p(x, y)$ 已归一化”; 请随后在共同支持上代入 $I(X; Y)$ 并合并一项, 用若观察 Y 不能改变 X 的条件分布, 则条件熵等于边缘熵, 互信息为 0 验收。

6.4 互信息

推导目标

从 KL 定义推出互信息的熵差表达式, 并说明该表达式为何关于 X, Y 对称。

推导准备

设 X, Y 取值于有限字母表, 联合分布 $p(x, y)$ 已归一化; 边缘分布为 $p_X(x) = \sum_y p(x, y)$ 与 $p_Y(y) = \sum_x p(x, y)$, 并采用 $0 \log 0 = 0$ 约定。有限性保证下列拆项与熵差均合法。

推导第 1 步：展开 KL。 按定义

$$I(X; Y) = D_{KL}(p_{XY} \| p_X p_Y) = \sum_{x, y} p(x, y) \log \frac{p(x, y)}{p_X(x) p_Y(y)}. \quad (6.3)$$

式 (6.3) 也是可数或一般空间中的基本定义 (一般空间把 $p_X p_Y$ 换成乘积分布 $P_X \otimes P_Y$); 即使某些熵为 $+\infty$, 该 KL 定义仍不会制造 $+\infty - \infty$ 。将对数拆成三项并分别求和, 得到

$$I(X; Y) = H(X) + H(Y) - H(X, Y). \quad (6.4)$$

推导第 2 步：使用熵的链式法则。 由 $H(X, Y) = H(Y) + H(X | Y)$,

$$I(X; Y) = H(X) - H(X | Y). \quad (6.5)$$

再把 $H(X, Y) = H(X) + H(Y | X)$ 代入 $I(X; Y) = H(X) + H(Y) - H(X, Y)$, 逐项约去 $H(X)$, 得到

$$I(X; Y) = H(X) + H(Y) - \{H(X) + H(Y | X)\} = H(Y) - H(Y | X).$$

推导第 3 步：核对性质。 式 $H(X) + H(Y) - H(X, Y)$ 在交换 X, Y 后不变, 所以互信息对称; 其 KL 形式给出 $I(X; Y) \geq 0$, 且等号成立当且仅当 $p(x, y) = p_X(x)p_Y(y)$, 即两变量独立。互信息因此衡量观察一个变量后另一个变量不确定性的平均下降。

几何理解

几何解释。可以把联合分布与“独立模型” $p_X p_Y$ 看作概率单纯形中的两个点，互信息用 KL 量化二者偏离。它不是对称度量，却以零集合精确刻画独立流形。

概率解释

若观察 Y 不能改变 X 的条件分布，则条件熵等于边缘熵，互信息为 0；若 Y 完全决定 X ，则条件熵为 0，互信息达到 $H(X)$ 。

优化解释

优化解释。最大化互信息可用于选择保留标签信息的特征或表示，但高维中联合密度估计困难，有限样本估计会产生偏差；实际目标常采用可计算下界或离散计数估计。

读前自检：信息增益。 把数据集 D 按常量特征 A 分组；请计算 $H(D | A) = H(D)$ ，代入 $g(D, A) = H(D) - H(D | A)$ 并核对信息增益为 0。

6.5 信息增益与信息增益比

数据集 D 按特征 A 分组后，信息增益定义为

$$g(D, A) = H(D) - H(D | A),$$

等于经验标签与特征之间的互信息。取值越大，划分后标签越纯。为抑制取值很多的特征偏好，定义 $g_R(D, A) = g(D, A)/H_A(D)$ ，其中 $H_A(D)$ 是样本在特征取值上的划分熵；分母为 0 时该特征不能形成有效划分。

模型。 在一个决策树节点上，以经验频率估计标签分布和“特征取值 - 标签”联合分布。**学习策略。** 比较候选特征造成的加权条件熵下降，并在信息增益相近时用增益比控制多值偏好。

离散特征的信息增益与增益比评估：五步阅读

输入。 写出数据对象、固定参数与必须成立的条件。

初始化。 标明主状态、计数器和第一个合法状态。

核心更新。 只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。 写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。 列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 6.1: 离散特征的信息增益与增益比评估

输入: 数据 D , 有序候选 $\mathcal{A}$, K , 评分准则与固定并列规则

输出: 最后合法评分记录与推荐; $\alpha_{\text{done}}, s_{\text{done}}$; **status** 与诊断

- 1 若 $n < 1$ 、 $K < 1$ 、标签/特征编码或规则非法, 返回空记录、计数 0、**invalid_input** 及字段诊断
- 2 初始化类别计数并计算父节点熵 H_D , 置 $\alpha_{\text{done}} = s_{\text{done}} = 0$; 若非有限则返回 **numerical_failure** 及父熵诊断
- 3 若 $\mathcal{A} = \emptyset$, 返回空记录与推荐、**completed** 及空候选诊断
- 4 **对** $A \in \mathcal{A}$ **执行**
 - 5 初始化临时“取值 – 类别”计数表
 - 6 **对** $i \leftarrow 1$ **至** n **执行**
 - 7 读取并更新临时计数; 成功后增加 s_{done} ; 若计数异常, 返回旧记录、**numerical_failure** 及 (A, i) 诊断
 - 8 **结束**
 - 9 形成临时 $H(D|A), H_A(D), g_A$; 若 $H_A(D) > 0$ 则形成 r_A , 否则标记增益比未定义
 - 10 若任一应定义量非有限, 则返回旧记录、**numerical_failure** 及 A 评分诊断
 - 11 原子追加 $(A, g_A, r_A, \text{有效标志})$ 并增加 α_{done}
- 12 **结束**
- 13 按冻结准则从完整有效记录中选择; 若集合为空则保持空推荐; 返回 **completed** 及并列/退化最终诊断

算法实现说明: 首次阅读只做“父熵—条件熵—得分—选择”; 实现时再处理零分母、非法编码、并列与失败状态完整 C1–C14 契约

终止与退化说明。 候选特征集和样本集均有限时, 过程完成确定次数的计数与比较后终止, 不存在参数极限过程。空数据、空候选集或全部增益比分母为零时, 评分规则在当前输入上未定义, 应报告相应退化条件而不产生特征推荐。

6.6 基尼指数

类别概率为 $p_1, \dots, p_K$ 时, 基尼不纯度为

$$G(p) = 1 - \sum_{k=1}^K p_k^2 = \sum_k p_k(1 - p_k).$$

它等于按 p 随机抽取两个独立标签时二者不同的概率。二分类时 $G = 2p(1 - p)$; 纯节点为 0, 均匀类别分布达到最大值 $1 - 1/K$ 。

读前自检: 复杂度分析: 基尼指数。 信息论基础中的基尼指数依赖“若需现场排序、哈希扩容或处理开放词表, 应把相应实现成本另行加入”; 请据此由 n 的总成本剥离一次迭代或一次样本因子, 并直接核对预测复杂度: 本算法只给出特征排序, 并未训练可对新样本输出标签的预测器。

复杂度分析

复杂度假设。 以下界假设每个离散特征值已映射为可在单位时间索引的有限状态, 顺序扫描全部 n 个样本和 M 个候选特征; V_j 只计已登记的状态数。若需现场排序、哈希扩容或处理开放词表, 应把相应实现成本另行加入。设 n 为样本数、 K 为类别数、 M 为候选特征数, V_j 为第 j 个特征的取值数。**训练复杂度:** 逐特征计数与评分为 $O(nM + K \sum_j V_j)$; 计数已知后,

熵或基尼的计算线性于非零状态数。**预测复杂度**：本算法只给出特征排序，并未训练可对新样本输出标签的预测器。**存储复杂度**：顺序处理特征时为 $O(K \max_j V_j + M)$ ，同时保存全部“取值 - 类别”表时为 $O(K \sum_j V_j)$ 。

适用条件与局限性

适用条件：离散熵和基于频数的划分准则适用于类别或经过明确离散化的特征；交叉熵适合概率预测并要求模型对真实支持赋正概率。**局限性**：高维互信息的经验估计偏差较大，信息增益偏爱多值特征，增益比可能偏爱极端不均衡划分，KL 散度不对称且不满足三角不等式。

读前自检：常见错误与误用边界：基尼指数。 信息论基础中的基尼指数以“边界框首项禁止把条件熵写成未按条件变量概率加权的平均”为约束；请把固定错误“把条件熵写成未按条件变量概率加权的平均”中的对象、操作与结论按本节定义拆开，指出第一个不满足的定义条件，再把该处改为本节允许的写法，并确认改写后的运算或判断有定义，且不再触发“把条件熵写成未按条件变量概率加权的平均”。

常见错误

典型误用包括：漏写负号导致“熵”为负；混用对数底却比较绝对数值；把条件熵写成未按条件变量概率加权的平均；交换 KL 方向；在模型概率为零处忽略无限损失；把信息增益比的零分母当作零；使用未归一化计数代替概率计算熵。

易混淆概念对比

概念对比：熵描述单一分布的不确定性，交叉熵评价用另一分布编码的代价；在本章有限字母表主线下，KL 等于交叉熵减去熵，而一般情形应保留 KL 本身的定义，不能相减两个无穷量。互信息是联合分布偏离边缘独立模型的 KL。信息增益使用熵下降，基尼下降使用二次不纯度下降，二者常给出相近但不必相同的划分排序。KL 不是距离，而互信息虽对变量对称，也不是变量取值之间的距离。

本章共 18 道练习。每道题干后立即给出同号解析；长解析可自然跨页，续页标题保留题号。

练习 6.1. 以 2 为底计算概率分别为 $1/2, 1/4, 1/8$ 的结果所携带的信息量。

练习 6.1 解析

自信息 $I(p) = -\log_2 p$ 在 $0 < p \leq 1$ 时有限, 零概率事件按极限取 $I(0) = +\infty$ 。对三个正概率,

$$\begin{aligned} I(1/2) &= -\log_2(2^{-1}) = 1 \text{ bit}, \\ I(1/4) &= -\log_2(2^{-2}) = 2 \text{ bit}, \\ I(1/8) &= -\log_2(2^{-3}) = 3 \text{ bit}, \\ I(p/2) &= -\log_2 p + 1 = I(p) + 1. \end{aligned}$$

这些是单个结果的信息量; 只有对完整归一化分布作概率加权后才得到熵。

练习 6.2. 计算伯努利 (1/4) 的二元熵, 并与伯努利 (1/2) 比较。

练习 6.2 解析

伯努利分布支持为 $\{0, 1\}$, 采用 $0 \log 0 = 0$ 约定, 故所有 $p \in [0, 1]$ 的二元熵均有限。以 2 为底,

$$\begin{aligned} H_b(1/4) &= -\frac{1}{4} \log_2 \frac{1}{4} - \frac{3}{4} \log_2 \frac{3}{4} \\ &= \frac{1}{2} - \frac{3}{4} \log_2 \frac{3}{4} \approx 0.8113 \text{ bit}, \\ H_b(1/2) &= -2 \left(\frac{1}{2} \log_2 \frac{1}{2} \right) = 1 \text{ bit}, \\ H_b(1/4) &< H_b(1/2). \end{aligned}$$

因此偏置伯努利变量在 $p = 1/4$ 时的熵约为 0.8113 bit, 小于公平情形的 1 bit。

练习 6.3. 证明独立随机变量 X, Y 满足 $H(X, Y) = H(X) + H(Y)$ 。

练习 6.3 解析

设 X, Y 离散独立, 边缘分布已归一化, 并假定 $H(X), H(Y) < \infty$, 从而下列求和可合法拆分。由 $p(x, y) = p_X(x)p_Y(y)$,

$$\begin{aligned} H(X, Y) &= -\sum_{x,y} p_X(x)p_Y(y) \log(p_X(x)p_Y(y)) \\ &= -\sum_x p_X(x) \log p_X(x) \sum_y p_Y(y) \\ &\quad - \sum_y p_Y(y) \log p_Y(y) \sum_x p_X(x) \\ &= H(X) + H(Y). \end{aligned}$$

零质量项按 $0 \log 0 = 0$ 处理; 没有独立性时只能使用 $H(X, Y) = H(X) + H(Y | X)$ 。

练习 6.4. 若 $Y = X$, 证明 $H(X | Y) = 0$ 并求 $H(X, Y)$ 。

练习 6.4 解析

设 X 离散且 $H(X) < \infty$, 并令 $Y = X$. 联合支持仅在对角线 $\{(x, x)\}$ 上; 对每个 $p_Y(y) > 0$ 的条件值,

$$\begin{aligned} P(X = x | Y = y) &= \mathbf{1}\{x = y\}, \\ H(X | Y = y) &= -1 \log 1 - \sum_{x \neq y} 0 \log 0 = 0, \\ H(X | Y) &= \sum_y p_Y(y) H(X | Y = y) = 0, \\ H(X, Y) &= H(Y) + H(X | Y) = H(X). \end{aligned}$$

所以当 $Y = X$ 时, 观测 Y 完全消除了 X 的不确定性, 并有 $H(X, Y) = H(X)$.

练习 6.5. 设 X, Y 是公平比特, 且 $P(X = Y) = 3/4$, 联合分布对交换和 0/1 翻转对称. 求 $H(X | Y)$.

练习 6.5 解析

联合支持为 $\{0, 1\}^2$. 交换与翻转对称性连同 $P(X = Y) = 3/4$ 给出

$$\begin{aligned} p(0, 0) &= p(1, 1) = \frac{3}{8}, & p(0, 1) &= p(1, 0) = \frac{1}{8}, \\ P(X = Y | Y = y) &= \frac{3}{4}, & P(X \neq Y | Y = y) &= \frac{1}{4}, \\ H(X | Y = y) &= H_b(1/4), & y \in \{0, 1\}, \\ H(X | Y) &= \frac{1}{2} H_b(1/4) + \frac{1}{2} H_b(1/4) \approx 0.8113 \text{ bit}. \end{aligned}$$

因此给定任一 Y 值后的翻转概率都是 $1/4$, 条件熵为 $H_b(1/4) \approx 0.8113 \text{ bit}$.

练习 6.6. 用链式法则把 $H(X_1, X_2, X_3)$ 展开, 并说明变量独立时如何化简.

练习 6.6 解析

假定三个离散变量的相关熵均有限. 逐次应用链式法则,

$$\begin{aligned} H(X_1, X_2, X_3) &= H(X_1) + H(X_2, X_3 | X_1) \\ &= H(X_1) + H(X_2 | X_1) + H(X_3 | X_1, X_2). \end{aligned}$$

若 X_1, X_2, X_3 相互独立, 则

$$H(X_2 | X_1) = H(X_2), \quad H(X_3 | X_1, X_2) = H(X_3),$$

故联合熵化为 $\sum_{i=1}^3 H(X_i)$; 仅有两两独立不足以保证最后一个条件等式.

练习 6.7. 对 $P = (1/2, 1/2)$ 、 $Q = (3/4, 1/4)$, 计算 $D(P \| Q)$ 与 $D(Q \| P)$.

练习 6.7 解析

P, Q 在二点支持上均严格为正, 故两个 KL 有限。以自然对数计,

$$\begin{aligned} D_{\text{KL}}(P\|Q) &= \frac{1}{2} \log \frac{1/2}{3/4} + \frac{1}{2} \log \frac{1/2}{1/4} \\ &= \frac{1}{2} \log \frac{4}{3} \approx 0.1438, \\ D_{\text{KL}}(Q\|P) &= \frac{3}{4} \log \frac{3/4}{1/2} + \frac{1}{4} \log \frac{1/4}{1/2} \\ &= \frac{3}{4} \log \frac{3}{2} + \frac{1}{4} \log \frac{1}{2} \approx 0.1308. \end{aligned}$$

期望权重随方向改变, 所以两者不同。

练习 6.8. 证明经验分布上的平均负对数似然就是经验分布与模型分布的交叉熵。

练习 6.8 解析

设 $n \geq 1$, 经验分布支持为样本中出现的有限集合, 并要求 $Q_{\theta}(x_i) > 0$ 以得到有限目标。定义

$$\begin{aligned} \hat{P}_n(x) &= \frac{1}{n} \sum_{i=1}^n \mathbf{1}\{x_i = x\}, \\ H(\hat{P}_n, Q_{\theta}) &= - \sum_x \hat{P}_n(x) \log Q_{\theta}(x) \\ &= - \frac{1}{n} \sum_x \sum_{i=1}^n \mathbf{1}\{x_i = x\} \log Q_{\theta}(x) \\ &= - \frac{1}{n} \sum_{i=1}^n \log Q_{\theta}(x_i). \end{aligned}$$

若某个已观察 x_i 满足 $Q_{\theta}(x_i) = 0$, 两侧都按扩展实数取 $+\infty$ 。

练习 6.9. 若 P 在某点概率为正而 Q 在该点概率为零, 解释交叉熵和 KL 为何为无穷。

练习 6.9 解析

设存在支持点 x_0 满足 $P(x_0) > 0$ 而 $Q(x_0) = 0$ 。该点破坏 $P \ll Q$, 并产生

$$\begin{aligned} -P(x_0) \log Q(x_0) &= -P(x_0)(-\infty) = +\infty, \\ P(x_0) \log \frac{P(x_0)}{Q(x_0)} &= P(x_0) \log \frac{P(x_0)}{0} = +\infty, \\ H(P, Q) &= +\infty, \quad D_{\text{KL}}(P\|Q) = +\infty. \end{aligned}$$

这不是 $0 \log 0 = 0$ 的情形, 因为乘在对数前的权重 $P(x_0)$ 严格为正; 概率平滑会改变模型本身。

练习 6.10. 若 $Y = X$ 且 X 为公平比特, 求 $I(X; Y)$; 若 Y 与 X 独立又是多少?

练习 6.10 解析

X 是支持 $\{0, 1\}$ 上的公平比特, 故 $H(X) = 1 \text{ bit}$ 且所有熵有限。用 $I(X; Y) = H(X) - H(X | Y)$,

$$Y = X \implies H(X | Y) = 0 \implies I(X; Y) = 1 - 0 = 1 \text{ bit},$$

$$Y \perp X \implies H(X | Y) = H(X) = 1 \implies I(X; Y) = 1 - 1 = 0.$$

两种情形分别对应完全确定与不减少任何平均不确定性。

练习 6.11. 证明 $I(X; Y) = I(Y; X)$, 要求从联合分布的求和式展开。

练习 6.11 解析

设 X, Y 离散且互信息求和良定义; 在 $p(x, y) = 0$ 处采用 $0 \log 0 = 0$, 在正联合质量处边缘也必为正。直接交换有限或绝对收敛求和次序:

$$\begin{aligned} I(X; Y) &= \sum_{x,y} p(x, y) \log \frac{p(x, y)}{p_X(x)p_Y(y)} \\ &= \sum_{y,x} p(y, x) \log \frac{p(y, x)}{p_Y(y)p_X(x)} \\ &= I(Y; X). \end{aligned}$$

这里 $p(y, x)$ 表示同一联合质量换序书写; 对称性不推广到任意 $D_{\text{KL}}(P \| Q)$ 。

练习 6.12. 设 $X \rightarrow Y \rightarrow Z$ 构成马尔可夫链。用“ Z 只通过 Y 获得 X 信息”的含义解释数据处理不等式 $I(X; Z) \leq I(X; Y)$ 。

练习 6.12 解析

马尔可夫链 $X \rightarrow Y \rightarrow Z$ 表示 $p(z | x, y) = p(z | y)$, 即 $X \perp Z | Y$ 。假定相关互信息有限, 则链式法则给出

$$I(X; Y, Z) = I(X; Y) + I(X; Z | Y) = I(X; Y),$$

$$I(X; Y, Z) = I(X; Z) + I(X; Y | Z),$$

$$I(X; Y) - I(X; Z) = I(X; Y | Z) \geq 0.$$

因此 $I(X; Z) \leq I(X; Y)$; 经过从 Y 到 Z 的随机通道只能保留或丢失关于 X 的信息。

练习 6.13. 父节点有正负样本各 4 个。某特征把数据分成两个子节点, 分别为 $(3+, 1-)$ 与 $(1+, 3-)$ 。求以 2 为底的信息增益。

练习 6.13 解析

父节点含 8 个样本且正负各半；两个非空子节点各含 4 个样本，经验概率均有有限支持。以 2 为底，

$$\begin{aligned} H(Y) &= H_b(1/2) = 1, \\ H(Y | A) &= \frac{4}{8}H_b(3/4) + \frac{4}{8}H_b(1/4) = H_b(1/4) \\ &= -\frac{1}{4}\log_2 \frac{1}{4} - \frac{3}{4}\log_2 \frac{3}{4} \approx 0.8113, \\ \text{Gain}(A) &= H(Y) - H(Y | A) \approx 1 - 0.8113 = 0.1887 \text{ bit}. \end{aligned}$$

所以该划分的信息增益约为 0.1887 bit。

练习 6.14. 说明“样本编号”特征为何可能有最大信息增益，却不适合作为泛化划分。

练习 6.14 解析

设训练集有 n 个互异编号，按编号划分后每个非空子节点仅含一个样本，故其经验标签分布是点质量：

$$\begin{aligned} H(Y | \text{ID} = i) &= 0, \quad i = 1, \dots, n, \\ H(Y | \text{ID}) &= \sum_{i=1}^n \frac{1}{n} 0 = 0, \\ \text{Gain}(\text{ID}) &= H(Y) - H(Y | \text{ID}) = H(Y). \end{aligned}$$

该最大训练增益来自逐样本记忆；新编号没有可复用条件分布，因此不能据此保证泛化。增益比、最小叶规模和验证集只能作为额外控制。

练习 6.15. 某特征在所有样本上取值相同。求其信息增益、划分熵，并说明增益比如何处理。

练习 6.15 解析

特征 A 只有一个观测取值 a_0 且 $P_n(A = a_0) = 1$ ，因此划分支持退化为单点。于是

$$\begin{aligned} H_n(Y | A) &= 1 \cdot H_n(Y) = H_n(Y), \\ \text{Gain}(A) &= H_n(Y) - H_n(Y | A) = 0, \\ H_n(A) &= -1 \log_2 1 = 0, \\ \text{GainRatio}(A) &= \frac{0}{0} \text{ 未定义}. \end{aligned}$$

算法必须先检查 $H_n(A) > 0$ ；此处应排除该特征，而不是把未定义比值强行设成有效分数。

练习 6.16. 计算类别计数 (6, 3, 1) 的基尼不纯度，并与纯节点比较。

练习 6.16 解析

节点有 10 个样本，类别支持为三类，经验概率 $p = (0.6, 0.3, 0.1)$ 已归一化。计算

$$\begin{aligned} G(p) &= 1 - \sum_{k=1}^3 p_k^2 \\ &= 1 - (0.6^2 + 0.3^2 + 0.1^2) \\ &= 1 - (0.36 + 0.09 + 0.01) = 0.54, \\ G(1, 0, 0) &= 1 - 1^2 = 0. \end{aligned}$$

纯节点不纯度为零；0.54 也等于从该经验分布独立抽取两个标签时二者不同的概率。

练习 6.17. 父节点有 10 个样本，且父节点基尼指数为 $G_{\text{parent}} = 0.50$ 。候选划分产生大小分别为 4 和 6、基尼指数分别为 0.375 和 0.50 的两个子节点。求加权基尼指数与基尼下降。

练习 6.17 解析

两个子节点非空且大小之和为 $4 + 6 = 10$ ，对应权重为 $4/10$ 与 $6/10$ 且和为 1。因此

$$\begin{aligned} G_{\text{child}} &= \frac{4}{10}(0.375) + \frac{6}{10}(0.5) \\ &= 0.15 + 0.30 = 0.45, \\ \Delta G &= G_{\text{parent}} - G_{\text{child}} = 0.50 - 0.45 = 0.05. \end{aligned}$$

核验：对二分类节点有 $0 \leq G \leq 0.5$ ，这里 $G_{\text{child}} = 0.45$ 合法；同时 $\Delta G = 0.05 \geq 0$ ，说明该候选划分使不纯度下降。故加权基尼指数为 0.45，基尼下降为 0.05。

练习 6.18. 证明二分类基尼 $2p(1-p)$ 在 $p = 1/2$ 最大，并比较二元熵在端点和中心的行为。

练习 6.18 解析

定义域为概率闭区间 $p \in [0, 1]$ 。基尼函数在内部可微，且需连同端点检查：

$$\begin{aligned} G(p) &= 1 - p^2 - (1-p)^2 = 2p(1-p), \\ G'(p) &= 2 - 4p = 0 \iff p = \frac{1}{2}, \\ G''(p) &= -4 < 0, \quad G(0) = G(1) = 0, \quad G(1/2) = \frac{1}{2}. \end{aligned}$$

二元熵按 $0 \log 0 = 0$ 连续延拓后满足

$$H_b(0) = H_b(1) = 0, \quad H_b(1/2) = 1 \text{ bit},$$

也在中心最大，但尺度和曲率不同。

读前自检：本章结论与下一步。 信息论基础章末由“熵、KL 散度、交叉熵、互信息与基尼指数”落到“先核对绝对连续与归一化，再计算候选划分分数”；请把前者产出和后者输入逐项对齐，固定核对前者末项的输出类型能否作为后者首项的输入类型。

本章结论与下一步

核心结论：熵、KL 散度、交叉熵、互信息与基尼指数

关键依据：Jensen 证明 KL 非负，熵链式法则推出互信息恒等式

可执行自检：先核对绝对连续与归一化，再计算候选划分分数

适用边界：概率模型损失解释与决策树特征选择

下一步：进入第 7 章：凸优化与拉格朗日对偶；本章信息论准则将在第 15 章的决策树等处复用

1. 能否从联合分布推导熵的链式法则、互信息的熵差与 KL 形式，并说明独立时的化简？
 2. 能否在不交换方向的前提下完整复现 KL 非负证明及等号条件？
 3. 能否由计数表正确计算信息增益、增益比与加权基尼，并处理零分母？不能则回看节 6.2– 节 6.6。

第7章 凸优化与拉格朗日对偶

本章地图

核心问题：约束优化何时能由局部条件确认全局最优

可检验学习目标：

- 严格区分可行性、局部最优、全局最优、凸性与严格凸性；
- 从原问题逐步构造拉格朗日函数、对偶函数和对偶问题，证明弱对偶并说明强对偶条件；
- 能够写出并检验 KKT 条件，解释互补松弛对应的活动约束。

最短先修：需要向量、内积、正定矩阵、梯度、Hessian 和方向导数。有限加权 Jensen 不等式已在章 6 随用随教；本章从凸性定义重新建立并证明它。概率模型中的最大似然或最大后验问题可通过取负号改写为本章的最小化形式。

依赖路线：可行域 + 目标函数 → 优化问题；凸集 + 凸函数 → 局部最优等于全局最优；约束 → 拉格朗日函数 → 对偶函数 → 弱/强对偶 → KKT 与互补松弛。

完成标准与返回：资格条件或乘子符号不清楚时返回原问题与拉格朗日节

本章符号表

符号	取值	含义
$x \in \mathbb{R}^d$	决策向量	待优化变量
$f(x)$	$\mathbb{R}$	目标函数
$c_i(x), h_j(x)$	$\mathbb{R}$	不等式约束与等式约束函数
α_i, β_j	$\alpha_i \geq 0, \beta_j \in \mathbb{R}$	拉格朗日乘子
$L(x, \alpha, \beta)$	$\mathbb{R}$	拉格朗日函数
p^*, d^*	扩展实数	原问题与对偶问题最优值

读前自检：优化问题的基本形式。 约束优化标准形以决策 x 、目标 $f(x)$ 及 $c_i(x) \leq 0, h_j(x) = 0$ 为对象；请把“最大化 g 、约束 $a(x) \geq b$ ”分别改写为最小化 $-g$ 和 $b - a(x) \leq 0$ ，核对不等号方向统一。

7.1 优化问题、目标函数与约束

读前自检：目标函数。 凸优化与拉格朗日对偶中的目标函数把问题限定在“目标函数把每个可行决策映射为可比较的标量”；请把“目标函数把每个可行决策映射为可比较的标量”中的已声明对象代回凸优化与拉格朗日对偶中的目标函数的定义，检查是否得到统计学习中常由经验损失、正则项或负对数似然组成。

定义 7.1 (约束优化问题). 给定目标函数、决策变量及一组等式和不等式约束，在全部满足约束的决策中寻找目标值最小者，称为约束最小化问题；若目标与不等式函数凸、等式函数仿射，则称为凸优化问题。

本章采用约束最小化标准形式

$$\min_{x \in \mathbb{R}^d} f(x) \quad \text{s.t.} \quad c_i(x) \leq 0 \ (i = 1, \dots, m), \quad h_j(x) = 0 \ (j = 1, \dots, r).$$

最大化 g 可改写为最小化 $-g$ ，而 $a(x) \geq b$ 可改写为 $b - a(x) \leq 0$ 。符号方向必须在构造乘子前统一。目标函数把每个可行决策映射为可比较的标量。统计学习中常由经验损失、正则项或负对数似然组成。等式约束把解限制在低维集合上；不等式约束定义带边界的可行区域。约束函数的尺度不改变可行集，却会改变对应乘子的尺度。

读前自检：可行域。 在“任何不满足全部约束的点即使目标更小，也不能与可行最优点竞争”成立时处理凸优化与拉格朗日对偶中的可行域：请代入正文给出的取等边界检验 $\mathcal{C} = \{x : c_i(x) \leq 0, h_j(x) = 0\}$ ，并以不等号方向、边界取等和定义域彼此相容判定结果。

读前自检：局部最优与全局最优。 局部最优 x^* 只要求某邻域内 $f(x^*) \leq f(x)$ ，全局最优则要求该式对整个可行域成立；请用同一 x^* 逐项比较两个量词范围，并核对全局最优必为局部最优、反向一般不成立。

模型。 模型由决策变量、目标函数和约束族组成；同一预测任务选择不同正则项，会得到不同的优化模型。**学习策略。** 先统一最小化与“ ≤ 0 ”记号，再检查可行域非空、目标下界和约束资格，最后选择一阶或二阶算法。

7.2 可行域与局部/全局最优

可行域 $\mathcal{C} = \{x : c_i(x) \leq 0, h_j(x) = 0\}$ ；任何不满足全部约束的点即使目标更小，也不能与可行最优点竞争。可行点 x^* 是局部最优，若存在半径 $\delta > 0$ ，对 $\mathcal{C} \cap B(x^*, \delta)$ 中所有点有 $f(x^*) \leq f(x)$ ；若该关系对全部可行点成立，则为全局最优。

读前自检：凸集。 围绕凸优化与拉格朗日对偶中的凸集，先采用条件“集合 $\mathcal{C}$ 凸是指任意 $x, y \in \mathcal{C}$ 与 $t \in [0, 1]$ 满足 $tx + (1-t)y \in \mathcal{C}$ ”，再对 $\mathcal{C}$ 完成一项求导、代入或边界比较；最后验证凸集的任意交仍凸。

读前自检：凸函数。 凸优化与拉格朗日对偶中的凸函数中的“函数 $f : \mathcal{C} \rightarrow \mathbb{R}$ 在凸域上凸”决定可执行范围；请对 $f : \mathcal{C} \rightarrow \mathbb{R}$ 完成一项求导、代入或边界比较，结果须满足结果的形状、符号和取等条件与定义一致。

读前自检：严格凸函数。 把严格凸函数放在“函数 $f : \mathcal{C} \rightarrow \mathbb{R}$ 在凸域上凸”下考察：对 $f : \mathcal{C} \rightarrow \mathbb{R}$ 完成一项求导、代入或边界比较，并检查结果的形状、符号和取等条件与定义一致。

7.3 凸集与凸函数

集合 C 凸是指任意 $x, y \in C$ 与 $t \in [0, 1]$ 满足 $tx + (1-t)y \in C$ 。仿射子空间、半空间、范数球均为凸集；凸集的任意交仍凸。函数 $f: C \rightarrow \mathbb{R}$ 在凸域上凸，若

$$f(tx + (1-t)y) \leq tf(x) + (1-t)f(y).$$

若对 $x \neq y$ 和 $t \in (0, 1)$ 上式严格小于，则 f 严格凸。严格凸目标在凸可行域上至多有一个全局最优点，但最优点存在仍需另行保证。

阅读目标：逐步说明为何任意对偶可行值都不超过任意原可行值。

对象：任意原可行点 x 与乘子 $\alpha \geq 0, \beta$ 。

合法条件：不等式采用 $c_i(x) \leq 0$ 约定；等式约束满足 $h_j(x) = 0$ 。

第一步：先由可行性写 $L(x, \alpha, \beta) = f(x) + \sum_i \alpha_i c_i(x) + \sum_j \beta_j h_j(x) \leq f(x)$ 。

推导目标

由定义逐步推出弱对偶，明确每个不等号的条件。

推导准备

固定任意原可行 x 与任意 $\alpha \geq 0, \beta$ ；对偶函数定义为拉格朗日函数对 x 的下确界。

推导第1步：下确界不大于任一函数值，故 $g(\alpha, \beta) = \inf_z L(z, \alpha, \beta) \leq L(x, \alpha, \beta)$ 。

推导第2步：原可行性给出 $c_i(x) \leq 0, h_j(x) = 0$ ，对偶可行性给出 $\alpha_i \geq 0$ ，所以 $L(x, \alpha, \beta) \leq f(x)$ 。

推导第3步：先对全部对偶可行乘子取上确界，再对全部原可行 x 取下确界，保持方向得到 $d^* \leq p^*$ 。

读前自检：KKT 条件。 KKT 条件包含原可行、对偶可行、驻点与互补松弛；请对一个候选 (x^*, α^*, β^*) 逐项代入四组关系，核对凸目标/不等式与仿射等式下满足这些条件即可推出全局最优。

读前自检：定理 C 3。 定理 C.3 区分 KKT 的充分性、必要性与 Slater 作用；请核对“凸目标和不等式、仿射等式”使 KKT 点充分为全局最优，而从局部最优反推乘子还需约束资格，不能把两方向互换。

7.4 KKT 条件与互补松弛

先分清三个方向。

- 充分性：**若目标与不等式约束凸、等式约束仿射，则任何原 - 对偶可行且满足驻点与互补松弛的点都是全局最优；这一方向不需要 Slater 条件。

2. **必要性**: 从“局部最优”推出乘子和 KKT 条件, 需要线性无关、MFCQ、Slater 等适用的约束资格, 不能只凭凸性。
3. **Slater 的作用**: 对凸问题, 严格可行性保证强对偶; 在本章的可微有限维设定及最优值可达到等常见正则前提下, 它也保证最优点具有 KKT 乘子。

因此, 对可微约束问题, 若局部最优点满足相应约束资格, 则存在乘子使以下条件成立:

读前自检: 互补松弛条件。 互补松弛要求 $\alpha_i^* c_i(x^*) = 0$ 且 $\alpha_i^* \geq 0, c_i(x^*) \leq 0$; 请分别代入 $c_i(x^*) < 0$ 与 $\alpha_i^* > 0$, 核对前者推出 $\alpha_i^* = 0$ 、后者推出约束取等。

$\nabla_x L(x^*, \alpha^*, \beta^*) = 0$	驻点条件,
$c_i(x^*) \leq 0$	原可行性,
$h_j(x^*) = 0$	原可行性,
$\alpha_i^* \geq 0$	对偶可行性,
$\alpha_i^* c_i(x^*) = 0$	互补松弛.

在凸性与仿射等式前提下, 这些条件本身已经足以证明全局最优; Slater 用于反方向的必要性与强对偶, 不是该充分性证明的附加前提。若 $c_i(x^*) < 0$, 则必须 $\alpha_i^* = 0$; 若 $\alpha_i^* > 0$, 则约束必须活动, 即 $c_i(x^*) = 0$ 。乘子为零时约束可以活动也可以非活动。

阅读目标: 把驻点、可行性与互补松弛连成全局最优性证明。

对象: 凸目标、凸不等式、仿射等式及候选原 - 对偶变量 (x^*, α^*, β^*) 。

合法条件: x^* 原可行, (α^*, β^*) 对偶可行, 并满足驻点与互补松弛。

第一步: 先由凸性和驻点证明 x^* 是 $L(x, \alpha^*, \beta^*)$ 关于 x 的全局极小点。

推导目标

证明在目标与不等式约束凸、等式约束仿射时, 一组满足 KKT 条件的原 - 对偶变量给出全局最优解与零对偶间隙。

推导准备

采用 $c_i(x) \leq 0, \alpha_i \geq 0$ 的符号约定; x^* 原可行, (α^*, β^*) 对偶可行, 并满足驻点与互补松弛。固定乘子后, $L(x, \alpha^*, \beta^*)$ 关于 x 为可微凸函数。

推导第 1 步: 由驻点得到拉格朗日函数的全局极小。凸可微函数的一阶条件给出

$$\nabla_x L(x^*, \alpha^*, \beta^*) = 0 \implies x^* \in \arg \min_x L(x, \alpha^*, \beta^*).$$

因此 $g(\alpha^*, \beta^*) = L(x^*, \alpha^*, \beta^*)$ 。

推导第2步：用可行性与互补松弛消去约束项。 等式可行性使 $\beta_j^* h_j(x^*) = 0$ ，互补松弛使 $\alpha_i^* c_i(x^*) = 0$ ，于是

$$L(x^*, \alpha^*, \beta^*) = f(x^*).$$

推导第3步：夹逼原 – 对偶目标。 弱对偶对任意原、对偶可行点给出

$$g(\alpha^*, \beta^*) \leq d^* \leq p^* \leq f(x^*).$$

前两步已给出左右端相等，故链中各量相等； x^* 与 (α^*, β^*) 分别全局最优，且 $p^* - d^* = 0$ 。

推论 7.1 (零间隙证书) 若凸问题的一组原 – 对偶变量满足 KKT 条件，则其原目标等于对偶目标，因而二者均最优。

读前自检：证明：零间隙证书。 零间隙证书已由拉格朗日函数极小性、约束项消去和弱对偶夹逼得到 $g(\alpha^*, \beta^*) = f(x^*)$ ；请写出夹逼链并核对等号同时证明原 – 对偶最优与零间隙。

证明。 前述三级推导分别建立拉格朗日函数极小性、约束项消去和弱对偶夹逼，已经得到 $g(\alpha^*, \beta^*) = f(x^*)$ ，所以零间隙与原 – 对偶最优性成立。□

例题 7.1 (带非负约束的二次问题)。 分别求 $\min_x (x-2)^2$ 与 $\min_x (x+1)^2$ ，共同约束为 $x \geq 0$ ，并比较非活动与活动约束的 KKT 乘子。

例题 7.1 解答

读题翻译 对两个具有共同非负约束的一维凸二次问题分别求 KKT 解，并比较约束非活动与活动时的乘子。

已知与合法条件 可行域为 $[0, \infty)$ ，标准不等式写作 $-x \leq 0$ ；两个目标均凸且存在严格可行点，KKT 条件充分必要。

为什么想到这个方法 分别写出拉格朗日函数和 KKT 四类条件，按互补松弛求解；再与无约束极小点及边界单调性比较。

方法选择 对 f_1, f_2 各解一次驻点、原可行性、对偶可行性和互补条件，最后直接检查无约束候选是否落在 $[0, \infty)$ 内。

推导/计算 可行域为 $\mathcal{C} = [0, \infty)$ ，标准约束 $c(x) = -x \leq 0$ 满足 Slater 条件，例如 $x = 1$ 严格可行；两个目标均凸，因此 KKT 条件充分且必要。对 $f_1(x) = (x-2)^2$ ，

$$\begin{aligned} L_1(x, \alpha) &= (x-2)^2 - \alpha x, & \alpha &\geq 0, \\ 2(x-2) - \alpha &= 0, & x &\geq 0, & \alpha x &= 0, \\ (x_1^*, \alpha_1^*) &= (2, 0). \end{aligned}$$

对 $f_2(x) = (x+1)^2$,

$$L_2(x, \alpha) = (x+1)^2 - \alpha x,$$

$$2(x+1) - \alpha = 0, \quad x \geq 0, \quad \alpha \geq 0, \quad \alpha x = 0,$$

$$(x_2^*, \alpha_2^*) = (0, 2).$$

独立核验 f_1 的无约束极小点 $x = 2$ 可行, 故约束不改变它; f_2 的无约束极小点 $x = -1$ 不可行, 且 $f_2'(x) = 2(x+1) > 0$ 对 $x \geq 0$ 成立, 故边界 $x = 0$ 最优。直接比较与 KKT 解一致。

结论 第一问 $(x^*, \alpha^*) = (2, 0)$, 约束非活动; 第二问 $(x^*, \alpha^*) = (0, 2)$, 约束活动。

几何理解

几何解释。 凸集内任意两点之间的整条线段都留在集合中; 凸函数图像位于任意弦的下方。对凸问题, 沿最优点与任意候选点连线移动不会先上升后下降, 因此局部谷底不能隐藏另一个更低谷底。




图 7.1 凸集中任意两点的线段仍位于可行域内

用图 7.1 检验候选集合时, 不能只找一条留在集合内的线段; 定义要求任意 x_1, x_2 和任意 $t \in [0, 1]$ 都成立。要否定凸性, 只需给出一对端点及一个落到集合外的凸组合。

读前自检: 凸函数的一阶条件。 先锁定凸函数的一阶条件的条件“可微函数在开凸集上凸”: 对 x 完成一项求导、代入或边界比较, 所得结果应满足凸函数始终位于其切平面之上。

读前自检: 凸函数的二阶条件。 对凸函数的二阶条件, 条件“二次可微函数在开凸集上凸, 当且仅当 $\nabla^2 f(x) \geq 0$ 对所有 x 成立”不可省; 请对 $\nabla^2 f(x) \geq 0$ 完成一项求导、代入或边界比较, 再用若 f 可微且凸, C 凸作检查。

7.5 一阶与二阶凸性条件

可微函数在开凸集上凸，当且仅当

$$f(y) \geq f(x) + \nabla f(x)^T(y - x), \quad \forall x, y.$$

右侧是 x 处切平面；凸函数始终位于其切平面之上。二次可微函数在开凸集上凸，当且仅当 $\nabla^2 f(x) \geq 0$ 对所有 x 成立；若 Hessian 处处正定，则 f 严格凸。

定理 7.1 (凸问题的一阶最优条件) 若 f 可微且凸， C 凸，则 $x^* \in C$ 为全局最优点当且仅当 $\nabla f(x^*)^T(x - x^*) \geq 0$ 对所有 $x \in C$ 成立。

读前自检：证明：凸问题的一阶最优条件。 凸问题的一阶最优条件把问题限定在“若条件成立”；请补出 $f(x) \geq f(x^*) + \nabla f(x^*)^T(x - x^*) \geq f(x^*)$ 到下一关系的一步不等式或求导，检查是否得到单变量函数在 $t = 0$ 处右导数不能为负，因此得到所述内积非负。

证明。 若条件成立，凸函数一阶下界给出 $f(x) \geq f(x^*) + \nabla f(x^*)^T(x - x^*) \geq f(x^*)$ 。反之若 x^* 最优，对任意 $x \in C$ ，线段 $x^* + t(x - x^*)$ 可行；单变量函数在 $t = 0$ 处右导数不能为负，因此得到所述内积非负。 $\square$

7.6 Jensen 不等式

章 6 已在信息论首次使用前给出有限加权形式。这里把它放回凸函数主线并证明：若 f 凸， $\lambda_i \geq 0$ 且 $\sum_i \lambda_i = 1$ ，则

$$f\left(\sum_i \lambda_i x_i\right) \leq \sum_i \lambda_i f(x_i).$$

概率形式为 $f(\mathbb{E}X) \leq \mathbb{E}f(X)$ 。若 f 严格凸，等号要求 X 几乎处处为常数；对凹函数不等号方向反转。

读前自检：有限 Jensen 的归纳形式。 在“二点凸性定义可递推推出任意有限个点的加权 Jensen 不等式”成立时处理有限 Jensen 的归纳形式：请把“二点凸性定义可递推推出任意有限个点的加权 Jensen 不等式”中的已声明对象代回有限 Jensen 的归纳形式的定义，并以对象、条件与结论逐项闭合，且每项都可直接判为成立或失败判定结果。

引理 7.1 (有限 Jensen 的归纳形式) 二点凸性定义可递推推出任意有限个点的加权 Jensen 不等式。

读前自检：证明：有限 Jensen 的归纳形式。 有限 Jensen 的归纳形式所用的明确前提是“设最后一个权重为 $\lambda_n < 1$ ”；完成补出 z 到下一关系的一步不等式或求导后，核对先对 z, x_n 应用二点凸性，再对 z 的 $n - 1$ 点表达应用归纳假设，合并权重后得到结论。

证明. 设最后一个权重为 $\lambda_n < 1$, 把前 $n-1$ 项归一化为点 $z = (1 - \lambda_n)^{-1} \sum_{i < n} \lambda_i x_i$. 先对 z, x_n 应用二点凸性, 再对 z 的 $n-1$ 点表达应用归纳假设, 合并权重后得到结论. 边界权重为 0 或 1 时直接删去零权重点. $\square$

读前自检: 拉格朗日乘子法. 等式约束 $h(x) = 0$ 在候选最优点 x^* 处满足约束梯度正则; 请核对 $\nabla f(x^*) + J_h(x^*)^\top \beta = 0$, 并说明乘子 β 给出约束右端微扰下最优值的一阶敏感度.

7.7 拉格朗日乘子与拉格朗日函数

等式约束下, 若约束梯度正则, 最优值处目标梯度属于约束梯度张成空间. 乘子刻画放宽约束对最优值的一阶敏感度. 对标准形式定义

$$L(x, \alpha, \beta) = f(x) + \sum_{i=1}^m \alpha_i c_i(x) + \sum_{j=1}^r \beta_j h_j(x), \quad \alpha_i \geq 0.$$

不等式乘子非负保证对可行点有 $L(x, \alpha, \beta) \leq f(x)$; 等式项在可行点为零.

读前自检: 原问题. 原问题以 $f(x)$ 及 $c_i(x) \leq 0, h_j(x) = 0$ 定义可行域, 最优值记为 p^* ; 请先判断一个候选 x 是否可行, 再核对可行域为空时按约定 $p^* = +\infty$.

读前自检: 拉格朗日对偶性. 拉格朗日对偶性从 $L(x, \alpha, \beta) = f(x) + \sum_i \alpha_i c_i(x) + \sum_j \beta_j h_j(x)$ 出发; 请在 $\alpha \geq 0$ 下对 x 取下确界, 核对 $g(\alpha, \beta)$ 不超过任一原可行点的目标值.

读前自检: 原始问题. 原始问题采用最小化 $f(x)$ 并满足 $c_i(x) \leq 0, h_j(x) = 0$ 的标准形; 请把 $a(x) \geq b$ 改写成 $b - a(x) \leq 0$, 核对可行集合保持不变.

读前自检: 对偶函数. 从凸优化与拉格朗日对偶中的对偶函数的条件 “ $g(\alpha, \beta) = \inf_x L(x, \alpha, \beta)$.” 出发, 请把 $g(\alpha, \beta)$ 展开一次并检查其类型或边界; 所得量应符合无论原问题是否凸, g 总是凹函数.

读前自检: 对偶问题. 对偶问题在 $\alpha \geq 0, \beta$ 自由的域上最大化 $g(\alpha, \beta)$; 请对任一对偶可行乘子写出 $g(\alpha, \beta) \leq p^*$, 再核对最优值 d^* 仍是原最优值的下界.

读前自检: 对偶问题. 对偶问题 $\max_{\alpha \geq 0, \beta} g(\alpha, \beta)$ 区分不等式与等式乘子; 请逐项核对 α 的非负域、 β 的自由域, 并确认最大值记作 d^* .

7.8 原问题、对偶函数与对偶问题

原问题就是本章标准约束最小化, 其最优值记为 p^* . 可用广义拉格朗日函数把不可行点惩罚为 $+\infty$, 从而与原问题等价.

$$g(\alpha, \beta) = \inf_x L(x, \alpha, \beta).$$

它是关于乘子的仿射函数族的逐点下确界, 因此无论原问题是否凸, g 总是凹函数. 对偶问题为 $\max_{\alpha \geq 0, \beta} g(\alpha, \beta)$, 最优值记为 d^* . 对偶可行乘子给出原最优值的下界.

读前自检：弱对偶。 先锁定凸优化与拉格朗日对偶中的弱对偶的条件“对任何原可行 x 与对偶可行 (α, β) ”：代入正文给出的取等边界检验 $g(\alpha, \beta) \leq L(x, \alpha, \beta) \leq f(x)$ ，所得结果应满足不等号方向、边界取等和定义域彼此相容。

读前自检：原始问题和对偶问题的关系。 对原始问题和对偶问题的关系，条件“对任何原可行 x 与对偶可行 (α, β) ”不可省；请计算 $g(\alpha, \beta) \leq L(x, \alpha, \beta) \leq f(x)$ ，两边之差并判号，再用不等号方向、边界取等和定义域彼此相容作检查。

读前自检：定理 C 1。 定理 C 1 把问题限定在“对任何原可行 x 与对偶可行 (α, β) ”；请把 $g(\alpha, \beta) \leq L(x, \alpha, \beta) \leq f(x)$ ，用到的关键定义展开并完成下一步变形，检查是否得到变形没有增加前提且得到证明所述结论。

7.9 弱对偶、强对偶与 Slater 条件

对任何原可行 x 与对偶可行 (α, β) ，有

$$g(\alpha, \beta) \leq L(x, \alpha, \beta) \leq f(x),$$

故 $d^* \leq p^*$ 。差 $p^* - d^*$ 称为对偶间隙。

读前自检：推论 C 1。 在“若找到原可行与对偶可行解且目标值相等”成立时处理推论 C 1：请把“若找到原可行与对偶可行解且目标值相等”中的已声明对象代回推论 C 1 的定义，并以两者分别为各自问题的最优解判定结果。

读前自检：强对偶。 凸优化与拉格朗日对偶中的强对偶所用的明确前提是“强对偶指 $d^* = p^*$ ”；完成检查 $d^* = p^*$ 中每项的类型后完成等式变形后，核对它不是所有约束问题都自动具有的性质。

若找到原可行与对偶可行解且目标值相等，则两者分别为各自问题的最优解。强对偶指 $d^* = p^*$ ；它不是所有约束问题都自动具有的性质。考虑有限维凸问题：目标与不等式函数凸，等式约束写成 $Ax = b$ ，且各函数有共同定义域。若存在 $\tilde{x} \in \text{ri}(\text{dom } f_0 \cap \cdots \cap \text{dom } f_m)$ 满足 $f_i(\tilde{x}) < 0$ （所有非仿射不等式）并满足 $A\tilde{x} = b$ ，则称满足 Slater 条件；它保证强对偶，并在常见可达性条件下保证对偶最优乘子存在。

读前自检：定理 C 2。 定理 C.2 的强对偶证明用超平面分离原问题可达集合与更优不可达点；请列出集合非空、凸性及相对内部或闭包边界条件，并指出缺少这些条件时分离步骤不能直接调用。

定理 7.2 (凸问题的强对偶) 有限维凸目标与凸不等式约束、仿射等式约束在上述相对内部 Slater 条件下满足 $d^* = p^*$ 。

扩展讨论：分离定理在这里做什么

强对偶证明常用有限维凸集分离：主线只需把它理解为“把原问题可达集合与更优但不可达的点用超平面隔开”。严格版本必须说明集合非空、凸性以及相对内部或闭包边界条件；这些条件不作为本章计算 KKT 残差的前置要求。

候选原 – 对偶解的 KKT 残差检验：五步阅读

输入。 写出数据对象、固定参数与必须成立的条件。

初始化。 标明主状态、计数器和第一个合法状态。

核心更新。 只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。 写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。 列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 7.1: 候选原 – 对偶解的 KKT 残差检验

- 输入:** 候选 x, α, β ; 函数与梯度; 容差 $\varepsilon > 0$
输出: 最后合法残差、活动集、通过标志; c_{done} ; **status** 与诊断
- 1 若维数、容差、范数或接口非法, 返回空证书、 $c_{\text{done}} = 0$ 、**invalid_input** 及字段诊断
 - 2 初始化 $\mathcal{A} \leftarrow \emptyset, R \leftarrow 0, c_{\text{done}} \leftarrow 0$, 形成 $R_s^+ \leftarrow \|\nabla_x L(x, \alpha, \beta)\|$
 - 3 若驻点量非有限, 返回空证书、**numerical_failure** 及梯度诊断; 否则提交 $R_s \leftarrow R_s^+, R \leftarrow R_s$
 - 4 对 $i \leftarrow 1$ 至 m 执行
 - 5 形成第 i 项原可行、对偶可行与互补残差候选; 非有限时返回旧记录、**numerical_failure** 及 i 诊断
 - 6 原子追加第 i 项残差、更新 R 与活动集并增加 c_{done}
 - 7 结束
 - 8 对 $j \leftarrow 1$ 至 r 执行
 - 9 形成 $|h_j(x)|$; 非有限时返回旧记录、**numerical_failure** 及 j 诊断; 否则原子追加、更新 R 并增加 c_{done}
 - 10 结束
 - 11 令通过标志为 $\mathbf{1}\{R \leq \varepsilon\}$; 返回完整证书、**completed** 及主导残差/容差最终诊断

算法实现说明: 首次阅读只计算驻点、原可行、对偶可行、互补残差并取最大值; 实现时再检查非有限值、活动集和返回状态 完整 C1–C14 契约

收敛与非收敛说明。 KKT 残差检验只评价一个给定候选点, 不自行生成参数序列, 因此不讨论检验器自身的迭代收敛。返回“未通过”表示候选点没有满足容差, 不等同于某个外部优化器已经被证明不收敛。

概率解释

归一化约束、概率非负约束和对数似然目标都可纳入 KKT 框架。非负乘子可解释为某个概率边界对最优目标的影子价格, 但只有在模型和约束资格成立时该解释才可靠。

优化解释

优化解释。 对偶变量为原问题提供下界和敏感度; 原 – 对偶间隙给出可计算停止准则。KKT 把可行性、驻点和活动约束统一成方程与不等式系统, 是后续支持向量机、最大熵和约束统计估计的共同语言。

读前自检：复杂度分析：弱对偶、强对偶与 Slater 条件。 弱对偶、强对偶与 Slater 条件中的“采用稀疏或矩阵自由方法时，复杂度应以非零元和迭代次数参数化”决定可执行范围；请由 $(m+r)d$ 的总成本剥离一次迭代或一次样本因子，结果须满足稀疏结构、Schur 补和迭代法可降低实际成本。

复杂度分析

复杂度假设。 以下界假设函数值和梯度已经可用，稠密线性约束矩阵按全部 $(m+r)d$ 个系数访问，稠密 KKT 系统用直接分解求解；函数求值、自动微分以及稀疏预处理成本需另计。采用稀疏或矩阵自由方法时，复杂度应以非零元和迭代次数参数化。设 d 为变量维数， m, r 分别为不等式与等式个数。**核验复杂度：**KKT 残差检验只核验给定候选点，不更新模型参数。一次稠密线性约束核验为 $O((m+r)d)$ ，直接求解稠密 KKT 线性系统则通常为 $O((d+r)^3)$ 。**预测复杂度：**检验器不定义新样本预测映射。**存储复杂度：**保存稠密约束矩阵为 $O((m+r)d)$ ，残差与活动集额外为 $O(m+r)$ ；稀疏结构、Schur 补和迭代法可降低实际成本。

适用条件与局限性

适用条件：凸优化理论适用于凸目标、凸不等式和仿射等式；Slater 条件常用来保证强对偶，KKT 可作为充分必要证书。**局限性：**非凸问题中 KKT 通常只给必要候选，约束资格失败时最优点甚至可能没有乘子；严格凸只保证解至多唯一，不自动保证存在；数值算法还受条件数与尺度影响。

读前自检：常见错误与误用边界：弱对偶、强对偶与 Slater 条件。 把弱对偶、强对偶与 Slater 条件放在“边界框首项禁止把局部最优自动当全局最优而未检查凸性”下考察：把固定错误“把局部最优自动当全局最优而未检查凸性”中的对象、操作与结论按本节定义拆开，指出第一个不满足的定义条件，再把该处改为本节允许的写法，并检查改写后的运算或判断有定义，且不再触发“把局部最优自动当全局最优而未检查凸性”。

常见错误

典型误用包括：混淆最大化与最小化符号；把 $c_i \geq 0$ 直接配非负乘子却仍套用本章公式；认为 Hessian 在一个点半正定即可证明全域凸；把局部最优自动当全局最优而未检查凸性；把弱对偶误写成 $d^* \geq p^*$ ；漏掉 KKT 中的原可行、对偶可行或互补松弛。

易混淆概念对比

概念对比：凸集是域的几何性质，凸函数是函数沿线段的性质；严格凸关乎解唯一性，强凸还给出统一曲率下界。弱对偶总成立，强对偶需要附加条件。活动约束满足等号，正乘子必对应活动约束，但活动约束可有零乘子。KKT 是最优性系统，拉格朗日函数本身不是无条件的惩罚目标。

例题 7.2 (原点到半空间的 KKT 投影). 设 $a \in \mathbb{R}^d \setminus \{0\}$ 、 $b > 0$ 。求 $\min_x \frac{1}{2} \|x\|_2^2$ 且 $a^\top x \geq b$ 的 KKT 解。

例题 7.2 解答

读题翻译 求原点到半空间 $a^T x \geq b$ 的最小范数点, 同时给出 KKT 乘子和最优目标值。

已知与合法条件 $a \in \mathbb{R}^d \setminus \{0\}$, $b > 0$; 目标严格凸, 约束仿射且存在严格可行点, 因此 KKT 解存在并唯一确定原变量。

为什么想到这个方法 把约束写成 $b - a^T x \leq 0$, 由驻点条件与互补松弛解出候选; 再用 Cauchy-Schwarz 给出独立范数下界。

方法选择 写出拉格朗日函数与 KKT 条件, 由 $x = \alpha a$ 判定约束活动并求 α, x ; 最后验证候选达到所有可行点的范数下界。

推导/计算 目标严格凸, 标准约束 $c(x) = b - a^T x \leq 0$ 仿射, 可行域为非空闭半空间; 取足够大的 $x = ta$ 可严格可行, 故 Slater 成立。拉格朗日函数与 KKT 条件为

$$\begin{aligned} L(x, \alpha) &= \frac{1}{2} \|x\|_2^2 + \alpha(b - a^T x), \\ x - \alpha a &= 0, \quad b - a^T x \leq 0, \quad \alpha \geq 0, \\ \alpha(b - a^T x) &= 0. \end{aligned}$$

由 $x = \alpha a$ 且 $x = 0$ 不可行, 约束必须活动。因此

$$\begin{aligned} a^T x^\star &= b \implies \alpha^\star \|a\|_2^2 = b, \\ \alpha^\star &= \frac{b}{\|a\|_2^2} > 0, \quad x^\star = \frac{b a}{\|a\|_2^2}. \end{aligned}$$

目标严格凸而约束集凸, 故该 KKT 点是唯一全局最优解。

独立核验 任意可行 x 由 Cauchy-Schwarz 不等式满足 $b \leq a^T x \leq \|a\|_2 \|x\|_2$, 所以 $\|x\|_2 \geq b/\|a\|_2$; 候选 $x^\star = ba/\|a\|_2^2$ 恰好取等。

结论 $x^\star = ba/\|a\|_2^2$, $\alpha^\star = b/\|a\|_2^2$, 最优值为 $b^2/(2\|a\|_2^2)$; 该点是原点到半空间边界的正交投影。

本章共 18 道练习。每道题干后立即给出同号解析; 长解析可自然跨页, 续页标题保留题号。

练习 7.1. 把“最大化 $a^T x$, 满足 $Bx \geq b$ 与 $\mathbf{1}^T x = 1$ ”改写成本章标准形式。

练习 7.1 解析

设 $x \in \mathbb{R}^d$ 、 $a \in \mathbb{R}^d$ 、 $B \in \mathbb{R}^{m \times d}$ 、 $b \in \mathbb{R}^m$ 。原可行域与标准最小化形式为

$$\begin{aligned} \mathcal{C} &= \{x \in \mathbb{R}^d : Bx \geq b, \mathbf{1}^\top x = 1\}, \\ \min_{x \in \mathbb{R}^d} \quad & f(x) = -a^\top x, \\ \text{s.t.} \quad & c_i(x) = b_i - B_i x \leq 0, \quad i = 1, \dots, m, \\ & h(x) = \mathbf{1}^\top x - 1 = 0. \end{aligned}$$

若 $\mathcal{C} \neq \emptyset$ ，该改写保持可行点和最优解。各目标与约束均为仿射函数，所以任一满足 $\alpha_i \geq 0$ 的 KKT 点都足以证明全局最优；若要保证最优点必存在相应乘子，还需适当约束资格条件。

练习 7.2. 对岭回归 $\min_w \|Xw - y\|_2^2 + \lambda \|w\|_2^2$ ，指出变量、目标和参数，并说明是否有显式约束。

练习 7.2 解析

声明 $X \in \mathbb{R}^{n \times d}$ 、 $y \in \mathbb{R}^n$ 、变量 $w \in \mathbb{R}^d$ 与给定参数 $\lambda \geq 0$ 。目标和可行域为

$$\begin{aligned} f(w) &= \|Xw - y\|_2^2 + \lambda \|w\|_2^2, \\ \mathcal{C} &= \mathbb{R}^d \quad (\text{无显式约束}), \\ \nabla f(w) &= 2X^\top(Xw - y) + 2\lambda w, \\ \nabla^2 f(w) &= 2(X^\top X + \lambda I_d) \geq 0. \end{aligned}$$

无约束 KKT 退化为 $\nabla f(w^\star) = 0$ 。若 $\lambda > 0$ ，Hessian 正定，故唯一全局解存在；若 $\lambda = 0$ ，还需 X 满列秩才保证唯一。

练习 7.3. 求 $f(x) = x^3 - 3x$ 在区间 $[-2, 2]$ 上的全部局部与全局最优点。

练习 7.3 解析

目标 $f(x) = x^3 - 3x$ 连续，可行域 $\mathcal{C} = [-2, 2]$ 非空紧，故全局极值存在。内部驻点与单调性为

$$\begin{aligned} f'(x) &= 3(x^2 - 1) = 0 \iff x \in \{-1, 1\}, \\ f'(x) &> 0 \text{ 于 } (-2, -1) \cup (1, 2), \quad f'(x) < 0 \text{ 于 } (-1, 1). \end{aligned}$$

因此相对于可行域的局部分类及函数值为

x	-2	-1	1	2
局部类型	极小	极大	极小	极大
$f(x)$	-2	2	-2	2

故全局极小点为 $\{-2, 1\}$ ，全局极大点为 $\{-1, 2\}$ 。端点采用单侧可行邻域，也属于局部最优点。

练习 7.4. 证明若可行域非空且紧、目标连续，则全局最优解存在。

练习 7.4 解析

设可行域 $\mathcal{C} \subseteq \mathbb{R}^d$ 非空且紧，目标 $f: \mathcal{C} \rightarrow \mathbb{R}$ 连续。连续映射保持紧性，因此

$$\begin{aligned} \mathcal{C} \neq \emptyset, \mathcal{C} \text{紧} &\implies f(\mathcal{C}) \neq \emptyset, f(\mathcal{C}) \text{紧}, \\ m &:= \inf f(\mathcal{C}) \in f(\mathcal{C}), \\ \exists x^\star \in \mathcal{C} : & f(x^\star) = m = \min_{x \in \mathcal{C}} f(x). \end{aligned}$$

这就是 Weierstrass 定理；该存在性结论不需要凸性或 KKT。若可行域不闭或无界，下确界可能不被任何可行点取得。

练习 7.5. 证明半空间 $C = \{x: a^\top x \leq b\}$ 为凸集。

练习 7.5 解析

对象为半空间 $C = \{x \in \mathbb{R}^d: a^\top x \leq b\}$ 。任取 $x, y \in C$ 及 $t \in [0, 1]$,

$$\begin{aligned} a^\top (tx + (1-t)y) &= t a^\top x + (1-t)a^\top y \\ &\leq tb + (1-t)b = b, \\ tx + (1-t)y &\in C. \end{aligned}$$

故 C 为凸集。证明也覆盖 $a = 0$ 时的退化空集或全空间；本题只判断集合凸性，不涉及目标函数或 KKT。

练习 7.6. 判断集合 $\{x \in \mathbb{R}^2: \|x\|_2 = 1\}$ 是否凸，并给出反例点。

练习 7.6 解析

集合 $C = \{x \in \mathbb{R}^2: \|x\|_2 = 1\}$ 只有圆周而不含内部。取两个可行点及 $t = 1/2$,

$$\begin{aligned} x &= (1, 0)^\top \in C, \quad y = (-1, 0)^\top \in C, \\ \frac{1}{2}x + \frac{1}{2}y &= (0, 0)^\top, \\ \left\| \frac{1}{2}x + \frac{1}{2}y \right\|_2 &= 0 \neq 1. \end{aligned}$$

故 C 不凸。相反， $\|x\|_2 \leq 1$ 定义的闭球因三角不等式而凸；集合判定本身不适用 KKT。

练习 7.7. 用 Hessian 判断 $f(x) = \frac{1}{2}x^\top Qx + b^\top x$ 的凸性与严格凸性。

练习 7.7 解析

对象为 $f: \mathbb{R}^d \rightarrow \mathbb{R}$, $Q \in \mathbb{R}^{d \times d}$, $b \in \mathbb{R}^d$, 定义域是凸开集 $\mathbb{R}^d$ 。令 $S = (Q + Q^\top)/2$, 则

$$\begin{aligned} x^\top Q x &= x^\top S x, \\ \nabla f(x) &= Sx + b, \\ \nabla^2 f(x) &= S, \\ f \text{ 凸} &\iff S \geq 0, \quad f \text{ 严格凸} \iff S > 0. \end{aligned}$$

若 S 有负特征值, 沿对应方向二阶曲率为负, 故不凸。无约束最优化时 KKT 仅为 $Sx + b = 0$; 解的存在唯一性还取决于 S 与 b 。

练习 7.8. 证明 $f(x) = \log \sum_{k=1}^K e^{x_k}$ 是凸函数。

练习 7.8 解析

函数 $f: \mathbb{R}^K \rightarrow \mathbb{R}$ 处处有限。令 $Z = \sum_{j=1}^K e^{x_j} > 0$ 及 $p_k = e^{x_k}/Z$, 则 $\mathbf{p}$ 是有限支持上的概率向量。逐次求导,

$$\begin{aligned} \nabla f(x) &= \mathbf{p}, \\ \nabla^2 f(x) &= \text{diag}(\mathbf{p}) - \mathbf{p}\mathbf{p}^\top, \\ v^\top \nabla^2 f(x) v &= \sum_{k=1}^K p_k v_k^2 - \left(\sum_{k=1}^K p_k v_k \right)^2 \\ &= \text{Var}_{K \sim \mathbf{p}}(v_K) \geq 0. \end{aligned}$$

故 f 凸; 沿 $\mathbf{1}$ 方向有 $f(x + t\mathbf{1}) = f(x) + t$, 所以在整个 $\mathbb{R}^K$ 上不严格凸。本题是函数凸性证明, 无独立约束, KKT 不另行使用。

练习 7.9. 用 Jensen 证明正数 $x_1, \dots, x_n$ 的算术平均不小于几何平均。

练习 7.9 解析

给定 $n \geq 1$ 与 $x_i > 0$, 算术平均和对数均有定义。凹函数 $\log$ 的 Jensen 不等式给出

$$\begin{aligned} \log \left(\frac{1}{n} \sum_{i=1}^n x_i \right) &\geq \frac{1}{n} \sum_{i=1}^n \log x_i \\ &= \log \left(\prod_{i=1}^n x_i \right)^{1/n}, \\ \frac{1}{n} \sum_{i=1}^n x_i &\geq \left(\prod_{i=1}^n x_i \right)^{1/n}. \end{aligned}$$

指数函数严格递增, 故保持不等号; 因权重均为正, 等号当且仅当 $x_1 = \dots = x_n$ 。

练习 7.10. 设 $X > 0$ 且相关期望有限, 用 Jensen 比较 $E[1/X]$ 与 $1/E[X]$ 。

练习 7.10 解析

假定 $X > 0$ 几乎处处, $0 < E[X] < \infty$ 且 $E[1/X] < \infty$, 使两侧均为有限实数。函数 $\phi(x) = 1/x$ 在 $(0, \infty)$ 上满足

$$\begin{aligned}\phi''(x) &= \frac{2}{x^3} > 0, \\ \phi(E[X]) &\leq E[\phi(X)], \\ \frac{1}{E[X]} &\leq E\left[\frac{1}{X}\right].\end{aligned}$$

严格凸性的等号条件为 X 几乎处处为常数; 若允许 $E[1/X] = +\infty$, 不等式仍可按扩展实数成立, 但不再是有限量比较。

练习 7.11. 用乘子法求 $\min x_1^2 + x_2^2$, 满足 $x_1 + x_2 = 1$ 。

练习 7.11 解析

目标 $f(x) = x_1^2 + x_2^2$ 严格凸, 可行域 $\mathcal{C} = \{x \in \mathbb{R}^2 : x_1 + x_2 = 1\}$ 非空且由仿射等式定义。拉格朗日函数及等式 KKT 条件为

$$\begin{aligned}L(x, \beta) &= x_1^2 + x_2^2 + \beta(x_1 + x_2 - 1), \\ \nabla_x L &= \begin{bmatrix} 2x_1 + \beta \\ 2x_2 + \beta \end{bmatrix} = \mathbf{0}, \quad x_1 + x_2 = 1, \\ x_1 = x_2 &= -\frac{\beta}{2}, \quad x_1^\star = x_2^\star = \frac{1}{2}, \quad \beta^\star = -1, \\ f(x^\star) &= \frac{1}{4} + \frac{1}{4} = \frac{1}{2}.\end{aligned}$$

仿射等式与严格凸目标使该 KKT 点成为唯一全局最优解。

练习 7.12. 解释标准约束 $c(x) \leq 0$ 的乘子为何要求非负, 并说明若允许负值会破坏什么下界关系。

练习 7.12 解析

考虑原问题 $\min_{x \in \mathcal{C}} f(x)$, 标准不等式 $c_i(x) \leq 0$, 拉格朗日函数 $L(x, \alpha) = f(x) + \sum_i \alpha_i c_i(x)$ 。对任意原可行 x , 若 $\alpha_i \geq 0$, 则

$$\begin{aligned}\alpha_i c_i(x) &\leq 0, \\ L(x, \alpha) &\leq f(x), \\ g(\alpha) &:= \inf_z L(z, \alpha) \leq L(x, \alpha) \leq f(x), \\ g(\alpha) &\leq p^\star.\end{aligned}$$

这就是弱对偶下界。若允许某个 $\alpha_i < 0$, 则在 $c_i(x) < 0$ 处可能有 $\alpha_i c_i(x) > 0$, 中间的 $L(x, \alpha) \leq f(x)$ 失效, 故 KKT 的对偶可行性必须要求 $\alpha \geq 0$ 。

练习 7.13. 对无约束二次函数 $L(x, \alpha) = \frac{1}{2}x^2 + \alpha(1 - x)$, 求对偶函数。

练习 7.13 解析

对偶函数的定义域先取所有 $\alpha \in \mathbb{R}$, 并对无约束变量 $x \in \mathbb{R}$ 取下确界。因 x 方向二阶导数为 1, 极小点存在且唯一:

$$\begin{aligned} g(\alpha) &= \inf_{x \in \mathbb{R}} \left\{ \frac{1}{2}x^2 + \alpha(1 - x) \right\}, \\ \frac{\partial L}{\partial x} &= x - \alpha = 0 \implies x_\alpha = \alpha, \\ g(\alpha) &= L(\alpha, \alpha) = \frac{1}{2}\alpha^2 + \alpha(1 - \alpha) = \alpha - \frac{1}{2}\alpha^2, \\ g''(\alpha) &= -1 < 0. \end{aligned}$$

若 α 对应标准不等式 $1 - x \leq 0$, 对偶可行域还须限制为 $\alpha \geq 0$ 。

练习 7.14. 证明对偶函数作为仿射函数的逐点下确界是凹函数。

练习 7.14 解析

设乘子域 $\mathcal{D}$ 为凸集, 且对每个固定 x , $L(x, u)$ 关于 u 仿射。先取 $g(u), g(v)$ 有限的 $u, v \in \mathcal{D}$ 及 $t \in [0, 1]$,

$$\begin{aligned} L(x, tu + (1 - t)v) &= tL(x, u) + (1 - t)L(x, v) \\ &\geq tg(u) + (1 - t)g(v), \quad \forall x, \\ g(tu + (1 - t)v) &= \inf_x L(x, tu + (1 - t)v) \\ &\geq tg(u) + (1 - t)g(v). \end{aligned}$$

故 g 在 $\mathcal{D}$ 上凹; 若某端值为 $-\infty$, 扩展实数意义下的不等式平凡成立。该结论不要求原问题凸, 但把 g 用作有效下界仍需乘子满足对偶可行性。

练习 7.15. 若某对偶可行点给出下界 7, 某原可行点目标为 9, 可以对最优值和对偶间隙作何判断?

练习 7.15 解析

设问题为最小化, 已知一个对偶可行点的对偶值 $g(\alpha) = 7$ 及一个原可行点的目标值 $f(x) = 9$ 。弱对偶给出

$$\begin{aligned} 7 = g(\alpha) &\leq d^* \leq p^* \leq f(x) = 9, \\ p^* &\in [7, 9], \\ f(x) - g(\alpha) &= 9 - 7 = 2, \\ 0 &\leq p^* - d^* \leq 2. \end{aligned}$$

没有强对偶或 KKT 证书时, 不能断言任一给定可行点最优; 只有上下界相等才直接证明最优。

练习 7.16. 检查问题 $\min_x x^2$, 满足 $x \leq 1$ 是否满足 Slater 条件。

练习 7.16 解析

目标 $f(x) = x^2$ 凸, 标准约束 $c(x) = x - 1 \leq 0$ 仿射, 可行域 $\mathcal{C} = (-\infty, 1]$ 非空。取 $\tilde{x} = 0$,

$$c(\tilde{x}) = 0 - 1 = -1 < 0,$$

$$\exists \tilde{x} : c(\tilde{x}) < 0 \implies \text{Slater 条件成立},$$

$$x^\star = 0, \quad c(x^\star) = -1 < 0, \quad \alpha^\star = 0.$$

因此该凸问题强对偶, KKT 条件必要且充分。严格可行点只用于资格条件, 不必预先等于最优点; 本例恰好相同。

练习 7.17. 求 $\min_x \frac{1}{2}x^2$, 满足 $x \geq 1$ 的 KKT 解与最优值。

练习 7.17 解析

目标 $f(x) = \frac{1}{2}x^2$ 凸, 约束 $c(x) = 1 - x \leq 0$ 定义可行域 $[1, \infty)$; 取 $x = 2$ 严格可行, 故 Slater 成立。完整 KKT 系统为

$$L(x, \alpha) = \frac{1}{2}x^2 + \alpha(1 - x),$$

$$\text{驻点: } x - \alpha = 0,$$

$$\text{原可行: } 1 - x \leq 0,$$

$$\text{对偶可行: } \alpha \geq 0,$$

$$\text{互补松弛: } \alpha(1 - x) = 0.$$

若 $\alpha = 0$ 则驻点给 $x = 0$, 违反原可行性; 故约束活动:

$$x^\star = 1, \quad \alpha^\star = 1, \quad f(x^\star) = \frac{1}{2}.$$

凸性与 Slater 条件使该 KKT 点为全局最优点。

练习 7.18. 在 KKT 点处若 $c_i(x^\star) < 0$, 证明 $\alpha_i^\star = 0$; 其逆命题是否成立?

练习 7.18 解析

在满足 KKT 的点 $(x^\star, \alpha^\star)$, 原可行、对偶可行及互补松弛给出

$$c_i(x^\star) \leq 0, \quad \alpha_i^\star \geq 0,$$

$$\alpha_i^\star c_i(x^\star) = 0,$$

$$c_i(x^\star) < 0 \implies \alpha_i^\star = 0.$$

逆命题不成立。反例取凸问题 $\min_x x^2$, 满足 $x \geq 0$, 即 $c(x) = -x \leq 0$ 。其 KKT 解为

$$x^\star = 0, \quad \alpha^\star = 0, \quad c(x^\star) = 0,$$

因为驻点 $2x - \alpha = 0$ 成立。乘子为零但约束恰好活动。

读前自检：本章结论与下一步。 凸优化与拉格朗日对偶章末由“目标、可行域、凸性、乘子与对偶”落到“统一约束方向，检查原/对偶可行、驻点和互补松弛”；请把前者产出和后者输入逐项对齐，固定核对前者末项的输出类型能否作为后者首项的输入类型。

本章结论与下一步

核心结论： 目标、可行域、凸性、乘子与对偶

关键依据： 从拉格朗日下确界推出弱对偶，并在资格条件下使用 KKT

可执行自检： 统一约束方向，检查原/对偶可行、驻点和互补松弛

适用边界： 证明候选解全局最优或构造可核验下界

下一步： 进入章8的数值求解，并保留条件证书

1. 能否把任意方向的不等式统一成 $c_i(x) \leq 0$ 并正确规定乘子符号？
2. 能否用线段定义、一阶下界和 Hessian 三种方式检验适当对象的凸性？
3. 能否逐行证明弱对偶并说明 Slater 条件中的严格可行含义？
4. 能否对一个候选解完整检查五类 KKT 条件并解释活动约束？未通过时依次回看节 7.1、7.3—7.6、7.8 和 7.9。

读前自检：本章地图：数值优化方法。 数值优化方法章地图把“从下降方向直达线搜索、Newton 与拟 Newton 方法”作为主线；请为其中首条箭头补出必要条件，并检查终点仍落在本章声明的输出域。

第 8 章 数值优化方法

本章地图

核心问题：怎样在有限计算中稳定逼近驻点并区分各种终止原因

可检验学习目标：

- 能够从局部模型推导梯度下降、牛顿法及拟牛顿方向，明确步长与下降条件；
- 掌握 Armijo 回溯、停止判据、DFP/BFGS 更新与坐标下降的完整伪代码；
- 能够比较收敛速度、单步成本、存储成本和适用条件，并为改进迭代尺度法准备凸优化基础。

最短先修：需要梯度、Hessian、Taylor 展开、正定矩阵、范数、凸性、强凸性和线性方程组求解。实现中只应解 $Hp = -g$ ，不应显式形成 H^{-1} 。

依赖路线：梯度 → 下降方向 → 步长搜索 → 梯度下降；二阶 Taylor 模型 → 牛顿方向 → 拟牛顿割线条件 → DFP/BFGS；可分结构 → 坐标下降；指数族凸目标 → 改进迭代尺度更新。

完成标准与返回：方向不下降或线搜索无可行步时返回相应前提而非宣称收敛

本章符号表

符号	取值	含义
x_k, g_k, H_k	向量、向量、矩阵	第 k 次迭代点、梯度与 Hessian
p_k, α_k	向量、正数	搜索方向与步长
s_k, y_k	向量	$x_{k+1} - x_k$ 与 $g_{k+1} - g_k$
B_k, G_k	正定矩阵	Hessian 与逆 Hessian 近似
ε	正数	停止容差
c	$(0, 1)$	Armijo 充分下降常数
ρ	$(0, 1)$	回溯步长缩减因子，拒绝后令 $\alpha \leftarrow \rho\alpha$

读前自检：梯度下降与步长。 梯度下降与步长依赖“在可微函数的当前点 x ，若向量 p 满足 $\nabla f(x)^\top p < 0$ ”；请据此对 x 完成一项求导、代入或边界比较，并直接核对由 Cauchy-Schwarz 不等式，它在 $d = -g_k/\|g_k\|$ 处最小。

8.1 梯度下降与步长

定义 8.1 (下降方向). 在可微函数的当前点 x ，若向量 p 满足 $\nabla f(x)^\top p < 0$ ，则称 p 为该点的下降方向。由方向导数定义，存在足够小的正步长使 $f(x + \alpha p) < f(x)$ 。

在点 x_k 处，单位方向 d 的一阶变化率为 $\nabla f(x_k)^\top d$ 。由 Cauchy-Schwarz 不等式，它在 $d = -g_k/\|g_k\|$ 处最小，因此负梯度是欧氏范数下的最陡下降方向。基本更新为

$$x_{k+1} = x_k - \alpha_k g_k,$$

其中步长过大可能越过低谷并发散, 过小则使进展缓慢。

定理 8.1 (光滑函数的下降引理) 若梯度 L -Lipschitz, 则

$$f(y) \leq f(x) + \nabla f(x)^T(y - x) + \frac{L}{2}\|y - x\|^2.$$

取 $y = x - \alpha \nabla f(x)$ 且 $0 < \alpha < 2/L$, 只要梯度非零就有目标下降。

读前自检：证明：光滑函数的下降引理。 光滑函数的下降引理以“再取 $d = -\alpha \nabla f(x)$ ”为约束；请把 $f(x - \alpha \nabla f(x)) - f(x) \leq -\alpha(1 - L\alpha/2)\|\nabla f(x)\|^2$. 用到的关键定义展开并完成下一步变形，并确认目标下降。

证明. 记 $d = y - x$ 并令 $\phi(t) = f(x + td)$ 。微积分基本定理给出

$$f(y) - f(x) = \int_0^1 \nabla f(x + td)^T d \, dt.$$

减去 $\nabla f(x)^T d$ 后, 由 Cauchy-Schwarz 与梯度的 L -Lipschitz 性,

$$\begin{aligned} f(y) - f(x) - \nabla f(x)^T d &= \int_0^1 [\nabla f(x + td) - \nabla f(x)]^T d \, dt \\ &\leq \int_0^1 \|\nabla f(x + td) - \nabla f(x)\| \|d\| \, dt \\ &\leq \int_0^1 Lt \|d\|^2 \, dt = \frac{L}{2} \|d\|^2. \end{aligned}$$

这就是所需二次上界。再取 $d = -\alpha \nabla f(x)$, 得到

$$f(x - \alpha \nabla f(x)) - f(x) \leq -\alpha(1 - L\alpha/2)\|\nabla f(x)\|^2.$$

当 $0 < \alpha < 2/L$ 且梯度非零时, 右端严格为负, 故目标下降。 □

8.2 线搜索、停止条件与收敛判据

给定下降方向 p_k , 精确线搜索最小化 $\phi(\alpha) = f(x_k + \alpha p_k)$; 实际常用回溯 Armijo 条件

$$f(x_k + \alpha p_k) \leq f(x_k) + c\alpha g_k^T p_k, \quad 0 < c < 1.$$

它要求实际下降至少达到线性预测的一定比例。这里 c 只控制充分下降; 另取 $0 < \rho < 1$ 作为回溯缩减因子, 每次拒绝候选步长后令 $\alpha \leftarrow \rho\alpha$, 两者不可混用。

读前自检：梯度下降法。 梯度下降从初值 x_0 按负梯度方向更新; 请写出 $x_{t+1} = x_t - \eta_t \nabla f(x_t)$, 核对每一步状态仍与 x_t 同维, 并说明梯度范数达到停止容差时结束。

读前自检：梯度下降法。 梯度下降法的状态是当前点 x_t 及目标/梯度诊断；请对给定步长 η_t 完成一轮 $x_t \mapsto x_{t+1}$ ，比较更新前后目标值，并按既定容差判断提交或继续，并核对候选按既定门槛提交或继续。

读前自检：梯度下降法。 梯度下降轨迹同时依赖初值、变量尺度与步长策略；请把同一 $\nabla f(x_t)$ 分别代入两个正步长做一次更新，对照位移范数并核对停止量也须在同一尺度下比较。

梯度下降从初始点开始，反复选择负梯度方向与步长，直到满足停止条件。初始点、尺度和步长策略共同决定迭代轨迹。常用判据包括 $\|g_k\| \leq \varepsilon_g$ 、 $\|x_{k+1} - x_k\| \leq \varepsilon_x(1 + \|x_k\|)$ 、 $|f_{k+1} - f_k| \leq \varepsilon_f(1 + |f_k|)$ 与最大迭代次数。单一“变化小”也可能由步长失败造成，宜联合使用。

模型。 每轮以局部一阶模型预测下降，线搜索用真实目标值校验模型是否可信。 **学习策略。** 方向负责“往哪里走”，线搜索负责“走多远”；相对容差与最大迭代次数共同避免尺度依赖和无休止计算。

阅读目标： 由二阶局部模型得到牛顿方程，并判断该方向何时下降。

对象： 当前梯度 g_k 、Hessian H_k 与步长方向 p 。

合法条件： H_k 对称正定，因此可逆且二次模型严格凸。

第一步： 先对 $m_k(p) = f(x_k) + g_k^T p + \frac{1}{2} p^T H_k p$ 关于 p 求梯度并令零。

推导目标

由二阶 Taylor 模型推导牛顿方向，并证明正定 Hessian 下它是下降方向。

推导准备

在当前点计算 g_k, H_k ，假设 H_k 对称正定，从而线性方程组有唯一解。

推导第1步： 对局部模型关于 p 求梯度，得到 $\nabla_p m_k(p) = g_k + H_k p$ 。

推导第2步： 令模型梯度为零，解线性系统 $H_k p_k = -g_k$ 。正定性保证这是模型的唯一极小点。

推导第3步： 若 $g_k \neq 0$ ，则 $g_k^T p_k = -p_k^T H_k p_k < 0$ ，所以 p_k 是原目标的一阶下降方向；再用线搜索控制局部模型在远离最优点时的误差。

读前自检：二次函数的一步收敛。 正定二次函数 $f(x) = \frac{1}{2} x^T H x - b^T x$ 满足 $\nabla f = Hx - b$ ；请代入 Newton 步 $-H^{-1} \nabla f(x)$ ，核对新点恰为 $H^{-1}b$ 且梯度为零。

推论 8.1 (二次函数的一步收敛) 对正定二次函数 $f(x) = \frac{1}{2} x^T H x - b^T x + c$ ，精确牛顿法从任意初始点一步到达唯一最优点 $H^{-1}b$ 。

读前自检：证明：二次函数的一步收敛。 二次函数的一步收敛所用的明确前提是“梯度为 $Hx - b$ ，Hessian 恒为 H ”；完成把 $p = H^{-1}b - x$ 用到的关键定义展开并完成下一步变形后，核对牛顿更新解 $Hp = -(Hx - b)$ ，所以 $p = H^{-1}b - x$ ，全步后 $x + p = H^{-1}b$ 。

证明. 梯度为 $Hx - b$, Hessian 恒为 H 。牛顿更新解 $Hp = -(Hx - b)$, 所以 $p = H^{-1}b - x$, 全步后 $x + p = H^{-1}b$ 。正定性保证该驻点是唯一全局最优解。□

例题 8.1 (正定二次函数的一步 Newton 更新). 对 $f(x_1, x_2) = 2x_1^2 + x_2^2 - 2x_1 - 4x_2$, 从 $(0, 0)$ 执行一个全步 Newton 更新。

例题 8.1 解答

读题翻译 从零点解一次全步 Newton 方向方程, 并判断新点是否已经是该正定二次函数的唯一全局极小点。

已知与合法条件 f 定义在 $\mathbb{R}^2$ 上, 初值 $x^{(0)} = (0, 0)^T$; 其 Hessian 为常矩阵, 若正定则 Newton 方向唯一且全步更新适用。

为什么想到这个方法 先求梯度与常 Hessian, 解 $Hp_0 = -\nabla f(x^{(0)})$ 并作全步更新; 再用新点梯度和配方作两条独立核验。

方法选择 计算 ∇f 与 H , 由方向方程得到 $x^{(1)}$; 随后检查 $\nabla f(x^{(1)}) = 0$, 并把 f 配方以确认全局最优性和最小值。

推导/计算 目标域为 $\mathbb{R}^2$, Hessian 正定, 故牛顿方程有唯一解且全步适用:

$$\begin{aligned} g(x) &= \begin{bmatrix} 4x_1 - 2 \\ 2x_2 - 4 \end{bmatrix}, & H &= \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix} > 0, \\ Hp_0 &= -g(0, 0) = \begin{bmatrix} 2 \\ 4 \end{bmatrix}, & p_0 &= \begin{bmatrix} 1/2 \\ 2 \end{bmatrix}, \\ x_1 &= x_0 + p_0 = \begin{bmatrix} 1/2 \\ 2 \end{bmatrix}, & g(x_1) &= 0. \end{aligned}$$

独立核验 H 的两个特征值为 4, 2, 均为正; 同时 $g(x^{(1)}) = 0$ 。独立配方

$$f(x) = 2(x_1 - 1/2)^2 + (x_2 - 2)^2 - 9/2$$

给出同一极小点及最小值, 因此驻点与全局最优性相互核对。

结论 一次全步 Newton 更新得到 $x^{(1)} = (1/2, 2)^T$; 它是唯一全局极小点, 且 $f_{\min} = -9/2$ 。

读前自检: 拟牛顿法。 拟牛顿法用正定 G_k 近似逆 Hessian; 请核对方向 $p_k = -G_k \nabla f(x_k)$ 与梯度内积为负, 从而在非驻点处给出下降方向。

读前自检: 牛顿法和拟牛顿法。 Newton 法解 $\nabla^2 f(x_k)p_k = -\nabla f(x_k)$, 拟 Newton 法改用 $B_k p_k = -\nabla f(x_k)$; 请比较两次方向方程, 核对状态同维但曲率矩阵来源不同。

读前自检: 牛顿法。 牛顿法以 x_k 为状态; 请解 $\nabla^2 f(x_k)p_k = -\nabla f(x_k)$ 、形成 $x_{k+1} = x_k + p_k$, 再以梯度范数核对停止。

读前自检：牛顿法。 全步 Newton 候选为 $x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$ ；请检查 Hessian 可逆性和方向下降性，若任一失败则说明为何必须阻尼或线搜索。

读前自检：拟牛顿法的思路。 拟牛顿更新由 $s_k = x_{k+1} - x_k$ 与 y_k 构造；请把候选矩阵代入 $B_{k+1}s_k = y_k$ ，核对 $s_k^T y_k > 0$ 保护正定性。

读前自检：DFP (Davidon-Fletcher-Powell) 算法。 DFP 逆 Hessian 更新以 $s_k^T y_k > 0$ 为条件；请将更新式右乘 y_k ，核对抵消项后得到 $G_{k+1}y_k = s_k$ 。

读前自检：DFP 算法。 DFP 算法维护正定 G_k ；请对非零 v 展开 $v^T G_{k+1}v$ ，核对更新保持正定并满足割线条件。

读前自检：BFGS (Broyden-Fletcher-Goldfarb-Shanno) 算法。 BFGS 更新使用 s_k 和 y_k 修正曲率近似；请把 B_{k+1} 乘 s_k ，核对 $B_{k+1}s_k = y_k$ ，并检查曲率条件下正定性保持。

读前自检：BFGS 算法。 逆 BFGS 令 $\rho_k = (y_k^T s_k)^{-1}$ ；请把逆更新式右乘 y_k 并展开，核对结果等于 s_k 。

8.3 拟牛顿法、DFP 与 BFGS

拟牛顿法用正定矩阵 B_k 近似 Hessian，或用 $G_k = B_k^{-1}$ 近似逆 Hessian，避免每轮显式计算二阶导数。牛顿法的二阶模型与线性系统仍是拟牛顿更新的目标参照。

阅读目标：验证两种逆 Hessian 更新都重现最新位移 - 梯度差关系。

对象： $s_k = x_{k+1} - x_k$ 、 $y_k = g_{k+1} - g_k$ 与对称正定矩阵 G_k 。

合法条件：曲率条件 $s_k^T y_k > 0$ ，故相关分母非零。

第一步：先把局部线性关系 $y_k \approx H_{k+1}s_k$ 改写为逆形式的割线条件 $G_{k+1}y_k = s_k$ 。

推导目标

从观测到的位移 s_k 与梯度差 y_k 建立割线条件，验证 DFP 和逆 BFGS 更新都满足 $G_{k+1}y_k = s_k$ ，并说明正曲率条件的作用。

推导准备

令 $s_k = x_{k+1} - x_k$ 、 $y_k = g_{k+1} - g_k$ ， $G_k \in \mathbb{R}^{d \times d}$ 对称正定；假设 $s_k^T y_k > 0$ ，并记 $\gamma_k = (s_k^T y_k)^{-1}$ 。

推导第 1 步：由梯度变化得到割线条件。微积分基本定理给出

$$y_k = \int_0^1 \nabla^2 f(x_k + ts_k) s_k dt.$$

用 B_{k+1} 近似线段上的平均 Hessian，就要求 $B_{k+1}s_k = y_k$ ；对逆矩阵近似 G_{k+1} ，对应条件为 $G_{k+1}y_k = s_k$ 。

推导第2步：验证 DFP 更新。取

$$G_{k+1}^{\text{DFP}} = G_k + \frac{s_k s_k^T}{s_k^T y_k} - \frac{G_k y_k y_k^T G_k}{y_k^T G_k y_k}.$$

右乘 y_k 后，第二项等于 s_k ，第三项等于 $-G_k y_k$ ，恰与第一项 $G_k y_k$ 抵消，所以 $G_{k+1}^{\text{DFP}} y_k = s_k$ 。

读前自检：Broyden 类算法。 Broyden 类在满足割线条件的秩二更新之间插值；请取族参数的两个端点，核对分别恢复 DFP 与 BFGS 且都满足同一 s_k, y_k 关系。

推导第3步：验证逆 BFGS 并核对正定性。 令 $V_k = I - \gamma_k s_k y_k^T$ ，则

$$G_{k+1}^{\text{BFGS}} = V_k G_k V_k^T + \gamma_k s_k s_k^T.$$

因为 $V_k^T y_k = 0$ 且 $\gamma_k s_k^T y_k = 1$ ，右乘 y_k 得到 s_k 。又因 $G_k > 0$ 且 $\gamma_k > 0$ ，任意非零向量 z 满足

$$z^T G_{k+1}^{\text{BFGS}} z = (V_k^T z)^T G_k (V_k^T z) + \gamma_k (s_k^T z)^2 > 0,$$

两个非负项不可能同时为零：若 $s_k^T z = 0$ 且 $V_k^T z = 0$ ，由 $V_k^T z = z - \gamma_k y_k (s_k^T z)$ 可得 $z = 0$ ，与假设矛盾。因此更新保持正定；若 $s_k^T y_k \leq 0$ ，该结论失效，算法必须阻尼或跳过更新。DFP 与 BFGS 可置于满足割线条件的秩二更新族中；不同成员在数值稳定性与近似度量上取舍不同。

读前自检：带曲率保护的逆 BFGS 方法：执行契约。 带曲率保护的逆 BFGS 方法输入“光滑目标 f 与梯度、有限初值 x_0 、容差、外层预算 K 及冻结的 Wolfe 线搜索参数/预算”，条件“ $K \in \mathbb{N}_0$ 、容差为正，线搜索参数合法， $f, \nabla f$ 接口维数一致且初值在定义域内”；请执行“步长、候选点/梯度和受保护逆 Hessian 全部通过有限性与正定门禁后才原子提交，并增加 k_{done} ”，以“梯度/联合步长证书、外层预算耗尽、线搜索失败或数值失败时停止”判停。

带曲率保护的逆 BFGS 方法：五步阅读

输入。 写出数据对象、固定参数与必须成立的条件。

初始化。 标明主状态、计数器和第一个合法状态。

核心更新。 只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。 写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。 列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 8.1: 带曲率保护的逆 BFGS 方法

输入: 目标 f 、梯度、初始点 x_0
输出: 最后合法 $(\hat{x}, \hat{G}, \hat{f}, \hat{g})$; $k_{\text{done}}, j_{\text{done}}, g_{\text{done}}$; **status** 与诊断
数据: 梯度/相对变化容差 ε ; 外层预算 K ; 冻结的 Wolfe 参数、曲率保护规则与每轮线搜索预算

- 1 若维数、容差、预算或线搜索参数非法, 返回空结果、计数 0、**invalid_input** 及字段诊断
- 2 置 $\hat{x} \leftarrow x_0, \hat{G} \leftarrow I, k_{\text{done}} \leftarrow 0, j_{\text{done}} \leftarrow 0$; 计算 $\hat{f} = f(x_0), \hat{g} = \nabla f(x_0)$ 并置 $g_{\text{done}} = 1$
- 3 若初始量非有限, 返回初值占位、**numerical_failure** 及初始化诊断; 若 $\|\hat{g}\| \leq \varepsilon$, 返回 **converged** 及零轮梯度证书
- 4 当 $k_{\text{done}} < K$ 执行
 - 5 形成 $p \leftarrow -\hat{G}\hat{g}$; 若非有限或非下降, 返回上一合法状态、**numerical_failure** 及方向诊断
 - 6 按冻结 Wolfe 规则逐候选试探并增加 j_{done} ; 若预算内无有限合格步, 返回上一合法状态、**line_search_failed** 及试探诊断
 - 7 形成 x^+, f^+, g^+ 并增加 g_{done} ; 若任一非有限, 返回上一合法状态、**numerical_failure** 及候选求值诊断
 - 8 令 $s = x^+ - \hat{x}, y = g^+ - \hat{g}$; 按预登记规则形成受阻尼的 G^+ 或在曲率不足时令 $G^+ = \hat{G}$
 - 9 若 G^+ 非有限、非对称或非正定, 返回上一合法状态、**numerical_failure** 及曲率阶段诊断
 - 10 原子提交 $(\hat{x}, \hat{f}, \hat{g}, \hat{G}) \leftarrow (x^+, f^+, g^+, G^+)$ 并增加 k_{done}
 - 11 若梯度范数与预登记相对变化证书满足, 返回最后合法状态、**converged** 及联合证书诊断
- 12 结束
- 13 返回最后合法状态、**budget_stop** 及“外层预算耗尽、证书未满足”最终诊断

算法实现说明: 首次阅读只跟踪搜索方向、步长、 s_k, y_k 与曲率条件; 实现时再处理曲率保护、线搜索失败和最后合法状态 完整 C1–C14 契约

定理 8.2 (BFGS 结论的适用层次) 设 f 在初始水平集上连续可微且下有界, 梯度 Lipschitz 连续; 若每步方向均为下降方向、线搜索接受满足 Wolfe 条件的步长, 并且 G_k 的特征值一致地夹在两个正数之间, 则 Zoutendijk 论证给出 $\|\nabla f(x_k)\|_2 \rightarrow 0$ 。这只是一般光滑目标的一阶驻点结论。若进一步 f 为 μ -强凸函数, 则 $\|x_k - x^*\|_2 \leq \|\nabla f(x_k)\|_2 / \mu \rightarrow 0$, 从而得到从该水平集到唯一极小点的全局迭代结论。若再假设 f 在极小点邻域二阶连续可微、Hessian Lipschitz 连续, 且标准 BFGS 更新满足 Dennis–Moré 条件并最终接受单位步, 则还可得到局部超线性收敛。若 Wolfe 线搜索失败、曲率条件不能通过阻尼恢复, 或仅因预算耗尽停止, 上述结论均不能宣称成立。

8.4 坐标下降

坐标下降每次只优化一个坐标或一个块:

$$x_j \leftarrow \arg \min_z f(x_1, \dots, x_{j-1}, z, x_{j+1}, \dots, x_d).$$

循环、随机或贪心选坐标均可。若每个子问题易解且目标具有可分正则项, 单步成本低; 高度相关特征会减慢逐坐标推进。

几何理解

几何解释。坐标下降沿坐标轴折线靠近等高线中心; 当椭圆主轴与坐标轴不对齐时会频繁之字形。预条件或块坐标方法相当于改变允许移动的方向, 可缓解轴不匹配。




图 8.1 坐标下降的每个子步只改变一个坐标，因此轨迹沿轴向折线逼近最优解。

图 8.1 中的之字形可用来诊断坐标系失配：若椭圆主轴与坐标轴夹角大，单坐标更新会把大量步长消耗在横纵折返上；旋转、缩放或分块变量可减少这种无效往返。

读前自检：最大熵与改进迭代尺度法的优化基础。 在条件最大熵模型中，设 $Z_w(x)$ 有限。请对负对数似然求 w_i 偏导，核对结果为模型特征期望减经验特征期望。

8.5 专项算法章节边界：改进迭代尺度法预告

IIS 的完整推导、算法与状态语义属于章 17；本节仅作为最大熵优化的依赖预告，第一次阅读可直接跳到本章总结。条件最大熵模型可写为

$$p_w(y|x) = \frac{\exp(w^T f(x, y))}{Z_w(x)}, \quad Z_w(x) = \sum_y \exp(w^T f(x, y)).$$

阅读目标：识别“模型特征期望减经验特征期望”的梯度结构及凸性来源。

对象：参数 $w \in \mathbb{R}^d$ 、特征向量 $f(x, y)$ 、经验分布 $\tilde{p}$ 与配分函数 $Z_w(x)$ 。

合法条件：输出集合有限， $Z_w(x) > 0$ ，特征二阶矩有限。

第一步：先把负条件对数似然写成“ $\log Z_w(x)$ 项减去观测特征线性项”。

推导目标

推导条件最大熵负对数似然的梯度与 Hessian，说明特征期望匹配和目标凸性的来源。

推导准备

输出集合有限， $Z_w(x) > 0$ ；经验分布记为 $\tilde{p}(x, y)$ ，特征向量 $f(x, y) \in \mathbb{R}^d$ 二阶矩有限，因此有限求和可逐项求导。

推导第 1 步：写出目标。 忽略与 w 无关的常数，平均负条件对数似然为

$$J(w) = \sum_{x,y} \tilde{p}(x, y) [\log Z_w(x) - w^T f(x, y)].$$

推导第 2 步：对参数分量求导。由链式法则，

$$\frac{\partial \log Z_w(x)}{\partial w_i} = \sum_{y'} p_w(y' | x) f_i(x, y').$$

代回并对经验分布加权，得到“模型特征期望减经验特征期望”的梯度；梯度为零正是两种期望匹配。

推导第 3 步：再求导。固定 x 时， $\log Z_w(x)$ 的 Hessian 是 $f(x, Y)$ 在 $p_w(\cdot | x)$ 下的协方差矩阵；对经验 x 加权后仍半正定。因此 $\nabla^2 J(w) \geq 0$ ，目标为凸函数。改进迭代尺度法利用特征非负性及总特征量构造可分辅助函数，为每个参数求一维增量后同时更新坐标。

概率解释

最大熵模型在满足经验特征约束的分布中选择不额外引入结构的分布；归一化因子确保每个 x 下类别概率之和为 1。参数更新的目标是让模型特征期望逐步匹配经验期望。

优化解释

优化解释。对数配分函数凸，使负对数似然成为凸目标。迭代尺度法的辅助函数提供单调改进，而牛顿、BFGS 或坐标法则直接利用梯度与曲率；选择方法时需权衡特征稀疏性、维数和线搜索成本。

IIS 专项接口预告（不在本章重复算法）

本章只保留四个优化依赖：对数配分函数的凸性、经验期望与模型期望之差、可分辅助函数以及同时坐标更新。IIS 的非负特征约定、一维增量方程、完整伪代码、失败分支和状态语义统一由章 17 承载；后章是唯一专项定义源。

引理 8.1 (正定近似给出下降方向) 若 G_k 对称正定且 $g_k \neq 0$ ，则 $p_k = -G_k g_k$ 是下降方向。

读前自检：证明：正定近似给出下降方向。 围绕正定近似给出下降方向，先采用条件“正定性使右侧严格小于零”，再把 $g_k^T p_k$ 用到的关键定义展开并完成下一步变形；最后验证方向满足一阶下降判据。

证明。 $g_k^T p_k = -g_k^T G_k g_k$ 。正定性使右侧严格小于零，因此方向满足一阶下降判据。该结论解释了 DFP/BFGS 更新为何必须保护正定性。□

复杂度分析

复杂度假设。以下界把实际接受的外层更新数记为 T ，把一次目标和梯度求值成本记为 C_f, C_g ；稠密 Hessian 或逆 Hessian 近似按完整 $d \times d$ 矩阵存取。回溯线搜索的重复求值、稀疏线性代数和预条件成本必须按实际实现另行累计，不能隐藏在一次迭代中。设 d 为参数维数、 T 为迭代数、 m 为 L-BFGS 保留的校正对， C_f, C_g 为一次目标与梯度求值成本。**训练复**

杂度：梯度下降为 $O(T(C_f + C_g))$ ；稠密牛顿每轮分解为 $O(d^3)$ ，BFGS 为 $O(d^2)$ ，L-BFGS 为 $O(md)$ ；IIS 每轮还需按样本、类别和非零特征重新归一化并求特征期望。**预测复杂度：**优化器本身不定义预测映射；拟合后模型的单样本预测成本由该模型而不是梯度、BFGS 或 IIS 更新规则决定。**存储复杂度：**梯度下降为 $O(d)$ ，稠密牛顿与 BFGS 为 $O(d^2)$ ，L-BFGS 为 $O(md)$ ，IIS 还需保存参数、特征统计与当前归一化量。

适用条件与局限性

适用条件：梯度法适合大规模一阶可微问题；牛顿法适合中等维、Hessian 可得且局部正定的高精度求解；L-BFGS 适合大维光滑目标；坐标下降适合可分正则与廉价一维子问题；IIS 适合特定最大熵特征结构。**局限性：**病态尺度会拖慢一阶法，非正定 Hessian 会破坏牛顿下降性，拟牛顿受噪声梯度影响，坐标法受强耦合影响，IIS 的一维方程与归一化可能昂贵。

读前自检：常见错误与误用边界：专项算法章节边界：改进迭代尺度法预告。 专项算法章节边界：改进迭代尺度法预告中的“边界框首项禁止把梯度方向而非负梯度当下降方向”决定可执行范围；请把固定错误“把梯度方向而非负梯度当下降方向”中的对象、操作与结论按本节定义拆开，指出第一个不满足的定义条件，再把该处改为本节允许的写法，结果须满足改写后的运算或判断有定义，且不再触发“把梯度方向而非负梯度当下降方向”。

常见错误

典型误用包括：把梯度方向而非负梯度当下降方向；固定大步长却不检查下降；只因目标变化小就宣布收敛；显式求 Hessian 逆；Hessian 不正定时仍取全牛顿步；在 $s^T y \leq 0$ 时无保护地执行 BFGS；把 DFP 与 BFGS 的 Hessian 形式和逆 Hessian 形式混写。

易混淆概念对比

概念对比：梯度下降使用一阶局部模型，牛顿使用真实二阶曲率，拟牛顿从梯度差学习曲率；线搜索选择步长，信赖域限制模型可信范围。DFP 与 BFGS 都满足割线条件但采用不同秩二修正。循环坐标法顺序更新，IIS 由可分辅助函数产生同时更新。收敛阶描述局部误差速度，单步时间决定实际总成本，两者需一起比较。

读前自检：带 Armijo 回溯的梯度下降：执行契约。 带 Armijo 回溯的梯度下降输入“可微目标 f 与梯度、有限初值 x_0 、Armijo 参数、最小步长、回溯预算 J 、外层预算 K 与停止容差”，条件“ $\alpha_0, \alpha_{\min}, \varepsilon > 0$ ，步长缩减因子 $0 < \rho < 1$ ，充分下降常数 $0 < c < 1$ ， $J, K \in \mathbb{N}_0$ ，函数接口维数一致”；请执行“候选点、目标和新梯度全部有限后才原子提交，并增加 k_{done} ”，以“梯度或联合相对变化证书、外层预算耗尽、线搜索失败或数值失败时停止”判停。

带 Armijo 回溯的梯度下降：五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 8.2: 带 Armijo 回溯的梯度下降

输入: 可微目标 f 与梯度; 初始点 x_0

输出: 最后合法 $(\hat{x}, \hat{f}, \hat{g})$; $k_{\text{done}}, j_{\text{done}}, f_{\text{done}}, g_{\text{done}}$; **status** 与诊断

数据: $\alpha_0 > 0$, 步长缩减因子 $0 < \rho < 1$, 充分下降常数 $0 < c < 1$, $\alpha_{\min} > 0$; 容差 ε ; 外层/回溯预算 $K, J \in \mathbb{N}_0$

- 1 若维数、初值、容差、步长或预算参数非法, 返回空结果、计数 0、**invalid_input** 及字段诊断
- 2 计算 $\hat{f} \leftarrow f(x_0), \hat{g} \leftarrow \nabla f(x_0)$ 并置 $\hat{x} \leftarrow x_0, k_{\text{done}} = j_{\text{done}} = 0, f_{\text{done}} = g_{\text{done}} = 1$
- 3 若初始量非有限, 返回初值占位、**numerical_failure** 及初始化诊断; 若 $\|\hat{g}\| \leq \varepsilon$, 返回 **converged** 及零轮梯度证书
- 4 **当** $k_{\text{done}} < K$ **执行**
 - 5 置 $p \leftarrow -\hat{g}, \alpha \leftarrow \alpha_0$ 并清除接受标志
 - 6 **对** 本轮回溯候选 $j \leftarrow 0$ **至** J **执行**
 - 7 形成 $x^+ = \hat{x} + \alpha p$ 并试算 $f^+ = f(x^+)$, 增加 $j_{\text{done}}, f_{\text{done}}$; 若有限且满足 Armijo 则记录候选并退出回溯, 否则令 $\alpha \leftarrow \rho \alpha$
 - 8 **结束**
 - 9 若没有合格步或 $\alpha < \alpha_{\min}$, 返回上一合法状态、**line_search_failed** 及回溯诊断
 - 10 计算 $g^+ = \nabla f(x^+)$ 并增加 g_{done} ; 若非有限, 返回上一合法状态、**numerical_failure** 及梯度诊断
 - 11 原子提交 $(\hat{x}, \hat{f}, \hat{g}) \leftarrow (x^+, f^+, g^+)$ 并增加 k_{done}
 - 12 若梯度或联合相对变化证书满足, 返回最后合法状态、**converged** 及证书诊断
- 13 **结束**
- 14 返回最后合法状态、**budget_stop** 及“外层预算耗尽、证书未满足”最终诊断

算法实现说明: 首次阅读只跟踪下降方向、Armijo 判据、 $\alpha \leftarrow \rho \alpha$ 与梯度停止; 实现时再处理回溯预算、最小步长和失败状态 完整 C1-C14 契约

定理 8.3 (Armijo 梯度法的一阶收敛条件) 设 f 在迭代所在水平集上有 L -Lipschitz 梯度且下有限; 方向满足 $g_k^T p_k \leq -m \|g_k\|_2^2$ 与 $\|p_k\|_2 \leq M \|g_k\|_2$, 其中 $m, M > 0$; 取 $0 < c < 1$ 、 $0 < \rho < 1$ 、 $\alpha_0 > 0$, 并假设回溯在每个有限迭代都接受步长且接受步长有统一下界 $\alpha_k \geq \underline{\alpha} > 0$ 。若不以预算、最小步长或数值失败提前截断, 则

$$\sum_{k=0}^{\infty} \|g_k\|_2^2 \leq \frac{f(x_0) - \inf f}{cm\underline{\alpha}} < \infty, \quad \|g_k\|_2 \rightarrow 0.$$

算法返回 **budget_stop**、**line_search_failed** 或 **numerical_failure** 时, 只报告停止原因, 不援引本定理宣称收敛。

8.6 牛顿法

牛顿法在 x_k 处用二阶 Taylor 模型

$$m_k(p) = f(x_k) + g_k^\top p + \frac{1}{2} p^\top H_k p$$

近似目标。若 H_k 正定，模型唯一极小方向满足 $H_k p_k = -g_k$ ，再以 $x_{k+1} = x_k + \alpha_k p_k$ 更新；靠近非退化最优值时常取全步 $\alpha_k = 1$ 。

例题 8.2 (病态二次函数的三种尺度处理). 比较病态二次函数 $f(x) = \frac{1}{2} x^\top \text{diag}(1, 100)x$ 上的固定步长梯度法、Newton 法与 BFGS 的尺度处理。

例题 8.2 解答

读题翻译 题目要比较三种方法如何处理两个坐标方向相差百倍的曲率尺度，而不是求三条未指定初值和线搜索的完整迭代轨迹。

已知与合法条件 $H = \text{diag}(1, 100)$ ；固定步长梯度法使用同一 α 缩放两个方向，Newton 取全步，BFGS 中的 B_k 表示 Hessian 近似并由割线对更新。

为什么想到这个方法 二次函数的尺度行为完全由 Hessian 谱控制：先读出特征值和条件数，再分别考察梯度迭代矩阵、Newton 预条件和 BFGS 割线条件。

方法选择 求 H 的谱与条件数；推导 GD 稳定区间和 Newton 全步；最后说明 BFGS 怎样从 (s_k, y_k) 学习曲率，并用一个数值步与曲率条件复核。

推导/计算 目标域为 $\mathbb{R}^2$ ， $H \succ 0$ 的特征值为 1, 100，故二范数条件数为 $\kappa_2(H) = 100$ 。三类方法的关键关系为

$$\begin{aligned} x_{k+1}^{\text{GD}} &= (I - \alpha H)x_k, & 0 < \alpha < \frac{2}{\lambda_{\max}(H)} &= 0.02, \\ p_k^{\text{Newton}} &= -H^{-1}Hx_k = -x_k, & x_{k+1} &= 0 \quad (\text{全步}), \\ B_{k+1}s_k &= y_k = Hs_k & & (\text{BFGS 逐步学习曲率尺度}). \end{aligned}$$

固定步长 GD 只有在两个谱因子的绝对值都小于 1 时收敛，因此 $0 < \alpha < 0.02$ ；Newton 全步一次到达极小点；BFGS 则不预先使用 H ，而由 $y_k = Hs_k$ 逐步学习曲率尺度。

独立核验 取 $\alpha = 0.01$ 、 $x_0 = (1, 1)^\top$ ，GD 得 $x_1 = (0.99, 0)^\top$ ，而 Newton 得 0 且新梯度为零；对任意 $s_k \neq 0$ ， $s_k^\top y_k = s_k^\top Hs_k > 0$ ，BFGS 正定更新的曲率条件成立。

结论 固定步长 GD 受 $\lambda_{\max} = 100$ 约束而在低曲率方向缓慢；Newton 用 H^{-1} 消除尺度并全步一次到达 0；BFGS 则通过割线对逐步学习这一曲率度量。

本章共 18 道练习。每道题干后立即给出同号解析；长解析可自然跨页，续页标题保留题号。

练习 8.1. 对 $f(x) = \frac{1}{2}ax^2$ ($a > 0$), 写出固定步长梯度下降递推, 并给出收敛步长范围。

练习 8.1 解析

目标 $f: \mathbb{R} \rightarrow \mathbb{R}$ 满足 $a > 0$, 固定步长 $\alpha \geq 0$ 。梯度下降递推及所有初值收敛条件为

$$\begin{aligned} f'(x) &= ax, & x^\star &= 0, \\ x_{k+1} &= x_k - \alpha ax_k = (1 - \alpha a)x_k, \\ x_k &= (1 - \alpha a)^k x_0, \\ x_k \rightarrow 0 \forall x_0 &\iff |1 - \alpha a| < 1 \iff 0 < \alpha < \frac{2}{a}. \end{aligned}$$

$x_0 = 0$ 对任意步长保持不变, 但不能用该退化初值推断一般收敛域; $\alpha = 1/a$ 时一步到达最优点。

练习 8.2. 证明在非零梯度处, $-g$ 是下降方向, 并说明任意正倍数是否仍为下降方向。

练习 8.2 解析

设 f 在定义域内部点 x 可微, $g = \nabla f(x) \neq 0$ 。方向 p 的一阶下降判据为 $g^\top p < 0$, 因此

$$\begin{aligned} p &= -g &\implies g^\top p &= -\|g\|_2^2 < 0, \\ p_c &= -cg, \quad c > 0 &\implies g^\top p_c &= -c\|g\|_2^2 < 0, \\ f(x + tp_c) &= f(x) + t g^\top p_c + o(t) &< f(x) &\text{ 对充分小的 } t > 0. \end{aligned}$$

故任意正倍数仍是下降方向; $c < 0$ 时变为上升方向, $g = 0$ 时一阶判据不能给出严格下降。

练习 8.3. 对 $f(x_1, x_2) = x_1^2 + 10x_2^2$, 从 $(1, 1)$ 做一步步长 0.05 的梯度下降。

练习 8.3 解析

目标域为 $\mathbb{R}^2$, 初值 $x_0 = (1, 1)^\top$, 步长 $\alpha = 0.05$ 。一步更新可复算为

$$\begin{aligned} \nabla f(x) &= \begin{bmatrix} 2x_1 \\ 20x_2 \end{bmatrix}, & \nabla f(x_0) &= \begin{bmatrix} 2 \\ 20 \end{bmatrix}, \\ x_1 &= x_0 - \alpha \nabla f(x_0) = \begin{bmatrix} 1 \\ 1 \end{bmatrix} - 0.05 \begin{bmatrix} 2 \\ 20 \end{bmatrix} = \begin{bmatrix} 0.9 \\ 0 \end{bmatrix}, \\ f(x_0) &= 11, & f(x_1) &= 0.9^2 = 0.81 < 11. \end{aligned}$$

因此一步梯度下降得到 $x_1 = (0.9, 0)^\top$, 并把目标值从 11 降至 0.81。

练习 8.4. 若 $g^\top p = -4$ 、 $f(x) = 10$ 、 $c = 0.1$ 、 $\alpha = 0.5$, Armijo 允许的新目标上界是多少?

练习 8.4 解析

Armijo 条件要求 $c \in (0, 1)$ 、 $\alpha > 0$ 及下降方向 $g^T p < 0$ 。代入题设数值,

$$\begin{aligned} f(x + \alpha p) &\leq f(x) + c\alpha g^T p \\ &= 10 + (0.1)(0.5)(-4) \\ &= 10 - 0.2 = 9.8. \end{aligned}$$

因此候选目标不超过 9.8 才接受; 若 $g^T p \geq 0$, 应先修正方向而不是继续回溯。

练习 8.5. 说明只用 $|f_{k+1} - f_k|$ 很小作为停止条件可能出现的两种误判。

练习 8.5 解析

令 $\Delta f_k = |f(x_{k+1}) - f(x_k)|$ 。仅检查 $\Delta f_k \leq \varepsilon_f$ 不能区分以下状态:

$$\begin{aligned} \alpha_k \downarrow 0, \|\nabla f(x_k)\|_2 \neq 0 &\implies \Delta f_k \approx \alpha_k |\nabla f(x_k)^T p_k| \rightarrow 0, \\ f \mapsto cf &\implies \Delta f_k \mapsto c \Delta f_k, \end{aligned}$$

前者把失败的小步长误判为收敛, 后者使固定绝对阈值依赖目标尺度。应联合检查相对目标变化、相对步长、梯度范数, 并单独报告最大迭代或最小步长退出。

练习 8.6. 设 $a > 0$ 。对一维二次函数 $f(x) = \frac{1}{2}ax^2 - bx$, 在线搜索域 $\alpha \geq 0$ 上求负梯度方向的精确步长。

练习 8.6 解析

目标 $f: \mathbb{R} \rightarrow \mathbb{R}$ 满足 $a > 0$, 线搜索域为 $\alpha \geq 0$, 当前梯度 $g = ax - b$ 且方向 $p = -g$ 。沿线目标满足

$$\begin{aligned} \phi(\alpha) &= f(x - \alpha g), \\ \phi'(\alpha) &= -g[a(x - \alpha g) - b] = -g^2(1 - a\alpha), \\ \phi''(\alpha) &= ag^2 \geq 0. \end{aligned}$$

若 $g \neq 0$, 则唯一精确步长和更新为

$$\alpha^\star = \frac{1}{a} > 0, \quad x - \alpha^\star g = \frac{b}{a}.$$

若 $g = 0$, 当前点已最优且所有 α 产生同一点, 算法通常取 $\alpha = 0$ 停止。

练习 8.7. 对 $f(x) = x^4 - 3x^2 + 2$ 写出一维牛顿更新, 并说明在哪些点公式无定义。

练习 8.7 解析

目标定义在 $\mathbb{R}$ 上, 但牛顿映射只在二阶导数非零处定义:

$$\begin{aligned} f'(x) &= 4x^3 - 6x, & f''(x) &= 12x^2 - 6, \\ x_{k+1} &= x_k - \frac{4x_k^3 - 6x_k}{12x_k^2 - 6}, \\ 12x_k^2 - 6 &= 0 \iff x_k = \pm \frac{1}{\sqrt{2}}. \end{aligned}$$

在这两点分母为零; 当 $f''(x_k) < 0$ 时, 牛顿方向也未必是下降方向, 需线搜索或正定修正。

练习 8.8. 解释为什么数值实现应解 $H_k p = -g_k$ 而不是先计算 H_k^{-1} 。

练习 8.8 解析

给定 $H_k \in \mathbb{R}^{d \times d}$ 与 $g_k \in \mathbb{R}^d$, 目标只是得到满足线性系统的 p_k , 不是矩阵逆本身:

$$\begin{aligned} H_k p_k &= -g_k, \\ H_k = R^\top R &\implies R^\top z = -g_k, \quad R p_k = z, \\ \hat{p}_k &= -\text{solve}(H_k, g_k) \quad \text{而非} \quad -\widehat{H_k^{-1}} g_k. \end{aligned}$$

分解求解能保留稀疏或对称结构并检测奇异、病态或非正定情况; 显式逆通常更耗存储且放大舍入误差。

练习 8.9. 证明正定 Hessian 下牛顿减量 $\lambda^2 = g^\top H^{-1} g$ 非负, 并写成方向 p 的形式。

练习 8.9 解析

设 $H = H^\top > 0$ 、 $g \in \mathbb{R}^d$, 则 $H^{-1} > 0$ 且牛顿方向 $p = -H^{-1}g$ 唯一。于是

$$\begin{aligned} \lambda^2 &= g^\top H^{-1} g \geq 0, \\ H p &= -g \implies -g^\top p = p^\top H p, \\ \lambda^2 &= -g^\top p = p^\top H p \geq 0. \end{aligned}$$

等号当且仅当 $g = 0$, 此时 $p = 0$; 正定性是非负性与唯一性的关键。

练习 8.10. 证明割线条件 $B_{k+1} s_k = y_k$ 可由梯度差的一阶积分近似解释。

练习 8.10 解析

设 f 在线段 $\{x_k + ts_k : 0 \leq t \leq 1\}$ 的邻域二次连续可微, $s_k = x_{k+1} - x_k$, $y_k = \nabla f(x_{k+1}) - \nabla f(x_k)$ 。则

$$\begin{aligned} y_k &= \int_0^1 \frac{d}{dt} \nabla f(x_k + ts_k) dt \\ &= \left[\int_0^1 \nabla^2 f(x_k + ts_k) dt \right] s_k \\ &\approx B_{k+1} s_k. \end{aligned}$$

因此用单个矩阵近似线段平均 Hessian 时, 自然要求割线条件 $B_{k+1} s_k = y_k$ 。

练习 8.11. 说明 $s^T y > 0$ 对保持逆 BFGS 正定性的作用。

练习 8.11 解析

设 $G_k > 0$, $s^T y > 0$, 令 $\gamma = (s^T y)^{-1} > 0$ 及 $V = I - \gamma s y^T$ 。逆 BFGS 更新满足

$$\begin{aligned} G_{k+1} &= V G_k V^T + \gamma s s^T, \\ z^T G_{k+1} z &= (V^T z)^T G_k (V^T z) + \gamma (s^T z)^2 \geq 0. \end{aligned}$$

若二次型为零, 则 $s^T z = 0$ 且 $V^T z = z = 0$, 与 $z \neq 0$ 矛盾, 故 $G_{k+1} > 0$ 。若 $s^T y \leq 0$, γ 不再为正且证明失效, 需阻尼、Wolfe 线搜索或跳过更新。

练习 8.12. 比较稠密牛顿法与稠密 BFGS 每轮所需的二阶信息、时间和空间。

练习 8.12 解析

设参数维数 d , 矩阵稠密且实数运算单位成本。每轮的主要需求为

方法	二阶信息	主要时间	主要存储
Newton	$\nabla^2 f$ 或其作用	$O(d^3)$ 分解	$O(d^2)$
BFGS	仅函数与梯度	$O(d^2)$ 秩二更新	$O(d^2)$
L-BFGS	m 组 (s, y)	$O(md)$	$O(md)$

这些界不含具体函数与梯度求值成本; 稀疏或结构化线性求解可显著改变 Newton 时间。

练习 8.13. 对 $f(x, y) = (x - 1)^2 + 2(y + 2)^2$, 从 $(0, 0)$ 依次精确优化 x 坐标和 y 坐标。

练习 8.13 解析

目标域为 $\mathbb{R}^2$ 且 $\text{Hessiand} \text{diag}(2, 4) > 0$ 。从 $(x^{(0)}, y^{(0)}) = (0, 0)$ 依次精确求解两个无约束一维子问题:

$$\begin{aligned} x^{(1)} &= \arg \min_{x \in \mathbb{R}} (x - 1)^2 + 2(0 + 2)^2 = 1, \\ y^{(1)} &= \arg \min_{y \in \mathbb{R}} (1 - 1)^2 + 2(y + 2)^2 = -2, \\ (x^{(1)}, y^{(1)}) &= (1, -2), \quad f(1, -2) = 0. \end{aligned}$$

严格凸性保证这也是唯一全局极小点。

练习 8.14. 对 $f(x, y) = x^2 + 2\rho xy + y^2$ ($|\rho| < 1$), 写出精确循环坐标更新。

练习 8.14 解析

$|\rho| < 1$ 使 $\text{Hessian}2 \begin{bmatrix} 1 & \rho \\ \rho & 1 \end{bmatrix} > 0$, 目标在 $\mathbb{R}^2$ 上有唯一极小点。第 k 轮循环更新为

$$\begin{aligned} \frac{\partial f}{\partial x} = 2x + 2\rho y^{(k)} = 0 &\implies x^{(k+1)} = -\rho y^{(k)}, \\ \frac{\partial f}{\partial y} = 2y + 2\rho x^{(k+1)} = 0 &\implies y^{(k+1)} = -\rho x^{(k+1)} = \rho^2 y^{(k)}. \end{aligned}$$

因此 $y^{(k)} = \rho^{2k} y^{(0)} \rightarrow 0$, 随后 $x^{(k)} \rightarrow 0$; $|\rho|$ 接近 1 时收敛因子接近 1。

练习 8.15. 说明带 ℓ_1 正则的平方损失为何适合坐标下降, 并指出一维子问题的典型解形状。

练习 8.15 解析

固定其余坐标后, 典型一维子问题可写为 $a > 0$, $\lambda \geq 0$ 下

$$\begin{aligned} \min_{\beta \in \mathbb{R}} \quad q(\beta) &= \frac{a}{2}(\beta - z)^2 + \lambda|\beta|, \\ 0 &\in a(\beta - z) + \lambda \partial|\beta|, \\ \beta^\star &= S_{\lambda/a}(z) = \text{sgn}(z)(|z| - \lambda/a)_+. \end{aligned}$$

平方损失给出严格凸二次项, ℓ_1 惩罚按坐标可分; 软阈值在 $|z| \leq \lambda/a$ 时产生精确零。

练习 8.16. 推导最大熵负对数似然对参数 w_i 的梯度形式。

练习 8.16 解析

设训练集 $T = \{(x_n, y_n)\}_{n=1}^N$ 固定、标签集 $\mathcal{Y}$ 有限, 且 $p_w(y | x) = e^{w^\top f(x, y)} / Z_w(x)$ 。平均负对数似然为

$$\begin{aligned} \mathcal{L}(w) &= \frac{1}{N} \sum_{n=1}^N [\log Z_w(x_n) - w^\top f(x_n, y_n)], \\ \frac{\partial \mathcal{L}}{\partial w_i} &= \frac{1}{N} \sum_{n=1}^N \left[\sum_{y' \in \mathcal{Y}} p_w(y' | x_n) f_i(x_n, y') - f_i(x_n, y_n) \right]. \end{aligned}$$

只要有限求和中的特征值有限, 梯度存在; 驻点表示模型条件特征期望与经验特征平均匹配。

练习 8.17. 说明最大熵目标 Hessian 为何半正定, 并指出参数不可识别时会发生什么。

练习 8.17 解析

在有限标签集和有限特征下, 对固定训练输入 x_n , 令随机标签 $Y \sim p_{w(\cdot | x_n)}$ 。则

$$\begin{aligned}\nabla^2 \mathcal{L}(w) &= \frac{1}{N} \sum_{n=1}^N \text{Cov}_{p_{w(\cdot | x_n)}}[f(x_n, Y)], \\ v^\top \nabla^2 \mathcal{L}(w) v &= \frac{1}{N} \sum_{n=1}^N \text{Var}_{p_{w(\cdot | x_n)}}(v^\top f(x_n, Y)) \geq 0.\end{aligned}$$

故目标凸。若存在 $v \neq 0$ 使每个 x_n 上 $v^\top f(x_n, y)$ 对所有 y 为同一常数, 则上述方差全为零, 参数不可识别且极小参数可能不唯一。

练习 8.18. 比较 IIS 同时更新与普通循环坐标下降在更新耦合和单调性依据上的差别。

练习 8.18 解析

令目标为 $\mathcal{L}(w)$, 旧参数为 $w^{(k)}$ 。两类更新的依赖结构可形式化为

$$\begin{aligned}\text{循环坐标: } w_i^{(k,i)} &\in \arg \min_u \mathcal{L}(w_1^{(k,i)}, \dots, u, \dots), \\ \mathcal{L}(w^{(k,i)}) &\leq \mathcal{L}(w^{(k,i-1)}), \\ \text{IIS: } \Delta_i^{(k)} &\in \arg \min_{\Delta} Q_i(\Delta | w^{(k)}), \quad w^{(k+1)} = w^{(k)} + \Delta^{(k)}, \\ \mathcal{L}(w^{(k)} + \Delta) - \mathcal{L}(w^{(k)}) &\leq Q(\Delta | w^{(k)}), \quad Q(0 | w^{(k)}) = 0, \\ Q(\Delta^{(k)} | w^{(k)}) &\leq 0 \implies \mathcal{L}(w^{(k+1)}) \leq \mathcal{L}(w^{(k)}).\end{aligned}$$

前者使用最新坐标并顺序耦合; IIS 在旧模型下求各增量后同时更新, 单调性依赖有效辅助上界及其适用条件。

读前自检：本章结论与下一步。 数值优化方法章末由“梯度、Hessian、搜索方向、步长与曲率近似”落到“每轮计算方向、线搜索、更新并记录唯一终止原因”；请把前者产出和后者输入逐项对齐，固定核对前者末项的输出类型能否作为后者首项的输入类型。

本章结论与下一步

核心结论： 梯度、Hessian、搜索方向、步长与曲率近似

关键依据： 下降引理控制梯度步, Taylor 模型导出 Newton 步, 割线条件更新 BFGS

可执行自检： 每轮计算方向、线搜索、更新并记录唯一终止原因

适用边界： 按维数、稀疏性、曲率与精度选择优化器

下一步： 进入第 9 章：统计学习的基本框架；自第 12 章起进入具体模型

1. 能否由方向导数和下降引理分别说明方向与步长为何合理？
2. 能否从二阶 Taylor 模型逐步推出牛顿方程并说明正定性用途？
3. 能否写出 s_k, y_k 、割线条件和逆 BFGS 更新, 并先检查曲率？
4. 能否根据维数、稀疏性、导数和精度要求选择梯度、牛顿、L-BFGS、坐标法或 IIS？未通过时依次回看节 8.1—8.6。

第9章 统计学习的基本框架

读前自检：本章可检验学习目标。 统计学习的基本框架目标中的“能用数据空间、假设空间、评价准则和求解过程完整表述一个统计学习问题”必须可复核；请用数据空间、假设空间、评价准则和求解过程完整表述一个统计学习问题，所得结果仅在“中间结果逐项包含首目标“能用数据空间、假设空间、评价准则和求解过程完整表述一个统计学习问题”声明的对象、条件与结论”时通过。

本章地图

核心问题：有限数据上的学习问题怎样被完整而可复现地定义

可检验学习目标：

- 能用数据空间、假设空间、评价准则和求解过程完整表述一个统计学习问题；
- 能区分监督学习、无监督学习与强化学习，并说明输入、特征和输出在三类任务中的角色；
- 能辨认概率模型与非概率模型、在线学习与批量学习，并用“模型 - 策略 - 算法”三要素审查一种学习方法。

最短先修：本章直接使用样本、特征、标签与参数的角色约定，以及总体、样本和统计量的区别。若不能说明“观测到的数据”与“由学习过程选出的参数”有何不同，应先回看节 1.5；若不能区分总体规律与有限样本统计量，应回看节 5.4。

依赖路线：本章局部依赖关系为

数据及变量角色 $\longrightarrow$ 学习类型 $\longrightarrow$ 输入、特征与输出空间 $\longrightarrow$ 假设空间 $\longrightarrow$ 模型、策略与算法。

“学习类型”决定可获得的反馈，“空间”决定模型的定义域和值域，“假设空间”限定搜索范围，策略和算法才在该范围内选择具体模型。

完成标准与返回：任一接口缺失时返回本章对应空间或三要素小节

本章符号表		
符号	类型或维数	含义
$\mathcal{X}, \mathcal{Z}, \mathcal{Y}$	集合	输入空间、特征空间与输出空间
X, Y, Z	随机变量	输入、监督输出与潜在表示
$x, \phi(x), y$	相应空间中的元素	一个实例、特征表示与输出值
$T = \{(x_i, y_i)\}_{i=1}^N$	样本集合	含 N 个输入 – 输出对的监督训练集
$P(X, Y)$	联合分布	产生监督样本的总体统计规律
$\mathcal{F}$	模型集合	学习算法允许选择的假设空间
f_θ 或 $P_\theta(Y X)$	模型	决策函数或条件概率分布
$\theta \in \Theta$	参数	具体模型的索引及其允许取值范围
$L(y, f(x))$	非负标量	单次预测的损失
$R(f), \hat{R}_T(f)$	非负标量	期望风险与经验风险
γ, r_t, G_t	标量	折扣因子、即时奖励与累计回报, 其中 $0 \leq \gamma \leq 1$
$\mathcal{A}$	映射	把训练数据和设定变为所选模型的学习算法

问题提出

统计学习面对的并不是“把数据代入一个现成公式”这一单步问题。它必须同时回答五个问题：数据怎样产生、允许考虑哪些模型、怎样比较模型、怎样找到较优模型，以及模型将怎样处理新输入。缺少其中任何一项，任务都可能没有可复现的含义。例如，只说“训练一个分类器”并未声明标签集合、候选模型、损失和训练规则，也就不能判断两个结果谁更好。

读前自检：本讲义的工作性检查框架。 统计学习工作框架用输入空间 $\mathcal{X}$ 、输出空间 $\mathcal{Y}$ 、训练集 $\mathcal{D}$ 、模型族 $\mathcal{F}$ 与准则定义学习映射；请把一个候选训练集代入，核对输出 $\hat{f}$ 确属 $\mathcal{F}$ 。

本讲义的工作性检查框架

为避免漏项，本讲义用六元组

$$(\mathcal{X}, \mathcal{Y}, \mathcal{D}, \mathcal{F}, L, \mathcal{A})$$

检查任务接口。 $\mathcal{X}$ 与 $\mathcal{Y}$ 分别是输入、输出空间； $\mathcal{D}$ 规定可观测数据及其反馈形式； $\mathcal{F}$ 是候选模型集合； L 度量模型一次输出的代价；学习算法 $\mathcal{A}$ 依据数据、假设空间和准则返回 $\hat{f} \in \mathcal{F}$ 。这不是覆盖所有学习范式的公理化定义；无监督或强化学习可用潜变量、动作、奖励或环境状态改写相应槽位，但必须明确可观测量和评价目标。

本册统一约定：比较两个标量风险或损失时用绝对值 $|a - b|$ ；比较向量参数、预测或残差时使用并就地声明范数 $\|u - v\|$ 。

模型、策略与学习算法

模型描述输入与输出、表示或动作之间允许成立的关系。模型可以是函数 $f_\theta: \mathcal{X} \rightarrow \mathcal{Y}$ ，也可以是条件分布 $P_\theta(Y|X)$ ；参数 θ 的可取范围连同函数形式共同确定假设空间，而一个具体 θ 只确定其中一个模型。

策略规定怎样评价候选模型。监督学习中常把单次损失汇总为经验风险，并可加入复杂度惩罚；无监督学习可评价重构、聚类或概率拟合；强化学习常评价长期累计回报。策略给出“什么叫好”，却不自动给出达到该目标的计算步骤。

算法是由明确的状态、输入接口、可选随机源、更新规则以及停止或预算规则定义的可执行过程。确定性算法在给定输入时轨迹唯一；随机算法还必须声明随机种子或概率转移核。算法可以在有限预算后返回当前状态，也可以通过无限序列定义渐近性质，因此“算法”本身不限定为确定性的有限过程。它给出“怎样寻找”。同一模型和策略可以配合不同算法，同一算法也可在更换模型族或损失后用于不同任务，因此三要素必须分别声明。

核心推导：经验风险为何能够估计期望风险

阅读目标：用无偏性、方差缩减与概率界连接样本平均和总体风险。

对象：固定模型 f ，令 $U_i = L(Y_i, f(X_i))$ ，经验风险为 $\hat{R}_N(f) = N^{-1} \sum_i U_i$ 。

合法条件： U_i 独立同分布， $\mathbb{E}U_i = R(f)$ 且 $\text{Var}(U_i) = \sigma_f^2 < \infty$ ； f 必须固定。

第一步：先分别写出总体风险 $R(f) = \mathbb{E}U_i$ 与样本平均 $\hat{R}_N(f)$ 。

推导目标

固定模型 f ，在样本独立同分布且损失方差有限时，推导经验风险的期望和偏离概率，说明样本平均与总体风险之间的联系。

推导准备

设 (X_i, Y_i) 独立同分布于 $P(X, Y)$ ， $U_i = L(Y_i, f(X_i))$ ，且 $\mathbb{E}[U_i] = R(f)$ 、 $\text{Var}(U_i) = \sigma_f^2 < \infty$ 。固定 f 意味着本推导不把使用同一批数据选模造成的依赖混入计算。

推导第1步：写出总体量与样本量。 定义

$$R(f) = \mathbb{E}_{(X,Y) \sim P}[L(Y, f(X))], \quad \hat{R}_T(f) = \frac{1}{N} \sum_{i=1}^N U_i.$$

推导第2步：交换有限和与期望。 由期望的线性性和同分布性，

$$\mathbb{E}[\hat{R}_T(f)] = \frac{1}{N} \sum_{i=1}^N \mathbb{E}[U_i] = \frac{1}{N} \cdot NR(f) = R(f).$$

所以对预先固定的 f ，经验风险是期望风险的无偏估计。

推导第3步：计算方差并控制偏离。 独立性使协方差项为零，因此

$$\text{Var}(\hat{R}_T(f)) = \frac{1}{N^2} \sum_{i=1}^N \text{Var}(U_i) = \frac{\sigma_f^2}{N}.$$

对任意 $\varepsilon > 0$ 应用 Chebyshev 不等式，得到

$$\Pr(|\hat{R}_T(f) - R(f)| \geq \varepsilon) \leq \frac{\sigma_f^2}{N\varepsilon^2}.$$

样本量增大使固定模型的估计更稳定；这一结论本身不等于对数据自适应选出的任意模型都已获得泛化保证。

定理 9.1 (固定模型经验风险的一致性界) 在上述独立同分布和有限方差条件下， $\hat{R}_T(f)$ 无偏估计 $R(f)$ ，且对每个 $\varepsilon > 0$ 满足

$$\Pr(|\hat{R}_T(f) - R(f)| \geq \varepsilon) \leq \frac{\sigma_f^2}{N\varepsilon^2}.$$

从而 $\hat{R}_T(f)$ 依概率收敛到 $R(f)$ 。

读前自检：证明：固定模型经验风险的一致性界。 固定模型经验风险的一致性界以“独立性给出 $\text{Cov}(U_i, U_j) = 0$ ($i \neq j$)”为约束；请把 $\mathbb{E}[\hat{R}_T(f)] = R(f)$ 用到的关键定义展开并完成下一步变形，并确认固定 ε 后，右端随 $N \rightarrow \infty$ 趋于零，这正是依概率收敛的定义。

证明. 令 $U_i = L(Y_i, f(X_i))$ 。同分布性给出 $\mathbb{E}[U_i] = R(f)$ ，期望的线性性随即给出 $\mathbb{E}[\hat{R}_T(f)] = R(f)$ 。独立性给出 $\text{Cov}(U_i, U_j) = 0$ ($i \neq j$)，所以样本平均的方差为 σ_f^2/N 。把随机变量 $\hat{R}_T(f)$ 、均值 $R(f)$ 和方差 σ_f^2/N 代入 Chebyshev 不等式便得概率界。固定 ε 后，右端随 $N \rightarrow \infty$ 趋于零，这正是依概率收敛的定义。证明中的每个条件都有作用：同分布性统一各项均值，独立性消去协方差，有限方差保证界为有限数。□

几何理解

几何解释。 可把假设空间 $\mathcal{F}$ 看成模型点构成的搜索区域，把风险看成该区域上的高度。策略确定等高线的形状，算法规定从初始点沿何种路径移动。改变特征映射会改变模型看到的数据几何，即使原始输入没有变化，搜索问题也可能由弯曲边界变为近似线性边界。

概率解释

联合分布 $P(X, Y)$ 刻画总体生成规律，训练集是从该规律得到的有限观测。概率模型直接给出 $P_\theta(Y | X)$ 或相关分布，非概率模型则给出确定的函数输出。两类模型都可在随机数据上评价风险；“模型是否概率化”与“数据是否随机”是两个不同问题。

优化解释

优化解释。当策略取经验风险最小化时，学习被写成 $\hat{f} \in \arg \min_{f \in \mathcal{F}} \hat{R}_T(f)$ 。假设空间给出可行域，风险给出目标函数，算法近似或精确求解该问题。若目标有多个极小点，还必须声明并列处理规则，输出才可复现。




图 9.1 统计学习从数据到模型再到新数据处理的基本闭环。反馈的形式由学习类型决定。

沿图 9.1 审计实验时，应逐条标出哪些数据参与拟合、候选比较和最终评价；一旦测试反馈回流到策略或算法，测试集就已变成开发数据，不能再作为一次性泛化证据。

例题 9.1 (两个候选分类规则的经验比较). 设 $\mathcal{X} = \{a, b\}$ 、 $\mathcal{Y} = \{0, 1\}$ ，训练集为 $T = \{(a, 0), (a, 0), (b, 1), (b, 0)\}$ 。假设空间只含 $f_0(x) \equiv 0$ 与 $f_1(a) = 0, f_1(b) = 1$ ，策略取 0-1 经验风险。求两个风险并按“风险相同则优先 f_0 ”的规则选模。

例题 9.1 解答

读题翻译 只需在给定四个训练样本上比较 f_0, f_1 的 0-1 经验风险；若两者并列，再应用题设优先 f_0 的规则。

已知与合法条件 f_0 恒预测 0； $f_1(a) = 0, f_1(b) = 1$ ；经验风险是四个误分类指示量的平均，并列规则已预先固定。

为什么想到这个方法 有限假设空间可逐候选、逐样本计数错误；风险最小化集合确定后，再单独执行并列规则。

方法选择 分别列出 f_0, f_1 在四个样本上的误分类指示量，求和除以 4，比较风险并处理并列。

推导/计算 固定训练集 $T = ((x_i, y_i))_{i=1}^4$ ，候选集 $\mathcal{F} = \{f_0, f_1\}$ ，经验风险仅在该训练集上计算：

$$\hat{R}_T(f) := \frac{1}{4} \sum_{i=1}^4 \mathbf{1}\{f(x_i) \neq y_i\},$$

$$\begin{aligned} (\mathbf{1}\{f_0(x_i) \neq y_i\})_{i=1}^4 &= (0, 0, 1, 0), & \hat{R}_T(f_0) &= \frac{1}{4}, \\ (\mathbf{1}\{f_1(x_i) \neq y_i\})_{i=1}^4 &= (0, 0, 0, 1), & \hat{R}_T(f_1) &= \frac{1}{4}. \end{aligned}$$

于是最小化集合为

$$\arg \min_{f \in \mathcal{F}} \hat{R}_T(f) = \{f_0, f_1\}.$$

独立核验 两组指示量之和都为 1, 故 $4\hat{R}_T(f_0) = 4\hat{R}_T(f_1) = 1$, 恰好恢复各自的一个错分; 这一并列只关于固定训练集, 不能推出总体风险相等。

结论 两个经验风险均为 1/4; 按题设并列规则最终选择 $\hat{f} = f_0$ 。

有限假设空间的经验风险选择算法

下面给出可逐项审查的严格伪代码; 它穷举有限假设空间, 不使用任何特定编程语言语法。输入为训练集 T 、有序候选集合 $\mathcal{F} = (f_1, \dots, f_M)$ 和可计算损失 L ; 输出为经验风险最小的模型、最小风险与完整比较记录。参数 N 是样本数, M 是候选模型数; 候选次序只用于风险并列时的确定性选择, 不应被误解为模型质量排序。初始化最优风险 $r^* \leftarrow +\infty$ 、最优模型 $\hat{f} \leftarrow \emptyset$, 比较记录为空。第 m 轮计算 f_m 在全部样本上的平均损失; 若严格小于当前最优风险, 则同步更新 r^* 与 $\hat{f}$, 相等时保留先出现的候选。停止条件是 $m = M$, 即每个候选恰被评价一次; 若 $N = 0$ 、 $M = 0$ 或损失不可计算, 则在进入循环前停止并报告输入不合法。收敛条件是 N, M 有限且每次损失计算在有限时间结束。算法终止时返回全局经验风险最小者; 这项最优性只相对于给定有限 $\mathcal{F}$ 和训练集成立。

有限假设空间的经验风险选择：五步阅读

输入。 写出数据对象、固定参数与必须成立的条件。

初始化。 标明主状态、计数器和第一个合法状态。

核心更新。 只手算一次从旧状态到候选状态的更新, 并指出何时提交。

数学停止。 写出能直接核验的停止证书; 预算耗尽不等同于收敛。

输出。 列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 9.1: 有限假设空间的经验风险选择

输入: 训练集 $T = \{(x_i, y_i)\}_{i=1}^N$; 有序候选 $\mathcal{F} = (f_1, \dots, f_M)$; 损失 L
输出: 最后合法记录与 $(\hat{f}, r^*)$; $m_{\text{done}}, l_{\text{done}}$; **status** 与诊断
数据: 预先冻结的风险并列规则; 单次预测 - 损失必须返回有限实数

- 1 若 N, M 、维数、接口或并列规则非法, 返回空记录、计数 0、**invalid_input** 及字段诊断
- 2 初始化 $r^* \leftarrow +\infty, \hat{f} \leftarrow \emptyset, m_{\text{done}} \leftarrow 0, l_{\text{done}} \leftarrow 0$ 并清空记录
- 3 对 $m \leftarrow 1$ 至 M 执行
 - 4 $s_m \leftarrow 0$
 - 5 对 $i \leftarrow 1$ 至 N 执行
 - 6 计算临时损失 $u_{mi} \leftarrow L(y_i, f_m(x_i))$; 若非有限, 返回旧记录与当前最优、**numerical_failure** 及 (m, i) 诊断
 - 7 $s_m \leftarrow s_m + u_{mi}$ 并增加 l_{done} ; 若和非有限则返回旧记录、**numerical_failure** 及累加诊断
 - 8 **结束**
 - 9 形成 $\hat{R}_m \leftarrow s_m/N$; 若非有限则返回旧记录、**numerical_failure** 及 m 诊断
 - 10 原子追加 $(m, \hat{R}_m)$ 、按固定并列规则更新 $(r^*, \hat{f})$ 并增加 m_{done}
- 11 **结束**
- 12 返回完整记录、 $\hat{f}, r^*$ 、**completed** 及并列/覆盖最终诊断

算法实现说明：首次阅读只做“逐候选算经验风险并取最小者”；实现时再处理接口失败、并列、覆盖率和状态 完整 C1-C14 契约

读前自检：复杂度分析：有限假设空间的经验风险选择算法。 先锁定有限假设空间的经验风险选择算法的条件“以下界假设 M 个候选函数均已给定，单个候选对单个样本完成预测与损失计算的最坏成本为 c ”：由 M 的总成本剥离一次迭代或一次样本因子，所得结果应满足保存全部 M 项比较记录则为 $O(M)$ 。

复杂度分析

复杂度假设。以下界假设 M 个候选函数均已给定，单个候选对单个样本完成预测与损失计算的最坏成本为 c ，且所有损失有限并可在单位额外空间累计。候选模型本身的训练与存储成本不包含在有限经验风险扫描中，若需要现场拟合必须另计。**训练复杂度。**设候选数为 M 、样本数为 N ，一次候选预测与损失计算成本上界为 c ；有限经验风险选择为 $O(MNc)$ ，当 c 视为常数时为 $O(MN)$ 。**预测复杂度。**选出 $\hat{f}$ 后，一个新样本的成本为 $C_{\text{pred}}(\hat{f})$ ；模型选择记录不会增加逐样本预测阶数。**存储复杂度。**除候选模型和输入数据外，只保留当前和最优风险需 $O(1)$ 额外空间；保存全部 M 项比较记录则为 $O(M)$ 。

适用条件与局限性

适用条件。有限穷举适合候选数较少、每个模型都能完整评价且需要可审计选择记录的任务；更一般的统计学习框架也适用于连续参数、无监督目标和强化学习，只需相应重定义数据反馈、模型与策略。

方法局限。候选空间巨大或连续时不能穷举；经验风险最小不自动保证总体风险最小；训练分布改变、反馈有偏或损失与实际目标不一致时，即使优化充分，所选模型也可能不适用于部署环境。

读前自检：常见错误与误用边界：有限假设空间的经验风险选择算法。 对有限假设空间的经验风险选择算法，条件“边界框首项禁止把“训练集误差低”等同于“新数据表现好””不可省；请把固定错误“把“训练集误差低”等同于“新数据表现好””中的对象、操作与结论按本节定义拆开，指出第一个不满足的定义条件，再把该处改为本节允许的写法，再用改写后的运算或判断有定义，且不再触发“把“训练集误差低”等同于“新数据表现好””作检查。

常见错误

典型误用包括：把“训练集误差低”等同于“新数据表现好”；把特征空间与输入空间强行视为同一集合；把概率模型误写成只输出类别的函数；把在线学习等同于强化学习；只给模型公式而不声明策略与算法；在同一数据上反复选模后仍套用固定模型的无偏性结论。

读前自检：易混淆概念对比：有限假设空间的经验风险选择算法。 有限假设空间的经验风险选择算法把问题限定在“对比表首个数据行是“模型与假设空间 | 一个候选关系还是全部候选的集合 | f_θ 与 $\mathcal{F} = \{f_\theta : \theta \in \Theta\}$ ””；请按列复述“模型与假设空间 | 一个候选关系还是全部候选的集合

| f_θ 与 $\mathcal{F} = \{f_\theta : \theta \in \Theta\}$ ” 中的对象、假设与结论，检查是否得到各列均对应首行对象“模型与假设空间”，且未与表中下一行互换。

易混淆概念对比		
概念	核心问题	典型形式
模型与假设空间	一个候选关系还是全部候选的集合	f_θ 与 $\mathcal{F} = \{f_\theta : \theta \in \Theta\}$
策略与算法	什么模型更好还是怎样找到它	风险最小化与梯度、穷举等求解过程
概率与非概率模型	输出分布还是确定函数值	$P_\theta(Y X)$ 与 $y = f_\theta(x)$
在线与批量学习	数据逐次到达更新还是集中训练	逐时刻更新 θ_t 与一次求得 $\hat{\theta}$
监督与强化学习	标签反馈还是动作后的延迟回报	(x, y) 样本对与状态 – 动作 – 奖励序列

9.1 统计学习与机器学习

统计学习以数据为研究对象，借助概率统计、信息论、优化和计算方法构建模型，并用模型预测或分析未观测数据。机器学习的范围常与统计学习高度重合；本讲义强调模型的统计假设、评价准则和可验证推导，因而使用“统计学习”这一名称。监督学习是其中从标注数据学习预测映射的重要部分，但不是全部。

统计学习具有五个相互约束的特点：以计算系统为实现平台，以数据而非手写规则为主要信息来源，以预测和结构分析为主要目标，以学习方法连接数据与模型，并由概率、统计、信息和优化理论共同支撑。研究工作可分为方法、理论和应用三个层次：方法提出可执行过程，理论研究有效性与效率，应用把任务结构、数据质量和代价纳入设计。

一个完整工作流可写为：明确任务与评价对象，收集并检查数据，确定假设空间，确定选择准则，执行算法得到模型，最后在未参与训练的数据或实际环境中评价。顺序不是形式要求：若先训练再决定评价指标，容易用结果反向选择有利指标；若训练与测试信息混合，所得评价会产生乐观偏差。

9.2 监督学习、无监督学习与强化学习

统计学习可按反馈形式、模型形式、数据到达方式和所用技巧分类。同一种方法可以同时拥有多个标签，例如一个方法既可以是监督的、概率的和在线的，也可以使用贝叶斯推断。分类的目的不是给算法贴唯一名称，而是明确它获得什么信息、输出什么对象以及受什么假设约束。

读前自检：基本分类。 在“强化学习的动作会影响以后看到的数据，奖励还可能延迟”成立时处理统计学习的基本框架中的基本分类：请把 $\phi(x)$ 展开一次并检查其类型或边界，并以“输出空间通常更小”是一种常见任务现象，不是数学定义中的必要条件判定结果。

定义 9.1 (三类基本学习问题). 监督学习从含目标输出的样本对中学习输入到输出的预测规律; 无监督学习只观测输入, 学习其表示、结构或生成规律; 强化学习中的智能体通过状态、动作、奖励和后续状态的交互序列学习使长期累计回报较大的策略。

监督学习的直接反馈是标签, 典型输出包括类别、实数或结构化序列。无监督学习没有逐样本“标准答案”, 聚类编号、低维表示和密度模型需通过任务目标评价。强化学习的动作会影响以后看到的数据, 奖励还可能延迟, 因此不能把每一步简单改写为相互独立的带标签样本。

半监督学习联合少量标注数据与大量未标注数据; 主动学习由系统选择最有信息的实例请求标注。二者通常更接近监督学习, 因为最终目标仍是预测输出, 但数据获得机制改变了。选择主动查询时还要记录标注成本和查询偏差。

9.3 输入、特征与输出空间

在监督学习中, 输入随机变量 X 取值于输入空间 $\mathcal{X}$, 输出随机变量 Y 取值于输出空间 $\mathcal{Y}$ 。一个具体输入 x 称为实例。原始输入可以是文本、图像或复合记录, 模型实际使用的特征由映射 $\phi: \mathcal{X} \rightarrow \mathcal{Z}$ 给出; $\mathcal{Z}$ 称特征空间。只有在 ϕ 为恒等映射时, 输入空间与特征空间才可不加区分。

若 $\phi(x) = (x^{(1)}, \dots, x^{(d)})^T \in \mathbb{R}^d$, 上标标记同一实例的特征分量; 训练集

$$T = \{(x_1, y_1), \dots, (x_N, y_N)\}$$

中的下标标记样本。模型通常定义在特征空间上, 可写为 $f: \mathcal{Z} \rightarrow \mathcal{Y}$, 完整预测是 $f(\phi(x))$ 。把上标与下标混用会混淆“第几个特征”和“第几个样本”。

输出空间的类型决定监督任务名称: Y 为连续实数时通常是回归, Y 取有限类别时是分类, Y 为可变长的标签序列时是标注或结构预测。输入与输出都可为向量或结构对象; “输出空间通常更小”是一种常见任务现象, 不是数学定义中的必要条件。

读前自检: 按模型分类。 固定同一参数域 Θ , 请比较确定性族 $\{f_\theta: \mathcal{X} \rightarrow \mathcal{Y}\}$ 与概率族 $\{P_\theta(Y|X)\}$; 核对后者对 Y 非负归一, 并用给定损失的 Bayes 决策把它转换为点预测。

9.4 假设空间与概率模型

定义 9.2 (假设空间). 假设空间 $\mathcal{F}$ 是学习算法获准选择的全部模型集合。确定性监督模型可写为

$$\mathcal{F} = \{f_\theta: \mathcal{X} \rightarrow \mathcal{Y} \mid \theta \in \Theta\},$$

概率监督模型可写为

$$\mathcal{F} = \{P_\theta(Y|X) \mid \theta \in \Theta\}.$$

参数空间 Θ 与函数或分布的形式共同限定学习范围。

概率模型输出满足非负与归一化条件的分布, 例如 $P_\theta(y|x)$; 需要点预测时可取概率最大的类别, 或按任务损失计算 Bayes 决策。非概率模型直接给出 $y = f_\theta(x)$ 。二者都描述输入与输出关系, 区别在于是否显式保存不确定性, 而不在于是否能够产生最终类别。

概率模型的推理以加法与乘法规则为基础：对离散 Y ,

$$P(x) = \sum_y P(x, y), \quad P(x, y) = P(x)P(y | x).$$

连续变量只需把求和换成对相应测度的积分。由乘法规则的两种分解还可推出 Bayes 公式。每次使用这些公式都要说明求和或积分变量，并检查所得边缘分布仍非负且归一化。

模型还可沿另外两条轴分类。若 $f(x)$ 或 $g(x)$ 对输入是线性映射，则称为线性模型，否则为非线性模型；这里判断的是模型的函数结构，不是参数估计算法是否线性。参数化模型由固定维数的有限参数刻画，非参数化模型的有效复杂度可以随数据量增长。“非参数”不表示完全没有参数，而是模型容量不由预先固定的有限维参数完全限制。

无监督情形可用 $P_\theta(Z | X)$ 描述表示或聚类归属，用 $P_\theta(X | Z)$ 描述潜在结构怎样生成观测，也可用 $z = g_\theta(x)$ 给出确定表示。强化学习还可区分显式学习环境转移模型的方法与不直接学习环境模型的方法。由此可见，“概率/非概率”“有模型/无模型”是不同分类轴。

条件概率模型与决策函数在特定操作后可以互相导出：从 $P_\theta(Y | X)$ 可通过最小化条件期望损失得到决策；反方向则需补充分数标定或噪声假设，单个类别函数本身不能唯一恢复概率。

读前自检：按算法分类。 围绕按算法分类，先采用条件“在线学习在时刻 t 先用当前参数产生 $\hat{y}_t = f_{\theta_t}(x_t)$ ”，再把 θ_{t+1} 展开一次并检查其类型或边界；最后验证监督、无监督和强化学习都可有在线形式，强化交互天然带有逐时刻特征，但二者概念并不等同。

9.5 模型、策略与算法

按数据到达和更新方式，学习可分为批量学习与在线学习。批量学习在获得一批数据后集中求得模型 $\hat{\theta} = \mathcal{A}(T)$ ，随后用于预测；在线学习在时刻 t 先用当前参数产生 $\hat{y}_t = f_{\theta_t}(x_t)$ ，收到反馈后再更新

$$\theta_{t+1} = U(\theta_t, x_t, \text{feedback}_t).$$

在线方式适合数据流、存储受限或分布随时间变化的环境，但每次更新信息较少，结果还依赖到达次序。监督、无监督和强化学习都可有在线形式，强化交互天然带有逐时刻特征，但二者概念并不等同。

按核心技巧还可区分贝叶斯方法与核方法等。贝叶斯方法用先验与似然得到后验，并依据后验进行估计或预测；核方法通过 $K(x, x') = \langle \phi(x), \phi(x') \rangle$ 计算特征空间内积，避免显式构造高维 $\phi(x)$ 。这两类名称描述所用推理或表示技巧，不直接规定任务是监督、无监督还是在线。

若 D 表示观测数据，贝叶斯更新和后验预测分别为

$$P(\theta | D) = \frac{P(\theta)P(D | \theta)}{P(D)}, \quad P(x | D) = \int P(x | \theta, D)P(\theta | D) d\theta.$$

前式中 $P(D)$ 负责归一化，后式对参数不确定性做平均。极大似然估计只寻找使 $P(D | \theta)$ 最大的点；在先验为常数且最大点存在时，最大后验点与极大似然点可重合，但完整后验分布仍比单个点包含更多不确定性信息。

读前自检：统计学习方法三要素。 统计学习方法三要素中的“三者的接口必须匹配：模型输出要能被损失评价，策略形成的目标要能被算法计算或近似”决定可执行范围；请把统计学习方法展开一次并检查其类型或边界，结果须满足展开后的量满足定义中的域、维数或符号限制。

一种统计学习方法由模型、策略和算法构成，可用

$$\text{统计学习方法} = \text{模型} + \text{策略} + \text{算法}$$

概括。三者的接口必须匹配：模型输出要能被损失评价，策略形成的目标要能被算法计算或近似，算法返回的对象必须仍属于假设空间。只更换一个要素就可能形成另一种方法。

在监督学习中，模型是条件概率分布或决策函数，假设空间包含全部候选。以线性回归为例，模型族可为 $f_{w,b}(x) = w^T x + b$ ，策略可取平方经验风险，算法可用正规方程或迭代优化。相同线性模型若改用绝对损失，策略已经改变；相同平方损失若把模型换成非线性函数族，搜索空间也已改变。

设计算法规范时还应逐项写明输入输出、参数含义、初始化、更新和停止条件，并说明计算复杂度与适用范围。本章算法 9.1 给出有限空间的精确版本；连续参数算法通常以目标变化、梯度范数或迭代上限停止，收敛结论则取决于目标结构和更新规则。

本章共 12 道练习。每道题干后立即给出同号解析；长解析可自然跨页，续页标题保留题号。

练习 9.1 (完整任务表述). 某系统根据邮件文本判断“正常”或“垃圾”。请分别指出输入、输出、数据反馈、候选模型、策略和算法需要声明的内容。

练习 9.1 解析

先固定邮件总体 $\mathcal{X}$ 、标签空间 $\mathcal{Y} = \{\text{正常}, \text{垃圾}\}$ 与带标签训练集 $T = \{(x_i, y_i)\}_{i=1}^N \subset \mathcal{X} \times \mathcal{Y}$ ，其中 $N \geq 1$ 。六个对象可形式化为

输入与输出： $x \in \mathcal{X}, y \in \mathcal{Y}$,

反馈与表示： y_i 由预定标注规则取得， $z_i = \phi(x_i) \in \mathbb{R}^d$,

候选模型： $\mathcal{F} = \{f_\theta : \mathbb{R}^d \rightarrow \mathcal{Y} \mid \theta \in \Theta\}$,

策略： $\hat{R}_T(\theta) = \frac{1}{N} \sum_{i=1}^N L(y_i, f_\theta(z_i))$,

算法： $\hat{\theta} \in \arg \min_{\theta \in \Theta} \hat{R}_T(\theta)$.

损失 L 须写明漏报与误报代价；算法还须规定初始化、停止条件及最小点不唯一时的并列规则。

练习 9.2 (研究层次). 把下列工作分别归入方法、理论或应用研究：提出一种新的更新规则；证明其样本量增大时风险收敛；把它用于医学筛查并设计漏诊代价。

练习 9.2 解析

令 M, T, A 分别表示方法、理论与应用研究，分类判据为“主要产出是什么”：

$$\begin{aligned} \text{新更新规则 } U(\theta_t, \text{data}_t) &\mapsto M, \\ [\text{条件 } C_N] \implies R(\hat{f}_N) \rightarrow R^\star &\mapsto T, \\ (\mathcal{X}, \mathcal{Y}, L_{FN}, L_{FP})_{\text{screening}} &\mapsto A. \end{aligned}$$

因此三项依次属于方法、理论、应用；它们相互衔接，但一个工作可同时跨越多个层次。

练习 9.3 (信息泄漏诊断). 研究者先查看测试集结果，再从十种特征方案中选择测试准确率最高者并报告同一准确率。指出问题并给出可复现修正。

练习 9.3 解析

原流程把测试误差写入了选择规则

$$\begin{aligned} j^\star_{\text{leak}} &= \arg \min_{1 \leq j \leq 10} \hat{R}_{\text{test}}(\hat{f}_j), \\ \hat{f}_j &= \mathcal{A}_j(D_{\text{train}}), \end{aligned}$$

所以 D_{test} 不再独立于最终模型。可复现修正是预先作互不相交的划分

$$\begin{aligned} D &= D_{\text{tr}} \dot{\cup} D_{\text{val}} \dot{\cup} D_{\text{te}}, \\ \hat{f}_j &= \mathcal{A}_j(D_{\text{tr}}), \\ j^\star &= \arg \min_{1 \leq j \leq 10} \hat{R}_{\text{val}}(\hat{f}_j), \\ \text{最终报告} &= \hat{R}_{\text{te}}(\hat{f}_{j^\star}). \end{aligned}$$

D_{te} 只在方案、指标和并列规则冻结后使用一次；若数据独立同分布抽样，它才提供独立的最终评估。

练习 9.4 (场景分类). 判断下列任务的基本类型并说明反馈：依据历史房价预测新房价格；把无标签新闻分组；机器人移动后收到耗电与到达奖励并改进路线。

练习 9.4 解析

按观测到的反馈对象分类：

$$\begin{aligned} \{(x_i, y_i) : y_i \in \mathbb{R}\}_{i=1}^N &\mapsto \text{监督回归 (房价)}, \\ \{x_i\}_{i=1}^N, \quad y_i \text{ 不可观测} &\mapsto \text{无监督聚类 (新闻)}, \\ (S_t, A_t, R_{t+1}, S_{t+1})_{t \geq 0}, \quad G_t = \sum_{k \geq 0} \gamma^k R_{t+k+1} &\mapsto \text{强化学习 (机器人)}. \end{aligned}$$

第三类中动作会改变后续状态分布，故不能把各时刻反馈当成相互独立的固定标签。

练习 9.5 (半监督与主动学习). 一个系统有一万张未标注图像和一百张已标注图像。比较“同时使用全部图像训练”与“挑选最不确定图像请专家标注后再训练”的学习类型。

练习 9.5 解析

记已标注集与未标注池为

$$D_L = \{(x_i, y_i)\}_{i=1}^{100}, \quad D_U = \{x_j\}_{j=1}^{10000}.$$

两种机制分别为

$$\begin{aligned} \hat{f}_{\text{semi}} &= \mathcal{A}(D_L, D_U) && (\text{半监督: 标签集合不由算法扩充}), \\ x^\star &\in \arg \max_{x \in D_U} u_{\hat{f}}(x), \quad D_L \leftarrow D_L \cup \{(x^\star, y^\star)\} && (\text{主动学习}). \end{aligned}$$

主动查询会改变被标注样本的分布, 因此还须记录查询规则、标注预算和标注成本。

练习 9.6 (延迟回报). 某策略产生三步奖励 $r_1 = 0, r_2 = -1, r_3 = 4$, 折扣因子 $\gamma = 1/2$ 。计算从第一步开始的折扣回报 $G_1 = r_1 + \gamma r_2 + \gamma^2 r_3$, 并说明为何不能只按 r_1 评价第一步动作。

练习 9.6 解析

奖励是同一条轨迹上的随机反馈; 对给定实现 $r_1 = 0, r_2 = -1, r_3 = 4$,

$$\begin{aligned} G_1 &= r_1 + \gamma r_2 + \gamma^2 r_3 \\ &= 0 + \frac{1}{2}(-1) + \left(\frac{1}{2}\right)^2 4 \\ &= -\frac{1}{2} + 1 = \frac{1}{2}. \end{aligned}$$

$r_1 = 0$ 只描述即时后果, 而 G_1 还纳入动作通过后续状态带来的奖励, 所以不能仅用 r_1 评价第一步动作。

练习 9.7 (样本与特征索引). 数据矩阵 $Z \in \mathbb{R}^{40 \times 6}$ 按行存放样本。写出第 7 个样本、第 3 个特征列和分量 $Z_{7,3}$ 的维数与含义。

练习 9.7 解析

由“行存样本”且 $Z \in \mathbb{R}^{40 \times 6}$,

$$\begin{aligned} z_7^\top &= Z_{7,:} \in \mathbb{R}^{1 \times 6}, \quad z_7 \in \mathbb{R}^6, \\ Z_{:,3} &\in \mathbb{R}^{40}, \quad Z_{7,3} \in \mathbb{R}. \end{aligned}$$

因此 z_7 是第 7 个样本的六维特征向量, $Z_{:,3}$ 收集全部 40 个样本的第 3 个特征, 而 $Z_{7,3}$ 是二者交叉处的标量。

练习 9.8 (输出空间与任务). 分别判断 $y = \mathbb{R}$ 、 $y = \{\text{红, 黄, 绿}\}$ 、 $y = \bigcup_{m \geq 1} \{0, 1\}^m$ 通常对应哪类监督任务。

练习 9.8 解析

输出对象的目标域直接给出任务类型：

$$\begin{aligned} f: \mathcal{X} \rightarrow \mathbb{R} &\implies \text{实值回归,} \\ f: \mathcal{X} \rightarrow \{\text{红, 黄, 绿}\} &\implies \text{三分类,} \\ f: \mathcal{X} \rightarrow \bigcup_{m \geq 1} \{0, 1\}^m &\implies \text{可变长结构化序列预测.} \end{aligned}$$

最后一个并集中的各分支长度不同，故输出域不是某个固定维数的 $\{0, 1\}^m$ 。

练习 9.9 (概率模型归一化). 二分类模型给出未归一化分数 $s_0(x) = 1$ 、 $s_1(x) = 3$ 。按 $P(y | x) = s_y(x)/(s_0(x) + s_1(x))$ 归一化，求两类概率与最大概率决策。

练习 9.9 解析

支持集为 $y = \{0, 1\}$ ，且两个分数非负、总和严格为正。于是

$$\begin{aligned} S(x) &= \sum_{y \in \mathcal{Y}} s_y(x) = 1 + 3 = 4, \\ P(0 | x) &= \frac{s_0(x)}{S(x)} = \frac{1}{4}, \\ P(1 | x) &= \frac{s_1(x)}{S(x)} = \frac{3}{4}, \\ \sum_{y \in \mathcal{Y}} P(y | x) &= 1. \end{aligned}$$

在 0-1 损失下 $\arg \max_{y \in \mathcal{Y}} P(y | x) = \{1\}$ ，故唯一输出为 1。

练习 9.10 (模型与决策). 已知 $P(Y = 1 | x) = 0.6$ 。若把正类误判为负类的损失为 5，把负类误判为正类的损失为 1，比较输出 0 和 1 的条件期望损失。

练习 9.10 解析

令动作域 $\mathcal{A} = \{0, 1\}$ ，并取正确分类损失为 0。由 $P(Y = 1 | x) = 0.6$ 、 $P(Y = 0 | x) = 0.4$ ，

$$\begin{aligned} \rho(0 | x) &= 5P(Y = 1 | x) + 0P(Y = 0 | x) = 3, \\ \rho(1 | x) &= 0P(Y = 1 | x) + 1P(Y = 0 | x) = 0.4, \\ \arg \min_{a \in \mathcal{A}} \rho(a | x) &= \{1\}. \end{aligned}$$

因此代价敏感决策输出 1；这里它恰与最大后验决策一致，但依据是条件风险而非仅比较概率。

练习 9.11 (三要素辨认). 某方法使用 $f_{w,b}(x) = w^\top x + b$, 最小化平方经验风险, 并用梯度下降求参数。分别指出模型、策略和算法。

练习 9.11 解析

设 $x_i, w \in \mathbb{R}^d$, $b, y_i \in \mathbb{R}$ 且 $N \geq 1$ 。三要素依次是

$$\mathcal{F} = \{f_{w,b}(x) = w^\top x + b : (w, b) \in \mathbb{R}^{d+1}\}, \quad \text{模型,}$$

$$J(w, b) = \frac{1}{N} \sum_{i=1}^N (y_i - w^\top x_i - b)^2, \quad \text{策略,}$$

$$(w_{t+1}, b_{t+1}) = (w_t, b_t) - \eta_t \nabla J(w_t, b_t), \quad \text{算法.}$$

梯度下降还需给定初值、步长 $\eta_t > 0$ 与停止条件; 只写 $\min J$ 并未指定如何取得最小点。

练习 9.12 (在线均值更新). 在线估计均值时令 $\mu_1 = x_1$, 对 $t \geq 2$ 使用 $\mu_t = \mu_{t-1} + (x_t - \mu_{t-1})/t$ 。样本依次为 2, 4, 9, 求 μ_1, μ_2, μ_3 并核对最终结果。

练习 9.12 解析

对按顺序到达的实数流 $(x_1, x_2, x_3) = (2, 4, 9)$,

$$\mu_1 = x_1 = 2,$$

$$\mu_2 = \mu_1 + \frac{x_2 - \mu_1}{2} = 2 + \frac{4 - 2}{2} = 3,$$

$$\mu_3 = \mu_2 + \frac{x_3 - \mu_2}{3} = 3 + \frac{9 - 3}{3} = 5,$$

$$\frac{1}{3} \sum_{i=1}^3 x_i = \frac{2 + 4 + 9}{3} = 5.$$

最终在线均值与批量均值一致; 此结论来自该递推式精确维护前 t 个样本均值。

读前自检: 本章结论与下一步。 统计学习的基本框架章末由“数据反馈、输入输出空间、假设空间与三要素”落到“冻结任务边界、训练数据和并列规则后执行学习与评价”; 请把前者产出和后者输入逐项对齐, 固定核对前者末项的输出类型能否作为后者首项的输入类型。

本章结论与下一步

核心结论: 数据反馈、输入输出空间、假设空间与三要素

关键依据: 用损失把模型输出变成策略目标, 再由算法搜索候选

可执行自检: 冻结任务边界、训练数据和并列规则后执行学习与评价

适用边界: 比较不同学习类型或完整描述一种方法

下一步: 进入章 10, 区分拟合、选择与最终评估

1. 能否把一个实际任务写成输入空间、反馈、假设空间、损失和算法均明确的学习问题? 未通过时回看节 9.1 及本章严格定义。
2. 能否仅依据反馈结构区分监督、无监督和强化学习, 并辨认半监督与主动学习? 未通过时回看节 9.2。

3. 能否区分样本下标与特征上标, 并说明 $\phi: \mathcal{X} \rightarrow \mathcal{Z}$ 何时丢失信息? 未通过时回看节 9.3。
4. 能否区分一个模型与假设空间、概率输出与最终决策? 未通过时回看节 9.4。
5. 能否为任一方法分别写出模型、策略、算法及输入、更新、停止和复杂度? 未通过时回看节 9.5 与算法 9.1。

第 10 章 模型评估、选择与泛化

读前自检：本章可检验学习目标。 模型评估、选择与泛化学习目标固定核验“能够从损失函数严格定义期望风险、经验风险、训练误差、测试误差与泛化误差，并阐明它们各自依赖的数据”；请实际完成“从损失函数严格定义期望风险、经验风险、训练误差、测试误差与泛化误差，并阐明它们各自依赖的数据”，并用“中间结果逐项包含首目标“能够从损失函数严格定义期望风险、经验风险、训练误差、测试误差与泛化误差，并阐明它们各自依赖的数据”声明的对象、条件与结论”判定通过或失败。

读前自检：先修自检。 模型评估、选择与泛化先修自检固定核验“给定离散联合分布，能否计算函数 $g(X, Y)$ 的期望”；请给定离散联合分布，实际计算函数 $g(X, Y)$ 的期望并写出中间结果，再按“ $g(X, Y)$ 的计算或证明结果满足首项所列等式、定义域或判断”明确判为通过或失败。

本章地图

核心问题： 怎样避免把训练拟合误当成未知数据表现

可检验学习目标：

- 能够从损失函数严格定义期望风险、经验风险、训练误差、测试误差与泛化误差，并阐明它们各自依赖的数据；
- 能够用正则化和交叉验证完成模型选择，写出无数据泄漏的折叠评估流程并分析计算成本；
- 能够逐步证明有限假设空间的泛化误差上界，解释样本容量、假设空间容量与置信度之间的定量关系；
- 能够比较生成方法与判别方法的学习目标、信息利用方式、适用条件和局限。

最短先修： 本章需要上一章中的监督学习三要素、训练集与假设空间，还需要条件概率、期望、独立同分布抽样、指示函数、对数、范数和优化中的最小化记号。泛化界证明将使用 Hoeffding 不等式与有限事件并集界。

依赖路线： 损失函数 → 期望风险与经验风险 → 经验风险最小化；训练误差与测试误差 → 过拟合诊断 → 正则化和交叉验证；独立同分布样本 → 集中不等式 → 有限假设空间泛化界；联合分布与条件分布 → 生成方法和判别方法。

完成标准与返回： 数据角色或选择流程混淆时返回风险与交叉验证节

本章符号表		
符号	取值	含义
$Z = (X, Y)$	$\mathcal{X} \times \mathcal{Y}$	输入输出对，服从未知分布 P
$T = (z_1, \dots, z_N)$	样本序列	独立同分布训练样本
$\mathcal{F}$	函数集合	候选模型或假设空间
$L(y, f(x))$	非负实数	预测 $f(x)$ 相对真实输出 y 的损失
$R(f), \hat{R}_N(f)$	非负实数	期望风险与训练样本上的经验风险
$\lambda, J(f)$	非负数、非负函数	正则化强度与复杂度函数
K, M	正整数	交叉验证折数与候选配置数
d, δ	正整数、 $(0, 1)$	有限假设数与失败概率上限

10.1 损失函数与风险函数

监督学习必须回答一个先于优化的问题：什么样的预测算作好预测。损失函数度量一次预测的代价，风险函数则把这种代价放回数据分布中平均；更换损失函数就可能更换最优模型。

读前自检：策略。 模型评估、选择与泛化中的策略依赖“对数损失的期望在真实条件分布处达到最小”；请据此把 $R(f)$ 展开一次并检查其类型或边界，并直接核对它不仅要求类别预测正确，还要求概率校准合理。

学习策略规定如何从假设空间 $\mathcal{F}$ 中比较模型。理想策略是选择期望风险最小的模型，但未知分布使期望风险不能直接计算，因此实际策略要用样本构造可计算的替代目标，并控制替代目标与期望风险之间的偏差。

定义 10.1 (损失函数与期望风险). 设 $f \in \mathcal{F}$, 损失函数 $L : \mathcal{Y} \times \hat{\mathcal{Y}} \rightarrow [0, \infty)$. 模型 f 的期望风险定义为

$$R(f) = \mathbb{E}_{(X,Y) \sim P}[L(Y, f(X))].$$

离散情形对所有 (x, y) 求和；连续情形对联合分布积分。期望风险也称期望损失。

常用损失具有不同的统计含义：

$$L_{01}(y, f(x)) = \mathbf{1}\{y \neq f(x)\},$$
$$L_2(y, f(x)) = (y - f(x))^2,$$
$$L_1(y, f(x)) = |y - f(x)|,$$
$$L_{\log}(y, q(\cdot | x)) = -\log q(y | x).$$

0-1 损失直接对应分类错误率但通常不便优化；平方损失强调大残差；绝对损失对离群点更稳健；对数损失评价整个预测分布并对给真实类别极小概率施加强惩罚。

概率解释

对数损失的期望在真实条件分布处达到最小, 因此它不仅要求类别预测正确, 还要求概率校准合理。平方损失下的 Bayes 预测是条件均值, 绝对损失下是条件中位数, 0-1 损失下是条件众数。

读前自检：算法。 模型评估、选择与泛化以“给定训练样本 $T = \{(x_i, y_i)\}_{i=1}^N$ ”为约束; 请沿 $\int L(y, f(x)) d\hat{P}_N(x, y)$ 标出输入域、输出域和一次运算结果的形状, 并确认推导第2步: 以 $\hat{P}_N$ 替代 P 。

10.2 经验风险与期望风险

算法是实现学习策略的具体计算过程。给定训练样本 $T = \{(x_i, y_i)\}_{i=1}^N$, 以经验分布替代未知分布, 可得到经验风险

$$\hat{R}_N(f) = \frac{1}{N} \sum_{i=1}^N L(y_i, f(x_i)).$$

在固定假设空间内, 经验风险最小化选择

$$\hat{f}_N \in \arg \min_{f \in \mathcal{F}} \hat{R}_N(f).$$

模型。 候选模型由假设空间 $\mathcal{F}$ 给定; 同一参数化族在不同参数处对应不同候选函数。模型规定可以表达什么, 不能表达的关系无法靠优化补回。

学习策略。 经验风险最小化只比较样本拟合; 结构风险最小化还加入复杂度:

$$\hat{f}_\lambda \in \arg \min_{f \in \mathcal{F}} \{\hat{R}_N(f) + \lambda J(f)\}, \quad \lambda \geq 0.$$

前者追求样本内最优, 后者用可控偏差换取较小波动和更好的样本外表现。

阅读目标: 把训练样本表示成经验测度, 并由积分直接得到样本平均损失。

对象: 经验分布 $\hat{P}_N = N^{-1} \sum_i \delta_{(x_i, y_i)}$ 与损失 $L(y, f(x))$ 。

合法条件: 样本数 $N \geq 1$; 损失在所有样本点上有定义。

第一步: 先把风险泛函中的总体分布 P 替换为经验分布 $\hat{P}_N$ 。

推导目标

从经验分布逐步推出经验风险, 并说明为何最小化经验风险是对理想风险最小化的样本近似。

推导准备

把训练样本视为经验分布 $\hat{P}_N = \frac{1}{N} \sum_{i=1}^N \delta_{(x_i, y_i)}$ 的全部质量点; δ_z 表示集中在 z 处的点质量。

推导第1步: 理想目标为 $R(f) = \int L(y, f(x)) dP(x, y)$, 未知量只在分布 P 。

推导第2步：以 $\hat{P}_N$ 替代 P ，点质量积分化为有限和：

$$\int L(y, f(x)) d\hat{P}_N(x, y) = \frac{1}{N} \sum_{i=1}^N L(y_i, f(x_i)) = \hat{R}_N(f).$$

推导第3步：在同一 $\mathcal{F}$ 内最小化这个可计算量得到 $\hat{f}_N$ 。对固定 f ，大数定律使 $\hat{R}_N(f)$ 随 N 增加趋近 $R(f)$ ；若 f 也由同一数据选择，还需控制整个假设空间上的偏差，这正是后续泛化界解决的问题。

当 f 给出条件概率且采用对数损失时，

$$\hat{R}_N(f) = -\frac{1}{N} \sum_{i=1}^N \log p_f(y_i | x_i),$$

最小化它等价于最大化条件似然。目标乘以正的常数 N 不会改变最优解。

读前自检：模型评估与模型选择。 模型选择固定使用训练折拟合、验证折选择，模型评估固定使用一次封存测试集；请标出候选配置锁定前后两个阶段，核对测试结果没有反馈到候选或超参数选择。

10.3 训练误差与测试误差

模型评估针对已经确定的学习流程估计样本外表现；模型选择则在候选模型、超参数或特征方案之间作决定。若用测试集反复挑选候选，测试集已经参与选择，所得数值不再是独立的最终评估。

读前自检：训练误差与测试误差。 对训练误差与测试误差，条件“对独立测试集 $T' = \{(x'_j, y'_j)\}_{j=1}^{N'}$ ”不可省；请把 $e_{\text{test}}(\hat{f})$ 展开一次并检查其类型或边界，再用展开后的量满足定义中的域、维数或符号限制作检查。

读前自检：训练误差与测试误差。 训练误差与测试误差把问题限定在“对独立测试集 $T' = \{(x'_j, y'_j)\}_{j=1}^{N'}$ ”；请把 $e_{\text{test}}(\hat{f})$ 展开一次并检查其类型或边界，检查是否得到设学习算法从训练集得到 $\hat{f}$ 。

定义 10.2 (训练误差与测试误差). 设学习算法从训练集得到 $\hat{f}$ 。训练误差是 $\hat{f}$ 在训练集上的平均损失。对独立测试集 $T' = \{(x'_j, y'_j)\}_{j=1}^{N'}$ ，测试误差为

$$e_{\text{test}}(\hat{f}) = \frac{1}{N'} \sum_{j=1}^{N'} L(y'_j, \hat{f}(x'_j)).$$

只有测试集未参与拟合、超参数选择、阈值选择和特征选择时，它才是有效的样本外评估。

在 0-1 损失下, 测试错误率为 $N'^{-1} \sum_j \mathbf{1}\{y'_j \neq \hat{f}(x'_j)\}$, 准确率为 $N'^{-1} \sum_j \mathbf{1}\{y'_j = \hat{f}(x'_j)\}$, 二者之和为 1。训练误差很大常提示欠拟合、优化失败或特征不足; 训练误差很小而测试误差明显较大常提示过拟合, 但差距也受样本随机性影响。

例题 10.1 (训练—测试错误率差距)。某分类器训练集上有 200 个样本并错分 10 个, 独立测试集上有 80 个样本并错分 12 个。计算训练错误率、测试错误率及二者之差, 并解释其边界。

例题 10.1 解答

读题翻译 分别把训练、测试错分数除以各自样本数, 并按题意计算“测试错误率减训练错误率”; 最后解释这个样本差距能说明什么。

已知与合法条件 训练集大小为 200、错分 10; 独立测试集大小为 80、错分 12; 差值方向固定为 $\hat{R}_{te} - \hat{R}_{tr}$ 。

为什么想到这个方法 错误率是错分频数除以对应样本数; 两个样本量不同, 不能直接比较错分个数。

方法选择 先分别计算两个错误率, 再作测试减训练, 并用乘回样本数和概率边界复核。

推导/计算

$$\begin{aligned}\hat{R}_{tr} &= \frac{10}{200} = 0.05, \\ \hat{R}_{te} &= \frac{12}{80} = 0.15, \\ \hat{R}_{te} - \hat{R}_{tr} &= 0.15 - 0.05 = 0.10.\end{aligned}$$

独立核验 $0.05 \times 200 = 10$ 、 $0.15 \times 80 = 12$, 均恢复原错分数; 两个错误率在 $[0, 1]$ 内, 差 0.10 也属于允许的 $[-1, 1]$ 范围。

结论 训练错误率为 5%, 测试错误率为 15%, 测试减训练的差为 10 个百分点; 它只是本次独立划分的样本估计, 可提示泛化差距, 但不能单独证明模型必然过拟合。

读前自检：过拟合与模型选择。 若增加模型复杂度后训练误差下降而独立验证误差上升, 请据此判定过拟合, 并核对模型选择应比较验证风险而不是继续最小化训练误差。

10.4 过拟合、正则化与模型选择

过拟合是模型把训练样本中的偶然波动也当作可推广规律, 表现为训练误差继续降低而样本外误差反而上升。模型选择的目标不是找到训练误差最小的候选, 而是找到预期样本外风险较小的学习流程。

读前自检：正则化与交叉验证。 对固定候选正则强度表, 训练阶段把 $\lambda J(f)$ 加入经验风险, 选择阶段只比较各候选的折外验证损失; 请核对正则化改变训练准则, 而交叉验证决定最终 λ 。

正则化通过改变拟合目标控制复杂度, 交叉验证通过重复样本外评估选择复杂度。前者进入训练准则, 后者进入选择准则; 实践中常由交叉验证选择正则化强度。

读前自检：正则化。 正则化经验风险为 $N^{-1} \sum_i L(y_i, f(x_i)) + \lambda J(f)$ ，其中 $J(f) \geq 0$ ；请比较 $\lambda = 0$ 与 $\lambda > 0$ 的同一候选，核对 ℓ_2 光滑而 ℓ_1 在零点需次梯度。

定义 10.3 (正则化经验风险). 给定复杂度函数 $J(f) \geq 0$ 和 $\lambda \geq 0$ ，正则化学习求解

$$\min_{f \in \mathcal{F}} \left\{ \frac{1}{N} \sum_{i=1}^N L(y_i, f(x_i)) + \lambda J(f) \right\}.$$

$\lambda = 0$ 退化为经验风险最小化； λ 增大时，复杂度惩罚相对更重要。

线性回归中常见 $J(w) = \frac{1}{2} \|w\|_2^2$ 与 $J(w) = \|w\|_1$ 。 ℓ_2 正则连续收缩全部系数， ℓ_1 正则的折角可把部分系数压到零。惩罚量必须结合特征尺度解释，未标准化的特征会受到不一致的有效惩罚。

几何理解

几何解释。 ℓ_2 约束集边界光滑，最优等高线通常在非坐标轴位置相切； ℓ_1 约束集带有坐标轴尖角，等高线更可能在尖角处首次接触，从而产生零系数。正则化也可理解为限制搜索区域。

概率解释

平方损失配合 ℓ_2 惩罚对应高斯噪声下的高斯参数先验； ℓ_1 惩罚对应 Laplace 型先验。最大后验估计的负对数目标由负对数似然与负对数先验相加，因此正则化可解释为对复杂参数赋予较小先验权重。

优化解释

优化解释。 ℓ_2 惩罚提高光滑目标的曲率并缓解病态； ℓ_1 目标在零点不可微，需用次梯度、近端或坐标方法。正则化强度既改变统计偏差与方差，也改变数值条件，不能只按优化收敛速度选择。




图 10.1 模型复杂度增加时训练误差通常下降，而验证误差可能先降后升。

在图 10.1 上选择容量时只使用验证曲线和预先约定的规则；训练误差持续下降并不构成增大容量的证据。灰度阅读时按线型和标记识别：实线表示训练误差，虚线表示验证误差，金色实心点和竖向参考线共同标出按预先约定规则选中的复杂度。候选锁定后还需在未参与选择的数据上报告一次最终误差。

例题 10.2 (验证误差选择多项式次数). 候选多项式次数为 1, 3, 9，验证均方误差分别为 0.42, 0.18, 0.31，训练均方误差分别为 0.40, 0.12, 0.01。按验证误差选择次数。

例题 10.2 解答

读题翻译 三个次数要按同一验证协议下的验证均方误差比较；训练误差只用于观察拟合程度，不能替代验证误差作次数选择。

已知与合法条件 候选域为 {1, 3, 9}，三者使用同一训练/验证划分和均方误差口径；最小验证误差规则及并列时的低复杂度优先规则在查看结果前固定，测试集保持封存。

为什么想到这个方法 逐项比较 $\hat{R}_{\text{val}}(d)$ 并取最小者；再用最优值与次优值之差核对是否触发并列规则。

方法选择 列出训练与验证误差向量，求验证误差的唯一最小点，最后检查选择过程没有读取测试结果。

解答 (续)

推导/计算 令候选域 $\mathcal{D} = \{1, 3, 9\}$, 各模型只在训练子集拟合, 验证子集仅用于选择。计算为

$$\begin{aligned}(\hat{R}_{\text{tr}}(d))_{d \in \mathcal{D}} &= (0.40, 0.12, 0.01), \\(\hat{R}_{\text{val}}(d))_{d \in \mathcal{D}} &= (0.42, 0.18, 0.31), \\d^{\star} \in \arg \min_{d \in \mathcal{D}} \hat{R}_{\text{val}}(d) &= \{3\}.\end{aligned}$$

独立比较可见 $0.18 < 0.31 < 0.42$, 最优验证误差与次优值的间隔为 $0.31 - 0.18 = 0.13 > 0$, 所以并列规则不会被触发。九次模型训练误差最低却验证误差上升; 一次划分下的这一现象仍需重复划分或交叉验证检查稳定性。


独立核验 选择只读取训练/验证结果, $d = 3$ 的验证误差唯一最小; 测试集未参与次数选择, 最终只对锁定模型评估一次。

结论 按验证误差规则唯一选择三次模型 $d = 3$; 训练误差更低的九次模型不改变这一结论。

10.5 交叉验证

简单留出法把数据分为训练、验证与测试三部分; k 折交叉验证把用于开发的数据划为 K 个互不相交折, 每轮用一个折验证、其余折训练, 最后平均验证损失; 当 $K = N$ 时称留一交叉验证。分类问题通常使用分层划分维持类别比例, 分组或时间相关数据则必须按组或时间切分, 不能假设样本可任意打乱。

学习算法不仅包含单次模型拟合, 还包含预处理、特征选择、超参数搜索和决策阈值选择。所有从数据估计的步骤都必须放入训练折内部, 否则验证折的信息会提前进入模型。



读前自检: 无泄漏的模型选择: 执行契约。 无泄漏的模型选择输入“开发数据 D 、有序候选配置 Λ 、完整训练流程、折数 K 、冻结划分/失败/并列规则与全局拟合预算 B_{fit} ”, 条件“ $K \geq 2$ 、候选与数据非空, 划分规则可执行, 损失/硬约束/失败和并列规则预先冻结, $B_{\text{fit}} \in \mathbb{N}_0$ ”; 请执行“单折拟合、预测、损失与硬约束诊断完成后才原子写入该折记录”, 以“全部候选 - 折任务及一次重训完成、拟合预算不足或首次不可恢复失败时停止”判停。

无泄漏的模型选择：五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 10.1: 无泄漏的 k 折模型选择

输入: 开发数据 D 、候选集合 Λ 、折数 K 与完整训练流程 A_λ

输出: 选中配置 λ^* 、全开发集重训模型与折外记录

1 在查看任何得分前冻结划分、预处理、损失、失败与并列规则，并生成互斥折 $D_1, \dots, D_K$

2 对每个 $\lambda \in \Lambda$ 执行

3 | 只用 $D \setminus D_k$ 拟合全部数据依赖步骤，再在 D_k 计算折外损失，遍历 $k = 1, \dots, K$

4 结束

5 只比较具有同口径 K 个合法折外记录的候选，按冻结规则选择 λ^*

6 用 λ^* 在全部 D 上重训一次；测试集始终不进入本协议

7 返回 λ^* 、重训模型与完整折记录；失败、预算和随机源分支按进阶契约保留上一合法记录

算法实现说明：核心五步是冻结规则、折内拟合、折外评价、同口径选择和全开发集重训；逐折失败、预算、随机源和原子记录留在进阶契约 完整 C1–C14 契约

收敛与非收敛说明。外层模型选择枚举有限候选与有限折，不形成趋于极限的参数序列，因此无需设置外层渐近收敛判据。若某折的内层训练未收敛或产生非有限指标，该折和配置按失败处理；全部配置失败时返回“无可行候选”，不得用测试集补选。

初始化。划分规则、随机种子、指标方向、评价损失、硬约束、失败政策和并列规则应在观察验证结果前固定；每个折的预处理参数从该折训练部分重新估计。

更新规则。每个样本恰作为验证样本一次，但不同折的训练集高度重叠，所以折外损失一般相关，不能称为独立观测或据此套用独立样本标准误。每完成一折就同时写入 E_{mk} 与有效标志 V_{mk} ；折容量不等时按验证样本数加权。

停止条件。枚举完所有候选和折即停止；训练失败、非有限损失、硬约束违反或缺折不应被静默忽略，也不得通过仅平均成功折让有效折数不同的配置互相比较。

统计条件。算法在有限循环后必然终止，但交叉验证估计的可靠性还依赖划分与部署数据机制一致。候选集合不断根据同一验证结果扩张，会使选择再次过拟合。

读前自检：复杂度分析：交叉验证。把模型评估、选择与泛化中的交叉验证放在“复杂度假设”下考察：由 M, K 的总成本剥离一次迭代或一次样本因子，并检查并行折按并发数增加模型内存。

复杂度分析

复杂度假设。以下界假设 M, K 有限，折划分预先生成并顺序执行； C_{fit} 与 C_{eval} 已经包含该折内预处理、模型训练和评价的完整实际成本。并行执行、缓存特征或折大小不等会改变常数与内存，应按并发数和实际折容量计数。**训练复杂度：**设样本数为 N 、特征数为 p ，单次训练和评价成本为 $C_{\text{fit}}(n, p)$ 、 $C_{\text{eval}}(n, p)$ 。 M 个候选的 k 折验证约为

$O(MK[C_{\text{fit}}((1-1/K)N, p) + C_{\text{eval}}(N/K, p)])$, 另加一次全数据重训。**预测复杂度**: 部署时只使用选中并重训的模型, 单样本成本为 $C_{\text{pred}}(p)$, 不再乘 M 或 K 。**存储复杂度**: 顺序执行时除数据外需一个模型和 $M \times K$ 得分, 额外为 $O(S_{\text{model}} + MK)$; 并行折按并发数增加模型内存。

读前自检: 泛化能力。 泛化误差把训练集 T 学习出的随机模型 $\hat{f}_T$ 固定在条件中; 请写出 $R(\hat{f}_T) = \mathbb{E}_{(X,Y) \sim P}[L(Y, \hat{f}_T(X)) | T]$, 并核对新样本与 T 独立时, 更换 T 仍可能改变 $\hat{f}_T$ 及其风险。

10.6 泛化能力与泛化界

泛化能力是学习方法由有限训练数据得到模型后, 对同一数据机制产生的未知样本进行预测的能力。测试误差是有限样本估计; 理论分析关注风险与经验风险之间的随机偏差。

对训练集 T 学习得到的随机模型 $\hat{f}_T$, 其泛化误差定义为

$$R(\hat{f}_T) = \mathbb{E}_{(X,Y) \sim P}[L(Y, \hat{f}_T(X)) | T].$$

这里的新样本与训练集独立, 条件在 T 上强调模型已经由训练数据确定。不同训练集会产生不同 $\hat{f}_T$ 和不同风险。

读前自检: 泛化误差上界。 从泛化误差上界的条件“好的上界随 N 增加而减小, 并随假设空间容量或更高置信要求而增大”出发, 请把 $\hat{R}_N(f)$ 展开一次并检查其类型或边界; 所得量应符合展开后的量满足定义中的域、维数或符号限制。

泛化误差上界以高概率把不可见的 $R(f)$ 控制在可计算的 $\hat{R}_N(f)$ 与复杂度项之和内。好的上界随 N 增加而减小, 并随假设空间容量或更高置信要求而增大。

读前自检: 泛化误差上界: 有限二类分类假设空间。 泛化误差上界: 有限二类分类假设空间依赖“设 $\mathcal{F} = \{f_1, \dots, f_d\}$ 是含 d 个函数的二类分类假设空间”; 请据此标出 $\mathcal{F} = \{f_1, \dots, f_d\}$ 两侧的形狀并完成一次乘法或正交检查, 并直接核对则对任意 $0 < \delta < 1$, 至少以概率 $1 - \delta$ 。

定理 10.1 (有限假设空间的泛化误差上界) 设 $\mathcal{F} = \{f_1, \dots, f_d\}$ 是含 d 个函数的二类分类假设空间, 训练样本独立同分布, 损失为 0-1 损失。则对任意 $0 < \delta < 1$, 至少以概率 $1 - \delta$, 对所有 $f \in \mathcal{F}$ 同时成立

$$R(f) \leq \hat{R}_N(f) + \varepsilon(d, N, \delta), \quad \varepsilon(d, N, \delta) = \sqrt{\frac{\log d + \log(1/\delta)}{2N}}.$$

概率取自训练样本的随机抽取。

阅读目标: 把固定模型的偏差界升级为对整个有限候选类同时成立的结论。

对象: 有限候选类 $\mathcal{F}$ 、有界损失 $L \in [0, 1]$ 与数据依赖选择结果 $\hat{f} \in \mathcal{F}$ 。

合法条件: 样本独立同分布; $\mathcal{F}$ 在应用界前固定且有限。

第一步: 先对每个固定 $f \in \mathcal{F}$ 应用 Hoeffding 界, 再对坏事件取并集。

推导目标

从固定函数的 Hoeffding 偏差界, 经过有限并集界, 逐步推出可用于数据依赖选择结果的同时泛化界。

推导准备

固定 f 时, 变量 $L(Y_i, f(X_i))$ 独立且位于 $[0, 1]$, 其均值为 $R(f)$, 样本均值为 $\hat{R}_N(f)$ 。

读前自检：证明：有限假设空间的泛化误差上界。 有限假设空间的泛化误差上界以“推导第1步：固定一个函数”为约束；请补出 $\epsilon > 0$ 到下一关系的一步不等式或求导，并确认因为结论同时覆盖全部 f ，所以也覆盖由同一训练集选出的随机函数。

证明. 推导第1步：固定一个函数。 由 Hoeffding 不等式的单侧形式，对任意 $\epsilon > 0$,

$$\mathbb{P}(R(f) - \hat{R}_N(f) \geq \epsilon) \leq \exp(-2N\epsilon^2).$$

推导第2步：同时控制有限集合。 令 $A_f = \{R(f) - \hat{R}_N(f) \geq \epsilon\}$ 。并集界给出

$$\mathbb{P}(\exists f \in \mathcal{F} : A_f) \leq \sum_{f \in \mathcal{F}} \mathbb{P}(A_f) \leq d \exp(-2N\epsilon^2).$$

因此，以至少 $1 - d \exp(-2N\epsilon^2)$ 的概率，没有任何 f 违反 $R(f) < \hat{R}_N(f) + \epsilon$ 。

推导第3步：换成置信参数。 令 $\delta = d \exp(-2N\epsilon^2)$ ，取对数并解出

$$\epsilon = \sqrt{\frac{\log d + \log(1/\delta)}{2N}}.$$

将该值代回上一步即得同时上界。因为结论同时覆盖全部 f ，所以也覆盖由同一训练集选出的随机函数。 $\square$

推论 10.1 (经验风险最小化解的上界) 若 $\hat{f}_N \in \arg \min_{f \in \mathcal{F}} \hat{R}_N(f)$ ，则在定理的同一事件上

$$R(\hat{f}_N) \leq \hat{R}_N(\hat{f}_N) + \sqrt{\frac{\log d + \log(1/\delta)}{2N}}.$$

读前自检：证明：经验风险最小化解的上界。 经验风险最小化上界的高概率事件对有限类 $\mathcal{F}$ 中所有 f 同时成立；请在该事件中令 $f = \hat{f}_N$ ，核对随机选出的 $\hat{f}_N \in \mathcal{F}$ 仍受同一上界约束，并说明单个预固定 f 的界不能这样代入。

证明. 定理的事件对 $\mathcal{F}$ 中的每个函数同时成立，而 $\hat{f}_N$ 无论由样本选成哪一个都属于 $\mathcal{F}$ ，故可直接把 f 替换为 $\hat{f}_N$ 。只对预先固定的单个 f 成立的界不能做这一步，这正是并集界不可缺少的原因。 $\square$

上界揭示三种单调关系： N 增大使置信项按 $N^{-1/2}$ 下降； d 增大只通过 $\sqrt{\log d}$ 进入； δ 减小意味着要求更高置信度，因而 $\log(1/\delta)$ 增大。该结果只处理有限假设空间和有界损失，对无限空间需要其他容量刻画。

读前自检：生成模型与判别模型。 对生成模型与判别模型，条件“生成方法学习联合分布 $P(X, Y)$ 或等价分解 $P(Y)P(X | Y)$ ”不可省；请将 $P(Y | X) = \frac{P(X, Y)}{P(X)}$ 左端按正文定义展开一层，再逐项对齐右端，再用两端运算均有定义、类型一致且化为同一结果作检查。

10.7 生成方法与判别方法

定义 10.4 (生成方法与判别方法). 生成方法学习联合分布 $P(X, Y)$ 或等价分解 $P(Y)P(X | Y)$, 预测时由

$$P(Y | X) = \frac{P(X, Y)}{P(X)}$$

得到条件分布。判别方法直接学习 $P(Y | X)$ 或决策函数 $Y = f(X)$, 不要求给出输入的边缘分布。

生成模型描述不同类别如何产生输入，因而可以采样、处理部分隐变量或利用未标注结构；但对 $P(X | Y)$ 的错误假设会影响最终判别。判别模型把表示能力直接用于预测边界，通常允许灵活特征并获得较好的预测精度；但它一般不能恢复完整联合分布。

适用条件与局限性

适用条件：需要模拟数据、补全缺失变量、显式建模类别机制或联合使用标注与未标注信息时，生成方法更自然；目标只是在给定输入后准确预测，且有充分标注数据和灵活特征时，判别方法常更直接。**局限性：**生成方法依赖联合分布假设，判别方法缺少输入机制模型；实际选择还受样本量、模型错设、计算成本和校准需求影响。

读前自检：常见错误与误用边界：生成方法与判别方法。 生成方法与判别方法把问题限定在“边界框”内禁止把折内训练误差当作折外验证误差；请把固定错误“把折内训练误差当作折外验证误差”中的对象、操作与结论按本节定义拆开，指出第一个不满足的定义条件，再把该处改为本节允许的写法，检查是否得到改写后的运算或判断有定义，且不再触发“把折内训练误差当作折外验证误差”。

常见错误

典型误用包括：把损失与评价指标混为一谈；用训练集评价泛化；用测试集选择超参数；在划分前用全数据拟合预处理；把折内训练误差当作折外验证误差；把高概率上界误读为每个数据集上的确定等式；在有限类上界中遗漏并集界产生的 $\log d$ ；认为所有学习条件概率的模型都是生成模型。

读前自检：易混淆概念对比：生成方法与判别方法。 在“对比表首个数据行是“学习对象 | $P(X, Y)$ 或 $P(Y)P(X | Y)$ | $P(Y | X)$ 或 $f(X)$ ””成立时处理生成方法与判别方法：请按列复述“学习对象 | $P(X, Y)$ 或 $P(Y)P(X | Y)$ | $P(Y | X)$ 或 $f(X)$ ”中的对象、假设与结论，并以各列均对应首行对象“学习对象”，且未与表中下一行互换判定结果。

易混淆概念对比		
概念对比：		
比较维度	生成方法	判别方法
学习对象	$P(X, Y)$ 或 $P(Y)P(X Y)$	$P(Y X)$ 或 $f(X)$
预测依据	由联合分布归一化得到后验	直接输出后验或决策
附加能力	采样、输入似然、部分缺失机制	灵活边界、直接优化预测目标
主要风险	联合模型错设传播到预测	缺乏完整数据生成解释

本章共 18 道练习。每道题干后立即给出同号解析；长解析可自然跨页，续页标题保留题号。

练习 10.1. 证明独立样本上的条件对数似然最大化与平均对数损失最小化等价。

练习 10.1 解析

固定独立训练样本 $D = \{(x_i, y_i)\}_{i=1}^N$, $N \geq 1$, 并令 $p_f(y_i | x_i) > 0$ 。条件独立性与对数单调性给出

$$\begin{aligned}\mathcal{L}_D(f) &= \prod_{i=1}^N p_f(y_i | x_i), \\ \arg \max_{f \in \mathcal{F}} \mathcal{L}_D(f) &= \arg \max_{f \in \mathcal{F}} \sum_{i=1}^N \log p_f(y_i | x_i) \\ &= \arg \min_{f \in \mathcal{F}} \left[-\frac{1}{N} \sum_{i=1}^N \log p_f(y_i | x_i) \right].\end{aligned}$$

方括号内正是平均对数损失。若某个已发生标签的概率为零，则约定 $\log 0 = -\infty$ ，相应负对数损失为 $+\infty$ ；等价关系在扩展实数意义下仍成立。

练习 10.2. 二分类标签为 $\{0, 1\}$ 。某输入处 $P(Y = 1 | X = x) = 0.7$ 。分别求在 0-1 损失下预测 0 与预测 1 的条件风险，并给出最优预测。

练习 10.2 解析

动作域为 $\mathcal{A} = \{0, 1\}$ ，损失为 $L(y, a) = \mathbf{1}\{y \neq a\}$ 。因 $P(Y = 1 | x) = 0.7$,

$$\begin{aligned}\rho(0 | x) &= P(Y = 1 | x) = 0.7, \\ \rho(1 | x) &= P(Y = 0 | x) = 1 - 0.7 = 0.3, \\ \arg \min_{a \in \mathcal{A}} \rho(a | x) &= \{1\}, & \min_{a \in \mathcal{A}} \rho(a | x) &= 0.3.\end{aligned}$$

练习 10.2 解析 (续)

所以最优类别输出为 1；概率 0.7 是决策依据，不是类别标签本身。

练习 10.3. 随机输出 Y 取 0 和 2 的概率分别为 0.25 和 0.75。在常数预测 a 下，比较 $a = 1$ 与 $a = 1.5$ 的平方损失风险。

练习 10.3 解析

随机变量 Y 的支持集为 $\{0, 2\}$ ，故二阶矩有限。对 $a \in \mathbb{R}$ ，

$$\begin{aligned} R(1) &= \frac{1}{4}(0-1)^2 + \frac{3}{4}(2-1)^2 = 1, \\ R(1.5) &= \frac{1}{4}(0-1.5)^2 + \frac{3}{4}(2-1.5)^2 = \frac{3}{4}, \\ \mathbb{E}[Y] &= 0 \cdot \frac{1}{4} + 2 \cdot \frac{3}{4} = \frac{3}{2}, \\ R(a) &= \text{Var}(Y) + (a - \mathbb{E}Y)^2. \end{aligned}$$

因此 $a = 1.5$ 风险更小，并且它是全部实数常数预测中的唯一最优点。

练习 10.4. 说明为什么对数损失不能接受真实类别概率为 0，并计算真实类别概率从 0.8 降至 0.2 时损失的增量。

练习 10.4 解析

真实类别的预测概率满足 $q \in [0, 1]$ ，对数损失按扩展值定义：

$$\begin{aligned} \ell(q) &= -\log q, \quad q \in (0, 1], \\ \ell(0) &:= \lim_{q \downarrow 0} -\log q = +\infty, \\ \ell(0.2) - \ell(0.8) &= -\log 0.2 + \log 0.8 \\ &= \log \frac{0.8}{0.2} = \log 4. \end{aligned}$$

因此给已发生事件零概率会得到无限损失，且从 0.8 降至 0.2 的损失增量为 $\log 4$ 。

练习 10.5. 某二分类器在 8 个训练样本上错分 2 个，在另外 5 个独立样本上错分 2 个。求两个样本集上的 0-1 经验风险，并说明能否把它们直接合并为不加权平均。

练习 10.5 解析

两组样本互不相交，容量分别为 $N_1 = 8, N_2 = 5$ 。在 0-1 损失下，

$$\begin{aligned} \hat{R}_1 &= \frac{2}{8} = \frac{1}{4}, \\ \hat{R}_2 &= \frac{2}{5} = 0.4, \\ \hat{R}_{1 \cup 2} &= \frac{N_1 \hat{R}_1 + N_2 \hat{R}_2}{N_1 + N_2} \\ &= \frac{8(1/4) + 5(2/5)}{13} = \frac{4}{13}. \end{aligned}$$

练习 10.5 解析 (续)

不加权平均会给容量不同的两组相同权重, 因而不等于合并后逐样本平均。

练习 10.6. 模型 A, B 的经验风险分别为 $0.12, 0.09$, 复杂度分别为 $2, 5$ 。结构风险取 $\hat{R} + \lambda J$ 。求选择 A 的 λ 范围。

练习 10.6 解析

正则化参数的定义域为 $\lambda \geq 0$ 。两候选的目标值满足

$$\begin{aligned} Q_A(\lambda) &= 0.12 + 2\lambda, \\ Q_B(\lambda) &= 0.09 + 5\lambda, \\ Q_A(\lambda) \leq Q_B(\lambda) &\iff 0.03 \leq 3\lambda \\ &\iff \lambda \geq 0.01. \end{aligned}$$

故 $\lambda > 0.01$ 唯一选择 A , $0 \leq \lambda < 0.01$ 唯一选择 B ; $\lambda = 0.01$ 时二者并列, 尚需预先规定并列规则。

练习 10.7. 一个模型在测试集中对 40 个样本预测正确 34 个。求测试错误率与准确率, 并核对互补关系。

练习 10.7 解析

测试集容量 $N_{\text{te}} = 40 > 0$, 且每个样本恰分为正确或错误两类。于是

$$\begin{aligned} n_{\text{err}} &= 40 - 34 = 6, \\ \hat{R}_{\text{te}} &= \frac{n_{\text{err}}}{N_{\text{te}}} = \frac{6}{40} = 0.15, \\ \widehat{\text{Acc}}_{\text{te}} &= \frac{34}{40} = 0.85, \\ \hat{R}_{\text{te}} + \widehat{\text{Acc}}_{\text{te}} &= 1. \end{aligned}$$

若允许拒绝预测或改用代价加权损失, 这个二项互补关系便不再直接适用。

练习 10.8. 说明为什么不能根据较小的训练误差断定两个学习方法中哪一个泛化更好。

练习 10.8 解析

对学习算法 $\mathcal{A}_k$, 训练数据既生成模型又评价模型:

$$\begin{aligned} \hat{f}_k &= \mathcal{A}_k(D_{\text{tr}}), \\ \hat{R}_{\text{tr}}(\hat{f}_k) &= \frac{1}{|D_{\text{tr}}|} \sum_{(x,y) \in D_{\text{tr}}} L(y, \hat{f}_k(x)), \\ R(\hat{f}_k) &= \mathbb{E}_{(X,Y) \sim P} L(Y, \hat{f}_k(X)). \end{aligned}$$

前一量不等于后一总体风险, 且因 $\hat{f}_k$ 依赖 D_{tr} 通常偏乐观。比较方法应使用未参与拟合与选择的 D_{te} , 或使用折外损失, 并同时报告抽样不确定性。

练习 10.9. 某研究者先在测试集上比较 20 个超参数，再报告其中最小的测试误差。指出信息泄漏发生在哪里，并给出修正后的数据角色。

练习 10.9 解析

泄漏发生在把测试损失写进二十选一的规则：

$$\begin{aligned}\lambda_{\text{leak}}^{\star} &= \arg \min_{\lambda \in \{\lambda_1, \dots, \lambda_{20}\}} \hat{R}_{\text{te}}(\hat{f}_{\lambda}), \\ D &= D_{\text{tr}} \dot{\cup} D_{\text{val}} \dot{\cup} D_{\text{te}}, \\ \hat{f}_{\lambda} &= \mathcal{A}_{\lambda}(D_{\text{tr}}), \\ \lambda^{\star} &\in \arg \min_{\lambda} \hat{R}_{\text{val}}(\hat{f}_{\lambda}), \\ \text{最终评估} &= \hat{R}_{\text{te}}(\hat{f}_{\lambda^{\star}}).\end{aligned}$$

D_{te} 必须在全部选择冻结后只用一次；样本少时可用内层选择、外层评估的嵌套交叉验证。

练习 10.10. 两个模型的训练误差和验证误差分别为 $A : (0.04, 0.09)$ 、 $B : (0.01, 0.18)$ 。应优先选择哪个模型？这能否证明另一个模型永远更差？

练习 10.10 解析

模型均只在 D_{tr} 拟合，并在同一独立 D_{val} 上比较。给定数值为

$$\begin{aligned}(\hat{R}_{\text{tr}}(A), \hat{R}_{\text{val}}(A)) &= (0.04, 0.09), \\ (\hat{R}_{\text{tr}}(B), \hat{R}_{\text{val}}(B)) &= (0.01, 0.18), \\ \arg \min_{m \in \{A, B\}} \hat{R}_{\text{val}}(m) &= \{A\}.\end{aligned}$$

所以本次协议选 A 。有限验证集上的 $0.09 < 0.18$ 不是总体风险的确定排序，不能证明 B 在所有未来样本上都更差。

练习 10.11. 在目标 $\hat{R}(w) + \lambda \|w\|_2^2/2$ 中，把全部特征乘以常数 $c > 0$ 而不调整惩罚，会怎样影响系数尺度与有效正则化？

练习 10.11 解析

设 $x, w \in \mathbb{R}^d$ 且 $c > 0$ 。为保持同一线性预测，令 $x' = cx$ 、 $w' = w/c$ ，则

$$\begin{aligned}w'^{\text{T}} x' &= (w/c)^{\text{T}} (cx) = w^{\text{T}} x, \\ \frac{\lambda}{2} \|w'\|_2^2 &= \frac{\lambda}{2c^2} \|w\|_2^2, \\ \lambda_{\text{eff}} &= \frac{\lambda}{c^2}.\end{aligned}$$

因此特征换单位却保持 λ 不变，会改变有效正则化。交叉验证时，均值和尺度须在每个训练折内估计，再应用到对应验证折。

练习 10.12. 设负对数似然为 $-\ell(w)$, 先验密度满足 $p(w) \propto \exp(-\lambda\|w\|_1)$ 。写出最大后验估计对应的最小化目标。

练习 10.12 解析

参数域取 $w \in \mathbb{R}^d$; 当 $\lambda > 0$ 时 $p(w) \propto e^{-\lambda\|w\|_1}$ 可归一化。由 Bayes 公式,

$$\begin{aligned} p(w | D) &\propto p(D | w)p(w), \\ -\log p(w | D) &= -\ell(w) + \lambda\|w\|_1 + C_D, \\ \hat{w}_{\text{MAP}} &\in \arg \min_{w \in \mathbb{R}^d} \{-\ell(w) + \lambda\|w\|_1\}. \end{aligned}$$

常数 C_D 与 w 无关, 故不改变最小点; 若最小点不唯一, $\arg \min$ 是集合。

练习 10.13. 有 6 个候选配置, 做 5 折交叉验证并在选定配置后全数据重训。总共需要多少次模型拟合?

练习 10.13 解析

设候选数 $M = 6$ 、折数 $K = 5$, 且每个“候选 - 折”组合独立拟合一次。则

$$\begin{aligned} n_{\text{CV}} &= MK = 6 \cdot 5 = 30, \\ n_{\text{refit}} &= 1, \\ n_{\text{total}} &= n_{\text{CV}} + n_{\text{refit}} = 31. \end{aligned}$$

这里未计外层嵌套评估; 若存在外层, 每个外层训练集都会重新发生内层拟合。

练习 10.14. 说明留一交叉验证的折数、每次训练容量和验证容量, 并指出它为何可能计算昂贵。

练习 10.14 解析

对 $N \geq 2$ 个样本, 留一交叉验证的折集合为

$$\begin{aligned} K &= N, \\ D_{\text{val}}^{(k)} &= \{z_k\}, & |D_{\text{val}}^{(k)}| &= 1, \\ D_{\text{tr}}^{(k)} &= D \setminus \{z_k\}, & |D_{\text{tr}}^{(k)}| &= N - 1, \\ \hat{R}_{\text{LOO}} &= \frac{1}{N} \sum_{k=1}^N L(y_k, \mathcal{A}(D_{\text{tr}}^{(k)})(x_k)). \end{aligned}$$

算法需拟合 N 次近乎全量的数据; 不能快速更新时, 计算代价因而很高。

练习 10.15. 取 $d = 1000$ 、 $N = 500$ 、 $\delta = 0.05$, 估算定理中的置信项, 并给出经验风险为 0.08 时的风险上界。

练习 10.15 解析

设 $\mathcal{F}$ 是含 $d = 1000$ 个固定分类器的有限类, 训练样本 $D \sim P^N$ 独立同分布, 损失为 $[0, 1]$ 值。取 $N = 500, \delta = 0.05$,

$$\begin{aligned}\varepsilon &= \sqrt{\frac{\log d + \log(1/\delta)}{2N}} \\ &= \sqrt{\frac{\log 1000 + \log 20}{1000}} \approx 0.0995, \\ R(f) &\leq \hat{R}_D(f) + \varepsilon \quad \text{对所有 } f \in \mathcal{F}, \\ R(f) &\leq \min\{1, 0.08 + 0.0995\} \approx 0.1795.\end{aligned}$$

上述同时事件关于随机训练集 D 的概率至少为 $1 - \delta = 0.95$, 不是每个数据集上的确定等式。

练习 10.16. 希望置信项不超过 $\eta > 0$ 。由定理求样本容量 N 的充分条件。

练习 10.16 解析

假设有限候选数 $d \geq 1$ 、置信参数 $\delta \in (0, 1)$ 及目标精度 $\eta > 0$ 。则

$$\begin{aligned}\sqrt{\frac{\log d + \log(1/\delta)}{2N}} \leq \eta &\iff \frac{\log d + \log(1/\delta)}{2N} \leq \eta^2 \\ &\iff N \geq \frac{\log d + \log(1/\delta)}{2\eta^2}.\end{aligned}$$

由于 N 为正整数, 一个充分条件是

$$\begin{aligned}N &\geq N_{\min}, \\ N_{\min} &:= \left\lceil \frac{\log d + \log(1/\delta)}{2\eta^2} \right\rceil.\end{aligned}$$

它只控制置信项; 若经验风险不小, 总体风险上界仍可能很大。

练习 10.17. 已知 $P(Y = 1) = 0.4$ 、 $P(X = x | Y = 1) = 0.6$ 、 $P(X = x | Y = 0) = 0.2$ 。用生成模型计算 $P(Y = 1 | X = x)$ 。

练习 10.17 解析

标签支持集为 $\{0, 1\}$, 故 $P(Y = 0) = 1 - 0.4 = 0.6$ 。Bayes 分母为

$$\begin{aligned}P(X = x) &= P(X = x | Y = 1)P(Y = 1) \\ &\quad + P(X = x | Y = 0)P(Y = 0) \\ &= 0.6(0.4) + 0.2(0.6) = 0.36 > 0.\end{aligned}$$

因此条件概率合法且

$$P(Y = 1 | X = x) = \frac{0.6(0.4)}{0.36} = \frac{0.24}{0.36} = \frac{2}{3}.$$

所以在观测到 $X = x$ 后, 类别 $Y = 1$ 的后验概率为 $2/3$ 。

练习 10.18. 判断下列学习目标属于生成式还是判别式：学习 $P(X | Y)$ 与 $P(Y)$ ；直接学习 $P(Y | X)$ ；直接学习符号函数 $f(X)$ 。

练习 10.18 解析

以“是否刻画联合分布”为判据，

$$(P(X | Y), P(Y)) \implies P(X, Y) = P(Y)P(X | Y) \implies \text{生成式},$$

$$P(Y | X) \implies \text{概率判别式},$$

$$f : \mathcal{X} \rightarrow \mathcal{Y} \implies \text{非概率判别式}.$$

分类取决于学习对象，不取决于使用哪一种数值优化算法。

读前自检：本章结论与下一步。 模型评估、选择与泛化章末由“损失、风险、数据划分、复杂度与假设空间”落到“训练用于拟合、验证用于选择、测试只用于一次最终评估”；请把前者产出和后者输入逐项对齐，固定核对前者末项的输出类型能否作为后者首项的输入类型。

本章结论与下一步

核心结论： 损失、风险、数据划分、复杂度与假设空间

关键依据： 由 Hoeffding 不等式和并集界控制有限候选的泛化偏差

可执行自检： 训练用于拟合、验证用于选择、测试只用于一次最终评估

适用边界： 调参、比较模型和陈述未知数据保证

下一步： 进入第 11 章：监督学习任务与应用；随后由第 12 章开始第 2 册具体方法

1. 能否针对分类、回归和概率预测选择损失，并写出对应风险？
2. 能否画出训练、验证、测试信息流，指出一次流程中是否发生泄漏？
3. 能否写出正则化目标和完整 k 折伪代码，并解释每个预处理步骤为何必须折内拟合？
4. 能否从固定函数的 Hoeffding 界开始，逐步完成并集界和 δ 代换？
5. 能否根据学习对象而不是模型名称区分生成方法与判别方法？未通过时依次回看节 10.1—10.7。

第 11 章 监督学习任务与应用

读前自检：本章可检验学习目标。 监督学习任务与应用学习目标固定核验“从输入空间、输出空间和数据单位出发，严格区分分类、标注与回归任务”；请实际完成“从输入空间、输出空间和数
据单位出发，严格区分分类、标注与回归任务”，并用“中间结果逐项包含首目标“从输入空间、
输出空间和数据单位出发，严格区分分类、标注与回归任务”声明的对象、条件与结论”判定通
过或失败。

读前自检：先修自检。 监督学习任务与应用先修自检固定核验“给定应用描述，能否先写出一个
样本的输入 x 和输出 y ，再选择模型”；请给定应用描述，实际先写出一个样本的输入 x 和输出 y ，
再选择模型并写出中间结果，再按“中间结果直接回答首项“给定应用描述，能否先写出一个样
本的输入 x 和输出 y ，再选择模型”并给出通过或失败”明确判为通过或失败。

本章地图

核心问题：任务结构怎样决定损失、解码和评价指标

可检验学习目标：

- 从输入空间、输出空间和数据单位出发，严格区分分类、标注与回归任务；
- 能够由条件风险推导 Bayes 分类决策，正确计算准确率、精确率、召回率、 F_1 值及回归误差；
- 能够把真实问题写成可训练、可验证的监督学习任务，并识别类别不平衡、序列依赖和数据泄漏。

最短先修：需要掌握随机变量、条件概率、期望、损失函数、经验风险与交叉验证；还要会区分样本、
特征、标签和数据集划分。分类的输出是有限集合元素，回归的输出通常属于实数空间，标注的一个
样本则包含相互关联的多个位置。

依赖路线：输出空间类型 → 任务类型；条件分布与损失 → Bayes 决策；独立样本 → 分类或回归经验
风险；序列结构 → 标注的联合解码；业务代价 → 评价指标；数据生成过程 → 划分方案与方法选择。

完成标准与返回：任务边界或指标不一致时返回相应任务小节重新定义

本章符号表

符号	取值	含义
$\mathcal{X}, \mathcal{Y}$	集合	输入空间与输出空间
$T = \{(x_i, y_i)\}_{i=1}^N$	样本集	含 N 个标注样本的训练数据
$f, \hat{y}$	映射、输出	预测函数与 $\hat{y} = f(x)$
$p(y x)$	$[0, 1]$	给定输入时输出的条件概率
TP, FP, FN, TN	非负整数	二分类混淆矩阵四项计数
$X_{1:n}, Y_{1:n}$	序列	长度 n 的观测序列与标记序列
L, R	非负函数	损失与条件风险

读前自检：监督学习应用。 把监督学习应用放在“监督学习应用的第一步不是挑选算法，而是确
定一个样本、可用信息、预测时点和允许输出”下考察：把“监督学习应用的第一步不是挑选算

法，而是确定一个样本、可用信息、预测时点和允许输出”中的已声明对象依次标成输入、输出与判据，并检查每个对象只承担正文声明的接口角色，且判据能给出通过或失败。

11.1 分类问题

监督学习应用的第一步不是挑选算法，而是确定一个样本、可用信息、预测时点和允许输出。只有这些对象固定后，数据划分与评价才有明确含义。

读前自检：分类问题。 分类问题在 0-1 损失下的条件风险为 $R(a | x) = 1 - p(a | x)$ ；请比较两个候选类别的后验概率，核对最大后验类别恰使条件风险最小。

定义 11.1 (分类任务). 若输出空间 $\mathcal{Y} = \{1, \dots, C\}$ 为有限类别集合，则从训练集学习 $f: \mathcal{X} \rightarrow \mathcal{Y}$ 或条件分布 $p(y | x)$ 并预测新输入类别的任务称为分类。 $C = 2$ 时为二分类， $C > 2$ 时为多分类。

这里定义的是每个样本只取一个标签的普通分类。多标签任务的输出应另写为有限幂集 $2^{\{1, \dots, C\}}$ 或等价指示向量 $\{0, 1\}^C$ ；序列、树等结构化输出具有单独的输出空间和依赖关系，不把它们混入上述有限单标签定义。

本章统一采用“真实值在前、预测或动作在后”的损失记号 $L(y, a)$ ；平方损失、绝对损失与后文风险式都遵守这一顺序。

模型。 概率分类器给出 $p(y | x)$ ，决策函数再按损失把概率转换成类别。若使用 0-1 损失，预测为条件概率最大的类别；若不同错误代价不同，最优阈值会随代价改变。

学习策略。 训练阶段最小化经验损失或正则化风险；评估阶段必须使用未参与拟合和调参的数据。类别严重不均衡时，准确率会掩盖少数类错误，应同时报告精确率、召回率和 F_1 值。

二分类把关注类称为正类。四项计数给出

$$P = \frac{TP}{TP + FP}, \quad R = \frac{TP}{TP + FN}, \quad F_1 = \frac{2PR}{P + R} = \frac{2TP}{2TP + FP + FN}.$$

分母为零时必须预先规定评价约定，不能临时忽略样本。

阅读目标： 从条件风险统一推出代价敏感规则与 0-1 损失特例。

对象： 有限类别集合、动作 a 、真实类别 y 、损失 $L(y, a)$ 与后验概率 $p(y | x)$ 。

合法条件： $L(y, a) \geq 0$ 且给定 x 时后验分布已归一化。

第一步： 先对每个候选动作写条件风险 $R(a | x) = \sum_y L(y, a)p(y | x)$ 。

推导目标

从条件风险推导任意有限类别、任意代价矩阵下的 Bayes 分类规则，并得到 0-1 损失的最大后验规则。

推导准备

设动作 $a \in \mathcal{Y}$ ，真实类别为 y ，损失 $L(y, a) \geq 0$ ；给定 x 时 $p(y | x)$ 已知。

推导第 1 步：固定输入 x 和候选动作 a ，对未知真实类别取条件期望，

$$R(a | x) = \sum_{y \in \mathcal{Y}} L(y, a) p(y | x).$$

推导第 2 步：对每个输入分别选择条件风险最小的动作，

$$f^*(x) \in \arg \min_{a \in \mathcal{Y}} R(a | x).$$

对 x 再取期望不会改变逐点最小化，因此该规则使总体风险达到最小。

推导第 3 步：0-1 损失满足 $L(y, a) = \mathbf{1}(y \neq a)$ ，于是 $R(a | x) = 1 - p(a | x)$ ，故

$$f^*(x) \in \arg \max_{a \in \mathcal{Y}} p(a | x).$$

并列最大值需要固定且可复现的决胜规则。

定理 11.1 (Bayes 分类器的风险最优性) 在有限输出空间且条件分布已知时，逐点选择条件风险最小动作的分类器在全部可测决策函数中具有最小期望风险。

读前自检：证明：Bayes 分类器的风险最优性。 Bayes 分类器 f^* 在每个 x 处最小化条件风险；请对任意决策函数 g 写出 $R(f^*(x) | x) \leq R(g(x) | x)$ ，再按输入边缘分布积分，核对总体风险不等式及并列最小时的取等情形。

证明。 任取另一决策函数 g 。对每个 x ，Bayes 动作的定义给出 $R(f^*(x) | x) \leq R(g(x) | x)$ 。以输入边缘分布对两边积分，得到 $\mathbb{E}_X R(f^*(X) | X) \leq \mathbb{E}_X R(g(X) | X)$ 。左、右两边分别是 f^* 和 g 的总体期望损失，因此结论成立。等号允许在条件风险并列最小处出现。 $\square$

几何理解

几何解释。 分类器把特征空间划分为若干决策区域；决策边界是相邻动作条件风险相等的点集。改变误判代价会移动边界，即使概率模型本身不变。

概率解释

条件概率描述不确定性，最终类别是概率与损失共同作用的决策。把 $p(y | x) = 0.6$ 直接称为“60%正确”还需要概率校准假设；准确率只评价硬决策，不能单独检验概率质量。

例题 11.1 (混淆矩阵的四项分类指标)。某二分类测试集有 $TP = 36, FP = 9, FN = 4, TN = 51$ 。计算准确率、精确率、召回率和 F_1 。

例题 11.1 解答

读题翻译 四个计数分别记录真阳性、假阳性、假阴性和真阴性；题目要在同一“正类”约定下计算四个分类指标，而不是把混淆矩阵作矩阵乘法。

已知与合法条件 固定题设正类，四格计数均非负；总样本数由四格相加得到，且精确率、召回率的分母在本题中均严格为正。

为什么想到这个方法 先由四格恢复总样本数，再分别写出准确率、精确率、召回率的计数分母；最后用计数式和调和平均式两种方式复算 F_1 。

方法选择 逐项代入四个计数，检查分母与取值范围，并用四格总和及 F_1 的等价公式作独立核验。

推导/计算 以题设正类为正类，且各指标分母均严格为正。总样本数与四项指标为

$$\begin{aligned} N &= TP + FP + FN + TN = 100, \\ \text{Acc} &= \frac{TP + TN}{N} = \frac{36 + 51}{100} = 0.87, \\ \text{Precision} &= \frac{TP}{TP + FP} = \frac{36}{45} = 0.8, \\ \text{Recall} &= \frac{TP}{TP + FN} = \frac{36}{40} = 0.9, \\ F_1 &= \frac{2TP}{2TP + FP + FN} = \frac{72}{85} \approx 0.847. \end{aligned}$$

独立地用调和平均式核验

$$\frac{2 \times 0.8 \times 0.9}{0.8 + 0.9} = \frac{72}{85} \approx 0.847,$$

与计数式一致。

独立核验 四格之和 $36 + 9 + 4 + 51 = 100$ 恢复总样本数；三个分母 100, 45, 40 均为正，且四个指标都落在 $[0, 1]$ 内。

结论 准确率、精确率、召回率和 F_1 依次为 0.87, 0.80, 0.90, $72/85 \approx 0.847$ ；较高召回率对应较少漏报， $FP = 9$ 仍表明存在误报。

读前自检：标注问题。 标注问题给定观测序列 $X_{1:n}$ 并输出同长度标签 $Y_{1:n}$ ；请写出 $\hat{Y}_{1:n} \in \arg \max_{y_{1:n}} p(y_{1:n} | X_{1:n})$ ，再核对改变单个 y_t 会同时影响本地项与相邻转移项。

11.2 标注问题

定义 11.2 (序列标注). 给定观测序列 $X_{1:n} = (X_1, \dots, X_n)$ ，预测同长度或按任务规则对齐的标记序列 $Y_{1:n} = (Y_1, \dots, Y_n)$ ，称为标注。模型需要处理输出位置之间的结构依赖，而非把每个位置机械地视为独立分类。

概率模型可表示 $p(Y_{1:n} | X_{1:n})$ ，解码规则为

$$\hat{Y}_{1:n} \in \arg \max_{y_{1:n} \in \mathcal{Y}^n} p(y_{1:n} | X_{1:n}).$$

若标记集大小为 K ，未经结构分解的候选序列有 K^n 个；动态规划之所以重要，是因为局部因子可复用重叠子问题。

HMM 任务卡

输入：观测序列 $X_{1:n}$ 。

输出：最可能的隐状态路径 $Y_{1:n}$ 。

箭头语义：状态生成下一状态与当前观测，属于生成式联合模型。

CRF 任务卡

输入：完整观测序列 $x_{1:n}$ 。

输出：条件得分最高的标记路径 $y_{1:n}$ 。

因子语义：局部因子在给定观测下连接相邻标记，不表示由标记生成观测。




图 11.1 HMM 与线性链 CRF 都利用相邻标记关系，但箭头只用于 HMM 的生成方向；CRF 中的无向线段表示给定观测后的局部因子。

由图 11.1 可见，改变一个 y_t 会同时影响本地观测项和相邻转移项；逐位置取最大值因此可能拼出全局低分序列，解码必须保留跨位置的动态规划状态。

读前自检：回归问题。 监督学习任务与应用中的回归问题以“若输出 Y 取连续数值，通常 $y \subseteq \mathbb{R}^q$ ”为约束；请独立化简 $\mathbb{E}[(Y - a)^2 | X = x]$ 的两端，并确认“指出一段配送轨迹中每个时刻所处状态”以状态序列为输出，是标注。

11.3 回归问题

定义 11.3 (回归任务). 若输出 Y 取连续数值，通常 $y \subseteq \mathbb{R}^q$ ，从训练数据学习 $f: \mathcal{X} \rightarrow \mathcal{Y}$ 并预测数值的任务称为回归。 $q = 1$ 为一元输出回归， $q > 1$ 为多输出回归；“线性/非线性”描述模型形式，不由输入维数决定。

平方损失和绝对损失分别为

$$L_2(y, \hat{y}) = (y - \hat{y})^2, \quad L_1(y, \hat{y}) = |y - \hat{y}|.$$

阅读目标：分别证明条件均值和条件中位数为何是最优点预测。

对象：固定输入 x ，标量条件分布 $Y | X = x$ 与候选预测 $a \in \mathbb{R}$ 。

合法条件：平方损失需条件二阶矩有限；绝对损失需条件一阶矩有限，并用条件分布函数处理非唯一中位数。

第一步：平方损失先围绕 $\mu(x) = \mathbb{E}[Y | X = x]$ 展开平方；绝对损失则考察左右导数或次梯度。

推导目标

对固定输入 x ，分别求平方损失和绝对损失下使条件风险最小的预测值。

推导准备

以下推导明确限于标量回归 $q = 1$ 。条件分布记为 $Y | X = x$ ；平方损失情形假设条件二阶矩有限，令 $\mu(x) = \mathbb{E}[Y | X = x]$ ；绝对损失情形令条件分布函数为 $F_x(a) = P(Y \leq a | X = x)$ 。

推导第1步：平方损失中心化。对任意常数预测 a ,

$$\mathbb{E}[(Y - a)^2 | X = x] = \text{Var}(Y | X = x) + (\mu(x) - a)^2,$$

因为交叉项含 $\mathbb{E}[Y - \mu(x) | X = x] = 0$ 。第二项在且仅在 $a = \mu(x)$ 时最小。

推导第2步：绝对损失使用次梯度。函数 $R_1(a) = \mathbb{E}[|Y - a| | X = x]$ 为凸函数，其次梯度区间为

$$\partial R_1(a) = [2F_x(a^-) - 1, 2F_x(a) - 1].$$

最优性条件 $0 \in \partial R_1(a)$ 等价于 $F_x(a^-) \leq 1/2 \leq F_x(a)$ ，这正是条件中位数的定义。

推导第3步：比较结论。平方损失的条件 Bayes 预测是条件均值，绝对损失的条件 Bayes 预测是任一条件中位数。两者不同说明选择损失等于声明哪类误差更昂贵，而不是只更换一个计算公式。

对 $q > 1$ ，结论取决于损失的具体定义。平方欧氏损失 $\|Y - a\|_2^2$ 的 Bayes 动作是条件均值向量 $\mathbb{E}[Y | X = x]$ ；逐坐标绝对损失 $\sum_{j=1}^q |Y_j - a_j|$ 的 Bayes 动作由各坐标条件中位数组成；欧氏距离损失 $\|Y - a\|_2$ 的 Bayes 动作则是条件几何中位数。这三者不能用标量“中位数”一句话混写。

优化解释

优化解释。经验平方损失对线性参数是凸二次函数，正规方程或迭代法可求全局最优；绝对损失在零点不可微但仍凸，对异常值的增长速度较慢。加入正则项是在拟合误差与参数复杂度之间取舍。

11.4 监督学习应用与方法选择

本节把前三节的定义组合成可执行规范。对每个应用依次写出：预测时点、一个样本、输入空间、输出空间、允许使用的特征、损失、评价指标、数据划分单位与部署后的分布变化。

同一业务目标可能对应不同任务。例如“预计订单是否延迟”以有限类别为输出，是分类；“预计延迟多少小时”以连续时间为输出，是回归；“指出一段配送轨迹中每个时刻所处状态”以状态序列为输出，是标注。三者可以共享原始记录，却不能共享未经说明的标签、损失和指标。方法选择还应服从部署约束：离线批处理可容许较高延迟，在线决策需要明确单次预测预算；高代价领域应保留概率或置信信息，并把人工复核作为允许动作之一。评价集要模拟实际预测方向，例如用过去预测未来，而不是把未来记录随机混入训练数据。

任务	单个输出	典型损失	评价关注
分类	有限类别	对数损失、0-1 损失	错误类型、阈值与概率质量
标注	标记序列	序列负对数似然	位置、片段与整序列一致性
回归	连续数值	平方或绝对损失	误差尺度、尾部与分群残差

章末项目检查表（核心流程，不作为数学算法）

1. 写清应用决策与错误代价；

2. 冻结预测时点；

3. 冻结样本单位及时间或群组边界；

4. 声明 $\mathcal{X}$ 与 $\mathcal{Y}$ ；

5. 列出预测时不可用的信息；

6. 预先确定损失与评价指标；

7. 预先确定阈值、并列规则和部署门槛；

8. 冻结互斥划分规则；

9. 把预处理和特征选择放入训练折；

10. 只用训练数据拟合候选；

11. 只用验证数据比较候选；

12. 预登记训练、数值与随机源失败政策；

13. 给搜索设定有限预算；

14. 记录每个合法候选；

15. 按冻结规则更新当前最优；

16. 只有预登记证书满足时才早停；

17. 无合法候选时停止并报告；

18. 选择结束后一次性冻结任务、处理、模型和阈值；

19. 冻结前不得读取测试集；

20. 冻结后只读取测试集一次；

21. 报告总体与预设分群指标；

22. 测试结果不得回流到搜索；

23. 归档规范、预算、失败记录、测试结果与部署判定。

稳健实现细节契约。 以下保留失败分支、预算和状态语义，项目执行时查阅；它不是本章需要手算的数学算法。

算法执行契约：五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

稳健实现说明：六阶段评估闭环（不编号为数学算法）

1. **定义：**冻结预测时点、样本单位、 x, y 、损失、指标和禁止信息；
2. **划分：**按时间或群组边界生成互斥训练、验证与测试索引；
3. **开发：**只在训练集拟合，只在验证集选择，并原子记录每个合法候选；
4. **冻结：**按预登记证书或预算停止后，冻结处理、模型、阈值与并列规则；
5. **测试：**冻结后恰读取测试集一次，报告总体与预设分群指标；
6. **归档：**保存最后合法状态、实际计数、失败阶段、预算余量与部署判定，测试结果不得回流。

算法实现说明：核心流程使用上方章末项目检查表；六阶段闭环是项目实现附录，不占用数学算法编号，完整失败分支和状态语义仍由 C1–C14 契约保存 完整 C1–C14 契约

该流程的参数包括误判代价、阈值、验证规则和资源预算；初始化决定可用信息边界；更新规则只依赖训练与验证数据；停止条件在搜索前固定。这里的“收敛”表示模型选择过程按预设规则终止，不等同于某个优化器的参数收敛。

读前自检：复杂度分析：监督学习应用与方法选择。先锁定监督学习应用与方法选择的条件“训练复杂度：若每个候选的拟合成本为 C_{fit} 、验证成本为 C_{val} ”：由 $C_{\text{fit}}, C_{\text{val}}, C_{\text{pred}}$ 的总成本剥离一次迭代或一次样本因子，所得结果应满足保存全部预测为 $O(N)$ ，序列回溯指针通常为 $O(nK)$ ，模型参数另计。

复杂度分析

复杂度假设。以下界假设候选数、数据划分和停止预算预先固定， $C_{\text{fit}}, C_{\text{val}}, C_{\text{pred}}$ 分别包含单个候选的完整训练、验证和预测成本；分类指标可流式累计。链式解码界假设 K 个标记间转移稠密，稀疏转移时应按实际边数重计。设候选数为 M 、评估样本数为 N 、类别数为 C 。**训练复杂度：**若每个候选的拟合成本为 C_{fit} 、验证成本为 C_{val} ，一次有限搜索为 $O(M(C_{\text{fit}} + C_{\text{val}}))$ ；分类混淆计数与回归误差汇总为 $O(N)$ 。**预测复杂度：**选定模型后，普通单样本预测为其自身的 C_{pred} ；具有 K 种标记、长度 n 的链式序列动态规划解码为 $O(nK^2)$ 。**存储复杂度：**指标累计需 $O(C^2)$ 混淆计数或常数级回归汇总；保存全部预测为 $O(N)$ ，序列回溯指针通常为 $O(nK)$ ，模型参数另计。

适用条件与局限性

适用条件：分类适合有限互斥或多标签输出，标注适合输出内部有位置或结构依赖，回归适合连续数值输出。**局限性：**监督学习依赖标签质量与训练—部署分布的一致性；类别不均衡、标签延迟、群组相关、概念漂移和未观测混杂都会使随机划分的离线成绩过于乐观。

读前自检：常见错误与误用边界：监督学习应用与方法选择。 对监督学习应用与方法选择，条件“边界框首项禁止把数值编码的类别当作连续回归目标”不可省；请把固定错误“把数值编码的类别当作连续回归目标”中的对象、操作与结论按本节定义拆开，指出第一个不满足的定义条件，再把该处改为本节允许的写法，再用改写后的运算或判断有定义，且不再触发“把数值编码的类别当作连续回归目标”作检查。

常见错误

典型误用包括：把数值编码的类别当作连续回归目标；按行随机拆分同一用户或同一序列造成泄漏；在测试集上反复选择阈值；类别不均衡时只报准确率；把逐位置准确率当作整序列准确率；只报均方误差而不检查分群偏差和残差尺度；使用预测时点以后才产生的特征。

读前自检：易混淆概念对比：监督学习应用与方法选择。 监督学习应用与方法选择把问题限定在“概念对比：分类预测有限类别，回归预测连续数值，标注预测结构化标记序列”；请按表格顺序核对监督学习应用与方法选择对比表的首个数据行，检查是否得到监督学习应用与方法选择首行两端的对象、条件与不可互换项逐列一致。

易混淆概念对比

概念对比：分类预测有限类别，回归预测连续数值，标注预测结构化标记序列。概率模型给出不确定性，决策规则结合损失产生动作。精确率控制预测正类的可信度，召回率控制真实正类的覆盖率； F_1 是二者的调和平均，但不含真负类。训练误差用于拟合，验证指标用于选择，测试指标只用于最终估计。

本章共 12 道练习。每道题干后立即给出同号解析；长解析可自然跨页，续页标题保留题号。

练习 11.1. 测试集的 $TP = 24, FP = 6, FN = 8, TN = 62$ 。计算准确率、精确率、召回率和 F_1 。

练习 11.1 解析

以题设正类为正类；这里 $N = 100$ 且精确率、召回率的分母均为正。于是

$$\begin{aligned} \text{Acc} &= \frac{24 + 62}{24 + 6 + 8 + 62} = 0.86, \\ \text{Precision} &= \frac{24}{24 + 6} = 0.8, \\ \text{Recall} &= \frac{24}{24 + 8} = 0.75, \\ F_1 &= \frac{2TP}{2TP + FP + FN} = \frac{48}{62} = \frac{24}{31} \approx 0.774. \end{aligned}$$

一般若 $TP + FP = 0$ ，精确率按该比值定义将是未定义，必须另行声明评价库采用的约定。

练习 11.2. 某输入的三类后验概率为 $(0.2, 0.5, 0.3)$ 。在 0-1 损失下给出 Bayes 预测和最小条件风险。

练习 11.2 解析

标签与动作域均为 $\mathcal{Y} = \mathcal{A} = \{1, 2, 3\}$, 且 $L(y, a) = \mathbf{1}\{y \neq a\}$ 。因此

$$\begin{aligned}\rho(a | x) &= \sum_{y \in \mathcal{Y}} L(y, a) P(y | x) = 1 - P(Y = a | x), \\ (\rho(1 | x), \rho(2 | x), \rho(3 | x)) &= (0.8, 0.5, 0.7), \\ \arg \min_{a \in \mathcal{A}} \rho(a | x) &= \{2\}, \quad \min_{a \in \mathcal{A}} \rho(a | x) = 0.5.\end{aligned}$$

故 Bayes 预测为第 2 类, 最小条件风险为 0.5。

练习 11.3. 若漏诊正类的代价为 5, 误报正类的代价为 1, 正确分类代价为 0, 推导预测正类的概率阈值。

练习 11.3 解析

记 $p = P(Y = 1 | x) \in [0, 1]$, 动作 1 表示预测正类。两动作的条件风险为

$$\begin{aligned}\rho(1 | x) &= 1 \cdot P(Y = 0 | x) = 1 - p, \\ \rho(0 | x) &= 5 \cdot P(Y = 1 | x) = 5p, \\ \rho(1 | x) \leq \rho(0 | x) &\iff 1 - p \leq 5p \\ &\iff p \geq \frac{1}{6}.\end{aligned}$$

若规定风险并列时预测正类, 则阈值规则为 $p \geq 1/6$; 若并列时预测负类, 不等号应改为严格大于。

练习 11.4. 标记集有 4 种标记, 长度为 6。若不利用任何结构, 候选标记序列有多少个? 逐位置独立选择为何可能不合法?

练习 11.4 解析

设标记集 $\mathcal{Y}$ 满足 $|\mathcal{Y}| = 4$, 序列长度 $n = 6$ 。未经约束的输出域为

$$\begin{aligned}\mathcal{Y}^6 &= \{(y_1, \dots, y_6) : y_t \in \mathcal{Y}\}, \\ |\mathcal{Y}^6| &= |\mathcal{Y}|^6 = 4^6 = 4096.\end{aligned}$$

若任务有合法转移集合 $\mathcal{E} \subseteq \mathcal{Y} \times \mathcal{Y}$, 真正可行域是

$$\mathcal{Y}_{\text{legal}}^6 := \{y_{1:6} \in \mathcal{Y}^6 : (y_{t-1}, y_t) \in \mathcal{E}, 2 \leq t \leq 6\} \subseteq \mathcal{Y}^6.$$

逐位置独立最大化未检查 $\mathcal{E}$, 因而可能输出不合法序列。

练习 11.5. 两个长度均为 5 的序列中, 模型分别标对 5 个和 4 个位置。计算逐位置准确率与整序列准确率。

练习 11.5 解析

两条序列的长度均为 5, 位置正确数分别为 5 与 4。故

$$\begin{aligned}\text{Acc}_{\text{token}} &= \frac{5+4}{5+5} = \frac{9}{10} = 0.9, \\ \mathbf{1}\{\hat{y}_{1:5}^{(1)} = y_{1:5}^{(1)}\} &= 1, \\ \mathbf{1}\{\hat{y}_{1:5}^{(2)} = y_{1:5}^{(2)}\} &= 0, \\ \text{Acc}_{\text{seq}} &= \frac{1+0}{2} = \frac{1}{2} = 0.5.\end{aligned}$$

逐位置准确率衡量十个局部判断; 整序列准确率要求一条序列的全部位置同时正确。

练习 11.6. 长度 2、标记集 $\{A, B\}$ 的四个序列未归一化分数分别为 $AA: 3, AB: 5, BA: 4, BB: 2$ 。给出最大分数解码及其归一化概率。

练习 11.6 解析

候选域为 $\mathcal{Y}^2 = \{AA, AB, BA, BB\}$ 。把题给非负分数解释为未归一化权重, 则

$$\begin{aligned}\hat{y} &\in \arg \max_{y \in \mathcal{Y}^2} s(y) = \{AB\}, \\ Z &= \sum_{y \in \mathcal{Y}^2} s(y) = 3 + 5 + 4 + 2 = 14 > 0, \\ P(AB | X) &= \frac{s(AB)}{Z} = \frac{5}{14}, \\ \sum_{y \in \mathcal{Y}^2} P(y | X) &= 1.\end{aligned}$$

若题给的是对数分数 $\ell(y)$, 归一化应改为 $P(y | X) = e^{\ell(y)} / \sum_{y'} e^{\ell(y')}$, 不能直接除以分数和。

练习 11.7. 证明常数预测 a 在平方损失下的总体风险由 $a = \mathbb{E}[Y]$ 最小化。

练习 11.7 解析

设 Y 为实值随机变量且 $\mathbb{E}[Y^2] < \infty$, 于是 $\mu = \mathbb{E}[Y]$ 与 $\text{Var}(Y)$ 均有限。对任意 $a \in \mathbb{R}$,

$$\begin{aligned}R(a) &= \mathbb{E}[(Y - a)^2] \\ &= \mathbb{E}[(Y - \mu + \mu - a)^2] \\ &= \mathbb{E}[(Y - \mu)^2] + 2(\mu - a)\mathbb{E}[Y - \mu] + (\mu - a)^2 \\ &= \text{Var}(Y) + (\mu - a)^2.\end{aligned}$$

因此 $R(a) \geq \text{Var}(Y)$, 且等号当且仅当 $a = \mu$; 故唯一最小点是 $a = \mathbb{E}[Y]$ 。

练习 11.8. 真实值为 $(1, 2, 6)$ ，预测为 $(2, 2, 3)$ 。计算均方误差与平均绝对误差。

练习 11.8 解析

固定残差约定为 $e_i = \hat{y}_i - y_i$ 。由 $y = (1, 2, 6)$ 、 $\hat{y} = (2, 2, 3)$,

$$e = \hat{y} - y = (1, 0, -3),$$

$$\text{MSE} = \frac{1}{3} \sum_{i=1}^3 e_i^2 = \frac{1+0+9}{3} = \frac{10}{3},$$

$$\text{MAE} = \frac{1}{3} \sum_{i=1}^3 |e_i| = \frac{1+0+3}{3} = \frac{4}{3}.$$

第三个残差的绝对值为 3，平方后贡献 9，故均方误差对大残差更敏感。

练习 11.9. 输入 $x \in \mathbb{R}^{20}$ 、输出 $y \in \mathbb{R}$ 。说明这是“一元回归”还是“多元回归”，并区分“多输出回归”。

练习 11.9 解析

题设预测映射的定义域与目标域为

$$f : \mathbb{R}^{20} \longrightarrow \mathbb{R},$$

$$x = (x^{(1)}, \dots, x^{(20)})^\top \longmapsto \hat{y}.$$

所以按输入维数它是多元回归，按输出维数它是单输出回归。多输出回归则具有

$$g : \mathbb{R}^{20} \longrightarrow \mathbb{R}^q, \quad q > 1.$$

使用“一元/多元”术语时应明确是在计输入变量还是输出分量。

练习 11.10. “预测每位患者未来 30 天是否再入院”应建模为哪类任务？写出一个样本的输入、输出和避免泄漏的划分方式。

练习 11.10 解析

以一次出院事件 (u, t) 为一个样本，其中 u 为患者、 t 为出院时点。任务是二分类：

$$x_{u,t} = \phi(\text{截至时点 } t \text{ 可获得的病历}) \in \mathcal{X},$$

$$y_{u,t} = \mathbf{1}\{\text{患者 } u \text{ 在 } (t, t+30\text{日}] \text{ 再入院}\} \in \{0, 1\},$$

$$f : \mathcal{X} \rightarrow \{0, 1\}.$$

为同时阻断患者重复与未来信息泄漏，应采用患者分组并按时间向前的划分，例如

$$\{u : (u, t) \in D_{\text{tr}}\} \cap \{u : (u, t) \in D_{\text{te}}\} = \emptyset,$$

$$\max t_{\text{tr}} < \min t_{\text{te}}.$$

任何在 t 之后产生的诊疗记录都不得进入 $x_{u,t}$ 。

练习 11.11. 垃圾邮件仅占 1%，一个总预测“非垃圾”的模型准确率是多少？为什么该指标不足，应补充什么？

练习 11.11 解析

以垃圾邮件为正类，设测试集 $N > 0$ 且正类恰占 1%。总预测负类时

$$\begin{aligned} TP &= 0, & FP &= 0, \\ FN &= 0.01N, & TN &= 0.99N, \\ \text{Acc} &= \frac{TN}{N} = 0.99, \\ \text{Recall} &= \frac{TP}{TP + FN} = 0, \\ \text{Precision} &= \frac{TP}{TP + FP} = \frac{0}{0} \quad (\text{未定义}). \end{aligned}$$

由计数式 $F_1 = 2TP/(2TP + FP + FN)$ 可按常用约定报告 $F_1 = 0$ ；若软件从未定义的精确率计算，则结果可能为未定义，必须声明采用的零分母约定。还应报告混淆矩阵、召回率、精确率及与任务代价一致的指标。

练习 11.12. 某团队在测试集上比较 20 个模型并选择最高分者，再把该最高分作为最终泛化成绩。指出偏差来源并给出修正流程。

练习 11.12 解析

把二十个测试成绩取最大值等价于让测试集参与选择：

$$\begin{aligned} m_{\text{leak}}^{\star} &\in \arg \max_{1 \leq m \leq 20} \widehat{\text{Score}}_{\text{te}}(\hat{f}_m), \\ D &= D_{\text{tr}} \dot{\cup} D_{\text{val}} \dot{\cup} D_{\text{te}}, \\ \hat{f}_m &= \mathcal{A}_m(D_{\text{tr}}), \\ m^{\star} &\in \arg \max_{1 \leq m \leq 20} \widehat{\text{Score}}_{\text{val}}(\hat{f}_m), \\ \text{最终成绩} &= \widehat{\text{Score}}_{\text{te}}(\hat{f}_{m^{\star}}). \end{aligned}$$

选择规则和阈值冻结后， D_{te} 只使用一次；若原测试集已反复查看，应另取独立测试数据，或采用内层选择、外层评估的嵌套交叉验证。

读前自检：本章结论与下一步。 监督学习任务与应用章末由“分类标签、结构化序列与连续响应”落到“冻结样本、预测时点、特征、损失、指标与划分后训练评估”；请把前者产出和后者输入逐项对齐，固定核对前者末项的输出类型能否作为后者首项的输入类型。

本章结论与下一步

核心结论： 分类标签、结构化序列与连续响应

关键依据： 条件风险导出分类决策，动态规划组合局部结构，损失决定回归目标

可执行自检： 冻结样本、预测时点、特征、损失、指标与划分后训练评估

适用边界： 把业务问题映射为可验证的监督学习任务

下一步： 进入第 2 册具体方法，并用本章任务规范检查适配性

1. 能否由输出空间和数据单位区分分类、标注与回归？
2. 能否从条件风险三步推导 **Bayes** 分类规则，并按代价改变阈值？
3. 能否计算并解释准确率、精确率、召回率、 F_1 、均方误差和整序列准确率？
4. 能否为一个真实应用冻结预测时点、样本、特征边界、划分、指标和退出规则？未通过时依次回看节 11.1—11.4。

第 2 册：基础监督学习方法

本册集中比较五类基础监督学习方法的表示、策略与算法：从线性分离和距离度量，到生成式概率模型、树结构划分与条件概率建模。

- 1. 感知机；
- 2. k 近邻法；
- 3. 朴素贝叶斯法；
- 4. 决策树；
- 5. 逻辑斯谛回归。

关键结论

学习时重点比较模型假设、损失或概率目标、训练算法、预测代价与适用数据结构，形成可复用的模型选择视角。

跨册依赖

本册默认掌握第 2 章的向量与距离、第 5 章的极大似然，以及第 8 章的梯度与数值优化。感知机和逻辑斯谛回归突出线性决策边界， k 近邻法和决策树强调局部结构，朴素贝叶斯法提供生成式概率视角。

完成标准

完成本册后，应能从表示、策略、算法三个层面说明五类方法，手算小样本训练或预测过程，辨析生成式与判别式建模，并根据数据规模、特征类型和解释需求给出有依据的模型选择。

建议用法

每学完一种方法，使用同一份小型分类数据记录其决策边界、训练信息、预测开销和主要误差来源；完成五章后再用统一表格横向比较，可避免只记公式而忽略适用条件。

第 12 章 感知机

读前自检：先修自检。 感知机先修自检固定核验“给定 $w \in \mathbb{R}^d$ 和 $x \in \mathbb{R}^d$ ，能否说明 $w^\top x$ 是标量并写出其分量和”；请给定 $w \in \mathbb{R}^d$ 和 $x \in \mathbb{R}^d$ ，实际说明 $w^\top x$ 是标量并写出其分量和并写出中间结果，再按“ $w \in \mathbb{R}^d$ 的计算或证明结果满足首项所列等式、定义域或判断”明确判为通过或失败。

本章地图

核心问题： 误分类更新何时能在有限步找到分隔超平面

可检验学习目标：

- 从线性可分条件出发，说明感知机的模型、损失函数与误分类更新之间的联系；
- 能够手工执行原始形式和对偶形式，逐步证明线性可分数据上的有限步收敛；
- 能够判断方法的适用条件、复杂度与局限，并用几何图像检查计算结果。

最短先修： 需要掌握向量内积、欧氏范数、超平面、点到超平面的距离、梯度与随机梯度更新。还应理解二分类标签 $\{-1, +1\}$ 、训练集与判别函数；这些内容分别支撑几何分离、损失构造和参数迭代。

依赖路线： 向量内积与超平面 $\rightarrow$ 线性分类模型；标签编码 $\rightarrow$ 统一的正确分类条件；点到超平面的距离 $\rightarrow$ 误分类损失；随机梯度更新 $\rightarrow$ 原始形式；参数的样本线性组合 $\rightarrow$ 对偶形式；正间隔 $\rightarrow$ 有限次误分类上界。

完成标准与返回： 若数据不可分或间隔前提缺失，回看模型与收敛性两节

模型认识卡：感知机

任务与输入： 线性可分二分类， $x \in \mathbb{R}^d, y \in \{-1, +1\}$ 。 **输出类型：** 类别符号与线性得分。

模型： $f(x) = \text{sign}(w^\top x + b)$ 。 **策略：** 减少误分类点的带符号间隔损失。 **算法：** 按固定次序扫描，仅在 $y_i(w^\top x_i + b) \leq 0$ 时更新。

预测： 取线性得分符号。 **关键假设与边界：** 有限步收敛需要正间隔线性可分；不可分数据上必须另设预算或改用软间隔模型。

本章符号表

符号	取值或维数	含义
$T = \{(x_i, y_i)\}_{i=1}^N$	$x_i \in \mathbb{R}^d, y_i \in \{-1, +1\}$	二分类训练集
w, b	$w \in \mathbb{R}^d, b \in \mathbb{R}$	超平面的法向量与截距
$g(x), f(x)$	实数、 $\{-1, +1\}$	判别分数 $g(x) = w^\top x + b$ 与类别 $f(x) = \text{sign } g(x)$
M	$\{1, \dots, N\}$ 的子集	当前被误分类的样本下标集合
η	正实数	学习率
α_i	非负实数	第 i 个样本触发更新的累计强度
G	$\mathbb{R}^{N \times N}$	Gram 矩阵, $G_{ij} = x_i^\top x_j$
$\hat{x}_i, \hat{w}$	$\mathbb{R}^{d+1}$	增广向量 $(x_i^\top, 1)^\top$ 与 $(w^\top, b)^\top$

读前自检：感知机。 感知机以 $x \in \mathbb{R}^d, y \in \{-1, +1\}$ 为样本；请计算 $y(w^\top x + b)$ ，核对仅当该带符号分数不大于 0 时触发参数更新。

12.1 二分类与线性分离

感知机研究一个基础问题：能否用一张超平面把正类与负类训练样本完全分开？若可以，还要构造一套只在发生误分类时修改参数的学习过程。该方法因此同时包含几何对象、判别规则和迭代算法。

对任意 $x \in \mathbb{R}^d$ ，线性分数 $g(x) = w^\top x + b$ 把空间分成 $g(x) > 0$ 与 $g(x) < 0$ 两个开半空间。约定

$$\text{sign}(z) = \begin{cases} +1, & z \geq 0, \\ -1, & z < 0, \end{cases} \quad f(x) = \text{sign}(w^\top x + b).$$

边界上的取值约定会影响 $g(x) = 0$ 时的预测，但训练中把 $y_i g(x_i) \leq 0$ 统一视为需要更新，可以避免边界样本被误当作具有正间隔的正确分类点。

读前自检：数据集线性可分性定义。 数据集线性可分性定义中的“存在 $w \in \mathbb{R}^d$ 和 $b \in \mathbb{R}$ ”决定可执行范围；请将 $T = \{(x_i, y_i)\}_{i=1}^N$ 左端按定义展开一层，再与右端逐项对齐，结果须满足严格不等式意味着每个训练点都位于边界之外。

读前自检：线性可分训练集。 把线性可分训练集放在“存在 $w \in \mathbb{R}^d$ 和 $b \in \mathbb{R}$ ”下考察：独立化简 $T = \{(x_i, y_i)\}_{i=1}^N$ 的两端，并检查严格不等式意味着每个训练点都位于边界之外。

定义 12.1 (线性可分训练集). 设 $T = \{(x_i, y_i)\}_{i=1}^N$ ，其中 $x_i \in \mathbb{R}^d$ 且 $y_i \in \{-1, +1\}$ 。若存在 $w \in \mathbb{R}^d$ 和 $b \in \mathbb{R}$ ，使每个 i 都满足

$$y_i(w^\top x_i + b) > 0,$$

则称 T 线性可分，并称 $w^\top x + b = 0$ 为一个分离超平面。严格不等式意味着每个训练点都位于边界之外。

定义中的一个不等式同时覆盖两类： $y_i = +1$ 时要求 $g(x_i) > 0$ ， $y_i = -1$ 时要求 $g(x_i) < 0$ 。若有样本落在超平面上，则乘积为零，尚未形成严格分离。分离超平面通常不唯一；感知机的最终参数会受样本访问顺序、初值和学习率影响。

读前自检：感知机定义。 感知机把 $x \in \mathbb{R}^d$ 映到 $y \in \{-1, +1\}$ ；请计算 $f(x) = \text{sign}(w^\top x + b)$ ，核对输出属于二类标签集合。

12.2 感知机模型

读前自检：感知机模型。 感知机超平面 $w^\top x + b = 0$ 分割输入空间；请分别代入一个正分数和负分数，核对 $f(x)$ 返回 $+1$ 与 -1 ，零分数按并列规则处理。

定义 12.2 (感知机模型). 感知机是从输入空间 $\mathcal{X} \subseteq \mathbb{R}^d$ 到输出空间 $\mathcal{Y} = \{-1, +1\}$ 的函数

$$f(x) = \text{sign}(w^\top x + b),$$

其中 $w \in \mathbb{R}^d$ 称为权向量, $b \in \mathbb{R}$ 称为偏置。模型对应的几何边界是超平面 $w^\top x + b = 0$, w 决定法向方向, b 决定沿该方向的平移。

读前自检：几何解释：点 x_0 到决策超平面的欧氏距离为 $\frac{|w^\top x_0 + b|}{\|w\|_2}$ 带标签的归一化分数.....。点 x_0 到感知机决策超平面的距离为 $|w^\top x_0 + b|/\|w\|_2$ ；请再乘标签得到带符号归一化分数，核对其正负对应正确侧与错误侧。

几何理解

几何解释。 点 x_0 到决策超平面的欧氏距离为

$$\frac{|w^\top x_0 + b|}{\|w\|_2}.$$

带标签的归一化分数 $y_i(w^\top x_i + b)/\|w\|_2$ 为正时表示方向正确，其绝对值等于点到超平面的距离；为负时表示样本位于标签所要求半空间的另一侧。




图 12.1 超平面、法向量与两类样本的几何关系。法向量指向分数增大的半空间。

图 12.1 中的边界方向由 w 控制。把 (w, b) 同乘正数不会改变直线和预测，但会同比放大未归一化分数；因此几何距离需要除以 $\|w\|_2$ 。

读前自检：感知机学习策略。 感知机学习策略以 “ $M(w, b) = \{i : y_i(w^\top x_i + b) \leq 0\}$,” 为约束；请把 $M(w, b)$ 展开一次并检查其类型或边界，并确认展开后的量满足定义中的域、维数或符号限制。

12.3 误分类驱动的学习策略

感知机不直接最小化误分类个数，因为该目标是离散且不可导的。它先选出当前误分类集合

$$M(w, b) = \{i : y_i(w^\top x_i + b) \leq 0\},$$

再用这些点到超平面的错误侧距离构造连续的代理损失。

读前自检：感知机学习策略的损失函数。 感知机在固定误分类集合 M 时使用 $L(w, b) = -\sum_{i \in M} y_i(w^\top x_i + b)$ ；请对单项求梯度，核对负梯度步得到 $w \leftarrow w + \eta y_i x_i, b \leftarrow b + \eta y_i$ 。

阅读目标：区分几何距离与函数间隔，并从误分类代理损失得到更新式。

对象：样本 (x_i, y_i) 、参数 (w, b) 、函数间隔 $y_i(w^\top x_i + b)$ 与当前误分类集合 M 。

合法条件：求一次方向时先固定 M ；参数更新后必须重新判定误分类集合。

第一步：先定义 $L(w, b) = -\sum_{i \in M} y_i(w^\top x_i + b)$ ，不要把除以 $\|w\|$ 的几何距离直接当作优化目标。

推导目标

区分几何距离与函数间隔，直接定义感知机代理损失并推导随机梯度更新。

推导准备

固定当前参数 (w, b) 并把误分类集合记作 M 。在求一次更新方向时先把 M 视为不变；当参数更新后，再重新判断哪些样本属于 M 。

推导第1步：若 $i \in M$ ，则 $y_i(w^\top x_i + b) \leq 0$ ，样本到边界的距离可写为

$$\frac{|w^\top x_i + b|}{\|w\|_2} = -\frac{y_i(w^\top x_i + b)}{\|w\|_2}.$$

最后一个等号利用了 $y_i \in \{-1, +1\}$ 以及误分类时带符号分数非正。

推导第2步：几何距离之和含有随 w 变化的分母 $\|w\|_2$ ，所以不能把 $1/\|w\|_2$ 当作常数从该优化目标中删除。感知机方法另行定义误分类点负函数间隔之和为代理损失

$$L(w, b) = -\sum_{i \in M} y_i(w^\top x_i + b), \quad L(w, b) \geq 0.$$

当 $M = \emptyset$ 时空和为零，表示全部训练点已具有正确的严格符号。若固定 $\|w\|_2$ ，该代理损失与几何距离之和只差固定正因子；在未固定范数的通常感知机迭代中，两者是不同目标。

推导第3步：固定 M 后逐分量求导，

$$\nabla_w L = -\sum_{i \in M} y_i x_i, \quad \frac{\partial L}{\partial b} = -\sum_{i \in M} y_i.$$

若每次只取一个误分类点 (x_i, y_i) 作随机梯度下降, 则

$$w \leftarrow w + \eta y_i x_i, \quad b \leftarrow b + \eta y_i.$$

更新后该点的带符号分数增加 $\eta(\|x_i\|_2^2 + 1)$, 所以更新确实把它朝正确半空间推动。

概率解释

感知机是确定性的判别模型, 不输出校准的 $p(y | x)$ 。分数 $w^T x + b$ 的大小不能直接解释为概率; 同一分类边界在正比例缩放参数后产生不同分数, 却给出相同类别。若应用需要概率, 应另行建立概率模型或执行有验证依据的校准。

读前自检：优化解释：在固定误分类集合 M 时, L 关于 (w, b) 为线性函数, 随机更新就是对单个损失项.....。对在固定误分类集合 M 时, L 关于 (w, b) 为线性函数, 随机更新就是对单个损失项....., 条件“在固定误分类集合 M 时, L 关于 (w, b) 为线性函数, 随机更新就是对单个损失项作一步梯度下降”不可省; 请对 M 完成一项求导、代入或边界比较, 再用集合 M 会随参数改变, 因此整体过程是分段线性的在线优化作检查。

优化解释

优化解释。在固定误分类集合 M 时, L 关于 (w, b) 为线性函数, 随机更新就是对单个损失项作一步梯度下降。集合 M 会随参数改变, 因此整体过程是分段线性的在线优化; 在线性不可分数据上, 零损失点可能不存在, 算法会在不同误分类点之间持续更新。

例题 12.1 (一次误分类更新). 设 $w^{(0)} = (0, 0)^T, b^{(0)} = 0, \eta = 1$, 抽到 $x = (2, -1)^T, y = +1$ 。求一次感知机更新后的参数与该样本的新带符号分数。

例题 12.1 解答

读题翻译 先用旧参数判断该样本是否触发感知机更新; 若触发, 只执行一次 w, b 更新, 再计算同一样本的新带符号分数。

已知与合法条件 $w^{(0)} = (0, 0)^T, b^{(0)} = 0, \eta = 1, x = (2, -1)^T, y = 1$; 采用 $m = y(w^T x + b) \leq 0$ 时更新的约定。

为什么想到这个方法 感知机原始形式在误分类或边界样本上使用 $w \leftarrow w + \eta y x, b \leftarrow b + \eta y$ 。

方法选择 计算 $m^{(0)}$ 判定是否更新; 代入一次更新式求 $w^{(1)}, b^{(1)}$; 再直接代入并用增量恒等式复核 $m^{(1)}$ 。

推导/计算 更新前的带符号分数和参数更新为

$$\begin{aligned} m^{(0)} &= y((w^{(0)})^T x + b^{(0)}) = 0 \leq 0, \\ w^{(1)} &= w^{(0)} + \eta y x = (2, -1)^T, \\ b^{(1)} &= b^{(0)} + \eta y = 1. \end{aligned}$$

更新后的带符号分数为

$$m^{(1)} = y((w^{(1)})^T x + b^{(1)}) = 2^2 + (-1)^2 + 1 = 6 > 0.$$

独立核验 更新恒等式给出 $m^{(1)} = m^{(0)} + \eta \|x\|_2^2 + \eta = 0 + 5 + 1 = 6$, 与直接代入一致; 这只证明本样本更新后被正确分类, 不代表全训练集已经收敛。

结论 一次更新后 $w^{(1)} = (2, -1)^T$ 、 $b^{(1)} = 1$, 该样本的新带符号分数为 $m^{(1)} = 6$ 。

读前自检：感知机学习算法。 感知机学习算法输入“非空有限训练集 T 、有限正学习率 η 、扫描预算 K 与固定样本次序”，条件“样本同维且坐标有限”；请做一轮“仅当 $m_i \leq 0$ 时构造并核验 (w^+, b^+) ，再原子提交”，以“完整一轮零更新给出数学停止证书”核对停止证书。

读前自检：感知机学习算法的原始形式。 感知机学习算法的原始形式输入“非空有限训练集 T 、有限正学习率 η 、扫描预算 K 与固定样本次序”，条件“样本同维且坐标有限”；请做一轮“仅当 $m_i \leq 0$ 时构造并核验 (w^+, b^+) ，再原子提交”，以“完整一轮零更新给出数学停止证书”核对停止证书。

读前自检：感知机学习算法原始形式。 感知机学习算法原始形式输入“非空有限训练集 T 、有限正学习率 η 、扫描预算 K 与固定样本次序”，条件“样本同维且坐标有限”；请做一轮“仅当 $m_i \leq 0$ 时构造并核验 (w^+, b^+) ，再原子提交”，以“完整一轮零更新给出数学停止证书”核对停止证书。

12.4 原始形式学习算法

原始形式直接维护 w 和 b 。每轮按既定顺序访问样本，只要发现 $y_i(w^T x_i + b) \leq 0$ 就更新；一整轮没有更新时，所有训练样本都已被严格正确分类。

感知机学习算法的原始形式：五步阅读

输入。 写出数据对象、固定参数与必须成立的条件。

初始化。 标明主状态、计数器和第一个合法状态。

核心更新。 只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。 写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。 列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 12.1: 感知机学习算法的原始形式

输入: 训练集 $T = \{(x_i, y_i)\}_{i=1}^N$, 其中 $x_i \in \mathbb{R}^d, y_i \in \{-1, +1\}$

输出: 最后合法参数 (w, b) 、完整扫描轮数 epoch 、样本检查数 v 、累计更新数 update_count 、 status 与最终诊断

数据: 学习率 $\eta > 0$; 最大扫描轮数 $K \in \mathbb{N}_0$; 固定样本次序

- 1 $w \leftarrow 0, b \leftarrow 0, \text{epoch} \leftarrow 0, v \leftarrow 0, \text{update_count} \leftarrow 0, u_{\text{epoch}} \leftarrow 0$
- 2 若 $T = \emptyset$ 、样本维数不一致、标签不在 $\{-1, +1\}$ 、特征非有限、 η 不是有限正数或 $K \notin \mathbb{N}_0$, 则返回当前零初值、计数 0、 invalid_input 及具体字段诊断
- 3 对 $t \leftarrow 1$ 至 K 执行
 - 4 置本轮更新计数 $u_{\text{epoch}} \leftarrow 0$
 - 5 对 $i \leftarrow 1$ 至 N 执行
 - 6 计算 $m_i \leftarrow y_i(w^\top x_i + b)$
 - 7 若 m_i 非有限, 则返回未改动的最后合法 (w, b) 、 $\text{epoch}, v, \text{update_count}$ 、 numerical_failure , 诊断为失败位置 (t, i)
 - 8 $v \leftarrow v + 1$
 - 9 若 $m_i \leq 0$ 则
 - 10 先计算候选 $w^+ \leftarrow w + \eta y_i x_i, b^+ \leftarrow b + \eta y_i$; 若候选含非有限值, 则返回未改动的最后合法 (w, b) 、当前计数、 numerical_failure , 诊断为失败位置 (t, i)
 - 11 $w \leftarrow w^+, b \leftarrow b^+, u_{\text{epoch}} \leftarrow u_{\text{epoch}} + 1, \text{update_count} \leftarrow \text{update_count} + 1$
 - 12 结束
 - 13 结束
 - 14 $\text{epoch} \leftarrow t$
 - 15 若 $u_{\text{epoch}} = 0$ 则
 - 16 返回 $(w, b), \text{epoch}, v, \text{update_count}, \text{converged}$, 最终诊断记录“整轮零更新”及最小训练间隔
 - 17 结束
 - 18 结束
- 19 返回最后合法 $(w, b), \text{epoch}, v, \text{update_count}, \text{budget_stop}$, 最终诊断记录“扫描预算耗尽”及末轮更新数 u_{epoch}

算法实现说明: 工程层只补充有限性检查、扫描预算和失败位置; epoch 只在完整扫描结束后增加, update_count 只在参数更新提交后增加。完整 C1-C14 契约

算法 12.1 的输入、输出和参数均在伪代码中列明。初始化可取零或任意有限向量; 更新顺序必须先计算当前带符号分数, 再同时修改 w, b 。停止条件是完整扫描一轮且 $u = 0$; 在线性可分和固定正学习率条件下, Novikoff 定理保证误分类更新次数有限。达到预算上限属于工程停止, 不等同于数学收敛。

例题 12.2 (原始形式的手工执行). 取 $(3, 3), (4, 3)$ 为正类, $(1, 1)$ 为负类, 令 $\eta = 1, w^{(0)} = 0, b^{(0)} = 0$ 并按该顺序循环。求一条收敛的更新轨迹, 并验证最终参数严格分离训练集。

读题翻译 “一条轨迹”要求按固定扫描次序只记录真正触发的参数更新; “收敛”还必须由下一整轮零更新核验。

为什么想到这个方法 感知机每次只检查带符号分数 $y_i(w^\top x_i + b)$; 非正时按 $w \leftarrow w + y_i x_i, b \leftarrow b + y_i$ 更新。

例题 12.2 解答

读题翻译 题目要求按给定顺序手算一条感知机轨迹；箭头只记录真正触发的参数更新，最终还要用下一整轮零更新证明这条轨迹已经停止。

已知与合法条件 学习率为 1，初值为零，扫描顺序固定为两个正类样本后接一个负类样本；每次访问只检查当前带符号分数 $y_i(w^T x_i + b)$ 。

为什么想到这个方法 带符号分数非正时同时更新 $w \leftarrow w + y_i x_i$ 和 $b \leftarrow b + y_i$ ，为正时保持参数不变；得到候选终点后重新计算三个样本的分数。

方法选择 按固定顺序逐点扫描，只列发生更新的状态；随后把最终参数代回全部样本，并再扫一整轮确认没有更新。

推导/计算 只记录触发更新后的状态，可得

$$\begin{aligned} ((0, 0), 0) &\xrightarrow{(3, 3), +1} ((3, 3), 1) \xrightarrow{(1, 1), -1} ((2, 2), 0) \\ &\xrightarrow{(1, 1), -1} ((1, 1), -1) \xrightarrow{(1, 1), -1} ((0, 0), -2) \\ &\xrightarrow{(3, 3), +1} ((3, 3), -1) \xrightarrow{(1, 1), -1} ((2, 2), -2) \\ &\xrightarrow{(1, 1), -1} ((1, 1), -3). \end{aligned}$$

对 $w = (1, 1)^T, b = -3$ ，三个带符号分数依次为

$$\begin{aligned} (+1)((1, 1)(3, 3)^T - 3) &= 3, \\ (+1)((1, 1)(4, 3)^T - 3) &= 4, \\ (-1)((1, 1)(1, 1)^T - 3) &= 1. \end{aligned}$$

三者均严格为正，最小带符号分数为 1，故该参数严格分离训练集。再完整扫描三个样本时不会触发任何更新，这一“整轮零更新”给出停止证书；访问次序改变时，所得分离超平面不必唯一。

卡住时先看 不要按样本访问次数编号箭头；未触发更新的访问仍属于扫描过程，但不产生新的参数状态。

方法迁移 对任意手工感知机题，最后都单独列出全部样本的带符号分数，再用一次零更新全扫描作为停止证书。

独立核验 从零初值到 $(w, b) = ((1, 1)^T, -3)$ 共发生 7 次更新；三个最终带符号分数为 3, 4, 1，下一整轮均为正，轨迹与停止条件相互一致。

结论 在题定扫描顺序下，一条收敛轨迹终止于 $w = (1, 1)^T, b = -3$ ；它严格分离三个训练样本。

表 12.1 只记录实际更新；未触发更新的访问仍属于扫描成本。最后再完整扫描一轮且没有更新，才能按算法的停止条件报告训练集收敛。

表 12.1 三点示例按固定顺序扫描时的参数更新

更新序号	旧状态 (w, b)	触发样本	新状态 (w, b)
1	$((0, 0)^T, 0)$	$(3, 3), +1$	$((3, 3)^T, 1)$
2	$((3, 3)^T, 1)$	$(1, 1), -1$	$((2, 2)^T, 0)$
3	$((2, 2)^T, 0)$	$(1, 1), -1$	$((1, 1)^T, -1)$
4	$((1, 1)^T, -1)$	$(1, 1), -1$	$((0, 0)^T, -2)$
5	$((0, 0)^T, -2)$	$(3, 3), +1$	$((3, 3)^T, -1)$
6	$((3, 3)^T, -1)$	$(1, 1), -1$	$((2, 2)^T, -2)$
7	$((2, 2)^T, -2)$	$(1, 1), -1$	$((1, 1)^T, -3)$

读前自检：感知机学习算法的收敛性。 感知机收敛性假设增广样本范数不超过 R ，且存在单位 $\hat{w}_*$ 使 $y_i \hat{w}_*^T \hat{x}_i \geq \gamma > 0$ ；请比较第 k 次误更新后的内积下界与范数上界，并核对得到有限误更新次数。

读前自检：Novikoff 定理。 Novikoff 定理在增广样本线性可分、范数界 R 和间隔 $\gamma > 0$ 下成立；请把 $\hat{w}_k^T \hat{w}_* \geq k\eta\gamma$ 与 $\|\hat{w}_k\|^2 \leq k\eta^2 R^2$ 合并，核对误更新次数至多 $(R/\gamma)^2$ 。

12.5 收敛性证明

为把偏置纳入内积，定义 $\hat{x}_i = (x_i^T, 1)^T$ 与 $\hat{w} = (w^T, b)^T$ 。一次误分类更新统一写成 $\hat{w}_k = \hat{w}_{k-1} + \eta y_i \hat{x}_i$ 。

定理 12.1 (Novikoff 误分类上界) 设增广训练集线性可分，且存在单位向量 $\hat{w}_* \in \mathbb{R}^{d+1}$ 与常数 $\gamma > 0$ ，使每个 i 满足

$$y_i \hat{w}_*^T \hat{x}_i \geq \gamma.$$

再设 $R = \max_i \|\hat{x}_i\|_2 < \infty$ 。感知机从 $\hat{w}_0 = 0$ 出发，以固定 $\eta > 0$ 在带符号分数非正的样本上更新，则误分类更新总次数 k 满足

$$k \leq \left(\frac{R}{\gamma}\right)^2.$$

该结论的用途是保证线性可分有限样本上的更新次数有限，而不是保证所得分离超平面唯一。

证明。 证明目标是同时控制 $\hat{w}_k$ 沿正确方向的增长与自身范数的增长，再用 Cauchy-Schwarz 不等式消去未知向量。

第 j 次误分类更新使用样本 $(\hat{x}_{i_j}, y_{i_j})$ 。与 $\hat{w}_*$ 取内积并使用间隔条件，得到

$$\hat{w}_j^T \hat{w}_* = \hat{w}_{j-1}^T \hat{w}_* + \eta y_{i_j} \hat{x}_{i_j}^T \hat{w}_* \geq \hat{w}_{j-1}^T \hat{w}_* + \eta\gamma.$$

由 $\hat{w}_0 = 0$ 逐次累加，

$$\hat{w}_k^T \hat{w}_* \geq k\eta\gamma. \quad (1)$$

另一方面, 更新发生前该样本满足 $y_{i_j} \hat{w}_{j-1}^T \hat{x}_{i_j} \leq 0$, 因此

$$\begin{aligned}\|\hat{w}_j\|_2^2 &= \|\hat{w}_{j-1} + \eta y_{i_j} \hat{x}_{i_j}\|_2^2 \\ &= \|\hat{w}_{j-1}\|_2^2 + 2\eta y_{i_j} \hat{w}_{j-1}^T \hat{x}_{i_j} + \eta^2 \|\hat{x}_{i_j}\|_2^2 \\ &\leq \|\hat{w}_{j-1}\|_2^2 + \eta^2 R^2.\end{aligned}$$

再次累加得

$$\|\hat{w}_k\|_2^2 \leq k\eta^2 R^2. \quad (2)$$

由于 $\|\hat{w}_\star\|_2 = 1$, Cauchy-Schwarz 不等式与式 (1)-(2) 给出

$$\begin{aligned}k\eta\gamma &\leq \hat{w}_k^T \hat{w}_\star \\ &\leq \|\hat{w}_k\|_2 \\ &\leq \sqrt{k\eta}R.\end{aligned}$$

当 $k > 0$ 时除以 $\sqrt{k\eta\gamma}$ 并平方, 得到

$$\sqrt{k} \leq \frac{R}{\gamma}, \quad k \leq \left(\frac{R}{\gamma}\right)^2.$$

$k = 0$ 也满足结论。故误分类更新次数有限, 定理结论成立。 $\square$

读前自检：感知机学习算法的对偶形式。 感知机对偶形式从零初值维护 α_i 与 b ; 对一个满足 $y_i(\sum_j \alpha_j y_j G_{ji} + b) \leq 0$ 的样本, 请执行 $\alpha_i \leftarrow \alpha_i + \eta$ 、 $b \leftarrow b + \eta y_i$, 回代核对 $w = \sum_j \alpha_j y_j x_j$ 与原始更新一致。

12.6 对偶形式与 Gram 矩阵

从零初值出发, 每次更新都向 w 加入 $\eta y_i x_i$ 。若第 i 个样本累计触发的强度为 $\alpha_i \geq 0$, 则

$$\begin{aligned}w &= \sum_{i=1}^N \alpha_i y_i x_i, \\ b &= \sum_{i=1}^N \alpha_i y_i.\end{aligned}$$

这里把固定学习率吸收到 α_i 的增量中; 若每次增量为 η , 则 α_i 是 η 乘以该样本的更新次数。

读前自检：感知机学习算法对偶形式。 感知机学习算法对偶形式输入“非空有限训练集 T 、有限正学习率 η 、扫描预算 K 、Gram 模式与固定样本次序”, 条件“样本同维且有限”; 请做一轮“误分时构造 α_i^+, b^+, w^+ , 核验有限后同步提交”, 以“完整一轮零更新给出数学停止证书”核对停止证书。

把 $w = \sum_j \alpha_j y_j x_j$ 代入第 i 个样本的判断条件, 得到

$$y_i \left(\sum_{j=1}^N \alpha_j y_j x_j^\top x_i + b \right) \leq 0.$$

预先计算 $G_{ji} = x_j^\top x_i$ 后, 每次判断只需要访问内积表。误分类时更新 $\alpha_i \leftarrow \alpha_i + \eta$ 与 $b \leftarrow b + \eta y_i$; 训练结束后再由线性组合恢复 w 。

感知机学习算法的对偶形式：五步阅读

输入。 写出数据对象、固定参数与必须成立的条件。

初始化。 标明主状态、计数器和第一个合法状态。

核心更新。 只手算一次从旧状态到候选状态的更新, 并指出何时提交。

数学停止。 写出能直接核验的停止证书; 预算耗尽不等同于收敛。

输出。 列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 12.2: 感知机学习算法的对偶形式

输入: 训练集 $T = \{(x_i, y_i)\}_{i=1}^N$
输出: 最后合法的系数 α 、偏置 b 与 w ; epoch、 v 、update_count、status 与最终诊断
数据: 学习率 $\eta > 0$; 最大轮数 $K \in \mathbb{N}_0$; Gram 矩阵模式与固定样本次序

- 1 $\alpha \leftarrow 0, b \leftarrow 0, w \leftarrow 0, \text{epoch} \leftarrow 0, v \leftarrow 0, \text{update_count} \leftarrow 0, u_{\text{epoch}} \leftarrow 0$
- 2 若训练集为空、维数或标签非法、特征非有限、 η 不是有限正数或 $K \notin \mathbb{N}_0$, 则返回当前零状态、计数 0、invalid_input 及字段诊断
- 3 若选择预存模式, 则在临时表计算全部 $G_{ij} \leftarrow x_i^T x_j$, 核对称性与有限性后提交; 若任一内积非有限或核验证失败, 则返回未改动的零状态、numerical_failure, 诊断为失败位置 (i, j)
- 4 对 $t \leftarrow 1$ 至 K 执行
 - 5 置 $u_{\text{epoch}} \leftarrow 0$
 - 6 对 $i \leftarrow 1$ 至 N 执行
 - 7 令 $g_{ji} = G_{ji}$ (预存模式) 或即时计算 $g_{ji} = x_j^T x_i$, 再计算 $m_i \leftarrow y_i(\sum_{j=1}^N \alpha_j y_j g_{ji} + b)$
 - 8 若 m_i 非有限, 则返回最后合法 (α, b, w) 、epoch、 v 、update_count、numerical_failure, 诊断为失败位置 (t, i)
 - 9 $v \leftarrow v + 1$
 - 10 若 $m_i \leq 0$ 则
 - 11 先计算候选 $\alpha_i^+ \leftarrow \alpha_i + \eta$ 、 $b^+ \leftarrow b + \eta y_i$ 、 $w^+ \leftarrow w + \eta y_i x_i$; 若任一候选非有限, 则返回未改动的最后合法状态与 numerical_failure 诊断
 - 12 $\alpha_i \leftarrow \alpha_i^+, b \leftarrow b^+, w \leftarrow w^+, u_{\text{epoch}} \leftarrow u_{\text{epoch}} + 1, \text{update_count} \leftarrow \text{update_count} + 1$
 - 13 结束
 - 14 结束
 - 15 epoch $\leftarrow t$
 - 16 若 $u_{\text{epoch}} = 0$ 则
 - 17 返回 (α, b, w) 、epoch、 v 、update_count、converged, 最终诊断记录“整轮零更新”、Gram 模式与最小训练间隔
 - 18 结束
- 19 结束
- 20 返回最后合法 (α, b, w) 、epoch、 v 、update_count、budget_stop, 最终诊断记录“扫描预算耗尽”、末轮更新数与 Gram 模式

算法实现说明: 预存与即时 Gram 模式共享同一数学更新; 工程实现只需记录非法内积位置、预算余量和最后合法状态, 不改变 epoch 与 update_count 的含义。完整 C1-C14 契约

对代表性三点 $(3, 3), (4, 3), (1, 1)$, Gram 矩阵为

$$G = \begin{pmatrix} 18 & 21 & 6 \\ 21 & 25 & 7 \\ 6 & 7 & 2 \end{pmatrix}.$$

矩阵必须对称且半正定; 若手工计算得到 $G_{ij} \neq G_{ji}$, 说明内积表存在算术错误。

读前自检: 复杂度分析: 对偶形式与 Gram 矩阵。 从对偶形式与 Gram 矩阵的条件“若显式使用对偶形式”出发, 请由 d 的总成本剥离一次迭代或一次样本因子; 所得量应符合若即时计算内积可省去 Gram 矩阵, 但会重复承担特征维度上的计算。

复杂度分析

复杂度假设。以下界采用稠密 d 维实向量的单位成本算术，并把训练期间实际检查的样本总数记为 Q ；若显式使用对偶形式，则假设 Gram 矩阵按稠密数组预计算并保存。稀疏特征或即时核计算应分别以非零元数和核求值成本重计。设训练样本数为 N 、特征维数为 d 、训练期间累计检查样本数为 Q ，待预测样本数为 M 。

训练复杂度：原始形式每次检查 and 实际更新均为 $O(d)$ ，总训练时间为 $O(Qd)$ 。对偶形式预计算 Gram 矩阵需 $O(N^2d)$ ，之后一次样本判断在稠密 α 下需 $O(N)$ ，完整一轮为 $O(N^2)$ ；总时间还要乘以实际扫描轮数。

预测复杂度：恢复原始参数 (w, b) 后，单样本预测计算一个 d 维内积，时间为 $O(d)$ ； M 个样本批量预测为 $O(Md)$ 。

存储复杂度：原始形式除训练集外只需 $O(d)$ 参数；对偶形式需 $O(N)$ 系数与 $O(N^2)$ 的 Gram 矩阵。若即时计算内积可省去 Gram 矩阵，但会重复承担特征维度上的计算。

12.7 例题、判别计算与练习

适用条件与局限性

适用条件：感知机适合标签为 $\{-1, +1\}$ 、希望得到线性判别边界且训练数据近似线性可分的任务，也可作为在线学习与核方法的入门模型。**局限性：**不可分或含标签冲突的数据上，基本算法没有零误分类收敛保证；结果不唯一、不输出概率，也不主动选择最大几何间隔，对特征尺度和访问顺序较敏感。

常见错误

典型误用包括：把 $y_i(w^T x_i + b) < 0$ 写成唯一更新条件而漏掉边界点；在距离公式中忘记除以 $\|w\|_2$ ；梯度下降更新误写为减去 $\eta y_i x_i$ ；对偶形式遗漏标签 y_j ；把学习率吸收到 α 后又重复乘一次；把“有限步停止”推广到不可分数据；把判别分数当作概率。

读前自检：易混淆概念对比：例题、判别计算与练习。 例题、判别计算与练习依赖“概念对比：函数间隔 $y_i(w^T x_i + b)$ 会随参数正比例缩放”；请据此按表格顺序核对例题、判别计算与练习对比表的首个数据行，并直接核对例题、判别计算与练习首行两端的对象、条件与不可互换项逐列一致。

易混淆概念对比

概念对比：函数间隔 $y_i(w^T x_i + b)$ 会随参数正比例缩放，几何间隔再除以 $\|w\|_2$ 后具有尺度不变性。原始形式维护 d 维参数，适合特征维度不高或样本数较大；对偶形式维护 N 个系数并复用内积，便于引出核技巧。感知机只寻求某个分离面，最大间隔方法还会在可行分离面中优化间隔。

例题 12.3 (线性不可分的异或结构). 四个点 $(0,0), (1,1)$ 标为 $+1$, $(1,0), (0,1)$ 标为 -1 。这组数据形成异或结构, 任何二维直线都不能把两类完全分开。判断不可分不能只靠一次失败的训练轨迹, 需要给出几何或代数上的矛盾。

例题 12.3 解答

读题翻译 需要证明同一条二维直线不可能严格分离四个 XOR 点; 一次训练失败不是证明, 必须从四个标签约束推出矛盾。

已知与合法条件 正类为 $(0,0), (1,1)$, 负类为 $(1,0), (0,1)$; 假设分离函数为 $g(x) = w^T x + b$, 并要求正类 $g > 0$ 、负类 $g < 0$ 。

为什么想到这个方法 对有限点集的线性不可分性, 可假设严格分离存在并把每个样本写成线性不等式; 矛盾即否定该假设。

方法选择 写出四个点的严格符号约束, 将两个负类约束相加, 与 $(1,1)$ 的正类约束比较; 再用两类凸包相交独立核验。

推导/计算 若存在 $w = (w_1, w_2)^T, b$ 严格分离, 则四点分别要求

$$b > 0, \quad w_1 + w_2 + b > 0, \quad w_1 + b < 0, \quad w_2 + b < 0.$$

后两个不等式相加得到 $w_1 + w_2 + 2b < 0$, 于是 $w_1 + w_2 + b < -b < 0$, 这与第二个正类条件矛盾。

独立核验 两个正类点与两个负类点的中点都等于 $(1/2, 1/2)$; 两类凸包相交, 同样排除严格分离超平面。

结论 这四个 XOR 点在原二维特征下线性不可分, 基本感知机不可能收敛到零训练误分类的分离解。

贯穿例：四点二维分类数据

本章角色：把同一组可手算数据作为线性分类的起点, 先检验可分性与感知机的适用前提。后续五章始终复用

i	1	2	3	4
x_i	$(-1, -1)$	$(-1, 1)$	$(1, -1)$	$(1, 1)$
y_i	-1	-1	$+1$	$+1$

取 $w = (1, 0)^T, b = 0$ 便有 $y_i(w^T x_i + b) = 1$, 所以数据确实线性可分, 满足感知机收敛结论的关键假设; 本章关注误分类驱动的参数更新, 并不把这个小样本当作泛化性能证据。下一站见 k 近邻法的局部投票表示。

本章共 12 道练习。每道题干后立即给出同号解析; 长解析可自然跨页, 续页标题保留题号。

【原书练习整理】

练习 12.1. 用不等式证明题设中的异或四点在原二维特征空间中线性不可分，并指出一次迭代未停止为何不足以构成证明。

练习 12.1 解析

记 $g(x) = w^T x + b$ 。若异或四点可被严格分离，则两个正类点 $(0,0), (1,1)$ 与两个负类点 $(1,0), (0,1)$ 必须同时满足

$$\begin{aligned} g(0,0) &= b > 0, & g(1,1) &= w_1 + w_2 + b > 0, \\ g(1,0) &= w_1 + b < 0, & g(0,1) &= w_2 + b < 0. \end{aligned}$$

后两个负类条件给出显式矛盾链

$$\begin{aligned} (w_1 + b) + (w_2 + b) &< 0 \\ \implies w_1 + w_2 + 2b &< 0 \\ \implies w_1 + w_2 + b &< -b < 0, \end{aligned}$$

这与正类点 $(1,1)$ 所要求的 $w_1 + w_2 + b > 0$ 矛盾，故原二维特征空间中不存在严格分离参数。一次迭代未停止只说明当前参数存在未严格分类的样本，即

$$\exists i : y_i g(x_i) \leq 0;$$

线性不可分却要求

$$\forall (w, b), \exists i : y_i g(x_i) \leq 0.$$

前者没有排除其他参数，因而不能单独构成不可分证明。

练习 12.2. 证明有限两类点集线性可分，当且仅当它们的凸包不相交。可使用分离超平面定理，但必须说明两个方向。

练习 12.2 解析

设非空有限正、负类点集分别为 $P, N \subset \mathbb{R}^d$ ，并记 $g(x) = w^T x + b$ 。

先证“线性可分 $\Rightarrow$ 凸包不交”。若

$$g(p) > 0 \quad (p \in P), \quad g(n) < 0 \quad (n \in N),$$

则对任意凸组合

$$u = \sum_{i=1}^r \alpha_i p_i \in \text{conv}(P), \quad v = \sum_{j=1}^s \beta_j n_j \in \text{conv}(N),$$

其中 $\alpha_i, \beta_j \geq 0$ 且 $\sum_i \alpha_i = \sum_j \beta_j = 1$ ，有

$$g(u) = \sum_i \alpha_i g(p_i) > 0, \quad g(v) = \sum_j \beta_j g(n_j) < 0.$$

练习 12.2 解析 (续)

若两凸包相交, 则可取 $u = v$, 从而得到显式矛盾链

$$u = v \implies 0 < g(u) = g(v) < 0.$$

故两凸包不相交。

再证“凸包不交 $\Rightarrow$ 线性可分”。有限点集的凸包是紧凸集; 若

$$A = \text{conv}(P), \quad B = \text{conv}(N), \quad A \cap B = \emptyset,$$

则强分离定理给出 $w \neq 0$ 与 $\tau \in \mathbb{R}$, 使蕴含链

$$A \cap B = \emptyset \implies \sup_{v \in B} w^\top v < \tau < \inf_{u \in A} w^\top u.$$

令 $b = -\tau$, 便有

$$w^\top p + b > 0 \quad (p \in P), \quad w^\top n + b < 0 \quad (n \in N),$$

所以原两类有限点集被严格线性分离。

练习 12.3. 设某训练点满足 $y_i(w^\top x_i + b) = 0$ 。说明它是否满足线性可分定义, 并解释训练时为何仍应触发更新。

练习 12.3 解析

记该点的带符号分数为

$$m_i = y_i(w^\top x_i + b) = 0.$$

严格线性可分要求每个训练点满足 $m_i > 0$, 因此

$$m_i = 0 \implies m_i \not> 0,$$

该点位于当前决策边界上, 尚未满足严格分离定义。

取学习率 $\eta > 0$ 并按边界点更新,

$$w^+ = w + \eta y_i x_i, \quad b^+ = b + \eta y_i.$$

该点更新后的带符号分数为

$$\begin{aligned} m_i^+ &= y_i((w^+)^\top x_i + b^+) \\ &= m_i + \eta y_i^2 (\|x_i\|_2^2 + 1) \\ &= \eta (\|x_i\|_2^2 + 1) > 0. \end{aligned}$$

所以把 $m_i \leq 0$ 统一作为更新条件, 既处理误分类点, 也避免算法在零间隔边界状态误报停止。

练习 12.4. 证明若 (w, b) 分离训练集, 则任意 $c > 0$ 时 (cw, cb) 也分离同一训练集; 再说明 $c < 0$ 为何不保留标签方向。

练习 12.4 解析

设 (w, b) 严格分离训练集, 即

$$m_i = y_i(w^T x_i + b) > 0, \quad i = 1, \dots, N.$$

对任意 $c > 0$, 缩放后的带符号分数满足

$$\begin{aligned} m_i(c) &= y_i((cw)^T x_i + cb) \\ &= c y_i(w^T x_i + b) \\ &= c m_i > 0. \end{aligned}$$

故 (cw, cb) 仍严格分离同一训练集。若 $c < 0$, 则

$$m_i(c) = c m_i < 0 \quad (i = 1, \dots, N),$$

标签方向全部反转; 若 $c = 0$, 则 $m_i(c) = 0$, 所有点都落在边界上。因而只有正比例缩放保留原标签方向, 同时函数间隔会被乘以 c , 不能用未归一化函数间隔比较等价超平面。

练习 12.5. 对 $w = (3, 4)^T, b = -5, x_0 = (1, 2)^T$, 计算判别分数、预测类别以及 x_0 到超平面的距离。

练习 12.5 解析

对象满足 $w \in \mathbb{R}^2, b \in \mathbb{R}, x_0 \in \mathbb{R}^2$, 且 $w \neq 0$ 。判别分数与预测类别为

$$\begin{aligned} g(x_0) &= w^T x_0 + b \\ &= 3 \times 1 + 4 \times 2 - 5 \\ &= 6, \\ \hat{y}_0 &= \text{sign } g(x_0) = +1. \end{aligned}$$

法向量范数和点到超平面的距离为

$$\begin{aligned} \|w\|_2 &= \sqrt{3^2 + 4^2} = 5, \\ \text{dist}(x_0, \{x : g(x) = 0\}) &= \frac{|g(x_0)|}{\|w\|_2} = \frac{6}{5} = 1.2. \end{aligned}$$

分数的符号决定类别; 除以 $\|w\|_2$ 后的绝对值才是几何距离。

练习 12.6. 参数 $w = (1, -1)^T, b = 0$, 样本 $x = (1, 3)^T, y = +1$, 学习率 $\eta = 0.5$ 。判断是否更新并给出新参数。

练习 12.6 解析

记更新前状态为 $(w^{(0)}, b^{(0)}) = ((1, -1)^T, 0)$ 。先计算当前带符号分数：

$$\begin{aligned} g^{(0)}(x) &= (w^{(0)})^T x + b^{(0)} \\ &= 1 \times 1 + (-1) \times 3 = -2, \\ m^{(0)} &= y g^{(0)}(x) = -2 \leq 0. \end{aligned}$$

因此触发一次同步更新，状态链为

$$\begin{aligned} w^{(1)} &= w^{(0)} + \eta y x \\ &= (1, -1)^T + 0.5(1, 3)^T \\ &= (1.5, 0.5)^T, \\ b^{(1)} &= b^{(0)} + \eta y = 0.5. \end{aligned}$$

代回同一样本核验：

$$m^{(1)} = y((w^{(1)})^T x + b^{(1)}) = 1.5 + 1.5 + 0.5 = 3.5 > 0.$$

故新参数为 $w^{(1)} = (1.5, 0.5)^T, b^{(1)} = 0.5$ ，该样本已被推向正确一侧。

练习 12.7. 说明为什么不能把 $w^T x + b = 0.9$ 直接解释成“正类概率为 0.9”，并给出一个缩放反例。

练习 12.7 解析

感知机只用分数的符号作决策。对任意 $c > 0$ ，参数 (w, b) 与 (cw, cb) 满足

$$\begin{aligned} g_c(x) &= (cw)^T x + cb = c g(x), \\ \text{sign } g_c(x) &= \text{sign } g(x), \\ \{x : g_c(x) = 0\} &= \{x : g(x) = 0\}. \end{aligned}$$

因此它们表示同一分类边界与同一类别预测。取 $c = 10$ 并代入题设分数，

$$g(x) = 0.9 \implies g_c(x) = 10 \times 0.9 = 9.$$

若把分数直接当作正类概率，同一分类器便会同时给出 0.9 与 9，而

$$9 \notin [0, 1], \quad P(Y = +1 | x) + P(Y = -1 | x) = 1$$

也无法由感知机分数自动保证。故 $w^T x + b$ 只能解释为有方向的判别分数，不能未经概率模型或校准便解释成条件概率。

练习 12.8. 从 $w = 0, b = 0$ 开始, 按 $x_1 = (2, 1), y_1 = +1$ 与 $x_2 = (-1, -2), y_2 = -1$ 的顺序扫描, $\eta = 1$ 。写出首轮全部更新。

练习 12.8 解析

令首轮开始状态为

$$(w^{(0)}, b^{(0)}) = ((0, 0)^T, 0).$$

访问 $(x_1, y_1) = ((2, 1)^T, +1)$ 时,

$$m_1^{(0)} = y_1((w^{(0)})^T x_1 + b^{(0)}) = 0 \leq 0,$$

$$w^{(1)} = w^{(0)} + \eta y_1 x_1 = (2, 1)^T,$$

$$b^{(1)} = b^{(0)} + \eta y_1 = 1.$$

随后访问 $(x_2, y_2) = ((-1, -2)^T, -1)$,

$$g^{(1)}(x_2) = (2, 1)(-1, -2)^T + 1 = -3,$$

$$m_2^{(1)} = y_2 g^{(1)}(x_2) = (-1)(-3) = 3 > 0,$$

故第二个样本不触发更新。首轮状态链为

$$((0, 0)^T, 0) \xrightarrow{x_1, m_1=0} ((2, 1)^T, 1) \xrightarrow{x_2, m_2=3} ((2, 1)^T, 1).$$

下一轮复核 $m_1 = 6 > 0, m_2 = 3 > 0$, 整轮更新数为 0, 所以算法按停止条件结束。

练习 12.9. 构造两个标签相反但特征完全相同的训练样本, 并说明原始形式为何不可能以一轮零更新的状态结束。

练习 12.9 解析

固定任意 $x \in \mathbb{R}^d$, 构造两个训练样本

$$(x_+, y_+) = (x, +1), \quad (x_-, y_-) = (x, -1).$$

任意参数 (w, b) 对二者产生同一个原始分数 $g(x) = w^T x + b$, 而带符号分数为

$$m_+ = g(x), \quad m_- = -g(x).$$

严格分类要求 $m_+ > 0$ 且 $m_- > 0$, 即同时要求

$$g(x) > 0 \quad \text{与} \quad g(x) < 0,$$

这是矛盾。等价地, 对所有 $g(x) \in \mathbb{R}$ 都有

$$\min\{m_+, m_-\} = \min\{g(x), -g(x)\} = -|g(x)| \leq 0.$$

因此每次完整扫描这两个样本时至少有一个样本触发更新, 不可能出现一整轮更新数为零; 算法只能由预设迭代上限等非收敛停止规则终止。

练习 12.10. 若 $R = 5, \gamma = 0.5$, 计算定理给出的误分类次数上界。该上界是否等于实际更新次数?

练习 12.10 解析

在定理的线性可分、正间隔与有限半径条件下, 误分类更新次数 $k \in \mathbb{Z}_{\geq 0}$ 满足

$$k \leq \left(\frac{R}{\gamma}\right)^2.$$

代入 $R = 5$ 与 $\gamma = 0.5$,

$$\begin{aligned} k &\leq \left(\frac{5}{0.5}\right)^2 \\ &= 10^2 \\ &= 100. \end{aligned}$$

所以可得集合界

$$k \in \{0, 1, \dots, 100\},$$

而不是等式 $k = 100$ 。实际更新次数还取决于样本访问顺序、初值以及数据可实现的间隔; 该定理给出最坏情形有限上界, 不给出精确步数。

练习 12.11. 补全范数递推中交叉项为何非正, 并指出若在正确分类样本上也更新, 证明的哪一步会失效。

练习 12.11 解析

第 j 次更新使用样本 $(\hat{x}_i, y_i)$, 其中 $\eta > 0$ 、 $\|\hat{x}_i\|_2 \leq R$, 且触发条件为

$$y_i \hat{w}_{j-1}^\top \hat{x}_i \leq 0.$$

由更新式 $\hat{w}_j = \hat{w}_{j-1} + \eta y_i \hat{x}_i$ 展开范数, 得到

$$\begin{aligned} \|\hat{w}_j\|_2^2 &= \|\hat{w}_{j-1}\|_2^2 + 2\eta y_i \hat{w}_{j-1}^\top \hat{x}_i + \eta^2 y_i^2 \|\hat{x}_i\|_2^2 \\ &\leq \|\hat{w}_{j-1}\|_2^2 + \eta^2 R^2, \end{aligned}$$

其中使用了 $y_i^2 = 1$ 以及

$$2\eta y_i \hat{w}_{j-1}^\top \hat{x}_i \leq 0.$$

从 $\hat{w}_0 = 0$ 递推便有

$$\|\hat{w}_k\|_2^2 \leq k\eta^2 R^2.$$

若在正确分类样本上也更新, 则可能出现

$$y_i \hat{w}_{j-1}^\top \hat{x}_i > 0,$$

交叉项不能删去, 上述单步上界及其后的范数递推同时失效。

练习 12.12. 比较 $N = 1000, d = 5$ 与 $N = 50, d = 10000$ 两种场景下存储完整 Gram 矩阵的代价, 并说明何时原始形式更合适。

练习 12.12 解析

比较训练集之外的主要状态: 原始形式保存 $w \in \mathbb{R}^d$ 与 $b \in \mathbb{R}$, 对偶形式保存 $\alpha \in \mathbb{R}^N$ 、 $b \in \mathbb{R}$ 与 $G \in \mathbb{R}^{N \times N}$, 故

$$S_{\text{primal}} = O(d + 1) = O(d), \quad S_{\text{dual}} = O(N + 1 + N^2) = O(N^2).$$

两种场景的 Gram 矩阵条目数分别为

(N, d)	N^2	d	若每项 8 字节的 Gram 存储量
(1000, 5)	10^6	5	8×10^6 字节
(50, 10000)	2500	10000	2×10^4 字节

而显式预计算稠密 Gram 矩阵的算术量为 $O(N^2 d)$, 代入后得到

$$\begin{aligned} (1000, 5): \quad N^2 d &= 5 \times 10^6, \\ (50, 10000): \quad N^2 d &= 2.5 \times 10^7. \end{aligned}$$

因此第一种场景中 $N^2 \gg d$, 原始形式在模型状态存储上明显更合适; 第二种场景中 Gram 矩阵比 d 维权向量小, 但预计算高维内积更昂贵, 只有在 N 较小且内积会被反复复用或需核化时, 对偶形式才可能占优。概括地说,

$$d \ll N^2 \implies \text{优先考虑原始形式}, \quad N^2 \ll d \text{ 且内积可复用} \implies \text{对偶形式可考虑}.$$

因此选择表示形式时应同时比较模型状态规模与内积复用收益, 而不能只看单个维度大小。

读前自检：本章结论与下一步。 感知机章末由“线性判别函数、误分类集合与 Gram 矩阵”落到“仅在误分类点更新, 并记录停止原因与并列规则”; 请把前者产出和后者输入逐项对齐, 固定核对前者末项的输出类型能否作为后者首项的输入类型。

本章结论与下一步

核心结论: 线性判别函数、误分类集合与 Gram 矩阵

关键依据: 利用正间隔控制权重增长和投影下界

可执行自检: 仅在误分类点更新, 并记录停止原因与并列规则

适用边界: 线性可分二分类与在线更新基线

下一步: 进入 k 近邻法, 对比参数化边界与局部记忆

1. 能否用 $y_i(w^T x_i + b) > 0$ 同时解释正、负两类的严格正确分类? 若不能, 回看第 12.1 节。
2. 能否从点到超平面的距离逐步推导误分类损失与更新? 若不能, 回看第 12.3 节。
3. 能否不跳步地复现 Novikoff 证明中的方向增长、范数增长和 Cauchy-Schwarz 三环节? 若不能, 回看第 12.5 节。
4. 能否根据 N, d 比较原始形式与对偶形式的时间和空间代价, 并识别不可分数据下迭代不能得到零训练误差的情形? 若不能, 回看第 12.6–12.7 节。

第13章 k 近邻法

读前自检：先修自检。 k 近邻法先修自检固定核验“能否分别计算 $(1, 2)$ 与 $(4, 6)$ 的 L_1, L_2, L_∞ 距离”；请分别计算 $(1, 2)$ 与 $(4, 6)$ 的 L_1, L_2, L_∞ 距离并写出中间结果，再按“ L_1, L_2, L_∞ 的计算或证明结果满足首项所列等式、定义域或判断”明确判为通过或失败。

本章地图

核心问题：邻域选择怎样共同决定预测并影响搜索代价

可检验学习目标：

- 严格定义 L_p 距离、 k 近邻集合和多数表决，并解释距离、 k 值与决策规则三要素；
- 能够从局部 0-1 经验风险推导多数表决，并把方法扩展到多类分类与回归；
- 能够手工构造平衡 kd 树，执行带回溯与剪枝的精确最近邻搜索，并分析复杂度退化条件。

最短先修：需要掌握向量坐标、绝对值、求和、 L_p 范数、指示函数、有限集合上的最小化以及二叉树。还应理解训练样本与查询样本的区别，并会计算分类 0-1 损失和回归平方损失。

依赖路线：向量范数 $\rightarrow$ 距离度量；距离与训练集 $\rightarrow$ 邻域；邻域标签计数 $\rightarrow$ 多数表决；局部同质性 $\rightarrow$ 分类与回归估计；坐标轴切分 $\rightarrow$ kd 树；距离下界 $\rightarrow$ 回溯剪枝；维度升高 $\rightarrow$ 搜索效率退化。

完成标准与返回：若距离尺度、并列或剪枝依据不清，回看度量与搜索两节

读前自检：模型认识卡：法。 k 近邻模型卡给定查询 $x \in \mathbb{R}^n$ 、带标签训练集、距离和 $1 \leq k \leq N$ ；请计算一个训练点到 x 的距离并更新最近邻集合，核对分类/回归输出类型与任务一致。

模型认识卡： k 近邻法

任务与输入：分类或回归，查询 $x \in \mathbb{R}^n$ 与带标签训练集。 **输出类型：**类别、实值或局部频率。

模型：由距离 D 、近邻数 k 与聚合规则共同确定的局部预测器。 **策略：**最小化固定邻域上的局部经验损失。 **算法：**线性扫描或 kd 树维护 k 个最优候选。

预测：分类投票、回归均值。 **关键假设与边界：**距离须表达任务相似性；kd 树加速依赖低维、较平衡且分布不过度集中的数据。

本章符号表

符号	取值或维数	含义
$T = \{(x_i, y_i)\}_{i=1}^N$	$x_i \in \mathbb{R}^n$	含 N 个样本的训练集
$\mathcal{Y} = \{c_1, \dots, c_C\}$	有限集合	分类标签空间
k	$\{1, \dots, N\}$	用于预测的近邻个数
p	$[1, \infty]$	L_p 距离的阶数
$N_k(x)$	k 元素索引集合	查询 x 的 k 个最近训练样本
$\mathbb{I}(\cdot)$	$\{0, 1\}$	条件成立取 1, 否则取 0 的指示函数
$n_c(x)$	$\{0, \dots, k\}$	邻域中类别 c 的样本数
a, h	$\{1, \dots, n\}$ 、非负整数	kd 树切分轴与节点深度
r	非负实数	搜索过程中当前最优距离或候选半径

13.1 距离度量、 k 值与分类决策

k 近邻法没有先拟合一个有限维参数向量，而是在收到查询 x 时，从训练集中寻找距离最近的 k 个样本，再用其输出作局部决策。这种“先保存、后计算”的方式也称为惰性学习；训练阶段轻，预测成本取决于近邻搜索。

读前自检：距离度量。 k 近邻法中的距离度量把问题限定在“对 $x_i, x_j \in \mathbb{R}^n$ 和 $1 \leq p < \infty$ ”；请把 $L_p(x_i, x_j)$ 展开一次并检查其类型或边界，检查是否得到当前定义中的 p 决定“近”的几何含义，必须在选择邻域前固定。

读前自检： L_p 距离。 在“对 $x_i, x_j \in \mathbb{R}^n$ 和 $1 \leq p < \infty$ ”成立时处理 L_p 距离：请把 $L_p(x_i, x_j)$ 展开一次并检查其类型或边界，并以当前定义中的 p 决定“近”的几何含义，必须在选择邻域前固定判定结果。

定义 13.1 (L_p 距离). 对 $x_i, x_j \in \mathbb{R}^n$ 和 $1 \leq p < \infty$ ，定义

$$L_p(x_i, x_j) = \left(\sum_{\ell=1}^n |x_i^{(\ell)} - x_j^{(\ell)}|^p \right)^{1/p}.$$

当 $p = 1$ 时为曼哈顿距离，当 $p = 2$ 时为欧氏距离；极限情形

$$L_\infty(x_i, x_j) = \max_{1 \leq \ell \leq n} |x_i^{(\ell)} - x_j^{(\ell)}|$$

取各坐标差的最大值。这里的 p 决定“近”的几何含义，必须在选择邻域前固定。

学习策略。 k 很小时，预测由极少数样本决定，局部边界曲折、训练误差低而方差较大； k 增大后，邻域跨越更广，决策更平滑、方差下降但偏差可能上升。当 $k = N$ 时，每个查询的邻域都

是全部训练样本，因此分类器确定地输出训练集总体多数类；若最高票并列，则按预先声明的稳定规则决胜。实践中应在训练数据内部用交叉验证选择 k ，不能反复查看测试集后调参。

给定已经确定的 $N_k(x)$ ，多数表决写成

$$\hat{y}(x) = \arg \max_{c \in \mathcal{Y}} \sum_{i \in N_k(x)} \mathbb{I}(y_i = c) = \arg \max_{c \in \mathcal{Y}} n_c(x).$$

若多个类别并列达到最大计数， $\arg \max$ 是集合；算法必须预先规定稳定规则，例如按固定类别顺序选择，或在并列类中比较总距离。二分类常取奇数 k 减少计数平局，但多分类仍可能平局。

阅读目标：把邻域分类转化为“错分数最少”等价于“票数最多”。

对象：固定邻域 $N_k(x)$ 、类别集合 $\mathcal{Y}$ 与候选常量类别 c 。

合法条件：邻域非空；并列时必须预先声明稳定的决胜规则。

第一步：先写局部风险 $R(c) = \sum_{i \in N_k(x)} \mathbb{I}\{y_i \neq c\}$ 。

推导目标

证明固定邻域上的多数表决等价于最小化“用一个常量类别代表整个邻域”的 0-1 经验风险。

推导准备

固定查询 x 及其邻域 $N_k(x)$ 。候选动作 $c \in \mathcal{Y}$ 对邻域中的每个样本都预测同一类别，损失为 $\mathbb{I}(y_i \neq c)$ 。

推导第 1 步：候选类别 c 的局部经验风险为

$$\hat{R}_x(c) = \frac{1}{k} \sum_{i \in N_k(x)} \mathbb{I}(y_i \neq c).$$

推导第 2 步：对每个 i ， $\mathbb{I}(y_i \neq c) = 1 - \mathbb{I}(y_i = c)$ ，所以

$$\hat{R}_x(c) = 1 - \frac{1}{k} \sum_{i \in N_k(x)} \mathbb{I}(y_i = c) = 1 - \frac{n_c(x)}{k}.$$

推导第 3 步：常数 1 与正因子 $1/k$ 不改变最优类别，故

$$\arg \min_{c \in \mathcal{Y}} \hat{R}_x(c) = \arg \max_{c \in \mathcal{Y}} n_c(x),$$

这正是多数表决。推导只依赖已固定的邻域，不说明距离或 k 本身已经最优。

定理 13.1 (局部多数表决的经验风险最优性) 对任意非空有限邻域 $N_k(x)$ 和有限类别集 $\mathcal{Y}$ ，使用 0-1 损失且在整个邻域内输出同一类别时，经验风险的全部最小化解恰为计数 $n_c(x)$ 最大的类别。若最大计数并列，则每个并列类别都是风险最小化解。

读前自检：证明：局部多数表决的经验风险最优性。 局部风险满足 $\hat{R}_x(c) = 1 - n_c(x)/k$ ；设 $n_{c_\star}(x) = \max_c n_c(x)$ ，请比较任意 c 的计数并核对 $\hat{R}_x(c_\star) \leq \hat{R}_x(c)$ ，再证明非最大计数类别不可能最优。

证明。 证明目标是比较任意两个候选类别的经验风险。由上面的恒等式，对每个 c 都有 $\hat{R}_x(c) = 1 - n_c(x)/k$ 。设 $c_\star$ 满足 $n_{c_\star}(x) = \max_c n_c(x)$ ，则任意 c 都满足 $n_{c_\star}(x) \geq n_c(x)$ 。两边乘以负数 $-1/k$ 会反转不等号，再加 1 得到

$$\hat{R}_x(c_\star) = 1 - \frac{n_{c_\star}(x)}{k} \leq 1 - \frac{n_c(x)}{k} = \hat{R}_x(c).$$

所以每个最大计数类别都是最小风险解。反过来，若某 c' 不是最大计数类别，则存在 $c_\star$ 使 $n_{c_\star}(x) > n_{c'}(x)$ ，从而 $\hat{R}_x(c_\star) < \hat{R}_x(c')$ ，故 c' 不可能最优。两方向合并后，最小化解集合与最大计数类别集合完全相同，定理得证。□

读前自检：几何解释：L_p 单位球 $\{z : L_p(z, 0) \leq 1\}$ 的形状随 p 改变。 L_p 单位球为 $\{z : L_p(z, 0) \leq 1\}$ ；请把二维点 (1, 0) 与 (1, 1) 分别代入 $p = 1, 2, \infty$ ，核对菱形、圆与正方形的边界差异。

几何理解

几何解释。 L_p 单位球 $\{z : L_p(z, 0) \leq 1\}$ 的形状随 p 改变。在二维中， $p = 1$ 是菱形， $p = 2$ 是圆， $p = \infty$ 是轴对齐正方形。同一组训练点在不同几何下可能产生不同近邻次序，所以距离选择是模型的一部分，而不是无关紧要的计算细节。

读前自检：概率解释：邻域比例 $p(c|x) = n_c(x)/k$ 可看作局部条件概率的经验估计：它假设足够靠近.....。 k 近邻局部类别比例为 $\hat{p}(c|x) = n_c(x)/k$ ，其中 $k > 0$ ；请把邻域内各类计数求和，核对 $\sum_c n_c(x) = k$ 从而概率非负且总和为 1。

概率解释

邻域比例 $\hat{p}(c|x) = n_c(x)/k$ 可看作局部条件概率的经验估计：它假设足够靠近 x 的样本具有近似相同的条件分布。邻域太小会使估计波动大，邻域太大又会混合不同区域。该比例未必经过校准，尤其在距离失真、类别不均衡或采样机制改变时不能直接当作可靠概率。

优化解释

优化解释。 k 近邻预测把一个组合搜索问题分成两层：先按距离选出 k 个最小者，再在有限类别集合上最小化局部经验风险。第一层没有可训练参数的梯度优化；第二层由计数直接求解。交叉验证选择距离、特征缩放与 k ，属于外层模型选择问题。

图 13.1 把相同半径下的可达集合画在同一坐标系中： L_1 边界由坐标绝对值之和固定， L_2 边界由平方和固定， L_∞ 边界由最大坐标差固定。因此距离阶数改变时，邻域边界与近邻次序都可能改变。




图 13.1 二维 L_p 单位球。不同边界形状会改变哪些训练点先进入查询邻域。

例题 13.1 (距离阶数改变近邻). 查询 $x = (0, 0)$, 候选点 $a = (3, 0)$ 与 $b = (2, 2)$ 。分别在 L_1 和 L_2 距离下判断最近邻。

例题 13.1 解答

读题翻译 查询点 x 不变, 只改变距离阶数; 需要在 L_1 与 L_2 两种口径下分别比较 a, b , 不能把不同度量的数值交叉排序。

已知与合法条件 $x = (0, 0)$ 、 $a = (3, 0)$ 、 $b = (2, 2)$ 均属于 $\mathbb{R}^2$; L_1 取坐标差绝对值之和, L_2 取坐标差平方和的平方根。

为什么想到这个方法 L_1 可直接比较绝对值之和; L_2 距离非负, 而平方函数在 $[0, +\infty)$ 上严格递增, 所以可比较平方距离避免无必要开方。

方法选择 先计算 x 到两个候选点的 L_1 距离, 再计算两项平方欧氏距离; 每种度量内部取严格较小者作为唯一最近邻。

推导/计算 两种距离下的逐点计算为

$$\begin{aligned} L_1(x, a) &= |3| + |0| = 3, & L_1(x, b) &= |2| + |2| = 4, \\ L_2(x, a) &= \sqrt{3^2 + 0^2} = 3, & L_2(x, b) &= \sqrt{2^2 + 2^2} = \sqrt{8}. \end{aligned}$$

于是

$$L_1(x, a) < L_1(x, b), \quad L_2(x, a) > L_2(x, b).$$

独立核验 L_1 比较为 $3 < 4$; 平方欧氏距离比较为 $9 > 8$, 且开方不改变非负数的次序。两次比较均为严格不等式, 不需要调用并列规则。

结论 L_1 下唯一最近邻为 a ; L_2 下唯一最近邻为 b 。距离阶数改变确实使最近邻发生翻转。

表 13.1 汇总了三种常见距离的计算形式及其二维单位球，便于比较距离阶数对邻域几何的影响。

表 13.1 常见距离的计算与二维单位球

距离	表达式	二维单位球
L_1	$\sum_{\ell} x^{(\ell)} - z^{(\ell)} $	菱形
L_2	$\sqrt{\sum_{\ell} (x^{(\ell)} - z^{(\ell)})^2}$	圆
L_{∞}	$\max_{\ell} x^{(\ell)} - z^{(\ell)} $	轴对齐正方形

读前自检： k 近邻模型。 固定训练集、距离度量与 $k = 1$ ；请写出由相邻训练点等距位置形成的决策边界，并核对距离决定近邻次序、 k 决定平滑尺度、投票规则决定输出，三者共同定义 k 近邻模型。

13.2 k 近邻模型与三要素

固定训练集、距离度量和 k 后，特征空间被划分成若干决策区域：区域内的查询共享相同或相近的邻域与预测。 $k = 1$ 时每个训练点拥有一个以“离它最近”为条件的单元，边界由相邻训练点的等距位置组成； k 增大时，预测由更大范围的标签组合决定。

k 近邻法的三要素是：距离度量决定近邻次序， k 值决定局部平滑尺度，分类决策规则把邻域标签转换为输出。任意一个要素改变，都可能改变最终模型，因此三者应共同进入验证方案。

读前自检： k 近邻算法。 k 近邻算法输入带标签训练集、查询 x 、距离和 $1 \leq k \leq N$ ；请扫描一个样本并更新当前最近 k 项，核对处理完 N 个样本后按固定并列规则投票输出。

读前自检： k 近邻法算法。 k 近邻法对查询点计算全部训练距离；请完成一次“插入候选并裁回 k 项”的更新，核对距离次序不降且完整扫描后停止。

最直接的实现是线性扫描全部训练样本并保留 k 个最小距离。它不依赖空间索引，对任何能计算的距离都适用，也是检查 kd 树结果是否正确的基准。

读前自检：线性扫描的分类：执行契约。 线性扫描的 k 近邻分类输入非空训练集 T 、查询 x 和 $1 \leq k \leq N$ ；请计算一个有限非负距离，将候选插入临时 H^+ 并按固定并列规则裁至 k 项，核对次序后提交 H, r ，完成 N 个距离时停止。

读前自检：线性扫描的分类。 线性扫描的 k 近邻分类维护至多 k 个按距离排序的候选；请把一个新训练样本的距离插入 H 并裁回 k 项，核对候选数不超过 k 、距离次序不降，完整扫描 N 项后再由固定投票规则输出类别。

算法 13.1: 线性扫描的 k 近邻分类**输入:** 非空训练集 $T = \{(x_i, y_i)\}_{i=1}^N$, 查询 x **输出:** 预测 $\hat{y}$ 、近邻集合 $N_k(x)$ 、实际完成距离数 i_{done} 、**status** 与最终诊断**数据:** $k \in \{1, \dots, N\}$, 距离 D , 距离并列规则与类别并列规则

- 1 初始化 $\hat{y} \leftarrow \perp$ 、候选集合 $H \leftarrow \emptyset$ 、候选半径 $r \leftarrow +\infty$ 、 $i_{\text{done}} \leftarrow 0$, 诊断为空
- 2 若训练集为空、 k 越界、样本与查询维数不一致、输入含非有限坐标、距离规则或并列规则未定义, 则返回当前空候选、 $i_{\text{done}} = 0$ 、**invalid_input** 及字段诊断
- 3 对 $i \leftarrow 1$ 至 N 执行
 - 4 计算 $d_i \leftarrow D(x, x_i)$; 若求值失败、 d_i 非有限或 $d_i < 0$, 则返回最后合法 H, r 、未定义预测、 i_{done} 、**numerical_failure**, 诊断为失败位置 i
 - 5 在临时候选 H^+ 中按稳定次序纳入 (d_i, i, y_i) ; 若 $|H^+| > k$, 删除距离最大且并列优先级最低者; 令 r^+ 为 H^+ 中最大距离
 - 6 若候选次序或 $|H^+| \leq k$ 不变量失败, 则返回未改动的 H, r 与 **numerical_failure** 诊断; 否则 $H \leftarrow H^+$ 、 $r \leftarrow r^+$ 、 $i_{\text{done}} \leftarrow i$
- 7 结束
- 8 对每个 $c \in \mathcal{Y}$ 计算 $n_c \leftarrow \sum_{i \in H} \mathbb{I}(y_i = c)$, 按预设规则选择最大计数类别 $\hat{y}$
- 9 返回 $\hat{y}, H, i_{\text{done}} = N, \text{completed}$, 最终诊断记录最终半径 r 、并列次数与各类票数

算法 13.1 在有限 N 步后停止, 不涉及参数优化的迭代收敛。候选集可用大小为 k 的最大堆维护; 线性扫描时每个新距离与当前最差候选比较。稳定次序保证距离并列时结果可复现。

13.3 多类分类与回归扩展

多数表决原生支持 $C > 2$ 的多类分类, 只需对每个类别计数。回归情形把标签改为实数 $y_i \in \mathbb{R}$, 在平方损失下用邻域均值

$$\hat{y}(x) = \frac{1}{k} \sum_{i \in N_k(x)} y_i.$$

若采用绝对损失, 则邻域中位数比均值更符合风险最小化目标; 因此“聚合规则”必须与损失函数一致。

阅读目标: 把局部常量预测写成一维平方损失极小化。

对象: 非空邻域 $N_k(x)$ 、响应 $y_i \in \mathbb{R}$ 与常量预测 $a \in \mathbb{R}$ 。

合法条件: $k \geq 1$; 邻域固定; 平方损失有限。

第一步: 先对 $Q(a) = \sum_{i \in N_k(x)} (y_i - a)^2$ 求一阶导数。

推导目标

说明平方损失下邻域均值为何是最佳常量回归预测。

推导准备

固定非空邻域 $N_k(x)$ 且 $k \geq 1$, 响应 $y_i \in \mathbb{R}$ 。候选输出 $a \in \mathbb{R}$ 在整个邻域内取同一常数, 局部目标为平方损失之和; 因此只需在实数轴上检查一阶驻点和二阶导数符号。

推导第1步：设候选预测为 $a \in \mathbb{R}$ ，展开局部平方风险：

$$Q(a) = \sum_{i \in N_k(x)} y_i^2 - 2a \sum_{i \in N_k(x)} y_i + ka^2.$$

推导第2步：逐项求导得到

$$Q'(a) = 2ka - 2 \sum_{i \in N_k(x)} y_i, \quad Q''(a) = 2k.$$

推导第3步：令 $Q'(a) = 0$ 可得 $a = k^{-1} \sum_i y_i$ 。因为 $k \geq 1$ ，所以 $Q''(a) = 2k > 0$ ，该驻点是唯一全局最小点。邻域均值因此是平方损失对应的最优常量，而不是任意选择。

概率解释

多类邻域比例给出局部类别频率；回归邻域均值估计局部条件期望 $\mathbb{E}(Y | X = x)$ 。二者都依赖邻域内分布近似稳定。距离加权可以让更近样本贡献更大，但零距离样本需要单独规则，权重函数及其参数也必须用训练数据验证。

读前自检：k 近邻法的实现：kd 树。 kd 树结点以第 a 个坐标和切分值 s 划分 n 维样本；请把点集分成 $x^{(a)} < s$ 与 $x^{(a)} \geq s$ 两侧，核对左右子树仍保存 n 维点且原距离定义不变。

13.4 kd 树的构造

kd 树是一棵保存 n 维样本点的二叉树。每个内部节点选择一个坐标轴和一个切分值，把空间分成两个轴对齐区域；左、右子树分别保存切分值两侧的点。树结构不改变距离定义或预测规则，只加速候选邻域的寻找。

读前自检：构造 kd 树。 对构造 kd 树，条件“为避免把近邻个数 k 与空间维数混淆，本章用 n 表示特征维数”不可省；请将 $a = 1 + (h \bmod n)$ 左端按正文定义展开一层，再逐项对齐右端，再用坐标并列时需要固定次级排序，保证每次递归的点数严格减少作检查。

读前自检：构造平衡 kd 树。 构造平衡 kd 树把问题限定在“为避免把近邻个数 k 与空间维数混淆，本章用 n 表示特征维数”；请将 $a = 1 + (h \bmod n)$ 左端按定义展开一层，再与右端逐项对齐，检查是否得到坐标并列时需要固定次级排序，保证每次递归的点数严格减少。

为避免把近邻个数 k 与空间维数混淆，本章用 n 表示特征维数。深度为 h 的节点选择轴 $a = 1 + (h \bmod n)$ ，再取该轴坐标的中位点作为节点；小于中位坐标的点进入左子树，其余未选点进入右子树。坐标并列时需要固定次级排序，保证每次递归的点数严格减少。

读前自检：按坐标循环构造平衡 kd 树：执行契约。 按坐标循环构造平衡 kd 树输入“有限带标记点集 $S \subset \mathbb{R}^n$ 、节点预算 B 、轴与并列规则”，条件“ $n \geq 1$ ”；请执行“稳定选中位点、验证左右严格真分割后才连接候选节点并增加 m ”，以“任务栈为空、节点预算耗尽或首次失败时停止”判停。

读前自检：按坐标循环构造平衡 kd 树。 按坐标循环构造平衡 kd 树输入“有限带标记点集 $S \subset \mathbb{R}^n$ 、节点预算 B 、轴与并列规则”，条件“ $n \geq 1$ ”；请做一轮“稳定选中位点、验证左右严格真分割后才连接候选节点并增加 m ”，以“任务栈为空、节点预算耗尽或首次失败时停止”核对停止证书。

算法 13.2: 按坐标循环构造平衡 kd 树

输入: 有限带标记点集 $S \subset \mathbb{R}^n$
输出: 最后合法的部分或完整 kd 树 $\mathcal{T}$ 、实际建成节点数 m 、**status** 与最终诊断
数据: 节点预算 $B \in \mathbb{N}_0$ ；轴规则 $a = 1 + (h \bmod n)$ ；固定并列排序与样本唯一序号

- 1 $\mathcal{T} \leftarrow \emptyset$, 待处理栈 $Q \leftarrow \emptyset$, $m \leftarrow 0$, 诊断初始化为空
- 2 若 $n < 1$ 、点的维数不一致、坐标非有限、样本序号不唯一、并列规则缺失或 $B \notin \mathbb{N}_0$, 则返回空树、 $m = 0$ 、**invalid_input** 及字段诊断
- 3 若 $S \neq \emptyset$, 把任务 $(S, 0, \text{root})$ 压入 Q ；否则返回空树、 $m = 0$, **completed** 及“空输入对应合法空树”诊断
- 4 当 $Q \neq \emptyset$ 执行
 - 5 若 $m = B$ 则
 - 6 返回最后合法部分树 $\mathcal{T}$ 、 m , **budget_stop**, 最终诊断记录未展开任务数与最大已建深度
 - 7 结束
 - 8 弹出非空任务 (S_t, h_t, ℓ_t) , 令 $a \leftarrow 1 + (h_t \bmod n)$, 按 $(x^{(a)}, \text{id})$ 稳定选择中位点 q
 - 9 若排序或选择失败、比较结果不一致, 则返回未改动的 $\mathcal{T}, m$, **numerical_failure** 及失败子集、深度诊断
 - 10 在临时状态中令 S_L, S_R 为 q 前后的点；若二者不交、并集或严格缩小不变量失败, 则返回未改动的最后合法树与 **numerical_failure** 诊断
 - 11 构造记录 (q, a, h_t) 的候选节点并连接到位置 ℓ_t ；连接核验成功后提交到 $\mathcal{T}$ 并令 $m \leftarrow m + 1$
 - 12 对非空的 S_R, S_L 分别把深度 $h_t + 1$ 的右、左任务压入 Q
- 13 结束
- 14 返回完整 $\mathcal{T}, m = |S|$, **completed**, 最终诊断记录节点数、树高与并列处理次数

例题 13.2 (六点平衡 kd 树). 对点集 $\{(2, 3), (5, 4), (9, 6), (4, 7), (8, 1), (7, 2)\}$ 构造 kd 树。切分轴按第一、第二坐标交替；偶数个点时取稳定排序后的上中位点，坐标并列时按样本序号排序。

例题 13.2 解答

读题翻译 要把六个二维点递归组织成 kd 树：根层按第一坐标切分，下一层按第二坐标切分；偶数点集必须使用题设的上中位点规则。

已知与合法条件 点集含六个互异点；切分轴按第一、第二坐标交替，排序稳定，坐标并列时以样本序号决胜，因此每个非空子集的中位点选择都有唯一结果。

为什么想到这个方法 平衡 kd 树的每个结点都由“当前轴稳定排序—取中位点—递归处理左右真子集”确定；轴轮换保证第二层必须按第二坐标重排。

方法选择 先在六点全集按第一坐标取上中位点为根，再对根的左右子集按第二坐标分别取中位点；子集降为单点或空集时停止。

推导/计算 第一层按第一坐标排序：

(2, 3), (4, 7), (5, 4), (7, 2), (8, 1), (9, 6),

故根为 (7, 2), 左右子集为

$$S_L = \{(2, 3), (4, 7), (5, 4)\}, \quad S_R = \{(8, 1), (9, 6)\}.$$

第二层改按第二坐标排序:

$$S_L : (2, 3), \boxed{(5, 4)}, (4, 7), \quad S_R : (8, 1), \boxed{(9, 6)}.$$

因此左侧的下一结点是 (5, 4), 其两个单点子集为 (2, 3) 与 (4, 7); 右侧的下一结点是 (9, 6), 其左侧单点子集为 (8, 1)。

深度	切分轴	旧点集	中位点与子集	停止证书
0	第 1 坐标	6 点全集	根 (7, 2); 左 3 点、右 2 点	根已提交, 递归处理两侧
1 左	第 2 坐标	S_L	根 (5, 4); 孩子 (2, 3), (4, 7)	子集降为单点
1 右	第 2 坐标	S_R	根 (9, 6); 左孩子 (8, 1)	子集降为单点/空集

独立核验 逐结点清点可见六个输入点各出现且只出现一次, 根层满足 $3 + 1 + 2 = 6$; 第二层的每个孩子都位于父结点切分轴允许的一侧。稳定排序、上中位点与轴轮换均已逐层使用。

结论 唯一构造结果的根为 (7, 2); 左子树根为 (5, 4), 左右孩子依次为 (2, 3), (4, 7); 右子树根为 (9, 6), 左孩子为 (8, 1)。




图 13.2 六点示例的一棵平衡 kd 树。节点同时保存样本与本层切分轴。

图 13.2 与第 13.4 节的递归构造相对应: 根结点按第一坐标切分, 下一层按第二坐标切分; 每条根到叶路径给出一组轴对齐约束。树的左右位置只编码递归区域, 不表示节点之间的欧氏距离。

读前自检: 搜索 kd 树。 围绕搜索 kd 树, 先采用条件“候选堆未满时不能据此剪枝, 堆满后才用当前第 k 近距离作为搜索半径”, 再构造一个满足条件的最小结点状态并执行一次分支或停止判断; 最后验证结点输出与分支条件相符且没有遗漏停止情形。

13.5 kd 树的搜索

搜索先沿查询点所在的切分区域下降到叶节点，随后沿路径回溯并维护至多 k 个候选。切分平面距离只给出一个便宜、通常不紧的可剪枝下界；候选堆未满时不能据此剪枝，堆满后才用当前第 k 近距离作为搜索半径。

读前自检：用 kd 树的搜索。 用 kd 树的搜索中的“若节点以第 a 轴的值 $q^{(a)}$ 切分”决定可执行范围；请将 $\delta = |x^{(a)} - q^{(a)}|$ 左端按定义展开一层，再与右端逐项对齐，结果须满足 $\delta = |x^{(a)} - q^{(a)}|$ 是远侧区域距离的一个简单保守下界。

对 L_p 距离，任意向量的距离不小于任一坐标差。若节点以第 a 轴的值 $q^{(a)}$ 切分，则 $\delta = |x^{(a)} - q^{(a)}|$ 是远侧区域距离的一个简单保守下界，并不保证等于该区域真实最近距离。候选堆已满且 $\delta \geq r_k$ 时，另一侧不可能产生严格优于当前第 k 名的点。

引理 13.1 (kd 树切分平面的安全剪枝) 设大小为 k 的候选堆已经填满，堆顶第 k 近距离为 r_k ，且 $1 \leq p \leq \infty$ 。某切分平面为 $z^{(a)} = s$ ，而待检查区域完全位于平面的另一侧。若 $|x^{(a)} - s| \geq r_k$ ，则该区域中不存在与 x 距离严格小于 r_k 的点。若还需按规则区分等距离候选，应在等号时访问该区域或证明并列规则与其无关；堆未满时不得剪去任何非空远侧区域。

读前自检：证明：kd 树切分平面的安全剪枝。 把 kd 树切分平面的安全剪枝放在“由于 x 与 z 位于切分平面的两侧”下考察：把 $L_p(x, z)$ 用到的关键定义展开并完成下一步变形，并检查故任何该区域点都不能进入距离严格小于 r_k 的候选集合，剪枝不会遗漏更优点。

证明。 取另一侧区域任意点 z 。由于 x 与 z 位于切分平面的两侧，坐标差满足 $|x^{(a)} - z^{(a)}| \geq |x^{(a)} - s|$ 。当 $p < \infty$ 时，

$$L_p(x, z) = \left(\sum_{\ell=1}^n |x^{(\ell)} - z^{(\ell)}|^p \right)^{1/p} \geq |x^{(a)} - z^{(a)}| \geq |x^{(a)} - s| \geq r_k.$$

$p = \infty$ 时，最大坐标差同样不小于第 a 坐标差。故任何该区域点都不能进入距离严格小于 r_k 的候选集合，剪枝不会遗漏更优点。 $\square$

有限步终止与统计一致性

k 近邻法没有训练参数的迭代收敛过程。线性扫描和 kd 树搜索讨论的是有限步终止与剪枝正确性；统计一致性则需要另行给出样本量、 k 和邻域半径的渐近条件，不能把二者写成训练迭代收敛。

kd 树的精确 k 近邻搜索：五步阅读

输入。 写出数据对象、固定参数与必须成立的条件。

初始化。 标明主状态、计数器和第一个合法状态。

核心更新。 只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。 写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。 列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 13.3: kd 树的精确 k 近邻搜索

输入: 非空 kd 树 $\mathcal{T}$, 查询 $x \in \mathbb{R}^n$, $k \in \{1, \dots, N\}$
输出: 按距离与稳定并列规则排序的 k 个近邻集合 H
数据: 距离 L_p ; 大小至多为 k 的最大堆 H ; 任务栈 Q

- 1 $H \leftarrow \emptyset$, 把根任务 (root, 0) 压入 Q
- 2 当 $Q \neq \emptyset$ 执行
 - 3 弹出任务 (t, ℓ) ; 若 $|H| = k$ 且 ℓ 不优于堆顶距离 r_k (含并列规则), 则剪去该子树并继续
 - 4 计算 $d = L_p(x, q_t)$, 将 (d, t) 插入 H ; 若 $|H| > k$ 则删除最差候选, 并令 r_k 为堆顶距离
 - 5 按查询坐标确定近、远子树, 并令 $\delta = |x^{(a_t)} - q_t^{(a_t)}|$
 - 6 若近侧非空则压入下界 0 的近侧任务; 若远侧非空且 $|H| < k$ 或 δ 可能优于 r_k , 则压入下界 δ 的远侧任务
- 7 结束
- 8 返回排序后的 H 与 completed

算法实现说明: 工程实现须核验树无环、距离有限且非负, 并记录访问/剪枝计数; 访问预算耗尽返回 budget_stop, 完整搜索栈清空才返回 completed。完整 C1-C14 契约

算法 13.3 直接输出一组 k 近邻; $k = 1$ 只是其特例。停止来自有限搜索栈清空, 正确性来自保守下界不会剪去可能进入前 k 名的点, 而不是数值迭代收敛。

13.6 例题、复杂度与练习

读前自检: 复杂度分析: 例题、复杂度与练习。 例题、复杂度与练习要求先确认“若构造平衡 kd 树, 每层重新排序时为 $O(N \log^2 N)$ ”; 请随后由 n 的总成本剥离一次迭代或一次样本因子, 用线性扫描的候选堆为 $O(k)$ 验收。

复杂度分析

复杂度假设。 以下界假设每次读取一个稠密 n 维样本并计算 L_p 距离需 $O(n)$, 训练样本驻留内存; 平衡 kd 树的典型界依赖近似均匀的低维分布, 最坏界不作该分布假设。堆维护按二叉最大堆计, 其他索引结构应按其操作成本重计。设训练样本数为 N 、特征维数为 n 、近邻数为 k 。

训练复杂度: 直接线性扫描形式只需登记训练样本, 复制存储时为 $O(Nn)$ 。若构造平衡 kd 树, 每层重新排序时为 $O(N \log^2 N)$; 预排序或线性选中位数时典型为 $O(N \log N)$ 。

预测复杂度: 线性扫描对一个查询计算 N 次 n 维距离, 配合大小 k 的堆为 $O(N(n + \log k))$ 。低维且分布较均匀时, kd 树最近邻搜索常接近 $O(\log N)$ 次节点访问, 最坏仍为 $O(N)$, 每次完整距离计算另需 $O(n)$ 。

存储复杂度: 训练样本与树节点的数据为 $O(Nn)$, 树链接为 $O(N)$, 平衡递归栈为 $O(\log N)$; 线性扫描的候选堆为 $O(k)$ 。

适用条件与局限性

适用条件：特征距离能表达任务相似性、同一区域的输出较平滑、样本量允许保存并在预测时检索。**kd** 树更适合维度较低、连续数值特征和轴对齐切分仍有辨别力的场景。**局限性：**预测与存储成本随训练集增长；尺度、无关特征和高维距离集中会破坏邻域；类别不均衡与采样密度差异会偏置投票；**kd** 树在高维或高度相关数据上可能退化为近线性搜索。

读前自检：常见错误与误用边界：例题、复杂度与练习。 从例题、复杂度与练习的条件“边界框

首项禁止把平均 $O(\log N)$ 写成无条件最坏复杂度”出发，请把固定错误“把平均 $O(\log N)$ 写成无条件最坏复杂度”中的对象、操作与结论按本节定义拆开，指出第一个不满足的定义条件，再把该处改为本节允许的写法；所得量应符合改写后的运算或判断有定义，且不再触发“把平均 $O(\log N)$ 写成无条件最坏复杂度”。

常见错误

典型误用包括：混淆近邻个数 k 与特征维数；未缩放不同量纲特征；用训练样本原顺序代替距离排序；没有规定距离或类别平局；把局部频率直接称为真实概率；回归时仍使用多数表决；**kd** 树回溯只检查叶节点而漏掉祖先；用到切分节点的完整距离代替到切分平面的下界；把平均 $O(\log N)$ 写成无条件最坏复杂度。

读前自检：易混淆概念对比：例题、复杂度与练习。 例题、复杂度与练习依赖“概念对比： k 控制邻域样本数， p 控制距离几何”；请据此按表格顺序核对例题、复杂度与练习对比表的首个数据行，并直接核对例题、复杂度与练习首行两端的对象、条件与不可互换项逐列一致。

易混淆概念对比

概念对比： k 控制邻域样本数， p 控制距离几何；前者调节平滑程度，后者改变近邻次序。线性扫描适用于任意距离且结果易核验，但每次查询检查全部样本；**kd** 树以额外构造和树存储换取低维查询加速。分类用多数类最小化局部 0-1 损失，平方损失回归用均值；两种聚合不能互换。

例题 13.3 (不同 L_p 距离下的最近邻). 设 $x_1 = (1, 1)$ ，候选 $x_2 = (5, 1)$ 与 $x_3 = (4, 4)$ 。对范数参数 $p \geq 1$ ，从 x_1 出发有 $L_p(x_1, x_2) = 4$ ；而

$$L_p(x_1, x_3) = (3^p + 3^p)^{1/p} = 3 \cdot 2^{1/p}.$$

近邻会随 p 改变，需要逐个比较而不能只凭图形印象判断。

例题 13.3 解答

读题翻译 要比较常数距离 4 与随 p 变化的 $3 \cdot 2^{1/p}$ ，并找出二者换序的唯一临界范数参数。

已知与合法条件 $p \geq 1$ ， $L_p(x_1, x_2) = 4$ ， $L_p(x_1, x_3) = 3 \cdot 2^{1/p}$ ；两距离使用同一个 p 比较。

为什么想到这个方法 先解两距离相等的临界 p ；再利用 $2^{1/p}$ 对 p 严格递减，确定临界点两侧的近邻。

方法选择 计算 $p = 1, 2, 3, 4$ 的代表值，解 $3 \cdot 2^{1/p} = 4$ 得到 $p_\star$ ，最后用单调性和端点极限判定三个区间。

推导/计算 对 $p = 1, 2, 3, 4$ 逐项比较：

p	$L_p(x_1, x_2)$	$L_p(x_1, x_3)$	较近点
1	4	6	x_2
2	4	$3\sqrt{2} \approx 4.24$	x_2
3	4	$3\sqrt[3]{2} \approx 3.78$	x_3
4	4	$3\sqrt[4]{2} \approx 3.57$	x_3

连续范数参数 $p \geq 1$ 下的换序阈值满足

$$3 \cdot 2^{1/p} = 4 \iff \frac{\log 2}{p} = \log \frac{4}{3} \iff p = \frac{\log 2}{\log(4/3)} \approx 2.41.$$

函数 $2^{1/p}$ 随 p 严格递减，故该阈值至多出现一次。

独立核验 $p = 1, 2, 3$ 时 x_3 的距离依次为 $6, 3\sqrt{2}, 3\sqrt[3]{2}$ ，分别给出 x_2, x_2, x_3 ；且 $p \rightarrow \infty$ 时该距离趋于 $3 < 4$ ，与临界点两侧的判断一致。

结论 令 $p_\star = \log 2 / \log(4/3) \approx 2.4094$ 。当 $1 \leq p < p_\star$ 时 x_2 更近； $p = p_\star$ 时并列； $p > p_\star$ 时 x_3 更近。特别地，整数 $p = 1, 2$ 选 x_2 ，整数 $p \geq 3$ 选 x_3 。

贯穿例：四点二维分类数据

本章角色：保留四个训练点及其标签，用欧氏距离说明局部记忆式分类。

仍取 $x_i \in \{(-1, -1), (-1, 1), (1, -1), (1, 1)\}$ ，标签由第一坐标的符号给出。对查询点 $q = (0.8, 0.6)$ ，四个欧氏距离中最小者是

$$\|q - (1, 1)\|_2 = \sqrt{0.2} = 0.447 \dots,$$

故 $k = 1$ 时预测 +1。两个坐标在该数据中量纲和取值范围一致，因此这里没有把未标准化量纲差异偷偷带入距离； k 近邻也不需要上一章的线性可分假设。上一站见感知机的线性分隔表示；下一站见朴素贝叶斯的生成式表示。

本章共 12 道练习。每道题干后立即给出同号解析；长解析可自然跨页，续页标题保留题号。

【原书练习整理】

练习 13.1. 说明 $k = 1$ 与较大 k 如何改变特征空间划分的复杂度, 并讨论训练误差和泛化误差的不同趋势。

练习 13.1 解析

分类规则可形式化为

$$\hat{y}_k(x) = \arg \max_{c \in \mathcal{Y}} \sum_{i \in \mathcal{N}_k(x)} \mathbf{1}\{y_i = c\},$$

其中类别票数平局按预先固定的类别顺序处理; 距离平局则按预先固定的训练样本顺序 $\prec$ 处理。 $k = 1$ 时, 令

$$i^*(x) = \min_{\prec} \arg \min_{1 \leq j \leq n} D(x, x_j), \quad V_i^{\prec} = \{x : i^*(x) = i\}.$$

于是 $\{V_i^{\prec}\}_{i=1}^n$ 是互不相交且覆盖输入空间的带平局规则 Voronoi 划分, 并且

$$\hat{y}_1(x) = y_i \quad (x \in V_i^{\prec}).$$

在训练点互异且评价时包含样本自身的条件下,

$$\hat{R}_{\text{train}}(1) = 0;$$

存在重复位置但标签冲突时, 这个结论不成立。增大 k 后, 单点标签必须得到更大邻域支持, 零散小区域通常被合并, 可概括为

$$k \uparrow \implies \text{模型局部波动与方差通常下降, 偏差通常上升.}$$

训练误差与泛化误差不必同向变化; 后者必须由独立验证估计, 不能由训练误差推出。

练习 13.2. 把最近邻 kd 树搜索改为输出两个近邻, 并说明当候选只有一个时为什么不能剪除任何非空远侧区域。

练习 13.2 解析

令候选集合 C 至多含两个点, 并按距离维护最大堆。搜索半径定义为

$$r_2 = \begin{cases} +\infty, & |C| < 2, \\ \max_{z \in C} D(x, z), & |C| = 2. \end{cases}$$

访问新点 q 时执行

$$C \leftarrow \begin{cases} C \cup \{q\}, & |C| < 2, \\ (C \setminus \{z_{\max}\}) \cup \{q\}, & |C| = 2, D(x, q) < r_2, \\ C, & \text{其他情形.} \end{cases}$$

设远侧区域的距离下界为 δ 。只寻找严格更近点时, 安全剪枝条件是

$$\delta \geq r_2.$$

练习 13.2 解析 (续)

候选只有一个时 $r_2 = +\infty$, 任意有限 δ 都满足 $\delta < r_2$, 所以不能剪除非空远侧区域; 候选凑满两个后才可使用该条件。

练习 13.3. 计算 $x = (1, 1)$ 与 $z = (4, 5)$ 之间的 L_1, L_2, L_∞ 距离, 并按从小到大排列。

练习 13.3 解析

坐标差为 $z - x = (3, 4)$, 因此

$$L_1(x, z) = |3| + |4| = 7,$$

$$L_2(x, z) = \sqrt{3^2 + 4^2} = 5,$$

$$L_\infty(x, z) = \max\{|3|, |4|\} = 4.$$

所以本题数值次序为

$$L_\infty(x, z) < L_2(x, z) < L_1(x, z).$$

这是同一点在三种度量下的数值比较, 不表示某一种度量对所有任务都更合适。

练习 13.4. 说明为什么特征“年龄”和“年收入”直接使用欧氏距离可能使收入坐标支配近邻, 并给出一种不泄漏测试信息的处理方式。

练习 13.4 解析

设两个样本的年龄差与收入差分别为 $\Delta a, \Delta s$, 未经缩放的欧氏距离为

$$D^2 = \Delta a^2 + \Delta s^2.$$

若 $|\Delta s| \gg |\Delta a|$, 则

$$\frac{\Delta s^2}{D^2} = \frac{\Delta s^2}{\Delta a^2 + \Delta s^2} \approx 1,$$

近邻次序便几乎只由收入坐标决定。只在训练集上估计

$$\mu_j^{\text{tr}} = \frac{1}{N_{\text{tr}}} \sum_{i \in \text{tr}} x_{ij}, \quad s_j^{\text{tr}} > 0,$$

再对训练、验证和测试统一应用

$$x'_{ij} = \frac{x_{ij} - \mu_j^{\text{tr}}}{s_j^{\text{tr}}}.$$

验证与测试样本不得参与 $\mu_j^{\text{tr}}, s_j^{\text{tr}}$ 的估计, 否则会泄漏待评估数据的信息; 若 $s_j^{\text{tr}} = 0$, 该常量特征应删除或按预定规则处理。

练习 13.5. 比较线性扫描用无序长度 k 候选表与最大堆维护候选时, 处理一个新样本的最坏代价。

练习 13.5 解析

对一个 n 维新样本, 距离计算代价为 $O(n)$ 。候选已满时, 无序表与最大堆的维护代价分别为

$$T_{\text{list}} = O(k), \quad T_{\text{heap}} = O(\log k).$$

因此每处理一个训练样本, 最坏代价为

$$T_{\text{list}}^{(1)} = O(n + k), \quad T_{\text{heap}}^{(1)} = O(n + \log k).$$

线性扫描 N 个训练样本时,

$$T_{\text{list}}^{(N)} = O(N(n + k)), \quad T_{\text{heap}}^{(N)} = O(N(n + \log k)),$$

两种方法的候选存储均为 $O(k)$ 。当距离计算 $O(n)$ 占主导时, 堆只降低维护候选的部分。

练习 13.6. 某查询的 7 个邻居标签为 A, A, A, B, B, C, C 。计算三类局部频率并给出预测。

练习 13.6 解析

三类计数与局部经验频率为

$$(n_A, n_B, n_C) = (3, 2, 2), \quad (\hat{p}_A, \hat{p}_B, \hat{p}_C) = \left(\frac{3}{7}, \frac{2}{7}, \frac{2}{7}\right).$$

归一化检查给出

$$\hat{p}_A + \hat{p}_B + \hat{p}_C = \frac{3 + 2 + 2}{7} = 1.$$

多数表决为

$$\hat{y} = \arg \max_{c \in \{A, B, C\}} n_c = A.$$

这些是当前邻域的经验频率; 是否接近真实条件概率仍取决于样本量、邻域尺度与采样分布。

练习 13.7. 回归邻域的响应为 2, 4, 9。分别计算平方损失下的均值预测及其损失, 并与预测 $a = 4$ 比较。

练习 13.7 解析

令常数预测为 $a \in \mathbb{R}$, 平方损失为

$$L(a) = (2 - a)^2 + (4 - a)^2 + (9 - a)^2.$$

其驻点与二阶导数为

$$L'(a) = 2(a - 2) + 2(a - 4) + 2(a - 9) = 6a - 30 = 0 \implies a^* = 5, \quad L''(a) = 6 > 0.$$

练习 13.7 解析 (续)

故 $a^* = 5$ 是唯一全局最小点。代值比较：

$$L(5) = (2-5)^2 + (4-5)^2 + (9-5)^2 = 9 + 1 + 16 = 26,$$

$$L(4) = (2-4)^2 + (4-4)^2 + (9-4)^2 = 4 + 0 + 25 = 29.$$

于是 $L(5) < L(4)$ ；比较使用的是同一邻域与同一平方损失。

练习 13.8. 距离加权回归使用权重 $1/D(x, x_i)$ 时，若某训练点与查询完全重合会发生什么？给出稳定处理规则。

练习 13.8 解析

令零距离样本指标集为

$$I_0(x) = \{i : D(x, x_i) = 0\}.$$

若 $I_0(x) = \emptyset$ ，可使用归一化权重

$$\tilde{w}_i(x) = \frac{D(x, x_i)^{-1}}{\sum_j D(x, x_j)^{-1}}, \quad \hat{y}(x) = \sum_i \tilde{w}_i(x) y_i.$$

若 $I_0(x) \neq \emptyset$ ，原权重出现 $1/0$ ，应切换到预先声明的零距离规则。例如平方损失回归取

$$\hat{y}(x) = \frac{1}{|I_0(x)|} \sum_{i \in I_0(x)} y_i,$$

绝对损失回归可取这些响应的中位数；多数表决只适用于分类，不能作为通用回归聚合。另一方案是使用 $1/(D + \varepsilon)$ ，但 $\varepsilon > 0$ 成为必须在训练流程内选择的超参数。

练习 13.9. 对点 $(1, 4), (2, 2), (3, 5), (4, 1), (5, 3)$ ，从第一坐标开始按中位数构造 kd 树；偶数个点时取稳定排序后的上中位点。写出根及第一层两个子树的根。

练习 13.9 解析

第一层按第一坐标排序：

$$(1, 4), (2, 2), (\underbrace{3, 5}_{\text{中位点}}), (4, 1), (5, 3),$$

故根为 $(3, 5)$ ，左右子集分别为

$$S_L = \{(1, 4), (2, 2)\}, \quad S_R = \{(4, 1), (5, 3)\}.$$

下一层按第二坐标稳定排序，并依题设取上中位点：

$$S_L : (2, 2), (\underbrace{1, 4}_{\text{中位点}}), \quad S_R : (4, 1), (\underbrace{5, 3}_{\text{中位点}}).$$

因此左、右子树根分别为 $(1, 4)$ 与 $(5, 3)$ 。若改用下中位数会得到另一棵合法树，所以该约定必须在题设中固定并在递归中保持一致。

练习 13.10. 三个点在当前切分轴上的坐标都相等。说明只按“严格小于去左，其余去右”可能造成什么问题，并给出修复办法。

练习 13.10 解析

设当前集合 S 含 $m = 3$ 个点，且切分坐标均等于 c 。若只用“ $x^{(a)} < c$ 进左侧，否则进右侧”，则

$$S_L = \emptyset, \quad S_R = S \quad (\text{若中位点未先删除}),$$

递归规模不变，因而可能无法终止。即使先删除中位点，也只有

$$|S_L| = 0, \quad |S_R| = m - 1 = 2,$$

树会严重偏斜。修复方法是用“切分坐标、样本唯一序号”形成稳定全序，按排序位置选择中位元素 q 并从集合中删除：

$$S_L = \{s_{(1)}, \dots, s_{(h-1)}\}, \quad S_R = \{s_{(h+1)}, \dots, s_{(m)}\}.$$

于是 $|S_L|, |S_R| < m$ ，每次递归规模严格减小，有限点集上必然终止。

练习 13.11. 当前最近距离 $r = 2$ ，查询到切分平面的距离 $\delta = 2.5$ 。在只需严格更近点时是否访问远侧子树？说明依据。

练习 13.11 解析

设远侧区域任意点为 z ，切分轴为 a 。坐标差给出距离下界

$$D_p(x, z) \geq |x^{(a)} - z^{(a)}| \geq \delta = 2.5.$$

当前最近距离 $r = 2$ ，所以

$$\inf_{z \in \text{远侧}} D_p(x, z) \geq 2.5 > 2 = r.$$

远侧不可能包含严格更近点，因此不访问该子树。剪枝判据使用查询到切分平面的距离 δ ，而不是查询到当前节点的完整距离。

练习 13.12. 解释为何高维空间中 kd 树可能访问接近全部节点，即使树保持平衡。

练习 13.12 解析

kd 树在一次回溯中只能用单个切分坐标给出下界

$$\delta = |x^{(a)} - q^{(a)}|, \quad D_2(x, q) = \sqrt{\sum_{j=1}^d (x^{(j)} - q^{(j)})^2} \geq \delta.$$

高维时，完整距离由 d 个坐标差累积，而 δ 只使用其中一个，因而常出现

$$\delta < r,$$

练习 13.12 解析 (续)

使远侧子树无法剪枝。以独立均匀坐标为例，两个随机点满足

$$\mathbb{E} D_2^2(X, Y) = \sum_{j=1}^d \mathbb{E}(X_j - Y_j)^2 = \frac{d}{6},$$

典型距离随 $\sqrt{d}$ 增长，而单轴下界仍为常数量级。平衡性只保证树高 $O(\log N)$ ，不保证访问节点数也是 $O(\log N)$ ；最坏情况下仍有

$$T_{\text{query}} = O(Nd),$$

接近线性扫描。

读前自检：本章结论与下一步。 k 近邻法章末由“距离度量、邻域、投票规则与 kd 树”落到“先更新候选，再用到切分平面的距离下界剪枝”；请把前者产出和后者输入逐项对齐，固定核对前者末项的输出类型能否作为后者首项的输入类型。

本章结论与下一步

核心结论：距离度量、邻域、投票规则与 kd 树

关键依据：由局部经验风险推出分类多数表决和回归均值

可执行自检：先更新候选，再用到切分平面的距离下界剪枝

适用边界： k 近邻分类、回归与低维相似样本检索

下一步：进入朴素贝叶斯法，对比局部记忆与生成式概率建模

1. 能否计算 L_1, L_2, L_∞ 并说明改变 p 为何会改变近邻？若不能，回看第 13.1 节。
2. 能否从局部 0-1 风险推出多数表决，并为平局规定可复现规则？若不能，回看第 13.1-13.2 节。
3. 能否手工构造一棵平衡 kd 树并处理坐标并列？若不能，回看第 13.4 节。
4. 能否在每次回溯时先更新候选，再用切分平面下界判断远侧分支，并区分平均与最坏复杂度？若不能，回看第 13.5-13.6 节。

第14章 朴素贝叶斯法

读前自检：本章可检验学习目标。 朴素贝叶斯法目标中的“能够从生成式分类出发写出类别先验、类条件分布与条件独立假设，并说明参数量为何显著减少”必须可复核；请从生成式分类出发写出类别先验、类条件分布与条件独立假设，并说明参数量为何显著减少，所得结果仅在“中间结果逐项包含首目标“能够从生成式分类出发写出类别先验、类条件分布与条件独立假设，并说明参数量为何显著减少”声明的对象、条件与结论”时通过。

读前自检：先修自检。 朴素贝叶斯法先修自检固定核验“能否把 $P(X, Y)$ 写成 $P(Y)P(X | Y)$ 并用贝叶斯公式求 $P(Y | X)$ ”；请把 $P(X, Y)$ 写成 $P(Y)P(X | Y)$ 并用贝叶斯公式求 $P(Y | X)$ 并写出中间结果，再按“ $P(Y)P(X | Y)$ 的计算或证明结果满足首项所列等式、定义域或判断”明确判为通过或失败。

本章地图

核心问题：怎样用可估计的一维条件表完成稳定的多类分类

可检验学习目标：

- 能够从生成式分类出发写出类别先验、类条件分布与条件独立假设，并说明参数量为何显著减少；
- 能够逐步推出朴素贝叶斯后验得分，证明后验概率最大化在 0-1 损失下最优；
- 能够从分类计数推导极大似然估计与对称 Dirichlet 平滑，辨认零频率问题；
- 能够用对数域伪代码完成训练与预测，分析时间、空间、适用条件和模型错误风险。

最短先修：需要条件概率、贝叶斯公式、联合分布、条件独立、离散随机变量、指示函数、极大似然、Dirichlet 先验以及生成方法与判别方法的区别。默认训练样本独立同分布，类别和本章主要讨论的特征取值均为有限集合。

依赖路线：联合分布分解 → 生成式分类；给定类别的特征条件独立 → 类条件分布乘积；贝叶斯公式 → 后验得分 → 最小条件分类风险；类别与特征计数 → 极大似然估计 → Dirichlet 平滑 → 稳定预测。

完成标准与返回：若零概率、未知取值或独立性含义不清，回看估计与平滑两节

模型认识卡：朴素贝叶斯

任务与输入：有限离散特征分类， $x = (x^{(1)}, \dots, x^{(n)})$ 。 **输出类型：**类别后验与类别。

模型： $P(Y) \prod_j P(X^{(j)} | Y)$ 。 **策略：**估计生成分布，并在 0-1 损失下取后验最大类。 **算法：**计数、正伪计数平滑、对数域评分。

预测：比较各类对数未归一化得分。 **关键假设与边界：**给定类别后条件独立；零频、未知取值与概率校准必须显式处理。

本章符号表

符号	取值	含义
$X = (X^{(1)}, \dots, X^{(n)})$	$\mathcal{X}$	含 n 个特征的随机输入
Y	$\{c_1, \dots, c_K\}$	类别随机变量
$A_j = \{a_{j1}, \dots, a_{jS_j}\}$	有限集合	第 j 个特征的可能取值
N_k	非负整数	训练集中类别 c_k 的样本数
N_{jkl}	非负整数	类别 c_k 且第 j 个特征取 a_{jl} 的样本数
π_k, θ_{jkl}	$[0, 1]$	类别先验与类条件概率
λ	非负实数	对称平滑强度
$s_k(x)$	实数或 $-\infty$	类别 c_k 的对数后验未归一化得分

14.1 生成式分类与条件独立

直接为离散向量 X 在每个类别下建立联合频率表，需要面对取值组合数的乘法增长。朴素贝叶斯用一个强但可计算的条件独立假设，把高维联合分布拆成一维条件分布的乘积。

读前自检：朴素贝叶斯法。 朴素贝叶斯法把问题限定在“朴素贝叶斯是生成式分类方法：先学习 $P(Y)$ 与 $P(X | Y)$ ”；请将 $P(X, Y) = P(Y)P(X | Y)$ 左端按定义展开一层，再与右端逐项对齐，检查是否得到两端运算均有定义、类型一致且化为同一结果。

朴素贝叶斯是生成式分类方法：先学习 $P(Y)$ 与 $P(X | Y)$ ，由 $P(X, Y) = P(Y)P(X | Y)$ 得到联合模型，再通过贝叶斯公式进行分类。名称中的“贝叶斯”指分类时使用贝叶斯公式，不等同于参数的贝叶斯估计。

读前自检：朴素贝叶斯法的学习与分类。 在“学习阶段估计类别先验和各特征在类别条件下的分布”成立时处理朴素贝叶斯法的学习与分类：请把“学习阶段估计类别先验和各特征在类别条件下的分布”中的已声明对象依次标成输入、输出与判据，并以分类阶段将观测特征代入各类别得分，输出得分最大的类别判定结果。

学习阶段估计类别先验和各特征在类别条件下的分布；分类阶段将观测特征代入各类别得分，输出得分最大的类别。训练与预测共用同一生成模型，但二者的输入和计算任务不同。

读前自检：基本方法。 朴素贝叶斯在 $Y = c_k$ 下假设各特征条件独立；请展开 $P(X = x, Y = c_k) = P(Y = c_k) \prod_{j=1}^n P(X^{(j)} = x^{(j)} | Y = c_k)$ ，并核对分类时只需比较各 k 的这一未归一化得分。

读前自检：朴素贝叶斯条件独立模型。 围绕朴素贝叶斯条件独立模型，先采用条件“ $P(X = x, Y = c_k) = P(Y = c_k) \prod_{j=1}^n P(X^{(j)} = x^{(j)} | Y = c_k)$ ”，再将 $P(X = x, Y = c_k)$ 左端按正文定义展开一层，再逐项对齐右端；最后验证配合 $P(Y = c_k)$ 。

定义 14.1 (朴素贝叶斯条件独立模型). 若对每个类别 c_k 和输入 $x = (x^{(1)}, \dots, x^{(n)})$ 有

$$P(X = x | Y = c_k) = \prod_{j=1}^n P(X^{(j)} = x^{(j)} | Y = c_k),$$

则称特征在给定类别后条件独立。配合 $P(Y = c_k)$, 得到朴素贝叶斯联合模型

$$P(X = x, Y = c_k) = P(Y = c_k) \prod_{j=1}^n P(X^{(j)} = x^{(j)} | Y = c_k).$$

模型。 若第 j 个离散特征有 S_j 个取值, 完整类条件表每个类别需要 $\prod_j S_j - 1$ 个自由参数; 条件独立模型只需 $\sum_j (S_j - 1)$ 个。加上 $K - 1$ 个类别先验自由度, 总参数量从指数级组合表降为对特征数近似线性增长。

学习策略。 以类条件独立模型近似真实联合分布, 并用似然或后验均值估计参数。即使条件独立不完全成立, 只要各类别得分的相对次序仍正确, 分类器仍可能有效; 概率校准则通常比类别排序更敏感。




图 14.1 朴素贝叶斯的条件依赖结构：给定 Y 后，各特征节点相互独立

图 14.1 中从 Y 指向各特征的箭头表示类条件分布 $P(X^{(j)} | Y)$; 特征之间没有边, 对应给定 Y 后的乘积分解。该图不表示特征在无条件分布下相互独立。

14.2 朴素贝叶斯学习与分类

由贝叶斯公式与条件独立假设,

$$P(Y = c_k | X = x) = \frac{P(Y = c_k) \prod_{j=1}^n P(X^{(j)} = x^{(j)} | Y = c_k)}{\sum_{r=1}^K P(Y = c_r) \prod_{j=1}^n P(X^{(j)} = x^{(j)} | Y = c_r)}.$$

分母对所有候选类别相同, 因此分类时只需比较分子。

读前自检：朴素贝叶斯算法。 朴素贝叶斯算法中的 “ $\mathcal{R}(c_r | x) = \sum_{k \neq r} P(Y = c_k | X = x) = 1 - P(Y = c_r | X = x)$.” 决定可执行范围; 请把 $\mathcal{R}(c_r | x)$ 展开一次并检查其类型或边界, 结果须满足需要概率输出、阈值决策或校准评估时必须归一化。

定义未归一化类别得分

$$q_k(x) = P(Y = c_k) \prod_{j=1}^n P(X^{(j)} = x^{(j)} | Y = c_k),$$

则分类规则为 $\hat{y} = \arg \max_{c_k} q_k(x)$ 。数值实现使用

$$s_k(x) = \log P(Y = c_k) + \sum_{j=1}^n \log P(X^{(j)} = x^{(j)} | Y = c_k),$$

因为对数严格递增，所以 $\arg \max_k s_k(x) = \arg \max_k q_k(x)$ 。

阅读目标：直接把 0-1 条件风险改写成 1 减后验概率。

对象：固定输入 x ，候选输出类别 c_r 与后验概率 $P(Y = c_k | x)$ 。

合法条件：类别有限，后验概率非负且总和为 1。

第一步：先写 $R(c_r | x) = \sum_k \mathbb{I}\{c_k \neq c_r\} P(Y = c_k | x)$ 。

推导目标

从条件风险出发，证明在等代价 0-1 损失下，后验概率最大化等价于 Bayes 风险最小化。

推导准备

对固定输入 x ，若决定输出类别 c_r ，条件风险是所有真实类别损失按后验概率加权的和。

定理 14.1 (后验最大化的 Bayes 最优性) 本章统一用 $\mathbb{I}\{\cdot\}$ 表示指示函数。在 $L(y, c) = \mathbb{I}\{y \neq c\}$ 下，对每个给定输入 x ，任何后验概率最大的类别都是条件风险最小的分类决定。

阅读目标：在概率单纯形约束下从似然推出类别先验与类条件概率。

对象：计数 $m_l \geq 0$ 、参数 $\theta_l \geq 0$ ，满足 $\sum_l \theta_l = 1$ 。

合法条件：总计数 $M = \sum_l m_l > 0$ ；零计数分量允许得到边界估计。

第一步：先写 $\ell(\theta) = \sum_l m_l \log \theta_l$ ，并为归一化约束引入拉格朗日乘子。

证明. 推导第 1 步：输出 c_r 的条件风险为

$$\mathcal{R}(c_r | x) = \sum_{k=1}^K L(c_k, c_r) P(Y = c_k | X = x).$$

推导第 2 步：0-1 损失只在 $k \neq r$ 时为 1，因此

$$\mathcal{R}(c_r | x) = \sum_{k \neq r} P(Y = c_k | X = x) = 1 - P(Y = c_r | X = x).$$

推导第3步：常数1与 r 无关，故最小化条件风险等价于最大化 $P(Y = c_r | X = x)$ 。若多个类别后验并列，它们具有相同的最小条件风险，需用预先约定规则处理并列。□

概率解释

类别先验表达分类前的基准比例，似然乘积表达观测特征对类别的支持，归一化分母把非负得分变成概率。只做分类时分母可约去；需要概率输出、阈值决策或校准评估时必须归一化。

读前自检：朴素贝叶斯法的参数估计。 朴素贝叶斯计数 N_k 与 N_{jkl} 分别统计类别和类别内特征取值；请对固定 k, j 将 N_{jkl} 按 l 求和，核对等于 N_k ，再归一得到条件概率行。

14.3 极大似然参数估计

训练阶段需要估计 $\pi_k = P(Y = c_k)$ 与 $\theta_{jkl} = P(X^{(j)} = a_{jl} | Y = c_k)$ 。定义

$$N_k = \sum_{i=1}^N \mathbb{I}\{y_i = c_k\}, \quad N_{jkl} = \sum_{i=1}^N \mathbb{I}\{x_i^{(j)} = a_{jl}, y_i = c_k\}.$$

读前自检：极大似然估计。 极大似然估计要求先确认“ $\hat{\pi}_k = \frac{N_k}{N}$, $\hat{\theta}_{jkl} = \frac{N_{jkl}}{N_k}$,”；请随后把观测对应因子代入 $\hat{\pi}_k$ 并合并一次，用第一式是类别频率，第二式是在类别 c_k 子样本中的特征值频率验收。

极大似然估计为

$$\hat{\pi}_k = \frac{N_k}{N}, \quad \hat{\theta}_{jkl} = \frac{N_{jkl}}{N_k},$$

其中 $N_k > 0$ 。第一式是类别频率，第二式是在类别 c_k 子样本中的特征值频率。

读前自检：学习与分类算法。 离散朴素贝叶斯先由训练集形成 N_k, N_{jkl} 并转成概率表；请将查询的每个取值按训练时字典映射、累计各类别对数得分，再按冻结并列规则输出类别，核对预测阶段未重估编码。

学习先扫描训练集形成 N_k, N_{jkl} ，再转成概率表；分类将查询值映射到各表项并累计类别对数得分。计数表、取值字典和并列规则都是模型的一部分，预测时必须沿用训练时的编码。

扩展讨论：极大似然解在单纯形边界上的严格处理。 主线只需使用频率闭式解并认识“零计数产生零概率”；下面证明解释为何零计数坐标的最优解落在边界，不参与后续分类例题的计算流程。

推导目标

在概率和为1的约束下，从多项分布似然推出类别先验和类条件概率的频率估计。

推导准备

对固定 j, k ，把 $\theta_l = \theta_{jkl}$ 、 $m_l = N_{jkl}$ ，有 $\theta_l \geq 0$ 、 $\sum_l \theta_l = 1$ 且 $\sum_l m_l = N_k$ 。

推导第1步：先分离正计数支持。与 θ 有关的对数似然为

$$\ell(\theta) = \sum_{l=1}^{S_j} m_l \log \theta_l, \quad 0 \log 0 := 0.$$

设 $I_+ = \{l : m_l > 0\}$ 。当 $N_k > 0$ 时 I_+ 非空。任何在 I_+ 上取 $\theta_l = 0$ 的候选都有 $\ell(\theta) = -\infty$ ，而单纯形内点给出有限似然，故最大点在 I_+ 上的坐标必严格为正。若这样的候选还把总质量 $s > 0$ 分给 I_+^c ，则把正计数坐标改为 $\theta'_l = \theta_l/(1-s)$ 并把零计数坐标改为 0，可使目标增加

$$\ell(\theta') - \ell(\theta) = -N_k \log(1-s) > 0.$$

因此最优解必在边界上满足 $\theta_l = 0$ ($l \notin I_+$)。

推导第2步：在正计数支持上求内点解。构造

$$\mathcal{L}(\theta, \nu) = \sum_{l \in I_+} m_l \log \theta_l + \nu \left(\sum_{l \in I_+} \theta_l - 1 \right).$$

此时每个 m_l, θ_l 都严格为正，驻点条件合法，并给出

$$\frac{m_l}{\theta_l} + \nu = 0, \quad 1 = -\frac{\sum_{l \in I_+} m_l}{\nu} = -\frac{N_k}{\nu}.$$

推导第3步：恢复单纯形边界。故 $\nu = -N_k$ ，并得到

$$\hat{\theta}_l = \begin{cases} m_l/N_k, & m_l > 0, \\ 0, & m_l = 0. \end{cases}$$

对类别计数作同样的正支持论证，得到 $\hat{\pi}_k = N_k/N$ ($N > 0$)。若 $N_k = 0$ ，则该类别的所有 m_l 均为 0，类条件似然在整个单纯形上为常数，点估计不可由数据识别；此时应使用下节先验/平滑，而不能写 m_l/N_k 。

优化解释

优化解释。离散朴素贝叶斯的极大似然在分组计数后有闭式解，无需迭代优化。对数似然对概率向量是凹函数，内部驻点为全局最大；零计数使最优点落在边界，也造成后续概率乘积被单个零因子归零。

14.4 贝叶斯估计与平滑

对每个类别先验概率赋予对称 Dirichlet 参数 λ ，并对每个类别内第 j 个特征的 S_j 值赋予同样参数，后验均值为

$$\tilde{\pi}_k = \frac{N_k + \lambda}{N + K\lambda}, \quad \tilde{\theta}_{jkl} = \frac{N_{jkl} + \lambda}{N_k + S_j\lambda}, \quad \lambda > 0.$$

$\lambda = 1$ 是加一平滑；当 $\lambda \downarrow 0$ 且相关分母非零时退回极大似然频率。

定理 14.2 (对称平滑的概率合法性) 若 $\lambda > 0$, 则所有 $\tilde{\pi}_k$ 与 $\tilde{\theta}_{jkl}$ 严格为正, 并分别对 k 和 l 求和为 1。

读前自检：证明：对称平滑的概率合法性。 对称平滑令 $\tilde{\theta}_{jkl} = (N_{jkl} + \lambda)/(N_k + \lambda S_j)$ 且 $\lambda > 0$; 请对 $l = 1, \dots, S_j$ 求和, 核对分子和等于分母, 故每项为正且总和为 1。

证明. 计数非负而 $\lambda > 0$, 故每个分子严格为正, 分母也为正。又有 $\sum_k N_k = N$, 所以 $\sum_k \tilde{\pi}_k = (N + K\lambda)/(N + K\lambda) = 1$ 。固定 j, k 时, $\sum_l N_{jkl} = N_k$, 因此 $\sum_l \tilde{\theta}_{jkl} = (N_k + S_j\lambda)/(N_k + S_j\lambda) = 1$ 。故这些量构成合法概率分布。□

当 $N_k > 0$ 时, 平滑还可写成样本频率和均匀分布的凸组合:

$$\tilde{\theta}_{jkl} = \frac{N_k}{N_k + S_j\lambda} \frac{N_{jkl}}{N_k} + \frac{S_j\lambda}{N_k + S_j\lambda} \frac{1}{S_j}.$$

若 $N_k = 0$, 不能使用含 N_{jkl}/N_k 的拆分式; 直接由原平滑公式得到

$$\tilde{\theta}_{jkl} = \frac{0 + \lambda}{0 + S_j\lambda} = \frac{1}{S_j}.$$

因此空类别得到均匀类条件分布; 非空类别中, 类别样本越少, 均匀先验的相对权重越大, 数据增加后样本频率逐渐主导。只有在 $N_k > 0$ 时, $\lambda \downarrow 0$ 才退回经验频率 N_{jkl}/N_k 。

14.5 参数估计、例题与练习

实际实现应保存计数的取值字典、类别顺序和平滑强度, 并在对数域累计得分。测试时遇到训练字典之外的新取值, 需要预先设计“未知”桶或使用能为未知事件分配质量的模型; 不能把不存在的表项静默当作概率 1。

读前自检：带对称平滑的离散朴素贝叶斯训练与分类：执行契约。 带对称平滑的离散朴素贝叶斯训练与分类输入“离散训练集 T 、查询 x 、取值字典 A_j 、类别集合、平滑强度 λ 与归一化容差 τ_{norm} ”，条件“ $T \neq \emptyset$ ”；请执行“完整样本计数后增加 i_{done} ”，以“训练及预测有限扫描完成或首次失败时停止”判停。

带对称平滑的离散朴素贝叶斯训练与分类：五步阅读

输入。 写出数据对象、固定参数与必须成立的条件。

初始化。 标明主状态、计数器和第一个合法状态。

核心更新。 只手算一次从旧状态到候选状态的更新, 并指出何时提交。

数学停止。 写出能直接核验的停止证书; 预算耗尽不等同于收敛。

输出。 列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 14.1: 带对称平滑的离散朴素贝叶斯训练与分类

输入: 训练集 $T = \{(x_i, y_i)\}_{i=1}^N$; 待分类输入 x ; 各特征取值集合 A_j

输出: 最后合法模型 $\mathcal{M}$ 、预测 $\hat{y}$ 、对数得分与后验概率; 实际完成训练样本数 i_{done} 、预测因子数 e_{done} 、 status 与最终诊断

数据: 类别集合 $\{c_1, \dots, c_K\}$; 平滑强度 $\lambda > 0$; 归一化核容差 $\tau_{\text{norm}} \geq 0$; 固定并列、缺失值与未知桶规则

- 1 $\mathcal{M} \leftarrow \emptyset$, $\hat{y} \leftarrow \perp$, $i_{\text{done}} \leftarrow 0$, $e_{\text{done}} \leftarrow 0$, 诊断初始化为空
- 2 若 $T = \emptyset$ 、 $K < 2$ 、 λ 不是有限正数、 τ_{norm} 不是有限非负数、登记字典为空、样本维数或类别非法、训练/查询值无法由登记字典或预设“未知”桶编码, 则返回空模型、计数 0、`invalid_input` 及字段或取值位置诊断
- 3 初始化 $N_k \leftarrow 0$ 、 $N_{jkl} \leftarrow 0$, 并把计数结构作为当前最后合法 $\mathcal{M}$
- 4 **对** $i \leftarrow 1$ **至** N **执行**
 - 5 更新 $N_{y_i} \leftarrow N_{y_i} + 1$ **对** $j \leftarrow 1$ **至** n **执行**
 - 6 | 按 $x_i^{(j)}$ 的取值更新对应 $N_{j,y_i,l}$
 - 7 **结束**
 - 8 | $i_{\text{done}} \leftarrow i$
- 9 **结束**
- 10 在临时表中按平滑公式计算 $\tilde{\pi}_k$ 与 $\tilde{\theta}_{jkl}$; 若分母、概率或对数不是有限实数, 或概率未落在 $[0, 1]$, 则返回计数模型、 i_{done} 、 e_{done} 、`numerical_failure` 及失败表项诊断
- 11 核验各概率表归一化后, 提交 $\mathcal{M} \leftarrow (\tilde{\pi}, \tilde{\theta}, A_1, \dots, A_n)$
- 12 **对** $k \leftarrow 1$ **至** K **执行**
 - 13 初始化 $s_k \leftarrow \log \tilde{\pi}_k$ **对** $j \leftarrow 1$ **至** n **执行**
 - 14 | 若 $x^{(j)}$ 已观测, 则先计算候选 $s_k^+ \leftarrow s_k + \log \tilde{\theta}_{jk,l(x^{(j)})}$; 若非有限则返回最后合法模型、未定义预测、当前计数、`numerical_failure`, 诊断为失败项 (k, j) ; 否则 $s_k \leftarrow s_k^+$ 、 $e_{\text{done}} \leftarrow e_{\text{done}} + 1$
 - 15 **结束**
- 16 **结束**
- 17 取 $\hat{y} \leftarrow c_{\arg \max_k s_k}$, 用 `log-sum-exp` 在临时向量中归一化; 若归一化常数或后验非有限、为负, 或 $|\sum_k p_k - 1| > \tau_{\text{norm}}$, 则返回最后合法模型与 `numerical_failure` 诊断
- 18 返回 $\mathcal{M}, \hat{y}, s, p, i_{\text{done}} = N, e_{\text{done}}, \text{completed}$, 最终诊断记录类别票据、归一化残差和未知桶使用次数

初始化。计数必须从零开始, 类别和特征值使用固定索引; 训练前先确定缺失值与未知值的编码策略。

更新规则。每个样本恰好更新一个类别计数, 并为每个已观测特征更新一个类条件计数; 预测阶段只累加对应表项的对数。

停止条件。训练扫描完 N 个样本、预测扫描完 K 个类别和 n 个特征即停止; 该闭式算法没有迭代容差。

收敛条件。有限扫描精确得到给定数据上的平滑估计。若模型正确、取值集合固定且样本独立同分布, 频率估计随各类样本数增加收敛到相应概率; 模型错设不会因样本增加而消失。

有限步终止与统计一致性。训练与预测均为有限计数、查表和归一化, 不存在数值优化迭代; 上句的“收敛到概率”是统计一致性陈述。输入条件不满足、未知值无法编码或 `log-sum-exp` 前得分不是有限实数时, 算法停止并说明原因。

读前自检: 复杂度分析: 参数估计、例题与练习。先锁定参数估计、例题与练习的条件“以下假设每个样本的 n 个离散特征均可在单位时间映射到已登记状态, 类别与条件概率表按稠密数组

访问”：由 n 的总成本剥离一次迭代或一次样本因子，所得结果应满足存储复杂度：类别先验和全部离散条件表为 $O(K + K \sum_j S_j)$ ，计数可原位转成对数概率。

复杂度分析

复杂度假设。以下界假设每个样本的 n 个离散特征均可在单位时间映射到已登记状态，类别与条件概率表按稠密数组访问；稀疏输入只扫描已观测项时，应以非零特征数代替 n 。开放词表扩容、哈希冲突和数据读取成本需另计。设样本数为 N 、特征数为 n 、类别数为 K ，第 j 个离散特征有 S_j 个取值。

训练复杂度：一次稠密扫描计数为 $O(Nn)$ ，将计数转成概率表需 $O(K \sum_j S_j)$ 。

预测复杂度：单个输入对 K 个类别累计 n 个条件对数概率，时间为 $O(Kn)$ ；稀疏输入可按非零特征数计。

存储复杂度：类别先验和全部离散条件表为 $O(K + K \sum_j S_j)$ ，计数可原位转成对数概率。

几何理解

几何解释。在离散特征的一位有效编码 $\phi(x)$ 中，对数得分 $s_k(x)$ 是 $\phi(x)$ 的线性函数；任意两类的决策边界由 $s_k(x) = s_r(x)$ 给出。因此，生成模型的条件独立参数在对数空间诱导出分段线性的类别比较。

例题 14.1 (加一平滑后的朴素 Bayes 分类). 两类 A, B 的训练计数为 6 和 4。两个二值特征中，类 A 取值 1 的计数为 4 和 3，类 B 为 1 和 3。取 $\lambda = 1$ ，分类 $x = (1, 1)$ 。

例题 14.1 解答

读题翻译 需要用训练计数和 $\lambda = 1$ 同时平滑类别先验与两个二值特征的条件概率，再比较 $x = (1, 1)$ 在两类下的后验得分。

已知与合法条件 总样本数 $N = 10$ ，类别数 $K = 2$ ， $N_A = 6, N_B = 4$ ；两个特征各有 $S_1 = S_2 = 2$ 个可能取值，故先验分母为 $N + K\lambda$ ，类条件分母为 $N_k + S_j\lambda$ ，均严格为正。

为什么想到这个方法 朴素 Bayes 条件独立假设把每类得分分解为“平滑先验 $\times$ 两个平滑条件概率”；得分归一化后才是后验概率。

方法选择 先按 $K = 2$ 平滑两类先验，再按 $S_1 = S_2 = 2$ 平滑四个所需条件概率；乘出 q_A, q_B ，最后用 $q_A + q_B$ 归一化并比较。

推导/计算 二类先验和平滑条件概率为

$$\begin{aligned}\hat{P}(A) &= \frac{6+1}{10+2} = \frac{7}{12}, & \hat{P}(B) &= \frac{4+1}{10+2} = \frac{5}{12}, \\ \hat{P}(X_1=1|A) &= \frac{4+1}{6+2} = \frac{5}{8}, & \hat{P}(X_2=1|A) &= \frac{3+1}{6+2} = \frac{4}{8}, \\ \hat{P}(X_1=1|B) &= \frac{1+1}{4+2} = \frac{2}{6}, & \hat{P}(X_2=1|B) &= \frac{3+1}{4+2} = \frac{4}{6}.\end{aligned}$$

未归一化得分及其归一化为

$$\begin{aligned} q_A &= \frac{7}{12} \frac{5}{8} \frac{4}{8} = \frac{35}{192} \approx 0.1823, \\ q_B &= \frac{5}{12} \frac{2}{6} \frac{4}{6} = \frac{5}{54} \approx 0.0926, \\ P(A | x) &= \frac{q_A}{q_A + q_B} = \frac{189}{285} = \frac{63}{95} \approx 0.663, \\ P(B | x) &= \frac{32}{95} \approx 0.337. \end{aligned}$$

独立核验 后验赔率 $q_A/q_B = 63/32 > 1$ 独立确认类别次序；同时 $63/95 + 32/95 = 1$ ，两个后验均非负，归一化合法。

结论 $P(A | x) = 63/95 > P(B | x) = 32/95$ ，故 $x = (1, 1)$ 的唯一预测类别为 A 。

适用条件与局限性

适用条件：朴素贝叶斯适合高维稀疏数据、样本较少、需要快速增量计数或希望得到可解释特征证据的任务。**局限性：**强相关特征会被重复计入证据；离散化和分布族选择影响结果；未校准后验可能过度自信；训练字典之外的取值需要额外机制。

复杂度边界：稠密离散数据的计数训练时间复杂度为 $O(Nn)$ ，单样本对 K 类评分的时间复杂度为 $O(Kn)$ ；保存各类别、各特征取值的条件概率表时，空间复杂度为 $O(K \sum_{j=1}^n s_j)$ ，其中 s_j 是第 j 个特征的取值数。

读前自检：常见错误与误用边界：参数估计、例题与练习。 对参数估计、例题与练习，条件“边框首项禁止把条件独立误写成无条件独立”不可省；请把固定错误“把条件独立误写成无条件独立”中的对象、操作与结论按本节定义拆开，指出第一个不满足的定义条件，再把该处改为本节允许的写法，再用改写后的运算或判断有定义，且不再触发“把条件独立误写成无条件独立”作检查。

常见错误

典型误用包括：把朴素贝叶斯与参数贝叶斯估计混为一谈；把条件独立误写成无条件独立；条件概率分母误用总样本数；分类时漏乘类别先验；直接连乘大量小概率造成下溢；平滑只改分子而不改分母；把缺失特征当作概率 0；用同一强相关信息构造多个重复特征。

易混淆概念对比

概念对比。极大似然用原始频率，零计数产生零概率；对称 Dirichlet 后验均值把频率向均匀分布收缩。朴素贝叶斯是带条件独立结构的生成分类器，“Bayes 最优分类器”则指在真实后验已知时最小化给定损失的决策规则。前者用估计模型近似后者，两者不能互换称呼。

贯穿例：四点二维分类数据

本章角色：把两个坐标视为二值离散特征，展示条件概率分解与平滑，而不把条件独立当作数据事实。

复用四点数据，并令每个特征的取值字典为 $\{-1, +1\}$ 。采用对称加一平滑时，查询 $x = (1, -1)$ 的两个未归一化类别得分为

$$\underbrace{\frac{1}{2} \cdot \frac{3}{4} \cdot \frac{1}{2}}_{Y=+1} = \frac{3}{16}, \quad \underbrace{\frac{1}{2} \cdot \frac{1}{4} \cdot \frac{1}{2}}_{Y=-1} = \frac{1}{16},$$

因而预测 $+1$ 。离散取值、固定字典和正平滑系数保证计算合法；给定类别后两坐标条件独立仍是本章的建模假设，不能由这四个样本验证。上一站见 [k 近邻法的局部投票表示](#)；下一站见 [决策树的递归划分表示](#)。

本章共 12 道练习。每道题干后立即给出同号解析；长解析可自然跨页，续页标题保留题号。

【原书练习整理】

练习 14.1. 从离散朴素贝叶斯模型的多项分布似然出发，在概率和为 1 的约束下，推导类别先验与类条件概率的极大似然估计。须写出计数、拉格朗日函数和归一化步骤。

练习 14.1 解析

记

$$N_k = \sum_i \mathbb{I}\{y_i = c_k\}, \quad N_{jkl} = \sum_i \mathbb{I}\{y_i = c_k, x_i^{(j)} = a_{jl}\},$$

并约定 $0 \log 0 = 0$ 。先考虑 $N > 0$ 且所有 $N_k > 0$ 的内点情形。类别先验的拉格朗日函数为

$$\mathcal{L}(\pi, \nu) = \sum_k N_k \log \pi_k + \nu \left(\sum_k \pi_k - 1 \right).$$

驻点与归一化条件给出

$$\frac{N_k}{\pi_k} + \nu = 0 \implies \pi_k = -\frac{N_k}{\nu}, \quad 1 = \sum_k \pi_k = -\frac{N}{\nu} \implies \hat{\pi}_k = \frac{N_k}{N}.$$

若某些 $N_k = 0$ ，令 $I_+ = \{k : N_k > 0\}$ 。任何给零计数类别分配总质量 $s > 0$ 的候选，都可把其余概率除以 $1 - s$ 而得到更大的对数似然：

$$\sum_{k \in I_+} N_k \log \frac{\pi_k}{1-s} - \sum_{k \in I_+} N_k \log \pi_k = -N \log(1-s) > 0.$$

故边界最优解仍为

$$\hat{\pi}_k = \frac{N_k}{N},$$

其中零计数类别满足 $\hat{\pi}_k = 0$ 。

练习 14.1 解析 (续)

固定 j, k 且 $N_k > 0$, 对 $\theta_{jk1}, \dots, \theta_{jL_j}$ 同理有

$$\begin{aligned}\mathcal{L}_{jk}(\theta, \mu) &= \sum_l N_{jkl} \log \theta_{jkl} + \mu \left(\sum_l \theta_{jkl} - 1 \right), \\ \frac{N_{jkl}}{\theta_{jkl}} + \mu &= 0, \quad 1 = -\frac{N_k}{\mu}, \\ \hat{\theta}_{jkl} &= \frac{N_{jkl}}{N_k}.\end{aligned}$$

零单元格 $N_{jkl} = 0$ 对应单纯形边界 $\hat{\theta}_{jkl} = 0$, 不能把含 $1/\theta_{jkl}$ 的内点驻点式直接代入该格。若 $N_k = 0$, 则所有 $N_{jkl} = 0$, 类条件似然在整个单纯形上为常数, θ_{jkl} 不可由数据识别, 需要平滑或先验; 若 $N = 0$, 类别先验也同样不可识别。

练习 14.2. 对类别数 K 、第 j 个特征取值数 S_j 和对称伪计数 $\lambda > 0$, 推导平滑后的 $\tilde{\pi}_k$ 与 $\tilde{\theta}_{jkl}$, 并验证两组概率分别归一化。

练习 14.2 解析

类别计数的总和为 $\sum_k N_k = N$ 。给每个类别加入伪计数 λ 后, 总伪样本数增加 $K\lambda$, 因此

$$\tilde{\pi}_k = \frac{N_k + \lambda}{N + K\lambda}, \quad \sum_{k=1}^K \tilde{\pi}_k = \frac{N + K\lambda}{N + K\lambda} = 1.$$

对固定 j, k , 有 $\sum_{l=1}^{S_j} N_{jkl} = N_k$ 。给每个取值加入 λ 后,

$$\tilde{\theta}_{jkl} = \frac{N_{jkl} + \lambda}{N_k + S_j \lambda}, \quad \sum_{l=1}^{S_j} \tilde{\theta}_{jkl} = 1.$$

由于 $\lambda > 0$, 分子和分母均为正, 未出现过的取值不再得到零概率。该推导对应对称 Dirichlet 先验的后验均值或伪计数解释; 若改用非对称先验, 分子和分母中的伪计数也必须相应改变。

练习 14.3. 设 $K = 3$, 有 4 个特征且每个特征均有 5 个取值。比较完整离散类条件表与朴素条件独立模型的自由参数数目, 不含类别先验。

练习 14.3 解析

完整联合取值数为

$$M = \prod_{j=1}^4 5 = 5^4 = 625.$$

每个类别的条件概率表满足一条和为 1 的约束, 故完整模型的自由参数数为

$$d_{\text{full}} = K(M - 1) = 3(625 - 1) = 1872.$$

练习 14.3 解析 (续)

朴素条件独立模型为每个类别、每个特征分别保存一个五项分布，因此

$$d_{\text{NB}} = K \sum_{j=1}^4 (5 - 1) = 3 \times 4 \times 4 = 48.$$

参数减少量为 $1872 - 48 = 1824$ ；这通常降低估计方差，但若条件独立假设不成立，会引入模型偏差。

练习 14.4. 构造一个例子，说明 $X^{(1)}$ 与 $X^{(2)}$ 给定 Y 后独立，但无条件下并不独立。

练习 14.4 解析

令

$$P(Y = 0) = P(Y = 1) = \frac{1}{2}, \quad X^{(1)} = Y, \quad X^{(2)} = Y.$$

给定 $Y = y$ 后，对任意 $a, b \in \{0, 1\}$,

$$\begin{aligned} P(X^{(1)} = a, X^{(2)} = b \mid Y = y) &= \mathbb{I}\{a = y, b = y\} \\ &= \mathbb{I}\{a = y\} \mathbb{I}\{b = y\} \\ &= P(X^{(1)} = a \mid Y = y) P(X^{(2)} = b \mid Y = y). \end{aligned}$$

故 $X^{(1)} \perp X^{(2)} \mid Y$ 。但无条件下

$$P(X^{(1)} = 1, X^{(2)} = 1) = \frac{1}{2} \neq \frac{1}{2} \cdot \frac{1}{2} = P(X^{(1)} = 1) P(X^{(2)} = 1),$$

所以二者并不边缘独立；共同变量 Y 造成了相关性。

练习 14.5. 两类先验为 0.6, 0.4。对观测 x ，两类的条件概率乘积为 0.10, 0.18。求未归一化得分、后验概率和预测类别。

练习 14.5 解析

未归一化得分为

$$q_1 = 0.6 \times 0.10 = 0.060, \quad q_2 = 0.4 \times 0.18 = 0.072.$$

归一化常数和后验为

$$\begin{aligned} Z &= q_1 + q_2 = 0.132, \\ P(Y = 1 \mid x) &= \frac{0.060}{0.132} = \frac{5}{11} \approx 0.455, \\ P(Y = 2 \mid x) &= \frac{0.072}{0.132} = \frac{6}{11} \approx 0.545. \end{aligned}$$

因此 $\hat{y} = 2$ 。比较的是“先验 $\times$ 条件似然”，条件似然较大的类别不一定获胜。

练习 14.6. 二分类中, 把真实正类判为负类的代价为 4, 把真实负类判为正类的代价为 1。求选择正类的后验概率阈值。

练习 14.6 解析

记 $p = P(Y = 1 | x)$, 决策 $\hat{y} \in \{0, 1\}$ 。两种决策的条件风险为

$$R(1 | x) = 1 \cdot (1 - p), \quad R(0 | x) = 4p.$$

选择正类当且仅当

$$R(1 | x) \leq R(0 | x) \iff 1 - p \leq 4p \iff p \geq \frac{1}{5}.$$

故最小风险阈值为 $1/5$; $p = 1/5$ 时两种决策风险相同, 须按预先规定的平局规则处理。 $1/2$ 阈值只对应两类错分代价相等的情形。

练习 14.7. 在类别 c 的 10 个样本中, 某三值特征的计数为 6, 3, 1。求其类条件概率极大似然估计并计算和。

练习 14.7 解析

对三个取值 $l = 1, 2, 3$, 极大似然估计为

$$\hat{\theta}_l = \frac{N_l}{N_c}, \quad (N_1, N_2, N_3) = (6, 3, 1), \quad N_c = 10.$$

因此

$$(\hat{\theta}_1, \hat{\theta}_2, \hat{\theta}_3) = \left(\frac{6}{10}, \frac{3}{10}, \frac{1}{10} \right) = (0.6, 0.3, 0.1),$$

并且

$$\sum_{l=1}^3 \hat{\theta}_l = \frac{6+3+1}{10} = 1.$$

分母是类别 c 内样本数 N_c ; 用全部训练样本数会得到联合频率而非类条件概率。

练习 14.8. 解释一个训练中未出现的“类别 - 特征值”组合为何会使某类别的整项朴素贝叶斯得分为 0。

练习 14.8 解析

若类别 k 中取值 a_{jl} 未出现, 且 $N_k > 0$, 则

$$N_{jkl} = 0 \implies \hat{\theta}_{jkl} = \frac{N_{jkl}}{N_k} = 0.$$

对包含该取值的观测 x , 类别 k 的未归一化得分为

$$q_k(x) = \hat{\pi}_k \prod_{r=1}^n \hat{\theta}_{rk,x(r)} = 0,$$

练习 14.8 解析 (续)

因为乘积中至少有一个零因子。在对数域中同一现象写成

$$\log q_k(x) = \log \hat{\pi}_k + \sum_r \log \hat{\theta}_{rk,x(r)} = -\infty.$$

这只是有限样本的零计数, 不证明总体概率为零; 正伪计数平滑可使该因子严格为正。

练习 14.9. 在某类别的 5 个样本中, 四值特征计数为 (3, 2, 0, 0)。取 $\lambda = 1$, 求平滑概率。

练习 14.9 解析

四值特征有 $S = 4$, 类别计数 $N_k = 5$, 故加一平滑为

$$\tilde{\theta}_l = \frac{N_l + 1}{N_k + S} = \frac{N_l + 1}{9}.$$

代入 $(N_1, N_2, N_3, N_4) = (3, 2, 0, 0)$ 得

$$(\tilde{\theta}_1, \tilde{\theta}_2, \tilde{\theta}_3, \tilde{\theta}_4) = \left(\frac{4}{9}, \frac{3}{9}, \frac{1}{9}, \frac{1}{9}\right),$$

且

$$\sum_{l=1}^4 \tilde{\theta}_l = \frac{4 + 3 + 1 + 1}{9} = 1.$$

加一平滑是在计数上加 1 后重新归一化, 不是直接给概率加 1。

练习 14.10. 固定计数后, 说明 $\lambda \rightarrow \infty$ 时 $\tilde{\theta}_{jkl}$ 的极限, 并解释含义。

练习 14.10 解析

固定有限计数 N_{jkl}, N_k , 有

$$\begin{aligned} \tilde{\theta}_{jkl}(\lambda) &= \frac{N_{jkl} + \lambda}{N_k + S_j \lambda} \\ &= \frac{N_{jkl}/\lambda + 1}{N_k/\lambda + S_j}. \end{aligned}$$

因此

$$\lim_{\lambda \rightarrow \infty} \tilde{\theta}_{jkl}(\lambda) = \frac{0 + 1}{0 + S_j} = \frac{1}{S_j}.$$

极限分布在 S_j 个取值上均匀, 表示无限强的对称先验压过有限数据; 过大的 λ 会造成欠拟合, 应结合先验知识或训练流程内的验证选择。

练习 14.11. 类别对数得分为 -12.4, -10.9, -15.2。给出预测类别, 并写出稳定归一化后验的计算方法。

练习 14.11 解析

记 $s = (-12.4, -10.9, -15.2)$, 先取

$$m = \max_k s_k = -10.9.$$

平移后的指数权重为

$$u_k = e^{s_k - m}, \quad u = (e^{-1.5}, 1, e^{-4.3}) \approx (0.22313, 1, 0.01357).$$

归一化得到

$$p_k = \frac{u_k}{\sum_r u_r}, \quad p \approx (0.1804, 0.8086, 0.0110).$$

故 $\hat{y} = 2$ 。对任意共同平移 c ,

$$\frac{e^{s_k - c}}{\sum_r e^{s_r - c}} = \frac{e^{s_k}}{\sum_r e^{s_r}},$$

所以减去最大值不改变后验, 却避免直接计算极小的 e^{s_k} 。

练习 14.12. 有 $N = 10^5$ 个样本、 $n = 100$ 个离散特征和 $K = 4$ 类。给出朴素训练与单样本预测的渐近时间复杂度。

练习 14.12 解析

稠密离散数据训练时, 每个样本扫描 n 个特征, 因此

$$T_{\text{count}} = O(Nn) = O(10^5 \times 100) = O(10^7).$$

由计数生成全部条件概率表另需

$$T_{\text{table}} = O\left(K \sum_{j=1}^n S_j\right),$$

该步骤在训练后执行一次。单样本预测需对每个类别累计 n 项对数条件概率:

$$T_{\text{pred}} = O(Kn) = O(4 \times 100) = O(400).$$

这些界假设离散取值能以常数时间映射到已登记表项; 稀疏输入时可用非零特征数替代 n 。

本章结论与下一步

核心结论：类别先验、条件概率表与条件独立分解

关键依据：由受约束极大似然推得分组频率并用对称 Dirichlet 先验平滑

可执行自检：固定取值字典，在对数域累计类别得分并显式处理未知值

适用边界：高维离散特征的快速生成式分类基线

下一步：进入决策树，以数据驱动划分替代全局条件独立假设

1. 能否写出条件独立分解并计算完整表与朴素表的自由参数数目？
 2. 能否从条件风险三步证明后验最大化的最优性，并处理非对称代价？
 3. 能否从计数和概率和约束推出极大似然公式，再写出平滑公式？
 4. 能否给出对数域训练与预测伪代码，说明初始化、终止与复杂度？
 5. 能否区分模型条件独立、参数贝叶斯估计和 Bayes 决策规则？未通过时依次回看第 14.1 节、第 14.2 节、第 14.3–14.4 节与第 14.5 节。

第15章 决策树

读前自检：本章可检验学习目标。 决策树学习目标固定核验“能把分类树解释为互斥完备的 if-then 规则集合，以及特征空间划分上的条件概率分布”；请实际完成“把分类树解释为互斥完备的 if-then 规则集合，以及特征空间划分上的条件概率分布”，并用“中间结果逐项包含首目标“能把分类树解释为互斥完备的 if-then 规则集合，以及特征空间划分上的条件概率分布”声明的对象、条件与结论”判定通过或失败。

读前自检：先修自检。 决策树先修自检固定核验“对概率向量 $(1/2, 1/4, 1/4)$ ，能否计算以 2 为底的熵并解释其单位”；请对概率向量 $(1/2, 1/4, 1/4)$ ，实际计算以 2 为底的熵并解释其单位并写出中间结果，再按“ $(1/2, 1/4, 1/4)$ 的计算或证明结果满足首项所列等式、定义域或判断”明确判为通过或失败。

读前自检：依赖路线。 决策树依赖路线从“条件概率与特征空间划分 → 树模型”进入“经验熵与条件熵 → 信息增益和信息增益比 → ID3 与 C4.5”；请写出箭头成立所需的定义域条件，并核对前者输出能作为后者输入。

本章地图

核心问题： 怎样在拟合能力与树结构复杂度之间取得可验证的平衡

可检验学习目标：

- 能把分类树解释为互斥完备的 if-then 规则集合，以及特征空间划分上的条件概率分布；
- 能从经验熵与经验条件熵逐步计算信息增益和信息增益比，并说明 ID3 与 C4.5 的选择差异；
- 能写出决策树生成、熵惩罚剪枝、CART 分类与回归生成以及最弱环节剪枝的严格伪代码；
- 能证明平方误差叶结点的最优输出是样本均值，分析树算法的复杂度、适用条件、局限和常见错误；
- 能用训练集生成候选树、用独立验证信息选择子树，并完整复现本章例题与练习计算。

最短先修： 本章直接使用条件概率、经验分布、对数、熵、期望与平方误差；还需要理解训练误差和验证误差的角色、过拟合与正则化、分类和回归任务。阅读前应能计算离散概率分布，能按特征取值把样本集合分组，并能区分模型、学习策略与实现算法。

依赖路线： 条件概率与特征空间划分 → 树模型；经验熵与条件熵 → 信息增益和信息增益比 → ID3 与 C4.5；经验损失与复杂度惩罚 → 决策树剪枝；平方误差与基尼指数 → CART 回归树和分类树；代价复杂度函数 → 最弱环节剪枝序列 → 验证集选择最优子树。

完成标准与返回： 若权重、停止条件或验证流程不清，回看特征选择与剪枝两节

模型认识卡：决策树

任务与输入： 表格型分类或回归， $x \in \mathcal{X}$ 。 **输出类型：** 类别、概率向量或实值。

模型： 互斥完备叶区域上的分段常数规则。 **策略：** 局部降低不纯度或平方误差，并以剪枝控制复杂度。 **算法：** 递归生成候选树，再构造嵌套剪枝序列并验证选择。

预测： 沿唯一根到叶路径读取叶输出。 **关键假设与边界：** 每个内部结点须有完备分支或默认路由；高基数特征、缺失值与小叶会放大过拟合。

本章符号表

符号	取值或维数	含义
$D = \{(x_i, y_i)\}_{i=1}^N$	N 个样本	当前结点上的训练数据集
$\mathcal{A}$	有限特征集合	当前仍可用于划分的特征
C_k	D 的子集	属于第 k 类的样本集合
D_i	D 的子集	特征 A 取第 i 个值时的样本集合
$H(D), H(D A)$	非负实数	经验熵与按特征 A 分组的经验条件熵
$g(D, A), g_R(D, A)$	非负实数	信息增益与信息增益比
$T, T $	树、正整数	决策树及其叶结点数
R_m, c_m	区域、实数	回归树的第 m 个区域与区域输出
$\text{Gini}(D, A)$	$[0, 1)$	经特征测试后子集不纯度的加权值
$C_\alpha(T)$	非负实数	拟合损失与叶结点复杂度惩罚之和

15.1 树模型与条件概率分布

决策树要解决的问题是：如何把一组带标记样本组织为可解释、可计算、可推广的递归决策规则。树的生成追求局部划分纯度，树的剪枝控制整体复杂度；两者共同决定最终模型，而不是把训练样本分得越细越好。

读前自检：决策树。 围绕决策树中的决策树，先采用条件“决策树既可用于分类，也可用于回归”，再构造一个满足条件的最小结点状态并执行一次分支或停止判断；最后验证从根到叶的一条路径是一连串特征测试，预测过程只需沿一条路径向下访问。

决策树既可用于分类，也可用于回归。分类树的叶结点给出类别或类别分布，回归树的叶结点给出实值；从根到叶的一条路径是一连串特征测试，预测过程只需沿一条路径向下访问。

读前自检：决策树模型与学习。 决策树模型与学习中的“树模型规定结点、边和叶输出”决定可执行范围；请构造一个满足条件的最小结点状态并执行一次分支或停止判断，结果须满足生成阶段递归建立局部结构，剪枝阶段比较整棵子树与把它收缩为单叶的代价，因此前者是局部扩张，后者是全局简化。

树模型规定结点、边和叶输出；学习过程包括特征选择、树生成和树剪枝。生成阶段递归建立局部结构，剪枝阶段比较整棵子树与把它收缩为单叶的代价，因此前者是局部扩张，后者是全局简化。

读前自检：决策树模型。 把决策树模型放在“从根结点到任一叶结点的路径定义一个特征条件的合取”下考察：构造一个满足条件的最小结点状态并执行一次分支或停止判断，并检查结点输出与分支条件相符且没有遗漏停止情形。

定义 15.1 (分类决策树). 分类决策树是由有向边连接的树形分类模型。内部结点对应一个特征或属性测试，出边对应测试结果，叶结点对应一个类别或类别概率分布。从根结点到任一叶结点的路径定义一个特征条件的合取。

模型。 设叶结点对应的区域为 $R_1, \dots, R_M$ ，它们互不相交且并为特征空间 $\mathcal{X}$ 。分类树可写为

$$f(x) = \sum_{m=1}^M c_m \mathbf{1}\{x \in R_m\},$$

其中 c_m 是区域 R_m 的类别标记。若保留叶内类别频率，则模型还给出分段常数的条件概率估计

$$\hat{P}(Y = k | X = x) = \frac{N_{mk}}{N_m}, \quad x \in R_m,$$

N_m 为叶 m 的样本数， N_{mk} 为其中第 k 类样本数。

从根到叶 m 的路径若依次满足条件 $B_{m1}, \dots, B_{mq_m}$ ，就对应规则

$$\text{if } B_{m1} \wedge \dots \wedge B_{mq_m} \text{ then } Y = c_m.$$

要使同一棵确定性树的叶路径互斥且覆盖整个输入空间，每个内部结点必须满足下列二者之一：出边穷尽测试的全部可能结果；或除显式出边外，再登记唯一默认分支。未见类别、缺失值和数值越界都按训练前冻结的默认规则路由（例如走训练权重最大的子结点）；禁止同时命中多个分支。于是任意输入在每个内部结点都有且只有一个后继，最终恰好到达一个叶结点。规则的前件是路径上的全部测试，遗漏其中任一条件都会扩大覆盖区域并改变模型。

读前自检：决策树与条件概率分布。 决策树与条件概率分布要求先确认“树也可看成定义在特征空间划分上的条件概率分布”；请随后把决策树与条件概率分布在其支持上求和或积分一次，用每个叶区域内的经验条件分布通常集中于一个类别，分类输出取叶内概率最大的类别验收。

树也可看成定义在特征空间划分上的条件概率分布。每个叶区域内的经验条件分布通常集中于一个类别，分类输出取叶内概率最大的类别。叶内样本很少时，频率估计方差较大，宜设置最小叶容量、剪枝或平滑，而不能把纯叶频率机械理解为确定概率。

读前自检：决策树学习。 从决策树学习的条件“每一步只在当前结点比较候选特征与切分，随后对子结点重复处理，再通过剪枝修正局部贪心导致的过度复杂”出发，请构造一个满足条件的最小结点状态并执行一次分支或停止判断；所得量应符合结点输出与分支条件相符且没有遗漏停止情形。

15.2 特征选择问题

在所有可能树中直接寻找经验损失和复杂度都最优的树通常不可行，实际方法采用启发式递归划分。每一步只在当前结点比较候选特征与切分，随后对子结点重复处理，再通过剪枝修正局部贪心导致的过度复杂。

读前自检：特征选择。 决策树中的特征选择依赖“特征选择不是挑选与标签边际相关性最大的变量，而是选择在当前样本子集上最能降低类别不确定性的划分”；请据此把“特征选择不是挑选与标签边际相关性最大的变量，而是选择在当前样本子集上最能降低类别不确定性的划分”中的已声明对象依次标成输入、输出与判据，并直接核对树的最终选择还要结合验证误差或带复杂度惩罚的整体目标。

学习策略。 特征选择不是挑选与标签边际相关性最大的变量，而是选择在当前样本子集上最能降低类别不确定性的划分。信息增益、信息增益比和基尼指数都是局部代理目标；树的最终选择还要结合验证误差或带复杂度惩罚的整体目标。

学习算法。 在当前数据 D 上，对每个候选特征枚举允许的切分，计算切分后各子集不纯度的加权平均，选择使不纯度下降最多的候选。若结点已足够纯、候选特征为空、改进不超过阈值或子结点过小，则停止扩张并输出叶结点。

一个有分类能力的特征会让子集的类别分布比父结点更集中。类别取值很多的离散特征可能把样本切成许多极小子集，在训练数据上获得很高纯度却缺乏推广能力；这正是信息增益比和剪枝要处理的问题。

15.3 熵、信息增益与信息增益比

设 D 为非空有限样本集，类别数 $K < \infty$ ，其中第 k 类样本集合为 C_k 。因此下列经验熵都是有限实数：

$$H(D) = - \sum_{k=1}^K \frac{|C_k|}{|D|} \log_2 \frac{|C_k|}{|D|},$$

并约定零概率项贡献为零。特征 A 有 n 个取值并产生子集 $D_1, \dots, D_n$ 时，经验条件熵为

$$H(D | A) = \sum_{i=1}^n \frac{|D_i|}{|D|} H(D_i).$$

读前自检：信息增益的算法。 信息增益计算把当前结点 D 按 A 分成 D_i ；请计算 $H(D | A) = \sum_i |D_i| H(D_i) / |D|$ ，核对各权重和为 1，并验证小子集不会与大子集等权。

计算信息增益时，先统计父结点类别计数，再按 A 的取值建立子集类别计数；由这些计数分别求 $H(D)$ 和 $H(D | A)$ ，最后相减。每个子集的容量权重 $|D_i|/|D|$ 必须保留，否则一个很小但很纯的子集会被赋予与大子集相同影响。

读前自检：信息增益的定义。 先锁定信息增益的定义的条件“ $g(D, A) = H(D) - H(D | A)$ ”：检查 $g(D, A) = H(D) - H(D | A)$ 中每项的类型后完成等式变形，所得结果应满足两端运算均有定义、类型一致且化为同一结果。

信息增益为

$$g(D, A) = H(D) - H(D | A).$$

它度量得知特征 A 后类别不确定性的经验减少量，也等于经验联合分布下类别与特征的互信息。

读前自检：信息增益比。 对信息增益比，条件“ $H_A(D) = -\sum_{i=1}^n \frac{|D_i|}{|D|} \log_2 \frac{|D_i|}{|D|}$,”不可省；请把 $H_A(D)$ 展开一次并检查其类型或边界，再用展开后的量满足定义中的域、维数或符号限制作检查。

信息增益偏向取值较多的特征。令特征取值本身的经验熵为

$$H_A(D) = -\sum_{i=1}^n \frac{|D_i|}{|D|} \log_2 \frac{|D_i|}{|D|},$$

在 $H_A(D) > 0$ 时，用 $H_A(D)$ 对增益归一化。

读前自检：信息增益比的定义。 信息增益比定义为 $g_R(D, A) = g(D, A)/H_A(D)$ ；请先计算分裂信息 $H_A(D)$ ，核对 $H_A(D) = 0$ 时必须移除候选 A 而不能执行除零。

信息增益比定义为

$$g_R(D, A) = \frac{g(D, A)}{H_A(D)}.$$

若 A 在当前结点只有一个取值，则 $H_A(D) = 0$ 且不能提供切分，应把它从候选中移除，而不是执行除零。

阅读目标：从类别计数和特征分组计数看清每个熵权重的样本来源。

对象：当前结点样本集 D 、类别 C_k 、特征分组 D_i 与交叉计数 $D_{ik} = D_i \cap C_k$ 。

合法条件： D_i 构成 D 的划分；所有概率均由当前结点经验频率估计。

第一步：先用 $|D \cap C_k|/|D|$ 写父结点熵，再用 $|D_i|/|D|$ 加权各子结点熵。

推导目标

从类别计数和特征分组计数出发，分三步推出信息增益的可计算表达式，并明确每个权重来自哪一部分样本。

推导准备

记 $D_{ik} = D_i \cap C_k$ ，则 $|D_i| = \sum_k |D_{ik}|$ 且 $|D| = \sum_i |D_i|$ 。所有概率都用当前结点上的经验频率估计。

推导第1步：父结点中第 k 类的经验概率是 $|C_k|/|D|$ ，代入熵定义得到 $H(D)$ 。

推导第2步：在条件 $A = a_i$ 下，第 k 类的经验概率为 $|D_{ik}|/|D_i|$ ，所以

$$H(D_i) = -\sum_{k=1}^K \frac{|D_{ik}|}{|D_i|} \log_2 \frac{|D_{ik}|}{|D_i|}.$$

按事件 $A = a_i$ 的经验概率 $|D_i|/|D|$ 加权，得到 $H(D | A)$ 。

推导第3步：用观察 A 之前的不确定性减去观察后的平均不确定性：

$$g(D, A) = -\sum_{k=1}^K \frac{|C_k|}{|D|} \log_2 \frac{|C_k|}{|D|} + \sum_{i=1}^n \frac{|D_i|}{|D|} \sum_{k=1}^K \frac{|D_{ik}|}{|D_i|} \log_2 \frac{|D_{ik}|}{|D_i|}.$$

该式只依赖有限计数，可在每个候选特征上重复计算。

定理 15.1 (经验信息增益的非负性) 对当前结点上的任意离散特征 A 与类别 Y , 有 $g(D, A) \geq 0$ 。等号成立当且仅当经验联合分布中 A 与 Y 独立, 即每个非空特征取值组的类别比例都与父结点相同。

读前自检: 证明: 经验信息增益的非负性。 在“等号要求每个正概率项满足 $r_{ik}/p_{ik} = 1$, 即 $p_{ik} = p_i q_k$ ”成立时处理经验信息增益的非负性: 请把 $\sum_{i,k} p_{ik} \ln \frac{p_{ik}}{r_{ik}} \geq \sum_{i,k} (p_{ik} - r_{ik})$ 用到的关键定义展开并完成下一步变形, 并以对自然对数使用 $-\ln u \geq 1 - u$, 并取 $u = r_{ik}/p_{ik}$ 判定结果。

证明. 令 $p_{ik} = |D_{ik}|/|D|$ 、 $p_i = |D_i|/|D|$ 、 $q_k = |C_k|/|D|$ 。把熵差展开并合并同类项可写成

$$g(D, A) = \sum_{i,k: p_{ik} > 0} p_{ik} \log_2 \frac{p_{ik}}{p_i q_k}.$$

令 $r_{ik} = p_i q_k$ 。对自然对数使用 $-\ln u \geq 1 - u$, 并取 $u = r_{ik}/p_{ik}$, 得到

$$\sum_{i,k} p_{ik} \ln \frac{p_{ik}}{r_{ik}} \geq \sum_{i,k} (p_{ik} - r_{ik}) = 1 - 1 = 0.$$

换底只乘以正数 $1/\ln 2$, 所以 $g(D, A) \geq 0$ 。等号要求每个正概率项满足 $r_{ik}/p_{ik} = 1$, 即 $p_{ik} = p_i q_k$; 这正是经验独立性。反过来, 若经验独立, 则每个对数比为零, 信息增益也为零。□

几何理解

几何解释。 一次轴对齐测试把当前矩形或离散单元切成若干子区域; 递归测试把特征空间细化为叶区域。树越深, 划分边界越曲折, 能表示的局部模式越多, 同时每个区域可用于估计条件概率的样本通常越少。

概率解释

$H(D)$ 是当前叶区域内类别随机变量的经验不确定性, $H(D | A)$ 是观察特征取值后的剩余不确定性。信息增益是二者之差; 信息增益比再除以特征取值的不确定性, 以抑制仅靠大量取值记忆样本的候选。

读前自检: 优化解释: 每个结点执行有限候选集合上的局部最优化: ID3 最大化信息增益。 决策树结点在有限候选切分中比较 ID3 信息增益或 CART 不纯度下降; 请对一个候选按子集容量加权计算切分后不纯度, 核对只有目标改善最大的候选被选中。

优化解释

优化解释。 每个结点执行有限候选集合上的局部最优化: ID3 最大化信息增益; 经典 C4.5 先保留信息增益不低于候选平均值的切分, 再在该子集中最大化信息增益比; CART 最小化加

权平方误差或加权基尼指数。若跳过 C4.5 的第一层筛选，只能称为“直接最大化增益比的教学简化版”。局部最优切分不保证整棵树的全局最优，因此还需停止规则和剪枝控制模型复杂度。




图 15.1 决策树中的每条根到叶路径对应特征空间中的一个轴对齐区域。

图 15.1 左侧的每条根到叶路径都对应右侧一个互斥区域；叶结点输出只在该区域内生效。全部叶区域的并集覆盖输入空间时，树模型才对每个输入给出唯一预测。

例题 15.1 (八样本二叉划分的信息增益). 父结点有 8 个样本，正负类各 4 个。特征 A 把样本分成两个容量均为 4 的子集，其正负计数分别为 (3, 1) 和 (1, 3)。求特征 A 的信息增益。

例题 15.1 解答

读题翻译 要计算特征 A 带来的信息增益：先求划分前的类别熵，再求两个容量相同子集的加权条件熵，二者作差。

已知与合法条件 父结点共有八个样本，正负类各四个；两个子集容量均为四，类别计数分别为 (3, 1) 与 (1, 3)。本题统一使用以 2 为底的对数，结果单位为 bit。

为什么想到这个方法 信息增益定义为 $g(D, A) = H(D) - H(D | A)$ ；条件熵必须按子集容量 $|D_v|/|D|$ 加权，而不是对熵值再作无依据缩放。

方法选择 依次计算父熵、两个子熵与权重和，再得到条件熵和熵差；最后用四格经验联合分布计算互信息作独立核验。

推导/计算 父结点熵为

$$H(D) = -\frac{1}{2} \log_2 \frac{1}{2} - \frac{1}{2} \log_2 \frac{1}{2} = 1.$$

两个子集的熵相同：

$$H(D_1) = H(D_2) = -\frac{3}{4} \log_2 \frac{3}{4} - \frac{1}{4} \log_2 \frac{1}{4} = 2 - \frac{3}{4} \log_2 3 \approx 0.811278.$$

容量权重之和为 $4/8 + 4/8 = 1$, 所以

$$\begin{aligned} H(D|A) &= \frac{4}{8}H(D_1) + \frac{4}{8}H(D_2) \\ &= 2 - \frac{3}{4}\log_2 3, \\ g(D,A) &= \frac{3}{4}\log_2 3 - 1 \approx 0.188722. \end{aligned}$$

独立核验 直接由 2×2 经验联合表核验: 四格概率为 $3/8, 1/8, 1/8, 3/8$, 类别与特征边缘都为 $1/2$, 故

$$I(Y;A) = 2 \cdot \frac{3}{8} \log_2 \frac{3/8}{1/4} + 2 \cdot \frac{1}{8} \log_2 \frac{1/8}{1/4} \approx 0.188722,$$

与熵差一致, 且 $0 \leq g(D,A) \leq H(D) = 1$ 。

结论 特征 A 的信息增益为 $g(D,A) = \frac{3}{4}\log_2 3 - 1 \approx 0.188722$ bit。

读前自检: ID3 算法。 ID3 在当前结点计算全部候选特征的信息增益并按冻结并列规则取最大者; 请核对最大增益低于停止阈值时叶化, 否则按该特征各取值建立分支, 且流程不包含后剪枝。

15.4 ID3 与 C4.5 生成算法

ID3 在每个结点选择信息增益最大的特征, 按该特征的不同取值建立多个分支。它只负责生成树, 不包含后剪枝; 若阈值过小且特征较多, 容易形成对训练数据过细的划分。

读前自检: 决策树的生成。 决策树的生成中的“生成过程从根结点开始, 把当前结点的数据和可用特征视为一个状态”决定可执行范围; 请构造一个满足条件的最小结点状态并执行一次分支或停止判断, 结果须满足否则选择划分、建立子结点, 并把新的数据子集与删去已用离散特征后的候选集合传给子结点。

生成过程从根结点开始, 把当前结点的数据和可用特征视为一个状态。若状态满足叶条件就赋予多数类; 否则选择划分、建立子结点, 并把新的数据子集与删去已用离散特征后的候选集合传给子结点。

读前自检: ID3 的递归过程。 对 ID3 当前结点依次检查固定停止顺序: 样本已纯、候选特征为空、最佳信息增益低于阈值; 请分别写出叶标签, 核对后两种情形均采用当前数据多数类。

若当前数据全部属于同一类, 叶标签就是该类; 若特征集合为空, 叶标签取当前数据中的多数类; 若最佳信息增益低于阈值, 停止继续划分, 同样用多数类作为叶标签。这三类停止条件分别对应纯度、表示资源和最小改进。

读前自检: C4.5 生成算法。 C4.5 生成算法在当前结点的有限候选集 $\mathcal{C}_t$ 上, 先保留 $g(D_t, A) \geq |\mathcal{C}_t|^{-1} \sum_{B \in \mathcal{C}_t} g(D_t, B)$ 且 $H_A(D_t) > 0$ 的候选形成 $\mathcal{C}_t^+$; 请对一个给定候选 A 计算这两个量, 判定它是否进入 $\mathcal{C}_t^+$, 再只在 $\mathcal{C}_t^+$ 中比较信息增益比。

C4.5 的递归框架与 ID3 相同，但经典选择规则不是在全部分候选上直接最大化信息增益比。设当前结点的合法切分候选为有限集 $\mathcal{C}_t$ ，先计算

$$\bar{g}_t = \frac{1}{|\mathcal{C}_t|} \sum_{c \in \mathcal{C}_t} g(D_t, c), \quad \mathcal{C}_t^+ = \{c \in \mathcal{C}_t : g(D_t, c) \geq \bar{g}_t\},$$

再在 $\mathcal{C}_t^+$ 中选取信息增益比最大的候选；分母为零的候选不进入 $\mathcal{C}_t^+$ 。这样先保证原始信息增益不低，再比较归一化比值，避免一个增益与切分熵都很小的候选仅凭不稳定比值胜出。若实现使用另一个预先固定的增益阈值，必须明确标为变体并记录阈值。

读前自检：C4.5 的算法步骤。 C4.5 对离散特征采用多叉分支、对连续特征枚举阈值形成二分测试；请核对训练后保存分支规则、叶标签、默认路径与缺失值约定，并验证预测阶段不从测试数据重估这些规则。

ID3 与 C4.5 对离散特征可采用多叉分支；连续特征通常需要先枚举阈值形成二分测试。训练阶段必须保存分支规则、叶标签、默认路径和缺失值处理约定，预测时不能重新从测试数据估计这些规则。

读前自检：ID3/C4.5 统一递归生成流程：执行契约。 ID3/C4.5 统一递归流程以非空训练集 D 、候选特征与准则 q 为输入；请处理一个队首结点：满足纯度、容量、深度或改进停止条件时叶化，否则核验指标和严格分割后原子提交切分与子任务，并在队列 Q 为空时停止。

ID3/C4.5 统一递归生成流程：五步阅读

输入。 写出数据对象、固定参数与必须成立的条件。

初始化。 标明主状态、计数器和第一个合法状态。

核心更新。 只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。 写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。 列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 15.1: ID3/C4.5 统一递归生成流程

输入: 训练集 D ; 可用特征集 $\mathcal{A}$ 及类型 $\text{type}(\mathcal{A}) \in \{\text{discrete}, \text{continuous}\}$; 准则 $q \in \{\text{gain}, \text{ratio}\}$

输出: 最后合法的部分或完整决策树 T 、实际处理结点数 v 、**status** 与最终诊断

数据: 改进阈值 $\varepsilon \geq 0$; 最小叶容量 $n_{\min} \geq 1$; 深度上限 $h_{\max} \in \mathbb{N}$; 预先固定的并列与缺失值规则

- 1 $T \leftarrow \emptyset$, $Q \leftarrow \emptyset$, $v \leftarrow 0$, 诊断初始化为空
- 2 若 $D = \emptyset$ 、任务类别集合为空、样本或特征类型非法、 q 不合法、阈值参数越界、并列或缺失值规则未固定, 则返回空树、 $v = 0$ 、**invalid_input** 及字段诊断
- 3 初始化根结点, 令其状态为 $(D, \mathcal{A}, 0)$, 建立 $Q \leftarrow \{\text{root}\}$, 此时 T 是含一个待处理根的最后合法部分树
- 4 当 Q 中存在未处理结点 **执行**
- 5 取出结点 t 及其状态 $(D_t, \mathcal{A}_t, h_t)$ 若 D_t 同类, 或 $\mathcal{A}_t = \emptyset$, 或 $|D_t| < 2n_{\min}$, 或 $h_t = h_{\max}$ **则**
- 6 将 t 置为叶结点, 以 D_t 的多数类和类别频率作为输出; 令 $v \leftarrow v + 1$ 并继续下一结点
- 7 **结束**
- 8 对每个 $A \in \mathcal{A}_t$ 枚举合法切分: 离散特征枚举预定分组, 连续特征枚举当前 D_t 上的有限阈值 **若** 候选集为空 **则**
- 9 将 t 置为多数类叶结点; 令 $v \leftarrow v + 1$ 并继续下一结点
- 10 **结束**
- 11 为每个合法切分 c 计算 $g(D_t, c)$; 若 $q = \text{ratio}$, 再计算切分熵非零时的 $g_R(D_t, c)$ 若任一熵、信息增益或增益比求值失败或非有限, 则返回未改动的最后合法 $T, v, \text{numerical_failure}$ 及结点、候选诊断
- 12 若 $q = \text{gain}$, 在全部合法候选中最大化 g ; 若 $q = \text{ratio}$, 先保留 $g \geq \bar{g}_t$ 者, 再在其中最大化 g_R 选择切分 $c^* = (A^*, s^*)$, 并按预定规则处理并列 **若** c^* 的原始信息增益不超过 ε **则**
- 13 将 t 置为多数类叶结点; 令 $v \leftarrow v + 1$ 并继续下一结点
- 14 **结束**
- 15 在临时状态按 c^* 建立至少两个候选子集 $D_{t1}, \dots, D_{tr}$ 若 $\text{type}(A^*) = \text{discrete}$ 且按一次性多叉规则使用, 令 $\mathcal{A}_{ti} \leftarrow \mathcal{A}_t \setminus \{A^*\}$ 若 $\text{type}(A^*) = \text{continuous}$, 令 $\mathcal{A}_{ti} \leftarrow \mathcal{A}_t$ 并只在结点 t 记录阈值 s^* 核验子集互斥、并集为 D_t 且沿每个分支严格缩小; 失败则返回未改动的 $T, v, \text{numerical_failure}$ 及划分不变量诊断
- 16 提交切分, 对每个子结点写入状态 $(D_{ti}, \mathcal{A}_{ti}, h_t + 1)$ 并加入 Q , 令 $v \leftarrow v + 1$
- 17 **结束**
- 18 返回完整 $T, v, \text{completed}$, 最终诊断记录叶数、最大深度、数值候选数与并列处理次数

停止与终止性。当 Q 为空时停止, 返回有限树 T 。每次有效切分都把当前样本集分成非空真子集, 所以沿任一路径样本数严格减少; 同时深度显式受 $h_{\max}$ 限制, 且当前样本上的连续阈值候选有限。因此路径长度至多 $\min\{h_{\max}, |D| - 1\}$, 即使连续特征在后继结点复用, 流程也有限终止。

参数含义。 q 决定使用信息增益还是信息增益比; ε 控制必须达到的最小局部改进; $n_{\min}$ 限制叶结点容量。阈值越宽松, 树通常越大, 但生成阶段的树大小不能代替验证集上的模型选择。

初始化方法。根结点接收全部训练样本和全部候选特征; 多数类、并列处理、未见取值与缺失值规则应在训练前固定。连续特征候选阈值只能由当前训练子集产生。

参数更新规则。每次扩张后, 子结点的数据改为对应非空真子集; 对一次性离散特征, 从路径的候选集合删除已使用特征; 连续特征保留在候选集合中, 当前阈值只属于当前结点。结点输出的类别频率由该结点训练样本重新计算。

停止条件。同类、无可用特征、容量不足、最佳改进不超过阈值或达到预定深度时停止。停止后叶标签取当前结点多数类, 而不是全局多数类。

收敛与终止性。该流程不是连续参数迭代的极限收敛；它依靠有限状态严格终止。每次有效扩张至少把一个结点变为内部结点，并使任一子路径上的样本数严格减少；深度还受 $h_{\max}$ 限制。离散特征删除只是额外的有限性保证，不是连续特征情形的终止依据。

读前自检：决策树剪枝。决策树剪枝以“完全生长的树往往把训练样本的偶然波动编码为细小分支”为约束；请构造一个满足条件的最小结点状态并执行一次分支或停止判断，并确认剪枝从已生成的树中收缩子树或删除叶结点，使父结点成为新叶，以较小的训练拟合损失增加换取明显的复杂度下降。

15.5 决策树剪枝

完全生长的树往往把训练样本的偶然波动编码为细小分支。剪枝从已生成的树中收缩子树或删除叶结点，使父结点成为新叶，以较小的训练拟合损失增加换取明显的复杂度下降。

读前自检：树的剪枝算法。树的剪枝算法输入“生成完成的有限树 T 、守恒结点计数与有限复杂度参数 α ”，条件“ T 非空无环”；请做一轮“仅在候选树计数和代价核验成功后提交局部收缩并增加 p ”，以“ Q 为空或首次失败时停止”核对停止证书。

对分类树 T ，设叶结点 t 有 N_t 个样本，其中第 k 类有 N_{tk} 个，叶经验熵为

$$H_t(T) = - \sum_{k=1}^K \frac{N_{tk}}{N_t} \log \frac{N_{tk}}{N_t}.$$

定义训练拟合项和代价复杂度目标

$$C(T) = \sum_{t=1}^{|T|} N_t H_t(T), \quad C_\alpha(T) = C(T) + \alpha |T|, \quad \alpha \geq 0.$$

α 越大，减少一个叶所节省的复杂度代价越重要； $\alpha = 0$ 时只比较训练拟合。

给定的自底向上熵剪枝：五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 15.2: 给定 α 的自底向上熵剪枝

输入: 生成完成的树 T ; 各结点训练样本计数; 复杂度参数 $\alpha \geq 0$

输出: C_α 不再因局部收缩而下降的最后合法子树 T_α 、实际比较数 v 、实际剪枝数 p 、**status** 与最终诊断

- 1 初始化当前树 $T' \leftarrow T$ 、工作表 $Q \leftarrow \emptyset$ 、 $v \leftarrow 0$ 、 $p \leftarrow 0$ ，诊断为空
- 2 若 T 为空、 α 非有限或 $\alpha < 0$ ，或结点计数缺失、为负、非整数或前后不守恒，则返回未改动的 T' 、计数 0、**invalid_input** 及字段诊断
- 3 把原树内部结点按深度非增、固定并列次序放入 Q
- 4 **当 $Q \neq \emptyset$ 执行**
- 5 从 Q 取出下一内部结点 t
- 6 在临时变量中计算保留以 t 为根子树和收缩为多数类单叶时的局部 C_α 贡献
- 7 若任一熵、代价或差值求值失败或非有限，则返回未改动的最后合法 T' 、 v 、 p 、**numerical_failure** 及失败结点诊断
- 8 $v \leftarrow v + 1$
- 9 **若** 收缩后的贡献不大于保留贡献 **则**
- 10 在候选树中删除 t 的后代并把 t 置为叶；核验计数与代价后提交 T' ，令 $p \leftarrow p + 1$ ；核验失败则返回原 T' 与 **numerical_failure** 诊断
- 11 **结束**
- 12 **结束**
- 13 返回 $T_\alpha \leftarrow T'$ 、 v 、 p 、**completed**，最终诊断记录最终 C_α 、叶数和“无可改进局部收缩”

剪枝比较只需计算被收缩子树与新叶的局部目标差，因为树外部分在两个候选中完全相同。验证集仍应用于选择 α 或候选子树；训练目标较小并不保证样本外误差较小。

读前自检：CART 算法。 CART 先生成充分生长树，再按代价复杂度构造由大到小的嵌套子树序列；请用独立验证损失比较该序列，核对最终树来自序列且测试集未参与选择。

15.6 CART 分类与回归树

CART 统一处理分类和回归，并约束每个内部结点执行二叉切分。生成阶段尽量生长较大的树，剪枝阶段构造嵌套子树序列，再用独立验证信息选择最终子树。

读前自检：CART 生成。 CART 回归树在候选切分 (j, s) 下形成 R_1, R_2 ；请先把各区响应均值代入 c_1, c_2 ，再计算两区平方残差和，核对使该和最小的 (j, s) 才被提交。

回归树使用平方误差最小化选择切分变量 j 与切分点 s ：

$$R_1(j, s) = \{x : x^{(j)} \leq s\}, \quad R_2(j, s) = \{x : x^{(j)} > s\},$$

$$\min_{j, s} \left[\min_{c_1} \sum_{x_i \in R_1(j, s)} (y_i - c_1)^2 + \min_{c_2} \sum_{x_i \in R_2(j, s)} (y_i - c_2)^2 \right].$$

读前自检：最小二乘回归树生成算法。 最小二乘回归树最终得到区域 $R_1, \dots, R_M$ ；请计算每区均值 $\hat{c}_m = N_m^{-1} \sum_{x_i \in R_m} y_i$ 并写出 $f(x) = \sum_{m=1}^M \hat{c}_m \mathbf{1}\{x \in R_m\}$ ，核对每个 x 只落入一个区域。

选定切分后，对两个子区域继续递归划分。最终区域为 $R_1, \dots, R_M$ 时，回归树写为

$$f(x) = \sum_{m=1}^M \hat{c}_m \mathbf{1}\{x \in R_m\}, \quad \hat{c}_m = \frac{1}{N_m} \sum_{x_i \in R_m} y_i.$$

读前自检：平方误差叶结点的最优常数。 给定非空叶区域响应 $y_1, \dots, y_m$ ，请对 $Q(c) = \sum_{i=1}^m (y_i - c)^2$ 求导，核对唯一驻点 $c = \bar{y} = m^{-1} \sum_i y_i$ 且二阶导数为 $2m > 0$ 。

定理 15.2(平方误差叶结点的最优常数) 给定非空叶区域 R 及其中响应 $y_1, \dots, y_m$ ，函数 $Q(c) = \sum_{i=1}^m (y_i - c)^2$ 的唯一最小点为样本均值 $\bar{y} = m^{-1} \sum_i y_i$ 。

读前自检：证明：平方误差叶结点的最优常数。 围绕平方误差叶结点的最优常数，先采用条件“对任意 c ，写 $y_i - c = (y_i - \bar{y}) + (\bar{y} - c)$ ”，再把 $Q(c)$ 用到的关键定义展开并完成下一步变形；最后验证因此 $\bar{y}$ 取得唯一最小值。

证明。 对任意 c ，写 $y_i - c = (y_i - \bar{y}) + (\bar{y} - c)$ 。展开平方和得

$$Q(c) = \sum_i (y_i - \bar{y})^2 + 2(\bar{y} - c) \sum_i (y_i - \bar{y}) + m(\bar{y} - c)^2.$$

由均值定义， $\sum_i (y_i - \bar{y}) = 0$ ，所以中间项为零。第一项与 c 无关，第三项非负且仅在 $c = \bar{y}$ 时为零。因此 $\bar{y}$ 取得唯一最小值。 $\square$

分类问题中，类别概率为 $p_1, \dots, p_K$ 时，基尼指数为

$$\text{Gini}(p) = \sum_{k=1}^K p_k(1 - p_k) = 1 - \sum_{k=1}^K p_k^2.$$

样本集合 D 的经验基尼指数为 $1 - \sum_k (|C_k|/|D|)^2$ 。若测试把 D 分成 D_1, D_2 ，则切分后的加权基尼指数为

$$\text{Gini}(D, A) = \frac{|D_1|}{|D|} \text{Gini}(D_1) + \frac{|D_2|}{|D|} \text{Gini}(D_2).$$

读前自检：CART 生成算法。 CART 生成算法中的“分类 CART 枚举特征与二值切分，选择加权基尼指数最小的候选”决定可执行范围；请把“分类 CART 枚举特征与二值切分，选择加权基尼指数最小的候选”中的已声明对象代回 CART 生成算法的定义，结果须满足两者使用同一递归骨架，但叶输出和局部损失不同，不能把基尼指数用于连续响应回归。

分类 CART 枚举特征与二值切分，选择加权基尼指数最小的候选；回归 CART 选择子区域平方误差和最小的候选。两者使用同一递归骨架，但叶输出和局部损失不同，不能把基尼指数用于连续响应回归。

读前自检：CART 生成与候选树构造：执行契约。 CART 生成与候选树构造输入“有限训练集 D 、分类或回归任务类型 r 与 CART 停止参数”，条件“ $D \neq \emptyset$ ”；请执行“有限损失与严格二分不变量核验后才提交左右子结点并增加 v ”，以“ Q 为空或首次失败时停止”判停。

读前自检：CART 生成与候选树构造。 CART 生成与候选树构造输入“有限训练集 D 、分类或回归任务类型 r 与 CART 停止参数”，条件“ $D \neq \emptyset$ ”；请做一轮“有限损失与严格二分不变量检验后才提交左右子结点并增加 v ”，以“ Q 为空或首次失败时停止”核对停止证书。

算法 15.3: CART 生成与候选树构造

输入: 训练集 D ；任务类型 $r \in \{\text{classification, regression}\}$
输出: 最后合法的部分或充分生长二叉树 T_0 、结点统计、实际处理结点数 v 、**status** 与最终诊断
数据: 最小叶容量 $n_{\min}$ ；最小损失下降 η ；最大深度 $h_{\max}$ ；固定并列与缺失值规则

- 1 $T_0 \leftarrow \emptyset$, $Q \leftarrow \emptyset$, $v \leftarrow 0$, 诊断初始化为空
- 2 若 $D = \emptyset$ 、任务类型 r 不合法、样本/响应非有限，容量、下降、深度参数越界，或并列/缺失值规则未固定，则返回空树、 $v = 0$, **invalid_input** 及字段诊断
- 3 初始化根结点状态为 D , $Q \leftarrow \{\text{root}\}$, 把含待处理根的 T_0 作为最后合法部分树
- 4 **当** Q 非空 **执行**
- 5 取出结点 t
- 6 **若** t 达到 $h_{\max}$ 或所含样本少于 $2n_{\min}$ **则**
- 7 写入分类多数类/频率或回归均值；令 $v \leftarrow v + 1$ 并继续下一结点
- 8 **结束**
- 9 枚举所有满足两侧容量约束的 (j, s) **若** 无合法切分 **则**
- 10 写入分类多数类/频率或回归均值；令 $v \leftarrow v + 1$ 并继续下一结点
- 11 **结束**
- 12 分类时计算加权基尼指数，回归时计算两侧最小平方误差和若任一候选损失、叶统计或下降量求值失败或非有限，则返回未改动的最后合法 $T_0, v, \text{numerical_failure}$ 及结点、候选诊断
- 13 选择目标最小的 (j^*, s^*) ，并计算相对父结点的损失下降**若** 下降不超过 η **则**
- 14 分类叶输出多数类和频率；回归叶输出响应均值；令 $v \leftarrow v + 1$ 并继续下一结点
- 15 **结束**
- 16 在临时状态按 (j^*, s^*) 建立左右非空真子集；若容量、互斥、覆盖或严格缩小不变量失败，则返回未改动的 $T_0, v, \text{numerical_failure}$ 及划分诊断
- 17 提交左右子结点，写入统计并加入 Q ，令 $v \leftarrow v + 1$
- 18 **结束**
- 19 返回有限树 $T_0, v, \text{completed}$ ，最终诊断记录叶数、最大深度、候选求值数和最终训练损失

读前自检：CART 剪枝。 CART 剪枝对内部结点 t 比较单叶损失 $C(t)$ 与子树损失 $C(T_t)$ ；请由两者代价取等推得 $g(t) = [C(t) - C(T_t)]/(|T_t| - 1)$ ，并核对分子两项采用同一损失口径。

CART 从充分生长树 T_0 出发，经典代价复杂度剪枝使用

$$C_\alpha(T) = C(T) + \alpha|T|$$

评价子树。经典分类 CART 的 $C(T)$ 取叶内重代入误分类风险，回归 CART 取叶内平方误差；用叶内 Gini 和代替分类误分类风险是常见的教学或工程简化变体，必须在实现中单独标明，并始终用同一损失计算 $C(t)$ 与 $C(T_t)$ 。随着 α 增大，最优子树从大到小变化。

对内部结点 t ，记以 t 为根的子树为 T_t 。把 T_t 收缩为单叶 t 时，两者代价相等的临界参数满足

$$C(t) + \alpha = C(T_t) + \alpha|T_t|,$$

所以

$$g(t) = \frac{C(t) - C(T_t)}{|T_t| - 1}.$$

当前树中 $g(t)$ 最小的内部结点最先成为“最弱环节”；同时剪去所有达到最小值的结点，可生成嵌套子树序列。

读前自检：CART 最弱环节剪枝算法。 CART 最弱环节剪枝算法输入“有限充分生长树 T_0 、一致口径的结点与子树训练损失、独立验证集和固定并列规则”，条件“ T_0 非空有限且无环”；请做一轮“在临时表核验分母和损失，生成严格更小的候选树后才提交 T 并加入 $\mathcal{S}$ ”，以“树收缩为根叶后完成序列，再以验证损失选树”核对停止证书。

读前自检：CART 最弱环节剪枝。 CART 最弱环节剪枝输入“有限充分生长树 T_0 、一致口径的结点与子树训练损失、独立验证集和固定并列规则”，条件“ T_0 非空有限且无环”；请做一轮“在临时表核验分母和损失，生成严格更小的候选树后才提交 T 并加入 $\mathcal{S}$ ”，以“树收缩为根叶后完成序列，再以验证损失选树”核对停止证书。

CART 最弱环节剪枝：五步阅读

输入。 写出充分生长树、统一口径的训练损失、独立验证集与并列规则。

初始化。 从 $T = T_0$ 、 $\mathcal{S} = \{T_0\}$ 和零计数开始。

核心更新。 计算所有内部结点的 $g(t)$ ，同时剪去最小者，并只提交严格变小的候选树。

数学停止。 树收缩为根叶时序列构造有限终止；这不是连续参数收敛。

输出。 返回嵌套序列、验证选中的 T^* 、实际计数、中心状态和诊断。

算法 15.4: CART 最弱环节剪枝

输入: 充分生长树 T_0 及每个结点、子树的训练损失; 独立验证集与固定并列规则

输出: 最后合法嵌套序列 $\mathcal{S} = (T_0, \dots, T_k)$ 、验证选择 T^* 、实际剪枝轮数 k 、实际 $g(t)$ 评价数 v 、**status** 与最终诊断

- 1 $k \leftarrow 0, v \leftarrow 0$, 当前树 $T \leftarrow \emptyset$, 候选序列 $\mathcal{S} \leftarrow \emptyset, T^* \leftarrow \perp$, 诊断初始化为空
- 2 若 T_0 为空、损失缺失或非有限、叶计数不合法、树结构含环或验证集/并列规则不可用, 则返回空序列、计数 0、**invalid_input** 及字段诊断
- 3 $T \leftarrow T_0, \mathcal{S} \leftarrow \{T_0\}$; 若 T 只含根叶, 则令 $T^* \leftarrow T_0$ 并返回 $\mathcal{S}, T^*, k = 0, v = 0, \text{completed}$ 及“无需剪枝”诊断
- 4 **当 T 不只含根叶 执行**
- 5 自底向上在临时表计算每个内部结点 t 的 $g(t) = [C(t) - C(T_t)]/(|T_t| - 1)$, 每次合法计算令 $v \leftarrow v + 1$
- 6 若分母非正、任一 $g(t)$ 求值失败或非有限, 则返回最后合法 $\mathcal{S}$ 、未定义 T^* 、 $k, v, \text{numerical_failure}$ 及失败结点诊断
- 7 令 $\alpha_k \leftarrow \min_t g(t)$; 在候选树中同时把所有满足 $g(t) = \alpha_k$ 的最弱子树收缩为叶并更新输出
- 8 若候选树未严格减少结点、损失或统计不合法, 则返回未改动的 $T, \mathcal{S}, k, v, \text{numerical_failure}$ 及剪枝不变量诊断
- 9 提交候选树为 T
- 10 令 $k \leftarrow k + 1$, 把更新后的树记为 T_k 并加入 $\mathcal{S}$
- 11 **结束**
- 12 在独立验证集上评价 $\mathcal{S}$ 中的每棵树; 若任一验证损失非有限, 则返回完整候选序列、未定义 T^* 、 $k, v, \text{numerical_failure}$ 及树序号诊断
- 13 按预定并列规则选择 T^* , 返回 $\mathcal{S}, T^*, k, v, \text{completed}$, 最终诊断记录候选数、所选树索引与验证损失

算法实现说明: 工程层只需核验树无环、损失有限、每轮结点数严格减少, 并记录验证并列规则; 同一轮必须同时剪去全部最小 $g(t)$ 子树, 才能得到可复现的嵌套序列。完整 C1-C14 契约

有限步终止。生成、局部剪枝与最弱环节剪枝都在有限样本、有限特征和有限树结点上执行, 每次生成使可用特征或深度预算减少, 每次剪枝使结点数严格减少, 因此有限终止; 它们不是连续参数迭代。输入不满足条件、损失不是有限实数或验证集不可用时, 算法停止并说明原因。

复杂度分析

复杂度假设。以下界假设 d 个特征可逐结点顺序访问; “重新排序”与“预排序”分别按文中两种实现计, 结点统计可缓存并原位更新。平衡树界需要树高为对数量级, 链式退化树使用最坏界; 复制数据而非保存索引会额外增加内存。设样本数为 N 、特征数为 d 、最终树结点数为 $|T|$ 、树高为 h , 待预测样本数为 M 。

训练复杂度。若每个数值特征在结点内重新排序, 含 m 个样本的结点扫描成本为 $O(dm \log m)$; 预排序并维护计数可把一次扫描降至 $O(dm)$ 。平衡树的总扫描量常为 $O(dN \log N)$, 高度接近 N 时最坏可达 $O(dN^2)$ 。

令充分生长树有 $V = |T_0|$ 个结点。最弱环节剪枝若每一阶段都遍历全部内部结点, 并为每个候选重新遍历其整棵子树以计算 $C(T_t)$ 与 $|T_t|$, 至多 $O(V)$ 个阶段给出朴素上界 $O(V^3)$ 时间、 $O(V)$ 额外空间; 若先以后序遍历缓存每个结点的叶数和子树损失, 但每阶段仍全表扫描, 则时间降为 $O(V^2)$ 。进一步维护父指针、缓存统计和以 $g(t)$ 为键的可更新优先队列时, 初始化为 $O(V)$, 每次剪枝只更新受影响祖先; 总时间可写成 $O(Vh \log V)$ 、额外空间 $O(V)$, 其中 h

为树高。平衡树时该界为 $O(V \log^2 V)$ ，退化链仍可能达到 $O(V^2 \log V)$ ；这些增量界都依赖缓存与堆实现，不能无条件称为近线性。

预测复杂度。单个输入沿一条根到叶路径执行至多 h 次特征判断，时间为 $O(h)$ ； M 个输入为 $O(Mh)$ 。平衡树常有 $h = O(\log |T|)$ ，退化链式树则有 $h = O(|T|)$ 。

存储复杂度。保存数据与特征通常需要 $O(Nd)$ 空间，树结构和结点统计需要 $O(|T|)$ 空间；深度优先遍历额外栈空间为 $O(h)$ 。若为每个结点复制完整样本矩阵，内存会远高于 $O(Nd + |T| + h)$ 这一存储界，实践中应保存样本索引或原位分区。

15.7 例题、树模型计算与练习

以下例题把前六节的模型与算法串联为统一流程，用于比较树的生成、剪枝、预测与评价步骤。

ID3 复现。在每个训练子集计算信息增益，按最大值生成二叉树，并把阈值、并列规则与叶容量一并记录。

C4.5 复现。保持相同递归骨架，把局部准则换为信息增益比，并排除取值熵为零或原始增益不足的候选。

熵剪枝复现。对固定 α 自底向上比较子树和单叶的 C_α ，直到没有局部收缩能降低目标。

最小二乘树复现。每个连续特征扫描候选阈值，选择左右区域平方误差和最小的切分，叶输出取区域响应均值。

CART 生成复现。分类任务最小化加权基尼指数，回归任务最小化平方误差；两者都生成二叉树并保存结点统计。

CART 剪枝复现。由 $g(t)$ 最小的内部结点逐轮产生嵌套子树，再用独立验证数据选择最终模型，测试数据只用于一次最终评估。

适用条件与局限性

适用条件。决策树适合同时含离散与连续特征、需要规则解释、特征交互明显或不宜假设线性边界的任务；CART 还能统一处理分类和回归。数据应覆盖将要部署的主要分支，叶容量要足以估计输出。

方法局限。贪心生成不保证全局最优；小数据扰动可能改变上层切分；轴对齐树表示斜边界时可能需要很多叶；未经校准的叶频率在小叶上不稳定；高基数特征、缺失值和类别不平衡都需要专门处理。

读前自检：常见错误与误用边界：例题、树模型计算与练习。 决策树计算若漏掉子集容量权重，会把很小的纯叶与大叶等量对待；请用 $H(D|A) = \sum_v |D_v| H(D_v) / |D|$ 重算一次，核对各权重非负且和为 1。

常见错误

典型误用包括：条件熵不按子集容量加权；把信息增益与信息增益比混为同一量；对 $H_A(D) = 0$ 执行除法；把 ID3 误写成基尼准则；把 CART 分类树写成二叉树；回归叶不取均值；用测

试集选择深度或子树；只报告训练纯度；剪枝时删除单个叶而破坏完备路径；在最薄弱环节公式中把分母写成 $|T_t|$ 而漏掉减 1。

读前自检：易混淆概念对比：例题、树模型计算与练习。 对例题、树模型计算与练习，条件“对比表首个数据行是“局部准则 | 信息增益最大 | 先筛选不低于平均增益，再令增益比最大 | 分类基尼最小；回归平方误差最小””不可省；请按列复述“局部准则 | 信息增益最大 | 先筛选不低于平均增益，再令增益比最大 | 分类基尼最小；回归平方误差最小”中的对象、假设与结论，再用各列均对应首行对象“局部准则”，且未与表中下一行互换作检查。

易混淆概念对比			
维度	ID3	C4.5	CART
局部准则	信息增益最大	先筛选不低于平均增益，再令增益比最大	分类基尼最小；回归平方误差最小
典型分支	离散特征多叉	离散多叉并可扩展连续阈值	始终二叉
任务	主要用于分类	主要用于分类	分类与回归
复杂度控制	需另加停止或剪枝	需另加停止或剪枝	最薄弱环节剪枝与验证选择
高基数偏好	较明显	由取值熵归一化缓和	受二值切分和验证控制

例题 15.2 (信息增益与基尼一致选择纯划分). 某二分类根结点有 8 个样本，正负类各 4 个。候选特征 A 产生两个等大子集，类别计数为 $(3,1)$ 与 $(1,3)$ ；候选特征 B 产生两个等大纯子集，类别计数为 $(4,0)$ 与 $(0,4)$ 。分别按信息增益和加权基尼指数选择根特征。

例题 15.2 解答

读题翻译 要分别按“信息增益最大”和“划分后加权基尼最小”比较候选 A,B ，并判断两种准则是否选择同一根特征。

已知与合法条件 父结点正负各 4；两个候选都产生容量为 4,4 的子集，故子结点权重均为 1/2； A 的计数为 $(3,1),(1,3)$ ， B 的两个子结点均纯。

为什么想到这个方法 同一划分的熵和基尼都按子结点样本比例加权；纯结点的两种不纯度都为零。

方法选择 计算父熵；分别求 A,B 的条件熵和信息增益；再求两者的加权基尼，并按各自方向选择。

推导/计算 父结点熵及两个候选的条件熵为

$$\begin{aligned} H(D) &= 1, \\ H(D|A) &= \frac{1}{2}H\left(\frac{3}{4}, \frac{1}{4}\right) + \frac{1}{2}H\left(\frac{1}{4}, \frac{3}{4}\right) \approx 0.811, \\ H(D|B) &= 0. \end{aligned}$$

因此

$$g(D, A) \approx 1 - 0.811 = 0.189, \quad g(D, B) = 1 - 0 = 1,$$

信息增益选择 B 。基尼指标方面,

$$\begin{aligned} \text{Gini}(D) &= 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = \frac{1}{2}, \\ \text{Gini}(D|A) &= \frac{1}{2} \left[1 - \left(\frac{3}{4}\right)^2 - \left(\frac{1}{4}\right)^2 \right] + \frac{1}{2} \left[1 - \left(\frac{1}{4}\right)^2 - \left(\frac{3}{4}\right)^2 \right] \\ &= 0.375, \\ \text{Gini}(D|B) &= 0. \end{aligned}$$

独立核验 两个子结点权重之和为 1。候选 B 使熵和基尼同时达到非负不纯度的下界 0, 所以其信息增益达到父熵 1, 无需依赖近似值即可确认最优。

结论 信息增益选择 B (增益 $1 > 0.188722$), 加权基尼也选择 B ($0 < 0.375$); 切分后两个子结点均纯净。

贯穿例：四点二维分类数据

本章角色：用同一训练集检验一次轴对齐划分怎样得到纯叶结点。

四个样本的第一坐标恰好决定标签, 因此根结点按 $x^{(1)} < 0$ 划分后, 两侧分别只含 -1 类与 $+1$ 类。父结点的经验熵为 1、基尼指数为 $1/2$, 两个子结点的熵和基尼指数均为 0; 信息增益为 1, 加权基尼下降为 $1/2$ 。该结论依赖本例存在轴对齐纯划分, 不能外推为任意线性可分数据都能由单层树表示。上一站见朴素贝叶斯的生成式表示; 下一站见逻辑斯谛回归的概率表示。

本章共 12 道练习。每道题干后立即给出同号解析; 长解析可自然跨页, 续页标题保留题号。

【原书练习整理】

练习 15.1. 给定训练数据

$$\begin{aligned} (x_i)_{i=1}^{10} &= (1, 2, 3, 4, 5, 6, 7, 8, 9, 10), \\ (y_i)_{i=1}^{10} &= (4.50, 4.75, 4.91, 5.34, 5.80, 7.05, 7.90, 8.23, 8.70, 9.00). \end{aligned}$$

使用平方误差准则生成二叉回归树的根结点: 枚举相邻样本之间的切分点, 确定最优第一次切分、两侧叶输出及切分后的平方误差, 并说明继续递归时必须补充什么停止规则。

练习 15.1 解析

候选切分点与每个候选的叶输出、平方误差定义为

$$s_j = \frac{x_j + x_{j+1}}{2} = j + \frac{1}{2}, \quad j = 1, \dots, 9,$$

$$c_L(s_j) = \frac{1}{j} \sum_{i=1}^j y_i, \quad c_R(s_j) = \frac{1}{10-j} \sum_{i=j+1}^{10} y_i,$$

$$Q(s_j) = \sum_{i=1}^j (y_i - c_L(s_j))^2 + \sum_{i=j+1}^{10} (y_i - c_R(s_j))^2.$$

逐候选计算得到

s_j	1.5	2.5	3.5	4.5	5.5	6.5	7.5	8.5	9.5
$Q(s_j)$	22.6480	17.7022	12.1935	7.3787	3.3587	5.0740	10.0525	15.1778	21.3280

最小值在 $j = 5$ 取得, 且

$$c_L(5.5) = \frac{25.30}{5} = 5.060, \quad c_R(5.5) = \frac{40.88}{5} = 8.176.$$

因此根结点的一次切分模型为

$$\hat{f}(x) = 5.060 \mathbf{1}\{x \leq 5.5\} + 8.176 \mathbf{1}\{x > 5.5\}, \quad Q(5.5) \approx 3.3587.$$

后续对子区域重复枚举; 必须同时规定最小叶容量、最小损失下降或最大深度, 否则分裂到单样本叶可使训练误差为 0, 却通常具有较高方差。

练习 15.2. 一棵二分类树先判断 $A = 1$, 若成立预测正类; 否则再判断 $B = 1$, 成立预测正类, 不成立预测负类。写出三条互斥完备规则。

练习 15.2 解析

三条叶规则对应集合

$$R_1 = \{x : A(x) = 1\}, \quad \hat{y}(x) = +1,$$

$$R_2 = \{x : A(x) \neq 1, B(x) = 1\}, \quad \hat{y}(x) = +1,$$

$$R_3 = \{x : A(x) \neq 1, B(x) \neq 1\}, \quad \hat{y}(x) = -1.$$

它们满足

$$R_i \cap R_j = \emptyset \quad (i \neq j), \quad R_1 \cup R_2 \cup R_3 = \mathcal{X}.$$

第二、三条必须保留祖先条件 $A \neq 1$, 否则会与第一条重叠。

练习 15.3. 解释为何叶区域构成划分时，条件概率模型可以逐叶定义；若两条路径覆盖同一输入，会出现什么问题？

练习 15.3 解析

设叶区域为 $\{R_m\}_{m=1}^M$ 。树的标准语义要求

$$\bigcup_{m=1}^M R_m = \mathcal{X}, \quad R_m \cap R_{m'} = \emptyset \quad (m \neq m').$$

于是每个 x 有唯一指标 $m(x)$ ，条件概率可逐叶定义为

$$P(Y = c | X = x) = p_{m(x),c}, \quad \sum_c p_{m,c} = 1.$$

若存在 $x \in R_m \cap R_{m'}$ 且 $m \neq m'$ ，则同一输入可能同时得到 $p_{m,\cdot}$ 与 $p_{m',\cdot}$ ，映射不再单值。额外优先级或混合权重会定义另一种模型，而不是原树语义。

练习 15.4. 某特征是每个训练样本唯一的编号。说明它为何可能取得极高信息增益，并说明为何不应据此认为它具有预测价值。

练习 15.4 解析

若编号特征 A 在 N 个训练样本上取 N 个不同值，则每个子集 D_v 只有一个样本：

$$|D_v| = 1 \implies H(D_v) = 0.$$

因此

$$H(D | A) = \sum_v \frac{|D_v|}{N} H(D_v) = 0, \quad g(D, A) = H(D).$$

该最大增益来自逐样本记忆。对未见编号 $v_{\text{new}} \notin \{v_i\}_{i=1}^N$ ，训练数据没有可复用的叶统计，故高训练增益不蕴含预测价值。应限制高基数特征、使用增益比，并以独立验证和剪枝检验泛化。

练习 15.5. 为什么在树生成前用全部数据筛选特征，再做交叉验证，会使验证误差偏乐观？给出正确流程。

练习 15.5 解析

设第 r 折训练、验证索引分别为 $I_r^{\text{tr}}, I_r^{\text{val}}$ 。无泄漏要求特征集合仅由训练折确定：

$$\begin{aligned} \mathcal{F}_r &= \text{Select}(X_{I_r^{\text{tr}}}, y_{I_r^{\text{tr}}}), \\ \text{Inputs}(\mathcal{F}_r) &= \{X_{I_r^{\text{tr}}}, y_{I_r^{\text{tr}}}\}, \\ y_{I_r^{\text{val}}} &\notin \text{Inputs}(\mathcal{F}_r). \end{aligned}$$

随后

$$f_r = \text{FitTree}(X_{I_r^{\text{tr}}}, \mathcal{F}_r, y_{I_r^{\text{tr}}}), \quad L_r = L(f_r; X_{I_r^{\text{val}}}, \mathcal{F}_r, y_{I_r^{\text{val}}}).$$

练习 15.5 解析 (续)

若先用全部数据选择 $\mathcal{F}$, 则 $y_{I^{\text{val}}} \rightarrow \mathcal{F} \rightarrow f_r$, 验证标签已影响模型, 误差会偏乐观。超参数锁定后, 才在全部开发数据上重做同一流程。

练习 15.6. 某结点类别计数为 (6, 2)。求以 2 为底的经验熵, 并说明若 8 个样本全属同一类时熵为何变化。

练习 15.6 解析

经验类别概率为

$$(p_1, p_2) = \left(\frac{6}{8}, \frac{2}{8}\right) = \left(\frac{3}{4}, \frac{1}{4}\right).$$

因此

$$H(D) = -\frac{3}{4} \log_2 \frac{3}{4} - \frac{1}{4} \log_2 \frac{1}{4} \approx 0.811 \text{ 比特}.$$

若 8 个样本全属一类, 则概率向量为 (1, 0)。约定 $0 \log_2 0 = 0$ 后,

$$H(D) = -1 \log_2 1 - 0 \log_2 0 = 0.$$

前者仍有类别不确定性, 后者在训练样本上已经纯净。

练习 15.7. 父结点熵为 1。特征 A 产生容量 2 和 6 的两个子结点, 熵分别为 0 和 0.8。求条件熵和信息增益。

练习 15.7 解析

条件熵按子集容量加权:

$$H(D | A) = \frac{2}{8} \times 0 + \frac{6}{8} \times 0.8 = 0.6.$$

故信息增益为

$$g(D, A) = H(D) - H(D | A) = 1 - 0.6 = 0.4.$$

若误用普通平均, 则

$$\frac{0 + 0.8}{2} = 0.4, \quad 1 - 0.4 = 0.6,$$

会忽略两个子集容量不同这一事实。

练习 15.8. 说明 ID3 与 C4.5 在递归框架、划分准则和高基数特征偏好上的共同点与差异。

练习 15.8 解析

两者共享递归框架

$$(D_t, \mathcal{A}_t) \xrightarrow{\text{选择}(A^*, s^*)} \{(D_{t,v}, \mathcal{A}'_{t,v})\}_v,$$

其中一次性离散特征取 $\mathcal{A}'_{t,v} = \mathcal{A}_t \setminus \{A^*\}$, 连续特征取 $\mathcal{A}'_{t,v} = \mathcal{A}_t$ 并只把阈值 s^* 记在当前结点; 并在结点纯净、候选耗尽、样本或深度预算耗尽、改进不足时停止。划分准则分别为

$$A_{\text{ID3}}^* = \arg \max_{A \in \mathcal{A}_t} g(D_t, A),$$

练习 15.8 解析 (续)

以及

$$A_{C4.5}^* = \arg \max_{A \in \mathcal{C}_t^+} \frac{g(D_t, A)}{H_A(D_t)}, \quad H_A(D_t) = - \sum_v \frac{|D_{t,v}|}{|D_t|} \log \frac{|D_{t,v}|}{|D_t|},$$

其中 $\mathcal{C}_t^+ = \{A : g(D_t, A) \geq |\mathcal{C}_t|^{-1} \sum_{B \in \mathcal{C}_t} g(D_t, B), H_A(D_t) > 0\}$ 。ID3 更偏好高基数特征；经典 C4.5 先做原始增益筛选，再用取值熵归一化以缓和该偏好。二者仍是局部贪心方法，都需复杂度控制和独立验证。

练习 15.9. 当前结点非纯，候选特征集合为空。算法应输出什么？为何不能任意选择祖先结点的某个特征再次多叉划分？

练习 15.9 解析

当前结点 t 满足 $\mathcal{A}_t = \emptyset$ 且样本非纯时，应输出叶结点

$$\hat{y}_t = \arg \max_c N_{t,c}, \quad \hat{P}(Y = c | t) = \frac{N_{t,c}}{|D_t|},$$

平局按预先固定规则处理。若祖先已按离散特征 A 的取值 v 进入当前结点，则

$$x \in D_t \implies A(x) = v.$$

再次按同一 A 多叉划分只会产生一个非空分支 D_t 和若干空分支，递归规模不减，可能无限重复。连续特征若允许复用，必须提供新的阈值候选与显式停止规则。

练习 15.10. 某子树有 3 个叶，拟合项为 10；收缩为一个叶后拟合项为 12。求保留与收缩目标相等时的 α 。

练习 15.10 解析

保留与收缩后的局部代价复杂度目标分别为

$$C_\alpha(T_t) = 10 + 3\alpha, \quad C_\alpha(t) = 12 + \alpha.$$

令二者相等：

$$10 + 3\alpha = 12 + \alpha \iff 2\alpha = 2 \iff \alpha = 1.$$

差值为

$$C_\alpha(T_t) - C_\alpha(t) = 2(\alpha - 1),$$

故 $\alpha < 1$ 时保留子树， $\alpha > 1$ 时收缩；等号时按预定并列规则处理。

练习 15.11. 设计一个无数据泄漏的树深度选择流程，明确训练、验证和测试数据分别参与哪些步骤。

练习 15.11 解析

先在查看测试集之前固定非空有限候选深度集

$$\emptyset \neq \mathcal{D} = \{d_1, \dots, d_m\} \subset \mathbb{N}_0,$$

并取整数 K 使 $2 \leq K \leq |D_{\text{dev}}|$, 各训练折与验证折均非空。再作一次互斥划分

$$D = D_{\text{dev}} \dot{\cup} D_{\text{test}}, \quad D_{\text{dev}} = D_r^{\text{tr}} \dot{\cup} D_r^{\text{val}} \quad (r = 1, \dots, K).$$

对每个深度 $d \in \mathcal{D}$ 和每一折 r , 全部预处理、阈值统计、树生成与剪枝只在训练折拟合:

$$f_{r,d} = \text{PipelineFit}(D_r^{\text{tr}}; d), \quad L_{r,d} = L(f_{r,d}; D_r^{\text{val}}).$$

选择

$$d^* = \min \arg \min_{d \in \mathcal{D}} \frac{1}{K} \sum_{r=1}^K L_{r,d}, \quad f^* = \text{PipelineFit}(D_{\text{dev}}; d^*).$$

这里对并列最优深度固定选取最浅者; 候选集有限且非空, 故 d^* 存在且由该规则唯一确定。最后只计算一次 $L(f^*; D_{\text{test}})$ 。测试结果不得反向修改 d^* 或训练流程。

练习 15.12. 某内部结点收缩成叶的损失为 18, 其子树损失为 12 并有 4 个叶。计算 $g(t)$, 解释该数值在剪枝中的含义。

练习 15.12 解析

最薄弱环节指标为

$$g(t) = \frac{R(t) - R(T_t)}{|T_t| - 1} = \frac{18 - 12}{4 - 1} = 2.$$

子树比单叶多 $4 - 1 = 3$ 个叶, 并减少 $18 - 12 = 6$ 单位训练损失, 因此每增加一个叶平均换来 2 单位损失下降。验证等价点:

$$R(T_t) + 2|T_t| = 12 + 2 \times 4 = 20, \quad R(t) + 2 = 18 + 2 = 20.$$

故复杂度参数 $\alpha = 2$ 时保留与收缩代价相同; 当前树中 $g(t)$ 最小的结点最先成为最薄弱环节。

本章结论与下一步

核心结论: 树结构、叶区域、划分准则与子树序列

关键依据: 由条件熵、平方误差和基尼指数得到局部划分目标

可执行自检: 递归生成候选树, 再用代价复杂度与独立验证选择子树

适用边界: 可解释的非线性分类、回归与规则提取

下一步: 进入逻辑斯谛回归, 对比树式分段与平滑概率边界

1. 能否把任一根到叶路径写成互斥完备规则, 并给出叶内条件概率估计?
2. 能否从类别计数计算 $H(D)$ 、 $H(D|A)$ 、 $g(D,A)$ 与 $g_R(D,A)$, 同时处理零概率和零分母?
3. 能否写出 ID3/C4.5 的输入、参数、初始化、更新、停止及有限终止理由, 并估算平衡树与极端深树的时间、空间成本?
4. 能否证明回归叶均值最优, 并分别写出 CART 回归和分类的局部准则?

5. 能否由代价相等条件推出 $g(t)$ ，说明验证集如何从嵌套子树序列中选择模型，并指出至少三类数据泄漏或剪枝错误及其回滚检查？若未通过，应依次回看第 15.1–15.3 节的模型与准则、第 15.4–15.5 节的生成与剪枝，以及第 15.6–15.7 节的 CART 与综合流程。

第 16 章 逻辑斯谛回归

读前自检：本章地图：逻辑斯谛回归。 逻辑斯谛回归章地图以“从线性得分直达概率模型、交叉熵与阻尼 Newton 法”组织内容；请把路线拆成起点、关键工具和终点，并核对三者的输入输出类型能依次衔接。

读前自检：本章可检验学习目标。 逻辑斯谛回归目标中的“从逻辑斯谛分布出发，建立二项逻辑斯谛回归的条件概率模型”必须可复核；请从逻辑斯谛分布出发，建立二项逻辑斯谛回归的条件概率模型，所得结果仅在“中间结果逐项包含首目标“从逻辑斯谛分布出发，建立二项逻辑斯谛回归的条件概率模型”声明的对象、条件与结论”时通过。

读前自检：最短先修。 逻辑斯谛回归的最短先修明确要求“本章需要线性函数、指数函数与对数函数、伯努利分布、条件概率、独立同分布抽样、极大似然估计、向量微分、正定与半正定矩阵、凸函数以及 Newton 方法”；请把首项“本章需要线性函数、指数函数与对数函数、伯努利分布、条件概率、独立同分布抽样、极大似然估计、向量微分、正定与半正定矩阵、凸函数以及 Newton 方法”中的第一个先修对象写成定义域 – 运算 – 输出三元组，并以“该三元组逐项满足首项“本章需要线性函数、指数函数与对数函数、伯努利分布、条件概率、独立同分布抽样、极大似然估计、向量微分、正定与半正定矩阵、凸函数以及 Newton 方法”的对象类型与成立条件”判断能否进入本章。

读前自检：依赖路线。 逻辑斯谛回归把“逻辑斯谛分布 $\rightarrow$ S 形概率映射”接到“线性预测量 $\rightarrow$ 对数几率线性模型 $\rightarrow$ 线性决策边界”；请用 $\rightarrow$ 补全这一步的等式或判据，再检查两端维数、支持或对象类型。

本章地图

核心问题：怎样得到可优化、可校准且数值稳定的分类概率

可检验学习目标：

- 从逻辑斯谛分布出发，建立二项逻辑斯谛回归的条件概率模型，并能在几率、对数几率和概率三种表示之间转换；
- 从伯努利似然逐步推导负对数似然、梯度和 Hessian 矩阵，说明目标函数的凸性以及正则化的作用；
- 掌握带回溯线搜索的阻尼 Newton 方法，明确输入输出、参数、初始化、更新、停止与收敛条件，并分析时间和空间复杂度；
- 把二项模型推广到多项逻辑斯谛回归，理解基准类参数化、softmax 参数化及其可识别性差异；
- 能够识别完全分离、数值溢出、数据泄漏、阈值误用和概率失准等常见问题，并给出可检验的处理方案。

最短先修：本章需要线性函数、指数函数与对数函数、伯努利分布、条件概率、独立同分布抽样、极大似然估计、向量微分、正定与半正定矩阵、凸函数以及 Newton 方法。默认样本写为 $T = \{(x_i, y_i)\}_{i=1}^N$ ，其中 $x_i \in \mathbb{R}^d$ ，二分类标签 $y_i \in \{0, 1\}$ 。若把截距并入参数，则在 x_i 末尾补 1，并相应扩充权重向量。

依赖路线：逻辑斯谛分布 $\rightarrow$ S 形概率映射；线性预测量 $\rightarrow$ 对数几率线性模型 $\rightarrow$ 线性决策边界；伯努利条件分布 $\rightarrow$ 极大似然 $\rightarrow$ 交叉熵目标；梯度与 Hessian $\rightarrow$ 凸优化 $\rightarrow$ 阻尼 Newton 迭代；二项归一化 $\rightarrow$ 多项归一化 $\rightarrow$ softmax 与最大熵解释。

完成标准与返回：若完全分离、溢出或阈值代价不清，回看优化实现与评估部分

读前自检：模型认识卡：逻辑斯谛回归。 逻辑斯谛回归模型卡给定 $x \in \mathbb{R}^d, w \in \mathbb{R}^d, b \in \mathbb{R}$ ；请计算 $z = w^T x + b$ 与 $\sigma(z)$ ，核对输出在 $(0, 1)$ 并按冻结阈值转为类别。

模型认识卡：逻辑斯谛回归

任务与输入：二类或多类分类， $x \in \mathbb{R}^d$ 。 **输出类型：**条件概率与阈值决策。

模型：二类用 $\sigma(w^T x + b)$ ，多类用 softmax。 **策略：**最小化条件负对数似然与可选正则项。

算法：梯度法或带线搜索的阻尼 Newton 法。

预测：报告概率，并按预先选择的阈值或最大概率决策。 **关键假设与边界：**对数几率在给定表示上线性；完全分离、病态曲率与失准概率需单独诊断。

本章符号表		
符号	取值或维数	含义
x, x_i	$\mathbb{R}^d$	输入特征向量与第 i 个样本的输入
y_i	$\{0, 1\}$ 或 $\{1, \dots, K\}$	二分类或多分类标签
w, b	$\mathbb{R}^d, \mathbb{R}$	权重向量与截距
$z = w^T x + b$	$\mathbb{R}$	二项模型的线性预测量
$\sigma(z)$	$(0, 1)$	逻辑斯谛函数 $1/(1 + e^{-z})$
p_i	$(0, 1)$	$P(Y = 1 \mid x_i)$ 的简记
X	$\mathbb{R}^{N \times d}$	以样本向量为行的设计矩阵
D	$\mathbb{R}^{N \times N}$	对角元为 $p_i(1 - p_i)$ 的权重矩阵
λ	$[0, \infty)$	L_2 正则化强度
K	正整数且 $K \geq 2$	多分类的类别数

16.1 二项逻辑斯谛模型

分类器既要给出类别，也常要给出可用于排序、阈值决策和风险控制的条件概率。线性函数 $w^T x + b$ 可以取任意实数，不能本身充当概率；逻辑斯谛函数把整个实数轴单调映射到 $(0, 1)$ ，从而把线性结构和概率输出连接起来。

读前自检：逻辑斯谛回归与最大熵模型。 把逻辑斯谛回归与最大熵模型放在“逻辑斯谛回归是条件概率模型”下考察：在共同支持上代入 $P(Y \mid X)$ 并合并一项，并检查最大熵模型同样得到指数族条件分布，本章后文将从对数配分函数说明两者的联系。

逻辑斯谛回归是条件概率模型。它不为 X 单独建立分布，而是直接描述 $P(Y | X)$ ；学习时以条件似然为准则。二项模型使用一个线性预测量，多项模型使用一组线性预测量。最大熵模型同样得到指数族条件分布，本章后文将从对数配分函数说明两者的联系。

读前自检：逻辑斯谛回归模型。 逻辑斯谛回归模型要求先确认“模型名称中的“回归”指对条件概率或对数几率建模，最终任务仍可为分类”；请随后把“模型名称中的“回归”指对条件概率或对数几率建模，最终任务仍可为分类”中的已声明对象依次标成输入、输出与判据，用每个对象只承担正文声明的接口角色，且判据能给出通过或失败验收。

逻辑斯谛回归把输入的线性组合送入 S 形函数。其参数控制决策面的方向、位置以及概率随法向距离变化的速度。模型名称中的“回归”指对条件概率或对数几率建模，最终任务仍可为分类。

读前自检：逻辑斯谛分布。 逻辑斯谛分布满足 $F(u) = 1/[1 + e^{-(u-\mu)/\gamma}]$ 且 $\gamma > 0$ ；请对 u 求导得到密度 $f(u)$ ，再核对 $f(u) \geq 0$ 且从 $-\infty$ 到 $+\infty$ 积分为 1。

定义 16.1 (逻辑斯谛分布). 设连续随机变量 U 的分布函数和密度函数分别为

$$F(u) = \frac{1}{1 + \exp[-(u - \mu)/\gamma]}, \quad f(u) = \frac{\exp[-(u - \mu)/\gamma]}{\gamma\{1 + \exp[-(u - \mu)/\gamma]\}^2},$$

其中 $\mu \in \mathbb{R}$ 是位置参数， $\gamma > 0$ 是尺度参数，则称 U 服从逻辑斯谛分布。

读前自检：逻辑斯谛分布的分布函数与密度函数。 逻辑斯谛分布的分布函数与密度函数依赖“分布函数关于 $u = \mu$ 中心对称地过渡： $F(\mu) = 1/2$ ”；请据此把 $F(\mu + t) = 1 - F(\mu - t)$ 在其支持上求和或积分一次，并直接核对 γ 越大，概率质量分布得越宽。

分布函数关于 $u = \mu$ 中心对称地过渡： $F(\mu) = 1/2$ ，且 $F(\mu + t) = 1 - F(\mu - t)$ 。密度也关于 μ 对称，在 μ 处取得峰值 $1/(4\gamma)$ 。 γ 越小，过渡越陡； γ 越大，概率质量分布得越宽。

读前自检：二项逻辑斯谛回归模型。 二项逻辑斯谛回归模型以“对 $x \in \mathbb{R}^d$ 和 $Y \in \{0, 1\}$ ”为约束；请独立化简 $\frac{P(Y=1|x)}{P(Y=0|x)}$ 的两端，并确认恰有 $b = \log[\tau/(1-\tau)]$ 时，等式在全空间成立，不能称作通常意义的分界超平面。

读前自检：二项逻辑斯谛回归的条件概率分布。 二项逻辑斯谛模型满足 $P(Y = 1 | x) = \sigma(w^T x + b)$ ；请计算优势比 $P(1 | x)/P(0 | x) = e^{w^T x + b}$ ，核对两类概率和为 1 且 $w \neq 0$ 时阈值边界为超平面。

读前自检：二项逻辑斯谛回归。 对二项逻辑斯谛回归，条件“对 $x \in \mathbb{R}^d$ 和 $Y \in \{0, 1\}$ ”不可省；请将 $P(Y = 1 | x)$ 左端按正文定义展开一层，再逐项对齐右端，再用两端运算均有定义、类型一致且化为同一结果作检查。

定义 16.2 (二项逻辑斯谛回归). 对 $x \in \mathbb{R}^d$ 和 $Y \in \{0, 1\}$, 二项逻辑斯谛回归规定

$$P(Y = 1 | x) = \frac{\exp(w^T x + b)}{1 + \exp(w^T x + b)}, \quad P(Y = 0 | x) = \frac{1}{1 + \exp(w^T x + b)}.$$

若令 $\tilde{x} = (x^T, 1)^T$ 、 $\tilde{w} = (w^T, b)^T$, 则两式可统一写成

$$P(Y = 1 | x) = \frac{\exp(\tilde{w}^T \tilde{x})}{1 + \exp(\tilde{w}^T \tilde{x})}, \quad P(Y = 0 | x) = \frac{1}{1 + \exp(\tilde{w}^T \tilde{x})}.$$

模型。记 $z = w^T x + b$ 和 $\sigma(z) = 1/(1 + e^{-z})$, 则 $P(Y = 1 | x) = \sigma(z)$, $P(Y = 0 | x) = 1 - \sigma(z)$ 。给定阈值 $\tau \in (0, 1)$, 分类规则为 $\hat{y} = \mathbf{1}\{\sigma(z) \geq \tau\}$ 。当 $\tau = 1/2$ 时, 分界面为 $w^T x + b = 0$; 改变阈值只沿法向平移分界面, 不改变其方向。

学习策略。独立样本的条件似然是各样本真实标签概率的乘积。最大化条件似然等价于最小化二元交叉熵; L_2 惩罚可控制被惩罚方向的参数规模并缓解共线性。只有当惩罚覆盖全部分离方向时, 它才保证完全分离数据具有有限解; 若截距不惩罚、数据只含单类, 或仍存在未惩罚分离方向, 则参数仍可能沿该方向发散。训练目标与最终决策代价并非同一概念: 模型先估计概率, 部署时再依据误判代价选择阈值。

16.2 几率、对数几率与概率解释

对事件 $Y = 1$, 若 $p = P(Y = 1 | x)$, 则几率定义为 $p/(1 - p)$ 。二项逻辑斯谛模型满足

$$\frac{P(Y = 1 | x)}{P(Y = 0 | x)} = \exp(w^T x + b), \quad \log \frac{P(Y = 1 | x)}{1 - P(Y = 1 | x)} = w^T x + b.$$

左侧称为**对数几率**或 *logit*。因此, 逻辑斯谛回归并非假设概率对 x 线性, 而是假设对数几率对 x 线性。若第 j 个特征增加一个单位且其他特征不变, 几率乘以 e^{w_j} ; 这一解释依赖特征单位, 标准化前后不能机械比较系数大小。

定理 16.1 (概率映射与线性分界) 逻辑斯谛函数 $\sigma(z) = 1/(1 + e^{-z})$ 严格递增, 且 $\sigma(-z) = 1 - \sigma(z)$ 。对任意阈值 $\tau \in (0, 1)$, 条件 $\sigma(w^T x + b) \geq \tau$ 等价于

$$w^T x + b \geq \log \frac{\tau}{1 - \tau}.$$

若 $w \neq 0$, 因而二项逻辑斯谛回归在原特征空间中的阈值分界是一个余维为 1 的超平面。若 $w = 0$, 分类器为常值: 严格不等式对应的决策区域只能是全空间或空集; 恰有 $b = \log[\tau/(1 - \tau)]$ 时, 等式在全空间成立, 不能称作通常意义的分界超平面。

读前自检: 证明: 概率映射与线性分界。 逻辑斯谛函数 $\sigma(z) = 1/(1 + e^{-z})$; 请直接变形核对 $\sigma(-z) = 1 - \sigma(z)$, 再求导得到 $\sigma'(z) = \sigma(z)[1 - \sigma(z)]$ 。

证明. 求导得 $\sigma'(z) = \sigma(z)[1 - \sigma(z)]$ 。对有限 z 有 $0 < \sigma(z) < 1$, 故导数为正, 函数严格递增。又有

$$\sigma(-z) = \frac{1}{1 + e^z} = 1 - \frac{e^z}{1 + e^z} = 1 - \sigma(z).$$

由 $\sigma(z) = \tau$ 解得 $e^z = \tau/(1 - \tau)$, 取对数得到 $z = \log[\tau/(1 - \tau)]$ 。严格单调性保持不等号方向。代入 $z = w^T x + b$ 后, $w \neq 0$ 时得到半空间及其边界超平面; $w = 0$ 时则直接得到上述常值分类器的三种退化情形。□

读前自检: 几何解释: 当 $w \neq 0$ 时, 向量 w 是等概率超平面的法向量。逻辑斯谛等概率面由 $w^T x + b$ 固定; 请令预测概率为 $1/2$ 解出 $w^T x + b = 0$, 核对 $w \neq 0$ 时它是法向量为 w 的超平面。

几何理解

几何解释. 当 $w \neq 0$ 时, 向量 w 是等概率超平面的法向量。点 x 到 $1/2$ 分界面的有符号距离为 $(w^T x + b)/\|w\|_2$ 。概率并不与距离线性变化, 而是先把距离乘以 $\|w\|_2$, 再经 S 形函数压缩。扩大 w, b 的共同尺度会使过渡带变窄, 却不改变 $1/2$ 分界面。

概率解释

对数几率每增加 Δ , 几率乘以 e^Δ ; 概率的增量还取决于当前 p , 因为 $dp/dz = p(1 - p)$ 。同样的线性预测量变化在 $p \approx 1/2$ 附近影响较大, 在 p 接近 0 或 1 时影响较小。模型输出只有在抽样机制、特征分布和标签定义与训练阶段相容, 并经过独立数据校准检查后, 才适合按频率意义解释。

优化解释. 参数学习等价于最小化伯努利负对数似然; 其 Hessian 为半正定矩阵, 因此目标函数是凸函数。梯度法从一阶方向降低目标, Newton 法利用局部曲率缩放更新; 正则化则在数据拟合与参数规模之间加入可控权衡。




图 16.1 逻辑斯谛函数把线性预测量映射为概率, 并满足关于 $(0, 1/2)$ 的中心对称性

图 16.1 显示 $z = 0$ 时概率为 $1/2$, 且 $\sigma(-z) = 1 - \sigma(z)$ 。线性预测量的符号决定概率位于 $1/2$ 哪一侧, 而绝对值增大只会使概率逐渐逼近 0 或 1, 不会越出概率区间。

读前自检：模型参数估计。 令 $p_i = \sigma(w^T x_i + b)$ ；请把独立样本似然写成 $L(w, b) = \prod_i p_i^{y_i} (1 - p_i)^{1-y_i}$ 并取对数，核对最大化 $\ell(w, b)$ 等价于最小化伯努利负对数似然。

16.3 极大似然与梯度推导

令 $p_i = \sigma(w^T x_i + b)$ 。独立样本的条件似然与对数似然分别为

$$L(w, b) = \prod_{i=1}^N p_i^{y_i} (1 - p_i)^{1-y_i}, \quad \ell(w, b) = \sum_{i=1}^N \{y_i \log p_i + (1 - y_i) \log(1 - p_i)\}.$$

最大化 ℓ 等价于最小化负对数似然。以下把截距并入增广参数，仍用 w 和 x_i 表示增广后的量，并令 $z_i = w^T x_i$ 。

阅读目标：把伯努利似然化为可稳定计算的凸目标，并得到一阶与 Newton 更新所需量。

对象：设计矩阵 X 、参数 w 、标签向量 y 、概率 $p_i = \sigma(x_i^T w)$ 。

合法条件： $y_i \in \{0, 1\}$ ；所有样本线性预测有限； $W = \text{diag}(p_i(1 - p_i)) \geq 0$ 。

第一步：先改写 $\ell(w) = \sum_i [\log(1 + e^{x_i^T w}) - y_i x_i^T w]$ 。

推导目标

从伯努利负对数似然推导梯度与 Hessian 矩阵，进而确定一阶优化和 Newton 更新所需的全部量。

推导准备

使用 $\sigma'(z) = \sigma(z)[1 - \sigma(z)]$ 以及 $\log \sigma(z) = z - \log(1 + e^z)$ 、 $\log[1 - \sigma(z)] = -\log(1 + e^z)$ 。记 $p = (p_1, \dots, p_N)^T$ 、 $y = (y_1, \dots, y_N)^T$ 。

推导第 1 步：整理单样本损失。 第 i 个样本的负对数似然为

$$j_i(w) = -y_i \log p_i - (1 - y_i) \log(1 - p_i) = \log(1 + e^{z_i}) - y_i z_i.$$

因此未正则化目标为 $J_0(w) = \sum_{i=1}^N j_i(w)$ 。

推导第 2 步：求梯度。 由于 $d \log(1 + e^z)/dz = \sigma(z)$ 且 $\nabla_w z_i = x_i$ ，有

$$\nabla j_i(w) = (p_i - y_i)x_i, \quad \nabla J_0(w) = \sum_{i=1}^N (p_i - y_i)x_i = X^T(p - y).$$

推导第 3 步：求 Hessian 矩阵。 再求一次导数，并记 $D = \text{diag}\{p_i(1 - p_i)\}$ ，得到

$$\nabla^2 J_0(w) = \sum_{i=1}^N p_i(1 - p_i)x_i x_i^T = X^T D X.$$

若使用 L_2 正则化 $J_\lambda(w) = J_0(w) + \lambda \|w\|_2^2/2$, 并且截距不参与惩罚, 则应把单位阵替换为截距位置为 0 的对角惩罚矩阵 R :

$$\nabla J_\lambda = X^T(p - y) + \lambda R w, \quad \nabla^2 J_\lambda = X^T D X + \lambda R.$$

定理 16.2 (负对数似然的凸性) 二项逻辑斯谛回归的负对数似然 J_0 关于 w 是凸函数。若对所有非零向量 v 都有某个样本满足 $x_i^T v \neq 0$ 且其 $p_i \in (0, 1)$, 则 Hessian 正定, J_0 严格凸; 加入覆盖相应方向的正定二次惩罚也可得到严格凸性。

读前自检: 证明: 负对数似然的凸性。 围绕负对数似然的凸性, 先采用条件“若 $v \neq 0$ 时至少一个非零平方项具有正权重”, 再对 $v^T \nabla^2 J_0(w) v$ 做一次条件化或边缘化; 最后验证任取 $v \in \mathbb{R}^d$ 。

证明. 任取 $v \in \mathbb{R}^d$, 由 Hessian 的求和表示有

$$v^T \nabla^2 J_0(w) v = \sum_{i=1}^N p_i(1 - p_i)(x_i^T v)^2 \geq 0.$$

所以 Hessian 半正定, J_0 为凸函数。若 $v \neq 0$ 时至少一个非零平方项具有正权重, 则二次型严格为正, Hessian 正定。加入二次惩罚后, 二次型再增加 $\lambda v^T R v$; 当数据项与惩罚项的零空间只有零向量时, 和矩阵正定。严格凸性保证至多一个有限极小点, 但完全分离时未惩罚似然可能只在参数趋于无穷时逼近下确界, 不能把凸性误解为有限最优解必然存在。□

定理 16.3 (L_2 正则化下有限解的充分条件) 令 $\tilde{y}_i = 2y_i - 1$, $\lambda > 0$ 且 $R \geq 0$ 。若每个非零未惩罚方向 $v \in \ker R$ 都不是弱分离方向, 即总存在某个 i 使 $\tilde{y}_i x_i^T v < 0$, 则 J_λ 在有限参数处达到最小值。特别地, $R \succ 0$ 是充分条件; 若只把截距留在 $\ker R$ 中, 则还需训练数据两类均非空。若存在非零 $v \in \ker R$ 使 $\tilde{y}_i x_i^T v \geq 0$ 对全部 i 成立且至少一处严格, 则正则项不惩罚该分离方向, 有限极小点不由“加入 L_2 ”自动保证。

读前自检: 证明: L_2 正则化下有限解的充分条件。 L_2 正则化下有限解的充分条件中的“沿 $\ker R$ 中的任一非零方向, 非弱分离条件保证至少一个样本的逻辑损失沿该方向线性增大”决定可执行范围; 请把 $\text{range}(R)$ 用到的关键定义展开并完成下一步变形, 结果须满足若存在未惩罚弱分离方向, 则沿该方向正则项不变而似然项不增加。

证明. 在 $\text{range}(R)$ 上, 二次项随参数范数增长而增长。沿 $\ker R$ 中的任一非零方向, 非弱分离条件保证至少一个样本的逻辑损失沿该方向线性增大; 对相反方向应用同一条件, 两个无界方向都被排除。因此 J_λ 的下水平集有界; 连续函数在闭有界下水平集上达到最小值。若存在未惩罚弱分离方向, 则沿该方向正则项不变而似然项不增加, 严格分离样本的损失还趋于 0, 故不能由正则项推出有限达到性。截距是唯一未惩罚坐标时, 两类均非空恰好排除截距单独把全部样本同向分离。□

条件最大熵模型可写成

$$P_w(y|x) = \frac{\exp\{w^T f(x, y)\}}{Z_w(x)}, \quad Z_w(x) = \sum_{y'} \exp\{w^T f(x, y')\}.$$

其条件对数似然是经验特征项 $\sum_i w^T f(x_i, y_i)$ 减去对数配分项 $\sum_i \log Z_w(x_i)$ 。最大熵约束问题的对偶目标具有同一结构，故条件最大熵的对偶求解与指数族条件模型的极大似然估计相合。二项逻辑斯谛回归是选择相应二值特征表示后的特例；这一联系不改变本节梯度推导所采用的条件似然对象。

读前自检：优化解释：优化性质。梯度是一阶矩条件的偏差，最优点满足 $X^T(p-y) + R w = 0$ 。 带二次正则的逻辑斯谛目标满足 $\nabla J(w) = X^T(p-y) + R w$ ；请核对 $X^T(p-y)$ 与 $R w$ 同维，并在最优点令其和为零。

优化解释

优化性质。 梯度是一阶矩条件的偏差，最优点满足 $X^T(p-y) + \lambda R w = 0$ 。Hessian 中的 $p_i(1-p_i)$ 给出样本的局部曲率权重：概率接近 1/2 的样本权重较大，饱和样本权重较小。纯 Newton 步在曲率良好且接近最优时收敛快；远离最优、矩阵病态或数据近分离时，应配合正则化、阻尼和回溯线搜索。

算法伪代码。 下述迭代不显式构造 D 以外的大型中间张量，并用线性方程求解 Newton 方向，避免计算矩阵逆。

输入输出。 输入为设计矩阵、标签、正则化设置与数值容差；输出为参数、目标函数值与梯度范数。

参数。 最大迭代次数 $T_{\max}$ 、梯度容差 ε_g 、步长容差 ε_w 、Armijo 常数 $c \in (0, 1)$ 、回缩率 $\rho \in (0, 1)$ 、正则化强度 $\lambda \geq 0$ 、最小、初始与最大阻尼 $0 < \delta_{\min} \leq \delta_0 \leq \delta_{\max} < \infty$ 、阻尼放大因子 $\gamma_\delta > 1$ 及回溯上限 $L_{\max}$ 。

初始化。 通常取 $w^{(0)} = 0$ ；若类别极不平衡，可在中心化特征下把截距初始化为样本正类率的 logit，并将其裁剪到有限区间。

带回溯线搜索的阻尼 Newton 逻辑斯谛回归：五步阅读

输入。 写出数据对象、固定参数与必须成立的条件。

初始化。 标明主状态、计数器和第一个合法状态。

核心更新。 只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。 写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。 列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 16.1: 带回溯线搜索的阻尼 Newton 逻辑斯谛回归

输入: 设计矩阵 $X \in \mathbb{R}^{N \times d}$, 标签 $y \in \{0, 1\}^N$, 惩罚矩阵 R , 初值 $w^{(0)}$

输出: 最后合法 $w, J_\lambda(w), g, t_{\text{done}}, s_{\text{done}}, \ell_{\text{done}}, \text{status}$ 与最终诊断

数据: $\lambda \geq 0; \varepsilon_g, \varepsilon_w > 0; T_{\text{max}}, L_{\text{max}} \in \mathbb{N}_0; \delta_{\min} \leq \delta_0 \leq \delta_{\max}; \gamma_\delta > 1; 0 < \rho, c < 1$

- 1 $w \leftarrow w^{(0)}, \delta \leftarrow \delta_0, t_{\text{done}} \leftarrow 0, s_{\text{done}} \leftarrow 0, \ell_{\text{done}} \leftarrow 0$, 诊断为空
- 2 若样本为空、维数不匹配、标签越界、 R 非对称半正定、初值非有限, 或预算、容差、阻尼、回溯参数不合法, 则返回当前初值与计数 0、`invalid_input` 及字段诊断
- 3 在最后合法 w 计算 $J \leftarrow J_\lambda(w)$ 与 $g \leftarrow \nabla J_\lambda(w)$; 若二者非有限则返回 $w, t_{\text{done}} = 0, \text{numerical_failure}$ 及初始化阶段诊断
- 4 若 $\|g\|_\infty \leq \varepsilon_g$, 则返回最后合法初值与 `converged`, 最终诊断记录“零步梯度证书”
- 5 当 $t_{\text{done}} < T_{\text{max}}$ 执行
 - 6 若 $\|g\|_\infty \leq \varepsilon_g$ 则
 - 7 返回 $w, J, g, t_{\text{done}}, s_{\text{done}}, \ell_{\text{done}}, \text{converged}$, 最终诊断记录梯度证书
 - 8 结束
 - 9 以当前 w 稳定计算 D, H ; 若任一项非有限, 则返回最后合法状态与 `numerical\_failure`, 诊断为曲率阶段 t_{done}
 - 10 从当前 δ 开始求解 $(H + \delta I)d = g$, 每次尝试令 $s_{\text{done}} \leftarrow s_{\text{done}} + 1$; 分解失败、方向非有限或 $g^T d \leq 0$ 时放大阻尼
 - 11 若 $\delta > \delta_{\max}$ 仍无有限下降方向, 则返回最后合法 $w, J, g, t_{\text{done}}, s_{\text{done}}, \ell_{\text{done}}, \text{numerical_failure}$, 诊断记录方向阶段与末次阻尼
 - 12 $\alpha \leftarrow 1, \text{accepted} \leftarrow \text{false}$
 - 13 对 $\ell \leftarrow 0$ 至 L_{max} 执行
 - 14 在临时状态计算 $w^+ \leftarrow w - \alpha d, J^+ \leftarrow J_\lambda(w^+)$ 并令 $\ell_{\text{done}} \leftarrow \ell_{\text{done}} + 1$
 - 15 若 w^+, J^+ 有限且 $J^+ \leq J - c\alpha g^T d$ 则
 - 16 计算 $g^+ \leftarrow \nabla J_\lambda(w^+)$; 若 g^+ 非有限则返回最后合法旧状态与 `numerical\_failure`, 诊断为候选梯度 (t_{done}, ℓ) ; 否则置 `accepted` $\leftarrow \text{true}$ 并终止回溯
 - 17 结束
 - 18 保持主状态不变并令 $\alpha \leftarrow \rho\alpha$
 - 19 结束
 - 20 若 $\neg \text{accepted}$ 则
 - 21 返回最后合法 $w, J, g, t_{\text{done}}, s_{\text{done}}, \ell_{\text{done}}, \text{line_search_failed}$, 诊断记录外层轮与全部试算值
 - 22 结束
 - 23 计算相对步长 $q_w \leftarrow \|w^+ - w\|_2 / (1 + \|w\|_2)$; 原子提交 $(w, J, g) \leftarrow (w^+, J^+, g^+), t_{\text{done}} \leftarrow t_{\text{done}} + 1, \delta \leftarrow \max\{\delta_{\min}, \delta/\gamma_\delta\}$
 - 24 若 $q_w \leq \varepsilon_w$ 且 $\|g\|_\infty > \varepsilon_g$ 则
 - 25 返回最后合法状态与 `numerical\_failure`, 最终诊断记录具体原因为“数值停滞但无一阶证书”、相对步长与梯度范数
 - 26 结束
- 27 结束
- 28 返回最后合法 $w, J, g, t_{\text{done}}, s_{\text{done}}, \ell_{\text{done}}, \text{budget_stop}$, 最终诊断记录外层预算耗尽与末次梯度范数

算法实现说明: 仅梯度证书允许返回 `converged`; 小步长而梯度未达标返回 `numerical\_failure` 并在诊断中记录“数值停滞”, 只有实际耗尽 T_{max} 才返回 `budget\_stop`. 候选点在有限性与 Armijo 门禁后原子提交, 线搜索失败保留专用状态。完整 C1–C14 契约

更新规则. 线性方程 $(H + \delta I)d = g$ 给出下降方向, 实际更新为 $w \leftarrow w - \alpha d$. 阻尼改善病态矩阵的可解性, 回溯线搜索保证每个被接受的步长满足充分下降条件。

停止条件。梯度无穷范数控制一阶最优性, 参数相对变化控制迭代停滞, 迭代上限提供保护。计算结果应同时给出最终目标值、梯度范数和迭代次数; 仅因达到上限而退出不能表述为已经收敛。

收敛说明。全局结论需分层陈述。若目标存在有限极小点、初始下水平集有界、梯度在该集合上 Lipschitz 连续、阻尼方向保持一致下降角且 Armijo 回溯总能接受正步长, 则目标单调不增, $\liminf_t \|\nabla J_\lambda(w^{(t)})\| = 0$, 每个有限聚点都是一阶驻点; 凸性再把有限驻点提升为全局极小点。若最优点邻域内 Hessian Lipschitz 连续且正定、阻尼最终降为 0 并接受全 Newton 步, 才有局部二次收敛。预算耗尽、参数停滞或线搜索失败都不是上述收敛证书。若完全分离且 $\lambda = 0$, 或 $\lambda > 0$ 但存在定理 16.3 排除不了的未惩罚分离方向, 有限极小点可能不存在, 此时必须先改变问题设定, 而不是仅增加迭代次数。

读前自检: 复杂度分析: 极大似然与梯度推导。极大似然与梯度推导要求先确认“设样本数为 N 、特征维数为 d 、类别数为 K 、实际迭代次数为 T ”; 请随后由 T 的总成本剥离一次迭代或一次样本因子, 用显式形成 X^TDX 为 $O(Nd^2)$ 验收。

复杂度分析

复杂度假设。以下界把实际接受的 Newton 或一阶更新数记为 T , 设计矩阵稠密时显式形成 $d \times d$ Hessian 并用稠密直接法求解; 回溯线搜索的重复目标计算按实际次数另计。稀疏或 Hessian 向量积实现以 $\text{nnz}(X)$ 和内层迭代次数参数化。设样本数为 N 、特征维数为 d 、类别数为 K 、实际迭代次数为 T , 稀疏设计矩阵非零元素数为 $\text{nnz}(X)$ 。

训练复杂度。一次梯度计算为 $O(Nd)$; 显式形成 X^TDX 为 $O(Nd^2)$, 稠密线性方程求解为 $O(d^3)$, 所以二项模型 T 次 Newton 迭代的总时间为 $O(T(Nd^2 + d^3))$, 另加回溯线搜索实际进行的目标计算。使用一阶或 Hessian 向量积方法时, 主要一次操作可按 $O(\text{nnz}(X))$ 计。

预测复杂度。二项模型单样本计算线性得分和 sigmoid 为 $O(d)$; K 类 softmax 模型为 $O(Kd)$, 批量预测再乘以样本数。

存储复杂度。保存稠密 X 、Hessian 及工作向量需要 $O(Nd + d^2)$ 空间; 流式累积梯度与 Hessian 时可降为 $O(d^2)$, 稀疏数据按 $O(\text{nnz}(X))$ 存储。 K 类模型的参数矩阵需要 $O(Kd)$ 空间。

16.4 多项逻辑斯谛回归

对 K 个互斥类别, 选第 K 类为基准类, 并为前 $K-1$ 类设置参数 $w_1, \dots, w_{K-1}$ 。把截距并入 x 后, 条件概率为

$$P(Y = k | x) = \frac{\exp(w_k^T x)}{1 + \sum_{r=1}^{K-1} \exp(w_r^T x)}, \quad k = 1, \dots, K-1,$$

$$P(Y = K | x) = \frac{1}{1 + \sum_{r=1}^{K-1} \exp(w_r^T x)}.$$

每个非基准类相对基准类的对数几率为

$$\log \frac{P(Y = k | x)}{P(Y = K | x)} = w_k^T x.$$

这些概率均为正且和为 1。基准类参数化固定了一个参照系，不表示第 K 类更重要；改变基准类只会改变参数表达，不会改变能够表示的条件概率族。

对称 softmax 形式为

$$P(Y = k | x) = \frac{\exp(a_k)}{\sum_{r=1}^K \exp(a_r)}, \quad a_k = w_k^T x + b_k.$$

若对所有 a_k 加同一常数，概率不变，因此参数存在共同平移的不可识别性。计算时令 $m = \max_r a_r$ 并使用 $\exp(a_k - m) / \sum_r \exp(a_r - m)$ ，既保持概率不变，又避免大正数指数溢出。多项负对数似然是多类交叉熵，其对第 k 类线性预测量的单样本导数为 $p_k - \mathbf{1}\{y = k\}$ 。

离散分布的熵为

$$H(P) = - \sum_x P(x) \log P(x).$$

在给定经验特征期望约束时最大化条件熵，拉格朗日乘子进入指数项，归一化约束产生对数配分函数，因而得到与 softmax 相同的指数归一化结构。这里的“最大熵”是在约束集合内选择最额外偏置的分布，不是要求每个输入上的类别概率都均匀。

16.5 数值优化、例题与练习

稳定实现应围绕目标函数而不是仅围绕分类准确率设计。对很大的正 z ，可用 $\sigma(z) = 1/(1 + e^{-z})$ ；对很小的负 z ，可用 $\sigma(z) = e^z/(1 + e^z)$ ，从而避免计算 e^{-z} 时溢出。单样本软加函数采用

$$\text{softplus}(z) = \max(0, z) + \log(1 + e^{-|z|}),$$

再以 $\text{softplus}(z) - yz$ 计算损失。特征缩放、缺失值填补、类别编码和阈值选择都必须纳入训练流程，并在每个训练折内重新估计。

例题 16.1 (一次概率预测与阈值决策). 某二项模型在两个标准化特征上的参数为 $w = (0.8, -1.2)^T$ 、 $b = -0.4$ 。对 $x = (1.5, -0.5)^T$ ，分别在阈值 0.5 和 0.85 下作出决策，并解释两种结果为何可以不同。

例题 16.1 解答

读题翻译 模型只产生一次概率 p ；题目要求把同一个 p 分别与 0.5 和 0.85 比较，并解释阈值变化为何能改变最终标签。

已知与合法条件 $w = (0.8, -1.2)^T$ 、 $x = (1.5, -0.5)^T$ 同属 $\mathbb{R}^2$ ， $b = -0.4$ ；概率映射为 $\sigma(z) = 1/(1 + e^{-z})$ ，决策规则明确取 $\hat{y}_\tau = \mathbf{1}\{p \geq \tau\}$ 。

为什么想到这个方法 先由内积得到线性预测量，再经严格单调的 sigmoid 得到概率；两个阈值只改变概率到行动的映射，不会重新计算模型概率。

方法选择 计算一次 $z = w^T x + b$ 和 $p = \sigma(z)$ ，再分别与两阈值比较；最后在 logit 尺度复核两次不等式。

推导/计算 线性预测量与预测概率为

$$z = w^T x + b = 0.8 \times 1.5 + (-1.2) \times (-0.5) - 0.4 = 1.4,$$

$$p = \sigma(z) = \frac{1}{1 + e^{-1.4}} \approx 0.8022.$$

用 $\hat{y}_\tau = \mathbf{1}\{p \geq \tau\}$ 作阈值决策, 则

$$\hat{y}_{0.5} = \mathbf{1}\{0.8022 \geq 0.5\} = 1, \quad \hat{y}_{0.85} = \mathbf{1}\{0.8022 \geq 0.85\} = 0.$$

独立核验 在 logit 尺度, $\text{logit}(0.5) = 0 < 1.4$, 而 $\text{logit}(0.85) = \log(17/3) \approx 1.735 > 1.4$, 与概率尺度的两次判定一致; 且 $0 < p < 1$ 、 $p + (1 - p) = 1$ 。

结论 $p = \sigma(1.4) \approx 0.802184$; 阈值 0.5 时预测 1, 阈值 0.85 时预测 0。两种结果不同是因为决策阈值改变, 模型给出的概率并未改变。

读前自检：适用条件与局限：数值优化、例题与练习。 逻辑斯谛回归要求训练划分尊重样本的分组或时间依赖; 请把同一主体或未来时点同时落入训练与验证作为固定违例, 指出泄漏位置, 再核对按主体分组或按时间前后划分后该泄漏消失。

适用条件与局限性

适用条件。 逻辑斯谛回归适合需要概率排序、可解释方向效应和快速基线模型的二分类或多分类任务。关键条件是: 样本依赖结构已被抽样或建模过程妥善处理; 标签定义一致; 训练与部署分布差异可控; 对数几率能由所选特征的线性组合及必要的变换、交互项近似; 样本量足以支撑参数数目; 验证数据代表实际决策场景。

方法局限

原始特征上的模型只能产生线性分界, 复杂边界需要基函数、交互项或其他模型; 异常值和高杠杆点可能显著影响系数; 高度相关特征使单个系数不稳定; 类别完全分离使无惩罚极大似然参数发散; 稀有事件和分布漂移会损害概率校准; 系数关联不等于因果效应, 遗漏变量和选择偏差不能由优化精度修复。

读前自检：常见错误与误用边界：数值优化、例题与练习。 数值优化、例题与练习依赖“边界框”首项禁止把 0.5 当作固定最优阈值”; 请据此把固定错误“把 0.5 当作固定最优阈值”中的对象、操作与结论按本节定义拆开, 指出第一个不满足的定义条件, 再把该处改为本节允许的写法, 并直接核对改写后的运算或判断有定义, 且不再触发“把 0.5 当作固定最优阈值”。

常见错误

1. 先在全数据上标准化再交叉验证，导致验证折信息泄漏；正确做法是在每个训练折拟合预处理器。

2. 对大幅度 z 直接计算 e^z 或 $\log(1 + e^z)$ ，导致溢出；应使用分支 `sigmoid` 和 `softplus` 恒等式。

3. 把 0.5 当作固定最优阈值；阈值应由误判代价、类别先验和资源约束确定。

4. 只报告准确率而忽略对数损失、区分度和校准；概率模型应同时检查排序与校准。

5. 在完全分离时继续增加迭代次数；应诊断分离、加入正则化或合并过稀类别。

易混淆概念对比

概念对比。

方法	建模对象	主要优势	主要风险
逻辑斯谛回归	$P(Y X)$ 及对数几率	凸目标、概率输出、系数方向可解释	线性 <code>logit</code> 假设、分离与校准漂移
朴素贝叶斯	$P(Y)$ 与 $P(X Y)$	小样本训练快、离散计数自然	条件独立偏差、概率常需再校准
线性回归作分类	$E(Y X)$ 的平方损失近似	计算简单、闭式分析方便	输出可越出 $[0, 1]$ ，损失与伯努利分布不匹配

贯穿例：四点二维分类数据

本章角色：用同一线性可分数据说明概率边界，同时显式处理完全分离造成的有限极大似然缺失。

对这四点取 $p(Y = +1 | x) = \sigma(w_1 x^{(1)} + b)$ 。样本关于原点和标签对称, 加入 $\lambda \|w\|_2^2 / 2 (\lambda > 0)$ 后可取 $b = 0$ 且最优 $w_1 > 0$, 从而在 $x^{(1)} = 0$ 处得到 0.5 决策边界。若不加正则, 沿 $w_1 \rightarrow +\infty$ 似然不断改善却没有有限最大点；因此本例适合说明分类边界，但不能把无正则的有限参数估计当作既成结论。上一站见决策树的轴对齐划分表示；下一站见支持向量机的最大间隔表示。

本章共 12 道练习。每道题干后立即给出同号解析；长解析可自然跨页，续页标题保留题号。

【原书练习整理】

练习 16.1. 写出二项逻辑斯谛回归模型学习的梯度下降算法。须明确目标函数、输入输出、初始化、梯度、更新顺序、停止条件，以及非有限数值或达到迭代上限时的返回状态。

练习 16.1 解析

采用增广设计矩阵 $X \in \mathbb{R}^{N \times d}$ 、标签 $y \in \{0, 1\}^N$ 和参数 $w \in \mathbb{R}^d$ 。令 $\lambda \geq 0$ ，并取

$$R \in \mathbb{R}^{d \times d}, \quad R = R^T \geq 0.$$

练习 16.1 解析 (续)

若 w 含截距坐标, 则令 R 对应的截距行、列为零, 使截距不受惩罚。目标函数为

$$J_{\lambda}(w) = \sum_{i=1}^N \left[\log(1 + e^{x_i^T w}) - y_i x_i^T w \right] + \frac{\lambda}{2} w^T R w.$$

由 $R = R^T$ 可得

$$\nabla \left(\frac{1}{2} w^T R w \right) = \frac{1}{2} (R + R^T) w = R w.$$

输入 X, y, λ, R 、初值 $w^{(0)}$ 、步长规则、容差 $\varepsilon > 0$ 和最大迭代次数 T ; 输出参数、目标值及梯度范数。第 t 轮用同一个 $w^{(t)}$ 依次计算

$$\begin{aligned} p_i^{(t)} &= \sigma(x_i^T w^{(t)}), \\ g^{(t)} &= X^T(p^{(t)} - y) + \lambda R w^{(t)}, \\ w^{(t+1)} &= w^{(t)} - \eta_t g^{(t)}, \quad \eta_t > 0. \end{aligned}$$

若 $\|g^{(t)}\|_{\infty} \leq \varepsilon$, 则停止并输出当前参数; 否则用固定步长或回溯线搜索确定 η_t 后更新。若目标、梯度或新参数不是有限实数, 则停止并保留最后一个有定义的迭代点; 若达到 T 次仍未满足容差, 则输出当前参数与梯度范数, 并明确“达到最大迭代次数”, 不得声称收敛。

练习 16.2. 二项模型在三个样本上的线性预测量分别为 $-\log 3, 0, \log 3$ 。求各样本属于类别 1 的条件概率。

练习 16.2 解析

使用 $\sigma(z) = e^z / (1 + e^z)$, 逐项代入:

$$\begin{aligned} \sigma(-\log 3) &= \frac{e^{-\log 3}}{1 + e^{-\log 3}} = \frac{1/3}{1 + 1/3} = \frac{1}{4}, \\ \sigma(0) &= \frac{1}{1 + 1} = \frac{1}{2}, \\ \sigma(\log 3) &= \frac{e^{\log 3}}{1 + e^{\log 3}} = \frac{3}{1 + 3} = \frac{3}{4}. \end{aligned}$$

由于

$$\sigma'(z) = \sigma(z)\{1 - \sigma(z)\} > 0,$$

三个概率保持线性预测量的次序; 导数在两端趋近 0, 体现饱和。

练习 16.3. 给定 $w = (2, -1)^T$ 、 $b = -0.5$ 和 $x = (1, 3)^T$, 写出增广向量并求 $P(Y = 1 | x)$ 。

练习 16.3 解析

增广向量为 $\tilde{x} = (1, 3, 1)^T$, 增广权重为 $\tilde{w} = (2, -1, -0.5)^T$ 。内积为 $2 - 3 - 0.5 = -1.5$, 所以

$$P(Y = 1 | x) = \frac{1}{1 + e^{1.5}} \approx 0.1824.$$

练习 16.3 解析 (续)

若阈值为 $1/2$, 预测类别 0; 截距必须与末尾的常数 1 配对, 不能在增广后再次另加一次。

练习 16.4. 某样本的正类概率为 0.8。求几率和对数几率; 若一个特征增加一单位使对数几率增加 $\log 2$, 新几率与新概率各是多少?

练习 16.4 解析

初始概率 $p_0 = 0.8$ 对应几率与对数几率

$$q_0 = \frac{p_0}{1 - p_0} = \frac{0.8}{0.2} = 4, \quad \text{logit}(p_0) = \log 4.$$

对数几率增加 $\log 2$ 后,

$$\log q_1 = \log 4 + \log 2 = \log 8 \implies q_1 = 8.$$

再变回概率:

$$p_1 = \frac{q_1}{1 + q_1} = \frac{8}{9} \approx 0.8889.$$

故对数几率的加法对应几率的乘法, 并不对应概率的等量增加。

练习 16.5. 证明 $\sigma(z)[1 - \sigma(z)] \leq 1/4$, 并说明其对概率敏感度的含义。

练习 16.5 解析

令 $p = \sigma(z) \in (0, 1)$ 。配方得

$$p(1 - p) = \frac{1}{4} - \left(p - \frac{1}{2}\right)^2 \leq \frac{1}{4},$$

等号仅在 $p = 1/2$ 即 $z = 0$ 时成立。由于 $\sigma'(z) = p(1 - p)$, 概率对线性预测量的局部敏感度不超过 $1/4$, 并在分界面处最大; 远离分界面时导数趋近 0。

练习 16.6. 给定 $w = (3, 4)^T$ 、 $b = -5$ 。求 $1/2$ 概率分界线, 并计算点 $x = (1, 1)^T$ 到该分界线的有符号距离及其正类概率。

练习 16.6 解析

分界线、法向量及其范数为

$$3x_1 + 4x_2 - 5 = 0, \quad w = (3, 4)^T, \quad \|w\|_2 = 5.$$

对 $x = (1, 1)^T$,

$$z = w^T x - 5 = 3 + 4 - 5 = 2, \quad d_{\text{signed}} = \frac{z}{\|w\|_2} = \frac{2}{5} = 0.4.$$

正类概率为

$$P(Y = 1 | x) = \sigma(2) = \frac{1}{1 + e^{-2}} \approx 0.8808.$$

练习 16.6 解析 (续)

有符号距离为正, 故该点位于预测正类一侧。

练习 16.7. 设某方向 v 满足 $Xv = 0$ 。说明未正则化目标沿 $w + tv$ 为何保持不变, 并给出使该方向具有正曲率的一种处理方法。

练习 16.7 解析

设 $v \neq 0$ 且 $Xv = 0$ 。对任意 $t \in \mathbb{R}$,

$$X(w + tv) = Xw + tXv = Xw.$$

因此线性预测量、概率与未正则化负对数似然均不变:

$$p(w + tv) = p(w), \quad J_0(w + tv) = J_0(w).$$

Hessian 在该方向的曲率为

$$v^T X^T DX v = (Xv)^T D(Xv) = 0.$$

加入 $\lambda \|w\|_2^2/2$ 且 $\lambda > 0$ 后,

$$v^T (X^T DX + \lambda I) v = \lambda \|v\|_2^2 > 0,$$

平坦方向被消除; 另一办法是删除线性相关特征, 使设计矩阵恢复所需秩。

练习 16.8. 某次迭代有 $g^T d = 6$, 目标值为 20, 取 $c = 0.1$ 。若候选点在 $\alpha = 1$ 和 $\alpha = 1/2$ 时的目标值分别为 19.7 和 19.65, 哪一个步长首先满足算法中的 Armijo 条件?

练习 16.8 解析

Armijo 充分下降条件为

$$J(w - \alpha d) \leq J(w) - c\alpha g^T d, \quad c = 0.1, \quad g^T d = 6.$$

当 $\alpha = 1$ 时,

$$J(w) - c\alpha g^T d = 20 - 0.1 \times 1 \times 6 = 19.4, \quad 19.7 > 19.4,$$

故不接受。回缩到 $\alpha = 1/2$ 时,

$$20 - 0.1 \times \frac{1}{2} \times 6 = 19.7, \quad J\left(w - \frac{1}{2}d\right) = 19.65 \leq 19.7.$$

因此首先接受 $\alpha = 1/2$ 。只要求目标下降而不要求充分下降, 可能接受过小而低效的改进。

练习 16.9. 三分类基准类模型的两个非基准类得分为 $\log 2$ 和 $\log 3$ 。求三个类别的条件概率。

练习 16.9 解析

两个非基准类指数得分为 2, 3, 基准类线性得分固定为 0, 故其指数得分为 $e^0 = 1$ 。归一化常数为

$$Z = 2 + 3 + 1 = 6.$$

练习 16.9 解析 (续)

三类概率为

$$(p_1, p_2, p_0) = \left(\frac{2}{Z}, \frac{3}{Z}, \frac{1}{Z}\right) = \left(\frac{1}{3}, \frac{1}{2}, \frac{1}{6}\right), \quad p_1 + p_2 + p_0 = 1.$$

基准类仍参与归一化；固定为 0 的是其线性得分，不是其概率。

练习 16.10. 证明 softmax 对得分的共同平移不变，并说明为何减去最大得分能够改善数值稳定性。

练习 16.10 解析

对任意常数 c ,

$$\frac{e^{a_k+c}}{\sum_r e^{a_r+c}} = \frac{e^c e^{a_k}}{e^c \sum_r e^{a_r}} = \frac{e^{a_k}}{\sum_r e^{a_r}}.$$

取 $c = -\max_r a_r$ 后，所有新得分不大于 0，最大指数为 1，其余指数位于 $(0, 1]$ ，从而避免对很大的正数取指数。极小项仍可能下溢为 0，但它们对分母的相对贡献也极小；需要对数概率时应使用 log-sum-exp 形式。

练习 16.11. 假阳性代价为 5，假阴性代价为 20，正确决策代价为 0。设 $p = P(Y = 1 | x)$ ，求选择正类的最小概率阈值。

练习 16.11 解析

预测正类的条件风险为 $5(1 - p)$ ，预测负类的条件风险为 $20p$ 。选择正类当且仅当

$$5(1 - p) \leq 20p,$$

整理得 $5 \leq 25p$ ，即 $p \geq 0.2$ 。假阴性代价较高使阈值低于 0.5。这里假设给出的 p 已经针对部署先验校准；若先验变化，应先校正概率或重新估计风险。

练习 16.12. 在五个预测概率均约为 0.8 的样本中长期只有约一半为正类。指出问题，并给出一种评估和一种修正途径。

练习 16.12 解析

对这五个样本形成的概率分箱 B ，平均预测与经验正类率约为

$$\bar{p}_B = \frac{1}{|B|} \sum_{i \in B} p_i \approx 0.8, \quad \bar{y}_B = \frac{1}{|B|} \sum_{i \in B} y_i \approx 0.5.$$

若该差异在足够大的独立样本上稳定存在，则校准偏差为

$$\bar{p}_B - \bar{y}_B \approx 0.3 > 0,$$

说明模型在该区间过度自信。可用可靠性图检查各分箱的 $(\bar{p}_B, \bar{y}_B)$ ，并报告

$$\text{Brier} = \frac{1}{N} \sum_{i=1}^N (p_i - y_i)^2$$

练习 16.12 解析 (续)

或对数损失。修正时只在独立校准集上拟合映射 $g: [0, 1] \rightarrow [0, 1]$, 如 Platt 缩放或保序回归 (isotonic regression), 并输出 $g(p)$; 若根因是分布漂移, 还需重加权或重新训练。

读前自检：本章结论与下一步。 逻辑斯谛回归章末由“线性得分、条件概率、交叉熵与 softmax”落到“阻尼、线搜索和正则化共同控制步长、曲率与参数规模”；请把前者产出和后者输入逐项对齐，固定核对前者末项的输出类型能否作为后者首项的输入类型。

本章结论与下一步

核心结论：线性得分、条件概率、交叉熵与 softmax

关键依据：由伯努利似然推得梯度、Hessian 与凸性

可执行自检：阻尼、线搜索和正则化共同控制步长、曲率与参数规模

适用边界：需要概率输出、阈值决策和校准评估的分类任务

下一步：继续学习最大熵等模型，理解多项逻辑斯谛的指数族视角

1. **概念：**能否不看正文写出逻辑斯谛分布、二项条件概率和 logit 关系，并解释系数的几率比含义？未通过则回看第 1、2 节。
2. **推导：**能否从伯努利似然依次得到交叉熵、梯度 $X^T(p - y)$ 和 $\text{Hessian} X^T D X$ ，并用二次型证明凸性？未通过则回看第 3 节的三步推导。
3. **算法：**能否完整叙述阻尼 Newton 方法的输入输出、参数、初始化、更新、停止与收敛条件，并给出一次迭代的时间和空间复杂度？未通过则回看算法与复杂度框。
4. **扩展：**能否写出基准类多项模型，说明 softmax 共同平移不变性及最大熵联系？未通过则回看第 4 节。
5. **应用：**能否针对完全分离、指数溢出、数据泄漏、阈值选择和概率失准分别提出诊断与处理？未通过则回看第 5 节；五项均能独立作答，并能完成每节至少两道练习，才算达到本章学习目标。

第 3 册：优化模型与序列模型

本册沿最大熵、间隔、加法模型、隐变量和序列结构五条线索，连接凸优化、概率建模与动态规划，并以统一视角比较监督学习方法。

- 1. 最大熵模型；
- 2. 支持向量机；
- 3. 提升方法；
- 4. EM 算法及其推广；
- 5. 隐马尔可夫模型；
- 6. 条件随机场；
- 7. 监督学习方法总结。

学习路径
最大熵与支持向量机分别从概率约束和最大间隔建立目标；提升方法研究加法模型；EM 处理含隐变量的似然；隐马尔可夫模型与条件随机场把推断扩展到序列结构。末章负责横向比较并形成选择框架。
跨册依赖与完成标准
建议先掌握第 7 章的拉格朗日对偶、第 8 章的数值优化，以及第 2 册的基础分类方法。完成后应能识别目标函数、约束、隐变量和图结构的作用，复述主要算法循环并判断收敛或推断条件。
建议用法
阅读推导时为每个模型单独维护“观测量、参数、隐变量、目标函数、核心迭代、停止条件”六列表；比较相邻章节时先对齐这六项，再讨论概率解释或几何解释。

第17章 最大熵模型

读前自检：本章地图：最大熵模型。 最大熵模型章地图沿“从熵约束直达指数族、对偶目标与IIS”推进；请标出该路线第一次改变对象类型的位置，并核对前一步产出正是后一步输入。

读前自检：本章可检验学习目标。 最大熵模型的首个可检验目标是“能把“只服从已知约束、其余保持最少偏置”的原则写成严格的条件熵约束优化问题”；请把“只服从已知约束、其余保持最少偏置”的原则写成严格的条件熵约束优化问题并写出中间结果，再按“中间结果逐项包含首目标“能把“只服从已知约束、其余保持最少偏置”的原则写成严格的条件熵约束优化问题”声明的对象、条件与结论”验收。

读前自检：先修自检。 最大熵模型先修自检固定核验“能否验证 $\tilde{P}(x, y) = v(x, y)/N$ 与 $\tilde{P}(x) = v(x)/N$ 均已归一化”；请验证 $\tilde{P}(x, y) = v(x, y)/N$ 与 $\tilde{P}(x) = v(x)/N$ 均已归一化并写出中间结果，再按“ $\tilde{P}(x, y) = v(x, y)/N$ 的计算或证明结果满足首项所列等式、定义域或判断”明确判为通过或失败。

本章地图

核心问题：怎样在可靠特征期望约束下选择条件分布并估计参数

可检验学习目标：

- 能把“只服从已知约束、其余保持最少偏置”的原则写成严格的条件熵约束优化问题；
- 能从经验特征期望约束逐行推导指数族条件分布、对数配分函数、对偶目标及其梯度；
- 能证明最大熵对偶极大化与条件极大似然估计等价，并解释梯度为何是两种特征期望之差；
- 掌握改进的迭代尺度法（IIS）和 BFGS 方法的输入、初始化、更新、停止及收敛条件；
- 能诊断不可行约束、冗余特征、零频数、数值溢出和参数不可识别等实际问题。

最短先修：本章使用离散条件概率、经验分布、数学期望、熵、极大似然、凸函数、等式约束的拉格朗日乘子法、对偶问题、梯度、Hessian 矩阵、Newton 法与拟 Newton 法。设训练集为 $T = \{(x_k, y_k)\}_{k=1}^N$ ，输入与输出的有限取值集合分别为 $\mathcal{X}$ 与 $\mathcal{Y}$ 。若实际变量连续，本章公式应在选定的离散特征或有限样本支撑上理解。

依赖路线：经验分布 → 特征经验期望；条件概率模型 → 模型特征期望；期望匹配约束 → 可行模型集合；条件熵最大化 → 拉格朗日对偶 → 指数族条件分布；对数配分函数 → 条件似然与矩条件；光滑凸优化 → IIS 或 BFGS 参数学习。

完成标准与返回：约束或支撑检查失败时返回节 17.1、17.4；优化细节不稳时回看节 17.2

模型认识卡：最大熵模型

任务与输入：有限输出条件概率建模，输入为样本与特征 $f_i(x, y)$ 。 **输出类型：**归一化条件分布。

模型： $P_w(y | x) \propto \exp\{w^T f(x, y)\}$ 。 **策略：**在经验矩约束下最大化条件熵，等价地优化条件似然对偶。 **算法：**一般实值特征可用 BFGS；满足非负尺度条件时可用 IIS。

预测：取条件概率或最大概率类别。 **关键假设与边界：**约束须可行且参数可识别；零频、冗余特征与分离会破坏有限参数解。

本章符号表

符号	取值或维数	含义
$\tilde{P}(x, y)$	$[0, 1]$	训练样本联合经验分布
$\tilde{P}(x)$	$[0, 1]$	输入的边缘经验分布
$P(y x)$	$[0, 1]$	待学习的条件概率, 且对每个 x 按 y 归一化
$f_i(x, y)$	$\mathbb{R}$	第 i 个特征函数, $i = 1, \dots, n$
$\tilde{E}(f_i)$	$\mathbb{R}$	特征在联合经验分布下的期望
$E_P(f_i)$	$\mathbb{R}$	特征在 $\tilde{P}(x)P(y x)$ 下的期望
w	$\mathbb{R}^n$	拉格朗日乘子组成的参数向量
$Z_w(x)$	$(0, \infty)$	对输入 x 的配分函数
$f^\#(x, y)$	$\mathbb{R}$	IIS 中的特征总量 $\sum_i f_i(x, y)$
δ_i	$\mathbb{R}$	IIS 对参数 w_i 的一次增量

读前自检：最大熵模型。 在“概率建模常只有部分可靠信息，例如若干事件概率之和、某些统计量的均值或训练样本给出的特征频率”成立时处理最大熵模型：请在共同支持上代入最大熵模型并合并一项，并以最大熵方法把“没有证据时不额外偏向某一结果”表述为熵最大化判定结果。

17.1 最大熵原理

概率建模常只有部分可靠信息，例如若干事件概率之和、某些统计量的均值或训练样本给出的特征频率。问题不是任意补齐未知概率，而是在满足这些信息的所有分布中选择一个模型。最大熵方法把“没有证据时不额外偏向某一结果”表述为熵最大化。

读前自检：最大熵原理。 最大熵原理在非空约束集合 $\mathcal{C}$ 中选择 $P^\star \in \arg \max_{P \in \mathcal{C}} H(P)$ ；请核对候选分布非负、归一化并满足线性矩约束，再比较其熵。

定义 17.1 (最大熵原理). 设 $\mathcal{C}$ 是由已知线性约束和概率归一化约束确定的非空分布集合。最大熵原理在 $\mathcal{C}$ 中选择

$$P^\star \in \arg \max_{P \in \mathcal{C}} H(P), \quad H(P) = - \sum_z P(z) \log P(z).$$

若目标严格凹且可行集合为凸集，则最优分布唯一。

模型。 模型对象是一个概率分布或条件概率分布；可行集合编码已经确认的信息，熵目标只在这个集合内部比较候选模型。没有约束时，有限集合上的最大熵分布是均匀分布；加入约束后，最优解通常不再均匀，但不会引入约束未要求的额外结构。

学习策略。 以熵为不确定性度量，在全部经验约束下最大化条件熵。约束负责“拟合已知事实”，熵负责“控制未被事实确定的自由度”。这与把误差项和正则项简单相加不同：基本最大熵模型把特征期望写成硬等式约束。

阅读目标：从条件熵优化的驻点方程看清指数项与配分函数的来源。

对象：条件分布 $P(y|x)$ 、线性特征约束及每个 x 上的归一化约束。

合法条件：考虑概率单纯形内部解 $P(y|x) > 0$ ；可行集凸，负熵为凸函数。

第一步：先写包含特征约束和 $\sum_y P(y|x) = 1$ 的拉格朗日函数，并对每个 $P(y|x)$ 求偏导。

推导目标

从条件熵约束优化问题推导最优条件分布的指数族形式，并明确配分函数如何由归一化约束产生。

推导准备

对 $\tilde{P}(x) > 0$ 的输入考虑 $P(y|x) > 0$ 的内部解。使用 $\partial[p \log p]/\partial p = \log p + 1$ 。线性等式约束与概率单纯形构成凸可行集， $-H(P)$ 为凸函数。

推导第1步：写出拉格朗日函数。

$$\begin{aligned} \mathcal{L}(P, w, \lambda) = & \sum_{x,y} \tilde{P}(x) P(y|x) \log P(y|x) \\ & + \sum_{i=1}^n w_i \{ \tilde{E}(f_i) - E_P(f_i) \} + \sum_x \lambda(x) \left\{ 1 - \sum_y P(y|x) \right\}. \end{aligned}$$

推导第2步：对每个概率分量求驻点。

$$\frac{\partial \mathcal{L}}{\partial P(y|x)} = \tilde{P}(x) \left[\log P(y|x) + 1 - \sum_i w_i f_i(x, y) \right] - \lambda(x) = 0.$$

将只依赖 x 的项合并为 $c(x)$ ，得到

$$P(y|x) = c(x) \exp \left\{ \sum_{i=1}^n w_i f_i(x, y) \right\}.$$

推导第3步：用归一化确定 $c(x)$ 。对 y 求和并令结果为 1，定义

$$Z_w(x) = \sum_{y \in \mathcal{Y}} \exp \left\{ \sum_{i=1}^n w_i f_i(x, y) \right\},$$

便有

$$P_w(y|x) = \frac{1}{Z_w(x)} \exp \left\{ \sum_{i=1}^n w_i f_i(x, y) \right\}.$$

配分函数严格为正，因此条件概率有定义并自动归一化。

定理 17.1 (最大熵模型的指数形式) 若期望约束可行，且最优解位于相关概率单纯形的相对内部，则存在参数 $w \in \mathbb{R}^n$ ，使最大熵模型具有本节给出的指数族形式。反过来，若某个 P_w 满足全部期望约束，则它是条件熵最大化问题的全局最优解。

读前自检：证明：最大熵模型的指数形式。 最大熵指数形式的反向证明把 $-H(P)$ 视为概率单纯形上的凸函数，并把期望约束写成仿射等式；请核对原可行性、驻点与乘子条件构成 KKT 证书，再用严格凹性判断条件分布何时唯一。

证明. 前半部分由拉格朗日驻点方程和归一化推导得到。对后半部分， $-H(P)$ 在概率单纯形上为凸函数，期望约束是仿射等式；因此满足原始可行性、驻点条件和乘子条件的点满足凸问题的 KKT 条件。凸问题的 KKT 点是全局极小点 $-H(P)$ ，也就是全局最大点 $H(P)$ 。若在有效方向上条件熵严格凹，则对应的条件分布唯一。至此两方向均成立。□

优化解释

优化解释。 特征权重 w_i 是相应期望约束的对偶变量。正的 w_i 提高 $f_i(x, y)$ 较大的结果的未归一化得分，负的 w_i 降低它们； $Z_w(x)$ 把这些得分投影回概率单纯形。对偶学习就是调整影子价格，直到模型期望与经验期望一致。

读前自检：极大似然估计。 最大熵模型条件对数似然的梯度为 $\tilde{E}(f_i) - E_{P_w}(f_i)$ ；请对 w_i 求导 $\log Z_w(x)$ ，核对最优点的每个坐标满足经验与模型特征期望相等。

17.2 对偶目标与参数估计

指数模型的平均条件对数似然为

$$\ell(w) = \sum_{x,y} \tilde{P}(x, y) \log P_w(y | x) = \sum_i w_i \tilde{E}(f_i) - \sum_x \tilde{P}(x) \log Z_w(x).$$

因此最小化负对数似然

$$J(w) = \sum_x \tilde{P}(x) \log Z_w(x) - \sum_i w_i \tilde{E}(f_i)$$

与最大化最大熵对偶函数是同一个优化问题。

读前自检：模型学习的最优化算法。 把模型学习的最优化算法放在“对 w_i 求导”下考察：独立化简 $\nabla J(w) = 0$ 的两端，并检查两端运算均有定义、类型一致且化为同一结果。

对 w_i 求导，

$$\frac{\partial J}{\partial w_i} = \sum_{x,y} \tilde{P}(x) P_w(y | x) f_i(x, y) - \tilde{E}(f_i) = E_{P_w}(f_i) - \tilde{E}(f_i).$$

Hessian 是条件特征协方差的经验加权和：

$$\frac{\partial^2 J}{\partial w_i \partial w_j} = \sum_x \tilde{P}(x) \text{Cov}_{P_w(\cdot|x)}(f_i(x, Y), f_j(x, Y)),$$

故半正定。最优性条件 $\nabla J(w) = 0$ 恰好是全部特征期望匹配。

读前自检：拟牛顿法。 最大熵模型的拟牛顿求解以负条件对数似然 $J(w)$ 为目标；请用正定 G_k 形成 $p_k = -G_k \nabla J(w_k)$ ，核对非驻点处为下降方向并以梯度范数判停。

读前自检：最大熵模型学习的 BFGS 算法。 最大熵模型学习的 BFGS 状态为 w_k, G_k 及梯度；请计算 s_k, y_k 并完成一次逆 BFGS 更新，核对 $G_{k+1} y_k = s_k$ 且曲率条件失败时不提交。

几何理解

几何解释。 含 K 个结果的概率向量位于 $(K-1)$ 维单纯形中；每条线性期望约束对应一个仿射超平面。可行模型集合是单纯形与这些超平面的交集。熵的等高面向均匀分布方向鼓起，最大熵解是可行截面上熵值最高的点。

概率解释

熵越大，概率质量越不集中。最大熵不是声称真实世界一定最随机，而是说：在当前约束以外没有可验证信息时，不应凭空把质量集中到少数结果。新增可靠约束后，可行集合缩小，模型才相应偏离均匀分布。




图 17.1 概率单纯形上的熵等高线与线性约束；本例约束交点是唯一可行的最大熵点

图 17.1 把概率归一化表示为单纯形，把已知统计量表示为线性约束；可行集是两者的交集，最大熵解是在该交集内而不是在整个单纯形内选择熵最大点。

读前自检：最大熵模型的定义。 最大熵模型约束经验特征期望 $\tilde{E}(f_i)$ 等于模型期望 $E_P(f_i)$ ；请对一个 f_i 分别按经验联合分布和 $\tilde{P}(x)P(y|x)$ 求和，核对两侧均为标量。

17.3 最大熵模型的定义

对训练集定义频数 $\nu(x, y)$ 与 $\nu(x)$, 经验分布为

$$\tilde{P}(x, y) = \frac{\nu(x, y)}{N}, \quad \tilde{P}(x) = \frac{\nu(x)}{N}.$$

给定特征 $f_i(x, y)$, 其经验期望与模型期望分别为

$$\tilde{E}(f_i) = \sum_{x, y} \tilde{P}(x, y) f_i(x, y), \quad E_P(f_i) = \sum_{x, y} \tilde{P}(x) P(y | x) f_i(x, y).$$

期望匹配约束 $E_P(f_i) = \tilde{E}(f_i)$ 要求模型在输入经验分布下复现训练数据中的特征统计量。

读前自检：满足经验约束的最大熵条件模型。 满足经验约束的最大熵条件模型以 “ $H(P) = -\sum_{x, y} \tilde{P}(x) P(y | x) \log P(y | x)$.” 为约束；请在共同支持上代入 $H(P)$ 并合并一项，并确认未在训练支撑中出现的输入需要依赖特征设计、参数共享或额外建模规则外推。

读前自检：条件最大熵模型。 先锁定条件最大熵模型的条件 “ $H(P) = -\sum_{x, y} \tilde{P}(x) P(y | x) \log P(y | x)$.”：在共同支持上代入 $H(P)$ 并合并一项，所得结果应满足在 $\mathcal{C}$ 中使 $H(P)$ 最大的条件分布称为最大熵模型。

定义 17.2 (条件最大熵模型). 设

$$\mathcal{C} = \left\{ P : E_P(f_i) = \tilde{E}(f_i), i = 1, \dots, n, \sum_{y \in \mathcal{Y}} P(y | x) = 1, P(y | x) \geq 0 \right\}.$$

条件熵定义为

$$H(P) = -\sum_{x, y} \tilde{P}(x) P(y | x) \log P(y | x).$$

若 $\mathcal{C}$ 非空，则在 $\mathcal{C}$ 中使 $H(P)$ 最大的条件分布称为最大熵模型。

条件熵是 $H(Y | X)$ 在输入边缘分布取 $\tilde{P}(x)$ 时的经验版本。只对 $\tilde{P}(x) > 0$ 的输入取值施加数
据驱动的约束；未在训练支撑中出现的输入需要依赖特征设计、参数共享或额外建模规则外推。

读前自检：最大熵模型的学习。 对最大熵模型的学习，条件 “以下对每个特征约束引入乘子 w_i , 并对每个 x 的归一化约束引入乘子 $\lambda(x)$ ” 不可省；请在共同支持上代入 $\liminf_k \|\nabla J(w^{(k)})\| = 0$ 并合并一项，再用达到迭代上限而梯度或期望残差仍未满足容差时，应保留最后参数并报告残差，不能称为已经收敛作检查。

17.4 约束与指数族形式

学习问题写成

$$\max_{P \in \mathcal{C}} H(P),$$

等价地最小化 $-H(P)$ 。以下对每个特征约束引入乘子 w_i , 并对每个 x 的归一化约束引入乘子 $\lambda(x)$ 。

算法与输入输出。BFGS 输入特征、经验分布、初始参数、梯度容差和线搜索参数，输出参数 w 、条件概率模型、目标值与梯度范数。算法以正定矩阵 B_k 近似 Hessian，不显式求真实 Hessian。

参数。最大迭代次数 $T_{\max}$ 、线搜索上限 $L_{\max}$ 、梯度容差 ε_g 、参数与目标相对变化容差 $\varepsilon_w, \varepsilon_J$ 、曲率容差 ε_c ，以及强 Wolfe 常数 $0 < c_1 < c_2 < 1$ 。低曲率时采用 Powell 型阻尼曲率对，修复失败则返回明确状态。

初始化。取 $w^{(0)} = 0$ 和正定对称矩阵 $B_0 = I$ ；在稀疏高维问题中可取对角缩放。初始化后计算 $J(w^{(0)})$ 与 $g_0 = \nabla J(w^{(0)})$ 。

更新规则。方向由 $B_k p_k = -g_k$ 给出，强 Wolfe 线搜索同时控制充分下降与方向导数；仅在曲率内积为正且高于数值容差时采用 BFGS 秩二更新，从而保持 B_{k+1} 正定。

停止条件。梯度无穷范数达到容差时返回 converged；参数相对变化与目标相对变化同时很小而梯度未达标时，只说明数值推进停滞，返回 numerical_failure 并把“数值停滞”作为具体诊断。迭代上限只是保护条件；达到上限只能报告 budget_stop，不能表述为收敛。

收敛条件。若 J 下有界、初始水平集有界、梯度 Lipschitz 连续，搜索方向保持下降性，强 Wolfe 线搜索成功且阻尼曲率对保持正定近似，则标准全局结论给出 $\liminf_k \|\nabla J(w^{(k)})\| = 0$ ，有限聚点为一阶驻点。因为 J 凸，任一有限驻点都是全局极小点；若 Hessian 在有效参数空间正定，则最优参数唯一。线搜索失败、曲率修复失败或迭代预算用尽时只返回最后合法参数与残差，不能援引该结论。

异常、退化与未满足停止准则的情形。约束不可行、经验期望为零但模型支撑强制为正、指数或对数不是有限实数、线搜索找不到下降步、IIS 一维方程无根时，算法应停止并说明相应数学条件。达到迭代上限而梯度或期望残差仍未满足容差时，应保留最后参数并报告残差，不能称为已经收敛。

读前自检：复杂度分析：约束与指数族形式。约束与指数族形式把问题限定在“若每个样本平均有 s 个非零特征、类别数为 K 、参数数为 n 、外层迭代数为 T ”；请由 s 的总成本剥离一次迭代或一次样本因子，检查是否得到曲率条件或线搜索条件不满足时，应重置近似矩阵、拒绝该步或停止并说明原因。

复杂度分析

训练时间复杂度。若每个样本平均有 s 个非零特征、类别数为 K 、参数数为 n 、外层迭代数为 T ，一次目标与梯度计算约为 $O(NKs)$ 。若维护 Hessian 近似 B_k 的稳定秩更新，方向求解与更新合计为 $O(n^2)$ ，总训练约为 $O(T[NKs + n^2])$ ；若每轮从头对稠密 B_k 分解，线性代数项改为 $O(Tn^3)$ 。

正确性依据。IIS 的尺度方程来自似然增量的可分下界驻点，接受更新时保持目标不下降；BFGS 在方向为下降方向且线搜索满足充分下降与曲率条件时接受迭代。曲率条件或线搜索条件不满足时，应重置近似矩阵、拒绝该步或停止并说明原因。

条件最大熵模型的 BFGS 学习：五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 17.1: 条件最大熵模型的 BFGS 学习

输入: 有限实值特征 $f_1, \dots, f_n$, 经验分布, 初值 $w^{(0)}$
输出: 最后合法 $w, J, g, P_w, k_{\text{done}}, \ell_{\text{done}}, c_{\text{reset}}, \text{status}$ 与最终诊断
数据: $T_{\max}, L_{\max} \in \mathbb{N}_0$; $\varepsilon_g, \varepsilon_w, \varepsilon_J, \varepsilon_c > 0$; 合法 Armijo 与强 Wolfe 常数

- 1 $w \leftarrow w^{(0)}, B \leftarrow I, k_{\text{done}} \leftarrow 0, \ell_{\text{done}} \leftarrow 0, c_{\text{reset}} \leftarrow 0$, 诊断为空
- 2 若经验分布或支撑非法、特征/维数/初值非有限或不相容, 或预算、容差、线搜索常数越界, 则返回当前初值、计数 0、invalid_input 及字段诊断
- 3 计算 $J \leftarrow J(w), g \leftarrow \nabla J(w)$ 与 P_w ; 若目标、梯度、配分函数或概率非有限, 则返回最后合法初值、numerical_failure 及初始化阶段诊断
- 4 若 $\|g\|_{\infty} \leq \varepsilon_g$, 则返回最后合法初值与 converged, 最终诊断记录“零步梯度及期望残差证书”
- 5 当 $k_{\text{done}} < T_{\max}$ 执行
 - 6 若 $\|g\|_{\infty} \leq \varepsilon_g$ 则
 - 7 返回最后合法状态与 converged, 最终诊断记录梯度及期望残差证书
 - 8 结束
 - 9 求解 $Bp = -g$; 若求解失败、 p 非有限或 $g^T p \geq 0$, 则取临时 $B^0 \leftarrow I, p \leftarrow -g$ 并令 $c_{\text{reset}} \leftarrow c_{\text{reset}} + 1$; 否则 $B^0 \leftarrow B$
 - 10 若重置后 p 仍非有限或不是下降方向, 则返回最后合法 w, J, g, P_w 、当前计数、numerical_failure, 诊断为方向阶段 k_{done}
 - 11 在至多 $L_{\max}$ 次试算中寻找同时满足 Armijo 与强 Wolfe 条件的 $\lambda > 0$; 每次令 $\ell_{\text{done}} \leftarrow \ell_{\text{done}} + 1$, 候选非有限时只拒绝不提交
 - 12 若没有有限可接受步长 则
 - 13 返回最后合法 $w, J, g, P_w, k_{\text{done}}, \ell_{\text{done}}, c_{\text{reset}}, \text{line_search_failed}$, 诊断记录搜索区间与末次方向导数
 - 14 结束
 - 15 令 $w^+ \leftarrow w + \lambda p$ 并新鲜计算 J^+, g^+, P_{w^+} ; 若任一结果非有限或概率未归一化, 则返回未改动的最后合法状态与 numerical_failure, 诊断为候选求值阶段 $(k_{\text{done}}, \lambda)$
 - 16 计算 $s \leftarrow w^+ - w, y \leftarrow g^+ - g$ 与双相对变化 q_w, q_J ; 以 B^0 按阻尼曲率规则构造 B^+ , 若曲率分母或 B^+ 不可靠则置 $B^+ \leftarrow I$ 并令 $c_{\text{reset}} \leftarrow c_{\text{reset}} + 1$
 - 17 核验 B^+ 有限、对称正定后原子提交 $(w, J, g, P_w, B) \leftarrow (w^+, J^+, g^+, P_{w^+}, B^+)$, 令 $k_{\text{done}} \leftarrow k_{\text{done}} + 1$
 - 18 若 $\|g\|_{\infty} \leq \varepsilon_g$ 则
 - 19 返回最后合法状态与 converged, 最终诊断记录梯度及期望残差证书和曲率重置数
 - 20 结束
 - 21 若 $q_w \leq \varepsilon_w$ 且 $q_J \leq \varepsilon_J$ 则
 - 22 返回最后合法状态与 numerical_failure, 最终诊断记录具体原因为“数值停滞但梯度未达标”、双相对变化和曲率重置数
 - 23 结束
- 24 结束
- 25 返回最后合法 $w, J, g, P_w, k_{\text{done}}, \ell_{\text{done}}, c_{\text{reset}}, \text{budget_stop}$, 最终诊断记录外层预算耗尽与期望残差

算法实现说明：BFGS 允许一般有限实值特征；非负尺度条件只属于 IIS。梯度证书返回 `converged`，双相对变化阈值只返回 `numerical_failure` 并把“数值停滞”写入诊断，实际耗尽 $T_{\max}$ 才返回 `budget_stop`。完整 C1-C14 契约

读前自检：复杂度分析：约束与指数族形式。 在“预测时间复杂度”成立时处理约束与指数族形式：请由 s_x 的总成本剥离一次迭代或一次样本因子，并以稠密特征或结构化输出会改变 Ks_x 项判定结果。

复杂度分析

预测时间复杂度。 对一个具有 s_x 个激活特征的新输入，计算 K 类得分、稳定配分函数和最大概率类别约为 $O(Ks_x)$ 。

存储与空间复杂度。 保存稀疏训练特征和概率工作量约为 $O(Ns + NK)$ ，完整 BFGS 矩阵需 $O(n^2)$ 。有限内存拟 Newton 法保存 h 对历史向量时为 $O(hn)$ 。**复杂度假设：**类别得分可由稀疏激活特征直接累计；稠密特征或结构化输出会改变 Ks_x 项。

读前自检：改进的迭代尺度法。 改进的迭代尺度法所用的明确前提是“从条件对数似然增量构造可按坐标分离的下界，推导 IIS 每个增量 δ_i 的一维方程”；完成计算 $e^{\sum_i [f_i/f^\#](\delta_i f^\#)} \leq \sum_i \frac{f_i}{f^\#} e^{\delta_i f^\#}$ ，两边之差并判号后，核对不等号方向、边界取等和定义域彼此相容。

读前自检：改进的迭代尺度算法 IIS。 IIS 用 $\sum_i f_i/f^\# = 1$ 对指数项应用 Jensen 上界；请展开该上界并对增量 δ_i 求导，核对常总特征量时得到一维尺度方程。

17.5 改进的迭代尺度法

阅读目标：把条件对数似然增量下界分离成每个特征参数的一维方程。

对象：非负特征 $f_i(x, y)$ 、总特征量 $f^\# = \sum_i f_i$ 、当前模型 R_w 与增量 δ_i 。

合法条件： $f_i \geq 0$ ；使用 $-\log a \geq 1 - a$ 与指数函数的加权 Jensen 不等式；零总特征项不依赖增量。

第一步：先写 $L(w + \delta) - L(w)$ ，再把归一化项表示成当前模型下 $e^{\sum_i \delta_i f_i}$ 的期望。

推导目标

从条件对数似然增量构造可按坐标分离的下界，推导 IIS 每个增量 δ_i 的一维方程，并说明常特征总量时为何有闭式解。

推导准备

设特征 $f_i(x, y) \geq 0$ ，当前模型为 $R_w(y | x)$ ，新参数为 $w + \delta$ ；记 $f^\#(x, y) = \sum_i f_i(x, y)$ 。使用 $-\log a \geq 1 - a$ 以及凸函数 e^u 的加权 Jensen 不等式；当 $f^\# = 0$ 时全部 $f_i = 0$ ，该项不依赖 δ 。

推导第1步：写出精确似然增量。 IIS 从当前 w 寻找增量 $\delta = (\delta_1, \dots, \delta_n)^T$ 。由新旧条件概率之比，

$$\ell(w + \delta) - \ell(w) = \sum_i \delta_i \tilde{E}(f_i) - \sum_x \tilde{P}(x) \log \sum_y P_w(y | x) e^{\sum_i \delta_i f_i(x, y)}.$$

对第二项使用 $-\log a \geq 1 - a$ ，再在 $f^\# > 0$ 处使用

$$e^{\sum_i [f_i/f^\#](\delta_i f^\#)} \leq \sum_i \frac{f_i}{f^\#} e^{\delta_i f^\#},$$

得到关于各 δ_i 可分的完整下界

$$\begin{aligned} \ell(w + \delta) - \ell(w) &\geq B(\delta | w) \\ &= \sum_i \delta_i \tilde{E}(f_i) - \sum_{x, y} \tilde{P}(x) P_w(y | x) \sum_{i: f^\#(x, y) > 0} \frac{f_i(x, y)}{f^\#(x, y)} (e^{\delta_i f^\#(x, y)} - 1). \end{aligned}$$

当 $f^\#(x, y) = 0$ 时，非负性推出全部 $f_i(x, y) = 0$ ，对应项对 δ 恒为零，因而不进入内层和式。这一约定同时避免了 $0/0$ 。

推导第2步：对分离下界逐坐标求驻点。 记

$$f^\#(x, y) = \sum_{i=1}^n f_i(x, y).$$

逐项求导得到

$$\frac{\partial B}{\partial \delta_i} = \tilde{E}(f_i) - \sum_{x, y} \tilde{P}(x) P_w(y | x) f_i(x, y) e^{\delta_i f^\#(x, y)}.$$

令该导数为零得到尺度方程

$$\sum_{x, y} \tilde{P}(x) P_w(y | x) f_i(x, y) \exp\{\delta_i f^\#(x, y)\} = \tilde{E}(f_i).$$

记左侧为 $g_i(\delta_i)$ ，则

$$g'_i(\delta_i) = \sum_{x, y} \tilde{P}(x) P_w(y | x) f_i(x, y) f^\#(x, y) e^{\delta_i f^\#(x, y)} \geq 0.$$

若模型在某个 $f_i > 0$ 且 $f^\# > 0$ 的配置上有正质量，则 g_i 严格递增，有限根至多一个。有限根存在还要求 $\tilde{E}(f_i)$ 落在 g_i 的值域内；支撑不相容时没有有限根。若 $\tilde{E}(f_i) = E_{P_w}(f_i) = 0$ ，该坐标不被数据或当前模型识别，应固定而不是声称根唯一；若 $\tilde{E}(f_i) = 0 < E_{P_w}(f_i)$ ，极限解为 $\delta_i \rightarrow -\infty$ ，也不存在有限 Newton 根。

若 $f^\#(x, y) \equiv M$ 且 $M > 0$ 为常数，则**推导第3步：化简常特征总量情形。**把 M 移出指数，左侧成为 $e^{M\delta_i} E_{P_w}(f_i)$ ，所以

$$\delta_i = \frac{1}{M} \log \frac{\tilde{E}(f_i)}{E_{P_w}(f_i)}.$$

该闭式只适用于分子、分母均为正的可识别坐标； $M = 0$ 时所有特征恒为零，尺度方程不含参数，不能使用上式。

零坐标分类。 令 $e_i = \tilde{E}(f_i)$ 、 $m_i = E_{P_W}(f_i)$ 。当 $e_i = m_i = 0$ 时，该坐标在当前支撑上不可识别，固定 $\delta_i = 0$ 并继续，不能把整个问题判为不可行；当 $|e_i - m_i| \leq \varepsilon$ 时记为“已匹配”；当 $e_i, m_i > 0$ 且未匹配时才进入有限一维求根。若 $e_i > 0, m_i = 0$ ，经验正质量落在模型零支撑上，才是需要报告的支撑冲突；若 $e_i = 0, m_i > 0$ ，无正则闭式只在 $\delta_i \rightarrow -\infty$ 的边界达到，有限精度实现应按预登记规则删除/固定该稀疏坐标或改用正则化，而不是伪造有限根。

IIS 的每轮更新提高对数似然下界，但通常比利用联合曲率的拟 Newton 法慢。它的教学价值在于把“期望不匹配”转化为每个参数的一维修正，并明确说明归一化因子与特征总量为何进入更新方程。

改进的迭代尺度法 (IIS)：五步阅读

输入。 写出数据对象、固定参数与必须成立的条件。

初始化。 标明主状态、计数器和第一个合法状态。

核心更新。 只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。 写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。 列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 17.2: 改进的迭代尺度法 (IIS)

输入: 非负特征 f_i , 经验分布, 边界坐标处理规则

输出: 最后合法 w, P_w 、期望残差、 $t_{\text{done}}, s_{\text{done}}, q_{\text{done}}$ 、**status** 与最终诊断

数据: $T_{\text{max}}, B_{\text{root}} \in \mathbb{N}_0$; 期望容差 $\varepsilon > 0$; 求根与目标数值容差

- 1 $w \leftarrow 0, t_{\text{done}} \leftarrow 0, s_{\text{done}} \leftarrow 0, q_{\text{done}} \leftarrow 0$, 预计算 $\tilde{E}(f_i)$ 和 $f^\#(x, y)$, 诊断为空
- 2 若经验分布未归一化、特征或 $f^\#$ 为负/非有限、边界规则未登记, 或预算、容差不合法, 则返回零参数、计数 0、**invalid_input** 及字段诊断
- 3 计算初始 P_w 、目标与模型期望; 若配分函数、概率、目标或期望非有限, 则返回最后合法零参数、**numerical_failure** 及初始化阶段诊断
- 4 令 $r \leftarrow \max_i |E_{P_w}(f_i) - \tilde{E}(f_i)|$; 若 $r \leq \varepsilon$, 则返回最后合法零参数与 **converged**, 最终诊断记录“零轮期望匹配证书”
- 5 **当** $t_{\text{done}} < T_{\text{max}}$ **执行**
- 6 令 $r \leftarrow \max_i |E_{P_w}(f_i) - \tilde{E}(f_i)|$; 若 $r \leq \varepsilon$, 则返回最后合法状态与 **converged**, 最终诊断记录期望匹配证书
- 7 在临时向量置 $\delta_i \leftarrow 0$
- 8 **对** $i \leftarrow 1$ **至** n **执行**
- 9 令 $e_i \leftarrow \tilde{E}(f_i), m_i \leftarrow E_{P_w}(f_i)$
- 10 若 $e_i = m_i = 0$ 或 $|e_i - m_i| \leq \varepsilon$, 保持 $\delta_i = 0$ 并记录坐标类别
- 11 若 $e_i > 0, m_i = 0$, 则返回最后合法 $w, P_w, t_{\text{done}}, s_{\text{done}}, q_{\text{done}}, \text{invalid_input}$, 诊断为支撑冲突 (t_{done}, i)
- 12 若 $e_i = 0, m_i > 0$, 则仅应用预登记的有限删除、固定或正则化规则; 规则不能产生有限候选时返回最后合法状态与 **invalid_input**, 诊断为边界坐标 (t_{done}, i)
- 13 对 $e_i, m_i > 0$ 且未匹配的坐标, 在至多 B_{root} 次根函数求值内求单调尺度方程的有限根, 每次令 $q_{\text{done}} \leftarrow q_{\text{done}} + 1$
- 14 若求根预算耗尽且无证书, 则返回最后合法状态与 **budget_stop**, 最终诊断记录坐标 i 与括区间
- 15 若根函数、括区间或有限根非有限, 则返回最后合法状态与 **numerical_failure**, 诊断为求根阶段 (t_{done}, i) ; 否则令 $s_{\text{done}} \leftarrow s_{\text{done}} + 1$
- 16 **结束**
- 17 在临时状态计算 $w^+ \leftarrow w + \delta$ 及 P_{w^+} 、目标和全部模型期望; 若任一结果非有限、概率未归一化或目标下降超出容差, 则返回未改动的最后合法状态与 **numerical_failure**, 诊断为同步验收阶段 t_{done}
- 18 原子提交 $w \leftarrow w^+, P_w \leftarrow P_{w^+}$ 及新目标、期望, 令 $t_{\text{done}} \leftarrow t_{\text{done}} + 1$
- 19 **结束**
- 20 返回最后合法 w, P_w 、期望残差、 $t_{\text{done}}, s_{\text{done}}, q_{\text{done}}, \text{budget_stop}$, 最终诊断记录外层预算耗尽与最大残差

算法实现说明: 核心流程跟踪经验/模型期望残差、逐坐标增量、整轮同时提交和双证书停止; 16 行长框是本章唯一 IIS 稳健实现细节源 完整 C1-C14 契约

17.6 例题、优化计算与练习

例题 17.1 (两事件约束的最大熵分布). 结果集合为 $\{a, b, c, d, e\}$, 约束为 $P(a) + P(b) = 3/10$ 和总概率为 1。求最大熵分布, 并写出对应的单特征指数模型。

例题 17.1 解答

读题翻译 约束只固定了两组结果的总概率; 最大熵要求先在各组内部均匀分配, 再把同一解写成单特征指数模型。

已知与合法条件 支持集为五个结果, $P(\{a, b\}) = 3/10$ 、 $P(\{c, d, e\}) = 7/10$; 特征取 $f(y) = \mathbf{1}\{y \in \{a, b\}\}$ 。

为什么想到这个方法 熵在概率单纯形上严格凹; 固定一组的总质量后, 该组内部等概率分配唯一地最大化组内熵。

方法选择 先按两组固定质量分别均分得到唯一最大熵分布, 再由指数模型的组质量方程解 e^w 和 $Z(w)$, 最后回代归一化。

推导/计算 令 $p = (p_a, p_b, p_c, p_d, p_e)^\top$ 。优化问题及可行域为

$$\begin{aligned} \max_{p \in \mathbb{R}^5} \quad & H(p) = - \sum_{y \in \{a, b, c, d, e\}} p_y \log p_y, \\ \text{s.t.} \quad & p_y \geq 0, \quad \sum_y p_y = 1, \\ & p_a + p_b = \frac{3}{10}, \end{aligned}$$

其中约定 $0 \log 0 = 0$ 。在两个组内分别应用熵的严格凹性, 固定组概率和时唯一最优点是均分点, 故

$$\begin{aligned} p_a &= p_b = \frac{1}{2} \cdot \frac{3}{10} = \frac{3}{20}, \\ p_c &= p_d = p_e = \frac{1}{3} \left(1 - \frac{3}{10}\right) = \frac{7}{30}. \end{aligned}$$

令 $f(y) = \mathbf{1}\{y \in \{a, b\}\}$, 相应单特征指数模型为

$$P_w(y) = \frac{e^{wf(y)}}{Z(w)}, \quad Z(w) = 2e^w + 3.$$

由约束得到可复算参数链

$$\begin{aligned} \frac{2e^w}{2e^w + 3} &= \frac{3}{10} \\ \Rightarrow 20e^w &= 6e^w + 9 \\ \Rightarrow e^w &= \frac{9}{14} \\ \Rightarrow w &= \log \frac{9}{14}. \end{aligned}$$

独立核验 $e^w = 9/14$ 给出 $Z = 2(9/14) + 3 = 30/7$; 前两项各为 $(9/14)/(30/7) = 3/20$, 其余三项各为 $1/(30/7) = 7/30$ 。五项非负、和为 1, 且前两项和为 $3/10$ 。

结论 唯一最大熵分布为 $(3/20, 3/20, 7/30, 7/30, 7/30)$; 对应单特征指数模型满足 $w = \log(9/14)$ 、 $Z(w) = 30/7$ 。

读前自检：适用条件与局限：例题、优化计算与练习。 最大熵模型用于有限输出且特征期望约束可行的任务; 请核对每个 x 上的 $P(y | x)$ 非负归一、经验约束存在可行解, 并在任一条件失败时判定该模型规格不可直接训练。

适用条件与局限性

适用条件。最大熵模型适合输出空间有限、能够构造有意义特征、训练统计量可可靠估计且需要条件概率输出的分类或标注问题。特征可以重叠而无须条件独立；优化前必须确认约束可行、样本支撑足够、参数规模与样本量相容。

方法局限

大量稀疏特征会带来高计算与存储成本；完全或近完全分离可能使无正则化参数发散；硬期望约束对抽样噪声敏感；模型只在选定特征所张成的指数族内表达关系，遗漏关键交互特征时，最大熵原则不能自动创造该结构。

读前自检：常见错误与误用边界：例题、优化计算与练习。把例题、优化计算与练习放在“边界框首项禁止忘记对每个 x 按 y 归一化，或用全局一个配分常数替代 $Z_w(x)$ ”下考察：把固定错误“忘记对每个 x 按 y 归一化，或用全局一个配分常数替代 $Z_w(x)$ ”中的对象、操作与结论按本节定义拆开，指出第一个不满足的定义条件，再把该处改为本节允许的写法，并检查改写后的运算或判断有定义，且不再触发“忘记对每个 x 按 y 归一化，或用全局一个配分常数替代 $Z_w(x)$ ”。

常见错误

1. 把联合经验分布 $\tilde{P}(x, y)$ 与模型联合量 $\tilde{P}(x)P(y | x)$ 混为一谈；
2. 忘记对每个 x 按 y 归一化，或用全局一个配分常数替代 $Z_w(x)$ ；
3. 在最小化负对数似然时把梯度符号写成经验期望减模型期望；
4. 对冗余特征仍宣称参数唯一，忽略共同平移或线性相关方向；
5. 直接计算巨大指数，未使用减最大得分与 $\log\text{-sum-exp}$ 。

易混淆概念对比

概念对比。		
概念	约束或目标	关键含义
最大熵	满足特征期望约束时最大化 $H(P)$	从可行分布中选择最少额外偏置者
条件极大似然	最大化 $\sum \tilde{P}(x, y) \log P_w(y x)$	在指数参数族中拟合观测条件分布
逻辑斯谛回归	线性得分经二类或多类指数归一化	最大熵指数族在特定特征设计下的实例
朴素贝叶斯	建模 $P(Y)P(X Y)$ 并作条件独立假设	生成式分解，不以熵约束为定义

本章共 18 道练习。每道题干后立即给出同号解析；长解析可自然跨页，续页标题保留题号。

练习 17.1. 在三个结果上没有其他约束。用拉格朗日乘子证明最大熵分布为 $(1/3, 1/3, 1/3)$ 。

练习 17.1 解析

令概率向量 $p \in \mathbb{R}^3$ ，并约定 $0 \log 0 = 0$ 。目标与可行域为

$$\max_{p \in \Delta_3} H(p), \quad H(p) = - \sum_{j=1}^3 p_j \log p_j, \quad \Delta_3 = \left\{ p : p_j \geq 0, \sum_{j=1}^3 p_j = 1 \right\}.$$

在正概率内点写拉格朗日函数

$$L(p, \lambda) = - \sum_{j=1}^3 p_j \log p_j + \lambda \left(\sum_{j=1}^3 p_j - 1 \right).$$

驻点与归一化给出

$$\begin{aligned} \frac{\partial L}{\partial p_j} = -(\log p_j + 1) + \lambda = 0 &\implies p_j = e^{\lambda-1}, \\ \sum_{j=1}^3 p_j = 1 &\implies 3e^{\lambda-1} = 1 \implies p_j = \frac{1}{3}. \end{aligned}$$

Δ_3 是非空紧凸集， H 在其上连续且严格凹；因此该可行驻点是唯一全局最大点。

练习 17.2. 四个结果满足 $P_1 + P_2 = 1/2$ ，其余没有约束。求最大熵分布。

练习 17.2 解析

可行域为

$$\mathcal{C} = \left\{ p \in \mathbb{R}^4 : p_j \geq 0, \sum_{j=1}^4 p_j = 1, p_1 + p_2 = \frac{1}{2} \right\},$$

所以也有 $p_3 + p_4 = 1/2$ 。对固定和为 s 的两个非负数，熵的严格凹性给出

$$-u \log u - v \log v \leq -2 \frac{s}{2} \log \frac{s}{2}, \quad u + v = s,$$

且等号当且仅当 $u = v = s/2$ 。分别取 $s = 1/2$ ，得到

$$p_1 = p_2 = p_3 = p_4 = \frac{1}{4}, \quad H(p) = -4 \cdot \frac{1}{4} \log \frac{1}{4} = \log 4.$$

均匀分布属于 $\mathcal{C}$ ，并由严格凹性成为唯一最大熵解。

练习 17.3. 说明为什么“最大熵”不能解释为“无论已知什么都取均匀分布”，并给出一个反例约束。

练习 17.3 解析

最大熵是在约束可行域内优化，而不是先验地选择均匀分布：

$$p^\star \in \arg \max_{p \in \mathcal{C}} H(p), \quad \mathcal{C} \subseteq \Delta_K.$$

练习 17.3 解析 (续)

例如在二点空间上施加 $P_1 = 0.8$, 则

$$\mathcal{C} = \{(p_1, p_2) \in \Delta_2 : p_1 = 0.8\} = \{(0.8, 0.2)\}.$$

此时

$$(0.5, 0.5) \notin \mathcal{C}, \quad \arg \max_{p \in \mathcal{C}} H(p) = \{(0.8, 0.2)\}.$$

因此最大熵只在约束未确定的自由度上保持最小额外偏置, 不能覆盖已知概率信息。

练习 17.4. 训练集中 $(a, 1), (a, 1), (a, 0), (b, 0)$ 各出现一次。写出 $\tilde{P}(x, y)$ 和 $\tilde{P}(x)$ 。

练习 17.4 解析

样本量 $N = 4$, 经验联合分布按频数除以 N 定义。完整表为

	$y = 0$	$y = 1$	$\tilde{P}(x)$
$x = a$	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{3}{4}$
$x = b$	$\frac{1}{4}$	0	$\frac{1}{4}$

也即

$$\tilde{P}(x, y) = \frac{1}{4} \begin{cases} 2, & (x, y) = (a, 1), \\ 1, & (x, y) \in \{(a, 0), (b, 0)\}, \\ 0, & \text{其他组合}. \end{cases}$$

边缘化与归一化复核为

$$\tilde{P}(a) = \frac{1}{4} + \frac{1}{2} = \frac{3}{4}, \quad \tilde{P}(b) = \frac{1}{4}, \quad \sum_{x, y} \tilde{P}(x, y) = \sum_x \tilde{P}(x) = 1.$$

因此经验联合分布与边缘分布均已正确归一化, 且 $\tilde{P}(a) = 3/4$ 、 $\tilde{P}(b) = 1/4$ 。

练习 17.5. 令 $f(x, y) = \mathbf{1}\{y = 1\}$ 。证明期望匹配约束等价于模型的经验输入加权正类概率等于训练正类比例。

练习 17.5 解析

对 $f(x, y) = \mathbf{1}\{y = 1\}$, 经验期望简化为

$$\begin{aligned} \tilde{E}(f) &= \sum_{x, y} \tilde{P}(x, y) \mathbf{1}\{y = 1\} \\ &= \sum_x \tilde{P}(x, 1) = \tilde{P}(Y = 1). \end{aligned}$$

模型期望使用联合量 $\tilde{P}(x)P_w(y | x)$, 故

$$\begin{aligned} E_{P_w}(f) &= \sum_{x, y} \tilde{P}(x)P_w(y | x) \mathbf{1}\{y = 1\} \\ &= \sum_x \tilde{P}(x)P_w(1 | x). \end{aligned}$$

练习 17.5 解析 (续)

于是期望匹配约束恰等价于

$$E_{P_w}(f) = \tilde{E}(f) \iff \sum_x \tilde{P}(x) P_w(1 | x) = \tilde{P}(Y = 1).$$

因此该特征的期望匹配要求模型加权后的正类概率恰好等于经验正类边缘概率。

练习 17.6. 若两个特征完全相同 $f_1 = f_2$, 说明约束集合与参数表示分别会发生什么。

练习 17.6 解析

若 $f_1 = f_2 = f$, 两条期望约束完全重复:

$$E_P(f_1) = \tilde{E}(f_1) \iff E_P(f_2) = \tilde{E}(f_2).$$

指数得分只依赖参数和

$$w_1 f_1(x, y) + w_2 f_2(x, y) = (w_1 + w_2) f(x, y).$$

因此对任意 $t \in \mathbb{R}$, 有不变链

$$(w_1, w_2) \mapsto (w_1 + t, w_2 - t) \implies w_1 + w_2 \text{ 不变} \implies P_{w_1, w_2}(y | x) \text{ 不变}.$$

约束集合没有改变, 但参数沿 $(1, -1)^\top$ 方向不可识别; 可合并重复特征或增加可识别约束。

练习 17.7. 只有一个二值输出特征 $f(x, y) = \mathbf{1}\{y = 1\}$, 求 $P_w(1 | x)$ 与 $P_w(0 | x)$ 。

练习 17.7 解析

输出支持集为 $\mathcal{Y} = \{0, 1\}$, 且 $f(x, 0) = 0$, $f(x, 1) = 1$ 。因此

$$Z_w(x) = \sum_{y \in \{0, 1\}} e^{w f(x, y)} = 1 + e^w.$$

两个条件概率为

$$P_w(1 | x) = \frac{e^w}{1 + e^w}, \quad P_w(0 | x) = \frac{1}{1 + e^w}.$$

对任意有限 $w \in \mathbb{R}$, 边界与归一化满足

$$0 < P_w(y | x) < 1, \quad P_w(0 | x) + P_w(1 | x) = 1.$$

该特征不依赖 x , 所以所得二项逻辑斯谛概率也不随输入变化。

练习 17.8. 证明对所有特征权重同时加上一个只产生输入函数 $c(x)$ 的参数方向, 不改变条件概率。

练习 17.8 解析

设原得分为 $s_w(x, y)$, 新参数方向对同一 x 的所有 y 只增加 $c(x)$ 。新配分函数满足

$$\begin{aligned} Z'(x) &= \sum_{y'} e^{s_w(x, y') + c(x)} \\ &= e^{c(x)} \sum_{y'} e^{s_w(x, y')} \\ &= e^{c(x)} Z_w(x). \end{aligned}$$

故条件概率具有消去链

$$\begin{aligned} P'(y | x) &= \frac{e^{s_w(x, y) + c(x)}}{Z'(x)} \\ &= \frac{e^{c(x)} e^{s_w(x, y)}}{e^{c(x)} Z_w(x)} \\ &= P_w(y | x). \end{aligned}$$

只产生 $c(x)$ 的参数方向不改变条件分布, 因而属于不可识别方向。

练习 17.9. 给定某输入的三类得分 $(2, 0, -1)$, 写出稳定计算条件概率的方法。

练习 17.9 解析

设得分向量 $s = (2, 0, -1)^T$, 先取有限最大值 $m = \max_j s_j = 2$ 。稳定的 log-sum-exp 为

$$\text{LSE}(s) = m + \log \sum_j e^{s_j - m} = 2 + \log(1 + e^{-2} + e^{-3}).$$

于是概率链为

$$\begin{aligned} p &= \frac{(e^2, 1, e^{-1})}{e^2 + 1 + e^{-1}} \\ &= \frac{(1, e^{-2}, e^{-3})}{1 + e^{-2} + e^{-3}} \\ &\approx (0.8438, 0.1142, 0.0420). \end{aligned}$$

共同减去 m 不改变归一化结果, 却使最大指数等于 1; 若任一得分非有限, 应先报告输入或数值失败而不是继续归一化。

练习 17.10. 从 $\log P_w(y | x) = w^T f(x, y) - \log Z_w(x)$ 推导 J 的第 i 个梯度分量。

练习 17.10 解析

设 $w, f(x, y) \in \mathbb{R}^n$ 。条件负对数似然可写为

$$J(w) = \sum_x \tilde{P}(x) \log Z_w(x) - w^T \tilde{E}(f), \quad Z_w(x) = \sum_y e^{w^T f(x, y)}.$$

练习 17.10 解析 (续)

对第 i 个坐标求导, 得到

$$\begin{aligned}\frac{\partial}{\partial w_i} \log Z_w(x) &= \frac{\sum_y e^{w^\top f(x,y)} f_i(x,y)}{Z_w(x)} \\ &= \sum_y P_w(y | x) f_i(x,y).\end{aligned}$$

因此

$$\begin{aligned}\frac{\partial J}{\partial w_i} &= \sum_x \tilde{P}(x) \sum_y P_w(y | x) f_i(x,y) - \tilde{E}(f_i) \\ &= E_{P_w}(f_i) - \tilde{E}(f_i).\end{aligned}$$

所以梯度第 i 个分量就是模型特征期望与经验特征期望之差。

练习 17.11. 为什么最大熵模型的负对数似然是凸函数? 请用任意方向 v 说明。

练习 17.11 解析

设 $f(x, Y), v \in \mathbb{R}^n$ 。Hessian 是条件协方差矩阵的非负加权和:

$$\nabla^2 J(w) = \sum_x \tilde{P}(x) \text{Cov}_{P_w(\cdot|x)}[f(x, Y)].$$

对任意方向 v , 有条件到结论链

$$\begin{aligned}v^\top \nabla^2 J(w) v &= \sum_x \tilde{P}(x) \text{Var}_{P_w(\cdot|x)}(v^\top f(x, Y)) \\ &\geq 0 \implies \nabla^2 J(w) \geq 0 \implies J \text{ 为凸函数}.\end{aligned}$$

若某个非零 v 使上述条件方差处处为零, 则该方向可能不可识别, 故一般只能推出凸性而非严格凸性。

练习 17.12. BFGS 某轮有 $y_k^\top s_k \leq 0$ 。说明为什么不应机械使用标准更新, 并给出处理方式。

练习 17.12 解析

记

$$s_k = w_{k+1} - w_k, \quad y_k = \nabla J(w_{k+1}) - \nabla J(w_k), \quad \rho_k = (y_k^\top s_k)^{-1}.$$

标准逆 Hessian 更新为

$$H_{k+1} = (I - \rho_k s_k y_k^\top) H_k (I - \rho_k y_k s_k^\top) + \rho_k s_k s_k^\top.$$

正定保持所需曲率条件是

$$H_k > 0, \quad y_k^\top s_k > 0 \implies H_{k+1} > 0.$$

练习 17.12 解析 (续)

若 $y_k^T s_k \leq 0$, 则 ρ_k 无效或符号错误, 不能机械代入。可跳过本次更新, 或用阻尼向量 $\tilde{y}_k$ 保证

$$s_k^T \tilde{y}_k \geq \varepsilon \|s_k\|_2^2 > 0,$$

必要时把 H_k 重置为正定对角矩阵, 并复查线搜索与梯度的有限性。

练习 17.13. 若 $f^\# \equiv 2$, 某特征经验期望为 0.30, 当前模型期望为 0.20, 求 IIS 增量。

练习 17.13 解析

这里 $M = f^\# = 2 > 0$, 且经验期望与模型期望均为正。IIS 尺度方程为

$$0.20e^{2\delta} = 0.30.$$

逐步求解得到

$$\delta = \frac{1}{2} \log \frac{0.30}{0.20} = \frac{1}{2} \log 1.5 \approx 0.2027 > 0.$$

因此参数按 $w_i^+ = w_i + \delta$ 增加; 随后必须重算配分函数, 不能只改某一个概率分量。

练习 17.14. 若某特征经验期望为 0 而当前模型期望为正, 常数 $f^\#$ 公式给出什么极限? 应如何处理?

练习 17.14 解析

设常数 $f^\# = M > 0$ 且当前模型期望 $E_{P_w}(f) > 0$ 。闭式增量形式为

$$\delta = \frac{1}{M} \log \frac{\tilde{E}(f)}{E_{P_w}(f)}.$$

当 $\tilde{E}(f) = 0$ 时, 只能取边界极限

$$\tilde{E}(f) \downarrow 0 \implies \frac{\tilde{E}(f)}{E_{P_w}(f)} \downarrow 0 \implies \delta \rightarrow -\infty.$$

因此尺度方程没有有限根, 有限精度实现不得执行“无穷更新”。应先核查零频数, 再选择删除或合并稀疏特征, 或用平滑、正则化把最优参数留在有限域内。

练习 17.15. 说明 IIS 为什么需要在一次外层迭代中用同一旧模型计算全部 δ_i , 再同时更新。

练习 17.15 解析

在第 t 轮, 全部一维尺度方程都以同一旧状态 $w^{(t)}$ 及同一分布 $P_{w^{(t)}}$ 构造:

$$g_i(\delta_i^{(t)}; P_{w^{(t)}}) = \tilde{E}(f_i), \quad i = 1, \dots, n.$$

练习 17.15 解析 (续)

求得整组增量后才进行同步状态更新

$$\delta^{(t)} = (\delta_1^{(t)}, \dots, \delta_n^{(t)})^\top, \quad w^{(t+1)} = w^{(t)} + \delta^{(t)}.$$

若先改一个坐标, 状态会变成

$$w^{(t)} \rightarrow w^{(t)} + \delta_1^{(t)} e_1 \implies P_w \text{ 已改变},$$

后续旧方程便不再对应同一个可分下界, 原单调改进论证随之失效。

练习 17.16. 在例题中验证所得分布的熵比组内不均分方案 (0.1, 0.2, 7/30, 7/30, 7/30) 更大。

练习 17.16 解析

两方案的后三项相同, 只需比较前两项。令

$$h(p) = -p \log p - (0.3 - p) \log(0.3 - p), \quad 0 < p < 0.3.$$

其导数链为

$$\begin{aligned} h'(p) &= \log \frac{0.3 - p}{p}, \\ h'(p) &= 0 \iff p = 0.15, \\ h''(p) &= -\frac{1}{p} - \frac{1}{0.3 - p} < 0. \end{aligned}$$

因此 $p = 0.15$ 是唯一最大点, 而且两种完整分布的熵差为

$$\begin{aligned} H_{\text{equal}} - H_{\text{unequal}} &= -0.3 \log 0.15 + 0.1 \log 0.1 + 0.2 \log 0.2 \\ &\approx 0.01697 > 0. \end{aligned}$$

因此在约束允许的分配中, 等分剩余质量取得唯一的最大熵。

练习 17.17. 某模型的两个特征梯度为 $(0.04, -0.02)^T$ 。解释每个符号在最小化 J 时建议的修正方向。

练习 17.17 解析

设最小化目标的梯度为

$$g = \nabla J(w) = (0.04, -0.02)^T.$$

取步长 $\eta > 0$ 时, 负梯度更新为

$$w^+ = w - \eta g = w + \eta(-0.04, 0.02)^T.$$

故 w_1 应减小、 w_2 应增大。对充分小的 η , 一阶变化为

$$J(w^+) - J(w) = -\eta \|g\|_2^2 + O(\eta^2) < 0.$$

具体步长仍须由曲率或线搜索确定, 不能把期望差直接当作最终参数增量。

练习 17.18. 设计最大熵模型的验收清单，至少覆盖概率、约束、优化与数值四类检查。

练习 17.18 解析

设 $w, f(x, y) \in \mathbb{R}^n$ ，验收时先检查概率对象及支持集：

$$\forall x, y \in \mathcal{Y} : \quad P_w(y | x) \geq 0, \quad \sum_{y \in \mathcal{Y}} P_w(y | x) = 1, \quad \log Z_w(x) \in \mathbb{R}.$$

约束残差向量与优化诊断量可定义为

$$r_i = E_{P_w}(f_i) - \tilde{E}(f_i), \quad \|r\|_\infty \leq \varepsilon_{\text{mom}}, \quad \|\nabla J(w)\|_2 \leq \varepsilon_{\text{opt}}.$$

完整清单至少包括

概率	P_w 非负、归一化，输出支持与题设一致
约束	$\ r\ _\infty$ 及每个超差坐标
优化	$J(w)$ 有限、梯度范数、相对改变量、停止原因
数值	得分、log-sum-exp、曲率量均为有限实数

此外应报告冗余特征、正则化与维数核对，不能只凭训练准确率验收。

读前自检：本章结论与下一步。 最大熵模型章末由“满足特征期望约束的条件分布与指数族参数”落到“IIS 最大化可分下界，BFGS 沿联合曲率求解，并先检查有限根与可行域”；请把前者产出和后者输入逐项对齐，固定核对前者末项的输出类型能否作为后者首项的输入类型。

本章结论与下一步

核心结论： 满足特征期望约束的条件分布与指数族参数

关键依据： 由 Lagrange 驻点、归一化和对偶微分得到指数族、梯度与协方差 Hessian

可执行自检： IIS 最大化可分下界，BFGS 沿联合曲率求解，并先检查有限根与可行域

适用边界： 需要从矩条件构造条件概率模型且特征与支撑可信时

下一步： 进入支持向量机的约束优化；本章自检失败则返回相应定义、对偶或尺度方程

- 概念：** 能否区分最大熵原理、条件最大熵模型和均匀分布？未通过则回看第 1、2 节。
- 推导：** 能否从期望约束写出拉格朗日函数，并逐行得到 P_w 与 $Z_w(x)$ ？未通过则回看第 3 节。
- 等价性：** 能否推导 J 的梯度和 Hessian，并说明与极大似然及期望匹配的关系？未通过则回看第 4 节。
- 算法：** 能否叙述 IIS 和 BFGS 的输入、初始化、更新、停止、收敛与复杂度？未通过则回看第 4、5 节。
- 应用：** 能否诊断不可行约束、参数冗余、零频数和指数溢出？未通过则回看第 6 节；五项均可独立回答，并能完成每节至少两道练习，才算达到本章学习目标。

第18章 支持向量机

读前自检：本章地图：支持向量机。 支持向量机章地图把“从几何间隔直达原始-对偶、核方法与SMO”作为主线；请为其中首条箭头补出必要条件，并检查终点仍落在本章声明的输出域。

读前自检：本章可检验学习目标。 支持向量机的首个可检验目标是“从超平面距离出发区分函数间隔与几何间隔，并把最大几何间隔转化为硬间隔凸二次规划”；请从超平面距离出发区分函数间隔与几何间隔，并把最大几何间隔转化为硬间隔凸二次规划并写出中间结果，再按“中间结果逐项包含首目标“从超平面距离出发区分函数间隔与几何间隔，并把最大几何间隔转化为硬间隔凸二次规划”声明的对象、条件与结论”验收。

读前自检：最短先修。 支持向量机的最短先修明确要求“本章需要向量内积与范数、超平面、点到超平面的距离、凸集与凸函数、凸二次规划、拉格朗日函数、弱对偶与强对偶、Slater条件、KKT条件、正定和半正定矩阵”；请把首项“本章需要向量内积与范数、超平面、点到超平面的距离、凸集与凸函数、凸二次规划、拉格朗日函数、弱对偶与强对偶、Slater条件、KKT条件、正定和半正定矩阵”中的第一个先修对象写成定义域-运算-输出三元组，并以“该三元组逐项满足首项“本章需要向量内积与范数、超平面、点到超平面的距离、凸集与凸函数、凸二次规划、拉格朗日函数、弱对偶与强对偶、Slater条件、KKT条件、正定和半正定矩阵”的对象类型与成立条件”判断能否进入本章。

读前自检：先修自检。 支持向量机先修自检固定核验“能否写出点 x 到超平面 $w^T x + b = 0$ 的距离 $|w^T x + b|/\|w\|_2$ ”；请写出点 x 到超平面 $w^T x + b = 0$ 的距离 $|w^T x + b|/\|w\|_2$ 并写出中间结果，再按“ $w^T x + b = 0$ 的计算或证明结果满足首项所列等式、定义域或判断”明确判为通过或失败。

读前自检：依赖路线。 支持向量机依赖路线从“内积与超平面→点到平面的距离→几何间隔”进入“间隔最大化→硬间隔原始问题→拉格朗日对偶与KKT”；请写出箭头成立所需的定义域条件，并核对前者输出能作为后者输入。

本章地图

核心问题：怎样把分类间隔写成有唯一分离超平面的凸优化问题

可检验学习目标：

- 从超平面距离出发区分函数间隔与几何间隔，并把最大几何间隔转化为硬间隔凸二次规划；
- 完整推导原始问题、拉格朗日对偶、强对偶与KKT条件，解释支持向量为何决定分类器；
- 从线性不可分数据推导松弛变量、软间隔对偶、合页损失及不同支持向量的KKT分段状态；
- 掌握核技巧、正定核充要条件、常用核和非线性支持向量机，能够检查Gram矩阵半正定性；
- 掌握SMO两变量解析更新、变量选择、阈值更新、停止条件、复杂度、适用范围和数值退化处理。

最短先修：本章需要向量内积与范数、超平面、点到超平面的距离、凸集与凸函数、凸二次规划、拉格朗日函数、弱对偶与强对偶、Slater条件、KKT条件、正定和半正定矩阵。训练集记为 $T = \{(x_i, y_i)\}_{i=1}^N$ ，其中 $x_i \in \mathbb{R}^d$ 为列向量， $y_i \in \{-1, +1\}$ 。

依赖路线：内积与超平面 → 点到平面的距离 → 几何间隔；间隔最大化 → 硬间隔原始问题 → 拉格朗日对偶与 KKT；允许约束违背 → 松弛变量 → 软间隔与合页损失；特征映射 → 内积替换 → 正定核 → 非线性支持向量机；软间隔对偶 → 两变量子问题 → SMO。

完成标准与返回：间隔尺度不清时回到节 18.2、18.3；对偶或核条件失败时回看节 18.4、18.7

模型认识卡：支持向量机

任务与输入：二分类， $x \in \mathbb{R}^d$ 、 $y \in \{-1, +1\}$ 。 **输出类型：**带间隔得分与类别。

模型：线性超平面或支持向量核展开。 **策略：**最小化参数范数与合页违约代价。 **算法：**原始/对偶凸二次规划，核对偶可用 SMO。

预测：取 $\sum_i \alpha_i y_i K(x_i, x) + b$ 的符号。 **关键假设与边界：**核的 Gram 矩阵须半正定；硬间隔要求线性可分，软间隔仍需验证 C 与核参数。

本章符号表

符号	取值或维数	含义
w, b	$\mathbb{R}^d, \mathbb{R}$	超平面法向量与截距
$g(x)$	$\mathbb{R}$	判别得分 $w^T x + b$ 或其核展开
$\hat{\gamma}_i$	$\mathbb{R}$	样本函数间隔 $y_i(w^T x_i + b)$
γ_i	$\mathbb{R}$	样本几何间隔 $\hat{\gamma}_i / \ w\ _2$
α_i	$[0, C]$	对偶变量；硬间隔时上界为 $+\infty$
ξ_i	$[0, \infty)$	第 i 个样本的松弛变量
C	$(0, \infty)$	软间隔违约惩罚系数
$K(x, z)$	$\mathbb{R}$	核函数，等于特征空间内积
E_i	$\mathbb{R}$	SMO 误差 $g(x_i) - y_i$
η	$[0, \infty)$	SMO 曲率 $K_{11} + K_{22} - 2K_{12}$

读前自检：支持向量机。 支持向量机把问题限定在“支持向量机在特征空间中学习分离超平面”；请标出 $f(x) = \text{sign } g(x)$ 两侧的 shape 并完成一次乘法或正交检查，检查是否得到线性、软间隔和核化三种形式共享这条主线。

18.1 线性可分支持向量机

支持向量机在特征空间中学习分离超平面。模型是 $g(x) = w^T x + b$ 及 $f(x) = \text{sign } g(x)$ ；策略是最大化离训练样本最近的间隔；算法是求解凸二次规划或其对偶。线性、软间隔和核化三种形式共享这条主线。

读前自检：线性可分支持向量机与硬间隔最大化。 在“若存在 (w, b) 使所有样本满足 $y_i(w^T x_i + b) > 0$ ，训练集线性可分”成立时处理线性可分支持向量机与硬间隔最大化：请标出 $y_i(w^T x_i + b) > 0$ 两侧的 shape 并完成一次乘法或正交检查，并以可分超平面通常不唯一，硬间隔最大化在规范化后选择离最近样本最远的超平面判定结果。

若存在 (w, b) 使所有样本满足 $y_i(w^T x_i + b) > 0$, 训练集线性可分。可分超平面通常不唯一, 硬间隔最大化在规范化后选择离最近样本最远的超平面。

读前自检：线性可分支持向量机。 线性可分支持向量机所用的明确前提是“对线性可分训练集, 通过硬间隔最大化求得 (w^*, b^*) 后”; 完成标出 $w^{*T}x + b^*$ 两侧的形状并完成一次乘法或正交检查后, 核对它把“拟合训练标签”和“选择更稳健的分界”合并为一个约束优化问题。

阅读目标：利用分类超平面的正尺度不变性固定函数间隔。

对象：线性可分样本、 $w \neq 0$ 、函数间隔 $y_i(w^T x_i + b)$ 与几何间隔。

合法条件： (w, b) 可同乘任意正数而不改变分类边界; 最小函数间隔为正。

第一步：先把 (w, b) 统一缩放, 使最小函数间隔恰为 1。

定义 18.1 (线性可分支持向量机). 对线性可分训练集, 通过硬间隔最大化求得 (w^*, b^*) 后,

$$w^{*T}x + b^* = 0, \quad f(x) = \text{sign}(w^{*T}x + b^*)$$

分别称为最大间隔分离超平面与线性可分支持向量机。

模型。法向量 w 决定超平面方向, b 决定位置; 得分符号给出类别, 得分绝对值只有除以 $\|w\|_2$ 后才具有距离单位。

学习策略。在能正确分类全部训练样本的超平面中, 最大化最小几何间隔。它把“拟合训练标签”和“选择更稳健的分界”合并为一个约束优化问题。

读前自检：函数间隔和几何间隔。 样本 (x_i, y_i) 关于 (w, b) 的函数间隔为 $\hat{\gamma}_i = y_i(w^T x_i + b)$; 请计算全部样本的 $\hat{\gamma}_i$ 并取最小值, 核对训练集函数间隔为 $\hat{\gamma} = \min_i \hat{\gamma}_i$ 。

读前自检：函数间隔。 SVM 样本函数间隔为 $\hat{\gamma}_i = y_i(w^T x_i + b)$, 训练集间隔取最小值; 请计算两个样本的带符号分数并取 $\min_i$, 核对共同缩放 (w, b) 会同比缩放函数间隔。

18.2 超平面、函数间隔与几何间隔

定义 18.2 (函数间隔). 样本 (x_i, y_i) 关于超平面 (w, b) 的函数间隔为

$$\hat{\gamma}_i = y_i(w^T x_i + b),$$

训练集的函数间隔为 $\hat{\gamma} = \min_i \hat{\gamma}_i$ 。

读前自检：几何间隔。 把支持向量机中的几何间隔放在“当 $w \neq 0$ 时”下考察: 把 γ_i 展开一次并检查其类型或边界, 并检查展开后的量满足定义中的域、维数或符号限制。

定义 18.3 (几何间隔). 当 $w \neq 0$ 时, 样本和训练集的几何间隔分别为

$$\gamma_i = \frac{y_i(w^T x_i + b)}{\|w\|_2}, \quad \gamma = \min_i \gamma_i.$$

正确分类时 γ_i 等于样本到超平面的距离。

读前自检：间隔最大化。 硬间隔最大化允许同时缩放 (w, b) ；请把最小函数间隔规范为 1，核对最大化几何间隔 $1/\|w\|_2$ 等价于最小化 $\|w\|_2^2/2$ 。

读前自检：线性可分支持向量机的规范定义。 线性可分 SVM 的规范原问题为 $\min_{w,b} \|w\|_2^2/2$ 且 $y_i(w^T x_i + b) \geq 1$ ；请检查一次共同正缩放，核对规范约束消除了尺度自由度。

18.3 硬间隔最大化与原始问题

利用参数尺度自由度，可令训练集最小函数间隔等于 1。最大化几何间隔 $1/\|w\|_2$ 等价于最小化 $\|w\|_2^2/2$ 。

推导目标

把最大几何间隔问题转换为标准的硬间隔凸二次规划，并说明每一次等价变换的尺度条件。

推导准备

训练集线性可分且 $w \neq 0$ 。几何间隔为 $\hat{\gamma}/\|w\|_2$ ； (w, b) 可同乘任意正数，所以可以固定 $\hat{\gamma} = 1$ 。

推导第 1 步：写出几何间隔问题。

$$\max_{w,b,\gamma} \gamma \quad \text{s.t.} \quad \frac{y_i(w^T x_i + b)}{\|w\|_2} \geq \gamma, \quad i = 1, \dots, N.$$

推导第 2 步：引入函数间隔。 令 $\hat{\gamma} = \gamma\|w\|_2$ ，目标改写为最大化 $\hat{\gamma}/\|w\|_2$ ，约束为 $y_i(w^T x_i + b) \geq \hat{\gamma}$ 。尺度自由度允许固定 $\hat{\gamma} = 1$ 。

推导第 3 步：改写单调等价目标。 在 $\hat{\gamma} = 1$ 下，最大化 $1/\|w\|_2$ 等价于最小化 $\|w\|_2$ ，再等价于最小化光滑目标 $\|w\|_2^2/2$ ，得到

$$\min_{w,b} \frac{1}{2} \|w\|_2^2 \quad \text{s.t.} \quad y_i(w^T x_i + b) \geq 1, \quad i = 1, \dots, N.$$

读前自检：线性可分支持向量机学习算法——最大间隔法。 线性可分支持向量机学习算法——最大间隔法依赖“该问题的目标凸、约束仿射，是凸二次规划”；请据此标出 $(w^\star, b^\star)$ 两侧的形状并完成一次乘法或正交检查，并直接核对求得最优 $(w^\star, b^\star)$ 后返回超平面与符号分类函数。

该问题的目标凸、约束仿射，是凸二次规划。求得最优 $(w^\star, b^\star)$ 后返回超平面与符号分类函数。

读前自检：最大间隔分离超平面的存在唯一性。 最大间隔分离超平面的存在唯一性以“若训练集中两类样本均非空且线性可分”为约束；请把 $w^\star$ 展开一次并检查其类型或边界，并确认最优法向量 $w^\star$ 唯一，最大间隔分离超平面也唯一。

定理 18.1 (最大间隔超平面的存在唯一性) 若训练集中两类样本均非空且线性可分，则硬间隔问题存在最优解；最优法向量 $w^\star$ 唯一，最大间隔分离超平面也唯一。

读前自检：证明：最大间隔超平面的存在唯一性。 先锁定最大间隔超平面的存在唯一性的条件“按最小函数间隔的倒数作正比例缩放，便得到满足规范约束的可行点”：把 L ：用到的关键定义展开并完成下一步变形，所得结果应满足因此最大间隔分离超平面唯一。

证明. 线性可分性给出严格分离的 $(\tilde{w}, \tilde{b})$ ；按最小函数间隔的倒数作正比例缩放，便得到满足规范约束的可行点。取一个目标有界的最小化序列 (w_n, b_n) 。由 $\|w_n\|^2/2$ 有界可知 w_n 有界。任选正类样本 x_+ 和负类样本 x_- ，可行性分别给出

$$b_n \geq 1 - w_n^T x_+, \quad b_n \leq -1 - w_n^T x_-.$$

右端随有界的 w_n 保持有界，故 b_n 也有界。于是 (w_n, b_n) 存在收敛子列；仿射不等式定义的可行集闭，极限仍可行且由目标连续性达到下确界，因此最优解存在。

若有两个不同最优法向量 w_1, w_2 ，取相应 b_1, b_2 ，二者的平均仍可行；平方范数严格凸给出

$$\left\| \frac{w_1 + w_2}{2} \right\|^2 < \frac{\|w_1\|^2 + \|w_2\|^2}{2},$$

与二者最优矛盾，故最优法向量只能是同一个 $w^\star$ 。固定它以后，全部规范约束等价于

$$L := \max_{i: y_i=1} (1 - w^{\star T} x_i) \leq b \leq U := \min_{i: y_i=-1} (-1 - w^{\star T} x_i).$$

若 $L < U$ ，取 $b_0 = (L + U)/2$ 和 $\delta = (U - L)/2 > 0$ ，则所有样本都满足 $y_i(w^{\star T} x_i + b_0) \geq 1 + \delta$ 。把 $(w^\star, b_0)$ 同乘 $(1 + \delta)^{-1}$ 仍满足规范约束，却把目标严格降为 $\|w^\star\|^2/[2(1 + \delta)^2]$ ，与最优性矛盾。故 $L = U$ 且 $b^\star = L = U$ 唯一；因此最大间隔分离超平面唯一。 $\square$

阅读目标：从松弛变量的驻点条件推出 $0 \leq \alpha_i \leq C$ 。

对象：松弛变量 ξ_i 、间隔乘子 $\alpha_i \geq 0$ 与非负约束乘子 $\mu_i \geq 0$ 。

合法条件：原目标含 $C \sum_i \xi_i$ ；约束写为 $1 - \xi_i - y_i(w^T x_i + b) \leq 0$ 和 $-\xi_i \leq 0$ 。

第一步：先对拉格朗日函数关于 ξ_i 求偏导，得到 $C - \alpha_i - \mu_i = 0$ 。

贯穿例：四点二维分类数据

本章角色：把同一线性可分训练集写成硬间隔约束，并核对最大间隔解与本章存在唯一性假设。

读题翻译 题目不是要任选一条可分直线，而是要在规范约束 $y_i(w^T x_i + b) \geq 1$ 下证明候选达到最小范数。

为什么想到这个方法 成对选择横坐标相反、纵坐标相同的正负样本，相加约束可以直接消去 b 和 w_2 ，给出 $\|w\|_2$ 的下界。精确沿用四个样本及其标签：

i	1	2	3	4
$x^{(i)}$	$(-1, -1)$	$(-1, 1)$	$(1, -1)$	$(1, 1)$
y_i	-1	-1	+1	+1

取 $w = (1, 0)^T, b = 0$ 时，四个规范化函数间隔都等于 $y_i(w^T x^{(i)} + b) = 1$ ，故该点满足硬间隔约束。任一可行解在第二坐标 $x_2 = -1$ 的正、负样本上分别满足 $w_1 - w_2 + b \geq 1$ 与 $w_1 + w_2 - b \geq 1$ ，相加得 $w_1 \geq 1$ ，所以 $\|w\|_2 \geq 1$ ；上述候选达到下界，因而就是硬间隔最优解。其几何间隔为 $\min_i y_i(w^T x^{(i)} + b) / \|w\|_2 = 1$ 。两类均非空且该解严格分隔数据，完全符合本章线性可分假设；这只是训练几何的核对，不把四点结论外推到一般数据。上一站见逻辑斯谛回归的概率边界表示。

卡住时先看 先只写两条同一纵坐标上的异类约束；它们相加后立刻得到 $w_1 \geq 1$ 。

方法迁移 一般硬间隔题也可先由少量“相对”的异类样本推出范数下界，再核验某个候选同时可行并达到该下界。

读前自检：学习的对偶算法。 对学习的对偶算法，条件“从硬间隔原始问题推导只含对偶变量的凸二次规划，并指出每个约束如何产生对偶可行条件”不可省；请把 $L(w, b, \alpha)$ 展开一次并检查其类型或边界，再用展开后的量满足定义中的域、维数或符号限制作检查。

18.4 拉格朗日对偶、KKT 与支持向量

阅读目标：消去 w, b ，得到只含对偶变量的凸二次规划。

对象：线性可分训练集、原变量 (w, b) 与约束乘子 $\alpha_i \geq 0$ 。

合法条件：存在严格可行点，Slater 条件成立；原约束为 $1 - y_i(w^T x_i + b) \leq 0$ 。

第一步：先构造拉格朗日函数，并令其对 w, b 的导数为零。

推导目标

从硬间隔原始问题推导只含对偶变量的凸二次规划，并指出每个约束如何产生对偶可行条件。

推导准备

原问题为最小化 $\|w\|^2/2$ ，约束写成 $1 - y_i(w^T x_i + b) \leq 0$ ；训练集线性可分，所以存在严格可行点，Slater 条件保证强对偶。每个不等式乘子 $\alpha_i \geq 0$ 。

推导第1步：构造 Lagrange 函数。对约束引入 $\alpha_i \geq 0$:

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 + \sum_i \alpha_i \{1 - y_i(w^T x_i + b)\}.$$

推导第2步：消去原始变量。分别对 w, b 求导并令其为零，得到

$$w = \sum_i \alpha_i y_i x_i, \quad \sum_i \alpha_i y_i = 0.$$

推导第3步：代回并整理。把 w 展开代入 L ，二次项与交叉线性项合并，得到等价的对偶最小化

$$\min_{\alpha} \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^T x_j - \sum_i \alpha_i, \quad \text{s.t.} \quad \sum_i \alpha_i y_i = 0, \alpha_i \geq 0.$$

优化解释

优化解释。线性可分时存在严格可行点，凸问题满足强对偶；原始最优值与对偶最优值相等。对偶变量衡量放松某个间隔约束对最优值的边际影响，只有活动或关键约束具有正权重。

读前自检：由对偶解恢复硬间隔原始解。由对偶解恢复硬间隔原始解把问题限定在“设 α^* 是对偶最优解，取任意 $\alpha_j^* > 0$ ”；请把 w^* 展开一次并检查其类型或边界，检查是否得到展开后的量满足定义中的域、维数或符号限制。

定理 18.2 (由硬间隔对偶解恢复分类器) 设 α^* 是对偶最优解，取任意 $\alpha_j^* > 0$ ，则

$$w^* = \sum_i \alpha_i^* y_i x_i, \quad b^* = y_j - \sum_i \alpha_i^* y_i x_i^T x_j.$$

读前自检：证明：由硬间隔对偶解恢复分类器。在“强对偶使 KKT 条件成立”成立时处理由硬间隔对偶解恢复分类器：请把 $\alpha_j^* [y_j(w^{*T} x_j + b^*) - 1]$ 用到的关键定义展开并完成下一步变形，并以利用 $y_j^2 = 1$ 解出 b^* 并代入 w^* 展开，便得到结论判定结果。

证明。强对偶使 KKT 条件成立。驻点条件给出 w^* 展开式；互补松弛 $\alpha_j^* [y_j(w^{*T} x_j + b^*) - 1] = 0$ 与 $\alpha_j^* > 0$ 共同给出 $y_j(w^{*T} x_j + b^*) = 1$ 。利用 $y_j^2 = 1$ 解出 b^* 并代入 w^* 展开，便得到结论。□

读前自检：线性可分支持向量机学习算法。线性可分 SVM 的对偶解 α^* 只通过样本内积进入目标；请恢复 $w^* = \sum_i \alpha_i^* y_i x_i$ 和由支持向量确定的 b^* ，再核对 $f(x) = \text{sign}(\sum_i \alpha_i^* y_i x_i^T x + b^*)$ 。

对偶解只通过内积依赖输入。计算 α^* ，恢复 w^*, b^* ，再构造

$$f(x) = \text{sign}\left(\sum_i \alpha_i^* y_i x_i^T x + b^*\right).$$

读前自检：支持向量。 围绕支持向量机中的支持向量，先采用条件“硬间隔对偶最优解中满足 $\alpha_i^* > 0$ 的样本 x_i 称为支持向量”，再标出 $y_i(w^* x_i + b^*) = 1$ 两侧的形状并完成一次乘法或正交检查；最后验证它满足 $y_i(w^* x_i + b^*) = 1$ ，位于两条间隔边界之一。

定义 18.4 (硬间隔支持向量). 硬间隔对偶最优解中满足 $\alpha_i^* > 0$ 的样本 x_i 称为支持向量。它满足 $y_i(w^* x_i + b^*) = 1$ ，位于两条间隔边界之一。

读前自检：线性支持向量机与软间隔最大化。 线性支持向量机与软间隔最大化中的“线性不可分时，为每个样本引入 $\xi_i \geq 0$ ”决定可执行范围；请标出 $y_i(w^T x_i + b) \geq 1 - \xi_i$ 两侧的形状并完成一次乘法或正交检查，结果须满足乘法内侧维数相等且结果落入声明空间。

18.5 线性支持向量机与软间隔

线性不可分时，为每个样本引入 $\xi_i \geq 0$ ，允许 $y_i(w^T x_i + b) \geq 1 - \xi_i$ ，并为违约支付 $C\xi_i$ 。

读前自检：线性支持向量机。 把线性支持向量机放在“给定 $C > 0$ ”下考察：标出 $\min_{w,b,\xi} \frac{1}{2}\|w\|^2 + C \sum_i \xi_i$ 两侧的 shape 并完成一次乘法或正交检查，并检查乘法内侧维数相等且结果落入声明空间。

读前自检：线性支持向量机的定义。 线性 SVM 在 $C > 0$ 下最小化 $\frac{1}{2}\|w\|^2 + C \sum_i \xi_i$ ，约束为 $y_i(w^T x_i + b) \geq 1 - \xi_i$ 、 $\xi_i \geq 0$ ；请代入一个候选 (w, b, ξ) 逐项检查可行性，再写出其符号决策函数。

定义 18.5 (线性支持向量机). 给定 $C > 0$ ，软间隔原始问题为

$$\min_{w,b,\xi} \frac{1}{2}\|w\|^2 + C \sum_i \xi_i \quad \text{s.t.} \quad y_i(w^T x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0.$$

其最优超平面和符号决策函数称为线性支持向量机。

读前自检：软间隔学习的对偶算法。 从软间隔学习的对偶算法的条件“推导软间隔对偶中的盒约束 $0 \leq \alpha_i \leq C$ ”出发，请代入正文给出的取等边界检验 $1 - \xi_i - y_i(w^T x_i + b) \leq 0$ ；所得量应符合不等号方向、边界取等和定义域彼此相容。

推导目标

推导软间隔对偶中的盒约束 $0 \leq \alpha_i \leq C$ ，并说明它来自松弛变量的非负约束而不是额外假设。

推导准备

把约束写成 $1 - \xi_i - y_i(w^T x_i + b) \leq 0$ 和 $-\xi_i \leq 0$ ，分别引入 $\alpha_i, \mu_i \geq 0$ ；原目标含 $C \sum_i \xi_i$ 。

推导第1步：对 w, b 取驻点。 得到与硬间隔相同的 $w = \sum_i \alpha_i y_i x_i$ 和 $\sum_i \alpha_i y_i = 0$ 。

推导第2步：对 ξ_i 取驻点。 由 $\partial L / \partial \xi_i = 0$ 有 $C - \alpha_i - \mu_i = 0$ ；结合 $\alpha_i, \mu_i \geq 0$ 得到 $0 \leq \alpha_i \leq C$ 。

推导第3步：消去 w, b, ξ, μ 。 代回并整理得到

$$\min_{\alpha} \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^T x_j - \sum_i \alpha_i, \quad \sum_i \alpha_i y_i = 0, \quad 0 \leq \alpha_i \leq C.$$

读前自检：由软间隔对偶解恢复原始解。 由软间隔对偶解恢复原始解依赖“若存在 $0 < \alpha_j^* < C$ ”；请据此把 w^* 展开一次并检查其类型或边界，并直接核对展开后的量满足定义中的域、维数或符号限制。

若存在 $0 < \alpha_j^* < C$ ，则

$$w^* = \sum_i \alpha_i^* y_i x_i, \quad b^* = y_j - \sum_i \alpha_i^* y_i x_i^T x_j.$$

实践中可对多个自由支持向量所得 b 取平均以减小数值误差。

读前自检：线性支持向量机学习算法。 线性支持向量机学习算法以“学习流程是选择 C 、求解带盒约束的对偶问题、由自由支持向量求 b ，最后构造线性判别函数”为约束；请标出 $\|w\|$ 两侧的形状并完成一次乘法或正交检查，并确认 C 大时更重视违约损失， C 小时更重视较小的 $\|w\|$ 。

学习流程是选择 C 、求解带盒约束的对偶问题、由自由支持向量求 b ，最后构造线性判别函数。 C 大时更重视违约损失， C 小时更重视较小的 $\|w\|$ 。

读前自检：软间隔支持向量。 先锁定软间隔支持向量的条件“ $\xi_i \in (0, 1)$ ”：标出 $\xi_i \in (0, 1)$ 两侧的形状并完成一次乘法或正交检查，所得结果应满足因此不能把 $\alpha_i = C$ 无条件等同于误分类样本。

软间隔 KKT 条件给出三种核心状态：

$$\begin{cases} \alpha_i = 0 & \Rightarrow y_i g(x_i) \geq 1, \\ 0 < \alpha_i < C & \Rightarrow y_i g(x_i) = 1, \xi_i = 0, \\ \alpha_i = C & \Rightarrow y_i g(x_i) \leq 1, \xi_i = 1 - y_i g(x_i) \geq 0. \end{cases}$$

最后一类中， $\xi_i = 0$ 表示样本恰在间隔边界但对偶变量饱和，这在退化或非唯一解中可能发生； $\xi_i \in (0, 1)$ 、 $= 1$ 、 > 1 依次表示“正确但侵入间隔”“位于分类面”“被误分类”。因此不能把 $\alpha_i = C$ 无条件等同于误分类样本。

读前自检：合页损失函数。 对合页损失函数，条件“对给定 w, b ”不可省；请对 $[z]_+ = \max(0, z)$ 完成一项求导、代入或边界比较，再用结果的形状、符号和取等条件与定义一致作检查。

18.6 松弛变量与合页损失

定义 $[z]_+ = \max(0, z)$ 。对给定 w, b ，使约束成立的最小松弛量为

$$\xi_i = [1 - y_i(w^T x_i + b)]_+,$$

这就是单样本合页损失。

读前自检：线性支持向量机原始最优化问题。 线性支持向量机原始最优化问题把问题限定在“ $\min_{w,b} \sum_{i=1}^N [1 - y_i(w^T x_i + b)]_+ + \lambda \|w\|^2$, $\lambda = \frac{1}{2C}$.”；请标出 $\min_{w,b} \sum_{i=1}^N [1 - y_i(w^T x_i + b)]_+ + \lambda \|w\|^2$ ，两侧的形状并完成一次乘法或正交检查，检查是否得到乘法内侧维数相等且结果落入声明空间。

读前自检：软间隔原始问题与合页损失等价。 固定 $C > 0$ 并令 $\lambda = 1/(2C)$ 。请消去各松弛变量 ξ_i ，核对其贡献变为合页损失 $[1 - y_i g(x_i)]_+$ 。

定理 18.3 (软间隔原始问题与合页损失等价) 软间隔问题等价于无显式松弛变量的优化

$$\min_{w,b} \sum_{i=1}^N [1 - y_i(w^T x_i + b)]_+ + \lambda \|w\|^2, \quad \lambda = \frac{1}{2C}.$$

读前自检：证明：软间隔原始问题与合页损失等价。 固定 w, b 后，第 i 个松弛量满足 $\xi_i \geq 0$ 且 $\xi_i \geq 1 - y_i g(x_i)$ ；请最小化 $C \xi_i$ ，核对其 $\xi_i = [1 - y_i g(x_i)]_+$ ，代回后得到合页损失与正则项。

证明。 固定 w, b 后，第 i 个松弛量必须同时满足 $\xi_i \geq 0$ 和 $\xi_i \geq 1 - y_i g(x_i)$ 。由于目标中 $C \xi_i$ 随 ξ_i 严格增加，最优值是两下界的最大值 $[1 - y_i g(x_i)]_+$ 。代回原目标并整体除以 $C > 0$ ，得到合页损失之和加 $(1/(2C))\|w\|^2$ 。正数缩放不改变最优解，因此两问题等价。 $\square$

合页损失在 $y g(x) \geq 1$ 时为 0，在 $y g(x) < 1$ 时线性增加。它不仅惩罚误分类，也惩罚正确但间隔不足的样本，是 0-1 损失的凸上界。

读前自检：非线性支持向量机与核函数。 围绕非线性支持向量机与核函数，先采用条件“非线性问题可先由 $\phi: \mathcal{X} \rightarrow \mathcal{H}$ 映射到特征空间”，再标出 $\langle \phi(x), \phi(z) \rangle$ 两侧的形状并完成一次乘法或正交检查；最后验证对偶只需要 $\langle \phi(x), \phi(z) \rangle$ 。

18.7 核技巧与正定核

非线性问题可先由 $\phi: \mathcal{X} \rightarrow \mathcal{H}$ 映射到特征空间，再在 $\mathcal{H}$ 中学习线性超平面。对偶只需要 $\langle \phi(x), \phi(z) \rangle$ 。

读前自检：核技巧。 支持向量机中的核技巧中的“核技巧以 $K(x, z)$ 直接计算特征空间内积，无需显式构造 $\phi(x)$ ”决定可执行范围；请把 $\phi(x)$ 展开一次并检查其类型或边界，结果须满足高维或无限维特征因此可以通过有限次核值计算进入优化。

核技巧以 $K(x, z)$ 直接计算特征空间内积，无需显式构造 $\phi(x)$ 。高维或无限维特征因此可以通过有限次核值计算进入优化。

读前自检：核函数的定义。 把核函数的定义放在“存在希尔伯特空间 $\mathcal{H}$ 及映射 $\phi : \mathcal{X} \rightarrow \mathcal{H}$ ”下考察：把 $K(x, z)$ 展开一次并检查其类型或边界，并检查称 K 为 $\mathcal{X}$ 上的核函数。

定义 18.6 (核函数). 若存在希尔伯特空间 $\mathcal{H}$ 及映射 $\phi : \mathcal{X} \rightarrow \mathcal{H}$, 使

$$K(x, z) = \langle \phi(x), \phi(z) \rangle_{\mathcal{H}},$$

则称 K 为 $\mathcal{X}$ 上的核函数。

读前自检：正定核。 支持向量机中的正定核要求先确认“对称函数 $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ 是正定核”；请随后检查 $G = [K(x_i, x_j)]_{m \times m}$ 中每项的类型后完成等式变形，用两端运算均有定义、类型一致且化为同一结果验收。

读前自检：正定核的充要条件。 从正定核的充要条件的条件“对称函数 $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ 是正定核”出发，请将 $G = [K(x_i, x_j)]_{m \times m}$ 左端按正文定义展开一层，再逐项对齐右端；所得量应符合两端运算均有定义、类型一致且化为同一结果。

定理 18.4 (正定核的 Gram 矩阵判据) 对称函数 $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ 是正定核，当且仅当对任意有限点 $x_1, \dots, x_m$, Gram 矩阵 $G = [K(x_i, x_j)]_{m \times m}$ 均半正定。

读前自检：证明：正定核的 Gram 矩阵判据。 正定核的 Gram 矩阵判据依赖“若 K 来自特征映射”；请据此把 $c^T G c$ 按证明中的分解展开一层，并直接核对因此存在所需特征映射。

证明. 若 K 来自特征映射，则对任意 $c \in \mathbb{R}^m$,

$$c^T G c = \sum_{i,j} c_i c_j \langle \phi(x_i), \phi(x_j) \rangle = \left\| \sum_i c_i \phi(x_i) \right\|_{\mathcal{H}}^2 \geq 0.$$

反方向在有限线性组合空间上令 $\phi(x) = K(\cdot, x)$ ，并以核的双线性组合定义内积。Gram 半正定保证该内积非负；商去零范数元素并完备化得到希尔伯特空间，且 $\langle \phi(x), \phi(z) \rangle = K(x, z)$ 。因此存在所需特征映射。□

读前自检：常用核函数。 常用核函数以“核参数和 C 必须在严格隔离的验证流程中联合选择”为约束；请把 $K_{\text{rbf}}(x, z)$ 展开一次并检查其类型或边界，并确认展开后的量满足定义中的域、维数或符号限制。

常用核包括

$$K_{\text{poly}}(x, z) = (x^T z + c)^p, \quad c \geq 0, p \in \mathbb{N},$$

$$K_{\text{rbf}}(x, z) = \exp\left(-\frac{\|x - z\|^2}{2\sigma^2}\right), \quad \sigma > 0.$$

多项式核控制交互阶数；高斯核的 σ 控制相似度衰减尺度。核参数和 C 必须在严格隔离的验证流程中联合选择。

读前自检：正定核的等价定义。 先锁定正定核的等价定义的条件“核必须对称且对任意有限样本产生半正定矩阵”：把“核必须对称且对任意有限样本产生半正定矩阵”中的已声明对象代回正定核的等价定义的定义，所得结果应满足只在某一个训练集上数值半正定不足以证明函数对所有输入都是合法核。

Gram 矩阵判据本身也可作为正定核的等价定义。核必须对称且对任意有限样本产生半正定矩阵；只在某一个训练集上数值半正定不足以证明函数对所有输入都是合法核。

读前自检：非线性支持向量分类机。 对非线性支持向量分类机，条件“非线性学习先选择正定核及惩罚参数，再在核矩阵上求解软间隔对偶，最后以支持向量核展开完成预测”不可省；请标出非线性支持向量分类机两侧的形状并完成一次乘法或正交检查，再用定义中的每个约束都将在这流程中保留作检查。

读前自检：非线性支持向量机学习算法。 非线性支持向量机学习算法把问题限定在“非线性学习先选择正定核及惩罚参数，再在核矩阵上求解软间隔对偶，最后以支持向量核展开完成预测”；请标出非线性支持向量机学习算法两侧的形状并完成一次乘法或正交检查，检查是否得到定义中的每个约束都将在这流程中保留。

18.8 非线性支持向量机

非线性学习先选择正定核及惩罚参数，再在核矩阵上求解软间隔对偶，最后以支持向量核展开完成预测；定义中的每个约束都将在这流程中保留。

读前自检：非线性支持向量机的定义。 在“选择正定核 K 和 $C > 0$ ”成立时处理非线性支持向量机的定义：请标出 $f(x)$ 两侧的形状并完成一次乘法或正交检查，并以预测时计算这些支持向量与新点的核值判定结果。

读前自检：非线性支持向量机。 非线性支持向量机所用的明确前提是“选择正定核 K 和 $C > 0$ ”；完成标出 $f(x)$ 两侧的形状并完成一次乘法或正交检查后，核对乘法内侧维数相等且结果落入声明空间。

定义 18.7 (非线性支持向量机). 选择正定核 K 和 $C > 0$ ，求解

$$\min_{\alpha} \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j K(x_i, x_j) - \sum_i \alpha_i, \quad \sum_i \alpha_i y_i = 0, \quad 0 \leq \alpha_i \leq C.$$

所得分类器为

$$f(x) = \text{sign} \left(\sum_i \alpha_i^{\star} y_i K(x_i, x) + b^{\star} \right).$$

算法选择合法核与超参数，求解核对称问题；从 $0 < \alpha_j^{\star} < C$ 的样本计算

$$b^{\star} = y_j - \sum_i \alpha_i^{\star} y_i K(x_i, x_j),$$

并只保存正 α_i^* 对应的支持向量。预测时计算这些支持向量与新点的核值。

读前自检：序列最小最优化算法。 围绕序列最小最优化算法，先采用条件“SMO 每次选择两个对偶变量，固定其余变量”，再将 $\sum_i \alpha_i y_i = 0$ 左端按正文定义展开一层，再逐项对齐右端；最后验证等式 $\sum_i \alpha_i y_i = 0$ 使两个变量中只有一个自由度，子问题可解析求解。

18.9 序列最小最优化算法

SMO 每次选择两个对偶变量，固定其余变量。等式 $\sum_i \alpha_i y_i = 0$ 使两个变量中只有一个自由度，子问题可解析求解。

设选择 α_1, α_2 。若 $y_1 \neq y_2$,

$$L = \max(0, \alpha_2^{\text{old}} - \alpha_1^{\text{old}}), \quad H = \min(C, C + \alpha_2^{\text{old}} - \alpha_1^{\text{old}});$$

若 $y_1 = y_2$,

$$L = \max(0, \alpha_1^{\text{old}} + \alpha_2^{\text{old}} - C), \quad H = \min(C, \alpha_1^{\text{old}} + \alpha_2^{\text{old}}).$$

令 $E_i = g(x_i) - y_i$ 与 $\eta = K_{11} + K_{22} - 2K_{12}$ 。

$$\alpha_2^{\text{unc}} = \alpha_2^{\text{old}} + \frac{y_2(E_1 - E_2)}{\eta}, \quad \alpha_2^{\text{new}} = \text{clip}(\alpha_2^{\text{unc}}, L, H),$$

$$\alpha_1^{\text{new}} = \alpha_1^{\text{old}} + y_1 y_2 (\alpha_2^{\text{old}} - \alpha_2^{\text{new}}).$$

若 η 接近 0，应比较区间端点的子目标而不是除以小数。

读前自检：SMO 变量的选择方法。 SMO 变量的选择方法中的“若该启发式无改进，再遍历非边界样本和全部样本”决定可执行范围；请代入正文给出的取等边界检验 $0 < \alpha_i < C$ ，结果须满足不等号方向、边界取等和定义域彼此相容。

第一个变量选择违反 KKT 最严重的样本，优先扫描 $0 < \alpha_i < C$ 者；第二个变量优先使 $|E_1 - E_2|$ 大，以获得较大的候选步。若该启发式无改进，再遍历非边界样本和全部样本。

读前自检：SMO 算法。 SMO 以二分类训练集、半正定核 K 、 C 、KKT/步长容差和扫描预算为输入；请为一对 (i, j) 形成 $\alpha_i^+, \alpha_j^+, b^+, E^+$ ，核对盒约束、等式约束、有限性与目标门后再提交，并以 KKT 残差判停。

读前自检：SMO 算法的完整流程。 SMO 完整流程从 $\alpha = 0, b = 0, E_i = -y_i$ 开始；请按固定规则扫描一个违反 KKT 的 i 并求解一个两变量子问题，核对只有候选门通过才增加更新计数，且 KKT/盒/等式残差同时达标才返回 converged。

几何理解

几何解释。两条间隔边界 $w^T x + b = \pm 1$ 平行于分类面 $w^T x + b = 0$, 它们之间的距离为 $2/\|w\|_2$ 。落在边界上的训练点最靠近分类面, 改变远离边界的点通常不改变最优超平面。KKT 条件保证 $\alpha_i > 0$ 的硬间隔样本必在边界; 反向命题在退化或非唯一对偶解中不成立, 某个边界点也可能取 $\alpha_i = 0$ 。




图 18.1 分类超平面、两条间隔边界与几何间隔

图 18.1 中的两条虚线满足 $w^T x + b = \pm 1$, 其法向量均为 w ; 沿单位法向量测得的两边界距离为 $2/\|w\|_2$, 支持向量位于至少一条间隔边界上。

从 KKT 推导到 SMO 更新。以上原始 - 对偶与 KKT 推导给出 SMO 的目标、可行域和停止证书; 下面把这些条件落实为可执行的两变量更新。

输入输出。输入训练集、核、 C 、KKT 容差、步长容差和迭代预算; 输出 α, b 、支持向量集合、目标值与 KKT 残差。

参数。KKT 容差 ε_{KKT} 、最小变量变化 ε_α 、最大无更新扫描次数 R_{max} 和最大外层轮数 T_{max} 。

初始化。取 $\alpha = 0, b = 0$, 于是 $E_i = -y_i$; 建立核缓存和误差缓存。初值满足盒约束与等式约束。

阈值更新。令 $\Delta\alpha_i = \alpha_i^{\text{new}} - \alpha_i^{\text{old}}$ 、 $\Delta\alpha_j$ 类似, 则

$$b_i = b^{\text{old}} - E_i - y_i K_{ii} \Delta\alpha_i - y_j K_{ji} \Delta\alpha_j,$$

$$b_j = b^{\text{old}} - E_j - y_i K_{ij} \Delta\alpha_i - y_j K_{jj} \Delta\alpha_j.$$

停止条件。在容差内满足等式、盒约束和分段 KKT 条件，并且一次完整扫描没有可接受更新；同时使用最大轮数和连续无更新扫描数作为保护。

序列最小最优化 (SMO)：五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 18.1: 序列最小最优化 (SMO)

输入: $T = \{(x_i, y_i)\}_{i=1}^N$, 核 K , 盒约束 C

输出: 最后合法 α, b, E 、支持向量、 $R_{\text{KKT}}, s_{\text{done}}, u_{\text{done}}, p_{\text{done}}, \text{status}$ 与最终诊断

数据: $\varepsilon_{\text{KKT}}, \varepsilon_{\alpha} > 0$; $T_{\text{max}} \in \mathbb{N}_0$; $R_{\text{max}} \in \mathbb{N}_+$; 固定变量对与并列规则

- 1 $\alpha \leftarrow 0, b \leftarrow 0, E_i \leftarrow -y_i, s_{\text{done}} \leftarrow 0, u_{\text{done}} \leftarrow 0, p_{\text{done}} \leftarrow 0, r_{\text{idle}} \leftarrow 0$, 诊断为空
- 2 若训练集为空、维数或标签非法、 C 或容差非有限正数、预算或变量选择规则不合法, 则返回零初值、计数 0、invalid_input 及字段诊断
- 3 计算并核验 Gram 矩阵有限、对称且在容差内半正定; 失败则返回最后合法零状态、numerical_failure 及核构造位置 (i, j) 诊断
- 4 新鲜计算初值的 R_{KKT} 及盒、等式残差; 若非有限则返回最后合法零状态、numerical_failure 及初始 KKT 诊断; 若证书满足容差则返回零状态与 converged, 最终诊断记录“零扫描 KKT 证书”
- 5 **当** $s_{\text{done}} < T_{\text{max}}$ **执行**
- 6 新鲜计算 R_{KKT} 及盒、等式残差; 若任一残差非有限, 则返回最后合法状态与 numerical_failure, 诊断为扫描前核验 s_{done}
- 7 **若** $R_{\text{KKT}} \leq \varepsilon_{\text{KKT}}$ 且可行性残差满足容差 **则**
- 8 返回最后合法状态与 converged, 最终诊断记录 KKT、盒及等式证书
- 9 **结束**
- 10 $u_{\text{scan}} \leftarrow 0$
- 11 **对** 按固定次序取得每个违反 KKT 的 i **执行**
- 12 **对** 按最大 $|E_i - E_j|$ 及稳定回退次序枚举 $j \neq i$ **执行**
- 13 令 $p_{\text{done}} \leftarrow p_{\text{done}} + 1$, 由旧状态计算 $[L, H]$; 若 $L = H$ 则拒绝并继续下一 j
- 14 计算 $\eta = K_{ii} + K_{jj} - 2K_{ij}$; 若相关核值或子目标非有限, 则返回最后合法状态与 numerical_failure, 诊断为子问题 (s_{done}, i, j)
- 15 若 η 大于曲率容差则剪辑无约束解, 否则比较 L, H 处有限子目标; 变化小于 ε_{α} 时拒绝并继续下一 j
- 16 在临时状态由等式约束形成 α_i^+, α_j^+ , 计算 b_i, b_j 、候选 b^+ 与全部 E^+
- 17 若候选非有限、违反盒/等式约束或对偶目标上升超出容差, 则返回未改动的最后合法状态与 numerical_failure, 诊断为候选核验 (s_{done}, i, j)
- 18 原子提交 $(\alpha_i, \alpha_j, b, E) \leftarrow (\alpha_i^+, \alpha_j^+, b^+, E^+)$, 令 $u_{\text{done}} \leftarrow u_{\text{done}} + 1, u_{\text{scan}} \leftarrow u_{\text{scan}} + 1$, 并终止当前 i 的 j 枚举
- 19 **结束**
- 20 **结束**
- 21 完整扫描结束后令 $s_{\text{done}} \leftarrow s_{\text{done}} + 1$; 若 $u_{\text{scan}} = 0$ 则 $r_{\text{idle}} \leftarrow r_{\text{idle}} + 1$, 否则 $r_{\text{idle}} \leftarrow 0$
- 22 新鲜计算 R_{KKT} ; 若非有限则返回最后合法状态与 numerical_failure, 诊断为扫描后核验 s_{done}
- 23 **若** $R_{\text{KKT}} \leq \varepsilon_{\text{KKT}}$ 且可行性残差满足容差 **则**
- 24 返回最后合法状态与 converged, 最终诊断记录实际扫描与更新数
- 25 **结束**
- 26 **若** $r_{\text{idle}} = R_{\text{max}}$ **则**
- 27 返回最后合法 $\alpha, b, E, R_{\text{KKT}}, s_{\text{done}}, u_{\text{done}}, p_{\text{done}}, \text{budget_stop}$, 最终诊断把具体原因记为“连续无更新保护预算耗尽”, 并记录未达标 KKT 残差与候选拒绝原因
- 28 **结束**
- 29 **结束**
- 30 返回最后合法 $\alpha, b, E, R_{\text{KKT}}, s_{\text{done}}, u_{\text{done}}, p_{\text{done}}, \text{budget_stop}$, 最终诊断记录扫描预算耗尽

算法实现说明: 返回 converged 必须同时给出 KKT、盒约束与等式残差证书; 连续无更新但证书未达标与实际扫描上限都返回 budget_stop, 具体停止原因留在诊断字段。每次两变量、阈值与误差缓存必须原子提交。完整 C1-C14 契约

收敛说明。每次接受的两变量更新不增加凸对偶目标并保持可行性。核矩阵半正定且变量选择持续访问违反 KKT 的坐标对时，精确坐标更新的极限点满足全局最优 KKT 条件；若使用固定正容差，实际停止只保证盒约束、等式约束与 KKT 残差落在给定容差内，即返回近似最优解。只有在容差趋于 0 并排除预算提前停止时，才能把极限表述为对偶全局最优集合。退化核可能使参数解不唯一；此时必须报告 Gram 矩阵条件数、有效秩与所用 PSD 修复。修复会改变优化目标，未经这些诊断不能笼统宣称决策函数稳定。

18.10 证明、例题与练习

例题 18.1 (一维软间隔状态判定). 某训练后模型对四个样本给出的 $y_i g(x_i)$ 依次为 1.4, 1, 0.3, -0.2。在满足 KKT 的前提下，判断各样本可能的 α_i 与松弛状态。

例题 18.1 解答

读题翻译 给定每个样本的带符号间隔 $m_i = y_i g(x_i)$ ，要用软间隔 KKT 条件判断最小松弛量和对应对偶变量所处的边界状态。

已知与合法条件 $C > 0$ ，标准软间隔约束为 $m_i \geq 1 - \xi_i$ 、 $\xi_i \geq 0$ 、 $0 \leq \alpha_i \leq C$ ；若模型含不正则化偏置 b ，还需满足 $\sum_i \alpha_i y_i = 0$ 。

为什么想到这个方法 先取使惩罚最小的 $\xi_i = \max\{0, 1 - m_i\}$ ，再用 $\alpha_i(m_i - 1 + \xi_i) = 0$ 与 $(C - \alpha_i)\xi_i = 0$ 逐点分类。

方法选择 由四个 m_i 计算 ξ_i ；按间隔外、间隔上、间隔内和误分类四种状态应用互补条件；最后回代约束余量并说明联合 KKT 限制。

推导/计算 间隔值为 $m_i = y_i g(x_i)$ ，即 $(m_1, m_2, m_3, m_4) = (1.4, 1, 0.3, -0.2)$ ；对应的最小可行松弛量由 $\xi_i = \max\{0, 1 - m_i\}$ 给出：

$$\begin{aligned}\xi_i &= \max\{0, 1 - m_i\}, \\ (\xi_1, \xi_2, \xi_3, \xi_4) &= (0, 0, 0.7, 1.2).\end{aligned}$$

互补条件给出

$$\alpha_i(m_i - 1 + \xi_i) = 0, \quad (C - \alpha_i)\xi_i = 0, \quad 0 \leq \alpha_i \leq C.$$

因此逐点有

i	m_i	ξ_i	α_i	逐点状态与证书
1	1.4	0	0	间隔外, $\alpha_1(m_1 - 1) = 0$
2	1	0	$[0, C]$	间隔上; 典型支持向量满足 $0 < \alpha_2 < C$
3	0.3	0.7	C	间隔内, $(C - \alpha_3)\xi_3 = 0$
4	-0.2	1.2	C	误分类, $(C - \alpha_4)\xi_4 = 0$

若模型含不受正则化的偏置 b , 全体对偶变量还必须共同满足偏置驻点条件

$$\sum_i \alpha_i y_i = 0,$$

故不能脱离其他样本和标签单独指定 α_2 的唯一数值。

独立核验 回代得 $m_i - 1 + \xi_i = (0.4, 0, 0, 0)$, 均非负; 第 1 点互补条件强制 $\alpha_1 = 0$, 第 3、4 点因 $\xi_i > 0$ 强制 $\alpha_i = C$ 。完整联合取值还须满足偏置驻点条件。

结论 最小松弛量为 $(\xi_1, \xi_2, \xi_3, \xi_4) = (0, 0, 0.7, 1.2)$; 逐点状态为 $\alpha_1 = 0$ 、 $\alpha_2 \in [0, C]$ 、 $\alpha_3 = \alpha_4 = C$, 其中 α_2 不能由给定间隔单独唯一确定。

复杂度分析

训练时间复杂度。 对 d 维稠密输入, 构造线性或需 $O(d)$ 运算的核 Gram 矩阵为 $O(N^2d)$ 时间、 $O(N^2)$ 存储; 一般记为 $O(N^2C_K(d))$ 。对称性检查为 $O(N^2)$, 完整特征值或 Cholesky 型 PSD/分解核验最坏为 $O(N^3)$; 若修复并重新分解, 仍须单独计入该立方项。缓存充分时一次 SMO 更新的误差刷新约为 $O(N)$; 若接受 T 次两变量更新, 总刷新主项为 $O(TN)$ 。 T 依数据、变量选择与容差而变, 不能用固定小常数承诺。

预测时间复杂度。 设支持向量数为 N_s , 对一个新点需计算 N_s 次核函数并累加, 若单次核计算代价为 $C_K(d)$, 则为 $O(N_s C_K(d))$; 线性模型预先合并 w 后为 $O(d)$ 。

存储与空间复杂度。 完整核矩阵需 $O(N^2)$ 空间, 受限缓存可降至 $O(NB)$; 对偶变量和误差缓存为 $O(N)$, 部署模型保存支持向量约为 $O(N_s d)$ 。**复杂度假设:** 采用稠密核缓存; 稀疏输入时应以非零特征数替代 d 。

正确性依据。 SMO 每次只优化两个对偶变量, 并用等式约束消去其中一个变量, 因此剪辑区间内的更新同时保持盒约束和 $\sum_i \alpha_i y_i = 0$; 阈值由新的 KKT 边界条件恢复。只有所有变量在给定容差内满足 KKT 时才报告近似最优, 否则返回退化、停滞或达到迭代上限但未满足 KKT 的状态。

异常、退化与不收敛情形。 若训练集为空、只含一个类别、核值非有限、核矩阵明显非半正定、可行区间 $L > H$ 或所有候选对长期无法降低 KKT 残差, 应停止并报告输入或求解失败。最大轮数、无更新扫描上限或正容差触发的是近似/预算停止; 只有 KKT 残差、盒约束和等式约束均满足登记容差时才记录收敛。

适用条件与局限性

适用条件。 SVM 适合中小样本、高维稀疏特征、类别边界可由线性或合适核近似且需要稳健间隔分类的任务。训练前应缩放连续特征, 按代价处理类别不平衡, 并用嵌套或严格隔离的验证过程选择 C 与核参数。

读前自检：不适用说明：证明、例题与练习。 核 SVM 对 N 个样本需保存 $N \times N$ Gram 矩阵；请计算其 $O(N^2)$ 存储并与给定内存预算比较，核对预算不足时应改用线性、低秩或近似核方案，而不能继续声明该核训练流程适用。

方法局限

核矩阵带来二次存储与较高训练成本；预测随支持向量数增长；核与尺度选择敏感；原始得分不是概率；严重重叠类别、标签噪声和分布漂移会削弱间隔含义。多分类还需一对一、一对其余或结构化扩展。

读前自检：概率解释：标准支持向量机优化间隔而非条件似然，因此 $g(x)$ 及 $\text{sign} g(x)$ 没有内生的概.....。 标准 SVM 输出间隔分数 $g(x)$ 及 $\text{sign} g(x)$ ，并不内生给出 $P(Y = 1 | x)$ ；请把同一正分数分别作为分类得分与未经校准的概率候选，核对后者缺少归一化/校准依据。

概率解释

标准支持向量机优化间隔而非条件似然，因此 $g(x)$ 及 $\text{sign} g(x)$ 没有内生的概率解释。若应用必须输出概率，可在独立校准集上拟合 $P(Y = 1 | g) = \{1 + \exp(Ag + B)\}^{-1}$ ；参数 A, B 属于后处理模型，既不能被视为 SVM 原始目标的一部分，也不应使用训练集预测直接校准而忽略过拟合。

读前自检：常见错误与误用边界：证明、例题与练习。 证明、例题与练习以“边界框首项禁止混淆函数间隔与几何间隔，忽略除以 $\|w\|$ ”为约束；请把固定错误“混淆函数间隔与几何间隔，忽略除以 $\|w\|$ ”中的对象、操作与结论按本节定义拆开，指出第一个不满足的定义条件，再把该处改为本节允许的写法，并确认改写后的运算或判断有定义，且不再触发“混淆函数间隔与几何间隔，忽略除以 $\|w\|$ ”。

常见错误

1. 混淆函数间隔与几何间隔，忽略除以 $\|w\|$ ；
2. 对约束 $1 - y_i g_i \leq 0$ 使用负乘子，导致对偶符号与 KKT 全错；
3. 忘记软间隔对偶上界 $\alpha_i \leq C$ ；
4. 未验证核的半正定性，或在全数据上调参造成验证泄漏；
5. SMO 更新一个变量却不联动另一个变量，破坏等式约束。

易混淆概念对比

概念对比。

方法	训练目标	边界与输出	主要代价
感知机	误分类点线性损失	线性边界、无概率	依赖可分性与更新顺序
逻辑斯谛回归	对数损失加正则	线性 logit 、条件概率	对异常点和分离敏感
线性 SVM	合页损失加范数	最大间隔线性得分	需校准才能给概率
核 SVM	核空间合页损失	非线性边界	核矩阵与支持向量成本

本章共 18 道练习。每道题干后立即给出同号解析；长解析可自然跨页，续页标题保留题号。

练习 18.1. 给定 $w = (2, -1)^T$, $b = -3$ 和 $x = (3, 1)^T$, 求得分、预测标签与到超平面的距离。

练习 18.1 解析

这里 $w, x \in \mathbb{R}^2$ 、 $b \in \mathbb{R}$ 且 $w \neq 0$ 。判别分数与标签为

$$\begin{aligned} g(x) &= w^T x + b = 2 \times 3 + (-1) \times 1 - 3 = 2, \\ \hat{y} &= \text{sign } g(x) = +1. \end{aligned}$$

法向量范数与点到超平面的距离为

$$\|w\|_2 = \sqrt{2^2 + (-1)^2} = \sqrt{5}, \quad \text{dist}(x, \{z : g(z) = 0\}) = \frac{|g(x)|}{\|w\|_2} = \frac{2}{\sqrt{5}}.$$

得分随参数尺度变化，除以法向量范数后才得到几何距离。

练习 18.2. 证明把 (w, b) 替换为 (cw, cb) , 其中 $c > 0$, 不会改变分类超平面与预测标签。

练习 18.2 解析

设 $w \neq 0$ 且 $c > 0$ 。超平面的零点集合满足

$$\{x : (cw)^T x + cb = 0\} = \{x : c(w^T x + b) = 0\} = \{x : w^T x + b = 0\}.$$

预测标签也保持不变:

$$\text{sign}((cw)^T x + cb) = \text{sign}(cg(x)) = \text{sign } g(x).$$

对带标签样本, 函数间隔乘以 c , 而几何间隔满足

$$\frac{y_i c g(x_i)}{\|cw\|_2} = \frac{c y_i g(x_i)}{c \|w\|_2} = \frac{y_i g(x_i)}{\|w\|_2}.$$

$c = 0$ 会使法向量失效, $c < 0$ 会反转预测符号, 所以二者不在结论内。

练习 18.3. 某样本满足 $y_i(w^T x_i + b) = 3$ 且 $\|w\|_2 = 5$ 。求函数间隔和几何间隔。

练习 18.3 解析

单样本函数间隔按定义为

$$\hat{\gamma}_i = y_i(w^T x_i + b) = 3.$$

因为 $\|w\|_2 = 5 > 0$, 几何间隔为

$$\gamma_i = \frac{\hat{\gamma}_i}{\|w\|_2} = \frac{3}{5} = 0.6.$$

尺度核验为

$$(\hat{\gamma}_i, \|w\|_2) = (3, 5) \mapsto (6, 10) \implies \gamma_i = \frac{3}{5} = \frac{6}{10}.$$

因此函数间隔为 3、几何间隔为 3/5, 且后者对参数的同比例缩放保持不变。

练习 18.4. 证明两条平面 $w^T x + b = 1$ 与 $w^T x + b = -1$ 之间的距离为 $2/\|w\|_2$ 。

练习 18.4 解析

设 $w \in \mathbb{R}^d \setminus \{0\}$, 并取 x_+ 满足 $w^T x_+ + b = 1$ 。沿单位法向量反向移动 $t \geq 0$:

$$x_- = x_+ - t \frac{w}{\|w\|_2}.$$

要求 x_- 落在另一平面上, 得到

$$\begin{aligned} w^T x_- + b &= w^T x_+ + b - t\|w\|_2 \\ &= 1 - t\|w\|_2 = -1 \\ \implies t &= \frac{2}{\|w\|_2}. \end{aligned}$$

平行平面的最短连线沿公法线, 故两平面距离就是 $2/\|w\|_2$ 。

练习 18.5. 一维样本 $x_1 = 2, y_1 = +1$ 与 $x_2 = 0, y_2 = -1$ 。求硬间隔最优 w, b 。

练习 18.5 解析

一维硬间隔原始问题为

$$\min_{w, b \in \mathbb{R}} \frac{1}{2} w^2, \quad 2w + b \geq 1, \quad -b \geq 1.$$

第二个约束给 $b \leq -1$, 代入第一个约束得到下界链

$$2w \geq 1 - b \geq 2 \implies w \geq 1 \implies \frac{1}{2} w^2 \geq \frac{1}{2}.$$

取 $w = 1$ 时, 可行性要求

$$2 + b \geq 1, \quad b \leq -1 \implies b = -1.$$

练习 18.5 解析 (续)

故唯一最优参数为 $(w^*, b^*) = (1, -1)$, 分类点 $x = 1$, 两条间隔边界为 $x = 0, 2$, 总宽度 $2/|w^*| = 2$ 。

练习 18.6. 为什么硬间隔原始目标不惩罚 b ? 这是否意味着 b 可以任意取值?

练习 18.6 解析

规范化后间隔宽度为 $2/\|w\|_2$, 所以原始目标只需最小化 $\|w\|_2^2/2$ 。但对固定 w , 全部约束仍把 b 限制在

$$L(w) := \max_{i: y_i = +1} (1 - w^T x_i) \leq b \leq U(w) := \min_{i: y_i = -1} (-1 - w^T x_i).$$

若两类均非空且最优时 $L(w^*) < U(w^*)$, 取中点 b_0 及 $\delta = (U - L)/2 > 0$, 则

$$y_i((w^*)^T x_i + b_0) \geq 1 + \delta \implies \left(\frac{w^*}{1 + \delta}, \frac{b_0}{1 + \delta} \right) \text{ 仍可行.}$$

新法向量范数严格更小, 与最优性矛盾; 故最优时 $L = U = b^*$ 。不惩罚 b 表示平移不直接进入目标, 并不表示 b 没有约束或可任意取值。

练习 18.7. 从拉格朗日函数求 $\nabla_w L$ 与 $\partial L / \partial b$, 写出两个驻点条件。

练习 18.7 解析

对 $w \in \mathbb{R}^d$ 、 $b \in \mathbb{R}$ 及 $\alpha_i \geq 0$, 拉格朗日函数为

$$L(w, b, \alpha) = \frac{1}{2} \|w\|_2^2 + \sum_{i=1}^N \alpha_i [1 - y_i(w^T x_i + b)].$$

两个驻点条件逐项为

$$\begin{aligned} \nabla_w L &= w - \sum_{i=1}^N \alpha_i y_i x_i = 0, \\ \frac{\partial L}{\partial b} &= - \sum_{i=1}^N \alpha_i y_i = 0. \end{aligned}$$

因此

$$w = \sum_{i=1}^N \alpha_i y_i x_i, \quad \sum_{i=1}^N \alpha_i y_i = 0.$$

因此驻点条件给出 w 的支持向量展开, 并要求带标签乘子的总和为零。

练习 18.8. 某硬间隔样本满足 $\alpha_i^* = 0$ 。它是否必须位于间隔边界? 说明 KKT 能推出的结论。

练习 18.8 解析

令原始约束余量为

$$r_i = y_i g(x_i) - 1 \geq 0.$$

练习 18.8 解析 (续)

KKT 互补松弛条件是

$$\alpha_i^* r_i = 0, \quad \alpha_i^* \geq 0, \quad r_i \geq 0.$$

当 $\alpha_i^* = 0$ 时, 逻辑链只能给出

$$0 \cdot r_i = 0 \text{ 对任意 } r_i \geq 0 \text{ 均成立} \implies y_i g(x_i) \geq 1,$$

不能推出 $r_i = 0$ 。该点既可能位于间隔边界, 也可能严格在间隔外; 它在 $w^* = \sum_j \alpha_j^* y_j x_j$ 中的贡献为零。

练习 18.9. 某样本 $y_i g(x_i) = 0.4$ 。求最小可行松弛变量并判断其状态。

练习 18.9 解析

软间隔可行域要求

$$y_i g(x_i) \geq 1 - \xi_i, \quad \xi_i \geq 0.$$

代入 $m_i = y_i g(x_i) = 0.4$, 得到

$$\xi_i \geq 1 - m_i = 0.6 \implies \xi_i^{\min} = \max\{0, 1 - m_i\} = 0.6.$$

由于 $C > 0$ 时目标对 ξ_i 单调增加, 最优取最小可行值。状态链为

$$0 < m_i < 1 \iff 0 < \xi_i^{\min} < 1,$$

故样本分类正确但位于分类面与间隔边界之间。

练习 18.10. 由 $C - \alpha_i - \mu_i = 0$ 和 $\mu_i \geq 0$ 证明 $\alpha_i \leq C$ 。

练习 18.10 解析

对松弛变量 $\xi_i \geq 0$ 引入乘子 $\mu_i \geq 0$, 驻点条件为

$$\frac{\partial L}{\partial \xi_i} = C - \alpha_i - \mu_i = 0.$$

因此

$$\alpha_i = C - \mu_i \leq C \quad (\mu_i \geq 0).$$

再结合间隔约束的对偶可行性 $\alpha_i \geq 0$, 得到

$$0 \leq \alpha_i \leq C.$$

该盒约束来自消去非负乘子 μ_i , 不是额外添加的假设。

练习 18.11. 分别计算 $yg = 1.4, 0.6, -0.2$ 时的合页损失。

练习 18.11 解析

对带符号分数 $m = yg \in \mathbb{R}$, 合页损失为 $\ell(m) = [1 - m]_+$ 。逐项代入得到

m	$[1 - m]_+$	状态
1.4	$[-0.4]_+ = 0$	间隔外
0.6	$[0.4]_+ = 0.4$	正确但侵入间隔
-0.2	$[1.2]_+ = 1.2$	误分类

因此损失向量为

$$(\ell(1.4), \ell(0.6), \ell(-0.2)) = (0, 0.4, 1.2).$$

所以三个样本的合页损失依次为 0、0.4 和 1.2。

练习 18.12. 证明 0-1 误分类指示 $\mathbf{1}\{yg \leq 0\}$ 不超过合页损失。

练习 18.12 解析

令 $z = yg \in \mathbb{R}$ 。若 $z > 0$, 则

$$\mathbf{1}\{z \leq 0\} = 0 \leq [1 - z]_+.$$

若 $z \leq 0$, 则

$$z \leq 0 \implies 1 - z \geq 1 \implies [1 - z]_+ = 1 - z \geq 1 = \mathbf{1}\{z \leq 0\}.$$

两种分支覆盖 $\mathbb{R}$, 所以

$$\mathbf{1}\{yg \leq 0\} \leq [1 - yg]_+ \quad \text{对所有 } yg \in \mathbb{R} \text{ 成立.}$$

因此合页损失逐点上界分类错误指示函数。

练习 18.13. 证明线性核 $K(x, z) = x^T z$ 是正定核。

练习 18.13 解析

对 $x, z \in \mathbb{R}^d$, 取特征映射 $\phi(x) = x$, 则

$$K(x, z) = x^T z = \langle \phi(x), \phi(z) \rangle_{\mathbb{R}^d},$$

且 $K(x, z) = K(z, x)$ 。对任意有限点集 $x_1, \dots, x_N$ 和系数 $c \in \mathbb{R}^N$, 有

$$\begin{aligned} \sum_{i,j=1}^N c_i c_j K(x_i, x_j) &= \sum_{i,j=1}^N c_i c_j x_i^T x_j \\ &= \left\| \sum_{i=1}^N c_i x_i \right\|_2^2 \\ &\geq 0. \end{aligned}$$

因此所有 Gram 矩阵均半正定, 线性核是合法正定核。

练习 18.14. 给定两点的 Gram 矩阵 $\begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}$, 判断它能否来自合法核。

练习 18.14 解析

给定对称矩阵

$$G = \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}, \quad \det(G - \lambda I) = (1 - \lambda)^2 - 4.$$

特征值链为

$$(1 - \lambda)^2 = 4 \implies \lambda \in \{3, -1\}.$$

也可取 $c = (1, -1)^\top$ 直接得到

$$c^\top G c = -2 < 0.$$

合法实值内积核要求任意有限 Gram 矩阵半正定; 该矩阵含负特征值, 故不能来自合法核。

练习 18.15. 两个支持向量的 $(\alpha_i y_i)$ 分别为 0.6 与 -0.4, 对新点的核值为 0.8 与 0.3, $b = -0.1$ 。求得分和标签。

练习 18.15 解析

核决策函数为

$$g(x) = \sum_{i \in \text{SV}} (\alpha_i y_i) K(x_i, x) + b.$$

代入两个支持向量的量, 得到

$$\begin{aligned} g(x) &= 0.6 \times 0.8 + (-0.4) \times 0.3 - 0.1 \\ &= 0.48 - 0.12 - 0.10 \\ &= 0.26 > 0. \end{aligned}$$

所以 $\hat{y} = \text{sign } g(x) = +1$; 标签符号已经包含在 $\alpha_i y_i$ 中, 不能丢弃。

练习 18.16. 为什么训练后可以丢弃 $\alpha_i^\star = 0$ 的样本而不改变预测?

练习 18.16 解析

训练完成后的固定预测函数为

$$g(x) = \sum_{i=1}^N \alpha_i^\star y_i K(x_i, x) + b^\star.$$

若 $\alpha_j^\star = 0$, 则对任意新输入 x 都有

$$\alpha_j^\star y_j K(x_j, x) = 0, \quad g(x) = \sum_{i: \alpha_i^\star > 0} \alpha_i^\star y_i K(x_i, x) + b^\star.$$

因此删除该样本的推理项不会改变得分或标签, 只减少存储与核计算; 这不等于从训练集删除它后重新训练仍得到同一模型。

练习 18.17. $y_1 \neq y_2$, $\alpha_1^{\text{old}} = 0.3, \alpha_2^{\text{old}} = 0.6, C = 1$ 。求 L, H 。

练习 18.17 解析

当 $y_1 \neq y_2$ 时, SMO 对 α_2 的可行区间为

$$L = \max(0, \alpha_2^{\text{old}} - \alpha_1^{\text{old}}), \quad H = \min(C, C + \alpha_2^{\text{old}} - \alpha_1^{\text{old}}).$$

代入数据得到

$$\begin{aligned} L &= \max(0, 0.6 - 0.3) = 0.3, \\ H &= \min(1, 1 + 0.6 - 0.3) = 1. \end{aligned}$$

故

$$\alpha_2^{\text{new}} \in [0.3, 1],$$

随后由 $y_1\alpha_1 + y_2\alpha_2$ 的不变量恢复 α_1^{new} , 同时保持盒约束与全局等式约束。

练习 18.18. 为什么特征缩放会同时影响线性 SVM 的正则化几何和高斯核的距离?

练习 18.18 解析

设可逆对角缩放为 $x' = Ax$ 。为了保持同一线性得分, 需要

$$w'^T x' = w^T x \implies w' = A^{-T} w.$$

但正则项变为

$$\|w'\|_2^2 = w^T A^{-1} A^{-T} w,$$

所以不同坐标的缩放改变了线性 SVM 的惩罚几何。对高斯核, 缩放后

$$K_A(x, z) = \exp\left(-\frac{\|A(x - z)\|_2^2}{2\sigma^2}\right),$$

也改变样本距离与核值。故缩放参数必须只在训练折估计, 并原样应用到验证或测试折; 否则既改变模型几何, 也造成信息泄漏。

读前自检: 本章结论与下一步。 支持向量机章末由“分离超平面、几何间隔、支持向量与核 Gram 矩阵”落到“SMO 保持等式与盒约束, 每次精确更新两个对偶变量并以 KKT 残差停止”; 请把前者产出和后者输入逐项对齐, 固定核对前者末项的输出类型能否作为后者首项的输入类型。

本章结论与下一步

核心结论: 分离超平面、几何间隔、支持向量与核 Gram 矩阵

关键依据: 规范化间隔得到凸二次规划, 再由驻点与 KKT 导出对偶、支持向量和软间隔盒约束

可执行自检: SMO 保持等式与盒约束, 每次精确更新两个对偶变量并以 KKT 残差停止

适用边界: 需要稳健二分类边界、可解释支持样本或核化非线性分界时

下一步: 进入提升方法; 若几何、对偶或核自检失败, 返回本章对应主节

1. **几何**：能否从点到超平面距离推导函数间隔、几何间隔和 $2/\|w\|$ ？未通过则回看第 1、2 节。
2. **优化**：能否从硬间隔原始问题逐行得到对偶，并完整列出 KKT 条件？未通过则回看第 3、4 节。
3. **软间隔**：能否推导盒约束、合页损失等价和三类支持向量状态？未通过则回看第 5、6 节。
4. **核方法**：能否证明 Gram 矩阵判据并写出核 SVM 决策函数？未通过则回看第 7、8 节。
5. **算法**：能否计算 SMO 的 L, H, η 、两变量和 b 更新，并说明停止与退化处理？未通过则回看第 9 节；五项均可独立完成，并能通过第 10 节的模型验收题，才算达到本章学习目标。

第 19 章 提升方法

读前自检：本章地图：提升方法。 提升方法章地图把“从弱学习器直达 AdaBoost、加法模型与梯度提升”作为主线；请为其中首条箭头补出必要条件，并检查终点仍落在本章声明的输出域。

读前自检：本章可检验学习目标。 提升方法学习目标固定核验“区分弱学习器、强学习器与基学习器，说明样本权重和分类器权重在提升中的不同作用”；请实际完成“区分弱学习器、强学习器与基学习器，说明样本权重和分类器权重在提升中的不同作用”，并用“中间结果逐项包含首目标“区分弱学习器、强学习器与基学习器，说明样本权重和分类器权重在提升中的不同作用”声明的对象、条件与结论”判定通过或失败。

读前自检：最短先修。 提升方法的最短先修明确要求“本章需要二类分类、经验风险、加权平均、指数函数与对数函数、条件概率、凸损失、一阶导数、函数空间方向导数、回归树的区域划分及平方损失”；请把首项“本章需要二类分类、经验风险、加权平均、指数函数与对数函数、条件概率、凸损失、一阶导数、函数空间方向导数、回归树的区域划分及平方损失”中的第一个先修对象写成定义域 - 运算 - 输出三元组，并以“该三元组逐项满足首项“本章需要二类分类、经验风险、加权平均、指数函数与对数函数、条件概率、凸损失、一阶导数、函数空间方向导数、回归树的区域划分及平方损失”的对象类型与成立条件”判断能否进入本章。

读前自检：先修自检。 提升方法先修自检固定核验“给定非负数 $D_1, \dots, D_N$ ，能否检查 $\sum_i D_i = 1$ 并计算加权错误率”；请给定非负数 $D_1, \dots, D_N$ ，实际检查 $\sum_i D_i = 1$ 并计算加权错误率并写出中间结果，再按“ $\sum_i D_i = 1$ 的计算或证明结果满足首项所列等式、定义域或判断”明确判为通过或失败。

读前自检：依赖路线。 提升方法把“弱学习器 → 样本分布重加权 → 加权多数表决”接到“AdaBoost 递推 → 规范化因子 → 训练误差界与间隔解释”；请用 → 补全这一步的等式或判据，再检查两端维数、支持或对象类型。

本章地图

核心问题：怎样逐轮组合简单学习器并控制代理损失

可检验学习目标：

- 区分弱学习器、强学习器与基学习器，说明样本权重和分类器权重在提升中的不同作用；
- 能够逐轮执行 AdaBoost，处理弱分类器误差为 0、1/2 或超过 1/2 的边界情形；
- 从权重递推证明训练误差乘积上界，并解释间隔、噪声与泛化之间的关系；
- 从加法模型和指数损失推导前向分步算法，证明 AdaBoost 是它的一个特例；
- 掌握回归提升树与梯度提升的输入、参数、初始化、更新、停止、收敛条件和复杂度。

最短先修：本章需要二类分类、经验风险、加权平均、指数函数与对数函数、条件概率、凸损失、一阶导数、函数空间方向导数、回归树的区域划分及平方损失。训练集记为 $T = \{(x_i, y_i)\}_{i=1}^N$ ；分类时 $y_i \in \{-1, +1\}$ ，回归时 $y_i \in \mathbb{R}$ 。

依赖路线：弱学习器 → 样本分布重加权 → 加权多数表决；AdaBoost 递推 → 规范化因子 → 训练误差界与间隔解释；加法模型 → 前向分步 → 指数损失 → AdaBoost；回归树 → 残差拟合 → 平方损失提升树；函数空间负梯度 → 伪残差 → 一般损失下的梯度提升。

完成标准与返回：权重归一化失败时回到节 19.2；前向分步或伪残差不清时回看节 19.4、19.6

模型认识卡：提升方法

任务与输入：分类或回归，输入为训练集与可加和的基学习器族。 **输出类型：**加法得分、类别或实值。

模型： $F_M(x) = F_0(x) + \sum_{m=1}^M \alpha_m G_m(x)$ 。 **策略：**前向分步降低代理损失或拟合函数空间负梯度。 **算法：**AdaBoost、残差提升树或梯度提升。

预测：分类取得分符号，回归输出加法值。 **关键假设与边界：**基学习器须能产生有效下降方向；噪声、无正边缘、学习率和早停共同限制可推进程度。

本章符号表

符号	取值或维数	含义
G_m	$\mathcal{X} \rightarrow \{-1, +1\}$	第 m 轮基分类器
$D_m(i)$	$[0, 1]$	第 m 轮第 i 个训练样本的权重
e_m	$[0, 1]$	G_m 在 D_m 下的加权错误率
α_m	$\mathbb{R}$	第 m 个基分类器的组合系数
Z_m	$(0, \infty)$	第 m 轮权重更新的规范化因子
F_m	$\mathcal{X} \rightarrow \mathbb{R}$	前 m 轮的实值加法模型
$b(x; \gamma)$	基函数类	参数为 γ 的基模型
$T(x; \Theta_m)$	回归树	第 m 轮树及其区域、叶值参数
r_{mi}	$\mathbb{R}$	梯度提升第 m 轮伪残差
ν	$(0, 1]$	收缩率或学习率

19.1 弱学习与强学习

提升方法按顺序训练多个基学习器，并把它们组合成一个性能更强的模型。后续基学习器针对当前组合尚未处理好的样本或函数方向工作，所以各轮并非相互独立。分类模型通常写成

$$F_M(x) = \sum_{m=1}^M \alpha_m G_m(x), \quad G(x) = \text{sign } F_M(x).$$

实值函数 F_M 保存组合置信方向，符号函数 G 给出最终类别。

读前自检：提升方法的基本思路。 提升方法的基本思路中的“在二类分类问题中，若学习算法在相关数据分布下产生的分类器错误率只需稳定低于 $1/2$ ”决定可执行范围；请把“在二类分类问题中，若学习算法在相关数据分布下产生的分类器错误率只需稳定低于 $1/2$ ”中的已声明对象依次标成输入、输出与判据，结果须满足弱、强均相对于指定假设类、数据分布及可学习性条件而言。

定义 19.1 (弱学习器与强学习器). 在二类分类问题中, 若学习算法在相关数据分布下产生的分类器错误率只需稳定低于 $1/2$, 则称其为弱学习器; 若学习算法能在给定精度与置信要求下产生错误率足够小的分类器, 则称其为强学习器。弱、强均相对于指定假设类、数据分布及可学习性条件而言。

两个权重层次。 样本权重 $D_m(i)$ 决定第 m 轮训练时哪些观测更受重视; 分类器权重 α_m 决定 G_m 在最终表决中的影响。AdaBoost 提高被当前分类器错分样本的相对权重, 同时让错误率较低的分类器取得较大的正系数。

学习策略。 提升法在加法模型族中逐轮降低经验代理损失: 每轮先按当前模型诱导的样本权重或负梯度选择一个基学习器, 再确定该学习器的系数。二类 AdaBoost 对应指数损失的前向分步; 回归与一般梯度提升则分别使用平方损失或任务指定的可微损失。独立验证只负责选择轮数与复杂度, 不参与同一轮参数拟合。




图 19.1 AdaBoost 中样本权重 D_m 决定下一轮训练重点, 分类器权重 α_m 与弱分类器 G_m 直接进入加法模型; 两类权重位于不同计算支路。

沿图 19.1 核对实现顺序时, D_m 只能进入第 m 轮弱学习器, 得到 G_m 与 α_m 后才生成 D_{m+1} ; 最终模型累加的是 $\alpha_m G_m$ 。把 α_m 写入样本分布或把 D_m 当作加法系数, 虽可能维度合法, 却已不对应指数损失推导。

读前自检: 提升方法 AdaBoost 算法。 把提升方法 AdaBoost 算法放在“给定第 m 轮分布 D_m , 先训练 G_m ”下考察: 把 α_m 展开一次并检查其类型或边界, 并检查两者之比为 $e^{2\alpha_m} = (1 - e_m)/e_m$ 。

19.2 AdaBoost 算法

给定第 m 轮分布 D_m , 先训练 G_m , 再计算

$$e_m = \sum_{i=1}^N D_m(i) \mathbf{1}\{G_m(x_i) \neq y_i\}.$$

当 $0 < e_m < 1/2$ 时, 组合系数和权重更新为

$$\alpha_m = \frac{1}{2} \log \frac{1 - e_m}{e_m}, \quad D_{m+1}(i) = \frac{D_m(i) \exp[-\alpha_m y_i G_m(x_i)]}{Z_m},$$

$$Z_m = \sum_{i=1}^N D_m(i) \exp[-\alpha_m y_i G_m(x_i)].$$

正确分类时 $y_i G_m(x_i) = 1$ ，未规范化权重乘 $e^{-\alpha_m}$ ；错分时乘 e^{α_m} 。两者之比为 $e^{2\alpha_m} = (1 - e_m)/e_m$ 。

读前自检：AdaBoost 算法。 AdaBoost 算法输入“有限非空二类训练集、可选验证集、带权基学习器 $\mathcal{A}$ 、轮数与早停/数值参数”，条件“ $y_i \in \{-1, +1\}$ ”；请做一轮“ D^+, F^+ 、训练/验证指标全部有限且权重归一化后才原子提交完整轮”，以“零训练误差、弱学习条件失效、验证耐心耗尽、轮数预算耗尽或首次失败时停止”核对停止证书。

算法契约。基学习算法必须接受样本权重，或通过按 D_m 重采样实现等价训练接口。若 $e_m > 1/2$ 而假设类不对反号封闭，本轮不能强行改号；若 $e_m = 1/2$ ，则 $\alpha_m = 0$ ，加入该分类器不改变模型；若 $e_m = 0$ ，理论系数发散，数值实现以 ε_{num} 和 α_{max} 截断，但必须先把当前 G_m 实际并入 F_m ，再依据组合训练错误或验证规则决定是否停止。

停止条件。三套提升算法都只在一个候选基学习器完成系数、权重与加法模型更新后检查停止。状态统一为：完成预定有限流程或达到零训练错误用 `completed`；目标/参数变化落入数值阈值但无最优性证书用 `numerical_failure`，诊断写明“数值平台”；独立验证耐心或实际 M 轮预算耗尽用 `budget_stop`，诊断区分预算种类；AdaBoost 对冻结候选类完整核验后仍无正边缘时用 `converged`，诊断明确该证书只相对于当前候选类。同因必须同码，且每种出口同时报告触发指标。

二类 AdaBoost 训练：五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 19.1: 二类 AdaBoost 训练

输入: 训练集 T , 可选验证集 T_{val} , 带权基学习算法 $\mathcal{A}$

输出: 最后合法轨迹与选定 F^*, G^* 、权重 D 、 $m_{\text{done}}, a_{\text{done}}$ 、**status** 与最终诊断

数据: $M \in \mathbb{N}_0$; 早停耐心 $p \in \mathbb{N}_+$; $0 < \varepsilon_{\text{num}} < 1/2$; $\alpha_{\text{max}} > 0$; 固定反号和并列规则

- 1 $D \leftarrow \emptyset, F \leftarrow 0, m_{\text{done}} \leftarrow 0, a_{\text{done}} \leftarrow 0$, 诊断为空
- 2 若训练集为空、标签/特征非有限或非法, 验证接口、基学习接口、预算、截断、反号或并列规则不合法, 则返回空权重与零模型、计数 0、**invalid_input** 及字段诊断
- 3 置 $D(i) \leftarrow 1/N$; 若有验证集, 以 F_0 初始化最佳记录
- 4 **当** $m_{\text{done}} < M$ **执行**
 - 5 令 $m \leftarrow m_{\text{done}} + 1$; 用 (T, D) 训练临时 $G_m \leftarrow \mathcal{A}(T, D)$ 并令 $a_{\text{done}} \leftarrow a_{\text{done}} + 1$
 - 6 若拟合失败、预测不覆盖训练集、不是有限二值值, 则返回最后合法 $F, D, m_{\text{done}}, a_{\text{done}}, \text{numerical_failure}$, 诊断为基学习阶段 m
 - 7 计算 $e_m \leftarrow \sum_i D(i) \mathbf{1}\{G_m(x_i) \neq y_i\}$; 若 e_m 非有限或不在 $[0, 1]$, 则返回最后合法状态与 numerical_failure , 诊断为误差阶段 m
 - 8 若 $e_m > 1/2$ 且规则允许反号, 则在候选中取 $G_m \leftarrow -G_m, e_m \leftarrow 1 - e_m$
 - 9 **若** $e_m \geq 1/2$ **则**
 - 10 返回最后合法轨迹与 **converged**, 最终诊断记录“冻结候选类内无正边缘”及反号规则、 m, e_m , 不得外推为全局最优
 - 11 **结束**
 - 12 令 $e_m^{\text{safe}} \leftarrow \max(e_m, \varepsilon_{\text{num}})$ 并计算有限截断系数 α_m ; 在临时状态计算 Z_m, D^+, F^+ 、训练错误和可选验证指标
 - 13 若 Z_m 不是有限正数、 D^+ 含负数/非有限值或归一化残差超容差, 或 F^+ 与指标非有限, 则返回未改动的最后合法状态与 **numerical_failure**, 诊断为权重/模型验收阶段 m
 - 14 原子提交 $D \leftarrow D^+, F \leftarrow F^+$ 及轨迹, 令 $m_{\text{done}} \leftarrow m$; 验证改善时更新最佳记录
 - 15 **若** $\text{sign } F$ 训练错误率为 0 **则**
 - 16 返回当前完整模型与 **completed**, 最终诊断记录零训练错误、截断和 Z_m
 - 17 **结束**
 - 18 **若** 验证指标连续 p 轮未改善 **则**
 - 19 返回最佳验证模型与 **budget_stop**, 最终诊断记录耐心耗尽、最佳轮和末轮指标
 - 20 **结束**
- 21 **结束**
- 22 返回最佳验证模型或最后完整模型、 $D, m_{\text{done}}, a_{\text{done}}, \text{budget_stop}$, 最终诊断记录轮数预算耗尽及末轮训练/验证误差

算法实现说明: 冻结候选类内无正边缘返回 **converged** 并记录相对证书; 验证耐心与轮数耗尽均返回 **budget_stop**, 由诊断区分。只有已提交完整轮才进入轨迹, 失败时保留上一合法模型。完整 C1-C14 契约

读前自检: AdaBoost 算法的解释。 从 AdaBoost 算法的解释的条件 “ $\sum_i D_{m+1}(i) = 1$ ” 出发, 请将 $\sum_i D_{m+1}(i) = 1$ 左端按正文定义展开一层, 再逐项对齐右端; 所得量应符合规范化因子使 $\sum_i D_{m+1}(i) = 1$, 同时记录本轮指数经验风险的缩减程度。

更新式还可写成

$$D_{m+1}(i) = \begin{cases} \frac{D_m(i)}{Z_m} e^{-\alpha_m}, & G_m(x_i) = y_i, \\ \frac{D_m(i)}{Z_m} e^{\alpha_m}, & G_m(x_i) \neq y_i. \end{cases}$$

这不是把错分样本复制一次的启发式操作，而是指数损失坐标下降诱导的精确重加权。规范化因子使 $\sum_i D_{m+1}(i) = 1$ ，同时记录本轮指数经验风险的缩减程度。

读前自检：AdaBoost 最终分类器的训练误差。 AdaBoost 训练误差以 $y_i F_M(x_i) \leq 0$ 判错；请用 $\mathbf{1}\{u \leq 0\} \leq e^{-u}$ 逐样本上界错误指示，再按权重递推核对指数损失均值等于 $\prod_m Z_m$ 。

读前自检：AdaBoost 算法的训练误差分析。 按本节权重递推展开最终指数损失。请核对其等于 $\prod_m Z_m$ ，并由此上界 0-1 训练误差。

19.3 训练误差与泛化解释

定理 19.1 (AdaBoost 训练误差的乘积上界) 设每轮权重均按 AdaBoost 规则规范化， $F_M(x) = \sum_{m=1}^M \alpha_m G_m(x)$ ，则

$$\frac{1}{N} \sum_{i=1}^N \mathbf{1}\{y_i F_M(x_i) \leq 0\} \leq \frac{1}{N} \sum_{i=1}^N e^{-y_i F_M(x_i)} = \prod_{m=1}^M Z_m.$$

读前自检：证明：AdaBoost 训练误差的乘积上界。 先锁定 AdaBoost 训练误差的乘积上界的条件“指示函数满足 $\mathbf{1}\{u \leq 0\} \leq e^{-u}$ ，所以第一个不等式成立”：补出 $D_{M+1}(i)$ 到下一关系的一步不等式或求导，所得结果应满足把权重递推连乘。

证明。 指示函数满足 $\mathbf{1}\{u \leq 0\} \leq e^{-u}$ ，所以第一个不等式成立。把权重递推连乘，

$$D_{M+1}(i) = \frac{D_1(i) \exp[-y_i \sum_{m=1}^M \alpha_m G_m(x_i)]}{\prod_{m=1}^M Z_m}.$$

由于 $D_1(i) = 1/N$ 且 $\sum_i D_{M+1}(i) = 1$ ，对 i 求和后得到

$$\frac{1}{N} \sum_i e^{-y_i F_M(x_i)} = \prod_m Z_m.$$

两式合并即为结论。 □

将正确与错误样本分开可写出

$$Z_m = (1 - e_m)e^{-\alpha_m} + e_m e^{\alpha_m}.$$

代入 $\alpha_m = \frac{1}{2} \log[(1 - e_m)/e_m]$ ，得到

$$Z_m = 2\sqrt{e_m(1 - e_m)}.$$

若 $e_m = \frac{1}{2} - \gamma_m$ 且 $\gamma_m > 0$, 则

$$Z_m = \sqrt{1 - 4\gamma_m^2} \leq e^{-2\gamma_m^2}, \quad \hat{R}_{\text{train}}(G) \leq \exp\left(-2 \sum_{m=1}^M \gamma_m^2\right).$$

只要各轮保持正边缘, 乘积上界会持续收缩。

若存在常数 $\gamma > 0$ 使每轮 $\gamma_m \geq \gamma$, 则

$$\hat{R}_{\text{train}}(G) \leq e^{-2M\gamma^2}.$$

该结论是训练误差上界, 不等同于测试误差保证。泛化还受假设类容量、轮数、基学习器复杂度、样本量、标签噪声和边际分布影响。常用归一化间隔为

$$\rho_i = \frac{y_i F_M(x_i)}{\sum_m |\alpha_m|}.$$

训练错误对应 $\rho_i \leq 0$; 在训练错误已经为 0 后继续提升, 仍可能把一部分小正间隔推大, 这为实践中的泛化现象提供解释。若异常点或错标样本长期保持负间隔, 指数损失会赋予它们很大影响并造成过拟合。

几何解释。 令 $g(x) = (G_1(x), \dots, G_M(x))^T$ 、 $\alpha = (\alpha_1, \dots, \alpha_M)^T$, 则 $yF_M(x) = \langle \alpha, yg(x) \rangle$ 是在“基分类器输出空间”中的有符号间隔。用 $\|\alpha\|_1$ 归一化后, ρ_i 等于正确表决策权重比例减去错误表决策权重比例, 取值位于 $[-1, 1]$; 它衡量样本离加权表决边界的相对位置, 但不是原输入空间中的欧氏距离。

概率解释。 设 $\eta(x) = P(Y = 1 | X = x)$, 在固定 x 处, 指数损失的条件风险为

$$\mathcal{R}(F | x) = \eta e^{-F} + (1 - \eta)e^F.$$

令其关于 F 的导数为零, 得到 $F^\star(x) = \frac{1}{2} \log[\eta(x)/(1 - \eta(x))]$, 从而 $\eta(x) = \{1 + \exp[-2F^\star(x)]\}^{-1}$ 。这一总体最优关系说明得分方向与条件概率相容; 有限样本、受限基函数和早停下的 F_M 不必已经校准, 若业务需要概率, 应在独立校准数据上检查并校准。

读前自检：前向分步算法。 对前向分步算法, 条件“给定基函数 $b(x; \gamma)$ ”不可省; 请把 $f_M(x)$ 展开一次并检查其类型或边界, 再用代价是早期已选参数通常不再回溯重估作检查。

读前自检：前向分步算法。 前向分步算法把问题限定在“给定基函数 $b(x; \gamma)$ ”; 请把 $f_M(x)$ 展开一次并检查其类型或边界, 检查是否得到代价是早期已选参数通常不再回溯重估。

19.4 加法模型与前向分步算法

读前自检：加法模型与前向分步。 在“给定基函数 $b(x; \gamma)$ ”成立时处理加法模型与前向分步: 请把 $f_M(x)$ 展开一次并检查其类型或边界, 并以展开后的量满足定义中的域、维数或符号限制判定结果。

定义 19.2 (加法模型与前向分步). 给定基函数 $b(x; \gamma)$, 加法模型为

$$f_M(x) = \sum_{m=1}^M \beta_m b(x; \gamma_m).$$

前向分步算法在第 m 轮固定已有 f_{m-1} , 只优化新加入的 (β_m, γ_m) :

$$(\beta_m, \gamma_m) = \arg \min_{\beta, \gamma} \sum_{i=1}^N L(y_i, f_{m-1}(x_i) + \beta b(x_i; \gamma)), \quad f_m = f_{m-1} + \beta_m b(\cdot; \gamma_m).$$

这种贪心分解把一次高维联合优化转化为一串低维子问题; 代价是早期已选参数通常不再回溯重估。

读前自检: AdaBoost 是前向分步加法算法的特例。 固定基分类器 G , 令误分与正确样本权重和分别为 W_-, W_+ ; 请最小化 $W_+ e^{-\alpha} + W_- e^{\alpha}$, 核对 $\alpha = \frac{1}{2} \log(W_+/W_-)$ 且 $e_m = W_-/(W_+ + W_-)$ 。

推导第 1 步: 固定旧模型。 对二类标签采用指数损失 $L(y, f) = e^{-yf}$, 并令基函数 $G(x) \in \{-1, +1\}$ 。第 m 轮目标为

$$\sum_i \exp\{-y_i[F_{m-1}(x_i) + \alpha G(x_i)]\} = \sum_i w_{mi} e^{-\alpha y_i G(x_i)}, \quad w_{mi} = e^{-y_i F_{m-1}(x_i)}.$$

推导第 2 步: 先选择基分类器。 对固定 G , 记

$$W_+ = \sum_{y_i=G(x_i)} w_{mi}, \quad W_- = \sum_{y_i \neq G(x_i)} w_{mi}.$$

目标化为 $W_+ e^{-\alpha} + W_- e^{\alpha}$ 。先在允许时对错误率大于 $1/2$ 的分类器反号, 使 $e = W_-/(W_+ + W_-) \in [0, 1/2]$; 其关于 α 的最小值为 $2(W_+ + W_-)\sqrt{e(1-e)}$, 在该区间随 e 单调增加, 所以选择 G_m 等价于最小化当前加权分类错误。若不限制到 $[0, 1/2]$, 这个单调性结论不成立。

推导第 3 步: 求组合系数。 令目标对 α 的导数为零,

$$-W_+ e^{-\alpha} + W_- e^{\alpha} = 0,$$

因而 $e^{2\alpha} = W_+/W_-$ 。用 $e_m = W_-/(W_+ + W_-)$ 表示, 得到

$$\alpha_m = \frac{1}{2} \log \frac{1 - e_m}{e_m}.$$

把 w_{mi} 规范化后就是 $D_m(i)$, 下一轮的指数因子也与 AdaBoost 权重更新完全一致。

读前自检: 前向分步算法与 AdaBoost。 围绕前向分步算法与 AdaBoost, 先采用条件“若基函数类由取值 $\{-1, +1\}$ 的分类器组成, 每轮精确最小化指数经验损失, 且 $0 < e_m < 1/2$ ”, 再把 $\{-1, +1\}$ 展开一次并检查其类型或边界; 最后验证前向分步得到的 G_m 、 α_m 及样本权重递推与 AdaBoost 对应轮一致。

定理 19.2 (指数损失前向分步与 AdaBoost 的等价性) 若基函数类由取值 $\{-1, +1\}$ 的分类器组成, 每轮精确最小化指数经验损失, 且 $0 < e_m < 1/2$, 则前向分步得到的 G_m 、 α_m 及样本权重递推与 AdaBoost 对应轮一致。

读前自检：证明：指数损失前向分步与 AdaBoost 的等价性。 指数损失前向分步固定 F_{m-1} 后选择 G_m, α_m ; 请把损失写成旧权重乘 $e^{-\alpha y_i G(x_i)}$, 按正确/错误样本分组求导, 核对 $\alpha_m = \frac{1}{2} \log[(1 - e_m)/e_m]$ 。

证明. 固定旧模型后, 指数损失按乘法分解为旧权重 w_{mi} 与新因子 $e^{-\alpha y_i G(x_i)}$ 。对 G 的优化等价于最小化规范化后的加权错误 e_m ; 对 α 的一元优化给出 $\frac{1}{2} \log[(1 - e_m)/e_m]$ 。更新 $f_m = f_{m-1} + \alpha_m G_m$ 后, 新一轮权重满足 $w_{m+1,i} = w_{mi} e^{-\alpha_m y_i G_m(x_i)}$ 。除以权重和便得到 AdaBoost 的 D_{m+1} , 三部分逐项相同。□

优化解释。 若候选基分类器集合有限, 每个 G 可看成函数空间中的一个坐标, 前向分步就是函数空间坐标下降: 基学习器近似选择与负梯度最一致的坐标, α_m 则沿该坐标完成一维线搜索。这个视角解释了为何基学习器需要针对当前权重训练, 也说明收缩步长、早停和基函数复杂度会共同正则化最终加法模型。

读前自检：提升树。 把提升方法中的提升树放在“若第 m 棵回归树把输入空间划分为互不相交区域 R_{mj} ”下考察: 独立化简 $j = 1, \dots, J_m$ 的两端, 并检查两端运算均有定义、类型一致且化为同一结果。

19.5 提升树

提升树以决策树为基函数。若第 m 棵回归树把输入空间划分为互不相交区域 R_{mj} , $j = 1, \dots, J_m$, 并在每个叶区域输出 c_{mj} , 则

$$T(x; \Theta_m) = \sum_{j=1}^{J_m} c_{mj} \mathbf{1}\{x \in R_{mj}\}, \quad f_M(x) = f_0(x) + \nu \sum_{m=1}^M T(x; \Theta_m), \quad 0 < \nu \leq 1.$$

树负责选择非线性分区, 加法结构负责逐轮修正。分类提升树可使用二类分类树与指数损失; 回归提升树可使用回归树与平方损失。

读前自检：提升树算法。 提升树以训练样本、损失、树轮数 M 和每轮基学习器预算为输入; 请在当前加法模型 f_{m-1} 上拟合一棵使经验损失下降的回归树并提交 $f_m = f_{m-1} + T_m$, 再按轮数预算或验证停止规则核对输出。

读前自检：回归问题的提升树算法。 回归提升树在平方损失下把第 m 轮残差 $r_{mi} = y_i - f_{m-1}(x_i)$ 作为拟合目标; 请计算一组 r_{mi} 、拟合叶结点常数并更新 f_m , 核对训练平方损失不增, 达到树轮数预算时停止。

阅读目标：把平方损失前向分步子问题改写为对残差的回归。

对象：已有模型 f_{m-1} 、残差 $r_i = y_i - f_{m-1}(x_i)$ 、固定叶区域 R_{mj} 与叶值 c_{mj} 。

合法条件：每个参与更新的叶区域非空；本轮区域划分固定。

第一步：先代入平方损失并写 $y_i - [f_{m-1}(x_i) + g(x_i)] = r_i - g(x_i)$ 。

推导目标

把平方损失的前向分步子问题化为残差回归，并推导固定叶区域后的最优叶值。

推导准备

固定已有模型 f_{m-1} 和本轮树的区域划分 $R_{m1}, \dots, R_{mJ_m}$ ；损失为 $L(y, f) = \frac{1}{2}(y - f)^2$ ，每个叶输出常数 c_{mj} ，空叶不允许进入求均值公式。

推导第1步：把目标改写为残差平方和。 已有模型 f_{m-1} 的本轮目标为

$$\frac{1}{2} \sum_i [y_i - f_{m-1}(x_i) - T(x_i; \Theta_m)]^2.$$

令残差 $r_{mi} = y_i - f_{m-1}(x_i)$ ，问题变成用一棵回归树拟合 (x_i, r_{mi}) 。这说明“拟合残差”不是额外经验规则，而是平方损失前向分步子问题的代数重写。

推导第2步：分离各叶子问题。 固定树划分后，不同叶包含互不相交的样本，第 j 个叶值独立求解

$$\min_c \frac{1}{2} \sum_{x_i \in R_{mj}} (r_{mi} - c)^2.$$

推导第3步：求驻点并核对极小性。 导数为 $-\sum_{x_i \in R_{mj}} (r_{mi} - c)$ ，二阶导数为 $|R_{mj}| > 0$ ；令一阶导数为零得到叶内残差均值 c_{mj} 。若叶为空则二阶导数为 0 且均值无定义，构树阶段必须禁止或回退该叶。加入收缩率 $\nu < 1$ 后，每轮只沿该树方向走部分步长。

复杂度分析

训练时间复杂度。 若一次带权基学习训练成本为 $C_{\mathcal{A}}(N, d)$ ，AdaBoost 的 M 轮训练约为 $O(M[C_{\mathcal{A}}(N, d) + N])$ 。提升树若每棵深度受限树的训练成本为 $C_{\text{tree}}(N, d)$ ，总训练约为 $O(MC_{\text{tree}})$ ；预排序或直方图会改变该参数化成本。

正确性依据。 AdaBoost 的权重更新以 Z_m 归一化为概率分布，并沿指数损失的一维精确系数更新；平方损失提升树的叶值是非空叶区域上的唯一均值极小点；一般梯度提升以负梯度构造下降方向，再由叶内一维优化确定步长。任一子问题不能完成时，算法停止并保留最后一个完整模型。

平方损失回归提升树：五步阅读

输入。 写出数据对象、固定参数与必须成立的条件。

初始化。 标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 19.2: 平方损失回归提升树

输入: 有限回归训练集 T , 可选验证集 T_{val} , 冻结的树结构约束

输出: 最后合法轨迹与选定 f^* , m_{done} , a_{done} , **status** 与最终诊断

数据: $M \in \mathbb{N}_0$; $0 < \nu \leq 1$; 训练容差 $\varepsilon_J > 0$; 早停耐心 $p \in \mathbb{N}_+$

- 1 $f \leftarrow \perp$, $m_{\text{done}} \leftarrow 0$, $a_{\text{done}} \leftarrow 0$, 诊断为空
- 2 若训练集为空、特征/响应非有限, 验证接口、树约束、 M, ν, ε_J, p 或并列规则不合法, 则返回空模型、计数 0、**invalid_input** 及字段诊断
- 3 计算 $\bar{y}$ 及初始训练/验证损失; 若非有限则返回空模型、**numerical_failure** 及初始化阶段诊断; 否则提交 $f \leftarrow \bar{y}$ 并初始化可选验证最佳记录
- 4 当 $m_{\text{done}} < M$ 执行
 - 5 令 $m \leftarrow m_{\text{done}} + 1$; 在临时状态计算全部 $r_i \leftarrow y_i - f(x_i)$; 若任一残差非有限, 则返回最后合法状态与 **numerical_failure**, 诊断为残差阶段 m
 - 6 用 (x_i, r_i) 拟合树并令 $a_{\text{done}} \leftarrow a_{\text{done}} + 1$; 若拟合失败、叶数为零、叶为空或区域不互斥覆盖, 则返回最后合法状态与 **numerical_failure**, 诊断为树阶段 m
 - 7 对每个叶 j 计算有限 $c_j = |R_j|^{-1} \sum_{x_i \in R_j} r_i$, 形成 T_m 、候选 $f^+ = f + \nu T_m$ 及训练/验证损失
 - 8 若任一叶值、预测或损失非有限, 则返回未改动的最后合法状态与 **numerical_failure**, 诊断为叶/模型验收 (m, j)
 - 9 计算训练相对下降 Δ_m , 原子提交 $f \leftarrow f^+$ 及树、指标轨迹, 令 $m_{\text{done}} \leftarrow m$; 验证改善时更新最佳记录
 - 10 若有验证集且验证损失连续 p 轮未改善 则
 - 11 返回最佳验证模型与 **budget_stop**, 最终诊断记录耐心耗尽、最佳轮和树规模
 - 12 结束
 - 13 若无验证集且 $0 \leq \Delta_m \leq \varepsilon_J$ 则
 - 14 返回当前完整模型与 **numerical_failure**, 最终诊断记录训练相对下降与当前梯度代理
 - 15 结束
- 16 结束
- 17 返回最佳验证模型或最后完整模型、 $m_{\text{done}}, a_{\text{done}}, \text{budget_stop}$, 最终诊断记录轮数预算耗尽与末轮损失

算法实现说明: 验证耐心耗尽统一返回 **budget_stop**; 训练损失相对变化很小只返回 **numerical_failure**, 并报告残差/梯度代理, 不把平台期称作数学收敛。完整 C1-C14 契约

19.6 梯度提升

对一般可微损失 $L(y, f)$, 第 m 轮在各训练点计算负梯度

$$r_{mi} = - \left[\frac{\partial L(y_i, f)}{\partial f} \right]_{f=f_{m-1}(x_i)}.$$

这些 r_{mi} 称为伪残差。基学习器拟合 (x_i, r_{mi}) , 相当于在训练点构成的函数空间中逼近最速下降方向。平方损失 $L = (y - f)^2/2$ 时 $r_{mi} = y_i - f_{m-1}(x_i)$, 退化为通常残差。

读前自检：梯度提升算法。 梯度提升算法依赖“下面的验收门使用预先固定的 $0 < \rho < 1$ 、回溯上限 $L_{\max}$ 、接受下降量 $\tau_{\text{dec}} \geq 0$ 与停止容差 $\varepsilon_J > 0$ ”；请据此对 $0 < \rho < 1$ 完成一项求导、代入或边界比较，并直接核对为避免“叶步长只算到一半就提交”，先把候选生成封装为不改主状态的子过程。

下面的验收门使用预先固定的 $0 < \rho < 1$ 、回溯上限 $L_{\max}$ 、接受下降量 $\tau_{\text{dec}} \geq 0$ 与停止容差 $\varepsilon_J > 0$ 。树深、叶数和最小叶样本数也在训练前冻结。为避免“叶步长只算到一半就提交”，先把候选生成封装为不改主状态的子过程。

读前自检：一般损失梯度提升的候选生成：执行契约。 一般损失梯度提升的候选生成输入“有限训练集 T 、可微损失 L 、最后合法旧模型 f_{old} 、冻结树约束与叶步长求解预算 B_ρ ”，条件“ $T \neq \emptyset$ ”；请执行“只写临时候选”，以“完整候选形成、叶求解预算耗尽或首次失败时停止”判停。

一般损失梯度提升的候选生成：五步阅读

输入。 写出数据对象、固定参数与必须成立的条件。

初始化。 标明主状态、计数器和第一个合法状态。

核心更新。 只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。 写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。 列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 19.3：一般损失梯度提升的候选生成

输入： 训练集 T ，损失 L ，最后合法旧模型 f_{old} ，冻结树约束

输出： 完整候选 $\mathcal{C}_m$ 或 f_{old} 、 i_{done} 、 j_{done} 、 q_{done} 、**status** 与最终诊断

数据： 每叶一维求解预算 $B_\rho \in \mathbb{N}_0$ ；导数、根/极小值与划分容差

- 1 $\mathcal{C}_m \leftarrow \emptyset$, $i_{\text{done}} \leftarrow 0$, $j_{\text{done}} \leftarrow 0$, $q_{\text{done}} \leftarrow 0$, 诊断为空；主状态 f_{old} 只读
- 2 若训练集为空、输入或旧预测非有限、损失/导数接口、树约束、预算、容差或并列规则不合法，则返回未改动 f_{old} 、计数 0、**invalid_input** 及字段诊断
- 3 计算 $J_{\text{old}} \leftarrow \sum_i L(y_i, f_{\text{old}}(x_i))$ ；若非有限则返回未改动 f_{old} 、**numerical_failure** 及旧目标阶段诊断
- 4 按 $i = 1, \dots, N$ 计算伪残差 r_i ，每个有限结果令 $i_{\text{done}} \leftarrow i$ ；若失败则返回未改动 f_{old} 与 **numerical_failure**，诊断为导数位置 i
- 5 用 (x_i, r_i) 拟合临时树；若拟合失败、叶数为零、存在空叶或划分不互斥覆盖，则返回未改动 f_{old} 与 **numerical_failure**，诊断为候选树阶段
- 6 对 $j \leftarrow 1$ 至 J_m 执行
 - 7 在至多 B_ρ 次有限目标求值内求叶步长 ρ_j ，每次令 $q_{\text{done}} \leftarrow q_{\text{done}} + 1$
 - 8 若预算耗尽且无可接受有限步长，则返回 f_{old} 、 i_{done} 、 j_{done} 、 q_{done} 、**budget_stop**，最终诊断记录失败叶 j 及求解区间
 - 9 若叶目标、求解残差或 ρ_j 非有限，则返回未改动 f_{old} 与 **numerical_failure**，诊断为叶求解 j ；否则令 $j_{\text{done}} \leftarrow j$
- 10 结束
- 11 形成并核验 $\mathcal{C}_m = (J_{\text{old}}, \{R_j, \rho_j\}_{j=1}^{J_m})$ ；返回完整候选、 i_{done} 、 j_{done} 、 q_{done} 、**completed**，最终诊断记录树规模、叶残差和主状态未修改

一般损失下的梯度提升树：验收与提交：五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 19.4：一般损失下的梯度提升树：验收与提交

输入： T ，可选 T_{val} ，损失 L ，算法 19.3 候选生成器
输出：最后合法轨迹与选定 f^* 、 m_{done} 、 ℓ_{done} 、**status** 与最终诊断
数据： $M \in \mathbb{N}_0$ ； $0 < \nu \leq 1$ ； $0 < \rho < 1$ ； $L_{\text{max}} \in \mathbb{N}_0$ ； $\tau_{\text{dec}} \geq 0$ ； $\varepsilon_J > 0$ ； $p \in \mathbb{N}_+$

- 1 $m_{\text{done}} \leftarrow 0$ ， $\ell_{\text{done}} \leftarrow 0$ ，诊断为空
- 2 若数据、验证接口、损失/候选接口、预算、收缩、回缩、下降、容差或早停规则不合法，则返回未提交模型、计数 0、**invalid_input** 及字段诊断
- 3 在临时状态求 $f_0 \leftarrow \arg \min_c \sum_i L(y_i, c)$
- 4 若 f_0 、初始目标或验证损失非有限，则返回最后合法常数模型与 **numerical_failure** 及初始化阶段诊断；否则提交 $f \leftarrow f_0$ 并初始化最佳记录
- 5 **当** $m_{\text{done}} < M$ **执行**
 - 6 令 $m \leftarrow m_{\text{done}} + 1$ ，保持 $f_{\text{old}} \leftarrow f$ 只读并调用候选生成器
 - 7 若候选返回 **invalid_input**、**numerical_failure** 或 **budget_stop**，则返回最后合法 f_{old} 、 m_{done} 、 ℓ_{done} 及同一规范状态，诊断附加候选阶段、叶和内部计数
 - 8 $\nu_{\text{trial}} \leftarrow \nu$ ，**accepted** $\leftarrow$ **false**
 - 9 **对** $\ell \leftarrow 0$ **至** L_{max} **执行**
 - 10 在临时状态构造 f^+ 并计算 J^+ ，令 $\ell_{\text{done}} \leftarrow \ell_{\text{done}} + 1$
 - 11 若 f^+ 、 J^+ 有限且 $J^+ \leq J_{\text{old}} - \tau_{\text{dec}}$ ，则置 **accepted** $\leftarrow$ **true** 并终止回溯；否则保持 $f = f_{\text{old}}$ 并令 $\nu_{\text{trial}} \leftarrow \rho \nu_{\text{trial}}$
 - 12 **结束**
 - 13 **若** $\neg$ **accepted** **则**
 - 14 返回最后合法 f_{old} 、 m_{done} 、 ℓ_{done} 、**line_search_failed**，诊断记录失败轮、全部试算目标和末次步长
 - 15 **结束**
 - 16 计算候选训练/验证指标与 $\Delta_m = (J_{\text{old}} - J^+)/ (1 + |J_{\text{old}}|)$ ；若任一指标或 Δ_m 非有限，则返回未改动的最后合法状态与 **numerical_failure**，诊断为外层验收 m
 - 17 原子提交 $f \leftarrow f^+$ 、目标、树、步长与指标轨迹，令 $m_{\text{done}} \leftarrow m$ ；验证改善时更新最佳记录
 - 18 **若** 验证耐心耗尽 **则**
 - 19 返回最佳验证模型与 **budget_stop**，最终诊断记录最佳轮、末轮指标和实际步长
 - 20 **结束**
 - 21 **若** $0 \leq \Delta_m \leq \varepsilon_J$ **则**
 - 22 返回当前完整模型与 **numerical_failure**，最终诊断记录训练目标相对下降和梯度代理
 - 23 **结束**
 - 24 **结束**
- 25 返回最佳验证模型或最后完整模型、 m_{done} 、 ℓ_{done} 、**budget_stop**，最终诊断记录外层预算耗尽及末轮目标

算法实现说明：回缩率严格满足 $0 < \rho < 1$ ，故连续拒绝时 ν_{trial} 严格减小；验证平台与训练数值平台分别返回 **budget_stop** 和 **numerical_failure**，外层轮数实际耗尽才返回 **budget_stop**。完整 C1-C14 契约

更新与收敛。负梯度只在训练点上给出数值，回归树承担“把离散梯度推广为输入函数”的投影任务，因此基学习器拟合误差会使方向偏离精确最速下降。若损失下有界、梯度具适当光滑性、每轮树方向与负梯度保持正相关，并用足够小的学习率或线搜索保证损失下降，则训练目标形成单调有下界的序列。该结论只保证目标值趋于极限；非凸树结构搜索和近似方向不保证到达全局最优模型。

读前自检：AdaBoost 的计算例题。 AdaBoost 计算例从归一权重 $D_m(i)$ 得到弱分类器加权错误率 e_m ；请计算 $\alpha_m = \frac{1}{2} \log[(1 - e_m)/e_m]$ 并更新一次权重，核对新 D_{m+1} 非负且和为 1。

19.7 例题、迭代计算与练习

例题 19.1 (两轮 AdaBoost 的完整计算). 四个样本初始权重均为 $1/4$ 。第一轮 G_1 只错分第 4 个样本；在更新后的分布上，第二轮 G_2 只错分第 1 个样本。计算两轮的错误率、分类器系数、权重分布与最终加法模型。

例题 19.1 解答

读题翻译 四个样本经历两轮加权更新；需要逐轮给出错误率、分类器系数、归一化因子和新权重，并在最后组合加法模型。

已知与合法条件 初始样本权重非负且和为 1；每轮错误率位于可定义分类器系数的范围，更新后的权重必须重新归一化。

为什么想到这个方法 按轮次计算加权错误率、分类器系数和样本权重归一化，再写出加法模型并核验权重和为 1。

方法选择 先由第一轮唯一错分点计算 e_1, α_1, Z_1, D_2 ，再在 D_2 上计算第二轮的 e_2, α_2, Z_2, D_3 ，最后组合两个弱分类器得到 F_2 。

推导/计算 初始分布与第一轮错误率为

$$D_1(i) = \frac{1}{4} \quad (i = 1, \dots, 4), \quad e_1 = \sum_{i=1}^4 D_1(i) \mathbf{1}\{y_i \neq G_1(x_i)\} = \frac{1}{4}.$$

因此

$$\alpha_1 = \frac{1}{2} \log \frac{1 - e_1}{e_1} = \frac{1}{2} \log 3.$$

未规范化权重、归一化因子与新分布形成状态链

$$\begin{aligned} \tilde{D}_2 &= \left(\frac{1}{4} e^{-\alpha_1}, \frac{1}{4} e^{-\alpha_1}, \frac{1}{4} e^{-\alpha_1}, \frac{1}{4} e^{\alpha_1} \right), \\ Z_1 &= \frac{3}{4} e^{-\alpha_1} + \frac{1}{4} e^{\alpha_1} = 2 \sqrt{\frac{1}{4} \frac{3}{4}} = \frac{\sqrt{3}}{2}, \\ D_2 &= \frac{\tilde{D}_2}{Z_1} = \left(\frac{1}{6}, \frac{1}{6}, \frac{1}{6}, \frac{1}{2} \right). \end{aligned}$$

第二轮只有第1个样本错分, 故

$$e_2 = D_2(1) = \frac{1}{6}, \quad \alpha_2 = \frac{1}{2} \log \frac{1-e_2}{e_2} = \frac{1}{2} \log 5.$$

第二轮更新还必须落到新的概率分布。由于仅第1个样本错分,

$$\begin{aligned} \tilde{D}_3 &= \left(\frac{\sqrt{5}}{6}, \frac{1}{6\sqrt{5}}, \frac{1}{6\sqrt{5}}, \frac{1}{2\sqrt{5}} \right), \\ Z_2 &= \sum_{i=1}^4 \tilde{D}_3(i) = \frac{\sqrt{5}}{3}, \\ D_3 &= \frac{\tilde{D}_3}{Z_2} = \left(\frac{1}{2}, \frac{1}{10}, \frac{1}{10}, \frac{3}{10} \right), \quad \sum_{i=1}^4 D_3(i) = 1. \end{aligned}$$

最终加法模型与比较结论为

$$F_2(x) = \frac{1}{2} \log 3 G_1(x) + \frac{1}{2} \log 5 G_2(x), \quad \alpha_2 > \alpha_1.$$

独立核验 D_2, D_3 的各分量均非负且分别求和为1; 两轮都有 $e_t < 1/2$ 。此外, 每轮唯一错分样本更新后的质量均为 $1/2$: $D_2(4) = 1/2$ 、 $D_3(1) = 1/2$, 与 AdaBoost 闭式更新一致。

结论

$$\begin{aligned} e_1 &= \frac{1}{4}, \quad \alpha_1 = \frac{1}{2} \log 3, \quad D_2 = \left(\frac{1}{6}, \frac{1}{6}, \frac{1}{6}, \frac{1}{2} \right), \\ e_2 &= \frac{1}{6}, \quad \alpha_2 = \frac{1}{2} \log 5, \quad D_3 = \left(\frac{1}{2}, \frac{1}{10}, \frac{1}{10}, \frac{3}{10} \right), \\ F_2(x) &= \frac{1}{2} \log 3 G_1(x) + \frac{1}{2} \log 5 G_2(x). \end{aligned}$$

当 G_1, G_2 意见相反时, 因 $\alpha_2 > \alpha_1$, 第二轮分类器主导表决。

可复核实现流程。

1. 在每轮开始检查权重非负、总和接近1, 并记录权重有效样本量 $1/\sum_i D_m(i)^2$;
2. 使用训练折内的权重拟合基学习器, 所有预处理参数也只能由该训练折估计;
3. 同时保存 e_m, α_m, Z_m 、训练指数损失、训练零一错误和独立验证指标;
4. 对指数更新采用对数权重或减去最大对数权重后再归一化, 避免上溢与下溢;
5. 固定初始化与候选切分规则, 并记录每棵树的结构, 使每轮预测都可重复核验;
6. 预测时严格按训练顺序累加, 分类只在最后取符号, 回归则直接输出实值和。

复杂度分析

预测时间复杂度。若单个基学习器预测代价为 C_{pred} , 顺序累加 M 个基模型为 $O(MC_{\text{pred}})$; 深度至多 D 的树集成通常写为 $O(MD)$ 。

存储与空间复杂度。训练需 $O(N)$ 样本权重或伪残差; 保存 M 棵至多 J 叶的树约为 $O(MJ)$ 。

复杂度假设: 基学习器串行训练且不同时保留每轮完整数据副本; 并行候选会增加峰值存储。

更新顺序与停止情形。每轮必须依次完成基学习器拟合、误差或负梯度计算、系数或叶值求解与模型累加，再检查停止。训练集为空、出现空叶、负梯度不是有限实数、叶内一维子问题无解或基学习器不能完成拟合时，算法在上一完整轮停止；达到 M 轮或验证早停条件而训练容差仍未满足时，不宣称优化已经收敛。

读前自检：适用条件与局限：例题、迭代计算与练习。 AdaBoost 要求冻结权重分布下的弱分类器误差 $e_m < 1/2$ ；请代入 $\alpha_m = \frac{1}{2} \log[(1 - e_m)/e_m]$ ，核对 $e_m \geq 1/2$ 时不产生正的提升系数并触发既定失败处理。

适用条件与局限性

适用条件与适用性。AdaBoost 适合可提供稳定弱边缘、标签质量较好的二类分类；树提升适合表格数据中的非线性、阈值效应和变量交互；梯度提升通过选择损失可处理回归、分类、排序及部分稳健估计问题。应用前必须明确评价指标、类别代价、缺失值机制与部署延迟预算。

方法局限

指数损失会持续放大难分样本和错标样本的影响；树提升的轮数、深度、学习率、叶样本数高度耦合；小学习率通常要求更多树；相关特征可能使树结构解释不稳定；训练分布变化会让历史残差方向失效。概率输出还需检查所用损失与校准方法，组合得分本身不能一概当作条件概率。

读前自检：常见错误与误用边界：例题、迭代计算与练习。 例题、迭代计算与练习把问题限定在“边界框首项禁止除以总权重”；请把固定错误“除以总权重”中的对象、操作与结论按本节定义拆开，指出第一个不满足的定义条件，再把该处改为本节允许的写法，检查是否得到改写后的运算或判断有定义，且不再触发“除以总权重”。

常见错误

1. 用未规范化权重的错分和冒充错误率，却没有除以总权重；
2. 把 α_m 误写为 $\log[(1 - e_m)/e_m]$ ，遗漏系数 $1/2$ ；
3. 先对 G_m 取最终符号再累加，丢失实值加法模型的幅度；
4. 将回归残差公式用于任意损失，而没有计算相应负梯度和叶内线搜索；
5. 用测试集选择轮数、深度或学习率，造成评价信息泄漏；
6. 达到轮数上限便报告“收敛”，却没有给出损失、梯度或验证早停证据。

选择顺序。先按任务确定损失和评价指标，再用验证方案联合选择基学习器复杂度、学习率和轮数；类别极不平衡时需在权重或损失中体现代价；标签噪声明显时应比较对异常点不那么敏

感的损失，并检查权重是否集中在少数样本。模型解释应同时报告全局性能、分组性能与误差案例，不能只展示训练损失曲线。

读前自检：易混淆概念对比：例题、迭代计算与练习。 在“对比表首个数据行是“AdaBoost | 降低指数分类损失 | 二类弱分类器 | 样本重加权与加权表决具有闭式系数””成立时处理例题、迭代计算与练习：请按列复述“AdaBoost | 降低指数分类损失 | 二类弱分类器 | 样本重加权与加权表决具有闭式系数”中的对象、假设与结论，并以各列均对应首行对象“AdaBoost”，且未与表中下一行互换判定结果。

易混淆概念对比			
对比与混淆类别。 提升与随机森林都组合多棵树，但前者串行修正损失方向，后者并行随机化后平均；不能因二者都输出树集成而混用训练逻辑。			
方法	每轮目标	典型基学习器	关键特点
AdaBoost	降低指数分类损失	二类弱分类器	样本重加权与加权表决具有闭式系数
回归提升树	拟合平方损失残差	回归树	残差就是平方损失负梯度
梯度提升树	拟合一般损失伪残差	回归树	以损失负梯度统一分类与回归
随机森林	并行降低方差	随机化决策树	不按残差串行训练, 主要靠平均去相关

本章共 12 道练习。每道题干后立即给出同号解析；长解析可自然跨页，续页标题保留题号。

练习 19.1. 某基分类器在均匀分布下错分 4 个样本中的 1 个。求其错误率，并判断它是否满足二类弱学习器在该轮所需的误差条件。

练习 19.1 解析

当前权重分布为

$$D(i) = \frac{1}{4}, \quad i = 1, \dots, 4, \quad \sum_{i=1}^4 D(i) = 1.$$

若错分集合只含一个样本 j ，加权错误率为

$$e = \sum_{i=1}^4 D(i) \mathbf{1}\{y_i \neq G(x_i)\} = D(j) = \frac{1}{4}.$$

因此

$$0 < e = \frac{1}{4} < \frac{1}{2},$$

练习 19.1 解析 (续)

该分类器在当前权重分布上优于随机猜测, 满足本轮二类弱误差条件; 权重改变后必须重新计算 e 。

练习 19.2. 解释为什么把全部样本权重同时乘以正数不会改变加权错误率, 但实现中仍应将权重规范化。

练习 19.2 解析

对非负且总和为正的权重 w_i , 加权错误率定义为

$$e(w) = \frac{\sum_i w_i \mathbf{1}\{y_i \neq G(x_i)\}}{\sum_i w_i}.$$

任取 $c > 0$, 缩放不变链为

$$e(cw) = \frac{c \sum_i w_i \mathbf{1}\{y_i \neq G(x_i)\}}{c \sum_i w_i} = e(w).$$

实现中仍令

$$D(i) = \frac{w_i}{\sum_j w_j}, \quad D(i) \geq 0, \quad \sum_i D(i) = 1,$$

从而把错误率写成离散期望, 并避免多轮指数更新导致数值尺度持续膨胀或收缩。

练习 19.3. 某轮错误率 $e_m = 0.2$ 。计算 α_m 以及错分样本相对于正确样本的权重倍率。

练习 19.3 解析

因 $e_m = 0.2 \in (0, 1/2)$, 分类器系数为

$$\alpha_m = \frac{1}{2} \log \frac{1 - e_m}{e_m} = \frac{1}{2} \log \frac{0.8}{0.2} = \frac{1}{2} \log 4 = \log 2.$$

权重更新中, 正确与错分样本的未规范化倍率分别为

$$e^{-\alpha_m} = \frac{1}{2}, \quad e^{\alpha_m} = 2.$$

因此错分样本相对正确样本的倍率为

$$\frac{e^{\alpha_m}}{e^{-\alpha_m}} = e^{2\alpha_m} = 4 = \frac{1 - e_m}{e_m}.$$

因此当 $e_m = 0.2$ 时, $\alpha_m = \log 2$, 错分样本相对正确样本被放大 4 倍。

练习 19.4. 设 $D_m = (0.2, 0.3, 0.5)$, 只有第二个样本被 G_m 错分, 且 $\alpha_m = \frac{1}{2} \log(7/3)$ 。写出未规范化权重和 Z_m 。

练习 19.4 解析

令 $r = e^{\alpha m} = \sqrt{7/3} > 0$, 则 $e^{-\alpha m} = r^{-1}$ 。第一、三个样本分类正确, 第二个样本错分, 所以

$$\tilde{D}_{m+1} = (0.2r^{-1}, 0.3r, 0.5r^{-1}).$$

归一化因子为

$$\begin{aligned} Z_m &= 0.7r^{-1} + 0.3r \\ &= 2\sqrt{0.7 \times 0.3} \\ &= \frac{\sqrt{21}}{5} \approx 0.9165. \end{aligned}$$

故下一轮状态为

$$D_{m+1} = \frac{1}{Z_m} \left(0.2\sqrt{\frac{3}{7}}, 0.3\sqrt{\frac{7}{3}}, 0.5\sqrt{\frac{3}{7}} \right), \quad \sum_i D_{m+1}(i) = 1.$$

因此以上权重除以 $Z_m = \sqrt{21}/5$ 后构成下一轮的合法概率分布。

练习 19.5. 若三轮加权错误率均为 0.1, 计算训练误差乘积上界。

练习 19.5 解析

每轮 $e_m = 0.1 \in (0, 1/2)$, 所以

$$Z_m = 2\sqrt{e_m(1-e_m)} = 2\sqrt{0.1 \times 0.9} = 0.6.$$

三轮训练误差乘积界为

$$\hat{R}_{\text{train}}(G_3) \leq \prod_{m=1}^3 Z_m = 0.6^3 = 0.216.$$

这是指数损失导出的训练错误上界, 实际训练错误可更小, 且该数值不是测试错误率。

练习 19.6. 已知每轮 $e_m \leq 0.4$, 求使上界 $e^{-2M(0.1)^2} \leq 0.05$ 所需的最小整数 M 。

练习 19.6 解析

每轮边缘满足

$$\gamma_m = \frac{1}{2} - e_m \geq \frac{1}{2} - 0.4 = 0.1.$$

因此上界链为

$$\hat{R}_{\text{train}}(G_M) \leq \exp\left(-2 \sum_{m=1}^M \gamma_m^2\right) \leq e^{-2M(0.1)^2} = e^{-0.02M}.$$

练习 19.6 解析 (续)

要求该上界不超过 0.05, 则

$$\begin{aligned} e^{-0.02M} &\leq 0.05 \\ \Leftrightarrow -0.02M &\leq \log 0.05 \\ \Leftrightarrow M &\geq \frac{-\log 0.05}{0.02} \approx 149.7866. \end{aligned}$$

由于 $M \in \mathbb{Z}_{>0}$, 最小整数为 $M_{\min} = 150$ 。

练习 19.7. 对 $Q(\alpha) = W_+e^{-\alpha} + W_-e^{\alpha}$ 求一阶、二阶导数, 并说明驻点为何是唯一极小点。

练习 19.7 解析

对 $\alpha \in \mathbb{R}$, 一、二阶导数为

$$\begin{aligned} Q'(\alpha) &= -W_+e^{-\alpha} + W_-e^{\alpha}, \\ Q''(\alpha) &= W_+e^{-\alpha} + W_-e^{\alpha}. \end{aligned}$$

若 $W_+ > 0$ 且 $W_- > 0$, 则

$$Q''(\alpha) > 0 \quad (\forall \alpha \in \mathbb{R}) \implies Q \text{ 严格凸}.$$

驻点链为

$$Q'(\alpha) = 0 \Leftrightarrow W_-e^{\alpha} = W_+e^{-\alpha} \Leftrightarrow e^{2\alpha} = \frac{W_+}{W_-} \Leftrightarrow \alpha^* = \frac{1}{2} \log \frac{W_+}{W_-}.$$

严格凸性保证该驻点是唯一全局极小点。若某一组权重为零, 则有限驻点不存在, 最优只在 $\alpha \rightarrow \pm\infty$ 的边界极限达到。

练习 19.8. 设 $W_+ = 9, W_- = 1$, 求最优 α 和最小目标值。

练习 19.8 解析

这里 $W_+ = 9 > 0$ 、 $W_- = 1 > 0$, 故有限唯一最优系数为

$$\alpha^* = \frac{1}{2} \log \frac{W_+}{W_-} = \frac{1}{2} \log 9 = \log 3.$$

代回目标得到

$$\begin{aligned} Q(\alpha^*) &= 9e^{-\log 3} + e^{\log 3} \\ &= \frac{9}{3} + 3 \\ &= 6 = 2\sqrt{W_+W_-}. \end{aligned}$$

并且 $Q''(\alpha^*) = 6 > 0$, 与唯一严格极小点的结论一致。

练习 19.9. 当前预测为 $(2, 1, 4)$, 真实响应为 $(3, 0, 5)$ 。求残差; 若一棵只有单叶的树拟合这些残差, 求叶值和更新后的预测。

练习 19.9 解析

令 $y = (3, 0, 5)^T$ 、 $f = (2, 1, 4)^T$ 。平方损失残差为

$$r = y - f = (1, -1, 1)^T.$$

单叶覆盖全部三个样本, 其最优常数是

$$c = \frac{1}{3} \sum_{i=1}^3 r_i = \frac{1-1+1}{3} = \frac{1}{3}.$$

对收缩率 $0 < \nu \leq 1$, 状态更新为

$$f^+ = f + \nu c \mathbf{1} = \left(2 + \frac{\nu}{3}, 1 + \frac{\nu}{3}, 4 + \frac{\nu}{3}\right)^T.$$

特别地, $\nu = 1$ 时 $f^+ = (7/3, 4/3, 13/3)^T$ 。

练习 19.10. 证明固定叶区域 R 时, 平方损失最优叶值是该区域残差均值, 并说明区域为空时为何不能使用该公式。

练习 19.10 解析

令叶区域索引集 $I_R = \{i : x_i \in R\}$ 。当 $|I_R| > 0$ 时, 叶值子问题为

$$\min_{c \in \mathbb{R}} Q(c), \quad Q(c) = \frac{1}{2} \sum_{i \in I_R} (r_i - c)^2.$$

最优性条件给出

$$\begin{aligned} Q'(c) &= - \sum_{i \in I_R} (r_i - c) = 0 \\ \Leftrightarrow c^\star &= \frac{1}{|I_R|} \sum_{i \in I_R} r_i, \end{aligned}$$

$$Q''(c) = |I_R| > 0.$$

因此残差均值是唯一最优叶值。若 $I_R = \emptyset$, 则

$$Q(c) \equiv 0, \quad \frac{1}{|I_R|} \sum_{i \in I_R} r_i = \frac{0}{0} \text{ 未定义,}$$

叶值不可识别, 树构造必须禁止空叶或删除该区域。

练习 19.11. 分别求平方损失 $L = (y - f)^2/2$ 和二类逻辑损失 $L = \log(1 + e^{-2yf})$ 关于 f 的伪残差。

练习 19.11 解析

伪残差定义为损失关于当前预测的负梯度：

$$r = -\frac{\partial L(y, f)}{\partial f}.$$

对平方损失，得到

$$L(y, f) = \frac{1}{2}(y - f)^2 \implies \frac{\partial L}{\partial f} = f - y \implies r = y - f.$$

对 $y \in \{-1, +1\}$ 的二类逻辑损失，得到

$$\begin{aligned} L(y, f) &= \log(1 + e^{-yf}), \\ \frac{\partial L}{\partial f} &= -\frac{ye^{-yf}}{1 + e^{-yf}} = -\frac{y}{1 + e^{yf}}, \\ r &= \frac{y}{1 + e^{2yf}}. \end{aligned}$$

两式均应在 $f = f_{m-1}(x_i)$ 处逐样本计算。

练习 19.12. 延续例题，计算第二轮系数 α_2 ，并比较 α_2 与 α_1 。

练习 19.12 解析

由例题的第二轮分布 $D_2 = (1/6, 1/6, 1/6, 1/2)$ ，且 G_2 只错分第 1 个样本，故

$$e_2 = D_2(1) = \frac{1}{6}.$$

系数计算链为

$$\alpha_2 = \frac{1}{2} \log \frac{1 - e_2}{e_2} = \frac{1}{2} \log \frac{5/6}{1/6} = \frac{1}{2} \log 5.$$

与第一轮比较，

$$\alpha_2 - \alpha_1 = \frac{1}{2} \log \frac{5}{3} > 0 \implies \alpha_2 > \alpha_1.$$

第二个分类器在其对应加权分布下错误率更低，因此获得更大表决权；不能用未加权错误率替代该比较。

读前自检：本章结论与下一步。 提升方法章末由“弱学习器、加法模型、样本权重与伪残差”落到“平方损失拟合残差”；请把前者产出和后者输入逐项对齐，固定核对前者末项的输出类型能否作为后者首项的输入类型。

本章结论与下一步

核心结论：弱学习器、加法模型、样本权重与伪残差

关键依据：指数损失前向分步导出 AdaBoost 系数、权重递推和训练误差乘积界

可执行自检：平方损失拟合残差；一般损失拟合负梯度并用叶内线搜索确定步长

适用边界：需要把多个简单分类器或回归树组合成高表达模型时

下一步：进入 EM 的隐变量迭代；提升模型选择仍须联合验证学习率、轮数与树复杂度

1. **概念与算法**：能否区分样本权重、分类器权重、弱学习器与强学习器，并从 D_m 完整算到 $G_m, e_m, \alpha_m, Z_m, D_{m+1}$ ，同时处理三个边界误差？未通过则回看第 1、2 节。
2. **证明**：能否从指示函数上界和权重连乘证明训练误差界？未通过则回看第 3 节。
3. **推导**：能否从指数损失的前向分步推导 AdaBoost 系数？未通过则回看第 4 节。
4. **树模型**：能否说明平方损失下为何拟合残差，以及一般损失下为何拟合伪残差？未通过则回看第 5、6 节。
5. **实践**：能否给出无测试泄漏的早停、调参与诊断方案？未通过则回看第 7 节。

第20章 EM 算法及其推广

读前自检：本章地图：EM 算法及其推广。 EM 算法及其推广章地图把“从边缘似然直达 Jensen 下界、EM 与高斯混合”作为主线；请为其中首条箭头补出必要条件，并检查终点仍落在本章声明的输出域。

读前自检：本章可检验学习目标。 EM 算法及其推广目标中的“能从不完全数据的边缘似然出发，说明直接极大化的困难，并严格定义完全数据对数似然与 Q 函数”必须可复核；请从不完全数据的边缘似然出发，说明直接极大化的困难，并严格定义完全数据对数似然与 Q 函数，所得结果仅在“中间结果逐项包含首目标“能从不完全数据的边缘似然出发，说明直接极大化的困难，并严格定义完全数据对数似然与 Q 函数”声明的对象、条件与结论”时通过。

读前自检：最短先修。 EM 算法及其推广的最短先修明确要求“本章直接使用离散与连续随机变量的联合、条件和边缘分布”；请把首项“本章直接使用离散与连续随机变量的联合、条件和边缘分布”中的第一个先修对象写成定义域 – 运算 – 输出三元组，并以“该三元组逐项满足首项“本章直接使用离散与连续随机变量的联合、条件和边缘分布”的对象类型与成立条件”判断能否进入本章。

读前自检：先修自检。 EM 算法及其推广先修自检固定核验“能否把 $P(Y | \theta)$ 写成对隐变量 Z 的求和或积分，并说明为何对数不能直接穿过求和”；请把 $P(Y | \theta)$ 写成对隐变量 Z 的求和或积分，并说明为何对数不能直接穿过求和并写出中间结果，再按“ $P(Y | \theta)$ 的计算或证明结果满足首项所列等式、定义域或判断”明确判为通过或失败。

读前自检：依赖路线。 EM 算法及其推广依赖链含“不完全数据与边缘化 $\rightarrow$ 难以直接极大化的对数似然”到“当前参数下的隐变量后验 $\rightarrow$ Jensen 下界与 Q 函数”这一跳；请固定写出前者输出类型与后者输入类型，并核对两者相同或存在正文声明的转换。

本章地图

核心问题：怎样在隐变量不可见时交替完成后验计算与参数极大化

可检验学习目标：

- 能从不完全数据的边缘似然出发，说明直接极大化的困难，并严格定义完全数据对数似然与 Q 函数；
- 能逐步用 Jensen 不等式构造与当前参数相切的下界，推出 E 步、M 步及似然单调不减性质；
- 能为高斯混合模型推导责任度、混合权重、均值和方差更新，并说明退化解、局部最优与初始化敏感性；
- 能解释 F 函数、坐标上升、EM、GEM 与条件极大化之间的关系，写出输入、输出、初始化、更新和停止条件完整的伪代码；
- 能估算主要实现的时间与空间复杂度，判断算法适用范围，并通过例题、练习和自检验证推导是否闭合。

最短先修：本章直接使用离散与连续随机变量的联合、条件和边缘分布，极大似然估计，条件期望，Jensen 不等式，KL 散度，Lagrange 乘子以及高斯分布。还需理解“观测变量”与“模型参数”不是同一类对象：前者来自数据，后者由学习过程估计。高斯混合部分默认已掌握加权均值和加权平方偏差。

依赖路线：不完全数据与边缘化 $\rightarrow$ 难以直接极大化的对数似然；当前参数下的隐变量后验 $\rightarrow$ Jensen 下界与 Q 函数；下界相切 $\rightarrow$ E 步和 M 步 $\rightarrow$ 似然单调不减；混合成分指示变量 $\rightarrow$ 责任度 $\rightarrow$ 高斯混合参数更新；变分分布与熵 $\rightarrow F$ 函数坐标上升 $\rightarrow$ EM、GEM 与条件极大化。

完成标准与返回：支撑或后验无定义时返回节 20.1、20.2；混合更新失败时回看节 20.5

读前自检：模型认识卡：EM 算法。 EM 算法及其推广中的 EM 算法依赖“任务与输入：含隐变量的概率模型，观测 Y 、隐变量 Z 与初值 $\theta^{(0)}$ ”；请据此把 $P(Z | Y, \theta^{(t)})$ 展开一次并检查其类型或边界，并直接核对展开后的量满足定义中的域、维数或符号限制。

模型认识卡：EM 算法

任务与输入：含隐变量的概率模型，观测 Y 、隐变量 Z 与初值 $\theta^{(0)}$ 。**输出类型：**参数估计、后验充分统计量与似然轨迹。

模型： $P(Y, Z | \theta)$ ，观测似然由对 Z 边缘化得到。**策略：**交替提高与观测似然相切的 Jensen 下界。**算法：**E 步求 $P(Z | Y, \theta^{(t)})$ ，M 步提高同一 Q 函数。

预测：由具体隐变量模型定义。**关键假设与边界：**E 步可算、M 步可行且支撑稳定；单调性不保证参数唯一或全局最优。

本章符号表

符号	取值或维数	含义
$Y = (y_1, \dots, y_N)$	观测空间	已观测数据；连续情形把对 Z 的和改为积分
Z	隐变量空间	未直接观测的完整数据分量
$\theta, \theta^{(t)}$	参数空间 Θ	模型参数及第 t 次迭代值
$\ell(\theta)$	$\mathbb{R} \cup \{-\infty\}$	观测数据对数似然 $\log P(Y \theta)$
$q_t(z)$	概率分布	当前后验 $P(z Y, \theta^{(t)})$
$Q(\theta, \theta^{(t)})$	$\mathbb{R} \cup \{-\infty\}$	q_t 下完全数据对数似然的期望
α_k	$[0, 1]$ 且和为 1	第 k 个混合成分的权重
μ_k, σ_k^2	$\mathbb{R}, (0, \infty)$	一维高斯成分的均值和方差
γ_{jk}	$[0, 1]$ 且对 k 求和为 1	样本 j 属于成分 k 的后验责任度
$F(q, \theta)$	$\mathbb{R} \cup \{-\infty\}$	期望完全数据对数似然与熵之和

20.1 隐变量、不完全数据与边缘似然

许多模型容易描述“若隐含选择已经知道，数据怎样生成”，却难以从观测数据直接求参数。例如混合模型中不知道每个样本来自哪个成分，含缺失值的数据中不知道未记录分量，序列模型中不知道隐藏状态路径。把这些未观测量统一记为 Z ，则参数学习面对的是对所有可能 Z 求和或积分后的边缘似然。

读前自检：EM 算法及其推广。 EM 算法及其推广以“它交替完成两件事：在当前参数下计算隐变量的条件分布，再在该条件分布给出的“软完整数据”上更新参数”为约束；请把“它交替完成两件事：在当前参数下计算隐变量的条件分布，再在该条件分布给出的“软完整数据”上更新参数”中的已声明对象代回 EM 算法及其推广的定义，并确认推广方法可以不把每个子问题精确求到最大，只要保持适当的上升性质。

EM 是一类处理含隐变量概率模型的迭代方法。它交替完成两件事：在当前参数下计算隐变量的条件分布，再在该条件分布给出的“软完整数据”上更新参数。推广方法可以不把每个子问题精确求到最大，只要保持适当的上升性质。

读前自检：EM 算法的引入。 先锁定 EM 算法的引入的条件“若 Z 离散”：把 $P(Y | \theta)$ 展开一次并检查其类型或边界，所得结果应满足展开后的量满足定义中的域、维数或符号限制。

若 Z 离散，观测似然与对数似然为

$$P(Y | \theta) = \sum_z P(Y, z | \theta), \quad \ell(\theta) = \log \sum_z P(Y, z | \theta).$$

连续隐变量时把求和换为积分。困难来自“对数包着求和”：即使固定 z 时 $\log P(Y, z | \theta)$ 容易优化， $\log \sum_z P(Y, z | \theta)$ 通常也不能分解。

定义 20.1 (不完全数据与完全数据). 观测到的 Y 称为不完全数据；若同时知道隐变量 Z ，则 (Y, Z) 称为完全数据。完全数据似然为 $P(Y, Z | \theta)$ ，观测数据似然由对 Z 边缘化得到。隐变量不是待优化的固定参数；它在模型中是随机变量，其不确定性必须由条件分布表达。

模型。 EM 要求能够计算当前后验 $q_t(z) = P(z | Y, \theta^{(t)})$ ，并能处理加权的完全数据对数似然。它不限定 Y, Z 必须离散，也不限定参数必须有闭式更新；但若 E 步后验不可计算，或 M 步连可靠的上升方向也难获得，就需要近似推断或其他优化方法。

学习策略。 目标仍是极大化 $\ell(\theta)$ ，不是最大化隐变量后验本身。E 步固定参数、更新关于 Z 的分布；M 步固定该分布、更新参数。两步分别简化了边缘化和参数优化，却共同服务于同一个观测似然目标。

读前自检：EM 算法。 对 EM 算法及其推广中的 EM 算法，条件“若 $q(z) > 0$ 而 $P(Y, z | \theta) = 0$ ，对应对数项为 $-\infty$ ”不可省；请把 $\ell(\theta)$ 展开一次并检查其类型或边界，再用在这些扩展实数约定下，再由凹函数 $\log$ 应用 Jensen 不等式作检查。

20.2 Jensen 不等式与下界构造

令 $S_q = \{z : q(z) > 0\}$ 。对任意 q ，先有

$$\ell(\theta) = \log \sum_z P(Y, z | \theta) \geq \log \sum_{z \in S_q} q(z) \frac{P(Y, z | \theta)}{q(z)}.$$

第一步在 $q(z) = 0$ 而 $P(Y, z | \theta) > 0$ 时一般是严格不等式；只有 $P(Y, \cdot | \theta)$ 的正支撑包含于 S_q 时才能把它写成等号。若 $q(z) > 0$ 而 $P(Y, z | \theta) = 0$ ，对应数项为 $-\infty$ 。在这些扩展实数约定下，再由凹函数 $\log$ 应用 Jensen 不等式。

读前自检：Q 函数。 EM 算法及其推广中的 Q 函数把问题限定在“给定当前参数 $\theta^{(t)}$ ，令 $q_t(z) = P(z | Y, \theta^{(t)})$ ”；请把 $Q(\theta, \theta^{(t)})$ 展开一次并检查其类型或边界，检查是否得到展开后的量满足定义中的域、维数或符号限制。

读前自检：Q 函数。 EM 算法及其推广中的 Q 函数输入“观测 Y 、联合模型 $P(Y, Z | \theta)$ 、可行域 Θ 、合法初值、容差与轮数预算”，条件“ Y 与模型接口合法”；请做一轮“ q, θ^+, ℓ^+ 有限、可行且单调门禁通过后才原子提交参数和一轮轨迹”，以“似然与参数双容差满足、轮数预算耗尽或首次失败时停止”核对停止证书。

定义 20.2 (Q 函数). 给定当前参数 $\theta^{(t)}$ ，令 $q_t(z) = P(z | Y, \theta^{(t)})$ 。完全数据对数似然关于 q_t 的条件期望称为 Q 函数：

$$Q(\theta, \theta^{(t)}) = \mathbb{E}_{q_t}[\log P(Y, Z | \theta)] = \sum_z q_t(z) \log P(Y, z | \theta).$$

连续 Z 时相应改用积分，并要求期望存在。

读前自检：EM 算法的导出。 EM 下界在当前后验 q_t 的支持 S_t 上计算；请在边缘似然求和中乘除 $q_t(z)$ 并应用 Jensen，得到 $F(q_t, \theta) \leq \ell(\theta)$ ，再代入 $\theta^{(t)}$ 核对下界在当前参数处取等。

阅读目标： 通过当前后验构造与边缘对数似然相切的 Jensen 下界。

对象： 边缘似然 $\ell(\theta) = \log \sum_z p(y, z | \theta)$ 与当前后验 $q_t(z)$ 。

合法条件： 只在 $q_t(z) > 0$ 的支持上计算比值；候选参数不得在该支持上把联合概率置零。

第一步： 先在求和中乘除 $q_t(z)$ ，把对数写成 $\log \sum_z q_t(z) p(y, z | \theta) / q_t(z)$ 。

推导目标

从边缘似然出发，分三步构造在当前参数处相切的下界，并证明极大化该下界等价于极大化 $Q(\theta, \theta^{(t)})$ 。

推导准备

记 $S_t = \{z : q_t(z) > 0\}$ ；只在 S_t 上计算比值，约定 $0 \log 0 = 0$ 。若候选参数在 S_t 上令联合概率为零，则下界为 $-\infty$ ；候选参数在 S_t 外新增正质量不破坏下界，但第一步不再是恒等式。定义熵 $H(q) = -\sum_z q(z) \log q(z)$ 。

推导第 1 步：插入当前后验。

$$\ell(\theta) \geq \log \sum_{z \in S_t} q_t(z) \frac{P(Y, z | \theta)}{q_t(z)}.$$

推导第2步：应用 Jensen 不等式。

$$\ell(\theta) \geq \sum_{z \in S_t} q_t(z) \log \frac{P(Y, z | \theta)}{q_t(z)} = Q(\theta, \theta^{(t)}) + H(q_t) \equiv B(\theta, \theta^{(t)}).$$

推导第3步：验证相切并极大化。当 $\theta = \theta^{(t)}$ 时， $P(Y, z | \theta^{(t)})/q_t(z) = P(Y | \theta^{(t)})$ 与 z 无关，Jensen 取等号。因此

$$\ell(\theta^{(t)}) = B(\theta^{(t)}, \theta^{(t)}), \quad \arg \max_{\theta} B(\theta, \theta^{(t)}) = \arg \max_{\theta} Q(\theta, \theta^{(t)}),$$

因为熵 $H(q_t)$ 对待优化的 θ 是常数。

定理 20.1 (EM 下界的 KL 分解) 若 $P(Y | \theta) > 0$ 且 $q \ll P(Z | Y, \theta)$ ，则在相关量有限时

$$\ell(\theta) = F(q, \theta) + D_{\text{KL}}(q(Z) \| P(Z | Y, \theta)), \quad F(q, \theta) = \mathbb{E}_q \log P(Y, Z | \theta) + H(q).$$

故 $F(q, \theta) \leq \ell(\theta)$ ；等号成立当且仅当 $q(Z) = P(Z | Y, \theta)$ 几乎处处成立。

读前自检：证明：EM 下界的 KL 分解。 围绕 EM 下界的 KL 分解，先采用条件“KL 散度为零当且仅当两个分布几乎处处相同”，再对 $P(Y, Z | \theta)$ 做一次条件化或边缘化；最后验证给出等号条件。

证明。 由 Bayes 公式 $P(Y, Z | \theta) = P(Z | Y, \theta)P(Y | \theta)$ ，有

$$\begin{aligned} D_{\text{KL}}(q \| P_{\theta}) &= \sum_z q(z) \log \frac{q(z)}{P(z | Y, \theta)} \\ &= \sum_z q(z) \log q(z) - \sum_z q(z) \log P(Y, z | \theta) + \ell(\theta) \\ &= \ell(\theta) - F(q, \theta). \end{aligned}$$

移项即得分解。KL 散度非负，所以 F 是下界；KL 散度为零当且仅当两个分布几乎处处相同，因此给出等号条件。□

几何理解

几何解释。在参数轴上， $B(\theta, \theta^{(t)})$ 是一条不超过 $\ell(\theta)$ 、并在当前点与其相接的代理曲线。M 步把参数移动到代理曲线更高的位置；新点处再由 E 步换一条相切下界。路径依赖初值，因而不同初值可能进入不同峰或鞍点邻域。

概率解释

E 步不是“猜一个缺失值”，而是计算所有隐状态的条件概率；Q 函数用这些概率对完全数据对数似然加权。后验越集中，软计数越接近硬计数；后验越分散，一个样本对多个隐状态同时贡献信息。

优化解释

优化解释。EM 可视为在 q 与 θ 两个坐标块上对 $F(q, \theta)$ 做坐标上升。E 步令 KL 项为零，M 步提高期望完全数据对数似然。该解释说明“每步上升”不等于“达到全局最大值”，也说明 GEM 只需提高而不必完全最大化 Q 。




图 20.1 可复算的相切下界: $B(\theta, 2) = \ell(\theta) - 0.16(\theta - 2)^2 \leq \ell(\theta)$, 并在 $\theta = 2$ 处函数值与导数同时相等。两条曲线按图中给定的显式函数精确绘制, 而非未标比例的定性示意。

图 20.1 只需抓住五个对象: 似然、当前相切下界、旧点、新点和上升箭头。E 步建立相切, M 步抬高该下界; 单调性链条的代数证明见定理 20.2。

20.3 E 步与 M 步

引入复现。边缘似然仍是原始目标; 本节只把上一节的后验下界转成可执行的两步迭代。**EM 复现。**E 步更新 q_t , M 步更新 θ , 两步优化的变量不同。**Q 函数复现。** Q 的第二个参数决定取期望所用的后验, 第一个参数才是 M 步中的待优化参数。

读前自检: EM 算法。EM 算法及其推广中的 EM 算法输入“观测 Y 、联合模型 $P(Y, Z | \theta)$ 、可行域 Θ 、合法初值、容差与轮数预算”, 条件“ Y 与模型接口合法”; 请做一轮“ q, θ^+, ℓ^+ 有限、可行且单调门禁通过后才原子提交参数和一轮轨迹”, 以“似然与参数双容差满足、轮数预算耗尽或首次失败时停止”核对停止证书。

学习算法。第 $t+1$ 轮先以 $\theta^{(t)}$ 计算 q_t 与 $Q(\theta, \theta^{(t)})$, 再求

$$\theta^{(t+1)} \in \arg \max_{\theta \in \Theta} Q(\theta, \theta^{(t)}).$$

若有多个最大点, 必须采用预先固定的选择规则; 否则同一输入可能产生不同轨迹。

EM 算法：五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 20.1: EM 算法

输入: 观测 Y ; 联合模型 $P(Y, Z | \theta)$; 可行域 Θ ; 初值 $\theta^{(0)}$
输出: 最后合法 $\theta, \ell, t_{\text{done}}$ 、status、目标轨迹与最终诊断
数据: $T_{\max} \in \mathbb{N}_0$; $\varepsilon_\ell, \varepsilon_\theta > 0$; 单调数值容差 $\tau_{\text{num}} \geq 0$; 固定 M 步并行规则

- 1 $\theta \leftarrow \theta^{(0)}$, $t_{\text{done}} \leftarrow 0$, 诊断与目标轨迹初始化为空
- 2 若数据/模型接口非法、 Θ 为空、初值不可行或非有限, 或预算、容差、 M 步选择规则不合法, 则返回当前初值、计数 0、invalid_input 及字段诊断
- 3 计算 $\ell \leftarrow \log P(Y | \theta)$; 若非有限则返回最后合法初值、numerical_failure 及初始化似然阶段诊断
- 4 **当** $t_{\text{done}} < T_{\max}$ **执行**
- 5 保存 $\theta_{\text{old}} \leftarrow \theta, \ell_{\text{old}} \leftarrow \ell$; 在临时状态计算 $q = P(Z | Y, \theta_{\text{old}})$ 及 $Q(\cdot, \theta_{\text{old}})$
- 6 若后验归一化常数非有限或非正、 q 非负/归一化核验失败, 或 Q 含非有限值, 则返回最后合法 $\theta_{\text{old}}, \ell_{\text{old}}, t_{\text{done}}, \text{numerical_failure}$, 诊断为 E 步及失败轮
- 7 按固定规则求 $\theta^+ \in \arg \max_{\theta \in \Theta} Q(\theta, \theta_{\text{old}})$; 若最大值集合为空、候选不可行或非有限, 则返回最后合法状态与 numerical_failure, 诊断为 M 步及失败轮
- 8 计算 $\ell^+ \leftarrow \log P(Y | \theta^+)$; 若非有限或 $\ell^+ < \ell_{\text{old}} - \tau_{\text{num}}$, 则返回未改动的最后合法状态与 numerical_failure, 诊断为似然门禁及新旧值
- 9 计算 $q_\ell \leftarrow |\ell^+ - \ell_{\text{old}}| / (1 + |\ell_{\text{old}}|)$ 与 $q_\theta \leftarrow \|\theta^+ - \theta_{\text{old}}\| / (1 + \|\theta_{\text{old}}\|)$
- 10 原子提交 $\theta \leftarrow \theta^+, \ell \leftarrow \ell^+$ 及轨迹, 令 $t_{\text{done}} \leftarrow t_{\text{done}} + 1$
- 11 **若** $q_\ell \leq \varepsilon_\ell$ **且** $q_\theta \leq \varepsilon_\theta$ **则**
- 12 返回最后合法 $\theta, \ell, t_{\text{done}}, \text{numerical_failure}$, 最终诊断记录双容差、末轮目标增量及可用的固定点/KKT 残差
- 13 **结束**
- 14 **结束**
- 15 返回最后合法 $\theta, \ell, t_{\text{done}}, \text{budget_stop}$, 最终诊断记录轮数预算耗尽、末轮目标与参数变化

算法实现说明: 似然与参数双小变化只是数值停止, 返回 numerical_failure; 只有另行核验 EM 固定点或相应 KKT 残差时, 才可在研究性报告中升级为数学收敛证书。完整 C1-C14 契约

参数含义。 ε_ℓ 控制目标值相对变化, ε_θ 控制参数变化, $T_{\max}$ 防止无限运行。两种容差同时使用可避免“似然平台上参数仍漂移”或“参数尺度很大时绝对容差失真”, 但双容差仅产生 numerical_failure, 不自动证明到达驻点或最优点。

初始化方法。 初值必须满足概率归一化、方差为正等约束。非凸问题应从多个可复现初值运行, 并只用训练目标及独立验证准则选择; 不能看到测试结果后再挑初值。混合模型应避免所有成分完全相同, 否则对称性可能使迭代停在无区分状态。

参数更新规则。 E 步的后验必须使用同一轮旧参数 $\theta^{(t)}$; M 步的所有闭式更新应由同一批后验充分统计量得到。若在一轮中边算责任度边改参数, 就改变了所极大化的 Q 函数, 单调性证明不再直接适用。

停止条件。相对似然变化和相对参数变化同时足够小可作为数值停止规则；最大轮数是保护条件，不是收敛证据。还应记录每轮目标值、最小方差、有效样本数等诊断量，发现非有限数、空成分或似然异常下降时立即报告。

收敛条件。精确 E 步与精确 M 步保证观测似然不下降。在似然有上界、映射具有适当闭性与连续性等条件下，似然值序列收敛；参数序列未必唯一收敛，更不保证到达全局最大值。参数不可识别时，不同参数还可能表示同一分布。

读前自检：EM 算法似然函数序列的单调性。 EM 似然序列令 $q_t = P(Z | Y, \theta^{(t)})$ ；请串联 $\ell(\theta^{(t+1)}) \geq F(q_t, \theta^{(t+1)}) \geq F(q_t, \theta^{(t)}) = \ell(\theta^{(t)})$ ，逐步标出 KL 非负、Q 不降和当前后验三个依据，并核对 $\ell(\theta^{(t+1)}) \geq \ell(\theta^{(t)})$ 。

20.4 单调性与收敛性质

定理 20.2 (EM 的似然单调性) 若 E 步计算精确后验，M 步选取的 $\theta^{(t+1)}$ 满足 $Q(\theta^{(t+1)}, \theta^{(t)}) \geq Q(\theta^{(t)}, \theta^{(t)})$ ，且相关支撑条件成立，则

$$\ell(\theta^{(t+1)}) \geq \ell(\theta^{(t)}).$$

读前自检：证明：EM 的似然单调性。 EM 似然单调性固定当前后验 q_t ；请先用 KL 非负把 $F(q_t, \theta^{(t+1)})$ 压在新似然下，再用 M 步的 Q 不降比较两个 F 值，核对终点等于 $\ell(\theta^{(t)})$ 。

证明。 记 $q_t = P(Z | Y, \theta^{(t)})$ 。由定理 20.1,

$$\ell(\theta^{(t+1)}) \geq F(q_t, \theta^{(t+1)}) \geq F(q_t, \theta^{(t)}) = \ell(\theta^{(t)}).$$

第一步来自 KL 散度非负，第二步来自 $H(q_t)$ 固定且 Q 不下降，最后一步来自 q_t 恰为当前后验。三个关系串联即得结论。□

读前自检：EM 算法的收敛性。 从 EM 算法的收敛性的条件“若 $\ell(\theta)$ 有有限上界”出发，请把 $\ell(\theta^{(t)})$ 展开一次并检查其类型或边界；所得量应符合单调序列 $\ell(\theta^{(t)})$ 必收敛。

单调性控制的是目标值，不自动控制参数。若 $\ell(\theta)$ 有有限上界，则单调序列 $\ell(\theta^{(t)})$ 必收敛；但参数可能在等价表示之间移动，或在平坦区域中形成多个聚点。要推出参数聚点为驻点，还需参数位于可行域内部、目标和更新映射足够光滑、M 步满足相应一阶条件等额外假设。

读前自检：EM 对数似然值与参数估计序列的收敛性。 EM 对数似然值与参数估计序列的收敛性依赖“若观测似然值有上界”；请据此把观测对应因子代入 EM 对数似然值与参数估计序列的收敛性并合并一次，并直接核对“参数收敛”“收敛到局部极大”“收敛到全局极大”是更强的三种说法，必须分别验证，不能由第一层直接推出。

定理 20.3 (EM 收敛结论的边界) 若观测似然值有上界, 则精确 EM 产生的似然值序列收敛。若进一步假定迭代序列有聚点、模型在聚点邻域可微、支撑不突变且更新映射满足标准正则性, 则每个内部聚点是观测似然的驻点; 该结论不声称聚点是全局最大点。

单调但有界的数列收敛是第一层结论; “参数收敛” “收敛到局部极大” “收敛到全局极大” 是更强的三种说法, 必须分别验证, 不能由第一层直接推出。

读前自检: 高斯混合模型。 高斯混合密度 $p(y | \theta) = \sum_{k=1}^K \alpha_k \phi(y | \mu_k, \sigma_k^2)$ 要求 $\alpha_k \geq 0$ 且 $\sum_k \alpha_k = 1$; 请对 y 积分, 核对各成分归一时混合密度也积分为 1。

读前自检: 高斯混合模型。 高斯混合模型的第 k 个成分采用方差 $\sigma_k^2 > 0$ 的高斯密度; 请把 $\phi(y | \mu_k, \sigma_k^2)$ 代入混合和, 核对 $\sigma_k^2 = 0$ 会使密度公式失去定义。

20.5 高斯混合模型

读前自检: 一维高斯混合模型。 设 $\alpha_k \geq 0$ 、 $\sum_k \alpha_k = 1$ 且 $\sigma_k^2 > 0$ 。请核对各高斯成分是密度, 从而混合式非负且积分为 1。

定义 20.3 (一维高斯混合模型). 含 K 个成分的高斯混合密度为

$$p(y | \theta) = \sum_{k=1}^K \alpha_k \phi(y | \mu_k, \sigma_k^2), \quad \alpha_k \geq 0, \quad \sum_{k=1}^K \alpha_k = 1, \quad \sigma_k^2 > 0,$$

其中

$$\phi(y | \mu_k, \sigma_k^2) = \frac{1}{\sqrt{2\pi\sigma_k^2}} \exp\left[-\frac{(y - \mu_k)^2}{2\sigma_k^2}\right].$$

读前自检: EM 算法在高斯混合模型学习中的应用。 EM 算法在高斯混合模型学习中的应用把问题限定在 “从高斯混合完全数据对数似然推导责任度、混合权重、均值和方差的 EM 更新, 并核对归一化与正方差条件”; 请把 Θ_σ 展开一次并检查其类型或边界, 检查是否得到展开后的量满足定义中的域、维数或符号限制。

阅读目标: 把后验责任度转成各成分的期望充分统计量。

对象: 样本 y_j 、独热隐变量 z_{jk} 、责任度 γ_{jk} 及参数 $(\alpha_k, \mu_k, \sigma_k^2)$ 。

合法条件: 旧参数合法、混合密度为正; M 步在 $\sigma_k^2 \geq \sigma_{\min}^2 > 0$ 的受约束空间内进行。

第一步: 先用 Bayes 公式计算 $\gamma_{jk} = P(z_{jk} = 1 | y_j, \theta^{(t)})$ 。

推导目标

从高斯混合完全数据对数似然推导责任度、混合权重、均值和方差的 EM 更新, 并核对归一化与正方差条件。

推导准备

样本 $y_1, \dots, y_N$ 独立; z_{jk} 为独热隐变量; 旧参数合法且每个样本的混合密度为正。为避免方差塌缩, 本节算法从建模开始就采用受约束参数空间

$$\Theta_{\sigma} = \left\{ \theta : \alpha_k \geq 0, \sum_k \alpha_k = 1, \sigma_k^2 \geq \sigma_{\min}^2 > 0 \right\}.$$

E 步固定旧参数, M 步把 $\gamma_{jk} = \mathbb{E}(z_{jk} | y_j)$ 视作常数, 并在 Θ_{σ} 内最大化 Q ; 这不是在无约束 MLE 之后临时裁剪。

为样本 y_j 引入独热隐变量 $z_{jk} \in \{0, 1\}$, 且 $\sum_k z_{jk} = 1$ 。完全数据对数似然为

$$\log P(Y, Z | \theta) = \sum_{j=1}^N \sum_{k=1}^K z_{jk} \left[\log \alpha_k - \frac{1}{2} \log(2\pi\sigma_k^2) - \frac{(y_j - \mu_k)^2}{2\sigma_k^2} \right].$$

读前自检: 高斯混合模型参数估计的 EM 算法。 在“推导第 1 步: 条件化独热变量”成立时处理高斯混合模型参数估计的 EM 算法: 请把 $(\sigma_k^2)^{(t+1)}$ 展开一次并检查其类型或边界, 并以展开后的量满足定义中的域、维数或符号限制判定结果。

推导第 1 步: 条件化独热变量。 E 步计算责任度

$$\gamma_{jk} = P(z_{jk} = 1 | y_j, \theta^{(t)}) = \frac{\alpha_k^{(t)} \phi(y_j | \mu_k^{(t)}, (\sigma_k^2)^{(t)})}{\sum_{r=1}^K \alpha_r^{(t)} \phi(y_j | \mu_r^{(t)}, (\sigma_r^2)^{(t)})}.$$

推导第 2 步: 更新混合权重。 记 $n_k = \sum_j \gamma_{jk}$ 。对 $\sum_{j,k} \gamma_{jk} \log \alpha_k$ 加入乘子 $\eta(\sum_k \alpha_k - 1)$, 驻点给出 $\alpha_k = -n_k/\eta$; 求和并用 $\sum_k n_k = N$ 得到 $\eta = -N$, 故 $\alpha_k = n_k/N$ 。

推导第 3 步: 更新均值和受约束方差。 固定 σ_k^2 对 μ_k 求导, 得到 $\sum_j \gamma_{jk}(y_j - \mu_k) = 0$ 。令新均值下的加权平方残差为 $S_k = \sum_j \gamma_{jk}(y_j - \mu_k^{(t+1)})^2$, 方差块目标为

$$Q_k(s) = -\frac{n_k}{2} \log s - \frac{S_k}{2s} + \text{const}, \quad s \geq \sigma_{\min}^2.$$

其导数为 $(S_k - n_k s)/(2s^2)$, 故无约束极大点是 S_k/n_k , 受约束极大点是二者与边界的较大者。所以 M 步为

$$\begin{aligned} \alpha_k^{(t+1)} &= \frac{n_k}{N}, \quad \mu_k^{(t+1)} = \frac{\sum_j \gamma_{jk} y_j}{n_k}, \\ (\sigma_k^2)^{(t+1)} &= \max \left\{ \sigma_{\min}^2, \frac{\sum_j \gamma_{jk} (y_j - \mu_k^{(t+1)})^2}{n_k} \right\}. \end{aligned}$$

方差更新必须使用新均值, 因为它是当前加权平方误差的唯一极小点; $\max$ 来自 Θ_{σ} 内的精确 M 步, 因而保持同一受约束模型的 EM 单调性。若在无约束 MLE 后另行裁剪, 则不能援引这条证明。若 $n_k = 0$, 三个更新均无定义, 必须按预登记空成分规则处理。

读前自检：高斯混合模型参数估计的 EM 算法。 高斯混合 EM 以样本、成分数 K 和合法初值 $(\alpha_k, \mu_k, \sigma_k^2)$ 为输入，其中 $\alpha_k \geq 0$ 、 $\sum_k \alpha_k = 1$ 且 $\sigma_k^2 > 0$ ；请完成一次责任度与参数更新，核对新权重归一、方差为正，并按似然增量容差判停。

读前自检：受约束高斯混合模型的多启动 EM：执行契约。 高斯混合模型 EM 从归一化混合权重和正方差初值出发；请先计算一轮 γ_{ik} ，再用责任度加权均值、方差和成分质量更新参数，核对 $\sum_k \gamma_{ik} = 1$ 及观测对数似然不降。

受约束高斯混合模型的多启动 EM：五步阅读

输入。 写出数据对象、固定参数与必须成立的条件。

初始化。 标明主状态、计数器和第一个合法状态。

核心更新。 只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。 写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。 列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 20.2：受约束高斯混合模型的多启动 EM

输入： 训练样本 $y_1, \dots, y_N$ ；成分数 K ；启动数 R ；预先固定的种子表 $(s_1, \dots, s_R)$

输出： 各启动最后合法状态与选中 $\hat{\theta}$ ； $r_{\text{done}}, t_{\text{done}}, e_{\text{done}}$ ；status 与诊断

数据： $\sigma_{\min}^2$ 、似然/责任度双容差、数值容差 τ_{num} 、轮预算 $T_{\max}$ 与冻结空成分规则

- 1 若数据、维数、下界、容差、预算、种子表或空成分规则非法，返回空记录、计数 0、invalid_input 及字段诊断
- 2 清空启动记录并置 $r_{\text{done}} = t_{\text{done}} = e_{\text{done}} = 0$
- 3 对 $r \leftarrow 1$ 至 R 执行
 - 4 仅由训练数据和 s_r 生成初值；若随机源调用失败，原子记录该启动 random_source_failure 及位置，增加 r_{done} 并进入下一启动
 - 5 核验 $\theta_r^{(0)} \in \Theta_\sigma$ 并计算 $\ell_r^{(0)}$ ；若失败，原子记录 numerical_failure 及初始化诊断，增加 r_{done} 并进入下一启动
 - 6 置该启动最后合法 $(\hat{\theta}_r, \hat{\ell}_r) \leftarrow (\theta_r^{(0)}, \ell_r^{(0)})$ 且启动状态为 budget_stop
 - 7 对本启动轮 $t \leftarrow 0$ 至 $T_{\max} - 1$ 执行
 - 8 以 $\hat{\theta}_r$ 在临时表稳定形成全部 γ_{jk}^+ ；每个有限归一行增加 e_{done}
 - 9 若 E 步任一行失败，则记录 numerical_failure 与 (r, t, j) ，保留上一合法状态并退出当前启动
 - 10 形成临时 n_k^+ ；若触发空成分，则只执行预登记修复，随机源失败记 random_source_failure，无合法修复记 numerical_failure，并退出当前启动
 - 11 在同一 Θ_σ 内形成精确 M 步候选 θ_r^+ 及 ℓ_r^+
 - 12 若候选非有限、不归一或 $\ell_r^+ < \hat{\ell}_r - \tau_{\text{num}}$ ，记录 numerical_failure 并退出当前启动
 - 13 计算 Δ_γ ；原子提交 $(\hat{\theta}_r, \hat{\ell}_r) \leftarrow (\theta_r^+, \ell_r^+)$ 并增加 t_{done}
 - 14 若似然与责任度双阈值满足，设置启动状态 numerical_failure 并记录责任度/参数变化，然后退出当前启动
 - 15 结束
 - 16 原子保存该启动的最后合法参数、实际轮数、状态与诊断，并增加 r_{done}
 - 17 结束
 - 18 在状态为 numerical_failure 或 budget_stop 的合法启动中按冻结口径选择；测试集不得参与
 - 19 若没有合法启动，则按全部失败类型返回 random_source_failure 或 numerical_failure 及全失败诊断
 - 20 返回选中启动、其规范状态、全部记录、实际计数及选择分母 R 最终诊断

算法实现说明：多启动中的似然/责任度平台统一记为 `numerical_failure`；标签置换匹配只让诊断可比，不构成最优性证书。选择只在合法启动间进行并保留各自原始状态。完整 C1-C14 契约

停止量与标签置换。观测似然和责任度变化不依赖成分标签的命名，故作为主停止量。若还报告参数差，必须先在 $K!$ 个置换（或等价的指派算法）中匹配新旧成分，再计算

$$\Delta_{\theta} = \min_{\pi \in \mathfrak{S}_K} \frac{\|\theta_{\text{new}} - \pi(\theta_{\text{old}})\|}{1 + \|\theta_{\text{old}}\|}.$$

未经成分匹配的参数差只能作诊断，不能单独决定停止；单纯达到轮数上限也不是收敛证书。

例题 20.1 (责任度加权的高斯混合 M 步). 两个样本为 $y_1 = 0, y_2 = 10$ ，某轮两个成分对它们的责任度分别为 $(0.9, 0.1)$ 与 $(0.2, 0.8)$ 。求 M 步的新权重和均值。

例题 20.1 解答

读题翻译 两行责任度分别对应样本 y_1, y_2 ，两列对应两个高斯成分； M 步要把每列责任度当作该成分的软计数，更新混合权重和均值。

已知与合法条件 $y_1 = 0, y_2 = 10$ ，责任度矩阵的两行为 $(0.9, 0.1)$ 与 $(0.2, 0.8)$ ，每行和为 1；样本数 $N = 2$ ，两个成分的有效样本数均为正。

为什么想到这个方法 高斯混合 M 步用充分统计量 $N_k = \sum_i \gamma_{ik}$ ，再取 $\alpha'_k = N_k/N$ 与 $\mu'_k = \sum_i \gamma_{ik} y_i / N_k$ 。

方法选择 先按列求 N_1, N_2 ，再分别更新两项权重和两项责任度加权均值；最后核对软计数和、权重归一化与加权一阶矩。

推导/计算 有效样本数 $N_1 = 0.9 + 0.2 = 1.1$ 、 $N_2 = 0.1 + 0.8 = 0.9$ ，所以

$$\alpha'_1 = \frac{1.1}{2} = \frac{11}{20}, \quad \alpha'_2 = \frac{0.9}{2} = \frac{9}{20},$$

$$\mu'_1 = \frac{0.9 \cdot 0 + 0.2 \cdot 10}{1.1} = \frac{20}{11}, \quad \mu'_2 = \frac{0.1 \cdot 0 + 0.8 \cdot 10}{0.9} = \frac{80}{9}.$$

独立核验 $N_1 + N_2 = 2$ 且 $\alpha'_1 + \alpha'_2 = 1$ ；两个均值都位于样本凸包 $[0, 10]$ 内。代回一阶矩得 $1.1(20/11) = 2$ 、 $0.9(80/9) = 8$ ，与两列责任度加权数据和一致。

结论 新权重为 $(\alpha'_1, \alpha'_2) = (11/20, 9/20)$ ，新均值为 $(\mu'_1, \mu'_2) = (20/11, 80/9)$ 。

读前自检：F 函数。 EM 算法及其推广中的 F 函数中的“对隐变量上的任意分布 q ”决定可执行范围；请把 $F(q, \theta)$ 展开一次并检查其类型或边界，结果须满足展开后的量满足定义中的域、维数或符号限制。

20.6 EM 算法推广与 GEM

定义 20.4 (F 函数). 对隐变量上的任意分布 q ，定义

$$F(q, \theta) = \mathbb{E}_q[\log P(Y, Z \mid \theta)] + H(q), \quad H(q) = -\mathbb{E}_q \log q(Z).$$

它同时依赖变分分布 q 和模型参数 θ 。

读前自检：固定参数时 F 函数极大化的唯一分布。 把固定参数时 F 函数极大化的唯一分布放在“固定 θ 并假定后验在相关支撑上确定”下考察：把 $q(Z) = P(Z | Y, \theta)$ 在其支持上求和或积分一次，并检查 $F(q, \theta)$ 关于 q 的唯一最大点是 $q(Z) = P(Z | Y, \theta)$ 。

读前自检：固定参数的 F 极大化。 固定参数的 F 极大化要求先确认“固定 θ 并假定后验在相关支撑上确定”；请随后检查 $q(Z) = P(Z | Y, \theta)$ 中每项的类型后完成等式变形，用 $F(q, \theta)$ 关于 q 的唯一最大点是 $q(Z) = P(Z | Y, \theta)$ 验收。

引理 20.1 (固定参数的 F 极大化) 固定 θ 并假定后验在相关支撑上确定，则 $F(q, \theta)$ 关于 q 的唯一最大点是 $q(Z) = P(Z | Y, \theta)$ ，最大值为 $\ell(\theta)$ 。

读前自检：证明：固定参数的 F 极大化。 固定参数 θ 时， $F(q, \theta) = \ell(\theta) - D_{\text{KL}}(q \| P_\theta)$ ；请用 KL 非负性比较任意 q 与 $q = P_\theta$ ，核对后者使散度为零并唯一达到最大值 $\ell(\theta)$ 。

证明。 由定理 20.1， $F(q, \theta) = \ell(\theta) - D_{\text{KL}}(q \| P_\theta)$ 。固定 θ 时第一项为常数，KL 散度的唯一零点是 $q = P_\theta$ ，故结论成立。□

读前自检：EM 算法的推广。 EM 算法的推广依赖“在 (q, θ) 两个坐标块上交替极大化 F ：先取 $q_{t+1} = P(Z | Y, \theta^{(t)})$ ”；请据此将 $q_{t+1} = P(Z | Y, \theta^{(t)})$ 左端按定义展开一层，再与右端逐项对齐，并直接核对第二步中熵固定，故等价于极大化 Q 。

读前自检：F 函数的极大-极大算法。 F 函数的极大-极大算法以“在 (q, θ) 两个坐标块上交替极大化 F ：先取 $q_{t+1} = P(Z | Y, \theta^{(t)})$ ”为约束；请独立化简 $q_{t+1} = P(Z | Y, \theta^{(t)})$ 的两端，并确认第二步中熵固定，故等价于极大化 Q 。

在 (q, θ) 两个坐标块上交替极大化 F ：先取 $q_{t+1} = P(Z | Y, \theta^{(t)})$ ，再极大化 $F(q_{t+1}, \theta)$ 。第二步中熵固定，故等价于极大化 Q 。这给出 EM 的“极大-极大”解释。

读前自检：F 函数与观测数据对数似然的等价关系。 先锁定 F 函数与观测数据对数似然的等价关系的条件“若把 q 限制在较小分布族中，只能得到变分下界问题，等价性一般不再成立”：把观测对应因子代入 $F(q_\theta, \theta) = \ell(\theta)$ 。并合并一次，所得结果应满足目标保留参数定义域且无需对参数归一化。

由 KL 分解，对后验 $q_\theta = P(Z | Y, \theta)$ 恒有

$$F(q_\theta, \theta) = \ell(\theta).$$

因此在精确后验族中最大化 F 与最大化观测对数似然等价；若把 q 限制在较小分布族中，只能得到变分下界问题，等价性一般不再成立。

读前自检：F 函数极大值与观测数据对数似然极大值的关系。 对 F 函数极大值与观测数据对数似然极大值的关系，条件“若允许 q 遍历全部合法分布，并把可能的无界情形按扩展实数理解”不可省；请把观测对应因子代入 $\sup_{\theta} \ell(\theta)$ 并合并一次，再用所得目标保留参数定义域且无需对参数归一化作检查。

定理 20.4 (F 函数与似然上确界) 若允许 q 遍历全部合法分布，并把可能的无界情形按扩展实数理解，则

$$\sup_{\theta} \ell(\theta) = \sup_{q, \theta} F(q, \theta).$$

若这个共同上确界有限且由某个联合最大对 (q^*, θ^*) 达到，则 $q^* = P(Z | Y, \theta^*)$ ，且 θ^* 也是观测似然的最大点。

读前自检：证明：F 函数与似然上确界。 F 函数与似然上确界把问题限定在“ $\max_q F(q, \theta) = \ell(\theta)$ ”；请对 $\max_q F(q, \theta) = \ell(\theta)$ 做一次条件化或边缘化，检查是否得到所以 q^* 是后验，并且 $F(q^*, \theta^*) = \ell(\theta^*)$ 达到左侧最大值。

证明。 对每个固定 θ ，引理 20.1 给出 $\max_q F(q, \theta) = \ell(\theta)$ 。再对 θ 取上确界便得到等式；这个论证不要求参数域紧致，也不预设似然最大值存在。若有限共同上确界由 (q^*, θ^*) 达到而 q^* 不是对应后验，则用对应后验替换会严格提高 F ，矛盾；所以 q^* 是后验，并且 $F(q^*, \theta^*) = \ell(\theta^*)$ 达到左侧最大值。□

读前自检：EM 算法的一次迭代可由 F 函数的极大-极大算法实现。 F 函数坐标上升先令 $q = P(Z | Y, \theta^{(t)})$ 完成 E 步，再在固定 q 下最大化 $F(q, \theta)$ 完成 M 步；请核对熵项与 θ 无关，故两次坐标更新与一次 EM 迭代相同。

第一坐标极大化由引理 20.1 给出精确后验，即 E 步；第二坐标极大化中熵与 θ 无关，等价于 M 步。因此两种描述产生相同的参数迭代。

读前自检：GEM 算法。 GEM 不要求精确最大化 M 步，只要求 $Q(\theta^{t+1}, \theta^t) \geq Q(\theta^t, \theta^t)$ ；请比较一个候选的两侧，核对通过该上升门后观测似然不降。

GEM 放宽精确 M 步，只要求选取 $\theta^{(t+1)}$ 使

$$Q(\theta^{(t+1)}, \theta^{(t)}) \geq Q(\theta^{(t)}, \theta^{(t)}).$$

它适合 M 步无闭式解但能用梯度、Newton 或受约束优化器找到上升点的模型。若内部优化使用近似值，必须以实际 Q 值验收，而不能只假设优化器“应该上升”。

基于 F 函数的交替极大化：五步阅读

输入。 写出数据对象、固定参数与必须成立的条件。

初始化。 标明主状态、计数器和第一个合法状态。

核心更新。 只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。 写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 20.3: 基于 F 函数的交替极大化

输入: 观测 Y ; $F(q, \theta)$; 合法分布族 $\mathcal{Q}$ 与参数域 Θ ; 初值 $\theta^{(0)}$

输出: 最后合法 (q, θ) , F , t_{done} , c_{done} , **status**、轨迹与最终诊断

数据: $T_{\text{max}} \in \mathbb{N}_0$; 目标与参数容差; 单调数值容差; 固定坐标并列规则

- 1 $t_{\text{done}} \leftarrow 0$, $c_{\text{done}} \leftarrow 0$, $\theta \leftarrow \theta^{(0)}$, 诊断与轨迹为空
- 2 若 F 接口、 $\mathcal{Q}$, Θ 或初值非法, 或预算、容差、坐标选择规则不合法, 则返回空分布、当前初值、计数 0、**invalid_input** 及字段诊断
- 3 求 $q \in \arg \max_{u \in \mathcal{Q}} F(u, \theta)$ 并令 $c_{\text{done}} \leftarrow c_{\text{done}} + 1$; 若最大值不存在、 q 不归一化或 $F(q, \theta)$ 非有限, 则返回当前初值、**numerical_failure** 及初始化 q 坐标诊断
- 4 令 $F_{\text{old}} \leftarrow F(q, \theta)$ 并把 (q, θ) 作为最后合法对
- 5 当 $t_{\text{done}} < T_{\text{max}}$ **执行**
- 6 在临时状态求 $q^+ \in \arg \max_{u \in \mathcal{Q}} F(u, \theta)$ 并令 $c_{\text{done}} \leftarrow c_{\text{done}} + 1$; 若失败、不可行、非有限或 $F(q^+, \theta) < F_{\text{old}} - \tau_{\text{num}}$, 则返回最后合法对与 **numerical_failure**, 诊断为 q 坐标及失败轮
- 7 再求 $\theta^+ \in \arg \max_{v \in \Theta} F(q^+, v)$ 并令 $c_{\text{done}} \leftarrow c_{\text{done}} + 1$; 若失败、不可行、非有限或 $F(q^+, \theta^+) < F(q^+, \theta) - \tau_{\text{num}}$, 则返回未改动的最后合法对与 **numerical_failure**, 诊断为 θ 坐标及失败轮
- 8 令 $F^+ \leftarrow F(q^+, \theta^+)$, 计算 $q_F \leftarrow |F^+ - F_{\text{old}}| / (1 + |F_{\text{old}}|)$ 与 $q_\theta \leftarrow \|\theta^+ - \theta\| / (1 + \|\theta\|)$
- 9 原子提交 $(q, \theta, F_{\text{old}}) \leftarrow (q^+, \theta^+, F^+)$ 及轨迹, 令 $t_{\text{done}} \leftarrow t_{\text{done}} + 1$
- 10 **若** $q_F \leq \varepsilon_F$ **且** $q_\theta \leq \varepsilon_\theta$ **则**
- 11 返回最后合法 (q, θ) , F_{old} , t_{done} , c_{done} , **numerical_failure**, 最终诊断记录双容差、分段增量与坐标残差
- 12 **结束**
- 13 **结束**
- 14 返回最后合法 (q, θ) , F_{old} , t_{done} , c_{done} , **budget_stop**, 最终诊断记录轮数预算耗尽与末轮增量

算法实现说明: 双坐标目标和参数平台只返回 **numerical_failure**; 每个坐标块均须完成并通过单调门禁后, 才提交一轮。完整 C1–C14 契约

读前自检: Q 函数单调上升的广义 EM。 Q 函数单调上升的广义 EM 输入“观测 Y 、联合模型、参数域 Θ 、合法初值、GEM 内层方向/回缩规则与停止参数”, 条件“模型、E 步和内层方向接口合法”; 请做一轮“候选 θ^+ , $Q_t(\theta^+)$, ℓ^+ 有限、可行且双门禁通过后才原子提交”, 以“目标与参数双容差满足、外层预算耗尽、回缩失败或首次数值失败时停止”核对停止证书。

以 Q 上升为门禁的 GEM: 五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新, 并指出何时提交。

数学停止。写出能直接核验的停止证书; 预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 20.4: 以 Q 上升为门禁的 GEM

输入: 观测 Y ; 联合模型; 参数可行域 Θ ; 初值 $\theta^{(0)}$

输出: 最后合法 $\theta, \ell, t_{\text{done}}, \ell_{\text{done}}, \text{status}$ 、轨迹与最终诊断

数据: $T_{\text{max}}, L_{\text{max}} \in \mathbb{N}_0$; 回缩率 $0 < \rho < 1$; Q /似然门禁容差及外层停止容差

- 1 $\theta \leftarrow \theta^{(0)}, t_{\text{done}} \leftarrow 0, \ell_{\text{done}} \leftarrow 0$, 诊断与轨迹为空
- 2 若数据/模型/E 步/方向接口、 Θ 或初值非法, 或预算、回缩、门禁和停止容差不合法, 则返回当前初值、计数 0、invalid_input 及字段诊断
- 3 计算 $\ell \leftarrow \log P(Y | \theta)$; 若非有限则返回最后合法初值、numerical_failure 及初始化似然诊断
- 4 **当** $t_{\text{done}} < T_{\text{max}}$ **执行**
- 5 保存 $\theta_{\text{old}} \leftarrow \theta, \ell_{\text{old}} \leftarrow \ell$; 精确 E 步得到 q_t 与固定 $Q_t(\cdot) = Q(\cdot, \theta_{\text{old}})$
- 6 若后验归一化失败或 $q_t, Q_t(\theta_{\text{old}})$ 非有限, 则返回最后合法状态与 numerical_failure, 诊断为 E 步
- 7 计算有限内层方向 d ; 若方向非有限或不能产生可行试算, 则返回最后合法状态与 numerical_failure, 诊断为方向阶段 t_{done}
- 8 $\alpha \leftarrow 1, \text{accepted} \leftarrow \text{false}$
- 9 **对** $j \leftarrow 0$ **至** L_{max} **执行**
- 10 在临时状态形成可行 θ^+ 并计算 $Q_t(\theta^+)$, 令 $\ell_{\text{done}} \leftarrow \ell_{\text{done}} + 1$
- 11 若候选与 Q 有限且 $Q_t(\theta^+) \geq Q_t(\theta_{\text{old}}) - \tau_Q$, 则置 $\text{accepted} \leftarrow \text{true}$ 并终止回缩; 否则保持主状态并令 $\alpha \leftarrow \rho\alpha$
- 12 **结束**
- 13 **若** $\neg \text{accepted}$ **则**
- 14 返回最后合法 $\theta_{\text{old}}, \ell_{\text{old}}, t_{\text{done}}, \ell_{\text{done}}, \text{line_search_failed}$, 诊断记录失败轮、全部 Q 值和末次步长
- 15 **结束**
- 16 计算 $\ell^+ \leftarrow \log P(Y | \theta^+)$; 若非有限或 $\ell^+ < \ell_{\text{old}} - \tau_\ell$, 则返回未改动的最后合法状态与 numerical_failure, 诊断为似然门禁及新旧值
- 17 计算似然与参数相对变化 q_ℓ, q_θ ; 原子提交 $\theta \leftarrow \theta^+, \ell \leftarrow \ell^+$ 及轨迹, 令 $t_{\text{done}} \leftarrow t_{\text{done}} + 1$
- 18 **若** $q_\ell \leq \varepsilon_\ell$ 且 $q_\theta \leq \varepsilon_\theta$ **则**
- 19 返回最后合法状态与 numerical_failure, 最终诊断记录双容差、 Q 增量、实际步长与方向残差
- 20 **结束**
- 21 **结束**
- 22 返回最后合法 $\theta, \ell, t_{\text{done}}, \ell_{\text{done}}, \text{budget_stop}$, 最终诊断记录外层预算耗尽与末轮增量

算法实现说明: GEM 只要求每轮 Q 不下降; 双小变化返回 numerical_failure, 回缩耗尽返回 line_search_failed, 不能用前者代替驻点证书。完整 C1-C14 契约

读前自检: 分块条件极大化的广义 EM。 分块条件极大化的广义 EM 输入“观测 Y 、分块参数 $\theta = (\theta_1, \dots, \theta_d)$ 、联合模型、各块可行域/求解器与初值”, 条件“ $d \geq 1$ ”; 请做一轮“所有块逐步不降且最终似然/可行性核验通过后才原子提交整轮参数”, 以“似然与参数双容差满足、外层/块求解预算耗尽或首次失败时停止”核对停止证书。

当 $\theta = (\theta_1, \dots, \theta_d)$ 时, 可把 M 步分成 d 个条件更新: 更新第 r 块时固定已经更新的前块和仍为旧值的后块。每个子步都不降低同一个 $Q(\cdot, \theta^{(t)})$, 完成一轮后仍满足 GEM 门禁。这类方法也称条件极大化或 ECM 式更新。

逐参数块条件极大化的 GEM：五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 20.5：逐参数块条件极大化的 GEM

输入：观测 Y ；分块参数 $\theta = (\theta_1, \dots, \theta_d)$ ；联合模型；初值 $\theta^{(0)}$

输出：最后合法 $\theta, \ell, t_{\text{done}}, b_{\text{done}}, \text{status}$ 、轨迹与最终诊断

数据： $T_{\text{max}} \in \mathbb{N}_0$ ；各块候选预算 $B_r \in \mathbb{N}_0$ ；目标、参数及单调数值容差；固定块次序

- 1 $\theta \leftarrow \theta^{(0)}, t_{\text{done}} \leftarrow 0, b_{\text{done}} \leftarrow 0$ ，诊断与轨迹为空
- 2 若 $d < 1$ 、数据/模型/E 步/块求解接口、任一块域或初值非法，或外层/块预算、容差、块次序不合法，则返回当前初值、计数 0、`invalid_input` 及字段诊断
- 3 计算 $\ell \leftarrow \log P(Y | \theta)$ ；若非有限则返回最后合法初值、`numerical_failure` 及初始化似然诊断
- 4 **当** $t_{\text{done}} < T_{\text{max}}$ **执行**
 - 5 保存 $\theta_{\text{old}} \leftarrow \theta, \ell_{\text{old}} \leftarrow \ell$ ；以 θ_{old} 执行 E 步并固定 $Q_t(\cdot)$
 - 6 若后验归一化失败或 $Q_t(\theta_{\text{old}})$ 非有限，则返回最后合法状态与 `numerical_failure`，诊断为 E 步
 - 7 令临时参数 $\tilde{\theta} \leftarrow \theta_{\text{old}}$
 - 8 **对** $r \leftarrow 1$ **至** d **执行**
 - 9 在至多 B_r 次试算内求有限可行 u_r 使 $Q_t(\tilde{\theta}_{-r}, u_r) \geq Q_t(\tilde{\theta}) - \tau_Q$
 - 10 若块预算耗尽仍无合格候选，则返回未改动的最后合法 $\theta_{\text{old}}, \ell_{\text{old}}, t_{\text{done}}, b_{\text{done}}, \text{budget_stop}$ ，最终诊断记录失败块 (t_{done}, r) 及试算值
 - 11 若候选或 Q 非有限、候选离开块域，则返回未改动的最后合法状态与 `numerical_failure`，诊断为块验收 (t_{done}, r)
 - 12 仅更新临时块 $\tilde{\theta}_r \leftarrow u_r$ ，令 $b_{\text{done}} \leftarrow b_{\text{done}} + 1$ ；主状态保持不变
 - 13 **结束**
 - 14 计算 $\ell^+ \leftarrow \log P(Y | \tilde{\theta})$ ；若非有限或 $\ell^+ < \ell_{\text{old}} - \tau_\ell$ ，则返回未改动的最后合法状态与 `numerical_failure`，诊断为整轮似然门禁 t_{done}
 - 15 计算似然与参数相对变化 q_ℓ, q_θ ；原子提交 $\theta \leftarrow \tilde{\theta}, \ell \leftarrow \ell^+$ 及轨迹，令 $t_{\text{done}} \leftarrow t_{\text{done}} + 1$
 - 16 **若** $q_\ell \leq \varepsilon_\ell$ **且** $q_\theta \leq \varepsilon_\theta$ **则**
 - 17 返回最后合法状态与 `numerical_failure`，最终诊断记录双容差、各块 Q 增量和块残差
 - 18 **结束**
- 19 **结束**
- 20 返回最后合法 $\theta, \ell, t_{\text{done}}, b_{\text{done}}, \text{budget_stop}$ ，最终诊断记录外层预算耗尽与末轮增量

算法实现说明：分块 M 步必须整轮原子提交；似然与参数平台返回 `numerical_failure`，任何块失败都回滚到上一完整外层轮。完整 C1-C14 契约

复杂度分析

训练时间复杂度。设 N 个样本、 K 个隐状态、参数维数 d 、外层迭代数 T 。可分解离散模型的一次 E/M 轮通常为 $O(NK)$ ，总训练为 $O(TNK)$ 。全协方差 d 维高斯混合每轮约为 $O(NKd^2 + Kd^3)$ ，总训练再乘 T ；GEM 还需计入每轮内层优化步数。

预测时间复杂度。离散 K 成分模型对一个新样本计算全部后验责任度通常为 $O(K)$ ；全协方差高斯混合在已缓存分解时约为 $O(Kd^2)$ ，再作归一化与最大责任度选择。

存储与空间复杂度。显式保存全部责任度需要 $O(NK)$ 空间；若 M 步只依赖可流式累积的充分统计量，可把额外工作空间降至 $O(Kd^2)$ 或相应模型规模。**复杂度假设：**样本条件独立且责任度可按样本计算；具有链或图结构的隐变量需换用相应推断复杂度。

正确性依据。精确 EM 的 E 步使 Jensen 下界在旧参数处取等， M 步最大化该下界，从而保证观测似然不降；GMM 更新分别是单纯形约束权重与加权均值、方差子问题的驻点。GEM 及分块版本不要求精确极大化，但每个被接受候选都必须通过同一轮 Q 函数的上升门禁。

异常、退化与停止情形。若 E 步后验无法归一化、 M 步不存在使目标不下降的可行候选、内部优化不能完成、混合成分有效样本数为零、协方差失去正定性或目标不是有限实数，必须拒绝该步并停在上一合法参数。似然增量小、参数增量小或达到迭代上限是不同的停止条件；在非凸模型中，满足任一停止条件都不等于获得全局最优解。

读前自检：EM 算法在无监督学习中的应用。把 EM 算法在无监督学习中的应用放在“ M 步候选必须通过实际 Q 值不下降检查”下考察：把“ M 步候选必须通过实际 Q 值不下降检查”中的已声明对象依次标成输入、输出与判据，并检查接近驻点时可能收敛缓慢。

20.7 例题、EM 计算与练习

无监督学习中隐变量常表示簇、主题、隐藏状态或缺失机制。EM 能把这些未观测结构转成后验软计数，但“能迭代”不代表模型假设正确；成分数、可识别性、退化约束和样本外检验仍需单独处理。

EM 复现。每轮完整保存后验统计量、参数和观测似然，检查似然不下降。**高斯混合 EM 复现。**使用责任度而非硬类别，空成分与方差下界规则在训练前固定。 **F 极值复现。**仅在 q 可取精确后验时， F 的联合最大值与观测似然最大值等价。 **F 坐标上升复现。**E 步与 M 步分别优化不同坐标块。**GEM 复现。** M 步候选必须通过实际 Q 值不下降检查。**条件极大化复现。**一轮内所有参数块共享同一个旧后验，并逐块保持 Q 不下降。

适用条件与局限性

适用条件。EM 适合联合模型易写、当前后验可精确或可靠计算、完全数据对数似然比边缘似然更易优化的问题。典型应用包括混合模型、含缺失数据模型和带隐藏结构的概率模型。

方法局限。目标通常非凸且依赖初值；接近驻点时可能收敛缓慢；高斯混合似然可退化无界；隐变量后验难算时 E 步仍不可行；参数不可识别会产生等价解；单调训练似然不能替代样本外模型检验。

读前自检：常见错误与误用边界：例题、EM 计算与练习。例题、EM 计算与练习要求先确认“边界框首项禁止把 Q 函数两个参数的角色写反”；请随后把固定错误“把 Q 函数两个参数的角色写反”中的对象、操作与结论按本节定义拆开，指出第一个不满足的定义条件，再把该处改为本节允许的写法，用改写后的运算或判断有定义，且不再触发“把 Q 函数两个参数的角色写反”验收。

常见错误

典型误用包括：把 Q 函数两个参数的角色写反；在 E 步使用已局部更新的新参数；把期望的对数误写成对数的期望；漏掉熵项却仍声称在优化 F ；把软责任度强制成 0-1；高斯方差更新使用旧均值；忽略空成分与方差塌缩；只看参数差不看似然；把“似然单调”误写成“必达全局最优”；用测试集选择初值或成分数。

读前自检：易混淆概念对比：例题、EM 计算与练习。 从例题、EM 计算与练习的条件“对比表首个数据行是“ E 步 | 完整后验 | 通常仍为完整后验 | 取单一最可能隐状态””出发，请按列复述“ E 步 | 完整后验 | 通常仍为完整后验 | 取单一最可能隐状态”中的对象、假设与结论；所得量应符合各列均对应首行对象“ E 步”，且未与表中下一行互换。

易混淆概念对比

维度	精确 EM	GEM	硬分配迭代
E 步	完整后验	通常仍为完整后验	取单一最可能隐状态
参数步	精确最大化 Q	只要求 Q 不下降	在硬标签上重新估计
单调依据	相切下界	下界上升门禁	一般不是同一软下界
典型优点	理论关系清楚	复杂 M 步可行	计算和解释较简单
主要风险	局部解、慢收敛	内层门禁实现错误	丢失隐变量不确定性

例题 20.2(三硬币模型的一轮 EM). 一个“三硬币”模型先抛选择硬币 A ：正面时选择硬币 B ，反面时选择硬币 C ；随后抛被选硬币一次， B 、 C 出现正面的概率分别为 p, q 。观测为 $Y = (1, 0, 1)$ ，当前参数为 $(\pi, p, q) = (1/2, 3/4, 1/4)$ ，其中 π 是 A 出现正面的概率。完成一轮 EM。

例题 20.2 解答

读题翻译 隐藏变量 $Z_i \in \{B, C\}$ 表示第 i 次观测由哪枚硬币产生； E 步求“来自 B ”的后验责任度， M 步再用软计数更新 π, p, q 。

已知与合法条件 $Y = (1, 0, 1)$ ，旧参数为 $\pi = 1/2, p = 3/4, q = 1/4$ ； $Z_i = B$ 等价于选择硬币 A 首次抛掷为正面。两种观测的边缘概率均严格为正，因此责任度有定义。

为什么想到这个方法 先用 Bayes 公式计算 $\gamma_i = P(Z_i = B | Y_i)$ ；随后 π' 取责任度均值， p' 和 q' 分别取对应软样本中的正面比例。

方法选择 分别计算 $y = 1$ 与 $y = 0$ 的责任度并映射到三次观测，汇总 B 、 C 的有效使用次数和加权正面数，再更新三个参数。

推导/计算 E 步中，对 $y = 1$ ，选择 B 的后验责任度（等价于选择硬币 A 首次抛掷为正面）为

$$\gamma(1) = \frac{(1/2)(3/4)}{(1/2)(3/4) + (1/2)(1/4)} = \frac{3}{4};$$

对 $y = 0$,

$$\gamma(0) = \frac{(1/2)(1/4)}{(1/2)(1/4) + (1/2)(3/4)} = \frac{1}{4}.$$

三个责任度为 $(3/4, 1/4, 3/4)$, 和为 $7/4$ 。M 步得到

$$\pi' = \frac{7}{12}, \quad p' = \frac{(3/4)1 + (1/4)0 + (3/4)1}{7/4} = \frac{6}{7},$$

$$q' = \frac{(1/4)1 + (3/4)0 + (1/4)1}{5/4} = \frac{2}{5}.$$

独立核验 三个新参数都在 $[0, 1]$ 内。旧参数下每次正面或反面的边缘概率均为 $1/2$, 故观测似然为 $1/8$; 新参数下正面概率为 $(7/12)(6/7) + (5/12)(2/5) = 2/3$, 似然为 $(2/3)^2(1/3) = 4/27 > 1/8$, 与 EM 单调性一致。

结论 E 步责任度为 $\gamma = (3/4, 1/4, 3/4)$; M 步更新为 $(\pi', p', q') = (7/12, 6/7, 2/5)$ 。

卡住时先看 先分别算 $\gamma(1)$ 和 $\gamma(0)$, 再按观测序列复用为 $(\gamma(1), \gamma(0), \gamma(1))$ 。

方法迁移 混合 Bernoulli 或高斯模型都遵循同一软计数模板; 若某成分有效使用次数为 0, 必须调用预先声明的平滑、保留或重启规则。

本章共 18 道练习。每道题干后立即给出同号解析; 长解析可自然跨页, 续页标题保留题号。

练习 20.1. 设 $Z \in \{1, 2\}$, 且 $P(Y, z = 1 | \theta) = 0.3\theta$ 、 $P(Y, z = 2 | \theta) = 0.2(1 - \theta)$, $0 \leq \theta \leq 1$ 。写出观测似然并求最大点。

练习 20.1 解析

隐变量支持为 $\{1, 2\}$, 参数可行域为 $\Theta = [0, 1]$ 。边缘似然为

$$L(\theta) = P(Y | \theta) = \sum_{z=1}^2 P(Y, z | \theta) = 0.2 + 0.1\theta.$$

因为

$$L'(\theta) = 0.1 > 0 \quad (\theta \in [0, 1]),$$

目标在可行区间严格递增, 故边界最优解为

$$\theta^* = 1, \quad L(\theta^*) = 0.3.$$

两个完全数据项共享同一 θ , 不能分别最大化后再相加。

练习 20.2. 解释为何把每个样本硬分给当前最可能的隐类别, 再把该类别当作已观测标签, 不等同于一般 EM 的 E 步。

练习 20.2 解析

一般 E 步使用完整后验分布

$$q_t(z) = P(z | y, \theta^{(t)}), \quad q_t(z) \geq 0, \quad \sum_z q_t(z) = 1.$$

硬分配改成点质量

$$z^\star \in \arg \max_z q_t(z), \quad q_t^{\text{hard}}(z) = \mathbf{1}\{z = z^\star\}.$$

两者产生的辅助目标分别为

$$Q_t(\theta) = \sum_z q_t(z) \log P(y, z | \theta), \quad Q_t^{\text{hard}}(\theta) = \log P(y, z^\star | \theta).$$

只有 q_t 本身为点质量时二者相同；否则硬分配是分类 EM 式近似，不是精确 E 步。

练习 20.3. 一个模型的隐变量有 K 个可能值， N 个样本条件独立。直接枚举联合隐配置有多少种？为何 EM 常按样本责任度计算而不枚举联合配置？

练习 20.3 解析

每个 Z_j 有 K 种取值，故联合隐配置数为

$$|\mathcal{Z}^N| = K^N.$$

若给定参数后样本条件独立，则后验因子化为

$$P(z_1, \dots, z_N | Y, \theta) = \prod_{j=1}^N P(z_j | y_j, \theta),$$

只需保存局部责任度

$$\gamma_{jk} = P(Z_j = k | y_j, \theta), \quad j = 1, \dots, N, k = 1, \dots, K,$$

即 NK 个量，而不枚举 K^N 条配置。若后验不具这种分解，E 步仍可能需要结构化推断。

练习 20.4. 设 $q = (1/4, 3/4)$ ，对应比值 $P(Y, z | \theta)/q(z)$ 为 2, 6。计算 Jensen 下界并与对数边缘似然比较。

练习 20.4 解析

令 $r(z) = P(Y, z | \theta)/q(z)$ 。边缘似然为

$$P(Y | \theta) = \sum_z q(z)r(z) = \frac{1}{4} \cdot 2 + \frac{3}{4} \cdot 6 = 5.$$

练习 20.4 解析 (续)

Jensen 下界为

$$\begin{aligned}\sum_z q(z) \log r(z) &= \frac{1}{4} \log 2 + \frac{3}{4} \log 6 \\ &= \log(2^{1/4} 6^{3/4}) \\ &\approx 1.5171.\end{aligned}$$

而 $\log P(Y | \theta) = \log 5 \approx 1.6094$ 。因 $2 \neq 6$ 且 q 两项均为正, 严格 Jensen 不等式给出 $1.5171 < 1.6094$ 。

练习 20.5. 为什么 $H(q_t)$ 在 M 步可忽略, 而在比较不同 q 时不能忽略?

练习 20.5 解析

F 函数为

$$F(q, \theta) = \mathbb{E}_q[\log P(Y, Z | \theta)] + H(q).$$

M 步固定 q_t , 因此

$$\arg \max_{\theta} F(q_t, \theta) = \arg \max_{\theta} \mathbb{E}_{q_t}[\log P(Y, Z | \theta)],$$

因为 $H(q_t)$ 与 θ 无关。比较不同 q 时却有

$$H(q_1) \neq H(q_2) \quad \text{一般成立,}$$

删除熵会改变 q 坐标目标, 并可能把软后验优化误写成硬选择。

练习 20.6. 给出 Jensen 下界在当前点取等号的充分必要条件, 并把它翻译为后验分布条件。

练习 20.6 解析

先要求 $P(Y | \theta) > 0$, 且在联合概率的正支撑上 $q(z) > 0$ 。严格凹函数 $\log$ 的 Jensen 等号条件为

$$\frac{P(Y, z | \theta)}{q(z)} = c \quad (q(z) > 0).$$

对 z 求和得到

$$P(Y | \theta) = \sum_z P(Y, z | \theta) = c \sum_z q(z) = c.$$

于是

$$q(z) = \frac{P(Y, z | \theta)}{P(Y | \theta)} = P(z | Y, \theta).$$

反向取 q 为该后验时, 比值恒为 $P(Y | \theta)$, 故这是取等的充分必要条件。

练习 20.7. 某轮 Q 函数为 $Q(\theta, \theta^{(t)}) = -4(\theta - 3)^2 + C$ 。若 $\Theta = \mathbb{R}$, 写出 M 步更新; 若 $\Theta = [0, 2]$, 更新为何改变?

练习 20.7 解析

M 步子问题为

$$\theta^{(t+1)} \in \arg \max_{\theta \in \Theta} \{-4(\theta - 3)^2 + C\}.$$

若 $\Theta = \mathbb{R}$, 一阶条件给出

$$Q'(\theta) = -8(\theta - 3) = 0 \implies \theta^{(t+1)} = 3.$$

若 $\Theta = [0, 2]$, 无约束解不可行, 故投影到最近端点:

$$\theta^{(t+1)} = \arg \min_{\theta \in [0, 2]} (\theta - 3)^2 = 2.$$

练习 20.8. 若连续两轮对数似然分别为 -100.0000 与 -99.9995 , 取 $\varepsilon_\ell = 10^{-5}$, 是否满足算法中的相对似然停止条件?

练习 20.8 解析

相对似然变化为

$$r_\ell = \frac{|-99.9995 - (-100.0000)|}{1 + |-100.0000|} = \frac{0.0005}{101} \approx 4.95 \times 10^{-6}.$$

因此

$$r_\ell \approx 4.95 \times 10^{-6} < 10^{-5},$$

似然条件满足。若算法还规定参数条件

$$\frac{\|\theta^{(t+1)} - \theta^{(t)}\|}{1 + \|\theta^{(t)}\|} \leq \varepsilon_\theta,$$

则必须同时核验, 不能仅凭平坦目标区的似然变化宣布停止。

练习 20.9. 说明为何每轮都重算观测似然虽有额外成本, 仍是重要的实现检查。

练习 20.9 解析

精确 EM 的理论门禁为

$$\ell(\theta^{(t+1)}) - \ell(\theta^{(t)}) \geq 0.$$

实现中可登记容差 $\tau_{\text{num}} \geq 0$ 并检查

$$\Delta_t = \ell(\theta^{(t+1)}) - \ell(\theta^{(t)}) \begin{cases} \geq -\tau_{\text{num}}, & \text{接受并记录,} \\ < -\tau_{\text{num}}, & \text{拒绝并报告异常.} \end{cases}$$

明显下降通常暴露后验归一化、更新公式、数值缩放或新旧参数混用错误; 似然序列同时提供停止诊断。

练习 20.10. 构造一个单调递增且有上界的数列, 说明它的增量趋于零为何不代表对应参数已经到达全局最优。

练习 20.10 解析

取

$$a_t = 1 - \frac{1}{t+1}, \quad t = 0, 1, \dots$$

则

$$a_{t+1} - a_t = \frac{1}{(t+1)(t+2)} > 0, \quad a_t < 1, \quad a_{t+1} - a_t \rightarrow 0.$$

若 a_t 只是非凸目标沿某条轨迹的值, 而另有可行参数 θ' 满足

$$J(\theta') = 2 > \lim_t a_t = 1,$$

则增量趋零只说明轨迹停滞, 不构成全局最优证书。

练习 20.11. 若 M 步只找到 Q 值比旧参数更高的新参数, 但没有找到最大点, 定理 20.2 是否仍适用?

练习 20.11 解析

GEM 只要求候选通过上升门禁

$$Q(\theta^{(t+1)}, \theta^{(t)}) \geq Q(\theta^{(t)}, \theta^{(t)}),$$

不要求达到该轮全局最大值。由 EM 下界关系得到

$$Q \text{ 不降} \implies \ell(\theta^{(t+1)}) \geq \ell(\theta^{(t)}).$$

因此定理的单调结论仍适用; 若 Q 下降, 上述蕴含链的门禁失效。

练习 20.12. 标签交换为何会使混合模型的参数估计不唯一, 但不改变观测分布?

练习 20.12 解析

混合密度为

$$p(y | \theta) = \sum_{k=1}^K \alpha_k p(y | \eta_k).$$

对任意置换 σ , 令

$$\alpha'_k = \alpha_{\sigma(k)}, \quad \eta'_k = \eta_{\sigma(k)}.$$

则

$$p(y | \theta') = \sum_k \alpha_{\sigma(k)} p(y | \eta_{\sigma(k)}) = p(y | \theta).$$

因此标签交换改变参数坐标而不改变观测分布或似然, 参数估计只在置换等价类上可识别。

练习 20.13. 证明责任度对每个固定样本满足 $\sum_k \gamma_{jk} = 1$ 。

练习 20.13 解析

若混合权重非负、各成分密度非负，且样本 y_j 的混合密度

$$d_j = \sum_{r=1}^K \alpha_r \phi(y_j | \mu_r, \sigma_r^2) > 0,$$

则责任度定义为

$$\gamma_{jk} = \frac{\alpha_k \phi(y_j | \mu_k, \sigma_k^2)}{d_j} \geq 0.$$

对 k 求和得到归一化链

$$\sum_{k=1}^K \gamma_{jk} = \frac{\sum_k \alpha_k \phi(y_j | \mu_k, \sigma_k^2)}{d_j} = \frac{d_j}{d_j} = 1.$$

$d_j = 0$ 时后验未定义，不能继续 E 步。

练习 20.14. 在固定责任度下，用 Lagrange 乘子推导 $\alpha_k = n_k/N$ 。

练习 20.14 解析

令 $n_k = \sum_j \gamma_{jk} \geq 0$ ，则 $\sum_k n_k = N$ 。权重子问题为

$$\max_{\alpha \in \Delta_K} \sum_{k=1}^K n_k \log \alpha_k, \quad \Delta_K = \{\alpha : \alpha_k \geq 0, \sum_k \alpha_k = 1\}.$$

对 $n_k > 0$ 的内点坐标，拉格朗日驻点给出

$$\frac{n_k}{\alpha_k} - \lambda = 0 \implies \alpha_k = \frac{n_k}{\lambda}, \quad \sum_k \alpha_k = 1 \implies \lambda = N.$$

故

$$\alpha_k^{\text{new}} = \frac{n_k}{N}.$$

若 $n_k = 0$ ，该坐标的结论来自边界 KKT 条件 $\alpha_k = 0$ ，而不能使用未定义的 n_k/α_k 内点方程。

练习 20.15. 若 GEM 候选使 Q 从 -120 提高到 -119.5 ，但没有求到该轮最大值 -117 ，是否可接受？说明理由。

练习 20.15 解析

候选的实际增量为

$$\Delta Q = (-119.5) - (-120) = 0.5 > 0.$$

所以它满足 GEM 门禁

$$Q(\theta^{(t+1)}, \theta^{(t)}) \geq Q(\theta^{(t)}, \theta^{(t)}),$$

练习 20.15 解析 (续)

可以接受。未达到该轮最大值 -117 只影响内层优化充分程度与收敛速度, 不破坏单调性; 仍应记录 ΔQ 与外层停止原因。

练习 20.16. 证明依次更新两个参数块, 若每个子步都不降低固定后验下的同一 Q 函数, 则整轮更新也不降低 Q 。

练习 20.16 解析

固定第 t 轮后验并记 $Q_t(a, b) = Q((a, b), \theta^{(t)})$ 。两个子步满足

$$Q_t(a', b^{(t)}) \geq Q_t(a^{(t)}, b^{(t)}),$$

以及

$$Q_t(a', b') \geq Q_t(a', b^{(t)}).$$

由传递性得到整轮链

$$Q_t(a', b') \geq Q_t(a', b^{(t)}) \geq Q_t(a^{(t)}, b^{(t)}).$$

两步必须共享同一个固定后验; 中途重算后验会改变 Q_t , 不能沿用该链。

练习 20.17. 在练习题设的三硬币模型中, 若所有最终观测均为正面, 说明 p 与 q 为何可能难以分别识别。

练习 20.17 解析

单次观测的正面概率只依赖组合量

$$r = P(Y = 1) = \pi p + (1 - \pi)q.$$

若 N 次观测全为正面, 观测似然为

$$L(\pi, p, q) = r^N = [\pi p + (1 - \pi)q]^N.$$

因此

$$\pi p + (1 - \pi)q = r \implies L \text{ 相同},$$

许多参数三元组无法由观测区分; EM 可返回其中一组, 但分解依赖初值且不唯一。

练习 20.18. 设计多初值 EM 的无数据泄漏选择流程。

练习 20.18 解析

先固定互不重叠的数据角色

$$D = D_{\text{train}} \dot{\cup} D_{\text{val}} \dot{\cup} D_{\text{test}}.$$

只在训练集上生成预先规定的合法初值 $\theta_0^{(r)}$, 并用同一停止规则得到

$$\hat{\theta}^{(r)} = \text{EM}(D_{\text{train}}, \theta_0^{(r)}), \quad r = 1, \dots, R.$$

练习 20.18 解析 (续)

排除非有限或退化运行后，按预先固定的验证准则选择

$$r^{\star} \in \arg \max_{r \in \mathcal{R}_{\text{valid}}} \ell_{\text{val}}(\hat{\theta}(r)).$$

锁定规则后可在开发数据上重训； D_{test} 只用于一次最终评价，不反向选择初值。

本章结论与下一步

核心结论：观测似然、隐变量后验、辅助函数与责任度

关键依据：以当前后验构造相切 Jensen 下界，M 步提高同一 Q 函数从而推出观测似然不降

可执行自检：E 步更新后验；M 步在参数域内极大化；GEM 只要求同一辅助函数不降

适用边界：边缘化困难而完整数据似然易处理的潜变量模型

下一步：进入 HMM；使用 EM 前必须先核对观测概率、后验支撑、空成分和边界 KKT 条件

1. 能否从边缘似然分三步推出 Jensen 下界，并写出取等号的后验条件？
2. 能否说明 $Q(\theta, \theta^{(t)})$ 两个参数的不同职责，写出完整 EM 伪代码，并比较显式保存责任度与流式统计的时间、空间成本？
3. 能否用 KL 分解证明似然单调性，同时准确表述收敛结论不包含什么？
4. 能否从责任度推导高斯混合的权重、均值与方差更新，并处理空成分和方差塌缩？
5. 能否证明固定 θ 时 F 由后验唯一最大化，区分 EM、GEM 与硬分配迭代，并设计开发集选择、完整重拟合和一次测试解封的无泄漏多初值流程？若未通过，应依次回看第 20.1–20.2 节的目标与下界、第 20.3–20.4 节的算法和证明，以及第 20.5–20.7 节的模型更新与实现边界。

第 21 章 隐马尔可夫模型

读前自检：本章地图：隐马尔可夫模型。 隐马尔可夫模型章地图以“从状态链直达前向 – 后向、Baum–Welch 与 Viterbi”组织内容；请把路线拆成起点、关键工具和终点，并核对三者的输入输出类型能依次衔接。

读前自检：本章可检验学习目标。 隐马尔可夫模型学习目标固定核验“能严格定义随机过程、马尔可夫链与离散隐马尔可夫模型”；请实际完成“严格定义随机过程、马尔可夫链与离散隐马尔可夫模型”，并用“中间结果逐项包含首目标“能严格定义随机过程、马尔可夫链与离散隐马尔可夫模型”声明的对象、条件与结论”判定通过或失败。

读前自检：先修自检。 隐马尔可夫模型先修自检固定核验“给定行随机矩阵 A 和概率行向量 ρ ，能否计算下一时刻分布 ρA ”；请给定行随机矩阵 A 和概率行向量 ρ ，实际计算下一时刻分布 ρA 并写出中间结果，再按“ ρA 的计算或证明结果满足首项所列等式、定义域或判断”明确判为通过或失败。

读前自检：依赖路线。 隐马尔可夫模型依赖路线从“随机过程 → 一阶马尔可夫链 → 隐状态转移”进入“状态条件下的观测独立 → HMM 联合概率分解”；请写出箭头成立所需的定义域条件，并核对前者输出能作为后者输入。

本章地图

核心问题：怎样对指数多条隐藏路径进行求和、学习和最优路径选择

可检验学习目标：

- 能严格定义随机过程、马尔可夫链与离散隐马尔可夫模型，写出状态转移、观测独立和齐次性假设及联合概率分解；
- 能区分概率计算、参数学习和状态序列预测三个基本问题，并为同一模型选择正确算法；
- 能从路径求和逐步推出前向与后向递推，计算状态后验、相邻状态后验及期望计数；
- 能把 Baum–Welch 算法解释为 EM，推导初始分布、转移概率与观测概率更新，并说明单调性、初始化和停止条件；
- 能写出 Viterbi 最大乘积递推与回溯，比较逐时刻后验解码，分析时间空间复杂度、数值稳定性、适用条件和局限。

最短先修：本章使用条件概率、全概率公式、离散随机变量、矩阵乘法、极大似然、EM 算法以及动态规划。还需能区分“状态在时间上相关”和“给定状态后观测条件独立”。阅读前应熟悉概率向量归一化、对数概率计算和有限状态有向图。

依赖路线：随机过程 → 一阶马尔可夫链 → 隐状态转移；状态条件下的观测独立 → HMM 联合概率分解；路径和的公共前缀/后缀 → 前向 – 后向递推 → 后验期望计数；期望计数 → Baum–Welch 参数更新；路径概率的最大值 → Viterbi 递推与回溯；转移矩阵结构 → 有限时刻可达性；长期平稳与遍历性质留到第 30 章。

完成标准与返回：观测概率为零时返回节 21.2、21.3；更新行未占用时回看节 21.4

读前自检：模型认识卡：隐马尔可夫模型。 HMM 模型卡给定初始分布 π 、转移矩阵 A 、发射矩阵 B 与观测 O ；请为一条状态路径写出联合概率乘积，核对各因子索引合法并说明求和、后验或最大路径对应三类输出。

模型认识卡：隐马尔可夫模型

任务与输入：有限状态序列概率、学习与解码，观测 $O = (o_1, \dots, o_T)$ 。**输出类型：**观测概率、状态后验或整条状态路径。

模型：隐藏一阶链 A 与状态条件发射 B ，初始分布为 π 。**策略：**利用链分解共享路径前缀/后缀。**算法：**前向 - 后向、Baum-Welch 与 Viterbi。

预测：边缘解码或全局 MAP 路径。**关键假设与边界：**有限状态、一阶齐次与条件发射；零概率前缀、不可识别状态和局部最优需显式处理。

本章符号表		
符号	取值或维数	含义
$I = (i_1, \dots, i_T)$	$\{1, \dots, N\}^T$	隐状态序列
$O = (o_1, \dots, o_T)$	$\{v_1, \dots, v_M\}^T$	观测序列
$A = (a_{ij})$	$N \times N$ 行随机矩阵	状态 i 到状态 j 的转移概率
$B = (b_j(k))$	$N \times M$ 行随机矩阵	状态 j 产生观测 v_k 的概率
$\pi = (\pi_i)$	N 维概率向量	初始状态分布
$\lambda = (A, B, \pi)$	参数三元组	离散 HMM 模型参数
$\alpha_t(i), \beta_t(i)$	非负实数	前向概率与后向概率
$\gamma_t(i)$	$[0, 1]$	给定完整观测时，时刻 t 处于状态 i 的后验
$\xi_t(i, j)$	$[0, 1]$	给定完整观测时，相邻状态为 i, j 的后验
$\delta_t(i), \psi_t(i)$	非负实数、状态索引	Viterbi 最优前缀值与回溯指针

21.1 马尔可夫性质与概率图结构

序列数据同时包含局部依赖与长期结果：若直接为每条可能状态路径分配概率，参数量和计算量都会随长度指数增长。HMM 用“一阶隐藏状态链+状态条件下的局部观测”压缩依赖结构，使联合分布可以分解，并让求和与最大化都能用动态规划完成。

有限状态序列概念桥

长度为 T 的观测序列是 $O = (o_1, \dots, o_T)$ ，隐藏状态序列是 $I = (i_1, \dots, i_T)$ ；一条**路径**就是一组具体状态取值。转移概率 a_{ij} 描述相邻时刻，发射概率 $b_j(o_t)$ 描述状态 j 生成当前观测。前向算法对所有合法路径**求和**，Viterbi 对所有合法路径**取最大**，二者都只依赖有限层动态规划。学习本章无需预先掌握不可约、非周期或遍历定理；这些长期性质统一在第 30 章严格定义。

读前自检：随机过程。 在“离散时间、有限状态随机过程满足 $t \in \{1, 2, \dots\}$ 且每个 X_t 取有限个值”成立时处理隐马尔可夫模型中的随机过程：请沿 $\{X_t : t \in \mathcal{T}\}$ 标出输入域、输出域和一次运算结果的形状，并以运算闭合且结果落入声明的空间或集合判定结果。

定义 21.1 (随机过程). 随机过程是一族按时间或其他有序指标排列的随机变量 $\{X_t : t \in \mathcal{T}\}$ 。其有限维分布描述任意有限时刻联合取值的概率。离散时间、有限状态随机过程满足 $t \in \{1, 2, \dots\}$ 且每个 X_t 取有限个值。

读前自检：马尔可夫性质。 马尔可夫性质所用的明确前提是“对所有有正概率的历史”；完成检查 $P(X_{t+1} = j \mid X_1 = x_1, \dots, X_t = i)$ 中每项的类型后完成等式变形后，核对并不表示不同时刻彼此独立。

定义 21.2 (一阶马尔可夫性质). 若对所有有正概率的历史，

$$P(X_{t+1} = j \mid X_1 = x_1, \dots, X_t = i) = P(X_{t+1} = j \mid X_t = i),$$

则过程具有一阶马尔可夫性质。它表示给定当前状态后，更早历史不再为下一状态提供额外信息；并不表示不同时刻彼此独立。

有限状态马尔可夫链由初始分布与转移概率决定。若转移概率不随 t 改变，称为齐次链，并记 $a_{ij} = P(X_{t+1} = j \mid X_t = i)$ 。每行满足 $a_{ij} \geq 0$ 且 $\sum_j a_{ij} = 1$ 。

读前自检：隐马尔可夫模型。 围绕隐马尔可夫模型，先采用条件“HMM 把马尔可夫链状态设为不可直接观测，并在每个时刻由当前状态随机生成一个观测”，再把“HMM 把马尔可夫链状态设为不可直接观测，并在每个时刻由当前状态随机生成一个观测”中的已声明对象依次标成输入、输出与判据；最后验证状态链表达时序结构，观测分布表达状态如何留下可见证据。

HMM 把马尔可夫链状态设为不可直接观测，并在每个时刻由当前状态随机生成一个观测。状态链表达时序结构，观测分布表达状态如何留下可见证据。

读前自检：隐马尔可夫模型。 隐马尔可夫模型中的“观测 $o_t \in \{v_1, \dots, v_M\}$ 在给定 i_t 后独立于其他状态和观测”决定可执行范围；请沿 $o_t \in \{v_1, \dots, v_M\}$ 标出输入域、输出域和一次运算结果的形状，结果须满足运算闭合且结果落入声明的空间或集合。

定义 21.3 (隐马尔可夫模型). 离散 HMM 是参数 $\lambda = (A, B, \pi)$ 确定的时序概率模型。隐藏状态 $i_t \in \{1, \dots, N\}$ 构成齐次一阶马尔可夫链；观测 $o_t \in \{v_1, \dots, v_M\}$ 在给定 i_t 后独立于其他状态和观测，并按 $b_{i_t}(o_t)$ 生成。

模型使用两项核心条件独立假设：

$$P(i_t \mid i_{1:t-1}, o_{1:t-1}) = P(i_t \mid i_{t-1}),$$

$$P(o_t \mid i_{1:T}, o_{1:t-1}, o_{t+1:T}) = P(o_t \mid i_t).$$

因此联合概率分解为

$$P(O, I | \lambda) = \pi_{i_1} b_{i_1}(o_1) \prod_{t=1}^{T-1} a_{i_t i_{t+1}} b_{i_{t+1}}(o_{t+1}).$$

动态规划预备复现。 同一终点状态的多条路径拥有相同的未来子问题；把它们的概率和或最大值压缩成一个状态量，便可避免重复枚举完整路径。

模型。 HMM 是生成模型：它定义 $P(O, I)$ ，从而也定义 $P(O)$ 与 $P(I | O)$ 。边缘观测通常在时间上相关；“观测独立”只在给定隐藏状态序列后成立。状态编号没有固有语义，交换全部相关参数的编号不改变观测分布。

贯穿例：三时刻天气序列

本章角色：把短序列解释为 HMM 的联合生成事件，明确正支撑与本章条件独立假设。精确复用观测序列 $x = (\text{干}, \text{湿}, \text{干})$ 与隐藏状态序列 $y = (\text{晴}, \text{雨}, \text{晴})$ 。本章为二者建立联合生成模型，指定路径的联合概率为

$$p(y, x) = \pi_{\text{晴}} b_{\text{晴}}(\text{干}) a_{\text{晴}, \text{雨}} b_{\text{雨}}(\text{湿}) a_{\text{雨}, \text{晴}} b_{\text{晴}}(\text{干}).$$

要让该事件处在模型正支撑上，除 $\pi_{\text{晴}} > 0$ 外，路径实际使用的转移事件 $a_{\text{晴}, \text{雨}}, a_{\text{雨}, \text{晴}}$ 与发射事件 $b_{\text{晴}}(\text{干}), b_{\text{雨}}(\text{湿})$ 都必须为正。有限状态、有限观测字典和这些正支撑条件使该短序列与 HMM 假设相容；观测条件独立只是在给定整条状态路径后的本章生成假设。下一站见条件随机场对同一序列的条件建模。

21.2 HMM 定义与三个基本问题

状态转移矩阵 $A = (a_{ij})_{N \times N}$ 的第 i 行是给定当前状态 i 后的下一状态条件分布。矩阵乘法 A^r 给出 r 步转移概率；行列方向必须与所用向量约定一致，本章统一用行概率向量。

读前自检：隐马尔可夫模型的定义。 把隐马尔可夫模型的定义放在 “ $A = (a_{ij})$, $a_{ij} = P(i_{t+1} = q_j | i_t = q_i)$,” 下考察：把 A 展开一次并检查其类型或边界，并检查展开后的量满足定义中的域、维数或符号限制。

令状态集合 $Q = \{q_1, \dots, q_N\}$ ，观测集合 $V = \{v_1, \dots, v_M\}$ 。参数为

$$A = (a_{ij}), \quad a_{ij} = P(i_{t+1} = q_j | i_t = q_i),$$

$$B = (b_j(k)), \quad b_j(k) = P(o_t = v_k | i_t = q_j),$$

$$\pi = (\pi_i), \quad \pi_i = P(i_1 = q_i).$$

三者每一行或向量都必须非负且归一化。

读前自检：观测序列的生成。 观测序列的生成输入 “有限离散 HMM 参数 $\lambda = (A, B, \pi)$ 、长度 T 、可复现随机源和固定离散采样器”，条件 “ $T \geq 1$ ”；请做一轮 “同一时刻的状态和观测两次抽样

均成功且索引合法后才原子追加到前缀”，以“恰好生成 T 个时刻或首次失败时停止”核对停止证书。

读前自检：观测序列的生成过程。 观测序列的生成过程输入“有限离散 HMM 参数 $\lambda = (A, B, \pi)$ 、长度 T 、可复现随机源和固定离散采样器”，条件“ $T \geq 1$ ”；请做一轮“同一时刻的状态和观测两次抽样均成功且索引合法后才原子追加到前缀”，以“恰好生成 T 个时刻或首次失败时停止”核对停止证书。

HMM 观测序列生成：五步阅读

输入。 写出数据对象、固定参数与必须成立的条件。

初始化。 标明主状态、计数器和第一个合法状态。

核心更新。 只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。 写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。 列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 21.1: HMM 观测序列生成

输入: HMM 参数 $\lambda = (A, B, \pi)$ ；长度 T ；可复现随机源

输出: 最后合法 (O, I) 前缀、 $t_{\text{done}}, q_{\text{done}}, \text{status}$ 与最终诊断

数据: 概率和容差 $\varepsilon_{\text{prob}}$ ；固定离散采样器与端点规则

- 1 $O \leftarrow \emptyset, I \leftarrow \emptyset, t_{\text{done}} \leftarrow 0, q_{\text{done}} \leftarrow 0$, 诊断为空
- 2 若 $T < 1$, A, B, π 维数不一致、含负数/非有限值或未在容差内归一化，或随机源、采样器、端点规则不合法，则返回空前缀、计数 0、`invalid_input` 及字段诊断
- 3 调用随机源按 π 暂存 i^+ ；若随机源失败则返回空前缀、`random_source_failure` 及首状态调用诊断；成功后令 $q_{\text{done}} \leftarrow q_{\text{done}} + 1$
- 4 若累计概率非有限或 i^+ 越界，则返回空前缀、`numerical_failure` 及首状态采样诊断
- 5 调用随机源按 B_{i^+} 暂存 o^+ ；若随机源失败则返回空前缀、当前 $q_{\text{done}}, \text{random_source_failure}$ 及首发发射调用诊断；成功后令 $q_{\text{done}} \leftarrow q_{\text{done}} + 1$
- 6 若累计概率非有限或 o^+ 越界，则返回空前缀、`numerical_failure` 及首发发射采样诊断；否则原子追加 (i^+, o^+) 并令 $t_{\text{done}} \leftarrow 1$
- 7 当 $t_{\text{done}} < T$ 执行
 - 8 令 $t \leftarrow t_{\text{done}} + 1$ ；按 $A_{i_{t-1}}$ 暂存 i^+ ；随机源失败则返回最后合法前缀、`random_source_failure` 及转移阶段 t 诊断；成功令 $q_{\text{done}} \leftarrow q_{\text{done}} + 1$
 - 9 若累计概率非有限或 i^+ 越界，则返回最后合法前缀、`numerical_failure` 及转移采样 (t, i_{t-1}) 诊断
 - 10 按 B_{i^+} 暂存 o^+ ；随机源失败则返回最后合法前缀、`random_source_failure` 及发射阶段 t 诊断；成功令 $q_{\text{done}} \leftarrow q_{\text{done}} + 1$
 - 11 若累计概率非有限或 o^+ 越界，则返回最后合法前缀、`numerical_failure` 及发射采样 (t, i^+) 诊断
 - 12 原子追加 (i^+, o^+) 到 (I, O) 并令 $t_{\text{done}} \leftarrow t$
- 13 结束
- 14 返回完整 $(O, I), t_{\text{done}} = T, q_{\text{done}} = 2T, \text{completed}$, 最终诊断记录种子、概率和最大残差与终态

算法实现说明：核心四步是抽初态、按当前状态发射、按转移分布推进、返回完整路径；随机源与概率残差属于稳健实现细节 完整 C1-C14 契约

读前自检：隐马尔可夫模型的3个基本问题。 HMM 三类基本问题分别输出 $P(O | \lambda)$ 、参数估计 $\hat{\lambda}$ 和最优状态路径；请把同一 O, λ 映射到三项，核对状态未标注时学习需隐变量方法而状态已标注时可归一化频数。

给定模型或数据，HMM 有三个基本问题：

1. **概率计算：**给定 λ, O ，求 $P(O | \lambda)$ ；
2. **学习：**给定一个或多个观测序列，估计 λ 使观测似然较大；
3. **预测或解码：**给定 λ, O ，求最可能状态路径，或计算逐时刻状态后验。

学习策略。隐藏状态已标注时，极大似然估计由初始、转移和观测频数归一化得到；仅有观测时，使用 Baum-Welch 的软期望计数。模型选择如状态数 N 、拓扑约束与平滑强度必须在验证协议内确定，不能用最终测试序列反复调节。

读前自检：动态规划与递推。 HMM 动态规划以“时刻 t 与状态 i ”标识子问题；请把所有到达 i 的前缀概率先求和，再乘同一出边和下一观测因子，核对所得递推无需重新枚举共享前缀。

21.3 前向与后向算法

动态规划把所有以同一状态 i 结束的前缀路径概率先求和，再通过同一组出边扩展；后向递推则把同一状态出发的所有后缀压缩。每个子问题由“时刻+状态”唯一标识。

读前自检：前向 - 后向递推。 前向量 $\alpha_t(i)$ 表示截至 t 的观测与状态 i 的联合概率，后向量 $\beta_t(i)$ 表示给定状态 i 后的未来观测概率；请相乘并对 i 求和，核对任意 t 都得到同一 $P(O | \lambda)$ 。

前向量包含过去观测与当前状态的联合概率，后向量包含给定当前状态后的未来观测概率。二者在任一时刻相乘并归一化，可得到使用全部观测信息的平滑后验。

读前自检：概率计算算法。 HMM 直接概率计算枚举 N^T 条状态路径且每条含 $O(T)$ 个因子；请比较其 $O(TN^T)$ 成本与前向算法 $O(TN^2)$ 成本，并核对二者计算的是同一 $P(O | \lambda)$ 。

直接计算需要枚举 N^T 条路径，每条路径含 $O(T)$ 个因子，成本为 $O(TN^T)$ 。前向或后向算法利用分配律重排求和，把指数成本降为 $O(TN^2)$ 。

读前自检：直接算法。 给定 HMM 参数 λ 与观测 O 。请枚举全部状态路径并累加其联合概率，核对总和为 $P(O | \lambda)$ 。

直接表达式为

$$P(O | \lambda) = \sum_{i_1=1}^N \cdots \sum_{i_T=1}^N \pi_{i_1} b_{i_1}(o_1) \prod_{t=1}^{T-1} a_{i_t i_{t+1}} b_{i_{t+1}}(o_{t+1}).$$

它是递推算法的正确性基准，却不是长序列的可行实现。

读前自检：前向概率。 前向概率定义为 $\alpha_t(i) = P(o_{1:t}, i_t = q_i | \lambda)$ ；请对 i 求和，核对结果是前缀观测概率 $P(o_{1:t} | \lambda)$ 而不是必须等于 1 的状态后验。

定义 21.4 (前向概率).

$$\alpha_t(i) = P(o_1, \dots, o_t, i_t = q_i | \lambda).$$

它同时包含截至 t 的观测证据与当前状态事件, 因而不是归一化的状态后验。

读前自检: 观测序列概率的前向算法。 观测序列概率的前向算法从 $\alpha_1(i) = \pi_i b_i(o_1)$ 开始; 请手算一轮 $\alpha_{t+1}(i) = [\sum_j \alpha_t(j) a_{ji}] b_i(o_{t+1})$, 再对终层求和核对 $P(O | \lambda)$ 。

读前自检: 前向算法。 前向算法利用给定当前状态后的转移与观测条件独立; 请把 $P(o_{1:t}, i_t = q_j | \lambda)$ 、 a_{ji} 与 $b_i(o_{t+1})$ 相乘并对 j 求和, 核对得到 $\alpha_{t+1}(i)$ 。

学习算法。 前向递推为

$$\alpha_1(i) = \pi_i b_i(o_1),$$

$$\alpha_{t+1}(i) = \left[\sum_{j=1}^N \alpha_t(j) a_{ji} \right] b_i(o_{t+1}), \quad P(O | \lambda) = \sum_{i=1}^N \alpha_T(i).$$

阅读目标: 用全概率公式和条件独立性把长度 $t+1$ 的前缀概率拆开。

对象: 前向概率 $\alpha_t(j)$ 、转移概率 a_{ji} 与发射概率 $b_i(o_{t+1})$ 。

合法条件: 时刻 t 的状态构成互斥完备事件; 模型满足一阶马尔可夫性和条件观测独立性。

第一步: 先固定终点状态 i , 并对上一时刻状态 j 应用全概率公式。

推导目标

从前向概率定义出发, 分三步推出递推式, 明确求和、转移和观测因子的条件独立来源。

推导准备

固定 $t+1$ 的终点状态 i , 把时刻 t 的状态 j 作为互斥完备事件求和; 使用一阶马尔可夫性与当前状态条件下的观测独立性。

推导第 1 步: 按前一状态分解。

$$\alpha_{t+1}(i) = \sum_j P(o_{1:t+1}, i_t = q_j, i_{t+1} = q_i | \lambda).$$

推导第 2 步: 使用条件独立结构。

$$P(o_{1:t}, i_t = q_j | \lambda) P(i_{t+1} = q_i | i_t = q_j) P(o_{t+1} | i_{t+1} = q_i) = \alpha_t(j) a_{ji} b_i(o_{t+1}).$$

推导第 3 步: 求和并终止。 对 j 求和得到递推式; 在 $t = T$ 对终点状态 i 求和, 得到 $P(O | \lambda)$ 。

读前自检: 前向 - 后向分解。 前向 - 后向分解对任意 $t \in \{1, \dots, T\}$ 成立; 请计算 $\sum_i \alpha_t(i) \beta_t(i)$, 核对前缀联合概率与条件未来概率相乘后恰为 $P(O | \lambda)$ 。

定理 21.1 (前向 – 后向分解) 对任意 $t \in \{1, \dots, T\}$,

$$P(O | \lambda) = \sum_{i=1}^N \alpha_t(i) \beta_t(i),$$

其中 $\beta_t(i) = P(o_{t+1}, \dots, o_T | i_t = q_i, \lambda)$ 。

读前自检：证明：前向 – 后向分解。 前向 – 后向分解对时刻 t 的状态应用全概率公式；请在给定 $i_t = q_i$ 后将过去与未来观测分离成 $\alpha_t(i) \beta_t(i)$ 并对 i 求和，核对 $t = T$ 时 $\beta_T(i) = 1$ 退化为前向终止式。

证明。 对时刻 t 的状态应用全概率公式：

$$P(O | \lambda) = \sum_i P(o_{1:t}, i_t = q_i, o_{t+1:T} | \lambda).$$

给定 i_t 后，过去观测与未来观测由马尔可夫结构分离，所以每项可写为

$$P(o_{1:t}, i_t = q_i | \lambda) P(o_{t+1:T} | i_t = q_i, \lambda) = \alpha_t(i) \beta_t(i).$$

对 i 求和即得结论。 $t = T$ 时 $\beta_T(i) = 1$ ，退化为前向终止公式。 $\square$

读前自检：后向算法。 隐马尔可夫模型中的后向算法要求先确认 “ $\beta_t(i) = P(o_{t+1}, \dots, o_T | i_t = q_i, \lambda)$ 。”；请随后把 $\beta_t(i)$ 展开一次并检查其类型或边界，用 $\beta_T(i) = 1$ 验收。

读前自检：后向概率。 后向概率 $\beta_t(i) = P(o_{t+1:T} | i_t = q_i, \lambda)$ 不是状态分布；请由 $\beta_T(i) = 1$ 向前做一次递推，核对各项非负，但不要把 $\sum_i \beta_t(i)$ 误当成 1。

定义 21.5 (后向概率)。

$$\beta_t(i) = P(o_{t+1}, \dots, o_T | i_t = q_i, \lambda).$$

末时刻未来观测为空，故 $\beta_T(i) = 1$ 。

读前自检：观测序列概率的后向算法。 观测序列概率的后向算法以 $\beta_T(i) = 1$ 初始化；请计算 $\beta_t(i) = \sum_j a_{ij} b_j(o_{t+1}) \beta_{t+1}(j)$ ，再核对 $P(O | \lambda) = \sum_i \pi_i b_i(o_1) \beta_1(i)$ 。

后向递推为

$$\beta_t(i) = \sum_{j=1}^N a_{ij} b_j(o_{t+1}) \beta_{t+1}(j), \quad t = T-1, \dots, 1,$$

并有 $P(O | \lambda) = \sum_i \pi_i b_i(o_1) \beta_1(i)$ 。

前向、后向量给出

$$\gamma_t(i) = P(i_t = q_i | O, \lambda) = \frac{\alpha_t(i) \beta_t(i)}{P(O | \lambda)},$$

$$\xi_t(i, j) = P(i_t = q_i, i_{t+1} = q_j | O, \lambda) = \frac{\alpha_t(i) a_{ij} b_j(o_{t+1}) \beta_{t+1}(j)}{P(O | \lambda)}.$$

于是 $\sum_t \gamma_t(i)$ 是状态 i 出现次数的后验期望, $\sum_t \xi_t(i, j)$ 是 $i \rightarrow j$ 转移次数的后验期望。

几何理解

几何解释。长度 T 、每层 N 个结点的状态格构成有向无环图。前向算法从左到右做“入边加权求和”，后向算法从右到左做“出边加权求和”，Viterbi 则把求和半环换成最大乘积半环。图结构相同，聚合运算不同。

概率解释

$\alpha_t(i)$ 只看过去与当前, $\beta_t(i)$ 只看给定当前状态后的未来; 乘积合并两侧证据。 $\gamma_t(i)$ 是归一化后的单状态后验, $\xi_t(i, j)$ 是相邻状态联合后验, 分别为观测和转移的软计数提供权重。

优化解释

优化解释。前向-后向本身不是参数优化, 而是固定参数下的精确求和推断。它为 Baum-Welch 的 E 步计算充分统计量; Viterbi 把同一递推图上的求和换为最大化, 从而求解最大概率单路径这一不同目标。




图 21.1 HMM 状态格的三种读法: 前向与后向对共享路径求和, Viterbi 只保存获胜前驱

图 21.1 中每条边表示一次合法状态转移。前向与后向递推对到达同一结点的路径概率求和, Viterbi 递推则取最大值并保存获胜前驱, 因此二者不能只替换一个运算符而忽略回溯信息。

例题 21.1 (两状态 HMM 的前向概率). 二状态 HMM 有 $\pi = (0.6, 0.4)$, $A = \begin{pmatrix} 0.7 & 0.3 \\ 0.4 & 0.6 \end{pmatrix}$ 。观测符号为 R, B , 且 $b_1(R) = 0.5, b_2(R) = 0.1, b_1(B) = 0.5, b_2(B) = 0.9$ 。求 $O = (R, B)$ 的概率。

例题 21.1 解答

读题翻译 要求的是观测序列 $O = (R, B)$ 的边缘概率, 需要把所有隐藏状态路径的联合概率求和, 而不是寻找最大概率路径。

已知与合法条件 初始分布 $\pi = (0.6, 0.4)$, 转移矩阵每行和为 1; 两个状态对 R, B 的发射概率均非负且各行归一化, 观测长度为 2。

为什么想到这个方法 前向算法按“初始概率乘首个发射—对前驱求和—乘当前发射”递推，最后对终态求和，正好完成隐藏路径边缘化。

方法选择 先计算 $\alpha_1(j) = \pi_j b_j(R)$ ，再对每个终态按 $\alpha_2(j) = [\sum_i \alpha_1(i) a_{ij}] b_j(B)$ 更新，最后求 $\sum_j \alpha_2(j)$ 。

推导/计算 初始化 $\alpha_1 = (0.6 \cdot 0.5, 0.4 \cdot 0.1) = (0.30, 0.04)$ 。递推得

$$\alpha_2(1) = [0.30(0.7) + 0.04(0.4)](0.5) = 0.113,$$

$$\alpha_2(2) = [0.30(0.3) + 0.04(0.6)](0.9) = 0.1026.$$

独立核验 直接枚举四条状态路径的联合概率得到 0.105, 0.081, 0.008, 0.0216，其和为 0.2156，与 $0.113 + 0.1026$ 一致。前向量分量非负，但其和是观测前缀概率而非必须等于 1 的后验分布。

结论 $\alpha_2 = (0.113, 0.1026)$ ，因此 $P(O = (R, B) | \lambda) = 0.2156$ 。

参数含义。 N, M, T 分别控制状态数、观测符号数和序列长度；缩放因子 c_t 保存每步被除去的概率质量。若采用对数域，则用 $-\infty$ 表示零概率，并用 log-sum-exp 聚合，不能把零概率替换为任意小常数而不说明模型变化。

初始化方法。 前向初值必须同时包含初始状态概率与首个观测概率；后向初值为 $\beta_T(i) = 1$ ，表示空后缀概率。Baum-Welch 参数初值需全部合法且通常保持小的正概率；Viterbi 的回溯指针首时刻设为空标记。

参数更新规则。 前向按“所有前驱之和—转移—当前观测”更新，后向按“转移—下一观测—下一后向值”更新；观测因子在两式中的时间下标不同。缩放前后向必须共用一致因子，否则 γ, ξ 归一化会出错。

缩放前向算法：五步阅读

输入。 写出数据对象、固定参数与必须成立的条件。

初始化。 标明主状态、计数器和第一个合法状态。

核心更新。 只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。 写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。 列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 21.2: 缩放前向算法**输入:** HMM 参数 $\lambda = (A, B, \pi)$; 观测 $O = (o_1, \dots, o_T)$ **输出:** 最后合法前向层与因子、 $\log P(O | \lambda)$ 、 t_{done} 、 r_{done} 、**status** 与最终诊断**数据:** $0 < \varepsilon_{\text{prob}} < 1$; 归一化容差; 确定性 log-sum-exp 回退

- 1 $t_{\text{done}} \leftarrow 0$, $r_{\text{done}} \leftarrow 0$, 前向层与因子为空, 诊断为空
- 2 若 $T < 1$ 、观测越出字典, 模型维数/概率/归一化非法, 或阈值、容差、回退接口不合法, 则返回空前缀、**invalid_input** 及字段诊断
- 3 计算临时 $\tilde{\alpha}_1(i) = \pi_i b_i(o_1)$ 及 $c_1 = \sum_i \tilde{\alpha}_1(i)$
- 4 若 $c_1 = 0$, 则返回空前向前缀、 $\log P = -\infty$, $t_{\text{done}} = 0$, $r_{\text{done}} = 0$, **completed**, 最终诊断记录零概率前缀
 $t = 1$
- 5 若 c_1 非有限或为负, 则返回空前前缀、**numerical_failure** 及首层求和诊断
- 6 若 $0 < c_1 \leq \varepsilon_{\text{prob}}$, 则令 $r_{\text{done}} \leftarrow 1$ 并从 $t = 1$ 用 log-sum-exp 重算; 每个无 NaN/+ ∞ 的归一化对数层增加
 t_{done} , 零路径返回 **completed** 诊断, 非法数返回 **numerical_failure** 诊断, 完整重算返回 **completed**
及对数域最终诊断
- 7 计算候选 $\hat{\alpha}_1 = \tilde{\alpha}_1/c_1$; 核验有限非负且和为 1 后原子提交首层并令 $t_{\text{done}} \leftarrow 1$, 否则返回空前前缀、
numerical_failure 及首层归一化诊断
- 8 当 $t_{\text{done}} < T$ 执行
 - 9 令 $t \leftarrow t_{\text{done}} + 1$, 在临时状态计算 $\tilde{\alpha}_t(i) = [\sum_j \hat{\alpha}_{t-1}(j) a_{ji}] b_i(o_t)$ 与 c_t
 - 10 若 $c_t = 0$, 则返回最后合法前向前缀、 $\log P = -\infty$, t_{done} , r_{done} , **completed**, 最终诊断记录零概率
前缀 t
 - 11 若层或 c_t 非有限/为负, 则返回最后合法前缀、**numerical_failure** 及递推时刻 t 诊断
 - 12 若 $0 < c_t \leq \varepsilon_{\text{prob}}$, 则丢弃临时层、令 $r_{\text{done}} \leftarrow 1$ 并在独立临时表中从首层执行同一对数域重算; 零路
径时返回 **completed** 诊断, 非法数时返回既有最后合法缩放前缀与 **numerical_failure** 诊断, 完
整重算后才原子替换全部层并返回 **completed** 最终诊断
 - 13 计算并核验候选 $\hat{\alpha}_t = \tilde{\alpha}_t/c_t$ 后原子提交该层与 c_t , 令 $t_{\text{done}} \leftarrow t$; 失败则返回最后合法前缀、
numerical_failure 及归一化时刻 t 诊断
- 14 结束
- 15 计算 $L \leftarrow \sum_{t=1}^T \log c_t$; 若非有限则返回最后合法全部层、**numerical_failure** 及末端求和诊断; 否则返
回 L 、全部层与因子、 $t_{\text{done}} = T$, r_{done} , **completed**, 最终诊断记录最小因子和最大归一化残差

算法实现说明: 核心流程保留首层归一化、递推末缩放前向量、记录缩放因子和累加对数似然; 零缩放与非有限分支属于稳健实现细节 完整 C1-C14 契约

读前自检: 与前向缩放一致的后向算法: 执行契约。 与前向缩放一致的后向算法输入“合法 HMM 与观测、前向算法的完整同域前向层和正缩放/对数因子、后验容差”, 条件“前向状态为完整正概率结果”; 请执行“每个临时候向量或后验张量有限、非负且归一化核验通过后才原子提交该层”, 以“完成全部反向及后验层或首次失败时停止”判停。

读前自检: 与前向缩放一致的后向算法。 与前向缩放一致的后向算法输入“合法 HMM 与观测、前向算法的完整同域前向层和正缩放/对数因子、后验容差”, 条件“前向状态为完整正概率结果”; 请做一轮“每个临时候向量或后验张量有限、非负且归一化核验通过后才原子提交该层”, 以“完成全部反向及后验层或首次失败时停止”核对停止证书。

算法 21.3: 与前向缩放一致的后向算法**输入:** HMM 与观测; 前向算法输出的完整同域 $\hat{\alpha}_t$ 及缩放/对数因子**输出:** 最后合法 $\hat{\beta}, \gamma, \xi, b_{\text{done}}, g_{\text{done}}, x_{\text{done}}, \text{status}$ 与最终诊断**数据:** 后验归一化容差; 固定的缩放域或对数域标记

- 1 $b_{\text{done}} \leftarrow 0, g_{\text{done}} \leftarrow 0, x_{\text{done}} \leftarrow 0$, 输出层为空, 诊断为空
- 2 若模型/观测非法、前向未完整完成正概率序列、层数或实现域不一致, 缩放因子非有限正或对数因子非法, 或容差不合法, 则返回空后向结果、计数 0、`invalid_input` 及字段诊断
- 3 提交 $\hat{\beta}_T(i) \leftarrow 1$ (对数域为 0)
- 4 对 $t \leftarrow T-1, T-2, \dots, 1$ 执行
 - 5 在同一实现域临时计算后向层; 若结果含 NaN/+ ∞ 、缩放域含负值, 则返回最后合法后向前缀、`b_done, numerical_failure` 及反向时刻 t 诊断
 - 6 原子提交 $\hat{\beta}_t$ 并令 $b_{\text{done}} \leftarrow b_{\text{done}} + 1$
- 7 结束
- 8 对 $t \leftarrow 1$ 至 T 执行
 - 9 临时归一化 $\hat{\alpha}_t(i)\hat{\beta}_t(i)$ 得到 γ_t ; 若常数非有限/非正或后验非法, 则返回最后合法结果与 `numerical_failure`, 诊断为 γ 层 t
 - 10 原子提交 γ_t 并令 $g_{\text{done}} \leftarrow g_{\text{done}} + 1$
- 11 结束
- 12 对 $t \leftarrow 1$ 至 $T-1$ 执行
 - 13 临时归一化 $\hat{\alpha}_t(i)a_{ij}b_j(o_{t+1})\hat{\beta}_{t+1}(j)$ 得到 ξ_t ; 若常数非有限/非正或后验非法, 则返回最后合法结果与 `numerical_failure`, 诊断为 ξ 层 t
 - 14 原子提交 ξ_t 并令 $x_{\text{done}} \leftarrow x_{\text{done}} + 1$
- 15 结束
- 16 返回完整 $\hat{\beta}, \gamma, \xi, b_{\text{done}} = T-1, g_{\text{done}} = T, x_{\text{done}} = T-1, \text{completed}$, 最终诊断记录归一化最大残差和前向一致性误差

停止条件。前向、后向和 Viterbi 是有限长度递推, 到达边界时严格终止; Baum-Welch 的相对目标变化和后验充分统计量变化只构成数值平台判据, 返回 `numerical_failure`。参数变化仅在隐藏状态先完成标签匹配后作为辅助诊断; 只有另行给出固定点/KKT 残差才可报告数学收敛。达到最大轮数只说明计算被截断。

收敛与正确性。前向、后向和 Viterbi 由子问题递推与数学归纳保证有限步正确, 不涉及极限收敛。Baum-Welch 是 EM, 在精确 E/M 步和支撑条件下使观测似然不下降; 它仍可能停在局部驻点, 不保证隐藏状态语义唯一。

读前自检: 学习算法。对隐马尔可夫模型中的学习算法, 条件“若隐藏状态序列可见, 初始、转移和观测概率的极大似然估计都是相应频数归一化”不可省; 请把“若隐藏状态序列可见, 初始、转移和观测概率的极大似然估计都是相应频数归一化”中的已声明对象依次标成输入、输出与判据, 再用隐藏状态不可见时, 用后验期望计数替代真实计数, 这正是 EM 在 HMM 上的实现作检查。

21.4 Baum-Welch 学习算法

若隐藏状态序列可见, 初始、转移和观测概率的极大似然估计都是相应频数归一化。隐藏状态不可见时, 用后验期望计数替代真实计数, 这正是 EM 在 HMM 上的实现。

读前自检：监督学习方法。 监督学习方法把问题限定在“对多条带状态标注序列， π_i 取首状态为 i 的序列比例”；请把 a_{ij} 展开一次并检查其类型或边界，检查是否得到零计数行需要预先规定平滑或结构约束。

对多条带状态标注序列， π_i 取首状态为 i 的序列比例， a_{ij} 取 $i \rightarrow j$ 次数除以从 i 出发的总转移次数， $b_j(k)$ 取状态 j 发射 v_k 次数除以状态 j 总出现次数。零计数行需要预先规定平滑或结构约束。

读前自检：Baum-Welch 算法。 在“把前向 - 后向得到的状态与转移后验转成期望计数”成立时处理 Baum-Welch 算法：请把 $\gamma_t(i)$ 展开一次并检查其类型或边界，并以展开后的量满足定义中的域、维数或符号限制判定结果。

阅读目标： 把状态后验与转移后验解释为期望计数，并按概率单纯形归一化。

对象： $\gamma_t(i)$ 、 $\xi_t(i, j)$ 与 HMM 的初始、转移、发射参数。

合法条件： 前向 - 后向量使用同一缩放约定；相关期望总计数为正，零分母由预登记规则处理。

第一步： 先把 EM 的 Q 函数按初始分布、转移矩阵和发射矩阵三组参数分块。

推导目标

把前向 - 后向得到的状态与转移后验转成期望计数，推导 Baum-Welch 对初始分布、转移矩阵和发射矩阵的归一化更新。

推导准备

固定旧参数并用相同缩放约定计算 $\gamma_t(i)$ 与 $\xi_t(i, j)$ ；每个转移行和发射行分别位于概率单纯形。假设相应期望总计数为正；零分母情况留给预登记的平滑、重启或删除状态规则。

未标注时，E 步用前向 - 后向计算 $\gamma_t(i)$ 和 $\xi_t(i, j)$ ；M 步极大化期望完全数据对数似然

$$Q(\lambda, \lambda^{(r)}) = \sum_i \gamma_1(i) \log \pi_i + \sum_{t=1}^{T-1} \sum_{i,j} \xi_t(i, j) \log a_{ij} + \sum_{t=1}^T \sum_i \gamma_t(i) \log b_i(o_t).$$

读前自检：Baum-Welch 模型参数估计公式。 Baum-Welch 的 M 步用 $\gamma_t(i)$ 与 $\xi_t(i, j)$ 作为期望计数；请对固定状态 i 将 $\sum_t \xi_t(i, j)$ 按 j 归一化得到 a_{ij}^{new} ，核对该行和为 1，并指出零期望计数行没有无平滑 ML 更新。

推导第 1 步：初始分布。 初始项为 $\sum_i \gamma_1(i) \log \pi_i$ ；在 $\sum_i \pi_i = 1$ 下用 Lagrange 乘子求驻点，得到

$$\pi_i^{\text{new}} = \gamma_1(i),$$

推导第 2 步：转移行。 固定 i ，转移项是 $\sum_j [\sum_{t=1}^{T-1} \xi_t(i, j)] \log a_{ij}$ ；在 $\sum_j a_{ij} = 1$ 下归一化期望转移计数，得到

$$a_{ij}^{\text{new}} = \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)},$$

其中分母等于从状态 i 出发的期望转移总数。

推导第3步：发射行。固定状态 j ，按观测符号 v_k 汇总期望占用次数，并在 $\sum_k b_j(k) = 1$ 下归一化，得到

$$b_j^{\text{new}}(k) = \frac{\sum_{t=1}^T \mathbf{1}\{o_t = v_k\} \gamma_t(j)}{\sum_{t=1}^T \gamma_t(j)}.$$

每个子问题的 Hessian 在单纯形切空间上为负定或半负定，因此该归一化驻点达到对应 Q 块的最大值。多序列情形在分子、分母中再对序列求和，且 π_i 取各序列首状态后验的平均。

上式是**无平滑的 ML-EM**：目标是观测对数似然 $\ell(\lambda)$ ，零期望计数行没有 ML 更新，必须返回失败、保留结构上固定的旧行或重启，但不能临时加伪计数后仍声称在执行同一个 ML M 步。

若预先选择 **Dirichlet 先验下的 MAP-EM**，令允许的初始、转移与发射坐标分别具有参数 $\kappa_i, \eta_{ij}, \beta_{jk} > 1$ ，则 M 步极大化的是

$$Q_{\text{MAP}}(\lambda, \lambda^{(r)}) = Q_{\text{ML}}(\lambda, \lambda^{(r)}) + \sum_i (\kappa_i - 1) \log \pi_i + \sum_{i,j} (\eta_{ij} - 1) \log a_{ij} + \sum_{j,k} (\beta_{jk} - 1) \log b_j(k).$$

相应更新把各期望计数分别加上 $\kappa_i - 1, \eta_{ij} - 1, \beta_{jk} - 1$ 后逐行归一化。此时单调不减的目标是 $\ell(\lambda) + \log p(\lambda)$ ，不是无先验的观测似然；先验、允许支撑与目标必须在训练前固定。

读前自检：复杂度分析：Baum Welch 学习算法。 围绕 Baum Welch 学习算法，先采用条件“若外层迭代数为 M ，总训练为 $O(MRTN^2)$ ”，再由 T 的总成本剥离一次迭代或一次样本因子；最后验证稀疏转移图有 E 条允许边时，相应主项可降为 $O(MRTE)$ 。

复杂度分析

训练时间复杂度。直接枚举长度 T 路径为 $O(TN^T)$ 。对 R 条平均长度 T 的序列，Baum-Welch 每轮为 $O(RTN^2)$ ；若外层迭代数为 M ，总训练为 $O(MRTN^2)$ 。稀疏转移图有 E 条允许边时，相应主项可降为 $O(MRTE)$ 。

读前自检：Baum-Welch 算法。 Baum-Welch 算法输入“非空观测序列集合、状态数/允许拓扑、目标 $u \in \{\text{ML}, \text{MAP}\}$ 、合法初值及可选 Dirichlet 先验”，条件“序列符号合法”；请做一轮“全部序列 E 步、 M 步行归一化、拓扑和单调目标门禁通过后才原子提交参数”，以“目标相对增量满足容差、轮数预算耗尽或首次失败时停止”核对停止证书。

区分 ML 与 MAP 目标的 Baum-Welch 学习：五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 21.4: 区分 ML 与 MAP 目标的 Baum-Welch 学习

输入: 观测序列 $\{O_s\}_{s=1}^S$; 状态数与允许拓扑; $u \in \{\text{ML}, \text{MAP}\}$; 初值 $\lambda^{(0)}$

输出: 最后合法 λ 、目标轨迹、 $r_{\text{done}}, s_{\text{done}}$ 、**status** 与最终诊断

数据: $R_{\text{max}} \in \mathbb{N}_0$; $\varepsilon_L > 0$; $\tau_{\text{num}} \geq 0$; MAP 时固定 Dirichlet 参数; 固定并列规则

- 1 $\lambda \leftarrow \lambda^{(0)}$, $r_{\text{done}} \leftarrow 0$, $s_{\text{done}} \leftarrow 0$, 目标轨迹与诊断为空
- 2 若 $S < 1$ 、序列为空或含字典外符号、状态/拓扑/初值非法、 u 非法、MAP 先验不合法, 或预算、容差、并列规则不合法, 则返回当前初值、计数 0、**invalid_input** 及字段诊断
- 3 按 u 计算 $L \leftarrow \ell(\lambda)$ 或 $\ell(\lambda) + \log p(\lambda)$; 若非有限则返回最后合法初值、**numerical_failure** 及初始化目标诊断
- 4 **当** $r_{\text{done}} < R_{\text{max}}$ **执行**
- 5 保存 $\lambda_{\text{old}} \leftarrow \lambda, L_{\text{old}} \leftarrow L$, 清零临时期望计数
- 6 **对** $s \leftarrow 1$ **至** S **执行**
- 7 只用 λ_{old} 执行同域前向 - 后向; 若序列概率为零、后验归一化失败或结果非有限, 则返回最后合法 $\lambda_{\text{old}}, L_{\text{old}}, r_{\text{done}}, s_{\text{done}}, \text{numerical_failure}$, 诊断为 E 步 (r_{done}, s)
- 8 把有限 $\gamma_1, \sum_t \xi_t$ 和发射占用加入临时累计量, 令 $s_{\text{done}} \leftarrow s_{\text{done}} + 1$
- 9 **结束**
- 10 若 $u = \text{ML}$, 按原始期望计数形成 λ^+ ; 任一允许行分母为零时返回最后合法状态与 **numerical_failure**, 诊断为 ML M 步零计数行
- 11 若 $u = \text{MAP}$, 仅加预登记 Dirichlet 减一形成 λ^+ ; 候选计数为负、分母非正或先验支撑不一致时返回最后合法状态与 **numerical_failure**, 诊断为 MAP M 步参数行
- 12 保持禁止转移为零并核验 λ^+ 各行有限、非负、归一化; 失败则返回未改动的最后合法状态与 **numerical_failure**, 诊断为候选参数核验
- 13 按同一 u 计算 L^+ ; 若非有限或 $L^+ < L_{\text{old}} - \tau_{\text{num}}$, 则返回未改动的最后合法状态与 **numerical_failure**, 诊断为目标门禁及新旧值
- 14 原子提交 $\lambda \leftarrow \lambda^+, L \leftarrow L^+$ 及轨迹, 令 $r_{\text{done}} \leftarrow r_{\text{done}} + 1$; 记录后验变化与目标增量
- 15 **若** $|L - L_{\text{old}}| \leq \varepsilon_L(1 + |L_{\text{old}}|)$ **则**
- 16 返回最后合法 $\lambda, L, r_{\text{done}}, s_{\text{done}}, \text{numerical_failure}$, 最终诊断记录目标平台、ML/MAP 口径、后验变化及可用固定点残差
- 17 **结束**
- 18 **结束**
- 19 返回最后合法 $\lambda, L, r_{\text{done}}, s_{\text{done}}, \text{budget_stop}$, 最终诊断记录轮数预算耗尽与末轮目标增量

算法实现说明: Baum-Welch 的似然小变化只返回 **numerical_failure**; 固定点/KKT 残差未核验时不得写作 converged, 实际耗尽 R_{max} 才返回 **budget_stop**。完整 C1-C14 契约

21.5 Viterbi 预测算法

定义

$$\delta_t(i) = \max_{i_1, \dots, i_{t-1}} P(i_1, \dots, i_{t-1}, i_t = q_i, o_1, \dots, o_t \mid \lambda).$$

它保存所有以 i 结尾的前缀中概率最大者; $\psi_t(i)$ 保存实现最大值的前驱状态。

读前自检: 预测算法。 把隐马尔可夫模型中的预测算法放在 “ $I^* = \arg \max_I P(I \mid O, \lambda) = \arg \max_I P(O, I \mid \lambda)$,” 下考察: 把 I^* 展开一次并检查其类型或边界, 并检查展开后的量满足定义中的域、维数或符号限制。

预测目标是

$$I^* = \arg \max_I P(I | O, \lambda) = \arg \max_I P(O, I | \lambda),$$

因为对固定 O, λ , 分母 $P(O | \lambda)$ 与路径无关。

读前自检：近似算法。 隐马尔可夫模型中的近似算法要求先确认“若两条前缀都到达同一状态，未来扩展因子完全相同，只需保留概率更大的前缀及其回溯指针”；请随后检查 $i_t^* = \arg \max_i \gamma_t(i)$ 中每项的类型后完成等式变形，用两端运算均有定义、类型一致且化为同一结果验收。

逐时刻后验解码取 $i_t^* = \arg \max_i \gamma_t(i)$ 。它最大化每个位置正确的后验期望数，但不保证拼成的路径联合概率最大，也可能违反零转移约束。只有目标确实是逐位置损失时才应使用它。

动态规划复现。 若两条前缀都到达同一状态，未来扩展因子完全相同，只需保留概率更大的前缀及其回溯指针。

读前自检：Viterbi 算法。 Viterbi 递推维护最优路径分数 $\delta_t(i)$ 与回溯指针 $\psi_t(i)$ ；请完成一层最大-乘积更新，取 $i_T^* = \arg \max_i \delta_T(i)$ 后按 ψ 逐层回溯，核对得到长度 T 的合法状态路径。

递推为

$$\delta_1(i) = \pi_i b_i(o_1), \quad \psi_1(i) = 0,$$

$$\delta_t(i) = \max_j [\delta_{t-1}(j) a_{ji}] b_i(o_t), \quad \psi_t(i) = \arg \max_j [\delta_{t-1}(j) a_{ji}].$$

终止时 $i_T^* = \arg \max_i \delta_T(i)$ ，再按 $i_t^* = \psi_{t+1}(i_{t+1}^*)$ 回溯。

读前自检：Viterbi 算法。 Viterbi 算法输入“有限合法 HMM 参数 λ 、非空观测 O 、 $\log 0 = -\infty$ 约定及固定并列决胜规则”，条件“模型概率非负有限且归一化”；请做一轮“同一 DP 层的值和指针全部为有限或 $-\infty$ 且索引合法后才原子提交整层”，以“完整递推与回溯完成、发现零合法路径前缀或首次失败时停止”核对停止证书。

对数域 Viterbi 算法：五步阅读

输入。 写出数据对象、固定参数与必须成立的条件。

初始化。 标明主状态、计数器和第一个合法状态。

核心更新。 只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。 写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。 列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 21.5: 对数域 Viterbi 算法

输入: HMM 参数 λ ; 观测 $O = (o_1, \dots, o_T)$

输出: 最后合法 d, ψ, I^* 或无路径标记、对数概率、 $t_{\text{done}}, b_{\text{done}}, \text{status}$ 与最终诊断

数据: $\log 0 = -\infty$; 并列最优固定决胜规则; 零路径判据

- 1 $d, \psi \leftarrow \emptyset, I^* \leftarrow \emptyset, t_{\text{done}} \leftarrow 0, b_{\text{done}} \leftarrow 0$, 诊断为空
- 2 若 $T < 1$ 、观测越出字典, 模型维数/概率/归一化非法, 或对数、并列、零路径规则不合法, 则返回空 DP、计数 0、`invalid_input` 及字段诊断
- 3 在临时层计算 $d_1^+(i) = \log \pi_i + \log b_i(o_1)$ 、 $\psi_1^+(i) = 0$; 若含 NaN/+ ∞ , 则返回空 DP、`numerical_failure` 及首层状态 i 诊断
- 4 若所有 $d_1^+(i) = -\infty$, 则返回无路径标记、 $-\infty, t_{\text{done}} = 0, b_{\text{done}} = 0, \text{completed}$, 最终诊断记录零合法初始路径
- 5 原子提交 $d_1 \leftarrow d_1^+, \psi_1 \leftarrow \psi_1^+$ 并令 $t_{\text{done}} \leftarrow 1$
- 6 当 $t_{\text{done}} < T$ 执行
 - 7 令 $t \leftarrow t_{\text{done}} + 1$; 在临时层对每个 i, j 计算 $c_t(j, i) = d_{t-1}(j) + \log a_{ji}$
 - 8 若任一候选含 NaN/+ ∞ , 则返回最后合法 DP 与 `numerical_failure`, 诊断为候选位置 (t, j, i)
 - 9 对每个 i 按固定规则取最大前驱; 全为 $-\infty$ 时置 $d_t^+(i) = -\infty, \psi_t^+(i) = 0$, 否则写入合法指针和 $d_t^+(i) = \max_j c_t(j, i) + \log b_i(o_t)$
 - 10 若临时层含非法数或指针越界, 则返回最后合法 DP 与 `numerical_failure`, 诊断为层核验 (t, i)
 - 11 若所有 $d_t^+(i) = -\infty$, 则返回最后合法 DP、无路径标记、 $-\infty, t_{\text{done}}, b_{\text{done}} = 0, \text{completed}$, 最终诊断记录零合法观测前缀 t
 - 12 原子提交 $d_t \leftarrow d_t^+, \psi_t \leftarrow \psi_t^+$ 并令 $t_{\text{done}} \leftarrow t$
- 13 结束
- 14 按固定规则取有限终态 i_T^* 并暂存路径后缀; 若终态选择失败则返回最后合法 DP 与 `numerical_failure`, 诊断为终止阶段
- 15 对 $t \leftarrow T-1, T-2, \dots, 1$ 执行
 - 16 读取 $i_t^* \leftarrow \psi_{t+1}(i_{t+1}^*)$; 若指针越界则返回最后合法 DP 和已暂存后缀、`numerical_failure` 及回溯位置 t 诊断; 否则令 $b_{\text{done}} \leftarrow b_{\text{done}} + 1$
- 17 结束
- 18 提交完整 I^* ; 返回 $I^*, \max_i d_T(i), t_{\text{done}} = T, b_{\text{done}} = T-1, \text{completed}$, 最终诊断记录终态、并列次数与最大对数概率

算法实现说明: 有限 DP 有两类 `completed` 结果: 完整回溯得到最优路径, 或某层全为 $-\infty$ 并证明当前观测前缀无合法路径; 最终诊断明确结果类型。NaN、非法指针等才返回 `numerical_failure`。完整 C1-C14 契约

21.6 条件独立、复杂度与实现

概率图与条件独立复现。链式图中, 给定 i_t 后, 过去与未来由该状态分隔; 给定完整状态序列后, 各观测彼此独立。边缘化隐藏状态后, 观测之间通常仍相关。

到第 30 章的前向链接。若概率行向量 ρ 满足代数固定点方程 $\rho = \rho A$, 以 ρ 初始化会使隐藏状态的单时刻边缘分布保持不变; 本章只用这一有限时刻核验。固定点是否唯一、任意初值是否趋近它, 以及“不可约、非周期、遍历”等严格条件, 统一留到第 30 章。前向-后向、Baum-Welch 和 Viterbi 处理有限序列, 并不以那些长期定理为先修。

复杂度分析

预测时间复杂度。前向似然、后验边缘和 Viterbi 对每个时刻的 N 个终点扫描 N 个前驱，单序列均为 $O(TN^2)$ ；稀疏拓扑为 $O(TE)$ 。

存储与空间复杂度。只求似然可滚动保存两层，额外空间 $O(N)$ ；保存全部前向量或 Viterbi 回溯指针为 $O(TN)$ 。若显式保存所有 $\xi_t(i, j)$ 需 $O(TN^2)$ ，可在反向扫描时流式累计。**复杂度假设：**状态离散且转移矩阵稠密；连续观测只改变发射概率计算项。

异常、退化与停止情形。前向缩放因子为零表示观测在当前模型下没有合法路径；后向递推必须使用同一缩放约定；Viterbi 若终点全为 $-\infty$ ，应说明不存在可行路径。Baum-Welch 的零期望计数行按给定平滑或重启规则处理；达到最大轮数而似然容差仍未满足时，应报告末轮似然增量，不能把 EM 的单调性等同于全局最优。

数值实现。长序列概率连乘会下溢，应使用一致缩放或对数域。缩放因子不仅用于稳定数值，也用于恢复对数似然。多序列训练必须在序列边界重置初始分布，不能把不同个体首尾错误地连接成一次转移。

21.7 例题与练习

本节把概率计算、参数学习与序列预测放在同一模型流程中，比较五个算法的输入、递推量与适用条件。

生成复现。按 π 抽首状态，再交替按转移行和观测行抽样，序列边界重新初始化。**前向复现。**先乘首观测，随后按前驱求和并乘当前观测，末端对状态求和。**后向复现。**末端置 1，向前聚合“转移 - 下一观测 - 下一后向值”，可与前向交叉核对似然。**Baum-Welch 复现。**用 γ, ξ 形成期望计数并逐行归一化，每轮检查总对数似然不下降。**Viterbi 复现。**前向最大化并保存前驱，终点选择后反向回溯整条路径。

适用条件与局限性

适用条件。HMM 适合离散阶段随时间转移、每时刻观测主要由当前阶段解释、需要概率计算或路径解码的序列任务。转移结构应能表达领域允许路径，训练数据应覆盖主要状态和观测。

方法局限。一阶齐次假设可能过强；状态持续时间隐含为几何分布；状态数与语义通常不可识别；Baum-Welch 目标非凸且依赖初值；长程依赖、上下文相关发射和连续高维观测需要扩展模型；逐点后验与最优路径回答不同问题。

读前自检：常见错误与误用边界：例题与练习。例题与练习以“边界框首项禁止把 A 按列归一化却仍使用行向量约定”为约束；请把固定错误“把 A 按列归一化却仍使用行向量约定”中的对象、操作与结论按本节定义拆开，指出第一个不满足的定义条件，再把该处改为本节允许的写法，并确认改写后的运算或判断有定义，且不再触发“把 A 按列归一化却仍使用行向量约定”。

常见错误

典型误用包括：把 A 按列归一化却仍使用行向量约定；前向递推漏乘当前观测；后向递推误乘 o_t 而非 o_{t+1} ；把 α_t 当成归一化状态后验； ξ 漏掉转移或下一观测；Baum–Welch 分母时间范围写错；多序列首尾相连；零概率在对数域未设为 $-\infty$ ；Viterbi 不保存回溯指针；把逐点后验路径当成全局最优路径；用测试序列选择状态数。

读前自检：易混淆概念对比：例题与练习。 先锁定例题与练习的条件“对比表首个数据行是“目标 | 路径概率求和与后验 | 提高观测似然 | 最大概率单路径””：按列复述“目标 | 路径概率求和与后验 | 提高观测似然 | 最大概率单路径”中的对象、假设与结论，所得结果应满足各列均对应首行对象“目标”，且未与表中下一行互换。

易混淆概念对比			
维度	前向 – 后向	Baum–Welch	Viterbi
目标	路径概率求和与后验	提高观测似然	最大概率单路径
参数是否更新	否	是	否
聚合运算	求和 – 乘积	E 步求和，M 步归一化	最大 – 乘积
主要输出	$P(O), \gamma, \xi$	A, B, π	路径与回溯指针
典型复杂度	$O(TN^2)$	每轮 $O(TN^2)$	$O(TN^2)$

例题 21.2 (两状态 HMM 的 Viterbi 路径). 沿用第 21.3 节的数值模型与观测 $O = (R, B)$ 。求 Viterbi 最优路径，并与观测概率区分。

例题 21.2 解答

读题翻译 这里要最大化单条隐藏路径与观测的联合概率；不能把前向算法的路径概率总和或逐时刻边缘最大状态当作 Viterbi 答案。

已知与合法条件 沿用同一合法 HMM 和 $O = (R, B)$ ；首层最优前缀为 $\delta_1 = (0.30, 0.04)$ ，每个第二时刻终态都必须比较两个前驱并保存获胜指针。

为什么想到这个方法 Viterbi 采用最大 – 乘积递推：到达同一终态的前缀共享相同未来，因此只保留较大联合概率及其前驱，再由最优终态回溯。

方法选择 初始化 δ_1 ，分别计算 $\delta_2(1), \delta_2(2)$ 和 ψ_2 ；选取最大终态并回溯，最后枚举四条路径核对最大值与前向总和的区别。

推导/计算 初始化 $\delta_1 = (0.30, 0.04)$ 。到时刻 2:

$$\delta_2(1) = \max\{0.30(0.7), 0.04(0.4)\}(0.5) = 0.105, \quad \psi_2(1) = 1,$$
$$\delta_2(2) = \max\{0.30(0.3), 0.04(0.6)\}(0.9) = 0.081, \quad \psi_2(2) = 1.$$

独立核验 四条路径概率为 0.105, 0.081, 0.008, 0.0216, 唯一最大值是 0.105; 四项之和 0.2156 等于前向观测概率, 验证“最大”与“求和”没有混用。

结论 Viterbi 唯一最优路径为 (1, 1), 联合概率为 0.105; 观测概率仍为全部路径之和 0.2156。

卡住时先看 先算首层两个 δ_1 , 再对第二层每个终态分别比较两个前驱。

方法迁移 把递推中的“最大”换成“求和”得到前向算法; 但 Viterbi 还必须保存 ψ , 否则无法恢复整条路径。

本章共 18 道练习。每道题干后立即给出同号解析; 长解析可自然跨页, 续页标题保留题号。

练习 21.1. 设二状态链转移矩阵为 $A = \begin{pmatrix} 0.8 & 0.2 \\ 0.3 & 0.7 \end{pmatrix}$, 当前分布为 (0.6, 0.4)。求下一时刻分布。

练习 21.1 解析

以行向量表示当前分布 $p_t = (0.6, 0.4)$, 状态更新为

$$\begin{aligned} p_{t+1} &= p_t A \\ &= (0.6, 0.4) \begin{pmatrix} 0.8 & 0.2 \\ 0.3 & 0.7 \end{pmatrix} \\ &= (0.60, 0.40). \end{aligned}$$

归一化核验为

$$p_{t+1}(i) \geq 0, \quad 0.60 + 0.40 = 1.$$

结果与 p_t 相同, 所以该分布还是此链的平稳分布。

练习 21.2. 为什么一阶马尔可夫性质不推出 i_{t+1} 与 i_{t-1} 边缘独立?

练习 21.2 解析

一阶马尔可夫性质给出的是

$$I_{t+1} \perp I_{t-1} \mid I_t, \quad P(i_{t+1} \mid i_t, i_{t-1}) = P(i_{t+1} \mid i_t).$$

边缘化中间状态后却有

$$P(i_{t+1} \mid i_{t-1}) = \sum_{i_t} P(i_{t+1} \mid i_t) P(i_t \mid i_{t-1}),$$

右侧一般随 i_{t-1} 变化。因此删除条件变量 I_t 后, I_{t+1} 与 I_{t-1} 通常仍相关。

练习 21.3. 写出长度 3 状态路径 (i_1, i_2, i_3) 和观测 (o_1, o_2, o_3) 的联合概率。

练习 21.3 解析

对合法状态 i_t 与观测 o_t , HMM 联合概率按初始化、转移与发射分解:

$$\begin{aligned} P(O, I | \lambda) &= P(i_1)P(o_1 | i_1)P(i_2 | i_1)P(o_2 | i_2) \\ &\quad \cdot P(i_3 | i_2)P(o_3 | i_3) \\ &= \pi_{i_1} b_{i_1}(o_1) a_{i_1 i_2} b_{i_2}(o_2) a_{i_2 i_3} b_{i_3}(o_3). \end{aligned}$$

每个转移只连接相邻状态, 每个发射只依赖同一时刻状态。

练习 21.4. 检查 $A = \begin{pmatrix} 0.4 & 0.6 \\ 0.2 & 0.7 \end{pmatrix}$ 能否作为转移矩阵; 若不能, 指出原因。

练习 21.4 解析

合法转移矩阵要求

$$a_{ij} \geq 0, \quad \sum_j a_{ij} = 1 \quad \text{对每一行 } i.$$

题设矩阵的行和为

$$0.4 + 0.6 = 1, \quad 0.2 + 0.7 = 0.9 \neq 1,$$

所以它不是合法转移矩阵。若输入只是未归一化非负权重, 必须显式改成

$$(0.2, 0.7)/0.9 = (2/9, 7/9),$$

不能在算法中静默接受原矩阵。

练习 21.5. 对固定状态路径 I , 计算 $P(O, I | \lambda)$ 属于三个基本问题中的哪一步? 它为何还不是观测概率?

练习 21.5 解析

固定路径 $I = (i_1, \dots, i_T)$ 时, 计算的是一个联合路径贡献

$$P(O, I | \lambda) = \pi_{i_1} b_{i_1}(o_1) \prod_{t=2}^T a_{i_{t-1} i_t} b_{i_t}(o_t).$$

观测概率属于概率计算问题, 需边缘化全部 N^T 条路径:

$$P(O | \lambda) = \sum_{I \in \{1, \dots, N\}^T} P(O, I | \lambda).$$

单一路径只是一项, 不能替代路径和。

练习 21.6. 说明逐时刻求 $\arg \max_i P(i_t = i | O)$ 和求 $\arg \max_I P(I | O)$ 分别属于什么输出，二者为何可能不同。

练习 21.6 解析

逐时刻后验解码输出

$$\hat{i}_t^{\text{marg}} \in \arg \max_i P(I_t = i | O), \quad t = 1, \dots, T.$$

Viterbi 输出整条 MAP 路径

$$\hat{I}^{\text{MAP}} \in \arg \max_I P(I | O) = \arg \max_I P(O, I | \lambda),$$

其中 $P(O | \lambda)$ 对 I 为常数。逐点最大边缘可能来自不同高概率路径，其拼接甚至可能含非法转移，故一般不等于整条 MAP 路径。

练习 21.7. 若某时刻 $\alpha_t = (0.12, 0.08)$ 、 $\beta_t = (0.5, 1.0)$ ，求归一化后的 γ_t 。

练习 21.7 解析

单点后验的未归一化权重为

$$u_i = \alpha_t(i)\beta_t(i), \quad u = (0.12 \cdot 0.5, 0.08 \cdot 1) = (0.06, 0.08).$$

归一化常数与后验为

$$\sum_i u_i = 0.14 > 0, \quad \gamma_t = \frac{u}{0.14} = \left(\frac{3}{7}, \frac{4}{7}\right).$$

两个分量非负且和为 1。

练习 21.8. 证明对每个 $t < T$ 有 $\sum_j \xi_t(i, j) = \gamma_t(i)$ 。

练习 21.8 解析

先假设 $P(O | \lambda) > 0$ 。相邻后验为

$$\xi_t(i, j) = \frac{\alpha_t(i)a_{ij}b_j(o_{t+1})\beta_{t+1}(j)}{P(O | \lambda)}.$$

对 j 求和并使用后向递推，得到

$$\begin{aligned} \sum_j \xi_t(i, j) &= \frac{\alpha_t(i) \sum_j a_{ij}b_j(o_{t+1})\beta_{t+1}(j)}{P(O | \lambda)} \\ &= \frac{\alpha_t(i)\beta_t(i)}{P(O | \lambda)} \\ &= \gamma_t(i). \end{aligned}$$

若 $P(O | \lambda) = 0$ ，两个后验分母均未定义，应停止并检查模型支撑。

练习 21.9. 比较只求 $P(O)$ 与还要保存全部 γ_t 时的空间需求。

练习 21.9 解析

只求 $P(O)$ 时, 前向状态更新为

$$\alpha_t(j) = b_j(o_t) \sum_i \alpha_{t-1}(i) a_{ij},$$

只需滚动保存两层 N 维向量, 所以

$$S_{P(O)} = O(N).$$

若要输出全部 $\gamma_t(i)$, 通常保存 T 层前向量并反向扫描, 故

$$S_\gamma = O(TN),$$

也可用检查点与重算换取较低空间和较高时间。

练习 21.10. 某状态 i 的期望转移计数为 $i \rightarrow 1 : 2.4$ 、 $i \rightarrow 2 : 1.6$ 。求新转移行。

练习 21.10 解析

该行总期望转移计数为

$$N_i = 2.4 + 1.6 = 4 > 0.$$

逐行归一化得到

$$a_{i1}^{\text{new}} = \frac{2.4}{4} = 0.6, \quad a_{i2}^{\text{new}} = \frac{1.6}{4} = 0.4.$$

于是

$$a_{ij}^{\text{new}} \geq 0, \quad \sum_j a_{ij}^{\text{new}} = 1.$$

若拓扑禁止某条转移, E 步与归一化必须始终使用同一可行支持。

练习 21.11. 从带约束目标 $\sum_{i,j} n_{ij} \log a_{ij}$ 推导固定 i 时 $a_{ij} = n_{ij} / \sum_r n_{ir}$ 。

练习 21.11 解析

固定 i 并令 $N_i = \sum_j n_{ij} > 0$ 。优化问题为

$$\max_{a_i:} \sum_j n_{ij} \log a_{ij}, \quad a_{ij} \geq 0, \quad \sum_j a_{ij} = 1.$$

对正计数坐标写拉格朗日驻点:

$$\frac{n_{ij}}{a_{ij}} - \eta_i = 0 \implies a_{ij} = \frac{n_{ij}}{\eta_i}, \quad \sum_j a_{ij} = 1 \implies \eta_i = N_i.$$

因此

$$a_{ij}^{\text{new}} = \frac{n_{ij}}{\sum_r n_{ir}}.$$

练习 21.11 解析 (续)

零计数坐标由边界 KKT 处理; 若 $N_i = 0$, 整行不可识别, 公式成为 $0/0$, 须按预先规定的伪计数、保留或重初始化规则处理。

练习 21.12. 若某状态在 E 步中的总期望占用为零, 直接使用更新公式会怎样? 给出可复现处理方案。

练习 21.12 解析

若状态 i 的总期望占用为零, 则典型更新为

$$a_{ij}^{\text{new}} = \frac{n_{ij}}{\sum_r n_{ir}} = \frac{0}{0},$$

没有定义。可复现方案必须在训练前固定, 例如 Dirichlet 伪计数

$$a_{ij}^{\text{new}} = \frac{n_{ij} + \beta_{ij}}{\sum_r (n_{ir} + \beta_{ir})}, \quad \beta_{ij} > 0,$$

或保留上一轮合法行、重初始化状态; 不同选择对应不同估计规则, 不能由测试表现临时决定。

练习 21.13. 某时刻到状态 1 的两个候选前缀值为 0.08, 0.12, 对应转移概率为 0.5, 0.2, 当前观测概率为 0.4。求 $\delta_t(1)$ 及回溯前驱。

练习 21.13 解析

到状态 1 的两个候选转移前缀为

$$c_1 = 0.08 \times 0.5 = 0.04, \quad c_2 = 0.12 \times 0.2 = 0.024.$$

递推与指针为

$$\begin{aligned} \psi_t(1) &= \arg \max\{c_1, c_2\} = \text{第一前驱}, \\ \delta_t(1) &= \max\{c_1, c_2\} \times 0.4 \\ &= 0.04 \times 0.4 = 0.016. \end{aligned}$$

观测因子对固定终点相同, 不改变前驱比较, 但必须乘入最优前缀值。

练习 21.14. 为什么只保存每层最大 δ 值而不保存 ψ , 通常无法恢复整条最优路径?

练习 21.14 解析

Viterbi 状态与前驱分别为

$$\delta_t(j) = b_j(o_t) \max_i \delta_{t-1}(i) a_{ij}, \quad \psi_t(j) \in \arg \max_i \delta_{t-1}(i) a_{ij}.$$

终止只给出

$$i_T^* \in \arg \max_j \delta_T(j),$$

练习 21.14 解析 (续)

而 $\delta_T(j)$ 不编码获胜前驱身份。保存全部 $\psi_t(j)$ 需 $O(TN)$ 空间, 并允许按

$$i_{t-1}^* = \psi_t(i_t^*)$$

线性回溯; 否则必须重算或枚举前缀。

练习 21.15. 验证 $(0.6, 0.4)$ 是 $A = \begin{pmatrix} 0.8 & 0.2 \\ 0.3 & 0.7 \end{pmatrix}$ 的平稳分布。

练习 21.15 解析

候选分布 $p = (0.6, 0.4)$ 满足 $p_i \geq 0$ 且 $\sum_i p_i = 1$ 。右乘转移矩阵得到

$$\begin{aligned} pA &= (0.6, 0.4) \begin{pmatrix} 0.8 & 0.2 \\ 0.3 & 0.7 \end{pmatrix} \\ &= (0.6 \cdot 0.8 + 0.4 \cdot 0.3, 0.6 \cdot 0.2 + 0.4 \cdot 0.7) \\ &= (0.6, 0.4) = p. \end{aligned}$$

因此 $pA = p$, 它是平稳分布; 固定点核验本身不证明唯一性, 唯一性还需链结构条件。

练习 21.16. 一个二状态链只允许 $1 \rightarrow 2$ 和 $2 \rightarrow 1$, 且两条转移概率均为 1。从状态 1 出发写出前四个时刻的状态, 并说明这种交替结构是否妨碍有限长度前向或 Viterbi 递推。

练习 21.16 解析

转移矩阵为

$$A = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}.$$

从状态 1 出发, 前四个时刻依次为 1, 2, 1, 2; 允许路径被拓扑唯一确定并呈两步交替。有限长度前向递推仍可沿允许边求和, Viterbi 也仍可沿允许边取最大并回溯, 因此二者不需要先判断任何长期遍历性质。若要讨论任意初始分布的长期极限, 再转到第 30 章学习严格条件。

练习 21.17. 在代表例题中, 计算路径 $(1, 2)$ 的联合概率, 并验证它对应 $\delta_2(2)$ 的获胜前驱。

练习 21.17 解析

路径 $(1, 2)$ 的联合概率为

$$P(O, I = (1, 2) \mid \lambda) = \pi_1 b_1(R) a_{12} b_2(B) = 0.6(0.5)(0.3)(0.9) = 0.081.$$

另一个到状态 2 的前驱路径为

$$P(O, I = (2, 2) \mid \lambda) = 0.4(0.1)(0.6)(0.9) = 0.0216.$$

因此

$$0.081 > 0.0216 \implies \delta_2(2) = 0.081, \quad \psi_2(2) = 1,$$

练习 21.17 解析 (续)

与例题回溯指针一致。

练习 21.18. 设计一个前向与后向实现的交叉检查，不依赖已知答案。

练习 21.18 解析

对同一合法模型和观测，未缩放前向量 α_t 与后向量 β_t 应满足三种一致的似然表达：

$$P(O) = \sum_i \alpha_T(i) = \sum_i \pi_i b_i(o_1) \beta_1(i) = \sum_i \alpha_t(i) \beta_t(i) \quad (1 \leq t \leq T).$$

若实现采用本章算法 21.2–21.3 的缩放约定，则不能把帽变量直接代入上式；应改查

$$\sum_i \hat{\alpha}_t(i) \hat{\beta}_t(i) = 1, \quad \log P(O) = \sum_{t=1}^T \log c_t.$$

后验还应满足

$$\sum_i \gamma_t(i) = 1, \quad \sum_{i,j} \xi_t(i,j) = 1, \quad \sum_j \xi_t(i,j) = \gamma_t(i).$$

将这些等式的最大绝对残差与预定浮点容差比较，超差即报告时间下标、归一化或缩放错误。

读前自检：本章结论与下一步。 隐马尔可夫模型章末把“隐藏状态链、观测序列、转移与发射概率”收束为“Baum–Welch 用期望计数逐行归一化”；请把 γ, ξ 代入对应定义并写出结果类型，再核对“代入结果满足定义域与取值域”且该结果能直接进入章末所述方法。

本章结论与下一步

核心结论： 隐藏状态链、观测序列、转移与发射概率

关键依据： 前向 – 后向把路径求和化为动态规划并构造 γ, ξ 后验

可执行自检： Baum–Welch 用期望计数逐行归一化；Viterbi 用最大递推和前驱回溯选择单路径

适用边界： 序列具有一阶隐藏状态依赖且状态/观测空间有限时

下一步： 进入 CRF；若观测概率、零占用行或缩放自检失败则返回本章对应递推与更新节

1. 能否写出 HMM 两项条件独立假设和完整联合概率分解，解释观测为何边缘相关，并区分概率计算、学习、逐点后验和最优路径四类目标？
2. 能否分三步推出前向递推，并独立写出后向递推、 γ 与 ξ ？
3. 能否从期望计数推导 Baum–Welch 三组更新并处理零分母、多序列和拓扑约束？
4. 能否在对数域写出 Viterbi 初始化、递推、终止与回溯，并解释回溯指针的空间成本？
5. 能否核验 $\rho = \rho A$ 这一代数固定点，并说明有限序列推断不以第 30 章的长期马尔可夫链定理为先修，同时设计数值与数据泄漏检查？若未通过，应依次回看第 21.1–21.2 节的模型结构、第 21.3 节的求和递推、第 21.4–21.5 节的学习与预测，以及第 21.6–21.7 节的实现边界。

第 22 章 条件随机场

读前自检：本章地图：条件随机场。 条件随机场章地图以“从图马尔可夫性直达线性链 CRF、前后向与 Viterbi”组织内容；请把路线拆成起点、关键工具和终点，并核对三者的输入输出类型能依次衔接。

读前自检：本章可检验学习目标。 条件随机场目标中的“从条件独立、团、势函数和归一化出发理解概率无向图模型的因子分解”必须可复核；请从条件独立、团、势函数和归一化出发理解概率无向图模型的因子分解，所得结果仅在“中间结果逐项包含首目标“从条件独立、团、势函数和归一化出发理解概率无向图模型的因子分解”声明的对象、条件与结论”时通过。

读前自检：最短先修。 条件随机场的最短先修明确要求“本章需要联合概率、条件概率、条件独立、指数族、极大似然、凸函数、梯度、Hessian、BFGS 和动态规划”；请把首项“本章需要联合概率、条件概率、条件独立、指数族、极大似然、凸函数、梯度、Hessian、BFGS 和动态规划”中的第一个先修对象写成定义域 – 运算 – 输出三元组，并以“该三元组逐项满足首项“本章需要联合概率、条件概率、条件独立、指数族、极大似然、凸函数、梯度、Hessian、BFGS 和动态规划”的对象类型与成立条件”判断能否进入本章。

读前自检：先修自检。 条件随机场先修自检固定核验“能否把 $A \perp B | C$ 写成条件概率乘积关系，并说明分母为零时为何不能使用比值形式”；请把 $A \perp B | C$ 写成条件概率乘积关系，并说明分母为零时为何不能使用比值形式并写出中间结果，再按“ $A \perp B | C$ 的计算或证明结果满足首项所列等式、定义域或判断”明确判为通过或失败。

读前自检：依赖路线。 条件随机场依赖链含“条件独立 → 无向图马尔可夫性 → 最大团因子分解”到“势函数 → 条件指数族 → 线性链条件随机场”这一跳；请固定写出前者输出类型与后者输入类型，并核对两者相同或存在正文声明的转换。

本章地图

核心问题： 怎样在给定观测时联合建模整条标签序列

可检验学习目标：

- 从条件独立、团、势函数和归一化出发理解概率无向图模型的因子分解；
- 写出一般条件随机场与线性链条件随机场的严格定义，并在局部特征、全局特征和矩阵三种表示之间转换；
- 用前向 – 后向递推计算规范化因子、单点/相邻点边缘概率和特征期望；
- 从条件对数似然推导梯度与 Hessian，理解改进迭代尺度和 BFGS 学习；
- 用 Viterbi 动态规划求最优标记序列，并分析学习、推断与预测的时间和空间复杂度。

最短先修：本章需要联合概率、条件概率、条件独立、指数族、极大似然、凸函数、梯度、Hessian、BFGS 和动态规划。序列写为 $x = (x_1, \dots, x_n)$ 与 $y = (y_1, \dots, y_n)$ ，真实标签集合记为 $\mathcal{Y}$ ，大小 $m = |\mathcal{Y}|$ ；加入两个仅用于边界计算的状态后，明确记

$$\bar{\mathcal{Y}} = \mathcal{Y} \cup \{\text{start}, \text{stop}\}, \quad \bar{m} = |\bar{\mathcal{Y}}| = m + 2.$$

边界状态不属于 $\mathcal{Y}$ ，也不会成为真实位置的预测标签。条件随机场只建模 $P(Y | X)$ ，不要求为观测序列 X 指定生成分布。

依赖路线：条件独立 $\rightarrow$ 无向图马尔可夫性 $\rightarrow$ 最大团因子分解；势函数 $\rightarrow$ 条件指数族 $\rightarrow$ 线性链条件随机场；链式因子 $\rightarrow$ 前向 - 后向 $\rightarrow$ 边缘概率与特征期望；条件似然 $\rightarrow$ 梯度/曲率 $\rightarrow$ IIS 或 BFGS 学习；加性路径得分 $\rightarrow$ 最优子结构 $\rightarrow$ Viterbi 预测。

完成标准与返回：图分解条件不清时回到节 22.1；概率或解码递推失败时回看节 22.4、22.5

模型认识卡：条件随机场

任务与输入：给定观测 x 联合标注有限标签序列 y 。 **输出类型：**条件序列概率、边缘概率或 MAP 路径。

模型： $P_w(y | x) \propto \exp\{w^\top F(y, x)\}$ ，仅对合法路径归一化。 **策略：**最大化正则化条件似然。

算法：前向 - 后向求配分函数与梯度，BFGS 学习，Viterbi 解码。

预测：取全局最大得分合法路径。 **关键假设与边界：**标签链局部依赖、合法支持非空；禁止转移为零但合法路径权重严格为正。

本章符号表

符号	取值或维数	含义
$G = (V, E)$	无向图	随机变量之间的依赖结构
C, Y_C	结点子集	团及团中随机变量
$\psi_C(Y_C)$	$(0, \infty)$	团上的势函数
X, Y	随机序列	观测序列与标记序列
$\mathcal{Y}, m$	有限集、正整数	真实标签集合及其大小 $m = \mathcal{Y} $
$\bar{\mathcal{Y}}$	有限集，大小 $\bar{m} = m + 2$	加入起点和终点后的计算状态集
$f_k(y_{i-1}, y_i, x, i)$	$\mathbb{R}$	第 k 个局部特征函数
$F_k(y, x)$	$\mathbb{R}$	第 k 个全局特征总和
$w \in \mathbb{R}^K$	参数向量	全部特征权重
$M_i(x)$	$\mathbb{R}_+^{\bar{m} \times \bar{m}}$	含边界状态的非负局部因子矩阵
α_i, β_i	$\mathbb{R}_+^{\bar{m}}$	前向与后向非规范化权重
$Z_w(x)$	$(0, \infty)$	给定 x 的规范化因子

22.1 概率图、因子与势函数

序列标注需要同时利用观测与相邻标签关系。若为所有标签序列逐一指定概率，参数量和求和规模都随长度指数增长；图结构把全局分布拆成局部因子，使条件独立、计算和参数共享能够统一表达。

读前自检：因子到条件概率的概念桥。 CRF 局部因子相乘只给出合法路径的非规范化权重；请对全部合法标签路径求和得到 $Z(x)$ ，再用单条路径权重除以 $Z(x)$ ，核对所得条件概率非负且总和为 1。

因子到条件概率的概念桥

因子是作用在少量变量上的非负函数；严格正的因子常称**势函数**，它本身不是概率。把一条合法路径的局部因子相乘，得到**非规范化权重**；对所有合法路径求和得到**配分函数** $Z(x)$ ，再用权重除以 $Z(x)$ 才得到条件概率。**合法路径**从 **start** 出发、只走允许转移并在 **stop** 结束；禁止转移由硬因子 0 编码，不要求对这些非法路径谈严格正性。

概率图模型用结点表示随机变量，用边或有向箭头表达直接依赖。无向图中的“无边”只有结合分隔集合和马尔可夫性质才具有条件独立含义，不能把任意未相连结点解释为无条件独立。成对、局部和全局马尔可夫性从不同尺度描述同一结构，在严格正分布下可与最大团因子分解联系起来。

读前自检：条件随机场。 条件随机场要求先确认“条件随机场是给定输入随机变量 X 时，输出随机变量 Y 构成马尔可夫随机场的条件概率模型”；请随后把“条件随机场是给定输入随机变量 X 时，输出随机变量 Y 构成马尔可夫随机场的条件概率模型”中的已声明对象代回条件随机场的定义，用对象、条件与结论逐项闭合，且每项都可直接判为成立或失败验收。

条件随机场是给定输入随机变量 X 时，输出随机变量 Y 构成马尔可夫随机场的条件概率模型。它把输入序列视为已知条件，允许特征同时依赖整个 x 与局部标签，从而避免 HMM 必须生成观测的限制。

读前自检：概率无向图模型。 从概率无向图模型的条件“ P 满足图 G 给出的全局马尔可夫性：当结点集 C 在图中分隔 A 与 B 时”出发，请把 $P(Y_v | Y_{V \setminus \{v\}})$ 在其支持上求和或积分一次；所得量应符合全局形式更适合从图上读取独立关系，局部形式更适合设计局部计算。

读前自检：模型定义。 条件随机场中的模型定义依赖“ P 满足图 G 给出的全局马尔可夫性：当结点集 C 在图中分隔 A 与 B 时”；请据此把 $P(Y_v | Y_{V \setminus \{v\}})$ 展开一次并检查其类型或边界，并直接核对全局形式更适合从图上读取独立关系，局部形式更适合设计局部计算。

读前自检：概率无向图模型的马尔可夫性质。 概率无向图模型的马尔可夫性质以“ P 满足图 G 给出的全局马尔可夫性：当结点集 C 在图中分隔 A 与 B 时”为约束；请把 $P(Y_v | Y_{V \setminus \{v\}})$ 在其支持上求和或积分一次，并确认全局形式更适合从图上读取独立关系，局部形式更适合设计局部计算。

读前自检：概率无向图模型。 先锁定概率无向图模型的条件“对每个最大团 C 给定严格正势函数 $\psi_C(y_C)$ ”：把 $P(y)$ 在其支持上求和或积分一次，所得结果应满足势函数不是边缘概率，不要求单独求和为 1，整体乘积经 Z 归一化后才成为分布。

定义 22.1 (概率无向图模型). 设 $Y = (Y_v)_{v \in V}$ 具有联合分布 $P(Y)$, 无向图 $G = (V, E)$ 的每个结点 v 对应 Y_v . 若 P 满足图 G 给出的全局马尔可夫性: 当结点集 C 在图中分隔 A 与 B 时,

$$Y_A \perp Y_B \mid Y_C,$$

则称 P 是由 G 表示的概率无向图模型或马尔可夫随机场。

局部马尔可夫性把结点 v 与其邻居集合 $N(v)$ 之外的变量分离:

$$P(Y_v \mid Y_{V \setminus \{v\}}) = P(Y_v \mid Y_{N(v)}),$$

其中等式只在相应条件事件概率为正时解释。全局形式更适合从图上读取独立关系, 局部形式更适合设计局部计算。

读前自检: 团与最大团。 对团与最大团, 条件“若再加入任何结点都会破坏这一性质”不可省; 请把“若再加入任何结点都会破坏这一性质”中的已声明对象代回团与最大团的定义, 再用最大团不是结点数最大的团, 而是不能被严格包含于更大团的团作检查。

无向图中任意两结点都有边相连的结点子集称为团; 若再加入任何结点都会破坏这一性质, 则为最大团。最大团不是结点数最大的团, 而是不能被严格包含于更大团的团。

读前自检: 因子分解、势函数与归一化。 因子分解、势函数与归一化把问题限定在“对每个最大团 C 给定严格正势函数 $\psi_C(y_C)$ ”; 请把 $P(y)$ 展开一次并检查其类型或边界, 检查是否得到势函数不是边缘概率, 不要求单独求和为 1, 整体乘积经 Z 归一化后才成为分布。

读前自检: 概率无向图模型的因子分解。 在“对每个最大团 C 给定严格正势函数 $\psi_C(y_C)$ ”成立时处理概率无向图模型的因子分解: 请把 $P(y)$ 在其支持上求和或积分一次, 并以势函数不是边缘概率, 不要求单独求和为 1, 整体乘积经 Z 归一化后才成为分布判定结果。

对每个最大团 C 给定严格正势函数 $\psi_C(y_C)$, 定义

$$P(y) = \frac{1}{Z} \prod_C \psi_C(y_C), \quad Z = \sum_y \prod_C \psi_C(y_C).$$

Z 把所有非规范化权重归一化。常写 $\psi_C(y_C) = \exp\{-E_C(y_C)\}$; 势函数不是边缘概率, 不要求单独求和为 1, 整体乘积经 Z 归一化后才成为分布。

读前自检: Hammersley-Clifford 定理。 Hammersley-Clifford 定理所用的明确前提是“严格正性保证当前定义中的对数有限”; 完成把 $\sum_{y_A, y_B} g(y_A, y_C) h(y_B, y_C)$ 用到的关键定义展开并完成下一步变形后, 核对由于没有最大团能够同时跨越被 C 分隔的 A 与 B 。

定理 22.1 (合法支持上的 Hammersley–Clifford 因子分解) 设 Ω 是由 G 的局部硬约束给出的非空有限合法配置空间, $P(y) = 0$ 对 $y \notin \Omega$, 且 $P(y) > 0$ 对每个 $y \in \Omega$ 。把这些硬约束作为取值 0/1 的团因子后, 若 P 在合法支持上满足 G 的马尔可夫性, 则存在严格正的软团势 ψ_C , 使

$$P(y) = \frac{\mathbb{I}\{y \in \Omega\}}{Z} \prod_C \psi_C(y_C).$$

反向地, 这种“局部硬因子 $\times$ 严格正软势”的分解在合法条件事件上满足 G 给出的全局马尔可夫性。无硬约束时 Ω 就是全部配置, 退化为通常定理。

读前自检: 证明: 合法支持上的 Hammersley–Clifford 因子分解。 若 P 由 G 的局部 0/1 硬团因子与严格正软团势分解, 且 S 分隔 $A, B, P(y_S) > 0$, 请按两侧重组因子并归一化, 核对 $Y_A \perp Y_B \mid Y_S$ 。

证明. 先把描述 Ω 的局部 0/1 硬因子提出; 它们只删除非法配置, 不参与取对数。固定一个合法基准配置 y^0 , 在合法支持上记 $h(y) = \log P(y)$; 严格正性保证这里的对数有限。对与局部硬约束相容的坐标块 $D \subseteq V$ 定义 Möbius 交互项

$$\theta_D(y_D) = \sum_{B \subseteq D} (-1)^{|D \setminus B|} h(y_B, y_{V \setminus B}^0).$$

布尔格上的 Möbius 反演逐项给出

$$h(y) = \sum_{D \subseteq V} \theta_D(y_D).$$

若 D 不是团, 则其中含有一对不相邻结点 u, v 。由严格正分布的图马尔可夫性可取成对形式 $Y_u \perp Y_v \mid Y_{V \setminus \{u, v\}}$ 。因此对任意其余变量配置 c , 条件优势比为 1, 即

$$h(y_u, y_v, c) - h(y_u, y_v^0, c) - h(y_u^0, y_v, c) + h(y_u^0, y_v^0, c) = 0.$$

在 θ_D 的交替和中, 先按是否含 u, v 把合法四项配对, 上式使每一组都抵消, 故 $\theta_D \equiv 0$ 。所以合法支持上的 h 只含团上的交互项。将每个非最大团项分配给任一包含它的最大团, 并令 $\psi_C(y_C) = \exp\{\sum_{D \supset C} \theta_D(y_D)\} > 0$, 便有 $P(y) = Z^{-1} \mathbb{I}\{y \in \Omega\} \prod_C \psi_C(y_C)$; 常数项吸收到 Z 中。这完成正向构造。

再证因子分解到全局马尔可夫性。设 C 分隔 A 与 B 。把全部最大团因子按是否涉及 A 归入第一组, 其余归入第二组; 由于没有最大团能够同时跨越被 C 分隔的 A 与 B , 可写

$$P(y_A, y_B, y_C) = Z^{-1} g(y_A, y_C) h(y_B, y_C).$$

固定 y_C 并分别对 y_A, y_B 求和, 条件分布的归一化常数分解为

$$\sum_{y_A, y_B} g(y_A, y_C) h(y_B, y_C) = \left(\sum_{y_A} g \right) \left(\sum_{y_B} h \right).$$

因此 $P(y_A, y_B | y_C) = P(y_A | y_C)P(y_B | y_C)$ ，全局马尔可夫性成立。两个方向都已证明。 $\square$




图 22.1 线性链 CRF 的边界状态、相邻标签因子与已知观测依赖

图 22.1 显示：给定整段观测 x 后，标签之间只保留相邻边，局部势仍可读取整个 x 。链结构提供动态规划所需的最优子结构，并不意味着特征只能依赖相邻观测。

22.2 线性链条件随机场

序列标注给定观测 $x = (x_1, \dots, x_n)$ ，输出同长度标签 $y = (y_1, \dots, y_n)$ 。逐位置独立分类忽略相邻标签约束，而枚举 m^n 条序列代价过高。线性链条件随机场用相邻标签因子保留结构，再以动态规划完成求和和最大化。

读前自检：条件随机场的定义与形式。 条件随机场的定义与形式中的“设 X, Y 为随机变量， $P(Y | X)$ 为给定 X 时 Y 的条件分布”决定可执行范围；请把 $P(Y_v | X, Y_{V \setminus \{v\}})$ 展开一次并检查其类型或边界，结果须满足展开后的量满足定义中的域、维数或符号限制。

读前自检：条件随机场的定义。 把条件随机场的定义放在“设 X, Y 为随机变量， $P(Y | X)$ 为给定 X 时 Y 的条件分布”下考察：把 $P(Y_v | X, Y_{V \setminus \{v\}})$ 展开一次并检查其类型或边界，并检查展开后的量满足定义中的域、维数或符号限制。

读前自检：一般条件随机场。 一般条件随机场要求先确认“设 X, Y 为随机变量， $P(Y | X)$ 为给定 X 时 Y 的条件分布”；请随后把 $P(Y_v | X, Y_{V \setminus \{v\}})$ 展开一次并检查其类型或边界，用展开后的量满足定义中的域、维数或符号限制验收。

读前自检：条件随机场。 从条件随机场的条件“当 $Y_1, \dots, Y_n$ 构成链时”出发，请把 $P(Y_i | X, Y_{-i})$ 展开一次并检查其类型或边界；所得量应符合注意整个观测序列 X 都可以进入局部特征，链结构只限制标签之间的直接依赖。

定义 22.2 (条件随机场). 设 X, Y 为随机变量， $P(Y | X)$ 为给定 X 时 Y 的条件分布。若对无向图 $G = (V, E)$ 中的每个结点 v 都有

$$P(Y_v | X, Y_{V \setminus \{v\}}) = P(Y_v | X, Y_{N(v)}),$$

则称 $P(Y | X)$ 为图 G 上的条件随机场。

读前自检：线性链条件随机场。 线性链条件随机场依赖“当 $Y_1, \dots, Y_n$ 构成链时”；请据此把 $P(Y_i | X, Y_{-i})$ 展开一次并检查其类型或边界，并直接核对注意整个观测序列 X 都可以进入局部特征，链结构只限制标签之间的直接依赖。

当 $Y_1, \dots, Y_n$ 构成链时，内部位置满足

$$P(Y_i | X, Y_{-i}) = P(Y_i | X, Y_{i-1}, Y_{i+1}),$$

端点只保留存在的邻居。注意整个观测序列 X 都可以进入局部特征，链结构只限制标签之间的直接依赖。

读前自检：线性链条件随机场的参数化形式。 线性链 CRF 用转移特征 t_k 、状态特征 s_l 及系数 u_k, v_l 构造 $P(y | x)$ ；请对一条合法路径累加特征得分并除以 $Z(x)$ ，核对对全部标签序列求和为 1，且 start, stop 不占真实标签位置。

模型。 令 $t_k(y_{i-1}, y_i, x, i)$ 为转移特征， $s_l(y_i, x, i)$ 为状态特征；为避免与后文 L_2 正则强度 λ 混淆，分别把两类特征系数记为 u_k 与 v_l ，则

$$P(y | x) = \frac{1}{Z(x)} \exp \left[\sum_{i,k} u_k t_k(y_{i-1}, y_i, x, i) + \sum_{i,l} v_l s_l(y_i, x, i) \right],$$

其中 $Z(x)$ 对全部候选标签序列求和。令 $y_0 = \text{start}$ 、 $y_{n+1} = \text{stop}$ ；这两个边界状态不属于任何真实标签位置，只允许起点到 y_1 及 y_n 到终点的边界转移。

把 u_k, v_l 依次并入统一参数向量 w ，并把全部局部特征统一记为 $f_k(y_{i-1}, y_i, x, i)$ ，定义

$$F_k(y, x) = \sum_{i=1}^{n+1} f_k(y_{i-1}, y_i, x, i), \quad F(y, x) = (F_1, \dots, F_K)^T.$$

则

$$P_w(y | x) = \frac{\exp\{w^T F(y, x)\}}{Z_w(x)}, \quad Z_w(x) = \sum_y \exp\{w^T F(y, x)\}.$$

这是条件对数线性模型。 w_k 为正时提高激活特征的序列得分，为负时降低得分；概率仍由全部路径共同归一化。

贯穿例：三时刻天气序列

本章角色： 把同一观测与标签序列改写为条件模型，在不生成观测的前提下复用局部和转移结构。

精确复用观测 $x = (\text{干}, \text{湿}, \text{干})$ 与标签 $y = (\text{晴}, \text{雨}, \text{晴})$ 。本章直接对给定 x 后的标签序列建模：若把该路径的局部得分与两次标签转移得分之和记为 $S(y, x)$ ，则

$$p(y | x) = \frac{\exp\{S(y, x)\}}{\sum_{y'} \exp\{S(y', x)\}}.$$

同一“逐位置局部项加相邻标签转移项”的结构与线性链 CRF 相容；有限标签集和有限得分保证规范化因子为正。本章把 x 当作已经观测到的条件，不要求给出 $p(x)$ ，局部特征还可以读取整个 x 。因此上一站 HMM 的发射分布及“给定状态后观测独立”假设不能外推到这里。上一站见 HMM 对同一序列的联合生成模型。

在增广状态集 $\bar{y}$ 上，对 $i = 1, \dots, n+1$ 定义 $\bar{m} \times \bar{m}$ 矩阵

$$M_i(a, b | x) = \begin{cases} \exp \left\{ \sum_{k=1}^K w_k f_k(a, b, x, i) \right\}, & (a, b) \text{ 在位置 } i \text{ 可行,} \\ 0, & \text{其他情形,} \end{cases}$$

其中 $i = 1$ 只允许 $\text{start} \rightarrow y$ ， $2 \leq i \leq n$ 只允许 $y \rightarrow y$ ， $i = n+1$ 只允许 $y \rightarrow \text{stop}$ 。一条合法路径的非规范化权重为 $\prod_{i=1}^{n+1} M_i(y_{i-1}, y_i | x)$ ，规范化因子是所有 start-stop 路径权重之和，即 $M_1 \cdots M_{n+1}$ 的 start-stop 元素。零填充只用于统一矩阵维数，不引入额外标签路径。

阅读目标：在一条边处拼接前缀、局部因子与后缀，并除以配分函数。

对象：前向量 $\alpha_{i-1}(a)$ 、边因子 $M_i(a, b | x)$ 、后向量 $\beta_i(b)$ 与 $Z_w(x)$ 。

合法条件：标签集有限、不可行转移因子为 0、 $Z_w(x) > 0$ ；前后向量使用一致的数值缩放。

第一步：先按固定相邻标签 (a, b) 把整条序列权重分成“前缀 $\times$ 当前边 $\times$ 后缀”。

推导目标

由前后向量得到相邻标签边缘概率，并据此计算特征期望。

推导准备

给定输入 x 与有限标签集 y ；矩阵因子 $M_i(a, b | x) \geq 0$ ，不可行转移填 0； $Z_w(x) > 0$ 。前向量汇总固定终点前缀权重，后向量汇总固定起点后缀权重，二者采用相同的缩放或对数域约定。

推导第 1 步：拆分路径。固定位置 i 的相邻标签为 (a, b) 。所有满足该约束的路径权重分成三段：到 a 的前缀总权重 $\alpha_{i-1}(a)$ 、局部因子 $M_i(a, b | x)$ 和从 b 出发的后缀总权重 $\beta_i(b)$ 。

推导第 2 步：规范化。三段相乘并除以全部路径权重和，得到

$$P(Y_{i-1} = a, Y_i = b | x) = \frac{\alpha_{i-1}(a) M_i(a, b | x) \beta_i(b)}{Z_w(x)}.$$

对 a 求和可得 $P(Y_i = b | x) = \alpha_i(b) \beta_i(b) / Z_w(x)$ 。

推导第 3 步：交换有限求和。因为 $F_k(y, x) = \sum_i f_k(y_{i-1}, y_i, x, i)$ 且所有集合有限，

$$\mathbb{E}_w[F_k | x] = \sum_{i=1}^{n+1} \sum_{a, b} f_k(a, b, x, i) P(Y_{i-1} = a, Y_i = b | x).$$

这把对 m^n 条序列的求和化为 $n+1$ 组 m^2 个局部边缘。

读前自检：概率计算。 线性链 CRF 用前向量 α_i 与后向量 β_i 计算单点边缘；请形成 $P(Y_i = b | x) \propto \alpha_i(b)\beta_i(b)$ 并对 b 归一，核对概率和为 1。

单点边缘用于逐位置置信度，相邻点边缘用于转移统计。为避免长序列下溢，可以在每一步缩放 α_i, β_i 并累计对数缩放因子，或在数域使用 log-sum-exp；前后向必须采用相容的缩放约定。

读前自检：期望值的计算。 CRF 经验特征期望由真实标签直接计数，模型期望由前向 - 后向边缘加权；请对同一特征 f_k 各算一项，核对两侧都是可比较标量。

对训练集经验分布，经验特征期望由真实标记直接计数；模型特征期望需要对每个输入 x_j 做前向 - 后向。二者之差构成条件对数似然的梯度，是训练算法的核心信号。

读前自检：条件随机场的学习算法。 条件随机场学习目标为带 L_2 正则的负条件对数似然 $J(w) = \sum_j [\log Z_w(x_j) - w^T F(y_j, x_j)] + \lambda \|w\|_2^2 / 2$ ；请对 w_k 求导，核对得到模型特征期望减经验计数再加 λw_k 。

22.3 改进迭代尺度与拟牛顿学习

学习策略。 对训练集 $\{(x_j, y_j)\}_{j=1}^N$ ，带 L_2 正则的负条件对数似然为

$$J(w) = \sum_{j=1}^N [\log Z_w(x_j) - w^T F(y_j, x_j)] + \frac{\lambda}{2} \|w\|_2^2.$$

它只比较同一 x_j 下的标签序列，不建模 $P(X)$ 。

阅读目标： 把经验特征计数、模型特征期望和凸性放在同一公式中。

对象： 参数 $w \in \mathbb{R}^K$ 、全局特征 $F(y, x)$ 、配分函数 $Z_w(x)$ 与正则强度 λ 。

合法条件： 每个输入的可行标签序列有限， $Z_w(x) > 0$ ，且 $\lambda \geq 0$ 。

第一步： 先把单样本负对数似然写为 $\log Z_w(x) - w^T F(y, x)$ ，再逐项求导。

推导目标

推导 CRF 负条件对数似然的梯度与 Hessian，说明模型期望、经验计数和凸性从何而来。

推导准备

参数 $w \in \mathbb{R}^K$ ，全局特征 $F(y, x) \in \mathbb{R}^K$ ，每个训练输入的可行标签序列有限且 $Z_w(x) > 0$ ；有限求和允许交换求导与求和， L_2 正则强度 $\lambda \geq 0$ 。

推导第 1 步：求配分函数的导数。 由 $Z_w(x) = \sum_y e^{w^T F(y, x)}$,

$$\frac{\partial \log Z_w(x)}{\partial w_k} = \frac{\sum_y F_k(y, x) e^{w^T F(y, x)}}{Z_w(x)} = \mathbb{E}_w(F_k | x).$$

推导第2步：组合各项。对第 k 个参数求导，

$$\frac{\partial J}{\partial w_k} = \sum_j [\mathbb{E}_w(F_k | x_j) - F_k(y_j, x_j)] + \lambda w_k.$$

推导第3步：再求一次导数。指数族期望对参数的导数是条件协方差，故 $\nabla^2 J(w) = \sum_j \text{Cov}_w(F | x_j) + \lambda I$ 。协方差矩阵半正定，所以 Hessian 半正定； $\lambda > 0$ 时提供严格正曲率。最优点使正则化后的模型期望与经验统计平衡。

读前自检：改进的迭代尺度法。IIS 闭式增量只在 $\lambda = 0$ 、特征非负且总特征量 $F^\#(y, x) \equiv S > 0$ 时成立；请把经验期望与模型期望代入 $\delta_k = S^{-1} \log[\tilde{E}(F_k)/E_w(F_k)]$ ，并先检查零期望分支。

读前自检：条件随机场模型学习的改进的迭代尺度法。条件随机场 IIS 若 $F^\#$ 不恒定或 $\lambda > 0$ ，就不能直接用对数比闭式更新；请写出含 $\exp \delta_k F^\#(y, x)$ 或 $\lambda(w_k + \delta_k)$ 的一元条件，核对该坐标应由求根而非闭式更新。

IIS 逐坐标寻找增量 δ_k ，使更新后的模型期望向经验期望靠近。只有在无正则 $\lambda = 0$ 、全部尺度特征非负，且每条候选路径的总特征量 $F^\#(y, x) = \sum_r F_r(y, x)$ 恒等于同一常数 $S > 0$ 时，尺度方程才化为闭式更新

$$\delta_k = \frac{1}{S} \log \frac{\tilde{E}[F_k]}{E_w[F_k]}, \quad w_k \leftarrow w_k + \delta_k.$$

若 $F^\#$ 不恒定，无正则 IIS 需要为每个坐标求解含 $\exp\{\delta_k F^\#(y, x)\}$ 的一元尺度方程，或在满足条件时加入松弛特征。若 $\lambda > 0$ ，精确坐标最优条件还包含 $\lambda(w_k + \delta_k)$ ，通常也需一维求根；此时不能使用上面的对数比闭式。IIS 每轮需要重新计算模型期望，特征稀疏时才具有可接受成本。

对每个坐标必须先分类零期望分支。记经验期望为 e_k 、模型期望为 m_k ： $e_k = m_k = 0$ 时该坐标在当前支撑上不可识别，固定增量为 0； $|e_k - m_k|$ 在容差内时标为已匹配； $e_k, m_k > 0$ 时才使用对数比或一维求根； $e_k > 0, m_k = 0$ 表示经验正质量落在模型零支撑上，应返回支撑冲突； $e_k = 0, m_k > 0$ 对应无正则边界解 $\delta_k \rightarrow -\infty$ ，应按预登记的删除、固定或正则化规则处理，不能执行无穷更新或把整个问题笼统判为不可行。

读前自检：拟牛顿法。CRF 拟牛顿学习用梯度差近似曲率而不显式形成完整 Hessian；请核对特征向量 $F(y, x) \in \mathbb{R}^K$ 与参数 w 同维，写出“经验特征计数减模型期望计数再加正则项”的梯度，并检查 BFGS 曲率对 (s_k, y_k) 的维数要求。

读前自检：条件随机场模型学习的 BFGS 算法。CRF 的 BFGS 学习每次目标与梯度计算都调用前向 - 后向；请形成一个满足 Wolfe 条件的候选 w^+ ，用 $s_k = w^+ - w_k$ 和梯度差 y_k 检查曲率条件，核对梯度范数达容差才报告收敛，目标停滞或预算耗尽须另报状态。

学习算法。BFGS 用梯度差近似曲率，不显式计算 CRF 的完整 Hessian。每次目标和梯度计算都调用前向 - 后向；线搜索保证下降并维护曲率条件。

参数含义。 λ 为正则强度, B_k 为 Hessian 近似, c_1, c_2 为 Wolfe 条件常数, ε_g 为梯度容差, ε_J 为目标相对变化停滞容差, $T_{\max}$ 为最大迭代数。**停止条件:** 梯度满足容差时视为收敛; 目标变化停滞或达到最大迭代数时停止并输出当前参数, 同时给出梯度范数以区分是否满足收敛容差。

训练时间复杂度。 设所有序列总长度为 L , 标签数 m 、参数数 K 、每个转移平均激活 r 个特征、优化迭代数 T 。一次目标与梯度约为 $O(Lm^2r)$; 完整 BFGS 总训练约为 $O(T[Lm^2r + K^2])$, L-BFGS 以历史长度 h 把线性代数项降为 $O(ThK)$ 。

几何解释。 每条候选序列对应特征空间中的点 $F(y, x) \in \mathbb{R}^K$, 参数 w 给出线性得分 $w^T F(y, x)$ 。预测选择投影最大的点; 训练则调整法向量 w , 使真实序列特征相对模型平均特征获得更高得分。

概率解释。 规范化因子对同一 x 的所有路径求和, 因此不同序列相互竞争概率质量。局部因子大不代表局部事件概率大, 只有结合前缀、后缀和 $Z_w(x)$ 才能得到边缘概率。

优化解释。 正则化条件对数似然的梯度等于经验特征计数与模型期望特征计数之差再加正则项; 训练就是调节 w 使两类计数匹配。Hessian 由条件协方差与正则项组成。 $\lambda > 0$ 时目标强凸且二次项使其强制有界, 有限极小点唯一; $\lambda = 0$ 时仅能保证凸, 冗余特征可造成不可识别平坦方向, 条件分离还可能使有限极小点不存在。BFGS 的全局结论必须同时假定有限极小点存在、水平集有界、梯度光滑以及线搜索和曲率门禁持续成立。

读前自检: 条件随机场的概率计算问题。 CRF 相邻点边缘满足 $P(Y_{i-1} = a, Y_i = b | x)$ 由前向量、局部势和后向量相乘再除以 $Z_w(x)$; 请对 a, b 求和, 核对总和为 1。

22.4 条件随机场的概率计算

概率计算包括 $Z_w(x)$ 、单点边缘 $P(Y_i = b | x)$ 、相邻点边缘 $P(Y_{i-1} = a, Y_i = b | x)$ 及特征期望。逐条枚举有 m^n 项; 链结构使共享前缀和后缀只计算一次。

读前自检: 前向 - 后向算法。 前向 - 后向算法输入“训练序列、有限特征函数、正则强度 λ 、有限初值、强 Wolfe 参数、外层与线搜索预算及容差”, 条件“序列与标签支撑相容”; 请做一轮“候选 w^+, J^+, g^+, B^+ 全部通过有限性与曲率门禁后原子提交”, 以“梯度范数证书、外层预算耗尽或首次失败时停止”核对停止证书。

把 α_i, β_i 都视为以 $\bar{y}$ 为坐标的 m 维向量。初始化 $\alpha_0(\text{start}) = 1$, 其余坐标为 0; 对 $i = 1, \dots, n+1$ 及 $b \in \bar{y}$ 递推

$$\alpha_i(b) = \sum_{a \in \bar{y}} \alpha_{i-1}(a) M_i(a, b | x).$$

反向初始化 $\beta_{n+1}(\text{stop}) = 1$, 其余坐标为 0, 并对 $i = n, \dots, 0$ 及 $a \in \bar{y}$ 递推

$$\beta_i(a) = \sum_{b \in \bar{y}} M_{i+1}(a, b | x) \beta_{i+1}(b).$$

由不可行转移的零填充, 内部位置只有 y 坐标可能非零; 因此计算量仍由 m^2 个真实标签转移主导, 并且 $Z_w(x) = \alpha_{n+1}(\text{stop}) = \beta_0(\text{start})$ 。

线性链 CRF 的 BFGS 学习：五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 22.1：线性链 CRF 的 BFGS 学习

输入：训练序列、特征、 $\lambda, w^{(0)}, T_{\max}, L_{\max}$ 、强 Wolfe 参数及 $\varepsilon_g, \varepsilon_J, \varepsilon_c$
输出：最后合法 w, J, g ； $k_{\text{done}}, \ell_{\text{done}}, q_{\text{fb}}$ ；**status** 与最终诊断

- 1 $w \leftarrow w^{(0)}, B \leftarrow I, k_{\text{done}} \leftarrow 0, \ell_{\text{done}} \leftarrow 0, q_{\text{fb}} \leftarrow 0$ ，诊断为空
- 2 若序列/标签支撑、维数、 λ 、初值、预算或线搜索参数非法，则返回初始占位、计数 0、**invalid_input** 及字段诊断
- 3 以前向 - 后向计算 J, g 并令 $q_{\text{fb}} \leftarrow 1$ ；若配分函数、边缘、 J 或 g 非有限，则返回最后合法初值、**numerical_failure** 及初始化诊断
- 4 若 $\|g\|_{\infty} \leq \varepsilon_g$ ，则返回当前状态、计数与 **converged**，诊断记录零步梯度证书
- 5 **当** $k_{\text{done}} < T_{\max}$ **执行**
- 6 解 $Bp = -g$ ；若求解非有限则返回最后合法状态与 **numerical_failure** 及方向求解诊断；若 $p^T g \geq 0$ ，则令 $B \leftarrow I, p \leftarrow -g$ 并记录重置
- 7 $\eta \leftarrow 1$ ，本轮接受标志置假
- 8 **对** $\ell \leftarrow 1$ **至** $L_{\max}$ **执行**
- 9 试算 $w_{\text{tr}} = w + \eta p$ ，以前向 - 后向计算 $J_{\text{tr}}, g_{\text{tr}}$ ，并令 $\ell_{\text{done}} \leftarrow \ell_{\text{done}} + 1, q_{\text{fb}} \leftarrow q_{\text{fb}} + 1$
- 10 若候选有限且满足 Armijo 与强 Wolfe 条件，则保留候选并置接受标志为真，跳出试算循环；否则令 $\eta \leftarrow \rho \eta$
- 11 **结束**
- 12 若未接受，则返回最后合法 w, J, g 、现有计数、**line_search_failed** 及失败 $(k_{\text{done}}, L_{\max})$ 诊断
- 13 由 $s = w_{\text{tr}} - w, q = g_{\text{tr}} - g$ 形成阻尼 BFGS 候选 B^+ ；曲率低于 ε_c 时重置 $B^+ = I$ ；若 B^+ 仍非有限或非正定，则返回旧状态与 **numerical_failure** 及曲率阶段诊断
- 14 保存旧 J ，再原子提交 $(w, J, g, B) \leftarrow (w_{\text{tr}}, J_{\text{tr}}, g_{\text{tr}}, B^+)$ 并令 $k_{\text{done}} \leftarrow k_{\text{done}} + 1$
- 15 若 $\|g\|_{\infty} \leq \varepsilon_g$ ，则返回最后合法状态、**converged** 及梯度证书与目标相对变化诊断
- 16 **结束**
- 17 返回最后合法状态、实际计数、**budget_stop** 及“梯度未达标、外层预算耗尽”诊断

算法实现说明：梯度证书满足才返回 **converged**；所有前向 - 后向、线搜索与曲率对象在原子提交前核验，线搜索失败和外层预算耗尽保留不同状态。完整 C1-C14 契约

若预算耗尽而梯度容差未满足，不能称为已经收敛。仅当有限极小点存在、水平集有界、梯度 Lipschitz 连续且线搜索与曲率条件持续满足时，才可说有限聚点为全局极小点； $\lambda > 0$ 时该极小点唯一， $\lambda = 0$ 时还须排除不可识别和分离方向。

预测时间复杂度。长度为 n 的单条序列用 Viterbi 扫描 m^2 个相邻标签对，计入每条边 r 个激活特征后为 $O(nm^2r)$ ；局部得分预缓存时为 $O(nm^2)$ 。

存储与空间复杂度。只求 Z 时可滚动保存两个 m 维向量；求全部边缘通常保存 $O(Lm)$ 向量，并临时处理 m^2 转移。完整 BFGS 保存 $O(K^2)$ 矩阵，L-BFGS 保存 $O(hK)$ 历史向量；Viterbi 回溯为 $O(nm)$ 。**复杂度假设：**采用一阶稠密标签链；稀疏转移约束可按允许边数替换 m^2 。

正确性依据。前向 – 后向递推按相同的局部势分解枚举全部合法路径，因而给出规范化因子和边缘概率；BFGS 只在下降方向、有限目标梯度与 Wolfe 线搜索同时成立时接受参数更新。线搜索、曲率或数值条件不满足时，保留最后一组合法参数并停止。

更新顺序与停止情形。每轮先用前向 – 后向得到同一参数下的目标和梯度，再求下降方向、执行线搜索、接受新参数，最后更新曲率近似。若分区函数或梯度不是有限实数、线搜索未得到可接受步长或所有路径均被禁止，则停止并说明相应数学条件；目标停滞或达到最大迭代数而梯度容差仍未满足时，应报告梯度范数，不能称为已经收敛。

读前自检：条件随机场的预测算法。从条件随机场的预测算法的条件“ $y^* = \arg \max_y P_w(y | x) = \arg \max_y w^T F(y, x)$ ”出发，请把 y^* 展开一次并检查其类型或边界；所得量应符合预测无需计算规范化因子，但仍须寻找全局最优路径。

22.5 Viterbi 预测

预测求

$$y^* = \arg \max_y P_w(y | x) = \arg \max_y w^T F(y, x),$$

因为对固定 x ， $Z_w(x)$ 与 y 无关，指数函数严格单调。预测无需计算规范化因子，但仍须寻找全局最优路径。

读前自检：条件随机场预测的 Viterbi 算法。条件随机场预测的 Viterbi 算法依赖“ $\delta_i(b) = \max_a \{\delta_{i-1}(a) + q_i(a, b)\}$ ， $\Psi_i(b) = \arg \max_a \{\delta_{i-1}(a) + q_i(a, b)\}$ ”；请据此把 $\delta_i(b)$ 展开一次并检查其类型或边界，并直接核对该递推式给出从 start 到 stop 的全局最大得分路径。

令局部加性得分为 $q_i(a, b) = \sum_k w_k f_k(a, b, x, i)$ 。初始化

$$\delta_1(b) = q_1(\text{start}, b).$$

对 $i = 2, \dots, n$ 递推

$$\delta_i(b) = \max_a \{\delta_{i-1}(a) + q_i(a, b)\}, \quad \Psi_i(b) = \arg \max_a \{\delta_{i-1}(a) + q_i(a, b)\}.$$

结合终止得分选出 y_n^* ，再按 $y_{i-1}^* = \Psi_i(y_i^*)$ 回溯。

定理 22.2 (Viterbi 递推的最优性) 若序列总得分是相邻局部得分之和，则该递推式给出从 start 到 stop 的全局最大得分路径。

读前自检：证明：Viterbi 递推的最优性。Viterbi 递推的最优性以“若前缀不是最优，用同终点 a 的最优前缀替换会提高或保持总得分”为约束；请把 $i = 1$ 用到的关键定义展开并完成下一步变形，并确认因此对 a 取最大得到 $\delta_i(b)$ 。

证明。对位置 i 归纳。 $i = 1$ 时， $\delta_1(b)$ 按定义是到达 b 的唯一一步最优得分。假设 $\delta_{i-1}(a)$ 已是到达每个 a 的最优前缀得分。任一到达 b 的长度 i 路径必从某个 a 转入，其得分等于到 a 的前缀得

分加 $q_i(a, b)$; 若前缀不是最优, 用同终点 a 的最优前缀替换会提高或保持总得分。因此对 a 取最大得到 $\delta_i(b)$ 。终点取最大并沿记录的 Ψ 回溯, 恢复达到该值的完整路径。证毕。□

22.6 序列标注例题与练习

例题 22.1 (手工执行三步 Viterbi). 标签为 A, B 。位置 1 从 start 到 A, B 的得分为 $0.4, 0.1$; 位置 2 的局部得分依次为 $q_2(A, A) = 0.3$ 、 $q_2(B, A) = 0.6$ 、 $q_2(A, B) = 0.5$ 、 $q_2(B, B) = 0.2$; 位置 3 对应得分为 $0.2, 0.4, 0.1, 0.3$ 。本例把两个终止附加分都取为 0, 求最优路径, 位置 2 平时选 A 作前驱。

例题 22.1 解答

读题翻译 输入是三位置线性链的局部加性得分; 要求在零终止附加分和指定平分规则下, 求整条 start-stop 路径的最大总分并回溯标签。

已知与合法条件 标签集为 $\{A, B\}$, 首层得分为 $0.4, 0.1$; 位置 3 的四项依次对应 $q_3(A, A) = 0.2$, $q_3(B, A) = 0.4$, $q_3(A, B) = 0.1$, $q_3(B, B) = 0.3$ 。位置 2 出现平时选 A 作前驱。

为什么想到这个方法 加性 Viterbi 对每个“位置 - 当前标签”只保留最大前缀得分和获胜前驱; 完整保存 Ψ 后, 终态选择才能恢复整条路径。

方法选择 初始化 δ_1 , 逐标签计算位置 2 与位置 3 的最大累计得分并记录所有获胜前驱; 加入零终止分选终态, 再完整回溯。

推导/计算 初始化 $\delta_1(A) = 0.4$ 、 $\delta_1(B) = 0.1$ 。位置 2 有

$$\delta_2(A) = \max(0.4 + 0.3, 0.1 + 0.6) = 0.7,$$

平分规则记录 $\Psi_2(A) = A$;

$$\delta_2(B) = \max(0.4 + 0.5, 0.1 + 0.2) = 0.9, \quad \Psi_2(B) = A.$$

位置 3 有

$$\delta_3(A) = \max(0.7 + 0.2, 0.9 + 0.4) = 1.3, \quad \Psi_3(A) = B,$$

以及

$$\delta_3(B) = \max(0.7 + 0.1, 0.9 + 0.3) = 1.2, \quad \Psi_3(B) = B.$$

零终止分不改变终态比较, 故选终态 A , 再由 $\Psi_3(A) = B$ 、 $\Psi_2(B) = A$ 回溯。

独立核验 枚举八条路径 (A, A, A) , (A, A, B) , (A, B, A) , (A, B, B) , (B, A, A) , (B, A, B) , (B, B, A) , (B, B, B) , 得分依次为 $0.9, 0.8, 1.3, 1.2, 0.9, 0.8, 0.7, 0.6$; 唯一最大值为 1.3 , 并与动态规划终值一致。

结论 在给定平分规则和零终止附加分下, 唯一最优路径为 (A, B, A) , 总得分为 1.3 。

卡住时先看 为每个位置画两格: 格内写最大累计分, 格旁写前驱; 不要只保留每层全局最大值。

方法迁移 若终止因子不为 0，把它作为第 $n + 1$ 步加入终态比较；若某转移禁止，则把其对应数得分设为 $-\infty$ 并跳过。

读前自检：适用条件与局限：序列标注例题与练习。 线性链 CRF 要求输入已观测、标签集有限且局部特征可在给定 x 与相邻标签时计算；请逐项核对这三个接口，并在输出含未建模长程依赖时判定线性链规格不足。

适用条件与局限性

适用条件。 线性链 CRF 适合输入已观测、输出为有限标签序列、相邻标签依赖占主导且需要联合归一化的任务。训练与部署的标签集合、分词或位置定义必须一致；特征应能在给定 x 和局部标签时计算；数据量应足以估计参数，长尾特征需正则化。

方法局限

一阶链难以表示长距离标签依赖；精确推断代价随标签数平方增长；大量稀疏特征使训练缓慢；条件训练不能生成或评估输入分布；标签偏差虽比局部归一化模型缓解，但数据偏差、特征缺失与分布漂移仍会影响结果。高阶 CRF 会进一步扩大状态和计算量。

- 常见错误**
1. 把势函数或局部因子当作已经归一化的概率；
 2. 在前向、后向或 Viterbi 中遗漏 start/stop 边界因子；
 3. 计算梯度时只用真实路径特征，漏掉模型期望；
 4. 在长序列上直接连乘指数权重，产生上溢或下溢；
 5. 把逐位置边缘最大化与整条序列 MAP 预测混为同一决策。

易混淆概念对比		
对比	第一项	第二项
HMM 与 CRF	生成 $P(X, Y)$ 并约束观测生成	直接建模 $P(Y X)$ ，特征更灵活
最大熵与线性链 CRF	单个非结构化标签的条件指数族，不含链式标签依赖	具有链式标签因子的条件指数族
前向 - 后向与 Viterbi	以求和半环计算概率和边缘	以最大值和回溯计算 MAP 路径
势函数与概率	局部正权重，不单独归一化	全局除以 $Z(x)$ 后的分布
IIS 与 BFGS	依赖尺度方程的坐标更新	以梯度差构造曲率近似

本章共 18 道练习。每道题干后立即给出同号解析；长解析可自然跨页，续页标题保留题号。

练习 22.1. 在链 $Y_1 - Y_2 - Y_3 - Y_4$ 中, 给出一条由图结构蕴含的条件独立关系。

练习 22.1 解析

在无向链 $Y_1 - Y_2 - Y_3 - Y_4$ 中, 结点集 $\{Y_2\}$ 分隔 Y_1 与 $\{Y_3, Y_4\}$ 。全局马尔可夫性给出

$$Y_1 \perp (Y_3, Y_4) \mid Y_2.$$

等价的条件分布表达为

$$P(y_1, y_3, y_4 \mid y_2) = P(y_1 \mid y_2)P(y_3, y_4 \mid y_2),$$

$$P(y_1 \mid y_2, y_3, y_4) = P(y_1 \mid y_2)$$

(在条件事件概率为正时)。这是条件独立, 不推出无条件独立。

练习 22.2. 两个二值变量的势函数矩阵为 $\psi = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}$ 。若只有这一个团, 求 Z 和四个联合概率。

练习 22.2 解析

两个二值变量共有四个配置, 势权重均非负。配分函数为

$$Z = \sum_{a,b \in \{0,1\}} \psi(a,b) = 1 + 2 + 3 + 4 = 10 > 0.$$

联合分布为

$$P(a,b) = \frac{\psi(a,b)}{Z} = \begin{pmatrix} 0.1 & 0.2 \\ 0.3 & 0.4 \end{pmatrix}.$$

四项非负且

$$\sum_{a,b} P(a,b) = \frac{10}{10} = 1.$$

练习 22.3. 说明 Hammersley-Clifford 定理中严格正性条件的作用。

练习 22.3 解析

严格正性只要求在声明的合法支持 Ω 上成立:

$$P(y) > 0 \quad \text{对所有 } y \in \Omega.$$

于是 $\log P(y)$ 处处有限, 才能构造团势的加性分解

$$\log P(y) = \sum_C \varphi_C(y_C) - \log Z \iff P(y) = \frac{1}{Z} \prod_C \psi_C(y_C),$$

其中 $\psi_C = e^{\varphi_C} > 0$ 。非法配置 $y \notin \Omega$ 可由局部 0/1 硬因子赋零, 不违反这一条件; 若某个声明为合法的配置仍有 $P(y) = 0$, 则 $\log P(y) = -\infty$, 不能直接使用严格正软势的结论。

练习 22.4. 证明 $P_w(y | x)$ 对所有 y 求和为 1。

练习 22.4 解析

对有限标签序列支持 $\mathcal{Y}(x)$, 定义

$$Z_w(x) = \sum_{y \in \mathcal{Y}(x)} \exp\{w^T F(y, x)\} > 0.$$

因此

$$\begin{aligned} \sum_{y \in \mathcal{Y}(x)} P_w(y | x) &= \sum_y \frac{\exp\{w^T F(y, x)\}}{Z_w(x)} \\ &= \frac{Z_w(x)}{Z_w(x)} = 1. \end{aligned}$$

每条合法路径对应的指数权重严格为正, 故所得条件概率在合法支持上归一化; 非法路径不进入求和。

练习 22.5. 某序列的全局特征为 $F = (2, 1, -1)^T$, 参数 $w = (0.5, -0.2, 0.3)^T$ 。求非规范化权重。

练习 22.5 解析

这里 $w, F \in \mathbb{R}^3$ 。路径得分为

$$w^T F = 0.5 \times 2 + (-0.2) \times 1 + 0.3 \times (-1) = 0.5.$$

非规范化权重为

$$\tilde{P}_w(y | x) = e^{w^T F} = e^{0.5} \approx 1.6487.$$

条件概率还需除以包含所有合法路径的 $Z_w(x)$; 只有一个路径权重时不能完成归一化。

练习 22.6. 解释为什么 CRF 允许特征依赖整个 x , 却仍可用线性链动态规划。

练习 22.6 解析

给定观测 x 后, 局部因子可依赖整个 x , 但对未知标签只需满足链式分解

$$\tilde{P}_w(y | x) = \left[\prod_{i=1}^n M_i(y_{i-1}, y_i | x) \right] M_{n+1}(y_n, \text{stop} | x).$$

前向状态仍按相邻标签递推:

$$\alpha_i(b) = \sum_{a \in \mathcal{Y}} \alpha_{i-1}(a) M_i(a, b | x).$$

x 在条件化后只是已知系数, 不扩大标签图的团; 因此每层仍计算 m^2 个转移。

练习 22.7. 标签数 $m = 3$ 、序列长度 $n = 100$ 。比较枚举与前向算法在路径数量量级上的差异。

练习 22.7 解析

标签支持大小 $m = 3$ 、长度 $n = 100$ ，枚举路径数为

$$m^n = 3^{100} \approx 5.15 \times 10^{47}.$$

前向算法的状态、初始化、递推与终止为

$$\alpha_1(b) = M_1(\text{start}, b), \quad \alpha_i(b) = \sum_a \alpha_{i-1}(a) M_i(a, b), \quad Z = \sum_b \alpha_n(b) M_{n+1}(b, \text{stop}).$$

核心转移数为

$$nm^2 = 100 \times 9 = 900,$$

量级 $O(nm^2)$ 远小于指数枚举。

练习 22.8. 已知 $\alpha_{i-1}(a) = 2$ 、 $M_i(a, b) = 3$ 、 $\beta_i(b) = 5$ 、 $Z = 60$ ，求该相邻标签事件的边缘概率。

练习 22.8 解析

相邻标签事件的边缘公式为

$$P(Y_{i-1} = a, Y_i = b | x) = \frac{\alpha_{i-1}(a) M_i(a, b) \beta_i(b)}{Z}.$$

代入题设数值得到

$$\frac{2 \times 3 \times 5}{60} = \frac{30}{60} = \frac{1}{2}.$$

同一位置所有 (a, b) 边缘还应满足

$$\sum_{a,b} P(Y_{i-1} = a, Y_i = b | x) = 1.$$

练习 22.9. 某二值特征只在位置 2、转移 $A \rightarrow B$ 时取 1。写出它在给定 x 下的模型期望。

练习 22.9 解析

该全局特征为事件指示函数

$$F(y, x) = \mathbf{1}\{y_1 = A, y_2 = B\}.$$

所以模型期望为

$$\mathbb{E}_w[F | x] = P(Y_1 = A, Y_2 = B | x) = \frac{\alpha_1(A) M_2(A, B | x) \beta_2(B)}{Z_w(x)}.$$

若特征可在多个位置激活，则

$$\mathbb{E}_w[F | x] = \sum_i P(Y_{i-1} = A, Y_i = B | x).$$

练习 22.10. 当 $\lambda = 0$ 时, 写出最优点第 k 维梯度为零所表达的矩匹配关系。

练习 22.10 解析

无正则负对数似然的第 k 维梯度为

$$\frac{\partial J}{\partial w_k} = \sum_j \mathbb{E}_w[F_k(Y, x_j) | x_j] - \sum_j F_k(y_j, x_j).$$

最优点梯度为零给出矩匹配

$$\sum_j \mathbb{E}_w(F_k | x_j) = \sum_j F_k(y_j, x_j).$$

加入 L_2 正则后, 梯度多出 λw_k , 两侧一般不再精确相等。

练习 22.11. 在 $\lambda = 0$ 、非负特征且 $F^\# \equiv S = 4$ 的常数总量情形中, 某特征经验期望为 0.30、模型期望为 0.20。求闭式尺度更新增量。

练习 22.11 解析

常数总量 $S = 4 > 0$ 且两个期望均为正, 闭式尺度方程为

$$0.20e^{4\delta} = 0.30.$$

因此

$$\delta = \frac{1}{4} \log \frac{0.30}{0.20} = \frac{1}{4} \log 1.5 \approx 0.1014 > 0.$$

参数增加, 使该特征激活路径权重上升; 若有正则、负特征或非常数总量, 应回到一般一元方程或其他优化器。

练习 22.12. 说明为什么 BFGS 线搜索必须检查下降方向和曲率条件。

练习 22.12 解析

设当前梯度 $g_k = \nabla J(w_k)$ 与搜索方向 p_k 。下降方向条件是

$$g_k^\top p_k < 0.$$

若 $g_k^\top p_k \geq 0$, 正步长不保证目标下降, 应重置近似并改用 $-g_k$ 。记

$$s_k = w_{k+1} - w_k, \quad q_k = g_{k+1} - g_k.$$

BFGS 正定保持需要

$$s_k^\top q_k > 0.$$

若曲率条件失败, 应阻尼、跳过或重置更新, 并复查线搜索与数值有限性。

练习 22.13. 为什么 CRF 的 Viterbi 预测可以忽略 $Z_w(x)$, 而计算边缘概率不能忽略?

练习 22.13 解析

对固定 x , MAP 路径满足

$$\arg \max_y P_w(y | x) = \arg \max_y \frac{e^{w^T F(y, x)}}{Z_w(x)} = \arg \max_y w^T F(y, x),$$

因为 $Z_w(x) > 0$ 与 y 无关。边缘概率却必须归一化:

$$P(Y_i = b | x) = \frac{\sum_{y: y_i=b} e^{w^T F(y, x)}}{Z_w(x)}, \quad \sum_b P(Y_i = b | x) = 1.$$

去掉 $Z_w(x)$ 后不再得到概率。

练习 22.14. 标签数 $m = 20$ 、长度 $n = 50$ 。给出 Viterbi 核心时间复杂度和保存全部回溯指针的空间复杂度。

练习 22.14 解析

Viterbi 递推状态为

$$\delta_i(b) = \max_{a \in \{1, \dots, m\}} \{\delta_{i-1}(a) + q_i(a, b)\}.$$

每个位置有 m^2 次候选比较, 所以

$$T_{\text{Vit}} = O(nm^2) = O(50 \times 20^2) = O(20000).$$

保存全部前驱指针需要

$$S_{\Psi} = O(nm) = O(50 \times 20) = O(1000),$$

另有 $O(m)$ 滚动得分空间。

练习 22.15. 逐位置选择最大边缘标签与 Viterbi 路径可能不同。解释原因。

练习 22.15 解析

逐位置决策为

$$\hat{y}_i^{\text{marg}} \in \arg \max_b P(Y_i = b | x),$$

它逐位置最小化 0-1 损失。Viterbi 则求

$$\hat{y}^{\text{MAP}} \in \arg \max_y P(y | x),$$

优化整条序列的联合概率。各位置最大边缘可能由不同路径贡献, 故

$$(\hat{y}_1^{\text{marg}}, \dots, \hat{y}_n^{\text{marg}}) \neq \hat{y}^{\text{MAP}}$$

练习 22.15 解析 (续)

一般可能发生。

练习 22.16. 对例题中的位置 2, 若平时改选 B 作为 $\delta_2(A)$ 的前驱, 最终最优路径是否改变?

练习 22.16 解析

终止状态仍由

$$y_3^* = \arg \max\{\delta_3(A), \delta_3(B)\} = A$$

确定。回溯状态链为

$$y_2^* = \Psi_3(A) = B, \quad y_1^* = \Psi_2(B) = A.$$

因此

$$y^* = (A, B, A).$$

修改的是 $\Psi_2(A)$, 而回溯没有访问该指针, 所以最终路径不变。

练习 22.17. 设计两个检查量, 用于发现前向 - 后向实现中的归一化或索引错误。

练习 22.17 解析

第一类检查是前向、后向终止量一致:

$$Z_w(x) = \alpha_{n+1}(\text{stop}) = \beta_0(\text{start}) > 0.$$

第二类检查是边缘归一化与相容性:

$$\sum_b P(Y_i = b | x) = 1, \quad \sum_{a,b} P(Y_{i-1} = a, Y_i = b | x) = 1,$$

以及

$$\sum_a P(Y_{i-1} = a, Y_i = b | x) = P(Y_i = b | x).$$

超出预定容差通常表明归一化、边界或索引错误。

练习 22.18. 若任务存在必须满足的标签转移禁令, 如何在 CRF 中编码, 并说明数值实现注意事项。

练习 22.18 解析

对禁止转移 (a, b) , 可定义

$$M_i(a, b | x) = 0 \iff q_i(a, b | x) = -\infty.$$

于是任何包含该转移的路径权重为零。递推时只在可行前驱集 $\mathcal{A}_i(b)$ 上聚合:

$$\alpha_i(b) = \sum_{a \in \mathcal{A}_i(b)} \alpha_{i-1}(a) M_i(a, b), \quad \delta_i(b) = \max_{a \in \mathcal{A}_i(b)} [\delta_{i-1}(a) + q_i(a, b)].$$

练习 22.18 解析 (续)

对数域 $\log\text{-sum-exp}$ 应跳过 $-\infty$ 项, 并检查至少存在一条 **start-stop** 可行路径; 否则 $Z_w(x) = 0$, 条件模型未定义。

读前自检：本章结论与下一步。 条件随机场章末由“图分隔、团势、条件对数线性序列与局部特征”落到“IIS 或 BFGS 优化条件似然”；请把前者产出和后者输入逐项对齐，固定核对前者末项的输出类型能否作为后者首项的输入类型。

本章结论与下一步

核心结论：图分隔、团势、条件对数线性序列与局部特征

关键依据：严格正性配合 Möbius 反演得到团分解；前向 - 后向得到配分函数、边缘与特征期望

可执行自检：IIS 或 BFGS 优化条件似然；Viterbi 以最大递推和前驱指针求整条序列 MAP

适用边界：需要联合预测有限标签序列并显式表达相邻标签依赖时

下一步：进入监督方法总结；若图条件、归一化或 MAP 自检失败则返回对应主节

1. **定义：**能否写出无向图马尔可夫性、最大团因子分解和一般 CRF 定义？未通过则回看第 1、2 节。
2. **表示：**能否从局部转移/状态特征得到全局向量形式和矩阵形式？未通过则回看第 2 节。
3. **概率：**能否推导相邻边缘和特征期望，并说明缩放或 $\log\text{-sum-exp}$ ？未通过则回看第 3 节。
4. **学习：**能否写出负条件对数似然、梯度和 BFGS 流程，并说明 IIS 闭式更新的条件？未通过则回看第 4 节。
5. **预测：**能否独立填写 Viterbi 递推表、终止并回溯，同时给出复杂度？未通过则回看第 5、6 节；五项均能独立完成，并能通过边缘归一化与路径得分检查，才算达到本章学习目标。

第 23 章 监督学习方法总结

读前自检：本章地图：监督学习方法总结。 监督学习方法总结章地图以“从任务约束直达模型、准则、算法与评估选择”组织内容；请把路线拆成起点、关键工具和终点，并核对三者的输入输出类型能依次衔接。

读前自检：本章可检验学习目标。 监督学习方法总结目标中的“用“任务、模型、策略、算法、评估”五个层次统一描述监督学习方法”必须可复核；请用“任务、模型、策略、算法、评估”五个层次统一描述监督学习方法，所得结果仅在“中间结果逐项包含首目标“用“任务、模型、策略、算法、评估”五个层次统一描述监督学习方法”声明的对象、条件与结论”时通过。

读前自检：最短先修。 监督学习方法总结的最短先修明确要求“本章依赖前文关于监督学习、经验风险、结构风险、生成模型、判别模型、交叉验证和常见分类指标的定义”；请把首项“本章依赖前文关于监督学习、经验风险、结构风险、生成模型、判别模型、交叉验证和常见分类指标的定义”中的第一个先修对象写成定义域 - 运算 - 输出三元组，并以“该三元组逐项满足首项“本章依赖前文关于监督学习、经验风险、结构风险、生成模型、判别模型、交叉验证和常见分类指标的定义”的对象类型与成立条件”判断能否进入本章。

读前自检：先修自检。 监督学习方法总结先修自检固定核验“能否写出经验风险最小化与带正则项的结构风险最小化目标”；请写出经验风险最小化与带正则项的结构风险最小化目标并写出中间结果，再按“中间结果直接回答首项“能否写出经验风险最小化与带正则项的结构风险最小化目标”并给出通过或失败”明确判为通过或失败。

本章地图

核心问题：怎样在同一信息边界下比较已经学习的监督方法

可检验学习目标：

- 用“任务、模型、策略、算法、评估”五个层次统一描述监督学习方法；
- 区分生成方法与判别方法、概率模型与非概率模型，并指出这些分类维度并不等价；
- 比较线性模型、核方法、树模型与集成方法的表示能力、计算代价和归纳偏好；
- 从数据规模、特征类型、错误代价、概率需求和部署约束出发选择候选方法；
- 能够设计无数据泄漏的训练、验证、选择和最终评估流程。

最短先修：本章依赖前文关于监督学习、经验风险、结构风险、生成模型、判别模型、交叉验证和常见分类指标的定义，并默认读者已经学习感知机、 k 近邻、朴素贝叶斯、决策树、逻辑斯谛回归、最大熵模型、支持向量机、提升方法、隐马尔可夫模型与条件随机场。比较方法时必须固定任务、数据划分和评价指标，不能把不同实验条件下的结果直接排列。

依赖路线：学习任务 → 数据表示与损失；模型族 → 可表达的决策规则；学习策略 → 经验目标与正则化；学习算法 → 参数或结构的求解；验证协议 → 超参数和模型选择；独立测试 → 对部署风险的有限样本估计。

完成标准与返回：任务或评价口径不清时返回[节 23.1](#)；候选不可比时回看[节 23.5](#)

读前自检：模型认识卡：监督学习方案选择。 监督学习方案选择卡固定任务、训练/验证划分、有限候选 $\mathcal{F}_m$ 与预算；请在训练集拟合每个候选并按同一验证指标选取一项，核对候选集和规则在看分数前已冻结。

模型认识卡：监督学习方案选择

任务与输入：固定任务、训练开发数据、有限候选集与资源约束。 **输出类型：**锁定的学习方案与一次最终评估规则。

模型：候选模型族 $\mathcal{F}_m$ 。 **策略：**在同一损失、数据边界和约束下比较验证风险。 **算法：**折内拟合、候选汇总、可行性筛选、近优并列决策与全量重训。

预测：由锁定候选给出。 **关键假设与边界：**候选和规则须在查看验证结果前冻结；测试集不得返回选择闭环。

本章符号表

符号	取值或维数	含义
$T = \{(x_i, y_i)\}_{i=1}^N$	样本集合	监督训练数据
$\mathcal{X}, \mathcal{Y}$	集合	输入空间与输出空间
$\mathcal{F}$	函数集合	候选模型或假设空间
f_θ	$\mathcal{X} \rightarrow \mathcal{Y}$ 或分布	参数为 θ 的模型
$L(y, f(x))$	$[0, \infty)$	单样本损失
$\hat{R}_N(f)$	$[0, \infty)$	经验风险
$\Omega(f)$	$[0, \infty)$	复杂度或正则项
λ	$[0, \infty)$	监督学习模型选择中的正则化强度
$\mathcal{M}$	有限候选集合	待比较的方法与超参数配置
$C(a, y)$	$[0, \infty)$	采取动作 a 而真实标签为 y 的代价

23.1 监督学习方法共同框架

监督学习不是某一个固定算法，而是一类从带标签样本学习预测规则的问题。比较方法之前应先问五个问题：预测什么、允许使用什么信息、如何衡量错误、在什么模型族中搜索、通过什么计算过程得到结果。若这五项没有固定，所谓“哪个算法更好”没有可检验含义。

监督学习方法可以写成闭环：任务给出 $(\mathcal{X}, \mathcal{Y})$ 和数据生成条件；模型规定 $f \in \mathcal{F}$ ；策略规定风险或约束；算法根据有限样本求出 $\hat{f}$ ；评估在未参与选择的数据上估计误差。数据预处理、特征构造和阈值选择也属于学习流程，必须与模型一起接受验证。

读前自检：本章工作性框架：监督学习方案。 把本章工作性框架：监督学习方案放在“这个四元组是本讲义用于检查比较条件是否齐全的记号，不作为来源教材中的编号定义”下考察：把 $\mathcal{A}$ 展开一次并检查其类型或边界，并检查它接收 T 并输出预测规则及其适用条件说明。

本章工作性框架：监督学习方案

为便于比较本章已经学习的方法，设训练样本 T 来自未知分布 $P(X, Y)$ ，并把一次完整学习选择记为四元组

$$\mathcal{A} = (\mathcal{F}, \mathcal{J}, \mathcal{O}, \mathcal{E}),$$

其中 $\mathcal{F}$ 是模型族， $\mathcal{J}$ 是由损失与正则项构成的学习准则， $\mathcal{O}$ 是求解准则的算法， $\mathcal{E}$ 是固定的数据划分、指标和选择规则。这个四元组是本讲义用于检查比较条件是否齐全的记号，不作为来源教材中的编号定义；它接收 T 并输出预测规则及其适用条件说明。

模型。模型描述输入与输出之间允许出现的关系。线性分类器用超平面组织决策；决策树用分区组织决策；概率模型给出条件分布或联合分布；核方法在由核决定的特征空间中使用线性结构；集成方法组合多个基学习器。模型族既提供表达能力，也引入归纳偏好。

读前自检：学习策略。监督学习策略以损失 L 定义经验风险 $\hat{R}_N(f)$ ，并可加 $\lambda\Omega(f)$ 形成结构风险；请把同一候选 f 代入两式，核对正则项只在 $\lambda > 0$ 时改变候选排序。

学习策略。给定损失 L ，经验风险为

$$\hat{R}_N(f) = \frac{1}{N} \sum_{i=1}^N L(y_i, f(x_i)).$$

结构风险最小化进一步求

$$\hat{f} \in \arg \min_{f \in \mathcal{F}} \{\hat{R}_N(f) + \lambda\Omega(f)\}.$$

不同方法的差异可能来自模型族，也可能来自损失、正则化或约束；只比较最终公式而忽略这些层次会产生错误归因。

阅读目标：分离参数拟合、超参数选择与最终测试，阻断评价信息回流。

对象：预先固定的候选集合 $\mathcal{M}$ 、训练集、验证集与封存测试集。

合法条件：每个候选只访问训练部分拟合；验证集只用于选择；测试集在方案锁定前不得访问。

第一步：先条件于训练数据观察：训练风险同时参与了参数最小化，因此不是所选模型的独立泛化评价。

推导目标

说明为什么模型选择必须使用未参与拟合的数据，而不能用训练风险直接选择任意复杂度。

推导准备

候选集合 $\mathcal{M}$ 在查看验证与测试结果前固定；训练、验证、测试样本按任务允许的独立或分组机制划分。对每个 m ，训练算法只访问训练部分；损失可积，最终测试集在方案锁定前不参与任何选择。

推导第1步：固定候选。对每个预先给定的候选 $m \in \mathcal{M}$ ，训练算法只使用训练集得到 $\hat{f}_m$ 。训练风险同时参与了参数选择，因而对该模型的未知风险通常偏乐观。

推导第2步：条件比较。给定训练集以后， $\hat{f}_m$ 已经固定。独立验证样本上的损失均值

$$\hat{R}_{\text{val}}(\hat{f}_m) = \frac{1}{n_{\text{val}}} \sum_{i \in I_{\text{val}}} L(y_i, \hat{f}_m(x_i))$$

才是在相同条件下比较候选的估计量。所有预处理参数也必须仅由训练部分确定。

推导第3步：选择后再评估。令

$$\hat{m} \in \arg \min_{m \in \mathcal{M}} \hat{R}_{\text{val}}(\hat{f}_m).$$

验证集已经参与 $\hat{m}$ 的选择，因此不能再把同一个验证误差报告为无偏最终性能。应在锁定整个方案后，用独立测试集估计 $R(\hat{f}_{\hat{m}})$ 。

定理 23.1 (有限候选的验证误差控制) 给定训练集后，设 $M = |\mathcal{M}| < \infty$ ，各候选模型固定，验证损失独立且位于 $[0, 1]$ 。则对任意 $\delta \in (0, 1)$ ，以至少 $1 - \delta$ 的概率，对所有 $m \in \mathcal{M}$ 同时成立

$$R(\hat{f}_m) \leq \hat{R}_{\text{val}}(\hat{f}_m) + \sqrt{\frac{\log M + \log(1/\delta)}{2n_{\text{val}}}}.$$

证明。证明目标是得到一个对全部候选同时成立的事件。固定 m 后，对独立的 $[0, 1]$ 损失应用单侧 Hoeffding 不等式，得到

$$P(R(\hat{f}_m) - \hat{R}_{\text{val}}(\hat{f}_m) > \epsilon) \leq e^{-2n_{\text{val}}\epsilon^2}.$$

对 M 个候选取并集界，任一候选违反该界的概率不超过 $Me^{-2n_{\text{val}}\epsilon^2}$ 。令该上界等于 δ 并解出 ϵ ，得到定理中的根号项。由于事件对全部 m 同时成立，也适用于由验证集选出的 $\hat{m}$ 。这只控制预先给定的有限候选集合；反复查看验证结果并继续扩展候选会改变 M 及选择过程，需使用嵌套验证或新的独立数据。证毕。□

23.2 生成方法与判别方法比较

生成方法学习联合分布 $P(X, Y)$ ，常通过 $P(Y)P(X | Y)$ 分解后再用 Bayes 公式预测；判别方法直接学习 $P(Y | X)$ 或决策函数 $f(X)$ 。这个分类关注学习对象，不等同于“是否输出概率”。逻辑斯谛回归是判别概率模型，支持向量机通常是判别非概率模型，朴素贝叶斯和隐马尔可夫模型属于生成概率模型，条件随机场属于判别概率模型。

概率解释。生成方法能够计算或近似 $P(X)$ 、处理某些缺失变量并从模型采样，但需要为输入分布作较强假设。判别方法把建模能力集中于预测所需的条件边界，通常减少对 $P(X)$ 无关部分的假设。若生成假设接近真实，小样本时额外结构可能降低方差；若假设偏离严重，偏差会抵消这一优势。

易混淆概念对比		
维度	生成方法	判别方法
学习对象	$P(X, Y)$ 或 $P(Y)P(X Y)$	$P(Y X)$ 或决策函数
预测	由联合分布导出条件规则	直接计算条件概率或得分
额外能力	可描述输入、采样、部分缺失推断	聚焦预测边界，少建模无关变化
主要风险	输入分布假设错误	条件模型仍可能失配或过拟合
代表方法	朴素贝叶斯、HMM	逻辑斯谛回归、SVM、CRF

23.3 概率模型与非概率模型

概率模型以满足非负性和归一化的分布描述不确定性；非概率模型可以输出距离、间隔、排序分数或确定性结构。二者都能产生决策，但分数不能在未经验证时解释为概率。即使模型输出归一化概率，有限样本、正则化、类别重加权和分布漂移也可能导致校准偏差。

几何解释。在线性二分类中， $w^T x + b = 0$ 给出同一个超平面。逻辑斯谛回归把有符号法向距离单调映射为概率，支持向量机把距离与间隔损失联系起来，感知机只依据符号纠正误分类。几何边界可以相近，但训练策略和输出语义不同。

读前自检：学习算法。 从监督学习方法总结中的学习算法的条件“算法的迭代变量、停止条件与数值精度会影响训练成本，但不能改变模型和损失所规定的统计目标”出发，请把“算法的迭代变量、停止条件与数值精度会影响训练成本，但不能改变模型和损失所规定的统计目标”中的已声明对象依次标成输入、输出与判据；所得量应符合测试集只有从锁定方案到一次最终评价的单向边，若测试结果返回候选族或超参数，测试集便转化为新的验证信息。

23.4 线性模型、核方法与集成方法

学习算法把策略变成可执行的求解过程。线性模型通常优化有限维参数；核方法通过 Gram 矩阵或核展开在隐式特征空间求解；树模型递归选择分裂；提升方法按轮加入基学习器。算法的迭代变量、停止条件与数值精度会影响训练成本，但不能改变模型和损失所规定的统计目标。




图 23.1 监督学习方法选择闭环。测试集不进入返回候选模型族的反馈回路。

图 23.1 把训练、验证反馈限制在候选选择闭环内；测试集只有从锁定方案到一次最终评价的单向边，若测试结果返回候选族或超参数，测试集便转化为新的验证信息。

读前自检：易混淆概念对比：线性模型、核方法与集成方法。 线性模型、核方法与集成方法依赖“对比表首个数据行是“线性模型 | 原特征或基函数上线性 | 常为 $O(Nd)$ 级迭代 | 快速、可解释、易正则化””；请据此按列复述“线性模型 | 原特征或基函数上线性 | 常为 $O(Nd)$ 级迭代 | 快速、可解释、易正则化”中的对象、假设与结论，并直接核对各列均对应首行对象“线性模型”，且未与表中下一行互换。

易混淆概念对比			
方法族	归纳偏好	主要计算量	典型优势
线性模型	原特征或基函数上线性	常为 $O(Nd)$ 级迭代	快速、可解释、易正则化
核方法	核定义的平滑相似性	朴素 Gram 存储 $O(N^2)$	小中样本非线性边界
树模型	轴对齐递归分区	依分裂搜索而定	混合类型、非线性与交互
集成方法	多个弱或不稳定模型组合	基学习器成本乘轮数	提升预测能力、控制偏差或方差

23.5 模型选择与适用条件

方法选择应先写成约束表：输出是类别、序列还是连续量；是否需要概率；错误代价是否对称；训练样本与特征维数多大；特征是否稀疏、混合或具有序列结构；预测延迟、内存和解释性要求是什么；分布漂移如何监测。候选方法由这些条件筛出，再用同一验证协议比较，而不是从算法名称出发寻找理由。

优化解释。模型选择是外层离散优化，参数拟合是内层优化。设候选配置为 m ，训练算子为 $\hat{\theta}(m; T_{tr})$ ，则外层目标是

$$\min_{m \in \mathcal{M}} \hat{R}_{val}(\hat{\theta}(m; T_{tr})).$$

若同一验证集被反复用于扩展 $\mathcal{M}$ ，外层同样会过拟合。嵌套交叉验证把外层性能评估与内层超参数选择分开。

学习算法。下面给出一个不依赖具体编程语言的方法筛选流程。它要求先固定指标和约束，再产生候选；测试集只在方案锁定后使用一次。

参数含义。候选集合 $\mathcal{M}$ 含方法族、特征流程和超参数； K 是交叉验证折数； τ 是允许的最大延迟或资源阈值； ϵ 是把验证性能视为近似相当的容差。

读前自检：受约束的监督学习方案选择流程。 受约束的监督学习方案选择流程以“一次测试：锁定方案后只在独立测试集评价一次”为约束；请把 $T \setminus D_k$ 展开一次并检查其类型或边界，并确认先应用硬约束得到可行集 $\mathcal{V}$ 。

受约束的监督学习方案选择流程

1. **冻结**：在查看验证结果前固定 k 折划分、候选 $\mathcal{M}$ 、折内预处理、主指标、资源阈值 τ_r 、 ϵ 近优与并列规则。
2. **折内拟合**：对每个 (m, k) ，只用 $T \setminus D_k$ 拟合预处理器和模型，只在 D_k 计算分数与资源量；失败候选位置化记录并退出比较。
3. **同口径汇总**：只有恰有 K 个成功折的候选才按共同分母汇总；先应用硬约束得到可行集 $\mathcal{V}$ 。
4. **选择与重训**：在 $\mathcal{V}$ 中形成 ϵ 近优集，再按冻结的复杂度、波动和并列规则选 m^* ，最后用全部开发数据重训 f^* 。
5. **一次测试**：锁定方案后只在独立测试集评价一次；测试结果不得反向改变候选、阈值或预处理。

算法实现说明：每折记录至少含候选、折号、内部停止状态、验证指标和资源量；任一预处理都必须在训练折内拟合。无可行候选与全量重训失败均应显式报告，不能伪造“最佳方案”。完整 C1-C14 契约

有限候选数与固定的 k 折保证外层选择在有限步后停止；所有入选候选都以相同分母 K 和预先冻结的汇总口径比较，内层最优化仍按各模型已经给定的数学停止准则求解。

独立测试集不参与上述选择； m^* 固定后，只用它评价最终泛化误差一次。

训练时间复杂度。若候选 m 在一个训练折上的拟合成本为 C_m 、验证预测成本为 E_m ， k 折选择总成本约为 $\sum_m K(C_m + E_m)$ ，另加所选方案在全部开发数据上的一次重训。

预测时间复杂度。最终部署预测复杂度由所选模型给出，记为 $P_{m^*}(d)$ ；模型选择过程不能用验证阶段的总成本替代该部署成本。

存储与空间复杂度。除数据外，串行执行需要当前候选模型的最大工作存储量 S_m 及折外预测 $O(N)$ ；并行执行多个候选时，各候选的工作存储量近似相加。**复杂度假设**：各折顺序复用存储空间；缓存全部候选会增加到近似求和规模。

正确性依据。每个候选的分数只由其未参与拟合的验证折产生，硬约束先于并列决胜规则应用；方案锁定后才用全部开发数据重训，并且测试集只评估一次。因此所得方案满足预先给定的可行性与选择规则；内层训练未完成或没有可行候选时，不产生虚假的最优方案。

更新顺序与停止情形。依次固定候选与数据划分、逐折拟合和验证、汇总可比指标、应用既定并列规则、重训选中方案，最后一次性测试。若没有可比较的候选、某折缺少必要类别或资源指标口径不一致，应停止比较或排除相应候选并说明原因；外层枚举结束并不表示内层训练已经满足停止准则。

23.6 综合自检与学习路线

模型选择应同时说明任务、数据划分、预处理、候选模型、评价指标、资源约束与失效条件，才能比较不同方案并解释结论。

例题 23.1 (代价与资源共同约束下的方法选择). 某二分类任务的验证结果如下: 线性模型的召回率为 0.91、延迟 2 毫秒; 核模型的召回率为 0.93、延迟 18 毫秒; 提升树的召回率为 0.94、延迟 7 毫秒。部署要求延迟不超过 10 毫秒, 且把召回率相差不超过 0.02 视为近似相当。应如何选择?

例题 23.1 解答

读题翻译 选择顺序是先满足延迟硬约束, 再只在可行模型中比较召回率; 0.02 容差用于判断可行候选是否近似相当。

已知与合法条件 线性、核、提升树的 (召回率, 延迟) 依次为 (0.91, 2)、(0.93, 18)、(0.94, 7); 延迟上限为 10 毫秒, 近似相当阈值为 0.02。

为什么想到这个方法 硬约束必须先筛掉不可行候选; 性能容差不能让违反资源约束的模型重新进入比较。

方法选择 先按延迟构造可行集, 再比较可行模型的召回率差是否超过 0.02, 最后按冻结规则选模并复核资源与性能。

推导/计算 记线性、核与提升树模型分别为 L, K, B 。候选的召回率与延迟为

m	L	K	B
r_m	0.91	0.93	0.94
t_m (毫秒)	2	18	7

延迟硬约束先确定可行集:

$$\mathcal{F} = \{m \in \{L, K, B\} : t_m \leq 10\} = \{L, B\}, \quad K \notin \mathcal{F}.$$

在可行候选中, 召回率差为

$$|r_B - r_L| = |0.94 - 0.91| = 0.03 > 0.02,$$

所以两者不属于预先定义的“近似相当”, 选择结果为

$$m^* = \arg \max_{m \in \mathcal{F}} r_m = B.$$

独立核验 所选 B 满足 $7 \leq 10$ 毫秒, 且相对唯一另一可行候选 L 有 $0.03 > 0.02$ 的召回优势; K 虽比 L 的召回率高, 但因 $18 > 10$ 不在可行集。

结论 按预先冻结的延迟硬约束与召回容差, 应选择提升树 B ; 锁定后仍须在独立测试集报告召回率、误判代价和实际延迟。

读前自检：适用条件与局限：综合自检与学习路线。 监督学习方案框架要求输入、输出、损失和验证协议都明确，且数据划分代表部署依赖结构；请把时间序列随机打散作为单一违例，指出信息泄漏位置，并改用保持时间顺序的划分核对。

适用条件与局限性

适用条件。本章框架适用于可以明确输入、输出、损失和验证协议的监督任务。训练与验证样本应代表部署条件，标签含义应稳定，评价指标必须与实际错误代价一致，候选模型及调整预算应在查看测试结果前确定。序列、分组或时间数据还必须使用尊重依赖结构的划分。

方法局限

有限验证不能证明模型在所有未来分布上可靠；稀有子群、极端代价和分布漂移可能没有被平均指标揭示。统计预测能力也不能自动提供因果解释、公平性或安全保证。候选集合之外的方法不会被比较，计算预算本身会限制可达到的结果。

读前自检：常见错误与误用边界：综合自检与学习路线。 对综合自检与学习路线，条件“边界框
首项禁止用测试集反复调参，再把最后一次测试分数称为独立评估”不可省；请把固定错误“用
测试集反复调参，再把最后一次测试分数称为独立评估”中的对象、操作与结论按本节定义拆开，
指出第一个不满足的定义条件，再把该处改为本节允许的写法，再用改写后的运算或判断有定义，
且不再触发“用测试集反复调参，再把最后一次测试分数称为独立评估”作检查。

常见错误

1. 用测试集反复调参，再把最后一次测试分数称为独立评估；
2. 在交叉验证之前用全数据做标准化、特征选择或缺失值填补；
3. 把算法名称当作完整方案，忽略损失、正则化、停止条件和阈值；
4. 只比较平均分数，不报告波动、校准、子群表现与资源约束；
5. 看到验证结果后修改指标、候选集合或容差，却不重新建立独立验证层。

易混淆概念对比

概念对	第一项	第二项
模型与算法	规定可表达的函数或分布	规定如何求得参数或结构
生成与概率	生成/判别按学习对象划分	概率/非概率按输出数学对象划分
验证误差与测试误差	用于选择方案	用于锁定方案后的最终估计
高表达能力与高泛化能力	描述可拟合关系的丰富程度	描述未知样本上的预测表现
相关解释与因果解释	描述模型条件关联	需要额外识别假设和研究设计

本章共 10 道练习。每道题干后立即给出同号解析；长解析可自然跨页，续页标题保留题号。

练习 23.1. 分别指出模型、策略、算法和评估协议在“带 L_2 正则的逻辑斯谛回归，用阻尼 Newton 法训练并以五折交叉验证选择 λ ”中的对应部分。

练习 23.1 解析

模型是线性对数几率条件概率族

$$P_w(Y = 1 | x) = \sigma(w^T x + b).$$

策略是对每个候选 $\lambda \geq 0$ 最小化

$$J_\lambda(w, b) = - \sum_i \log P_{w,b}(y_i | x_i) + \frac{\lambda}{2} \|w\|_2^2.$$

算法是带步长 $\eta_t \in (0, 1]$ 的阻尼 Newton 更新

$$\theta_{t+1} = \theta_t - \eta_t [\nabla^2 J_\lambda(\theta_t)]^{-1} \nabla J_\lambda(\theta_t).$$

评估协议是五折、折内预处理、候选 λ 集合、指标与最终重训规则；四者任一改变都会形成不同学习方案。

练习 23.2. 验证集有 200 个样本，候选模型数 $M = 8$ ，取 $\delta = 0.05$ 。计算定理 23.1 中的同时偏差上界。

练习 23.2 解析

代入验证样本数 $n = 200$ 、候选数 $M = 8$ 及 $\delta = 0.05$ ，同时偏差项为

$$\begin{aligned} \varepsilon &= \sqrt{\frac{\log M + \log(1/\delta)}{2n}} \\ &= \sqrt{\frac{\log 8 + \log 20}{400}} \\ &= \sqrt{\frac{2.0794 + 2.9957}{400}} \\ &\approx 0.1126. \end{aligned}$$

因此定理给出的同时事件形式为

$$\max_{1 \leq m \leq 8} (R_m - \hat{R}_m) \leq 0.1126$$

(概率至少 $1 - \delta$)。这是与定理一致的单侧同时上界；它不控制 $\hat{R}_m - R_m$ 这一反方向。若需要双侧绝对偏差，必须改用含 $\log(2M/\delta)$ 的常数。

练习 23.3. 判断逻辑斯谛回归、朴素贝叶斯、支持向量机和条件随机场属于生成方法还是判别方法，并说明依据。

练习 23.3 解析

分类依据是学习对象：

方法	主要学习对象	类别
逻辑斯谛回归	$P(Y X)$	判别
朴素贝叶斯	$P(Y)P(X Y)$	生成
支持向量机	$g(X)$ 及分离边界	判别
条件随机场	$P(Y_{1:n} X)$	判别

生成模型可由联合分布得到条件分布

$$P(Y = y | X = x) = \frac{P(Y = y)P(X = x | Y = y)}{\sum_{y'} P(Y = y')P(X = x | Y = y')},$$
$$\hat{y}(x) = \arg \max_y P(Y = y | X = x).$$

但分类仍由其建模对象决定，而不是由是否出现概率符号决定。

练习 23.4. 某文本分类任务只有很少标注样本，但已有可信的类别词频模型。解释生成方法可能具有的优势以及必须核查的假设。

练习 23.4 解析

若可信词频模型提供类条件分布，预测可写为

$$P(Y = k | x) \propto P(Y = k)P(x | Y = k).$$

在朴素分解下，参数结构进一步减少为

$$P(x | Y = k) = \prod_j P(x_j | Y = k),$$

少量标注数据主要估计先验与少数修正量，可能降低方差。必须核验

条件独立近似、词表一致、未登录词平滑、类别先验稳定，

否则结构优势会转化为系统偏差。

练习 23.5. 某 SVM 输出得分 3.2。能否据此报告正类概率为 0.96？说明还需要什么步骤。

练习 23.5 解析

不能直接报告。对任意 $c > 0$ ，分类边界满足

$$\text{sign } g(x) = \text{sign}[c g(x)],$$

练习 23.5 解析 (续)

但数值 3.2 会变成 3.2c, 说明得分尺度不是概率。若需概率, 应在独立校准集或折外预测上拟合, 例如

$$\hat{P}(Y = 1 | g) = \frac{1}{1 + \exp(Ag + B)},$$

再用 Brier 分数、对数损失和可靠性图验证。校准拟合与评估不能复用同一训练得分而忽略过拟合。

练习 23.6. 给定三类概率 (0.6, 0.3, 0.1) 和 0-1 损失, 求 Bayes 动作; 若把真实第 2 类判成第 1 类的代价改为 5, 说明还需怎样计算。

练习 23.6 解析

在 0-1 损失下, 条件风险为

$$R(a | x) = 1 - P(Y = a | x),$$

故

$$a^* = \arg \min_a R(a | x) = \arg \max_a P(Y = a | x) = 1.$$

一般代价矩阵 $C(a, y)$ 下必须计算

$$R(a | x) = \sum_{y=1}^3 C(a, y)P(Y = y | x), \quad a^* \in \arg \min_a R(a | x).$$

只给 $C(1, 2) = 5$ 不足以比较全部动作, 还需其余代价元素。

练习 23.7. 样本数 N 很大而特征维数 d 中等时, 比较线性模型与需要完整 Gram 矩阵的核方法的存储需求。

练习 23.7 解析

忽略共同训练数据后, 线性模型参数状态为

$$w \in \mathbb{R}^d, \quad S_{\text{linear}} = O(d).$$

完整核方法保存 Gram 矩阵

$$G \in \mathbb{R}^{N \times N}, \quad S_{\text{kernel}} = O(N^2).$$

当 $N \gg d$ 时,

$$\frac{S_{\text{kernel}}}{S_{\text{linear}}} = O\left(\frac{N^2}{d}\right),$$

二次存储通常成为瓶颈, 可考虑线性模型、核近似或分块求解。

练习 23.8. 解释为什么提升树虽由简单树组成，整体模型仍可具有很强表达能力。

练习 23.8 解析

提升树的整体函数是加法模型

$$F_M(x) = F_0(x) + \nu \sum_{m=1}^M T_m(x), \quad 0 < \nu \leq 1.$$

每轮树拟合当前负梯度或重加权误差：

$$r_{mi} = - \left. \frac{\partial L(y_i, F)}{\partial F} \right|_{F=F_{m-1}(x_i)}, \quad T_m \approx r_m.$$

不同树在不同区域叠加分段修正，能形成细致分区与高阶交互；表达能力随 M 、树深和 ν 增长，因此需正则化、早停和独立验证。

练习 23.9. 一个任务需要毫秒级预测、系数方向可解释且样本数远大于维数。给出首选基线及仍需验证的风险。

练习 23.9 解析

首选基线可取带正则的逻辑斯谛回归：

$$P(Y = 1 | x) = \sigma(w^\top x + b), \quad T_{\text{pred}} = O(d), \quad S_{\text{model}} = O(d).$$

其系数方向满足

$$w_j > 0 \implies \text{在其他输入固定时，第 } j \text{ 维增加会提高 logit,}$$

但仍需验证线性 logit、共线性、校准、类别不平衡、折外预处理和部署漂移；相关系数不能解释成因果效应。

练习 23.10. 列出一份可复现监督学习实验至少应记录的六类信息。

练习 23.10 解析

可把一次实验登记为结构化记录

$$\mathcal{R} = (\mathcal{T}, \mathcal{D}, \mathcal{P}, \mathcal{M}, \mathcal{O}, \mathcal{V}, \mathcal{E}),$$

其中至少包括

$\mathcal{T}$	任务、标签与评价对象
$\mathcal{D}$	数据来源、时间、划分及排除规则
$\mathcal{P}$	特征与折内预处理
$\mathcal{M}$	模型、损失、正则化与超参数域
$\mathcal{O}$	优化器、初始化、随机种子与停止条件
$\mathcal{V}$	验证指标、选择规则与并列规则
$\mathcal{E}$	阈值、资源测量及一次性测试结果

练习 23.10 解析 (续)

记录需足以重建数据边界、训练状态和选择过程，而不只保存最终分数。具体地，训练信息与评价信息至少满足

$$\begin{aligned}\mathcal{R}_{\text{train}} &= (\mathcal{D}, \mathcal{P}, \mathcal{M}, \mathcal{O}), \\ \mathcal{R}_{\text{eval}} &= (\mathcal{V}, \mathcal{E}), \quad \mathcal{R} = (\mathcal{T}, \mathcal{R}_{\text{train}}, \mathcal{R}_{\text{eval}}).\end{aligned}$$

读前自检：本章结论与下一步。 监督学习方法总结章末把“任务、模型族、学习准则、求解算法与评估协议”收束为“用交叉验证形成可行候选集，在 ϵ 近优集合中按复杂度、波动与约束选择”；请把 ϵ 代入对应定义并写出结果类型，再核对“代入结果满足定义域与取值域”且该结果能直接进入章末所述方法。

读前自检：全册方法选择速查。 在“需要条件概率且强调可解释系数时，先检查逻辑斯谛回归或最大熵模型”成立时处理全册方法选择速查：请把“需要条件概率且强调可解释系数时，先检查逻辑斯谛回归或最大熵模型”中的已声明对象依次标成输入、输出与判据，并以存在隐变量时先写出完整数据似然，再判断 EM 的 E 步和 M 步是否可计算、单调性条件是否成立判定结果。

读前自检：模型选择的数学核对条件。 模型选择的数学核对条件所用的明确前提是“下列条件限定候选之间何时可以比较，并把拟合、选择和最终评价分开”；完成把 ϵ 展开一次并检查其类型或边界后，核对只有这些数学对象与信息边界都固定，候选得分才具有可比性。

本章结论与下一步

核心结论：任务、模型族、学习准则、求解算法与评估协议

关键依据：按学习对象区分生成/判别，按输出语义区分概率/非概率，并在相同数据边界比较风险

可执行自检：用交叉验证形成可行候选集，在 ϵ 近优集合中按复杂度、波动与约束选择

适用边界：需要为具体监督任务比较方法、调参或解释为什么某方法不适用时

下一步：进入无监督学习；任何测试反馈都不得反向改变本章已经固定的选择规则

1. **框架：**能否把任一已学方法拆成模型、策略、算法和评估协议？未通过则回看第 1 节。
2. **分类：**能否不看表格区分生成/判别与概率/非概率，并为四种组合各判断实例？未通过则回看第 2、3 节。
3. **比较：**能否从归纳偏好、训练成本、预测成本、概率语义和可解释性比较四类模型？未通过则回看第 4 节。
4. **选择：**能否设计不泄漏的交叉验证、候选筛选和一次性测试流程？未通过则回看第 5 节及流程 23.5。
5. **应用：**能否为一个新任务列出错误代价、资源约束、漂移风险和复现记录？未通过则回看第 6 节；五项均能独立作答，并能完成每节至少两道练习，才算达到本章学习目标。

全册方法选择速查

1. 需要条件概率且强调可解释系数时，先检查逻辑斯谛回归或最大熵模型；需要生成机制时再比较朴素贝叶斯等生成模型。
2. 需要大间隔与核化非线性时检查支持向量机，同时评估 Gram 矩阵、支持向量数和概率校准成本。
3. 需要处理复杂交互且允许加法集成时比较提升方法，并把树深、学习率、轮数和早停作为联合控制量。

- 4. 存在隐变量时先写出完整数据似然, 再判断 EM 的 E 步和 M 步是否可计算、单调性条件是否成立。
- 5. 面向序列时区分生成式 HMM 与判别式 CRF, 分别核对条件独立假设、特征设计和动态规划复杂度。
- 6. 无论选择哪类方法, 都必须冻结数据划分、预处理、评价指标、阈值、资源测量和测试时点。

常见错误

本册结论不能替代任务验证: 同一算法在标签口径、错误代价、数据漂移或部署预算改变后可能不再合适。最终选择必须保留失败模式、替代基线和可复现实验记录。
建议为一个真实任务完成一页复盘记录: 写明首选模型与基线、三项关键假设、验证协议、资源上限、最可能的失效情形以及触发改换方法的观测信号。若这些信息无法明确填写, 说明方法选择仍未闭环。比较候选模型时应固定数据划分、预处理、初始化、计算预算与评价口径, 使结论可以重复核验。

模型选择的数学核对条件

- 下列条件限定候选之间何时可以比较, 并把拟合、选择和最终评价分开。
- 1. 各候选必须使用同一训练 - 验证划分, 并且每个预处理参数只由对应训练折估计。
 - 2. 各内层问题必须给出有限目标值、可行参数和各自的停止准则; 无有限解的候选不参与排序。
 - 3. 先按预定得分形成 ϵ 近优集合, 再用复杂度、波动与资源约束作并列选择, 不能由测试误差反向改变规则。
 - 4. 概率阈值若属于预测规则, 应在训练开发数据内一并选择; 最终测试集只估计固定规则的误差。只有这些数学对象与信息边界都固定, 候选得分才具有可比性。

第 4 册：无监督学习与矩阵分解

本册从没有标签监督的任务设定出发，通过相似性、低秩结构、重构目标与潜在变量逐步建立无监督学习方法体系。

- 1. 无监督学习概论；
- 2. 聚类方法；
- 3. 奇异值分解；
- 4. 主成分分析；
- 5. 潜在语义分析与非负矩阵分解；
- 6. 概率潜在语义分析。

关键结论

矩阵视角贯穿本册：既用于表示数据和相似关系，也用于提取低维结构，并与概率潜在变量模型建立联系。

学习路径

先用聚类明确相似性、目标函数和评价方式，再由 **SVD** 与 **PCA** 理解正交低秩表示；随后比较潜在语义分析、非负矩阵分解和概率潜在语义分析中的重构约束与潜在语义解释。

跨册依赖与完成标准

本册依赖第 2 章的矩阵与特征值基础，以及第 20 章的隐变量与 **EM** 框架。完成后应能区分聚类、降维、矩阵分解与概率潜变量任务，手算小矩阵的关键步骤，并用重构、稳定性和下游表现评价无监督结果。

第24章 无监督学习概论

读前自检：本章地图：无监督学习概论。 无监督学习概论章地图把“从无标签矩阵直达聚类、表示与潜变量建模”作为主线；请为其中首条箭头补出必要条件，并检查终点仍落在本章声明的输出域。

读前自检：本章可检验学习目标。 无监督学习概论目标中的“能以无标签样本、潜在变量和学习结果三部分严格表述无监督学习问题”必须可复核；请以无标签样本、潜在变量和学习结果三部分严格表述无监督学习问题，所得结果仅在“中间结果逐项包含首目标“能以无标签样本、潜在变量和学习结果三部分严格表述无监督学习问题”声明的对象、条件与结论”时通过。

读前自检：最短先修。 无监督学习概论的最短先修明确要求“本章使用向量与矩阵、欧氏范数、条件概率、贝叶斯公式、经验风险、期望、优化迭代和训练集 – 验证集划分”；请把首项“本章使用向量与矩阵、欧氏范数、条件概率、贝叶斯公式、经验风险、期望、优化迭代和训练集 – 验证集划分”中的第一个先修对象写成定义域 – 运算 – 输出三元组，并以“该三元组逐项满足首项“本章使用向量与矩阵、欧氏范数、条件概率、贝叶斯公式、经验风险、期望、优化迭代和训练集 – 验证集划分”的对象类型与成立条件”判断能否进入本章。

读前自检：先修自检。 无监督学习概论先修自检固定核验“能否核对矩阵 $X \in \mathbb{R}^{N \times M}$ 的每一行对应一个样本、每一列对应一个属性”；请核对矩阵 $X \in \mathbb{R}^{N \times M}$ 的每一行对应一个样本、每一列对应一个属性并写出中间结果，再按“ $X \in \mathbb{R}^{N \times M}$ 的计算或证明结果满足首项所列等式、定义域或判断”明确判为通过或失败。

本章地图

核心问题： 怎样在没有标签误差的情况下定义结构、目标和评价

可检验学习目标：

- 能以无标签样本、潜在变量和学习结果三部分严格表述无监督学习问题；
- 能区分聚类、降维、概率模型估计以及它们所利用的数据结构；
- 能把无监督方法拆成模型、策略、算法，并写出可复核的输入、更新与停止规则；
- 能从联合分布逐步推导潜在变量后验，并解释生成、表示与压缩三种视角；
- 能用稳定性、留出似然、重构误差和下游效用评价结果，同时识别不可辨识与数据泄漏。

最短先修： 本章使用向量与矩阵、欧氏范数、条件概率、贝叶斯公式、经验风险、期望、优化迭代和训练集 – 验证集划分。沿用全书“样本按行”的主约定：设无标签样本为

$$\mathcal{U} = \{x_1, \dots, x_N\}, \quad x_i \in \mathbb{R}^M,$$

并记

$$X = X_{\text{row}} = \begin{bmatrix} x_1^T \\ \vdots \\ x_N^T \end{bmatrix} \in \mathbb{R}^{N \times M}.$$

线性表示因此写成 $Z = XW \in \mathbb{R}^{N \times q}$, 其中 $W \in \mathbb{R}^{M \times q}$ 。只有文档模型使用特殊的词 - 文档计数矩阵 $N_{\text{wd}} \in \mathbb{N}_0^{V \times D}$ (词按行、文档按列); 若把每篇文档的词频向量视为普通样本, 则 $X_{\text{doc}} = N_{\text{wd}}^T \in \mathbb{R}^{D \times V}$ 。独立符号和这条转置桥防止同一个 X 静默换向。

依赖路线: 无标签样本 $\rightarrow$ 相似关系与统计规律; 纵向结构 $\rightarrow$ 聚类; 横向结构 $\rightarrow$ 降维与表示; 联合概率模型 $\rightarrow$ 潜在变量后验与生成; 模型、策略、算法 $\rightarrow$ 可执行学习过程; 内部指标、外部任务与重复抽样 $\rightarrow$ 结果评价和模型选择。

完成标准与返回: 行列约定不清时先核对本章入口; 结构或评价混淆时返回节 24.1、24.4

数据方向桥：行样本与列样本

全书默认把 N 个 M 维样本按行写成 $X_{\text{row}} \in \mathbb{R}^{N \times M}$ 。若局部题目明确改用列样本, 则必须同时写出

$$X_{\text{col}} = [x_1, \dots, x_N] = X_{\text{row}}^T \in \mathbb{R}^{M \times N}.$$

例如 $N = 4, M = 2$ 时, 两种表示分别为 4×2 与 2×4 ; 只改变存储方向, 不改变样本数和属性数。文档模型的词 - 文档矩阵采用列文档, 并使用独立符号避免静默换向。

本章符号表

符号	取值或维数	含义
N	正整数	样本数
M	正整数	每个样本的属性维数
X	$\mathbb{R}^{N \times M}$	以样本为行的数据矩阵
x_i	$\mathbb{R}^M$	第 i 个可观测样本
z_i	$\mathcal{Z}$	与 x_i 对应的潜在结构, 可为类别、低维向量或图结构
g_θ	$\mathcal{X} \rightarrow \mathcal{Z}$	确定性表示或分配函数
$p_\theta(z x)$	$[0, 1]$	给定样本后的潜在变量条件分布
$p_\theta(x z)$	密度或概率质量	潜在结构生成观测的条件模型
$L(\theta)$	$\mathbb{R}$	训练策略定义的目标函数
K	正整数	候选模型中的类别数、维数或复杂度参数

24.1 无监督学习问题

监督学习观察 (x_i, y_i) 并以标签误差约束预测; 无监督学习只观察 x_i , 学习目标不能由标签逐样本给出。它试图在数据中发现可重复的统计规律或潜在结构, 并把该结构用于描述、压缩、生成、异常识别或后续预测。缺少标签并不表示没有假设: 距离、低秩、独立性、稀疏性、平滑性和概率分布族都是结构假设。

读前自检: 无监督学习基本原理。 从无监督学习基本原理的条件“给定仅含观测的样本集 $\mathcal{U} = \{x_i\}_{i=1}^N$ ”出发, 请沿 $\hat{\theta} \in \arg \min_{\theta \in \Theta} L(\theta; \mathcal{U})$ 标出输入域、输出域和一次运算结果的形状; 所得量应符合任何指标都只在其假设范围内有效, 因此必须同时写出尺度、噪声模型和复杂度约束。

读前自检：无监督学习问题。 无监督学习问题给定无标签样本 $\mathcal{U}$ 、结构空间 Θ 和准则 L ；请求一个 $\hat{\theta} \in \arg \min_{\theta \in \Theta} L(\theta; \mathcal{U})$ ，并核对其输出表示或后验落在声明空间。

定义 24.1 (无监督学习问题). 给定仅含观测的样本集 $\mathcal{U} = \{x_i\}_{i=1}^N$ ，选定潜在结构空间 $\mathcal{Z}$ 、模型族 $\mathcal{M} = \{M_\theta : \theta \in \Theta\}$ 和可由无标签数据计算的准则 $L(\theta; \mathcal{U})$ ，无监督学习求

$$\hat{\theta} \in \arg \min_{\theta \in \Theta} L(\theta; \mathcal{U})$$

或等价的极大化问题，并输出表示 $z_i = g_{\hat{\theta}}(x_i)$ 、后验 $p_{\hat{\theta}}(z_i | x_i)$ 、生成模型 $p_{\hat{\theta}}(x, z)$ 或它们的组合。

模型。 模型规定“结构是什么”。确定性模型可写成 $z = g_\theta(x)$ ；概率模型可写成 $p_\theta(x, z)$ 、 $p_\theta(z | x)$ 或 $p_\theta(x | z)$ 。若 z 是有限类别，模型表达分组；若 $z \in \mathbb{R}^d$ 且 $d < M$ ，模型表达低维坐标；若 z 是图或主题比例，模型表达关系或混合成分。

学习策略。 策略把结构质量变成目标。常见策略包括最小化类内离差、最小化重构误差、最大化观测数据似然，或在拟合项上加入复杂度惩罚。任何指标都只在其假设范围内有效，因此必须同时写出尺度、噪声模型和复杂度约束。

读前自检：无监督学习的基本问题。 无监督学习的硬聚类输出 $z_i \in \{1, \dots, K\}$ ，软分配输出 q_{ik} ；请对一个样本检查 $q_{ik} \geq 0$ 并计算 $\sum_k q_{ik}$ ，核对应等于 1 后再与单一 z_i 的输出类型对照。

24.2 基本方法与任务分类

无监督学习的基本任务可按所寻找的结构分类：

1. **聚类：** 把相似样本归入同一类，揭示数据的纵向结构；
2. **降维：** 把高维样本变换为低维表示，揭示属性间的横向结构；
3. **概率模型估计：** 学习 $p_\theta(x, z)$ 的结构与参数，同时描述样本和潜在变量之间的关系；
4. **组合任务：** 先学习表示再聚类，或在潜变量模型中同时得到低维表示与软分配。

定义 24.2 (硬聚类与软聚类). 若每个样本只得到一个类别 $z_i \in \{1, \dots, K\}$ ，称为硬聚类；若输出满足

$$q_{ik} \geq 0, \quad \sum_{k=1}^K q_{ik} = 1$$

的成员概率或隶属度向量 q_i ，称为软聚类。软分配经过最大分量决策可变成硬分配，但会丢失不确定性。

读前自检：降维表示。 先锁定无监督学习概论中的降维表示的条件“给定 $d < M$ ，降维学习编码器 $g_\theta : \mathbb{R}^M \rightarrow \mathbb{R}^d$ ”：检查 $\hat{x}_i = h_\phi(z_i)$ 中每项的类型后完成等式变形，所得结果应满足线性降维限制 g_θ, h_ϕ 为线性映射，非线性降维允许曲面或分段结构。

定义 24.3 (降维表示). 给定 $d < M$, 降维学习编码器 $g_\theta: \mathbb{R}^M \rightarrow \mathbb{R}^d$, 令 $z_i = g_\theta(x_i)$; 若同时有解码器 $h_\phi: \mathbb{R}^d \rightarrow \mathbb{R}^M$, 则重构为 $\hat{x}_i = h_\phi(z_i)$ 。线性降维限制 g_θ, h_ϕ 为线性映射, 非线性降维允许曲面或分段结构。

定义 24.4 (潜变量概率模型). 潜变量模型以

$$p_\theta(x, z) = p_\theta(z)p_\theta(x | z), \quad p_\theta(x) = \sum_{z \in \mathcal{Z}} p_\theta(x, z)$$

描述观测与未观测结构; 连续 z 时将求和替换为积分。学习阶段用观测样本估计 θ , 推断阶段计算或近似 $p_\theta(z | x)$ 。

读前自检：易混淆概念对比：基本方法与任务分类。 无监督任务对比表区分聚类、降维、概率估计与组合任务; 请固定核对聚类和降维两行, 分别核对输出是类别/隶属度还是低维坐标/重构, 并写出各自一项关键风险。

易混淆概念对比			
任务分类与输出。			
任务	主要输出	常见目标	关键风险
聚类	类别或隶属度	类内紧致、类间分离	距离和类别数依赖
降维	低维坐标与可选重构	重构、方差或邻域保持	信息丢失与尺度失真
概率估计	密度、参数、潜变量后验	观测似然或其下界	模型错设与不可辨识
组合任务	表示、类别和生成结构	多个目标的加权组合	权重冲突与评价偏置

读前自检：机器学习三要素。 机器学习三要素把问题限定在“一个可复核的无监督方法必须同时给出三要素：模型规定候选结构”; 请把“一个可复核的无监督方法必须同时给出三要素：模型规定候选结构”中的已声明对象依次标成输入、输出与判据, 检查是否得到只给迭代步骤而不说明所优化的量, 也无法判断停止结果的含义。

24.3 生成式与表示学习视角

一个可复核的无监督方法必须同时给出三要素：模型规定候选结构; 策略规定比较候选结构的目标; 算法规定怎样在有限计算预算内寻找候选解。只写一个损失函数而不说明参数化和优化过程, 不能构成完整方法; 只给迭代步骤而不说明所优化的量, 也无法判断停止结果的含义。

生成式视角先描述潜变量怎样产生观测, 即 $p_\theta(z)p_\theta(x | z)$; 表示学习视角先描述观测怎样生成结构, 即 $z = g_\theta(x)$ 或 $q_\phi(z | x)$ 。二者可在同一模型中相遇: 编码器近似后验, 解码器近似生成条件分布。

无监督方法还可以按数据结构形成一张完整路线图: 聚类用距离或连通性刻画样本之间的纵向分组, 本册随后学习层次聚类与 k 均值; 降维用低秩或最大方差刻画属性之间的横向结构, 本册随后学习奇异值分解、主成分分析、潜在语义分析与非负矩阵分解; 话题分析把文档表示为主

题混合，本册的 PLSA 从极大似然出发，下一册的 LDA 再为文档主题比例加入先验；图分析把对象和关系写成网络，并在下一册用随机游走与 PageRank 寻找全局重要性。前两类首先回答“怎样分组或压缩”，后两类进一步回答“潜在混合或关系结构怎样生成观测”；它们都必须显式给出结构假设、评价准则和可复现算法。

阅读目标：从生成方向的联合分解得到归一化后验与 MAP 判别规则。

对象：潜变量 $z \in \{1, \dots, K\}$ 、先验 $p(z = k)$ 与似然 $p(x | z = k)$ 。

合法条件： $p(z = k) > 0$ 且给定观测满足 $p(x) > 0$ ；求和遍历全部潜状态。

第一步：先把证据写为 $p(x) = \sum_{\ell=1}^K p(z = \ell)p(x | z = \ell)$ 。

推导目标

从潜变量联合分布推导离散潜变量的后验，明确归一化分母和均匀先验下的判别边界。结果用于潜变量推断和最大后验分配。

推导准备

设 $\mathcal{Z} = \{1, \dots, K\}$ ， $p_{\theta}(z = k) > 0$ ，且对给定 x 有 $p_{\theta}(x) > 0$ 。联合分布按生成方向分解为 $p_{\theta}(x, z = k) = p_{\theta}(z = k)p_{\theta}(x | z = k)$ ；所有求和均遍历完整潜变量取值集合。

推导第 1 步：写出条件概率定义。

$$p_{\theta}(z = k | x) = \frac{p_{\theta}(x, z = k)}{p_{\theta}(x)}.$$

推导第 2 步：对潜变量边缘化。

$$p_{\theta}(x) = \sum_{j=1}^K p_{\theta}(x, z = j) = \sum_{j=1}^K p_{\theta}(z = j)p_{\theta}(x | z = j).$$

推导第 3 步：代入并归一化。

$$p_{\theta}(z = k | x) = \frac{p_{\theta}(z = k)p_{\theta}(x | z = k)}{\sum_{j=1}^K p_{\theta}(z = j)p_{\theta}(x | z = j)}.$$

分母不依赖候选类别 k ，所以最大后验分配比较的是 $p_{\theta}(z = k)p_{\theta}(x | z = k)$ 。

定理 24.1 (均匀先验下的后验排序) 若 $p_{\theta}(z = k) = 1/K$ 对所有 k 成立，则对任意 $p_{\theta}(x) > 0$ 的 x ,

$$\arg \max_k p_{\theta}(z = k | x) = \arg \max_k p_{\theta}(x | z = k).$$

若先验不均匀，条件密度相同的两个类别会优先选择先验概率较大的类别。

读前自检：证明：均匀先验下的后验排序。 均匀先验给出后验分子 $K^{-1}p_{\theta}(x | z = k)$ ；请对固定 x 约去各类共同的正分母与 K^{-1} ，核对后验排序等于条件密度排序；先验不均匀时改按 $p_{\theta}(z = k)p_{\theta}(x | z = k)$ 排序。

证明. 将均匀先验代入后验公式，分子为 $K^{-1}p_{\theta}(x | z = k)$ ，分母为所有分子的和。对固定 x ，分母与 k 无关且为正，乘子 K^{-1} 也对所有类相同，因此后验的大小顺序与条件密度的大小顺序一致。若先验不均匀，后验排序由 $p_{\theta}(z = k)p_{\theta}(x | z = k)$ 决定；在两个条件密度相等时，乘积随先验增大而增大。两项结论均得到证明。□

几何理解

几何解释。 把 N 个样本看作 $\mathbb{R}^M$ 中的点。聚类沿样本方向寻找点集的纵向分组；降维沿属性方向寻找低维子空间或流形；联合模型同时解释点的分组和组内形状。改变坐标尺度会改变距离几何，因此标准化属于模型假设的一部分。

概率解释

生成模型把每个潜在结构看作一种数据产生机制。后验分配不是“最近中心”的同义词，而是先验与类条件密度的共同结果。密度形状、方差和混合权重都会移动分配边界；输出后验还能表达靠近边界时的不确定性。

优化解释

优化解释。 表示学习常写成

$$\min_{\theta, \phi} \frac{1}{N} \sum_{i=1}^N \ell(x_i, h_{\phi}(g_{\theta}(x_i))) + \lambda \Omega(\theta, \phi).$$

第一项要求表示足以重构观测，第二项控制维数、平滑性、稀疏性或参数规模。没有 Ω 或容量限制时，模型可能记忆训练样本，而没有提取可迁移结构。




图 24.1 聚类、降维和概率建模分别从样本分组、属性压缩和联合生成三个方向把观测映射为可检验的潜在结构。

使用图 24.1 比较方法时，应先写明采用的是分组、压缩还是生成假设，再为右侧输出安排稳定性、留出指标或下游效用检验；训练目标本身不能替潜在结构命名语义。

24.4 评价、选择与应用

学习算法。下面给出通用的重复验证与有限候选选择流程。它不替代每个候选方法的内部求解算法，而是统一训练、诊断和比较协议。

严格伪代码。算法 24.1 把数据划分、候选训练、独立评价、稳定性计算和最终重拟合按固定顺序连接起来。

流程所需资料与结果。计算需要无标签样本、候选模型与超参数集合、评价准则、指标无量纲化规则、稳定性与复杂度权重 α, β 以及计算预算。比较结束后得到选定模型、结构结果、各项诊断量和停止原因。拟合、稳定性和独立评价彼此分开，避免用同一随机结果同时训练和宣称有效。

参数含义。设候选集合为 $\mathcal{H}$ ，重复次数 R ，验证比例 ρ ，训练容差 ε ，最大迭代数 $T_{\max}$ ，稳定性权重 $\alpha \geq 0$ ，复杂度权重 $\beta \geq 0$ 。 $\mathcal{H}$ 可包含类别数、表示维数、正则强度和初始化方案。

初始化。先固定数据预处理规则、随机重复方案、候选顺序和并列选择规则；每次重复仅用训练部分估计标准化参数。对每个候选配置使用预先登记的多组初值，使不同配置接受同等初始化预算。

常见错误

结构对齐、共同计划与接纳政策。跨重复比较前必须先按对象类型对齐：聚类优先使用 ARI、NMI 或共聚类矩阵等标签置换不变统计量；子空间先正交化，再用主角或投影矩阵距离；非唯一矩阵因子先固定列尺度，并用匈牙利匹配或正交 Procrustes 对齐；主题模型以主题相似度构造代价矩阵后求最优置换。所有候选共用同一组预先登记的 R 次重复。一次失败即淘汰只是可选的保守政策，并非统计定理；默认采用预登记成功率门槛 $\tau \in (0, 1]$ 和每次启动的诊断门。状态为 `budget_stop`，或状态为 `numerical_failure` 但诊断明确仅触发数值平台且目标有限、结构合法的记录，可以参与透明比较；其他数值失败不得冒充有效拟合。评价表不得删去失败记录，并同时报告 R 、成功数 c_h 、失败率、各状态与重启预算；严格全成功政策对应 $\tau = 1$ 。

无监督模型的重复验证与选择：五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

读前自检：无监督模型的重复验证与选择。 无监督模型的重复验证与选择输入“无标签样本、冻结的 R 次拆分或随机源、有限候选集、各候选内部预算、状态接纳规则、成功率门槛 τ 、评价/对齐/尺度/并列规则与 α, β ”，条件“ $R \geq 1$ ”；请做一轮“候选模型、有限指标与对齐结果全部核验

后原子提交该 (h, r) 记录”，以“完成 R 次共同重复、无合格候选、全量重拟合完成或首次全局失败时停止”核对停止证书。

算法 24.1: 无监督模型的重叠验证与选择

输入: $\mathcal{U}, \mathcal{H}, R, \rho, \tau, \alpha, \beta$, 冻结的拆分源、指标尺度、对齐、状态接纳及并列规则
输出: $\hat{h}$ 与全量拟合; $r_{\text{done}}, e_{\text{done}}, \{c_h\}$; **status**、记录表与最终诊断

- 1 若样本/候选为空, $R, \rho, \tau, \alpha, \beta$ 或规则非法, 则返回 $\perp$ 、计数 0、**invalid_input** 及字段诊断
- 2 对每个 h 置 $c_h \leftarrow 0$ 并清零状态计数与有限累计量; 置 $r_{\text{done}} \leftarrow 0, e_{\text{done}} \leftarrow 0$
- 3 **对** $r \leftarrow 1$ **至** R **执行**
- 4 从冻结计划读取或由登记随机源产生训练/验证索引; 随机源中断则保留已有记录并返回
 random_source_failure 及随机源位置诊断; 索引重叠、越界或出现空集则返回 **invalid_input**
 及拆分诊断
- 5 只用训练部分拟合预处理变换
- 6 **对每个** 按固定顺序的 $h \in \mathcal{H}$ **依次执行**
- 7 在候选内部预算内求 $\hat{\theta}_{hr}$ 并无条件保存状态与诊断; 若状态不在预登记接纳集, 或目标/结构/必
 要诊断不合格, 则记录失败但不提交评价
- 8 否则在验证部分计算固定损失/似然并执行本次结构对齐; 若任一对象非有限或不可对齐, 则记
 录失败但不提交评价
- 9 全部门禁通过后原子提交 (h, r) 记录, 令 $c_h \leftarrow c_h + 1, e_{\text{done}} \leftarrow e_{\text{done}} + 1$
- 10 **结束**
- 11 令 $r_{\text{done}} \leftarrow r$
- 12 **结束**
- 13 仅对 $c_h \geq \lceil \tau R \rceil$ 者以其已登记有效记录形成有限平均量, 并把 c_h/R 和失败状态并列报告; 形成
 $S(h) = \bar{L}_{\text{val}}(h) + \alpha\{1 - \text{stab}(h)\} + \beta \text{comp}(h)$
- 14 若汇总非有限则返回已有记录、**numerical_failure**; 若无合格候选则返回 $\hat{h} = \perp$ 、**completed** 及“无可
 用候选”诊断
- 15 按 S 及冻结并列规则选 $\hat{h}$, 再用全部样本新鲜重拟合; 若失败则保留选择与记录, 返回
 numerical_failure 及重拟合阶段诊断
- 16 返回 $\hat{h}$ 、全量模型、实际计数、**completed** 及最终评分/对齐/停止诊断

算法实现说明: 核心五步是冻结重复划分、折内拟合、对象对齐、汇总稳定性与验证量、按冻结规则选择; 失败记录
 和预算属于稳健实现细节 **完整 C1–C14 契约**

循环变量、判断条件与更新顺序。外层循环变量依次为 $r = 1, \dots, R$, 内层依次访问 $h \in \mathcal{H}$ 。每个重复先划分数据并拟合预处理, 再训练候选、保存状态、计算验证量, 随后才按对象类型对齐并计算跨重复稳定性; 全部重复完成后统一评分。判断条件包括数据划分合法、训练数值有限、候选诊断通过、 $c_h \geq \lceil \tau R \rceil$ 以及评分并列规则。

停止条件与返回结果。内层训练在目标相对变化、参数相对变化或一阶残差满足容差时停止; 达到迭代上限、出现非有限数值或空结构时以相应原因停止, 并使该候选整体不合格。外层在预定的同一组 R 次重复和全部候选完成后停止, 返回选定配置、全量重拟合模型、含计划分母 R 与成功次数 c_h 的评价表和每次停止原因。

正确性依据、收敛条件与不收敛情形。给定有限候选集合、固定评分和固定并列规则, 外层选出通过检查者中评分最小的候选, 这是有限枚举正确性的依据。某一候选满足其内部收敛条件, 只说明它在相应优化问题上达到该算法承诺的状态。达到预算上限、目标仍下降或残差未达容差时必须注明“未收敛”, 不得改记为收敛。外层只是有限枚举, 因此不讨论渐近数值收敛; 只需验证枚举终止及每个候选的内部停止条件。

异常与退化

若某次划分使训练集或验证集为空、候选产生非有限目标、全部候选均未通过质量检查，或稳定性因共同样本不足而没有定义，就不能继续静默选择。应明确说明哪一项检查未通过；若全部候选均失败，则给出“无可候选”的结论，并逐项列明原因。

读前自检：复杂度分析：评价、选择与应用。 围绕评价、选择与应用，先采用条件“若候选 h 为每个样本保存宽度 d_h 的表示，令 $D = \max_h d_h$ ”，再由 $H = |\mathcal{H}|$ 的总成本剥离一次迭代或一次样本因子；最后验证不同候选没有唯一共同公式，因此保留参数化表达。

复杂度分析

复杂度假设。 设候选数为 $H = |\mathcal{H}|$ ；候选 h 在一次划分上的训练、验证和新样本推断代价分别为 $C_h^{\text{train}}(N, M)$ 、 $C_h^{\text{eval}}(N, M)$ 和 $C_h^{\text{pred}}(N_{\text{new}}, M)$ 。假设各重复顺序执行，数据以稠密 $N \times M$ 行样本矩阵保存，结构一致性以每个样本的结构标签或表示计算。

训练时间复杂度。 重复选择主代价为 $O(R \sum_{h \in \mathcal{H}} (C_h^{\text{train}} + C_h^{\text{eval}}))$ ，另加跨重复稳定性比较；全量重拟合再增加 $C_{\hat{h}}^{\text{train}}(N, M)$ 。

预测时间复杂度。 对 N_{new} 个新样本应用选定模型的代价为 $O(C_{\hat{h}}^{\text{pred}}(N_{\text{new}}, M))$ ；不同候选没有唯一共同公式，因此保留参数化表达。

空间复杂度。 保存数据需 $O(NM)$ 。若候选 h 为每个样本保存宽度 d_h 的表示，令 $D = \max_h d_h$ ，全部重复的结构结果上界为 $O(RNHD)$ ；纯类别标签对应 $D = 1$ ，才简化为 $O(RNH)$ 。此外还要加各候选模型空间。大规模任务可只保存充分统计量和抽样一致性结果。

读前自检：适用条件与局限：评价、选择与应用。 无监督任务使用距离或概率模型前，先固定本单位、数据类型和独立评价准则；请核对所用距离对该数据类型有定义，并确认候选数和复杂度只由训练外准则选择。

适用条件与局限性

适用条件。 无监督学习适合标签稀缺但观测较多、目标是探索结构或学习预处理表示的任务。应用前应确认样本具有可比含义，距离或概率模型与数据类型相容，样本量足以支持候选复杂度，并且存在至少一种独立评价途径。

方法局限

无标签准则通常不能唯一指定语义；不同距离、先验或表示容量会得到不同结构。潜变量标签可任意置换，某些参数还存在旋转、缩放等不可辨识性。探索结果若没有稳定性与外部效用验证，不能解释为客观类别。

读前自检：常见错误与误用边界：评价、选择与应用。 把评价、选择与应用放在“边界框首项禁止把低维图上的视觉分离当成高维空间中必然存在的类别”下考察：把固定错误“把低维图上的

视觉分离当成高维空间中必然存在的类别”中的对象、操作与结论按本节定义拆开，指出第一个不满足的定义条件，再把该处改为本节允许的写法，并检查改写后的运算或判断有定义，且不再触发“把低维图上的视觉分离当成高维空间中必然存在的类别”。

常见错误

1. 在全部数据上标准化后再划分验证集，造成信息泄漏；

2. 只报告一次初始化的结果，忽略局部最优与随机波动；

3. 用训练目标选择复杂度，又用同一训练目标宣称泛化有效；

4. 把低维图上的视觉分离当成高维空间中必然存在的类别；

5. 把潜变量编号当成具有固定语义的数值大小。

读前自检：易混淆概念对比：评价、选择与应用。 评价、选择与应用要求先确认“对比表首个数据行是“训练目标 | 是否拟合选定策略 | 对新样本有效””；请随后按列复述“训练目标 | 是否拟合选定策略 | 对新样本有效”中的对象、假设与结论，用各列均对应首行对象“训练目标”，且未与表中下一行互换验收。

易混淆概念对比

易混淆概念与评价指标对比。

指标	回答的问题	不能单独保证的性质
训练目标	是否拟合选定策略	对新样本有效
留出似然或重构	是否泛化到同分布样本	结构具有目标语义
重复稳定性	结构是否对抽样和初值稳健	结构有用或无偏
下游效用	表示是否帮助指定任务	对其他任务仍有效
人工审查	结构是否可解释	统计上可重复

例题 24.1 (两个候选表示维数的选择). 某数据集比较 $d = 2$ 与 $d = 10$ 两个表示。五次重复后，标准化验证重构损失分别为 0.40 和 0.25，稳定性分别为 0.90 和 0.55，复杂度分数分别为 0.2 和 1.0。取 $\alpha = 0.5, \beta = 0.1$ ，选择哪个维数？

例题 24.1 解答

读题翻译 两个维数要用同一预先登记的评分规则比较：验证重构损失和复杂度越小越好，稳定性越大越好，因此稳定性以惩罚项 $1 - \text{stab}(d)$ 进入总分。

已知与合法条件 两个候选使用同样的五次重复验证协议，权重 $\alpha = 0.5, \beta = 0.1$ 在比较前固定；测试集不参与表示维数选择。

为什么想到这个方法 按 $S(d) = L_{\text{val}}(d) + \alpha\{1 - \text{stab}(d)\} + \beta \text{comp}(d)$ 计算两项总分，并选择总分较小的维数。

方法选择 分别计算 $d = 2$ 与 $d = 10$ 的总分, 再用分数之差独立核对排序, 最后同时报告三项原始指标所体现的权衡。

推导/计算 计算。 评分统一为

$$S(d) = L_{\text{val}}(d) + 0.5\{1 - \text{stab}(d)\} + 0.1 \text{comp}(d).$$

因此

$$S(2) = 0.40 + 0.5(0.10) + 0.1(0.2) = 0.47, \quad S(10) = 0.25 + 0.5(0.45) + 0.1(1.0) = 0.575.$$

独立核验。 直接比较两者分数之差,

$$S(10) - S(2) = (0.25 - 0.40) + 0.5(0.45 - 0.10) + 0.1(1.0 - 0.2) = 0.105 > 0,$$

与逐项计算的排序一致。

独立核验 权重和指标方向在比较前固定, $S(10) - S(2) = 0.105 > 0$; 测试集未参与选择, 且最终只输出一个维数结论。

结论 按预先登记的规则选择 $d = 2$ 。 $d = 10$ 的重构损失更低, 但稳定性下降和复杂度增加超过重构收益; 报告结论时应同时保留三项原始指标。

本章共 12 道练习。每道题干后立即给出同号解析; 长解析可自然跨页, 续页标题保留题号。

练习 24.1. 数据矩阵有 200 个样本、每个样本 30 个属性, 并按样本为列存储。写出 X 的维数; 若表示维数降为 5, 写出表示矩阵 Z 的维数。

练习 24.1 解析

按“属性为行、样本为列”的约定, 维数链为

$$x_i \in \mathbb{R}^{30}, \quad X = [x_1, \dots, x_{200}] \in \mathbb{R}^{30 \times 200},$$

$$z_i \in \mathbb{R}^5, \quad Z = [z_1, \dots, z_{200}] \in \mathbb{R}^{5 \times 200}.$$

表示映射只把每列由 30 维变成 5 维, 样本数仍是 200; 本题明确采用列样本, 所以若改写成 200×5 , 必须同时声明使用转置后的行样本表示, 不能静默换向。

练习 24.2. 说明“没有标签”为什么不等于“没有目标”, 并各举一个聚类 and 降维目标。

练习 24.2 解析

“无标签”只表示训练数据中没有给定 y_i ；结构假设仍会定义目标。例如， k 均值聚类使用

$$J_{\text{clu}}(c, \mu) = \sum_{i=1}^n \|x_i - \mu_{c_i}\|_2^2, \quad (\hat{c}, \hat{\mu}) \in \arg \min_{c_i \in [K], \mu_k \in \mathbb{R}^d} J_{\text{clu}},$$

而编码器 f 、解码器 g 的降维可使用

$$J_{\text{rec}}(f, g) = \sum_{i=1}^n \|x_i - g(f(x_i))\|_2^2, \quad (\hat{f}, \hat{g}) \in \arg \min_{f, g} J_{\text{rec}}.$$

两式均只读取 x_i ，但分别引入簇中心结构与可重构的低维结构。

练习 24.3. 两个属性分别以米和毫米记录。若直接使用欧氏距离，哪个属性更可能支配结果？给出一种处理方式及其代价。

练习 24.3 解析

同一物理差异满足 $1 \text{ m} = 1000 \text{ mm}$ ，所以直接计算平方距离时

$$(\Delta x_{\text{mm}})^2 = 10^6 (\Delta x_{\text{m}})^2,$$

毫米坐标更容易支配欧氏距离。只用训练集估计 $\mu_j, s_j > 0$ 后，可作

$$z_{ij} = \frac{x_{ij} - \mu_j}{s_j}, \quad \|z_i - z_\ell\|_2^2 = \sum_j \frac{(x_{ij} - x_{\ell j})^2}{s_j^2}.$$

代价是距离从物理单位变成标准差单位；若原尺度本就表达重要性，这一变换也会移除相应权重。

练习 24.4. 某方法为每个样本输出 $(0.1, 0.7, 0.2)$ 。判断这是硬聚类还是软聚类；若转为硬分配，类别是什么，损失了什么信息？

练习 24.4 解析

令 $r = (0.1, 0.7, 0.2)$ 。因为

$$r_k \geq 0 \ (k = 1, 2, 3), \quad \sum_{k=1}^3 r_k = 0.1 + 0.7 + 0.2 = 1,$$

r 是三类软分配。最大分量规则给出

$$\hat{c} = \arg \max_{k \in \{1, 2, 3\}} r_k = 2, \quad r \mapsto e_2 = (0, 1, 0).$$

硬分配只保留索引 2，丢失 0.7 的不确定程度以及其余两类的 0.1, 0.2 权重，因此不能从 e_2 恢复 r 。

练习 24.5. 编码器把 $\mathbb{R}^{100}$ 映射到 $\mathbb{R}^8$ 。若没有解码器, 能否仅由“维数更低”断言表示保留了主要信息?

练习 24.5 解析

不能。常数编码器就是反例:

$$f: \mathbb{R}^{100} \rightarrow \mathbb{R}^8, \quad f(x) \equiv 0 \implies f(x_i) = f(x_j) \text{ 对任意 } i, j.$$

它满足“100 维降到 8 维”, 却完全丢失样本差异。必须另定义可检验准则, 例如有解码器 g 时的

$$L_{\text{rec}} = \frac{1}{n} \sum_{i=1}^n \|x_i - g(f(x_i))\|_2^2,$$

或邻域保持、独立下游损失与重复拟合稳定性, 并与简单基线比较。

练习 24.6. 给定二类潜变量 $z \in \{1, 2\}$, 写出 $p_\theta(x)$, 并说明为什么只观察 x 仍可估计混合模型参数。

练习 24.6 解析

边缘分布为

$$p_\theta(x) = p_\theta(z=1)p_\theta(x|z=1) + p_\theta(z=2)p_\theta(x|z=2).$$

若观测 $x_1, \dots, x_n$ 独立同分布, 则

$$\hat{\theta} \in \arg \max_{\theta \in \Theta} \ell(\theta), \quad \ell(\theta) = \sum_{i=1}^n \log p_\theta(x_i).$$

所以即使 z 未观测, 样本仍通过边缘密度约束参数; 能否唯一恢复各成分还取决于可辨识性、样本量和初始化。

练习 24.7. 两类先验为 $(0.8, 0.2)$, 某点的类条件密度为 $(0.1, 0.3)$ 。计算未归一化后验权重和归一化后验。

练习 24.7 解析

未归一化权重及归一化后验依次为

$$\begin{aligned} \tilde{r}_1 &= 0.8 \times 0.1 = 0.08, & \tilde{r}_2 &= 0.2 \times 0.3 = 0.06, \\ r_1 &= \frac{0.08}{0.08 + 0.06} = \frac{4}{7}, & r_2 &= \frac{0.06}{0.08 + 0.06} = \frac{3}{7}. \end{aligned}$$

尽管第二类条件密度更高, 较大的第一类先验使最大后验类别变为第 1 类。

练习 24.8. 证明后验公式对 k 求和等于 1, 并指出证明所需的分母条件。

练习 24.8 解析

对 k 求和,

$$\sum_{k=1}^K p_{\theta}(z=k|x) = \frac{\sum_k p_{\theta}(z=k)p_{\theta}(x|z=k)}{\sum_j p_{\theta}(z=j)p_{\theta}(x|z=j)} = 1.$$

需要分母 $p_{\theta}(x)$ 严格为正; 若模型给 x 零边缘概率, 条件分布在该点没有定义, 应先修正支撑或模型。

练习 24.9. 在重构目标中令编码器和解码器容量足以逐样本记忆。说明训练重构误差为 0 为什么不能证明学到了稳定表示。

练习 24.9 解析

若模型容量足够, 可给每个训练样本分配专用码 z_i 并令

$$f(x_i) = z_i, \quad g(z_i) = x_i \implies L_{\text{train}} = \frac{1}{n} \sum_{i=1}^n \|x_i - g(f(x_i))\|_2^2 = 0.$$

这证明训练点被记忆, 并不推出对新样本 X' 有

$$L_{\text{test}} = \mathbb{E}\|X' - g(f(X'))\|_2^2 \approx 0.$$

因此还要检查独立样本重构或下游性能, 并用低维、平滑、稀疏、噪声扰动或参数正则限制记忆。

练习 24.10. 某配置三次聚类的一致性为 0.92, 0.90, 0.30。只报告平均值是否充分? 还应检查什么?

练习 24.10 解析

三次结果的均值和极差为

$$\bar{s} = \frac{0.92 + 0.90 + 0.30}{3} = 0.706\bar{6}, \quad R = \max_t s_t - \min_t s_t = 0.62.$$

$\bar{s}$ 掩盖了一次明显失稳, 所以还应报告逐次结果、最小值或分位数, 并检查该次的数据划分、初始化、空类、异常点和停止原因。若低值可重复出现, 应改进初始化、降低复杂度或承认结构对扰动敏感。

练习 24.11. 为什么标准化参数必须只用训练部分估计? 说明使用全体样本均值会泄漏什么。

练习 24.11 解析

设训练索引集为 T 、验证索引集为 V 。合法变换只由 T 决定:

$$\mu_T = \frac{1}{|T|} \sum_{i \in T} x_i, \quad s_T^2 = \frac{1}{|T|} \sum_{i \in T} (x_i - \mu_T)^2, \quad z_i = \frac{x_i - \mu_T}{s_T} \quad (i \in T \cup V).$$

练习 24.11 解析 (续)

若改用

$$\mu_{T \cup V} = \frac{1}{|T| + |V|} \sum_{i \in T \cup V} x_i,$$

则 V 中的取值已进入训练坐标变换, 验证集不再独立模拟新数据, 指标可能乐观。

练习 24.12. 一个模型达到最大迭代数时目标仍持续下降。应把停止状态写成“收敛”吗? 给出后续处理。

练习 24.12 解析

不能。若停止准则是相对目标变化不超过 ε , 则在 $t = T_{\max}$ 时仍有

$$\delta_t = \frac{|J_t - J_{t-1}|}{\max\{1, |J_{t-1}|\}} > \varepsilon, \quad J_t \leq J_{t-1},$$

只能记录为“达到迭代上限且尚未满足收敛准则”, 不能写成收敛。应保存 $J_t, \delta_t, T_{\max}$, 增加迭代上限或调整优化参数后复核; 比较模型时也不能把未充分优化的较差目标误判为模型本身能力不足。

读前自检: 本章结论与下一步。 无监督学习概论章末把“无标签样本、潜在结构、生成模型与表示映射”收束为“在重复划分中拟合有限候选, 记录全部状态, 并按预登记成功率和诊断门透明比较”; 请把 z 代入对应定义并写出结果类型, 再核对“代入结果满足定义域与取值域”且该结果能直接进入章末所述方法。

本章结论与下一步

核心结论: 无标签样本、潜在结构、生成模型与表示映射

关键依据: 由联合分布边缘化得到潜变量后验, 并区分从 z 到 x 的生成方向和从 x 到 z 的表示方向

可执行自检: 在重复划分中拟合有限候选, 记录全部状态, 并按预登记成功率和诊断门透明比较

适用边界: 需要聚类、降维、生成或异常结构而没有逐样本标签监督时

下一步: 进入聚类; 继续使用 $X \in \mathbb{R}^{N \times M}$ 的行样本约定, 文档矩阵另用 $\mathbf{N}_{\text{wd}}$ 并显式转置

1. **问题:** 能否用 $\mathcal{U}, \mathcal{Z}, \mathcal{M}, \mathcal{L}$ 完整写出无监督学习问题? 未通过则回看第 1 节。
2. **分类:** 能否区分聚类、降维和概率模型估计的输出与假设? 未通过则回看第 2 节。
3. **推导:** 能否从联合分布三步得到潜变量后验并解释先验作用? 未通过则回看第 3 节。
4. **算法:** 能否说明输入、候选、初始化、更新、停止、收敛和复杂度? 未通过则回看第 4 节。
5. **评价:** 能否识别泄漏、随机失稳、不可辨识和训练指标复用? 未通过则回看第 4 节; 五项均可独立作答, 并能完成至少八道练习, 才算达到本章学习目标。

第25章 聚类方法

读前自检：本章地图：聚类方法。 聚类方法章地图以“从表示与距离直达层次聚类和 k 均值”组织内容；请把路线拆成起点、关键工具和终点，并核对三者的输入输出类型能依次衔接。

读前自检：本章可检验学习目标。 聚类方法学习目标固定核验“能严格定义硬聚类、样本距离、类间连接和类内离差目标”；请实际完成“严格定义硬聚类、样本距离、类间连接和类内离差目标”，并用“中间结果逐项包含首目标“能严格定义硬聚类、样本距离、类间连接和类内离差目标”声明的对象、条件与结论”判定通过或失败。

读前自检：最短先修。 聚类方法的最短先修明确要求“本章使用向量范数、内积、均值、协方差矩阵、正定矩阵、集合划分、有限组合、条件概率和交替优化”；请把首项“本章使用向量范数、内积、均值、协方差矩阵、正定矩阵、集合划分、有限组合、条件概率和交替优化”中的第一个先修对象写成定义域 – 运算 – 输出三元组，并以“该三元组逐项满足首项“本章使用向量范数、内积、均值、协方差矩阵、正定矩阵、集合划分、有限组合、条件概率和交替优化”的对象类型与成立条件”判断能否进入本章。

读前自检：先修自检。 聚类方法先修自检固定核验“能否验证欧氏距离的非负性、对称性和三角不等式”；请验证欧氏距离的非负性、对称性和三角不等式并写出中间结果，再按“中间结果直接回答首项“能否验证欧氏距离的非负性、对称性和三角不等式”并给出通过或失败”明确判为通过或失败。

本章地图

核心问题：怎样把相似性、类间连接与类内目标变成可复算的划分

可检验学习目标：

- 能严格定义硬聚类、样本距离、类间连接和类内离差目标；
- 能判断闵可夫斯基距离、马哈拉诺比斯距离、相关系数与夹角余弦各自忽略或保留的信息；
- 能执行聚合层次聚类，并解释单连接、完全连接、中心连接和平均连接的边界；
- 能逐步推导 k 均值中心更新，证明目标单调不增与有限分配下的终止；
- 能完整说明算法输入、初始化、分配、更新、空类处理、停止、复杂度与模型选择。

最短先修：本章使用向量范数、内积、均值、协方差矩阵、正定矩阵、集合划分、有限组合、条件概率和交替优化。样本为 $x_i \in \mathbb{R}^m$, $i = 1, \dots, n$ ；数据矩阵按列排列为 $X = [x_1, \dots, x_n] \in \mathbb{R}^{m \times n}$ 。距离计算前必须先确定缺失值、类别属性和量纲的处理规则。

依赖路线：数据预处理 → 距离或相似度；样本距离 → 类内特征与类间连接；连接规则 → 层次合并序列；平方欧氏距离 → k 均值目标；固定中心的最近分配 ↔ 固定分配的均值更新；交替下降 → 局部最优与多初值选择。

完成标准与返回：尺度或距离无定义时回到节 25.2；目标不降或空类出现时回看节 25.4、25.5

数据方向桥：聚类公式采用列样本

本章为便于写中心和距离，采用 $X_{\text{col}} = [x_1, \dots, x_n] \in \mathbb{R}^{m \times n}$ ；它与全书默认的行样本矩阵满足

$$X_{\text{row}} = X_{\text{col}}^T \in \mathbb{R}^{n \times m}.$$

例如 $n = 4, m = 2$ 时，本章矩阵为 2×4 ，默认表示为 4×2 。均值、中心和距离都作用于 m 维样本，转置只改变矩阵存放方向。

本章符号表

符号	取值或维数	含义
n, m, k	正整数	样本数、属性维数、类别数
x_i	$\mathbb{R}^m$	第 i 个样本
G_ℓ	$\{x_1, \dots, x_n\}$ 的非空子集	第 ℓ 个类或簇
$C(i)$	$\{1, \dots, k\}$	样本 i 的硬类别编号
$d(x_i, x_j)$	$[0, \infty)$	样本距离
$D(G_p, G_q)$	$[0, \infty)$	两类之间的连接距离
μ_ℓ	$\mathbb{R}^m$	第 ℓ 类中心
n_ℓ	正整数	第 ℓ 类样本数
$W(C, \mu)$	$[0, \infty)$	类内平方和目标
T, V	正数	类内平均距离阈值与最大距离阈值

读前自检：聚类方法。 聚类方法中的聚类方法把问题限定在“聚类根据样本属性的相似度或距离，把样本归并为若干类”；请把“聚类根据样本属性的相似度或距离，把样本归并为若干类”中的已声明对象依次标成输入、输出与判据，检查是否得到聚类结果可用于数据概括、分层浏览、异常筛查和后续监督学习的预处理，但类别编号本身不具有数值次序。

25.1 聚类问题与相似度

聚类根据样本属性的相似度或距离，把样本归并为若干类。类并非预先标注；算法只能在选定表示和度量下寻找结构。聚类结果可用于数据概括、分层浏览、异常筛查和后续监督学习的预处理，但类别编号本身不具有数值次序。

读前自检：聚类的基本概念。 在“样本集合 $\mathcal{X} = \{x_1, \dots, x_n\}$ 的 k 类硬聚类是非空子集 $G_1, \dots, G_k$ ”成立时处理聚类的基本概念：请把 $G_p \cap G_q$ 展开一次并检查其类型或边界，并以展开后的量满足定义中的域、维数或符号限制判定结果。

读前自检：硬聚类。 硬聚类 $G_1, \dots, G_k$ 均非空；请逐对核对 $G_p \cap G_q = \emptyset (p \neq q)$ 并计算 $\bigcup_{\ell=1}^k G_\ell = \mathcal{X}$ ，再验证对应映射 C 是满射。

定义 25.1 (硬聚类). 样本集合 $\mathcal{X} = \{x_1, \dots, x_n\}$ 的 k 类硬聚类是非空子集 $G_1, \dots, G_k$, 满足

$$G_p \cap G_q = \emptyset \quad (p \neq q), \quad \bigcup_{\ell=1}^k G_\ell = \mathcal{X}.$$

等价地, 可用满射 $C: \{1, \dots, n\} \rightarrow \{1, \dots, k\}$ 表示, 其中 $C(i) = \ell$ 当且仅当 $x_i \in G_\ell$.

读前自检：工作性检查表：四种类内阈值。 四种类内阈值表设类 G 含 $n_G \geq 2$ 个样本；请对两点类计算全直径、近邻连通、平均距离与中心距离四项，核对平均距离分母 $n_G(n_G - 1)$ 非零。

工作性检查表：四种类内阈值

为比较不同聚类约束，设 G 含 $n_G \geq 2$ 个样本， $d_{ij} = d(x_i, x_j)$ 。给定 $T > 0$ ，以下四项是本讲义并列整理的检查条件，而不是来源教材中的一个编号定义；第四项另给 $V > 0$ ：

1. 对任意不同的 $x_i, x_j \in G$ ，有 $d_{ij} \leq T$ ；
2. 对每个 $x_i \in G$ ，至少存在 $x_j \in G \setminus \{x_i\}$ 使 $d_{ij} \leq T$ ；
3. 对每个 $x_i \in G$ ，有 $\frac{1}{n_G-1} \sum_{x_j \in G} d_{ij} \leq T$ ，其中 $d_{ii} = 0$ ；
4. 同时有 $\frac{1}{n_G(n_G-1)} \sum_{x_i \in G} \sum_{x_j \in G} d_{ij} \leq T$ 和 $d_{ij} \leq V$ 对所有点对成立。

第一项控制全部点对，第二项只要求局部邻接，第三项限制每一点到类内其余样本的平均距离，第四项同时限制总体平均与极端距离。阈值含义不同，不能只保留“类”这个名称而丢弃约束。

定义 25.2 (距离与相似度). 距离 $d(x, y)$ 通常满足 $d(x, y) \geq 0$ 、 $d(x, y) = 0 \Leftrightarrow x = y$ 、对称性和三角不等式；相似度 $s(x, y)$ 通常数值越大表示越相似，但未必满足度量公理。把相似度改写为 $1 - s$ 只有在取值范围和三角性质经过核对后才可能成为距离。

读前自检：相似度或距离。 相似度或距离中的“平方欧氏量 $\|x_i - x_j\|_2^2$ 常用于优化，但它本身不满足三角不等式”决定可执行范围；请把 $d_p(x_i, x_j)$ 展开一次并检查其类型或边界，结果须满足对 $x_i = (x_{1i}, \dots, x_{mi})^T$ 和 $x_j = (x_{1j}, \dots, x_{mj})^T$ 。

25.2 距离与相似度量

对 $x_i = (x_{1i}, \dots, x_{mi})^T$ 和 $x_j = (x_{1j}, \dots, x_{mj})^T$ ， $p \geq 1$ 时的闵可夫斯基距离为

$$d_p(x_i, x_j) = \left(\sum_{a=1}^m |x_{ai} - x_{aj}|^p \right)^{1/p}.$$

$p = 2$ 得到欧氏距离， $p = 1$ 得到曼哈顿距离， $p \rightarrow \infty$ 得到切比雪夫距离 $d_\infty(x_i, x_j) = \max_a |x_{ai} - x_{aj}|$ 。平方欧氏量 $\|x_i - x_j\|_2^2$ 常用于优化，但它本身不满足三角不等式。

若 $S \in \mathbb{R}^{m \times m}$ 正定, 马哈拉诺比斯距离为

$$d_S(x_i, x_j) = \sqrt{(x_i - x_j)^T S^{-1} (x_i - x_j)}.$$

令 $S = LL^T$, 则 $d_S(x_i, x_j) = \|L^{-1}(x_i - x_j)\|_2$, 所以它等于白化坐标中的欧氏距离。 S 奇异或估计不稳定时, 应使用正则化 $S_\gamma = S + \gamma I$; 若改用 Moore-Penrose 伪逆 S^+ , 则 $\sqrt{(x_i - x_j)^T S^+ (x_i - x_j)}$ 只保证为半度量, 因为相差向量落在 $N(S)$ 中的两个不同样本也可能得到零距离。

读前自检: 夹角余弦。 把聚类方法中的夹角余弦放在 “ $s_{\cos}(x_i, x_j) = \frac{x_i^T x_j}{\|x_i\|_2 \|x_j\|_2}$.” 下考察: 把 $s_{\cos}(x_i, x_j)$ 展开一次并检查其类型或边界, 并检查若数据含负值, 余弦可为负, 评价时不能默认取值在 $[0, 1]$ 。

非零向量的夹角余弦为

$$s_{\cos}(x_i, x_j) = \frac{x_i^T x_j}{\|x_i\|_2 \|x_j\|_2}.$$

它对正比例缩放不变, 主要比较方向; 零向量没有定义。若数据含负值, 余弦可为负, 评价时不能默认取值在 $[0, 1]$ 。

读前自检: 相关系数。 聚类方法中的相关系数要求先确认 “若某样本各属性恒定, 分母为 0, 相关系数没有定义”; 请随后检查 $\bar{x}_i = m^{-1} \sum_{a=1}^m x_{ai}$ 中每项的类型后完成等式变形, 用两种语义会产生不同聚类, 不能在算法运行后按结果好坏临时决定是否取绝对值验收。

将两个样本各自按属性中心化, 记 $\bar{x}_i = m^{-1} \sum_{a=1}^m x_{ai}$, 则相关系数为

$$r_{ij} = \frac{\sum_{a=1}^m (x_{ai} - \bar{x}_i)(x_{aj} - \bar{x}_j)}{\sqrt{\sum_a (x_{ai} - \bar{x}_i)^2} \sqrt{\sum_a (x_{aj} - \bar{x}_j)^2}}.$$

相关系数同时忽略加性平移与正比例缩放; 若某样本各属性恒定, 分母为 0, 相关系数没有定义。若 “同向变化” 才算相似, 应直接使用有符号 r_{ij} , 此时 $r_{ij} \approx -1$ 表示强烈反向而不是相似; 若只关心线性关联强度而不关心方向, 可预先声明使用 $|r_{ij}|$, 此时接近 1 的正、负相关都被视为相似。两种语义会产生不同聚类, 不能在算法运行后按结果好坏临时决定是否取绝对值。

读前自检: 全直径阈值类。 全直径阈值类要求任意不同 $x_i, x_j \in G$ 均满足 $d_{ij} \leq T$; 请计算类内全部点对距离的最大值 D_G , 核对 $D_G \leq T$ 时且仅当该条件通过。

读前自检: 近邻连通阈值类。 近邻连通阈值类要求每个 $x_i \in G$ 至少存在一个不同点 x_j 使 $d_{ij} \leq T$; 请对每个 i 计算 $\min_{j \neq i} d_{ij}$, 核对这些最小值全部不超过 T 。

读前自检: 平均距离阈值类。 平均距离阈值类设 $n_G \geq 2$; 请对每个 $x_i \in G$ 计算 $(n_G - 1)^{-1} \sum_{j \neq i} d_{ij}$, 核对分母非零且所有逐点平均均不超过 T 。

上述工作性检查表中的四个条件分别对应这四类约束。第一项会推出其余三项：逐点平均和总体平均均由不超过 T 的非负项组成，并可在第四项取 $V = T$ ；完整证明见章末原书练习整理。

类中心、直径、散布矩阵和样本协方差可写成

$$\bar{x}_G = \frac{1}{n_G} \sum_{x_i \in G} x_i, \quad D_G = \max_{x_i, x_j \in G} d_{ij},$$

$$A_G = \sum_{x_i \in G} (x_i - \bar{x}_G)(x_i - \bar{x}_G)^T, \quad S_G = \frac{1}{n_G - 1} A_G \quad (n_G > 1).$$

常见错误

经验证的来源勘误 (ERR-14-001)。核对对象为《统计学习方法（第2版）》2019年5月第2版、2019年6月第2次印刷，ISBN 978-7-302-51727-6；原书PDF第283页（印刷页第260页）式(14.13)写作 $S_G = A_G/(m-1)$ ，同页把 m 定义为属性维数。建议更正为无偏样本协方差 $S_G = A_G/(n_G-1)$ ；若明确采用高斯极大似然定义，则分母为 n_G 。独立核验包括：取 $n_G = 3, m = 2$ 和样本 $(0,0), (1,0), (2,0)$ ，有 $A_G = \text{diag}(2,0)$ ，无偏协方差应为 $\text{diag}(1,0)$ ，而原式错误给出 $\text{diag}(2,0)$ ；一维属性 $m = 1$ 时原式还会除以零。该结论另与 NIST 关于样本协方差自由度的定义交叉核对。此记录是工程内部页面、反例与权威定义核验，不冒充出版社官方勘误；完整证据见下列勘误记录。

设 G_p, G_q 的中心分别为 $\bar{x}_p, \bar{x}_q$ ，常见连接为

$$D_{\text{single}}(G_p, G_q) = \min_{x_i \in G_p, x_j \in G_q} d_{ij},$$

$$D_{\text{complete}}(G_p, G_q) = \max_{x_i \in G_p, x_j \in G_q} d_{ij},$$

$$D_{\text{centroid}}(G_p, G_q) = d(\bar{x}_p, \bar{x}_q),$$

$$D_{\text{average}}(G_p, G_q) = \frac{1}{n_p n_q} \sum_{x_i \in G_p} \sum_{x_j \in G_q} d_{ij}.$$

单连接重视最近桥点，完全连接重视最远点，平均连接折中全部点对，中心连接只保留一阶统计量。

常见错误

中心连接的合并高度不一定单调。树状图的纵轴记录“本轮所选连接值”，但对中心连接，合并后中心移动可能使下一连接值反而更小，形成倒置。例如在平面取

$$x_1 = (-1, 0), \quad x_2 = (1, 0), \quad x_3 = (0, \sqrt{3}).$$

三个点两两距离均为 2。若并列规则先合并 $\{x_1\}, \{x_2\}$ ，第一高度为 2；新中心是 $(0,0)$ ，到 x_3 的中心距离却为 $\sqrt{3} < 2$ ，故第二高度下降。这个反例说明不能把所有连接的合并高度都当作单调序列。初学实现优先使用 **single**、**complete**、**average** 或满足相应条件的 **Ward** 连接；若使用 **centroid**，必须保留原始合并次序并显式标记倒置，不能排序高度来“修复”树。

读前自检：层次聚类。 聚合层次聚类从 n 个单点类开始，并须固定样本度量、类间连接、并列规则与停止条件；请对当前距离最小的两个类执行一次合并，核对新划分严格嵌套且类数减少 1。

25.3 层次聚类

层次聚类输出一串嵌套划分。聚合法从 n 个单点类出发，每次合并两个类；分裂法从一个全集类出发，每次拆分一个类。本节采用聚合法。算法必须先固定样本度量、类间连接、并列最小值规则和停止条件，否则同一数据无法复现唯一合并序列。

阅读目标： 在簇划分固定时证明样本均值是类内平方和的唯一极小点。

对象： 非空簇 G_ℓ 、样本 $x_i \in \mathbb{R}^m$ 与中心 $\mu \in \mathbb{R}^m$ 。

合法条件： $n_\ell = |G_\ell| > 0$ ；簇成员在本步固定。

第一步： 先令 $\bar{x}_\ell = n_\ell^{-1} \sum_{i \in G_\ell} x_i$ ，并把 $x_i - \mu$ 分解为 $(x_i - \bar{x}_\ell) + (\bar{x}_\ell - \mu)$ 。

读前自检：聚合聚类算法。 聚合聚类算法输入“有限样本、非负有限样本距离、已定义连接、目标类数或阈值以及固定并列规则”，条件“ $n \geq 1, 1 \leq k_{\text{stop}} \leq n$ ”；请做一轮“新类到其余类的连接全部有限后，才原子替换两个旧类、提交合并记录并增加 m_{done} ”，以“达到 k_{stop} 、下一合并超过阈值或首次失败时停止”核对停止证书。

聚合层次聚类：五步阅读

输入。 写出数据对象、固定参数与必须成立的条件。

初始化。 标明主状态、计数器和第一个合法状态。

核心更新。 只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。 写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。 列出返回对象、实际计数、中心状态和用于复核的诊断。

读前自检：聚合层次聚类。 聚合层次聚类输入“有限样本、非负有限样本距离、已定义连接、目标类数或阈值以及固定并列规则”，条件“ $n \geq 1, 1 \leq k_{\text{stop}} \leq n$ ”；请做一轮“新类到其余类的连接全部有限后，才原子替换两个旧类、提交合并记录并增加 m_{done} ”，以“达到 k_{stop} 、下一合并超过阈值或首次失败时停止”核对停止证书。

参数、初始化与循环变量。 参数为 d, D, k_{stop}, T 和并列规则；初始化为 n 个单点类及其类间距离。循环变量可取当前类数 $|G|$ ，每次成功合并后严格减 1。

更新顺序与判断条件。 每轮先找最小连接类对，再判断阈值；只有通过阈值判断才创建并替换新类，随后更新新类到其余类的距离。不得先更新距离再决定本轮合并。

停止条件与返回结果。 达到目标类数、下一合并超过阈值或发现输入异常时停止，返回嵌套合并记录、最终划分和停止原因。仅给阈值时，算法也会在至多 $n - 1$ 次合并后停止。

异常与退化。 若 $n < 1, k_{\text{stop}} \notin \{1, \dots, n\}$ 、距离为负或非有限、连接未定义，输入不合法；所有距离并列时必须使用固定规则。完全重合样本可在高度 0 合并，这不是错误，但应保留样本身份。

算法 25.1: 聚合层次聚类

输入: 样本 $x_1, \dots, x_n$, 样本距离 d , 连接 D , 目标类数 k_{stop} 或阈值 T ; 仅用阈值时令 $k_{\text{stop}} = 1$

输出: 最后合法划分与合并表; $m_{\text{done}}, d_{\text{done}}$; **status** 与最终诊断

- 1 若 n, k_{stop}, T 、样本、距离/连接接口或并列规则非法, 则返回 **1**、计数 **0**、**invalid_input** 及字段诊断
- 2 初始化 $\mathcal{G} \leftarrow \{\{x_1\}, \dots, \{x_n\}\}$, 合并表为空, $m_{\text{done}} \leftarrow 0, d_{\text{done}} \leftarrow 0$; 计算所有不同类对连接并累计 d_{done} ; 若有负值或非有限值则返回单点划分、**numerical_failure** 及类对诊断
- 3 **当** $|\mathcal{G}| > k_{\text{stop}}$ **执行**
- 4 选择连接距离最小的类对 (G_p, G_q) ; 并列时按登记的类标识顺序选择
- 5 **若** 使用阈值停止且 $D(G_p, G_q) > T$ **则**
- 6 返回当前划分与记录、**completed** 及“下一合并超过阈值”诊断
- 7 **结束**
- 8 在临时对象中创建 $G_{\text{new}} = G_p \cup G_q$, 计算它到其余各类的连接并累计 d_{done} ; 若任一结果非有限或为负, 则拒绝候选并返回上一划分、**numerical_failure** 及失败类对诊断
- 9 原子地从 $\mathcal{G}$ 删除 G_p, G_q 、加入 G_{new} 并追加成员/高度记录; 令 $m_{\text{done}} \leftarrow m_{\text{done}} + 1$
- 10 **结束**
- 11 返回全部合并记录、最终划分、实际计数、**completed** 及“达到目标类数”诊断

正确性依据。初始时各单点类构成划分。每轮用两个不交类的并集替换它们, 既不丢样本也不引入交叠, 因此“当前类族是原样本集合的划分”是循环不变量; 每个新划分由前一划分合并得到, 所以输出层次嵌套。

终止条件与异常情形。当类数达到 k_{stop} 或下一合并越过 T 时满足终止条件。该算法是有限合并过程, 不涉及连续参数的无限迭代极限; 非法距离导致的提前退出也不能称为正常终止。

读前自检: 复杂度分析: 层次聚类。在“优先队列可改变选择代价, 但必须另行说明过期条目处理”成立时处理聚类方法中的层次聚类: 请由 m 的总成本剥离一次迭代或一次样本因子, 并以得到的单步时间与存储阶同复杂度框中的分解一致判定结果。

复杂度分析

复杂度假设。假设样本为稠密 m 维向量, 预先保存 $n \times n$ 对称距离矩阵, 并以朴素扫描寻找最小类对。

训练时间复杂度。初始样本距离需 $O(n^2m)$; 至多 $n - 1$ 轮朴素扫描和更新共 $O(n^3)$, 总计 $O(n^2m + n^3)$ 。

新样本归属。标准层次聚类只定义训练样本的树, 不自动给出新样本归属; 只有另行固定“接到最近叶类”等规则后, 才能按该规则分析推断代价。

空间复杂度。距离矩阵为 $O(n^2)$, 合并记录为 $O(n)$, 样本数据为 $O(nm)$ 。优先队列可改变选择代价, 但必须另行说明过期条目处理。

读前自检: k 均值聚类。 k 均值聚类所用的明确前提是“给定 $1 \leq k \leq n$ ”; 完成检查 $\mu = (\mu_1, \dots, \mu_k)$ 中每项的类型后完成等式变形后, 核对两端运算均有定义、类型一致且化为同一结果。

25.4 k 均值模型与目标函数

模型。给定 $1 \leq k \leq n$, k 均值模型是硬划分 C 与中心 $\mu = (\mu_1, \dots, \mu_k)$ 的组合, 其中 $\mu_\ell \in \mathbb{R}^m$ 且每个类非空。 $k = 1$ 与 $k = n$ 分别是单类和每点一类的退化边界; 通常只在 $1 < k < n$ 中选择有

解释意义的结构。模型的预测规则是把新点分配给最近中心；若距离并列，使用固定的最小编号规则。

读前自检：策略。 围绕聚类方法中的策略，先采用条件“采用平方欧氏距离”，再把 $J_\ell(\mu)$ 展开一次并检查其类型或边界；最后验证展开后的量满足定义中的域、维数或符号限制。

学习策略。 采用平方欧氏距离，最小化类内平方和

$$W(C, \mu) = \sum_{\ell=1}^k \sum_{i: C(i)=\ell} \|x_i - \mu_\ell\|_2^2.$$

把中心消去后， μ_ℓ 等于第 ℓ 类样本均值，问题变为在所有非空 k 划分中寻找最小 $W(C)$ 。候选无标号划分数为第二类 Stirling 数

$$S(n, k) = \frac{1}{k!} \sum_{r=1}^k (-1)^{k-r} \binom{k}{r} r^n,$$

它随 n 指数增长，因此实际采用交替迭代而非穷举。

推导目标

在划分 C 固定时，逐步证明使类内平方和最小的中心是该类样本均值，并给出维数检查。该结论用于 k 均值的中心更新步。

推导准备

固定某个非空类 G_ℓ ，记 $n_\ell = |G_\ell|$ 、 $\bar{x}_\ell = n_\ell^{-1} \sum_{i: C(i)=\ell} x_i \in \mathbb{R}^m$ 。只需最小化 $J_\ell(\mu) = \sum_{i: C(i)=\ell} \|x_i - \mu\|_2^2$ ，其中 $\mu \in \mathbb{R}^m$ 。

推导第 1 步：围绕均值分解每个差向量。

$$x_i - \mu = (x_i - \bar{x}_\ell) + (\bar{x}_\ell - \mu).$$

推导第 2 步：展开并消去交叉项。

$$\begin{aligned} J_\ell(\mu) &= \sum_{i: C(i)=\ell} \|x_i - \bar{x}_\ell\|_2^2 + n_\ell \|\mu - \bar{x}_\ell\|_2^2 \\ &\quad + 2(\bar{x}_\ell - \mu)^T \sum_{i: C(i)=\ell} (x_i - \bar{x}_\ell). \end{aligned}$$

按均值定义，最后一个求和等于 $\sum_i x_i - n_\ell \bar{x}_\ell = 0 \in \mathbb{R}^m$ ，所以交叉项是标量 0。

推导第 3 步：确定唯一极小点。

$$J_\ell(\mu) = J_\ell(\bar{x}_\ell) + n_\ell \|\mu - \bar{x}_\ell\|_2^2 \geq J_\ell(\bar{x}_\ell).$$

由于 $n_\ell > 0$, 等号仅在 $\mu = \bar{x}_\ell$ 时成立, 所以更新为

$$\mu_\ell = \frac{1}{n_\ell} \sum_{i: C(i)=\ell} x_i \in \mathbb{R}^m.$$

读前自检：算法特性。 聚类方法中的算法特性中的“若每当分配改变时目标严格下降”决定可执行范围；请把 $W^{(t)}$ 展开一次并检查其类型或边界，结果须满足稳定点是交替优化的坐标极小点，但未必是全局极小点。

定理 25.1 (k 均值的单调下降与有限终止) 假设每轮分配步按固定规则选择最近中心，中心步对每个非空类取均值，且不出现空类。则目标序列 $W^{(t)}$ 单调不增。若每当分配改变时目标严格下降，则算法经过有限轮后分配稳定；稳定点是交替优化的坐标极小点，但未必是全局极小点。

读前自检：证明：的单调下降与有限终止。 k 均值的单调下降证明要求分配步取最近中心、中心步取非空类均值且不触发空类修复；请串联两步目标不增式，核对 $W^{(t+1)} \leq W^{(t)}$ ，并说明这不保证全局最优。

证明。 固定 $\mu^{(t)}$ 时，最近中心分配逐样本最小化距离项，因此

$$W(C^{(t+1)}, \mu^{(t)}) \leq W(C^{(t)}, \mu^{(t)}).$$

固定 $C^{(t+1)}$ 时，上面的平方和分解表明类内均值使每一类目标最小，所以

$$W(C^{(t+1)}, \mu^{(t+1)}) \leq W(C^{(t+1)}, \mu^{(t)}).$$

串联两式得到 $W^{(t+1)} \leq W^{(t)}$ 。非空 k 划分的数量有限；若分配改变必使目标严格下降，就不能再次访问同一分配，也不能无限产生新分配，因此有限轮后分配保持不变。联合目标非凸，不同初值可能停在不同稳定分配，故结论不包含全局最优保证。 $\square$

几何理解

几何解释。 聚类是在选定几何中划分点集。同一批坐标在欧氏球、马氏椭球或角度圆锥下会产生不同邻域；所谓“相近”不是数据自带的事实，而是度量和预处理共同定义的关系。

概率解释

若各类先验相同，且 $x | z = \ell \sim \mathcal{N}(\mu_\ell, \sigma^2 I)$ 共享同一球形协方差，则最大后验硬分配等于选择最近均值。固定硬分配时，极大似然均值也是类内样本均值。不同协方差、不同先验或软后验会导向高斯混合模型，而不再是标准 k 均值。

优化解释

优化解释。 k 均值在两个变量块之间交替精确极小化：固定中心时，每个样本独立选择最近中心；固定分配时，每个中心取类内均值。每个子问题都求到全局最小，但联合问题非凸，因此整体只保证到达局部稳定解。




图 25.1 树的纵坐标表示合并高度；在虚线高度切割时，虚线以下的连通分支分别成为一个类。

图 25.1 对应层次聚类知识点：在所示高度切割得到 $\{x_1, x_2\}$ 、 $\{x_3\}$ 和 $\{x_4, x_5\}$ 三个类；改变切割高度只合并或拆分嵌套分支，不改变已经记录的合并顺序。

读前自检：算法。 k 均值算法需要数据、类别数 k 、启动数 R 、轮数预算 $T_{\max}$ 及停止容差；请核对这些量的定义域，再完成一次最近中心分配和类均值更新，记录目标值与停止原因。

读前自检： k 均值聚类算法。 k 均值交替执行最近中心分配与非空类均值更新；请对一轮候选同时检查有限性、空类状态和目标不增，只在门禁通过时提交，并按分配稳定或双容差判停。

25.5 k 均值算法与收敛

学习算法。 k 均值交替执行最近中心分配和类内均值更新，并在每次循环保留目标轨迹、空类修复记录与停止原因。

严格伪代码。 算法 25.2A 给出单次启动的原子更新，算法 25.2B 只负责逐空类修复，算法 25.2C 负责多启动选择；定理 25.1 的单调性只覆盖没有触发修复、且两个子问题都按定义精确求解的轮次。

算法所需量与计算结果。 计算需要数据、类别数、 R 组可复现初始中心或其种子、并列规则、空类规则和数值容差。多次启动后选取通过诊断且目标最小的非空划分与中心，并保留各次目标轨迹、迭代次数和停止原因。分配和更新必须使用同一预处理后的坐标与平方欧氏目标。

参数含义。 最大迭代数 $T_{\max} \geq 1$ ；目标相对变化容差 $\varepsilon_W \geq 0$ ；中心相对移动容差 $\varepsilon_\mu \geq 0$ ；重复初值数 $R \geq 1$ ；类别数 $1 \leq k \leq n$ 。容差用于浮点停止， R 用于缓解局部最优，二者不能替代类别数选择。

初始化。对 $r = 1, \dots, R$ 分别生成一组中心。可从不同位置的样本中选 k 个中心；距离加权播种先随机选一个中心，再按到最近已选中心的平方距离加权选取后续中心。初始化前去除完全重复候选或登记重复处理；每组初值、随机种子和固定并列规则都应保存以便复现。

带空类保护的单启动：五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

读前自检：带空类保护的单启动。带空类保护的单启动输入“有限数据 X 、类别数 k 、一组有限初始中心、单启动预算 $T_{\max}$ 、双容差、固定并列规则与空类修复子程序”，条件“ $1 \leq k \leq n$ 、 $T_{\max} \geq 1$ ”；请做一轮“ C^+, μ^+, W^+ 及单调性/有限性诊断全部通过后才原子提交，失败尝试不增加 t_{done} ”，以“分配稳定、目标与中心双容差、 $T_{\max}$ 轮预算耗尽或首次失败时停止”核对停止证书。

算法 25.2A：带空类保护的单启动 k 均值

输入： $X, k, \mu^{(0)}, T_{\max}, \varepsilon_W, \varepsilon_\mu$ 及固定并列/修复规则

输出：最后合法 C, μ, W ； $t_{\text{done}}, e_{\text{done}}$ ；status、轨迹与诊断

- 1 若 $X, k, \mu^{(0)}, T_{\max}$ 、容差或规则非法，则返回初始化占位、计数 0、invalid_input 及字段诊断
- 2 令 $\mu \leftarrow \mu^{(0)}, C \leftarrow \perp, W \leftarrow \perp, t_{\text{done}} \leftarrow 0, e_{\text{done}} \leftarrow 0$ ，轨迹为空
- 3 当 $t_{\text{done}} < T_{\max}$ 执行
 - 4 以 μ 按固定并列规则形成临时分配 C^+ ；距离非有限则返回最后合法状态与 numerical_failure 及分配阶段诊断
 - 5 调用算法 25.2B 修复 C^+ ；若子程序未返回 completed，则保留旧状态并以 numerical_failure 返回，诊断嵌套其失败位置
 - 6 由修复后 C^+ 计算全部 μ^+ 和 W^+ ；若非有限、有空类，或未修复轮的 W^+ 超过旧 W 与舍入容差之和，则拒绝候选并返回最后合法状态、numerical_failure 及均值/目标阶段诊断
 - 7 若 $C = \perp$ 则置分配稳定为假且 $\delta_W = +\infty$ ；否则计算分配稳定标志与 δ_W ；同时计算 Δ_μ ；原子提交 $(C, \mu, W) \leftarrow (C^+, \mu^+, W^+)$ ，追加轨迹并增加 t_{done} 及子程序移动数 e_{done}
 - 8 若分配稳定，或 $\delta_W \leq \varepsilon_W$ 且 $\Delta_\mu \leq \varepsilon_\mu$ ，则返回最后合法状态、converged 及停止证书
- 9 结束
- 10 返回最后合法状态、实际计数、budget_stop 及“预算耗尽、双证书未满足”诊断

读前自检：的逐空类修复子程序：执行契约。 k 均值逐空类修复以当前分配、旧中心和固定供体规则为状态；请移动一个供体样本，同时更新两个类容量、空类队列与修复日志，核对事务原子提交后空类数减少，并在队列为空时停止。

的逐空类修复子程序：五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 25.2B: k 均值的逐空类修复子程序

输入: X 、临时分配 C 、旧中心 μ 与固定并列规则

输出: $C_{\text{rep}}, e_{\text{done}}, \text{status}$ 及逐移动诊断

- 1 若分配未覆盖全部样本、类号越界, 或 X, μ, k 和规则非法, 则返回原分配、0, `invalid_input` 及字段诊断
- 2 复制 $C_{\text{rep}} \leftarrow C$, 置 $e_{\text{done}} \leftarrow 0$ 并计算各类容量
- 3 **当** 存在空类 **执行**
- 4 取编号最小空类 e ; 在容量至少 2 的供体类中, 按“对其旧中心平方贡献最大、再按固定标识”选择 x_{i^*}
- 5 若贡献非有限或无合法供体, 则返回最后合法 $C_{\text{rep}}, e_{\text{done}}, \text{numerical_failure}$ 及失败空类/阶段诊断
- 6 原子地把 x_{i^*} 移入 e , 更新两个容量并追加日志; 令 $e_{\text{done}} \leftarrow e_{\text{done}} + 1$
- 7 **结束**
- 8 返回非空 $C_{\text{rep}}, e_{\text{done}}, \text{completed}$ 及完整修复诊断

多启动的记录与选择: 五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新, 并指出何时提交。

数学停止。写出能直接核验的停止证书; 预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 25.2C: 多启动 k 均值的记录与选择

输入: $X, k, \{\mu_r^{(0)}\}_{r=1}^R, T_{\max}, \varepsilon_W, \varepsilon_\mu, \delta_C$ 及固定规则

输出: C^*, μ^*, W^* ; 启动表、 $r_{\text{done}}, t_{\text{total}}$; `status` 与诊断

- 1 若 R 或任一初值/规则非法, 则返回 1、计数 0、`invalid_input` 及字段诊断
- 2 令 $\mathcal{S}_A \leftarrow \emptyset, \mathcal{S}_B \leftarrow \emptyset, r_{\text{done}} \leftarrow 0, t_{\text{total}} \leftarrow 0$, 记录表为空
- 3 **对** $r \leftarrow 1$ **至** R **执行**
- 4 调用算法 25.2A; 令 `record[r]` 原子保存最后合法 $C, \mu, W, t_{\text{done}}, e_{\text{done}}, \text{status}$ 、末轮分配改变率、预算余量与诊断
- 5 若 `record[r]` 状态为 `converged` 且诊断通过, 则标记 A 级并加入 $\mathcal{S}_A$; 若状态为 `budget_stop` 且 W 有限、划分非空、轨迹无异常上升且分配改变率 $\leq \delta_C$, 则标记 B 级并加入 $\mathcal{S}_B$; 否则标记不接纳
- 6 令 $r_{\text{done}} \leftarrow r, t_{\text{total}} \leftarrow t_{\text{total}} + \text{record}[r].t_{\text{done}}$
- 7 **结束**
- 8 若 $\mathcal{S}_A \neq \emptyset$, 则只读记录表, 在 $\mathcal{S}_A$ 中按最小 W 、再按启动编号选取并返回 `completed` 及完整诊断
- 9 若 $\mathcal{S}_A = \emptyset$ 但 $\mathcal{S}_B \neq \emptyset$, 则只读记录表, 在 $\mathcal{S}_B$ 中按最小 W 、再按改变率和启动编号选取, 返回该有限预算结果、`budget_stop` 及“B 级接纳、未获数学收敛证书”诊断
- 10 否则返回 1、全部记录、按失败记录确定的规范状态及“无可接纳启动”诊断

循环变量、更新顺序与判断条件。外层循环变量为启动编号 $r = 1, \dots, R$, 内层为 $t = 0, 1, \dots$ 。每轮先用当前中心得到 C_{new} , 逐个修复所有空类, 再只根据该分配计算 μ_{new} 与目标。它与上一轮已经用于生成当前中心的 C_{prev} 比较, 因此不会把同一组中心重复产生的初始化分配误判为收敛。判断条件包括距离并列、多空类、供体类大小、分配不变、双容差、预算和跨启动择优。

停止条件与返回结果。 单次启动首选相邻两轮分配完全不变；浮点大数据中可要求目标相对变化和中心相对移动同时满足容差。达到迭代上限仍只表示预算停止，不能改写为 **converged**；但若其目标有限、划分非空、轨迹正常且末轮分配改变率通过预登记门槛，可作为 **B 级有限预算结果透明比较**。全部 R 次启动完成后，优先返回 **A 级** 中最小目标；**A 级** 为空时才返回 **B 级** 中最小目标，并连同状态、改变率、预算和所有失败记录报告。

正确性依据、收敛条件与不收敛或不适用情形。 无空类且不触发修复时，最近分配与均值重新分别精确极小化一个变量块，**定理 25.1** 给出目标不增；若分配改变必严格下降，则有限划分保证终止。逐个空类修复保持 k 个类非空，但它改变标准坐标下降轨迹，因此修复后的目标必须重算，单调性需从下一次未修复轮重新核对。目标上升超过数值容差、没有可移动供体、达到迭代上限而容差未满足，均属于未收敛或异常状态。外层只在有限 R 个合格结果中按固定规则取最小值；它改善初值鲁棒性但不保证联合目标全局最优，因而“保证收敛到全局最优”不适用。

常见错误

异常与退化。 若 $k \notin \{1, \dots, n\}$ 、输入含未处理的非有限值、初始中心维数错误或空类没有可移动样本，必须停止并报告输入不合法。空类修复改变标准交替步骤，修复后应重算受影响中心和目标，不能沿用修复前的单调性结论。

读前自检：复杂度分析： k 均值算法与收敛。 先锁定 k 均值算法与收敛的条件“假设 X 是稠密 $n \times m$ 数据，距离逐点计算而不保存完整 $n \times k$ 矩阵”：由 X 的总成本剥离一次迭代或一次样本因子，所得结果应满足得到的单步时间与存储阶同复杂度框中的分解一致。

复杂度分析

复杂度假设。 假设 X 是稠密 $n \times m$ 数据，距离逐点计算而不保存完整 $n \times k$ 矩阵，运行 T 轮并独立使用 R 组初值；层次聚类复杂度采用本章前述朴素距离矩阵实现。

训练时间复杂度。 k 均值每轮分配为 $O(nkm)$ ，更新为 $O(nm)$ ，单组初值主代价为 $O(Tnkm)$ ， R 组初值为 $O(RTnkm)$ 。聚合层次聚类为 $O(n^2m + n^3)$ 。

预测时间复杂度。 对 n_{new} 个新样本， k 均值最近中心预测为 $O(n_{\text{new}}km)$ ；标准层次树未规定样本外预测，因此其预测复杂度不适用，除非另行给出归属规则。

空间复杂度。 k 均值单次启动保存数据、中心、分配和最近距离需 $O(nm + km + n)$ ；若完整保留 R 次、每次至多 T 轮且每轮最多 $k-1$ 个空类修复事件的轨迹与诊断，再加 $O(RTk)$ ，不必同时保存 R 份数据。若只保存每轮修复次数等压缩摘要，该诊断项才可降为 $O(RT)$ 。层次聚类距离矩阵需 $O(n^2)$ 。分块距离计算可降低 k 均值额外工作空间。

类别数 k 的选择

对候选 $k \in \mathcal{K}$ 分别完成多初值训练。若最优合格划分为 $\mathcal{G}(k) = \{G_1^{(k)}, \dots, G_k^{(k)}\}$ ，可用类的平均直径

$$\bar{D}(k) = \frac{1}{k} \sum_{\ell=1}^k D_{G_\ell^{(k)}}, \quad D_G = \max_{x_i, x_j \in G} d(x_i, x_j)$$

衡量类内尺度。随着 k 增加, $\overline{D}(k)$ 通常先明显下降, 随后下降趋缓; 可在预先规定的相对下降阈值下选择曲线由陡转平的最小 k 。若实测曲线及阈值谓词可靠地单调, 可用二分方式缩小候选区间; 启发式求解、异常点或平均操作可能破坏单调性时, 应扫描全部候选而不能机械二分。

平均直径的拐点只是内部几何启发式: 它会偏好拆分大直径类, 也可能因单点类而人为变小。最终选择还应同时报告最小类大小、重复抽样稳定性、目标与 $\overline{D}(k)$ 曲线, 并在存在独立任务时检查留出效用; 不得看过测试标签后再挑 k 。

读前自检: 适用条件与局限: 类别数 k 的选择。 类别数 k 的选择只适合在固定预处理和独立评价下比较; 请让 $k = 1$ 或 $k = n$ 作边界对照, 核对类内损失单独变好并不等于结构稳定, 仍须用扰动稳定性或外部准则筛选。

适用条件与局限性

适用条件。 层次聚类适合需要多尺度树结构、样本数允许保存距离矩阵的场景; k 均值适合连续数值属性、平方欧氏几何合理、类别近似球形且类别数可预先选择的场景。两者都应在固定预处理和多次扰动下检查稳定性。

方法局限

层次聚类早期错误合并通常不能撤销, 且对连接和异常点敏感; k 均值必须给定 k , 受初值、尺度和异常点影响, 难以表示细长、不同密度或不同方差的类。两种方法都不给类别自动赋予业务语义。

读前自检: 常见错误与误用边界: 类别数 k 的选择。 k 均值误用清单警告平方欧氏距离、单次初值与全局最优三者不可混淆; 请让同一数据采用两个初值各跑一轮, 对照最终目标值, 核对单个局部稳定解不能证明全局最优。

常见错误

1. 把平方欧氏量当成满足三角不等式的距离;
2. 未标准化量纲差异巨大的属性, 或对类别编码直接使用欧氏距离;
3. 在马氏距离中对奇异协方差机械求逆;
4. 把单连接、完全连接和中心连接的更新结果混合;
5. k 均值出现空类后保留未定义均值, 或不记录修复;
6. 只运行一个初值, 并把局部稳定解称为全局最优。

读前自检: 易混淆概念对比: 类别数 k 的选择。 在“对比表首个数据行是“单连接层次聚类 | 最近跨类点对 | 可发现连通链状结构 | 易受桥点影响””成立时处理类别数 k 的选择: 请按列复述“单连接层次聚类 | 最近跨类点对 | 可发现连通链状结构 | 易受桥点影响”中的对象、假设与结论, 并以各列均对应首行对象“单连接层次聚类”, 且未与表中下一行互换判定结果。

易混淆概念对比			
易混淆概念与方法对比。			
方法	结构与目标	优势	主要边界
单连接层次聚类	最近跨类点对	可发现连通链状结构	易受桥点影响
完全连接层次聚类	最远跨类点对	倾向紧致小直径类	对异常点敏感
平均连接层次聚类	全部跨类距离平均	比两端规则平衡	需维护更多统计
k 均值	类内平方和	计算简洁、可扩展	球形偏好、需给 k
高斯混合模型	观测似然与软后验	表达不确定性和协方差	参数更多、可能退化

25.6 例题、聚类计算与练习

例题 25.1 (五点的 k 均值计算). 样本为

$$x_1 = (0, 2)^T, x_2 = (0, 0)^T, x_3 = (1, 0)^T, x_4 = (5, 0)^T, x_5 = (5, 2)^T,$$

取 $k = 2$, 初始中心 $\mu_1^{(0)} = x_1$ 、 $\mu_2^{(0)} = x_2$, 并列时取较小编号。求稳定划分。

例题 25.1 解答

读题翻译 从题设两个初始中心出发执行 k 均值：每轮先按平方欧氏距离分配五个点，再以簇内均值更新中心，直到分配不变。

已知与合法条件 $k = 2$, $\mu_1^{(0)} = x_1$ 、 $\mu_2^{(0)} = x_2$ ；距离并列时取较小簇编号，本例每轮均无空簇。

为什么想到这个方法 给定中心时逐点选择平方距离最小的簇；给定非空分配时，簇内均值唯一最小化该簇平方误差和。

方法选择 计算第一轮五行两列距离矩阵并更新两个中心；再用新中心复算分配，若不变则计算最终类内平方和并停止。

推导/计算 第一轮分配与更新。 平方距离矩阵（行对应 x_i , 列对应 $\mu_1^{(0)}, \mu_2^{(0)}$ ）为

$$D^{(0)} = \begin{bmatrix} 0 & 4 \\ 4 & 0 \\ 5 & 1 \\ 29 & 25 \\ 25 & 29 \end{bmatrix}.$$

逐行取较小值，得到

$$\begin{aligned} G_1^{(1)} &= \{x_1, x_5\}, & G_2^{(1)} &= \{x_2, x_3, x_4\}, \\ \mu_1^{(1)} &= \frac{x_1 + x_5}{2} = (2.5, 2)^T, & \mu_2^{(1)} &= \frac{x_2 + x_3 + x_4}{3} = (2, 0)^T. \end{aligned}$$

第二轮复核。用新中心复核, 平方距离矩阵变为

$$D^{(1)} = \begin{bmatrix} 6.25 & 8 \\ 10.25 & 4 \\ 6.25 & 1 \\ 10.25 & 9 \\ 6.25 & 13 \end{bmatrix}.$$

每行最小值对应的类别均未改变, 因此划分已经稳定, 且目标函数为

$$J = 6.25 + 6.25 + 4 + 1 + 9 = 26.5.$$

独立核验 初始中心下的目标为各行最小平方距离之和 $0 + 0 + 1 + 25 + 25 = 51$, 更新后降至 26.5; 同时 $D^{(1)}$ 逐行最小值仍给出 $\{x_1, x_5\}$ 与 $\{x_2, x_3, x_4\}$, 故“目标不增”和“分配不变”两项检查一致。

结论 稳定划分为 $G_1 = \{x_1, x_5\}$ 、 $G_2 = \{x_2, x_3, x_4\}$, 相应中心为 $(2.5, 2)^T$ 与 $(2, 0)^T$, 最终目标值为 26.5。

本章共 12 道练习。每道题干后立即给出同号解析; 长解析可自然跨页, 续页标题保留题号。

练习 25.1. 设计一种自上而下的分裂聚类算法, 并在明确数据结构和距离计算假设后分析时间与空间复杂度。

练习 25.1 解析

给出一种可复现的最远点二分方案。输入为 n 个 m 维样本、距离 d 、目标类数 k 和并列规则; 初始化 $\mathcal{G} = \{\mathcal{X}\}$ 。当 $|\mathcal{G}| < k$ 时, 先从可分类中选直径最大的 G , 再选达到直径的点 (a, b) 作为两个种子; 把 G 内每个点分给较近种子, 并按固定规则处理并列。两个种子分别留在不同子类, 所以当 $d(a, b) > 0$ 时两子类非空; 若直径为 0 而仍要求继续分裂, 则距离不能区分样本, 应返回“按该度量不可分”, 不能虚构几何边界。用两个子类替换 G , 直至达到 k 或不可再分。

若当前被分裂的类为 G , 两个子类定义为

$$G_a = \{x \in G : d(x, a) \leq d(x, b)\}, \quad G_b = G \setminus G_a,$$

其中距离并列再按固定样本序打破。预先计算稠密距离矩阵时, 初始化代价为

$$T_{\text{dist}} = O(n^2 m), \quad M_{\text{dist}} = O(n^2).$$

一次大小为 s 的类扫描最远点对需 $O(s^2)$, 至多分裂 $k - 1$ 次, 故朴素上界为

$$T(n, m, k) = O(n^2 m) + O(kn^2), \quad M(n, m, k) = O(n^2) + O(n + k).$$

练习 25.1 解析 (续)

若不保存距离而每次重算, 则 $T = O(kn^2m)$, 除数据外的空间降为 $O(n+k)$ 。

练习 25.2. 证明节 25.1 的第一种全直径条件可以推出其余三种类或簇条件, 并写清 n_G 与阈值的条件。

练习 25.2 解析

设 $n_G \geq 2$ 且第一项成立, 即任意不同点对都有 $0 \leq d_{ij} \leq T$ 。对每个 x_i 任选一个不同的 x_j , 便有 $d_{ij} \leq T$, 所以第二项成立。第三项的分子是 $n_G - 1$ 个不超过 T 的非负数之和, 因此

$$\frac{1}{n_G - 1} \sum_{x_j \in G} d_{ij} \leq \frac{(n_G - 1)T}{n_G - 1} = T.$$

对所有有序点对求和同样得到

$$\frac{1}{n_G(n_G - 1)} \sum_{x_i \in G} \sum_{x_j \in G} d_{ij} \leq T.$$

第一项还给出 $\max_{i,j} d_{ij} \leq T$, 故第四项可取 $V = T$ 。 $n_G \geq 2$ 保证“另一个样本”和两个平均分母均有定义; $T > 0$ 与距离非负性使这些界保持原方向。

练习 25.3. 证明 k 均值的候选划分个数可以随样本数呈指数增长。可从 $S(n, k)$ 的公式出发, 并给出一个固定 k 的具体情形。

练习 25.3 解析

对固定 $k = 2$, 第二类 Stirling 数公式给出

$$S(n, 2) = \frac{1}{2!} \left[-\binom{2}{1} 1^n + \binom{2}{2} 2^n \right] = 2^{n-1} - 1.$$

它是底数 2 的指数函数减去常数, 因此仅二类非空无标号划分的数量已经随 n 指数增长。更一般地, 对固定 $k \geq 2$, 公式的首项为 $k^n/k!$, 其余项的底数至多 $k-1$, 所以主导增长率仍为 k^n 量级。每个候选划分都对应一组类均值和目标值, 穷举这些划分不能成为大样本 k 均值的常规求解方式。

练习 25.4. 比较 k 均值聚类与高斯混合模型的 EM 算法: 说明模型、分配、目标、参数、退化情形和输出不确定性的异同。

练习 25.4 解析

k 均值使用硬分配 c_i 与中心 μ_k , 目标为

$$J(c, \mu) = \sum_{i=1}^n \|x_i - \mu_{c_i}\|_2^2, \quad (c^{(t+1)}, \mu^{(t+1)}) \implies J_{t+1} \leq J_t.$$

练习 25.4 解析 (续)

高斯混合模型的参数为 $\theta = (\pi_k, \mu_k, \Sigma_k)_{k=1}^K$, 观测对数似然与 E 步责任度为

$$\ell(\theta) = \sum_{i=1}^n \log \sum_{k=1}^K \pi_k \mathcal{N}(x_i | \mu_k, \Sigma_k),$$

$$r_{ik}^{(t)} = \frac{\pi_k^{(t)} \mathcal{N}(x_i | \mu_k^{(t)}, \Sigma_k^{(t)})}{\sum_j \pi_j^{(t)} \mathcal{N}(x_i | \mu_j^{(t)}, \Sigma_j^{(t)})}, \quad \ell(\theta^{(t+1)}) \geq \ell(\theta^{(t)}).$$

k 均值可视作等先验、共享球形协方差的高斯混合模型在方差趋零时的硬分配极限。

k 均值输出类别和中心, 无法表达边界不确定性; 高斯混合模型输出密度与后验责任度。标准 k 均值的主要退化是空类, 处理不当会破坏更新; 高斯混合模型还可能让某成分协方差趋于奇异并使似然无界。两者的单调性都只针对各自目标, 均不保证全局最优, 也不能把类别编号解释成固有数值次序。

练习 25.5. 集合 $\{1, 2, 3, 4\}$ 的候选聚类为 $G_1 = \{1, 2\}$ 、 $G_2 = \{2, 3\}$ 、 $G_3 = \{4\}$ 。它是否构成硬聚类? 说明违反的条件。

练习 25.5 解析

硬聚类 $\{G_k\}_{k=1}^K$ 必须同时满足

$$G_k \neq \emptyset, \quad \bigcup_{k=1}^K G_k = \{1, 2, 3, 4\}, \quad G_k \cap G_\ell = \emptyset \quad (k \neq \ell).$$

本题虽然

$$G_1 \cup G_2 \cup G_3 = \{1, 2, 3, 4\}, \quad G_1 \cap G_2 = \{2\} \neq \emptyset,$$

但样本 2 同时属于两个类, 故不构成硬聚类; 必须删除其中一个集合里的 2, 或改用软分配。

练习 25.6. 对 $x = (1, -1)^T$ 、 $y = (4, 3)^T$, 计算曼哈顿距离、欧氏距离和切比雪夫距离。

练习 25.6 解析

差向量与三种距离依次为

$$x - y = (-3, -4)^T,$$

$$d_1(x, y) = |-3| + |-4| = 7, \quad d_2(x, y) = \sqrt{(-3)^2 + (-4)^2} = 5,$$

$$d_\infty(x, y) = \max\{3, 4\} = 4, \quad d_\infty(x, y) \leq d_2(x, y) \leq d_1(x, y).$$

练习 25.7. 设 $S = \text{diag}(4, 1)$, $x - y = (2, 2)^T$ 。计算马哈拉诺比斯距离, 并与欧氏距离比较。

练习 25.7 解析

$S^{-1} = \text{diag}(1/4, 1)$, 所以

$$d_S^2 = (2, 2) \begin{bmatrix} 1/4 & 0 \\ 0 & 1 \end{bmatrix} \begin{pmatrix} 2 \\ 2 \end{pmatrix} = 1 + 4 = 5, \quad d_S = \sqrt{5}.$$

欧氏距离为 $\sqrt{8} = 2\sqrt{2}$ 。第一维方差较大, 马氏距离把该维差异缩小, 故结果较小。

练习 25.8. 类 $G_p = \{0, 4\}$ 、 $G_q = \{5, 9\}$ 位于实数轴上。分别计算单连接、完全连接、中心连接和平均连接。

练习 25.8 解析

跨类距离矩阵为

$$D_{pq} = \begin{bmatrix} |0-5| & |0-9| \\ |4-5| & |4-9| \end{bmatrix} = \begin{bmatrix} 5 & 9 \\ 1 & 5 \end{bmatrix}.$$

因此

$$\begin{aligned} d_{\min}(G_p, G_q) &= 1, & d_{\max}(G_p, G_q) &= 9, \\ d_{\text{avg}}(G_p, G_q) &= \frac{5+9+1+5}{4} = 5, & d_{\text{cen}}(G_p, G_q) &= |2-7| = 5. \end{aligned}$$

练习 25.9. 三点在实数轴上为 0, 2, 7。使用欧氏距离和单连接, 从单点类开始列出合并顺序与高度。

练习 25.9 解析

初始距离满足

$$d(0, 2) = 2 < d(2, 7) = 5 < d(0, 7) = 7,$$

故第一次在高度 $h_1 = 2$ 合并 $\{0\}, \{2\}$ 。随后单连接距离为

$$d_{\min}(\{0, 2\}, \{7\}) = \min\{d(0, 7), d(2, 7)\} = \min\{7, 5\} = 5,$$

所以第二次在高度 $h_2 = 5$ 合并, 且 $h_1 \leq h_2$ 。

练习 25.10. 类 $G = \{(0, 0)^T, (2, 0)^T, (4, 3)^T\}$ 的最优 k 均值中心是什么?

练习 25.10 解析

中心是坐标均值:

$$\mu = \frac{1}{3} \left[\begin{pmatrix} 0 \\ 0 \end{pmatrix} + \begin{pmatrix} 2 \\ 0 \end{pmatrix} + \begin{pmatrix} 4 \\ 3 \end{pmatrix} \right] = \begin{pmatrix} 2 \\ 1 \end{pmatrix}.$$

该向量位于 $\mathbb{R}^2$ 。对任意 $u \in \mathbb{R}^2$, 平方和分解为

$$\sum_{x \in G} \|x - u\|_2^2 = \sum_{x \in G} \|x - \mu\|_2^2 + 3\|u - \mu\|_2^2 \geq \sum_{x \in G} \|x - \mu\|_2^2.$$

等号仅在 $u = \mu = (2, 1)^T$ 时成立, 故它是唯一全局最小点。

练习 25.11. 一维数据 $\{0, 2, 9, 11\}$, 初始中心为 0 和 2。执行一轮分配与均值更新。

练习 25.11 解析

对初始中心 $(\mu_1^{(0)}, \mu_2^{(0)}) = (0, 2)$, 平方距离表为

x	0	2	9	11
$(x - \mu_1^{(0)})^2$	0	4	81	121
$(x - \mu_2^{(0)})^2$	4	0	49	81

于是

$$G_1^{(1)} = \{0\}, \quad G_2^{(1)} = \{2, 9, 11\},$$

$$\mu_1^{(1)} = 0, \quad \mu_2^{(1)} = \frac{2 + 9 + 11}{3} = \frac{22}{3}.$$

这只完成一轮, 仍须在新中心下重新分配后才能判断是否稳定。

练习 25.12. 某轮目标从 100 降至 80, 下一轮升至 81。在标准无空类 k 均值中, 这说明什么?

练习 25.12 解析

标准无空类 k 均值的分配步和均值步分别最小化同一平方和目标, 因此

$$J(c^{(t+1)}, \mu^{(t)}) \leq J(c^{(t)}, \mu^{(t)}),$$

$$J(c^{(t+1)}, \mu^{(t+1)}) \leq J(c^{(t+1)}, \mu^{(t)}).$$

合并即得 $J_{t+1} \leq J_t$; 而 $81 > 80$ 与此矛盾。应检查目标是否在同一分配 - 中心时点计算、是否使用平方欧氏距离、中心是否按当前分配更新, 以及空类或并列处理是否改变了问题, 不能把上升解释为正常振荡。

读前自检：本章结论与下一步。 聚类方法章末由“表示、样本距离、类间连接、划分与中心”落到“层次法有限次合并”；请把前者产出和后者输入逐项对齐，固定核对前者末项的输出类型能否作为后者首项的输入类型。

本章结论与下一步

核心结论：表示、样本距离、类间连接、划分与中心

关键依据：固定分配时平方距离的一阶条件给出类内均值，交替最小化推出目标不增

可执行自检：层次法有限次合并； k 均值交替最近分配与均值更新并按目标/分配停止

适用边界：需要探索样本分组且选定距离或平方欧氏原型假设合理时

下一步：进入 SVD；聚类自检失败应先返回距离定义、连接规则或空类边界

1. **定义：**能否写出硬划分和四种类内阈值条件？未通过则回看第 1、2 节。
2. **度量：**能否计算并比较闵氏、马氏、相关、余弦与四种连接？未通过则回看第 2 节。
3. **层次：**能否按指定连接复现合并序列与高度，并给出有限终止理由？未通过则回看第 3 节。
4. **推导：**能否三步证明均值最小化类内平方和？未通过则回看第 4 节。

5. **算法：**能否证明单调下降并说明输入、更新、停止、复杂度、空类和局部最优？未通过则回看第5、6节；五项均可独立作答，并能完成至少八道练习，才算达到本章学习目标。

第 26 章 奇异值分解

读前自检：本章可检验学习目标。 奇异值分解学习目标固定核验“能对任意 $m \times n$ 实矩阵写出完整、紧和截断 SVD，并逐项核对维数”；请实际完成“对任意 $m \times n$ 实矩阵写出完整、紧和截断 SVD，并逐项核对维数”，并用“ $m \times n$ 的核验结果逐项满足本条首目标（能对任意 $m \times n$ 实矩阵写出完整、紧和截断 SVD，并逐项核对维数）”判定通过或失败。

读前自检：最短先修。 奇异值分解的最短先修要求能计算 $A^T A$ 、识别正半定谱并核对矩阵乘法；请对 $A \in \mathbb{R}^{m \times n}$ 写出 $A^T A \in \mathbb{R}^{n \times n}$ ，并说明其特征值为何非负。

读前自检：先修自检。 奇异值分解先修自检固定核验“若 $A \in \mathbb{R}^{m \times n}$ ，能否写出 $A^T A$ 与 AA^T 的维数”；请在 $A \in \mathbb{R}^{m \times n}$ 条件下，实际写出 $A^T A$ 与 AA^T 的维数并写出中间结果，再按“ $A \in \mathbb{R}^{m \times n}$ 的计算或证明结果满足首项所列等式、定义域或判断”明确判为通过或失败。

本章地图

核心问题：怎样用正交方向和奇异值解释矩阵并控制近似误差

可检验学习目标：

- 能对任意 $m \times n$ 实矩阵写出完整、紧和截断 SVD，并逐项核对维数；
- 能从 $A^T A$ 的谱分解构造 SVD，完整证明存在性并说明非唯一来源；
- 能推导奇异值与 $A^T A, AA^T$ 特征值、左右奇异向量及四个基本子空间的关系；
- 能说明稳定截断 SVD 算法的输入、子空间迭代、残差、停止、收敛与复杂度；
- 能证明截断 SVD 在 Frobenius 范数和谱范数下的低秩最优性，并计算误差。

最短先修：本章使用矩阵乘法、转置、秩、零空间、值域、正交补、实对称矩阵谱分解、正半定矩阵、特征值与特征向量、向量二范数、Frobenius 范数和正交投影。统一记

$$A \in \mathbb{R}^{m \times n}, \quad p = \min(m, n), \quad r = \text{rank}(A).$$

所有矩形对角矩阵都只在前 p 个主对角位置可能非零。

依赖路线：对称矩阵谱分解 $\rightarrow A^T A$ 的非负特征值；特征值平方根 $\rightarrow$ 奇异值；正特征向量经 A 映射 $\rightarrow$ 左奇异向量；正交补全 $\rightarrow$ 完整 SVD；奇异值排序 $\rightarrow$ 紧 SVD 与截断 SVD；正交不变范数 $\rightarrow$ 低秩最优近似和误差公式。

完成标准与返回：维数或左右方向不清时回到节 26.1、26.2；低秩取等条件失败时回看节 26.5

数据方向桥：SVD 先看线性映射，再看样本

本章的 $A \in \mathbb{R}^{m \times n}$ 首先是任意线性映射矩阵，不自动把某一维解释为样本。若应用中每个 m 维样本占一列，则

$$A = X_{\text{col}} = [x_1, \dots, x_n] = X_{\text{row}}^T, \quad X_{\text{row}} \in \mathbb{R}^{n \times m}.$$

例如四个二维样本对应 $A \in \mathbb{R}^{2 \times 4}$ 与 $X_{\text{row}} \in \mathbb{R}^{4 \times 2}$ 。选择哪种语义后， AA^T 与 $A^T A$ 的对象空间也随之确定。

本章符号表

符号	维数或取值	含义
A	$m \times n$	待分解实矩阵
p	$\min(m, n)$	可能出现的奇异值个数
r	$0, \dots, p$	A 的秩及正奇异值个数
U	$m \times m$	左正交矩阵, 列为左奇异向量
V	$n \times n$	右正交矩阵, 列为右奇异向量
Σ	$m \times n$	矩形对角矩阵
σ_j	非负数	第 j 个奇异值, 按非增次序排列
U_r, Σ_r, V_r	$m \times r, r \times r, n \times r$	紧 SVD 的三个因子
A_k	$m \times n$	保留前 k 项的截断近似
$\ \cdot\ _2, \ \cdot\ _F$	非负数	谱范数与 Frobenius 范数

读前自检：奇异值分解。 奇异值分解要求先确认“奇异值分解把任意矩形线性变换拆成两个正交坐标变换和一个沿坐标轴的非负缩放”；请随后把“奇异值分解把任意矩形线性变换拆成两个正交坐标变换和一个沿坐标轴的非负缩放”中的已声明对象代回奇异值分解的定义，用它既适用于方阵，也适用于长矩阵、宽矩阵、满秩矩阵和秩亏矩阵验收。

26.1 SVD 定义与存在性

奇异值分解把任意矩形线性变换拆成两个正交坐标变换和一个沿坐标轴的非负缩放。它既适用于方阵，也适用于长矩阵、宽矩阵、满秩矩阵和秩亏矩阵，是矩阵压缩、最小二乘、主成分分析与潜在语义表示的基础工具。

读前自检：奇异值分解的定义与性质。 奇异值分解对任意 $A \in \mathbb{R}^{m \times n}$ 写成 $A = U\Sigma V^T$ ；请标出 U, Σ, V 的完整形状，核对两次内维相消并验证 U, V 正交、 Σ 对角元非负。

读前自检：定义与定理。 SVD 定义与存在定理以实矩阵 $A \in \mathbb{R}^{m \times n}$ 为对象；请从 $A^T A = V \Lambda V^T$ 取 $\sigma_i = \sqrt{\lambda_i}$ ，核对正特征值对应的 $u_i = Av_i/\sigma_i$ 为单位向量。

读前自检：奇异值分解的矩阵因子形式。 SVD 矩阵因子形式为 $A = U\Sigma V^T$ ，其中 $U \in \mathbb{R}^{m \times m}$ 、 $\Sigma \in \mathbb{R}^{m \times n}$ 、 $V \in \mathbb{R}^{n \times n}$ ；请逐因子相乘核对结果仍为 $m \times n$ 。

读前自检：完整奇异值分解。 完整 SVD 要求 $U^T U = I_m$ 、 $V^T V = I_n$ 且 $\sigma_1 \geq \dots \geq \sigma_p \geq 0$ ；请对一个矩形 A 核对三因子维数，并由 $U^T A V$ 回代得到 Σ 。

阅读目标：从右奇异向量出发构造奇异值与左奇异向量，并核对维数。

对象： $A \in \mathbb{R}^{m \times n}$ 、 $A^T A$ 的正交特征向量 v_i 与特征值 $\lambda_i \geq 0$ 。

合法条件: $A^T A$ 对称正半定; 对正特征值定义 $\sigma_i = \sqrt{\lambda_i} > 0$ 。

第一步: 先做谱分解 $A^T A = V \Lambda V^T$, 并令 $u_i = Av_i/\sigma_i$ 。

定义 26.1 (完整奇异值分解). 矩阵 $A \in \mathbb{R}^{m \times n}$ 的完整奇异值分解是

$$A = U \Sigma V^T,$$

其中 $U^T U = U U^T = I_m$, $V^T V = V V^T = I_n$, 并且

$$\Sigma = \begin{bmatrix} \text{diag}(\sigma_1, \dots, \sigma_p) & 0 \\ 0 & 0 \end{bmatrix}_{m \times n}, \quad \sigma_1 \geq \dots \geq \sigma_p \geq 0.$$

σ_j 称为奇异值, U 和 V 的列分别称为左、右奇异向量。

模型。 SVD 把 $A: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 表示为

$$x \xrightarrow{V^T} y \xrightarrow{\Sigma} z \xrightarrow{U} Ax.$$

V^T 与 U 保持长度和夹角, Σ 只沿互相正交的方向缩放; 零奇异值对应被压到零的方向。

贯穿例：文档—词项矩阵小例

本章角色: 把同一词项计数表首先视为未经中心化或概率化的实矩阵, 建立后续各章的共同输入。

词项为行、文档为列, 精确取

$$X = \begin{bmatrix} 2 & 0 & 1 \\ 1 & 2 & 0 \\ 0 & 1 & 3 \end{bmatrix}.$$

三列总数依次为 3, 3, 4, 全矩阵总计数为 10。本章只把 $X \in \mathbb{R}^{3 \times 3}$ 作为原始有限实矩阵做 SVD; 非负整数含义与列和不会进入 SVD 存在性条件, 也不要求预先中心化或归一化。因此该数据与本章“任意实矩阵”假设相容。下一站见 PCA 对同一矩阵的中心化样本表示。

预备结论。 实对称矩阵 B 存在正交谱分解 $B = Q \Lambda Q^T$ 。若 B 正半定, 则每个特征值非负。下文把这一结论用于 $B = A^T A$, 从而构造右奇异向量和奇异值。

学习策略。 先从 $A^T A$ 的谱分解构造完整 SVD, 再用左右奇异向量方程核对结果; 随后区分紧 SVD 与截断 SVD, 并把数值算法的残差、谱隙和低秩误差公式放在同一条验证链中。

读前自检：奇异值分解基本定理。 SVD 基本定理从 $A^T A v_i = \sigma_i^2 v_i$ 与 $u_i = A v_i / \sigma_i$ 出发; 请计算 $u_i^T u_j$, 利用 v_i 正交核对正奇异值对应的左奇异向量也标准正交。

推导目标

由 $A^T A$ 的谱分解构造 V, Σ, U , 并验证三因子维数及 $A = U \Sigma V^T$ 。

推导准备

$A^T A \in \mathbb{R}^{n \times n}$ 实对称且正半定, 因为 $x^T A^T A x = \|Ax\|_2^2 \geq 0$ 。因此存在 n 维标准正交特征向量 $v_1, \dots, v_n$ 和非负特征值 $\lambda_1 \geq \dots \geq \lambda_n \geq 0$ 。

推导第1步: 确定 V 与奇异值。 令

$$V = [v_1, \dots, v_n] \in \mathbb{R}^{n \times n}, \quad \sigma_j = \sqrt{\lambda_j} \quad (j = 1, \dots, p).$$

若 $r = \text{rank}(A)$, 则 $\sigma_1, \dots, \sigma_r > 0$, 其余奇异值为 0。由

$$\lambda_j = \frac{\|Av_j\|_2^2}{\|v_j\|_2^2}$$

可知 $\lambda_j = 0$ 当且仅当 $Av_j = 0$ 。

推导第2步: 构造 U 并证明正交性。 对 $j = 1, \dots, r$ 定义

$$u_j = \frac{Av_j}{\sigma_j} \in \mathbb{R}^m.$$

对 $i, j \leq r$,

$$u_i^T u_j = \frac{v_i^T A^T A v_j}{\sigma_i \sigma_j} = \frac{\lambda_j v_i^T v_j}{\sigma_i \sigma_j} = \delta_{ij}.$$

因此 $u_1, \dots, u_r$ 标准正交。再从 $N(A^T)$ 选取 $m - r$ 个标准正交向量补全, 得到 $U = [u_1, \dots, u_m] \in \mathbb{R}^{m \times m}$ 。

推导第3步: 构造 Σ 并验证矩阵等式。 令 $\Sigma \in \mathbb{R}^{m \times n}$ 的第 j 个主对角元为 σ_j , 其余元素为 0。对 v_j 这组基中的任意向量,

$$U \Sigma V^T v_j = \begin{cases} \sigma_j u_j = Av_j, & j \leq r, \\ 0 = Av_j, & j > r. \end{cases}$$

两个线性变换在 $\mathbb{R}^n$ 的一组基上取值相同, 所以 $U \Sigma V^T = A$ 。维数链为 $(m \times m)(m \times n)(n \times n) = m \times n$ 。

读前自检: 奇异值分解存在性。 SVD 存在性构造先对 $A^T A$ 谱分解, 再补齐左右零空间基; 请逐列核对 $Av_i = \sigma_i u_i$, 并确认这些列与补齐列组成正交 U, V 后有 $A = U \Sigma V^T$ 。

定理 26.1 (奇异值分解存在性) 每个 $A \in \mathbb{R}^{m \times n}$ 都存在完整 SVD。奇异值作为 $A^T A$ 非负特征值的平方根是唯一的; 单个奇异向量未必唯一: 向量符号可同时改变, 重奇异值对应子空间内可作正交旋转, 零奇异值对应的基可任意正交补全。

读前自检：证明：奇异值分解存在性。 证明 SVD 存在时，对每个 $\sigma_i > 0$ 定义 $u_i = Av_i/\sigma_i$ ；请先验证其两两正交，再说明 $N(A)$ 与 $N(A^T)$ 的标准正交基如何补齐 V, U ，核对矩阵等式逐列成立。

证明。 上面的三步构造给出正交矩阵 U, V 、矩形对角矩阵 Σ 并验证 $A = U\Sigma V^T$ ，因此存在性成立。 $A^T A$ 的特征值多重集合由 A 唯一确定，非负平方根也唯一，故奇异值唯一。若把某对 (u_j, v_j) 同时换成 $(-u_j, -v_j)$ ，外积 $\sigma_j u_j v_j^T$ 不变；若干奇异值相等时，在相应左右子空间中应用同一个正交变换也保持乘积；零空间的正交基只负责补全，不影响 A 。这些构造分别说明非唯一来源。 $\square$

26.2 奇异值和左右奇异向量

从 $A = U\Sigma V^T$ 出发，

$$A^T A = V\Sigma^T \Sigma V^T, \quad AA^T = U\Sigma \Sigma^T U^T.$$

因此 $A^T A$ 与 AA^T 的非零特征值相同，均为 $\sigma_1^2, \dots, \sigma_r^2$ 。前者的对应特征向量为 v_j ，后者的对应特征向量为 u_j 。

比较 $AV = U\Sigma$ 与 $A^T U = V\Sigma^T$ 的列，可得

$$Av_j = \sigma_j u_j, \quad A^T u_j = \sigma_j v_j, \quad j = 1, \dots, r.$$

零奇异方向满足

$$Av_j = 0 \quad (j = r+1, \dots, n), \quad A^T u_j = 0 \quad (j = r+1, \dots, m).$$

由此得到

$$\begin{aligned} R(A) &= \text{span}(u_1, \dots, u_r), & N(A^T) &= \text{span}(u_{r+1}, \dots, u_m), \\ R(A^T) &= \text{span}(v_1, \dots, v_r), & N(A) &= \text{span}(v_{r+1}, \dots, v_n). \end{aligned}$$

定理 26.2 (谱范数与最小放大率) 对任意 $A \in \mathbb{R}^{m \times n}$,

$$\max_{\|x\|_2=1} \|Ax\|_2 = \sigma_1.$$

若 A 列满秩，则

$$\min_{\|x\|_2=1} \|Ax\|_2 = \sigma_n > 0.$$

极值方向分别可取 v_1 和 v_n 。

读前自检：证明：谱范数与最小放大率。 谱范数与最小放大率所用的明确前提是“令 $y = V^T x$ ”；完成把 $\|Ax\|_2^2$ 用到的关键定义展开并完成下一步变形后，核对列满秩时 $n \leq m$ 且所有 n 个奇异值为正。

证明. 令 $y = V^T x$, 则 $\|y\|_2 = \|x\|_2 = 1$, 并且

$$\|Ax\|_2^2 = \|\Sigma y\|_2^2 = \sum_{j=1}^p \sigma_j^2 y_j^2.$$

该加权和不超过 $\sigma_1^2 \sum_j y_j^2 = \sigma_1^2$, 取 $y = e_1$ 达到上界。列满秩时 $n \leq m$ 且所有 n 个奇异值为正, 加权和不小于 $\sigma_n^2 \sum_j y_j^2 = \sigma_n^2$, 取 $y = e_n$ 达到下界。□

读前自检：紧奇异值分解与截断奇异值分解。 设 $r = \text{rank}(A) > 0$; 请从完整 SVD 删除零奇异值列得到紧 SVD, 再只保留前 $k \leq r$ 项得到截断 SVD, 核对前者精确重构 A 、后者在 $k < r$ 时留下尾部误差。

读前自检：紧奇异值分解。 紧 SVD 只保留 $r = \text{rank}(A) > 0$ 个正奇异值; 请核对 $U_r \in \mathbb{R}^{m \times r}$ 、 $\Sigma_r \in \mathbb{R}^{r \times r}$ 、 $V_r \in \mathbb{R}^{n \times r}$ 相乘后精确得到 A 。

26.3 紧致与截断 SVD

读前自检：紧奇异值分解。 紧 SVD 满足 $U_r^T U_r = V_r^T V_r = I_r$; 请计算 $U_r U_r^T$ 的形状与平方, 核对它一般是投影矩阵而非 I_m 。

定义 26.2 (紧奇异值分解). 若 $r = \text{rank}(A) > 0$, 只保留正奇异值及其向量, 得到

$$A = U_r \Sigma_r V_r^T,$$

其中

$$U_r \in \mathbb{R}^{m \times r}, \quad \Sigma_r = \text{diag}(\sigma_1, \dots, \sigma_r) \in \mathbb{R}^{r \times r}, \quad V_r \in \mathbb{R}^{n \times r}.$$

$U_r^T U_r = V_r^T V_r = I_r$, 但 $U_r U_r^T$ 与 $V_r V_r^T$ 通常只是投影矩阵。

读前自检：零矩阵的秩 0 紧 SVD。 零矩阵 $A = 0_{m \times n}$ 的紧 SVD 取 $r = 0$; 请依次相乘 $U_0 \in \mathbb{R}^{m \times 0}$ 、 $\Sigma_0 \in \mathbb{R}^{0 \times 0}$ 与 $V_0^T \in \mathbb{R}^{0 \times n}$, 核对结果形状为 $m \times n$ 且 $U_0^T U_0 = V_0^T V_0 = I_0$ 。

定义 26.3 (零矩阵的秩 0 紧 SVD). 若 $A = 0_{m \times n}$, 则 $r = 0$, 其紧 SVD 采用空因子约定

$$U_0 \in \mathbb{R}^{m \times 0}, \quad \Sigma_0 \in \mathbb{R}^{0 \times 0}, \quad V_0 \in \mathbb{R}^{n \times 0}, \quad A = U_0 \Sigma_0 V_0^T = 0_{m \times n}.$$

这里没有正奇异三元组需要计算; 空列正交条件 $U_0^T U_0 = V_0^T V_0 = I_0$ 按空矩阵约定成立。完整 SVD 仍可用任意正交 U, V 和全零 Σ 表示。因而“范数为零”是合法的秩 0 结果, 不是数值失败。

例题 26.1 (零矩阵回归例). 求 $A = 0_{2 \times 3}$ 的紧 SVD, 写出三个因子的维数, 并判断算法应返回的状态。说明为什么后续构造中不能执行除以奇异值的步骤。

例题 26.1 解答

读题翻译 零矩阵没有正奇异值列；需要用秩零空因子写出紧 SVD，并判断这种退化分解是否仍是合法输出。

已知与合法条件 $A = 0_{2 \times 3}$ ，故 $\|A\|_F = 0$ 且 $r = \text{rank}(A) = 0$ ；紧 SVD 只保留正奇异值对应的列。

为什么想到这个方法 先由零矩阵确定秩，再按秩零空因子约定写出三因子形状；核对精确重构，并检查所有除以奇异值的步骤。

方法选择 依次求 r 、写 U_0, Σ_0, V_0 的空维数、核对乘积外部形状与重构误差，最后说明为何不存在可执行的 Av_j/σ_j 步骤。

推导/计算 取

$$U_0 \in \mathbb{R}^{2 \times 0}, \quad \Sigma_0 \in \mathbb{R}^{0 \times 0}, \quad V_0 \in \mathbb{R}^{3 \times 0}.$$

于是

$$U_0 \Sigma_0 V_0^T \in \mathbb{R}^{2 \times 3}, \quad U_0 \Sigma_0 V_0^T = 0_{2 \times 3} = A.$$

独立核验 三个内部维数依次为 0 并能相消，乘积外部形状为 2×3 ；重构误差 $\|A - U_0 \Sigma_0 V_0^T\|_F = 0$ 。由于不存在 $\sigma_j > 0$ ，算法不得执行 $u_j = Av_j/\sigma_j$ 。

结论 应正常返回上述合法的秩零空分解；零范数表示退化但精确的紧 SVD，而不是数值失败。

读前自检：截断奇异值分解。 截断 SVD 在 $r = \text{rank}(A) > 0$ 且 $1 \leq k \leq r$ 时定义 $A_k = U_k \Sigma_k V_k^T$ ；请标出三因子的形状并核对 $A_k \in \mathbb{R}^{m \times n}$ 、 $\text{rank}(A_k) = k$ 。

读前自检：截断奇异值分解。 截断 SVD 满足 $A_k = \sum_{j=1}^k \sigma_j u_j v_j^T$ 且前 r 个奇异值为正；请分别代入 $k < r$ 与 $k = r$ ，核对前者遗漏非零项而 $A_k \neq A$ ，后者精确重构 A 。

定义 26.4 (截断奇异值分解). 若 $r = \text{rank}(A) > 0$ ，对 $1 \leq k \leq r$ ，令 U_k, V_k 取前 k 列， Σ_k 取前 k 个奇异值，定义

$$A_k = U_k \Sigma_k V_k^T = \sum_{j=1}^k \sigma_j u_j v_j^T.$$

$A_k \in \mathbb{R}^{m \times n}$ 且 $\text{rank}(A_k) = k$ 。由紧 SVD 的精确重构与 $\sigma_1, \dots, \sigma_r > 0$ 可知

$$A_k = A \iff k = r, \quad 1 \leq k < r \implies A_k \neq A.$$

因此 $k < r$ 时 A_k 是对 A 的有损近似，而 $k = r$ 时 A_r 就是精确的紧 SVD 重构。

读前自检：易混淆概念对比：紧致与截断 SVD。 完整、紧与截断 SVD 的表格分别使用 m/n 、秩 r 和保留秩 k ；请逐行核对三者的 U, Σ, V 形状，并确认只有完整与紧形式在相应条件下精确重构 A 。

易混淆概念对比

三种形式的维数。

形式	左因子	对角因子	右因子
完整 SVD	$U : m \times m$	$\Sigma : m \times n$	$V : n \times n$
紧 SVD	$U_r : m \times r$	$\Sigma_r : r \times r$	$V_r : n \times r$
截断 SVD	$U_k : m \times k$	$\Sigma_k : k \times k$	$V_k : n \times k$

紧 SVD 仍精确表示 A ，存储量约为 $r(m+n+1)$ ；截断 SVD 用 $k(m+n+1)$ 个标量近似 mn 个矩阵元素。只有在 $k(m+n+1) < mn$ 并计入索引与精度后，才产生实际存储节省。

第一次阅读路线

先掌握 SVD 定义、紧/截断形式与低秩误差公式；双边子空间迭代只是“怎样在大矩阵上近似算出前 k 项”的数值求解器进阶，不参与 SVD 存在性或 Eckart–Young–Mirsky 最优性的定义。手算与概念题可直接跳至节 26.5。

26.4 SVD 的计算

教学型构造可先对 $A^T A$ 求特征分解，再令 $\sigma_j = \sqrt{\lambda_j}$ 和 $u_j = Av_j/\sigma_j$ 。该路线适合手算和证明，但显式形成 $A^T A$ 会把二范数条件数平方：

$$\kappa_2(A^T A) = \kappa_2(A)^2$$

(在非零奇异子空间上)。数值计算通常先把 A 正交双对角化，或用只需矩阵–向量乘法的子空间方法求前几个奇异三元组。

算法所需量与计算结果。 下面的双边子空间迭代用于求前 k 个奇异三元组。计算需要 A 、目标秩、子空间宽度、初始子空间、迭代上限和容差；返回最后合法 Ritz 状态、实际提交轮/块乘/压缩 SVD 计数，以及 $\text{status} \in \{\text{converged}, \text{budget_stop}, \text{invalid_input}, \text{numerical_failure}\}$ 。若数值秩小于 k 、矩阵为零或初始化无效，应说明已检测的有效秩和诊断结论，不能给出并不存在的 k 个三元组。算法不显式形成 $A^T A$ 。

参数含义。 取 $1 \leq k \leq \ell = k + s \leq p$ ， $s \geq 0$ 为额外方向数； $T_{\max} \geq 1$ 为最大迭代数； $\varepsilon_{\text{sub}}, \varepsilon_{\text{res}} > 0$ 分别控制投影变化与奇异三元组残差。若 σ_k 与 σ_{k+1} 接近，应增大 ℓ 或迭代预算。

初始化。 先检查 A 元素有限、尺寸非空、 $1 \leq k \leq \ell \leq p$ 、两项容差为正且 $T_{\max} \geq 1$ 。若 $\|A\|_F = 0$ ，不进入迭代，直接按定义 26.3 返回 $r = 0$ 的空紧分解与 completed。否则构造 $Q^{(0)} \in \mathbb{R}^{m \times \ell}$ 且列标准正交；可对固定随机种子产生的矩阵作 QR 分解，也可从经过挑选的数据列开始。若正交化后的有效列数不是 ℓ ，初始化无效；还必须检查 $Q^{(0)}$ 与主左奇异子空间有非零投影。

截断 SVD 的双边子空间迭代：五步阅读

输入。 写出数据对象、固定参数与必须成立的条件。

初始化。 标明主状态、计数器和第一个合法状态。

算法 26.1: 截断 SVD 的双边子空间迭代

输入: 有限矩阵 $A \in \mathbb{R}^{m \times n}$, $1 \leq k \leq \ell \leq p$, $Q^{(0)}$, $T_{\max} \geq 1$, $\varepsilon_{\text{sub}}, \varepsilon_{\text{res}} > 0$
输出: 最后合法 Ritz 三元组与证书; $t_{\text{done}}, b_{\text{done}}, s_{\text{done}}$; **status** 及诊断

- 1 若 $A, k, \ell, Q^{(0)}$ 、预算或容差接口非法, 则返回 **1**、计数 0、**invalid_input** 及字段诊断
- 2 若 $\|A\|_F = 0$, 则返回 $U_0 \in \mathbb{R}^{m \times 0}, \Sigma_0 \in \mathbb{R}^{0 \times 0}, V_0 \in \mathbb{R}^{n \times 0}, r = 0$ 、计数 0、**completed** 及零矩阵精确重构诊断
- 3 正交化 $Q^{(0)}$; 若有效列数不足 ℓ , 则返回 **1**、计数 0、**numerical_failure** 及初始化秩诊断
- 4 令 $Q \leftarrow Q^{(0)}, \ell_t \leftarrow \ell, t_{\text{done}} \leftarrow 0, b_{\text{done}} \leftarrow 0, s_{\text{done}} \leftarrow 0$, 最后合法模型为 **1**
- 5 **当** $t_{\text{done}} < T_{\max}$ **执行**
- 6 计算 $Z^+ = \text{orth}(A^T Q)$ 并令 $b_{\text{done}} \leftarrow b_{\text{done}} + 1$; 若非有限或有效列数不足 k , 返回最后合法模型与 **numerical_failure** 及右阶段诊断; 否则按实际宽度缩小 ℓ_t
- 7 计算 $Q^+ = \text{orth}(AZ^+)$ 并令 $b_{\text{done}} \leftarrow b_{\text{done}} + 1$; 若非有限或有效列数不足 k , 返回最后合法模型与 **numerical_failure** 及左阶段诊断; 否则按实际宽度缩小 ℓ_t
- 8 计算 $\eta^+ = \|Q^+ Q^{+T} - Q Q^T\|_F$, 对 $B^+ = Q^{+T} A$ 求压缩 SVD 并令 $s_{\text{done}} \leftarrow s_{\text{done}} + 1$
- 9 恢复前 k 个 Ritz 三元组并计算左右最大残差 ρ^+ ; 若 SVD、三元组、 η^+ 或 ρ^+ 非有限, 则返回上一合法模型与 **numerical_failure** 及 Ritz 阶段诊断
- 10 原子提交 $(Q, U_k, \Sigma_k, V_k, \eta, \rho) \leftarrow (Q^+, U_k^+, \Sigma_k^+, V_k^+, \eta^+, \rho^+)$, 令 $t_{\text{done}} \leftarrow t_{\text{done}} + 1$
- 11 若 $\eta \leq \varepsilon_{\text{sub}}$ 且 $\rho \leq \varepsilon_{\text{res}}$, 则返回最后合法模型、实际计数、**converged** 及双证书诊断
- 12 **结束**
- 13 返回最后合法模型、实际计数、**budget_stop** 及“预算耗尽、双证书未满足”诊断

核心更新。只手算一次从旧状态到候选状态的更新, 并指出何时提交。

数学停止。写出能直接核验的停止证书; 预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

算法实现说明: 核心流程跟踪 $A^T Q$ 与 AZ 两次正交化、压缩 SVD、双边残差和停止; 秩亏与数值失败分支属于稳健实现细节 完整 C1-C14 契约

循环变量与更新顺序。循环变量是 $t = 1, \dots, T_{\max}$ 。每轮依次计算右子空间 $Z^{(t)}$ 、左子空间 $Q^{(t)}$ 、投影差、压缩矩阵 SVD 和左右残差; 后一步只使用本轮已更新对象。一次双边更新等价于把左子空间乘以 AA^T 后重新正交化, 但分两次乘法可避免形成法方程矩阵。

判断与停止条件。正常停止同时要求投影矩阵变化和左右残差达到容差; 达到迭代上限时返回最后有效结果并明确说明尚未满足收敛准则。正交化后有效列数不足 k 或出现非有限数时异常停止。仅观察奇异值变化可能漏掉重根子空间旋转。

收敛条件。若初始子空间与前 ℓ_t 个左奇异子空间有满秩投影, 并且目标子空间与其余方向之间存在谱隙, 则精确算术下子空间迭代收敛。只有在 $\ell_t < p$ 、 $\sigma_{\ell_t} > 0$ 且 $\sigma_{\ell_t} > \sigma_{\ell_t+1}$ 时, 单一边界的主误差因子才可写成 $(\sigma_{\ell_t+1}/\sigma_{\ell_t})^{2t}$; 比值接近 1 时收敛慢。若 $\ell_t = p$, 工作子空间之外没有奇异方向, 因而不需定义该比值; 若工作宽度因数值秩缩小, 应使用实际 ℓ_t 。重奇异值时应评价整个不变子空间, 而不是某一系列向量。

异常与退化情形。空尺寸矩阵、非有限元素、不合法的 k, ℓ 、非正容差、非正迭代预算或初始子空间有效列不足都使计算条件不成立; 目标数值秩小于 k 时只能说明有效秩和诊断结论, 不能给出 k 个正奇异三元组。元素全零的非空矩阵例外: 其数值秩与精确秩同为 0, 算法合法完成并返回空紧分解。若应用确实需要补出零奇异值对应的任意基, 必须另行使用完整 SVD 的基补全过程, 不能把它冒充为本迭代已经算出的正三元组。

正确性依据。每轮压缩矩阵满足 $B^{(t)} = Q^{(t)T}A$, 其左奇异向量经 $Q^{(t)}$ 提升后仍标准正交; 左右残差为零时, 返回的三元组满足 $Av_j = \sigma_j u_j$ 与 $A^T u_j = \sigma_j v_j$ 。当迭代子空间包含目标左奇异子空间时, Rayleigh–Ritz 压缩恢复相应奇异三元组。

不收敛或不适用情形。初始子空间漏掉目标方向、谱隙过小、容差低于浮点精度可达范围、矩阵 – 向量乘法不一致或迭代预算不足时, 方法可能未收敛。此时应报告残差和停止原因, 改用更宽子空间、重启或稳定的直接 SVD; 带缺失权重、非负约束的目标也不由本算法求解。

读前自检: 复杂度分析: SVD 的计算。稠密 $m \times n$ 矩阵的完整 SVD 时间量级为 $O(mn \min(m, n))$; 请令 $m \geq n$ 化简该量级, 并与只求前 k 个奇异三元组所需的输出存储 $O((m+n)k)$ 对照, 并核对时间与存储量级和算法框一致。

复杂度分析

训练时间复杂度。稠密 A 的一轮两次矩阵 – 块乘法为 $O(mn\ell)$, QR 与压缩矩阵处理为 $O((m+n)\ell^2)$; T 轮主代价为 $O(Tmn\ell)$ 。完整稠密 SVD 通常为 $O(mn \min(m, n))$ 量级。

新向量投影代价。本算法只完成矩阵分解, 不定义监督学习的逐样本预测。若下游把 b 个新向量投到 V_k 或 U_k 坐标, 另需 $O(nkb)$ 或 $O(mkb)$, 这属于因子应用而非分解计算。

空间复杂度。若 A 已存储, 需要 $O(mn)$; 子空间、工作矩阵与压缩因子需要 $O((m+n)\ell)$ 量级。对可流式乘法的线性算子, 可不显式保存 A 。

复杂度假设。上述界假设 A 为稠密实矩阵、一次标量运算为常数成本、QR 与小 SVD 采用稳定稠密实现, 且 $k \leq \ell \ll p$; 稀疏或算子表示应把 $mn\ell$ 替换为实际块乘法成本。

读前自检: 奇异值分解与矩阵近似。矩阵近似用 Frobenius 范数 $\|A\|_F^2 = \text{tr}(A^T A)$; 请把 $A - U_k \Sigma_k V_k^T$ 代入, 核对误差平方等于尾部奇异值平方和。

读前自检: 弗罗贝尼乌斯范数。Frobenius 范数定义为全部元素平方和开方; 请计算 $\text{tr}(A^T A)$, 核对两式相等且结果为非负标量。

26.5 低秩矩阵近似

读前自检: Frobenius 范数。Frobenius 范数对正交左右变换不变; 请展开 $\|QAP^T\|_F^2$ 的迹并用 $Q^T Q = P^T P = I$, 核对结果为 $\|A\|_F^2$ 。

定义 26.5 (Frobenius 范数).对 $A = [a_{ij}] \in \mathbb{R}^{m \times n}$,

$$\|A\|_F = \left(\sum_{i=1}^m \sum_{j=1}^n a_{ij}^2 \right)^{1/2} = \sqrt{\text{tr}(A^T A)}.$$

若 Q, P 为维数相容的正交矩阵, 则 $\|QAP^T\|_F = \|A\|_F$ 。

由正交不变性,

$$\|A\|_F^2 = \|\Sigma\|_F^2 = \sum_{j=1}^p \sigma_j^2, \quad \|A\|_2 = \sigma_1.$$

截断后的误差为

$$A - A_k = \sum_{j=k+1}^r \sigma_j u_j v_j^T,$$

候选误差因而满足

$$\|A - A_k\|_F^2 = \sum_{j=k+1}^r \sigma_j^2, \quad \|A - A_k\|_2 = \sigma_{k+1}.$$

读前自检：Frobenius 能量与相对范数误差。 截断 SVD 的保留能量 $E_k = \sum_{j=1}^k \sigma_j^2 / \sum_{j=1}^r \sigma_j^2$ 要求 $A \neq 0$ ；请对给定奇异值求 E_k ，核对其位于 $[0, 1]$ 且相对 Frobenius 误差平方为 $1 - E_k$ 。

定义 26.6 (Frobenius 能量与相对范数误差). 当 $A \neq 0$ 时，保留前 k 项的平方 Frobenius 能量比例与尾部平方损失为

$$E_k = \frac{\sum_{j \leq k} \sigma_j^2}{\sum_j \sigma_j^2}, \quad L_k = \frac{\|A - A_k\|_F^2}{\|A\|_F^2} = 1 - E_k.$$

相对 Frobenius 范数误差则是

$$\frac{\|A - A_k\|_F}{\|A\|_F} = \sqrt{L_k} = \sqrt{1 - E_k}.$$

因此“保留 90% 能量”等价于“尾部平方损失 10%”，但范数相对误差是 $\sqrt{0.1} \approx 31.62\%$ ，不是 10%。报告百分比时必须写明是平方能量、平方损失还是范数误差。

读前自检：矩阵的最优近似。 矩阵 A 的秩至多 k 近似满足 $\|A - B\|_2 \geq \sigma_{k+1}$ 和 $\|A - B\|_F^2 \geq \sum_{j>k} \sigma_j^2$ ；请把 $B = A_k$ 代入，核对截断 SVD 同时达到两个下界。

读前自检：截断 SVD 的低秩最优性。 截断 SVD 低秩最优性以 $\text{rank}(B) \leq k$ 为条件；请分别投影到被舍弃的 v_{k+1} 方向并展开 Frobenius 正交和，核对谱范数下界 σ_{k+1} 与 Frobenius 尾能量下界。

读前自检：Eckart-Young-Mirsky 低秩最优性。 把 Eckart-Young-Mirsky 低秩最优性放在“若 $\sigma_k > \sigma_{k+1}$ ，前 k 维左右奇异子空间唯一”下考察：把 $\|A - B\|_2 \geq \sigma_{k+1}$ ，按证明中的分解展开一层，并检查若 $\sigma_k = \sigma_{k+1}$ ，截断边界穿过重奇异值子空间。

定理 26.3 (Eckart-Young-Mirsky 低秩最优性) 设 $A \in \mathbb{R}^{m \times n}$ 的奇异值为 $\sigma_1 \geq \dots \geq \sigma_p \geq 0$ ，且 $1 \leq k < r$ 。对任意 $B \in \mathbb{R}^{m \times n}$ 且 $\text{rank}(B) \leq k$ ，

$$\|A - B\|_2 \geq \sigma_{k+1}, \quad \|A - B\|_F \geq \left(\sum_{j=k+1}^r \sigma_j^2 \right)^{1/2}.$$

$A_k = U_k \Sigma_k V_k^T$ 同时达到两个下界。若 $\sigma_k > \sigma_{k+1}$, 前 k 维左右奇异子空间唯一, 且 Frobenius 范数下的最优矩阵 A_k 唯一; 谱范数下的最优矩阵即使存在该间隙也可能不唯一。若 $\sigma_k = \sigma_{k+1}$, 截断边界穿过重奇异值子空间, Frobenius 最优矩阵也可能不唯一。

证明: Eckart-Young-Mirsky 低秩最优性: 证明阅读检查

动手检查。待证结论与所需条件分别是什么? 请在最小维度或最小样本上写出第一处关键变形, 并指出少一个条件时证明会在哪一步中断。

1. 先写清对象类型、目标结论与符号作用域。
2. 逐项核对定义域、维数、支持集、量词与交换运算所需条件。
3. 写出第一处可执行的数学动作, 不用“显然”跳过入口。
4. 沿现有编号完成中间关系, 并单独核对归一化、边界或等号条件。
5. 回到待证结论, 再说明它与后续公式、算法、图或例题的连接。

继续核对。完成上面的最小任务后, 再对照主体逐项核对定义域、更新式或关键变形、停止条件以及返回值; 阅读检查不代替正文中的数学论证。

证明. 谱范数下界。考虑 $(k+1)$ 维子空间 $S = \text{span}(v_1, \dots, v_{k+1})$ 。因为 $\text{rank}(B) \leq k$, 线性映射 $B|_S$ 的零空间至少一维, 所以存在单位向量 $x \in S$ 使 $Bx = 0$ 。写 $x = \sum_{j=1}^{k+1} c_j v_j$, 则

$$\|(A-B)x\|_2^2 = \|Ax\|_2^2 = \sum_{j=1}^{k+1} \sigma_j^2 c_j^2 \geq \sigma_{k+1}^2 \sum_{j=1}^{k+1} c_j^2 = \sigma_{k+1}^2.$$

取单位向量上的最大值, 得到 $\|A-B\|_2 \geq \sigma_{k+1}$ 。

Frobenius 范数下界。令 Q 为 B 的列空间, 维数 $q \leq k$, P_Q 为其正交投影。由于 $P_Q B = B$,

$$A-B = (I-P_Q)A + \{P_Q A - B\}.$$

两项的每一列互相正交, 所以

$$\|A-B\|_F^2 = \|(I-P_Q)A\|_F^2 + \|P_Q A - B\|_F^2 \geq \|(I-P_Q)A\|_F^2.$$

取 Q 的一组标准正交基 $q_1, \dots, q_q$, 由 $AA^T = \sum_{j=1}^p \sigma_j^2 u_j u_j^T$,

$$\|P_Q A\|_F^2 = \sum_{i=1}^q q_i^T A A^T q_i = \sum_{j=1}^p \sigma_j^2 \alpha_j, \quad \alpha_j = \sum_{i=1}^q (u_j^T q_i)^2.$$

这里 $0 \leq \alpha_j \leq 1$ 。若 Q 含有 $N(A^T)$ 中的分量, 则这些分量不出现在 $j=1, \dots, p$ 的和中, 因此只能断言 $\sum_{j=1}^p \alpha_j \leq q \leq k$; 该不等式已足够。按奇异值非增排列, 这个加权和不超过 $\sum_{j=1}^k \sigma_j^2$ 。因此

$$\|(I-P_Q)A\|_F^2 = \|A\|_F^2 - \|P_Q A\|_F^2 \geq \sum_{j=k+1}^r \sigma_j^2.$$

最后, A_k 的误差奇异值恰为 $\sigma_{k+1}, \dots, \sigma_r$, 所以它同时达到谱范数与 Frobenius 范数下界。

Frobenius 取等与唯一性。 上述两个不等式同时取等时, 必须有 $P_Q A = B$, 并且投影能量达到 $\sum_{j=1}^k \sigma_j^2$ 。若 $\sigma_k > \sigma_{k+1}$, 加权和取等迫使 $\alpha_j = 1 (j \leq k)$ 且 $\alpha_j = 0 (j > k)$, 故 $Q = \text{span}(u_1, \dots, u_k)$; 再由 $B = P_Q A$ 得到 $B = A_k$, Frobenius 最优矩阵唯一。若 $\sigma_k = \sigma_{k+1} = s$, 设严格大于 s 的奇异值有 $a < k$ 个, 则可在 s 对应的重根子空间中任选 $k - a$ 维子空间; 不同选择给出不同的 $P_Q A$, 但舍弃奇异值平方和相同, 所以最优误差唯一而最优矩阵一般不唯一。

谱范数非唯一性。 即使 $\sigma_k > \sigma_{k+1}$, 取非零 t 满足 $|t| \leq \sigma_{k+1}$, 矩阵

$$B_t = A_k + t u_1 v_1^T$$

仍有秩不超过 k , 而 $A - B_t$ 的最大奇异值为 $\max\{|t|, \sigma_{k+1}\} = \sigma_{k+1}$ 。因此 B_t 与 A_k 都是谱范数最优解, 说明谱隙不推出谱范数最优矩阵唯一。□

优化解释

优化解释。 截断 SVD 精确求解

$$\min_{\text{rank}(B) \leq k} \|A - B\|_F$$

以及谱范数版本。秩约束是非凸集合, 但正交不变性把问题化为保留最大的 k 个对角缩放。若加入非负、稀疏、缺失观测或加权误差约束, 截断 SVD 通常不再是该新问题的最优解。

读前自检: 概率解释: 若观测矩阵满足 $A = L + E$, 其中 L 的秩不超过 k , 噪声元素独立且 $E_{ij} \sim \mathcal{N}(0, \tau^2)$ 。低秩高斯噪声解释假设 $A = L + E$ 、 $\text{rank}(L) \leq k$ 且 $E_{ij} \sim \mathcal{N}(0, \tau^2)$ 独立同分布; 请展开负对数似然中依赖 L 的部分, 核对它与 $\|A - L\|_F^2$ 成正比。

概率解释

若观测矩阵满足 $A = L + E$, 其中 L 的秩不超过 k , 噪声元素独立且 $E_{ij} \sim \mathcal{N}(0, \tau^2)$, 则固定 τ 时负对数似然与 $\|A - L\|_F^2$ 只差正比例和常数。截断 SVD 因而是该同方差高斯噪声模型下的最大似然低秩估计。异方差或重尾噪声需要不同损失。

读前自检: 几何解释。 SVD 几何解释把单位球依次经 V^T 、 Σ 与 U 映射; 请跟踪一个单位向量, 核对正交因子保持长度而 Σ 把各轴缩放为 σ_j , 最大半轴为 $\|A\|_2$ 。


26.6 代数推导与几何解释

几何理解

几何解释。 单位球先经 V^T 旋转或反射, 仍为单位球; 再经 Σ 沿正交坐标轴缩放为半轴长度 $\sigma_1, \dots, \sigma_p$ 的椭球, 零奇异值把相应方向压扁; 最后经 U 旋转或反射到输出空间。最大半轴给出 $\|A\|_2$, 非零半轴个数给出秩。

如图 26.1 所示, 两个正交变换只改变坐标方向, 所有长度伸缩都集中在 Σ 的非负对角元上。

输入：单位圆 V^T ：正交旋转 Σ ：轴向缩放 U ：正交旋转



蓝向量与两条基方向贯穿四个面板；坐标范围一致

图 26.1 SVD 把线性变换分成正交变换、轴向缩放和正交变换

读前自检：矩阵的外积展开式。 SVD 外积展开为 $A = \sum_{j=1}^r \sigma_j u_j v_j^T$ ；请写出单项的 (a, b) 元素并核对其秩为 1，再比较前 k 项与前 $k+1$ 项的 Frobenius 误差平方相差 σ_{k+1}^2 。

将 $U\Sigma$ 按列、 V^T 按行分块，可得

$$A = \sum_{j=1}^r \sigma_j u_j v_j^T.$$

每个 $u_j v_j^T$ 是秩 1 矩阵，其 (a, b) 元素为 $u_{aj} v_{bj}$ 。奇异值给这些正交秩 1 成分排序；前 k 项之和就是 A_k ，后一项加入后误差能量减少 σ_{k+1}^2 。

谱分解联系。 前文把 $A^T A$ 的正交谱分解用于构造右奇异向量；同样地， AA^T 给出左奇异向量，而且两者具有相同的非零谱。这个联系也解释了 SVD、协方差特征分解和主成分方向之间的关系。

四个基本子空间。 SVD 给出彼此正交的分解

$$\mathbb{R}^n = R(A^T) \oplus N(A), \quad \mathbb{R}^m = R(A) \oplus N(A^T).$$

V_r 张成输入中会被映射的方向， V_0 张成被消去的方向； U_r 张成所有可能输出， U_0 张成输出空间中无法由 A 产生的方向。

26.7 例题与练习

例题 26.2 (一个长矩阵的完整、紧与截断 SVD). 给定

$$A = \begin{bmatrix} 3 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix} \in \mathbb{R}^{3 \times 2}.$$

写出完整 SVD 与紧 SVD，并求最佳秩 1 近似及两种范数误差。

例题 26.2 解答

读题翻译 要区分同一 3×2 矩阵的完整 SVD、紧 SVD 和最佳秩 1 截断，并分别报告谱范数与 Frobenius 范数误差。

已知与合法条件 $A \in \mathbb{R}^{3 \times 2}$ 、 $\text{rank}(A) = 2$ ；完整分解取 $U \in \mathbb{R}^{3 \times 3}$ ，紧分解只保留两个正奇异值对应的列。

为什么想到这个方法 先由 $A^T A$ 求右奇异向量与奇异值，再由 $u_j = Av_j/\sigma_j$ 构造左奇异向量；Eckart-Young 定理把最佳秩 1 误差化为舍弃奇异值。

方法选择 求 $A^T A$ 的谱，写出完整与紧分解；保留首个奇异三元组得到 A_1 ，再用尾部奇异值计算并直接复核两种误差。

推导/计算 完整与紧 SVD。 $A^T A = \text{diag}(9, 1)$ ，所以奇异值为 3, 1，可取

$$U = I_3, \quad \Sigma = \begin{bmatrix} 3 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}, \quad V = I_2.$$

矩阵秩 $r = 2$ ，紧 SVD 为

$$U_r = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}, \quad \Sigma_r = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}, \quad V_r = I_2.$$

秩 1 截断。 保留首项得到

$$A_1 = 3u_1v_1^T = 3e_1^{(3)}(e_1^{(2)})^T = \begin{bmatrix} 3 & 0 \\ 0 & 0 \\ 0 & 0 \end{bmatrix}.$$

被舍弃奇异值只有 1，因此 $\|A - A_1\|_F = 1$ 且 $\|A - A_1\|_2 = 1$ 。维数检查为 $(3 \times 1)(1 \times 1)(1 \times 2) = 3 \times 2$ 。

独立核验 直接相乘有 $U\Sigma V^T = A$ ，而 $A - A_1 = \text{diag}_{3 \times 2}(0, 1)$ ，其唯一非零奇异值为 1；这同时复核了两种误差和重构尺寸。

结论 完整 SVD 可取 $U = I_3$ 、 $\Sigma = \text{diag}_{3 \times 2}(3, 1)$ 、 $V = I_2$ ；紧 SVD 保留前两列；最佳秩 1 近似为 $A_1 = \text{diag}_{3 \times 2}(3, 0)$ ，且 $\|A - A_1\|_F = \|A - A_1\|_2 = 1$ 。

读前自检：适用条件与局限：例题与练习。 SVD 适用于线性低秩结构且 Frobenius 误差合理的矩阵任务；请计算截断误差 $\sum_{j>k} \sigma_j^2$ ，核对奇异值尾部未衰减或目标为非线性结构时不能仅凭该误差宣称适用。

适用条件与局限性

适用条件。 SVD 适合线性结构、二范数或 Frobenius 误差合理、需要正交方向排序的矩阵任务。截断 SVD 适合奇异值衰减较快且目标是压缩、去噪、潜在语义坐标或线性降维的场景；目标秩应由误差、稳定性和下游效用联合选择。

方法局限

SVD 对异常值敏感，Frobenius 目标默认各元素同等可信；缺失元素不能先任意填零后仍沿用完整观测结论；正交成分可能含正负载荷而缺少直接语义；奇异值衰减慢时，低秩压缩收益有限。

读前自检：常见错误与误用边界：例题与练习。 先锁定例题与练习的条件“边界框首项禁止形成 $A^T A$ 后忽略条件数平方和小奇异值误差”：把固定错误“形成 $A^T A$ 后忽略条件数平方和小奇异值误差”中的对象、操作与结论按本节定义拆开，指出第一个不满足的定义条件，再把该处改为本节允许的写法，所得结果应满足改写后的运算或判断有定义，且不再触发“形成 $A^T A$ 后忽略条件数平方和小奇异值误差”。

常见错误

1. 把 U, Σ, V 的维数都写成 $n \times n$ ，忽略矩形矩阵；
2. 把 V 误写成 V^T 的列，或在重构时漏掉转置；
3. 令 $u_j = Av_j/\sigma_j$ 时对 $\sigma_j = 0$ 作除法；
4. 把紧 SVD 和截断 SVD 都写成近似号，未区分精确与有损；
5. 形成 $A^T A$ 后忽略条件数平方和小奇异值误差；
6. 只报告累计奇异值而不是累计平方奇异值作为 Frobenius 能量。

读前自检：易混淆概念对比：例题与练习。 对例题与练习，条件“对比表首个数据行是“完整 SVD | 两侧正交、矩形对角 | 任意实矩阵存在 | 存储与全分解成本高””不可省；请按列复述“完整 SVD | 两侧正交、矩形对角 | 任意实矩阵存在 | 存储与全分解成本高”中的对象、假设与结论，再用各列均对应首行对象“完整 SVD”，且未与表中下一行互换作检查。

易混淆概念对比

分解与近似对比。			
方法	约束或结构	主要保证	典型边界
完整 SVD	两侧正交、矩形对角	任意实矩阵存在	存储与全分解成本高
截断 SVD	秩不超过 k	二范数和 Frobenius 最优	不处理非负或缺失约束
对称特征分解	方阵且对称	正交特征基	不直接适用一般矩形矩阵
QR 分解	列空间正交基与上三角	稳定求解线性系统	不按能量给低秩最优排序
非负矩阵分解	因子元素非负	部件式可解释性	非凸且无 SVD 式全局最优保证

本章共 18 道练习。每道题干后立即给出同号解析；长解析可自然跨页，续页标题保留题号。

练习 26.1. 求矩阵

$$A = \begin{bmatrix} 1 & 2 & 0 \\ 2 & 0 & 2 \end{bmatrix}$$

的奇异值分解, 并核对三个因子的维数。

练习 26.1 解析

先算

$$AA^T = \begin{bmatrix} 5 & 2 \\ 2 & 8 \end{bmatrix},$$

其特征值为 9, 4, 故奇异值为 $\sigma_1 = 3, \sigma_2 = 2$ 。可取

$$u_1 = \frac{1}{\sqrt{5}} \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad u_2 = \frac{1}{\sqrt{5}} \begin{bmatrix} -2 \\ 1 \end{bmatrix}.$$

由 $v_j = A^T u_j / \sigma_j$ 得到

$$v_1 = \frac{1}{3\sqrt{5}} \begin{bmatrix} 5 \\ 2 \\ 4 \end{bmatrix}, \quad v_2 = \frac{1}{\sqrt{5}} \begin{bmatrix} 0 \\ -2 \\ 1 \end{bmatrix}.$$

再取右零空间单位向量 $v_3 = (-2, 1, 2)^T / 3$ 。于是

$$U = [u_1, u_2], \quad \Sigma = \begin{bmatrix} 3 & 0 & 0 \\ 0 & 2 & 0 \end{bmatrix}, \quad V = [v_1, v_2, v_3]$$

满足 $A = U\Sigma V^T$ 。维数依次为 2×2 、 2×3 、 3×3 ；直接检查 $Av_j = \sigma_j u_j$ ($j = 1, 2$) 和 $Av_3 = 0$ 即可核对乘积。

练习 26.2. 求矩阵

$$A = \begin{bmatrix} 2 & 4 \\ 1 & 3 \\ 0 & 0 \\ 0 & 0 \end{bmatrix}$$

的奇异值分解, 并把 A 写成奇异值加权的秩 1 外积之和。

练习 26.2 解析

$$A^T A = \begin{bmatrix} 5 & 11 \\ 11 & 25 \end{bmatrix},$$

其特征值为 $\lambda_{\pm} = 15 \pm \sqrt{221}$, 故 $\sigma_{\pm} = \sqrt{15 \pm \sqrt{221}}$ 。令

$$d_{\pm} = \sqrt{121 + (10 \pm \sqrt{221})^2}, \quad v_{\pm} = \frac{1}{d_{\pm}} \begin{bmatrix} 11 \\ 10 \pm \sqrt{221} \end{bmatrix}.$$

练习 26.2 解析 (续)

两个 $v_{\pm}$ 互相正交, 因为其未归一化向量的内积为 $121 + (10 + \sqrt{221})(10 - \sqrt{221}) = 0$ 。再令

$$u_{\pm} = \frac{Av_{\pm}}{\sigma_{\pm}}.$$

它们是 $\mathbb{R}^4$ 中的标准正交向量, 且第三、第四分量为零。以 e_3, e_4 补全左正交基, 得到

$$U = [u_+, u_-, e_3, e_4], \quad \Sigma = \begin{bmatrix} \sigma_+ & 0 \\ 0 & \sigma_- \\ 0 & 0 \\ 0 & 0 \end{bmatrix}, \quad V = [v_+, v_-].$$

因此

$$A = U\Sigma V^T = \sigma_+ u_+ v_+^T + \sigma_- u_- v_-^T.$$

这也逐项给出了两个秩 1 外积成分。

练习 26.3. 比较一般矩阵的奇异值分解与实对称矩阵的正交对角化。对称矩阵的特征值可能为负时, 说明怎样由特征分解构造 SVD; 再说明正半定情形有什么简化。

练习 26.3 解析

一般 $A \in \mathbb{R}^{m \times n}$ 的 SVD 为 $A = U\Sigma V^T$, 左右正交基通常来自不同空间, Σ 的对角元非负。对实对称矩阵 $A = Q\Lambda Q^T$, 写 $D = \text{diag}(d_i)$, 其中 $\lambda_i \neq 0$ 时 $d_i = \text{sign}(\lambda_i)$, 零特征值处取 $d_i = 1$ 。则

$$A = Q\Lambda Q^T = Q(D|\Lambda|)Q^T = (QD)|\Lambda|Q^T$$

是一组 SVD: QD 与 Q 正交, $|\Lambda|$ 的对角元为 $|\lambda_i|$ 。若 $A \geq 0$, 则 $\Lambda \geq 0$, 可直接取 $U = V = Q$, $\Sigma = \Lambda$ 。因此对称对角化保留特征值符号, 而 SVD 把符号吸收到奇异向量中。

练习 26.4. 证明任意非零秩 1 矩阵都可写成两个非零向量的外积, 并给出一个 2×2 的具体例子。说明这种外积表示为什么不是唯一的。

练习 26.4 解析

设非零矩阵 $A = [a_1, \dots, a_n]$ 的秩为 1, 选取一个非零列 u 。因为列空间是一维的, 存在 $c_j \in \mathbb{R}$ 使

$$a_j = c_j u \quad (j = 1, \dots, n), \quad v = (c_1, \dots, c_n)^T,$$

从而

$$A = [c_1 u, \dots, c_n u] = uv^T, \quad u \neq 0, v \neq 0.$$

例如

$$\begin{bmatrix} 2 & -1 \\ 4 & -2 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \begin{bmatrix} 2 & -1 \end{bmatrix}.$$

对任意 $c \neq 0$, 有

$$(cu)(v/c)^T = uv^T = A,$$

所以未施加单位范数与符号约定时外积因子不唯一。

练习 26.5. 查询 $q_1, \dots, q_4$ 与网页 $u_1, \dots, u_5$ 之间的点击权重为

$$C = \begin{bmatrix} 0 & 20 & 5 & 0 & 0 \\ 10 & 0 & 0 & 3 & 0 \\ 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 & 0 \end{bmatrix}.$$

求 C 的紧 SVD, 并解释左奇异向量、奇异值和右奇异向量在查询 – 网页二部图中的含义。

练习 26.5 解析

数值计算给出一组紧 SVD $C = U_r \Sigma_r V_r^T$:

$$\Sigma_r \approx \text{diag}(20.616958, 10.440307, 1, 0.970075),$$

$$U_r \approx \begin{bmatrix} 0.999930 & 0 & 0 & -0.011790 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0.011790 & 0 & 0 & 0.999930 \end{bmatrix},$$

$$V_r^T \approx \begin{bmatrix} 0 & 0.970008 & 0.243074 & 0 & 0 \\ 0.957826 & 0 & 0 & 0.287348 & 0 \\ 0 & 0 & 0 & 0 & 1 \\ 0 & -0.243074 & 0.970008 & 0 & 0 \end{bmatrix}.$$

将三因子相乘可恢复给定点击矩阵, 数值舍入造成的误差在显示精度范围内。 U_r 的列描述查询侧的潜在模式, V_r 的列描述网页侧的潜在模式, 奇异值衡量对应模式的强度: 首个模式主要连接 q_1 与 u_2, u_3 , 第二个模式主要连接 q_2 与 u_1, u_4 , 第三个模式对应 q_3 与 u_5 , 第四个较弱模式区分 q_4 与 q_1 在 u_3 上的点击。奇异向量整体符号以及重根子空间内的基选择不影响这些关系。

练习 26.6. 若 $A \in \mathbb{R}^{5 \times 3}$, 写出完整 SVD 中 U, Σ, V 的维数和奇异值的最大个数。

练习 26.6 解析

对 $A \in \mathbb{R}^{5 \times 3}$, 完整 SVD 的维数链为

$$A_{5 \times 3} = U_{5 \times 5} \Sigma_{5 \times 3} V_{3 \times 3}^T,$$

$$p = \min\{5, 3\} = 3, \quad \#\{j : \sigma_j > 0\} = \text{rank}(A) \leq 3.$$

因此共有 3 个按重数计的奇异值槽位, 正奇异值个数可能少于 3。

练习 26.7. 求 $A = \text{diag}(3, -2)$ 的一组 SVD, 并说明负号如何处理。

练习 26.7 解析

可取

$$U = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}, \quad \Sigma = \begin{bmatrix} 3 & 0 \\ 0 & 2 \end{bmatrix}, \quad V = I_2.$$

练习 26.7 解析 (续)

于是 $U\Sigma V^T = \text{diag}(3, -2)$ 。奇异值按定义非负，原矩阵的负号吸收到左或右奇异向量中。

练习 26.8. 已知 $A^T A$ 的特征值为 25, 9, 0, 求 A 的奇异值和秩。

练习 26.8 解析

若 $A^T A$ 的特征值为 25, 9, 0, 则

$$(\sigma_1, \sigma_2, \sigma_3) = (\sqrt{25}, \sqrt{9}, \sqrt{0}) = (5, 3, 0),$$

$$\text{rank}(A) = \#\{j : \sigma_j > 0\} = 2.$$

完整 U, V 可以再含零空间方向，但零奇异值不增加秩。

练习 26.9. 证明 $N(A^T A) = N(A)$ 。

练习 26.9 解析

正向蕴含为

$$x \in N(A) \implies Ax = 0 \implies A^T Ax = 0 \implies x \in N(A^T A).$$

反向若 $x \in N(A^T A)$, 则

$$0 = x^T A^T Ax = \|Ax\|_2^2 \implies Ax = 0 \implies x \in N(A).$$

故 $N(A) = N(A^T A)$ 。

练习 26.10. 若奇异值为 10, 4, 1, 0, 秩是多少? 取 $k = 2$ 时 A_k 的秩是多少, 是否等于 A ?

练习 26.10 解析

由三个正奇异值可得

$$r = \#\{j : \sigma_j > 0\} = 3, \quad A = \sum_{j=1}^3 \sigma_j u_j v_j^T.$$

取 $k = 2$ 时

$$A_2 = \sum_{j=1}^2 \sigma_j u_j v_j^T, \quad \text{rank}(A_2) = 2,$$

且 $\sigma_3 = 1 > 0$ 推出 $A - A_2 = \sigma_3 u_3 v_3^T \neq 0$ 。只有保留全部三个正奇异值才得到精确紧 SVD。

练习 26.11. 比较存储一个 1000×500 稠密矩阵与其 $k = 20$ 截断 SVD 所需标量数。

练习 26.11 解析

原矩阵存储量为

$$M_{\text{full}} = 1000 \times 500 = 500000.$$

练习 26.11 解析 (续)

秩 20 截断分解只存 U_{20} 、20 个奇异值和 V_{20} ：

$$M_{20} = 1000 \times 20 + 20 + 500 \times 20 = 30020,$$

$$\frac{M_{20}}{M_{\text{full}}} = \frac{30020}{500000} = 0.06004 = 6.004\%.$$

这只是标量数比较，实际还要计入存储格式和计算成本。

练习 26.12. 若 $\kappa_2(A) = 10^6$ ，显式形成 $A^T A$ 后在非零子空间上的条件数是多少量级？

练习 26.12 解析

设 A 满列秩且 $\kappa_2(A) = 10^6$ 。因为 $A^T A$ 的极值特征值为 $\sigma_{\max}^2, \sigma_{\min}^2$ ，所以

$$\kappa_2(A^T A) = \frac{\lambda_{\max}(A^T A)}{\lambda_{\min}(A^T A)} = \frac{\sigma_{\max}^2}{\sigma_{\min}^2} = \kappa_2(A)^2 = 10^{12}.$$

条件数平方会放大奇异方向的相对误差，因此数值实现通常避免显式形成法方程。

练习 26.13. 在算法中 A 为 800×300 ， $k = 10, s = 5$ 。写出 Q, Z, B 的维数。

练习 26.13 解析

令目标秩 $k = 10$ 、过采样 $s = 5$ ，则

$$\ell = k + s = 15, \quad A \in \mathbb{R}^{800 \times 300}, \quad \Omega \in \mathbb{R}^{300 \times 15}.$$

随机子空间各步维数为

$$Y = A\Omega \in \mathbb{R}^{800 \times 15}, \quad Q \in \mathbb{R}^{800 \times 15}, \quad B = Q^T A \in \mathbb{R}^{15 \times 300}.$$

若 $B = \tilde{U}\Sigma V^T$ ，则 $\tilde{U} \in \mathbb{R}^{15 \times 15}$ ，而 $Q\tilde{U}$ 恢复为 800 维左奇异向量。

练习 26.14. 矩阵奇异值为 6, 3, 2, 1。求 $\|A\|_F$ 和最佳秩 2 近似的 Frobenius 误差。

练习 26.14 解析

$$\|A\|_F = \sqrt{6^2 + 3^2 + 2^2 + 1^2} = \sqrt{50} = 5\sqrt{2}.$$

最佳秩 2 近似舍弃 2, 1，故

$$\|A - A_2\|_F = \sqrt{2^2 + 1^2} = \sqrt{5}, \quad \frac{\|A - A_2\|_F^2}{\|A\|_F^2} = \frac{5}{50} = 10\%.$$

所以该题的平方 Frobenius 损失是 10%，而相对 Frobenius 范数误差为 $\sqrt{5/50} = \sqrt{0.1} \approx 31.62\%$ ；二者不能共用“误差 10%”这一含混说法。

练习 26.15. 若 $\sigma_2 = \sigma_3 = 4$ 且取 $k = 2$, 解释为什么最佳误差唯一而最佳子空间可能不唯一。

练习 26.15 解析

最佳秩 2 误差由 Eckart-Young 公式给出:

$$\min_{\text{rank}(B) \leq 2} \|A - B\|_F^2 = \sum_{j>2} \sigma_j^2.$$

题设 $\sigma_2 = \sigma_3 = 4$ 使截断边界穿过重根子空间。若 $\sigma_1 > 4$, 第一奇异方向必须保留, 并在 $\sigma = 4$ 子空间中任选一维; 若 $\sigma_1 = 4$, 则至少前三个方向同属同一重根子空间, 可任选二维子空间。不同选择都满足

$$\|A - B\|_F^2 = \sum_{j>2} \sigma_j^2,$$

所以最优误差唯一, 而主子空间及近似矩阵一般不唯一。

练习 26.16. 若 A 的奇异值为 $5, 2, 0$, 描述单位球经 A 后的几何形状和像空间维数。

练习 26.16 解析

若奇异值为 $5, 2, 0$, 则对单位右奇异向量 v_j 有

$$Av_1 = 5u_1, \quad Av_2 = 2u_2, \quad Av_3 = 0.$$

因此单位球像是半轴长 $5, 2, 0$ 的退化椭球, 并且

$$\dim R(A) = \#\{j : \sigma_j > 0\} = 2 = \text{rank}(A).$$

练习 26.17. $A \in \mathbb{R}^{4 \times 6}$ 且 $r = 3$ 。写出四个基本子空间的维数。

练习 26.17 解析

对 $A \in \mathbb{R}^{4 \times 6}$ 且 $\text{rank}(A) = 3$, 秩 - 零化度给出

$$\dim R(A) = 3, \quad \dim N(A^T) = 4 - 3 = 1,$$

$$\dim R(A^T) = 3, \quad \dim N(A) = 6 - 3 = 3.$$

于是两组正交分解的维数分别满足 $3 + 1 = 4$ 与 $3 + 3 = 6$ 。

练习 26.18. 对例题矩阵取 $k = 1$, 计算保留能量比例 $\sum_{j \leq k} \sigma_j^2 / \sum_j \sigma_j^2$ 。

练习 26.18 解析

例题矩阵的奇异值为 $3, 1$ 。取 $k = 1$ 时

$$E_1 = \frac{\sum_{j \leq 1} \sigma_j^2}{\sum_j \sigma_j^2} = \frac{3^2}{3^2 + 1^2} = \frac{9}{10} = 90\%.$$

练习 26.18 解析 (续)

不能改用

$$\frac{\sigma_1}{\sigma_1 + \sigma_2} = \frac{3}{4} = 75\%,$$

因为 Frobenius 能量对应奇异值平方和。

本章结论与下一步

核心结论：左右奇异子空间、奇异值、紧分解与截断矩阵

关键依据：由 $A^T A$ 谱分解构造 SVD，再用投影能量和正交分解证明最佳低秩误差及取等条件

可执行自检：稳定算法避免机械形成 $A^T A$ ，同时检查重构、正交性、左右残差和子空间变化

适用边界：矩阵压缩、去噪、潜在表示或 PCA 前的低秩线性代数时

下一步：进入 PCA；谱隙只保证相应子空间/Frobenius 解的条件性唯一，不保证谱范数解唯一

1. **定义：**能否对长矩阵和宽矩阵分别写出完整、紧、截断 SVD 维数？未通过则回看第 1、3 节。
2. **证明：**能否从 $A^T A$ 谱分解三步构造 SVD 并处理零空间？未通过则回看第 1 节。
3. **性质：**能否推导谱关系、奇异向量方程与四个基本子空间？未通过则回看第 2、6 节。
4. **算法：**能否说明初始化、双边更新、残差、停止、谱隙与复杂度？未通过则回看第 4 节。
5. **最优性：**能否证明并应用两种范数下的截断误差公式？未通过则回看第 5 节；五项均可独立作答，并能完成每节至少两道练习，才算达到本章学习目标。

第 27 章 主成分分析

读前自检：本章地图：主成分分析。 主成分分析章地图以“从中心化数据直达方差最大化、重构与 SVD 实现”组织内容；请把路线拆成起点、关键工具和终点，并核对三者的输入输出类型能依次衔接。

读前自检：本章可检验学习目标。 主成分分析目标中的“能在中心化前提下严格定义总体主成分与样本主成分，并解释特征值、载荷与方差贡献率”必须可复核；请在中心化前提下严格定义总体主成分与样本主成分，并解释特征值、载荷与方差贡献率，所得结果仅在“中间结果逐项包含首目标“能在中心化前提下严格定义总体主成分与样本主成分，并解释特征值、载荷与方差贡献率”声明的对象、条件与结论”时通过。

读前自检：最短先修。 主成分分析的最短先修明确要求“本章使用向量内积与正交投影、对称矩阵谱分解、半正定矩阵、迹运算、Lagrange 乘子、协方差与相关系数”；请把首项“本章使用向量内积与正交投影、对称矩阵谱分解、半正定矩阵、迹运算、Lagrange 乘子、协方差与相关系数”中的第一个先修对象写成定义域 - 运算 - 输出三元组，并以“该三元组逐项满足首项“本章使用向量内积与正交投影、对称矩阵谱分解、半正定矩阵、迹运算、Lagrange 乘子、协方差与相关系数”的对象类型与成立条件”判断能否进入本章。

读前自检：先修自检。 主成分分析先修自检固定核验“能否证明实对称矩阵具有一组标准正交特征向量”；请证明实对称矩阵具有一组标准正交特征向量并写出中间结果，再按“中间结果直接回答首项“能否证明实对称矩阵具有一组标准正交特征向量”并给出通过或失败”明确判为通过或失败。

读前自检：依赖路线。 主成分分析依赖链含“中心化随机向量 → 协方差二次型 → 单位方向上的方差最大化”到“Rayleigh 商 → 特征值问题 → 依次正交的总体主成分”这一跳；请固定写出前者输出类型与后者输入类型，并核对两者相同或存在正文声明的转换。

本章地图

核心问题：怎样寻找保留最大变异且重构误差最小的正交子空间

可检验学习目标：

- 能在中心化前提下严格定义总体主成分与样本主成分，并解释特征值、载荷与方差贡献率；
- 能分三步推出方差最大化问题，证明前 q 个特征向量同时给出最小均方重构误差；
- 能写清协方差 PCA、相关系数 PCA 和基于 SVD 的 PCA 之间的尺寸关系与适用条件；
- 能给出含输入、输出、初始化、更新、停止和诊断的完整算法，并估计主要时间、空间成本；
- 能识别未中心化、量纲支配、符号不唯一、重复特征值和数据泄漏等常见问题。

最短先修：本章使用向量内积与正交投影、对称矩阵谱分解、半正定矩阵、迹运算、Lagrange 乘子、协方差与相关系数，以及紧致奇异值分解。需要特别区分三个对象：随机向量的总体协方差、有限样本的样本协方差、以及中心化数据矩阵。三者尺寸相关但并不相同。

沿用全书行样本主约定，原始矩阵记为 $X_{\text{row}} \in \mathbb{R}^{n \times m}$ 。为复用“左奇异向量就是变量主轴”的传统 PCA 公式，本章只在公式局部定义显式转置桥

$$X_{\text{c,row}} = X_{\text{row}} - \mathbf{1}_n \bar{x}^T \in \mathbb{R}^{n \times m}, \quad X_{\text{c}} = X_{\text{c,col}} = X_{\text{c,row}}^T \in \mathbb{R}^{m \times n}.$$

此后出现 X_{c} 都指右侧的列样本工作矩阵；输入和数据切分仍以 X_{row} 为准。

依赖路线：中心化随机向量 $\rightarrow$ 协方差二次型 $\rightarrow$ 单位方向上的方差最大化；Rayleigh 商 $\rightarrow$ 特征值问题 $\rightarrow$ 依次正交的总主成分；投影矩阵 $\rightarrow$ 保留方差与残差方差分解 $\rightarrow$ 最小重构误差；样本中心化矩阵 $\rightarrow$ 样本协方差 $\rightarrow$ 特征分解或 SVD 实现；特征值谱 $\rightarrow$ 维数选择、稳定性诊断与解释边界。

完成标准与返回：中心化或 $n \geq 2$ 条件失败时回到节 27.1、27.3；载荷或重构不清时回看节 27.2、27.4

数据方向桥：PCA 输入与工作矩阵

数据切分和预处理始终使用行样本输入 $X_{\text{row}} \in \mathbb{R}^{n \times m}$ 。中心化后，为让左奇异向量直接表示变量主轴，本章定义

$$X_{\text{c}} = X_{\text{c,row}}^T \in \mathbb{R}^{m \times n}.$$

例如 $n = 4, m = 2$ 时，输入与工作矩阵分别为 4×2 和 2×4 。凡出现 $X_{\text{c}} X_{\text{c}}^T$ ，结果都是 $m \times m$ 变量协方差尺度；不得漏掉这次显式转置。

本章符号表

符号	取值或维数	含义
$x, \mu, z = x - \mu$	$\mathbb{R}^m$	随机向量、总体均值与中心化随机向量
Σ	$\mathbb{R}^{m \times m}, \Sigma \geq 0$	总体协方差矩阵 $E(z z^T)$
α_i, λ_i	$\mathbb{R}^m, \mathbb{R}_{\geq 0}$	第 i 个标准正交方向及其方差
y_i	$\mathbb{R}$	总体主成分 $\alpha_i^T z$
$A = [\alpha_1, \dots, \alpha_m]$	$\mathbb{R}^{m \times m}$	正交主轴矩阵, $A^T A = I$
$B = [\alpha_1, \dots, \alpha_q]$	$\mathbb{R}^{m \times q}$	前 q 个主轴, $B^T B = I_q$
$X_{\text{c,row}}, X_{\text{c}}$	$\mathbb{R}^{n \times m}, \mathbb{R}^{m \times n}$	行样本中心化矩阵及 $X_{\text{c}} = X_{\text{c,row}}^T$
S	$\mathbb{R}^{m \times m}$	样本协方差 $X_{\text{c}} X_{\text{c}}^T / (n - 1)$
R	$\mathbb{R}^{m \times m}$	标准化变量的样本相关系数矩阵
U, Γ, V	正交因子与非负对角矩阵	$X_{\text{c}} = U \Gamma V^T$ 的紧致 SVD
η_i	$[0, 1]$	第 i 主成分方差贡献率

27.1 总体主成分

当 m 个变量彼此相关时，逐变量观察既重复又难以形成整体结构。主成分分析寻找一组互相正交的线性组合，使第一组合具有最大方差，第二组合在与第一组合不相关的条件下具有最大方差，依次进行。它是坐标系的旋转与有序截断，不是对单个原变量的筛选。

读前自检：主成分分析。 PCA 对中心化观测 $z = x - \mu$ 取线性坐标 $y = \alpha^T z$ ；请核对 $z, \alpha \in \mathbb{R}^m$ 时 y 为标量，并计算 $\text{var}(y) = \alpha^T \Sigma \alpha$ 。

主成分分析把高维观测映射到少数线性坐标。排序依据是投影方差；若保留的方向解释了大部分总方差，就可用低维得分近似原数据。中心化是定义中的必要步骤，因为方差只描述围绕均值的变化。

设 $z = x - \mu$, $Ez = 0$, $\text{cov}(z) = \Sigma$ 。对任意单位向量 α ，投影 $y = \alpha^T z$ 的方差为

$$\text{var}(y) = E(\alpha^T z z^T \alpha) = \alpha^T \Sigma \alpha.$$

因此总体 PCA 只由 Σ 决定；平移 x 不会改变主轴，但若不做中心化，原点位置会错误地进入二阶矩。

读前自检：基本想法。 PCA 基本想法令 $A = [\alpha_1, \dots, \alpha_m]$ 正交并取 $y = A^T z$ ；请计算 $\text{cov}(y) = A^T \Sigma A$ ，核对选取协方差特征向量后该矩阵按降序对角化。

选择标准正交基 $A = [\alpha_1, \dots, \alpha_m]$ 并令 $y = A^T z$ 。由于 A 正交，变换不改变欧氏长度；它只旋转坐标。PCA 进一步要求 $\text{cov}(y) = A^T \Sigma A$ 为对角矩阵，并按对角元从大到小排列。

读前自检：定义和导出。 第一主轴解 $\max_{\alpha^T \alpha = 1} \alpha^T \Sigma \alpha$ ；请写 Lagrange 驻点方程 $\Sigma \alpha = \lambda \alpha$ ，核对后续主轴还需与已选方向正交。

第一主轴解决

$$\max_{\alpha \in \mathbb{R}^m} \alpha^T \Sigma \alpha \quad \text{s.t.} \quad \alpha^T \alpha = 1.$$

后续主轴增加 $\alpha^T \alpha_j = 0$ 的约束。对称矩阵的正交谱分解保证这些约束可同时满足。

读前自检：总体主成分定义。 总体主成分由 Σ 的标准正交特征向量定义为 $y_i = \alpha_i^T (x - \mu)$ ；请核对 $\text{var}(y_i) = \lambda_i$ ，并说明重复特征值时唯一的是特征子空间而非单根主轴。

读前自检：总体主成分。 总体主成分按 $\lambda_1 \geq \dots \geq \lambda_m$ 排序；请把 $y_i = \alpha_i^T (x - \mu)$ 代入协方差，核对不同 i, j 时结果为 0 且每个得分为标量。

定义 27.1 (总体主成分). 设 Σ 的特征值按 $\lambda_1 \geq \dots \geq \lambda_m \geq 0$ 排列，相应标准正交特征向量为 $\alpha_1, \dots, \alpha_m$ 。随机变量

$$y_i = \alpha_i^T (x - \mu), \quad i = 1, \dots, m,$$

称为第 i 个总体主成分。若特征值互异，则每个方向除整体符号外唯一；若有重复特征值，则对应特征子空间唯一而其中的基不唯一。

模型。 总体 PCA 可写成 $z = Ay$ ，其中 A 正交且 $\text{cov}(y) = \text{diag}(\lambda_1, \dots, \lambda_m)$ 。保留前 q 维时，近似模型为 $z \approx By_{1:q}$ ，再加回 μ 得到 x 的重构。

学习策略。 总体层面从 Σ 的谱结构选择方向；有限样本中以 S 或 R 估计该结构。维数 q 必须在训练数据上用预先规定的贡献率、验证误差或下游任务准则选择，不能看测试集后再决定。

读前自检：协方差矩阵特征对刻画总体主成分。 协方差特征对刻画 PCA 要求 $\Sigma = \Sigma^T \geq 0$ 和单位方向；请对 Rayleigh 商做一次受约束求导，核对最大方差等于 λ_1 ，正交子空间中的下一最大值为 λ_2 。

27.2 协方差矩阵与方差最大化

阅读目标：用 Rayleigh 商逐个得到最大方差方向及正交后续方向。

对象：对称半正定协方差矩阵 Σ 与单位方向 α 。

合法条件： $\alpha^T \alpha = 1$ ；后续方向还需与已选方向正交。

第一步：先极大化 $\alpha^T \Sigma \alpha$ ，并为单位范数约束写拉格朗日函数。

推导目标

从单位方向的方差出发，依次推出第一主成分、后续主成分与协方差特征对的关系。

推导准备

设 $\Sigma = \Sigma^T \geq 0$ ，并按降序记其特征值。使用约束 $\alpha^T \alpha = 1$ 排除任意缩放，否则二次型可随 $\|\alpha\|$ 无限增大。

推导第 1 步：构造约束目标。 第一投影方差为 $\alpha^T \Sigma \alpha$ ，Lagrange 函数取

$$\mathcal{L}(\alpha, \lambda) = \alpha^T \Sigma \alpha - \lambda(\alpha^T \alpha - 1).$$

推导第 2 步：求驻点并识别目标值。 对 α 求导得

$$2\Sigma\alpha - 2\lambda\alpha = 0, \quad \text{即} \quad \Sigma\alpha = \lambda\alpha.$$

左乘 α^T 并用单位约束，得到驻点方差等于 λ 。**推导第 3 步：排序并施加正交约束。** Rayleigh 商最大值是 λ_1 。在 $\alpha \perp \alpha_1, \dots, \alpha_{k-1}$ 的子空间中重复同一论证，最大值为 λ_k ，方向可取 α_k 。

定理 27.1 (协方差特征对与主成分) 设 Σ 为总体协方差矩阵。按降序排列的标准正交特征向量 α_i 给出总体主成分 $y_i = \alpha_i^T z$ ，且

$$\text{var}(y_i) = \lambda_i, \quad \text{cov}(y_i, y_j) = 0 \quad (i \neq j).$$

反之，依次解方差最大化与不相关约束得到的方向可选为这些特征向量。

读前自检：证明：协方差特征对与主成分。 协方差特征对证明使用 $\Sigma\alpha_j = \lambda_j\alpha_j$ 与 $\alpha_i^T \alpha_j = 0$ ；请展开 $\text{cov}(y_i, y_j)$ ，核对 $i \neq j$ 时为 0、 $i = j$ 时为 λ_i 。

证明。 特征方程给出 $\text{var}(y_i) = \alpha_i^T \Sigma \alpha_i = \lambda_i$ 。当 $i \neq j$ 时， $\text{cov}(y_i, y_j) = \alpha_i^T \Sigma \alpha_j = \lambda_j \alpha_i^T \alpha_j = 0$ 。反向结论由上述三步推导和对称矩阵的 Rayleigh–Ritz 定理得到。若有重复特征值，结论理解为选择对应特征子空间中的任一标准正交基。 $\square$

读前自检：总体主成分的主要性质。 总体主成分满足 $\text{Cov}(y_j, y_k) = 0 (j \neq k)$ 且总方差为 $\sum_i \lambda_i = \text{tr}(\Sigma)$ ；请把 α_{jk} 代入 $\rho(x_j, y_k) = \sqrt{\lambda_k} \alpha_{jk} / \sqrt{\Sigma_{jj}}$ ，并核对 $\Sigma_{jj} = 0$ 或 $\lambda_k = 0$ 时该载荷应记为未定义。

所有主成分两两不相关，总方差为 $\sum_i \lambda_i = \text{tr}(\Sigma)$ ；主轴的符号可任意翻转；原变量 x_j 与主成分 y_k 的相关系数为

$$\rho(x_j, y_k) = \frac{\sqrt{\lambda_k} \alpha_{jk}}{\sqrt{\Sigma_{jj}}},$$

这里 α_{jk} 是 α_k 的第 j 个分量。该式只在 $\Sigma_{jj} > 0$ 且 $\lambda_k > 0$ 时定义；零方差变量或零方差主成分与相关系数的分母不相容，此时载荷记为“未定义”，不能擅自填成 0。该相关系数常称因子载荷，不能与特征向量分量本身混为一谈。

读前自检：主成分个数。 若 $\text{rank}(\Sigma) = r$ ，协方差矩阵恰有 r 个正特征值；请把主成分方差逐项写为 λ_i ，核对只有前 r 个主成分非退化，选择 q 时不得超过有效秩。

若 $\text{rank}(\Sigma) = r$ ，只有 r 个特征值为正，因而至多有 r 个非退化主成分。选择 q 时常令累计贡献率达到阈值，但阈值不是普适定律；特征值间隙、重构目标和下游性能也应共同考虑。

变量量纲差异很大且活动变量满足 $\Sigma_{jj} > 0$ 时，令 $x_j^* = (x_j - \mu_j) / \sqrt{\Sigma_{jj}}$ ，再对相关矩阵 $R_{\text{pop}} = \text{cov}(x^*)$ 做 PCA。零方差变量不能执行该除法，必须由预处理契约明确保留为零行或删除并保存映射。相关 PCA 使每个活动变量的方差都为 1，但也会放大原本方差很小、测量噪声却很大的变量；是否标准化应由数据含义决定。

读前自检：前 q 个主成分具有最大方差。 对任意 $B \in \mathbb{R}^{m \times q}$ 且 $B^T B = I_q$ ，保留方差为 $\text{tr}(B^T \Sigma B)$ ；请代入前 q 个特征向量，核对达到上界 $\sum_{i=1}^q \lambda_i$ 。

定理 27.2 (前 q 维最大保留方差) 对任意 $B \in \mathbb{R}^{m \times q}$ 且 $B^T B = I_q$ ，有

$$\text{tr}(B^T \Sigma B) \leq \sum_{i=1}^q \lambda_i.$$

令 $\tau = \lambda_q$ ，并记

$$E_{>} = \bigoplus_{\lambda_i > \tau} \ker(\Sigma - \lambda_i I), \quad E_{=} = \ker(\Sigma - \tau I).$$

等号成立当且仅当 $E_{>} \subseteq \text{col}(B) \subseteq E_{>} \oplus E_{=}$ 且 $\dim \text{col}(B) = q$ 。也就是说，最优子空间必须包含所有严格大于截断值的特征方向，并从边界重根空间中任取所需维数；只有 $\lambda_q > \lambda_{q+1}$ 时，领先 q 维不变子空间才唯一（其正交基仍可旋转）。

证明：前 q 维最大保留方差：证明阅读检查

动手检查。 待证结论与所需条件分别是什么？请在最小维度或最小样本上写出第一处关键变形，并指出少一个条件时证明会在哪一步中断。

1. 先写清对象类型、目标结论与符号作用域。
2. 逐项核对定义域、维数、支持集、量词与交换运算所需条件。

3. 写出第一处可执行的数学动作, 不用“显然”跳过入口。
4. 沿现有编号完成中间关系, 并单独核对归一化、边界或等号条件。
5. 回到待证结论, 再说明它与后续公式、算法、图或例题的连接。

继续核对。 完成上面的最小任务后, 再对照主体逐项核对定义域、更新式或关键变形、停止条件以及返回值; 阅读检查不代替正文中的数学论证。

证明. 写 $\Sigma = A\Lambda A^T$ 并令 $C = A^T B$, 则 $C^T C = I_q$ 。记 $h_i = \sum_{j=1}^q c_{ij}^2$, 有 $0 \leq h_i \leq 1$ 且 $\sum_i h_i = q$ 。于是 $\text{tr}(B^T \Sigma B) = \sum_i \lambda_i h_i$ 。在这些约束下, 把权重放在最大的 q 个 λ_i 上取得最大值 $\sum_{i=1}^q \lambda_i$ 。若等号成立, 则 $\lambda_i > \tau$ 处必须有 $h_i = 1$, $\lambda_i < \tau$ 处必须有 $h_i = 0$, 剩余权重只能位于 $E_{\pm}$; 这恰好等价于定理中的夹含条件。反之, 满足该夹含条件的 q 维子空间显然取得同一迹值。 $\square$

读前自检: 舍弃主成分具有最小信息损失。 PCA 用前 q 个主轴重构时, 总体均方残差为 $\sum_{i=q+1}^m \lambda_i$; 请从总方差减去保留方差, 核对该残差在所有 q 维正交投影中最小。

若用投影重构衡量信息损失, 则保留前 q 维后的总体均方残差是 $\sum_{i=q+1}^m \lambda_i$ 。因此“方差最大”与“平方重构误差最小”不是两条无关经验, 而是同一正交投影问题的互补目标。

读前自检: 方差贡献率。 方差贡献率中的 “ $\eta_k = \frac{\lambda_k}{\sum_{i=1}^m \lambda_i}$, $\eta_{1:q} = \frac{\sum_{k=1}^q \lambda_k}{\sum_{i=1}^m \lambda_i}$.” 决定可执行范围; 请把 η_k 展开一次并检查其类型或边界, 结果须满足展开后的量满足定义中的域、维数或符号限制。

第 k 主成分的方差贡献率及前 q 维累计贡献率定义为

$$\eta_k = \frac{\lambda_k}{\sum_{i=1}^m \lambda_i}, \quad \eta_{1:q} = \frac{\sum_{k=1}^q \lambda_k}{\sum_{i=1}^m \lambda_i}.$$

只有在总方差大于零时这些比率才有定义。

对标准化变量, 前 q 个主成分对第 j 个原变量的累计解释量为

$$v_j^{(q)} = \sum_{k=1}^q \rho^2(x_j^*, y_k) = \sum_{k=1}^q \lambda_k \alpha_{jk}^2,$$

其范围为 $[0, 1]$ 。它回答“某个原变量被保留子空间解释多少”, 不同于全局累计方差贡献率。

几何理解

几何解释。 协方差椭圆的主轴就是 Σ 的特征向量, 半轴长度与 $\sqrt{\lambda_i}$ 成正比。PCA 把坐标轴旋转到椭圆主轴, 再保留最长的 q 根轴。若最大特征值重复, 椭圆在相应子空间内具有旋转对称性, 所以单根轴无法由数据唯一确定。

概率解释

PCA 只使用二阶矩，不要求数据服从高斯分布。若 $\mathbf{z}$ 恰为高斯向量，则主成分不相关进一步推出相互独立；对一般分布，不相关不代表独立。因此 PCA 消除的是线性二阶相关，而不是所有统计依赖。

优化解释

优化解释。单方向目标是 Rayleigh 商；多方向目标是 Stiefel 约束 $B^T B = I_q$ 上的迹最大化。最优值由谱决定，但当 $\lambda_q = \lambda_{q+1}$ 时，截断边界穿过重复特征子空间，最优基和部分最优子空间均可能不唯一。

如图 27.1 所示，二维 PCA 保留协方差椭圆的最长主轴，并把与该轴正交的剩余变化计入重构误差。




图 27.1 二维协方差椭圆与主轴示意

读前自检：样本主成分分析。 样本 PCA 先用 $\bar{x}$ 中心化 $x_1, \dots, x_n \in \mathbb{R}^m$ ，再形成 $S = (n-1)^{-1} \sum_i (x_i - \bar{x})(x_i - \bar{x})^T$ ；请核对 S 为 $m \times m$ 对称半正定矩阵。

27.3 样本主成分

给定样本 $x_1, \dots, x_n \in \mathbb{R}^m$ ，令 $\bar{x} = n^{-1} \sum_{j=1}^n x_j$ 。主数据矩阵按行写为 $X_{c, \text{row}} = [(x_1 - \bar{x})^T; \dots; (x_n - \bar{x})^T]$ ；公式工作矩阵为 $X_c = X_{c, \text{row}}^T = [x_1 - \bar{x}, \dots, x_n - \bar{x}]$ 。无偏样本协方差与高斯极大似然协方差分别为

$$S_{\text{unb}} = \frac{1}{n-1} X_c X_c^T, \quad S_{\text{ML}} = \frac{1}{n} X_c X_c^T = \frac{n-1}{n} S_{\text{unb}}.$$

本章以下约定 $S := S_{\text{unb}}$ 。两种分母给出完全相同的特征向量、主成分得分方向和方差排序； S_{ML} 的全部特征值仅统一乘以 $(n-1)/n$ 。因此子空间选择不变，但报告绝对方差、重构误差或似然时必须声明所用分母。

读前自检：样本主成分的定义和性质。 样本按列排列时 $X_c \in \mathbb{R}^{m \times n}$ ，按行排列时 $X_{c, \text{row}} = X_c^T$ ；请分别写出协方差乘积，核对两种约定都得到 $m \times m$ 矩阵。

定义 27.2 (样本主成分). 设 $Sa_i = \hat{\lambda}_i a_i$, $a_i^T a_j = \delta_{ij}$, 且 $\hat{\lambda}_1 \geq \dots \geq 0$. 第 i 个样本主成分得分向量为

$$s_i = a_i^T X_c \in \mathbb{R}^{1 \times n}.$$

它在样本间的无偏方差为 $\hat{\lambda}_i$ ，不同得分向量的样本协方差为零。

贯穿例：文档—词项矩阵小例

本章角色：先把特殊词—文档矩阵显式转置为行样本文档矩阵，再中心化并进入样本 PCA。词项为行、文档为列的特殊矩阵精确沿用

$$X = \begin{bmatrix} 2 & 0 & 1 \\ 1 & 2 & 0 \\ 0 & 1 & 3 \end{bmatrix},$$

而行样本主对象是 $X_{\text{doc, row}} = X^T \in \mathbb{R}^{3 \times 3}$ 。为使用下述变量主轴公式，再令 $X_c = X_{c, \text{row}}^T$ ，故数值上仍可按 X 的三列求均值。其列和为 3, 3, 4、总计数为 10；把三列视为 $\mathbb{R}^3$ 中的样本时，必须先按行计算

$$\bar{x} = (1, 1, 4/3)^T, \quad X_c = X - \bar{x} \mathbf{1}_3^T = \begin{bmatrix} 1 & -1 & 0 \\ 0 & 1 & -1 \\ -4/3 & -1/3 & 5/3 \end{bmatrix}.$$

三列均有限且样本数 $n = 3 \geq 2$ ，所以样本协方差有定义；PCA 分析的是 X_c 而不是上一站直接分解的原矩阵。上一站见 [SVD 对原始实矩阵的分解](#)；下一站见 [NMF 对原始非负计数的加性分解](#)。

若各变量单位不可比，对满足 $\hat{\sigma}_j$ 大于尺度容差的活动变量，用仅由训练集估计的标准差构造 $Z_{je} = (X_{je} - \bar{x}_j)/\hat{\sigma}_j$ ，再分解 $R = ZZ^T/(n-1)$ ；零方差行按本章算法固定为零并保存掩码，不执行除法。验证集和测试集必须沿用训练均值、训练尺度与同一掩码，不能各自重新标准化。

计算路线。当 m 较小，可显式形成 S 再求前 q 个特征对；当 m 远大于 n 时，直接对 X_c 做薄 SVD 通常更节省时间与存储，并避免形成条件数平方化的 $X_c X_c^T$ 。

读前自检：样本主成分的方差最大化刻画。 样本 PCA 算法依次中心化、求谱、按特征值降序取 q 维并计算得分；请对 S 的首个单位特征向量求 X_c 的投影，核对得分维数与所用列/行样本约定一致。

样本算法的核心顺序是：中心化或标准化、求谱、按特征值排序、选择 q 、计算得分并保存重构所需的均值和主轴。输出不只是低维坐标，还应包含预处理参数、特征值谱和诊断信息。

小型数值例子。取三个二维样本 $(2, 0)^T, (0, 2)^T, (-2, -2)^T$ ，均值为零，

$$S = \frac{1}{2} \begin{bmatrix} 8 & 4 \\ 4 & 8 \end{bmatrix} = \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix}.$$

特征值为 6, 2，第一主轴可取 $(1, 1)^T/\sqrt{2}$ ，其三个得分为 $\sqrt{2}, \sqrt{2}, -2\sqrt{2}$ ，样本均值为零且无偏方差为 6。

27.4 重构误差最小化

设 $B^T B = I_q$ 。中心化向量 z 在子空间 $\text{col}(B)$ 上的正交投影为 $BB^T z$ ，加回均值后重构为 $\hat{x} = \mu + BB^T(x - \mu)$ 。

读前自检：中心化 – 编码 – 重构三行桥接。 中心化 – 编码 – 重构链令 $B \in \mathbb{R}^{m \times q}$ 且 $B^T B = I_q$ ；请依次计算 $z = x - \mu$ 、 $y = B^T z$ 和 $\hat{x} = \mu + By$ ，核对维数为 m, q, m 。

中心化 – 编码 – 重构三行桥接

对 $1 \leq q \leq m$ 及 $B \in \mathbb{R}^{m \times q}$ 、 $B^T B = I_q$ ，三个对象与映射方向为

$$\begin{aligned} \text{中心化: } z &= x - \mu \in \mathbb{R}^m, \\ \text{编码: } y &= B^T z \in \mathbb{R}^q, \\ \text{重构: } \hat{z} &= By = BB^T z \in \mathbb{R}^m. \end{aligned}$$

回到原坐标时 $\hat{x} = \mu + \hat{z} \in \mathbb{R}^m$ 。

阅读目标：把平方重构误差化成“总方差减投影方差”。

对象：中心化随机向量 z 、协方差 Σ 与秩 q 正交投影 $P = BB^T$ 。

合法条件： $B^T B = I_q$ ，故 $P = P^T = P^2$ 。

第一步：先展开 $\|z - Pz\|_2^2 = z^T(I - P)z$ 。

推导目标

把前 q 维 PCA 的平方重构误差化为“总方差减保留方差”，从而与方差最大化目标建立严格等价关系。

推导准备

令 $P = BB^T$ ，其中 $B^T B = I_q$ ，则 $P = P^T = P^2$ 是秩 q 正交投影；并使用恒等式 $E(z^T M z) = \text{tr}(M \Sigma)$ 。

推导第 1 步：展开平方残差。 由于 $P = BB^T$ 满足 $P = P^T = P^2$ ，

$$\|z - Pz\|_2^2 = z^T(I - P)z.$$

推导第 2 步：取期望并化为迹。

$$\mathbb{E}\|z - Pz\|_2^2 = \text{tr}((I - P)\Sigma) = \text{tr}(\Sigma) - \text{tr}(B^T \Sigma B).$$

推导第 3 步：转为最大保留方差。 第一项与 B 无关，所以最小残差等价于最大化 $\text{tr}(B^T \Sigma B)$ 。由定理 27.2，最优 B 由前 q 个特征向量组成，最小值为 $\sum_{i=q+1}^m \lambda_i$ 。

读前自检：样本最优低维重构。 样本最优低维重构以“对中心化样本矩阵 X_c ，在所有秩不超过 q 的正交投影重构 $BB^T X_c$ 中”为约束；请独立化简 $\min_{B^T B = I_q} \|X_c - BB^T X_c\|_F^2$ 的两端，并确认两端运算均有定义、类型一致且化为同一结果。

推论 27.1 (样本最优低维重构) 对中心化样本矩阵 X_c ，在所有秩不超过 q 的正交投影重构 $BB^T X_c$ 中，前 q 个左奇异向量给出最小 Frobenius 误差，且

$$\min_{B^T B = I_q} \|X_c - BB^T X_c\|_F^2 = \sum_{i=q+1}^r \gamma_i^2,$$

其中 γ_i 为 X_c 的奇异值。

读前自检：证明：样本最优低维重构。 先锁定样本最优低维重构的条件“把 Σ 换为 $X_c X_c^T$ 重复总体推导”：把 $X_c X_c^T$ 用到的关键定义展开并完成下一步变形，所得结果应满足变形没有增加前提且得到证明所述结论。

证明。 把 Σ 换为 $X_c X_c^T$ 重复总体推导。其特征值是 γ_i^2 ，迹目标等于保留的奇异值平方和，故残差为尾部奇异值平方和。□

读前自检：数据矩阵的奇异值分解算法。 PCA 的截断 SVD 路线对中心化矩阵 X_c 取前 q 个左奇异向量 U_q ；请计算得分 $Y_q = U_q^T X_c$ 与重构 $U_q Y_q$ ，核对形状分别为 $q \times n$ 和 $m \times n$ 。

27.5 PCA 与 SVD 的联系

令 $X_c = UTV^T$ 为秩 r 的紧致 SVD，其中 $U \in \mathbb{R}^{m \times r}$ 、 $V \in \mathbb{R}^{n \times r}$ ， $\Gamma = \text{diag}(\gamma_1, \dots, \gamma_r)$ 。则

$$S = \frac{1}{n-1} X_c X_c^T = U \frac{\Gamma^2}{n-1} U^T.$$

所以样本主轴是 U 的列，样本特征值为 $\hat{\lambda}_i = \gamma_i^2 / (n-1)$ ，前 q 维得分矩阵为

$$Y_q = U_q^T X_c = \Gamma_q V_q^T \in \mathbb{R}^{q \times n}.$$

这三个尺寸等式是实现中最重要的自检。

当只需前 q 维时，可用截断 SVD 而不形成完整矩阵。若 $m \gg n$ ，计算右 Gram 矩阵 $X_c^T X_c$ 也可得到右奇异向量，再用 $u_i = X_c v_i / \gamma_i$ 恢复非零左奇异向量；极小奇异值处不应使用该除法。

读前自检：相关矩阵的特征值分解算法。 相关矩阵 PCA 要求 $n \geq 2$ 、活动变量尺度非零且 $1 \leq q \leq \min(m, n-1)$ ；请标准化一个变量并形成相关矩阵，核对其对角元为 1；零尺度变量须按预处理规则保留或删除。

27.6 主成分算法、例题与练习

算法所需量与计算结果。 计算需要有限训练矩阵 $X \in \mathbb{R}^{m \times n}$ 、预处理方式、目标维数或选择规则以及数值容差。完成后得到训练均值与尺度、零方差变量集合、前 q 个主轴、特征值、得分、累计贡献率、重构公式和数值诊断。

参数含义。 q 控制表示维数，必须满足 $1 \leq q \leq \min(m, n-1)$ 且不超过处理后数据的有效秩；贡献率阈值只是一种选择 q 的规则；标准化开关决定使用 S 还是 R ；容差用于识别数值零奇异值。此处采用确定性薄 SVD，不含随机种子或幂迭代次数。

初始化。 先检查 $m \geq 1, n \geq 2$ 、所有元素有限、选择规则合法；计算训练均值，并令尺度 $s = \mathbf{1}_m$ 、零方差变量集合 $Z_0 = \emptyset$ 。确定性薄 SVD 无需随机初值。本算法采用“保留原维数”策略：标准化时只用训练矩阵估计尺度；若某行标准差不超过容差，则把其中心化训练行置零、保持 $s_j = 1$ 并把 j 加入 Z_0 ，从而不执行除零。

计算顺序。 本过程不设外层训练循环，依次完成行样本数据检查、中心化、可选标准化、显式转置 $X_c = X_{c, \text{row}}^T$ 、薄 SVD、特征值换算、选择 q 、截断和诊断；后一步只使用此前已得到的对象。新增样本的在线 PCA 属于另一算法，必须同时更新均值和协方差。

判断与停止条件。 输入不合法、标准化后无有效变量、总方差为零或所选 q 超过有效秩时异常停止并返回诊断；否则在薄 SVD、谱排序、截断和全部数值检查完成后正常停止。容差只用于判断数值秩、正交残差与重构残差，不等同于数学收敛阈值。

正确性依据。 由 $X_c = UTV^T$ 可得 $S = U\Gamma^2U^T/(n-1)$ ，所以 U_q 正是样本协方差前 q 个特征向量， $Y_q = \Gamma_q V_q^T$ 是得分；前 q 维最大方差定理与样本最优低维重构推论给出目标正确性。该过程调用一次有限薄 SVD，不讨论外层迭代收敛；数值正确性由正交残差、谱残差和重构残差检验。

异常与退化情形。 非有限输入、 $n < 2$ 、总方差为零或非法 q 都会使计算条件不成立；单个尺度不超过容差时按既定零行规则保留维数并说明，若全部变量均进入 Z_0 则等价于总方差为零。重复特征值使单根主轴不唯一，但对应子空间与重构仍可验证；若底层 SVD 数值失败，不能给出未经诊断的主轴。PCA 不适用于以非线性流形、鲁棒损失、缺失加权或监督判别为主要目标的任务。

读前自检：中心化样本的主成分分析：执行契约。 中心化样本 PCA 以有限训练矩阵、预处理规则和 q 或贡献率阈值为输入；请先提交均值/尺度，再完成一轮谱分解与主轴筛选，核对主轴正交、重构维数闭合并按残差或预算状态停止。

中心化样本的主成分分析：五步阅读

输入。 写出数据对象、固定参数与必须成立的条件。

初始化。 标明主状态、计数器和第一个合法状态。

核心更新。 只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。 写出能直接核验的停止证书；预算耗尽不等同于收敛。

算法 27.1: 中心化样本的主成分分析

- 输入:** 有限行样本训练矩阵 $X_{\text{row}} \in \mathbb{R}^{n \times m}$; 选择规则; 是否按变量标准化; 数值容差
- 输出:** 最后合法预处理/PCA 模型; $p_{\text{done}}, s_{\text{done}}$; **status** 与最终诊断
- 1 置 $p_{\text{done}} \leftarrow 0, s_{\text{done}} \leftarrow 0$; 若 $m < 1, n < 2$ 、输入非有限或选择/标准化/容差规则非法, 则返回 1、计数 0、**invalid_input** 及字段诊断
 - 2 计算 $\bar{x} = n^{-1} X_{\text{row}}^T \mathbf{1}_n$ 与 $X_{c, \text{row}} = X_{\text{row}} - \mathbf{1}_n \bar{x}^T$; 令 $s \leftarrow \mathbf{1}_m, Z_0 \leftarrow \emptyset$ 并在有限性核验后令 $p_{\text{done}} \leftarrow 1$
 - 3 若选择标准化 则
 - 4 对 $X_{c, \text{row}}$ 每列计算训练标准差 $\hat{\sigma}_j$; 若 $\hat{\sigma}_j$ 大于尺度容差, 则令 $s_j \leftarrow \hat{\sigma}_j$ 并以 s_j 缩放该列
 - 5 否则令 $s_j \leftarrow 1$ 、把 $X_{c, \text{row}}$ 该列置零并把 j 加入 Z_0 , 记录“零方差变量保留为零列”
 - 6 结束
 - 7 若处理结果非有限或全部为零, 则返回最后合法均值/尺度、**numerical_failure** 及“标准化或总方差”诊断; 否则令 $X_c = X_{c, \text{row}}^T$, 原子提交两种方向的处理矩阵并令 $p_{\text{done}} \leftarrow 2$
 - 8 对 X_c 求一次薄 SVD 并令 $s_{\text{done}} \leftarrow 1$; 若求解失败或谱对象非有限, 则返回最后合法预处理状态、**numerical_failure** 及 SVD 诊断; 否则令 $p_{\text{done}} \leftarrow 3$
 - 9 计算 $\hat{\lambda}_i = \gamma_i^2 / (n - 1)$ 并按训练规则选 q ; 若未满足 $\hat{\lambda}_1 \geq \hat{\lambda}_2 \geq \dots \geq 0$, 或 q 超过有效秩, 则返回预处理与完整谱、**numerical_failure** 及谱选择诊断; 否则令 $p_{\text{done}} \leftarrow 4$
 - 10 形成 U_q, Y_q 并核对正交、得分均值、谱与重构残差; 失败则不提交 PCA 模型并返回最后合法预处理状态、**numerical_failure** 及模型验收诊断
 - 11 原子提交 $\bar{x}, s, Z_0, U_q, \hat{\lambda}_{1:q}, Y_q$, 令 $p_{\text{done}} \leftarrow 5$; 返回模型、实际计数、**completed** 及求解器/残差诊断

输出。 列出返回对象、实际计数、中心状态和用于复核的诊断。

复杂度分析

训练时间复杂度。 形成中心化或标准化矩阵需 $O(mn)$ 。本算法调用确定性稠密薄 SVD, 其成本为 $O(mn \min(m, n))$; 显式形成 $m \times m$ 协方差则需 $O(m^2 n)$ 。若改用迭代截断 SVD, 必须另行把工作宽度、遍历轮数与正交化成本参数化, 不能用 $O(mnq)$ 替代本算法的实际界。

预测时间复杂度。 对 b 个新样本, 沿用训练均值和尺度需 $O(mb)$, 计算 q 维得分需 $O(mqb)$; 若再重构, 另需 $O(mqb)$ 。

空间复杂度。 保存稠密 X_c 需 $O(mn)$, 薄 SVD 工作量与实现有关; 模型持久化需 $O(mq + m)$, 训练得分另需 $O(nq)$ 。

复杂度假设。 上述界假设输入是实值稠密 $n \times m$ 行样本矩阵, SVD 前显式取转置工作视图 $X_c \in \mathbb{R}^{m \times n}$, 标量运算为常数成本, 并把底层 SVD 视为稳定稠密实现; 稀疏数据应以非零元数替换相应的 mn 乘法成本。

适用条件与局限性

适用条件。 PCA 适合以欧氏平方误差为合理度量、主要结构近似线性、二阶变化具有解释价值的数据, 可用于压缩、去相关、可视化预处理和噪声方向截断。

局限性。 它对异常值敏感; 不能捕捉弯曲流形; 高方差不必然等于任务相关; 主轴载荷可能难以解释; 重复或接近的特征值使单根主轴不稳定; 标准化选择会显著改变结果; PCA 本身不提供因果解释或概率独立保证。

读前自检: 常见错误与误用边界: 主成分算法、例题与练习。 主成分算法、例题与练习所用的明确前提是“边界框首项禁止把特征向量分量当作相关载荷”; 完成把固定错误“把特征向量分量当

作相关载荷”中的对象、操作与结论按本节定义拆开，指出第一个不满足的定义条件，再把该处改为本节允许的写法后，核对改写后的运算或判断有定义，且不再触发“把特征向量分量当作相关载荷”。

常见错误

典型误用包括：未中心化便分解；未写 $X_C = X_{C, \text{row}}^T$ 便在行/列样本公式间切换；混淆协方差 PCA 和相关 PCA；把特征向量分量当作相关载荷；未明确按 $\lambda_1 \geq \lambda_2 \geq \dots$ 保留最大特征值；忽略主轴符号不唯一；用测试集均值标准化；在重复特征值下逐列比较向量；把累计贡献率当成预测性能保证；形成 Gram 矩阵后忽略条件数平方化；重构时忘记乘回尺度并加回均值。

读前自检：易混淆概念对比：主成分算法、例题与练习。 围绕主成分算法、例题与练习，先采用条件“对比表首个数据行是“输入处理 | 只中心化 | 中心化并逐变量缩放 | 可实现前两者任一预处理””，再按列复述“输入处理 | 只中心化 | 中心化并逐变量缩放 | 可实现前两者任一预处理”中的对象、假设与结论；最后验证各列均对应首行对象“输入处理”，且未与表中下一行互换。

易混淆概念对比			
维度	协方差 PCA	相关 PCA	截断 SVD 实现
输入处理	只中心化	中心化并逐变量缩放	可实现前两者任一预处理
强调对象	原始单位下的方差	各变量等权后的相关结构	数值求解路线, 不是另一统计目标
主轴来源	S 的特征向量	R 的特征向量	处理后数据的左奇异向量
主要风险	大量纲变量支配	放大小方差噪声	尺寸、缩放和截断秩写错

读前自检：主成分分析算法。 二维 PCA 例给出 $S = \begin{bmatrix} 5 & 2 \\ 2 & 2 \end{bmatrix}$ ；请展开 $\det(S - \lambda I)$ 得到 $\lambda_1 = 6, \lambda_2 = 1$ ，再核对首轴 $(2, 1)^T / \sqrt{5}$ 的贡献率为 $6/7$ 。

例题 27.1 (二维 PCA 投影与重构). 某二维原始数据在中心化后的样本协方差为 $S = \begin{bmatrix} 5 & 2 \\ 2 & 2 \end{bmatrix}$ 。

求第一主成分、方差贡献率，并写出一点 $x = (4, 1)^T$ 在均值 $\bar{x} = (1, 1)^T$ 下的一维重构。

例题 27.1 解答

读题翻译 先从中心化协方差矩阵找最大方差方向和贡献率，再把给定原始点中心化、投影到该主轴并映射回原坐标。

已知与合法条件 S 为 2×2 对称协方差矩阵，第一主轴须取最大特征值对应的单位特征向量；重构时必须加回均值 $\bar{x}$ 。

为什么想到这个方法 PCA 的一维子空间由 Rayleigh 商最大的单位方向给出，即 S 的最大特征向量；投影矩阵为 $u_1 u_1^T$ 。

方法选择 求 S 的两个特征值并归一化第一主轴, 计算 $\lambda_1/\text{tr}(S)$; 再对 $x - \bar{x}$ 投影、重构, 并用迹/行列式和正交残差复核。

推导/计算 谱分解。 协方差矩阵的特征方程为

$$\begin{aligned}\det(S - \lambda I) &= (5 - \lambda)(2 - \lambda) - 4 \\ &= \lambda^2 - 7\lambda + 6 \\ &= (\lambda - 6)(\lambda - 1) = 0.\end{aligned}$$

因此 $\lambda_1 = 6$ 、 $\lambda_2 = 1$ 。第一主轴及其方差贡献率为

$$(S - 6I)u_1 = 0 \implies -a_1 + 2a_2 = 0 \implies u_1 = \frac{1}{\sqrt{5}}(2, 1)^T, \quad \rho_1 = \frac{6}{6+1} = \frac{6}{7}.$$

投影与重构。 对给定样本, 中心化、投影和重构依次为

$$\begin{aligned}z &= x - \bar{x} = (3, 0)^T, \\ y_1 &= u_1^T z = \frac{6}{\sqrt{5}}, \\ \hat{z} &= u_1 y_1 = \left(\frac{12}{5}, \frac{6}{5}\right)^T, \\ \hat{x} &= \bar{x} + \hat{z} = \left(\frac{17}{5}, \frac{11}{5}\right)^T.\end{aligned}$$

独立核验 特征值满足 $\lambda_1 + \lambda_2 = 7 = \text{tr}(S)$ 且 $\lambda_1 \lambda_2 = 6 = \det(S)$ 。此外, 残差与第一主轴正交:

$$r = x - \hat{x} = \left(\frac{3}{5}, -\frac{6}{5}\right)^T, \quad u_1^T r = \frac{1}{\sqrt{5}}\left(\frac{6}{5} - \frac{6}{5}\right) = 0.$$

结论 第一主轴为 $u_1 = (2, 1)^T/\sqrt{5}$, 贡献率为 $6/7$, 给定点的一维重构为 $\hat{x} = (17/5, 11/5)^T$ 。

本章共 18 道练习。每道题干后立即给出同号解析; 长解析可自然跨页, 续页标题保留题号。

练习 27.1. 对数据矩阵

$$X = \begin{bmatrix} 2 & 3 & 3 & 4 & 5 & 7 \\ 2 & 4 & 5 & 5 & 6 & 8 \end{bmatrix}$$

作样本主成分分析: 求样本均值、协方差矩阵、主轴、主成分得分与方差贡献率。

练习 27.1 解析

六个样本的均值为

$$\bar{x} = \begin{bmatrix} 4 \\ 5 \end{bmatrix}, \quad X_c = \begin{bmatrix} -2 & -1 & -1 & 0 & 1 & 3 \\ -3 & -1 & 0 & 0 & 1 & 3 \end{bmatrix}.$$

练习 27.1 解析 (续)

因此无偏样本协方差为

$$S = \frac{1}{5} X_c X_c^T = \begin{bmatrix} 16/5 & 17/5 \\ 17/5 & 4 \end{bmatrix}.$$

令 $s = \sqrt{293}$, 其特征值为

$$\hat{\lambda}_1 = \frac{18+s}{5}, \quad \hat{\lambda}_2 = \frac{18-s}{5}.$$

可取标准正交主轴

$$a_1 = \frac{1}{\sqrt{17^2 + (2+s)^2}} \begin{bmatrix} 17 \\ 2+s \end{bmatrix} \approx \begin{bmatrix} 0.664514 \\ 0.747275 \end{bmatrix},$$

$$a_2 = \frac{1}{\sqrt{17^2 + (2+s)^2}} \begin{bmatrix} 2+s \\ -17 \end{bmatrix} \approx \begin{bmatrix} 0.747275 \\ -0.664514 \end{bmatrix}.$$

得分矩阵 $Y = A^T X_c$ 的两行为

$$y_1 \approx (-3.570855, -1.411790, -0.664514, 0, 1.411790, 4.235370),$$

$$y_2 \approx (0.498992, -0.082761, -0.747275, 0, 0.082761, 0.248283).$$

总方差为 $36/5$, 故两个贡献率分别为

$$\eta_1 = \frac{18 + \sqrt{293}}{36} \approx 97.55\%, \quad \eta_2 = \frac{18 - \sqrt{293}}{36} \approx 2.45\%.$$

主轴与得分可同时反号, 不影响方差或重构。

练习 27.2. 设整数 $n \geq 2$, 且 $x_1, \dots, x_n$ 独立同分布, 均值为 μ 、协方差为 Σ 且二阶矩有限。证明

$$S = \frac{1}{n-1} \sum_{j=1}^n (x_j - \bar{x})(x_j - \bar{x})^T$$

是 Σ 的无偏估计。

练习 27.2 解析

由题设 $n \geq 2$, 分母 $n-1$ 为正。令 $z_j = x_j - \mu$ 、 $\bar{z} = n^{-1} \sum_j z_j$, 则

$$\sum_{j=1}^n (z_j - \bar{z})(z_j - \bar{z})^T = \sum_{j=1}^n z_j z_j^T - n \bar{z} \bar{z}^T.$$

由 $\mathbb{E}(z_j z_j^T) = \Sigma$, 第一项的期望为 $n\Sigma$ 。独立性给出

$$\mathbb{E}(\bar{z} \bar{z}^T) = \text{cov}(\bar{z}) = \frac{\Sigma}{n},$$

所以第二项的期望为 Σ 。于是分子期望为 $(n-1)\Sigma$, 除以 $n-1$ 得到 $\mathbb{E}S = \Sigma$ 。有限二阶矩保证上述期望存在。

练习 27.3. 设样本矩阵已中心化（若变量量纲不可比，则先用训练样本标准化）。证明保留前 q 个样本主成分的 PCA 重构，等价于在所有秩不超过 q 的矩阵中求该中心化或标准化样本矩阵的 Frobenius 范数最佳近似。

练习 27.3 解析

记待分析矩阵为 Z ；它可以是中心化矩阵 X_c ，也可以是只用训练统计量得到的标准化矩阵。设紧 SVD 为

$$Z = U\Gamma V^T.$$

前 q 个样本主轴是 U_q ，得分为 $Y_q = U_q^T Z = \Gamma_q V_q^T$ ，故 PCA 重构为

$$U_q Y_q = U_q \Gamma_q V_q^T = Z_q.$$

Eckart-Young-Mirsky 定理说明，对任意 $\text{rank}(B) \leq q$,

$$\|Z - B\|_F \geq \|Z - Z_q\|_F = \left(\sum_{i>q} r_i^2 \right)^{1/2}.$$

所以 PCA 重构正是秩不超过 q 的最佳 Frobenius 近似。若 Z 经过标准化，结论在标准化坐标中成立；回到原量纲时还要乘回训练尺度并加回训练均值。

练习 27.4. 证明正交变换 $y = A^T x$ 保持总方差。

练习 27.4 解析

若 $y = A^T x$ 且 $A^T A = A A^T = I$ ，则

$$\text{cov}(y) = A^T \Sigma A.$$

利用迹的循环不变性，

$$\sum_j \text{var}(y_j) = \text{tr}(A^T \Sigma A) = \text{tr}(\Sigma A A^T) = \text{tr}(\Sigma).$$

总方差只被重新分配到新坐标，没有被正交旋转创造或消除。

练习 27.5. 若 $\lambda_1 = \lambda_2 > \lambda_3$ ，说明第一、第二主轴为何不唯一，但前二维投影为何唯一。

练习 27.5 解析

若最大特征值 λ 的特征子空间维数为 2，取任意标准正交基 $B \in \mathbb{R}^{m \times 2}$ ，则

$$\Sigma B = B(\lambda I_2), \quad B^T B = I_2.$$

对任意 2×2 正交矩阵 Q ， BQ 仍是该子空间的基，而且

$$(BQ)(BQ)^T = BQ Q^T B^T = B B^T.$$

所以单根主轴不唯一，但二维投影及其重构唯一。

练习 27.6. 设 $\Sigma = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$, 求两个主轴、方差及第一主成分贡献率。

练习 27.6 解析

特征方程给出

$$(\lambda_1, \lambda_2) = (3, 1), \quad \alpha_1 = \frac{1}{\sqrt{2}}(1, 1)^\top, \quad \alpha_2 = \frac{1}{\sqrt{2}}(1, -1)^\top.$$

因此

$$\text{var}(y_1) = 3, \quad \text{var}(y_2) = 1, \quad \eta_1 = \frac{3}{3+1} = \frac{3}{4}.$$

特征向量反号不改变方差或贡献率。

练习 27.7. 设标准化变量的相关矩阵 R 正定。证明 $\sum_{k=1}^m \rho^2(x_j^*, y_k) = 1$ 。

练习 27.7 解析

正定相关矩阵 $R = A\Lambda A^\top$ 满足 $\lambda_k > 0$, 且

$$\text{var}(y_k) = \lambda_k, \quad \rho^2(x_j^*, y_k) = \lambda_k \alpha_{jk}^2.$$

取谱分解第 j 个对角元,

$$1 = R_{jj} = \sum_k \lambda_k \alpha_{jk}^2 = \sum_k \rho^2(x_j^*, y_k).$$

若 R 仅半正定, $\lambda_k = 0$ 对应的主成分方差为 0, 相关系数没有定义; 代数恒等式仍成立, 但相关解释只适用于 $\lambda_k > 0$ 。

练习 27.8. 解释为何“累计贡献率达到 90%”不能自动保证下游分类性能接近最优。

练习 27.8 解析

PCA 按无监督贡献率选择维数:

$$q_\eta = \min \left\{ q : \frac{\sum_{j=1}^q \lambda_j}{\sum_{j=1}^m \lambda_j} \geq \eta \right\}.$$

该准则没有使用标签 Y , 所以一般不能推出分类风险最小:

$$q_\eta \not\Rightarrow \arg \min_q \hat{R}_{\text{val}}(h_q).$$

区分类别的方向可能低方差, 高方差方向也可能只是背景变化; 应在训练流程内用验证集选 q 并评价分类指标, 测试集不得参与选择。

练习 27.9. 证明 $X_c \mathbf{1}_n = 0$, 并据此说明 $\text{rank}(X_c) \leq n - 1$ 。

练习 27.9 解析

由 $\bar{x} = n^{-1} \sum_j x_j$,

$$X_c \mathbf{1}_n = \sum_{j=1}^n (x_j - \bar{x}) = \sum_{j=1}^n x_j - n\bar{x} = 0.$$

所以 $\mathbf{1}_n \neq 0$ 是右零向量, 进而

$$\text{rank}(X_c) \leq n - 1, \quad \text{rank}(X_c) \leq m, \quad \text{rank}(X_c) \leq \min\{m, n - 1\}.$$

练习 27.10. 说明为何在交叉验证的每个折中必须重新估计中心化均值。

练习 27.10 解析

在每个折中只允许用训练索引 T 估计

$$\bar{x}_T = \frac{1}{|T|} \sum_{i \in T} x_i, \quad X_{c,T} = [x_i - \bar{x}_T]_{i \in T}, \quad U_{q,T} = \text{PCA}(X_{c,T}).$$

验证样本必须按同一训练变换投影:

$$y_i = U_{q,T}^\top (x_i - \bar{x}_T), \quad i \in V.$$

若用 $T \cup V$ 估计均值或主轴, 验证观测已进入训练变换, 形成数据泄漏。

练习 27.11. 若协方差特征值为 10, 3, 2, 1, 求二维 PCA 的总体最小均方重构误差。

练习 27.11 解析

若特征值按 $\lambda_1 \geq \dots \geq \lambda_4$ 排列且尾部为 2, 1, 保留 $q = 2$ 维的最小总平方误差为

$$E_2^{\min} = \sum_{j=3}^4 \lambda_j = 2 + 1 = 3.$$

若题目另问每个原变量的平均误差, 则

$$\bar{E}_2 = \frac{E_2^{\min}}{4} = \frac{3}{4};$$

PCA 定理本身给出的是总平方误差。

练习 27.12. 证明 $BB^\top$ 不随 B 的列作正交换基而改变。

练习 27.12 解析

令 $\tilde{B} = BQ$, 其中 $Q^\top Q = QQ^\top = I_q$ 。则

$$\tilde{B}\tilde{B}^\top = BQQ^\top B^\top = BB^\top.$$

练习 27.12 解析 (续)

对任意中心化样本 x ,

$$\tilde{B}^T x = Q^T B^T x, \quad \tilde{B} \tilde{B}^T x = B B^T x.$$

低维坐标发生正交旋转, 但重构和残差不变。

练习 27.13. 给出不中心化直接最小化 $\|X - B B^T X\|_F^2$ 可能产生误导的原因。

练习 27.13 解析

未中心化目标使用过原点的线性子空间:

$$\min_{B^T B = I_q} \sum_i \|x_i - B B^T x_i\|_2^2.$$

它会把均值向量的大小也当作要解释的变化。仿射 PCA 应改为

$$\min_{B^T B = I_q} \sum_i \|(x_i - \bar{x}) - B B^T (x_i - \bar{x})\|_2^2,$$

$$\hat{x}_i = \bar{x} + B B^T (x_i - \bar{x}).$$

这样主轴描述协方差而不是数据云相对原点的位置。

练习 27.14. 已知 X_c 的奇异值为 6, 3, 1, 样本数 $n = 10$ 。求样本协方差的非零特征值。

练习 27.14 解析

由 $X_c = U T V^T$ 与 $n - 1 = 9$,

$$S = \frac{1}{n-1} X_c X_c^T = U \frac{\Gamma^2}{9} U^T.$$

若奇异值为 6, 3, 1, 则

$$(\hat{\lambda}_1, \hat{\lambda}_2, \hat{\lambda}_3) = \left(\frac{36}{9}, \frac{9}{9}, \frac{1}{9}\right) = \left(4, 1, \frac{1}{9}\right),$$

对应特征向量就是左奇异向量。

练习 27.15. 若 $U_q \in \mathbb{R}^{m \times q}$ 、 $\Gamma_q \in \mathbb{R}^{q \times q}$ 、 $V_q \in \mathbb{R}^{n \times q}$, 核对 $Y_q = \Gamma_q V_q^T$ 与重构 $U_q Y_q$ 的尺寸。

练习 27.15 解析

得分矩阵的尺寸链为

$$Y_q = \Gamma_q V_q^T : (q \times q)(q \times n) = q \times n.$$

重构尺寸为

$$U_q Y_q : (m \times q)(q \times n) = m \times n,$$

与中心化数据矩阵 $X_c \in \mathbb{R}^{m \times n}$ 一致。

练习 27.16. 为何通过 $X_c X_c^T$ 求特征值可能比直接 SVD 更易受浮点误差影响？

练习 27.16 解析

Gram 矩阵的非零特征值满足

$$\lambda_j(X_c X_c^T) = \sigma_j(X_c)^2.$$

若 X_c 满秩，则

$$\kappa_2(X_c X_c^T) = \frac{\sigma_{\max}^2}{\sigma_{\min}^2} = \kappa_2(X_c)^2.$$

小奇异方向因平方更接近机器精度，形成 Gram 矩阵时还会累积舍入误差，所以病态或近低秩数据通常直接做 SVD 更稳定。

练习 27.17. 设计三项检查，用于发现 PCA 实现中的尺寸或预处理错误。

练习 27.17 解析

三项可计算不变量为

$$\begin{aligned} \|X_c \mathbf{1}_n\|_2 &\approx 0, \\ \|U_q^T U_q - I_q\|_F &\approx 0, \\ \|X_c - U_q Y_q\|_F^2 &\approx \sum_{j>q} r_j^2. \end{aligned}$$

它们分别检查中心化轴向、主轴正交/维数以及得分转置与截断。若还做标准化，应验证训练行方差满足

$$\widehat{\text{var}}_T(z_j) \approx 1.$$

练习 27.18. 若前两特征值为 5.00, 4.99，第三为 1.00，解释为何分别比较第一、第二主轴可能不稳定，而二维子空间仍稳定。

练习 27.18 解析

相邻谱隙为

$$\delta_{1,2} = 5.00 - 4.99 = 0.01, \quad \delta_{2,3} = 4.99 - 1.00 = 3.99.$$

前者很小，故微小扰动可使第一、第二主轴在二维空间内明显旋转；后者较大，前二维空间与正交补分离良好。复核时应比较

$$P_2 = U_2 U_2^T \quad \text{或两个二维子空间的主角度,}$$

而不是要求两根主轴逐列稳定。

读前自检：本章结论与下一步。 主成分分析章末结论把中心化矩阵 X_c 、薄 SVD 与保留维数 q 连在一起；请核对 X_c 的列维数、前 q 个主轴的正交性及重构维数，并确认总方差减保留方差等于舍弃方差。

本章结论与下一步

核心结论：中心化数据、协方差谱、主轴、得分与正交投影

关键依据：单位约束方差最大化导出特征方程；总方差减保留方差连接最优重构

可执行自检：用训练均值/尺度构造 X_c ，对其薄 SVD 并按贡献率或验证准则选择 q

适用边界：需要线性降维、去相关、压缩或可视化且方差是合理信号时

下一步：进入 LSA 与 NMF；继续保留训练预处理，重复根时比较子空间而非单根向量

1. 能否从 $\text{var}(\alpha^T z)$ 分三步推到 $\Sigma\alpha = \lambda\alpha$?
2. 能否证明前 q 维最大保留方差，并推出尾部特征值和等于最小重构误差?
3. 能否区分特征向量分量、因子载荷、全局贡献率和单变量累计解释量?
4. 能否在样本按列的约定下写出 S 、SVD、得分与重构的全部尺寸?
5. 能否说明何时使用相关 PCA、标准化为何只能使用训练统计量，并给出算法的输入、输出、数值停止规则、复杂度与至少三项可计算诊断? 若未通过，应依次回看“总体主成分”“样本主成分”“最优低维重构”“PCA 与 SVD 的关系”以及“主成分算法、例题与练习”等相关内容。

第 28 章 潜在语义分析与非负矩阵分解

读前自检：本章可检验学习目标。 潜在语义分析与非负矩阵分解学习目标固定核验“能从词频或 TF-IDF 权值构造单词 – 文本矩阵，并核对“单词在行、文本在列”的维数约定”；请实际完成“从词频或 TF-IDF 权值构造单词 – 文本矩阵，并核对“单词在行、文本在列”的维数约定”，并用“中间结果逐项包含首目标“能从词频或 TF-IDF 权值构造单词 – 文本矩阵，并核对“单词在行、文本在列”的维数约定”声明的对象、条件与结论”判定通过或失败。

读前自检：最短先修。 潜在语义分析与非负矩阵分解的最短先修明确要求“本章直接使用向量内积与余弦、矩阵乘法、Frobenius 范数、梯度、凸函数、Jensen 不等式、奇异值分解和最佳低秩近似”；请把首项“本章直接使用向量内积与余弦、矩阵乘法、Frobenius 范数、梯度、凸函数、Jensen 不等式、奇异值分解和最佳低秩近似”中的第一个先修对象写成定义域 – 运算 – 输出三元组，并以“该三元组逐项满足首项“本章直接使用向量内积与余弦、矩阵乘法、Frobenius 范数、梯度、凸函数、Jensen 不等式、奇异值分解和最佳低秩近似”的对象类型与成立条件”判断能否进入本章。

读前自检：先修自检。 潜在语义分析与非负矩阵分解先修自检固定核验“若 $X \in \mathbb{R}^{m \times n}$ 且样本按列排列，能否写出 $X^T X$ 、 XX^T 和 $U_k^T X$ 的维数”；请在 $X \in \mathbb{R}^{m \times n}$ 且样本按列排列条件下，实际写出 $X^T X$ 、 XX^T 和 $U_k^T X$ 的维数并写出中间结果，再按“ $X \in \mathbb{R}^{m \times n}$ 的计算或证明结果满足首项所列等式、定义域或判断”明确判为通过或失败。

读前自检：依赖路线。 潜在语义分析与非负矩阵分解把“词频与文档频率 → TF-IDF 权值 → 单词 – 文本矩阵”接到“单词向量空间的同义与多义困难 → 低维话题表示”；请用 → 补全这一步的等式或判据，再检查两端维数、支持或对象类型。

本章地图

核心问题： 怎样在高维稀疏共现矩阵中提取低维语义结构

可检验学习目标：

- 能从词频或 TF-IDF 权值构造单词 – 文本矩阵，并核对“单词在行、文本在列”的维数约定；
- 能严格区分单词向量空间、话题向量空间、一般因子模型、基于截断 SVD 的潜在语义分析和非负矩阵分解；
- 能逐行推出 LSA 文本坐标、NMF 平方损失梯度、一套乘法更新与一套投影更新，并说明每一步的矩阵尺寸；
- 能证明截断 SVD 的正交低秩最优性以及平方损失 NMF 乘法更新的目标单调不增性质，同时准确限定这些结论；
- 能执行截断 SVD、平方损失乘法更新与投影梯度的核心步骤；广义 KL 求解细节作为进阶对照；
- 能用子空间与非负锥两种几何解释比较 LSA 和 NMF，并完成章末 12 道题的计算、推导和诊断。

最短先修： 本章直接使用向量内积与余弦、矩阵乘法、Frobenius 范数、梯度、凸函数、Jensen 不等式、奇异值分解和最佳低秩近似。统一令词表含 m 个单词、语料含 n 篇文本、潜在维数为 k ，并假定已阅读本册奇异值分解与主成分分析两章。NMF 的散度损失还用到 KL 散度的非负性与零项极限约定。

依赖路线：词频与文档频率 → TF-IDF 权值 → 单词 – 文本矩阵；单词向量空间的同义与多义困难 → 低维话题表示；截断 SVD 与低秩最优性 → 正交 LSA；非负约束与加性组合 → NMF 话题表示；平方损失或广义 KL 散度 → 乘法更新；目标轨迹、残差与多初值 → 可复核的模型选择。

完成标准与返回：矩阵方向或权重不清时回到节 28.1；低秩/非负更新失败时回看节 28.3、28.5

数据方向桥：词为行、文档为列

本章使用词 – 文档矩阵 $X_{\text{wd}} \in \mathbb{R}^{m \times n}$ ，第 j 列是第 j 篇文档的 m 维词权向量。若把文档视为全书默认的行样本，则

$$X_{\text{doc,row}} = X_{\text{wd}}^T \in \mathbb{R}^{n \times m}.$$

例如 $m = 1000, n = 200$ 时，两种表示分别为 1000×200 和 200×1000 。LSA 与 NMF 公式沿用前者，常规训练 – 验证切分可沿用后者，但转换时必须写出转置。

本章符号表

符号	取值或维数	含义
m, n, k	正整数, $1 \leq k < \min(m, n)$	词数、文本数和潜在话题数
w_i, d_j	离散对象	第 i 个单词与第 j 篇文本
f_{ij}, df_i	非负整数、 $1 \leq \text{df}_i \leq n$	词频与包含 w_i 的文本数
$X = [x_{ij}]$	$\mathbb{R}_{\geq 0}^{m \times n}$	单词 – 文本矩阵, $x_j = X[:, j]$ 表示文本 d_j
T, Y	$m \times k, k \times n$	一般 LSA 中的单词 – 话题矩阵与话题 – 文本矩阵
U_k, Σ_k, V_k	$m \times k, k \times k, n \times k$	X 的前 k 个奇异三元组
$W = [W_{i\ell}]$	$\mathbb{R}_{\geq 0}^{m \times k}$	NMF 的非负话题基矩阵
$H = [H_{\ell j}]$	$\mathbb{R}_{\geq 0}^{k \times n}$	NMF 的非负文本系数矩阵
$J_F(W, H)$	$\mathbb{R}_{\geq 0}$	平方 Frobenius 损失 $\frac{1}{2} \ X - WH\ _F^2$
$D(X \ WH)$	$\mathbb{R}_{\geq 0} \cup \{+\infty\}$	广义 KL 散度型损失
s, T_s, T_N	非负整数	$s = \text{nnz}(X)$ 及 SVD、NMF 迭代轮数
ϵ, δ	正数	停止容差与数值退化阈值

28.1 文档 – 单词矩阵与潜在语义

一篇文本先被分词并映射到固定词表 $\mathcal{V} = \{w_1, \dots, w_m\}$ 。若只记录每个词出现多少次而忽略顺序，就得到词袋表示。把文本集合 $\mathcal{D} = \{d_1, \dots, d_n\}$ 的列向量并排，形成

$$X = [x_1, \dots, x_n] = [x_{ij}] \in \mathbb{R}_{\geq 0}^{m \times n}, \quad x_j = (x_{1j}, \dots, x_{mj})^T \in \mathbb{R}_{\geq 0}^m.$$

这里 i 始终是单词下标， j 始终是文本下标。词袋模型保留“出现什么、出现多少”，舍弃词序；因而它是建模选择，不是原始文本的无损复制。

若 x_{ij} 采用归一化 TF-IDF 权值，记 f_{ij} 为词频、 $f_{\cdot j} = \sum_{r=1}^m f_{rj}$ 为文本长度、 df_i 为含词 w_i 的文本数，则

$$x_{ij} = \frac{f_{ij}}{f_{\cdot j}} \log \frac{n}{\text{df}_i}.$$

该式要求 $f_{ij} > 0$ 且训练词表中的 $\text{df}_i \geq 1$ 。空文本应在建矩阵前处理；新文本沿用训练语料确定的词表和逆文档频率，不能用测试语料重新估计。

采用上述不平滑逆文档频率时，若 $\text{df}_i = n$ ，第 i 个词的整行 TF-IDF 权值会变为 0；一篇只含这类词的文本也可能成为全零列。因此权值矩阵形成后必须再次检查全零行列：删除无信息词行并保存词表映射，回查或隔离全零文本列；若改用平滑逆文档频率，则应明确给出平滑公式和训练统计量。

读前自检：潜在语义分析。 潜在语义分析先在固定词表的单词空间比较非零文本 x_p, x_q ；请计算 $x_p^T x_q / (\|x_p\|_2 \|x_q\|_2)$ ，核对余弦落在 $[-1, 1]$ ，并指出任一文本为零向量时该式无定义。

读前自检：单词向量空间与话题向量空间。 单词向量 $x_j \in \mathbb{R}^m$ 经话题基 $U_k \in \mathbb{R}^{m \times k}$ 编码为 $y_j = U_k^T x_j \in \mathbb{R}^k$ ；请核对编码与 $U_k y_j$ 重构的维数，并说明 $k < m$ 时有损。

单词空间用两篇文本的内积 $x_p^T x_q$ 或

$$\cos(x_p, x_q) = \frac{x_p^T x_q}{\|x_p\|_2 \|x_q\|_2}$$

衡量两篇非零文本的相似度。它能利用共同词，却难以处理同义词分占不同坐标和多义词把不同语境错误连接的问题。潜在语义分析希望从大量共现模式中学习少量话题方向，再在话题空间中比较文本。

读前自检：单词向量空间。 LSA 因子 $T \in \mathbb{R}^{m \times k}, Y \in \mathbb{R}^{k \times n}$ 满足 $X \approx TY$ ；请对可逆 $R \in \mathbb{R}^{k \times k}$ 验证 $(TR)(R^{-1}Y) = TY$ ，核对一般话题基存在换基不唯一性。

在单词空间中，每个坐标轴对应一个词，维数为 m ；在话题空间中，每个坐标轴对应由若干词共同定义的潜在方向，维数为 $k \ll m$ 。降维可能缓解稀疏和词面不一致，但也会混合原本不同的细节，因此必须报告截断误差和下游评价。

阅读目标：区分投影、低维坐标与重构，并核对训练文本和新文本的尺寸。

对象： $X = U\Sigma V^T \in \mathbb{R}^{m \times n}$ 、截断基 U_k 与文本列 $x_j = X e_j$ 。

合法条件： $U_k^T U_k = I_k$ ；训练与新文本使用同一词表和预处理。

第一步：先左乘 U_k^T ，计算训练文本坐标 $U_k^T x_j$ 。

定义 28.1 (潜在语义因子模型). 给定非零矩阵 $X \in \mathbb{R}_{\geq 0}^{m \times n}$ ，令 $r = \text{rank}(X)$ 并取 $1 \leq k \leq r$ 。潜在语义因子模型寻找

$$T \in \mathbb{R}^{m \times k}, \quad Y \in \mathbb{R}^{k \times n}, \quad X \approx TY.$$

T 的第 ℓ 列 $t_\ell \in \mathbb{R}^m$ 表示第 ℓ 个话题方向， Y 的第 j 列 $y_j \in \mathbb{R}^k$ 表示文本 d_j 的话题坐标。若取 $T = U_k, Y = \Sigma_k V_k^T$ ，称为基于截断 SVD 的 LSA。 $k < r$ 是降维且有损的截断选择，此时 $X_k \neq X$ ；边界 $k = r$ 保留全部非零奇异三元组，维数为 $U_r \in \mathbb{R}^{m \times r}, \Sigma_r \in \mathbb{R}^{r \times r}, V_r \in \mathbb{R}^{n \times r}$ ，并精确重构 $X_r = U_r \Sigma_r V_r^T = X$ 。

一般分解存在缩放与换基不唯一性：对任意可逆 $R \in \mathbb{R}^{k \times k}$, $TY = (TR)(R^{-1}Y)$ 。SVD 用正交列和按序奇异值固定了大部分自由度，但成对符号仍可翻转；重复奇异值对应子空间内仍可旋转。因此解释应优先面向话题子空间、重构和相似关系，而不是执着于某一系列的符号。

28.2 LSA 模型

模型。对薄 SVD

$$X = U\Sigma V^T,$$

取前 k 项，得到

$$X_k = U_k \Sigma_k V_k^T = U_k Y, \quad Y = \Sigma_k V_k^T.$$

U_k 列标准正交，因而文本 x_j 在该子空间中的坐标为 $y_j = U_k^T x_j$ ；其重构为 $U_k y_j$ 。 U_k 和 Y 通常含正负元素，不能把它们直接解释为概率或非负份额。

学习策略。SVD-LSA 最小化秩不超过 k 的 Frobenius 重构误差：

$$\min_{\text{rank}(B) \leq k} \|X - B\|_F^2.$$

k 由训练阶段的尾部奇异值能量、语义稳定性、检索或聚类验证指标共同选择。只凭低维图好看或训练误差下降来选择 k ，会把视觉偏好或过拟合当成语义证据。

先定义模型，再选择求解器。LSA 规定无约束秩 k 最佳近似问题，NMF 规定非负因子下的平方或广义 KL 目标；这些最优性结论不依赖某个迭代器。求解阶段再选择完整或截断 SVD、乘法更新或投影梯度，并报告残差与预算。两者不能因“都写成两个矩阵的乘积”便被视为同一模型或同一算法。

读前自检：潜在语义分析算法。基于截断 SVD 的 LSA 输入非零词 - 文档矩阵 X 与 $1 \leq k \leq \text{rank}(X)$ ；请取 U_k, Σ_k, V_k 并计算 $Y = U_k^T X = \Sigma_k V_k^T$ ，核对重构 $U_k Y = X_k$ 及残差后结束。

读前自检：矩阵奇异值分解算法。LSA 的矩阵 SVD 路线对 $X \in \mathbb{R}^{m \times n}$ 提取前 k 个奇异三元组；请核对 $U_k^T U_k = I_k$ ，再算一列文本坐标 $y_j = U_k^T x_j$ ，以左右奇异残差判定分解是否合格。

28.3 截断 SVD 模型、坐标与最优性

推导目标

从截断 SVD 推出训练文本和新文本的话题坐标，并核对投影、坐标与重构的尺寸。

推导准备

设 $X = U\Sigma V^T$, $U_k^T U_k = I_k$ ，并把第 j 个标准基记为 $e_j \in \mathbb{R}^n$ 。第 j 列文本为 $x_j = X e_j \in \mathbb{R}^m$ 。

推导第 1 步：取前 k 维正交投影坐标。

$$y_j = U_k^T x_j \in \mathbb{R}^k.$$

推导第 2 步：把坐标写成右奇异向量形式。

$$U_k^T x_j = U_k^T U \Sigma V^T e_j = \Sigma_k V_k^T e_j.$$

因此全部训练文本的坐标矩阵为

$$Y = [y_1, \dots, y_n] = U_k^T X = \Sigma_k V_k^T \in \mathbb{R}^{k \times n}.$$

推导第 3 步：重构并推广到新文本。

$$\hat{x}_j = U_k y_j = U_k U_k^T x_j, \quad \hat{X} = U_k Y = X_k.$$

对使用同一词表和权值规则得到的新文本 $x_{\text{new}} \in \mathbb{R}^m$ ，编码为 $y_{\text{new}} = U_k^T x_{\text{new}}$ ，重构为 $U_k y_{\text{new}}$ 。维数链分别为 $(k \times m)(m \times 1) = k \times 1$ 和 $(m \times k)(k \times 1) = m \times 1$ 。

定理 28.1 (LSA 的正交低秩最优性) 设 X 的奇异值为 $\sigma_1 \geq \dots \geq \sigma_r > 0$, $1 \leq k < r$ 。则

$$X_k = U_k \Sigma_k V_k^T$$

在所有秩不超过 k 的矩阵中最小化 Frobenius 误差，并且

$$\|X - X_k\|_F^2 = \sum_{j=k+1}^r \sigma_j^2.$$

此外，LSA 训练坐标恰为 $Y = U_k^T X = \Sigma_k V_k^T$ 。

读前自检：证明：LSA 的正交低秩最优性。 围绕 LSA 的正交低秩最优性，先采用条件“由本册的 Eckart-Young-Mirsky 低秩最优性该定理”，再把 $\langle u_i v_i^T, u_j v_j^T \rangle_F$ 按证明中的分解展开一层；最后验证三个结论均成立。

证明. 由本册的 Eckart-Young-Mirsky 低秩最优性定理 26.3，任意 $\text{rank}(B) \leq k$ 的矩阵满足

$$\|X - B\|_F^2 \geq \sum_{j=k+1}^r \sigma_j^2.$$

截断矩阵与原矩阵之差为 $X - X_k = \sum_{j=k+1}^r \sigma_j u_j v_j^T$ 。这些秩一矩阵在 Frobenius 内积下两两正交，因为

$$\langle u_i v_i^T, u_j v_j^T \rangle_F = (u_i^T u_j)(v_i^T v_j) = \delta_{ij}.$$

所以 $\|X - X_k\|_F^2 = \sum_{j>k} \sigma_j^2$ ，达到上述下界。最后，

$$U_k^T X = U_k^T U \Sigma V^T = \Sigma_k V_k^T,$$

证明了坐标公式。三个结论均成立。 □

读前自检：非负矩阵分解算法。 NMF 给定 $X \in \mathbb{R}_{\geq 0}^{m \times n}$ 与秩 k ，寻找 $W \in \mathbb{R}_{\geq 0}^{m \times k}, H \in \mathbb{R}_{\geq 0}^{k \times n}$ ；请核对 WH 的形状与非负性，并把一列写成非负基向量的加权和。

读前自检：非负矩阵分解。 非负矩阵分解要求输入和两因子逐项非负，但不自动要求列和为 1；请用 $X \approx WH$ 核对一列重构为 $\sum_{\ell} H_{\ell j} w_{\ell}$ ，并说明若要概率解释还需额外归一化。

28.4 非负矩阵分解模型

读前自检：非负矩阵分解。 非负矩阵分解的广义 KL 型损失约定 $x_{ij} = 0$ 时对数项为 0；请检查一个 $x_{ij} > 0$ 的位置，若 $(WH)_{ij} = 0$ 则判损失为 $+\infty$ ，否则代入单项并核对它不要求对称。

定义 28.2 (非负矩阵分解). 给定 $X \in \mathbb{R}_{\geq 0}^{m \times n}$ 和潜在维数 k ，非负矩阵分解寻找

$$W \in \mathbb{R}_{\geq 0}^{m \times k}, \quad H \in \mathbb{R}_{\geq 0}^{k \times n}, \quad X \approx WH.$$

第 j 篇文本满足 $x_j \approx Wh_j = \sum_{\ell=1}^k H_{\ell j} w_{\ell}$ ，其中 $w_{\ell} = W[:, \ell]$ 是非负话题基， $h_j = H[:, j]$ 是非负组合系数。

贯穿例：文档—词项矩阵小例

本章角色：返回同一原始非负计数矩阵，用非负基与非负系数解释加性话题结构。

词项为行、文档为列，精确沿用

$$X = \begin{bmatrix} 2 & 0 & 1 \\ 1 & 2 & 0 \\ 0 & 1 & 3 \end{bmatrix}.$$

三列总数仍为 3, 3, 4，总计数仍为 10。矩阵逐项非负，故与 $X \approx WH$ 、 $W, H \geq 0$ 的 NMF 定义相容；本章必须使用这张原始计数表，不能把上一站含负元素的中心化矩阵 X_c 直接作为 NMF 输入。非负约束给出加性锥组合，但在未另行归一化时不把 W, H 自动解释为概率。上一站见 PCA 对同一数据的中心化表示；下一站见 PLSA 对同一计数的概率分解。

NMF 用于话题分析时，以 W 的列表示词在话题中的权重，以 H 的列表示文本的话题强度。所有项非负，所以重构只能“加入部件”，不会用正负抵消解释一个词。若希望把列解释为概率，还需另外归一化并声明概率模型；非负本身只给出锥组合，不给出总和为 1。

常用目标有两类：

$$J_F(W, H) = \frac{1}{2} \|X - WH\|_F^2, \quad W, H \geq 0,$$

以及

$$D(X \| WH) = \sum_{i=1}^m \sum_{j=1}^n \left[x_{ij} \log \frac{x_{ij}}{(WH)_{ij}} - x_{ij} + (WH)_{ij} \right], \quad W, H \geq 0.$$

约定 $x_{ij} = 0$ 时首项为 0；若 $x_{ij} > 0$ 而 $(WH)_{ij} = 0$ ，对应损失为 $+\infty$ 。第二个量通常不对称，也不满足度量公理；只有在归一化条件下才退化为概率分布的 KL 散度。

阅读目标：把梯度的正、负部分与自适应正步长配对，得到保持非负的更新。

对象： $X \geq 0$ 、 $W \geq 0$ 、 $H \geq 0$ 与目标 $\frac{1}{2}\|X - WH\|_F^2$ 。

合法条件：更新 W 时固定 H ；更新 H 时使用当前最新 W ；分母为正或按预先规则处理零项。

第一步：先计算 $\nabla_W J = WHH^T - XH^T$ 与 $\nabla_H J = W^T WH - W^T X$ 。

推导目标

用分量形式求平方损失对 $W_{i\ell}$ 和 $H_{\ell j}$ 的梯度，再把自适应正步长写成乘法更新。

推导准备

令 $Q = WH \in \mathbb{R}^{m \times n}$ 。固定 H 时更新 W ，固定新 W 时更新 H ；所有矩阵乘法都使用当前可用的最新因子。

推导第 1 步：对单个元素求偏导。

$$\frac{\partial J_F}{\partial W_{i\ell}} = - \sum_{j=1}^n [x_{ij} - Q_{ij}] H_{\ell j}, \quad \frac{\partial J_F}{\partial H_{\ell j}} = - \sum_{i=1}^m W_{i\ell} [x_{ij} - Q_{ij}].$$

推导第 2 步：整理为矩阵梯度。

$$\nabla_W J_F = WHH^T - XH^T \in \mathbb{R}^{m \times k}, \quad \nabla_H J_F = W^T WH - W^T X \in \mathbb{R}^{k \times n}.$$

推导第 3 步：选择逐元素步长。 对正因子选择

$$\lambda_{i\ell} = \frac{W_{i\ell}}{(WHH^T)_{i\ell}}, \quad \mu_{\ell j} = \frac{H_{\ell j}}{(W^T WH)_{\ell j}},$$

把 $W \leftarrow W - \lambda \odot \nabla_W J_F$ 和 $H \leftarrow H - \mu \odot \nabla_H J_F$ 逐元素展开，得到

$$W \leftarrow W \odot \frac{XH^T}{WHH^T}, \quad H \leftarrow H \odot \frac{W^T X}{W^T WH}.$$

分式表示同位置元素相除；顺序更新时，第二式使用已经更新并完成尺度补偿的 W 。

核心替代：交替投影梯度

乘法更新易解释但会零锁定。对同一平方损失，可保留一套投影方法作为主线替代：

$$W^+ = [W - \eta_W (WHH^T - XH^T)]_+, \quad H^+ = [H - \eta_H (W^{+\top} W^+ H - W^{+\top} X)]_+,$$

其中 $[a]_+ = \max(a, 0)$ 逐元素作用，第二步使用新 W^+ 。固定另一块时目标是凸二次函数；取

$$0 < \eta_W \leq \|HH^T\|_2^{-1}, \quad 0 < \eta_H \leq \|W^{+\top} W^+\|_2^{-1}$$

(或用回溯验证目标不减), 即可把每块更新解释为非负正交投影后的梯度步。实现只需保留“更新 W 、更新 H 、检查目标/KKT、预算停止”四步; 它允许零坐标重新变正, 不继承乘法更新的零锁定。

定理 28.2 (平方损失乘法更新的单调性) 若 $X \geq 0$ 且无全零行或全零列, 当前 W, H 严格为正, 按上式固定一块更新另一块, 并在每个块更新后使用新因子, 则各分母与乘法比率均为正, $J_F(W, H)$ 在每个子步均不增加。若一个子步不改变正因子, 则该块的梯度为零。

读前自检: 证明: 平方损失乘法更新的单调性。 从平方损失乘法更新的单调性的条件“记 $A = W^T W \geq 0$ 、 $b = W^T x \geq 0$ ”出发, 请补出 h^+ 到下一关系的一步不等式或求导; 所得量应符合另一块同样成立。

证明. 先固定 W 并考虑 H 的一列 h 及相应文本 x 。记 $A = W^T W \geq 0$ 、 $b = W^T x \geq 0$, 则

$$F(h) = \frac{1}{2} \|x - Wh\|_2^2, \quad \nabla F(h) = Ah - b.$$

在当前正向量 $\tilde{h}$ 处定义对角矩阵

$$K_{aa}(\tilde{h}) = \frac{(A\tilde{h})_a}{\tilde{h}_a}$$

和辅助函数

$$G(h, \tilde{h}) = F(\tilde{h}) + (h - \tilde{h})^T \nabla F(\tilde{h}) + \frac{1}{2} (h - \tilde{h})^T K(\tilde{h})(h - \tilde{h}).$$

对任意向量 z , 利用 $A_{ab} = A_{ba} \geq 0$, 逐项对称化得到

$$z^T (K - A) z = \frac{1}{2} \sum_{a,b} A_{ab} \tilde{h}_a \tilde{h}_b \left(\frac{z_a}{\tilde{h}_a} - \frac{z_b}{\tilde{h}_b} \right)^2 \geq 0.$$

所以 $K - A$ 半正定, $G(h, \tilde{h}) \geq F(h)$ 且 $G(\tilde{h}, \tilde{h}) = F(\tilde{h})$ 。令 G 对 h 的梯度为零, 得到

$$h^+ = \tilde{h} - K^{-1}(A\tilde{h} - b) = \tilde{h} \odot \frac{b}{A\tilde{h}}.$$

于是

$$F(h^+) \leq G(h^+, \tilde{h}) \leq G(\tilde{h}, \tilde{h}) = F(\tilde{h}).$$

对 H 的每一列求和, 得到 H 子步单调不减。固定 H 并对 W^T 应用同一论证, 得到 W 子步的结论。若正因子在子步中不变, 乘法比率全为 1, 故 $Ah - b = 0$; 另一块同样成立。□

推论 28.1 (固定支持面的边界版本) 若 W, H 只要求非负, 零坐标在更新中保持为零, 并且所有正坐标对应的分母严格为正, 则把定理 28.2 的辅助函数论证限制到这些正坐标张成的固定支持面, 仍可得到每个顺序子步目标不增加。该结论只说明当前支持面内的单调性; 零锁定可能阻止新方向进入, 因此既不等价于严格正初值定理, 也不提供全局 KKT 证书。

扩展讨论：广义 KL 乘法更新。 下述定理用于 Poisson 型计数损失的对照，不属于第一次阅读必须掌握的两套 NMF 求解主线。

读前自检：广义 KL 损失乘法更新的单调性。 广义 KL 损失乘法更新的单调性依赖“固定 W 并记当前因子为 $\tilde{H}$ 、 $\tilde{q}_{ij} = (W\tilde{H})_{ij} > 0$ ”；请据此对 $\alpha_{i\ell j}$ 做一次条件化或边缘化，并直接核对固定更新后的 H ，把行、列和两个因子的角色交换，得到 W 更新及相同的不增链。

定理 28.3 (广义 KL 损失乘法更新的单调性) 若 $X \geq 0$ 且无全零行或全零列， W, H 严格为正，则以下顺序块更新始终有定义、保持因子严格为正，并使 $D(X \| WH)$ 在每个子步不增加：

$$H_{\ell j} \leftarrow H_{\ell j} \frac{\sum_i W_{i\ell} X_{ij} / (WH)_{ij}}{\sum_i W_{i\ell}}, \quad W_{i\ell} \leftarrow W_{i\ell} \frac{\sum_j H_{\ell j} X_{ij} / (WH)_{ij}}{\sum_j H_{\ell j}}.$$

第二个子步使用第一个子步后的 H ；交换两块顺序也保持结论。

读前自检：证明：广义 KL 损失乘法更新的单调性。 广义 KL 损失乘法更新的单调性以“固定 W 并记当前因子为 $\tilde{H}$ 、 $\tilde{q}_{ij} = (W\tilde{H})_{ij} > 0$ ”为约束；请对 $\alpha_{i\ell j}$ 做一次条件化或边缘化，并确认固定更新后的 H ，把行、列和两个因子的角色交换，得到 W 更新及相同的不增链。

证明。 固定 W 并记当前因子为 $\tilde{H}$ 、 $\tilde{q}_{ij} = (W\tilde{H})_{ij} > 0$ 。定义

$$\alpha_{i\ell j} = \frac{W_{i\ell} \tilde{H}_{\ell j}}{\tilde{q}_{ij}}, \quad \sum_{\ell=1}^k \alpha_{i\ell j} = 1.$$

函数 $-\log z$ 在 $z > 0$ 上凸。将 $q_{ij} = \sum_{\ell} \alpha_{i\ell j} (W_{i\ell} H_{\ell j} / \alpha_{i\ell j})$ 代入 Jensen 不等式，得到

$$-\log q_{ij} \leq -\sum_{\ell} \alpha_{i\ell j} \log \frac{W_{i\ell} H_{\ell j}}{\alpha_{i\ell j}}.$$

在 $H = \tilde{H}$ 处，各个对数自变量都等于 $\tilde{q}_{ij}$ ，故不等式取等号。把它乘以 $X_{ij} \geq 0$ ，再加上线性项 $q_{ij} = \sum_{\ell} W_{i\ell} H_{\ell j}$ 和与 H 无关的项，得到一个在当前点相切且不小于原目标的辅助函数。该辅助函数对 $H_{\ell j}$ 的偏导为

$$-\frac{\sum_i X_{ij} \alpha_{i\ell j}}{H_{\ell j}} + \sum_i W_{i\ell}.$$

令其为零并代入 α ，得到定理中的 H 更新。辅助函数在该点取最小值，所以原目标不增加。固定更新后的 H ，把行、列和两个因子的角色交换，得到 W 更新及相同的不增链。两个子步串联后，整轮目标不增加。□

几何理解

几何解释。 SVD-LSA 把 x_j 正交投影到 $\text{span}(U_k)$ ，该子空间允许正负坐标；NMF 把 x_j 近似为 W 列向量的非负组合，所有重构落在这些列生成的凸锥中。前者强调正交与全局能量最优，后者强调非负的部件相加。

读前自检：概率解释：LSA 本身不是概率模型；若把 $X = TY + E$ 并假设 E_{ij} 独立服从同方差高斯分布.....。 LSA 只有在 $X = TY + E$ 且 E_{ij} 独立同方差高斯时，平方重构才有似然解释；请提取负对数似然中依赖 T, Y 的项，核对它与 $\|X - TY\|_F^2$ 成正比，且 LSA 本身不输出概率。

概率解释

LSA 本身不是概率模型；若把 $X = TY + E$ 并假设 E_{ij} 独立服从同方差高斯分布，平方重构目标才获得高斯噪声的似然解释。对计数矩阵，若假设 X_{ij} 独立服从均值 $(WH)_{ij}$ 的 Poisson 分布，去掉只依赖 X 的常数后，负对数似然等于广义 KL 损失。把 W, H 归一化为词分布与话题比例属于额外约束，不能由 NMF 自动推出。

读前自检：优化解释：截断 SVD 对无约束秩 k 问题给出全局最优解。 截断 SVD 对无约束秩 k 近似给出全局最优，而 NMF 要求 $W, H \geq 0$ 且联合非凸；请把同一秩 k 候选分别代入两种可行域，核对 SVD 最优性不能直接作为 NMF 全局最优证书。

优化解释

优化解释。 截断 SVD 对无约束秩 k 问题给出全局最优解。NMF 的可行集要求两个因子均非负，目标对固定 W 的 H 子问题和固定 H 的 W 子问题分别为凸，但对 (W, H) 联合并非凸。乘法更新给出目标单调性，不给出全局最优证书；多初值和独立验证仍是必要步骤。

如图 28.1 所示，两条路线从同一文本向量出发，却把“低维”解释为不同的可行几何。




图 28.1 LSA 的正交子空间表示与 NMF 的非负锥表示：二者维数相同，坐标约束和最优性不同

小型数值例子。 令

$$W = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{bmatrix}, \quad H = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}.$$

则

$$X = WH = \begin{bmatrix} 2 & 0 \\ 2 & 3 \\ 0 & 3 \end{bmatrix}.$$

第一篇文本是第一个话题基的 2 倍，第二篇是第二个话题基的 3 倍；中间词同时属于两个话题。所有贡献均为非负加法。若把第一列 W 乘 2 并把第一行 H 除以 2, X 不变，说明解释前需要统一尺度。

读前自检：平方损失下的乘法更新规则。 平方损失 NMF 在固定 H 时更新 $W \leftarrow W \odot (XH^T)/(WHH^T)$ ；请核对分子、分母与 W 同形且为非负，再用新 W 完成 H 子步并检查目标不增。

读前自检：散度损失下的乘法更新规则。 广义 KL-NMF 在严格正 W, H 和无全零行列的 X 上按 $H \rightarrow W$ 顺序乘法更新；请手算一个 $H_{\ell j}$ 比率，核对分母为正、更新保持正性且 $D(X\|WH)$ 不增。

读前自检：非负矩阵分解算法。 非负矩阵分解算法以非负 X 、秩 k 、严格正 W, H 及目标/KKT 容差为输入；请依次形成一轮 W 与 H 候选，核对非负、有限及目标不异常上升后提交，并按双证书或预算停止。

读前自检：非负矩阵分解的迭代算法。 NMF 迭代维护 W, H, J_F 与 KKT 残差；请从合法旧状态完成 $W \rightarrow$ 尺度补偿 $\rightarrow H$ 的一整轮，只在候选有限非负且目标门禁通过时原子提交，再按相对目标变化与 KKT 双证书判停。

28.5 数值实现：截断 SVD 与平方损失 NMF

读前自检：算法菜单。 算法菜单把截断 SVD 求解器分配给 LSA、平方损失乘法更新分配给 NMF；请分别写出两者的输入与输出，核对前者返回正交三元组/坐标，后者返回非负因子/目标与 KKT 轨迹。

算法菜单

本节保留两个完整实现：截断 SVD 求解器负责 LSA，平方损失乘法更新负责 NMF；上一节的交替投影梯度给出第二套 NMF 核心路线。广义 KL 更新只保留公式、适用域与单调性依据，不再重复一套长工程伪代码。这样“模型/最优性”先于“求解器/状态”，初学者不必并行追踪三套 NMF 循环。

所需量与计算结果。 SVD-LSA 需要非负单词 – 文本矩阵、 k 、子空间宽度与数值预算，计算得到 U_k, Σ_k, V_k, Y 、残差、截断误差和停止原因。NMF 需要 X, k 、损失类型、正初值、容差与最大轮数，计算得到 W, H 、目标与 KKT 残差轨迹、迭代数和停止原因。两类算法对新文本的处理均指低维编码，而不是监督标签预测。

参数含义。 k 控制压缩与表达能力；LSA 的子空间宽度满足 $k \leq \ell \leq \min(m, n)$ ，残差容差 ε_{svd} 和上限 T_S 控制迭代 SVD；NMF 的目标容差 ε_J 、KKT 容差 ε_K 、上限 T_N 和退化阈值 δ 控制停止与诊断。所有容差都应与数据尺度配套报告。

初始化。 LSA 对子空间迭代使用列标准正交的 $Q^{(0)} \in \mathbb{R}^{m \times \ell}$ ，并固定随机种子；必须确认初始子空间在目标奇异子空间上有非零投影。NMF 使用严格正的 $W^{(0)}, H^{(0)}$ ，可由非负随机数或确定性非负 SVD 启发式产生；保存每组初值并使用相同预算比较。

算法 28.1: 基于截断 SVD 的潜在语义分析

输入: $X \in \mathbb{R}_{\geq 0}^{m \times n}$, k , $k \leq \ell \leq \min(m, n)$, $Q^{(0)}$, T_s , ϵ_{svd}
输出: 最后合法 U_k, Σ_k, V_k, Y ; $t_{\text{done}}, b_{\text{done}}$; status、残差与诊断

- 1 若 $X, k, \ell, Q^{(0)}, T_s$ 或容差非法, 则返回 $\perp$ 、计数 0、invalid_input 及字段诊断
- 2 正交化 $Q^{(0)}$; 若有效列数不足 ℓ , 则返回 $\perp$ 、计数 0、numerical_failure 及初始化秩诊断
- 3 令 $Q \leftarrow Q^{(0)}$, $t_{\text{done}} \leftarrow 0$, $b_{\text{done}} \leftarrow 0$, 最后合法模型为 $\perp$
- 4 **当** $t_{\text{done}} < T_s$ **执行**
 - 5 计算 $Z^+ = \text{orth}(X^T Q)$ 、 $Q^+ = \text{orth}(X Z^+)$, 每次完成块乘即增加 b_{done} ; 任一步非有限或有效秩小于 k 则返回最后合法模型、numerical_failure 及左右阶段诊断
 - 6 对 $B^+ = Q^{+T} X$ 求薄 SVD 并恢复候选三元组, 计算前 k 个双侧残差、投影变化、 $Y^+ = \Sigma_k^+ V_k^{+T}$ 及重构误差
 - 7 若任一候选/诊断非有限, 则返回上一合法模型、numerical_failure 及 Ritz 阶段诊断
 - 8 原子提交 $(Q, U_k, \Sigma_k, V_k, Y) \leftarrow (Q^+, U_k^+, \Sigma_k^+, V_k^+, Y^+)$ 并令 $t_{\text{done}} \leftarrow t_{\text{done}} + 1$
 - 9 若双侧残差与投影变化均不超过 ϵ_{svd} , 则返回最后合法模型、实际计数、converged 及证书
- 10 **结束**
- 11 返回最后合法模型、实际计数、budget_stop 及“预算耗尽、证书未达标”诊断

KKT 残差口径。对可微目标 $F(W, H)$ 及非负约束, 本文使用逐元素最小值定义

$$r_{\text{KKT}}(W, H) = \frac{\sqrt{\|\min(W, \nabla_W F)\|_F^2 + \|\min(H, \nabla_H F)\|_F^2}}{\max\{1, \|X\|_F\}}.$$

这里平方损失梯度为 $\nabla_W J_F = W H H^T - X H^T$ 、 $\nabla_H J_F = W^T W H - W^T X$ 。对广义 KL 目标, 在 $q_{ij} = (WH)_{ij} > 0$ 处有 $\partial D / \partial W_{i\ell} = \sum_j H_{\ell j} (1 - X_{ij} / q_{ij})$ 与 $\partial D / \partial H_{\ell j} = \sum_i W_{i\ell} (1 - X_{ij} / q_{ij})$ 。残差为零恰好编码可行性、驻点与互补条件; 实现必须先完成 q_{ij} 有限且为正的检查。

基于截断 SVD 的潜在语义分析：五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新, 并指出何时提交。

数学停止。写出能直接核验的停止证书; 预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

读前自检：平方损失 NMF 的顺序乘法更新：执行契约。平方损失 NMF 的顺序乘法更新输入“非负有限矩阵 X 、秩 k 、严格正初值、轮预算、目标/KKT 容差、分母阈值和零行列预处理映射”, 条件“ $1 \leq k \leq \min(m, n)$ ”; 请执行“ $W^+, H^+, J_F^+, r_{\text{KKT}}^+$ 均有限非负且目标不异常上升后才原子提交”, 以“相对目标变化与 KKT 双证书、 T_N 轮预算耗尽或首次失败时停止”判停。

平方损失 NMF 的顺序乘法更新：五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新, 并指出何时提交。

数学停止。写出能直接核验的停止证书; 预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 28.2: 平方损失 NMF 的顺序乘法更新

输入: $X, k, W^{(0)}, H^{(0)}, T_N, \varepsilon_J, \varepsilon_K, \delta$ 及零行列预处理映射
输出: 最后合法 $W, H, J_F, r_{\text{KKT}}$; $t_{\text{done}}, a_{\text{done}}$; **status**、轨迹与诊断

- 1 若 X, k 、初值、预算、容差、阈值或预处理映射非法, 或仍含未处理全零行列, 则返回初值占位、计数 0、**invalid_input** 及字段诊断
- 2 令 $(W, H) \leftarrow (W^{(0)}, H^{(0)})$, 计算 J_F, r_{KKT} 并置 $t_{\text{done}} \leftarrow 0, a_{\text{done}} \leftarrow 0$; 若初始诊断非有限则返回 **numerical_failure**
- 3 若 $r_{\text{KKT}} \leq \varepsilon_K$, 则返回初值、**converged** 及零轮证书
- 4 **当** $t_{\text{done}} < T_N$ **执行**
- 5 令 $a_{\text{done}} \leftarrow a_{\text{done}} + 1$; 计算 $N_W = XH^T, D_W = WHH^T$; 若 D_W 含小于 δ 或非有限元素, 则返回旧因子、**numerical_failure** 及 W 阶段诊断
- 6 在临时量中令 $\bar{W} = W \odot N_W \oslash D_W$, 归一化其列并反向缩放 H 的对应行, 得到 $\bar{W}, \tilde{H}$
- 7 计算 $N_H = \bar{W}^T X, D_H = \bar{W}^T \bar{W} \tilde{H}$; 若分母退化则返回旧因子、**numerical_failure** 及 H 阶段诊断
- 8 形成 $H^+ = \tilde{H} \odot N_H \oslash D_H, W^+ = \bar{W}$, 计算 J_F^+, r_{KKT}^+
- 9 若候选非有限/非负性失败或 J_F^+ 异常上升, 则拒绝整轮并返回上一合法因子、**numerical_failure** 及尝试轮诊断
- 10 计算相对目标变化后原子提交 $(W, H, J_F, r_{\text{KKT}}) \leftarrow (W^+, H^+, J_F^+, r_{\text{KKT}}^+)$, 令 $t_{\text{done}} \leftarrow t_{\text{done}} + 1$ 并追加轨迹
- 11 若相对目标变化 $\leq \varepsilon_J$ 且 $r_{\text{KKT}} \leq \varepsilon_K$, 则返回最后合法因子、**converged** 及双证书
- 12 **结束**
- 13 返回最后合法因子、实际计数、**budget_stop** 及“预算耗尽、双证书未满足”诊断

算法实现说明: 核心流程按 $H \rightarrow W$ 顺序执行两条乘法更新, 并在整轮后检查目标与 KKT 残差; 零分母、支撑和单调门禁属于稳健实现细节 完整 C1-C14 契约

易混淆概念对比

广义 KL 实现要点 (进阶, 不再列第三套长算法)。严格正初始化后, 按定理 28.3 给出的 $H \rightarrow W$ 顺序更新; 每个子步只在 $X_{ij} > 0$ 处核对 $q_{ij} = (WH)_{ij} > 0$, 整轮复算 D_{KL} 与 KKT 残差。目标异常上升或支撑为零时返回 **numerical_failure**, 预算用尽而双条件未满足时返回 **budget_stop**。这一工程合同与平方损失算法同构, 差别只在损失、梯度、正支撑门和更新式, 故不重复占用一整页伪代码。

参数更新与顺序。LSA 每轮依次更新右试探子空间、左试探子空间, 再在小矩阵上提取奇异三元组。平方 NMF 按 $W \rightarrow$ 尺度补偿 $\rightarrow H$ 更新; KL-NMF 按 $H \rightarrow W \rightarrow$ 尺度补偿更新。每个分母都必须使用该子步规定的当前因子, 混用同一轮的新旧矩阵会破坏单调性依据。

判断与停止条件。LSA 同时检查左右奇异残差和投影子空间变化。NMF 同时检查相对目标变化与 KKT 残差; 达到 T_S 或 T_N 只记为预算停止。任一算法出现非有限值、分母退化、目标异常上升或有效秩不足时, 应保留诊断并停止, 不能把异常退出写成收敛。

正确性依据与收敛条件。定理 28.1 给出 LSA 重构正确性; 子空间迭代在初始投影非退化且目标与其余奇异子空间存在谱隙时收敛, 谱隙小时速度下降。定理 28.2 与 28.3 保证 NMF 目标单调且因下界为 0 而目标值收敛, 但不保证因子序列唯一或达到全局最优。

不收敛或退化情形。初始子空间与目标方向正交、目标谱隙过小、NMF 出现数值下溢、零锁定或预算过少时, 算法可能不能在预算内满足残差条件。若直接调用确定性全 SVD, 完成一次分解便停止, 不存在外层训练迭代; 此时应检查数值残差, 而不应虚构迭代收敛条件。

读前自检：复杂度分析：数值实现：截断 SVD 与平方损失 NMF。 数值实现：截断 SVD 与平方损失 NMF 要求先确认“平方损失 NMF 一轮若利用乘法次序，时间为 $O(sk + (m+n)k^2)$ ”；请随后由 $s = \text{nnz}(X)$ 的总成本剥离一次迭代或一次样本因子，用若求解器使用完整稠密中间矩阵，时间和空间上界会相应增加验收。

复杂度分析

训练时间复杂度。 设 $s = \text{nnz}(X)$ ，迭代 SVD 子空间宽度为 ℓ 。LSA 训练一轮矩阵-块乘法需 $O(s\ell)$ ， T_S 轮连同正交化约为 $O(T_S[s\ell + (m+n)\ell^2])$ ；稠密全 SVD 为 $O(mn \min(m, n))$ 量级。平方损失 NMF 一轮若利用乘法次序，时间为 $O(sk + (m+n)k^2)$ ；KL-NMF 只在 $\text{supp}(X)$ 上求比率时为 $O(sk + (m+n)k)$ ；二者稠密主项均为 $O(mnk)$ ， T_N 轮再乘 T_N 。

预测时间复杂度。 这里“预测”指新文本编码。LSA 计算 $U_k^T x$ ，稠密代价 $O(mk)$ ，稀疏代价 $O(\text{nnz}(x)k)$ 。固定 W 为新文本求非负系数，若运行 I 轮，时间为 $O(Imk)$ ，批量 b 篇为 $O(Imbk)$ 。

空间复杂度。 迭代截断 SVD 在训练中要同时保存稀疏 X 、宽度为 ℓ 的子空间块 Q, Z 、小型正交化矩阵以及 $B = Q^T X$ ，峰值总存储为 $O(s + (m+n)\ell + \ell^2)$ ，其中 $n\ell$ 项覆盖 B ；算法结束后若只持久化 (U_k, Σ_k, V_k, Y) ，模型存储才降为 $O((m+n)k + k^2)$ 。仅在另行声明 $\ell = \Theta(k)$ 时，训练峰值中的 ℓ 才能按量级换成 k 。NMF 需 $O(s + (m+n)k + k^2)$ 。KL 更新只在 $\text{supp}(X)$ 上按需计算比率，并用因子边际和计算散度的线性项，因而不必保存完整 $m \times n$ 重构矩阵。

复杂度假设。 上述估计假定 W, H 稠密、 $k \ll \min(m, n)$ 、稀疏乘法按非零元素执行，KL 比率只在 $\text{supp}(X)$ 上求值，并把 T_S, T_N, I 作为外部给定的实际迭代次数；若求解器使用完整稠密中间矩阵，时间和空间上界会相应增加。

读前自检：适用条件与局限：数值实现：截断 SVD 与平方损失 NMF。 固定训练词表后，LSA 允许带符号低秩因子并优化 Frobenius 误差，NMF 要求输入和因子非负；请对同一词-文档矩阵核对符号与损失条件，并据此判定应使用截断 SVD 还是平方损失 NMF。

适用条件与局限性

适用条件。 LSA 适合需要正交低秩压缩、文档相似度或检索表示，且 Frobenius 误差与线性子空间假设合理的语料。NMF 适合输入非负、希望得到加性部件解释的任务；平方损失适合近似同方差连续误差，广义 KL 损失更适合计数强度或相对误差结构。两者都要求固定训练词表、合理权值、足够样本和独立评价。

方法局限

词袋表示丢失词序与否定结构；线性低秩空间可能混合多个含义；LSA 话题含正负载荷，语义解释依赖符号与旋转；NMF 联合目标非凸并受初值影响，因子还存在置换和缩放不唯一性；两种方法都需预先选 k ，且高重构质量不保证检索、聚类或人工语义质量。

读前自检：常见错误与误用边界：数值实现：截断 SVD 与平方损失 NMF。 数值实现：截断 SVD 与平方损失 NMF 依赖“边界框首项禁止在测试集上重新计算词表”；请据此把固定错误“在测试

集上重新计算词表”中的对象、操作与结论按本节定义拆开，指出第一个不满足的定义条件，再把该处改为本节允许的写法，并直接核对改写后的运算或判断有定义，且不再触发“在测试集上重新计算词表”。

常见错误

1. 把文本放在行，却仍使用“ U_k 列是词空间话题”的尺寸解释；
2. 在测试集上重新计算词表、文档频率或归一化统计量，造成数据泄漏；
3. 把 V_k^T 误当成文本坐标，漏掉 Σ_k ；
4. 把 LSA 的负坐标或 NMF 的未归一化系数称为概率；
5. 在 NMF 中同时用旧 W 和旧 H 计算两个更新，却引用顺序块更新的单调性；
6. 用零初始化造成零锁定，或给分母机械加大常数而不检查目标是否仍单调；
7. 只报告目标变化，不报告残差、KKT 条件、多初值差异和停止原因。

读前自检：易混淆概念对比：数值实现：截断 SVD 与平方损失 NMF。 数值实现：截断 SVD 与平方损失 NMF 以“对比表首个数据行是“单词空间 | 稀疏 x_j 与内积或余弦 | 无训练即可计算 | 同义、多义与高维稀疏””为约束；请按列复述“单词空间 | 稀疏 x_j 与内积或余弦 | 无训练即可计算 | 同义、多义与高维稀疏”中的对象、假设与结论，并确认各列均对应首行对象“单词空间”，且未与表中下一行互换。

易混淆概念对比

方法	表示与目标	主要保证	关键边界
单词空间 SVD-LSA	稀疏 x_j 与内积或余弦 $X \approx U_k \Sigma_k V_k^T$	无训练即可计算 无约束秩 k 平方误差全局最优	同义、多义与高维稀疏 坐标可正可负，受异常值影响
平方 NMF KL-NMF	$X \approx WH, W, H \geq 0$ 最小化 $D(X \ WH)$	乘法子步目标不增 相应辅助函数下目标不增	非凸、初值与尺度不唯一 零项、强度模型与数值下溢
PCA	中心化样本的方差最大化	最优正交重构子空间	中心化改变词频零点含义

读前自检：潜在语义分析数值例子。 潜在语义分析数值例子的初值 $W^{(0)}$ 含零元素，并采用先更新 W 、再更新 H 的顺序；请完成题中一整轮平方损失乘法更新，核对零位置保持为零且重构损失不增。

28.6 例题、矩阵分解计算与练习

例题 28.1 (一次平方 NMF 顺序更新). 取

$$X = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}, \quad W^{(0)} = I_2, \quad H^{(0)} = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}.$$

本例故意使用含零元素的 $W^{(0)}$ 来展示零锁定, 适用的是推论 28.1 的固定支持面边界版本, 而不是定理 28.2 的严格正初值假设。本例不执行可选的列归一化, 并保持 W 先于 H 更新; 执行一整轮平方损失乘法更新, 求 $W^{(1)}, H^{(1)}$ 及新损失。

例题 28.1 解答

读题翻译 严格执行一整轮平方损失 NMF 乘法更新: 先由 $W^{(0)}, H^{(0)}$ 得到 $W^{(1)}$, 再用新的 $W^{(1)}$ 更新 H , 并检查零锁定与新损失。

已知与合法条件 $X, W^{(0)}, H^{(0)}$ 均为 2×2 非负矩阵; 不做列归一化, $W^{(0)}$ 含零元, 因此只使用固定支持面版本的非增性质。

为什么想到这个方法 乘法更新是逐元素的“旧值乘分子除分母”; 旧值为零的坐标保持为零, 且 H 子步必须使用刚更新的 $W^{(1)}$ 。

方法选择 先计算 $XH^{(0)T}$ 与 $W^{(0)}H^{(0)}H^{(0)T}$ 得到 $W^{(1)}$; 再计算 $W^{(1)T}X$ 与 $W^{(1)T}W^{(1)}H^{(0)}$ 得到 $H^{(1)}$, 最后重构并比较损失。

推导/计算 W 子步。先计算

$$XH^{(0)T} = \begin{bmatrix} 3 & 3 \\ 3 & 3 \end{bmatrix}, \quad W^{(0)}H^{(0)}H^{(0)T} = \begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix}.$$

与 $W^{(0)}$ 逐元素相乘后, 非对角零元素保持为零, 得到

$$W^{(1)} = \begin{bmatrix} 3/2 & 0 \\ 0 & 3/2 \end{bmatrix}.$$

H 子步。第二个子步使用 $W^{(1)}$:

$$W^{(1)T}X = \begin{bmatrix} 3 & 3/2 \\ 3/2 & 3 \end{bmatrix}, \quad W^{(1)T}W^{(1)}H^{(0)} = \begin{bmatrix} 9/4 & 9/4 \\ 9/4 & 9/4 \end{bmatrix}.$$

所以

$$H^{(1)} = \begin{bmatrix} 4/3 & 2/3 \\ 2/3 & 4/3 \end{bmatrix}, \quad W^{(1)}H^{(1)} = X.$$

新损失 $J_F^{(1)} = 0$ 。

独立核验 初始残差为 $X - W^{(0)}H^{(0)} = \text{diag}(1, 1)$, 故 $J_F^{(0)} = \frac{1}{2}\|X - W^{(0)}H^{(0)}\|_F^2 = 1$; 直接相乘又得 $W^{(1)}H^{(1)} = X$, 所以目标确由 1 降至 0。

结论 $W^{(1)} = \text{diag}(3/2, 3/2)$, $H^{(1)} = \begin{pmatrix} 4/3 & 2/3 \\ 2/3 & 4/3 \end{pmatrix}$, 新损失为 0; 该精确分解仍保留了 $W^{(0)}$ 的零支持, 一般实现应避免无意的零锁定。

本章共 12 道练习。每道题干后立即给出同号解析; 长解析可自然跨页, 续页标题保留题号。

练习 28.1. 给定下列单词 – 文本频数矩阵, 行依次为{airplane, aircraft, computer, apple, fruit, produce}, 列为 $d_1, \dots, d_4$:

$$X = \begin{bmatrix} 2 & 0 & 0 & 0 \\ 0 & 2 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 2 & 3 \\ 0 & 0 & 0 & 1 \\ 1 & 2 & 2 & 1 \end{bmatrix}.$$

取 $k = 2$ 作 SVD-LSA, 给出二维文本坐标的一个数值结果, 并比较降维前后 (d_1, d_2) 与 (d_3, d_4) 的余弦相似度。

练习 28.1 解析

先计算

$$X^T X = \begin{bmatrix} 5 & 2 & 2 & 1 \\ 2 & 8 & 4 & 2 \\ 2 & 4 & 9 & 8 \\ 1 & 2 & 8 & 11 \end{bmatrix}.$$

数值 SVD 的前两个奇异值约为 4.4770, 2.7520。一组二维坐标 $Y = \Sigma_2 V_2^T$ 为

$$Y \approx \begin{bmatrix} -0.7861 & -1.5721 & -2.8586 & -2.9635 \\ 1.0770 & 2.1540 & -0.1045 & -1.3276 \end{bmatrix}.$$

奇异向量整体变号会同步改变某一行坐标, 但不改变重构或余弦。原空间中

$$\cos(x_1, x_2) = \frac{2}{\sqrt{5}\sqrt{8}} \approx 0.3162, \quad \cos(x_3, x_4) = \frac{8}{3\sqrt{11}} \approx 0.8040.$$

二维坐标中, 前两列成正比例, 所以余弦为 1; 后两列余弦约为 0.9269。低秩共现结构把 airplane 与 aircraft 关联起来, 也增强了 apple 相关文本的联系。前两维保留的平方奇异值比例约为 0.8369, 因此这种语义平滑伴随可量化的信息损失。

练习 28.2. 给出广义 KL 损失下 NMF 的完整乘法更新算法: 推导 H 与 W 更新, 写明输入、输出、初始化、顺序、停止、退化处理与返回结果。

练习 28.2 解析

记 $q_{ij} = (WH)_{ij} > 0$ 。固定 W 时, 目标对 $H_{\ell j}$ 的梯度为

$$\frac{\partial D}{\partial H_{\ell j}} = \sum_i w_{i\ell} \left(1 - \frac{X_{ij}}{q_{ij}} \right).$$

定理 28.3 的辅助函数最小化给出

$$H_{\ell j} \leftarrow H_{\ell j} \frac{\sum_i w_{i\ell} X_{ij} / q_{ij}}{\sum_i w_{i\ell}}.$$

练习 28.2 解析 (续)

固定新 H 时同样得到

$$W_{ie} \leftarrow W_{ie} \frac{\sum_j H_{ej} X_{ij} / q_{ij}}{\sum_j H_{ej}}.$$

每轮先更新一块、重算 q ，再更新另一块；辅助函数保证

$$D_{\text{KL}}(X \| W^{(t+1)} H^{(t)}) \leq D_{\text{KL}}(X \| W^{(t)} H^{(t)}),$$

$$D_{\text{KL}}(X \| W^{(t+1)} H^{(t+1)}) \leq D_{\text{KL}}(X \| W^{(t+1)} H^{(t)}).$$

输入为 X, k 、严格正初值、容差与轮数上限；输出为 W, H 、散度与 KKT 轨迹和停止原因。散度相对变化与 KKT 残差同时满足

$$\frac{|D_t - D_{t-1}|}{\max\{1, D_{t-1}\}} \leq \varepsilon_D, \quad r_{\text{KKT}}^{(t)} \leq \varepsilon_K$$

时停止。结构性全零行列应先隔离并保存映射；若 q_{ij} 接近 0、出现非有限值或分母退化，则停止并调整精度或重启正初值，不能继续除法。

练习 28.3. 比较 SVD-LSA 与乘法更新 NMF 的训练时间、新文本编码时间和存储复杂度。分别说明稠密矩阵与 $s = \text{nnz}(X)$ 稀疏矩阵的假设。

练习 28.3 解析

对稠密 $m \times n$ 矩阵，完整 SVD 与 T_s 轮、子空间宽度 ℓ 的截断 SVD 分别为

$$T_{\text{full}} = O(mn \min\{m, n\}),$$

$$T_{\text{trunc, dense}} = O(T_s[mn\ell + (m+n)\ell^2]),$$

$$T_{\text{trunc, sparse}} = O(T_s[s\ell + (m+n)\ell^2]), \quad s = \text{nnz}(X).$$

只有另行假设 $\ell = \Theta(k)$ 时，才能把 ℓ 按量级替换为 k 。新文本 LSA 编码 $U_k^T x$ 的代价为 $O(mk)$ ，稀疏文本为 $O(\text{nnz}(x)k)$ 。

迭代截断 SVD 的训练峰值与持久模型存储为

$$M_{\text{train}} = O(s + (m+n)\ell + \ell^2), \quad M_{\text{model}} = O((m+n)k + k^2).$$

平方损失 NMF 每轮及 T_N 轮代价为

$$T_{\text{NMF, iter}} = O(mnk + (m+n)k^2), \quad T_{\text{NMF, total}} = T_N T_{\text{NMF, iter}}.$$

稀疏平方 NMF 把 mnk 换成 sk ；KL 更新只在 $\text{supp}(X)$ 上求比率时每轮为 $O(sk + (m+n)k)$ 。比较必须同时给出 ℓ, T_s, T_N 、稀疏结构和求解器假设。

练习 28.4. 列出潜在语义分析与主成分分析的相同点和不同点, 重点讨论中心化、矩阵方向、优化目标、文本零值含义和坐标解释。

练习 28.4 解析

PCA 先中心化数据, 求解

$$X_c = X - \bar{x}\mathbf{1}_n^T, \quad \min_{\text{rank}(B) \leq k} \|X_c - B\|_F^2.$$

文本 LSA 通常直接分解非负词频或 TF-IDF 矩阵:

$$X = U\Sigma V^T, \quad X_k = U_k \Sigma_k V_k^T, \quad Y = \Sigma_k V_k^T.$$

两者都用正交低维方向并与截断 SVD 相关, 但 PCA 解释围绕均值的方差, LSA 解释词 - 文本共现; 逐词减均值会把大量文本零值变为负数并改变稀疏语义。只有对同一矩阵采用同一预处理时, 两者才给出相同子空间。

练习 28.5. 三篇文本在两个词上的频数列为 $(2, 0)^T, (0, 1)^T, (1, 1)^T$ 。按本章 TF-IDF 定义计算 X , 并求第三篇文本与前两篇的余弦。

练习 28.5 解析

两个词都出现在两篇文本中, 所以逆文档频率相同, 记 $L = \log(3/2)$ 。三篇文本长度依次为 2, 1, 2, 故

$$X = L \begin{bmatrix} 1 & 0 & 1/2 \\ 0 & 1 & 1/2 \end{bmatrix}.$$

第三列为 $(L/2, L/2)^T$ 。与第一列的余弦为

$$\frac{L^2/2}{L \cdot (L/\sqrt{2})} = \frac{1}{\sqrt{2}},$$

与第二列同样为 $1/\sqrt{2}$ 。共同正比例因子 L 在余弦中抵消, 但在未归一化内积中不会抵消。

练习 28.6. 取 $x = (1, 1, 0)^T$ 、 $z = (2, 0, 0)^T$ 。计算内积和余弦; 把 z 乘 10 后再计算, 说明两种相似度分别保留什么信息, 并指出哪个输入会使余弦没有定义。

练习 28.6 解析

先计算

$$x^T z = 2, \quad \|x\|_2 = \sqrt{2}, \quad \|z\|_2 = 2,$$

故

$$\cos(x, z) = \frac{x^T z}{\|x\|_2 \|z\|_2} = \frac{1}{\sqrt{2}}.$$

把 z 改为 $10z$ 后, 内积变为 20, 而余弦仍为

$$\frac{x^T(10z)}{\|x\|_2 \|10z\|_2} = \frac{1}{\sqrt{2}}.$$

练习 28.6 解析 (续)

内积同时受方向与向量长度影响；余弦只比较方向并消除正比例长度。零向量的范数为 0，使余弦分母为 0，因此没有定义。

练习 28.7. 若 $X \in \mathbb{R}^{5 \times 4}$ 、 $k = 2$ 且 $X \approx TY$ ，写出 T, Y 的维数。对 $R = \text{diag}(2, 3)$ 证明 $(TR)(R^{-1}Y) = TY$ ，并解释这对话题解释的影响。

练习 28.7 解析

维数与尺度变换为

$$T \in \mathbb{R}^{5 \times 2}, \quad Y \in \mathbb{R}^{2 \times 4}, \quad TY \in \mathbb{R}^{5 \times 4}.$$

R 可逆，故

$$(TR)(R^{-1}Y) = T(RR^{-1})Y = TI_2Y = TY.$$

TR 把两个话题方向分别放大 2 倍、3 倍， $R^{-1}Y$ 把对应文本坐标分别缩小到 $1/2, 1/3$ ，重构不变。这说明一般因子分解的列尺度不能由数据唯一识别；比较话题强度前必须采用统一归一化约定。

练习 28.8. 由 $x_j = Xe_j$ 和 $X = U\Sigma V^T$ 推导 $U_k^T x_j = \Sigma_k V_k^T e_j$ ，再写出一个新文本的编码与重构公式以及全部尺寸。

练习 28.8 解析

由 $x_j = Xe_j = U\Sigma V^T e_j$ ，左乘 U_k^T ，

$$U_k^T x_j = U_k^T U \Sigma V^T e_j = \Sigma_k V_k^T e_j.$$

新文本的编码、重构与尺寸链为

$$y_{\text{new}} = U_k^T x_{\text{new}} \in \mathbb{R}^k, \quad (k \times m)(m \times 1) = k \times 1,$$

$$\hat{x}_{\text{new}} = U_k y_{\text{new}} \in \mathbb{R}^m, \quad (m \times k)(k \times 1) = m \times 1.$$

新文本必须使用训练词表和训练权值，否则坐标轴不一致。

练习 28.9. 令 $X = \text{diag}(4, 2, 1)$ 。取 $k = 2$ ，求 U_k, Σ_k, V_k, Y 、重构、Frobenius 误差和保留能量比例。

练习 28.9 解析

可取 $U = V = I_3$ ，奇异值为 4, 2, 1。于是

$$U_2 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}, \quad \Sigma_2 = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}, \quad V_2 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix},$$

$$Y = \Sigma_2 V_2^T = \begin{bmatrix} 4 & 0 & 0 \\ 0 & 2 & 0 \end{bmatrix}, \quad X_2 = U_2 Y = \text{diag}(4, 2, 0).$$

练习 28.9 解析 (续)

Frobenius 误差为 $\|X - X_2\|_F = 1$, 保留能量比例为 $(4^2 + 2^2)/(4^2 + 2^2 + 1^2) = 20/21$ 。

练习 28.10. 对 $W = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{bmatrix}$, $H = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}$, 计算 WH 并按列解释两篇文本。再用 $R = \text{diag}(2, 3)$ 构造另一组非负因子, 验证乘积不变。

练习 28.10 解析

矩阵乘法给出

$$WH = \begin{bmatrix} 2 & 0 \\ 2 & 3 \\ 0 & 3 \end{bmatrix}.$$

第一列是 $2w_1$, 第二列是 $3w_2$ 。令 $R = \text{diag}(2, 3)$, 则

$$W' = WR = \begin{bmatrix} 2 & 0 \\ 2 & 3 \\ 0 & 3 \end{bmatrix}, \quad H' = R^{-1}H = I_2.$$

因此 $W'H' = WH$ 且两因子仍非负。该构造再次表明尺度不唯一; 若要比话题权重, 可先把 W 各列归一化, 再把尺度补偿到 H 对应行。

练习 28.11. 复算例 28.1 的一轮更新; 若误把 H 更新的分母写成 $W^{(0)T}W^{(0)}H^{(0)}$, 求错误结果并说明违反了哪条更新顺序。

练习 28.11 解析

正确顺序在例题中给出 $W^{(1)} = \text{diag}(3/2, 3/2)$ 和 $H^{(1)} = \begin{bmatrix} 4/3 & 2/3 \\ 2/3 & 4/3 \end{bmatrix}$, 乘积等于 X 。题设只把 H 子步的分母误写成旧因子, 因此分子仍为

$$W^{(1)T}X = \begin{bmatrix} 3 & 3/2 \\ 3/2 & 3 \end{bmatrix}, \quad W^{(0)T}W^{(0)}H^{(0)} = H^{(0)}.$$

所以错误更新给

$$H_{\text{err}}^{(1)} = \begin{bmatrix} 3 & 3/2 \\ 3/2 & 3 \end{bmatrix}.$$

此时

$$W^{(1)}H_{\text{err}}^{(1)} = \begin{bmatrix} 9/2 & 9/4 \\ 9/4 & 9/2 \end{bmatrix} \neq X.$$

错误来自第二个子步的分母没有使用最新 $W^{(1)}$, 因而不对应定理中“固定当前另一块后最小化辅助函数”的顺序。

练习 28.12. 某个 NMF 元素在第 0 轮取 $W_{i\ell}^{(0)} = 0$ ，之后所有乘法比率均有限且为正。证明它永远为 0；若该位置梯度为负，解释为何这是错误锁定，并给出两种处理方法。

练习 28.12 解析

乘法更新写成

$$W_{i\ell}^{(t+1)} = W_{i\ell}^{(t)} r_t, \quad 0 < r_t < \infty.$$

由归纳链

$$W_{i\ell}^{(0)} = 0 \implies W_{i\ell}^{(1)} = 0r_0 = 0 \implies \dots \implies W_{i\ell}^{(t)} = 0 \quad (t \geq 0).$$

若边界处 $\partial F / \partial W_{i\ell} < 0$ ，则存在充分小的 $\epsilon > 0$ 使

$$F(W + \epsilon E_{i\ell}, H) < F(W, H),$$

而乘法更新仍不能离开 0，这就是零锁定。可使用严格正初值，或改用投影梯度/主动集方法；仅给分母加常数不能改变 0 乘有限比率仍为 0。

读前自检：本章结论与下一步。 潜在语义分析与非负矩阵分解章末把“词项坐标、文本列、低秩语义子空间与非负因子”收束为“LSA 一次 SVD 后投影”；请把 k 代入对应定义并写出结果类型，再核对“代入结果满足定义域与取值域”且该结果能直接进入章末所述方法。

本章结论与下一步

核心结论： 词项坐标、文本列、低秩语义子空间与非负因子

关键依据： 截断 SVD 给出无约束 Frobenius 最佳秩 k 近似；辅助函数证明 NMF 顺序块更新不增目标

可执行自检： LSA 一次 SVD 后投影；NMF 按固定顺序乘法更新并检查零锁定、残差与双重停止

适用边界： 文本共现需要线性低秩压缩或非负加性主题表示时

下一步： 进入 PLSA；冻结训练词表与 IDF，并根据误差假设区分平方、KL 和概率似然目标

1. 能否从词频和文档频率构造 X ，并解释空文本、零向量和测试统计量泄漏？未通过则回看第 1 节。
2. 能否写出 T, Y, U_k, Σ_k, V_k 的尺寸，从 $U_k^T x_j$ 推出训练与新文本坐标，并证明 LSA 低秩最优性而不把负坐标误称为概率？未通过则回看第 2、3 节和概率解释。
3. 能否分量求出平方损失乘法更新，并说明投影梯度如何避免零锁定？未通过则回看第 4 节；广义 KL 证明属于扩展讨论。
4. 能否分别说明截断 SVD 求解器、平方损失乘法更新与交替投影梯度的输入、更新、停止和退化？未通过则回看第 5 节及“核心替代”框。
5. 能否从正交子空间、非负锥、中心化 PCA 三个角度比较方法，并完成两组来源的 12 道题？未通过则回看第 4、6 节；五项均可独立作答，并能解释一次数值结果的维数、符号、误差与停止原因，才算达到本章学习目标。

第 29 章 概率潜在语义分析

读前自检：本章地图：概率潜在语义分析。 概率潜在语义分析章地图以“从共现计数直达 PLSA 生成模型、EM 与新文档折入”组织内容；请把路线拆成起点、关键工具和终点，并核对三者的输入输出类型能依次衔接。

读前自检：本章可检验学习目标。 概率潜在语义分析目标中的“能从单词 – 文档共现计数建立 PLSA 生成模型与共现模型，并写清全部条件独立和归一化约束”必须可复核；请从单词 – 文档共现计数建立 PLSA 生成模型与共现模型，并写清全部条件独立和归一化约束，所得结果仅在“中间结果逐项包含首目标“能从单词 – 文档共现计数建立 PLSA 生成模型与共现模型，并写清全部条件独立和归一化约束”声明的对象、条件与结论”时通过。

读前自检：最短先修。 概率潜在语义分析的最短先修明确要求“本章需要离散条件概率、全概率公式、Bayes 公式、多项分布、极大似然、Jensen 不等式、Lagrange 乘子、EM 算法、矩阵乘法、奇异值分解与非负矩阵分解”；请把首项“本章需要离散条件概率、全概率公式、Bayes 公式、多项分布、极大似然、Jensen 不等式、Lagrange 乘子、EM 算法、矩阵乘法、奇异值分解与非负矩阵分解”中的第一个先修对象写成定义域 – 运算 – 输出三元组，并以“该三元组逐项满足首项“本章需要离散条件概率、全概率公式、Bayes 公式、多项分布、极大似然、Jensen 不等式、Lagrange 乘子、EM 算法、矩阵乘法、奇异值分解与非负矩阵分解”的对象类型与成立条件”判断能否进入本章。

读前自检：先修自检。 概率潜在语义分析先修自检固定核验“给定联合分布，能否用 Bayes 公式计算 $P(Z = z_k | W = w_i, D = d_j)$ ”；请给定联合分布，实际用 Bayes 公式计算 $P(Z = z_k | W = w_i, D = d_j)$ 并写出中间结果，再按“ $P(Z = z_k | W = w_i, D = d_j)$ 的计算或证明结果满足首项所列等式、定义域或判断”明确判为通过或失败。

读前自检：依赖路线。 概率潜在语义分析依赖链含“单词 – 文档共现计数 → 潜在主题混合 → PLSA 生成模型”到“条件独立 → 联合概率分解 → 生成模型与共现模型等价”这一跳；请固定写出前者输出类型与后者输入类型，并核对两者相同或存在正文声明的转换。

本章地图

核心问题：怎样用主题单纯形解释单词 – 文档共现并估计概率因子

可检验学习目标：

- 能从单词 – 文档共现计数建立 PLSA 生成模型与共现模型，并写清全部条件独立和归一化约束；
- 能从观测对数似然逐行构造隐主题后验、辅助函数和两组 $\mathbf{M}$ 步更新，核对每个分母；
- 能证明两种模型参数化的等价性与 EM 似然单调不降性质，同时说明其成立条件和退化边界；
- 能用单纯形、概率矩阵分解和图模型三种视角解释主题、文档与单词之间的关系；
- 能完整执行含初始化、异常处理、双重停止准则和诊断输出的 PLSA 训练与新文档折入流程；
- 能比较 PLSA、LSA 与 NMF 的目标、约束和泛化方式，并估算训练、预测及存储复杂度。

最短先修：本章需要离散条件概率、全概率公式、Bayes 公式、多项分布、极大似然、Jensen 不等式、Lagrange 乘子、EM 算法、矩阵乘法、奇异值分解与非负矩阵分解。应能区分“每个观测对有一个未观测主题”与“整篇文档只有一个主题”，并熟悉概率向量的非负与归一化约束。

依赖路线：单词 - 文档共现计数 → 潜在主题混合 → PLSA 生成模型；条件独立 → 联合概率分解 → 生成模型与共现模型等价；观测对数似然 → 主题后验 → EM 辅助函数；单纯形约束 → Lagrange 乘子 → 两组规范化 M 步；概率矩阵分解 → LSA 与 NMF 对比 → 适用边界与新文档折入。

完成标准与返回：正计数位置概率为零时返回节 29.3；M 步分母或新文档处理不清时回看节 29.4、29.5

数据方向桥：PLSA 的词 - 文档计数

本章计数矩阵 $N = [n_{ij}] \in \mathbb{N}_0^{M \times N}$ 把词放在行、文档放在列；第 j 列的和是文档 d_j 的词元数。按全书默认行样本表示同一语料时，

$$X_{\text{doc,row}} = N^T \in \mathbb{N}_0^{N \times M}.$$

例如 $M = 1000, N = 200$ 时，PLSA 公式使用 1000×200 ，行样本接口使用 200×1000 。两者的计数总和相同，但行、列归一化的概率含义不能互换。

本章符号表

符号	类型、维数或范围	读法与作用
M, N, K	$\mathbb{N}_+$	单词数、文档数与预设主题数
W, D, Z	有限集合	$W = \{w_i\}_{i=1}^M, D = \{d_j\}_{j=1}^N, Z = \{z_k\}_{k=1}^K$
w, d, z	离散随机变量	取值分别位于 W, D, Z ； z 为隐变量
n_{ij}	$\mathbb{N}_0$	$n_{ij} = n(w_i, d_j)$ ，单词 - 文档对的共现次数
$\mathbf{N}_{\text{cnt}}$	$\mathbb{N}_0^{M \times N}$	$[\mathbf{N}_{\text{cnt}}]_{ij} = n_{ij}$ ，稀疏单词 - 文档计数矩阵
c_j, C	$\mathbb{N}_0, \mathbb{N}_+$	$c_j = n(d_j) = \sum_i n_{ij}$ ， $C = \sum_j c_j$ 为总词元数
π_j	$[0, 1]$	$\pi_j = P(d_j)$ ，本文取经验值 c_j/C
ϕ_{ik}	$[0, 1]$	$\phi_{ik} = P(w_i z_k)$ ，主题 k 的单词分布
θ_{kj}	$[0, 1]$	$\theta_{kj} = P(z_k d_j)$ ，文档 j 的主题混合
γ_{ijk}	$[0, 1]$	$\gamma_{ijk} = P(z_k w_i, d_j)$ ，E 步责任度
ρ_k, ψ_{jk}	$[0, 1]$	共现参数 $P(z_k)$ 与 $P(d_j z_k)$
Φ, Θ	$\mathbb{R}_+^{M \times K}, \mathbb{R}_+^{K \times N}$	分别以 ϕ_{ik} 和 θ_{kj} 为元素的列随机矩阵
X'	$\mathbb{R}_+^{M \times N}$	$X'_{ij} = P(w_i, d_j)$ 的联合概率矩阵
ℓ, Q'	$\mathbb{R} \cup \{-\infty\}$	观测对数似然与去除常数后的 EM 辅助函数
R, T, T_*	$\mathbb{N}_0$	非零共现对数、训练迭代数与新文档折入迭代数

29.1 潜在主题与混合表示

词项频率矩阵把文档表示为高维计数列，却没有显式回答“哪些词因共同语义而一起出现”。若直接为每个 (w_i, d_j) 配置独立概率，需要 $MN - 1$ 个自由度；PLSA 引入 K 个潜在主题，把每篇文档表示成主题分布，再把每个主题表示成单词分布。当 $K \ll \min(M, N)$ 时，这一结构同时提供压缩、软聚类和概率解释。

一篇文档不必只属于一个主题。向量 $\theta_{:j} = (\theta_{1j}, \dots, \theta_{Kj})^T$ 位于 $(K-1)$ 维概率单纯形中，表示文档 d_j 对各主题的混合权重；向量 $\phi_{:k}$ 位于 $(M-1)$ 维单词单纯形中，表示主题 z_k 的词概率。两层混合给出

$$P(w_i | d_j) = \sum_{k=1}^K \phi_{ik} \theta_{kj}.$$

该式的左侧是文档在词单纯形中的点，右侧是 K 个主题点的凸组合。

读前自检：概率潜在语义分析。 PLSA 的观测为单词 w 与文档指标 d ，隐变量为主题 z ；请写出 $P(w_i | d_j) = \sum_k \phi_{ik} \theta_{kj}$ ，逐列核对 Φ, Θ 非负归一并得到词概率分布。

概率潜在语义分析 (probabilistic latent semantic analysis, 本文统一简称 PLSA；PLSI 仅作为历史检索别名) 是面向共现数据的无监督潜变量模型。观测变量是单词 w 与文档指标 d ，隐变量是主题 z 。它直接最大化训练文档共现数据的似然，不为文档之外的协变量建模，也不给新文档预先规定主题先验。

读前自检：概率潜在语义分析模型。 PLSA 生成模型要求 π 、每列 $\phi_{:k}$ 和每列 $\theta_{:j}$ 归一；请对 $P(w_i, d_j, z_k) = \pi_j \theta_{kj} \phi_{ik}$ 依次对 i, k, j 求和，核对总质量为 1。

读前自检：PLSA 生成模型。 PLSA 生成一篇固定文档 d_j 的词元时先取 $z \sim \theta_{:j}$ 再取 $w \sim \phi_{:z}$ ；请边缘化 z 得到 $P(w_i | d_j)$ ，核对对 i 求和为 1 且同一文档可混合多个主题。

定义 29.1 (PLSA 生成模型). 设 $\pi = (\pi_1, \dots, \pi_N)$ 是文档分布， $\Phi = [\phi_{ik}]$ 和 $\Theta = [\theta_{kj}]$ 满足

$$\pi_j \geq 0, \quad \sum_j \pi_j = 1; \quad \phi_{ik} \geq 0, \quad \sum_i \phi_{ik} = 1; \quad \theta_{kj} \geq 0, \quad \sum_k \theta_{kj} = 1.$$

生成一个单词 - 文档观测对时，先取 $d \sim P(d)$ ，再取 $z \sim P(z | d)$ ，最后取 $w \sim P(w | z)$ 。给定 z 后， w 与 d 条件独立，因而

$$P(w_i, d_j, z_k) = \pi_j \theta_{kj} \phi_{ik}, \quad P(w_i, d_j) = \pi_j \sum_{k=1}^K \phi_{ik} \theta_{kj}.$$

读前自检：易混淆概念对比：潜在主题与混合表示。 潜在主题与混合表示依赖“联合词元视角：一次观测是 $(W, D) \in \{w_1, \dots, w_M\} \times \{d_1, \dots, d_N\}$ ”；请据此按表格顺序核对潜在主题与混合表示对比表的首个数据行，并直接核对潜在主题与混合表示首行两端的对象、条件与不可互换项逐列一致。

易混淆概念对比

两个样本空间，不可混写。

1. **联合词元视角**：一次观测是 $(W, D) \in \{w_1, \dots, w_M\} \times \{d_1, \dots, d_N\}$ ，在整个语料的 C 个词元上归一化。此时

$$P(D = d_j) = \pi_j = \frac{c_j}{C}, \quad P(W = w_i, D = d_j) = \pi_j \sum_k \phi_{ik} \theta_{kj},$$

且归一化对象是所有 (i, j) ： $\sum_{i,j} P(w_i, d_j) = 1$ 。

2. **给定文档视角**：先把 d_j 视为固定条件，样本空间只剩该文档的词元位置或词类型。此时

$$P(W = w_i | D = d_j) = \sum_k \phi_{ik} \theta_{kj}, \quad \sum_i P(w_i | d_j) = 1,$$

公式中不再抽样 D ，也不需要把 π_j 乘入条件似然。两种视角由 $P(w_i, d_j) = \pi_j P(w_i | d_j)$ 连接； $\pi_j = c_j/C$ 只属于联合视角。

主题不是预先给定的词表标签，而是通过共现模式估计的概率分布。若两个词在相近文档中反复出现，似然会倾向于把它们放入相同或相邻的主题分布；若一篇文档同时包含多组词，其 $\theta_{:j}$ 会分配给多个主题。主题编号可以整体置换，所以编号本身没有语义。

模型。在计数表示下，数据为 $\mathbf{N}_{\text{cnt}} = [n_{ij}]_{M \times N}$ 。把每个词元看作一次独立抽取时，参数相关的似然为

$$P(\mathbf{N}_{\text{cnt}} | \pi, \Phi, \Theta) \propto \prod_{i=1}^M \prod_{j=1}^N \left[\pi_j \sum_{k=1}^K \phi_{ik} \theta_{kj} \right]^{n_{ij}}.$$

若把 $\mathbf{N}_{\text{cnt}}$ 解释为无序多项计数，完整似然还含多项系数；该系数不依赖参数，不改变极大似然解。

学习策略。通常固定 $\pi_j = c_j/C$ ，以 EM 估计 Φ 和 Θ 。主题数 K 、初始化、停止容差与空主题处理规则都属于训练配置。由于目标非凸，应使用多组可复现初值，按训练外的验证准则或预先约定的模型选择准则比较结果，而不能把一次局部解当作唯一主题结构。

贯穿例：文档—词项矩阵小例

本章角色：把同一非负整数计数表归一化为经验条件分布或联合分布，再用 PLSA 主题混合逼近。

词项为行、文档为列，精确沿用

$$\mathbf{X} = \begin{bmatrix} 2 & 0 & 1 \\ 1 & 2 & 0 \\ 0 & 1 & 3 \end{bmatrix}.$$

文档词元数为 $(N_1, N_2, N_3) = (3, 3, 4)$ ，总计数为 10。因此每列都非空，可定义经验条件分布

$$\hat{p}(w_i | d_j) = \frac{X_{ij}}{N_j},$$

也可定义经验联合分布 $\hat{p}(w_i, d_j) = X_{ij}/10$ 。本章用 $\sum_k p(w_i | z_k) p(z_k | d_j)$ 拟合前者，或用等价共现参数化拟合后者；非负整数计数、正列和与正总量满足似然和归一化的定义域，正计

数位置还需由模型提供正概率通路。上一站见 **NMF 对同一计数的非负分解**；下一站见 **LDA 为同一计数加入 Dirichlet 随机层**。

读前自检：PLSA 生成模型。 PLSA 联合生成视角还先按 $\pi_j = c_j/C$ 抽取文档；请把它乘入 $P(w_i | d_j)$ 得到 $P(w_i, d_j)$ ，核对对所有 (i, j) 求和为 1，并与固定文档的条件视角区分。

29.2 PLSA 生成过程与模型

对长度为 L_j 的文档 d_j ，固定文档指标后重复 L_j 次“主题 – 单词”抽取。文档长度不必相等； $\pi_j = c_j/C$ 只是把整个语料中的词元归属到文档的经验比例。每个词元拥有自己的隐主题，因此同一文档能够呈现多个主题。




图 29.1 PLSA 生成图：文档决定主题混合，主题决定单词分布；给定主题后单词与文档条件独立

图 29.1 中的箭头对应联合分解 $P(d)P(z | d)P(w | z)$ 。外层文档选择与内层词元重复共同产生单词 – 文档共现计数。

另一种参数化先取 $z \sim \rho$ ，再在给定 z 时独立抽取 $w \sim \phi_{:z}$ 和 $d \sim \psi_{:z}$ ：

$$P(w_i, d_j) = \sum_{k=1}^K \rho_k \phi_{ik} \psi_{jk}, \quad P(w_i, d_j | z_k) = \phi_{ik} \psi_{jk}.$$

其中 $\rho_k = P(z_k)$ ， $\psi_{jk} = P(d_j | z_k)$ 。它强调联合共现矩阵的对称分解；生成参数化则强调“给定文档生成主题和单词”的非对称过程。

定理 29.1 (生成模型与共现模型的等价性) 当 $\pi_j > 0$ 时，生成参数 $\pi_j, \theta_{kj}, \phi_{ik}$ 与共现参数 $\rho_k, \psi_{jk}, \phi_{ik}$ 表示同一个 $P(w_i, d_j)$ 。允许零质量主题时，零质量主题上的条件分布不可识别，但不影响联合分布。

读前自检：证明：生成模型与共现模型的等价性。 先锁定生成模型与共现模型的等价性的条件“从生成参数出发”：把 ρ_k 用到的关键定义展开并完成下一步变形，所得结果应满足对 $\pi_j > 0$ 定义 $\theta_{kj} = \rho_k \psi_{jk} / \pi_j$ 。

证明. 从生成参数出发, 定义

$$\rho_k = \sum_{j=1}^N \pi_j \theta_{kj}, \quad \psi_{jk} = \frac{\pi_j \theta_{kj}}{\rho_k} \quad (\rho_k > 0).$$

归一化给出 $\sum_k \rho_k = 1$ 与 $\sum_j \psi_{jk} = 1$, 并且

$$\sum_k \rho_k \phi_{ik} \psi_{jk} = \sum_k \phi_{ik} \pi_j \theta_{kj} = \pi_j \sum_k \phi_{ik} \theta_{kj}.$$

若 $\rho_k = 0$, 该主题对联合分布的贡献为零, $\psi_{:k}$ 可任取概率向量。

反向从共现参数出发, 令 $\pi_j = \sum_k \rho_k \psi_{jk}$ 。对 $\pi_j > 0$ 定义 $\theta_{kj} = \rho_k \psi_{jk} / \pi_j$, 则 $\sum_k \theta_{kj} = 1$, 代回生成模型得到同一联合分布。若 $\pi_j = 0$, 该文档从联合分布中不可观测, 其主题混合无法由数据识别。两种参数化由此在正质量部分等价。□

29.3 似然函数与隐变量

固定经验文档概率 π_j 后, 参数相关的观测对数似然写为

$$\ell(\Phi, \Theta) = \sum_{i=1}^M \sum_{j=1}^N n_{ij} \log \left(\sum_{k=1}^K \phi_{ik} \theta_{kj} \right).$$

和式内部混合了未观测主题, 无法把 Φ 与 Θ 分开优化。为每个非零共现对引入责任度

$$\gamma_{ijk} = P(z_k | w_i, d_j) = \frac{\phi_{ik} \theta_{kj}}{\sum_{h=1}^K \phi_{ih} \theta_{hj}},$$

其分母是模型给文档 d_j 中单词 w_i 的概率。严格正初始化使第一次 E 步分母为正; 后续每轮仍须在所有 $n_{ij} > 0$ 的位置核对该分母, 因为边界更新或结构性零可能使正性条件失效。

完整数据可以理解为每个词元还附有主题标记。对这些标记取条件期望, 并删除固定 π_j 项, 得到

$$Q'(\Phi, \Theta | \Phi^{(t)}, \Theta^{(t)}) = \sum_{i,j} n_{ij} \sum_{k=1}^K \gamma_{ijk}^{(t)} (\log \phi_{ik} + \log \theta_{kj}).$$

这时 Φ 与 Θ 在求和中分离, M 步可在各自单纯形上求约束极大值。

学习算法概览. EM 交替执行: E 步以当前参数计算 γ_{ijk} ; M 步把责任度加权计数分别按主题和文档归一化。一次 E 步不会改变参数, 一次 M 步不会重新计算旧责任度, 更新顺序不能交换或混用两个迭代时刻。

读前自检: PLSA 算法. PLSA 的 E 步对每个 $n_{ij} > 0$ 计算 $\gamma_{ijk} = \phi_{ik} \theta_{kj} / \sum_h \phi_{ih} \theta_{hj}$; 请对 k 求和核为 1, 再把责任度加权词计数按主题归一得到新 $\phi_{:k}$ 。

读前自检: PLSA 参数估计的 EM 算法. PLSA 参数估计的 M 步用 $b_{kj} = \sum_i n_{ij} \gamma_{ijk}$ 更新 $\theta_{kj} = b_{kj} / c_j$; 请对 k 求和, 核为 $c_j > 0$ 时列归一, 而 $c_j = 0$ 时该文档混合不可由训练似然识别。

29.4 EM 参数估计

阅读目标：用主题责任度拆开对数和，再在两组概率单纯形上归一化期望计数。

对象：共现计数 n_{ij} 、主题责任度 γ_{ijk} 、主题 - 词分布 Φ 与文档 - 主题分布 Θ 。

合法条件：只对 $n_{ij} > 0$ 的共现对计算；其模型概率为正；每列参数位于相应概率单纯形。

第一步：先对 $\log \sum_k \phi_{ik} \theta_{kj}$ 引入当前责任度并应用 Jensen 不等式。

推导目标

从观测对数似然出发，构造可分离的 EM 下界，并在两组概率单纯形约束下推出责任度、主题 - 词分布和文档 - 主题分布的闭式更新。

推导准备

记旧参数为 $(\Phi^{(t)}, \Theta^{(t)})$ 。只对 $n_{ij} > 0$ 的共现对计算责任度。假设这些共现对的模型概率均为正，并约定 $0 \log 0 = 0$ 。定义期望主题计数

$$a_{ik} = \sum_j n_{ij} \gamma_{ijk}^{(t)}, \quad b_{kj} = \sum_i n_{ij} \gamma_{ijk}^{(t)}, \quad A_k = \sum_i a_{ik}.$$

推导第 1 步：由 Bayes 公式完成 E 步。 给定 (w_i, d_j) ，文档概率 π_j 在分子、分母中相消：

$$\begin{aligned} \gamma_{ijk}^{(t)} &= \frac{P(w_i, d_j, z_k | \Phi^{(t)}, \Theta^{(t)})}{P(w_i, d_j | \Phi^{(t)}, \Theta^{(t)})} \\ &= \frac{\pi_j \phi_{ik}^{(t)} \theta_{kj}^{(t)}}{\pi_j \sum_{h=1}^K \phi_{ih}^{(t)} \theta_{hj}^{(t)}} \\ &= \frac{\phi_{ik}^{(t)} \theta_{kj}^{(t)}}{\sum_{h=1}^K \phi_{ih}^{(t)} \theta_{hj}^{(t)}}. \end{aligned}$$

因此 $\gamma_{ijk}^{(t)} \geq 0$ 且 $\sum_k \gamma_{ijk}^{(t)} = 1$ 。

推导第 2 步：在主题 - 词单纯形上更新 Φ 。 固定 Θ 后，对每个主题 k 求

$$\max_{\phi_{:k}} \sum_i a_{ik} \log \phi_{ik} \quad \text{s.t.} \quad \sum_i \phi_{ik} = 1, \phi_{ik} \geq 0.$$

Lagrange 函数为 $\mathcal{L}_k = \sum_i a_{ik} \log \phi_{ik} + \tau_k (1 - \sum_i \phi_{ik})$ 。对正质量坐标求导，

$$\frac{a_{ik}}{\phi_{ik}} - \tau_k = 0 \implies \phi_{ik} = \frac{a_{ik}}{\tau_k}.$$

对 i 求和并用归一化约束得到 $\tau_k = A_k$, 从而

$$\phi_{ik}^{(t+1)} = \frac{\sum_{j=1}^N n_{ij} \gamma_{ijk}^{(t)}}{\sum_{m=1}^M \sum_{j=1}^N n_{mj} \gamma_{mjk}^{(t)}}.$$

当 $A_k = 0$ 时, 该主题没有期望计数, 公式无定义, 必须按预先规则删去或重新初始化该主题。

推导第3步: 在文档-主题单纯形上更新 Θ 。 对每个文档 j 求

$$\max_{\theta_{:j}} \sum_k b_{kj} \log \theta_{kj} \quad \text{s.t.} \quad \sum_k \theta_{kj} = 1, \theta_{kj} \geq 0.$$

同一约束极值计算给出 $\theta_{kj} = b_{kj} / \sum_h b_{hj}$ 。利用 $\sum_h \gamma_{ijh}^{(t)} = 1$,

$$\sum_h b_{hj} = \sum_i n_{ij} \sum_h \gamma_{ijh}^{(t)} = \sum_i n_{ij} = c_j,$$

故

$$\theta_{kj}^{(t+1)} = \frac{\sum_{i=1}^M n_{ij} \gamma_{ijk}^{(t)}}{c_j}.$$

当 $c_j = 0$ 时, 训练数据不含该文档的词元, $\theta_{:j}$ 不可估计, 应移除该空文档或明确指定外部先验。

以上两个 M 步公式的适用域必须分开: $A_k > 0$ 时主题列由期望计数唯一归一化, $A_k = 0$ 时该主题列不被 Q' 识别; $c_j > 0$ 时文档列由词元责任度唯一归一化, $c_j = 0$ 时该文档列不被训练似然识别。删除、重置或加 Dirichlet 伪计数是不同的外部建模选择, 不能伪装成同一条无条件闭式更新。

命题 29.1 (EM 似然单调性) 若 E 步分母为正, M 步精确极大化 Q' 且各更新保持概率约束, 则每轮 PLSA EM 满足 $\ell(\Phi^{(t+1)}, \Theta^{(t+1)}) \geq \ell(\Phi^{(t)}, \Theta^{(t)})$ 。该性质不保证到达全局最大值。

读前自检: 证明: EM 似然单调性。 PLSA 的 EM 单调性要求 E 步分母为正、 M 步精确提高 Q' 且概率约束保持; 请在旧后验正支撑上写出 Jensen 下界, 核对旧参数处取等、新参数提高 Q' 后观测似然不降。

证明. 对每个 $n_{ij} > 0$, 令 $I_{ij}^{(t)} = \{k : \gamma_{ijk}^{(t)} > 0\}$; 零责任度项按 $0 \log 0 = 0$ 解释, 不写成除以零的比值。在旧后验的正支撑上应用 Jensen 不等式:

$$\log \sum_k \phi_{ik} \theta_{kj} \geq \log \sum_{k \in I_{ij}^{(t)}} \phi_{ik} \theta_{kj} = \log \sum_{k \in I_{ij}^{(t)}} \gamma_{ijk}^{(t)} \frac{\phi_{ik} \theta_{kj}}{\gamma_{ijk}^{(t)}} \geq \sum_{k \in I_{ij}^{(t)}} \gamma_{ijk}^{(t)} \log \frac{\phi_{ik} \theta_{kj}}{\gamma_{ijk}^{(t)}}.$$

旧后验使该下界在旧参数处取等号。 M 步提高其中与参数有关的 Q' , 熵项 $-\sum_{i,j,k} n_{ij} \gamma_{ijk}^{(t)} \log \gamma_{ijk}^{(t)}$ 保持不变, 所以新参数处的观测似然不低于旧参数处。若 M 步只近似求解, 则必须另行检查下界或观测似然是否提高。□

读前自检：几何解释：每个 k 是 $(M-1)$ 维单词单纯形中的主题点。PLSA 数值例给出 $\theta_{:j} = (0.6, 0.4)^T$ 及词概率 $(0.2, 0.7)$ ；请算 $P(w_i | d_j) = 0.4$ 和两主题后验，核对责任度为 $(0.3, 0.7)$ 且和为 1。

几何理解

几何解释。每个 $\phi_{:k}$ 是 $(M-1)$ 维单词单纯形中的主题点。文档分布 $P(w | d_j) = \Phi \theta_{:j}$ 是这些主题点的凸组合，因此全部训练文档都落在由主题点张成的凸包中。 $K=1$ 时凸包退化为一点； $K=2$ 时为线段；主题点线性相关或重复时，有效维数低于 $K-1$ 。

概率解释

责任度 γ_{ijk} 不是“单词 w_i 永远属于主题 k ”的概率，而是给定单词与文档后的局部后验。同一个词在不同文档中可由不同主题解释。 Φ 刻画主题的词分布， Θ 刻画训练文档的主题分布，二者必须与后验责任度分开。

优化解释

优化解释。固定经验 π_j 时，PLSA 等价于在列随机约束下最小化经验条件分布与 $\Phi \Theta$ 之间的加权 KL 散度。目标对 Φ 和 Θ 分别具有较好结构，但对二者联合非凸；主题置换、重复主题和边界零概率都会造成非唯一解。




图 29.2 三个单词维度中的主题单纯形：文档分布是主题点按 $\theta_{:j}$ 形成的凸组合

图 29.2 把外层三角形表示为单词单纯形，把蓝色三角形表示为主题凸包。文档点的位置由 $\theta_{:j}$ 决定；不同参数可以给出相同文档点，说明潜在表示不必唯一。

小型数值例子。设某文档只有两个主题， $\theta_{:j} = (0.6, 0.4)^T$ ；某单词在两主题下的概率为 0.2 与 0.7。则 $P(w_i | d_j) = 0.2 \times 0.6 + 0.7 \times 0.4 = 0.4$ 。若观察到该词，后验责任度为

$$P(z_1 | w_i, d_j) = \frac{0.2 \times 0.6}{0.4} = 0.3, \quad P(z_2 | w_i, d_j) = 0.7.$$

先验主题权重为 $(0.6, 0.4)$ ，观察到更偏向第二主题的词后，后验转为 $(0.3, 0.7)$ 。

算法所需量与计算结果。计算需要稀疏共现计数 $\mathbf{N}_{\text{cnt}} = [n_{ij}]$ 、主题数 K 、最大迭代数、似然与参数容差、正初始化规则和退化处理规则。完成后得到 $\hat{\Phi}, \hat{\Theta}$ 、经验 $\hat{\pi}$ 、似然轨迹、迭代次数、停止原因与数值诊断。

参数含义。 K 控制主题容量； T_{max} 限制计算预算； ε_{ℓ} 控制相对似然增量； ε_p 控制参数最大变化； ε_0 只用于标记正概率过小所带来的浮点风险，而不能把数学上仍为正的的概率改判为“无定义”。多个初值的数量和随机种子也必须记录。

初始化。令 $\Phi^{(0)}$ 与 $\Theta^{(0)}$ 各列严格为正并归一化。可以使用固定种子的正随机初值或带小正扰动的启发式初值。若两主题列完全相同，EM 可能保持对称而不能分离主题；若初值含结构性零，部分词 - 主题通路可能永久关闭。

更新顺序与判断条件。每轮先用同一组旧参数计算全部责任度，再累加期望计数，随后同时生成新 Φ 和新 Θ 。不得在 E 步扫描中把刚更新的一列混入其余责任度。每轮判断 E 步分母、主题质量、概率归一化、似然变化和参数变化。

停止条件。在完成至少一轮更新后，同时满足

$$\delta_{\ell}^{(t)} = \frac{|\ell^{(t+1)} - \ell^{(t)}|}{1 + |\ell^{(t)}|} \leq \varepsilon_{\ell}, \quad \delta_p^{(t)} = \max\{\|\Phi^{(t+1)} - \Phi^{(t)}\|_{\infty}, \|\Theta^{(t+1)} - \Theta^{(t)}\|_{\infty}\} \leq \varepsilon_p$$

时停止。这个阈值事件只记为 `numerical_failure`，因为它没有给出参数到某个极限点的数学证书；达到 T_{max} 而上述准则仍未满足时，返回最后有效结果与 `budget_stop`。

数学性质与实现停止的区别。在每个观测对的模型概率为正、 M 步精确求解且数值计算保持归一化时，观测似然单调不降并受上界约束，所以似然值序列在理论上收敛。参数序列仍可能在等价主题、平坦方向或边界附近不唯一；因此有限精度下的双阈值只触发 `numerical_failure`。实现必须另外报告逐轮似然是否满足 $\ell^{(t+1)} \geq \ell^{(t)} - \varepsilon_{\text{mono}}$ ，不能把“小变化”改名为数学收敛。

读前自检：稀疏共现计数上的 PLSA EM 训练：执行契约。稀疏共现计数上的 PLSA EM 训练输入“稀疏非负词 - 文档计数、维数 M, N, K 、严格正列随机初值、轮预算 T_{max} 、双停止容差与数值容差”，条件“维数为正、计数有限非负且总量正，初值严格正并逐列归一， $T_{\text{max}} \in \mathbb{N}_0$ 且容差合法”；请执行“责任度、主题质量、列归一、似然有限性和单调门禁全部通过后才原子提交整轮，并增加 t_{done} ”，以“似然相对变化与参数变化双证书、轮预算耗尽或首次失败时停止”判停。

稀疏共现计数上的 PLSA EM 训练：五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 29.1: 稀疏共现计数上的 PLSA EM 训练

输入: $n_{ij} \geq 0$ 的非零项列表; M, N, K ; $T_{\max}$; $\varepsilon_\ell, \varepsilon_p, \varepsilon_0$; 严格正的列随机初值

输出: 最后合法参数与似然; $t_{\text{done}}, z_{\text{done}}, k_{\text{done}}$; **status** 与诊断

- 1 核验维数、计数、初值、预算和容差; 失败则返回空结果、计数 0、**invalid_input** 及字段诊断
- 2 计算 $c_j = \sum_i n_{ij}$, $C = \sum_j c_j$; 若 $C = 0$, 返回空结果、**invalid_input** 及零观测诊断
- 3 保留 $c_j > 0$ 的文档并形成 $\hat{\pi}_j = c_j/C$; 置 $t_{\text{done}} = z_{\text{done}} = k_{\text{done}} = 0$
- 4 复制 $(\hat{\Phi}, \hat{\Theta})$ 为严格正初值, 以 log-sum-exp 计算 $\hat{\ell}$
- 5 若任一正计数对零支撑或初始量非有限, 返回初值占位、**numerical_failure** 及初始化支撑诊断
- 6 **当** $t_{\text{done}} < T_{\max}$ **执行**
- 7 清零临时期望计数 a^+, b^+
- 8 **对每个** $n_{ij} > 0$ **依次执行**
- 9 以 $\hat{\Phi}, \hat{\Theta}$ 和 log-sum-exp 形成完整 γ_{ijk}^+ ; 若零支撑或非有限, 返回上一合法参数、**numerical_failure** 及 $(t_{\text{done}} + 1, i, j)$ 诊断; 否则累加临时计数并增加 z_{done}
- 10 **结束**
- 11 **对** $k \leftarrow 1$ **至** K **执行**
- 12 形成 $A_k^+ = \sum_i a_{ik}^+$; 若不正或非有限, 返回上一合法参数、**numerical_failure** 及空主题诊断;
 否则形成 Φ_k^+ 并增加 k_{done}
- 13 **结束**
- 14 由 b^+, c 同时形成 Θ^+ , 并以 log-sum-exp 形成 $\ell^+, \delta_\ell^+, \delta_p^+$
- 15 若候选非有限、不归一或 $\ell^+ < \hat{\ell}$ 且下降超过舍入容差, 返回上一合法参数、**numerical_failure** 及 M 步/似然诊断
- 16 原子提交 $(\hat{\Phi}, \hat{\Theta}, \hat{\ell}) \leftarrow (\Phi^+, \Theta^+, \ell^+)$ 并增加 t_{done}
- 17 若 $\delta_\ell^+ \leq \varepsilon_\ell$ 且 $\delta_p^+ \leq \varepsilon_p$, 返回最后合法参数、**numerical_failure** 及双阈值/似然单调性诊断
- 18 **结束**
- 19 返回最后合法参数、实际计数、**budget_stop** 及“轮预算耗尽、双证书未满足”最终诊断

算法实现说明: 核心四步是 E 步责任度、M 步主题/文档分布、整轮似然核对和停止; 稀疏计数、空主题与失败状态属于稳健实现细节 完整 C1-C14 契约

固定主题 – 词分布的新文档折入: 五步阅读

输入。 写出数据对象、固定参数与必须成立的条件。

初始化。 标明主状态、计数器和第一个合法状态。

核心更新。 只手算一次从旧状态到候选状态的更新, 并指出何时提交。

数学停止。 写出能直接核验的停止证书; 预算耗尽不等同于收敛。

输出。 列出返回对象、实际计数、中心状态和用于复核的诊断。

折入算法最大化固定 $\hat{\Phi}$ 下的独立目标

$$\ell_*(\theta_*) = \sum_{i: n_{i*} > 0} n_{i*} \log \left(\sum_{k=1}^K \hat{\phi}_{ik} \theta_{k*} \right), \quad \theta_* \in \Delta_{K-1},$$

不修改训练主题, 也不借用某篇训练文档的 θ 。其每轮时间为 $O(R_*K)$ 、工作空间为 $O(K)$ (另计稀疏计数)。

返回结果与正确性依据。 算法返回的每个 $\phi_{:k}$ 和 $\theta_{:,j}$ 都应非负且和为 1。E 步是当前参数下的精确条件分布, M 步分别极大化两个单纯形上的 Q' ; 命题 29.1 给出似然单调性的正确性依据。还应复算 $\Phi\Theta$ 、似然和列和, 而不能只检查迭代次数。

异常与退化。 主要异常包括空语料、空文档、E 步零分母、空主题、非有限对数似然和归一化漂移。伪代码在零分母或空主题处立即拒绝当前轮并终止当前启动, 因此不会继续执行无定义

算法 29.2: 固定主题 – 词分布的新文档折入

输入: $\hat{\Phi}$ 、训练词表、新文档计数、OOV 策略、 T_* 、 ε_ℓ 、 ε_p 、 ε_0 、严格正 $\theta_*^{(0)}$

输出: 最后合法 $\hat{\theta}_*$ 、 $\hat{\ell}_*$; t_{done} 、 z_{done} ; status、OOV 与诊断

- 1 若词表/矩阵维数、预算、容差、初值或 OOV 策略非法, 则返回初值占位、计数 0、invalid_input 及字段诊断
- 2 映射词元并记录 OOV; 仅按冻结的“忽略 OOV”策略丢弃, 否则返回 invalid_input; 若过滤后 $C_* = 0$, 返回 invalid_input 及空文档诊断
- 3 置 $\hat{\theta}_* \leftarrow \theta_*^{(0)}$, $t_{\text{done}} \leftarrow 0$, $z_{\text{done}} \leftarrow 0$, 以 log-sum-exp 计算 $\hat{\ell}_*$; 若有正计数词的模型概率为零或结果非有限, 则返回 numerical_failure 及初始化支撑诊断
- 4 **当** $t_{\text{done}} < T_*$ **执行**
 - 5 清零临时 u_k ; 对每个 $n_{i*} > 0$ 用当前 $\hat{\theta}_*$ 计算 $a_k = \log \hat{\phi}_{ik} + \log \hat{\theta}_{k*}$ 与 $L_i = \text{LSE}_k(a_k)$
 - 6 若所有 $a_k = -\infty$, 或稳定实现后 L_i 仍非有限/低于登记阈值, 则返回上一合法状态、numerical_failure 及失败 ($t_{\text{done}} + 1, i$) 诊断; 成功处理一项即增加 z_{done} 并累计 u_k
 - 7 形成 $\theta_*^+ = u/C_*$ 并计算 ℓ_*^+ 、相对似然变化及 $\|\theta_*^+ - \hat{\theta}_*\|_\infty$
 - 8 若候选非有限、未归一或似然显著下降, 则拒绝整轮并返回上一合法状态、numerical_failure 及候选验收诊断
 - 9 原子提交 $(\hat{\theta}_*, \hat{\ell}_*) \leftarrow (\theta_*^+, \ell_*^+)$ 并令 $t_{\text{done}} \leftarrow t_{\text{done}} + 1$
 - 10 若似然和参数双容差同时满足, 则返回最后合法状态、numerical_failure 及 OOV/双阈值/单调性诊断
- 11 **结束**
- 12 返回最后合法状态、实际计数、budget_stop 及 OOV 与“预算耗尽”诊断

的除法。删除主题或用正扰动重置必须由外层启动器完成: 重新确定 K 及矩阵维数, 重新初始化 Φ, Θ , 并从新的 $\ell^{(0)}$ 开始; 这不是原 EM 轨迹中的一次普通更新。把极小概率统一截断并重归一化也会改变原目标, 必须记录阈值。

不收敛或不适用情形。似然持续振荡或明显下降通常表示更新时刻混用、分母下溢或 M 步没有精确完成。即使似然收敛, 多个初值也可能到达不同局部解。极短文档、主题数接近文档数、需要自然处理新文档或要求贝叶斯不确定性时, PLSA 通常不是首选。

读前自检: 复杂度分析: EM 参数估计。EM 参数估计中的“计数以稀疏非零项存储, 责任度可边计算边累加, 且 $K \ll \min(M, N)$ ”决定可执行范围; 请由 $R = \{(i, j) : n_{ij} > 0\}$ 的总成本剥离一次迭代或一次样本因子, 结果须满足流式累加可避免该项, 但输出参数本身仍需 $O((M+N)K)$ 。

复杂度分析

复杂度假设。令 $R = \{(i, j) : n_{ij} > 0\}$, 训练迭代数为 T ; 计数以稀疏非零项存储, 责任度可边计算边累加, 且 $K \ll \min(M, N)$ 。若逐词元扫描而不聚合计数, 应把 R 替换为总词元数 C 。

训练时间复杂度。每个非零共现对计算 K 个责任度并累加两组计数, 一轮为 $O(RK)$; T 轮为 $O(TRK)$, 另有每轮 $O((M+N)K)$ 的归一化与参数检查。

预测时间复杂度。PLSA 没有直接的新文档参数。固定 $\hat{\Phi}$ 后, 对含 R_* 个非零词的新文档以 T_* 轮一文档 EM 折入, 时间为 $O(T_* R_* K)$; 已训练文档的一个词概率需 $O(K)$, 完整稠密词分布需 $O(MK)$ 。

空间复杂度。稀疏计数、模型输出和累计量分别需 $O(R)$ 、 $O(MK+NK)$ 与 $O(MK+NK)$ 。若显式保存全部责任度, 额外需要 $O(RK)$; 流式累加可避免该项, 但输出参数本身仍需 $O((M+N)K)$ 。

29.5 与 LSA、NMF 及 LDA 的联系

把 $X' = [P(w_i, d_j)]$ 写成矩阵, 可得共现参数化

$$X' = U' \Sigma' V'^T, \quad U' = [P(w_i | z_k)]_{M \times K}, \quad \Sigma' = \text{diag}(P(z_1), \dots, P(z_K)), \quad V' = [P(d_j | z_k)]_{N \times K}.$$

U' 与 V' 非负并按列归一化, Σ' 非负; 它们通常不正交。该分解在形式上连接了 PLSA、LSA 与 NMF, 但三者的目标和约束不同。

读前自检：易混淆概念对比：与 LSA、NMF 及 LDA 的联系。 把与 LSA、NMF 及 LDA 的联系放在“对比表首个数据行是“LSA | 对 $X \in \mathbb{R}^{M \times N}$ (词为行、训练文档为列) 作截断 SVD | $U_k \in \mathbb{R}^{M \times K}$ 是词空间基; $V_k \in \mathbb{R}^{N \times K}$ 是训练文档系数方向 | 新文档 $x_* \in \mathbb{R}^M$ 编码为 $U_k^T x_*$; 训练文档坐标为 $\Sigma_k V_k^T$ ””下考察: 按列复述“LSA | 对 $X \in \mathbb{R}^{M \times N}$ (词为行、训练文档为列) 作截断 SVD | $U_k \in \mathbb{R}^{M \times K}$ 是词空间基; $V_k \in \mathbb{R}^{N \times K}$ 是训练文档系数方向 | 新文档 $x_* \in \mathbb{R}^M$ 编码为 $U_k^T x_*$; 训练文档坐标为 $\Sigma_k V_k^T$ ”中的对象、假设与结论, 并检查各列均对应首行对象“LSA”, 且未与表中下一行互换。

易混淆概念对比

方法	分解与目标	约束与解释	新文档处理
LSA	对 $X \in \mathbb{R}^{M \times N}$ (词为行、训练文档为列) 作截断 SVD	$U_k \in \mathbb{R}^{M \times K}$ 是词空间基; $V_k \in \mathbb{R}^{N \times K}$ 是训练文档系数方向	新文档 $x_* \in \mathbb{R}^M$ 编码为 $U_k^T x_*$; 训练文档坐标为 $\Sigma_k V_k^T$
PLSA	最大化单词 - 文档共现似然, 等价于加权 KL 型拟合	因子非负且归一化; 主题、文档混合有概率语义	固定主题 - 词分布后另做折入估计
NMF	以 Frobenius、KL 或其他散度拟合 $X \approx WH$	$W, H \geq 0$, 尺度通常不唯一; 是否归一化取决于定义	固定 W 后解非负系数问题

PLSA 的参数量约为 $K(M-1) + N(K-1)$, 另有固定或可估的文档分布; 它随训练文档数 N 线性增长。LSA 的正交约束带来谱排序和最佳低秩平方误差保证, 但不提供离散生成概率。NMF 与 PLSA 都使用非负因子; 只有在特定归一化和散度目标下, 二者的优化形式才可对应, 不能只因矩阵形状相同便认定算法相同。

LDA 与 PLSA 也不能共用同一套参数更新。LDA 在文档层引入 $\theta_{:j} \sim \text{Dir}(\alpha)$, 通常还对主题 - 词列引入 Dirichlet 先验; 观测词元后需要计算或近似后验, 而不是把每篇文档的 $\theta_{:j}$ 都当作互不相关的极大似然参数。因而 PLSA 上面的责任度归一化来自固定参数的 Bayes 公式, LDA 中的相应量还包含先验与后验期望; 只有明确推断方法及超参数后, 才能写出 LDA 的变分、Gibbs 或其他更新。

读前自检：适用条件与局限：与 LSA、NMF 及 LDA 的联系。 PLSA 要求非负词 - 文档计数、主题概率归一且主题数小于词汇与文档规模; 请逐项核对这三条条件, 并用留出文档似然而非训练似然选择主题数。

适用条件与局限性

适用条件。PLSA 适合具有可靠非负共现计数、希望获得软主题和概率词分布、且训练文档集合相对固定的探索性文本建模。聚合计数应足以表达任务结构，主题数应明显小于词汇与文档规模，并通过训练外准则选择。

方法局限

PLSA 为每篇训练文档配置独立 $\theta_{:j}$ ，没有文档层先验，参数量随 N 增长；新文档必须折入；极大似然容易过拟合稀有共现；主题标签不可识别且局部最优依赖初始化；词袋假设忽略词序与上下文；预设 K 不能由模型自动确定。

读前自检：常见错误与误用边界：与 LSA、NMF 及 LDA 的联系。 从与 LSA、NMF 及 LDA 的联系的条件“边界框首项禁止将 Φ 按行归一化”出发，请把固定错误“将 Φ 按行归一化”中的对象、操作与结论按本节定义拆开，指出第一个不满足的定义条件，再把该处改为本节允许的写法；所得量应符合改写后的运算或判断有定义，且不再触发“将 Φ 按行归一化”。

常见错误

1. 把 $P(z | d)$ 与 $P(d | z)$ 混用，却没有乘以 $P(d)$ 和除以 $P(z)$ ；
2. 在 E 步分母漏掉对全部主题求和，或用新旧参数混合计算责任度；
3. 将 Φ 按行归一化、将 Θ 按文档以外的轴归一化；
4. 把共现次数 n_{ij} 漏出 E、M 步累计量，使高频与低频观测获得相同权重；
5. 只用似然增量停止，却不检查参数变化、空主题、列和与非有限数值；
6. 把训练文档的 $\theta_{:j}$ 直接分配给新文档，造成索引错位和数据泄漏。

读前自检：易混淆概念对比：与 LSA、NMF 及 LDA 的联系。 与 LSA、NMF 及 LDA 的联系依赖“对比表首个数据行是“ $P(z | d)$ 与 $P(z | w, d)$ | 文档的主题混合，是模型参数 | 观察具体词后的主题后验，是 E 步量””；请据此按列复述“ $P(z | d)$ 与 $P(z | w, d)$ | 文档的主题混合，是模型参数 | 观察具体词后的主题后验，是 E 步量”中的对象、假设与结论，并直接核对各列均对应首行对象“ $P(z | d)$ 与 $P(z | w, d)$ ”，且未与表中下一行互换。

易混淆概念对比

概念对	第一项	第二项
$P(z d)$ 与 $P(z w, d)$	文档的主题混合, 是模型参数	观察具体词后的主题后验, 是 E 步量
$P(w z)$ 与 $P(w d)$	单个主题的词分布	多主题按 $P(z d)$ 混合后的文档词分布
生成模型与共现模型	$d \rightarrow z \rightarrow w$, 参数含 $P(z d)$	z 共同指向 w, d , 参数含 $P(d z)$
似然收敛与参数收敛	目标值增量很小	两组概率矩阵本身稳定; 前者不推出后者唯一
主题编号与主题语义	编号可整体置换	语义来自高概率词和文档使用模式

29.6 例题、参数估计与练习

例题 29.1 (一次完整 E 步与 M 步). 设 $M = N = K = 2$, 计数矩阵为 $[n_{ij}] = \begin{pmatrix} 3 & 1 \\ 1 & 3 \end{pmatrix}$ 。初值取

$$\Phi^{(0)} = \begin{bmatrix} 0.8 & 0.2 \\ 0.2 & 0.8 \end{bmatrix}, \quad \Theta^{(0)} = \begin{bmatrix} 0.75 & 0.25 \\ 0.25 & 0.75 \end{bmatrix}.$$

计算一轮 E 步责任度和 M 步参数。

例题 29.1 解答

读题翻译 一轮 EM 包含两个不同对象: E 步用同一组旧参数计算每个词 - 文档位置的主题后验责任度, M 步再用计数加权的责任度更新两组概率参数。

已知与合法条件 $n_{ij} \geq 0$, $\Phi^{(0)}$ 和 $\Theta^{(0)}$ 按规定列归一化; 四个观测位置的混合概率分母均为正, 因此责任度定义良好。

为什么想到这个方法 先算 $\gamma_{ijk} \propto \phi_{ik}^{(0)} \theta_{kj}^{(0)}$ 并对主题归一化, 再分别按词和文档汇总 $n_{ij} \gamma_{ijk}$, 得到 $\Phi^{(1)}$ 与 $\Theta^{(1)}$ 。

方法选择 完整列出四个位置的 E 步责任度, 计算 M 步加权充分统计量, 最后检查非负性、正分母和每个规定轴上的归一化。

推导/计算 E 步。四个共现位置的第一主题责任度依次为

$$\gamma_{111} = \frac{0.8 \times 0.75}{0.8 \times 0.75 + 0.2 \times 0.25} = \frac{12}{13}, \quad \gamma_{121} = \frac{0.8 \times 0.25}{0.8 \times 0.25 + 0.2 \times 0.75} = \frac{4}{7},$$

$$\gamma_{211} = \frac{0.2 \times 0.75}{0.2 \times 0.75 + 0.8 \times 0.25} = \frac{3}{7}, \quad \gamma_{221} = \frac{0.2 \times 0.25}{0.2 \times 0.25 + 0.8 \times 0.75} = \frac{1}{13},$$

第二主题责任度均为 $1 - \gamma_{ij1}$ 。

M 步。第一主题对两个词的期望计数为

$$a_{11} = 3\frac{12}{13} + 1\frac{4}{7} = \frac{304}{91}, \quad a_{21} = 1\frac{3}{7} + 3\frac{1}{13} = \frac{60}{91},$$

故 $\phi_{11}^{(1)} = 304/364 = 76/91$ 、 $\phi_{21}^{(1)} = 15/91$ 。由对称性, 第二主题列为 $(15/91, 76/91)^T$ 。每篇文档词数 $c_1 = c_2 = 4$, 于是

$$\theta_{11}^{(1)} = \frac{3(12/13) + 1(3/7)}{4} = \frac{291}{364}, \quad \theta_{12}^{(1)} = \frac{1(4/7) + 3(1/13)}{4} = \frac{73}{364},$$

其余元素由列和为 1 得到。

独立核验 四个 E 步分母依次为 0.65, 0.35, 0.35, 0.65, 均严格为正; 每个位置满足 $\gamma_{ij1} + \gamma_{ij2} = 1$ 。更新后 $76/91 + 15/91 = 1$ 且 $291/364 + 73/364 = 1$, 所以 $\Phi^{(1)}$ 和 $\Theta^{(1)}$ 的每一列都是非负概率向量。

结论 一轮 EM 后的两组参数保持列归一化, 并加强“第一词 – 第一文档”和“第二词 – 第二文档”的对应结构。

本章共 18 道练习。每道题干后立即给出同号解析; 长解析可自然跨页, 续页标题保留题号。

【原书练习整理】

练习 29.1. 证明 PLSA 生成模型与共现模型等价。要求同时给出两个方向的参数转换, 并说明零质量主题或零质量文档为何使部分条件分布不可识别。

练习 29.1 解析

从生成参数出发, 令

$$\rho_k = \sum_j \pi_j \theta_{kj}, \quad \psi_{jk} = \frac{\pi_j \theta_{kj}}{\rho_k} \quad (\rho_k > 0).$$

则 $\sum_k \rho_k = 1$ 、 $\sum_j \psi_{jk} = 1$, 并且

$$\sum_k \rho_k \phi_{ik} \psi_{jk} = \pi_j \sum_k \phi_{ik} \theta_{kj} = P(w_i, d_j).$$

反向令 $\pi_j = \sum_k \rho_k \psi_{jk}$, 并在 $\pi_j > 0$ 时取 $\theta_{kj} = \rho_k \psi_{jk} / \pi_j$, 即可恢复生成参数化。若 $\rho_k = 0$, 主题 k 不贡献任何联合概率, $P(d | z_k)$ 无法由数据确定; 若 $\pi_j = 0$, 文档 j 从不出现, $P(z | d_j)$ 无法识别。这些条件分布的不唯一不会改变可观联合分布。

练习 29.2. 对共现模型 $P(w_i, d_j) = \sum_k \rho_k \phi_{ik} \psi_{jk}$ 推导 EM 算法, 其中 $\rho_k = P(z_k)$ 、 $\phi_{ik} = P(w_i | z_k)$ 、 $\psi_{jk} = P(d_j | z_k)$ 。写出 E 步、三组 M 步及全部归一化分母。

练习 29.2 解析

定义共现模型责任度

$$r_{ijk}^{(t)} = P(z_k | w_i, d_j) = \frac{\rho_k^{(t)} \phi_{ik}^{(t)} \psi_{jk}^{(t)}}{\sum_{h=1}^K \rho_h^{(t)} \phi_{ih}^{(t)} \psi_{jh}^{(t)}}.$$

删除与参数无关的项后, 辅助函数为

$$Q = \sum_{i,j,k} n_{ij} r_{ijk}^{(t)} (\log \rho_k + \log \phi_{ik} + \log \psi_{jk}).$$

记 $A_k = \sum_{i,j} n_{ij} r_{ijk}^{(t)}$, 总词元数为 $C = \sum_{i,j} n_{ij}$ 。分别在 $\sum_k \rho_k = 1$ 、 $\sum_i \phi_{ik} = 1$ 、 $\sum_j \psi_{jk} = 1$ 约束下作 Lagrange 极大化, 得到

$$\rho_k^{(t+1)} = \frac{A_k}{C}, \quad \phi_{ik}^{(t+1)} = \frac{\sum_j n_{ij} r_{ijk}^{(t)}}{A_k}, \quad \psi_{jk}^{(t+1)} = \frac{\sum_i n_{ij} r_{ijk}^{(t)}}{A_k}.$$

三组更新分别按主题总量、主题总量和主题总量归一化; 对 k 求和第一式为 1, 对 i 或 j 求和后两式也各为 1。若 $A_k = 0$, 该主题无期望计数, 后两式无定义, 应按预设规则删除或重新启动, 而不是除以零。

练习 29.3. 对下列单词 – 标题共现数据进行 PLSA 分析。取 $K = 2$, 给出可复现的正初始化、多初值比较与停止规则, 报告两个主题的高概率词、各标题的主题倾向, 并检查似然单调性与概率归一化。

	T1	T2	T3	T4	T5	T6	T7	T8	T9
book	0	0	1	1	0	0	0	0	0
dads	0	0	0	0	0	1	0	0	1
dummies	0	1	0	0	0	0	0	1	0
estate	0	0	0	0	0	0	1	0	1
guide	1	0	0	0	0	1	0	0	0
investing	1	1	1	1	1	1	1	1	1
market	1	0	1	0	0	0	0	0	0
real	0	0	0	0	0	0	1	0	1
rich	0	0	0	0	0	2	0	0	1
stock	1	0	1	0	0	0	0	1	0
value	0	0	0	1	1	0	0	0	0

练习 29.3 解析

该表有 11 个单词、9 个标题、31 个词元。以下使用条件目标

$$\ell(\Phi, \Theta) = \sum_{i,j} n_{ij} \log(\Phi\Theta)_{ij}, \quad (\Phi\Theta)_{ij} = \sum_{k=1}^K \phi_{ik} \theta_{kj}.$$

练习 29.3 解析 (续)

取 $T_{\max} = 10000$ 、 $\varepsilon_\ell = 10^{-8}$ 、 $\varepsilon_p = 10^{-6}$ ，并要求每次启动满足

$$\phi_{ik} \geq 0, \quad \sum_i \phi_{ik} = 1, \quad \theta_{kj} \geq 0, \quad \sum_k \theta_{kj} = 1.$$

第一组采用题面导向的指定初值：令 $\epsilon = 10^{-3}$ ，两组种子词分别为

$S_1 = \{\text{book, investing, market, stock, value}\},$

$S_2 = \{\text{dads, dummies, estate, guide, investing, real, rich}\}.$

集合内给未归一化权重 $1 + \epsilon$ ，其余给 ϵ 后按列归一化。 $T1, T3, T4, T5$ 的主题 1 权重取 0.9， $T2, T6, T7, T9$ 取 0.1， $T8$ 取 0.5，主题 2 取补数。其余九组分别以种子 0, 1, ..., 8 从 $U(0, 1)$ 独立生成 11×2 与 2×9 矩阵，每个元素再加 10^{-3} 并按列归一化；各次启动使用互不混用的伪随机流。十次启动结果为

启动	终止 ℓ	轮数
指定初值	-56.580927540	29
种子 0	-56.580927900	52
种子 1	-59.877417462	73
种子 2	-59.652105266	55
种子 3	-59.308111089	59
种子 4	-55.028905786	25
种子 5	-60.175354448	62
种子 6	-56.580927761	37
种子 7	-55.028905839	45
种子 8	-59.736227209	42

按终止似然选择种子 4，并交换主题列使第一列记为金融主题 F 、第二列记为地产主题 R 。所得 $\hat{\Phi}$ 如下表所示：

词	$P(w F)$	$P(w R)$
book	0.11111112	0.00000000
dads	0.00000000	0.15384614
dummies	0.11111112	0.00000000
estate	0.00000000	0.15384614
guide	0.05555553	0.07692312
investing	0.33333334	0.23076923
market	0.11111112	0.00000000
real	0.00000000	0.15384614
rich	0.00000000	0.23076922
stock	0.16666667	0.00000000
value	0.11111112	0.00000000

相应的金融主题权重 $\hat{\theta}_{Fj}$ 按 $T1$ 至 $T9$ 依次约为 (0.99999979, 1, 1, 1, 1, 0, 0.00000002, 1, 0)，地产主题权重为其补数。指定初值则在 29 轮得到 $\ell = -56.580927540$ ，并把 $T8$ 估为 (0.518195, 0.481805)；它更接近预设语义分组，却不是十次启动中的最高似然解。种子 4 的解把 **dummies** 以及 $T2, T8$ 放到金融侧，正好揭示“似然更高”与“人工期望语义”可能不同，不能用预期主题词替代实际训练报告。

练习 29.3 解析 (续)

十条轨迹的最小逐轮似然增量均大于 3.8×10^{-7} , 最大列和误差不超过 2.22×10^{-16} , 全部概率非负。比较主题稳定性时先用最优匹配消除列置换; 报告时同时保留初始化、轨迹、终值、停止原因和语义差异。由于目标非凸, 以上结果不表示存在与初始化无关的唯一矩阵。

练习 29.4. 固定经验文档分布 π 时, 求 PLSA 中 Φ, Θ 的自由参数个数。对 $M = 1000, N = 200, K = 10$ 计算数值, 并与直接为每篇文档估计一个 M 维词分布比较。

练习 29.4 解析

Φ 的每个主题列有 $M - 1$ 个自由度, 共 $K(M - 1)$; Θ 的每个文档列有 $K - 1$ 个自由度, 共 $N(K - 1)$ 。代入数值得

$$10(1000 - 1) + 200(10 - 1) = 9990 + 1800 = 11790.$$

若直接为每篇文档估计一个 M 维词分布, 则

$$d_{\text{direct}} = N(M - 1) = 200 \times 999 = 199800,$$

$$d_{\text{PLSA}} = 11790 < d_{\text{direct}}.$$

PLSA 以共享主题减少参数, 但文档混合部分 $N(K - 1)$ 仍随 N 线性增长。

练习 29.5. 两主题的某词概率分别为 0.1, 0.6, 某文档主题混合为 $(0.7, 0.3)^T$ 。求该词在文档中的概率; 观察到该词后, 求两个主题的后验责任度。

练习 29.5 解析

文档中的词概率为 $0.1 \times 0.7 + 0.6 \times 0.3 = 0.25$ 。Bayes 公式给出

$$P(z_1 | w, d) = \frac{0.1 \times 0.7}{0.25} = 0.28, \quad P(z_2 | w, d) = \frac{0.6 \times 0.3}{0.25} = 0.72.$$

两个后验非负且和为 1。虽然主题 2 先验权重只有 0.3, 该词在主题 2 下概率更高, 观察该词后主题 2 责任度上升到 0.72。

练习 29.6. 指出 w, d, z 中哪些是观测变量、哪些是隐变量, 并解释为何“每个文档只抽取一次主题”不等于本章 PLSA 模型。

练习 29.6 解析

w 与 d 出现在共现表中, 是观测变量; z 没有被记录, 是隐变量。标准 PLSA 对文档 j 中的每个词元位置 t 分别生成

$$z_{jt} \sim P(z | d_j), \quad w_{jt} \sim P(w | z_{jt}),$$

因此同一文档内可以有 $z_{jt} \neq z_{js}$ 。若整篇文档只抽一次主题, 则变成

$$z_j \sim P(z | d_j), \quad w_{jt} \sim P(w | z_j) \quad (\forall t),$$

练习 29.6 解析 (续)

所有词元共享 z_j ，联合分布和 E 步后验都会改变，那是另一种混合文档模型。

练习 29.7. 从有向关系 $d \rightarrow z \rightarrow w$ 推出 $P(w, d, z)$ 与 $P(w, d)$ ，再验证所得联合分布对 (w, d) 求和为 1。

练习 29.7 解析

有向分解为 $P(w_i, d_j, z_k) = P(d_j)P(z_k | d_j)P(w_i | z_k) = \pi_j \theta_{kj} \phi_{ik}$ 。对隐主题求和得到 $P(w_i, d_j) = \pi_j \sum_k \theta_{kj} \phi_{ik}$ 。再对全部观测值求和，

$$\sum_{i,j} P(w_i, d_j) = \sum_j \pi_j \sum_k \theta_{kj} \sum_i \phi_{ik} = \sum_j \pi_j = 1.$$

最后两步分别使用 Φ, Θ 的列归一化和文档分布的归一化。

练习 29.8. 已知 $\pi = (0.4, 0.6)$ ，且 $\Theta = \begin{pmatrix} 0.75 & 1/3 \\ 0.25 & 2/3 \end{pmatrix}$ 。计算共现参数 $\rho_k = P(z_k)$ 和 $\psi_{jk} = P(d_j | z_k)$ 。

练习 29.8 解析

主题边缘概率为

$$\rho_1 = 0.4 \times 0.75 + 0.6 \times \frac{1}{3} = 0.5, \quad \rho_2 = 0.4 \times 0.25 + 0.6 \times \frac{2}{3} = 0.5.$$

由 Bayes 转换，第一主题下的文档分布为 $(0.4 \times 0.75/0.5, 0.6 \times (1/3)/0.5) = (0.6, 0.4)$ ；第二主题下为 $(0.2, 0.8)$ 。两列均非负且和为 1，代回 $\rho_k \psi_{jk} = \pi_j \theta_{kj}$ 可逐项核对。

练习 29.9. 令 $n_{11} = n_{22} = 2$ 、其余计数为 0，并取 $\Phi = \Theta = \begin{pmatrix} 0.8 & 0.2 \\ 0.2 & 0.8 \end{pmatrix}$ 。计算去除固定文档概率后的观测对数似然。

练习 29.9 解析

两个正计数位置的混合概率分别为

$$p_{11} = 0.8 \times 0.8 + 0.2 \times 0.2 = 0.68, \quad p_{22} = 0.2 \times 0.2 + 0.8 \times 0.8 = 0.68.$$

只有这两个位置计数非零，所以

$$\ell = 2 \log 0.68 + 2 \log 0.68 = 4 \log 0.68 \approx -1.5426.$$

这里已经去掉固定 π_j 项；若计算完整联合似然，还要加 $\sum_j c_j \log \pi_j$ 。

练习 29.10. 某文档的主题混合为 $(0.6, 0.4)$, 某词在两主题下概率为 $(0.2, 0.7)$ 。计算观察该词后的责任度, 并比较先验与后验的变化。

练习 29.10 解析

分母为 $0.2 \times 0.6 + 0.7 \times 0.4 = 0.4$, 所以

$$\gamma_1 = \frac{0.12}{0.4} = 0.3, \quad \gamma_2 = \frac{0.28}{0.4} = 0.7.$$

先验主题权重从 $(0.6, 0.4)$ 变为后验 $(0.3, 0.7)$ 。变化来自该词在第二主题下的似然 0.7 高于第一主题的 0.2 ; 后验并非只由文档混合决定。

练习 29.11. 若对一个 $n_{ij} > 0$ 的共现对有 $\sum_k \phi_{ik} \theta_{kj} = 0$, 说明似然和 E 步分别发生什么, 并给出不改变问题定义的预防方式。

练习 29.11 解析

若 $n_{ij} > 0$ 但模型概率

$$p_{ij} = \sum_k \phi_{ik} \theta_{kj} = 0,$$

则

$$n_{ij} \log p_{ij} = n_{ij} \log 0 = -\infty, \quad \ell(\Phi, \Theta) = -\infty.$$

同时 E 步责任度的分母 p_{ij} 为 0, 后验没有定义。初始化应让活动坐标严格为正; 若有结构性零, 则每个 $n_{ij} > 0$ 的位置必须满足

$$\exists k : \phi_{ik} \theta_{kj} > 0,$$

不能把无定义的 $0/0$ 事后改成任意分布。

练习 29.12. 用 Jensen 不等式证明: 在 E 步取旧参数后验、M 步精确提高辅助函数时, PLSA 观测对数似然单调不降。指出该结论不包含哪一种最优性保证。

练习 29.12 解析

令旧后验为 $\gamma_{ijk}^{(t)}$ 。对每个正计数位置,

$$\log \sum_k \phi_{ik} \theta_{kj} = \log \sum_k \gamma_{ijk}^{(t)} \frac{\phi_{ik} \theta_{kj}}{\gamma_{ijk}^{(t)}} \geq \sum_k \gamma_{ijk}^{(t)} \log \frac{\phi_{ik} \theta_{kj}}{\gamma_{ijk}^{(t)}}.$$

旧后验使下界在旧参数处相等; M 步提高右侧中依赖参数的 Q' , 后验熵项不变, 因此新参数的左侧总和不低于旧值。结论只保证似然值单调不降, 不保证参数唯一、全局最优或不同初始化得到相同主题。

练习 29.13. 只有一个非空文档，两个词计数为 (3, 1)。两词对主题 1 的责任度分别为 0.8, 0.25。完成一次 M 步，求两列 Φ 和该文档的 θ 。

练习 29.13 解析

主题 1 的两个期望词计数为 $3 \times 0.8 = 2.4$ 与 $1 \times 0.25 = 0.25$ ，总量 $2.65 = 53/20$ ，故 $\phi_{:1} = (48/53, 5/53)^\top$ 。主题 2 责任度为 0.2, 0.75，期望计数为 0.6, 0.75，故 $\phi_{:2} = (4/9, 5/9)^\top$ 。文档总词数为 4，所以

$$\theta_{:1} = \left(\frac{2.65}{4}, \frac{1.35}{4} \right)^\top = \left(\frac{53}{80}, \frac{27}{80} \right)^\top.$$

两列 Φ 和文档主题向量都非负且各自和为 1。

练习 29.14. 分别判断下列性质主要属于 LSA、PLSA 还是一般 NMF：因子正交且可为负；因子是归一化概率；目标可任取 Frobenius 或 KL 型散度；训练文档各有独立主题参数。

练习 29.14 解析

三类模型的核心约束分别是

$$\text{LSA: } X_k = U_k \Sigma_k V_k^\top, \quad U_k^\top U_k = V_k^\top V_k = I_k,$$

$$\text{NMF: } X \approx WH, \quad W \geq 0, H \geq 0,$$

$$\text{PLSA: } P(w_i | d_j) = \sum_k \phi_{ik} \theta_{kj}, \quad \sum_i \phi_{ik} = 1, \quad \sum_k \theta_{kj} = 1.$$

故“因子正交且可为负”属于 LSA，“归一化概率”和“每个训练文档有独立 $\theta_{:j}$ ”属于 PLSA；NMF 可选 Frobenius 或 KL 型散度，但非负性本身不产生概率语义。

练习 29.15. 给定已训练的 $\hat{\Phi}$ 和一篇含 R_* 个非零词的新文档，写出只估计 θ_* 的折入 EM，并给出 T_* 轮的时间复杂度。

练习 29.15 解析

固定 $\hat{\Phi}$ 并以正概率向量初始化 $\theta_*^{(0)}$ 。第 t 轮对每个新文档非零词计算

$$\gamma_{ik}^{(t)} = \frac{\hat{\phi}_{ik} \theta_k^{(t)}}{\sum_h \hat{\phi}_{ih} \theta_h^{(t)}}, \quad \theta_k^{(t+1)} = \frac{\sum_i n_i \gamma_{ik}^{(t)}}{\sum_i n_i}.$$

用似然增量 and 参数变化共同停止， $\hat{\Phi}$ 始终不更新。每轮扫描 R_* 个非零词并处理 K 个主题， T_* 轮时间为 $O(T_* R_* K)$ ，额外工作空间可为 $O(K)$ 或 $O(R_* K)$ ，取决于是否保存责任度。

练习 29.16. 设 $M = 10000, N = 2000, K = 20, R = 50000$ 。比较显式保存全部非零对责任度与流式累加时的主要标量存储量，不计索引开销。

练习 29.16 解析

全部非零对责任度需要

$$M_\gamma = RK = 50000 \times 20 = 1000000$$

练习 29.16 解析 (续)

个标量。模型参数与稀疏计数分别为

$$M_{\text{param}} = MK + NK = (10000 + 2000) \times 20 = 240000, \quad M_X = R = 50000.$$

流式累加再保存一份同尺寸累计量时,

$$M_{\text{stream}} = 50000 + 240000 + 240000 = 530000,$$

$$M_{\text{explicit}} = M_{\text{stream}} + M_Y = 1530000.$$

双缓冲只改变常数倍; 渐近差别是显式方案含 $O(RK)$ 责任度表。

练习 29.17. 设计一个多初值 PLSA 实验的验收记录, 至少覆盖数据、初始化、停止、似然、概率约束、主题稳定性和模型选择边界。

练习 29.17 解析

比较不同启动时, 先固定数据 D 、主题数 K 和预处理, 并为每个种子 s 记录轨迹

$$\mathcal{R}_s = \{s, \Phi_s^{(0)}, \Theta_s^{(0)}, \ell_s^{(t)}, \Delta \ell_s^{(t)}, T_s, \text{stop}_s\}.$$

每轮必须核验

$$\Phi_s^{(t)} \geq 0, \quad \Theta_s^{(t)} \geq 0, \quad \max_k \left| \sum_i \phi_{ik}^{(t)} - 1 \right| \leq \varepsilon_p,$$

$$\max_j \left| \sum_k \theta_{kj}^{(t)} - 1 \right| \leq \varepsilon_p, \quad \ell_s^{(t+1)} \geq \ell_s^{(t)} - \varepsilon_{\text{num}}.$$

启动间先做最优主题匹配再比较稳定性。 K 和停止参数只能由训练内准则或独立验证信息选择, 测试集不得参与。

练习 29.18. 某实现输出的 Φ 每行和为 1、 Θ 每行和为 1, 且似然偶尔下降。指出至少三处应检查的问题, 并写出正确的不变量。

练习 29.18 解析

正确的概率约束是按列归一化:

$$\phi_{ik} \geq 0, \quad \sum_i \phi_{ik} = 1 \quad (\forall k),$$

$$\theta_{kj} \geq 0, \quad \sum_k \theta_{kj} = 1 \quad (\forall j).$$

E 步还应满足

$$\gamma_{ijk} \geq 0, \quad \sum_k \gamma_{ijk} = 1,$$

而精确 EM 应满足

$$\ell^{(t+1)} \geq \ell^{(t)} - \varepsilon_{\text{num}}.$$

练习 29.18 解析 (续)

若似然下降，应检查 E 步是否混用新旧参数、是否漏乘 n_{ij} 、是否出现零分母或下溢，以及 M 步是否使用完整期望计数。

读前自检：本章结论与下一步。 概率潜在语义分析章末由“文档主题分布、主题词分布、共现计数与责任度”落到“稀疏扫描正计数对，先算旧责任度再分别按主题总量和文档词数归一化，以似然和参数双容差停止”；请把前者产出和后者输入逐项对齐，固定核对前者末项的输出类型能否作为后者首项的输入类型。

本章结论与下一步

核心结论：文档主题分布、主题词分布、共现计数与责任度

关键依据：Bayes 公式连接生成/共现参数化；Jensen 下界和单纯形 Lagrange 条件导出 EM 更新与似然单调性

可执行自检：稀疏扫描正计数对，先算旧责任度再分别按主题总量和文档词数归一化，以似然和参数双容差停止

适用边界：训练文档集合相对固定、需要非负概率主题和软文档表示时

下一步：进入采样与 LDA；PLSA 新文档须折入，LDA 还必须声明 Dirichlet 先验与后验推断方法

1. **定义与等价：**能否写出 $P(w, d, z)$ 及全部概率约束，区分 $P(z | d)$ 与 $P(z | w, d)$ ，并双向转换生成模型与共现模型、处理零概率事件？未通过则回看第 1、2 节。
2. **推导与证明：**能否从 Bayes 责任度逐行推出两条 M 步公式，写出 Jensen 下界、等号条件和似然单调结论，并说明它不保证全局最优？未通过则回看第 3、4 节。
3. **算法：**能否完整说明输入、初始化、更新顺序、异常、停止、返回、收敛条件和三类复杂度？未通过则回看第 4 节算法框。
4. **比较：**能否从目标、约束、符号和新文档处理区分 LSA、PLSA 与 NMF？未通过则回看第 5 节。
5. **实践：**能否对多初值结果消除主题置换后比较稳定性，并独立完成 18 道练习？未通过则回看第 6 节；五项均可独立作答，且能用列和、似然轨迹、零分母与参数变化检查一次训练，才算达到本章学习目标。

第 5 册：采样方法、主题模型与图排序

本册把随机过程、蒙特卡罗计算、共轭先验、主题模型和网络排序串联起来，展示局部随机机制如何支持复杂分布推断与全局结构发现。

1. 马尔可夫链基础；
2. 蒙特卡罗方法与直接采样；
3. 马尔可夫链蒙特卡罗法；
4. Gibbs 抽样；
5. 狄利克雷分布与共轭先验；
6. 潜在狄利克雷分配；
7. PageRank 算法；
8. 无监督学习方法总结。

学习路径

先确认马尔可夫链的平稳性与收敛，再由直接采样过渡到 MCMC 和 Gibbs 抽样；狄利克雷共轭结构为主题模型提供可计算后验，PageRank 则把随机游走思想转化为图上的全局排序。

跨册依赖与完成标准

建议复习第 1 册的条件概率、期望、矩阵谱性质和数值迭代，并联系第 28 章的潜在语义矩阵分解与第 29 章的概率潜变量模型。完成后应能检查采样链条件、解释后验更新与主题生成过程，并分析阻尼、悬挂节点和收敛阈值对图排序的影响。

建议用法

对采样算法同时记录目标分布、转移核、接受或条件更新规则和诊断量；对主题模型与 PageRank 则分别追踪生成假设和线性迭代。把“收敛到什么”与“如何判断收敛”分开书写。

第 30 章 马尔可夫链基础

读前自检：依赖路线。 马尔可夫链基础依赖链含“第 3 册隐马尔可夫模型章的行随机转移约定 → 本章的有限链统一记号”到“随机过程 → 马尔可夫性质 → 转移矩阵或转移核”这一跳；请固定写出前者输出类型与后者输入类型，并核对两者相同或存在正文声明的转换。

本章地图

核心问题：给定一步随机规则，怎样区分“保持不变”“唯一”“时间平均收敛”和“固定时刻收敛”？

可检验学习目标：

- 在有限/可数状态主线中用条件概率表述马尔可夫性质，并能用转移核写出一一般可测空间版本；
- 从分布推进推导平稳方程，区分平稳分布的存在、唯一、逐步收敛与时间平均收敛；
- 判断有限链的不可约性、周期性、正常返与可逆性，并能构造反例检验错误命题；
- 手工执行有限状态链的分布推进算法，核对概率不变量、停止规则和复杂度；
- 分析无向图随机游走的平稳分布，以及二部图周期性和惰性的作用。

最短先修：本章使用条件概率、全概率公式、矩阵乘法、概率向量、最大公约数与级数的基本性质。概率分布统一写成行向量。阅读随机游走一节前，应复习第 3 册隐马尔可夫模型中“矩阵第 i 行表示从状态 i 出发的条件分布”这一约定。

依赖路线：第 3 册隐马尔可夫模型章的行随机转移约定 → 本章的有限链统一记号；随机过程 → 马尔可夫性质 → 转移矩阵或转移核；初始分布与转移规则 → 分布推进 → 平稳固定点；通信关系、返回时长与平均回返时间 → 不可约、非周期与正常返；这些结构条件 → 唯一平稳分布、逐步收敛与时间平均；细致平衡 → 可逆性 → 平稳性；图上的局部移动规则 → 随机游走。

完成标准与返回：先回看概率向量与全概率公式，再进入状态转移矩阵。

图 30.1 给出本章概念的依赖次序。箭头表示学习上的前置关系，不表示后一个性质能反向推出前一个性质；特别是，可逆性不能代替不可约性检查。




图 30.1 本章概念依赖：从马尔可夫性质和转移规则出发，分别经平稳固定点与结构条件到达长期结论；可逆性只提供通向平稳性的充分条件

读前自检：本章符号表。 马尔可夫链基础符号表规定 $\{X_t\}_{t \geq 0}$ 、 X_t 的类型或范围；请把 $\{X_t\}_{t \geq 0}$ 代入紧随其后的定义关系，逐项核对输入形状、输出形状与取值域。

本章符号表

符号	类型、维数或范围	读法与作用
$\{X_t\}_{t \geq 0}$	随机变量序列	随机过程; X_t 是时刻 t 的状态
$\mathcal{S}$	主线为有限/可数集; 进阶为一般可测空间	状态空间
$A = (a_{ij})$	$n \times n$ 行随机矩阵	$a_{ij} = P(X_{t+1} = j \mid X_t = i)$
ρ_t^{row} (简称 ρ_t)	$1 \times n$ 概率行向量	时刻 t 的边缘分布
$K(x, B)$	$[0, 1]$ 值马尔可夫核	从 x 一步进入可测集合 B 的概率
$\rho_\star^{\text{row}}$ (简称 $\rho_\star$)	$1 \times n$ 概率行向量	满足 $\rho_\star = \rho_\star A$ 的平稳分布
τ_i	$\mathbb{N}_0 \cup \{\infty\}$	首次到达状态 i 的时间
τ_i^+	$\mathbb{N}_+ \cup \{\infty\}$	从 i 出发的首次正回返时间
$d(i)$	$\mathbb{N}_0$	状态 i 所有可能正回返时长的最大公约数; 无正回返时约定为 0
$G = (V, E)$	有限图	随机游走的状态和允许移动关系

本章所有 $\rho_t, \rho_\star$ 都具有“概率行向量”角色; 完整角色记号分别是 $\rho_t^{\text{row}}, \rho_\star^{\text{row}}$ 。第 33 章 (第 5 册第 4 章) 二元正态例中的无粗体 ρ 则是标量相关系数, 二者类型不同且不可代换。

30.1 随机过程与马尔可夫性质

许多随机系统都按时间演化: 天气、排队长度、网页访问位置和采样器当前状态都可以写成随机变量序列。若每次预测都保存完整历史, 条件分布会随时间增长而变得难以表示。马尔可夫建模提出的问题是: 在什么条件下, 当前状态已经包含预测下一步所需的全部历史信息?

在马尔可夫链蒙特卡罗法中, X_t 可理解为采样器当前持有的样本: 先设计一条以目标分布为平稳分布的马尔可夫链, 再用足够长的样本路径估计目标分布下的期望。后续章节负责构造具体采样器; 本章先回答这种做法依赖的平稳性、正常返与遍历条件。

读前自检: 马尔可夫链的随机过程表述。 马尔可夫链随机过程 $\{X_t\}_{t \geq 0}$ 定义在 $(\Omega, \mathcal{F}, P)$ 上并取值于状态空间 $\mathcal{S}$; 请写出单个 $X_t: \Omega \rightarrow \mathcal{S}$ 的可测性要求, 核对有限状态事件 $\{X_t = i\}$ 属于 $\mathcal{F}$ 。

读前自检: 马尔可夫性质与时齐转移。 时齐马尔可夫链要求给定当前 $X_t = i$ 后, X_{t+1} 与更早历史无关, 且 $a_{ij} = P(X_{t+1} = j \mid X_t = i)$ 不依赖 t ; 请对 j 求和核对转移矩阵每行和为 1。

定义 30.1 (随机过程). 设 $(\Omega, \mathcal{F}, P)$ 为概率空间, $\mathcal{S}$ 为状态空间。由同一概率空间上的随机变量 $X_t: \Omega \rightarrow \mathcal{S}$ 组成的族 $\{X_t\}_{t \geq 0}$ 称为随机过程。一次实验给出的序列 $x_0, x_1, \dots$ 称为一条样本路径。

读前自检: 马尔可夫性质。 一阶马尔可夫性质在有限或可数状态空间 $\mathcal{S}$ 上要求历史事件概率为正; 请把 $P(X_{t+1} = x_{t+1} \mid X_{0:t} = x_{0:t})$ 约成 $P(X_{t+1} = x_{t+1} \mid X_t = x_t)$, 再核对连续状态单点概率为零时必须改用转移核。

读前自检：一阶马尔可夫性质：有限/可数状态主线。 有限或可数状态的一阶马尔可夫性质只在条件历史事件概率为正时用比值解释；请写出完整历史条件式并删去 $X_{0:t-1}$ ，核对右端只保留 X_t 。

定义 30.2 (一阶马尔可夫性质：有限/可数状态主线). 本节先限定 $\mathcal{S}$ 为有限或可数集合。对任意 $t \geq 0$ 和概率为正的历史事件 $\{X_{0:t} = x_{0:t}\}$ ，若

$$P(X_{t+1} = x_{t+1} | X_{0:t} = x_{0:t}) = P(X_{t+1} = x_{t+1} | X_t = x_t), \quad (30.1)$$

则称该过程具有一阶马尔可夫性质。若右端条件分布不依赖 t ，称为时齐马尔可夫链。

这里的单点条件概率公式依赖“历史事件概率为正”，所以只作为离散/可数主线定义；连续状态下单点通常概率为 0，必须改用后文的转移核与几乎处处条件分布。这里的“一阶”是条件独立陈述，不表示 X_{t+1} 与更早状态无关；更早状态会先影响 X_t ，再通过 X_t 影响下一步。

阅读目标：先用概率链式法则，再用 Markov 性删除多余历史。

对象：初始分布 μ 、一步转移概率 a_{ij} 与路径 $(i_0, \dots, i_T)$ 。

合法条件：路径状态均在状态空间内；涉及的一步条件概率有定义。

第一步：先写完整链式分解 $P(X_0 = i_0) \prod_{t=1}^T P(X_t = i_t | X_{0:t-1} = i_{0:t-1})$ 。

推导目标

在给定初始分布和一步转移概率后，把一条有限路径的联合概率写成逐步乘积。

推导准备

使用概率链式法则，并在每个条件概率中应用式 (30.1) 删除被当前状态屏蔽的更早历史。

推导第 1 步：链式展开。 对 $x_{0:T}$,

$$P(X_{0:T} = x_{0:T}) = P(X_0 = x_0) \prod_{t=0}^{T-1} P(X_{t+1} = x_{t+1} | X_{0:t} = x_{0:t}).$$

推导第 2 步：使用马尔可夫性质。 每个乘积因子只保留当前状态，得到

$$P(X_{0:T} = x_{0:T}) = P(X_0 = x_0) \prod_{t=0}^{T-1} P(X_{t+1} = x_{t+1} | X_t = x_t).$$

推导第 3 步：时齐化。 若链时齐，记一步转移概率为 $a_{x_t x_{t+1}}$ ，则

$$P(X_{0:T} = x_{0:T}) = \rho_0(x_0) \prod_{t=0}^{T-1} a_{x_t x_{t+1}}. \quad (30.2)$$

式 (30.2) 说明初始分布和一步转移规则共同决定有限维联合分布。

本章的模型对象是二元组 (ρ_0, A) ，或连续状态情形下的 (μ_0, K) 。模型回答“给定当前状态，下一步如何随机产生”；它并不自动回答转移规则如何从数据估计，也不保证长期行为与初始状态无关。

本章范围

本章研究给定转移矩阵或转移核的概率性质，不定义经验风险、似然或其他参数学习目标。本章不估计模型参数。后文的分布推进算法只是对已给定矩阵执行概率计算，不能把它改称参数学习。

30.2 状态转移矩阵

设有限状态空间为 $\mathcal{S} = \{1, \dots, n\}$ 。本讲义统一定义

$$a_{ij} = P(X_{t+1} = j \mid X_t = i), \quad a_{ij} \geq 0, \quad \sum_{j=1}^n a_{ij} = 1. \quad (30.3)$$

因此 $A = (a_{ij})$ 是行随机矩阵，矩阵第 i 行是从状态 i 出发的下一状态条件分布。图 30.2 把矩阵元素与有向边一一对应；所有从 i 出发的箭头标签之和必须为 1。




图 30.2 行随机约定下的两状态转移图，并给出到列随机 PageRank 约定的显式转置桥。

读图顺序：先看两侧相同的物理箭头 $i \rightarrow j$ ；再看左侧用 A 的 a_{ij} 记录这条边，经中央 $P = A^T$ 对应到右侧的 P_{ji} ；最终得到两种等价推进 $\rho_{t+1} = \rho_t A$ 与 $p^{(t+1)} = P p^{(t)}$ ，边的方向和概率均未改变。

若 $\rho_t = (P(X_t = 1), \dots, P(X_t = n))$ ，全概率公式给出

$$\rho_{t+1} = \rho_t A, \quad (\rho_{t+1})_j = \sum_{i=1}^n (\rho_t)_i a_{ij}. \quad (30.4)$$

进一步有 $\rho_t = \rho_0 A^t$ ，且

$$(A^m)_{ij} = P(X_m = j \mid X_0 = i). \quad (30.5)$$

与第 36 章（第 5 册第 7 章）的列随机 PageRank 约定之间只有一次同时转置：令

$$P = A^T, \quad p^{(t)} = \rho_t^T. \quad (30.6)$$

则 $\rho_{t+1} = \rho_t A$ 当且仅当 $p^{(t+1)} = P p^{(t)}$ ；同样， $\rho_\star = \rho_\star A$ 当且仅当 $p_\star = P p_\star$ 。因此改变行/列约定时必须同时转置矩阵与概率向量，不能只移动乘号一侧。

读前自检：易混淆概念对比：状态转移矩阵。 状态转移矩阵采用行向量约定 $a_{ij} = P(i \rightarrow j)$ ，故分布按 $\rho_{t+1} = \rho_t A$ 推进；请与列向量推进 $\rho_{t+1} = A^T \rho_t$ 对照，核对两式只差转置而不能混用。

易混淆概念对比		
第 30 章与第 36 章的转置桥。		
对象	本章行随机写法	第 36 章列随机写法
转移矩阵	$A_{ij} = P(i \rightarrow j), A\mathbf{1} = \mathbf{1}$	$P = A^\top, \mathbf{1}^\top P = \mathbf{1}^\top$
时刻分布	$\rho_t \in \mathbb{R}^{1 \times n}$	$p^{(t)} = \rho_t^\top \in \mathbb{R}^{n \times 1}$
一步推进	$\rho_{t+1} = \rho_t A$	$p^{(t+1)} = P p^{(t)}$
平稳方程	$\rho_\star = \rho_\star A$	$p_\star = P p_\star$
同一有向边及同一数值例只转置表示，不反向边，也不同时使用 $A\rho_t$ 或 $\rho_t P$ 。		

阅读目标：在中间时刻按状态分解路径，得到多步转移矩阵乘法。
对象：时齐 Markov 链、转移矩阵 A 与非负整数 m, ℓ 。
合法条件：中间状态集合互斥完备；后 ℓ 步转移只依赖中间状态。
第一步：先条件于 $X_m = k$ ，对所有中间状态 k 应用全概率公式。

推导目标
证明 $m + \ell$ 步转移可以分解为先走 m 步、再走 ℓ 步的矩阵乘法。

推导准备
在中间时刻 m 按状态 k 使用全概率公式；时齐性保证后 ℓ 步概率仍由 A^ℓ 表示。

推导第 1 步：按中间状态分割。

$$P(X_{m+\ell} = j \mid X_0 = i) = \sum_{k=1}^n P(X_m = k \mid X_0 = i) P(X_{m+\ell} = j \mid X_m = k, X_0 = i).$$

推导第 2 步：条件独立。马尔可夫性质使第二个条件概率不再需要 $X_0 = i$ ，时齐性又使它等于 $(A^\ell)_{kj}$ 。

推导第 3 步：识别矩阵乘法。

$$(A^{m+\ell})_{ij} = \sum_{k=1}^n (A^m)_{ik} (A^\ell)_{kj}. \tag{30.7}$$

这也是 Chapman–Kolmogorov 方程在有限状态空间中的矩阵形式。

进阶：一般可测状态空间。连续状态空间不能把所有转移概率列成有限矩阵。对可测空间 $(\mathcal{S}, \mathcal{B})$ ，马尔可夫核 K 满足：固定 x 时 $K(x, \cdot)$ 是概率测度，固定 B 时 $K(\cdot, B)$ 可测。时齐马尔可夫性质的严谨版本是：对每个 $B \in \mathcal{B}$,

$$P(X_{t+1} \in B \mid \sigma(X_0, \dots, X_t)) = K(X_t, B) \quad \text{几乎处处.}$$

右侧是给定当前状态的正则条件分布版本；它不要求单点事件 $\{X_t = x\}$ 具有正概率。若 X_t 的分布为 μ_t ，则

$$\mu_{t+1}(B) = \int_{\mathcal{S}} K(x, B) \mu_t(dx). \quad (30.8)$$

若概率测度 μ 满足

$$\mu(B) = \int_{\mathcal{S}} K(x, B) \mu(dx), \quad B \in \mathcal{B},$$

则称 μ 为该核的平稳测度。有限状态的式 (30.4) 正是上述积分公式的求和版本。

若 $\mathcal{S} \subseteq \mathbb{R}^d$ 且 K 关于 Lebesgue 测度有转移密度 $p(x, y)$ ，则

$$K(x, B) = \int_B p(x, y) dy, \quad p(x, y) \geq 0, \quad \int_{\mathcal{S}} p(x, y) dy = 1. \quad (30.9)$$

这里 $p(x, y)$ 是“已知当前状态为 x 时，下一状态在 y 附近”的条件密度，而不是单点概率。若 μ_t 有密度 m_t ，则密度推进式为

$$m_{t+1}(y) = \int_{\mathcal{S}} p(x, y) m_t(x) dx.$$

相应地，若沿用 $\mu(y)$ 记平稳密度，平稳方程就是

$$\mu(y) = \int_{\mathcal{S}} p(x, y) \mu(x) dx, \quad \mu(y) \geq 0, \quad \int_{\mathcal{S}} \mu(y) dy = 1. \quad (30.10)$$

读前自检：平稳分布的固定点定义。 平稳分布是非负行向量 ρ ，满足 $\sum_i \rho_i = 1$ 与 $\rho = \rho A$ ；请完成一次矩阵乘法并逐分量比较，核对推进前后分布相同且仍归一。

30.3 平稳分布

定义 30.3 (平稳分布). 概率行向量 ρ 若满足

$$\rho = \rho A, \quad \rho_i \geq 0, \quad \sum_i \rho_i = 1, \quad (30.11)$$

则称 ρ 为 A 的平稳分布。若 $X_0 \sim \rho$ ，式 (30.4) 保证所有 t 都有 $X_t \sim \rho$ 。

读前自检：平稳分布的流量解释。 二状态例给出 $\rho = (0.4, 0.6)$ 和 $A = \begin{pmatrix} 0.7 & 0.3 \\ 0.2 & 0.8 \end{pmatrix}$ ；请算 ρA ，核对流入两状态的质量仍为 0.4, 0.6。

平稳分布描述“边缘分布经过一步不变”，不是“样本路径停在同一个状态”。处于平稳状态时，链仍可在状态之间移动，只是流入每个状态的总概率质量恰好补偿流出的质量。

阅读目标： 保留一个独立平衡方程并同时核对非负性与归一化。

对象： $A = \begin{pmatrix} 0.7 & 0.3 \\ 0.2 & 0.8 \end{pmatrix}$ 与候选 $\rho = (r, 1-r)$ 。

合法条件： $0 \leq r \leq 1$ ； A 行随机；平稳方程与归一化方程中有一式冗余。

第一步： 先用第一分量写 $r = 0.7r + 0.2(1-r)$ 。

推导目标

求两状态链 $A = \begin{pmatrix} 0.7 & 0.3 \\ 0.2 & 0.8 \end{pmatrix}$ 的平稳分布，并核对全部约束。

推导准备

令 $\rho = (r, 1-r)$ 。平稳方程有一个分量与归一化方程冗余，只需保留一个独立平衡式并检查另一个分量。

推导第 1 步：写出第一分量。

$$r = 0.7r + 0.2(1-r).$$

推导第 2 步：解线性方程。 $0.5r = 0.2$ ，所以 $r = 0.4$ ，候选分布为 $\rho = (0.4, 0.6)$ 。

推导第 3 步：回代核验。

$$(0.4, 0.6) \begin{pmatrix} 0.7 & 0.3 \\ 0.2 & 0.8 \end{pmatrix} = (0.4, 0.6),$$

且两个分量非负、和为 1，故它确为平稳分布。

定理 30.1 (有限链的平稳分布与唯一性层次) 每个有限状态马尔可夫链至少有一个平稳分布。若链不可约，则平稳分布唯一且每个分量严格为正；非周期性不是唯一性的必要条件。

先读结论、条件与反例

有限且不可约保证唯一平稳分布及时间平均定律；再加非周期性，才保证固定时刻的边缘分布收敛。两状态确定性交替链 $A = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$ 不可约但周期为 2：访问频率趋于 $(1/2, 1/2)$ ，而 $\rho_0 A^t$ 在两个点质量之间振荡。恒等链 $A = I_2$ 则说明缺少不可约性时平稳分布不唯一。采样章节只需先会核对这两组条件和反例；以下完整证明属于进阶证明附录。

进阶证明附录（首次阅读可跳过）。

读前自检：证明：有限链的平稳分布与唯一性层次。 有限链先由 Cesàro 平均 $\bar{v}_N = N^{-1} \sum_{t=0}^{N-1} v A^t$ 取收敛子列；请展开 $\bar{v}_N A - \bar{v}_N$ 的望远镜差，核对极限为 0，从而得到一个平稳分布。

证明. 存在性。 任取初始概率行向量 v ，构造 Cesàro 平均

$$\bar{v}_N = \frac{1}{N} \sum_{t=0}^{N-1} v A^t.$$

每个 $\bar{v}_N$ 都在有限维概率单纯形中。该单纯形闭且有界，因而存在子列 $\bar{v}_{N_k} \rightarrow \rho$ 。另一方面，求和首尾相消给出

$$\bar{v}_N A - \bar{v}_N = \frac{v A^N - v}{N}, \quad \|\bar{v}_N A - \bar{v}_N\|_1 \leq \frac{2}{N}.$$

沿收敛子列令 $k \rightarrow \infty$, 矩阵乘法的连续性给出 $\rho A = \rho$; 极限仍非负且分量和为 1, 所以 ρ 是平稳分布。这里没有使用不可约性或非周期性。

不可约时严格为正。 若某个 $\rho_j = 0$, 则对任意 $m \geq 1$ 都有 $\rho = \rho A^m$, 从而

$$0 = \rho_j = \sum_i \rho_i (A^m)_{ij}.$$

至少存在一个 k 使 $\rho_k > 0$ 。不可约性保证对目标 j 存在某个 m 使 $(A^m)_{kj} > 0$, 上式右端便至少含有一个严格正项, 矛盾。因此每个 $\rho_j > 0$ 。

不可约时唯一。 设 π 和 ρ 都是平稳分布。由上一步二者所有分量均严格为正, 故有限集合上的比值有最大值

$$c = \max_i \frac{\pi_i}{\rho_i}.$$

令 $h = c\rho - \pi$, 则 $h \geq 0$ 、 $hA = h$, 并且在某个状态 k 有 $h_k = 0$ 。若存在状态 i 使 $h_i > 0$, 不可约性给出某个 m 满足 $(A^m)_{ik} > 0$, 于是

$$0 = h_k = (hA^m)_k = \sum_j h_j (A^m)_{jk} \geq h_i (A^m)_{ik} > 0,$$

再次矛盾。所以 $h = 0$, 即 $\pi = c\rho$; 两边分量和都是 1 迫使 $c = 1$, 故 $\pi = \rho$ 。整个唯一性证明仍未使用非周期性。 $\square$

定理 30.1 把“存在”与“唯一”分开。不可约但周期为 2 的链仍可有唯一平稳分布, 却可能从某些初始分布持续振荡。逐步收敛需要在不可约之外再排除周期障碍。

读前自检：马尔可夫链的性质。 状态 j 从 i 可达定义为存在 $m \geq 0$ 使 $(A^m)_{ij} > 0$; 请在给定小转移图中相乘或枚举一条 m 步正概率路径, 核对 $i \rightarrow j$ 是否成立。

读前自检：不可约性。 有限链不可约要求任意 i, j 都存在 $m \geq 0$ 使 $(A^m)_{ij} > 0$; 请对一个候选转移图逐对检查可达性, 并用一个封闭真子集作为不可约性失败证书。

30.4 不可约、非周期与正常返

若存在 $m \geq 0$ 使 $(A^m)_{ij} > 0$, 称 j 从 i 可达, 记作 $i \rightarrow j$ 。若 $i \rightarrow j$ 且 $j \rightarrow i$, 两状态通信。所有状态彼此通信时, 链称为不可约。不可约性是状态图的全局连通性质, 不能从某个局部概率等式中推断。

读前自检：非周期性。 状态 i 的回返时刻集为 $\mathcal{T}_i = \{m \geq 1 : (A^m)_{ii} > 0\}$, 周期是其最大公约数; 请对一个给定 $\mathcal{T}_i$ 取 gcd, 核对 gcd 为 1 时该状态非周期。

读前自检：周期。 马尔可夫链状态 i 的周期 $d(i) = \gcd\{m \geq 1 : (A^m)_{ii} > 0\}$; 请分别用只含偶数回路与同时含相邻长度回路的最小图作对照, 核对周期分别大于 1 与等于 1。

定义 30.4 (周期). 状态 i 的正回返时长集合为

$$\mathcal{T}_i = \{m \geq 1 : (A^m)_{ii} > 0\},$$

其周期定义为 $d(i) = \gcd \mathcal{T}_i$; 若 $\mathcal{T}_i = \emptyset$, 本讲义约定 $d(i) = 0$ 。若 $d(i) = 1$, 称状态 i 非周期。不可约链中所有状态周期相同, 因此可以称整条链非周期或周期为 d 。

命题 30.1 (通信状态具有相同周期) 若 i 与 j 通信, 则 $d(i) = d(j)$ 。

读前自检: 证明: 通信状态具有相同周期。 通信状态同周期命题以 i 与 j 通信为条件; 请把正概率回路长度 $r+s$ 和 $r+n+s$ 相减, 先推出 $d(j) \mid d(i)$, 再交换 i, j 核对 $d(i) = d(j)$ 。

证明. 若 $i = j$, 等式两边是同一个周期量, 结论成立; 以下设 $i \neq j$ 。由通信性, 可选 $r, s \geq 1$ 使 $(A^r)_{ji} > 0$ 和 $(A^s)_{ij} > 0$ 。于是从 j 出发, 先用 r 步到 i 、再用 s 步回 j 的路径有正概率, 所以 $d(j)$ 整除 $r+s$ 。对任意 $n \in \mathcal{T}_i$, 在两段路径之间插入 i 处的 n 步回路, 得到 j 处长长度 $r+n+s$ 的正概率回路, 因此 $d(j)$ 也整除 $r+n+s$ 。两式相减说明 $d(j)$ 整除每个 $n \in \mathcal{T}_i$, 故 $d(j) \mid d(i)$ 。交换 i, j 得到 $d(i) \mid d(j)$, 所以二者相等。 $\square$

定义首次到达时间和首次正回返时间

$$\tau_i = \inf\{t \geq 0 : X_t = i\}, \quad \tau_i^+ = \inf\{t \geq 1 : X_t = i\}. \quad (30.12)$$

记

$$\mathbb{P}_i(\cdot) = P(\cdot \mid X_0 = i), \quad \mathbb{E}_i[\cdot] = E[\cdot \mid X_0 = i].$$

从状态 i 出发, 若 $\mathbb{P}_i(\tau_i^+ < \infty) = 1$, 称 i 常返; 若进一步

$$\mathbb{E}_i[\tau_i^+] < \infty, \quad (30.13)$$

称 i 正常返, 也称正返。有限不可约链中的每个状态都正常返。

图 30.3 区分首次到达、首次正回返和任意时刻处于 i 这三类事件。正常返由平均首次正回返时间是否有限定义, 不由某个单独时刻的首次到达概率是否保持为正来定义。




图 30.3 首次到达与首次正回返的区分: 正常返考察从 i 出发的 $\mathbb{E}_i[\tau_i^+]$, 而不是某个固定时刻首次到达的概率

常见错误

令 $p_t = \mathbb{P}_j(\tau_i = t)$ 。不同 t 对应互斥的首次到达事件，所以 $\sum_{t \geq 0} p_t \leq 1$ ，从而 $p_t \rightarrow 0$ 。因此“首次到达时刻概率的极限大于零”不能定义正常返。即使把 p_t 误换成普通 t 步转移概率，二状态交替链也会因奇偶振荡而没有极限。正确判据是式 (30.13)。

读前自检：有限状态链的唯一平稳分布。 有限不可约链具有唯一严格正平稳分布；请解 $\rho = \rho A$ 与 $\sum_i \rho_i = 1$ ，核对所得 $\rho_i > 0$ ，并说明固定时刻分布收敛还需非周期性。

读前自检：不可约正常返链。 不可约正常返链的平稳质量满足 $\rho_i > 0$ 且平均回返时间为 $1/\rho_i$ ；请对一个状态代入两量，核对有限平均回返与正平稳质量相互对应。

条件的作用可整理为：有限不可约性带来唯一平稳分布和正常返；非周期性进一步消除按剩余类振荡的障碍。对可数状态空间，需要把正常返作为独立条件，不能由不可约性自动推出。

读前自检：遍历定理。 有限不可约链的遍历定理对任意函数 f 给出时间平均收敛到 $\sum_i \rho_i f(i)$ ；请取 $f = \mathbf{1}_{\{j\}}$ ，核对左端成为状态 j 的访问频率、右端为 ρ_j 。

30.5 遍历定理与可逆性

定理 30.2 (有限不可约链的两类长期行为) 设有限状态马尔可夫链不可约，唯一平稳分布为 ρ 。对满足 $\sum_i \rho_i |f(i)| < \infty$ 的函数 f ，时间平均满足

$$\frac{1}{T} \sum_{t=0}^{T-1} f(X_t) \rightarrow \sum_i \rho_i f(i) \quad \text{以概率 1 成立.} \quad (30.14)$$

若再加非周期性，则对任意 i, j 有

$$(A^t)_{ij} \rightarrow \rho_j, \quad (30.15)$$

从而任意初始分布 $\rho_0 A^t \rightarrow \rho$ 。

证明：有限不可约链的两类长期行为：证明阅读检查

动手检查。 待证结论与所需条件分别是什么？请在最小维度或最小样本上写出第一处关键变形，并指出少一个条件时证明会在哪一步中断。

1. 先写清对象类型、目标结论与符号作用域。
2. 逐项核对定义域、维数、支持集、量词与交换运算所需条件。
3. 写出第一处可执行的数学动作，不用“显然”跳过入口。
4. 沿现有编号完成中间关系，并单独核对归一化、边界或等号条件。
5. 回到待证结论，再说明它与后续公式、算法、图或例题的连接。

继续核对。 完成上面的最小任务后，再对照主体逐项核对定义域、更新式或关键变形、停止条件以及返回值；阅读检查不代替正文中的数学论证。

证明. 第1步：构造有限均值的再生周期。固定参考状态 o 。由有限性与不可约性，从每个状态 x 都可选一条到达 o 的正概率路径；取整数 $L \geq 1$ 不小于这些有限条路径长度的最大值，并把各条路径的边概率乘积取最小值，得到 $\eta > 0$ 。在每个长度为 L 的时间块起点重新使用马尔可夫性质，便有

$$\mathbb{P}_x(\tau_o > kL) \leq (1 - \eta)^k, \quad k = 0, 1, \dots$$

因此 $\mathbb{E}_x[\tau_o] \leq L/\eta < \infty$ 。从 o 出发，令

$$\sigma_0 = 0, \quad \sigma_r = \inf\{t > \sigma_{r-1} : X_t = o\}, \quad L_r = \sigma_r - \sigma_{r-1}.$$

从 o 先走一步，再从 X_1 使用上述命中界，可得 $\mathbb{E}_o[L_1] \leq 1 + L/\eta < \infty$ 。由强马尔可夫性质，各段 $\{X_{\sigma_{r-1}}, \dots, X_{\sigma_r-1}\}$ 独立同分布，所以 $(L_r)_{r \geq 1}$ 也是独立同分布序列。这个结论只用了不可约性，没有使用非周期性。

第2步：由一个周期恢复平稳分布。记一个周期内访问状态 j 的次数为

$$N_j = \sum_{t=0}^{\sigma_1-1} \mathbf{1}_{\{X_t=j\}}, \quad g_j = \mathbb{E}_o[N_j], \quad m = \mathbb{E}_o[\sigma_1] = \sum_j g_j.$$

逐分量计算期望转移次数。为处理随机上限，先把和写成 $\sum_{t \geq 0} \mathbf{1}_{\{t < \sigma_1\}}(\cdot)$ ；再由 Tonelli 定理与塔式法则使用 $\mathbb{E}_o[\mathbf{1}_{\{t < \sigma_1\}} \mathbf{1}_{\{X_{t+1}=j\}} | \mathcal{F}_t] = \mathbf{1}_{\{t < \sigma_1\}} a_{X_t j}$ ，得到

$$\begin{aligned} (gA)_j &= \mathbb{E}_o \left[\sum_{t=0}^{\sigma_1-1} a_{X_t j} \right] = \mathbb{E}_o \left[\sum_{t=0}^{\sigma_1-1} \mathbf{1}_{\{X_{t+1}=j\}} \right] \\ &= \mathbb{E}_o \left[\sum_{t=1}^{\sigma_1} \mathbf{1}_{\{X_t=j\}} \right] = g_j. \end{aligned}$$

最后一个等号成立，是因为周期起点 X_0 与终点 X_{σ_1} 都等于 o ，移去起点再添上终点不会改变任何状态的访问计数。因此 g/m 是概率行向量且满足 $(g/m)A = g/m$ 。由定理 30.1 的唯一性，

$$\rho_j = \frac{g_j}{m}. \quad (30.16)$$

第3步：周期奖励的强大数律。令第 r 个周期的奖励为

$$R_r = \sum_{t=\sigma_{r-1}}^{\sigma_r-1} f(X_t).$$

有限状态下 f 有界，并且 $\mathbb{E}_o[L_1] < \infty$ ，所以 R_r 可积。由式 (30.16)，

$$\mathbb{E}_o[R_1] = \sum_j f(j)g_j = m \sum_j \rho_j f(j).$$

对独立同分布的 (R_r, L_r) 使用强大数律, 几乎必然有

$$\frac{\sum_{r=1}^q R_r}{\sum_{r=1}^q L_r} \rightarrow \frac{\mathbb{E}_o[R_1]}{\mathbb{E}_o[L_1]} = \sum_j \rho_j f(j).$$

还需检查未完成周期。可积性给出 $\sum_{r \geq 1} \mathbb{P}(L_r > \varepsilon r) < \infty$, 故由 Borel–Cantelli 引理, $L_r/r \rightarrow 0$ 几乎必然成立。若 $Q(T) = \max\{r : \sigma_r \leq T\}$, 周期长度的强大数律给出 $Q(T)/T \rightarrow 1/m$, 从而 $Q(T) \rightarrow \infty$ 且

$$\frac{L_{Q(T)+1}}{T} = \frac{L_{Q(T)+1}}{Q(T)+1} \frac{Q(T)+1}{T} \rightarrow 0.$$

于是末段奖励的绝对值至多为 $\|f\|_\infty L_{Q(T)+1} = o(T)$ 。从任意状态出发时, 前述几何尾界保证首次到达 o 的时间几乎必然有限, 有限首段除以 T 也趋于 0。这就证明了式 (30.14), 全程没有要求非周期性。

第 4 步: 非周期性给出共同的正矩阵幂。 现在再假设链非周期。参考状态 o 的正回返时长集合的最大公约数为 1, 所以其中存在有限个 $n_1, \dots, n_q$ 满足 $\gcd(n_1, \dots, n_q) = 1$ 。把这些回路串接, 任意 $k_c \in \mathbb{N}_0$ 给出的线性组合 $\sum_{c=1}^q k_c n_c$ 仍是 o 的正回返时长。令 $a = n_1$; $n_1, \dots, n_q$ 在有限群 $\mathbb{Z}/a\mathbb{Z}$ 中生成全部剩余类, 而有限群中由这些剩余类生成的子幺半群就是它们生成的子群。因此对每个剩余类 b 都能选一个非负组合 u_b 落在该类。取 $N_0 = \max_b u_b$, 则任意 $N \geq N_0$ 都可写成 $u_b + ka$, 故

$$(A^N)_{oo} > 0, \quad N \geq N_0.$$

再为每个 i, j 分别固定正概率路径 $i \rightarrow o$ 和 $o \rightarrow j$, 长度记为 r_i, s_j , 允许 o 处长度为 0。取整数

$$M \geq \max\left\{1, N_0 + \max_{i,j} (r_i + s_j)\right\},$$

则中间还能插入长度 $M - r_i - s_j \geq N_0$ 的 o 处回路, 从而 $(A^M)_{ij} > 0$ 对所有 i, j 成立。

第 5 步: Doeblin 分解与收缩。 令

$$\delta = \min_{i,j} (A^M)_{ij} > 0, \quad \alpha = n\delta \in (0, 1], \quad u = (1/n, \dots, 1/n).$$

若 $\alpha = 1$, 行和为 1 迫使 A^M 的每一行都等于 u ; 又因 ρ 平稳, $\rho = \rho A^M = u$, 故任意初始分布 ν 都满足 $\nu A^M = u = \rho$, 经过一个 M 步块即到达平稳分布。若 $0 < \alpha < 1$, 则

$$B = \frac{A^M - \alpha \mathbf{1}u}{1 - \alpha}$$

仍是行随机矩阵。对任意两个概率行向量 ν, ξ , 利用 $\|zB\|_1 \leq \|z\|_1$ 得到

$$\|\nu A^M - \xi A^M\|_1 \leq (1 - \alpha) \|\nu - \xi\|_1.$$

把 $t = kM + r$, 其中 $0 \leq r < M$, 并取 $\xi = \rho$, 便有

$$\|\nu A^t - \rho\|_1 \leq (1 - \alpha)^k \|\nu A^r - \rho\|_1 \leq 2(1 - \alpha)^k \rightarrow 0.$$

于是每个分量都满足式 (30.15)，任意初始分布也收敛到 ρ 。 $\square$

式 (30.14) 描述一条长路径上的访问频率，式 (30.15) 描述固定时刻的边缘分布。周期链可以满足前者而不满足后者。

读前自检：范围说明。 可数状态空间中不可约不自动推出正常返；请用整数线上的对称随机游走作对照，核对任意两点互相可达，但不存在可归一化的平稳概率分布。

范围说明

可数状态空间中，不可约性不再自动保证正常返。不可约且正常返时，再生周期仍可证明时间平均结论；再加非周期性后，逐步极限可由离散更新定理证明。本定理把正式证明限定在有限状态情形，并在第 4–5 步明确使用有限性，不能把正矩阵幂与 Doeblin 常数的论证无条件套到可数链。

读前自检：可逆马尔可夫链。 可逆链满足细致平衡 $\rho_i a_{ij} = \rho_j a_{ji}$ ；请对 i 求和并用第 j 行和为 1，核对 $\sum_i \rho_i a_{ij} = \rho_j$ ，从而细致平衡推出平稳性。

定义 30.5 (细致平衡与可逆性). 若概率分布 ρ 满足

$$\rho_i a_{ij} = \rho_j a_{ji}, \quad i, j \in \mathcal{S}, \quad (30.17)$$

则称 A 关于 ρ 满足细致平衡，链关于 ρ 可逆。等式两边都是平稳权重下沿同一条边相反方向的一步概率流。

本讲义只使用式 (30.17) 或等价的双向前向条件概率表达，不使用把时间反向条件概率与前向条件概率混为同一个式子的写法。

阅读目标：逐分量求和，分清该证明与不可约性的关系。

对象：转移矩阵 A 与分布 ρ ，满足 $\rho_i a_{ij} = \rho_j a_{ji}$ 。

合法条件： A 每行和为 1；细致平衡对所有 i, j 成立。

第一步：先固定目标状态 j ，写 $(\rho A)_j = \sum_i \rho_i a_{ij}$ 。

推导目标

从细致平衡逐分量证明 ρ 是平稳分布，同时指出证明没有使用不可约性。

推导准备

固定目标状态 j ，对所有来源状态 i 求和；再使用 A 第 j 行的和为 1。

推导第 1 步：写出流入量。

$$(\rho A)_j = \sum_i \rho_i a_{ij}.$$

推导第2步：逐边反向。由细致平衡，

$$\sum_i \rho_i a_{ij} = \sum_i \rho_j a_{ji} = \rho_j \sum_i a_{ji}.$$

推导第3步：使用行和。这里 i 遍历的是矩阵第 j 行的目的状态，所以 $\sum_i a_{ji} = 1$ ，于是 $(\rho A)_j = \rho_j$ 。对每个 j 成立，故 $\rho A = \rho$ 。

常见错误

细致平衡只保证平稳性。取 $A = I_2$ 和任意严格正概率行向量 $\rho = (a, 1-a)$ ，其中 $0 < a < 1$ ，所有等式 $\rho_i a_{ij} = \rho_j a_{ji}$ 都成立，但两个状态互不可达，链可约，且平稳分布不唯一。再取 $f(1) = 0, f(2) = 1$ ：从状态 1 出发时路径恒留在 1，时间平均恒为 0，而指定分布下的空间平均为 $\sum_i \rho_i f(i) = 1-a > 0$ 。因此仅有可逆性也不保证无条件时间平均结论、非周期性或从任意初值逐步收敛；不可约性等条件必须另行验证。

几何解释。所有 n 维概率分布组成概率单纯形，映射 $\rho \mapsto \rho A$ 将该单纯形映回自身。平稳分布是这个仿射映射的固定点。图 30.4 在两状态概率区间上画出 $r \mapsto 0.2 + 0.5r$ ，固定点 $r = 0.4$ 对应 $\rho = (0.4, 0.6)$ 。




图 30.4 两状态概率单纯形上的平稳固定点：映射 $r \mapsto 0.2 + 0.5r$ 把任意初值逐步拉向 $r_{\star} = 0.4$


概率解释。不可约性回答“能否在状态之间往返”，周期性回答“回来的时刻是否被某个公因数锁定”，“正常返”回答“平均要等多久才能回来”，平稳性回答“总体概率质量是否保持不变”。四者回答的问题不同，不能用其中一个术语替代另一个。

读前自检：不适用说明：遍历定理与可逆性。马尔可夫链平稳分布由固定点与概率约束刻画，并无内生损失最小化目标；请把“梯度为零”当作错误判据构造反例，再用 $\rho = \rho A$ 重算并核对归一化。

固定点视角

本章的平稳分布由固定点方程 $\rho = \rho A$ 和概率约束刻画，没有内生损失函数或待极小化目标。可以用线性方程求解，无需另行构造优化目标。

图形辅助。图 30.5 并列展示可约非周期、不可约周期和不可约非周期三种状态图；是否存在自环、图是否连通以及返回路径长度必须分别检查。



结构性质不可相互替代：连通性、回返节律与期望回返时间必须分别检查

图 30.5 三类结构必须分别判断：支撑图连通性决定不可约性，正回返时长的最大公约数决定周期性

图 30.6 把相反方向的平稳概率流画在同一条边上，并同时给出 $A = I_2$ 的断开反例。流量对称不等于支撑图连通。




图 30.6 流量对称可证平稳，却不能证连通或唯一

例题 30.1 (周期链、惰性化与平稳性的数值辨析). 对周期链

$$C = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}, \quad \rho_0 = (1, 0),$$

计算前两步分布，求平稳分布并核验细致平衡；再比较惰性化矩阵 $C_L = (I + C)/2$ 的长期行为。

例题 30.1 解答

读题翻译 这条两状态链每步必换状态；需要同时辨清“存在平稳分布”“满足细致平衡”和“从给定初值逐步收敛”并不是同一结论，再看惰性化如何改变周期。

已知与合法条件 使用概率行向量递推 $\rho_{t+1} = \rho_t C$, $\rho_0 = (1, 0)$; $C_L = (I + C)/2$ 在两个状态都加入正自环。

为什么想到这个方法 先算前两步展示奇偶振荡，再解 $\rho = \rho C$ 并检验双向流；最后由回返长度的最大公因数判断周期。

方法选择 计算 ρ_1, ρ_2 ，求归一化平稳分布并验证细致平衡；再写出 C_L ，核对平稳分布、周期与任意初值的一步结果。

推导/计算 计算。原链的行向量递推为

$$\rho_1 = (0, 1), \quad \rho_2 = (1, 0),$$

所以边缘分布按奇偶时刻振荡。方程 $\rho_\star = \rho_\star C$ 给出唯一平稳分布 $\rho_\star = (1/2, 1/2)$ ，且

$$(\rho_\star)_1 c_{12} = \frac{1}{2} = (\rho_\star)_2 c_{21},$$

故链可逆且不可约，却因所有正回返长度均为偶数而周期为 2，平稳性并不推出逐步收敛。惰性化后 $C_L = \begin{pmatrix} 1/2 & 1/2 \\ 1/2 & 1/2 \end{pmatrix}$ ，同一 $\rho_\star$ 仍平稳，而正自环把周期降为 1；任意初始分布一步后即等于 $\rho_\star$ 。

独立核验 直接相乘有 $\rho_\star C = \rho_\star$ 、 $\rho_\star C_L = \rho_\star$ ，且 $C_L^2 = C_L$ ；后一恒等式说明任意概率行向量经一步映到 $\rho_\star$ 后保持不变。

结论 原链虽有唯一平稳分布 $(1/2, 1/2)$ 且可逆，但周期 2 使给定初值的边缘分布振荡；惰性化保留该平稳分布并把周期降为 1，任意初始分布一步后即到达它。本例专门展示周期障碍，后文例 30.2 再完成非对称转移矩阵的全量审计。

30.6 随机游走

贯穿例：四节点小图

本章角色：把同一加权有向小图行归一化为转移矩阵，分析分布推进与平稳性；第 36 章（第 5 册第 7 章）将转置后的同一数据用于 PageRank。

取

$$A = \begin{bmatrix} 0 & 1/3 & 1/3 & 1/3 \\ 1/2 & 0 & 0 & 1/2 \\ 1 & 0 & 0 & 0 \\ 0 & 1/2 & 1/2 & 0 \end{bmatrix}, \quad \rho_0 = \frac{1}{4} \mathbf{1}^\top.$$

矩阵 A 逐项非负且每行和为 1，所以它满足本章有限状态马尔可夫链的模型假设。它的平稳概率行向量是 $\rho_\star = (1/3, 2/9, 2/9, 2/9)$ 。第 36 章（第 5 册第 7 章）使用 $M = A^\top$ 和 $\mathbf{r}^{(0)} = \rho_0^\top$ ，

数据与边方向不变，只切换行/列表示。下一站见第36章（第5册第7章）的列随机 PageRank 表示。

设 $G = (V, E)$ 为无向图，顶点 i 的度数为 d_i 。简单随机游走从 i 出发，以相等概率选择一个邻点：

$$a_{ij} = \begin{cases} 1/d_i, & \{i, j\} \in E, \\ 0, & \text{其他情形.} \end{cases} \quad (30.18)$$

若图连通，链不可约。若图是二部图且没有自环，游走每步在两个顶点部之间交替，周期为 2。惰性随机游走把矩阵改为 $A_L = \frac{1}{2}(I + A)$ ，从而给每个状态加入正自环并保持原平稳分布。

阅读目标：沿每条无向边比较双向概率流，得到与结点度成正比的分布。

对象：连通无向图、结点度 d_i 与简单随机游走转移概率。

合法条件： $D = \sum_i d_i = 2|E| > 0$ ；孤立点不存在。

第一步：先取候选 $\rho_i = d_i/D$ ，并对相邻结点 i, j 计算 $\rho_i p_{ij}$ 。

推导目标

求连通无向图简单随机游走的平稳分布。

推导准备

令 $D = \sum_{k \in V} d_k = 2|E|$ ，候选分布取 $\rho_i = d_i/D$ 。沿无向边比较两个方向的概率流。

推导第 1 步：检查概率约束。 $\rho_i \geq 0$ 且 $\sum_i \rho_i = D/D = 1$ 。

推导第 2 步：检查每条边。 若 $\{i, j\} \in E$ ，则

$$\rho_i a_{ij} = \frac{d_i}{D} \frac{1}{d_i} = \frac{1}{D} = \frac{d_j}{D} \frac{1}{d_j} = \rho_j a_{ji};$$

非相邻顶点的两个方向都为 0。

推导第 3 步：使用细致平衡结论。 候选分布满足式 (30.17)，故

$$\rho_i = \frac{d_i}{\sum_k d_k} \quad (30.19)$$

是平稳分布。连通性进一步保证它唯一，但若图为二部图，普通逐步分布仍会按奇偶振荡。

图 30.7 展示三节点路径上的简单游走及其惰性版本。端点度数为 1、中点度数为 2，所以平稳分布为 $(1/4, 1/2, 1/4)$ ；加入自环后该分布不变。

输入与输出。 输入为 $n \times n$ 候选转移矩阵 A 、长度 n 的候选初始分布 ρ_0 、非负整数时域 T 和容差 ε ，其中 $n \geq 1$ 。算法先检查概率约束，再给出最后一个合法分布及其推进轨迹；若检查或更新失败，则停止在此前已经得到的合法分布，并说明原因。




图 30.7 三节点路径的简单游走与惰性游走：加入自环保持平稳分布并消除周期振荡

参数含义。 T 控制推进步数, $0 < \varepsilon < 1$ 只用于判断浮点求和误差 $|s - 1|$ 是否可接受, 不用于放宽分量的概率域, 也不是统计估计精度。每个分量都必须严格满足 $0 \leq x \leq 1$; 浮点数 -0 按 0 处理。行和、初始和与候选和一律采用补偿求和或具有同等误差控制的稳定求和实现。

初始化。先检查 A 是否为方阵且每个元素有限并位于 $[0, 1]$ 。第 i 行原始和 s_i 若满足 $|s_i - 1| \leq \varepsilon$, 则显式令 $\hat{a}_{ij} = a_{ij}/s_i$, 记录行号、原始和与缩放因子, 再复检分量域和行和; 超出容差或复检失败时返回 $\perp$ 。 ρ_0 按同一规则得到 $\hat{\rho}_0$ 。这里的规范化只修正已通过容差门的求和舍入误差, 绝不裁剪负分量或修补超出概率域的输出。

更新顺序与判断条件。循环变量为 $t = 0, \dots, T - 1$ 。每轮先保留当前有效分布, 再按行向量顺序用 $\hat{A}$ 计算候选 $v \leftarrow \rho_t \hat{A}$ 。只有当 v 有限、每个分量严格位于 $[0, 1]$ 且原始和 s^+ 满足 $|s^+ - 1| \leq \varepsilon$ 时, 才令 $\rho_{t+1} = v/s^+$ 并复检; 不得写成 $\hat{A}\rho_t$, 也不得把负分量裁成 0 。

停止条件。输入检查不通过时不进行矩阵推进; 中途候选或规范化复检失败时, 保留上一步合法分布和此前完成的 t 步, 失败候选不加入轨迹。正常停止发生在恰好完成 T 次更新后; $T = 0$ 仍检查输入并保留 $\hat{\rho}_0$ 。固定时域停止不等于已经达到平稳分布。

收敛条件。算法对有限 T 总能在有限步内结束。若讨论 $T \rightarrow \infty$ 的分布极限, 则有限链还需不可约且非周期; 只有不可约而周期时, 算法仍正确计算每一步, 但输出序列可能振荡。

读前自检：有限状态链的分布推进与合法性检查：执行契约。 有限状态链的分布推进与合法性检查输入“状态数 n 、候选行随机矩阵 A 、候选初始行分布 ρ_0 、有限推进步数 T 与求和容差 ε ”, 条件“ $n \geq 1, T \in \mathbb{N}_0, 0 < \varepsilon < 1$ ”; 请执行“ ρ^+ 通过有限性、 $[0, 1]$ 分量域和行和复检后, 才原子覆盖 ρ 、追加轨迹并增加 t_{done} ”, 以“恰好完成 T 步或首次失败时停止”判停。

有限状态链的分布推进与合法性检查：五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新, 并指出何时提交。

数学停止。写出能直接核验的停止证书; 预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 30.1: 有限状态链的分布推进与合法性检查

输入: 整数 $n \geq 1$; 候选矩阵 $A \in \mathbb{R}^{n \times n}$; 候选行向量 $\rho_0 \in \mathbb{R}^{1 \times n}$; $T \in \mathbb{N}_0$; $0 < \varepsilon < 1$

输出: 最后合法分布与轨迹; $t_{\text{done}}, r_{\text{done}}$; **status** 及最终诊断

- 1 令 $t_{\text{done}} \leftarrow 0, r_{\text{done}} \leftarrow 0$; 检查 n 、维数、有限值、 T 与 ε ; 若不满足则返回 $\perp, \emptyset, 0, 0, \text{invalid_input}$ 及字段诊断
- 2 对 $i \leftarrow 1, \dots, n$ 执行
 - 3 令 $s_i \leftarrow \sum_j a_{ij}$; 若某 $a_{ij} \notin [0, 1]$ 或 $|s_i - 1| > \varepsilon$, 则返回 $\perp, \emptyset, 0, r_{\text{done}}, \text{invalid_input}$ 及失败 (i, j) 或行和诊断
 - 4 在临时行中令 $\hat{a}_{ij} = a_{ij}/s_i$; 若有限性、分量域或行和复检失败, 则返回尚未完整的矩阵占位、**numerical_failure** 及行 i 诊断; 否则原子提交该行并令 $r_{\text{done}} \leftarrow i$
- 5 结束
- 6 令 $s_0 \leftarrow \sum_i (\rho_0)_i$; 若某 $(\rho_0)_i \notin [0, 1]$ 或 $|s_0 - 1| > \varepsilon$, 则返回 $\perp, \emptyset, 0, r_{\text{done}}, \text{invalid_input}$ 及初始分布诊断
- 7 令 $\hat{\rho}_0 = \rho_0/s_0$; 若复检失败则返回 $\perp, \emptyset, 0, r_{\text{done}}, \text{numerical_failure}$ 及初始规范化诊断
- 8 初始化 $\rho \leftarrow \hat{\rho}_0$ 及轨迹 $\mathcal{R} \leftarrow (\hat{\rho}_0)$
- 9 当 $t_{\text{done}} < T$ 执行
 - 10 按 $v_j \leftarrow \sum_i \rho_i \hat{a}_{ij}$ 依次计算全部 j 分量, 令 $s^+ \leftarrow \sum_j v_j$
 - 11 若 v 含非有限值、某分量不在 $[0, 1]$ 或 $|s^+ - 1| > \varepsilon$ 则
 - 12 返回 $\rho, \mathcal{R}, t_{\text{done}}, r_{\text{done}}, \text{numerical_failure}$ 及候选步 $t_{\text{done}} + 1$ 诊断; 不追加 v
 - 13 结束
 - 14 令 $\rho^+ \leftarrow v/s^+$; 若规范化后复检失败, 则返回上一合法 $\rho, \mathcal{R}, t_{\text{done}}, r_{\text{done}}, \text{numerical_failure}$ 及候选规范化诊断
 - 15 原子提交 $\rho \leftarrow \rho^+$ 并向 $\mathcal{R}$ 追加 ρ ; 令 $t_{\text{done}} \leftarrow t_{\text{done}} + 1$
- 16 结束
- 17 返回 $\rho, \mathcal{R}, t_{\text{done}}, r_{\text{done}}, \text{completed}$ 及概率不变量与计划/实际步数诊断

算法实现说明: 核心流程核对概率输入、重复计算 $\rho_{t+1} = \rho_t A$ 、保持总质量并按给定 T 停止; 容差规范化与失败诊断属于稳健实现细节 完整 C1–C14 契约

返回结果与正确性依据。预处理后的 $\hat{A}$ 逐行非负且行和为 1, $\hat{\rho}_0$ 也是真正的概率分布。若 ρ_t 有效, 则精确算术下 $v = \rho_t \hat{A}$ 非负且 $\sum_j v_j = \sum_j \sum_i (\rho_t)_i \hat{a}_{ij} = \sum_i (\rho_t)_i \sum_j \hat{a}_{ij} = 1$ 。实现中只对已通过严格分量域与求和容差检查的 v 除以其原始和, 并再次复检, 所以归纳地, 每个被接受并返回的向量都是真正的概率分布; 输入失败时则只返回 $\perp$ 。

异常与退化。异常包括维数不匹配、非有限数、任一分量越出 $[0, 1]$ 、总和超出容差和中途数值漂移。特别地, 第一行为 $(-\varepsilon/2, 1 + \varepsilon/2)$ 的矩阵虽然行和等于 1, 仍会在严格分量域检查处返回 $\perp$, 不会经过裁剪后伪装成概率行。可约链与周期链不是非法输入, 但它们使长期解释依赖初始闭类或奇偶时刻, 必须在诊断中与数值错误分开。

手工核对。对 $A = \begin{pmatrix} 0.7 & 0.3 \\ 0.2 & 0.8 \end{pmatrix}$ 、 $\rho_0 = (1, 0)$ 和 $T = 2$, 各原始和均为 1, 规范化因子均为 1, 两轮依次得到 $(0.7, 0.3)$ 与 $(0.55, 0.45)$, 均通过复检。把第一行改成 $(-\varepsilon/2, 1 + \varepsilon/2)$ 后, 算法在任何矩阵乘法之前停止。这两个用例分别覆盖正常路径和“行和正确但含负概率”的拒绝路径。

不收敛或不适用情形。周期链可以永久振荡; 可约链可能收敛到依赖初始分布的平稳组合; 连续状态核不能由此有限矩阵算法完整表示。达到 T 只表示预算执行完毕, 不能据此声称渐近收敛。

读前自检: 复杂度分析: 随机游走。稀疏 n 状态转移矩阵有 $s = \text{nnz}(A)$ 个非零元; 请计算一次行分布推进的 $\Theta(s)$ 时间与 $\Theta(n)$ 工作空间, 并核对保存全部 $T + 1$ 层时存储增为 $\Theta(Tn)$ 。

复杂度分析

复杂度假设。基本标量加乘和比较按 $O(1)$ 计；记 $s = \text{nnz}(\hat{A})$ 为规范化矩阵的非零元数。行随机矩阵每行至少有一个非零元，故 $s \geq n$ ；输出完整轨迹时计入 $\hat{\rho}_0$ 在内。

训练时间复杂度。不适用，因为算法不执行参数训练。矩阵合法性检查与规范化在稠密表示下为 $\Theta(n^2)$ ，在稀疏表示下为 $\Theta(s + n)$ 。

预测时间复杂度。这里“预测”指分布推进。含一次输入校验在内，稠密总时间为 $\Theta((T+1)n^2)$ ；稀疏总时间为 $\Theta((T+1)(s+n)) = \Theta((T+1)s)$ 。因此 $T=0$ 也不会跳过合法性检查。

空间复杂度。除输出外，当前、候选和下一分布占 $\Theta(n)$ 额外工作空间；若保留包含 $\hat{\rho}_0$ 的完整轨迹，输出占 $\Theta((T+1)n)$ 。若计入矩阵，稠密存储为 $\Theta(n^2)$ ，稀疏存储为 $\Theta(s)$ 。

适用条件与局限性

方法适用条件。算法适用于有限状态、时齐且转移矩阵已知的链，可用于有限时域概率预测、数值例题和长期行为的实验性检查。

方法局限性。它不估计 A ，不替代不可约性和周期性的结构证明，也不能仅凭有限轮数确认渐近收敛。状态数很大时应利用稀疏结构；连续状态时应改用核积分或采样方法。

常见错误。最常见的方向错误是把行概率向量推进写成 $A\rho_t$ ；另一些错误包括把行和检查成列和、裁剪负分量、把超出容差的非法输入静默归一化、把唯一平稳分布误当成逐步收敛，以及把可逆性误当成不可约性。

易混淆概念对比。平稳性是分布固定点，可逆性是逐边流量对称；不可约性是通信结构，非周期性是返回时长结构；正常返是平均回返时间有限，逐步收敛还需要消除周期障碍。

例题 30.2 (一条两状态链的完整审计). 给定

$$A = \begin{pmatrix} 0.7 & 0.3 \\ 0.2 & 0.8 \end{pmatrix}, \quad \rho_0 = (1, 0),$$

要求核对合法性，计算两步分布，求平稳分布，判断不可约、周期与可逆性，并说明逐步收敛条件是否满足。

例题 30.2 解答

读题翻译 要对给定两状态转移矩阵完成一条闭合审计链：随机矩阵合法性、两步推进、平稳分布、不可约性、周期、可逆性与逐步收敛条件缺一不可。

已知与合法条件 采用行随机约定 $\rho_{t+1} = \rho_t A$ ；平稳分布须同时满足 $\rho_\star A = \rho_\star$ 、 $\rho_\star \mathbf{1} = 1$ 和非负性。

为什么想到这个方法 先验证每行概率和并推进分布，再解平稳方程；两状态链可由双向正边判不可约、正自环判非周期，并用唯一非平凡边检查细致平衡。

方法选择 核对 $A\mathbf{1} = \mathbf{1}$ 与非负性，计算 ρ_1, ρ_2 ；求 $\rho_\star$ ，逐项检查结构和细致平衡，最后套用有限链收敛条件。

推导/计算 计算。合法性与两步更新可合并核验为

$$\begin{aligned} A\mathbf{1} &= \mathbf{1}, \quad A \geq 0, \\ \rho_1 &= (1, 0)A = (0.7, 0.3), \\ \rho_2 &= (0.7, 0.3)A = (0.55, 0.45). \end{aligned}$$

解 $\rho_\star = \rho_\star A$ 及 $\rho_\star \mathbf{1} = 1$ 得到 $\rho_\star = (0.4, 0.6)$, 且

$$0.4a_{12} = 0.4 \times 0.3 = 0.12 = 0.6 \times 0.2 = 0.6a_{21}.$$

所以链可逆。 $a_{12}, a_{21} > 0$ 给出不可约性, 正自环给出周期 1; 有限、不可约、非周期三项均满足, 故任意初始分布的逐步分布收敛到 $\rho_\star$ 。

独立核验 直接代回得到 $(0.4, 0.6)A = (0.4, 0.6)$; 同时 $\rho_1 \mathbf{1} = \rho_2 \mathbf{1} = 1$, 排除了分布推进中的行列约定错误。

结论 该链合法、不可约、非周期且可逆, 唯一平稳分布为 $(0.4, 0.6)$; 有限链条件齐全, 因此从任意初始分布逐步收敛到该分布。

常见错误

三个索引陷阱需要单独检查。第一, 反向条件概率不能在缺少平稳加权时与前向条件概率互换, 本章以式 (30.17) 为唯一细致平衡口径。第二, 细致平衡只推出平稳性; 没有不可约性时不推出唯一性或遍历收敛。第三, 考虑状态空间 $\{1, 2, \dots\}$ 上的生灭链: 状态 1 以概率 p 自环、以概率 q 到状态 2; 状态 $i \geq 2$ 以概率 p 向左、以概率 q 向右, 其中 $p + q = 1$ 且 $p > q$ 。令 $r = q/p \in (0, 1)$, 候选平稳分布应为

$$\rho_i = (1 - r)r^{i-1}, \quad i = 1, 2, \dots, \quad 0 < r < 1.$$

其归一化、相邻边细致平衡与状态 1 的边界方程依次为

$$\sum_{i=1}^{\infty} (1 - r)r^{i-1} = 1,$$

$$\rho_i q = (1 - r)r^{i-1}q = (1 - r)r^i p = \rho_{i+1} p, \quad i \geq 1,$$

$$\rho_1 p + \rho_2 p = (1 - r)p(1 + r) = (1 - r)(p + q) = \rho_1.$$

因此该序列既归一化又满足平稳方程。若把指数写成 i , 总质量会变成 r 而不是 1; 若 $0 < p \leq q$, 则 $r \geq 1$, 该几何序列无法归一化; 若 $p = 0$, 链只向右移动, 同样不存在该几何平稳分布。

本章共 14 道练习。每道题干后立即给出同号解析; 长解析可自然跨页, 续页标题保留题号。

【原书练习整理】

练习 30.1. 证明：若一条马尔可夫链不可约，且其中一个状态非周期，则所有状态都非周期。

练习 30.1 解析

记回返时长集合 $R_i = \{n \geq 1 : (A^n)_{ii} > 0\}$ ，周期 $d(i) = \gcd R_i$ 。不可约性保证可取 $r, s \geq 1$ 使 $(A^r)_{ji} > 0$ 、 $(A^s)_{ij} > 0$ 。于是对任意 $n \in R_i$ ，矩阵乘法给出

$$\begin{aligned}(A^{r+s})_{jj} &\geq (A^r)_{ji}(A^s)_{ij} > 0, \\ (A^{r+n+s})_{jj} &\geq (A^r)_{ji}(A^n)_{ii}(A^s)_{ij} > 0, \\ d(j) \mid (r+s), \quad d(j) \mid (r+n+s) &\implies d(j) \mid n.\end{aligned}$$

因此 $d(j)$ 整除 R_i 的每个元素。交换 i, j 后同理，故

$$d(j) \mid d(i), \quad d(i) \mid d(j) \implies d(i) = d(j).$$

若某个状态周期为 1，不可约类中的全部状态周期都为 1。

练习 30.2. 对行随机矩阵

$$A = \begin{pmatrix} 1/2 & 1/2 & 0 & 0 \\ 1/2 & 0 & 1/2 & 0 \\ 0 & 1/2 & 0 & 1/2 \\ 0 & 0 & 0 & 1 \end{pmatrix},$$

验证对应马尔可夫链可约但非周期，并写出通信类和关键返回路径。

练习 30.2 解析

合法性由 $A \geq 0$ 及 $A\mathbf{1} = \mathbf{1}$ 给出。正概率路径满足

$$\begin{aligned}1 &\leftrightarrow 2, & 2 &\leftrightarrow 3, \\ 3 &\rightarrow 4, & 4 &\rightarrow 4, & 4 \not\rightarrow \{1, 2, 3\}, \\ \mathcal{C}_1 &= \{1, 2, 3\}, & \mathcal{C}_2 &= \{4\}.\end{aligned}$$

$\mathcal{C}_2$ 闭而 $\mathcal{C}_1$ 非闭，故链可约。周期方面， $(A)_{11} > 0$ 与 $(A)_{44} > 0$ 给出 $d(1) = d(4) = 1$ ；又因 1, 2, 3 通信，

$$d(2) = d(3) = d(1) = 1, \quad d(4) = 1.$$

所以每个状态均非周期。这说明逐状态非周期性不推出不可约性。

练习 30.3. 对行随机矩阵

$$A = \begin{pmatrix} 0 & 1 & 0 & 0 \\ 1/2 & 0 & 1/2 & 0 \\ 0 & 1/2 & 0 & 1/2 \\ 0 & 0 & 1 & 0 \end{pmatrix},$$

验证对应马尔可夫链不可约但周期为 2。

练习 30.3 解析

正概率支撑图是双向路径 $1 \leftrightarrow 2 \leftrightarrow 3 \leftrightarrow 4$, 所以任意 i, j 都有某个 n 使 $(A^n)_{ij} > 0$, 链不可约。令 $C_0 = \{1, 3\}$ 、 $C_1 = \{2, 4\}$; 每步交换二部, 故

$$\begin{aligned}(A^{2m+1})_{ii} &= 0 & (m \geq 0), \\ (A^2)_{11} &\geq a_{12}a_{21} > 0, & (A^2)_{22} \geq a_{21}a_{12} > 0, \\ (A^2)_{33} &\geq a_{34}a_{43} > 0, & (A^2)_{44} \geq a_{43}a_{34} > 0.\end{aligned}$$

因此

$$R_i \subseteq 2\mathbb{N}, \quad 2 \in R_i \implies d(i) = \gcd R_i = 2.$$

链不可约但周期为 2。

练习 30.4. 判断命题“可逆马尔可夫链一定不可约”是否成立。若不成立, 给出最小有限状态反例, 并说明还需单独检查什么条件。

练习 30.4 解析

命题不成立。最小反例取状态空间 $S = \{1, 2\}$ 、 $A = I_2$ 和 $\rho = (a, 1-a)$, 其中 $0 < a < 1$; ρ 已归一化。对任意 $i, j \in S$,

$$\begin{aligned}\rho_i a_{ij} &= \rho_i \mathbf{1}\{i = j\} = \rho_j \mathbf{1}\{j = i\} = \rho_j a_{ji}, \\ \rho A &= \rho, \quad \{1\}, \{2\} \text{ 均为闭通信类.}\end{aligned}$$

所以链关于 ρ 可逆却可约, 且所有 $(b, 1-b)$ 都是平稳分布。再取 $f(1) = 0, f(2) = 1$ 并从状态 1 出发, 则

$$\frac{1}{T} \sum_{t=0}^{T-1} f(X_t) = 0 \quad \text{而} \quad E_\rho f = \sum_{i \in S} \rho_i f(i) = 1 - a > 0.$$

要得到唯一平稳分布、时间平均或固定时刻收敛, 必须分别核验不可约/正常返及非周期等条件。

练习 30.5. 两状态时齐链的矩阵为 $A = \begin{pmatrix} 0.7 & 0.3 \\ 0.2 & 0.8 \end{pmatrix}$, 且 $X_0 = 1$ 。计算路径 $(X_0, X_1, X_2) = (1, 2, 2)$ 的概率, 并写出所用的马尔可夫路径分解。

练习 30.5 解析

由 $X_0 = 1$ 可知初始因子为 1。路径依次使用从 1 到 2 的概率 $a_{12} = 0.3$ 和从 2 到 2 的概率 $a_{22} = 0.8$, 因此

$$P(X_0 = 1, X_1 = 2, X_2 = 2) = P(X_0 = 1)a_{12}a_{22} = 1 \times 0.3 \times 0.8 = 0.24.$$

这里马尔可夫性质恰用于第二步条件事件:

$$P(X_2 = 2 \mid X_1 = 2, X_0 = 1) = P(X_2 = 2 \mid X_1 = 2) = a_{22} = 0.8.$$

练习 30.6. 核对 $A = \begin{pmatrix} 0.7 & 0.3 \\ 0.2 & 0.8 \end{pmatrix}$ 是否为行随机矩阵。由 $\rho_0 = (1, 0)$ 计算 ρ_1, ρ_2 , 并逐步核对分量和。

练习 30.6 解析

四个元素均非负, 两行分别满足 $0.7 + 0.3 = 1$ 和 $0.2 + 0.8 = 1$, 所以 A 是行随机矩阵。按行向量方向推进,

$$\rho_1 = (1, 0)A = (0.7, 0.3),$$

两个分量和为 1。第二步为

$$\rho_2 = (0.7, 0.3)A = (0.7 \cdot 0.7 + 0.3 \cdot 0.2, 0.7 \cdot 0.3 + 0.3 \cdot 0.8) = (0.55, 0.45),$$

分量和仍为 1。若写成 $A\rho_t$, 维数方向和条件概率含义都会与本章约定冲突。

练习 30.7. 求矩阵 $A = \begin{pmatrix} 0.7 & 0.3 \\ 0.2 & 0.8 \end{pmatrix}$ 的平稳分布, 并验证细致平衡。

练习 30.7 解析

令 $\rho_\star = (r, 1 - r)$ 。平稳方程第一分量给出

$$r = 0.7r + 0.2(1 - r),$$

即 $0.5r = 0.2$, 所以 $r = 0.4$, $\rho_\star = (0.4, 0.6)$ 。回代第二分量有 $0.3 \times 0.4 + 0.8 \times 0.6 = 0.6$ 。两状态细致平衡只需检查非对角边:

$$(\rho_\star)_1 a_{12} = 0.4 \times 0.3 = 0.12 = 0.6 \times 0.2 = (\rho_\star)_2 a_{21}.$$

对角项两侧相同, 因此全部细致平衡等式成立, 链关于 $\rho_\star$ 可逆。

练习 30.8. 设 $B = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0.6 & 0.4 \\ 0 & 0.2 & 0.8 \end{pmatrix}$ 。求全部平稳分布, 并解释为什么答案形成一个连续族。

练习 30.8 解析

令 $\rho = (x, y, z)$ 。方程 $\rho = \rho B$ 的第一分量恒为 $x = x$; 第二分量给出

$$y = 0.6y + 0.2z,$$

所以 $z = 2y$ 。结合 $x + y + z = 1$, 取 $\alpha = x \in [0, 1]$, 得到全部平稳分布

$$\rho_\alpha = \left(\alpha, \frac{1-\alpha}{3}, \frac{2(1-\alpha)}{3} \right), \quad 0 \leq \alpha \leq 1.$$

状态 1 构成闭类, 状态 2, 3 构成另一个闭类。两个闭类各有自己的平稳分布, 在它们之间分配任意总质量 α 便形成连续族。可约性允许这种现象, 但并非每条可约链都一定有多个平稳分布。

练习 30.9. 令 $p_t = \mathbb{P}_j(\tau_i = t)$ 。证明 $p_t \rightarrow 0$ ，并说明这一结论为什么否定了用“ $\lim_{t \rightarrow \infty} p_t > 0$ ”定义正常返的做法。写出正常返的标准定义。

练习 30.9 解析

事件 $\{\tau_i = t\}$ 表示首次到达 i 恰好发生在时刻 t 。一条路径不能在两个不同时刻都首次到达 i ，所以这些事件两两互斥。因此

$$\sum_{t \geq 0} p_t = \mathbb{P}_j(\tau_i < \infty) \leq 1.$$

非负数列若级数有界，则通项趋于 0，故 $p_t \rightarrow 0$ 。于是要求 $\lim_{t \rightarrow \infty} p_t > 0$ 对首次到达分布不可能成立。正常返的标准定义是：从 i 出发的首次正回返时间 $\tau_i^+ = \inf\{t \geq 1 : X_t = i\}$ 满足 $\mathbb{E}_i[\tau_i^+] < \infty$ 。非周期性是逐步分布收敛的附加结构，不属于该定义。

$$\tau_i^+ = \inf\{t \geq 1 : X_t = i\}, \quad i \text{ 正常返} \iff \mathbb{E}_i[\tau_i^+] < \infty.$$

练习 30.10. 设概率分布 ρ 与行随机矩阵 A 满足 $\rho_i a_{ij} = \rho_j a_{ji}$ 。逐分量证明 $\rho = \rho A$ ，并指出证明中没有使用哪些常被误加的条件。

练习 30.10 解析

固定目标状态 j 。由矩阵乘法和细致平衡，

$$(\rho A)_j = \sum_i \rho_i a_{ij} = \sum_i \rho_j a_{ji} = \rho_j \sum_i a_{ji}.$$

最后的 a_{ji} 中 j 固定在第一个指标， i 遍历第二个指标，因此求和的是矩阵第 j 行。于是

$$\sum_i a_{ji} = 1 \implies (\rho A)_j = \rho_j \quad (\forall j) \implies \rho A = \rho.$$

证明没有使用不可约性或非周期性，它们分别服务于唯一性和逐步收敛等更强结论。

练习 30.11. 对交替链 $C = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$ ，求平稳分布，判断不可约性、周期和可逆性，再从 $\rho_0 = (1, 0)$ 计算 ρ_t 。说明“唯一平稳分布”为何不保证逐步收敛。

练习 30.11 解析

令 $\rho = (r, 1-r)$ 。平稳方程、归一化与细致平衡依次给出

$$\begin{aligned} \rho C = \rho &\iff (1-r, r) = (r, 1-r) \iff r = \frac{1}{2}, \\ \rho_1 c_{12} &= \frac{1}{2} = \rho_2 c_{21}. \end{aligned}$$

所以唯一平稳分布为 $(1/2, 1/2)$ 且链可逆。两状态一步互达，故不可约；回返集合 $R_1 = R_2 = \{2, 4, 6, \dots\}$ ，周期为 2。从 $\rho_0 = (1, 0)$ 出发，

$$\rho_t = \rho_0 C^t = \begin{cases} (1, 0), & t \text{ 为偶数}, \\ (0, 1), & t \text{ 为奇数}, \end{cases}$$

练习 30.11 解析 (续)

因此逐步分布不收敛。唯一固定点不能消除周期振荡。

练习 30.12. 设

$$D = \begin{pmatrix} 0.1 & 0.6 & 0.3 \\ 0.3 & 0.1 & 0.6 \\ 0.6 & 0.3 & 0.1 \end{pmatrix}.$$

证明均匀分布平稳, 并判断链是否不可约、非周期和可逆。

练习 30.12 解析

矩阵每行和与每列和都为 1, 所以对 $u = (1/3, 1/3, 1/3)$ 有

$$(uD)_j = \frac{1}{3} \sum_i d_{ij} = \frac{1}{3},$$

均匀分布平稳。矩阵所有元素都严格为正, 任意状态一步可达任意其他状态, 链不可约; 每个对角元为 $0.1 > 0$, 所以周期为 1。但

$$u_1 d_{12} = \frac{1}{3} \times 0.6 = 0.2, \quad u_2 d_{21} = \frac{1}{3} \times 0.3 = 0.1,$$

细致平衡失败, 链关于其唯一平稳分布不可逆。该例说明平稳性、不可约性和非周期性合在一起仍不推出可逆性。

练习 30.13. 在三节点路径 $1-2-3$ 上进行简单随机游走。写出行随机矩阵, 求平稳分布, 判断周期; 再写出 $A_L = (I + A)/2$ 并说明平稳分布和周期如何变化。

练习 30.13 解析

三节点路径的度数为 $(1, 2, 1)$, 简单随机游走矩阵为

$$A = \begin{pmatrix} 0 & 1 & 0 \\ 1/2 & 0 & 1/2 \\ 0 & 1 & 0 \end{pmatrix}.$$

由度数公式, 平稳分布为 $\rho = (1/4, 1/2, 1/4)$; 例如边 $1-2$ 满足 $(1/4) \cdot 1 = (1/2) \cdot (1/2)$ 。图连通, 所以链不可约; 二部划分 $\{1, 3\}$ 与 $\{2\}$ 使每次移动换部, 且存在两步回返, 故周期为 2。惰性矩阵为

$$A_L = \frac{1}{2}(I + A) = \begin{pmatrix} 1/2 & 1/2 & 0 \\ 1/4 & 1/2 & 1/4 \\ 0 & 1/2 & 1/2 \end{pmatrix}.$$

因为 $\rho A_L = \frac{1}{2}\rho + \frac{1}{2}\rho A = \rho$, 平稳分布不变。每个状态新增正自环, 周期变为 1, 连通性仍保持, 所以链从任意初始分布逐步收敛到 ρ 。

练习 30.14. 对 $A = \begin{pmatrix} 0.7 & 0.3 \\ 0.2 & 0.8 \end{pmatrix}$ 、 $\rho_0 = (1, 0)$ 和 $T = 2$ 手工执行算法 30.1。列出每轮不变量检查，并给出一般 n, T 下稠密与稀疏时间复杂度。

练习 30.14 解析

输入矩阵两行非负且行和为 1， ρ_0 非负且和为 1，初始化检查通过。第 1 轮计算

$$\begin{aligned} \rho_1 &= (1, 0)A = (0.7, 0.3), & \rho_1 \mathbf{1} &= 1, \\ \rho_2 &= (0.7, 0.3)A = (0.55, 0.45), & \rho_2 \mathbf{1} &= 1, \\ t = 2 = T & & \Rightarrow & \text{按预算停止.} \end{aligned}$$

每轮候选都有限、逐分量非负且归一化，故状态不变量保持。按预算停止不声称此时已等于平稳分布。

记 $s = \text{nnz}(\hat{A})$ 且 $s \geq n$ 。含输入校验和规范化的复杂度链为

$$\begin{aligned} T_{\text{dense}} &= \Theta((T+1)n^2), \\ T_{\text{sparse}} &= \Theta((T+1)(s+n)) = \Theta((T+1)s), \\ S_{\text{work}} &= \Theta(n), & S_{\text{trace}} &= \Theta((T+1)n). \end{aligned}$$

矩阵本身分别占 $\Theta(n^2)$ 或 $\Theta(s)$ 空间。

本章结论与下一步

核心结论：行随机矩阵以 $\rho_{t+1} = \rho_t A$ 推进；平稳、不可约、周期与正常返回不同问题。

关键依据：细致平衡推出平稳；有限不可约链给出唯一性与时间平均，非周期性另给固定时刻收敛。

可执行自检：分布推进按给定时域反复作行向量乘法，并逐步核验概率质量。

适用边界：适用于已知有限转移规则与图随机游走；有限步完成本身不是渐近收敛证明。

下一步：进入第 31 章：蒙特卡罗方法与直接采样；第 32 章再用本章结论分析相关的 MCMC 轨迹。

1. 能否从条件概率定义写出马尔可夫性质与路径概率乘积，并在不混用列随机约定的前提下计算 $\rho_0 A^t$ 和 $(A^t)_{ij}$ ？若不能，回看节 30.1、30.2。
2. 能否分别说明平稳分布存在、唯一、逐步收敛和时间平均各需哪些条件，并用通信路径、回返时长最大公约数与首次正回返期望判断不可约、周期与正常返？若不能，回看节 30.3—30.5。
3. 能否从细致平衡证明平稳性，并立即给出“可逆不推出不可约”的反例？若不能，重做练习 30.4 和 30.10。
4. 能否独立执行算法 30.1，报告停止原因、概率不变量和复杂度？若不能，重做练习 30.14。
5. 能否求无向图随机游走的度数平稳分布，并解释惰性化为何保持该分布？若不能，回看节 30.6；五项均可独立作答，并能完成对应算法与诊断，才算达到本章学习目标。

第31章 蒙特卡罗方法与直接采样

读前自检：本章地图：蒙特卡罗方法与直接采样。 蒙特卡罗方法与直接采样章地图给出“期望 → 独立样本均值 → 直接采样与重加权 → 误差诊断”；请写成一条带方向的依赖链，再用终点的输出说明它怎样回答本章核心问题，并核对路线“期望 → 独立样本均值 → 直接采样与重加权 → 误差诊断”的前一产出能够直接作为后一输入。

读前自检：本章可检验学习目标。 蒙特卡罗方法与直接采样目标中的“把期望与积分写成可验证的独立同分布样本均值，并分清可积、有限方差与中心极限定理所需的不同条件”必须可复核；请把期望与积分写成可验证的独立同分布样本均值，并分清可积、有限方差与中心极限定理所需的不同条件，所得结果仅在“中间结果逐项包含首目标“把期望与积分写成可验证的独立同分布样本均值，并分清可积、有限方差与中心极限定理所需的不同条件”声明的对象、条件与结论”时通过。

读前自检：最短先修。 蒙特卡罗先修要求能区分可积与有限方差；请对 $Y = h(X)$ 先检查 $E|Y| < \infty$ ，再在 $E(Y^2) < \infty$ 时写出 $\text{Var}(N^{-1} \sum_i Y_i) = \sigma^2/N$ 。

读前自检：先修自检。 蒙特卡罗方法与直接采样先修自检固定核验“若 $Y_1, \dots, Y_N$ 独立且方差均为 σ^2 ，能否逐项计算 $\text{Var}(N^{-1} \sum_i Y_i)$ ”；请在 $Y_1, \dots, Y_N$ 独立且方差均为 σ^2 条件下，实际逐项计算 $\text{Var}(N^{-1} \sum_i Y_i)$ 并写出中间结果，再按“ $\text{Var}(N^{-1} \sum_i Y_i)$ 的计算或证明结果满足首项所列等式、定义域或判断”明确判为通过或失败。

读前自检：依赖路线。 蒙特卡罗方法与直接采样依赖链含“第1册概率基础中的期望、大数定律与中心极限定理 → 本章的蒙特卡罗估计与误差条件”到“期望与积分 → 独立随机抽样 → 样本均值”这一跳；请固定写出前者输出类型与后者输入类型，并核对两者相同或存在正文声明的转换。

本章地图

核心问题：怎样从可抽样分布得到目标期望，并明确支持、矩条件和有限样本边界？

可检验学习目标：

- 把期望与积分写成可验证的独立同分布样本均值，并分清可积、有限方差与中心极限定理所需的不同条件；
- 用广义逆严格证明逆变换抽样，处理分布函数的跳跃、平坦段以及数值求逆误差；
- 推导接受 – 拒绝抽样的接受率和条件分布，理解支持覆盖、有限包络常数与预算停止；
- 区分普通重要性抽样与自归一化重要性抽样，推导最优提议分布及其零方差条件；
- 手工执行四个采样算法，识别数值异常与停止原因，并用标准误、有效样本量和支持检查诊断结果。

最短先修：本章使用第1册中的随机变量、密度或概率质量函数、期望、方差、分布函数、全概率公式、大数定律与中心极限定理，也使用集合上的绝对连续记号。读者还应能计算有限和、定积分和二分查找的迭代次数。所有核心样本均先假设独立同分布；相关的马尔可夫链样本留到后续章节。

依赖路线：第 1 册概率基础中的期望、大数定律与中心极限定理 → 本章的蒙特卡罗估计与误差条件；期望与积分 → 独立随机抽样 → 样本均值；分布函数 → 广义逆 → 逆变换抽样；提议分布与支持覆盖 → 接受 - 拒绝抽样或重要性抽样；二阶矩、样本方差与权重集中 → 标准误、有效样本量和失效诊断。

完成标准与返回：若不能区分一阶可积与有限方差，先回看概率基础再读蒙特卡罗估计。

图 31.1 只表示教学依赖，不表示三种采样方法彼此等价。接受 - 拒绝法输出未加权目标样本，重要性抽样则通常保留提议样本并改变其贡献大小。




图 31.1 本章知识依赖：由期望、积分与独立抽样进入蒙特卡罗估计，再分别学习三种直接采样或重加权方法，最后统一进行误差和支持诊断

读前自检：本章符号表。 蒙特卡罗方法与直接采样符号表规定 p, q, X_i, Y_i 的类型或范围；请把 p, q 代入紧随其后的定义关系，逐项核对输入形状、输出形状与取值域。

本章符号表		
符号	类型、维数或范围	读法与作用
p, q	同一可测空间上的概率密度或质量函数	目标分布与提议分布
X_i, Y_i	$\mathcal{X}$ 值随机变量	目标样本与提议样本；下标 i 是样本编号
f, h	可测实函数	f 用于期望， h 用于积分或被积函数
μ	实数	目标期望 $E_p[f(X)]$ 或目标积分
$\hat{\mu}_N$	实值估计量	N 个样本的蒙特卡罗均值
F, Q	分布函数与广义逆	$Q(u) = \inf\{x : F(x) \geq u\}$
c	$[1, \infty)$ 中的有限常数	接受 - 拒绝包络 $p \leq cq$
$w(x)$	$[0, \infty)$	重要性权重 $p(x)/q(x)$ 或未归一化权重
$s^2, \widehat{\text{SE}}$	非负统计量	样本方差与估计标准误
N, B	非负整数	目标样本数与最多允许的提议次数

31.1 蒙特卡罗估计

解析积分、复杂期望和分布特征常常没有闭式解。蒙特卡罗方法把“对整个空间求和或积分”改写为“从适当分布抽样后求平均”。这个改写只有在在抽样分布、可积性和独立性都被说明时才成立；样本数增加本身不能修复支持缺口或无限期望。

读前自检：蒙特卡罗估计。 蒙特卡罗估计以 $X_i \stackrel{\text{iid}}{\sim} p$ 和可积 h 为条件；请计算 $\hat{\mu}_N = N^{-1} \sum_i h(X_i)$ ，核对其目标是 $\mu = E_p[h(X)]$ 。

读前自检：蒙特卡罗法。 蒙特卡罗法把难积分 $\int h(x)p(dx)$ 改写为独立样本均值；请用一组样本做在线均值更新，核对第 N 步结果等于直接求和再除以 N 。

读前自检：随机抽样。 随机抽样要求 $X_1, \dots, X_N$ 独立且共同服从目标分布 p ；请检查一组生成规则的边缘分布与独立性，核对任一失败时不能直接套用 iid 均值方差公式。

读前自检：数学期望估计。 数学期望估计先要求 $E_p|h(X)| < \infty$ ；请把 μ 写成积分或求和并以 $h(X_i)$ 形成样本均值，核对强大数律的条件与目标对象一致。

读前自检：积分计算。 积分计算令 $Y_i = h(X_i)$ 且 $X_i \stackrel{\text{iid}}{\sim} p$ ；请代入一组 Y_i 计算均值，在 $\text{Var}(Y_i) = \sigma^2$ 时核对均方误差为 σ^2/N 。

读前自检：独立同分布蒙特卡罗估计。 iid 蒙特卡罗估计 $\hat{\mu}_N = N^{-1} \sum_i h(X_i)$ 要求 h 可积；请分别计算其期望与有限方差情形的方差，核对无偏性及 $1/N$ 方差缩减。

定义 31.1 (独立同分布蒙特卡罗估计). 设 $(\mathcal{X}, \mathcal{A})$ 为可测空间, p 为其上的概率分布, $X_1, \dots, X_N$ 独立同分布且共同服从 p , 记作 $X_i \stackrel{\text{iid}}{\sim} p$ 。若 $f: \mathcal{X} \rightarrow \mathbb{R}$ 可测且 $E_p|f(X)| < \infty$, 则

$$\mu = E_p[f(X)], \quad \hat{\mu}_N = \frac{1}{N} \sum_{i=1}^N f(X_i), \quad N \geq 1, \quad (31.1)$$

称为目标期望及其蒙特卡罗估计量。

本章的统一模型由目标量、抽样机制和观测函数三部分组成：目标量是 $\mu = E_p f$ 或 $\int f h$ ；抽样机制可以直接产生 p 的样本，也可以从较易抽样的 q 产生候选；观测函数把每个样本变成对目标量的一次贡献。模型必须同时给出分布的归一化、支持关系和函数的可积条件。

学习策略是用可计算估计量逼近固定目标量，并在不改变目标的前提下控制均方误差。对无偏估计量，均方误差等于方差；选择提议分布 q 、包络常数 c 或样本数 N ，实质上是在计算代价与估计方差之间折中。

学习算法由四类操作组成：独立抽样并在线更新均值、用广义逆把均匀数变成目标样本、用接受事件对提议样本进行筛选，以及保留提议样本并按似然比重加权。使用时应检查定义域、支持覆盖与有限性；遇到数值异常或达到预设采样上限，应停止并说明此前已经得到的部分。

阅读目标： 分开核对无偏性、方差、均方误差与积分表示所需条件。

对象： 独立样本 $X_i \sim p$ 、 $Y_i = f(X_i)$ 与估计量 $\hat{\mu}_N = N^{-1} \sum_i Y_i$ 。

合法条件： $E|Y_i| < \infty$ 保证期望；再有 $E(Y_i^2) < \infty$ 才能讨论方差与标准误。

第一步： 先用期望线性性计算 $E\hat{\mu}_N$ ，再用独立性计算方差。

推导目标

从独立样本均值逐步推出无偏性、方差、均方误差和积分改写，并分开记录每个结论所需的矩条件。

推导准备

设 $Y_i = f(X_i)$ 。一阶矩 $E|Y_i| < \infty$ 保证期望存在并可用强大数定律；只有再假设 $E(Y_i^2) < \infty$ ，方差和标准误才有定义。

推导第 1 步：期望的线性性。

$$E(\hat{\mu}_N) = \frac{1}{N} \sum_{i=1}^N E(Y_i) = \frac{1}{N} \cdot N\mu = \mu.$$

推导第 2 步：独立性消去协方差。 若 $\sigma^2 = \text{Var}(Y_1) < \infty$ ，则

$$\text{Var}(\hat{\mu}_N) = \frac{1}{N^2} \sum_{i=1}^N \text{Var}(Y_i) + \frac{2}{N^2} \sum_{i < j} \text{Cov}(Y_i, Y_j) = \frac{\sigma^2}{N}. \quad (31.2)$$

推导第 3 步：均方误差分解。 任意平方可积估计量 T 满足

$$E[(T - \mu)^2] = \text{Var}(T) + \{E(T) - \mu\}^2. \quad (31.3)$$

因此式 (31.1) 的均方误差为 σ^2/N ，均方根误差为 $\sigma/\sqrt{N}$ 。这个速率依赖独立同分布和有限方差，不能原样套到相关样本或无限方差情形。

积分改写也需要条件。设 h 在区域 $\mathcal{D}$ 上可积， p 是 $\mathcal{D}$ 上的概率密度。要求

$$p(x) = 0 \implies h(x) = 0 \quad \text{几乎处处}, \quad \int_{\mathcal{D}} |h(x)| dx < \infty. \quad (31.4)$$

在 $p(x) > 0$ 处定义 $f(x) = h(x)/p(x)$ ，在 $p(x) = 0$ 处定义 $f(x) = 0$ ，则

$$\int_{\mathcal{D}} h(x) dx = \int_{\mathcal{D}} f(x)p(x) dx = E_p[f(X)]. \quad (31.5)$$

若还要使用有限方差误差公式，则必须再有

$$\int_{\{p>0\}} \frac{h(x)^2}{p(x)} dx < \infty. \quad (31.6)$$

所以“选任意密度就能计算任意积分”不是正确命题；密度必须覆盖被积函数的非零区域，且比值必须满足相应可积条件。阅读图 31.2 时应具体回答：被积函数非零而 $p = 0$ 的区域会在哪一步丢失，以及式 (31.6) 为何比一阶积分改写多出一个 $1/p$ 因子。图只表示这两个逻辑接口，不提供随机复算坐标。




图 31.2 蒙特卡罗积分把曲线下的面积改写为分布下的期望；竖线表示固定的四个均匀样本，虚线表示该积分的参考值

读前自检：主线只使用强大数律结论。 主线只使用强大数律结论以“若 Y_i 独立同分布且 $E|Y_1| < \infty$ ”为约束；请独立化简 $N^{-1} \sum_{i=1}^N Y_i \rightarrow EY_1$ 的两端，并确认 $N^{-1} \sum_{i=1}^N Y_i \rightarrow EY_1$ 几乎必然成立。

主线只使用强大数律结论

若 Y_i 独立同分布且 $E|Y_1| < \infty$ ，则 $N^{-1} \sum_{i=1}^N Y_i \rightarrow EY_1$ 几乎必然成立。直接采样主线用这条强大数律解释一致性；无偏性来自期望线性， σ^2/N 误差公式还需有限二阶矩。下面的 Kolmogorov 级数准则与截断证明仅用于补足理论链，第一次阅读和执行算法均可跳过。

进阶证明附录：强大数律的一条证明路线。

引理 31.1 (Kolmogorov 独立级数收敛准则) 若 $Z_1, Z_2, \dots$ 相互独立， $E(Z_n) = 0$ ，且 $\sum_{n \geq 1} E(Z_n^2) < \infty$ ，则级数 $\sum_{n \geq 1} Z_n$ 几乎必然收敛。

证明. 先证明最大不等式。令 $S_k = \sum_{j=1}^k Z_j$ ，并把事件“首次有 $|S_j| \geq \varepsilon$ ”记为 $A_j = \{|S_1| < \varepsilon, \dots, |S_{j-1}| < \varepsilon, |S_j| \geq \varepsilon\}$ 。这些事件互不相交； A_j 只由 $Z_1, \dots, Z_j$ 决定，而 $S_n - S_j$ 与它独立且均值为 0。因此

$$E[\mathbf{1}_{A_j} S_n^2] = E[\mathbf{1}_{A_j} S_j^2] + E[\mathbf{1}_{A_j} (S_n - S_j)^2] \geq \varepsilon^2 P(A_j).$$

对 $j = 1, \dots, n$ 求和，并用事件互不相交，得到

$$P\left(\max_{1 \leq j \leq n} |S_j| \geq \varepsilon\right) \leq \frac{E(S_n^2)}{\varepsilon^2} = \frac{1}{\varepsilon^2} \sum_{j=1}^n E(Z_j^2).$$

同一论证可从任意 $m+1$ 开始。由于方差级数收敛，可选递增整数 m_r 使 $\sum_{j>m_r} E(Z_j^2) \leq 2^{-3r}$ 。令有限终点趋于无穷，便有

$$P\left(\sup_{k>m_r} |S_k - S_{m_r}| > 2^{-r}\right) \leq 2^{-r}.$$

右端关于 r 可求和, Borel–Cantelli 引理说明几乎每条样本路径从某个 r 起都满足该上确界不超过 2^{-r} 。于是任意 $n, k > m_r$ 都有 $|S_n - S_k| \leq 2^{1-r}$, 故 (S_n) 几乎必然为 Cauchy 序列并收敛, 等价于 $\sum_n Z_n$ 收敛。□

定理 31.1 (独立同分布蒙特卡罗估计的基本性质) 若 $X_i \stackrel{\text{iid}}{\sim} p$ 且 f 可测、 $E_p|f(X)| < \infty$, 则 $\hat{\mu}_N$ 无偏且 $\hat{\mu}_N \rightarrow \mu$ 几乎必然成立。若进一步 $E_p[f(X)^2] < \infty$, 则式 (31.2) 成立, 并且均方误差为 σ^2/N 。

读前自检：证明：独立同分布蒙特卡罗估计的基本性质。 iid 蒙特卡罗基本性质在 $E|Y_1| < \infty$ 下给强一致性, 在 $E(Y_1^2) < \infty$ 下再给方差式; 请展开样本均值期望和方差, 核对交叉协方差因独立性为 0。

证明. 令 $Y_i = f(X_i)$, 并以 Y 表示它们的共同分布。可积性使 $E(Y_i) = \mu$ 存在, 期望线性性给出 $E(\hat{\mu}_N) = \mu$, 所以估计量无偏。下面在本章内证明所需的强大数结论。

定义截断变量 $T_i = Y_i \mathbf{1}_{\{|Y_i| \leq i\}}$ 。尾和公式给出

$$\sum_{i=1}^{\infty} P(T_i \neq Y_i) = \sum_{i=1}^{\infty} P(|Y| > i) \leq E|Y| < \infty.$$

Borel–Cantelli 引理说明 $T_i = Y_i$ 最终几乎必然成立。另一方面, 交换非负求和与期望可得

$$\sum_{i=1}^{\infty} \frac{E(T_i^2)}{i^2} = E \left[Y^2 \sum_{i \geq \max(1, |Y|)} \frac{1}{i^2} \right] < \infty.$$

最后一个有限性来自: $|Y| < 1$ 时括号内有统一有限上界且 $Y^2 \leq |Y|$; $|Y| \geq 1$ 时尾和不超过 $2/|Y|$, 乘以 Y^2 后不超过 $2|Y|$ 。因此 $Z_i = (T_i - ET_i)/i$ 满足引理 31.1 的条件, 级数 $\sum_i (T_i - ET_i)/i$ 几乎必然收敛。

记 $A_n = \sum_{i=1}^n (T_i - ET_i)/i$ 。分部求和恒等式给出

$$\frac{1}{n} \sum_{i=1}^n (T_i - ET_i) = A_n - \frac{1}{n} \sum_{i=1}^{n-1} A_i \longrightarrow 0,$$

因为 A_n 与其 Cesàro 平均收敛到同一极限。又有 $ET_i \rightarrow EY = \mu$, 这是由 $|Y|$ 支配和支配收敛定理得到的; 故 $N^{-1} \sum_{i=1}^N ET_i \rightarrow \mu$ 。再结合 $T_i = Y_i$ 最终几乎必然成立, 有限个差异除以 N 趋于 0, 从而 $N^{-1} \sum_i Y_i \rightarrow \mu$ 几乎必然成立。

若二阶矩有限, 则 σ^2 存在; 独立性给出 $i \neq j$ 时 $\text{Cov}(Y_i, Y_j) = 0$, 逐项展开方差便得到式 (31.2)。最后把无偏性代入式 (31.3), 得到均方误差 σ^2/N 。上述各步共同证明结论。□

该定理用于确定一致性与误差量级; 若只有一阶矩, 则仍可使用强大数定律, 但方差、标准误和通常的正态区间可能不存在。马尔可夫链样本含有自相关, 不能把本定理的 σ^2/N 直接当作其方差公式。

读前自检：从给定分布抽样。 从 CDF F 抽样时用广义逆 $Q(u) = \inf\{x : F(x) \geq u\}$ ；请给定一个 $u \in (0, 1)$ 求 $Q(u)$ ，核对离散跳跃处选择第一个使 $F(x) \geq u$ 的点。

读前自检：逆变换抽样。 逆变换抽样取 $U \sim U(0, 1)$ 并令 $X = Q(U)$ ；请把事件 $Q(U) \leq x$ 改写成 $U \leq F(x)$ ，核对 $P(X \leq x) = F(x)$ 。

31.2 逆变换抽样

定义 31.2 (分布函数的广义逆). 设 $F(x) = P(X \leq x)$ 是实随机变量的分布函数。对 $0 < u < 1$ ，定义

$$Q(u) = \inf\{x \in \mathbb{R} : F(x) \geq u\}. \quad (31.7)$$

Q 读作分位数函数或广义逆；“首次达到”中的不等号必须是 $\geq$ ，这样才能覆盖离散跳跃和平坦区间。

定理 31.2 (广义逆变换定理) 若 $U \sim U(0, 1)$ ，并令 $X = Q(U)$ ，其中 Q 由式 (31.7) 定义，则 X 的分布函数是 F 。此结论允许 F 有跳跃和平坦段。

读前自检：证明：广义逆变换定理。 在“若 $u \leq F(x)$ ”成立时处理广义逆变换定理：请把 $Q(u) \leq x$ 用到的关键定义展开并完成下一步变形，并以故 X 确实服从 F 判定结果。

证明。 先证明对每个 $0 < u < 1$ 和 $x \in \mathbb{R}$ 都有

$$Q(u) \leq x \iff u \leq F(x). \quad (31.8)$$

由于 $0 < u < 1$ 且分布函数在两端的极限分别为 0 和 1，集合 $S_u = \{z : F(z) \geq u\}$ 非空且有下界，所以 $a = Q(u)$ 是有限实数。若 $u \leq F(x)$ ，则 $x \in S_u$ ，故 $Q(u) \leq x$ 。反过来，设 $a = Q(u) \leq x$ 。下确界定义保证对每个 n 存在 $z_n \in S_u$ 使 $a \leq z_n < a + 1/n$ ；又因 F 非降， S_u 向上封闭，所以 $a + 1/n \in S_u$ 。序列 $a + 1/n$ 从右侧单调趋于 a ，分布函数右连续，从而 $F(a) = \lim_n F(a + 1/n) \geq u$ ；再由 $a \leq x$ 与单调性得到 $F(x) \geq F(a) \geq u$ 。式 (31.8) 成立。于是

$$P(X \leq x) = P\{Q(U) \leq x\} = P\{U \leq F(x)\} = F(x),$$

最后一步使用 $0 \leq F(x) \leq 1$ 以及均匀分布的分布函数。故 X 确实服从 F 。□

图 31.3 把严格递增与离散跳跃放在同一“首次达到”规则下。若 F 有平坦段，普通代数逆可能不存在或不唯一，广义逆仍有定义。

读前自检：易混淆概念对比：逆变换抽样。 逆变换抽样固定采用只返回 $u \in (0, 1)$ 的随机源；若随机源返回精确 0 或 1，立即报告 `random_source_failure` 而不裁剪。请核对连续 CDF 求逆与离散最小下标规则均只接收合法 u 。




图 31.3 广义逆采用首次达到规则：连续情形沿水平线找到交点；离散情形中 $u = 0.7$ 落在第二个跳点，而 $u = 0.72$ 落在第三个跳点

易混淆概念对比

理论事件与有限精度端点政策。在概率论中，无论把连续均匀分布写作 $U(0,1)$ 还是 $U[0,1]$ ，都有 $P(U \in \{0,1\}) = 0$ ，所以定理的分布结论不要求“观测到端点就失败”。有限精度生成器却可能返回精确 0 或 1；这是接口政策问题。实现必须预先选择：使用保证开区间输出的生成器、在有限重抽预算内重抽，或以 `random_source_failure` 停止。不得事后静默裁剪到最近内点，因为裁剪会在该机器数上制造额外点质量。连续数值求逆还需括区间 $[L, R]$ 、宽度容差 δ 和 CDF 残差；离散表使用最小下标 k 使 $F_k \geq u$ 。逐坐标逆变换只能生成独立边缘，不能自动恢复多维相关结构。

读前自检：接受—拒绝抽样。 接受—拒绝抽样要求归一化密度 p, q 同支配测度且 $p(x) \leq cq(x)$ ；请对 $Y \sim q, U \sim U(0,1)$ 检查 $U \leq p(Y)/(cq(Y))$ ，核对接受率为 $1/c$ 。

31.3 接受—拒绝抽样

设 p 与 q 是关于同一支配测度 ν 的归一化密度；连续情形可取 Lebesgue 测度，离散情形可取计数测度。记 $p \ll q$ 表示 $q(x) = 0$ 时 $p(x) = 0$ 对 ν 几乎处处。假设存在有限常数

$$c \geq \operatorname{ess\,sup}_{q(x)>0} \frac{p(x)}{q(x)}, \quad p(x) \leq cq(x) \quad \text{几乎处处.} \quad (31.9)$$

由两边积分可知 $c \geq 1$ 。抽取 $Y \sim q$ 和独立的 $U \sim U(0,1)$ ，并在

$$U \leq \alpha(Y), \quad \alpha(y) = \frac{p(y)}{cq(y)} \quad (31.10)$$

时接受 Y 。在 $q = 0$ 的零概率区域可把 α 定义为 0；使用前仍需验证全局支配条件，不能靠恰好没抽到缺口来证明合法。

定理 31.3 (接受—拒绝抽样的分布与接受率) 在式 (31.9) 条件下, 对任意可测集合 A , 单次提议满足

$$P(Y \in A, \text{接受}) = \frac{1}{c} \int_A p(y) d\nu(y), \quad P(\text{接受}) = \frac{1}{c}.$$

因此条件分布 $P(Y \in A | \text{接受}) = \int_A p(y) d\nu(y)$; 连续重复独立试验所得的接受值组成独立同分布的 p 样本。

读前自检：证明：接受—拒绝抽样的分布与接受率。 接受—拒绝证明以 $0 \leq p(y)/(cq(y)) \leq 1$ 为条件; 请对集合 A 积分 $q(y)p(y)/(cq(y))$, 核对联合接受质量为 $c^{-1} \int_A p$, 条件分布因此为 p 。

证明. 固定 $Y = y$ 后, U 与 Y 独立且 $0 \leq \alpha(y) \leq 1$, 所以条件接受概率是 $\alpha(y)$ 。按 Y 积分得到

$$P(Y \in A, \text{接受}) = \int_{A \cap \{q>0\}} q(y)\alpha(y) d\nu(y) = \frac{1}{c} \int_{A \cap \{q>0\}} p(y) d\nu(y) = \frac{1}{c} \int_A p(y) d\nu(y),$$

其中最后一个等号使用 $p \ll q$ 。取 $A = \mathcal{X}$ 并使用 $\int p d\nu = 1$, 得到 $P(\text{接受}) = 1/c$ 。两式相除便得到接受值的条件分布。每次提议对 (Y, U) 都重新独立抽取; 一次接受之后, 后续提议块与此前提议块独立且规则不变。对连续多个接受值逐次使用这一条件分布, 可把其联合概率分解为各自 p 概率的乘积, 所以接受序列独立同分布。结论得证。□

每次成功概率为 $1/c$, 故得到一个接受值所需提议次数服从参数 $1/c$ 的几何分布, 期望为 c 。图 31.4 把合法包络、含边界接受门与普通拒绝放在同一绘图区; 图示取 $p(y) = 6y(1-y)$ 、 $q(y) = 1$ ($y \in [0, 1]$) 和 $c = 1.6 = 8/5$, 故 $p \leq cq$ 几乎处处且接受率为 $5/8$ 。圆点 $y = 1/4, h = 4/5$ 满足 $U = 1/2 \leq 45/64 = p/(cq)$ 而接受; 三角点 $y = 3/4, h = 27/20$ 满足 $U = 27/32 > 45/64 = p/(cq)$ 而拒绝, 但仍位于合法包络之下。




图 31.4 包络满足 $p \leq cq$ (几乎处处); 随机点 $(Y, Ucq(Y))$ 落在 p 曲线下方 (含边界) 时接受 Y 。

读图检查。先看实线 p 与虚线 cq 在 $[0, 1]$ 上保持合法支配且最小差为 $1/10$, 再按 $Ucq(Y) \leq p(Y)$ 逐一核对圆点与三角点, 最终由面积得到接受率 $5/8$ 、平均提议数 $8/5$ 和拒绝区面积 $3/5$; 三角点是普通拒绝, 不是包络失效。

图 31.5 给出带预算接受 - 拒绝的工程状态机: 全部输入与包络证书先于随机调用完成核验, 之后才进入计数、提议和接受分支。




图 31.5 带预算的接受—拒绝必须区分普通拒绝、收满目标、未收满而预算耗尽, 以及包络证书失败。

读图检查。先看顶部预检和初始化后的 $a = N$ 、 $m = B$ 两级短路: $N = 0$ (包括 $N = B = 0$) 先到 completed, 而 $N > 0, B = 0$ 到 budget_stop, 均不调用 q 抽样器或均匀源; 再看一次候选成功后 m 立即增加, 随机源或数值失败均保留 $X_{1:a}, m, a$ 并报告失败位置; 最后沿接受与普通拒绝两支

回到“先 $a = N$ 、再 $m = B$ ”的检查，得到只有接受分支追加 Y 并增加 a ，同轮同时命中目标与预算时仍优先 `completed`，包络越界则是 `invalid_input` 及 `envelope_condition_failure` 诊断。

有限状态例可把条件看清。若 $p = (1/2, 1/3, 1/6)$, $q = (1/3, 1/3, 1/3)$, 则 $p/q = (3/2, 1, 1/2)$, 最小可用包络常数为 $c = 3/2$ 。三个状态的条件接受概率依次为 $1, 2/3, 1/3$, 总体接受率为 $2/3 = 1/c$ 。若错误地取 $c = 9/8$, 第一个状态的比率会变成 $4/3 > 1$; 此时应停止并修正包络, 而不是用 $\min(1, \alpha)$ 静默裁剪。

31.4 重要性抽样

以下 p, q 仍表示关于同一支配测度 ν 的密度。设目标量为 $I = E_p[h(X)]$, 但只能从 q 抽样。要求 $p \ll q$, 并在 $q > 0$ 处定义 $w(x) = p(x)/q(x)$ 。若 $Y_i \stackrel{\text{iid}}{\sim} q$, 普通重要性估计为

$$\hat{I}_N^{\text{IS}} = \frac{1}{N} \sum_{i=1}^N w(Y_i) h(Y_i). \quad (31.11)$$

这不是“从 p 抽样后不加权”, 而是从 q 抽样后用密度比改变量的贡献。

若只能计算未归一化密度 $\tilde{p} = Zp$ 且归一化常数 $Z > 0$ 未知, 令 $\tilde{w} = \tilde{p}/q$, 自归一化估计为

$$\hat{I}_N^{\text{SNIS}} = \frac{\sum_{i=1}^N \tilde{w}(Y_i) h(Y_i)}{\sum_{i=1}^N \tilde{w}(Y_i)}. \quad (31.12)$$

分母必须为有限正数。自归一化形式消去了未知 Z , 但有限样本下一般有偏; 不能把普通重要性抽样的无偏性移植给它。

定理 31.4 (普通与自归一化重要性抽样) 若 $p \ll q$ 且 $E_q[w(Y)h(Y)] < \infty$, 则式 (31.11) 无偏并几乎必然收敛到 I 。若再有 $E_q[(w(Y)h(Y))^2] < \infty$, 其方差为 $\text{Var}_q(wh)/N$ 。对式 (31.12), 若 $E_q[\tilde{w}h] < \infty$ 且 $E_q\tilde{w} = Z \in (0, \infty)$, 则以概率 1 存在随机整数 N_0 , 使所有 $N \geq N_0$ 时分母有限且为正; 从此式 (31.12) 有定义, 并几乎必然收敛到 I 。

读前自检：证明：普通与自归一化重要性抽样。 普通重要性抽样要求 ph 由 q 覆盖, 自归一化形式还要求权重均值极限 $Z > 0$; 请分别写出两个样本平均并取比值, 核对分母最终大于 $Z/2$ 后比值可定义。

证明. 支持覆盖使

$$E_q[w(Y)h(Y)] = \int_{\{q>0\}} q(y)w(y)h(y) d\nu(y) = \int_{\{q>0\}} p(y)h(y) d\nu(y) = \int p(y)h(y) d\nu(y) = I,$$

其中最后一个等号使用 $p \ll q$ 。期望线性性给出普通估计无偏; 强大数定律给出其几乎必然一致性。二阶矩有限时, 把随机变量 wh 代入定理 31.1 的方差结论, 得到 $\text{Var}_q(wh)/N$ 。

对自归一化估计, 强大数定律分别给出

$$\frac{1}{N} \sum_i \tilde{w}(Y_i) h(Y_i) \rightarrow \int \tilde{p}(y) h(y) d\nu(y) = ZI, \quad \frac{1}{N} \sum_i \tilde{w}(Y_i) \rightarrow Z$$

几乎必然成立。因为 $Z > 0$ ，在该概率为 1 的收敛事件上，存在 N_0 使 $N \geq N_0$ 时分母平均值大于 $Z/2$ 且有限。除法在 (ZI, Z) 处连续，连续映射定理遂给出从 N_0 起有定义的比值收敛到 I 。有限样本分母仍可能恰为 0，此时式 (31.12) 不定义；这不影响上述几乎必然的最终正性与收敛结论。证明完成。 $\square$

图 31.6 固定共同定义域 $\mathcal{X} = [0, 5]$ ，并取 $p(x) = 6x(5-x)/125$ 、 $q_L(x) = (2/5)\mathbf{1}_{[0, 5/2]}(x)$ 、 $q_R(x) = 1/5$ 。支持覆盖是普通形式和自归一化形式共同的先决条件。观察任务：先找出左图 q_L 于 $x = 5/2$ 后的支持缺口，再在右图用 $w = p/q_R$ 复算 $x = 1, 5/2, 4$ 处的真实密度比；最后只判断 $p \ll q$ 是否成立，不据此断言方差低或估计可靠。




图 31.6 重要性抽样要求 $p \ll q$ 其中 q 未覆盖的目标区域不能由增加样本或有限加权恢复

读图检查 (仅针对图 31.6)。先看左图的点线支撑边界、空心端点、 $q_L = 0$ 基线与 $p > 0$ 纹理区，确认增加样本或有限加权都不能恢复该缺失目标区域；再看右图 $q_R = 1/5 > 0$ 的全域覆盖，并由同一公式核对 $w(1) = 0.96$ 、 $w(5/2) = 1.50$ 、 $w(4) = 0.96$ 。结论只到 $p \ll q_R$ 这一支持条件，不得从支持覆盖推成低方差或估计可靠性。

命题 31.1 (普通重要性抽样的方差最优提议) 假设 $0 < \int |h(x)|p(x) d\nu(x) < \infty$ ，且 $|h(x)| > 0$ 对 p 几乎处处成立。在所有满足 $p \ll q$ 且使二阶矩有限的密度 q 中，

$$q^*(x) = \frac{|h(x)|p(x)}{\int |h(t)|p(t) d\nu(t)}$$

使普通重要性贡献 $w(Y)h(Y)$ 的二阶矩最小。该提议给出零方差当且仅当 h 在 p 下几乎处处同号。

读前自检：证明：普通重要性抽样的方差最优提议。 普通重要性抽样的二阶矩在提议 q 下为 $E_q[(p(X)h(X)/q(X))^2]$ ；请用 Cauchy-Schwarz 推出下界，并核对 $q^*(x) \propto p(x)|h(x)|$ 达到该界。

证明. 对任意可行 q , 在 $q = 0$ 处把 $|h|p/\sqrt{q}$ 与 h^2p^2/q 都约定为 0; 这些约定与 $p \ll q$ 一致。Cauchy-Schwarz 不等式给出

$$\left(\int |h|p \, d\nu\right)^2 = \left(\int \frac{|h|p}{\sqrt{q}} \sqrt{q} \, d\nu\right)^2 \leq \left(\int \frac{h^2p^2}{q} \, d\nu\right) \left(\int q \, d\nu\right) = \int \frac{h^2p^2}{q} \, d\nu.$$

右端正是 $E_q[(wh)^2]$ 。等号条件要求 $|h|p/\sqrt{q}$ 与 $\sqrt{q}$ 成比例, 即 $q \propto |h|p$, 归一化后得到 $q^\star$ 。令 $A = \int |h|p \, d\nu$; 在 $q^\star$ 下, $w(x)h(x) = A \operatorname{sgn}(h(x))$ 。其方差为 $A^2 - I^2$, 等于零当且仅当 $|I| = A$, 这等价于 h 几乎处处不改变符号。命题成立。□

这个结果是方差最小化的理论基准, 不是可直接执行的万能选择, 因为 $q^\star$ 的归一化常数和抽样机制常与原积分同样困难。若 $h = 0$ 的集合具有正 p 概率, 则 $q^\star$ 会在该集合取零, 不再满足本章统一采用的 $p \ll q$ 强支持条件; 可用 $q_\varepsilon = (1 - \varepsilon)q^\star + \varepsilon p$ 保持覆盖, 并在 $\varepsilon \downarrow 0$ 时逼近理论下界。

31.5 估计误差与诊断

令 Y_i 表示任一独立同分布且方差为 $\sigma^2 < \infty$ 的蒙特卡罗贡献。只有 $N \geq 2$ 时, 样本方差和估计标准误才定义为

$$s^2 = \frac{1}{N-1} \sum_{i=1}^N (Y_i - \bar{Y}_N)^2, \quad \widehat{\text{SE}}(\bar{Y}_N) = \frac{s}{\sqrt{N}}. \quad (31.13)$$

为核对分母 $N-1$, 先使用恒等式

$$\sum_{i=1}^N (Y_i - \bar{Y}_N)^2 = \sum_{i=1}^N (Y_i - \mu)^2 - N(\bar{Y}_N - \mu)^2.$$

两边取期望: 第一项贡献 $N\sigma^2$, 第二项贡献 $N\operatorname{Var}(\bar{Y}_N) = \sigma^2$, 故平方离差和的期望为 $(N-1)\sigma^2$, 从而 $E(s^2) = \sigma^2$ 。在独立同分布、方差有限并满足中心极限定理的条件下,

$$\bar{Y}_N \sim \mathcal{N}(\mu, \sigma^2/N), \quad \bar{Y}_N \pm z_{1-\alpha/2} \frac{s}{\sqrt{N}} \quad (31.14)$$

给出大样本近似区间, 而不是有限样本精确覆盖保证。

接受-拒绝法若固定做 B 次独立提议, 则有效包络下的接受数 A_B 服从 $\text{Binomial}(B, 1/c)$, 所以 $E(A_B) = B/c$, $\operatorname{Var}(A_B) = B(1/c)(1 - 1/c)$ 。观测接受率远低于 $1/c$ 可能提示密度求值、已验证的包络不等式或随机数生成规则存在问题, 但一次有限样本偏差本身不是反证。

对非负权重 $w_1, \dots, w_N$ 且至少一个为正, 常用启发式有效样本量为

$$\text{ESS} = \frac{(\sum_i w_i)^2}{\sum_i w_i^2} = \frac{1}{\sum_i \tilde{w}_i^2}, \quad \tilde{w}_i = \frac{w_i}{\sum_j w_j}. \quad (31.15)$$

由于 $\sum_i \tilde{w}_i = 1$, 有 $\sum_i \tilde{w}_i^2 \leq 1$; Cauchy-Schwarz 又给出 $1 = (\sum_i \tilde{w}_i)^2 \leq N \sum_i \tilde{w}_i^2$ 。因此 $1 \leq \text{ESS} \leq N$ 。它只衡量权重集中程度, 不能发现共同遗漏的支持区域, 也不是普通估计量方差的精确等价样本数。

几何解释。蒙特卡罗积分用随机竖条的平均高度表示面积; 广义逆在分布函数纵轴上取均匀高度, 再水平投影到横轴; 接受-拒绝法在包络曲线下均匀取点, 只保留落到目标曲线下的点。三种图形共享“面积即概率”, 但输出对象不同。

概率解释。样本均值利用大数定律; 逆变换利用事件等价 $\{Q(U) \leq x\} = \{U \leq F(x)\}$; 接受-拒绝法是对提议分布做条件化稀疏; 重要性抽样是测度变换。条件化改变保留哪些样本, 重加权改变每个样本对和的贡献。

优化解释。包络常数越小, 理论接受率 $1/c$ 越高; 但 c 必须保持全局支配, 不能为追求接受率而取小。重要性抽样则通过命题 31.1 最小化二阶矩。两种优化都受支持和可抽样性约束, 不能只看局部曲线接近程度。

图 31.7 用固定的四个均匀数说明运行均值可以上下波动; 图 31.8 显示一个权重占 90% 时 ESS 会接近 1; 图 31.9 只在独立同分布且方差有限时画出 $N^{-1/2}$ 速率。




图 31.7 固定样本序列 0.8, 0.1, 0.7, 0.4 下 U_i^2 的运行均值; 曲线先降后升再下降, 说明收敛结论不等于逐步单调逼近




图 31.8 退化归一化权重 0.90, 0.05, 0.03, 0.02; 其启发式有效样本量约为 1.23, 提示少数样本主导估计, 但不能单独证明估计可靠




图 31.9 独立同分布且方差有限时的理论均方根误差速率；相关样本或无限方差情形不能直接沿用这条直线

例题 31.1 (稀有事件下的重要性抽样高方差). 在状态空间 $\{0, 1\}$ 上, 目标分布为 $p = (0.99, 0.01)$, 提议分布为 $q = (0.9999, 0.0001)$, 且 $h(0) = 0, h(1) = 100$. 求 $I = E_p h$ 、普通重要性贡献的方差, 并解释为什么四次都抽到状态 0 时估计和样本 ESS 会给出误导性的乐观诊断。

例题 31.1 解答

读题翻译 把普通重要性抽样的单次贡献写成 $Z = h(X)p(X)/q(X)$, 精确计算它的均值与方差; 再解释四个样本全落在常见状态时, 为何估计值和经验 ESS 会同时显得过度乐观。

已知与合法条件 $q(0), q(1) > 0$ 覆盖 p 的支持; 普通非自归一化估计使用 Z 的样本均值, 样本 ESS 只由本次实际观察到的权重计算。

为什么想到这个方法 无偏性由 $E_q Z = E_p h$ 给出, 而高方差由 $E_q Z^2 - I^2$ 暴露; 未抽到的稀有状态不会进入经验权重分散度。

方法选择 先算 I 、两状态权重和贡献, 再求 $E_q Z^2 - I^2$; 随后条件于四次全取状态 0, 计算估计、ESS 与该事件概率。

推导/计算 计算。精确目标值为 $I = 0.99 \cdot 0 + 0.01 \cdot 100 = 1$ 。两状态的重要性权重与贡献分别为

$$\frac{p(0)}{q(0)} = \frac{0.99}{0.9999} \approx 0.990099, \quad \frac{p(1)}{q(1)} = 100, \quad Wh \in \{0, 10000\}.$$

故 $E_q(Wh) = 1$, 但 $\text{Var}_q(Wh) = 0.0001 \times 10000^2 - 1^2 = 9999$ 。若四次都抽到常见状态 0, 普通估计为 0, 相对真值误差为 -1 ; 四个已观察权重却完全相等, 经验 ESS 会给出 4。

独立核验 二阶矩为 $E_q[(Wh)^2] = 10^4$, 减去均值平方再次得到方差 9999; 而四次均未命中状态 1 的概率是 $0.9999^4 \approx 0.99960006$, 说明这种“ESS 满额但估计为零”的样本并不罕见。

结论 $I = 1$ 且单次重要性贡献方差为 9999; 四次全取状态 0 时估计为 0、经验 ESS 却为 4。样本 ESS 不能发现尚未命中的稀有高贡献区域; 后文例 31.2 另行审计普通均匀样本均值。

以下四个算法都区分数学上概率为零的事件与实际出现的数值异常。有限值、定义域和支持覆盖必须逐项检查; 任何非法概率、负权重或非有限数都不能通过裁剪掩盖。

算法 31.1: 独立蒙特卡罗均值与 Welford 在线诊断

输入: 每次调用相互独立且同分布的目标抽样器 $\mathcal{S}_p$; 实值函数 f ; $N \in \mathbb{N}_0$
输出: 最后合法 (k, m, M_2) 与可定义统计量; u_{done} ; **status** 与诊断

- 1 核验 N 与抽样器契约; 若失败则返回 $k = 0$, `invalid_input` 及字段诊断; 令 $k \leftarrow 0, m \leftarrow 0, M_2 \leftarrow 0, u_{\text{done}} \leftarrow 0$
- 2 若 $N = 0$, 不调用随机源, 返回未定义估计、`completed` 及零预算诊断
- 3 对 $i \leftarrow 1, \dots, N$ 执行
 - 4 调用 $X \leftarrow \mathcal{S}_p()$ 并增加 u_{done} ; 若调用失败, 返回此前状态、`random_source_failure` 及 i 诊断
 - 5 计算 $y \leftarrow f(X)$; 若样本或 y 非有限, 返回此前状态、`numerical_failure` 及 $(i, \text{function})$ 诊断
 - 6 形成 $k^+ = k + 1, d = y - m, m^+ = m + d/k^+, M_2^+ = M_2 + d(y - m^+)$
 - 7 若候选非有限或 M_2^+ 显著为负, 返回此前状态、`numerical_failure` 及 (i, update) 诊断
 - 8 原子提交 $(k, m, M_2) \leftarrow (k^+, m^+, \max\{M_2^+, 0\})$
- 9 结束
- 10 若 $k = 0$, 返回未定义估计、`completed` 及零预算诊断; 若 $k = 1$, 返回 m 、未定义方差/标准误、`completed` 及单样本诊断
- 11 形成 $s^2 = M_2/(k-1)$ 与 $s/\sqrt{k}$; 若非有限, 返回 Welford 状态、`numerical_failure` 及汇总诊断; 否则返回完整统计量、`completed` 及最终诊断

独立蒙特卡罗在线估计。输入与输出。输入为独立目标抽样器、可测函数 f 和非负整数 N ; 输出为已生成样本数、在线均值, 以及在可定义时的样本方差与标准误。 $N = 0$ 时不调用随机源, 均值、方差与标准误均未定义; $N = 1$ 时均值已定义, 但方差和标准误仍未定义。

参数含义。 N 是请求的独立样本数; 抽样器必须保证每次调用独立且共同服从 p , f 把样本映为实贡献。无限方差不是可由有限前缀可靠排除的输入错误, 而是禁止使用常规标准误的适用性问题。

初始化。令计数 $k = 0$ 、均值 $m = 0$ 、中心平方和 $M_2 = 0$, 不预先构造长度 N 的数组。先检查 N 是非负整数, 并确认抽样器每次给出相互独立且同分布的样本。

循环变量、更新顺序与判断条件。循环变量 $i = 1, \dots, N$ 。每轮先抽取 X_i 并计算 $y_i = f(X_i)$, 只有 y_i 有限才执行 Welford 更新: $k \leftarrow k + 1, d \leftarrow y_i - m, m \leftarrow m + d/k, M_2 \leftarrow M_2 + d(y_i - m)$ 。异常贡献不计入此前的统计量。

停止条件与返回结果。正常完成 N 轮后有 $k = N$; 遇到非有限样本或贡献时立即停止, 并保留此前已经计算的统计量。 $k = 0$ 时估计未定义, $k = 1$ 时只给出 m , $k \geq 2$ 时再给出 $s^2 = M_2/(k-1)$ 与 $s/\sqrt{k}$ 。

正确性依据与收敛条件。Welford 递推保持 $m = k^{-1} \sum_{j=1}^k y_j$ 及 $M_2 = \sum_{j=1}^k (y_j - m)^2$ 。在独立同分布和一阶可积条件下, 完成估计由强大数定律收敛; 使用样本方差、标准误和正态近似还需有限二阶矩。不收敛或不适用情形包括相关样本、期望不存在, 以及用 iid 标准误分析 MCMC 输出。

独立蒙特卡罗均值与 Welford 在线诊断: 五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新, 并指出何时提交。

数学停止。写出能直接核验的停止证书; 预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

异常与退化。若 N 不是整数、无法保证独立同分布抽样, 或样本与函数值不是有限实数, 算法停止并保留此前完成的更新。 $N = 0$ 和 $N = 1$ 是有定义的退化分支, 不能执行除以 N 或 $N - 1$ 。**复杂度假设。**一次抽样和一次 f 求值的成本分别为 C_p, C_f , 标量运算按 $O(1)$ 计; 执行时间为 $\Theta(N(C_p + C_f))$, 除可选输出样本外工作空间为 $\Theta(1)$ 。

广义逆直接抽样。输入与输出。输入为合法分布函数表示、模式 (解析逆、离散累计表或连续数值逆)、各次调用相互独立且共同服从连续均匀分布的抽样器、预登记端点政策、均匀源调用预算 B_U 、 N 以及数值容差; 输出为所得样本、每个数值逆的括区间与残差, 以及完成次数。使用前必须验证 CDF 非降、右连续且具有正确两端极限; 离散表还需非负增量与末项为 1。端点政策只能是“生成器保证开区间”“预算内重抽”或“端点即报告随机源失败”, 不得静默裁剪。

参数、初始化与循环变量。 $N \in \mathbb{N}_0$; 连续数值模式给出 $\delta > 0$ 、残差阈值 $\eta \geq 0$ 、最大二分轮数 J 和能为每个 u 返回 $F(L) < u \leq F(R)$ 的括区间过程。初始化空前缀, 循环变量为 i 及数值模式内的 j 。

更新顺序与判断条件。每轮先取 u ; 若命中端点, 先执行已登记政策, 重抽时增加调用计数且不得超过 B_U 。只有得到有限内点 $0 < u < 1$ 后才进入求逆, 且永不裁剪。解析模式计算 $Q(u)$; 离散模式取最小 k 使 $F_k \geq u$; 连续数值模式保持 $F(L) < u \leq F(R)$, 按 $F(M) \geq u$ 更新右端, 否则更新左端。

停止条件、返回结果与异常退化。解析和离散模式每轮一次完成; 数值模式在区间宽度不超过 δ 且右端残差 $F(R) - u \leq \eta$ 时取 R 。达到 J 仍不满足时停止, 并保留此前已生成的样本。 $N = 0$ 不调用均匀随机源。分布函数非法、端点政策或重抽预算耗尽、求值不是有限实数、找不到离散下标或括区间失效时停止; 端点本身不是概率定理失败。

正确性依据、收敛条件与不适用情形。精确模式由定理 31.2 保证单次输出分布正确; 均匀数相互独立同分布进一步保证各次输出独立同分布。数值模式需 F 在目标分位点附近连续且严格递增; 在有效括区间内二分使宽度至多 $(R_0 - L_0)2^{-j}$, $\delta, \eta \rightarrow 0$ 时近似趋于广义逆。坐标逐一求逆不适用于直接生成有相关性的多元联合分布。

读前自检：带离散和数值分支的广义逆抽样：执行契约。带离散和数值分支的广义逆抽样输入“候选 CDF 及其解析逆/离散表/数值求值接口、独立均匀源、端点政策、均匀源调用预算 B_U 、样本数 N 、数值逆预算 J 与容差/括区间过程”, 条件“ $N, J, B_U \in \mathbb{N}_0$ 且 $B_U \geq N$ ”; 请执行“候选 x 及其括区间/残差全部通过定义域和有限性检查后才原子追加并增加 k ”, 以“生成 N 个样本、当前数值逆耗尽 J 轮或首次失败时停止”判停。

读前自检：带离散和数值分支的广义逆抽样。带离散和数值分支的广义逆抽样输入“候选 CDF 及其解析逆/离散表/数值求值接口、独立均匀源、端点政策、均匀源调用预算 B_U 、样本数 N 、数值逆预算 J 与容差/括区间过程”, 条件“ $N, J, B_U \in \mathbb{N}_0$ 且 $B_U \geq N$ ”; 请做一轮“候选 x 及其括区间/残差全部通过定义域和有限性检查后才原子追加并增加 k ”, 以“生成 N 个样本、当前数值逆耗尽 J 轮或首次失败时停止”核对停止证书。

复杂度假设。一次均匀抽样为 C_U , 解析逆为 C_Q , 离散支持点数为 K , 一次 CDF 求值为 C_F 。解析模式为 $\Theta(N(C_U + C_Q))$; 离散二分查找为 $\Theta(N(C_U + \log K))$, 线性扫描则为 $\Theta(N(C_U + K))$;

算法 31.2: 带离散和数值分支的广义逆抽样

输入: 候选 CDF F ; 模式 $\in \{\text{解析逆、离散累计表、连续数值逆}\}$; 独立均匀抽样器 $\mathcal{U}$; 端点政策与 B_U ; $N \in \mathbb{N}_0$; 数值模式的 δ, η, J 与括区间过程

输出: 最后合法样本前缀; $k, j_{\text{done}}, u_{\text{done}}$; **status**、括区间/残差与最终诊断

- 1 令 $k \leftarrow 0, j_{\text{done}} \leftarrow 0, u_{\text{done}} \leftarrow 0$ 及样本前缀为空; 核验 CDF、模式、 N, J 与容差/括区间规则; 失败则返回空前缀、计数 0、**invalid_input** 及字段诊断
- 2 若 $N = 0$, 则返回空前缀、计数 0、**completed** 及“零预算、未调用随机源”诊断
- 3 对 $i \leftarrow 1, \dots, N$ 执行
- 4 调用 $u \leftarrow \mathcal{U}()$ 并增加 u_{done} ; 调用失败或 u 非有限时返回 **random_source_failure**; 若 $u \in \{0, 1\}$ 则按登记政策重抽或停止, 重抽不得使 $u_{\text{done}} > B_U$, 且禁止裁剪; 得到 $u \notin (0, 1)$ 仍返回随机源失败及样本 i 诊断
- 5 **若** 解析逆模式 **则**
- 6 计算临时 $x = Q(u)$; 若非有限或越出支持, 返回前缀、**numerical_failure** 及解析逆诊断
- 7 **否则若** 离散模式 **则**
- 8 二分查找最小 r 使 $F_r \geq u$; 若不存在, 返回前缀、**numerical_failure** 及离散索引诊断; 否则令 x 为该支持点
- 9 **否则**
- 10 取得临时括区间; 无效则返回前缀、**numerical_failure** 及括区间诊断; 在保持不变量下至多二分 J 轮, 每轮增加 j_{done} ; 若仍未同时满足宽度与残差门, 则返回前缀、**budget_stop** 及样本 i 预算诊断; 否则令 $x = R$
- 11 **结束**
- 12 原子追加 x 及括区间/残差诊断, 并令 $k \leftarrow k + 1$
- 13 **结束**
- 14 返回 $X_{1:N}$ 、实际计数、**completed** 及最终模式/残差诊断

数值模式至多为 $\Theta(N(C_U + JC_F))$, 通常 J 按 $\lceil \log_2((R_0 - L_0)/\delta) \rceil$ 设定。除输出外工作空间为 $\Theta(1)$, 保存全部诊断为 $\Theta(N)$ 。

接受 – 拒绝抽样的数学主体与预算实现。 算法 31.3A 只保留证明分布正确性所需的数学主体; 有限提议预算、随机源失败、密度有限性与前缀返回放入算法后的鲁棒实现条带。这样每种采样方法只有一个核心算法, $p \leq cq$ 推出的接受分布证明不依赖人为预算, 工程实现又不会把“尚未收满”伪装成成功。

输入与输出。 核心算法输入归一化密度 p, q , q 的独立抽样器、支配条件 $p \leq cq$ 、有限 c 与目标接受数 N , 输出 N 个独立目标样本。工程调用另显式输入提议上限 B , 输出已经接受的样本前缀 $X_{1:a}$ 、实际提议数 m 、接受数 a 、状态和诊断; 失败时不得丢弃此前合法样本, 也不得把候选失败点计为接受。

参数、初始化与循环变量。 $N, B \in \mathbb{N}_0$ 且 $1 \leq c < \infty$ 。先核对 $p \ll q$ 与全局不等式 $p \leq cq$ 的调用方证书; 工程包装初始化 $m \leftarrow 0, a \leftarrow 0$ 、空样本表和空诊断。核心循环以 $a < N$ 为条件; 工程包装还同时检查 $m < B$, 每轮变量是候选 Y_m 和均匀数 U_m 。

更新顺序与判断条件。 先调用 q 抽样器得到 Y 并把实际提议数 m 增加 1, 再独立抽 $U \in (0, 1)$, 随后求 $p(Y), q(Y)$ 。密度必须有限非负且 $q(Y) > 0$; 计算 $\rho = p(Y)/(cq(Y))$ 后必须检查 $0 \leq \rho \leq 1$ 。只有 $U \leq \rho$ 才追加 Y 并增加 a 。若 c 过小导致 $\rho > 1$, 则状态为 **invalid_input**、诊断为 **envelope_condition_failure**, 禁止裁剪成 $\min(1, \rho)$ 或当作一次普通拒绝。

停止条件、返回结果与异常退化。 $a = N$ 时以 **completed** 结束; 工程包装中 $m = B$ 但 $a < N$ 时以 **budget_stop** 返回样本前缀。 $N = 0$ 在检查标量条件后返回空样本、 $m = a = 0$ 与 **completed**, 且不调用随机源; $N > 0, B = 0$ 返回 **budget_stop**。随机源、密度求值、支持或包络失败的状态与最小诊断字段见算法后的鲁棒实现条带。

算法 31.3A: 接受—拒绝抽样的数学主体

输入: 归一化密度 p, q 及理想 q /均匀源; $p(x) \leq cq(x)$ 证书; 有限 c ; $N \in \mathbb{N}_0$; 无人工提议上限
输出: 最后合法接受表 $X_{1:a}$; 实际 m, a ; **status** 与最终诊断

- 1 $m \leftarrow 0, a \leftarrow 0$, 样本表 X 初始化为空; 若 N, c 或支持/包络证书非法, 则返回空表、计数 0、**invalid_input** 及字段诊断
- 2 若 $N = 0$, 则返回空表、 $m = a = 0$ 、**completed** 及“无需理想随机调用”诊断
- 3 **当** $a < N$ **执行**
- 4 独立抽取 $Y \sim q$ 与 $U \sim U(0, 1)$
- 5 $m \leftarrow m + 1$
- 6 **若** $U \leq p(Y)/(cq(Y))$ **则**
- 7 原子追加 Y 并令 $a \leftarrow a + 1$
- 8 **结束**
- 9 **结束**
- 10 返回 $X_{1:N}, m, a = N, \text{completed}$ 及实际等待量/包络证书诊断

正确性依据、收敛条件与不适用情形。定理 31.3 证明核心算法中每个接受值服从 p 且接受值相互独立。没有数值迭代收敛问题; 有限 c 使每个接受值的等待时间几乎必然有限。工程包装只在 **completed** 时返回完整的 N 个样本; **budget_stop** 的前缀仍由合法接受事件产生, 但不是“已经完成 N 样本”的结果。不满足支持覆盖或不存在有限 c 时方法不适用。

读前自检: 接受—拒绝抽样的数学主体: 执行契约。 接受—拒绝抽样的数学主体输入“归一化密度 p, q 、理想独立提议/均匀源、全局包络证书、有限 c 与目标接受数 N ”, 条件“ $N \in \mathbb{N}_0, 1 \leq c < \infty$ ”; 请执行“接受事件成立时才原子追加样本并增加 a ”, 以“ $a = N$ 时停止”判停。

接受—拒绝抽样的数学主体: 五步阅读

输入。 写出数据对象、固定参数与必须成立的条件。

初始化。 标明主状态、计数器和第一个合法状态。

核心更新。 只手算一次从旧状态到候选状态的更新, 并指出何时提交。

数学停止。 写出能直接核验的停止证书; 预算耗尽不等同于收敛。

输出。 列出返回对象、实际计数、中心状态和用于复核的诊断。

算法实现说明: 实际调用另给提议上限 B , 循环条件改为 $a < N$ 且 $m < B$; $a = N$ 返回 **completed**, $m = B$ 且 $a < N$ 时返回合法前缀与 **budget_stop**。提议或均匀源失败返回 **random_source_failure**; 密度非有限、 $q(Y) \leq 0$ 或比率非有限返回 **numerical_failure**; $p(Y)/(cq(Y)) \notin [0, 1]$ 返回 **invalid_input** 并标记包络证书失败。所有分支保留 m, a 、失败阶段与此前合法前缀。完整 C1–C14 契约

复杂度假设。 一次 q 抽样及 p, q 求值总成本为 C_R , 追加一个样本按 $O(1)$ 均摊。最坏执行时间为 $\Theta(BC_R)$, 额外工作空间为 $\Theta(1)$, 输出空间为 $\Theta(N)$ 。在有效包络、无预算截断且独立试验下, 期望提议数为 Nc , 故期望时间为 $\Theta(NcC_R)$; 这个期望式不能替代最坏预算界。

普通与自归一化重要性估计。输入与输出。 输入为模式、各次调用相互独立且共同服从 q 的抽样器、目标密度 p 或未归一化密度 $\tilde{p} = Zp$ 、密度表示类型、可测函数 h 、支持覆盖条件、 N 及普通模式所需的归一化信息; 输出为估计、此前已经得到的记录、归一化权重和 ESS。普通模式若使用 $\tilde{p}$, 必须给出并验证 $Z \in (0, \infty)$; 未知 Z 时不能使用普通模式。

参数、初始化与循环变量。 模式只能是普通或自归一化; $N \in \mathbb{N}_0$ 。初始化空的 (h_i, ℓ_i) 前缀, 其中 ℓ_i 是对数权重。循环变量 $i = 1, \dots, N$ 。 $N = 0$ 不调用随机源, 估计与 ESS 未定义。

更新顺序与判断条件。每轮先独立抽 $Y_i \sim q$ 并计算 h_i 。普通模式输入 p 时取 $\ell_i = \log p(Y_i) - \log q(Y_i)$ ；普通模式输入 $\tilde{p}$ 和已知 Z 时取 $\ell_i = \log \tilde{p}(Y_i) - \log q(Y_i) - \log Z$ ；自归一化模式对所给目标表示 $\rho \in \{p, \tilde{p}\}$ 取 $\ell_i = \log \rho(Y_i) - \log q(Y_i)$ ，因为公共比例会在比值中消去。负密度、不是有限实数的求值或 $q(Y_i) \leq 0$ 都会使本次估计停止； $\ell_i = -\infty$ 表示合法零权。完成后取 $a = \max_i \ell_i$ 并令 $v_i = \exp(\ell_i - a)$ ，以共同缩放避免极端权重先溢出；若 ℓ_i 有限而机器数 $v_i = 0$ ，则发生了有限权重下溢。

停止条件与返回结果。遇到异常就停止并保留此前已经得到的记录。为允许有符号 h ，分别计算 $L_+ = \text{LSE}_{h_i > 0}(\ell_i + \log h_i)$ 与 $L_- = \text{LSE}_{h_i < 0}(\ell_i + \log(-h_i))$ ，空集合取 $-\infty$ ；再用有符号对数差（按较大者提取公因子并用 $\log 1p$ 或 expm1 ）得到分子符号 σ 与 $L_{\text{num}} = \log |e^{L_+} - e^{L_-}|$ 。普通模式返回 σ 和 $L_{\text{num}} - \log N$ ；自归一化模式还要求 $L_w = \text{LSE}_i \ell_i$ 有限，并返回 σ 和 $L_{\text{num}} - L_w$ 。只有该有符号对数值可表示为有限浮点数时才物化普通标量；正负贡献近抵消时也必须保留取消诊断。

异常与退化。若有限样本的普通权重全为零，则按定义估计为 0，但 ESS 未定义；同一情形在自归一化模式下因分母为零而不能形成估计。出现负权重、不是有限实数的权重或最终结果时也应停止。共同对数缩放降低中间溢出的风险，却不能保证 v_i 、 r 及最终乘积均可表示；有限 ℓ_i 对应的 $v_i = 0$ 、或缩放和非零而乘积下溢成 0 时，普通模式不能继续。ESS 按式 (31.15) 由 v_i 计算，并且只用作诊断。

正确性依据、收敛条件与不适用情形。若从 q 得到的样本相互独立同分布，则普通模式在目标已归一化、支持覆盖和一阶可积条件下无偏一致；若输入 $\tilde{p}$ ，减去 $\log Z$ 才恢复归一化权重。有限方差还需二阶矩。自归一化模式在定理 31.4 条件下只保证渐近一致，有限 N 通常有偏。支持缺口、自归一化的全零权重、未知归一化常数下的普通模式以及无限一阶矩均不适用。

对数缩放的普通或自归一化重要性估计：五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 31.4: 对数缩放的普通或自归一化重要性估计

输入: 模式; 独立 q 抽样器; h ; 目标 p 或 $\tilde{p}$; 支持证书; $N \in \mathbb{N}_0$; 普通模式所需 Z

输出: 最后合法记录; $i_{\text{done}}, q_{\text{done}}$; 估计/ESS; **status** 与最终诊断

- 1 $i_{\text{done}} \leftarrow 0, q_{\text{done}} \leftarrow 0$, 记录表为空; 若模式、 N 、支持证书或普通模式归一化信息非法, 则返回空记录、计数 0、**invalid_input** 及字段诊断
- 2 若 $N = 0$, 则返回空记录、未定义估计/ESS、**completed** 及“零预算、未调用随机源”诊断
- 3 **对** $i \leftarrow 1, \dots, N$ **执行**
- 4 调用 q 抽样器并增加 q_{done} ; 调用失败或样本非法时, 返回最后合法记录、实际计数、**random_source_failure** 及样本 i 诊断
- 5 在临时量中计算 $H_i = h(Y_i)$ 、 $q(Y_i)$ 及目标值; 求值失败、非有限、 $q(Y_i) \leq 0$ 或目标为负时, 返回记录、**numerical_failure** 及求值阶段诊断
- 6 按模式计算临时 ℓ_i , 零目标记为 $-\infty$; 若有限对数权重不能稳定表示, 则返回记录、**numerical_failure** 及权重诊断
- 7 原子追加 (Y_i, H_i, ℓ_i) 并令 $i_{\text{done}} \leftarrow i$
- 8 **结束**
- 9 令 $L_w \leftarrow \text{LSE}_i \ell_i$, 并在 L_w 有限时计算 $\log \text{ESS} = 2L_w - \text{LSE}_i(2\ell_i)$
- 10 令 $L_+ \leftarrow \text{LSE}_{H_i > 0}(\ell_i + \log H_i)$ 、 $L_- \leftarrow \text{LSE}_{H_i < 0}(\ell_i + \log(-H_i))$, 由稳定的有符号对数差得到 (σ, L_{num})
- 11 **若** 模式为普通 **则**
- 12 令 $L_{\text{est}} \leftarrow L_{\text{num}} - \log N$; 若正负项完全抵消则返回精确零
- 13 **否则**
- 14 若 $L_w = -\infty$ 则返回最后合法记录、未定义估计、**numerical_failure** 及“自归一化总权重为零”诊断; 令 $L_{\text{est}} \leftarrow L_{\text{num}} - L_w$
- 15 **结束**
- 16 若聚合结果非有限或标量化违反记录的上下溢策略, 则返回记录、**numerical_failure** 及聚合诊断
- 17 返回记录、 (σ, L_{est}) 、可表示标量、ESS、实际计数、**completed** 及取消/上下溢最终诊断

算法实现说明: 核心四步是从 q 抽样、计算对数权重、按普通或自归一模式聚合、报告估计与 ESS; 缩放和支撑失败属于稳健实现细节 完整 C1-C14 契约

复杂度假设。一次 q 抽样、目标密度、 q 与 h 求值总成本为 C_I 。两种模式执行时间均为 $\Theta(NC_I)$, 保存权重、函数值和诊断需 $\Theta(N)$ 空间; 若只做流式普通估计且不返回 ESS, 可降到 $\Theta(1)$ 工作空间, 自归一化与 ESS 的稳定对数缩放通常保留 N 条记录。

复杂度分析

时间复杂度总览。算法 31.1 线性使用 N 次目标抽样; 算法 31.2 取决于解析逆、离散查找或数值二分; 算法 31.3A 的确定上界由预算 B 控制、期望成本由 Nc 控制; 算法 31.4 线性使用 N 次提议抽样与权重求值。所有复杂度都把随机数、密度和函数求值成本参数化, 不能把它们无条件当作相同常数。

空间复杂度总览。在线均值只需常数工作空间; 返回全部样本、残差或权重时输出规模为 $\Theta(N)$ 。接受 - 拒绝法还需保存最多 N 个接受值, 但拒绝候选只需累计诊断; 数值逆在单次二分中只保存区间端点。

适用条件与局限性

适用条件。直接蒙特卡罗适用于能从目标分布独立抽样的可积期望; 逆变换适用于有可靠 CDF 与可计算广义逆的实值分布; 接受 - 拒绝法要求易抽样 q 和有限全局包络; 重要性抽样要求支持覆盖且权重贡献可积。

局限性。维数升高时包络常数和权重方差常迅速恶化; 解析逆可能不存在, 数值逆需要逐样本求根; ESS 不能检测共同支持缺口; iid 误差公式不覆盖相关样本和无限方差贡献。

常见错误。包括把端点均匀数静默裁剪、把 c 过小造成的 $\alpha > 1$ 改成普通接受、把部分接受前缀标为完整、从 q 抽样却忘记权重、宣称 SNIS 有限样本无偏、在 $N = 0$ 或 SNIS 总权重为零时除法，以及只看 ESS 而不检查支持。

易混淆概念对比。逆变换和接受 – 拒绝法产生未加权目标样本，普通重要性抽样产生无偏的加权估计而非目标样本；SNIS 消去未知归一化常数但引入有限样本偏差；接受 – 拒绝中的 $1/c$ 是精确接受率，ESS 只是权重集中度的启发式摘要。接受 – 拒绝的独立提议筛选也不同于后续会保留当前状态的 Metropolis–Hastings 转移。

例题 31.2 (固定样本下的蒙特卡罗估计与误差审计). 令 U_1, U_2, U_3, U_4 是来自 $U(0, 1)$ 的四个固定观测值

$$(u_1, u_2, u_3, u_4) = (0.4, 0.8, 0.1, 0.7),$$

用 $h(u) = u^2$ 估计 $I = \int_0^1 u^2 du$ ，并计算样本方差和标准误。

例题 31.2 解答

读题翻译 对四个固定均匀样本先逐个计算 $z_i = u_i^2$ 和样本均值，再用 $n - 1$ 分母估计 z_i 的方差，并由 $s/\sqrt{n}$ 给出均值标准误。

已知与合法条件 $n = 4$ ，目标真值为 $I = \int_0^1 u^2 du = 1/3$ ；题目要求的是无偏样本方差 s^2 ，不是用 n 作分母的经验二阶中心矩。

为什么想到这个方法 Monte Carlo 估计是函数值的算术平均；独立同分布样本均值的插件标准误为 $s/\sqrt{n}$ 。

方法选择 计算四个 z_i 、均值与真值误差；由离差平方和求 s^2 和标准误，再用原始二阶和公式独立复核方差。

推导/计算 计算。四个函数值依次为 0.16, 0.64, 0.01, 0.49，所以

$$\hat{I}_4 = \frac{0.16 + 0.64 + 0.01 + 0.49}{4} = 0.325, \quad I = \frac{1}{3}, \quad \hat{I}_4 - I = -\frac{1}{120}.$$

运行均值依次为 0.16, 0.40, 0.27, 0.325，既有上升也有下降；有限样本的波动不违背大数定律。以 $\bar{z} = 0.325$ 记最终均值，样本离差平方和为

$$(-0.165)^2 + (0.315)^2 + (-0.315)^2 + (0.165)^2 = 0.2529.$$

于是

$$s^2 = \frac{0.2529}{3} = 0.0843, \quad \widehat{SE} = \frac{s}{\sqrt{4}} = \sqrt{\frac{0.0843}{4}} \approx 0.14517.$$

独立核验 由原始二阶和 $\sum_i z_i^2 = 0.6754$ 可得

$$s^2 = \frac{\sum_i z_i^2 - 4\bar{z}^2}{3} = \frac{0.6754 - 4(0.325)^2}{3} = 0.0843,$$

与离差平方和算法一致。

结论 $\hat{I}_4 = 0.325$, 相对真值的误差为 $-1/120$; 样本方差 $s^2 = 0.0843$, 估计标准误约为 0.14517 。该标准误只是极小样本诊断, 不能据此声称有限样本正态区间具有精确覆盖率。

本章共 10 道练习。每道题干后立即给出同号解析; 长解析可自然跨页, 续页标题保留题号。

【原书练习整理】

练习 31.1. 用蒙特卡罗积分法计算

$$J = \int_{-\infty}^{\infty} x^2 \exp\left(-\frac{x^2}{2}\right) dx.$$

选取一个可直接抽样的概率分布, 把 J 写成期望, 给出无偏估计量, 并求出用于核验的精确值。

练习 31.1 解析

令 $X \sim \mathcal{N}(0, 1)$, 其密度为

$$\phi(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right).$$

因此

$$J = \sqrt{2\pi} \int_{-\infty}^{\infty} x^2 \phi(x) dx = \sqrt{2\pi} E(X^2).$$

若 $X_1, \dots, X_N$ 是独立标准正态样本, 则

$$\hat{J}_N = \frac{\sqrt{2\pi}}{N} \sum_{i=1}^N X_i^2$$

满足 $E(\hat{J}_N) = J$ 。标准正态分布有 $E(X^2) = 1$, 故精确值为

$$J = \sqrt{2\pi}.$$

还可用 $E(X^4) = 3$ 核对单次贡献的方差: $\text{Var}(\sqrt{2\pi}X^2) = 2\pi(3-1) = 4\pi$, 从而 $\text{Var}(\hat{J}_N) = 4\pi/N$ 。实际运行必须报告随机样本或种子; 原书页面未给出的一组坐标不能被反向伪造。

练习 31.2. 取 $U = (0.1, 0.4, 0.7, 0.8)$ 并令 $Z_i = U_i^2$ 。计算 $\bar{Z}$ 、无偏样本方差 s^2 、标准误 $s/\sqrt{4}$ 以及相对真值 $E(U^2) = 1/3$ 的误差。说明为什么这四个数不能证明收敛, 也不能推出总体方差为零。

练习 31.2 解析

函数值为 $0.01, 0.16, 0.49, 0.64$, 因此

$$\bar{Z} = \frac{1.30}{4} = 0.325, \quad \bar{Z} - \frac{1}{3} = -\frac{1}{120} \approx -0.00833.$$

练习 31.2 解析 (续)

相对 $\bar{Z}$ 的离差依次为 $-0.315, -0.165, 0.165, 0.315$, 离差平方和为 0.2529, 故

$$s^2 = \frac{0.2529}{4-1} = 0.0843, \quad \frac{s}{\sqrt{4}} = \sqrt{0.0843/4} \approx 0.14517.$$

大数定律讨论无限样本序列的极限, 四个固定数只能复算一次有限样本结果。即使这四次观测恰好相等, $s = 0$ 也只表示样本内没有观测到波动, 不能排除总体在未抽到位置上的变异。

练习 31.3. 设 $X \sim \text{Exp}(2)$ 。由 $u = 0.8$ 计算逆变换样本。另设离散分布在 $\{1, 2, 3\}$ 上的概率为 $(1/2, 1/3, 1/6)$, 分别求 $u = 0.2, 0.7, 0.95$ 对应的广义逆样本, 并写出每一步使用的“首次达到”不等式。

练习 31.3 解析

指数分布的分布函数为 $F(x) = 1 - e^{-2x}$ ($x \geq 0$), 所以

$$Q(u) = -\frac{1}{2} \log(1-u), \quad Q(0.8) = -\frac{1}{2} \log 0.2 \approx 0.804719.$$

离散分布的累计概率为 $F(1) = 1/2$ 、 $F(2) = 5/6$ 、 $F(3) = 1$ 。按 $Q(u) = \min\{x : F(x) \geq u\}$,

$$Q(0.2) = 1, \quad Q(0.7) = 2, \quad Q(0.95) = 3.$$

对应核验分别是 $0 < 0.2 \leq 1/2$ 、 $1/2 < 0.7 \leq 5/6$ 和 $5/6 < 0.95 \leq 1$ 。这里的弱不等号属于广义逆定义的一部分, 不能改成严格大于。

练习 31.4. 考虑满足

$$P(X = 0) = 0.7, \quad P(X = 1) = 0.3$$

的伯努利分布。计算 $Q(0.2)$, $Q(0.7)$, $Q(0.7001)$, $Q(0.9)$ 。再判断把随机数源返回的 $u = 0$ 或 $u = 1$ 静默裁剪到机器可表示的最近内点是否保持本章算法的数学条件, 并说明逐分量逆变换为何不能自动生成相关的多维分布。

练习 31.4 解析

支持集 $S = \{0, 1\}$ 上的质量满足 $0.7 + 0.3 = 1$ 。其 CDF 与广义逆判定链是

$$F(x) = 0 \ (x < 0), \quad 0.7 \ (0 \leq x < 1), \quad 1 \ (x \geq 1),$$

$$Q(u) = \inf\{x : F(x) \geq u\} = \begin{cases} 0, & 0 < u \leq 0.7, \\ 1, & 0.7 < u < 1, \end{cases}$$

$$(Q(0.2), Q(0.7), Q(0.7001), Q(0.9)) = (0, 0, 1, 1).$$

算法要求均匀数严格位于 $(0, 1)$ 。若得到 0、1 或非有限值, 应停止; 静默裁剪会引入一个未说明的近似分布, 并且在无界分布上可能掩盖无穷分位点。

逐分量逆变换只给出 $P(X_j \leq x) = F_j(x)$, 并不决定条件事件。令两个分量都有 $P(X_j = 1) = 0.3$, 则

$$P(X_1 = 1, X_2 = 1) = 0.3 \quad (X_2 = X_1), \quad P(X_1 = 1, X_2 = 1) = 0.3^2 = 0.09 \quad (X_1 \perp X_2).$$

练习 31.4 解析 (续)

两者边缘相同而联合分布不同；还需条件分布、copula 或其他联合抽样机制。

练习 31.5. 目标分布 $p = (1/2, 1/3, 1/6)$, 提议分布 $q = (1/3, 1/3, 1/3)$ 。求最小包络常数 c 、各状态的条件接受概率、总接受率和得到一个接受值所需提议次数的期望。直接核验给定“接受”时输出分布恰为 p 。

练习 31.5 解析

三个比率 p_i/q_i 依次为 $3/2, 1, 1/2$, 故最小包络常数是 $c = 3/2$ 。条件接受概率为

$$\alpha_i = \frac{p_i}{cq_i} = (1, 2/3, 1/3).$$

一次提议的总接受率为

$$\sum_{i=1}^3 q_i \alpha_i = \frac{1}{3} \left(1 + \frac{2}{3} + \frac{1}{3} \right) = \frac{2}{3} = \frac{1}{c},$$

所以得到一个接受值所需提议次数服从成功概率 $2/3$ 的几何分布, 期望为 $c = 3/2$ 。给定已经接受, 状态 i 的概率是

$$\frac{q_i \alpha_i}{2/3} = \left(\frac{1}{2}, \frac{1}{3}, \frac{1}{6} \right)_i = p_i.$$

这一步从联合提议 – 接受概率推导目标分布, 没有预先假设接受样本已经服从 p 。

练习 31.6. 设 $p(x) = 2x\mathbf{1}_{[0,1]}(x)$, $q(x) = \mathbf{1}_{[0,1]}(x)$ 。判断 $c = 2$ 与 $c = 1.5$ 是否分别给出合法包络。对目标样本数 $N = 2$ 、预算 $B = 0$ 说明算法应返回什么；若运行时算得 $\alpha = 4/3$, 比较“停止并修正包络”与把 α 裁剪成 1 两种处理的数学后果。

练习 31.6 解析

两密度的共同支持集是 $S = [0, 1]$, 且 $\int_S p = \int_S q = 1$ 。包络与接受概率为

$$\begin{aligned} \sup_{x \in S} \frac{p(x)}{q(x)} &= \sup_{0 \leq x \leq 1} 2x = 2, \\ c = 2 &\implies \alpha(x) = x \in [0, 1], \\ c = 1.5 &\implies \alpha(x) = \frac{4x}{3} > 1 \quad (x > 0.75). \end{aligned}$$

因此 $c = 2$ 合法, 而 $c = 1.5$ 违反全局支配。

当 $N = 2$ 而 $B = 0$ 时, 算法不得调用提议或均匀随机数；应返回空样本、已接受数 0 和已提议数 0, 并说明预算不足, 不能把空序列当成已生成两个样本。运行时出现 $\alpha = 4/3$ 说明支配条件、密度求值或 c 至少一项失效, 必须停止。若改成 $\min(1, \alpha)$, 实际接受密度正比于

$$q(x) \min \left\{ 1, \frac{p(x)}{cq(x)} \right\},$$

一般不再与 $p(x)$ 成比例, 因而会在不报警的情况下改变输出分布。

练习 31.7. 在三点空间上令 $p = (0.1, 0.3, 0.6)$ 、 $h = (1, 2, 4)$ 、 $q = (0.5, 0.3, 0.2)$ 。计算 $I = E_p h$ 、权重 $w = p/q$ 、单次普通重要性贡献的方差。若一次样本恰为 $(1, 2, 3)$ ，计算自归一化估计和启发式 ESS。最后求 $q^\star \propto |h|p$ 并核验其零方差性质。

练习 31.7 解析

目标期望与权重为

$$I = 0.1 \times 1 + 0.3 \times 2 + 0.6 \times 4 = 3.1, \quad w = (0.2, 1, 3).$$

单次普通重要性贡献 $G = wh$ 在三点上的取值为 $(0.2, 2, 12)$ ，所以

$$E_q(G^2) = 0.5(0.2)^2 + 0.3(2)^2 + 0.2(12)^2 = 30.02, \quad \text{Var}_q(G) = 30.02 - 3.1^2 = 20.41.$$

样本 $(1, 2, 3)$ 各出现一次时，

$$\hat{I}_{\text{SNIS}} = \frac{0.2 \times 1 + 1 \times 2 + 3 \times 4}{0.2 + 1 + 3} = \frac{14.2}{4.2} = \frac{71}{21} \approx 3.38095,$$

$$\text{ESS} = \frac{4.2^2}{0.2^2 + 1^2 + 3^2} = \frac{17.64}{10.04} \approx 1.75697.$$

又因 $|h|p = (0.1, 0.6, 2.4)$ ， $q^\star = (1, 6, 24)/31$ 。本题 $h > 0$ ，于是每个可能状态都有 $p_i h_i / q_i^\star = 3.1$ ，单次贡献为常数，理论方差为零。这个 $q^\star$ 是可核验的有限例子，不表示一般问题中其归一化常数或抽样器已知。

练习 31.8. 区分以下三种情形：一是普通重要性抽样的有限样本权重全部为零；二是自归一化重要性抽样的权重和为零；三是目标函数非零的某个集合在 q 下概率为零。分别说明估计值、ESS 或算法状态应如何报告，并判断“增加样本数总能修复问题”是否成立。

练习 31.8 解析

令 $w_i = p(Y_i)/q(Y_i)$ （或同比分母未知的核权重）。三种状态应由定义直接分开：

$$\text{普通 IS: } \hat{I}_N = \frac{1}{N} \sum_{i=1}^N w_i h_i = 0, \quad \sum_i w_i^2 = 0 \implies \text{ESS 未定义};$$

$$\text{SNIS: } \hat{I}_{\text{SNIS}} = \frac{\sum_i w_i h_i}{\sum_i w_i}, \quad \sum_i w_i = 0 \implies \text{估计未定义};$$

$$\text{支持缺口: } \exists A : \int_A |h|p > 0, q(A) = 0, E_p h = E_q(wh) \text{ 的改写失效.}$$

第一种是支持覆盖成立时可能出现的合法有限样本实现，估计值为 0 但 ESS 退化；第二种必须返回“零分母、未完成估计”；第三种是结构错误。对最后一种， $Y_i \sim q$ 给出

$$P_q(\exists i \leq N : Y_i \in A) = 1 - (1 - q(A))^N = 0,$$

故增加样本数永远不能访问缺失区域。

练习 31.9. 归一化权重为 $(0.90, 0.05, 0.03, 0.02)$ 。计算 ESS、最大归一化权重和零权重率。解释这些量能诊断什么、不能证明什么；再说明若四个函数值完全相同，为什么观测到 $s = 0$ 仍不能无条件推出总体方差为零。

练习 31.9 解析

归一化权重平方和为

$$0.9^2 + 0.05^2 + 0.03^2 + 0.02^2 = 0.8138,$$

所以

$$\text{ESS} = \frac{1}{0.8138} \approx 1.2288, \quad \max_i \tilde{w}_i = 0.90, \quad \text{零权重率} = 0.$$

这些数说明四个样本的加权贡献高度集中于一个样本，可用于比较提议分布或发现权重退化；它们不能证明支持覆盖、无偏性、一致性、有限方差或误差界。四个函数值完全相同时样本方差确为零，但总体仍可能在未抽到区域取不同值。只有另有数学条件证明函数在分布下几乎处处为常数，才能推出总体方差为零；否则学生化统计量还可能出现 $0/0$ 。

练习 31.10. 分别为下列任务选择逆变换、接受 - 拒绝、普通重要性抽样或自归一化重要性抽样，并写出最关键的适用条件与不能继续的情形：已知一维可逆 CDF 并要生成未加权样本；有全局包络但接受率很低；目标只知未归一化密度且只需期望；提议分布遗漏目标函数贡献区域。最后说明 $N^{-1/2}$ 误差率在哪些条件下才可使用。

练习 31.10 解析

四类选择可由输出对象和停止条件写成同一判定链：

$$\begin{aligned} F \text{ 合法且 } Q(u) \text{ 可算, } 0 < u < 1 &\implies X = Q(U) \quad (\text{逆变换}), \\ p \leq cq, c < \infty &\implies U \leq p(Y)/(cq(Y)) \quad (\text{接受 - 拒绝}), \\ p/q \text{ 可算且 } q > 0 \text{ 覆盖 } |h|p &\implies \hat{I} = N^{-1} \sum_i w_i h_i \quad (\text{普通 IS}), \\ \bar{p} \text{ 仅知到比例且 } \sum_i w_i > 0 &\implies \hat{I} = \sum_i w_i h_i / \sum_i w_i \quad (\text{SNIS}). \end{aligned}$$

第一类遇到非法端点或求逆失败停止；第二类低接受率不破坏正确性，但达到预设提议上限而未收集足量样本时不能冒充完成；第三类若归一化常数未知便不能继续；第四类必须接受有限样本通常有偏。若存在 $q(A) = 0$ 而 $\int_A |h|p > 0$ ，两种重要性改写都失效，只能更换 q 。对 iid 普通蒙特卡罗或普通 IS，令单次贡献为 G 。只有 $E(G^2) < \infty$ 时才有

$$\text{Var}(N^{-1} \sum_i G_i) = \frac{\text{Var}(G)}{N} \implies \text{RMSE} = \frac{\sigma}{\sqrt{N}}.$$

正态近似还需相应中心极限定理条件；相关样本、无限方差贡献和一般有限样本 SNIS 不能无条件套用该速率。

读前自检：本章结论与下一步。 蒙特卡罗方法与直接采样章末把“蒙特卡罗均值、广义逆、接受 - 拒绝和重要性抽样共享概率守恒，但输出对象与支持条件不同”收束为“数学主体分别是在线均值、 $Q(U)$ 、包络筛选与加权平均”；请把 $Q(U)$ 代入对应定义并写出结果类型，再核对“代入结果满足定义域与取值域”且该结果能直接进入章末所述方法。

本章结论与下一步

核心结论：蒙特卡罗均值、广义逆、接受—拒绝和重要性抽样共享概率守恒，但输出对象与支持条件不同。

关键依据：广义逆用事件等价证明；接受—拒绝由条件分布推出；重要性恒等式依赖支持覆盖，误差结论另需矩条件。

可执行自检：数学主体分别是在线均值、 $Q(U)$ 、包络筛选与加权平均；数值合法性和预算状态在数值实现部分另行处理。

适用边界：能独立抽样或构造覆盖提议时使用；支持缺口、无限方差与零权分母不能靠增大样本修复。

下一步：下一章以这些估计原则处理相关马尔可夫链样本，并把接受—拒绝思想改造成 MH 校正。

1. 能否从 E_{pf} 推出样本均值的无偏性、方差和均方误差并写出矩条件，再用事件等价证明广义逆定理并处理 CDF 跳跃、平坦段和 $u = 0, 1$ ？若不能，回看节 31.1、31.2。
2. 能否从联合接受事件推导接受率 $1/c$ 与条件输出分布，而不预设接受值已经服从 p ？若不能，回看节 31.3。
3. 能否区分普通 IS 的无偏估计与 SNIS 的有限样本偏差，并分别处理全零权重？若不能，重做练习 31.7 和 31.8。
4. 能否独立执行算法 31.1 至算法 31.4，说明适用条件、停止原因、已经得到的样本与复杂度？若不能，回看各算法前的实现说明。
5. 能否解释 ESS、样本标准误和接受率各自能诊断什么、不能证明什么，并在相关样本、无限方差、支持缺口和数值溢出时拒绝套用不成立的 $N^{-1/2}$ 结论？若不能，回看节 31.5。

第 32 章 马尔可夫链蒙特卡罗法

读前自检：本章地图：马尔可夫链蒙特卡罗法。 马尔可夫链蒙特卡罗法章地图把“目标密度 $\rightarrow$ 提议流 $\rightarrow$ MH 核 $\rightarrow$ 遍历均值与诊断”作为主线；请为其中首条箭头补出必要条件，并检查终点仍落在本章声明的输出域。

读前自检：本章可检验学习目标。 马尔可夫链蒙特卡罗法学习目标固定核验“把“从难抽样目标分布计算期望”转化为“构造以该分布为平稳分布的马尔可夫核””；请实际完成“把“从难抽样目标分布计算期望”转化为“构造以该分布为平稳分布的马尔可夫核””，并用“中间结果逐项包含首目标“把“从难抽样目标分布计算期望”转化为“构造以该分布为平稳分布的马尔可夫核””声明的对象、条件与结论”判定通过或失败。

读前自检：先修自检。 给定马尔可夫核 K 和候选分布 π ；请对任意可测集 A 计算 $(\pi K)(A) = \int \pi(dx)K(x, A)$ ，核对其是否等于 $\pi(A)$ ，并说明该等式表示平稳性，不要把细致平衡误当成必要条件。

读前自检：依赖路线。 马尔可夫链蒙特卡罗法依赖路线从“所引章节的平稳/遍历层次与所引章节的独立蒙特卡罗 $\rightarrow$ 相关轨迹估计”进入“未归一化目标 $\tilde{\pi}$ 与提议 $q \rightarrow$ 双向流、接受概率与拒绝自环 $\rightarrow$ 保持 π 的 MH 核”；请写出箭头成立所需的定义域条件，并核对前者输出能作为后者输入。

本章地图

核心问题：怎样构造保持目标分布的马尔可夫核，并准确说明各类长期结论所需条件？

可检验学习目标：

- 把“从难抽样目标分布计算期望”转化为“构造以该分布为平稳分布的马尔可夫核”，并区分平稳性、唯一性与遍历性；
- 从双向概率流推导 Metropolis–Hastings 接受概率与细致平衡，处理零流和拒绝自环，并说明正确性所需的可达与收敛条件；
- 手工执行一般与单分量 Metropolis–Hastings 算法，用轨迹、自相关、批均值标准误和有效样本量诊断计算质量；
- 以精确后验矩为基准核验随机计算，不虚构随机样本、接受率或数值输出。

最短先修：本章直接使用第 30 章的平稳、可逆与遍历层次，以及第 31 章的蒙特卡罗均值、未归一化密度和接受–拒绝抽样。还需条件概率、测度积分、对数与方差；有限状态可把 $\int$ 读成求和，连续状态统一相对于支配测度 μ 书写。

依赖路线：第 30 章提供平稳、可逆与遍历层次，第 31 章提供独立蒙特卡罗、未归一化密度与支持覆盖；本章把两条先修线汇合为目标 π 与提议 $q \rightarrow$ 接受率与 MH 核 $K \rightarrow$ 细致平衡证书 $\rightarrow \pi K = \pi$ ；另行核验有限状态不可约或一般状态正 Harris 常返 $\rightarrow$ 遍历时间平均；在相应结构条件上再加非周期性 $\rightarrow$ 边缘分布收敛。核 K 通常形成相关轨迹，但独立核是反例；相关性 $\rightarrow$ 轨迹、自相关、MCSE 和 ESS 诊断。

完成标准与返回：先复习第 30 章的长期行为和第 31 章的支持覆盖；连续状态还需熟悉可测核。

图 32.1 要求分支阅读：先沿“MH 构造 $\rightarrow K \rightarrow$ 细致平衡证书”核对 $\pi(dx)K(x,dy) = \pi(dy)K(y,dx)$ 只推出 $\pi K = \pi$ ；再分别沿链结构分支判断遍历时间平均与边缘分布收敛所需的附加条件，并沿诊断分支检查轨迹相关性。




图 32.1 细致平衡只验证平稳性；遍历平均和分布收敛还需相应链结构条件。

读图检查：平稳证书与收敛作用域。 只沿细致平衡分支能得到 $\pi K = \pi$ ，不能得到不可约或遍历；时间平均须另行核验有限状态不可约或一般状态正 Harris 常返，边缘分布收敛还须在相应结构条件上核验非周期性。图中的“通常相关轨迹”只是诊断动机；独立核 $K(x,dy) = \pi(dy)$ 说明相关性不是任意转移核的必然结论。

本章符号表		
符号	类型、维数或范围	含义
$(\mathcal{X}, \mathcal{B})$	可测空间	马尔可夫链状态空间
π	概率测度或密度	目标分布；满足 $\int \pi d\mu = 1$
$\tilde{\pi}$	$[0, \infty)$ 值函数	未归一化目标， $\tilde{\pi} = Z\pi$, $0 < Z < \infty$
$K(x, dy)$	马尔可夫核	从当前状态 x 到下一状态的转移规则
$q(x, y)$	非负密度	给定 x 时提议 y 的条件密度， $\int q(x, y)\mu(dy) = 1$
$g(x, y)$	非负函数	有向提议流 $\tilde{\pi}(x)q(x, y)$
$\alpha(x, y)$	$[0, 1]$	从 x 到提议 y 的接受概率
$r(x)$	$[0, 1]$	拒绝提议后留在 x 的自环质量
X_t	$\mathcal{X}$ 值随机变量	第 t 次转移后的链状态
m, n	非负整数	燃烧期转移数与保留状态数
$Y_t = f(X_t)$	实随机变量	目标函数沿轨迹的取值
γ_k, ρ_k	实数	平稳轨迹的滞后 k 自协方差与自相关
τ_{int}	非负实数（存在时）	积分自相关时间；ESS 仅在其严格为正时定义
N_{eff}	正实数（可定义时）	相对独立样本方差的有效样本量

读前自检：马尔可夫链蒙特卡罗目标期望。 MCMC 用相关轨迹 X_t 估计 $I = E_{\pi}f$ ；请在舍弃 m 步后计算 $\hat{I}_{m,n} = n^{-1} \sum_{t=m+1}^{m+n} f(X_t)$ ，核对输出仍是标量均值。

读前自检：MCMC 基本思想。 MCMC 基本思想是构造以 π 为平稳分布且可达目标支持的核 K ；请先核对 $\pi K = \pi$ ，再检查不可约/回返条件，说明只证平稳不足以保证时间平均正确。

读前自检：以平稳链估计目标期望。 若链从平稳分布启动，则每个 X_t 边缘都服从 π 但样本相关；请展开轨迹均值的期望，核对仍为 $E_\pi f$ ，而方差需包含自协方差项。

读前自检：MCMC 的目标保持与可达性。 MCMC 正确性需同时检查目标保持与可达性；请用恒等核 $K(x, \cdot) = \delta_x$ 作反例，核对它保持任意 π 却不能从初值访问其他状态。

32.1 MCMC 基本思想

设目标是计算

$$I = E_\pi[f(X)] = \int_{\mathcal{X}} f(x)\pi(x)\mu(dx), \quad (32.1)$$

但不能直接产生独立的 π 样本。MCMC 不把相关状态误称为独立样本，而是设计一个转移核 K ，使 π 保持不变，再以同一条链的时间平均

$$\hat{I}_{m,n} = \frac{1}{n} \sum_{t=m+1}^{m+n} f(X_t), \quad n \geq 1, \quad (32.2)$$

估计式 (32.1)。式中 m 不是证明链已经收敛的参数；丢弃前 m 步只能减弱某些初值影响，不能修复可约、周期、错误目标或错误转移核。

图 32.2 区分状态轨迹、提议与拒绝后重复的状态；图 32.3 显示从目标到估计量的完整链路。重复状态是 MH 核的组成部分，不应在保存轨迹时删除。




图 32.2 马尔可夫链在转移核 K 下产生相关样本路径；箭头 $x \rightarrow y$ 表示 $K(x, dy)$ 在 y 附近有正质量，自环表示链可能保持在当前状态

定义 32.1 (MCMC 构造). 给定目标概率分布 π 和函数 f ，若马尔可夫核 K 满足 $\pi K = \pi$ ，并且链的结构条件足以保证式 (32.2) 收敛到 $E_\pi f$ ，则“按 K 产生轨迹并计算时间平均”的方法称为以 π 为目标的马尔可夫链蒙特卡罗法。

定义包含两个层次： $\pi K = \pi$ 是目标保持条件；从给定初值出发的可达性、回返与遍历条件负责把时间平均连接到目标期望。只验证第一层不足以宣称估计一致。




图 32.3 MCMC workflow 按箭头依次完成三步：由目标分布 π 构造以 π 为平稳分布的转移核，运行链并舍弃预热段，再以保留样本的遍历平均估计 $\mathbb{E}_{\pi}[h(X)]$ 。

模型组成与合法性。本章的数学对象是五元组

$$((\mathcal{X}, \mathcal{B}), \mu, \tilde{\pi}, q, \nu_0).$$

要求 $(\mathcal{X}, \mathcal{B})$ 是标准 Borel 空间， μ 是 σ 有限测度； $\tilde{\pi}$ 可测且 $0 < Z = \int \tilde{\pi} d\mu < \infty$ ，从而 $\pi = \tilde{\pi}/Z$ 是概率密度； $q: \mathcal{X} \times \mathcal{X} \rightarrow [0, \infty)$ 关于 $\mathcal{B} \otimes \mathcal{B}$ 联合可测，且对每个合法 x 都有 $\int q(x, y) \mu(dy) = 1$ ；初始分布 ν_0 落在 $S = \{x: 0 < \tilde{\pi}(x) < \infty\}$ 内。联合可测性保证 $x \mapsto \int_B q(x, y) \mu(dy)$ 对每个 $B \in \mathcal{B}$ 可测，故 q 确实诱导提议马尔可夫核。若 $\tilde{\pi}$ 不可归一化，未知常数 Z 无法成为“会在比值中消去”的许可证，因为此时目标概率分布根本不存在。

常见错误

先保留数学主线。细致平衡只推出平稳，不推出不可约、唯一平稳或遍历；另外，MH 目标核必须存在有限正归一化常数。两个最小反例分别是恒等核 $K = I_2$ 和不可积的非负目标核。来源页码与核验过程统一移到章末“核验记录”，不插入算法推导。

学习策略。MCMC 在统计学习中的策略不是直接最小化一个经验风险，而是把后验期望、预测积分或隐变量期望写成式 (32.1)，再同时满足四项设计目标：

1. 目标保持： $\pi K = \pi$ ；
2. 可达性：目标支持内的重要区域属于同一可通信部分；
3. 可计算性：只使用 $\tilde{\pi}$ 的点值、提议抽样和提议密度比；
4. 统计效率：在正确性不受损的前提下降低相关性与计算成本。

第 1 项是代数条件，第 2 项是图或测度结构条件，第 3 项是可计算条件，第 4 项才涉及调参。高接受率、漂亮轨迹或小的经验 MCSE 都不能替代前 3 项。

学习算法。基本流程为：选取合法初值 x_0 ；在第 t 步根据 $q(x_{t-1}, \cdot)$ 产生提议 y_t ；用双向目标-提议流计算接受概率；接受时令 $x_t = y_t$ ，拒绝时令 $x_t = x_{t-1}$ ；固定执行 $m+n$ 次转移；最后保存完整状态与接受标志，按式 (32.2) 计算估计，并另行报告诊断。算法 32.1 在后文给出数学主体，异常与停止条件由紧邻算法的实现说明单列。

读前自检：细致平衡方程。 从细致平衡方程的条件 “ $\pi(x)k(x,y) = \pi(y)k(y,x)$ 对 $\mu \otimes \mu$ 几乎处处成立。” 出发，请把 $\pi(x)k(x,y)$ 展开一次并检查其类型或边界；所得量应符合第二步，对 x 积分。

32.2 平稳分布与细致平衡

读前自检：细致平衡。 设 π 为概率密度，马尔可夫核 K 有密度 k ，且 $\pi(x)k(x,y) = \pi(y)k(y,x)$ 对 $\mu \otimes \mu$ 几乎处处成立。请对 x 积分，核对总流入为 $\pi(y)$ ，故 $\pi K = \pi$ 。

定义 32.2 (细致平衡). 若对任意可测集合 $A, B \in \mathcal{B}$ 都有

$$\int_A \pi(dx) K(x, B) = \int_B \pi(dy) K(y, A), \quad (32.3)$$

则称 K 关于 π 满足细致平衡，或称平稳链关于 π 可逆。若 K 有密度 $k(x,y)$ ，条件化为

$$\pi(x)k(x,y) = \pi(y)k(y,x) \quad \text{对 } \mu \otimes \mu \text{ 几乎处处成立.} \quad (32.4)$$

从局部流到平稳分布的推导分三步。第一步，式 (32.4) 把 $x \rightarrow y$ 的平稳概率流与 $y \rightarrow x$ 的反向流配对。第二步，对 x 积分，

$$\int \pi(x)k(x,y) \mu(dx) = \int \pi(y)k(y,x) \mu(dx).$$

第三步使用 $\int k(y,x) \mu(dx) = 1$ ，右端成为 $\pi(y)$ ，于是总流入等于目标质量。图 32.4 把双向提议流与截平后的成对接受流分开绘制。




图 32.4 MH 接受机制把两个方向的已接受概率流同时截为两者较小值，从而满足细致平衡；该条件足以推出 π 平稳，但不是平稳性的必要条件

命题 32.1 (细致平衡推出平稳) 若概率测度 π 与马尔可夫核 K 满足式 (32.3)，则 $\pi K = \pi$ 。

读前自检：证明：细致平衡推出平稳。 细致平衡推出平稳以 “在该等式中取 $A = \mathcal{X}$ ” 为约束；请对 $(\pi K)(B)$ 做一次条件化或边缘化，并确认证明没有使用不可约性或非周期性，所以结论也不能附带唯一平稳分布、边缘收敛或时间平均收敛。

证明. 在式 (32.3) 中取 $A = \mathcal{X}$ 。因为 $K(y, \mathcal{X}) = 1$,

$$(\pi K)(B) = \int_{\mathcal{X}} \pi(dx) K(x, B) = \int_B \pi(dy) K(y, \mathcal{X}) = \pi(B)$$

对任意 $B \in \mathcal{B}$ 成立。因此 $\pi K = \pi$ 。证明没有使用不可约性或非周期性，所以结论也不能附带唯一平稳分布、边缘收敛或时间平均收敛。□

读前自检：Metropolis-Hastings 接受率。 Metropolis-Hastings 接受率比较双向流 $h(x, y) = \tilde{\pi}(x)q(x, y)$ 与 $h(y, x)$ ；请计算 $\alpha(x, y) = \min\{1, h(y, x)/h(x, y)\}$ ，并在正向流为 0 时按声明分支拒绝，并核对接受概率在 $[0, 1]$ 且零流不被伪正则化。

读前自检：双向目标—提议流。 MH 双向目标—提议流为 $h(x, y) = \tilde{\pi}(x)q(x, y)$ ；请交换 x, y 并取两者最小值，核对接受后的正反移动质量相等。

读前自检：Metropolis-Hastings 转移核。 MH 核由接受移动 $q(x, y)\alpha(x, y)$ 与补足总质量的拒绝自环组成；请对下一状态积分，核对接受移动质量加自环质量等于 1。

读前自检：Metropolis-Hastings 核可逆性。 令 $g(x, y)$ 和 $g(y, x)$ 为正反提议流。请分两者大小代入接受率，核对接受质量均为较小流。

阅读目标： 在成对细致平衡约束下选择最大的合法接受流。

对象： 正向提议流 $a = g(x, y)$ 、反向提议流 $b = g(y, x)$ 与接受概率 $\alpha_{xy}, \alpha_{yx} \in [0, 1]$ 。

合法条件： 已接受流需满足 $a\alpha_{xy} = b\alpha_{yx}$ ；零流情形必须单独约定。

第一步： 先令共同接受流为 h ，由概率上界得到 $0 \leq h \leq \min(a, b)$ 。

读前自检：Metropolis-Hastings 拒绝自环。 MH 拒绝时必须保留当前状态形成自环；请计算 $r(x) = 1 - \int q(x, y)\alpha(x, y) dy$ ，核对接受 $r(x) \geq 0$ 且加入 $r(x)\delta_x$ 后转移核归一。

读前自检：单分量 Metropolis-Hastings 算法。 单分量 MH 以当前 d 维状态、坐标提议核和扫描预算为输入；请只替换一个坐标形成候选，按完整目标与正反提议比接受或自环，完成一轮扫描后提交，并在预算结束时返回轨迹。

32.3 Metropolis-Hastings 算法

定义从状态 x 提议 y 的正向目标—提议流为

$$g(x, y) = \tilde{\pi}(x)q(x, y). \quad (32.5)$$

为避免在 $g(x, y) = g(y, x) = 0$ 时产生 0/0，先定义接受后的无向公共流

$$h(x, y) = \min\{g(x, y), g(y, x)\}. \quad (32.6)$$

再在实际有正向提议流时定义

$$\alpha(x, y) = \begin{cases} h(x, y)/g(x, y) = \min\left\{1, \frac{\tilde{\pi}(y)q(y, x)}{\tilde{\pi}(x)q(x, y)}\right\}, & g(x, y) > 0, \\ 0, & g(x, y) = 0. \end{cases} \quad (32.7)$$

第二个分支的取值不会改变从 x 实际产生的提议分布；算法仍需核验抽样器返回的候选与 q 求值器一致。若 $\tilde{\pi}(y) = 0$ 或 $q(y, x) = 0$ ，则 $h(x, y) = 0$ 并拒绝，不把零分子改成一个很小的正数。

由于 $\tilde{\pi}$ 与 q 联合可测， g, h, α 均可测；因 $0 \leq q\alpha \leq q$ ，下式中的积分是 $[0, 1]$ 值可测函数。拒绝概率和完整 MH 核分别为

$$r(x) = 1 - \int q(x, y)\alpha(x, y)\mu(dy), \quad (32.8)$$

$$K(x, dy) = q(x, y)\alpha(x, y)\mu(dy) + r(x)\delta_x(dy). \quad (32.9)$$

第一项已经包括离散情形下被接受的自提议；第二项专门记录所有拒绝造成的自环。删除重复状态会改变核和时间尺度。图 32.5 展示提议、接受、拒绝与留驻的关系。




图 32.5 Metropolis-Hastings 单次更新中的提议判定及拒绝自环。

读图顺序：先看从当前状态 $X_t = x$ 按 $q(x, \cdot)$ 提出候选 $Y = y$ ；再看 $g(x, y) > 0$ 时计算 $\alpha(x, y)$ ，抽取 $U \sim U(0, 1)$ 并比较 $U \leq \alpha(x, y)$ ；最终接受时令 $X_{t+1} = y$ ，拒绝时仍记录一次旧状态 $X_{t+1} = x$ ，形成自环。

定理 32.1 (MH 核的可逆性) 若 $(\mathcal{X}, \mathcal{B})$ 为标准 Borel 空间, μ 为 σ 有限测度, $0 < Z = \int \tilde{\pi} d\mu < \infty$, 且 q 是上述联合可测的合法提议密度, 则式 (32.7)–(32.9) 定义一个马尔可夫核 K 。该核关于 $\pi = \tilde{\pi}/Z$ 满足细致平衡, 因而 π 是 K 的平稳分布。

读前自检：证明：MH 核的可逆性。 MH 接受流满足 $\tilde{\pi}(x)q(x, y)\alpha(x, y) = h(x, y) = h(y, x)$ ；请除以共同归一化常数并对 $A \times B$ 积分，核对接受移动部分双向流相等，再验证拒绝自环项也满足详细平衡。

证明。 由式 (32.6)–(32.7)，对 $\mu \otimes \mu$ 几乎处处的 (x, y) ,

$$\tilde{\pi}(x)q(x, y)\alpha(x, y) = h(x, y) = h(y, x) = \tilde{\pi}(y)q(y, x)\alpha(y, x).$$

除以共同的正归一化常数 Z ，接受移动部分的双向流相等。对任意 $A, B \in \mathcal{B}$ ，接受部分满足

$$\int_A \int_B \pi(x)q(x, y)\alpha(x, y)\mu(dy)\mu(dx) = \int_B \int_A \pi(y)q(y, x)\alpha(y, x)\mu(dx)\mu(dy).$$

拒绝自环部分在两侧都等于

$$\int_{A \cap B} \pi(x)r(x)\mu(dx),$$

所以完整核满足式 (32.3)。命题 32.1 再给出 $\pi K = \pi$ 。此证明只建立可逆与平稳，没有建立不可约、唯一或遍历。□

读前自检：接受率的成对流推导。 成对接受流令 $a = g(x, y), b = g(y, x)$ 且 $0 \leq \alpha_{xy}, \alpha_{yx} \leq 1$ ；请由 $c = a\alpha_{xy} = b\alpha_{yx} \leq \min\{a, b\}$ 构造取等的双向接受率，并核对 $a = 0$ 或 $b = 0$ 时不计算 $0/0$ 。

32.4 接受率推导

推导目标

从细致平衡的成对流约束出发，推导在固定提议核下逐对最大的合法接受流，并由此得到包含零流边界的 Metropolis–Hastings 接受概率。

推导准备

固定 x, y ，记正向与反向提议流为 $a = g(x, y)$ 和 $b = g(y, x)$ 。接受概率必须属于 $[0, 1]$ ；若要求已接受流满足细致平衡，则 $a\alpha_{xy} = b\alpha_{yx}$ 。

推导第 1 步：给出共同流的上界。 令 $c = a\alpha_{xy} = b\alpha_{yx}$ 。由 $0 \leq \alpha_{xy}, \alpha_{yx} \leq 1$ ，同时有 $c \leq a$ 与 $c \leq b$ ，因而 $c \leq \min\{a, b\}$ 。

推导第 2 步：构造达到上界的双向接受概率。 当 $a, b > 0$ 时取 $\alpha_{xy} = \min\{a, b\}/a$ 及 $\alpha_{yx} = \min\{a, b\}/b$ ；若某一方向流为零，则共同流只能为零，并把由正流指向零反向流的移动确定拒绝。该构造在所有边界情形均不需要计算 $0/0$ 。

推导第 3 步：还原 MH 接受核。 在 $a > 0$ 的分支，正向接受概率化为 $\alpha(x, y) = \min\{1, b/a\}$ ；代回 $a = \tilde{\pi}(x)q(x, y)$ 与 $b = \tilde{\pi}(y)q(y, x)$ 即得式 (32.7)。未接受的剩余质量必须并入 x 处拒绝自环，才能得到总质量为 1 的马尔可夫核。

读前自检：成对约束下的最大接受流。 成对约束下的最大接受流要求先确认 “ $0 \leq \alpha_{xy}, \alpha_{yx} \leq 1$, $a\alpha_{xy} = b\alpha_{yx}$ ”；请随后把 $0 \leq \alpha_{xy}, \alpha_{yx} \leq 1$, $a\alpha_{xy}$ 移到同一边并核对符号，用该等式达到该上界验收。

命题 32.2 (成对约束下的最大接受流) 固定一对状态 x, y 并记 $a = g(x, y)$ 、 $b = g(y, x)$ 。在所有满足

$$0 \leq \alpha_{xy}, \alpha_{yx} \leq 1, \quad a\alpha_{xy} = b\alpha_{yx}$$

的接受规则中，共同流 $a\alpha_{xy} = b\alpha_{yx}$ 的最大值为 $\min\{a, b\}$ ；式 (32.7) 达到该上界。

读前自检：证明：成对约束下的最大接受流。 从成对约束下的最大接受流的条件 “若 $a > 0$ ，取 $\alpha_{xy} = \min\{a, b\}/a$ ” 出发，请把 $\alpha_{xy} = \min\{a, b\}/a$ 用到的关键定义展开并完成下一步变形；所得量应符合变形没有增加前提且得到证明所述结论。

证明。 设共同流为 c 。由 $\alpha_{xy} \leq 1$ 得 $c = a\alpha_{xy} \leq a$ ；由 $\alpha_{yx} \leq 1$ 得 $c = b\alpha_{yx} \leq b$ ，故 $c \leq \min\{a, b\}$ 。若 $a > 0$ ，取 $\alpha_{xy} = \min\{a, b\}/a$ ；若 $a = 0$ ，取 $\alpha_{xy} = 0$ 。对反向作同样定义，便有两侧共同流都等于 $\min\{a, b\}$ ，且接受概率位于 $[0, 1]$ 。因此该上界可以达到。将 a, b 换回式 (32.5) 即得 MH 接受率。 $\square$

图 32.6 同时画出比值小于与大于 1 的两段；“截到 1”来自概率上界，而不是数值补丁。




图 32.6 MH 接受概率是比值 r 的截断函数 $\alpha = \min\{1, r\}$ ，其中 $r = \pi(y)q(y, x)/[\pi(x)q(x, y)]$ ；独立提议时可写为 $r = w(y)/w(x)$

常见特例。 若 $q(x, y) = q(y, x)$ ，提议项消去，

$$\alpha(x, y) = \min\{1, \tilde{\pi}(y)/\tilde{\pi}(x)\}.$$

若 $q(x, y) = q(y)$ 与当前状态无关, 则

$$\alpha(x, y) = \min\left\{1, \frac{\tilde{\pi}(y)q(x)}{\tilde{\pi}(x)q(y)}\right\}.$$

对数实现使用

$$\Delta = \log \tilde{\pi}(y) - \log \tilde{\pi}(x) + \log q(y, x) - \log q(x, y), \quad \log \alpha = \min\{0, \Delta\},$$

但只有各正密度项可取对数; 零分子必须进入确定拒绝分支。

单分量 MH. 写 $x = (x_j, x_{-j})$, 在保持 x_{-j} 不变时从 $q_j(x_j, y_j | x_{-j})$ 提议 y_j 。令 $y = (y_j, x_{-j})$, 则

$$\alpha_j(x, y) = \min\left\{1, \frac{\tilde{\pi}(y_j, x_{-j})q_j(y_j, x_j | x_{-j})}{\tilde{\pi}(x_j, x_{-j})q_j(x_j, y_j | x_{-j})}\right\} \quad (32.10)$$

在分母正时成立, 零流仍按式 (32.6) 处理。

定理 32.2 (连续单坐标 MH 的独立不变性证明) 设 $x = \prod_{r=1}^d x_r$, 支配测度为 $\mu = \bigotimes_r \mu_r$, 目标有密度 $\pi(x)$ 。第 j 坐标提议 $q_j(x_j, y_j | x_{-j})$ 关于 $\mu_j(dy_j)$ 归一化且联合可测。用式 (32.10) 及零流分支构造的单坐标核 K_j 关于 π 可逆, 因而保持 π 。该结论不要求 $K_j(x, dy)$ 关于全维 $\mu(dy)$ 有密度。

证明: 连续单坐标 MH 的独立不变性证明: 证明阅读检查

动手检查。 待证结论与所需条件分别是什么? 请在最小维度或最小样本上写出第一处关键变形, 并指出少一个条件时证明会在哪一步中断。

1. 先写清对象类型、目标结论与符号作用域。
2. 逐项核对定义域、维数、支持集、量词与交换运算所需条件。
3. 写出第一处可执行的数学动作, 不用“显然”跳过入口。
4. 沿现有编号完成中间关系, 并单独核对归一化、边界或等号条件。
5. 回到待证结论, 再说明它与后续公式、算法、图或例题的连接。

继续核对。 完成上面的最小任务后, 再对照主体逐项核对定义域、更新式或关键变形、停止条件以及返回值; 阅读检查不代替正文中的数学论证。

证明. 单坐标提议的全维写法是

$$Q_j(x, dy) = q_j(x_j, y_j | x_{-j}) \mu_j(dy_j) \delta_{x_{-j}}(dy_{-j}),$$

它集中在 $y_{-j} = x_{-j}$ 的低维集合上, 通常对全维 Lebesgue 测度奇异, 故不能套用“存在 $q(x, y)$ 全维密度”的证明。改在三元组 (x_{-j}, x_j, y_j) 上取支配测度

$$\mu_{-j} := \bigotimes_{r \neq j} \mu_r, \quad \lambda_j = \mu_{-j}(\mathrm{d}x_{-j})\mu_j(\mathrm{d}x_j)\mu_j(\mathrm{d}y_j).$$

正向未接受流对 λ_j 的密度为

$$g_j(x_{-j}, x_j, y_j) = \pi(x_j, x_{-j})q_j(x_j, y_j | x_{-j}),$$

反向流只是交换 x_j, y_j 。接受后的非对角流密度为

$$g_j(x_{-j}, x_j, y_j)\alpha_j(x, y) = \min\{g_j(x_{-j}, x_j, y_j), g_j(x_{-j}, y_j, x_j)\},$$

在交换 x_j, y_j 时不变; 零正向流按约定不计算比值。拒绝概率产生的对角自环显然双向相同。因此整个 pair measure 在交换前后状态时对称, 即 $\pi(\mathrm{d}x)K_j(x, \mathrm{d}y) = \pi(\mathrm{d}y)K_j(y, \mathrm{d}x)$, 从而 $\pi K_j = \pi$ 。□

命题 32.3 (单分量核的保持性与扫描方式) 若每个坐标 MH 核 K_j 关于共同目标 π 可逆, 则每个 K_j 保持 π 。任意固定顺序的系统扫描复合核 $K_1 K_2 \cdots K_d$ 保持 π , 但一般不关于 π 可逆; 固定权重 $w_j > 0$ 、 $\sum_j w_j = 1$ 的随机扫描混合核 $\sum_j w_j K_j$ 关于 π 可逆。

读前自检：证明：单分量核的保持性与扫描方式。 单分量核的保持性与扫描方式依赖“除非这些核满足额外交换关系, 正序复合与逆序复合不相等”; 请据此把 $\pi K_1 K_2 \cdots K_d$ 用到的关键定义展开并完成下一步变形, 并直接核对变形没有增加前提且得到证明所述结论。

证明。 每个 K_j 可逆, 由命题 32.1 得到 $\pi K_j = \pi$ 。逐次代入可得

$$\pi K_1 K_2 \cdots K_d = (\cdots ((\pi K_1) K_2) \cdots) K_d = \pi,$$

所以系统扫描保持 π 。其伴随核的顺序为 $K_d \cdots K_2 K_1$; 除非这些核满足额外交换关系, 正序复合与逆序复合不相等, 因此不能从各分量可逆推出复合核可逆。对随机扫描, 任意 A, B 上的双向流是各 K_j 双向流的加权和, 每一项交换 A, B 后不变, 故混合核仍满足细致平衡。□

图 32.7 区分“一个坐标更新”与“完成一轮扫描”, 并标出系统扫描和随机扫描在可逆性上的差异。

读前自检：马尔可夫链蒙特卡罗法与统计学习。 有限状态 MH 若目标全支持且核不可约、正常返, 则遍历均值成立; 请取 $f = \mathbf{1}_{\{j\}}$, 核对访问频率趋于 $\pi(j)$, 再由有限求和推广到一般 f 。




图 32.7 分量 MH 的系统扫描与随机扫描。固定顺序的核复合通常不保证可逆；可逆坐标核的固定权重随机混合仍保持可逆。

32.5 收敛与样本诊断

定理 32.3 (有限状态 MH 的正确性条件) 设 $\mathcal{X}$ 有限, $\pi(x) > 0$ 对每个 $x \in \mathcal{X}$ 成立, K 为以 π 为目标的 MH 核。

1. π 是 K 的平稳分布。
2. 若 K 不可约, 则 π 是唯一平稳分布, 且对任意 $f: \mathcal{X} \rightarrow \mathbb{R}$ 及任意初值,

$$\frac{1}{n} \sum_{t=1}^n f(X_t) \longrightarrow E_{\pi} f \quad \text{几乎必然.}$$

3. 若 K 还非周期, 则对任意初始分布 ν_0 都有 $\nu_0 K^t \rightarrow \pi$ 。

读前自检：证明：有限状态 MH 的正确性条件。 有限状态 MH 已知不可约且以 π 可逆；请把 $f(X_t)$ 展开为 $\sum_x f(x) \mathbf{1}_{\{X_t=x\}}$ 并交换有限求和与时间极限，核和时间平均只需不可约，而 $\nu_0 K^t \rightarrow \pi$ 还需非周期性。

证明。 第 1 项由定理 32.1 得到。定理 30.1 在同一行随机与平稳约定下给出：有限不可约链的平稳分布唯一且各状态正常返。再由定理 30.2 的式 (30.14)，把 f 写成有限和

$$f(X_t) = \sum_{x \in \mathcal{X}} f(x) \mathbf{1}_{\{X_t=x\}},$$

对每个状态的访问频率使用该遍历定理，再交换有限求和与极限，得到第 2 项。若再加非周期性，定理 30.2 的式 (30.15) 给出 $K^t(x, \cdot) \rightarrow \pi$ ；按初始分布 ν_0 作有限加权和即得 $\nu_0 K^t \rightarrow \pi$ 。非周期性没有用于时间平均结论，因此不能把第 2 项与第 3 项合并成一个无条件断言。□

定理中的时间平均也覆盖任意固定燃烧期 m 。事实上，若 $S_N = N^{-1} \sum_{t=1}^N f(X_t) \rightarrow I$ ，则

$$\frac{1}{n} \sum_{t=m+1}^{m+n} f(X_t) = \frac{m+n}{n} S_{m+n} - \frac{1}{n} \sum_{t=1}^m f(X_t) \longrightarrow I,$$

因为 m 固定, 第二项的分子只含有限项。若 $X_0 \sim \pi$, 则每个 $X_t \sim \pi$, 并且

$$E_{\pi}(\hat{I}_{m,n}) = \frac{1}{n} \sum_{t=m+1}^{m+n} E_{\pi} f(X_t) = E_{\pi} f.$$

若从固定 x 启动,

$$E_x(\hat{I}_{m,n}) = \frac{1}{n} \sum_{t=m+1}^{m+n} K^t f(x),$$

有限 n 时一般不等于 $E_{\pi} f$ 。所以固定燃烧期不保证有限样本无偏; 它只在已有收敛条件下影响初值偏差的大小。

读前自检: 一般状态空间的可达与回返条件。 一般状态空间的 ψ -不可约性要求每个 $\psi(A) > 0$ 的集合都能从任意初态以正概率到达; 请给定一个集合 A 检查 $P_x(\tau_A < \infty) > 0$, 并与概率为 1 的回返条件区分。

定义 32.3 (一般状态空间的可达与回返条件). 给定非零 σ 有限测度 ψ , 若每个满足 $\psi(A) > 0$ 的可测集 A 都满足 $P_x(\tau_A < \infty) > 0$ (对所有 x), 则称链为 ψ -不可约; 若进一步 $P_x(\tau_A < \infty) = 1$ (对所有 x), 则称其 Harris 回返。Harris 回返链若存在不变概率分布 π , 称为正常 Harris 返。这里的陈述针对集合而不是单点, 所以适用于连续状态空间。

命题 32.4 (一般状态空间结论的条件分层) 设 K 为正常 Harris 返核且不变概率分布为 π 。

1. 对每个 $f \in L^1(\pi)$, 时间平均 $n^{-1} \sum_{t=1}^n f(X_t)$ 几乎必然收敛到 $E_{\pi} f$; 该结论不要求非周期性。
2. 若 K 还非周期, 则对该遍历定理覆盖的初始状态有 $\|K^t(x, \cdot) - \pi\|_{TV} \rightarrow 0$, 从而固定时刻的边缘分布收敛; 这不是时间平均结论的同义改写。
3. 中心极限定理、有限渐近方差以及批均值估计的一致性都不是前两项的自动推论; 它们还需相应矩条件与混合条件, 例如几何遍历配合 $E_{\pi}|f|^{2+\delta} < \infty$, 并按所用批均值定理选择批长增长条件。

易混淆概念对比

三个反例把结论边界分开。 两点确定翻转链不可约且具有唯一平稳分布 $(1/2, 1/2)$, 状态访问频率与可积函数时间平均仍正确, 但固定时刻分布按奇偶振荡; 缺少的是非周期性。恒等核 I_2 可逆且保持任意分布, 却可约、平稳分布不唯一, 时间平均由初值决定; 缺少的是跨类可达性。整数集 $\mathbb{Z}$ 上的简单对称随机游走不可约且 Harris 回返, 但为零常返, 没有不变概率分布; 因此不能把“会返回”替换成正常 Harris 返。最后, 即使正常 Harris 返保证 L^1 大数律, 若 f 没有所需二阶矩或链缺少相应混合速率, 中心极限定理与批均值误差估计仍可能失效。

因此, 连续状态空间中“从任意点到任意点的概率为正”既不必要也通常不可验证。平稳性只说明目标保持; ψ -不可约性只说明正 ψ 测度集合可达; 正常 Harris 返才支撑 L^1 时间平均; 非周期性另用于总变差或边缘收敛; MCSE 与批均值还要额外的矩和混合假设。有限状态定理不能只靠把求和符号改成积分就自动推广。

读前自检：平稳相关均值的有限样本方差。 平稳相关均值的有限样本方差把问题限定在“设链从平稳分布启动， $Y_t = f(X_t)$ 具有有限方差 $\gamma_0 > 0$ ”；请把 γ_k 展开一次并检查其类型或边界，检查是否得到展开后的量满足定义中的域、维数或符号限制。

命题 32.5 (平稳相关均值的有限样本方差) 设链从平稳分布启动， $Y_t = f(X_t)$ 具有有限方差 $\gamma_0 > 0$ ，并令

$$\gamma_k = \text{Cov}(Y_t, Y_{t+k}), \quad \rho_k = \gamma_k / \gamma_0.$$

则对 $\bar{Y}_n = n^{-1} \sum_{t=1}^n Y_t$,

$$\text{Var}(\bar{Y}_n) = \frac{\gamma_0}{n} \left[1 + 2 \sum_{k=1}^{n-1} \left(1 - \frac{k}{n} \right) \rho_k \right]. \quad (32.11)$$

读前自检：证明：平稳相关均值的有限样本方差。 在 “ $\text{Var}(\bar{Y}_n) = \frac{1}{n^2} \left[n\gamma_0 + 2 \sum_{k=1}^{n-1} (n-k)\gamma_k \right]$.” 成立时处理平稳相关均值的有限样本方差：请对 $\text{Var}(\bar{Y}_n)$ 做一次条件化或边缘化，并以所得量与证明紧接着给出的概率关系相同判定结果。

证明。 直接展开协方差双重和：

$$\text{Var}(\bar{Y}_n) = \frac{1}{n^2} \sum_{s=1}^n \sum_{t=1}^n \text{Cov}(Y_s, Y_t).$$

平稳性使协方差只依赖 $|s-t|$ 。滞后 0 有 n 项；对每个 $1 \leq k \leq n-1$ ，上三角和下三角各有 $n-k$ 对相距 k 的时刻。因此

$$\text{Var}(\bar{Y}_n) = \frac{1}{n^2} \left[n\gamma_0 + 2 \sum_{k=1}^{n-1} (n-k)\gamma_k \right].$$

提出 γ_0/n 并使用 $\rho_k = \gamma_k/\gamma_0$ ，得到式 (32.11)。□

若 $\sum_{k \geq 1} |\rho_k| < \infty$ ，定义

$$\tau_{\text{int}} = 1 + 2 \sum_{k=1}^{\infty} \rho_k, \quad \sigma_{\text{as}}^2 = \gamma_0 \tau_{\text{int}}. \quad (32.12)$$

在另有适当的马尔可夫链中心极限定理条件时， $\sqrt{n}(\bar{Y}_n - E_{\pi}f)$ 渐近服从方差 σ_{as}^2 的正态分布。有限样本的方差等效有效样本量为

$$N_{\text{eff},n} = \frac{n}{1 + 2 \sum_{k=1}^{n-1} (1 - k/n) \rho_k}, \quad (32.13)$$

前提是分母正且使用真实自相关。用截断经验自相关替换它只能得到诊断估计；负相关时 ESS 可以大于 n ，因此不应机械裁剪到 n 。

批均值提供另一条渐近方差估计路径。令 $n = ab$, 把轨迹分成 $a \geq 2$ 个连续批、每批长度 $b \geq 1$, 批均值为 $\bar{Y}^{(j)}$, 则

$$\hat{\sigma}_{\text{BM}}^2 = \frac{b}{a-1} \sum_{j=1}^a (\bar{Y}^{(j)} - \bar{Y}_n)^2, \quad \widehat{\text{MCSE}}_{\text{BM}} = \sqrt{\hat{\sigma}_{\text{BM}}^2/n}, \quad \hat{N}_{\text{eff,BM}} = n s_Y^2 / \hat{\sigma}_{\text{BM}}^2, \quad (32.14)$$

最后一个比值只在分子、分母有限且分母正时定义。批均值一致性要求随总长度增长时 a, b 都增长且满足相应混合与矩条件；一条有限轨迹不能单独证明这些条件。

图 32.8 展示固定诊断示意轨迹与保留样本运行均值。




图 32.8 舍弃前 5 步后, 保留样本运行均值在目标值 2 附近波动; 本图仅作诊断, 不构成收敛证明

读图时, 先看上面板如何把 $t = 1, \dots, 5$ 标为预热段; 再看下面板只从 $t = 6$ 起递推 $\bar{X}_{6:t}$; 最终比较其与目标值 2, 并核对 15 个保留样本在 $t = 20$ 时给出 $\bar{X}_{6:20} = 2.0000$ 。图 32.9 把经验 ACF 与同一预设窗口下的有限样本加权 ESS 并列为一个诊断单元。




图 32.9 固定窗口内的正经验自相关增大方差权重, 因而使同长度轨迹的有效样本量减小。

读图时, 先看左面板在 $k = 1, \dots, 6$ 的预设窗口内保留了哪些正经验自相关; 再看右面板如何有限样本权重形成 $\hat{t}_{6,n}$; 最终得到正相关增大方差权重、并使同长度轨迹的 $\hat{N}_{\text{eff}}$ 减小。

读前自检：常见错误与误用边界：收敛与样本诊断。 收敛与样本诊断所用的明确前提是“边界框首项禁止抽稀只取子序列，不制造独立性”；完成把固定错误“抽稀只取子序列，不制造独立性”中的对象、操作与结论按本节定义拆开，指出第一个不满足的定义条件，再把该处改为本节允许的写法后，核对改写后的运算或判断有定义，且不再触发“抽稀只取子序列，不制造独立性”。

常见错误

燃烧期不把可约链变成不可约链；抽稀只取子序列，不制造独立性；接受率既不是平稳性证明，也不是收敛证明；单条轨迹看似稳定可能只是困在一个模态。应同时保存多条不同初值链、未抽稀轨迹、运行均值、自相关、批均值 MCSE 与异常状态，并把这些量称为诊断而不是定理结论。

几何解释。 把 π 的高密度区看成状态空间中的山脊。提议核决定一步可走的方向与尺度，接受规则校正地形高低与提议的不对称。步长过小时会在局部缓慢爬行；步长过大会频繁撞到低密度区而留在原地。几何直觉用于调参，但目标保持仍由双向流证明。

概率解释。 MH 先生成有向提议流 $g(x, y)$ ，再把每对反向流削减到共同值 $\min\{g(x, y), g(y, x)\}$ 。多出的正向流变成拒绝自环，因此总概率仍为 1。正是“接受移动加拒绝留驻”的完整核保持目标分布。

优化解释。 命题 32.2 说明，在逐对满足细致平衡且接受概率不超过 1 的限制下，MH 选择最大的共同流。这是局部接受流最大化，不等于全局最小化自相关或 MCSE。改变提议 q 会同时改变移动距离、接受概率和计算成本；只最大化接受率通常把步长推向过小。

图 32.5 把目标、提议、接受流和拒绝自环组合成完整核。图 32.10 对比接受-拒绝抽样与 MH：前者拒绝后重新独立提议且只输出接受值，后者拒绝后把当前状态复制到下一时刻，输出是一条相关马尔可夫链。




图 32.10 接受-拒绝抽样拒绝候选后不输出该候选；MH 拒绝候选后把当前状态再次记入链，因此输出通常相关而非独立

例题 32.1 (单向提议造成的支持连通缺口). 在三点空间上令目标分布为 $\pi = (1/3, 1/3, 1/3)$ ，提议矩阵为定向三环

$$Q = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{pmatrix}.$$

计算 MH 接受率与所得核, 并解释为什么“提议图从每点都有出边”仍不足以保证可用的 MH 链。

例题 32.1 解答

读题翻译 虽然定向三环从每个状态都有一条出边, 但 MH 接受率还需要反向提议概率; 要逐边计算接受率, 写出完整核并判断链是否可用。

已知与合法条件 目标在三个状态上均为正且相等; Q 按行给出提议概率, 每条非对角转移为 $q_{ij}\alpha(i, j)$, 拒绝概率补到对角线。

为什么想到这个方法 MH 比值含 $\pi_j q_{ji}/(\pi_i q_{ij})$; 若正向边的反向提议为零, 则该正向提议必被拒绝。

方法选择 对 $1 \rightarrow 2$ 、 $2 \rightarrow 3$ 、 $3 \rightarrow 1$ 分别检查反向概率, 得到全部接受率并补全 K ; 再区分“ π 平稳”和“链不可约并收敛”。

推导/计算 计算。状态支持集是 $S = \{1, 2, 3\}$, 且每行提议概率之和为 1。从 1 只能提议 2, 但反向 $q_{21} = 0$, 故

$$\alpha(1, 2) = 0.$$

同理 $q_{32} = q_{13} = 0$ 分别使 $\alpha(2, 3) = \alpha(3, 1) = 0$, 因而所有提议都被拒绝, 所得核是 $K = I_3$ 。

独立核验 虽然 $\pi K = \pi$, 但从点质量 δ_1 出发有 $\delta_1 K^t = \delta_1$ 对所有 t 成立, 不会趋近 π ; 这直接证实平稳性没有带来不可约性。

结论 三条提议边的接受率全为 0, 所得 MH 核为 $K = I_3$; 任意分布虽都平稳, 但链完全可约且不会从一般初值收敛到 π 。问题在于每条有向提议边都缺少反向流; 后文例 32.2 再审计双向非对称提议。

本模块给出三个可独立执行的过程: 一般 MH、单分量 MH 和轨迹诊断。随机数序列给定后, 算法的控制路径完全确定; 若中途停止, 只使用此前完成的整次转移, 不能把部分轨迹当成完整结果。

输入与输出。 一般 MH 输入可归一化的未归一化目标 $\tilde{\pi}$ (满足 $0 < \int \tilde{\pi} d\mu < \infty$)、提议抽样器与双向密度求值器、合法初值 x_0 、相互独立的 $(0, 1)$ 均匀数、燃烧期 m 、保留数 n 及可选函数 f 。输出完整状态轨迹、提议、接受判定、保留样本, 以及在 $n > 0$ 且 f 合法时的均值。

参数含义。 $T = m + n$ 是固定转移预算; m 只决定哪些状态不进入均值, n 决定保留状态数。提议尺度属于 q 的一部分。若采用单分量算法, 还需维数 d 、每坐标提议 q_j 与扫描规则。诊断算法另需滞后上限 L 和满足 $n = ab$ 的批数 a 、批长 b 。

初始化。 先确认目标可归一化, 检查 $0 < \tilde{\pi}(x_0) < \infty$ 和整数参数; 令当前状态 $x \leftarrow x_0$, 轨迹以 x_0 开头, 接受计数为 0。不得从目标支持外启动后再靠一次非法比值“跳回”支持。

更新顺序。 每轮先由 $q(x, \cdot)$ 提议 y , 再独立取 $u \in (0, 1)$; 核对前向提议密度为有限正数。若 $\tilde{\pi}(y) = 0$ 或 $q(y, x) = 0$, 确定拒绝; 否则计算对数比 Δ 并比较 $\log u$ 与 $\min\{0, \Delta\}$ 。接受或拒绝后都必须追加新的链状态。

算法 32.1: 带零流分支和完整状态轨迹的一般 MH

输入: 已核验 $0 < \int \tilde{\pi} d\mu < \infty$ 的目标核; 提议密度 q 及一致抽样器; x_0 ; 独立均匀源; $m, n \in \mathbb{N}_0$; 可选 f

输出: 最后合法轨迹、提议/接受表与保留段; $t_{\text{done}}, p_{\text{done}}, u_{\text{done}}$; **status** 与最终诊断

- 1 核验目标证书、 m, n, x_0 及提议/随机接口; 失败则返回空结果、计数 0、**invalid_input** 及字段诊断
- 2 令 $T = m + n, X_0 = x_0, t_{\text{done}} = p_{\text{done}} = u_{\text{done}} = 0$, 提议/接受表为空; 若 $T = 0$, 返回 (X_0) 、空保留段、**completed** 及零预算诊断
- 3 **当** $t_{\text{done}} < T$ **执行**
- 4 令 $t = t_{\text{done}} + 1$; 从 $q(X_{t-1}, \cdot)$ 抽取临时 Y 并增加 p_{done} ; 调用失败或样本非法时, 返回完整前缀、**random_source_failure** 及提议阶段诊断
- 5 独立抽取 U 并增加 u_{done} ; 调用失败、非有限或 $U \notin (0, 1)$ 时, 返回前缀、**random_source_failure** 及均匀阶段诊断
- 6 计算 $q_{xy}, q_{yx}, \tilde{\pi}(Y)$; 求值失败、非有限、 $q_{xy} \leq 0, q_{yx} < 0$ 或目标为负时, 返回前缀、**numerical_failure** 及密度阶段诊断
- 7 **若** $\tilde{\pi}(Y) = 0$ 或 $q_{yx} = 0$ **则**
- 8 | 令 $A_t \leftarrow \text{false}$
- 9 **否则**
- 10 | 计算 Δ_t ; 非有限则返回前缀、**numerical_failure** 及接受比诊断; 令 $A_t = [\log U \leq \min\{0, \Delta_t\}]$
- 11 **结束**
- 12 令候选 $X^+ = Y$ 或 X_{t-1} ; 原子追加 Y, A_t, X^+ 并令 $t_{\text{done}} \leftarrow t$
- 13 **结束**
- 14 令保留段为 $X_{m+1:m+n}$; 若 $n > 0$ 且给出 f , 则新鲜求值, 任一失败时保留轨迹并返回 **numerical_failure** 及均值阶段诊断
- 15 返回全部最后合法结果、实际计数、**completed** 及接受率/零流/保留段最终诊断

停止条件。正常分支恰好执行 T 次转移。 $T = 0$ 时不调用任何随机数, 返回只含 x_0 的轨迹和空保留集。遇到不是有限实数的目标或提请求值、负密度、正反提请求值不一致、非法均匀数或函数值异常时立即停止, 只保留此前完成的整次转移。

正确性与收敛条件。定理 32.1 保证合法 MH 核保持 π ; 定理 32.3 说明有限状态下还需不可约性, 边缘逐步收敛还需非周期性。一般状态空间必须按定义 32.3 与命题 32.4 分别核验正常 Harris 返、非周期性以及 MCSE 所需的额外矩与混合条件。算法完成只表示预算执行完毕, 不表示这些数学条件已经由数据诊断证明。

不收敛或不适用情形。目标不可归一化、提议诱导的链无法经多步到达目标支持中的各个正质量区域(因而可约), 或连续状态链不满足所需 Harris 返性时, 增加燃烧期与样本数都不能补救正确性; 轨迹诊断算法也不适用于非有限输入或批数不足的序列。

复杂度假设。下述界把一次目标求值、正反提议密度求值与随机数调用的实际成本显式记入 C_{MH} 或 C_j , 并假设一次状态复制为 $O(d)$; 不把目标密度、提议器或坐标更新无条件视为常数时间。

带零流分支和完整状态轨迹的一般 MH: 五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新, 并指出何时提交。

数学停止。写出能直接核验的停止证书; 预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 32.2: 固定顺序的单分量 MH 扫描

输入: 目标核 π ; $x^{(0)} \in \mathbb{R}^d$; 合法坐标提议 q_j ; 独立均匀数; 扫描数 $T = m + n$

输出: 最后合法轮末轨迹与部分扫描诊断; $s_{\text{done}}, c_{\text{done}}, a_{\text{done}}$; **status** 及最终诊断

- 1 若 d, T 、目标/初值、坐标提议或随机接口非法, 则返回空结果、计数 0、**invalid_input** 及字段诊断
- 2 $x \leftarrow x^{(0)}, s_{\text{done}} = c_{\text{done}} = a_{\text{done}} = 0$, 轮末轨迹只含 $x^{(0)}$; 若 $T = 0$, 返回该轨迹、**completed** 及零预算诊断
- 3 对 $s \leftarrow 1, \dots, T$ 执行
 - 4 复制轮初状态为临时 x_{work}
 - 5 对 $j \leftarrow 1, \dots, d$ 执行
 - 6 从 $q_j(x_{\text{work},j}, \cdot | x_{\text{work},-j})$ 抽取 y_j ; 随机源失败或样本非法时, 返回上一轮末轨迹、当前只读 x_{work} 、**random_source_failure** 及 (s, j) 诊断
 - 7 令 $y = (y_j, x_{\text{work},-j})$ 并计算零流接受概率; 目标/密度/比率非有限或越界时, 返回上一轮末轨迹、只读 x_{work} 、**numerical_failure** 及 (s, j) 诊断
 - 8 抽取独立 u ; 随机源失败或 $u \notin (0, 1)$ 时, 返回上一轮末轨迹、只读 x_{work} 、**random_source_failure** 及均匀阶段诊断
 - 9 若 $u \leq \alpha_j$, 则原子令 $x_{\text{work}} \leftarrow y$ 并增加 a_{done} ; 无论接受与否增加 c_{done}
 - 10 结束
 - 11 原子提交 $x \leftarrow x_{\text{work}}$ 并追加 $x^{(s)}$; 令 $s_{\text{done}} \leftarrow s$
 - 12 结束
- 13 返回 $x^{(0:T)}$ 、实际计数、**completed** 及逐坐标接受/零流最终诊断

单分量 MH。更新规则。输入 d 维初值、共同目标、坐标提议 q_j 、每轮坐标顺序、总扫描数 $m + n$ 和随机数。一次扫描依次产生 d 个候选状态; 每个候选只替换当前坐标, 并立即成为下一坐标更新的当前状态。系统扫描输出每轮末状态; 若保存每次坐标更新, 时间下标与燃烧期必须相应改为坐标更新数, 不能混用。若第 j 个坐标更新失败, 只保留此前完成的整轮; 本轮中间状态另行说明, 不计作轮末样本。

固定顺序的单分量 MH 扫描: 五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新, 并指出何时提交。

数学停止。写出能直接核验的停止证书; 预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

自相关与批均值诊断。输入与输出。输入一条已保留的标量轨迹 $y_1, \dots, y_n$ 、滞后上限 L 、批数 a 、批长 b 及可选接受判定。要求 $n \geq 2, 0 \leq L < n, a \geq 2, b \geq 1$ 且 $n = ab$ 。输出样本均值、样本方差、经验自相关、有限样本加权截断 ESS、批均值 MCSE 与 ESS; 这些量不构成收敛证明。

读前自检: 有限样本权重与批均值并列的轨迹诊断: 执行契约。有限样本权重与批均值并列的轨迹诊断输入“有限非恒定标量轨迹 $y_{1:n}$ 、滞后上限 L 、批数 a 与批长 b ”, 条件“ $n \geq 2, 0 \leq L < n, a \geq 2, b \geq 1, n = ab$ 且全部轨迹值有限非恒定”; 请执行“全部统计一致性通过后才提交完整诊断输出”, 以“全部有限扫描完成或首次失败时停止”判停。

读前自检: 有限样本权重与批均值并列的轨迹诊断。有限样本权重与批均值并列的轨迹诊断输入“有限非恒定标量轨迹 $y_{1:n}$ 、滞后上限 L 、批数 a 与批长 b ”, 条件“ $n \geq 2, 0 \leq L < n, a \geq 2, b \geq$

算法 32.3: 有限样本权重与批均值并列的轨迹诊断

输入: 非恒定的有限实数轨迹 $y_{1:n}$; $0 \leq L < n$; $a \geq 2, b \geq 1$ 且 $n = ab$
输出: 最后合法统计; $y_{\text{done}}, k_{\text{done}}, b_{\text{done}}$; **status** 与最终诊断

- 1 置 $y_{\text{done}} = k_{\text{done}} = b_{\text{done}} = 0$; 若 n, L, a, b 或批划分非法, 则返回空统计、**invalid_input** 及字段诊断
- 2 逐项核验 y_t 有限并增加 y_{done} ; 若非有限或轨迹恒定, 则返回已验证前缀信息、**invalid_input** 及位置/方差诊断
- 3 计算 $\bar{y} \leftarrow n^{-1} \sum_t y_t$ 与 $s_Y^2 \leftarrow (n-1)^{-1} \sum_t (y_t - \bar{y})^2$
- 4 若均值或方差非有限或方差非正, 则返回最后合法输入诊断、**numerical_failure** 及基础统计阶段诊断
- 5 **对** $k \leftarrow 0, \dots, L$ **执行**
- 6 令 $\hat{\gamma}_k \leftarrow (n-k)^{-1} \sum_{t=1}^{n-k} (y_t - \bar{y})(y_{t+k} - \bar{y})$, $\hat{\rho}_k \leftarrow \hat{\gamma}_k / \hat{\gamma}_0$; 若非有限则返回基础统计与已提交 ACF、**numerical_failure** 及滞后 k 诊断; 否则原子追加并增加 k_{done}
- 7 **结束**
- 8 令 $\hat{t}_L \leftarrow 1 + 2 \sum_{k=1}^L (1 - k/n) \hat{\rho}_k$
- 9 若 $\hat{t}_L \leq 0$ 或非有限, 则返回基础统计/ACF、**numerical_failure** 及截断时间诊断; 否则令 $\widehat{\text{ESS}}_L = n / \hat{t}_L$
- 10 **对** $j \leftarrow 1, \dots, a$ **执行**
- 11 计算第 j 个连续批均值; 若非有限则返回已有统计、**numerical_failure** 及批 j 诊断; 否则原子追加并增加 b_{done}
- 12 **结束**
- 13 令 $\hat{\sigma}_{\text{BM}}^2 \leftarrow b(a-1)^{-1} \sum_j (\bar{y}^{(j)} - \bar{y})^2$
- 14 $\widehat{\text{MCSE}}_{\text{BM}} \leftarrow \sqrt{\hat{\sigma}_{\text{BM}}^2 / n}$ 并形成批均值 ESS; 若结果非有限或定义域失败, 则返回前述统计、**numerical_failure** 及批聚合诊断
- 15 原子提交完整诊断输出, 返回实际计数、**completed** 及“有限轨迹诊断不是收敛证明”最终诊断

1, $n = ab$ 且全部轨迹值有限非恒定”; 请做一轮“全部统计一致性通过后才提交完整诊断输出”, 以“全部有限扫描完成或首次失败时停止”核对停止证书。

算法实现说明: 核心流程保留丢弃预热、估计均值/自协方差、计算 ESS 和批均值误差、并列报告; 权重与退化诊断属于稳健实现细节 完整 C1-C14 契约

读前自检: 复杂度分析: 自相关与批均值诊断。 长度 T 的 MCMC 轨迹每步提议成本为 C_{MH} 时, 生成成本为 $\Theta(TC_{\text{MH}})$; 请再加滞后 L 的自相关诊断成本 $\Theta(TL)$, 核对只在线计数与保存完整轨迹的空间分别不同。

复杂度分析

时间复杂度。 设一次提议抽样、目标求值、双向提议密度求值的成本合计为 C_{MH} , 状态复制成本为 $O(d)$ 。一般 MH 执行 $T = m + n$ 步的时间为 $\Theta(T(C_{\text{MH}} + d))$ 。单分量算法若第 j 个坐标更新成本为 C_j , 则 T 轮成本为 $\Theta(T \sum_{j=1}^d C_j)$ 。直接计算 L 个经验自相关需 $\Theta(nL)$, 批均值与样本方差需 $\Theta(n)$; 这些界不把目标密度求值无条件视为常数。

空间复杂度。 只保留当前状态与在线接受计数时, 一般 MH 工作空间为 $\Theta(d)$; 返回完整轨迹需 $\Theta((m+n)d)$ 输出空间。单分量算法若保存轮内状态, 额外输出可达 $\Theta((m+n)d^2)$, 通常只保存轮末状态和 d 个接受判定。诊断算法保存输入轨迹与 $L+1$ 个自相关为 $\Theta(n+L)$, 批均值另需 $\Theta(a)$ 。

适用条件与局限性

适用条件。MH 适用于能计算未归一化目标点值、能从提议核抽样并能计算正反提议密度的问题。目标必须可归一化，初值必须在正目标支持内，所得核还需在目标支持上具备足够可达性。单分量 MH 适合全维提议难设计、而条件坐标提议容易构造的高维问题。

局限性。高维、多峰、强相关或狭窄支持会导致慢混合；密度比只使用局部点值，不能自动发现未访问模态。固定预算不能保证预定误差，有限轨迹也不能验证所有渐近条件。系统扫描虽保持目标，一般不再可逆；若目标本身不可归一化，任何调参都不能修复。

常见错误。包括遗漏 $q(y, x)/q(x, y)$ ；在 0/0 处硬算比值；删除拒绝产生的重复状态；把高接受率当作高 ESS；用燃烧期修复可约性；把抽稀后样本称为独立；只画单链轨迹便宣布收敛；把细致平衡扩张为唯一性；对不可归一化核运行 MCMC；以及报告未实际运行得到的随机样本或数值。

易混淆概念对比。平稳性是 $\pi K = \pi$ ，可逆性是更强的双向流条件；不可约性负责连接支持，非周期性负责消除边缘分布振荡。接受-拒绝抽样只输出接受候选并可产生 iid 样本，MH 拒绝时保留当前状态并产生相关链。燃烧期丢弃前缀，抽稀选择子序列，二者都不同于证明收敛。MCSE 量化给定诊断模型下的均值不确定性，ESS 把相关方差换算成 iid 尺度，二者都不是核正确性的证明。

32.6 例题、马尔可夫链计算与练习

例题 32.2 (由非对称提议构造完整 MH 核). 在状态空间 $\{1, 2, 3\}$ 上，目标分布和提议矩阵为

$$\pi = \left(\frac{1}{2}, \frac{1}{3}, \frac{1}{6}\right), \quad Q = \begin{pmatrix} 1/2 & 1/2 & 0 \\ 1/4 & 1/2 & 1/4 \\ 0 & 1/2 & 1/2 \end{pmatrix}.$$

任务如下：逐条计算非对角接受率，写出包含拒绝自环的 MH 矩阵 K ；用双向流核验 π 平稳；判断不可约性与非周期性；最后从 $x_0 = 1$ 出发，把固定测试输入

$$(y_1, u_1) = (2, 0.2), \quad (y_2, u_2) = (3, 0.8)$$

送入算法，给出两次转移后的状态。这里的两个数是确定性测试输入，不声称来自一次真实随机运行。

例题 32.2 解答

读题翻译 要把非对称提议逐边校正成完整 MH 核：计算双向接受率，把拒绝质量补到对角线，再核验平稳性、连通性、周期和两次固定输入分支。

已知与合法条件 $\pi_i > 0$ 且 Q 行随机；接受率为 $\alpha_{ij} = \min\{1, \pi_j q_{ji}/(\pi_i q_{ij})\}$ ，非对角核元为 $q_{ij}\alpha_{ij}$ 。

为什么想到这个方法 逐对比较正反概率流可同时得到接受率和细致平衡；所有非对角元确定后，对角元必须由每行和为 1 唯一补足。

方法选择 分别处理边 $1 \leftrightarrow 2$ 、 $2 \leftrightarrow 3$ ，构造完整 K ；核对双向流、连通图和自环，再按给定 (y_t, u_t) 顺序执行两次接受判定。

推导/计算 接受率。 对边 $1 \leftrightarrow 2$,

$$\alpha_{12} = \min \left\{ 1, \frac{(1/3)(1/4)}{(1/2)(1/2)} \right\} = \frac{1}{3}, \quad \alpha_{21} = 1.$$

对边 $2 \leftrightarrow 3$,

$$\alpha_{23} = \min \left\{ 1, \frac{(1/6)(1/2)}{(1/3)(1/4)} \right\} = 1, \quad \alpha_{32} = 1.$$

$q_{13} = q_{31} = 0$ ，这对边不产生提议流。**完整核。** 非对角转移概率是 $q_{ij}\alpha_{ij}$ ，对角元由行和为 1 补足，因此

$$K = \begin{pmatrix} 5/6 & 1/6 & 0 \\ 1/4 & 1/2 & 1/4 \\ 0 & 1/2 & 1/2 \end{pmatrix}.$$

平稳性与结构。 两个非零无向边上的流分别满足

$$\pi_1 K_{12} = \frac{1}{2} \cdot \frac{1}{6} = \frac{1}{12} = \frac{1}{3} \cdot \frac{1}{4} = \pi_2 K_{21},$$

$$\pi_2 K_{23} = \frac{1}{3} \cdot \frac{1}{4} = \frac{1}{12} = \frac{1}{6} \cdot \frac{1}{2} = \pi_3 K_{32}.$$

对角流与自身相等，故细致平衡成立；按命题 32.1， $\pi K = \pi$ 。图 1-2-3 连通，所以 K 不可约；三个状态都有正自环，因此周期为 1。有限状态定理 32.3 遂给出唯一平稳分布、时间平均收敛与边缘分布收敛。

确定性分支测试。 第 1 步从 1 提议 2，因为 $u_1 = 0.2 \leq 1/3$ 而接受，得到 $x_1 = 2$ ；第 2 步从 2 提议 3，接受概率为 1，故 $u_2 = 0.8$ 仍导致接受，得到 $x_2 = 3$ 。

独立核验 除逐边流量检查外，直接相乘也有

$$\pi K = \left(\frac{1}{2}, \frac{1}{3}, \frac{1}{6} \right), \quad K \mathbf{1} = \mathbf{1},$$

分别复核平稳性与随机矩阵约束。

结论 所得核为 $K = \begin{pmatrix} 5/6 & 1/6 & 0 \\ 1/4 & 1/2 & 1/4 \\ 0 & 1/2 & 1/2 \end{pmatrix}$ ，不可约、非周期并以 π 为唯一平稳分布；固定输入得到 $x_1 = 2, x_2 = 3$ ，只用于核验分支逻辑。

卡住时先看 先只写出对象、合法条件和第一轮/第一步中间量；若这些量无法定义，再返回相应定义。

读前自检：易混淆概念对比：例题、马尔可夫链计算与练习。 章末核验记录固定两条边界证据：请对 $K = I_2$ 与任意严格正分布 π 核对细致平衡与状态不连通，判定“可逆链一定不可约”为假；再检查 $\exp[-(x_1 - 1)^2(x_2 - 1)^2/2]$ 在 $\mathbb{R}^2$ 上的积分，核对积分发散使其不能归一化为概率密度。

易混淆概念对比

章末核验记录（不参与算法主线）。核对对象为《统计学习方法（第 2 版）》2019 年 5 月第 2 版、2019 年 6 月第 2 次印刷，ISBN 978-7-302-51727-6。原书练习 19.5（PDF 第 405 页、印刷页第 382 页）要求证明“可逆链一定不可约”；反例 $K = I_2$ 与任意严格正 π 满足细致平衡，但状态互不连通。原书例 19.9（PDF 第 396 页、印刷页第 373 页）的核 $\exp[-(x_1 - 1)^2(x_2 - 1)^2/2]$ 在 $\mathbb{R}^2$ 上积分发散，不能归一化为概率密度。两项只作为“平稳不推出可达性”和“未归一化目标仍须可归一”的边界证据；它们是内部数学核验，不冒充出版社官方勘误。

本章共 14 道练习。每道题干后立即给出同号解析；长解析可自然跨页，续页标题保留题号。

【原书练习整理】

练习 32.1. 从一般 Metropolis–Hastings 算法推导单分量 Metropolis–Hastings 算法。要求写出坐标提议核、正反提议流、接受概率和一轮系统扫描，并说明系统扫描保持目标分布但一般不再可逆。

练习 32.1 解析

设每个坐标空间 $(x_j, \mathcal{B}_j)$ 为标准 Borel 空间， μ_j 为 σ 有限测度，并要求 $q_j(x_j, y_j | x_{-j})$ 关于 (x, y_j) 联合可测、非负，且对每个 x 满足 $\int q_j(x_j, y_j | x_{-j}) \mu_j(dy_j) = 1$ 。于是对任意可测矩形 $B = B_j \times B_{-j}$ ， $x \mapsto Q_j(x, B)$ 可测；由单调类定理推广到所有乘积 σ 代数中的 B ，故下式确实定义马尔可夫核：写 $x = (x_j, x_{-j})$ ，单次只改第 j 个分量。坐标提议核可写为

$$Q_j(x, dy) = q_j(x_j, y_j | x_{-j}) \mu_j(dy_j) \delta_{x_{-j}}(dy_{-j}).$$

若 $y = (y_j, x_{-j})$ ，正向和反向未归一化流分别是

$$g_j(x, y) = \tilde{\pi}(x_j, x_{-j}) q_j(x_j, y_j | x_{-j}),$$

$$g_j(y, x) = \tilde{\pi}(y_j, x_{-j}) q_j(y_j, x_j | x_{-j}).$$

取公共流 $\min\{g_j(x, y), g_j(y, x)\}$ 并除以正向流，得到

$$\alpha_j(x, y) = \min \left\{ 1, \frac{\tilde{\pi}(y_j, x_{-j}) q_j(y_j, x_j | x_{-j})}{\tilde{\pi}(x_j, x_{-j}) q_j(x_j, y_j | x_{-j})} \right\},$$

这正是式 (32.10)。分母为零时不计算比值，而按零流分支处理。该坐标核的接受流对称，拒绝质量形成自环，故关于 π 可逆并保持 π 。

一轮系统扫描从当前状态开始，按 $j = 1, \dots, d$ 依次提议、判定并立即更新；后一个坐标看到的是前一个坐标更新后的状态。若轮核记为 $K_{\text{sys}} = K_1 \cdots K_d$ ，则

$$\pi K_{\text{sys}} = ((\pi K_1) K_2 \cdots) K_d = \pi.$$

但伴随核的顺序是 $K_d \cdots K_1$ ；这些核不交换时，正反顺序不同，系统扫描一般不再可逆。随机扫描 $\sum_j w_j K_j$ 是可逆核的凸组合，因而自动继承可逆性。

练习 32.2. 伯努利试验中, 先验为 $\theta \sim \text{Beta}(1, 1)$, 观测 $n = 10$ 次试验中有 $k = 4$ 次结果为 1。用 Metropolis-Hastings 算法估计后验分布的均值和方差。先推导后验, 再给出固定预算、合法初值、提议、随机数、接受规则、输出与停止情形; 不虚构随机样本。以精确后验均值和方差作为任何实际运行必须比较的基准。

练习 32.2 解析

先验密度在 $(0, 1)$ 上为 $\theta^{1-1}(1-\theta)^{1-1}/B(1, 1)$ 。观测 10 次、其中成功 4 次时, 完整二项似然为

$$L(\theta) = \binom{10}{4} \theta^4 (1-\theta)^6.$$

Bayes 公式的分子为 $B(1, 1)^{-1} \binom{10}{4} \theta^4 (1-\theta)^6$; 其中 $\binom{10}{4}/B(1, 1)$ 与 θ 无关, 归一化时从分子、分母同时约去。因此后验为

$$\theta | y \sim \text{Beta}(1 + 4, 1 + 10 - 4) = \text{Beta}(5, 7).$$

精确基准为

$$E(\theta | y) = \frac{5}{12}, \quad \text{Var}(\theta | y) = \frac{5 \cdot 7}{(5 + 7)^2(5 + 7 + 1)} = \frac{35}{1872} \approx 0.0186966. \quad (32.15)$$

给出一个可复算而不伪造输出的过程。输入 $m, n \in \mathbb{N}_0$ 、初值 $\theta_0 \in (0, 1)$ 、独立提议 $Y_t \sim U(0, 1)$ 和独立判定数 $U_t \sim U(0, 1)$ 。使用

$$\tilde{\pi}(\theta) = \theta^4(1-\theta)^6 \mathbf{1}_{(0,1)}(\theta), \quad q(x, y) = \mathbf{1}_{(0,1)}(y).$$

提议对称, 所以

$$\alpha(x, y) = \min \left\{ 1, \frac{y^4(1-y)^6}{x^4(1-x)^6} \right\}.$$

固定执行 $T = m + n$ 步; 若 $U_t \leq \alpha(X_{t-1}, Y_t)$ 则接受, 否则复制 X_{t-1} ; 保留 $X_{m+1}, \dots, X_{m+n}$ 。当 $n \geq 1$ 时返回

$$\hat{\mu} = \frac{1}{n} \sum_{t=m+1}^{m+n} X_t, \quad \hat{\nu} = \frac{1}{n} \sum_{t=m+1}^{m+n} (X_t - \hat{\mu})^2.$$

$\hat{\nu}$ 是后验方差的遍历均值估计, 并不因分母为 n 或 $n-1$ 而自动成为相关样本下的有限样本无偏估计。实际运行还必须返回随机源记录或可复现标识、完整轨迹、接受标志、MCSE 和 ESS, 并把 $\hat{\mu}, \hat{\nu}$ 与式 (32.15) 比较。 $m = n = 0$ 时不调用随机源且两项估计均未定义; 非法端点、非有限密度或不完整预算必须显式失败。题目没有提供一次实际随机流, 因此本解析不编造一组估计值。

练习 32.3. 给定两状态核

$$K = \begin{pmatrix} 1-a & a \\ b & 1-b \end{pmatrix}, \quad 0 < a, b \leq 1.$$

求平稳分布, 核验细致平衡, 并分别给出不可约、非周期、唯一平稳分布和边缘收敛所需的条件。特别讨论 $a = b = 1$ 。

练习 32.3 解析

设 $\pi = (\pi_1, \pi_2)$ 。细致平衡只需检查非对角边:

$$\pi_1 a = \pi_2 b, \quad \pi_1 + \pi_2 = 1.$$

解得

$$\pi = \left(\frac{b}{a+b}, \frac{a}{a+b} \right).$$

代回可得 $\pi_1 K_{12} = \pi_2 K_{21} = ab/(a+b)$, 故 π 平稳。因为 $a, b > 0$, 两个状态双向可达, 链不可约, 所以该平稳分布唯一。若 $a < 1$ 或 $b < 1$, 至少一个状态有正自环; 不可约性使两状态具有共同周期, 于是周期为 1, 边缘分布从任意初值收敛到 π 。

当 $a = b = 1$ 时, K 每步确定翻转, 仍不可约且唯一平稳分布为 $(1/2, 1/2)$, 但周期为 2。从确定状态启动的边缘分布在两个点质量之间振荡, 不逐步收敛; 访问频率仍各趋于 $1/2$, 所以时间平均结论不需要非周期性。

练习 32.4. 目标分布在 $\{1, 2, 3\}$ 上严格为正, 提议核为确定性有向环

$$q(1, 2) = q(2, 3) = q(3, 1) = 1.$$

逐边计算 MH 接受概率, 写出最终 MH 核。解释为什么提议链本身不可约并不能保证 MH 核不可约, 以及反向提议支持为何是算法成立的必要条件。

练习 32.4 解析

对提议边 $1 \rightarrow 2$, 反向密度 $q(2, 1) = 0$, 而 π_1, π_2 都为正, 所以

$$g(1, 2) > 0, \quad g(2, 1) = 0, \quad \alpha(1, 2) = 0.$$

对提议边 $2 \rightarrow 3$, 有 $q(3, 2) = 0$, 故 $g(3, 2) = 0$ 并且 $\alpha(2, 3) = 0$; 对提议边 $3 \rightarrow 1$, 有 $q(1, 3) = 0$, 故 $g(1, 3) = 0$ 并且 $\alpha(3, 1) = 0$ 。因此三条非对角移动都被拒绝, 最终核为

$$K = I_3.$$

原提议核沿有向环能在有限步到达任意状态, 因而作为提议链不可约; MH 校正却要求每条被接受边具有正反双向流。所有反向边缺失后, 接受流为零, MH 核退化为三个孤立自环。正确的设计检查应针对 $q(x, y) > 0$ 与 $q(y, x) > 0$ 共同形成的无向支持图及接受后的 K , 不能只检查提议链的有向可达性。

练习 32.5. 固定一对状态, 令 $a = g(x, y) > 0$, $b = g(y, x) > 0$ 。除 MH 接受率外, 考虑 Barker 规则

$$\alpha_B(x, y) = \frac{b}{a+b}.$$

证明它满足双向流平衡, 求共同接受流, 并与 MH 的 $\min\{a, b\}$ 比较。说明“MH 逐对最大化接受流”为什么不等于“MH 对任意提议都给出最小 MCSE”。

练习 32.5 解析

Barker 正向流为

$$a\alpha_B(x, y) = a \frac{b}{a+b} = \frac{ab}{a+b}.$$

反向接受率是 $a/(a+b)$, 所以反向流

$$b\alpha_B(y, x) = b \frac{a}{a+b} = \frac{ab}{a+b},$$

双向平衡成立。若 $a \leq b$, 则

$$\frac{ab}{a+b} \leq \frac{ab}{b} = a = \min\{a, b\};$$

$b \leq a$ 时对称地得到共同流不超过 b 。对 $a, b > 0$ 不等式严格, 因为 $a+b$ 严格大于较大的分母项。MH 共同流恰为 $\min\{a, b\}$, 因此在固定 q 与逐对细致平衡约束下更大。

MCSE 取决于整个核的谱、移动距离、目标函数 f 和单步计算成本。更换 q 会改变所有这些量; 逐对接受流最大只比较固定提议下的一次接受, 不提供“任意提议的全局最小 MCSE”结论。

练习 32.6. 设平稳标量轨迹长度 $n = 100$, 真实自相关满足 $\rho_1 = 0.4$ 、 $\rho_2 = 0.2$ 、其余 $\rho_k = 0$ 。使用式 (32.11) 的有限样本权重计算方差膨胀因子和 $N_{\text{eff},100}$, 再计算无限和对应的 τ_{int} 与渐近 ESS。解释两个结果不完全相同的原因。

练习 32.6 解析

有限样本方差膨胀因子为

$$\tau_{100} = 1 + 2 \left[\left(1 - \frac{1}{100}\right) 0.4 + \left(1 - \frac{2}{100}\right) 0.2 \right] = 1 + 2(0.396 + 0.196) = 2.184.$$

因此

$$N_{\text{eff},100} = \frac{100}{2.184} \approx 45.7875.$$

无限和对应

$$\tau_{\text{int}} = 1 + 2(0.4 + 0.2) = 2.2, \quad N_{\text{eff},\text{as}} \approx \frac{100}{2.2} = 45.4545.$$

有限样本均值中, 相距 k 的有序协方差对只有 $2(n-k)$ 个, 所以出现 $1-k/n$ 权重; 渐近式让固定 k 下的该权重趋于 1。这里使用题目给出的真实自相关; 实际以经验自相关截断代入还会增加估计误差。

练习 32.7. 评价下列说法, 并对错误说法给出反例或缺失条件: (a) 丢弃足够长的燃烧期可修复可约链; (b) 每 10 步抽稀一次后样本就是独立的; (c) 接受率约为 0.25 即可证明收敛; (d) 单条轨迹图稳定即可证明访问了全部模式; (e) MCSE 很小即可证明目标密度和程序都正确。

练习 32.7 解析

五个说法都不成立。

练习 32.7 解析 (续)

- (a) 对 $K = I_2$, $K^m = I_2$ 且 $P_x(X_m = x) = 1$; 任意长燃烧期后仍停在初始状态, 可约性不会改变。
- (b) 抽稀链的核是 K^{10} ; 除非 $K^{10}(x, \cdot) = \pi(\cdot)$ 对所有 x 成立, 否则相邻保留值仍依赖前态。
- (c) 令 A_t 为第 t 步的接受标志; 经验接受率 $\hat{a} = T^{-1} \sum_{t=1}^T A_t = 0.25$ 只统计局部判定, 不能推出 $K^m(x, A) > 0$ 的全局可达性。
- (d) 若链被困在模态 A , 则 $P(X_t \in A | X_0 \in A) = 1$ 仍可产生平稳外观; 多初值链只能提供警报, 不能形式证明覆盖全部支持。
- (e) $\widehat{\text{MCSE}} = \sqrt{\hat{\sigma}^2/n}$ 估计给定轨迹均值波动, 不控制目标写错或因模态造成的偏差 $E(\bar{f}) - E_{\pi}f$ 。

这些反例分别把状态更新、抽稀核、移动率、条件事件和估计误差拆开, 任何单一诊断量都不能替代核的数学条件。

$$\begin{aligned} K^m = I_2 &\implies P_x(X_m = x) = 1 \implies \text{燃烧期不修复可约性,} \\ K_{\text{thin}} = K^{10} &\not\equiv \mathbf{1}\pi \implies \text{抽稀后仍可能依赖前态,} \\ \widehat{\text{MCSE}}_{\text{小}} &\not\Rightarrow E(\bar{f}) = E_{\pi}f \implies \text{诊断量不证明目标正确.} \end{aligned}$$

尤其 $\hat{a} = 0.25$ 至多是一次有限轨迹摘要:

$$\hat{a} = 0.25 \not\Rightarrow \forall x, A (\pi(A) > 0 \Rightarrow \exists m : K^m(x, A) > 0).$$

练习 32.8. 比较三个两状态核

$$K_1 = I_2, \quad K_2 = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}, \quad K_3 = \frac{1}{2}(I_2 + K_2).$$

对每个核判断关于均匀分布的细致平衡、不可约性、周期性、平稳分布唯一性、时间平均和边缘分布收敛。

练习 32.8 解析

令 $u = (1/2, 1/2)$ 。三个矩阵都对称且行随机, 因而

$$u_i(K_r)_{ij} = u_j(K_r)_{ji}, \quad uK_r = u, \quad r = 1, 2, 3.$$

但它们的状态更新与极限不同:

$$\begin{aligned} K_1 : \quad X_t &= X_0, \quad \rho_t = \rho_0, & \text{可约, 平稳分布不唯一;} \\ K_2 : \quad X_t &= 3 - X_{t-1}, \quad \rho_{2m} = \rho_0, \rho_{2m+1} = \rho_0 K_2, & \text{不可约, 周期 2;} \\ K_3 : \quad K_3 &= \begin{pmatrix} 1/2 & 1/2 \\ 1/2 & 1/2 \end{pmatrix}, \quad \rho_t = u (t \geq 1), & \text{不可约, 周期 1.} \end{aligned}$$

K_1 的时间平均通常只等于 $f(X_0)$; K_2 的访问频率趋于 $(1/2, 1/2)$, 但边缘分布除平稳初值外振荡; K_3 的时间平均与边缘分布都从任意初值收敛到均匀目标。由此可见唯一性、时间平均和边缘收敛需要分开判断。

练习 32.9. 在三点空间的均匀目标下, 令

$$K_1 = \begin{pmatrix} 1/2 & 1/2 & 0 \\ 1/2 & 1/2 & 0 \\ 0 & 0 & 1 \end{pmatrix}, \quad K_2 = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1/2 & 1/2 \\ 0 & 1/2 & 1/2 \end{pmatrix}.$$

证明 K_1, K_2 各自可逆且保持均匀目标, 计算系统扫描复合核 $K_1 K_2$ 并判断其是否可逆; 再证明随机扫描混合 $(K_1 + K_2)/2$ 可逆。

练习 32.9 解析

K_1, K_2 都对称且双随机, 所以关于均匀目标可逆并保持该目标。矩阵相乘得到

$$K_1 K_2 = \begin{pmatrix} 1/2 & 1/4 & 1/4 \\ 1/2 & 1/4 & 1/4 \\ 0 & 1/2 & 1/2 \end{pmatrix}.$$

每列和为 1, 故均匀目标仍平稳; 但 $(K_1 K_2)_{13} = 1/4$ 而 $(K_1 K_2)_{31} = 0$ 。在均匀目标下, 细致平衡等价于矩阵对称, 因此该系统扫描复合核不可逆。

$$u K_1 K_2 = (u K_1) K_2 = u, \quad u_1 (K_1 K_2)_{13} = \frac{1}{12} \neq 0 = u_3 (K_1 K_2)_{31}.$$

随机扫描核 $\bar{K} = (K_1 + K_2)/2$ 仍是对称行随机矩阵, 所以关于均匀目标可逆。更一般地, 可逆核的固定非负权重混合把每条双向平衡等式线性相加, 仍满足细致平衡。

练习 32.10. 对轨迹

$$(1, 1, 3, 3, 5, 5, 7, 7)$$

取 $a = 4$ 个连续批、每批 $b = 2$ 。计算样本均值、无偏样本方差、批均值、 $\hat{\sigma}_{\text{BM}}^2$ 、批均值 MCSE 和批均值 ESS。说明这些数为什么仍不是收敛证明。

练习 32.10 解析

总均值为

$$\bar{y} = \frac{1+1+3+3+5+5+7+7}{8} = 4.$$

相对均值的平方离差和为

$$2(3^2) + 2(1^2) + 2(1^2) + 2(3^2) = 40,$$

故无偏样本方差 $s_Y^2 = 40/7$ 。四个批均值为 $(1, 3, 5, 7)$, 其相对 4 的平方离差和为 20, 所以

$$\hat{\sigma}_{\text{BM}}^2 = \frac{b}{a-1} 20 = \frac{2}{3} 20 = \frac{40}{3}.$$

于是

$$\widehat{\text{MCSE}}_{\text{BM}} = \sqrt{\frac{(40/3)}{8}} = \sqrt{\frac{5}{3}} \approx 1.2910,$$

$$\hat{N}_{\text{eff,BM}} = \frac{8(40/7)}{40/3} = \frac{24}{7} \approx 3.4286.$$

练习 32.10 解析 (续)

这些量只复算了一个长度为 8 的固定序列；批数与批长都很小，无法验证批均值一致性所需的混合、矩和渐近增长条件，也无法证明这条序列来自正确目标。

练习 32.11. 判断

$$\tilde{\pi}(x_1, x_2) = \exp\left[-\frac{1}{2}(x_1 - 1)^2(x_2 - 1)^2\right], \quad (x_1, x_2) \in \mathbb{R}^2$$

能否归一化为联合密度。先固定 $x_2 \neq 1$ 对 x_1 积分，再考察 $x_2 = 1$ 邻域。若不能归一化，说明为何“MH 只需要未归一化密度”不能挽救该目标。

练习 32.11 解析

固定 $x_2 \neq 1$ ，令 $z = (x_1 - 1)|x_2 - 1|$ ，则 $dx_1 = dz/|x_2 - 1|$ ，所以

$$\int_{-\infty}^{\infty} \exp\left[-\frac{1}{2}(x_1 - 1)^2(x_2 - 1)^2\right] dx_1 = \frac{\sqrt{2\pi}}{|x_2 - 1|}.$$

再对 x_2 积分时，任取 $\varepsilon > 0$ ，

$$\int_{1-\varepsilon}^{1+\varepsilon} \frac{\sqrt{2\pi}}{|x_2 - 1|} dx_2 = \infty.$$

在 $x_2 = 1$ 这条线上，被积函数甚至恒为 1 而不随 x_1 衰减。由 Tonelli 定理，非负函数的二重积分为无穷，因此不存在有限正归一化常数，不能定义目标概率分布。

MH 比值能消去的是一个已经存在的有限正常数 Z ；这里 $Z = \infty$ ，不存在 $\pi = \tilde{\pi}/Z$ 。即便某个数值过程能运行，它也不具有本章定理所要求的可归一化平稳目标，不能被解释为从该“联合密度”抽样。

练习 32.12. 分别给出算法 32.1 在下列输入下的规定输出或状态： $m = n = 0$ ；初值处 $\tilde{\pi}(x_0) = 0$ ；抽样器返回 y 但求值得 $q(x, y) = 0$ ；提议点 $\tilde{\pi}(y) = 0$ ；反向提议 $q(y, x) = 0$ ；均匀源返回 $u = 1$ ；以及 $n = 1$ 时请求样本方差和 ESS。

练习 32.12 解析

设合法支持 $S = \{x : 0 < \tilde{\pi}(x) < \infty\}$ ，总预算 $T = m + n$ 。算法状态与停止分支可写为

$$\begin{aligned} T = 0 : & \quad X_{0:T} = (x_0), \quad X_{m+1:m+n} = \emptyset; \\ x_0 \notin S : & \quad \text{初始化失败, 完成转移数 } 0; \\ q(x, y) = 0 \text{ 却抽到 } y : & \quad \text{抽样器/密度不一致, 立即停止;} \\ \tilde{\pi}(y)q(y, x) = 0 : & \quad \alpha(x, y) = 0, \quad X_t = X_{t-1}; \\ u \notin (0, 1) : & \quad \text{随机源非法, 当前转移不提交.} \end{aligned}$$

其中 $\tilde{\pi}(y) = 0$ 或 $q(y, x) = 0$ 是合法零反向流，必须把拒绝后的重复状态追加到轨迹；它们不同于 $q(x, y) = 0$ 却被抽到的一致性错误。若 $n = 1$ ，仅有

$$\hat{\mu} = X_{m+1}, \quad s^2 = \frac{\sum_{t=m+1}^{m+n} (X_t - \hat{\mu})^2}{n-1} \quad \text{未定义,}$$

练习 32.12 解析 (续)

故样本方差、自相关与 ESS 均标记未定义，不得除零。

练习 32.13. 从输出对象、全局包络、拒绝后的行为、样本独立性、归一化常数与不能继续的情形六个方面比较接受 – 拒绝抽样和 MH。说明为什么不能把接受 – 拒绝法中的接受概率 $p(y)/(cq(y))$ 直接替换成 MH 接受概率而仍沿用原输出规则。

练习 32.13 解析

比较项	接受 – 拒绝抽样	Metropolis–Hastings
输出对象	只输出接受候选	每轮输出下一链状态，拒绝时重复当前状态
全局条件	需要 $p(y) \leq cq(y)$ 的有限包络	不需要全局包络，但需要合法双向提议流
拒绝后行为	丢弃候选并从 q 重新独立提议	保留当前状态，形成自环
独立性	独立提议下，接受值为 iid 目标样本	一般为相关马尔可夫链
归一化常数	接受概率通常使用归一化目标与已知包络	目标公共有限正常数在双向比值中消去
不能继续的情形	包络越界、达到预设提议上限与提议异常	目标不可归一化、支持断裂、双向提议密度不合法或未完成预设转移数

接受 – 拒绝的条件输出分布依赖全局包络归一化：

$$P(Y \in dy \mid A) = \frac{q(y) p(y)/(cq(y))}{P(A)} dy = \frac{p(y)/c}{1/c} dy = p(y) dy.$$

MH 则定义完整状态核

$$K(x, dy) = q(x, y)\alpha(x, y) dy + \left[1 - \int q(x, z)\alpha(x, z) dz\right] \delta_x(dy).$$

若把接受 – 拒绝概率换成 MH 接受率却仍丢弃拒绝并只收集接受候选，条件密度变为

$$\tilde{p}_x(y) = \frac{q(x, y)\alpha(x, y)}{\int q(x, z)\alpha(x, z) dz},$$

它一般依赖当前 x 且不等于 $p(y)$ ；同时 MH 核中的拒绝自环消失。反过来，把 iid 接受值按 MH 轨迹解释也会凭空引入错误依赖。算法必须连同输出规则整体使用。

练习 32.14. 计划运行四条不同初值的链。写出一份不依赖具体程序语言的诊断报告清单，至少包括完整未抽稀轨迹、运行均值、接受标志、经验自相关、批均值 MCSE、ESS、链间比较和异常状态。逐项说明它能发现什么，以及不能证明什么。

练习 32.14 解析

一份合格报告至少包含：

1. **完整未抽稀轨迹：**可发现长时间停滞、边界粘连和不同模态；不能证明未画出的区域没有问题。
2. **运行均值：**可显示估计是否仍有系统漂移；平台期不能证明平台等于目标期望。

练习 32.14 解析 (续)

3. **提议与接受标志**: 可定位零反向流、连续拒绝和数值异常; 某个经验接受率不能证明可达性。
4. **经验自相关**: 可量化已访问轨迹的滞后依赖并构造截断 ESS; 滞后上限和估计噪声会影响结果。
5. **批均值 MCSE 与 ESS**: 可把均值波动换算为误差尺度; 短批、少批或慢混合会使估计不可靠。
6. **四链比较**: 不同初值链分离可暴露多模态和初值敏感; 四链重合仍不能形式证明已经覆盖全部目标支持。
7. **异常与停止原因**: 记录不是有限实数的求值、零目标、零反向提议、达到预设转移上限和已经完成的转移; 没有异常不等于数学条件已经证明。

报告中的量必须能由保存的状态递推复算:

$$\begin{aligned}
 X_t &= \begin{cases} Y_t, & U_t \leq \alpha_t, \\ X_{t-1}, & U_t > \alpha_t, \end{cases} \\
 \bar{f}_t &= \frac{1}{t} \sum_{s=1}^t f(X_s), \\
 \hat{a}_t &= \frac{1}{t} \sum_{s=1}^t A_s, \quad A_s = \mathbf{1}\{U_s \leq \alpha_s\}, \\
 \widehat{\text{MCSE}}_{\text{BM}} &= \sqrt{\hat{\sigma}_{\text{BM}}^2/n}, \quad \hat{N}_{\text{eff}} = ns_f^2/\hat{\sigma}_{\text{BM}}^2.
 \end{aligned}$$

四链比较还应保留逐链估计而非只保留合并均值:

$$\hat{\mu}_c = \frac{1}{n} \sum_{t=1}^n f(X_t^{(c)}), \quad c = 1, 2, 3, 4; \quad \max_c \hat{\mu}_c - \min_c \hat{\mu}_c \text{ 大} \implies \text{链间分离警报}.$$

最后两式仅在相应分母有限且为正时报告。还应列出目标分布的具体定义、提议参数、 m, n 、批划分、随机种子及生成规则, 使诊断可复算; 停止时报告已完成的整次转移数和原因。结论措辞应是“未发现某类问题”或“出现某类警报”, 不能写成“诊断证明收敛”。

本章结论与下一步

核心结论: MCMC 用保持 π 的可测马尔可夫核产生相关轨迹; 平稳性、唯一性、时间平均和边缘收敛必须分开。

关键依据: MH 以双向公共流处理零密度并建立可逆性; 有限不可约链给时间平均, 正常 Harris 返是一般状态对应条件, 非周期性另管边缘收敛。

可执行自检: 每步提议、计算含零流分支的接受率、接受或复制当前状态; 拒绝自环必须保留。

适用边界: 适用于目标可归一化且提议可计算的后验期望; CLT、MCSE 与批均值还需额外矩和混合条件。

下一步: 第 33 章 (第 5 册第 4 章) 把提议取成精确满条件分布, 得到接受率为 1 的 Gibbs 坐标更新。

1. 能否从集合细致平衡推出 $\pi K = \pi$, 用 I_2 反例否定“可逆必不可约”, 并区分系统扫描的目标保持性与可逆性? 若不能, 回看节 32.2 与命题 32.3。

2. 能否从双向提议流推出式 (32.7), 处理零流而不算非法比值, 并写出含拒绝自环的式 (32.9)? 若不能, 回看节 32.3。
3. 能否分别说明不可约、非周期和正常返对唯一性、时间平均及边缘收敛的作用, 并由协方差双重和计算 ACF-ESS 与批均值 MCSE? 若不能, 回看节 32.5。
4. 能否独立执行算法 32.1 至算法 32.3, 报告空预算、零流、非法随机数和部分前缀, 并把轨迹、ACF、ESS 和多链比较明确写成“诊断而非证明”?
5. 能否推导 $\text{Beta}(5, 7)$ 后验及精确矩, 拒绝在没有随机流时编造 MH 估计, 并证明不可归一化核不能用“常数消去”? 若不能, 重做练习练习 32.2、32.11。

第 33 章 Gibbs 抽样

读前自检：本章地图：Gibbs 抽样。 Gibbs 抽样章地图把“联合目标 → 满条件概率核 → 坐标更新 → 扫描链与诊断”作为主线；请为其中首条箭头补出必要条件，并检查终点仍落在本章声明的输出域。

读前自检：本章可检验学习目标。 Gibbs 抽样的首个可检验目标是“从联合分布严格定义满条件分布，说明归一化分母、支持集和“正比于”记号的合法边界”；请从联合分布严格定义满条件分布，说明归一化分母、支持集和“正比于”记号的合法边界并写出中间结果，再按“中间结果逐项包含首目标“从联合分布严格定义满条件分布，说明归一化分母、支持集和“正比于”记号的合法边界”声明的对象、条件与结论”验收。

读前自检：最短先修。 Gibbs 抽样的最短先修明确要求“本章直接使用所引章节的目标分布、马尔可夫核、细致平衡、Metropolis–Hastings 零流分支和样本诊断”；请把首项“本章直接使用所引章节的目标分布、马尔可夫核、细致平衡、Metropolis–Hastings 零流分支和样本诊断”中的第一个先修对象写成定义域 – 运算 – 输出三元组，并以“该三元组逐项满足首项“本章直接使用所引章节的目标分布、马尔可夫核、细致平衡、Metropolis–Hastings 零流分支和样本诊断”的对象类型与成立条件”判断能否进入本章。

读前自检：先修自检。 Gibbs 抽样先修自检固定核验“给定联合密度 $\pi(x_1, x_2)$ ，能否计算边缘 $\pi_2(x_2)$ 并写出 $\pi(x_1 | x_2)$ ”；请给定联合密度 $\pi(x_1, x_2)$ ，实际计算边缘 $\pi_2(x_2)$ 并写出 $\pi(x_1 | x_2)$ 并写出中间结果，再按“ $\pi(x_1 | x_2)$ 的计算或证明结果满足首项所列等式、定义域或判断”明确判为通过或失败。

读前自检：依赖路线。 Gibbs 抽样依赖路线从“所引章节的 MH 可逆性、零流分支与一般状态收敛条件 → 本章的坐标 Gibbs 核”进入“联合目标 $\pi(x_1, \dots, x_d) \rightarrow$ 每个坐标的满条件分布 $\pi_j(\cdot | x_{-j}) \rightarrow$ 单坐标 Gibbs 核 $K_j \rightarrow$ 系统扫描乘积核或随机扫描混合核 $\rightarrow$ 平稳性与可达性检查 $\rightarrow$ 燃烧期后的相关样本与 Monte Carlo 诊断”；请写出箭头成立所需的定义域条件，并核对前者输出能作为后者输入。

本章地图

核心问题：怎样从联合分布构造可测的满条件版本，并证明逐坐标更新保持目标？

可检验学习目标：

- 从联合分布严格定义满条件分布，说明归一化分母、支持集和“正比于”记号的合法边界；
- 把单坐标 Gibbs 更新写成马尔可夫核，证明它关于目标分布可逆并保持目标分布；
- 区分系统扫描与随机扫描，证明二者的平稳性，并说明系统扫描一般不再可逆；
- 从 Metropolis–Hastings 接受比推导“精确满条件提议必接受”，同时处理零边缘质量与不精确条件抽样器；
- 手工执行二元正态 Gibbs 更新，推导相关系数对混合速度和有效样本量的影响；

- 按完整数学步骤实现逐变量抽样，检查中途停止、不可约性、数值异常与复杂度，不虚构随机运行结果。

最短先修：本章直接使用第 32 章的目标分布、马尔可夫核、细致平衡、Metropolis–Hastings 零流分支和样本诊断；还使用第 1 册概率基础中的联合、边缘、条件分布与条件独立。读者应能把联合密度积分成边缘密度，并能判断一个条件密度是否归一化。涉及连续变量时统一相对于乘积支配测度 $\mu = \mu_1 \otimes \cdots \otimes \mu_d$ 书写；有限状态情形把积分替换为求和。

依赖路线：第 32 章的 MH 可逆性、零流分支与一般状态收敛条件 → 本章的坐标 Gibbs 核；联合目标 $\pi(x_1, \dots, x_d)$ → 每个坐标的满条件分布 $\pi_j(\cdot | x_{-j})$ → 单坐标 Gibbs 核 K_j → 系统扫描乘积核或随机扫描混合核 → 平稳性与可达性检查 → 燃烧期后的相关样本与 Monte Carlo 诊断；概率图的局部分解 → Markov 毯 → 只保留与当前变量相连的因子 → 可计算的局部满条件分布。

完成标准与返回：先复习第 32 章的 MH 零流与一般状态收敛层次，再进入满条件核。

图 33.1 概括从联合目标与局部因子到 Monte Carlo 诊断的六节点学习与计算主链。




图 33.1 满条件把联合目标转为单坐标更新，扫描后得到需以 MCSE、ESS 与轨迹诊断的相关样本

读图顺序。先看给定其余坐标 x_{-j} 后，满条件 $\pi_j(\cdot | x_{-j})$ 如何只重抽 x_j ；再看单坐标核 K_j 怎样组成系统或随机扫描核并产生相关样本；最终用 MCSE、ESS 与轨迹诊断评估统计误差和混合效率。主链箭头只表示学习与计算依赖，不是概率图的生成时间方向；目标保持仍不自动推出不可约、收敛或快速混合。

本章符号表		
符号	类型、维数或范围	含义
$\mathcal{X} = \prod_{j=1}^d \mathcal{X}_j$	乘积状态空间	d 个坐标或变量块的联合取值空间
$x = (x_1, \dots, x_d)$	$\mathcal{X}$ 中元素	一个完整链状态
x_{-j}	$\prod_{\ell \neq j} \mathcal{X}_\ell$ 中元素	删除第 j 个坐标后的其余状态
$\pi(x)$	概率密度或质量函数	Gibbs 链的目标联合分布
$\pi_{-j}(x_{-j})$	非负边缘密度	对 x_j 积分或求和得到的边缘
$\pi_j(t \mid x_{-j})$	条件密度	给定其余坐标时第 j 个坐标的满条件分布
K_j	马尔可夫核	只重抽第 j 个坐标的 Gibbs 更新
K_{sys}	马尔可夫核	一轮系统扫描 $K_1 K_2 \cdots K_d$
K_{rs}	马尔可夫核	固定权重随机扫描 $\sum_j w_j K_j$
w_j	正数且 $\sum_j w_j = 1$	随机扫描选择坐标 j 的概率
m, n, T	非负整数	燃烧轮数、保留轮数及 $T = m + n$
ρ	$(-1, 1)$	标准二元正态的相关系数
ε_{jt}	标准正态随机量	二元正态 Gibbs 第 t 轮第 j 步的创新

读前自检：Gibbs 抽样的满条件分解。 Gibbs 满条件由联合密度固定其余坐标后归一化得到；请对二元 $\pi(x_1, x_2)$ 写出 $\pi_1(x_1 \mid x_2)$ ，核对系统扫描第二步必须使用刚更新的 x_1 而非旧值。

33.1 完整条件分布

设目标联合密度 $\pi(x_1, \dots, x_d)$ 可以计算，但从整个 d 维目标直接抽样困难。若固定 x_{-j} 后的一维或低维条件分布容易抽样，就可以依次重抽各坐标，把高维问题拆成一系列局部问题。图 33.2 具体采用零均值、单位方差、相关系数 $\rho = 3/5$ 的二元正态，并固定 $a = 1$ 、 $b = 4/5$ ；阅读任务是先看联合密度上的水平与竖直切片，再核对边缘分母 $m_2(b) = \phi(4/5)$ 与 $m_1(a) = \phi(1)$ (ϕ 为标准正态密度)，最后得到归一化的满条件密度。切片不是任意截面，必须在该条件值的边缘密度为正时归一化。

读图顺序。 先看左图固定 $x_2 = b = 4/5$ 的水平切片与固定 $x_1 = a = 1$ 的竖直切片；再看两条无交叉箭头如何分别用 $m_2(b) = \phi(4/5)$ 与 $m_1(a) = \phi(1)$ 归一化原始联合截面；得到 $\mathcal{N}(12/25, 16/25)$ 与 $\mathcal{N}(3/5, 16/25)$ 两条全实线积分为 1 的满条件密度。本高斯例两个分母均为正；一般情形分母为 0 时须采用预先指定的可测正则条件版本，且该版本仅在边缘几乎处处意义下唯一。




图 33.2 同一二元正态联合密度的两条截面除以相应边缘密度后, 得到方差 16/25、全实线积分为 1 的满条件密度; 零边缘处须使用预先指定的正则条件版本。

读题翻译 “联合分布难以一次抽样” 翻译成两个可执行问题: 固定 x_2 后能否抽 $x_1 | x_2$, 固定新 x_1 后能否抽 $x_2 | x_1$ 。Gibbs 每次只解决其中一个问题。

为什么想到这个方法 看到联合目标的各个满条件分布容易抽样, 就按“固定其余坐标、抽一个坐标、立即写回”的顺序构造一轮扫描。

例题 33.1 (先会执行: 二元正态的一轮 Gibbs). 设 (X_1, X_2) 为零均值、单位方差、相关系数 $\rho \in (-1, 1)$ 的二元正态, 且

$$X_1 | X_2 = x_2 \sim \mathcal{N}(\rho x_2, 1 - \rho^2), \quad X_2 | X_1 = x_1 \sim \mathcal{N}(\rho x_1, 1 - \rho^2).$$

从 $x^{(0)} = (0, 0)$ 出发, 取固定标准正态创新 $\varepsilon_1 = 1, \varepsilon_2 = 0$ 。执行一轮系统扫描 Gibbs 更新, 求 $x^{(1)}$, 并说明第二步应使用旧值还是同轮新值。

例题 33.1 解答

读题翻译 固定创新量把一轮随机 Gibbs 扫描变成确定性顺序更新; 关键是先用旧 $x_2^{(0)}$ 生成新 $x_1^{(1)}$, 再立即用同轮新 $x_1^{(1)}$ 生成 $x_2^{(1)}$ 。

已知与合法条件 $\rho \in (-1, 1)$, 故 $\sigma = \sqrt{1 - \rho^2} > 0$; 初值 $x^{(0)} = (0, 0)$, 创新量 $(\varepsilon_1, \varepsilon_2) = (1, 0)$ 均已固定。

为什么想到这个方法 对条件正态写成“条件均值加条件标准差乘创新量”，并按系统扫描次序在每次坐标更新后立即写回。

方法选择 先算 $x_1^{(1)} = \rho x_2^{(0)} + \sigma \varepsilon_1$ ，再算 $x_2^{(1)} = \rho x_1^{(1)} + \sigma \varepsilon_2$ ；第二式不得读取旧 $x_1^{(0)}$ 。

推导/计算 第一步使用旧的 $x_2^{(0)} = 0$ ：

$$x_1^{(1)} = \sqrt{1 - \rho^2},$$

第二步立即使用该新值以及 $\varepsilon_2 = 0$ ：

$$x_2^{(1)} = \rho x_1^{(1)} + \sqrt{1 - \rho^2} \varepsilon_2 = \rho \sqrt{1 - \rho^2}.$$

独立核验 两个标准化残差分别满足 $(x_1^{(1)} - \rho x_2^{(0)})/\sigma = 1$ 与 $(x_2^{(1)} - \rho x_1^{(1)})/\sigma = 0$ ；当 $\rho = 0$ 时结果退化为 $(1, 0)$ ，也与独立坐标的条件更新一致。

结论 一轮后的状态为

$$x^{(1)} = (\sqrt{1 - \rho^2}, \rho \sqrt{1 - \rho^2}).$$

第二步必须使用同轮新值 $x_1^{(1)}$ ；若仍用 $x_1^{(0)}$ ，得到的是并行更新而非本题规定的系统扫描。

读前自检：满条件分布。 满条件 $\pi_j(t | x_{-j})$ 只在边缘归一化常数正且有限时由比值定义；请对 t 积分核对为 1，并在零分母分支采用预先指定的条件核版本。

定义 33.1 (满条件分布). 以下给出进阶严格版本。设 $\mathcal{X} = \prod_{\ell=1}^d \mathcal{X}_\ell$ ，每个 $(\mathcal{X}_\ell, \mathcal{B}_\ell)$ 都是非空标准 Borel 空间， μ_ℓ 是 σ 有限测度， $\mu = \bigotimes_{\ell=1}^d \mu_\ell$ ，而 π 是关于 μ 联合可测的概率密度。对固定 j 定义

$$\pi_{-j}(x_{-j}) = \int_{\mathcal{X}_j} \pi(x_{-j}, s) \mu_j(ds). \quad (33.1)$$

由 Tonelli 定理， π_{-j} 可测；令 $D_j = \{x_{-j} : 0 < \pi_{-j}(x_{-j}) < \infty\}$ 。当 $x_{-j} \in D_j$ 时，第 j 个坐标的满条件密度为

$$\pi_j(t | x_{-j}) = \frac{\pi(x_{-j}, t)}{\pi_{-j}(x_{-j})}, \quad t \in \mathcal{X}_j. \quad (33.2)$$

它在 μ_j 意义下积分为 1。固定一个锚点 $x_j^\circ \in \mathcal{X}_j$ ，并在所有条件值上定义概率核

$$\Pi_j(B | x_{-j}) = \begin{cases} \frac{\int_B \pi(x_{-j}, t) \mu_j(dt)}{\pi_{-j}(x_{-j})}, & x_{-j} \in D_j, \\ \delta_{x_j^\circ}(B), & x_{-j} \notin D_j, \end{cases} \quad B \in \mathcal{B}_j. \quad (33.3)$$

联合可测性与 Tonelli 定理保证 $x_{-j} \mapsto \Pi_j(B | x_{-j})$ 可测，所以 Π_j 是正则条件分布的一个可测版本。集合 D_j^c 的 π_{-j} 质量为 0；在该集合上换用任何概率核都不改变联合分解或目标保持性，且绝不能把式 (33.2) 解释成 0/0。

模型组成与合法性。一个可执行的 Gibbs 模型至少包含

$$(\mathcal{X}, \mu, \pi, x^{(0)}, \{c_j\}_{j=1}^d, \mathcal{R}),$$

其中 π 是可归一化的目标概率密度, $x^{(0)}$ 位于其支持内, c_j 表示从式 (33.2) 精确抽样的步骤, $\mathcal{R}$ 提供彼此独立的随机数。只知道未归一化联合核 $\tilde{\pi}$ 并不妨碍推导满条件, 因为与 t 无关的共同常数会在归一化时消去; 但仍必须确认联合目标可归一化, 并能对每个实际遇到的 x_{-j} 构造合法条件抽样器。

学习策略。Gibbs 抽样不是通过最小化损失得到一个点, 而是构造保持整个目标分布的链。设计时依次检查: 目标联合分布是否可归一化; 满条件分布是否相容于同一个联合目标; 单坐标移动是否能连接目标支持; 更新顺序是否固定且明确; 条件抽样是否精确; 最后才比较分块方式、相关性和单轮成本。把条件众数代替条件随机抽样会得到坐标上升类算法, 不再是 Gibbs 抽样。

学习算法。在系统扫描中, 第 t 轮从 $x^{(t-1)}$ 开始, 先抽 $x_1^{(t)}$, 再抽 $x_2^{(t)}$; 第 j 步使用本轮已经更新的 $x_1^{(t)}, \dots, x_{j-1}^{(t)}$ 与尚未更新的 $x_{j+1}^{(t-1)}, \dots, x_d^{(t-1)}$ 。图 33.3 明确区分“轮内状态”和“轮末样本”。算法 33.1 及其前置说明另行区分完整轮次与中途停止状态。




图 33.3 系统扫描按固定次序即时写回; 当前子步的前段使用本轮新值, 后段沿用前轮旧值; 末位更新结束后, 末位状态与本轮样本状态相同并记录为轮末样本。

读图顺序。先按上方编号与箭头确认 $j = 1, \dots, d$ 的固定次序; 再看 $x^{[j]}$ 左侧坐标已写入同轮新值、右侧坐标仍保留上一轮旧值, 因而后续更新会读取此前的新值; 最终只把 $x^{[d]} = x^{(t)}$ 记作本轮样本, 不把中间状态当作一轮输出。

读前自检: Gibbs 抽样的满条件提议。Gibbs 坐标提议 K_j 从满条件更新 x_j 并保持 x_{-j} 不变; 请写出 $K_j(x, dy) = \Pi_j(dy_j | x_{-j})\delta_{x_{-j}}(dy_{-j})$, 核对它是归一化核。

读前自检: 系统扫描 Gibbs 算法。系统扫描 Gibbs 以合法初态、各坐标满条件抽样器和扫描预算为输入; 请按 $j = 1, \dots, d$ 依次用最新坐标状态更新一整轮, 轮末原子提交, 并在预算用尽时返回轨迹与诊断。

读前自检: Gibbs 坐标核的目标保持。单坐标 Gibbs 核 K_j 只改变第 j 坐标; 请把联合密度分解为边缘乘满条件, 交换 x_j, y_j 核对双向测度不变, 从而 $\pi K_j = \pi$ 。

33.2 逐变量 Gibbs 抽样

阅读目标：用边缘 – 条件分解证明精确满条件更新保持联合目标分布。

对象：联合目标 π 、除第 j 坐标外的状态 x_{-j} 与满条件核 $\Pi_j(x_{-j}, dx_j)$ 。

合法条件：采用可测的满条件版本；零边缘质量集合上使用预先选定版本，不使用密度比。

第一步：先写分解 $\pi(dx) = \pi_{-j}(dx_{-j})\Pi_j(x_{-j}, dx_j)$ 。

推导目标

从联合目标 π 构造只更新坐标 j 的核，证明它保持目标分布，并说明精确满条件提议为什么无需 Metropolis–Hastings 拒绝步骤。

推导准备

使用定义 33.1 构造的可测概率核 Π_j 、联合密度的边缘 – 条件分解和单坐标仅改变 x_j 这一事实。集合 D_j^c 具有零边缘质量，其上只使用预先选定的版本，不使用密度比。

由式 (33.2)，对 t 变化时与 t 无关的因子可以并入归一化常数，因此

$$\pi_j(t | x_{-j}) \propto \pi(x_{-j}, t), \quad (33.4)$$

但右侧必须在 x_j 上具有有限正积分。

步骤 1：定义局部核。 定义单坐标更新核

$$K_j(x, dy) = \Pi_j(dy_j | x_{-j}) \delta_{x_{-j}}(dy_{-j}). \quad (33.5)$$

因为 Π_j 是概率核，而 $x \mapsto \delta_{x_{-j}}(B_{-j})$ 可测，式 (33.5) 先在可测矩形上满足核的可测性，再由单调类定理推广到乘积 σ 代数；故 K_j 确实是马尔可夫核。**步骤 2：分解联合目标。** 若 $y_{-j} = x_{-j}$ ，把联合密度分解为

$$\pi(x) = \pi_{-j}(x_{-j})\pi_j(x_j | x_{-j}).$$

步骤 3：比较双向流。 正向平稳流中与坐标 j 有关的部分为

$$\pi_{-j}(x_{-j})\pi_j(x_j | x_{-j})\pi_j(y_j | x_{-j}), \quad (33.6)$$

交换 x_j, y_j 后式 (33.6) 不变，所以单坐标核满足细致平衡。

定理 33.1 (单坐标 Gibbs 核的可逆性) 在定义 33.1 的标准 Borel 与 σ 有限条件下，用式 (33.3) 的可测正则条件版本构造式 (33.5)。则 K_j 关于 π 可逆，因而 $\pi K_j = \pi$ ；在 D_j^c 上更换版本不改变该结论。

读前自检：证明：单坐标 Gibbs 核的可逆性。 单坐标 Gibbs 联合测度只在 $x_{-j} = y_{-j}$ 上有质量，且含 $\Pi_j(dx_j | x_{-j})\Pi_j(dy_j | x_{-j})$ ；请交换 x_j, y_j 核对测度不变，再积分一侧得到 $\pi K_j = \pi$ 。

证明. 记 $\mu_{-j} = \bigotimes_{\ell \neq j} \mu_\ell$ 。在 D_j 上有 $\pi(\mathbf{x})\mu(d\mathbf{x}) = \pi_{-j}(x_{-j})\mu_{-j}(dx_{-j})\Pi_j(dx_j | x_{-j})$ 。在 D_j^c 上，外层边缘测度为 0，所以任意版本贡献的联合质量都为 0。因此在 $\mathcal{X} \times \mathcal{X}$ 上，联合测度可写为

$$\pi(d\mathbf{x})K_j(\mathbf{x}, d\mathbf{y}) = \pi_{-j}(x_{-j})\mu_{-j}(dx_{-j})\Pi_j(dx_j | x_{-j})\Pi_j(dy_j | x_{-j})\delta_{x_{-j}}(dy_{-j}).$$

该测度只在 $x_{-j} = y_{-j}$ 上有质量，并且两个条件概率因子的乘积在交换 x_j, y_j 后不变。因此

$$\pi(d\mathbf{x})K_j(\mathbf{x}, d\mathbf{y}) = \pi(d\mathbf{y})K_j(\mathbf{y}, d\mathbf{x}),$$

即满足细致平衡。对 $\mathbf{x}$ 积分便得到 $\pi K_j = \pi$ 。这也明确说明了零边缘版本为何不会进入任何正质量的双向流。 $\square$

命题 33.1 (系统扫描与随机扫描) 若每个 K_j 保持 π ，则系统扫描核

$$K_{\text{sys}} = K_1 K_2 \cdots K_d$$

保持 π 。若 $w_j > 0$ 、 $\sum_j w_j = 1$ 且权重不依赖当前状态，则随机扫描核

$$K_{\text{rs}} = \sum_{j=1}^d w_j K_j$$

关于 π 可逆。系统扫描核一般只保证平稳，不保证可逆。

读前自检：证明：系统扫描与随机扫描。 系统扫描与随机扫描要求先确认“当这些核不交换时，正序与反序不同，不能由各分量可逆推出乘积可逆”；请随后把 πK_{sys} 用到的关键定义展开并完成下一步变形，用乘以常数 w_j 再求和仍然对称，所以 K_{rs} 可逆验收。

证明. 逐个使用 $\pi K_j = \pi$ 得到

$$\pi K_{\text{sys}} = (((\pi K_1) K_2) \cdots) K_d = \pi.$$

对随机扫描，定理 33.1 给出每个 K_j 的对称双向流；乘以常数 w_j 再求和仍然对称，所以 K_{rs} 可逆。系统扫描的伴随核按反序排列为 $K_d \cdots K_1$ ；当这些核不交换时，正序与反序不同，不能由各分量可逆推出乘积可逆。 $\square$

定理 33.2 (有限全支持情形的遍历性) 设 $\mathcal{X} = \prod_{j=1}^d \mathcal{X}_j$ 为有限乘积空间，且 $\pi(\mathbf{x}) > 0$ 对每个 $\mathbf{x} \in \mathcal{X}$ 成立。则一轮系统扫描核 K_{sys} 的每个矩阵元素都严格为正。因此该轮末链不可约、非周期， π 是唯一平稳分布，并且从任意初值出发的边缘分布收敛到 π 。

读前自检：证明：有限全支持情形的遍历性。 有限全支持 Gibbs 从 $\mathbf{x}$ 依次把前 j 个坐标改成 $\mathbf{y}$ ；请把一轮转移写成 $\prod_{j=1}^d \pi_j(y_j | \mathbf{x}_{-j}^{[j-1]})$ ，核对其严格为正，并令 $\mathbf{y} = \mathbf{x}$ 验证不可约且周期为 1。




图 33.4 二维 Gibbs 轨迹在更新 x_1 时水平移动、更新 x_2 时竖直移动；折线是固定的教学示意而非伪造随机轨迹，倾斜狭长目标中的短轴向步揭示了强相关导致的慢混合

证明. 任取 $x, y \in \mathcal{X}$ 。令中间状态 $x^{[j]}$ 的前 j 个坐标等于 y ，其余坐标等于 x 。从 $x^{[j-1]}$ 更新第 j 个坐标到 y_j 的概率是相应满条件概率。全支持假设使联合质量与边缘质量都严格为正，所以每个满条件概率严格为正。于是

$$K_{\text{sys}}(x, y) = \prod_{j=1}^d \pi_j(y_j | x_{-j}^{[j-1]}) > 0.$$

故任意状态一步轮末转移即可到达任意状态，核不可约；取 $y = x$ 又有 $K_{\text{sys}}(x, x) > 0$ ，所以周期为 1。有限状态马尔可夫链定理随后给出唯一平稳分布与边缘收敛，而命题 33.1 已确认该平稳分布就是 π 。□

常见错误

定理边界与反例。 定理 33.2 的全支持条件很强。若目标支持受约束，单坐标移动可能无法连接不同部分。例如 $\{(0, 0), (1, 1)\}$ 上的均匀分布具有合法但退化的满条件分布；从任一点更新单个坐标都不能离开原状态，Gibbs 核等于恒等核。增加迭代轮数不能修复这种可约性。

33.3 与 Metropolis–Hastings 的关系

几何解释。 在二维连续状态空间中，更新 x_1 时 x_2 固定，所以轨迹沿水平方向移动；随后更新 x_2 时 x_1 固定，轨迹沿竖直方向移动。图 33.4 把这种折线路径叠加在目标等密度线上。沿坐标轴移动不表示目标分布轴对齐；当等密度椭圆非常狭长且倾斜时，许多短的横纵步才能沿长轴前进。

概率解释。更新坐标 j 时，算法保留 x_{-j} ，并用其正确条件分布中的新抽样替换旧 x_j 。给定 x_{-j} 后，新旧坐标是同一条件分布的两个取值，式 (33.6) 因此天然对称。若把满条件分布作为单坐标 Metropolis-Hastings 提议，则在正流分支上

$$R(x, y) = \frac{\pi(y)\pi_j(x_j | y_{-j})}{\pi(x)\pi_j(y_j | x_{-j})} \quad (33.7)$$

$$= \frac{\pi_{-j}(x_{-j})\pi_j(y_j | x_{-j})\pi_j(x_j | x_{-j})}{\pi_{-j}(x_{-j})\pi_j(x_j | x_{-j})\pi_j(y_j | x_{-j})} = 1, \quad (33.8)$$

因为 $y_{-j} = x_{-j}$ 。所以精确满条件提议必接受。图 33.5 同时说明：若只近似满条件或改用其他提议，接受率不再自动等于 1，此时必须恢复 Metropolis-Hastings 校正。




图 33.5 精确满条件分布作为单坐标提议时，正流分支的 Metropolis-Hastings 比值恒为 1，Gibbs 更新无需拒绝；若提议只近似满条件或改用其他分布，则必须恢复接受率校正和拒绝自环

优化解释及不适用边界。标准 Gibbs 抽样没有要逐轮单调下降的目标函数，因此“优化收敛率”“局部最优点”和“每步改进损失”不适用于本算法。若把条件抽样改成条件众数，会得到迭代条件众数或坐标上升方法；其输出是点估计，不能替代后验样本。这里唯一可作设计优化的是分块、参数化与实现成本，而不是把随机状态更新解释成确定性下降。

图形辅助。图 33.3 强调轮内新旧坐标的混合使用；图 33.4 强调坐标方向路径；图 33.5 强调精确条件提议与一般提议的接受规则。三图分别服务于更新顺序、几何混合与算法边界，不能互相替代。

命题 33.2 (二元正态 Gibbs 的边缘递推) 设

$$(X_1, X_2)^T \sim N\left(0, \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}\right), \quad |\rho| < 1.$$

按 x_1 后 x_2 的顺序系统扫描，并令 $\sigma = \sqrt{1 - \rho^2}$ 。则

$$X_1^{(t)} = \rho X_2^{(t-1)} + \sigma \varepsilon_{1t}, \quad (33.9)$$

$$X_2^{(t)} = \rho X_1^{(t)} + \sigma \varepsilon_{2t} = \rho^2 X_2^{(t-1)} + \xi_t, \quad (33.10)$$

其中 $\varepsilon_{1t}, \varepsilon_{2t}$ 独立同分布于 $N(0, 1)$ ， ξ_t 独立于过去且 $\text{Var}(\xi_t) = 1 - \rho^4$ 。在平稳状态下， X_2 的滞后 k 自相关为 ρ^{2k} ，从而

$$\tau_{\text{int}} = \frac{1 + \rho^2}{1 - \rho^2}, \quad \frac{N_{\text{eff}}}{N} = \frac{1 - \rho^2}{1 + \rho^2}.$$

读前自检：证明：二元正态 Gibbs 的边缘递推。 二元正态 Gibbs 按 x_1 后 x_2 扫描且 $|\rho| < 1$ ；请把两条满条件更新代入，得到 $X_2^{(t)} = \rho^2 X_2^{(t-1)} + \xi_t$ ，再算 $\text{Var}(\xi_t) = 1 - \rho^4$ 并核对滞后相关为 ρ^{2k} 。

证明。 联合密度指数中的二次型满足

$$x_1^2 - 2\rho x_1 x_2 + x_2^2 = (x_1 - \rho x_2)^2 + (1 - \rho^2)x_2^2.$$

固定 x_2 后，与 x_1 有关的部分给出 $X_1 | X_2 = x_2 \sim N(\rho x_2, 1 - \rho^2)$ ；交换坐标得到 $X_2 | X_1 = x_1 \sim N(\rho x_1, 1 - \rho^2)$ 。代入两步更新便得到边缘递推，其中

$$\xi_t = \sigma(\rho \varepsilon_{1t} + \varepsilon_{2t}), \quad \text{Var}(\xi_t) = (1 - \rho^2)(1 + \rho^2) = 1 - \rho^4.$$

这是系数为 ρ^2 的平稳 AR(1) 递推，所以 $\text{Corr}(X_2^{(t)}, X_2^{(t+k)}) = \rho^{2k}$ 。对几何级数求和得到 $1 + 2 \sum_{k \geq 1} \rho^{2k} = (1 + \rho^2)/(1 - \rho^2)$ ，再按 ESS 定义取倒数比例。□

图 33.6 显示两个正态满条件切片。




图 33.6 取 $\rho = 0.6$ 、 $a = 1$ 、 $b = 0.75$ 时，两个满条件分布分别为 $N(0.45, 0.64)$ 与 $N(0.60, 0.64)$ ；图中曲线按同一组参数直接计算。

图 33.7 使用上述解析自相关而非伪造轨迹，比较不同 $|\rho|$ 下的混合速度。




图 33.7 二元正态系统 Gibbs 的轮末解析自相关为 ρ^{2k} ，渐近有效样本比例为 $(1-\rho^2)/(1+\rho^2)$ ；当 $|\rho|$ 接近 1 时相关性衰减缓慢，即使内核正确且接受率为 1，固定长度链的统计效率仍会显著下降

读图时应先看左面板中轮末自相关 ρ^{2k} 随滞后 k 的衰减，再看右面板中渐近有效样本比例 $(1-\rho^2)/(1+\rho^2)$ 随 $|\rho|$ 的下降；当 $|\rho| \rightarrow 1^-$ 时，前者衰减趋于停滞而后者趋于 0，这只是从合法区域 $|\rho| < 1$ 内逼近边界的极限，并不表示可以取退化相关系数 $|\rho| = 1$ 。

例题 33.2 (两轮确定性更新测试). 取 $\rho = 1/2$ 、 $\sigma = \sqrt{3}/2$ 、初值 $x^{(0)} = (2, -1)$ 。把两轮标准正态输入固定为

$$(\varepsilon_{11}, \varepsilon_{21}) = (0, 1), \quad (\varepsilon_{12}, \varepsilon_{22}) = (-1, 0).$$

按“先 X_1 后 X_2 ”的系统扫描顺序复算两轮轮末状态，并说明该确定性测试能验证什么。

例题 33.2 解答

读题翻译 给定创新量把两轮随机更新固定成可逐步复算的确定性测试；每轮必须先得到新 $x_1^{(t)}$ ，再用它计算同轮 $x_2^{(t)}$ 。

已知与合法条件 $\rho = 1/2$ 、 $\sigma = \sqrt{3}/2$ 、初值和四个创新量均已固定；本题只核验顺序更新公式，不用两轮数值判断随机链收敛。

为什么想到这个方法 逐轮执行 $x_1^{(t)} = \rho x_2^{(t-1)} + \sigma \varepsilon_{1t}$ ，立即把新 $x_1^{(t)}$ 代入 $x_2^{(t)} = \rho x_1^{(t)} + \sigma \varepsilon_{2t}$ 。

方法选择 保留每轮两个中间值，完成两轮后把结果代回两条残差恒等式，专门检查第二坐标没有误用旧 x_1 。

推导/计算 第一轮。 得到

$$\begin{aligned} x_1^{(1)} &= \rho x_2^{(0)} + \sigma \varepsilon_{11} = -\frac{1}{2}, \\ x_2^{(1)} &= \rho x_1^{(1)} + \sigma \varepsilon_{21} = -\frac{1}{4} + \frac{\sqrt{3}}{2}. \end{aligned}$$

第二轮。得到

$$\begin{aligned}x_1^{(2)} &= \rho x_2^{(1)} + \sigma \varepsilon_{12} = -\frac{1}{8} - \frac{\sqrt{3}}{4}, \\x_2^{(2)} &= \rho x_1^{(2)} + \sigma \varepsilon_{22} = -\frac{1}{16} - \frac{\sqrt{3}}{8}.\end{aligned}$$

独立核验 四个更新分别满足 $x_1^{(t)} - \rho x_2^{(t-1)} = \sigma \varepsilon_{1t}$ 与 $x_2^{(t)} - \rho x_1^{(t)} = \sigma \varepsilon_{2t}$ ；第二式确实使用同轮新 $x_1^{(t)}$ ，因此可检出误用旧值的并行更新。

结论 两轮轮末状态分别为 $(-1/2, -1/4 + \sqrt{3}/2)$ 与 $(-1/8 - \sqrt{3}/4, -1/16 - \sqrt{3}/8)$ 。该确定性测试只验证更新次序与代数，不证明随机链已经收敛。

读前自检：抽样计算。 Gibbs 一轮依次调用 d 个满条件抽样器；若第 j 个求值与抽样成本为 C_j, U_j ，请求和得到 T 轮时间 $O(T \sum_j (C_j + U_j))$ ，并核对状态空间为 $O(d)$ 。

33.4 收敛、抽样计算与练习

概率图模型常把目标写成局部因子的乘积。以观测 y 、超参数 α 、模型参数 θ 和隐变量 z 为例，

$$\pi(\alpha, \theta, z | y) \propto p(z, y | \theta) p(\theta | \alpha) p(\alpha). \quad (33.11)$$

因此更新某个变量时，只需保留含该变量的因子。例如

$$\pi(\alpha_i | \alpha_{-i}, \theta, z, y) \propto p(\theta | \alpha) p(\alpha), \quad (33.12)$$

$$\pi(\theta_j | \theta_{-j}, \alpha, z, y) \propto p(z, y | \theta) p(\theta | \alpha), \quad (33.13)$$

$$\pi(z_k | z_{-k}, \alpha, \theta, y) \propto p(z, y | \theta). \quad (33.14)$$

图 33.8 把这条“只看 Markov 毯”的消因子规则画成概率图；未写入当前条件核的每个因子都必须确实与当前变量无关。




图 33.8 因子图中更新 θ 只需读取与 θ 相连的两个因子 $p(\theta | \alpha)$ 和 $p(z, y | \theta)$ ；Markov 毯变量为 α, z, y ，而与 θ 无关的因子 $p(\alpha)$ 可从满条件核中消去

伪代码。 算法 33.1 把一次完整系统扫描定义为依次完成 d 个坐标更新。它保存轮末轨迹；若还保存轮内状态，必须使用独立下标，不把一次坐标更新误记成一整轮。

输入与输出。输入为可归一化的目标、维数 d 、合法初值 $x^{(0)}$ 、 d 个精确满条件抽样方法、彼此独立的随机数、燃烧轮数 m 、保留轮数 n 和可选函数 f 。输出包括完整轮末轨迹、逐坐标抽样记录、保留样本和可选样本均值；若某坐标更新失败，另行说明失败位置与本轮已经更新的中间状态。

参数含义。 $T = m + n$ 是完整扫描轮数；一轮含 d 次坐标抽样。 m 只决定哪些轮末状态不进入估计，不能证明链已收敛； $n = 0$ 时允许只测试更新步骤，但均值、MCSE 和 ESS 未定义。分块 Gibbs 把一个“坐标”替换为变量块，所有定义相应使用块满条件分布。

初始化。开始前验证 π 可归一化、 $x^{(0)}$ 位于目标支持、每个条件抽样器与式 (33.2) 一致、随机源类型正确以及 m, n, d 合法。不能从支持外启动后期待退化条件分布自动把状态修回支持。

参数更新。第 t 轮第 j 步使用当前轮内状态的 x_{-j} 调用 c_j ，验证返回值属于 x_j 且新完整状态位于目标支持，再立即覆盖 x_j 。后续坐标必须看到此前已更新的值。若某步失败，记录位置 (t, j) ；本轮中间状态不计作轮末样本。

停止条件。正常分支恰好完成 T 轮； $T = 0$ 时不调用随机数，返回只含初值的轨迹和空保留集。若条件分布未定义、抽样结果不是有限实数、样本越界、新状态离开支持或 f 不是有限实数，则立即停止。主轨迹只保留此前完成的轮末状态，失败轮的中间状态另行说明。

正确性与收敛条件。定理 33.1 与命题 33.1 只证明目标保持。有限全支持时，定理 33.2 进一步给出时间平均；非周期性另用于固定时刻边缘收敛。一般受约束或连续状态必须按定义 32.3 和命题 32.4 分别核验正常 Harris 返、非周期性以及 CLT/批均值所需的额外矩与混合条件。图 33.7 说明即使这些结论成立， $|\rho|$ 接近 1 时统计效率仍可很低。

时间复杂度。设第 j 个满条件抽样与支持验证的实际成本为 C_j ，一次坐标就地更新成本为 U_j 。完成 $T = m + n$ 轮的时间为

$$O\left(T \sum_{j=1}^d (C_j + U_j)\right).$$

若每次轮末复制 d 维状态，还需 $O(Td)$ 复制成本。概率图实现中 C_j 应按 Markov 毯因子求值计入，不能无条件写成 $O(1)$ 。

空间复杂度。只保留当前状态需要 $O(d)$ 空间；保存 n 个轮末样本需要 $O(nd)$ ；保存全部 T 轮及每次坐标更新可达 $O(Td^2)$ 个标量。流式计算均值可把统计量附加空间降为 $O(1)$ 或 $O(\dim f)$ ，但用于诊断的轨迹不能在未记录替代信息时丢弃。

适用条件。Gibbs 抽样适合联合目标难以直接抽样、各满条件分布可精确且高效抽样、支持可由所选坐标或分块更新连通的模型。共轭层次模型、离散潜变量模型和稀疏概率图常满足这一结构。若只能近似抽满条件，应明确改用 Metropolis-within-Gibbs、slice-within-Gibbs 或其他带正确性证明的内核。

局限性。强相关会使轴向路径混合缓慢；确定性约束会令单坐标条件分布退化；不当参数化可造成近不可约行为；高维全扫描成本可能很大；系统扫描缺少一般可逆性。分块、重参数化和随机扫描可能改善效率，但每次修改都必须重新核验目标保持与可达性。

常见错误。不得把本轮尚未更新的坐标误写成新值；不得在条件归一化常数发散时继续抽样；不得把条件众数当条件随机样本；不得因“接受率为 1”便跳过支持检查；不得把一次坐标更新与一次完整扫描混用时间下标；不得删除重复状态、只看单链轨迹或用固定燃烧期代替收敛条件。

易混淆概念对比。

对比	Gibbs 抽样	相关但不同的方法
精确满条件与 MH	条件提议在正流分支接受率为 1	其他提议需计算接受率并可能拒绝
系统扫描与随机扫描	固定顺序乘积核保持 π ，一般不再可逆	固定权重混合核可逆，但每步只更新一个坐标
条件抽样与条件众数	产生保持完整分布的随机链	条件众数更新是点优化，不给后验样本
单坐标与分块	单步便宜但可能强相关	分块成本较高，可能沿相关方向移动更远
正确性与效率	平稳性、可达性和返性决定正确性	ESS、MCSE 与运行时间描述给定正确内核的效率

循环变量与更新顺序。外层循环变量为完整扫描轮 $t = 1, \dots, T$ ，内层循环变量为坐标 $j = 1, \dots, d$ ；每次抽样成功后立即覆盖 x_j ，因此第 $j + 1$ 步读取本轮最新状态。

判断条件。每个坐标步核验条件分布是否定义、抽样值是否有限且属于坐标空间、新完整状态是否落在目标支持；可选函数 f 另行核验有限性。

返回结果、异常与退化。正常分支给出完整轮末轨迹和保留样本；中途停止时给出此前完整轮、 (t, j) 位置及本轮中间状态。 $T = 0$ 不调用随机数， $n = 0$ 不构造样本均值。

正确性依据。定理 33.1 保证每个坐标核保持 π ，命题 33.1 保证其系统乘积仍保持 π 。

不收敛或不适用情形。目标不可归一化、满条件不相容或不可精确抽样、单坐标支持可约，或一般状态链不满足定义 32.3 中的正常 Harris 返条件时，本算法不能给出所需遍历均值保证；增加燃烧轮数不能修复这些问题。即便时间平均成立，固定时刻边缘收敛仍需非周期性，MCSE 与批均值仍需命题 32.4 第 3 项的额外条件。

复杂度假设。复杂度使用本节定义的 C_j, U_j ，并显式计入状态复制；不把满条件归一化、因子求值、随机采样或支持验证无条件视为常数时间。

带部分扫描诊断的系统 Gibbs 抽样：五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。写出能直接核验的停止证书；预算耗尽不等同于收敛。

算法 33.1: 带部分扫描诊断的系统 Gibbs 抽样

输入: 可归一化的目标; d 个精确满条件抽样方法 $\mathcal{C}_j$; 合法 $x^{(0)}$; 独立随机数; m, n ; 可选 f

输出: 最后合法轮末轨迹、部分扫描/保留段; $t_{\text{done}}, c_{\text{done}}, q_{\text{done}}$; **status** 与最终诊断

- 1 若 d, m, n 、目标/初值、满条件接口或随机源契约非法, 则返回空结果、计数 0、**invalid_input** 及字段诊断
- 2 令 $T = m + n, x = x^{(0)}, t_{\text{done}} = c_{\text{done}} = q_{\text{done}} = 0$, 轮末轨迹 $\mathcal{T} = (x^{(0)})$; 若 $T = 0$, 返回该轨迹、空保留段、**completed** 及零预算诊断
- 3 **对** $t \leftarrow 1, \dots, T$ **执行**
- 4 令 $x^{\text{start}} \leftarrow x, x_{\text{work}} \leftarrow x$, 本轮坐标记录为空
- 5 **对** $j \leftarrow 1, \dots, d$ **执行**
- 6 使用 $x_{\text{work}, -j}$ 调用 $\mathcal{C}_j$ 并增加 q_{done} ; 调用失败则返回前 $t - 1$ 轮、只读 x_{work} 、**random_source_failure** 及 (t, j) 诊断
- 7 若条件归一化诊断、 y_j 有限性/坐标域或新完整状态支持检查失败, 则返回上一完整轨迹、只读部分状态、**numerical_failure** 及 (t, j) 诊断
- 8 原子令 $x_{\text{work}, j} \leftarrow y_j$, 增加 c_{done} 并记录条件上下文/轮内状态
- 9 **结束**
- 10 原子提交 $x \leftarrow x_{\text{work}}$ 并向 $\mathcal{T}$ 追加; 令 $t_{\text{done}} \leftarrow t$, 记录本轮变化
- 11 **结束**
- 12 令保留集 $\mathcal{S} \leftarrow (X^{(m+1)}, \dots, X^{(m+n)})$
- 13 若给出 f 且 $n > 0$, 核验所有 $f(X)$ 有限并计算均值; 失败时保留轨迹/样本并返回 **numerical_failure** 及均值阶段诊断
- 14 返回 $\mathcal{T}, \mathcal{S}$ 、实际计数、**completed** 及扫描/保留段最终诊断; $n = 0$ 时均值未定义

输出。 列出返回对象、实际计数、中心状态和用于复核的诊断。

例题 33.3 (五分类模型的可复算 Gibbs 目标). 五类概率为

$$p_1 = \frac{\theta}{4} + \frac{1}{8}, \quad p_2 = \frac{\theta}{4}, \quad p_3 = \frac{\eta}{4}, \quad p_4 = \frac{\eta}{4} + \frac{3}{8}, \quad p_5 = \frac{1 - \theta - \eta}{2},$$

参数域为 $D = \{(\theta, \eta) : \theta > 0, \eta > 0, \theta + \eta < 1\}$, 观测计数为 $(14, 1, 1, 1, 5)$ 。仅有似然不足以定义后验; 本例明确补充 D 上的均匀先验。任务是推导后验核、两个满条件分布的精确有限混合表示, 并给出无需随机运行的精确矩基准。

例题 33.3 解答

读题翻译 用 D 上的均匀先验与多项计数似然定义三角域后验, 再把两个满条件写成可直接抽样的有限 Beta 混合, 并给出不依赖随机运行的精确矩基准。

已知与合法条件 参数域 D 有界, 先验在 D 上均匀; 观测计数固定, 且 $\theta, \eta, 1 - \theta - \eta$ 在 D 内均为正。

为什么想到这个方法 先写后验核; 固定一个参数后把另一个缩放到 $(0, 1)$ 并作有限多项式展开, 从而识别 Beta 混合; 最后用单纯形积分计算矩。

方法选择 依次得到后验核、 $u = \theta/(1 - \eta)$ 的 15 分量 Beta 混合、 $v = \eta/(1 - \theta)$ 的二分量 Beta 混合, 再用 Dirichlet 积分恒等式求四个后验矩。

推导/计算 后验核。 多项式系数以及 8, 4, 2 的幂与参数无关, 可以并入归一化常数。因此

$$\pi(\theta, \eta | y) \propto (1 + 2\theta)^{14} \theta \eta (3 + 2\eta) (1 - \theta - \eta)^5 \mathbf{1}_D(\theta, \eta). \quad (33.15)$$

θ 满条件。 固定 η 并令 $s = 1 - \eta$ 、 $u = \theta/s$ 。二项展开给出

$$(1 + 2su)^{14}u(1-u)^5 = \sum_{r=0}^{14} \binom{14}{r} (2s)^r u^{r+1} (1-u)^5.$$

所以 $u | \eta$ 是 $\text{Beta}(r+2, 6)$ 的 15 分量混合, 分量权重为

$$\omega_r^{(\theta)}(s) = \frac{\binom{14}{r} (2s)^r B(r+2, 6)}{\sum_{\ell=0}^{14} \binom{14}{\ell} (2s)^\ell B(\ell+2, 6)}, \quad r = 0, \dots, 14, \quad (33.16)$$

抽得 u 后令 $\theta = su$ 。

η 满条件。 固定 θ 并令 $s = 1 - \theta$ 、 $v = \eta/s$, 则

$$\eta(3 + 2\eta)(s - \eta)^5 d\eta \propto [3v(1-v)^5 + 2sv^2(1-v)^5], dv.$$

因此 $v | \theta$ 是 $\text{Beta}(2, 6)$ 和 $\text{Beta}(3, 6)$ 的二分量混合, 未归一化权重分别为 $3B(2, 6)$ 与 $2sB(3, 6)$; 抽得 v 后令 $\eta = sv$ 。两步都保持 D , 且是精确满条件抽样。

确定性矩基准。 定义

$$I_{a,b} = \int_D \theta^a \eta^b (1 + 2\theta)^{14} \theta \eta (3 + 2\eta) (1 - \theta - \eta)^5 d\theta d\eta.$$

计算时先用二项式展开 $(1 + 2\theta)^{14}$, 再把 $3 + 2\eta$ 拆成两项。对 $A, B, C > 0$, 所用的单纯形 Dirichlet 恒等式为

$$\int_D \theta^{A-1} \eta^{B-1} (1 - \theta - \eta)^{C-1} d\theta d\eta = \frac{\Gamma(A)\Gamma(B)\Gamma(C)}{\Gamma(A+B+C)}.$$

对展开式的第 r 项, 常数 3 对应 $(A, B, C) = (r + a + 2, b + 2, 6)$, 而 2η 对应 $(A, B, C) = (r + a + 2, b + 3, 6)$ 。逐项代入即得

$$I_{a,b} = \sum_{r=0}^{14} \binom{14}{r} 2^r \left[\frac{3 \Gamma(r + a + 2) \Gamma(b + 2) \Gamma(6)}{\Gamma(r + a + b + 10)} \right. \quad (33.17)$$

$$\left. + \frac{2 \Gamma(r + a + 2) \Gamma(b + 3) \Gamma(6)}{\Gamma(r + a + b + 11)} \right]. \quad (33.18)$$

于是 $E(\theta^a \eta^b | y) = I_{a,b}/I_{0,0}$ 。确定性复算结果为

$$E(\theta | y) \approx 0.51995509, \quad \text{Var}(\theta | y) \approx 0.01776292,$$

$$E(\eta | y) \approx 0.12316991, \quad \text{Var}(\eta | y) \approx 0.00655205.$$

独立核验 后验核在有界域 D 上非负可积；两组混合权重归一化后均和为 1。 $u, v \in (0, 1)$ 分别保证 $0 < \theta < 1 - \eta$ 与 $0 < \eta < 1 - \theta$ 。独立的三角域数值积分复得上述四个矩，并给出 $E(\theta + \eta | y) \approx 0.64312500 < 1$ 。

结论 令 $u = \theta/(1 - \eta)$ ，则 $u | \eta, y$ 是 15 分量 $\text{Beta}(r + 2, 6)$ 混合，且 $\theta = (1 - \eta)u$ ；令 $v = \eta/(1 - \theta)$ ，则 $v | \theta, y$ 是 $\text{Beta}(2, 6)$ 与 $\text{Beta}(3, 6)$ 混合，且 $\eta = (1 - \theta)v$ 。后验均值约为 0.51995509, 0.12316991，方差约为 0.01776292, 0.00655205。这些数值是确定性积分基准，不是一次随机 Gibbs 运行的样本结果。

本章共 12 道练习。每道题干后立即给出同号解析；长解析可自然跨页，续页标题保留题号。

【原书练习整理】

练习 33.1. 五分类概率、参数域和观测计数如例 33.3。回答：(a) 为什么只给似然不能唯一确定“参数均值与方差”；(b) 在 D 上均匀先验下推导后验核；(c) 推导 $\theta | \eta, y$ 与 $\eta | \theta, y$ 的精确有限 Beta 混合抽样法；(d) 给出后验均值、方差的可复算确定性基准；(e) 写明一次真实 Gibbs 估计还必须保存哪些证据。不得在没有随机流时虚构样本均值。

练习 33.1 解析

(a) 参数的“均值与方差”必须相对于一个概率分布定义。似然 $L(\theta, \eta; y)$ 只描述给定参数时数据的相对可能性；不同先验会给出不同后验矩。因此原题数据还需先验或其他目标分布约定。
(b) 在 D 上取均匀先验后，多项式似然中与参数无关的常数消去，得到

$$\pi(\theta, \eta | y) \propto (1 + 2\theta)^{14} \theta \eta (3 + 2\eta)(1 - \theta - \eta)^5 \mathbf{1}_D,$$

与式 (33.15) 一致。

(c) 固定 η ，令 $s = 1 - \eta$ 、 $u = \theta/s$ 。展开 $(1 + 2su)^{14}$ 后， u 是 $\text{Beta}(r + 2, 6)$ 、 $r = 0, \dots, 14$ 的混合，权重正是式 (33.16)。固定 θ ，令 $s = 1 - \theta$ 、 $v = \eta/s$ ，则 v 的核为

$$3v(1 - v)^5 + 2sv^2(1 - v)^5,$$

所以两分量分别为 $\text{Beta}(2, 6)$ 与 $\text{Beta}(3, 6)$ ，未归一化权重为 $3B(2, 6)$ 与 $2sB(3, 6)$ 。每次抽样后分别令 $\theta = su$ 、 $\eta = sv$ ，状态始终留在 D 。

(d) 对例 33.3 中的 $I_{a,b}$ 求比值得

$$E(\theta | y) \approx 0.51995509, \quad \text{Var}(\theta | y) \approx 0.01776292,$$

$$E(\eta | y) \approx 0.12316991, \quad \text{Var}(\eta | y) \approx 0.00655205.$$

这些数来自有限 Gamma 函数和，不依赖随机运行。

(e) 真实报告至少说明先验、初值、扫描顺序、混合分量、随机数生成原则、完整轮末轨迹、燃烧与保留规则、MCSE/ESS，以及样本矩对上述精确矩的误差。没有实际运行时只能给出算法步骤与解析基准，不能报告一次虚构的 Gibbs 估计。

练习 33.2. 设 $(X_1, X_2) \in \{0, 1\}^2$ 的联合质量依次为

$$\pi(0, 0) = \frac{1}{10}, \quad \pi(0, 1) = \frac{2}{10}, \quad \pi(1, 0) = \frac{3}{10}, \quad \pi(1, 1) = \frac{4}{10}.$$

计算两个坐标的全部满条件概率, 并从 $(0, 0)$ 出发计算一轮“先 X_1 后 X_2 ”系统扫描的四个轮末转移概率。

练习 33.2 解析

固定 $X_2 = 0$ 时, 该列总质量为 $(1 + 3)/10$, 所以

$$P(X_1 = 1 | X_2 = 0) = \frac{3}{4}, \quad P(X_1 = 0 | X_2 = 0) = \frac{1}{4}.$$

固定 $X_2 = 1$ 得到 $P(X_1 = 1 | X_2 = 1) = 4/(2 + 4) = 2/3$ 。按行归一化又有

$$P(X_2 = 1 | X_1 = 0) = \frac{2}{3}, \quad P(X_2 = 1 | X_1 = 1) = \frac{4}{7}.$$

从 $(0, 0)$ 先更新 X_1 。若新 $X_1 = 0$, 概率为 $1/4$, 随后 X_2 取 $0, 1$ 的概率为 $1/3, 2/3$; 若新 $X_1 = 1$, 概率为 $3/4$, 随后概率为 $3/7, 4/7$ 。因此

$$K_{12}((0, 0), \cdot) = \left(\frac{1}{12}, \frac{1}{6}, \frac{9}{28}, \frac{3}{7} \right)$$

按 $(0, 0), (0, 1), (1, 0), (1, 1)$ 排列。四项之和为 1。

练习 33.3. 目标密度在三角域 $D = \{(x_1, x_2) : x_1 > 0, x_2 > 0, x_1 + x_2 < 1\}$ 上为常数 2, 域外为 0。推导两个满条件密度, 说明它们的支持怎样随另一坐标改变, 并解释为什么不能在 $x_2 = 1$ 处套用密度比定义 $x_1 | x_2$ 。

练习 33.3 解析

对 $0 < x_2 < 1$, 边缘密度为

$$\pi_2(x_2) = \int_0^{1-x_2} 2 dx_1 = 2(1 - x_2).$$

故两个满条件概率核为

$$\pi_1(x_1 | x_2) = \frac{\mathbf{1}_{(0, 1-x_2)}(x_1)}{1 - x_2}, \quad \pi_2(x_2 | x_1) = \frac{\mathbf{1}_{(0, 1-x_1)}(x_2)}{1 - x_1}.$$

各自积分为 1, 且另一坐标越大, 条件支持越短。 $x_2 = 1$ 时

$$\pi_2(1) = \int_0^0 2 dx_1 = 0, \quad \frac{\pi(x_1, 1)}{\pi_2(1)} = \frac{0}{0},$$

该条件事件在目标下为零概率; 只能选取正则条件分布的一个版本, 不能由密度比唯一指定。

练习 33.4. 目标在 $\{(0,0), (1,1)\}$ 上各赋概率 $1/2$ 。写出两个满条件分布和系统 Gibbs 核, 判断平稳性、可逆性、不可约性与唯一平稳分布。给出一种能连接两个状态的合法分块更新。

练习 33.4 解析

若 $X_2 = 0$, 目标支持只允许 $X_1 = 0$; 若 $X_2 = 1$, 只允许 $X_1 = 1$ 。因此

$$P(X_1 = x_2 | X_2 = x_2) = 1, \quad P(X_2 = x_1 | X_1 = x_1) = 1.$$

任何单坐标更新都保持原状态, 在状态顺序 $(0,0), (1,1)$ 下,

$$K_{\text{sys}} = I_2, \quad \pi K_{\text{sys}} = \pi, \quad \pi_i K_{ij} = \pi_j K_{ji}.$$

所以它关于均匀目标可逆并保持目标, 但可约; 事实上任意两个状态上的概率分布都平稳, 故不唯一。

把两个坐标作为一个块并从联合目标抽样, 得到

$$K_{\text{block}} = \begin{pmatrix} 1/2 & 1/2 \\ 1/2 & 1/2 \end{pmatrix}, \quad \pi K_{\text{block}} = \pi.$$

该核一步连接两个状态。

练习 33.5. 在 $\{-1,1\}^3$ 上令

$$\pi(x) \propto \exp\{\beta(x_1 x_2 + x_2 x_3)\}.$$

推导三个 Bernoulli 满条件概率。取 $\beta = (\log 3)/2$ 、初值 $(-1, 1, -1)$, 按 $1, 2, 3$ 更新, 并用固定均匀数 $(0.2, 0.9, 0.4)$ 执行一轮; 约定 $u \leq P(X_j = 1 | x_{-j})$ 时取 1。

练习 33.5 解析

只保留含当前坐标的指数项。对 $s \in \{-1, 1\}$,

$$P(X_1 = s | x_2) = \frac{e^{\beta s x_2}}{e^{\beta x_2} + e^{-\beta x_2}}, \quad P(X_3 = s | x_2) = \frac{e^{\beta s x_2}}{e^{\beta x_2} + e^{-\beta x_2}},$$

$$P(X_2 = s | x_1, x_3) = \frac{e^{\beta s(x_1 + x_3)}}{e^{\beta(x_1 + x_3)} + e^{-\beta(x_1 + x_3)}}.$$

当 $\beta = (\log 3)/2$ 且当前 $x_2 = 1$ 时, $P(X_1 = 1 | x_2) = 3/4$; $u_1 = 0.2$ 给出 $x_1 = 1$ 。此后 $x_1 + x_3 = 0$, 故 $P(X_2 = 1 | x_1, x_3) = 1/2$; $u_2 = 0.9$ 给出 $x_2 = -1$ 。最后 $P(X_3 = 1 | x_2 = -1) = 1/4$; $u_3 = 0.4$ 给出 $x_3 = -1$ 。轮末状态为 $(1, -1, -1)$ 。这是固定输入下的精确执行结果。

练习 33.6. 把精确满条件 $\pi_j(\cdot | x_{-j})$ 代入单坐标 Metropolis-Hastings 接受比, 逐项证明正流分支的接受率为 1。若改用一般提议 $q_j(y_j | x_j, x_{-j})$, 写出正确接受率, 并说明反向提议为零时怎样处理。

练习 33.6 解析

单坐标候选满足 $y_{-j} = x_{-j}$ 。在 $\pi(x) > 0$ 、 $\pi(y) > 0$ 且正反条件密度为正的分支,

$$\frac{\pi(y)\pi_j(x_j | x_{-j})}{\pi(x)\pi_j(y_j | x_{-j})} = 1$$

的约分过程与正文相同, 所以 $\alpha = 1$ 。候选由精确满条件产生时, 目标零质量点的抽样概率为零; 零边缘条件值则不能用该比值定义。

一般提议 q_j 下, 正确接受率为

$$\alpha(x, y) = \min \left\{ 1, \frac{\tilde{\pi}(y)q_j(x_j | y_j, x_{-j})}{\tilde{\pi}(x)q_j(y_j | x_j, x_{-j})} \right\}.$$

若正向流为正而反向提议为零, 则双向公共流为零, 必须确定拒绝; 不能用一个人为小正数替代零。

练习 33.7. 对命题 33.2 中的目标取 $\rho = 0.8$ 。推导两个满条件分布、 X_2 轮末链的 AR 系数与创新方差, 并计算理论积分自相关时间及渐近 ESS 比例。解释“每步接受”为什么不等于“样本近似独立”。

练习 33.7 解析

$\rho = 0.8 = 4/5$ 时, $1 - \rho^2 = 9/25$, 所以

$$X_1 | X_2 = x_2 \sim N\left(\frac{4}{5}x_2, \frac{9}{25}\right), \quad X_2 | X_1 = x_1 \sim N\left(\frac{4}{5}x_1, \frac{9}{25}\right).$$

轮末 X_2 的 AR 系数为 $\rho^2 = 16/25$, 创新方差为 $1 - \rho^4 = 1 - 256/625 = 369/625$ 。理论积分自相关时间和 ESS 比例为

$$\tau_{\text{int}} = \frac{1 + 16/25}{1 - 16/25} = \frac{41}{9} \approx 4.5556, \quad \frac{N_{\text{eff}}}{N} = \frac{9}{41} \approx 0.2195.$$

每个条件候选都被采用只说明没有 MH 拒绝; 相邻状态仍通过旧坐标传递相关性, 因此远非独立。

练习 33.8. 在同一二元正态目标下取 $\rho = 1/2$ 、 $x^{(0)} = (0, 0)$, 两轮创新依次为 $(1, 0)$ 和 $(0, -1)$ 。精确计算两轮轮末状态, 并说明这些固定输入能检验什么、不能证明什么。

练习 33.8 解析

此时 $\sigma = \sqrt{3}/2$ 。第一轮

$$x_1^{(1)} = \frac{1}{2} \cdot 0 + \frac{\sqrt{3}}{2} \cdot 1 = \frac{\sqrt{3}}{2}, \quad x_2^{(1)} = \frac{1}{2}x_1^{(1)} + \frac{\sqrt{3}}{2} \cdot 0 = \frac{\sqrt{3}}{4}.$$

第二轮

$$x_1^{(2)} = \frac{1}{2}x_2^{(1)} = \frac{\sqrt{3}}{8}, \quad x_2^{(2)} = \frac{1}{2}x_1^{(2)} - \frac{\sqrt{3}}{2} = -\frac{7\sqrt{3}}{16}.$$

练习 33.8 解析 (续)

这些值可检验更新顺序、旧值/新值使用、均值和标准差系数；两轮固定创新不能证明随机数生成器正确、链收敛或样本矩接近目标矩。

练习 33.9. 证明固定权重随机扫描 Gibbs 核可逆。再使用练习 33.2 的联合分布，分别计算从 $(0, 0)$ 到 $(1, 1)$ 的一轮正序扫描 $K_1 K_2$ 与反序扫描 $K_2 K_1$ 概率，据此说明系统扫描一般不具有可逆性。

练习 33.9 解析

每个 K_j 关于 π 的双向流对称，常数加权和 $K_{rs} = \sum_j w_j K_j$ 仍满足

$$\pi(dx)K_{rs}(x, dy) = \pi(dy)K_{rs}(y, dx),$$

所以固定权重随机扫描可逆。

对练习 33.2，正序从 $(0, 0)$ 到 $(1, 1)$ 的概率为

$$K_1 K_2((0, 0), (1, 1)) = \frac{3}{4} \cdot \frac{4}{7} = \frac{3}{7}.$$

反序则为

$$K_2 K_1((0, 0), (1, 1)) = \frac{2}{3} \cdot \frac{2}{3} = \frac{4}{9}.$$

两者不等，故 K_1, K_2 不交换。由于 $(K_1 K_2)^* = K_2 K_1$ ，正序系统扫描不等于自身伴随核，因而在这个例子中不具可逆性；两种顺序仍都保持 π 。

练习 33.10. 设

$$p(\alpha, \theta, z, y) = p(\alpha)p(\theta | \alpha) \prod_{k=1}^N p(z_k | \theta)p(y_k | z_k, \theta).$$

分别写出 α 、 θ 和单个 z_k 的满条件分布中必须保留的因子，并解释为什么其他因子可以消去。若 z_k 只在一个因子中出现，说明其 Markov 毯。

练习 33.10 解析

条件化时，与当前变量无关的因子并入归一化常数。于是

$$p(\alpha | \theta, z, y) \propto p(\alpha)p(\theta | \alpha),$$

$$p(\theta | \alpha, z, y) \propto p(\theta | \alpha) \prod_{k=1}^N p(z_k | \theta)p(y_k | z_k, \theta),$$

而对单个 z_k ,

$$p(z_k | z_{-k}, \alpha, \theta, y) \propto p(z_k | \theta)p(y_k | z_k, \theta).$$

其他观测与隐变量因子不含 z_k ，所以对 z_k 归一化时消去。 z_k 的 Markov 毯由它的父变量 θ 、子变量 y_k 以及 y_k 的其他父变量组成；在给定因子结构中没有额外变量。

练习 33.11. 算法 33.1 计划执行 T 轮、每轮 d 个坐标，第 t 轮第 j 个坐标失败。回答：主轮末轨迹应含多少个状态，完成轮数是多少，失败轮怎样返回；若每坐标成本上界为 C 且轮末复制成本为 $O(d)$ ，失败前的时间上界和保存全部轮内状态的空间上界分别是什么？

练习 33.11 解析

停止前已完成 $t-1$ 轮，所以完整轮数为 $t-1$ ；主轮末轨迹还含初值，共 t 个状态。第 t 轮只完成了前 $j-1$ 个坐标更新，当前中间状态必须单列，不能追加为一个轮末样本。

$$N_{\text{round}} = t-1, \quad |\mathcal{T}_{\text{main}}| = t, \quad N_{\text{coordinate}} = (t-1)d + (j-1).$$

失败前最多完成 $(t-1)d + (j-1)$ 次坐标更新，坐标成本上界为

$$O(((t-1)d + j-1)C).$$

再计入 $t-1$ 次轮末复制得到 $O(((t-1)d + j)C + (t-1)d)$ 的参数化上界；若把更新成本统一并入 C ，可简写为 $O(tdC)$ 。保存至多 T 轮的全部 d 个轮内 d 维状态需要 $O(Td^2)$ 标量空间；只保存轮末状态则是 $O(Td)$ 。

$$S_{\text{all inner}} = O(Td^2), \quad S_{\text{endpoints}} = O(Td).$$

练习 33.12. 判断下列说法，并为错误说法给出反例或缺失条件：(a) 任意给出的一组满条件分布都对应某个联合分布；(b) Gibbs 每步接受，所以一定混合很快；(c) 足够长的燃烧期可修复可约链；(d) 系统扫描总是可逆；(e) 任意依赖当前状态的坐标选择概率都保持目标分布；(f) 漂亮的单链轨迹足以证明程序和目标都正确。

练习 33.12 解析

六个说法都缺条件或错误。

$$P(X=1 | Y=0) = P(X=1 | Y=1) = \frac{1}{2},$$

$$P(Y=1 | X=0) = \frac{1}{4}, \quad P(Y=1 | X=1) = \frac{3}{4}$$

不能来自同一严格正联合分布：前一行推出 X 与 Y 独立，后一行却要求依赖，给出 (a) 的具体不相容反例。

- (a) 满条件必须彼此相容并对应同一个可归一化联合分布；任意指定的一组条件分布可能不存在共同联合分布。
- (b) 练习 33.7 中每步都采用新值，但 $\rho = 0.8$ 时理论 ESS 比例约为 0.2195，所以接受不保证快速混合。
- (c) 练习 33.4 的核为恒等核；丢弃任意多步后仍停在初值。
- (d) 练习 33.9 给出 $K_1 K_2 \neq K_2 K_1$ 的具体系统扫描，因此一般不具可逆性。
- (e) 状态依赖选择权重会改变正反更新流；除非另有平衡证明或校正，不能沿用固定权重混合核的证明。
- (f) 单链轨迹只能显示已访问路径。错误目标、共同遗漏的模式或程序与理论同时犯错都可能产生平滑轨迹；还需目标、转移核、独立测试、多个初值和定量诊断证据。

练习 33.12 解析 (续)

$$K = I \implies K^m = I \quad (\text{燃烧期不修复可约性}),$$

$$(K_1 K_2)^* = K_2 K_1 \neq K_1 K_2 \quad (\text{系统扫描一般不可逆}).$$

本章结论与下一步

核心结论：满条件首先是可测概率核；正边缘处由密度比给出，零边缘集合上必须选定版本。

关键依据：单坐标核的条件概率乘积关于新旧坐标对称，故可逆并保持 π ；系统扫描保持 π 但通常不可逆。

可执行自检：一轮依固定次序从当前轮内状态抽取各坐标，后一步立即读取前一步新值。

适用边界：适合满条件可精确抽样且坐标移动连通目标支持的模型；强相关与退化约束会导致慢混合或可约。

下一步：进入第 35 章：潜在狄利克雷分配，把本章坐标 Gibbs 用于主题后验推断。

1. 能否从联合密度得到式 (33.2) 并处理零边缘质量，再用对称条件流证明单坐标核可逆、说明系统扫描只自动继承平稳性？
2. 能否检查单坐标支持连通性、构造可约 Gibbs 反例，并完整执行算法 33.1 以区分轮末轨迹与部分扫描？
3. 能否推导二元正态满条件、AR 递推、积分自相关时间与 ESS 比例，同时从概率图因子识别 Markov 毯并说明消去项？
4. 能否为原书五分类任务补齐先验、推导精确条件混合并用解析矩核验运行？若不能，重做练习 33.1。
5. 能否拒绝用接受率、燃烧期或单链图替代不可约性和程序正确性证据？若不能，重做练习 33.12。

第 34 章 狄利克雷分布与共轭先验

读前自检：本章地图：狄利克雷分布与共轭先验。 狄利克雷分布与共轭先验章地图沿“类别计数 → Gamma/Beta 恒等式 → Dirichlet 分布 → 共轭预测”推进；请标出该路线第一次改变对象类型的位置，并核对前一步产出正是后一步输入。

读前自检：本章可检验学习目标。 狄利克雷分布与共轭先验的首个可检验目标是“区分类别观测序列与多项计数向量，写出各自的概率、支持集以及只与参数有关的似然核”；请区分类别观测序列与多项计数向量，写出各自的概率、支持集以及只与参数有关的似然核并写出中间结果，再按“中间结果逐项包含首目标“区分类别观测序列与多项计数向量，写出各自的概率、支持集以及只与参数有关的似然核”声明的对象、条件与结论”验收。

读前自检：最短先修。 Dirichlet 先修要求会用 Gamma/Beta 积分与单纯形变量变换；请先验证 $B(a, b) = \Gamma(a)\Gamma(b)/\Gamma(a + b)$ ，再核对 $a, b > 0$ 保证积分有限。

读前自检：依赖路线。 狄利克雷分布与共轭先验依赖链含“第 1 册的 Gamma/Beta 积分与第 2 册的 Bayes 先验—似然—后验分解 → 本章的 Dirichlet 共轭”到“类别概率向量 θ → 类别序列与计数向量 → 多项似然”这一跳；请固定写出前者输出类型与后者输入类型，并核对两者相同或存在正文声明的转换。

本章地图

核心问题：怎样在单纯形上归一化先验，并从完整似然推导后验、证据与预测？

可检验学习目标：

- 区分类别观测序列与多项计数向量，写出各自的概率、支持集以及只与参数有关的似然核；
- 从 Gamma 函数、Beta 函数和多元 Beta 函数建立狄利克雷密度的归一化常数；
- 在单纯形参考测度下严格定义狄利克雷分布，推导矩、协方差、边缘、聚合、条件与期望对数；
- 用独立同率 Gamma 变量的归一化构造证明分布归一化，并把这一构造转化为可复算的抽样步骤；
- 完整推导 Dirichlet-多项共轭后验、边际证据、单步与多步后验预测；
- 分清均值参数、浓度参数、伪计数和众数修正，正确处理边界参数与数值退化。

最短先修：本章使用概率质量函数、联合密度、条件概率、期望与协方差、变量变换的 Jacobian、Bayes 公式和指数族对数配分函数。直接前置包括第 1 册概率基础中的 Gamma 与 Beta 积分、第 2 册贝叶斯估计中的先验—似然—后验分解，以及本章前面的多项分布。读者需要能对有限类别计数、能进行分部积分，并能区分“概率密度的归一化常数”和“似然中与参数无关的常数”。

依赖路线：第 1 册的 Gamma/Beta 积分与第 2 册的 Bayes 先验—似然—后验分解 → 本章的 Dirichlet 共轭；类别概率向量 θ → 类别序列与计数向量 → 多项似然；Gamma 函数 → Beta 函数与多元 Beta 函数 → 单纯形上的狄利克雷密度；独立 Gamma 变量 → 归一化比例 → 狄利克雷抽样与矩；Dirichlet 先验 + 多项计数 → 参数逐分量相加 → 闭式后验、边际证据与后验预测。

完成标准与返回：先复习计数向量与有序序列的区别，再进入多项分布。

图 34.1 给出本章共轭更新、预测结论与解释支线的学习顺序；后续主题模型只是应用出口，不是本章的学习前置。




图 34.1 Dirichlet- 多项共轭更新与单步后验预测主链

读图顺序。先看左侧“类别计数”和“Gamma/Beta 归一化”怎样汇入多项似然与 Dirichlet 先验；再看中央实线主链如何把参数逐分量相加为 $\text{Dir}(\alpha + n)$ ，并读出 $\Pr(Y_{N+1} = i | n, \alpha) = (\alpha_i + n_i) / (\alpha_0 + N)$ ；最终区分下方无箭头的参数解释支链与虚线主题模型应用出口。

本章符号表

符号	类型、维数或范围	含义
K	正整数	类别数；非退化单纯形通常取 $K \geq 2$
Y_t	$\{1, \dots, K\}$ 中离散变量	第 t 次类别观测
$n = (n_1, \dots, n_K)$	$\mathbb{N}_0^K$	类别计数, $N = \sum_i n_i$
$\theta = (\theta_1, \dots, \theta_K)$	Δ_{K-1}	类别概率向量, $\sum_i \theta_i = 1$
Δ_{K-1}	$(K-1)$ 维单纯形	$\theta_i \geq 0$ 且分量和为 1 的集合
$\alpha = (\alpha_1, \dots, \alpha_K)$	$(0, \infty)^K$	狄利克雷形状参数
α_0	正实数	总浓度 $\sum_i \alpha_i$
m	Δ_{K-1}	均值参数 α / α_0
$\Gamma(a)$	$a > 0$	Gamma 函数
$B(a, b)$ 、 $B(\alpha)$	正实数	二元与多元 Beta 函数
$\psi(a)$	$a > 0$	digamma 函数 $d \log \Gamma(a) / da$
α^{post}	$(0, \infty)^K$	后验参数 $\alpha + n$
α_0^{post}	正实数	后验总浓度 $\alpha_0 + N$

读前自检：狄利克雷—多项建模入口。 Dirichlet- 多项入口假设每次观测落入 K 个互斥类别之一，参数 $\theta_i \geq 0, \sum_i \theta_i = 1$ ；请把一条类别序列压缩为计数 n_i ，核对 $\sum_i n_i = N$ 。

读前自检：多项分布定义。 多项计数 n 满足 $n_i \in \mathbb{N}_0$ 与 $\sum_i n_i = N$ ；请代入 $N! \prod_i \theta_i^{n_i} / \prod_i n_i!$ ，并在所有合法计数上求和核对为 1。

34.1 多项分布

问题提出。 设每次观测只落入 K 个互斥类别之一。若只记录类别序列，概率是逐次类别概率的乘积；若压缩为计数向量，还必须乘上产生相同计数的序列条数。贝叶斯推断要寻找一个定义

在单纯形上的先验，使多项似然乘入以后仍属于同一分布族。本章将说明这个先验是狄利克雷分布，并进一步给出证据与预测，而不是只停留在未归一化后验核。

读前自检：类别分布与多项分布。 类别序列概率为 $\prod_t \theta_{y_t}$ ，计数向量概率还含多项系数；请将同一计数的序列数 $N! / \prod_i n_i!$ 乘入，核对两种观测对象的支持与概率不同。

定义 34.1 (类别分布与多项分布). 给定 $\theta \in \Delta_{K-1}$ ，若

$$\Pr(Y = i \mid \theta) = \theta_i, \quad i = 1, \dots, K,$$

则称 Y 服从以 θ 为参数的类别分布。令 $Y_1, \dots, Y_N$ 在给定 θ 后条件独立同分布，并定义 $n_i = \sum_{t=1}^N \mathbf{1}\{Y_t = i\}$ 。计数向量 $\mathbf{n}$ 的支持为

$$\mathcal{C}_{N,K} = \{\mathbf{n} \in \mathbb{N}_0^K : \sum_{i=1}^K n_i = N\},$$

其概率质量函数为

$$\Pr(\mathbf{n} \mid N, \theta) = \frac{N!}{\prod_{i=1}^K n_i!} \prod_{i=1}^K \theta_i^{n_i}, \quad \mathbf{n} \in \mathcal{C}_{N,K}. \quad (34.1)$$

约定 $0^0 = 1$ 只用于表示计数为零时该因子不参与乘积。

对一条确定的有序序列 $\mathbf{y} = (y_1, \dots, y_N)$,

$$\Pr(\mathbf{y} \mid \theta) = \prod_{t=1}^N \theta_{y_t} = \prod_{i=1}^K \theta_i^{n_i}. \quad (34.2)$$

式 (34.1) 中的组合系数计算同一计数对应的序列数。它与 θ 无关，所以在推导后验参数核时可以消去；在计算计数向量的概率或边际证据时不能遗漏。图 34.2 把“序列压缩为计数”与“计数概率重新乘组合系数”画成两条不同路径。




图 34.2 多项分布把有序的独立类别试验压缩为计数向量；多项系数统计产生同一计数的不同序列数，支持集同时要求非负整数约束和总计数约束，不能把计数向量误当作概率向量

模型。 本章的基本贝叶斯模型是

$$\theta \sim \text{Dir}(\alpha), \quad Y_t \mid \theta \stackrel{\text{iid}}{\sim} \text{Categorical}(\theta), \quad t = 1, \dots, N. \quad (34.3)$$

模型对象包括类别集合、 K 维参数向量、参考单纯形、严格正超参数 α 、观测序列或经核验的计数向量。若只收到计数，必须同时收到 N 或核验 $N = \sum_i n_i$ ；不能把概率参数 θ 与随机计数 n 混为一类向量。

学习策略。先把多项似然写成各 θ_i 的幂，再选择具有同样乘积幂结构的先验。观测到 n_i 次类别 i 后，指数由 $\alpha_i - 1$ 增加到 $\alpha_i + n_i - 1$ 。这条“指数相加”规则说明分布族闭合，但完整推断还要核验三件事：先验是否可正规化，后验归一化常数是什么，以及预测与证据中哪些组合系数需要保留。

学习算法。从原始序列开始时先按类别扫描并累加计数，然后逐分量计算 $\alpha_i^{\text{post}} = \alpha_i + n_i$ 。从已验证计数开始时直接做向量加法。闭式更新没有需要等待的迭代收敛过程；后文算法仍将明确输入、退化分支、数值稳定和复杂度。图 34.3 同时区分类别/多项、Bernoulli/二项以及 Dirichlet/Beta 之间的维数关系与共轭关系。




图 34.3 六个常用分布之间同时存在特殊情形关系和共轭关系：Beta 是二维 Dirichlet，二项是二维多项，类别分布是单次多项，Bernoulli 同时是单次二项；粗箭头表示共轭先验而不是集合包含

34.2 Gamma 函数与 Beta 分布

阅读目标：通过变量变换把 Gamma 积分分解为总量和比例，并推广到单纯形。

对象：正参数 a, b 、独立 Gamma 变量及变换 $s = x + y$ 、 $t = x/(x + y)$ 。

合法条件：统一采用 shape-rate 参数化；明确变换区域并计入 Jacobian s 。

第一步：先把 $\Gamma(a)\Gamma(b)$ 写成第一象限二重积分，再作 $(x, y) = (st, s(1 - t))$ 变换。

推导目标

从 Gamma 积分建立 Beta-Gamma 恒等式，再把它推广为多元 Beta 函数；随后利用独立 Gamma 变量的和与比例证明狄利克雷密度归一化，并为矩、共轭和后验预测提供统一计算工具。

推导准备

以下 Gamma 分布统一采用 shape-rate 参数化：

$$g(x | a, b) = \frac{b^a}{\Gamma(a)} x^{a-1} e^{-bx}, \quad x > 0, a, b > 0.$$

rate 是指数项中的 b ；若把 scale 写成 b 会导致后续和分布与数值计算全部错位。变量变换证明同时记录取值域与 Jacobian。

对 $a > 0$,

$$\Gamma(a) = \int_0^{\infty} x^{a-1} e^{-x} dx. \quad (34.4)$$

分部积分给出 $\Gamma(a+1) = a\Gamma(a)$, 并由 $\Gamma(1) = 1$ 得到 $\Gamma(n) = (n-1)!$ 。二元 Beta 函数定义为

$$B(a, b) = \int_0^1 t^{a-1} (1-t)^{b-1} dt, \quad a, b > 0. \quad (34.5)$$

步骤 1: 写成二维 Gamma 积分。 考虑 $\Gamma(a)\Gamma(b)$ 并把两个正半轴积分合并为正象限积分。

步骤 2: 改用总量与比例。 令 $x = st$, $y = s(1-t)$, 其中 $s > 0$, $0 < t < 1$, Jacobian 绝对值为 s 。

步骤 3: 分离两个积分。 被积函数化为 $s^{a+b-1} e^{-s} t^{a-1} (1-t)^{b-1}$, 从而总量积分和比例积分分别成为 $\Gamma(a+b)$ 与 $B(a, b)$ 。

读前自检: Beta-Gamma 恒等式。 把 Beta-Gamma 恒等式放在“对 $a, b > 0$ ”下考察: 把 $B(a, b)$ 展开一次并检查其类型或边界, 并检查展开后的量满足定义中的域、维数或符号限制。

定理 34.1 (Beta-Gamma 恒等式) 对 $a, b > 0$,

$$B(a, b) = \frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)}. \quad (34.6)$$

读前自检: 证明: Beta-Gamma 恒等式。 Beta-Gamma 恒等式要求先确认“由 Tonelli 定理”; 请随后把 $\Gamma(a)\Gamma(b)$ 用到的关键定义展开并完成下一步变形, 用变形没有增加前提且得到证明所述结论验收。

证明。 由 Tonelli 定理, 非负被积函数允许把两个 Gamma 积分写成

$$\Gamma(a)\Gamma(b) = \int_0^{\infty} \int_0^{\infty} x^{a-1} y^{b-1} e^{-(x+y)} dx dy.$$

在正象限使用 $x = st$, $y = s(1-t)$ 。变换把区域一一映到 $s > 0$, $0 < t < 1$, 且

$$\left| \frac{\partial(x, y)}{\partial(s, t)} \right| = s.$$

因此

$$\begin{aligned} \Gamma(a)\Gamma(b) &= \int_0^{\infty} \int_0^1 s^{a+b-1} e^{-s} t^{a-1} (1-t)^{b-1} dt ds \\ &= \Gamma(a+b)B(a, b). \end{aligned}$$

由于 $\Gamma(a+b) > 0$, 两边除以该量得到式 (34.6)。

□

Beta 分布的密度为

$$f(t | a, b) = \frac{t^{a-1}(1-t)^{b-1}}{B(a, b)}, \quad 0 < t < 1.$$

多元 Beta 函数把式 (34.6) 推广为

$$B(\alpha) = \frac{\prod_{i=1}^K \Gamma(\alpha_i)}{\Gamma(\alpha_0)}, \quad \alpha_0 = \sum_{i=1}^K \alpha_i. \quad (34.7)$$

读前自检: 狄利克雷分布的矩与条件性质。 Dirichlet 参数 $\alpha_i > 0, \alpha_0 = \sum_i \alpha_i$; 请代入 $E\Theta_i = \alpha_i/\alpha_0$ 与协方差公式, 核对各均值之和为 1 且非对角协方差非正。

读前自检: 狄利克雷分布定义。 Dirichlet 密度定义在开单纯形 $\theta_i > 0, \sum_i \theta_i = 1$ 上; 请写出 $B(\alpha)^{-1} \prod_i \theta_i^{\alpha_i-1}$, 核对应 $\alpha_i > 0$ 时积分为 1。

34.3 狄利克雷分布

读题翻译 首次阅读只追踪四件事: Gamma 变量归一化后为什么得到单纯形上的分布, 均值与方差怎样解释参数, 计数怎样更新共轭后验, 以及后验怎样给出下一次预测。Jacobian 细节、任意阶矩、期望对数与边际证据属于进阶支线, 不是理解共轭更新的前置。

读前自检: 狄利克雷分布。 若 $G_i \sim \text{Gamma}(\alpha_i, 1)$ 独立并令 $S = \sum_i G_i, \Theta_i = G_i/S$; 请核对应 Θ 落在单纯形, 并由 Gamma 归一化表示确认其为 $\text{Dir}(\alpha)$ 。

定义 34.2 (狄利克雷分布). 设 $K \geq 2, \alpha_i > 0$, 并令

$$\Delta_{K-1}^\circ = \{\theta \in (0, 1)^K : \sum_{i=1}^K \theta_i = 1\}.$$

若 Θ 在单纯形上相对于坐标 $(\theta_1, \dots, \theta_{K-1})$ 的 $(K-1)$ 维 Lebesgue 测度具有密度

$$p(\theta | \alpha) = \frac{1}{B(\alpha)} \prod_{i=1}^K \theta_i^{\alpha_i-1}, \quad \theta_K = 1 - \sum_{i=1}^{K-1} \theta_i, \quad (34.8)$$

则记 $\Theta \sim \text{Dir}(\alpha)$ 。边界按其极限行为理解; 密度不是相对于整个 $\mathbb{R}^K$ 的 K 维 Lebesgue 测度定义的。

当 $K=2$ 时, $\Theta_2 = 1 - \Theta_1$, 式 (34.8) 退化为 $\Theta_1 \sim \text{Beta}(\alpha_1, \alpha_2)$ 。若某个 $\alpha_i < 1$, 密度靠近相应面时可以趋于无穷, 但只要所有 $\alpha_i > 0$ 仍可积; 把 $\alpha_i = 0$ 代入密度不再给出可正规化的狄利克雷分布。

图 34.4 说明三分类概率向量虽然写成三个分量, 却只有两个自由度。

几何面: 概率向量住在哪里?




图 34.4 三类别概率向量位于二维单纯形上，三个顶点分别代表一个类别概率为 1；内部点的重心坐标就是三个类别概率，因此 Dirichlet 分布虽写在三维坐标中，实际支撑集只有二维

定理 34.2 (Gamma 归一化构造) 设 G_i 彼此独立，且

$$G_i \sim \text{Gamma}(\alpha_i, b), \quad i = 1, \dots, K,$$

其中采用共同 rate $b > 0$ 。令 $S = \sum_i G_i$ 、 $\Theta_i = G_i/S$ 。则

$$\Theta \sim \text{Dir}(\alpha), \quad S \sim \text{Gamma}(\alpha_0, b),$$

并且 Θ 与 S 独立。

进阶证明：变量变换与 Jacobian。 以下证明用于核验归一化常数；首次阅读可先接受定理结论，直接转到均值、方差与共轭更新。

证明。 联合密度为

$$\prod_{i=1}^K \frac{b^{\alpha_i}}{\Gamma(\alpha_i)} g_i^{\alpha_i-1} e^{-bg_i}.$$

作变量变换 $g_i = s\theta_i$, $i < K$, 以及 $g_K = s(1 - \sum_{i < K} \theta_i)$ 。取值域是 $s > 0$ 与 $\theta \in \Delta_{K-1}^\circ$, Jacobian 绝对值为 s^{K-1} 。代入后联合密度分解为

$$\underbrace{\frac{b^{\alpha_0}}{\Gamma(\alpha_0)} s^{\alpha_0-1} e^{-bs}}_{\text{Gamma}(\alpha_0, b)} \underbrace{\frac{\Gamma(\alpha_0)}{\prod_i \Gamma(\alpha_i)} \prod_i \theta_i^{\alpha_i-1}}_{\text{Dir}(\alpha)}.$$

两个因子分别只含 s 与 θ 。第一个因子已经是归一化的 $\text{Gamma}(\alpha_0, b)$ 密度；原始联合密度的积分为 1，所以由 Tonelli 定理，

$$1 = \int_0^\infty f_S(s) ds \int_{\Delta_{K-1}} h(\theta) d\theta = \int_{\Delta_{K-1}} h(\theta) d\theta.$$

因此第二个因子也归一化，其常数正是 $1/B(\alpha)$ 。这先证明定义 34.2 归一化，再由联合密度分解得到所述边缘分布与独立性，避免把待证的 Dirichlet 归一化当作前提。□

图 34.5 把“独立正变量—总量—比例向量”分成三个可检验步骤；共同 rate 保证归一化比例具有所述 Dirichlet 参数。




图 34.5 独立且具有共同率参数的 Gamma 变量除以其总和后得到 Dirichlet 随机向量；总量与归一化比例相互独立，二维情形退化为 Beta 分布，这一构造同时给出可复现的 Dirichlet 抽样方法

构造面：正变量怎样变成概率向量？

读前自检：均值、方差与协方差。 对 $\Theta \sim \text{Dir}(\alpha)$ ，请计算 $E\Theta_i = \alpha_i/\alpha_0$ 与 $\text{Cov}(\Theta_i, \Theta_j)$ ，核对总和恒为 1 导致每行协方差和为 0。

命题 34.1 (均值、方差与协方差) 若 $\Theta \sim \text{Dir}(\alpha)$ ，则

$$\mathbb{E}(\Theta_i) = \frac{\alpha_i}{\alpha_0}, \quad (34.9)$$

$$\text{Var}(\Theta_i) = \frac{\alpha_i(\alpha_0 - \alpha_i)}{\alpha_0^2(\alpha_0 + 1)}, \quad (34.10)$$

$$\text{Cov}(\Theta_i, \Theta_j) = -\frac{\alpha_i \alpha_j}{\alpha_0^2(\alpha_0 + 1)}, \quad i \neq j. \quad (34.11)$$

读前自检：证明：均值、方差与协方差。 对均值、方差与协方差，条件“分别把 Θ_i 、 Θ_i^2 与 $\Theta_i \Theta_j$ 乘入密度”不可省；请把 $\Gamma(a+1) = a\Gamma(a)$ 按证明中的分解展开一层，再用各项维数闭合且需消失的交叉项确为零作检查。

证明。 分别把 Θ_i 、 Θ_i^2 与 $\Theta_i \Theta_j$ 乘入密度，所得积分都是参数增加后的多元 Beta 积分。由 $\Gamma(a+1) = a\Gamma(a)$ 得

$$\mathbb{E}\Theta_i^2 = \frac{\alpha_i(\alpha_i + 1)}{\alpha_0(\alpha_0 + 1)}, \quad \mathbb{E}(\Theta_i \Theta_j) = \frac{\alpha_i \alpha_j}{\alpha_0(\alpha_0 + 1)}.$$

分别减去均值平方与均值乘积便得到方差和协方差。 $\square$

34.4 一般矩、条件分布与期望对数

以下结果服务于变分推断和高阶性质；首次阅读可跳到第 34.5 节的共轭更新。

命题 34.2 (一般矩公式) 若 $\Theta \sim \text{Dir}(\alpha)$, 且 $r_i > -\alpha_i$, 则

$$\mathbb{E} \left[\prod_{i=1}^K \Theta_i^{r_i} \right] = \frac{B(\alpha + r)}{B(\alpha)}. \quad (34.12)$$

读前自检：证明：一般矩公式。 一般矩公式把问题限定在“条件 $r_i > -\alpha_i$ 保证新积分有限”；请把 $\alpha_i + r_i - 1$ 用到的关键定义展开并完成下一步变形，检查是否得到变形没有增加前提且得到证明所述结论。

证明。 把乘积幂移入式 (34.8)，积分中的指数变为 $\alpha_i + r_i - 1$ 。条件 $r_i > -\alpha_i$ 保证新积分有限，于是

$$\mathbb{E} \left[\prod_i \Theta_i^{r_i} \right] = \frac{1}{B(\alpha)} \int_{\Delta_{K-1}} \prod_i \theta_i^{\alpha_i + r_i - 1} d\theta = \frac{B(\alpha + r)}{B(\alpha)}.$$

$\square$

命题 34.3 (聚合与条件性质) 把 $\{1, \dots, K\}$ 分成互不相交的非空组 $A_1, \dots, A_L$ 。若 $\Theta \sim \text{Dir}(\alpha)$, 则

$$\left(\sum_{i \in A_1} \Theta_i, \dots, \sum_{i \in A_L} \Theta_i \right) \sim \text{Dir} \left(\sum_{i \in A_1} \alpha_i, \dots, \sum_{i \in A_L} \alpha_i \right).$$

因而

$$\Theta_i \sim \text{Beta}(\alpha_i, \alpha_0 - \alpha_i). \quad (34.13)$$

此外，下式取正则条件分布版本。令 $U = (\Theta_j / (1 - \Theta_i))_{j \neq i}$ ；则对 $\text{Beta}(\alpha_i, \alpha_0 - \alpha_i)$ 几乎处处的 $t \in (0, 1)$ (并可选取对每个 $0 < t < 1$ 都成立的版本)，

$$\mathcal{L}(U \mid \Theta_i = t) = \text{Dir}(\alpha_{-i}), \quad (34.14)$$

且右侧不依赖 t 。等价地，该正则条件核相对于剩余单纯形测度的密度为

$$k(t, u) = \frac{1}{B(\alpha_{-i})} \prod_{j \neq i} u_j^{\alpha_j - 1}, \quad u \in \Delta_{K-2}^\circ,$$

其中右端不含 t ；这避免把零概率事件 $\{\Theta_i = t\}$ 当作普通离散条件事件。

读前自检：证明：聚合与条件性质。 在“采用该定理中的独立 Gamma 表示”成立时处理聚合与条件性质：请把 $\frac{\Theta_j}{1 - \Theta_i}$ 用到的关键定义展开并完成下一步变形，并以而 Θ_i 只由 G_i 与该和决定，故 U 与 Θ_i 独立判定结果。

证明. 采用定理 34.2 中的独立 Gamma 表示。每一组 $H_\ell = \sum_{i \in A_\ell} G_i$ 是 shape 为 $\sum_{i \in A_\ell} \alpha_i$ 、rate 为 b 的 Gamma 变量；不同组仍独立。把 $H_1, \dots, H_L$ 除以共同总和便得到聚合结论。取两组 $\{i\}$ 与其补集得到式 (34.13)。另一方面，

$$\frac{\Theta_j}{1 - \Theta_i} = \frac{G_j}{\sum_{\ell \neq i} G_\ell}, \quad j \neq i.$$

该归一化比例服从 $\text{Dir}(\alpha_{-i})$ ，并独立于 $\sum_{\ell \neq i} G_\ell$ ；它还独立于 G_i 。而 Θ_i 只由 G_i 与该和决定，故 U 与 Θ_i 独立。于是可把无条件 Dirichlet 密度选作上述正则条件核；该核对边缘分布几乎处处唯一，并且此版本对所有 $0 < t < 1$ 都有定义。□

命题 34.4 (期望对数) 若 $\Theta \sim \text{Dir}(\alpha)$ ，则

$$\mathbb{E}[\log \Theta_i] = \psi(\alpha_i) - \psi(\alpha_0). \quad (34.15)$$

读前自检：证明：期望对数。 Dirichlet 期望对数由归一化常数求导得到；请对 $\log B(\alpha)$ 关于 α_i 求导，核对 $\mathbb{E}[\log \Theta_i] = \psi(\alpha_i) - \psi(\alpha_0)$ 。

证明. 归一化恒等式为

$$B(\alpha) = \int_{\Delta_{K-1}} \prod_j \theta_j^{\alpha_j-1} d\theta.$$

在所有 $\alpha_j > 0$ 的紧子区域内可用一个可积上界控制参数导数；对 α_i 求导并除以 $B(\alpha)$ 得到

$$\frac{\partial}{\partial \alpha_i} \log B(\alpha) = \mathbb{E}[\log \Theta_i].$$

再由式 (34.7) 求导：

$$\frac{\partial}{\partial \alpha_i} \log B(\alpha) = \psi(\alpha_i) - \psi(\alpha_0),$$

故式 (34.15) 成立。□

图 34.6 把 $\log B(\alpha)$ 的梯度与期望充分统计 $\mathbb{E} \log \Theta_i$ 对应起来。必须区分 $\mathbb{E}[\log \Theta_i]$ 与 $\log \mathbb{E}[\Theta_i]$ ；严格非退化时，凹性给出前者更小。

读前自检：共轭先验。 共轭先验要求后验仍属于同一分布族；请把多项似然核 $\prod_i \theta_i^{n_i}$ 乘 Dirichlet 先验核，合并指数并核对后验参数为 $\alpha_i + n_i$ 。

34.5 Dirichlet- 多项共轭

给定计数 $n \in \mathcal{C}_{N,K}$ ，似然与先验分别为

$$p(n | \theta) = \frac{N!}{\prod_i n_i!} \prod_i \theta_i^{n_i}, \quad (34.16)$$

$$p(\theta | \alpha) = \frac{1}{B(\alpha)} \prod_i \theta_i^{\alpha_i-1}. \quad (34.17)$$

左：Dirichlet 密度的指数族拆分

$$p(\theta | \alpha) = h(\theta) \exp\left\{\sum_k \eta_k T_k(\theta) - A(\alpha)\right\}$$

三项与对数配分函数共同确定密度

base measure
 $h(\theta) = \mathbf{1}_{\Delta^{K-1}}(\theta)$

自然参数
 $\eta_k = \alpha_k - 1$

充分统计量
 $T_k(\theta) = \log \theta_k$

右：对数配分函数给出对数矩

$$A(\alpha) = \sum_k \log \Gamma(\alpha_k) - \log \Gamma(\alpha_0)$$

$$\Downarrow$$

$$\frac{\partial A}{\partial \alpha_k}$$

$$\mathbb{E}[\log \Theta_k] = \psi(\alpha_k) - \psi(\alpha_0)$$

$$\mathbb{E}[\log \Theta_k] \neq \log \mathbb{E}[\Theta_k]$$

图 34.6 把 Dirichlet 分布写成指数族后，充分统计量是 $\log \theta_k$ ，对数配分函数对 α_k 的导数给出 $\mathbb{E}[\log \Theta_k] = \psi(\alpha_k) - \psi(\alpha_0)$ ；该对数矩不能用均值取对数替代

后验推导保留归一化常数：

$$\begin{aligned} p(\theta | n, \alpha) &= \frac{p(n | \theta) p(\theta | \alpha)}{p(n | \alpha)} \\ &\propto \prod_i \theta_i^{n_i} \prod_i \theta_i^{\alpha_i - 1} \\ &= \prod_i \theta_i^{\alpha_i + n_i - 1}. \end{aligned} \quad (34.18)$$

令 $\alpha^{\text{post}} = \alpha + n$ ，对式 (34.18) 在单纯形上积分得到 $B(\alpha^{\text{post}})$ 。

读前自检：共轭。 Dirichlet-多项共轭要求 $\alpha_i > 0$ 且计数 $n_i \geq 0$ ；请合并先验与似然的幂指数，核对 $\alpha + n$ 仍严格为正并定义合法 Dirichlet 后验。

定理 34.3 (Dirichlet-多项共轭) 在模型 (34.3) 中，若 $\alpha \in (0, \infty)^K$ 且 $n \in \mathcal{C}_{N,K}$ ，则

$$\Theta | n, \alpha \sim \text{Dir}(\alpha + n). \quad (34.19)$$

进阶旁支（边际证据）。若还需比较模型或核验计数概率，则计数向量的边际概率为

$$p(n | \alpha) = \frac{N!}{\prod_i n_i!} \frac{B(\alpha + n)}{B(\alpha)}. \quad (34.20)$$

读前自检：证明：共轭。 证明共轭时只保留关于 θ 的核；请计算 $\prod_i \theta_i^{\alpha_i - 1} \prod_i \theta_i^{n_i}$ ，核对指数为 $\alpha_i + n_i - 1$ 并由 Beta 常数归一化。

证明. 式 (34.18) 与定义 34.2 的核相同，参数为 $\alpha^{\text{post}} = \alpha + n$ 。所有 $\alpha_i^{\text{post}} > 0$ ，所以归一化积分有限且为 $B(\alpha^{\text{post}})$ ，由此得到

$$p(\theta | n, \alpha) = \frac{1}{B(\alpha + n)} \prod_i \theta_i^{\alpha_i + n_i - 1}.$$

对联合分布积分则有

$$\begin{aligned} p(\mathbf{n} | \boldsymbol{\alpha}) &= \int_{\Delta_{K-1}} p(\mathbf{n} | \boldsymbol{\theta}) p(\boldsymbol{\theta} | \boldsymbol{\alpha}) d\boldsymbol{\theta} \\ &= \frac{N!}{\prod_i n_i!} \frac{1}{B(\boldsymbol{\alpha})} \int_{\Delta_{K-1}} \prod_i \theta_i^{\alpha_i + n_i - 1} d\boldsymbol{\theta} \\ &= \frac{N!}{\prod_i n_i!} \frac{B(\boldsymbol{\alpha} + \mathbf{n})}{B(\boldsymbol{\alpha})}. \end{aligned}$$

这同时给出后验归一化分母与计数向量证据。

□

图 34.7 把先验形状、观测计数与后验形状按分量对齐；相加发生在参数上，不是把两个概率向量相加。




图 34.7 Dirichlet- 多项共轭来自先验核与多项似然核中同一组 $\log \theta_i$ 充分统计量：相乘只把指数逐分量相加，因此后验参数是 $\boldsymbol{\alpha} + \mathbf{n}$ ；保留归一化常数还可得到 Dirichlet- 多项边缘分布

共轭面：数据怎样改写参数？

读前自检：后验预测。 Dirichlet 后验为 $\text{Dir}(\boldsymbol{\alpha} + \mathbf{n})$ ；请对下一类别概率取后验期望，核对 $P(Y_{N+1} = i | \mathbf{n}, \boldsymbol{\alpha}) = (\alpha_i + n_i) / (\alpha_0 + N)$ 且总和为 1。

命题 34.5 (后验预测) 在定理 34.3 的条件下，新观测的后验预测概率为

$$\Pr(Y_{N+1} = i | \mathbf{n}, \boldsymbol{\alpha}) = \frac{\alpha_i + n_i}{\alpha_0 + N}. \quad (34.21)$$

若未来 M 次观测的计数为 $\mathbf{r} \in \mathcal{C}_{M,K}$, 则

$$\Pr(\mathbf{r} | \mathbf{n}, \boldsymbol{\alpha}) = \frac{M!}{\prod_i r_i!} \frac{B(\boldsymbol{\alpha} + \mathbf{n} + \mathbf{r})}{B(\boldsymbol{\alpha} + \mathbf{n})}. \quad (34.22)$$

读前自检：证明：后验预测。 后验预测证明用全概率公式积分 $P(Y_{N+1} = i | \boldsymbol{\theta}) = \theta_i$ ；请对 $\text{Dir}(\boldsymbol{\alpha} + \mathbf{n})$ 求 $E\theta_i$ ，核对得到 $(\alpha_i + n_i)/(\alpha_0 + N)$ 。

证明。 由全概率公式和式 (34.9),

$$\Pr(Y_{N+1} = i | \mathbf{n}, \boldsymbol{\alpha}) = \int \theta_i p(\boldsymbol{\theta} | \mathbf{n}, \boldsymbol{\alpha}) d\boldsymbol{\theta} = \frac{\alpha_i + n_i}{\alpha_0 + N}.$$

把后验 $\text{Dir}(\boldsymbol{\alpha} + \mathbf{n})$ 视作未来计数的先验，再应用式 (34.20)，得到 (34.22)。□

34.6 后验预测与例题

几何解释。 均值 $\mathbf{m} = \boldsymbol{\alpha}/\alpha_0$ 给出单纯形中的中心，而 α_0 控制围绕该中心的集中程度；二者必须分开解释。

浓度面之一：形状参数跨过一时，密度怎样改变？ 图 34.8 在同一三分类单纯形上比较全部形状分量大于、等于和小于 1 时的真实密度边界行为。




图 34.8 三元 Dirichlet 的全部形状分量从大于 1 跨到等于 1 再到小于 1 时，密度由内部集中变为均匀，并在边界发散。

读图顺序。 先比较三图共同的单纯形坐标；再看 $(2, 2, 2)$ 在三条面上趋零、 $(1, 1, 1)$ 保持常数、 $(1/2, 1/2, 1/2)$ 在三条面附近发散。由此可知，内点 MAP 公式不能跨过 $\alpha_i \leq 1$ 继续使用。

浓度面之二：固定均值时，总浓度怎样改变不确定性？ 图 34.9 固定 $\mathbf{m} = (0.5, 0.3, 0.2)$ ，只改变总浓度 α_0 。




图 34.9 固定均值 $m = (0.5, 0.3, 0.2)$ 时，增大总浓度 α_0 不移动均值，却使方差和负协方差按 $1/(\alpha_0 + 1)$ 收缩。

读图顺序。先沿左侧线性 α_0 轴核对三组 $\alpha = \alpha_0 m$ ；再沿同一线型的箭头找到右侧同心的 0.8 σ 协方差椭圆。三椭圆中心相同而面积比为 1 : 4/11 : 4/31，故变化来自浓度而非均值。

概率解释。把 α_i 看作更新规则中的先验质量，则观测类别 i 一次就把该分量加一。式 (34.21) 等价于 Pólya 瓮规则：当前类别 i 的质量为 $\alpha_i + n_i$ ，总质量为 $\alpha_0 + N$ ；抽到一个类别后把对应质量再加一。因此未来观测虽然在给定 Θ 后条件独立，积分掉 Θ 以后却具有正的同类强化，并且预测序列仍可交换。

优化解释与边界。狄利克雷后验均值是


$$\hat{\theta}_i^{\text{mean}} = \frac{\alpha_i + n_i}{\alpha_0 + N}.$$

若所有 $\alpha_i^{\text{post}} = \alpha_i + n_i > 1$ ，拉格朗日乘子法给出唯一内点众数

$$\hat{\theta}_i^{\text{MAP}} = \frac{\alpha_i^{\text{post}} - 1}{\alpha_0^{\text{post}} - K}. \quad (34.23)$$

若任一 $\alpha_i^{\text{post}} \leq 1$ ，式 (34.23) 的内点条件失效；峰值可能位于边界，某些方向的密度还会无界。“ α_i 是伪计数”适合描述后验更新与预测；“ $\alpha_i - 1$ 是众数修正”只在内点众数条件成立时使用，二者不能互换。

图形辅助。图 34.10 沿 $\alpha \rightarrow \alpha + n \rightarrow (\alpha + n)/(\alpha_0 + N)$ 展示先验、数据与预测的三段映射。图 34.3 说明二维 Dirichlet 是 Beta 分布，而不是说任意单个分量都与其他分量独立；单分量边缘为 Beta，但所有分量受和为 1 的约束而负相关。



顺序更新产生平滑与强化; 积分掉 θ 后序列可交换, 但它不是固定参数条件下的 iid 序列。

图 34.10 积分消去 θ 后, 下一类别的后验预测概率等于当前伪计数占总伪计数的比例; 观测到类别 j 只增加该类计数, 因而实现平滑并产生可顺序更新的强化预测, 但这不是固定参数下的独立同分布序列

例题 34.1 (三分类先验的矩、更新与预测). 取

$$\alpha = (2, 3, 5), \quad n = (4, 1, 0).$$

求先验与后验均值、下一类别预测、后验 MAP, 以及未来依次出现类别 1, 2 与不计顺序各出现一次的概率。

例题 34.1 解答

读题翻译 先用 Dirichlet 矩公式读取先验中心, 再把计数加到参数得到后验; 随后分别计算后验均值、内点 MAP、下一类预测, 以及“指定顺序”和“无序计数”两种未来事件。

已知与合法条件 $\alpha = (2, 3, 5)$ 、 $n = (4, 1, 0)$, 故先验总浓度为 10、样本数为 5; 更新后参数各分量都大于 1, 内点 MAP 公式适用。

为什么想到这个方法 遇到 Dirichlet-多项共轭模型, 先做 $\alpha^{\text{post}} = \alpha + n$; 均值与单步预测除以总浓度, MAP 则用 $(\alpha_i^{\text{post}} - 1) / (\alpha_0^{\text{post}} - K)$ 。

方法选择 依次求先验/后验总浓度与均值、后验 MAP, 再按 Pólya 预测逐步更新分母; 无序事件最后乘相应排列数。

推导/计算 先验与后验更新链为

$$\alpha_0 = 2 + 3 + 5 = 10, \quad \alpha^{\text{post}} = \alpha + n = (6, 4, 5), \quad \alpha_0^{\text{post}} = 15.$$

因此

$$\mathbb{E}(\Theta) = \left(\frac{1}{5}, \frac{3}{10}, \frac{1}{2}\right), \quad \mathbb{E}(\Theta | n) = \left(\frac{2}{5}, \frac{4}{15}, \frac{1}{3}\right).$$

后一向量也是下一次观测的预测概率。所有 $\alpha_i^{\text{post}} > 1$, 所以后验 MAP 为

$$\left(\frac{5}{12}, \frac{1}{4}, \frac{1}{3}\right).$$

未来依次出现类别 1、类别 2 的概率是

$$\frac{6}{15} \frac{4}{16} = \frac{1}{10};$$

若只关心未来两次中两个类别各出现一次，则还要计入两种顺序，概率为 $1/5$ 。

独立核验 后验预测分量和为 $2/5 + 4/15 + 1/3 = 1$ ；MAP 分量和为 $5/12 + 1/4 + 1/3 = 1$ 。反向顺序的概率为 $(4/15)(6/16) = 1/10$ ，与正向顺序相加确为 $1/5$ 。

结论 先验均值为 $(1/5, 3/10, 1/2)$ ；后验为 $\text{Dir}(6, 4, 5)$ ，其均值及下一次预测均为 $(2/5, 4/15, 1/3)$ ，MAP 为 $(5/12, 1/4, 1/3)$ 。未来指定顺序 $(1, 2)$ 的概率为 $1/10$ ，两个类别无序各出现一次的概率为 $1/5$ 。

伪代码。算法 34.1 是由共轭公式派生的确定性闭式流程，不是需要迭代至收敛的优化程序。它接受原始类别序列或经验证的计数向量，二者只能选择一种；算法保留完整组合系数，因此同一过程既能给后验参数，也能给计数证据与未来计数预测。

输入与输出。输入是类别数 K 、严格正先验参数 α 、原始序列 y 或计数向量 n ，以及可选的未来计数 r 。输出为经核验的 N 与 n 、后验参数 α^{post} 、完整预测向量、可选计数向量对数证据和可选未来计数对数概率。

参数含义。 K 决定向量维数； $\alpha_i > 0$ 保证先验可正规化； α_0 与 α_0^{post} 分别是先验和后验总浓度； N 是已观测样本数； $M = \sum_i r_i$ 是未来计数总数。数值实现采用 $\log \Gamma$ 累加计算 $\log B$ ，不直接形成可能上溢的阶乘与 Gamma 乘积。

初始化。先核验 $K \geq 1$ 、 α 长度为 K 且所有分量有限严格为正。若输入序列，初始化 $n_i \leftarrow 0$ ；若输入计数，复制为整数工作向量并核验非负。空序列或全零计数是合法的 $N = 0$ 情形，后验等于先验； $K = 1$ 是退化零维单纯形，唯一概率为 1。这里的 $K = 1$ 只是算法对退化情形的显式扩展，不属于定义 34.2 所规定的 $K \geq 2$ 非退化 Dirichlet 分布。

循环变量与更新顺序。序列输入时，循环变量 $t = 1, \dots, N$ ，按观测顺序核验 $y_t \in \{1, \dots, K\}$ 并执行 $n_{y_t} \leftarrow n_{y_t} + 1$ 。计数完成后，按 $i = 1, \dots, K$ 依次更新 $\alpha_i^{\text{post}} \leftarrow \alpha_i + n_i$ ，再统一计算 α_0^{post} 与预测概率 $\alpha_i^{\text{post}} / \alpha_0^{\text{post}}$ 。未来计数只用于预测，不得混入当前后验。

判断条件与停止条件。类别序列与计数向量必须恰好提供一种：仅序列时核验类别并累计计数，仅计数时核验后复制；两者都给或都不给均返回 `invalid_input`。任何维数不符、非有限超参数、非正 α_i 、非法类别、非整数或负计数、总数不一致、未来计数非法，也都以 `invalid_input` 停止并附具体诊断；停止前的部分计数不作为后验输出。两条合法分支汇合后才统一计算 N 、后验参数、证据与预测。正常情形在一次输入扫描和一次长度 K 的向量扫描后结束，没有容差型终止条件。

正确性依据与收敛条件。正确性依据是定理 34.3 和命题 34.5。计数向量对数证据由式 (34.20) 在对数域稳定求值。该闭式算法没有渐近迭代，因此“迭代收敛条件”不适用；完成有限次精确算术操作即得到理论值。浮点输出仍需满足有限性、概率非负以及预测和在舍入容差内等于 1。不收敛或不适用情形是：把它误用于非多项似然、非 Dirichlet 先验、含负权计数的数据，或要求从未知复杂后验产生样本。

训练时间复杂度。从原始序列计数并形成后验的训练时间复杂度为 $O(N + K)$ ；若已经提供合法计数，则为 $O(K)$ 。计算计数边际证据再做常数项 K 项 $\log \Gamma$ 求和，仍为 $O(K)$ 。

预测时间复杂度与空间复杂度。形成全部 K 类预测概率的预测时间复杂度为 $O(K)$ ；在已保存 $\alpha_i^{\text{post}}, \alpha_0^{\text{post}}$ 后查询单个类别是 $O(1)$ 。计算一个长度 K 的未来计数概率为 $O(K)$ 。工作空间复杂度为 $O(K)$ ；若允许原地覆盖调用方计数可减少常数，但不能破坏原始计数输入。

读前自检：闭式更新与后验预测。 闭式更新与后验预测输入“类别数 K 、严格正 Dirichlet 参数、恰好一种观测表示及可选总数/未来计数”，条件“ K 为正整数，参数长度为 K 且有限严格为正，类别序列与计数向量恰好提供一种”；请执行一轮“后验/预测/特殊函数结果全部通过后才原子提交完整输出”，以“所有有限扫描和输出一致性检查完成时返回 `completed`，没有渐近收敛判定”核对停止证书。

算法 34.1: Dirichlet- 多项闭式更新与后验预测

输入: $K \geq 1$ ；严格正 α ；二选一的类别序列 y 或计数 n ；可选总数 N_{in} 与未来计数 r
输出: 最后合法工作状态及完整后验/预测；实际处理量 w ；`status` 与最终诊断

```

1  $w \leftarrow 0$ 
2 核验  $K$  是正整数、 $\alpha$  长度为  $K$  且分量有限严格为正；失败则返回 invalid_input 及字段诊断
3 若 仅提供类别序列  $y$  则
4     初始化  $n_i \leftarrow 0, i = 1, \dots, K$ 
5     对  $t \leftarrow 1, \dots, |y|$  执行
6          $w \leftarrow w + 1$ 
7         若  $y_t \notin \{1, \dots, K\}$ ，则返回 invalid_input、诊断 invalid_class(t) 且不返回部分后验
8          $n_{y_t} \leftarrow n_{y_t} + 1$ 
9     结束
10 否则若 仅提供计数向量  $n$  则
11      $w \leftarrow w + K$ 
12     若其长度不是  $K$ ，则返回最后合法空工作状态、invalid_input 及 length_mismatch 诊断
13     若任一分量不是非负整数，则返回最后合法空工作状态、invalid_input 及 invalid_count(i) 诊断；
        否则复制为工作向量
14 否则
15     返回 invalid_input，并诊断“类别序列与计数向量必须恰好提供一种”
16 结束
17 令  $N \leftarrow \sum_i n_i$ ；此后两种输入共用同一后验、证据与预测分支
18 若提供  $N_{\text{in}}$  但  $N_{\text{in}} \neq N$ ，则返回 invalid_input 及 total_mismatch 诊断
19 对  $i \leftarrow 1, \dots, K$  执行
20      $w \leftarrow w + 1$ 
21     在临时向量中令  $\alpha_i^+ \leftarrow \alpha_i + n_i$ 
22 结束
23 令  $\alpha_0^+ = \sum_i \alpha_i^+, p_i^+ = \alpha_i^+ / \alpha_0^+$ 
24 用  $\log \Gamma$  计算临时计数对数证据  $\log N! - \sum_i \log n_i! + \log B(\alpha^+) - \log B(\alpha)$ 
25 若提供  $r$ ，逐项核验并增加  $w$ ；非法时返回计数工作状态、invalid_input 及未来计数位置诊断；否则在
    对数域形成临时未来概率
26 判断全部临时输出有限、预测非负且在容差内为 1；失败则返回计数工作状态、numerical_failure 及
    特殊函数/预测诊断
27 原子提交  $(\alpha^{\text{post}}, \alpha_0^{\text{post}}, p_{\text{pred}})$  及可选对数概率；返回完整结果、 $w, \text{completed}$  及归一化/退化最终诊断
```

算法实现说明：核心流程跟踪先验参数加计数、得到后验、读取均值与后验预测；特殊函数、空计数和边界状态属于稳健实现细节 完整 C1-C14 契约

复杂度假设与实现口径

类别索引访问、浮点加法和一次 $\log \Gamma$ 求值按固定精度视为 $O(1)$ ；输入是稠密长度 K 向量。若使用任意精度算术，单次特殊函数成本随目标精度增长，不能再把上述界理解为位复杂度。

适用条件。该方法适合有限互斥类别、固定概率向量、条件独立类别观测和 Dirichlet 先验。它也适合作为更大概率模型中的局部共轭更新。若概率随样本协变量变化、类别并非互斥、观测带非整数权重或先验不是 Dirichlet，必须重新推导后验，不能机械相加。

局限性。共轭性提高可计算性，却不自动表达类别间的任意相关结构；单个 Dirichlet 只能给出由和约束产生的负协方差。固定 α 也可能过强地平滑稀有类别。层次 Dirichlet、混合分布或协变量模型可以扩大表达能力，但相应超参数推断通常不再保持本章全部闭式性质。

常见错误。不得把 $B(\alpha)$ 与其倒数互换；不得在计数证据中丢掉多项组合系数；不得允许 $\alpha_i = 0$ 后仍声称先验可正规范化；不得把 α_0 和均值向量混成同一作用；不得写 $\mathbb{E} \log \Theta_i = \log \mathbb{E} \Theta_i$ ；不得在 $\alpha_i^{\text{post}} \leq 1$ 时套用内点 MAP 公式；多步预测必须在每一步更新分子和分母。

易混淆概念对比。

对比	本章对象	容易误写的对象
有序序列与计数	序列概率无组合系数	计数概率必须乘序列条数
概率向量与计数向量	$\theta \in \Delta_{K-1}$	$n \in \mathbb{N}_0^K$ 且和为 N
均值与浓度	α/α_0 控制中心	α_0 控制集中程度
先验质量与众数修正	更新使用 α_i	内点 MAP 使用 $\alpha_i - 1$
边缘与独立	单分量边缘是 Beta	分量并不相互独立
单步与多步预测	每次观测后更新计数	重复乘同一单步概率通常错误

例题 34.2 (Beta 特例与 Bernoulli 更新). 令 $\Theta \sim \text{Beta}(2, 3)$ 。先核验归一化常数、均值与方差；随后观察四次 Bernoulli 试验，其中三次成功、一次失败，求后验和下一次成功概率。

例题 34.2 解答

读题翻译 先核验 $\text{Beta}(2, 3)$ 的归一化并求先验矩，再把三次成功和一次失败分别加入两个形状参数，读取后验及下一次成功的后验预测。

已知与合法条件 先验形状参数为 $a = 2, b = 3$ ；Bernoulli 数据的成功、失败计数为 $s = 3, f = 1$ ，四个量均满足共轭更新的合法条件。

为什么想到这个方法 Beta 归一化用 $B(a, b)$ ，均值和方差用 $a/(a+b)$ 与 $ab/[(a+b)^2(a+b+1)]$ ；Bernoulli 计数使后验变为 $\text{Beta}(a + s, b + f)$ 。

方法选择 先由 Gamma 函数比值计算 $B(2, 3)$ 和先验矩，再更新为 $(5, 4)$ ，最后用后验均值给出下一次成功概率。

推导/计算 由式 (34.6)，

$$B(2, 3) = \frac{\Gamma(2)\Gamma(3)}{\Gamma(5)} = \frac{1!2!}{4!} = \frac{1}{12}.$$

所以密度为 $12\theta(1-\theta)^2$ 。均值和方差分别是

$$\mathbb{E}\Theta = \frac{2}{5}, \quad \text{Var}(\Theta) = \frac{2 \cdot 3}{5^2(5+1)} = \frac{1}{25}.$$

三次成功与一次失败把两个参数分别加 3 与 1, 故

$$\Theta | D \sim \text{Beta}(5, 4), \quad \Pr(Y_{\text{new}} = 1 | D) = \frac{5}{9}.$$

独立核验 密度积分为 $12B(2, 3) = 1$; 先验方差 $1/25 > 0$, 且后验预测 $5/9$ 恰等于 $\text{Beta}(5, 4)$ 的后验均值。

结论 先验密度为 $12\theta(1-\theta)^2$, 均值 $2/5$ 、方差 $1/25$; 观测后 $\Theta | D \sim \text{Beta}(5, 4)$, 下一次成功概率为 $5/9$ 。

例题 34.3 (Gamma 归一化的确定性测试). 给定正值 $(g_1, g_2, g_3) = (2, 3, 5)$ 。检验归一化与支持处理, 给出 θ 和总量 s ; 说明该确定性输入能检验什么、不能证明什么。

例题 34.3 解答

读题翻译 把三个给定正数视为 Gamma 归一化接口的一次确定性输入: 先求总量 s , 再逐分量除以 s 得到单纯形向量; 同时区分“数值接口测试”与“随机生成分布证明”。

已知与合法条件 $(g_1, g_2, g_3) = (2, 3, 5)$ 均严格为正, 故 $s = \sum_i g_i$ 严格为正, 归一化除法有定义。

为什么想到这个方法 对正 Gamma 变量接口使用 $s = \sum_i g_i$ 与 $\theta_i = g_i/s$; 确定性测试应核对正支持、分量和及反向重构, 而分布结论还需要独立 Gamma 随机样本的生成假设。

方法选择 计算 s 和三个比值, 检查 θ 落在开单纯形并用 $s\theta$ 重构输入, 最后界定该固定输入能验证的范围。

推导/计算 总量 $s = 2 + 3 + 5 = 10$, 归一化结果为

$$\theta = \left(\frac{1}{5}, \frac{3}{10}, \frac{1}{2}\right).$$

支持与归一化检查为

$$g_i > 0, \quad s = \sum_{i=1}^3 g_i = 10 > 0, \quad \theta_i = \frac{g_i}{s} > 0, \quad \sum_i \theta_i = 1.$$

独立核验 反向重构满足 $s\theta = (2, 3, 5) = g$, 且 $1/5 + 3/10 + 1/2 = 1$; 三分量都严格为正。

结论 $s = 10$ 且 $\theta = (1/5, 3/10, 1/2)$ 。该固定输入可检验求和、除法、输出维数、正支持与归一化, 但不是带随机源记录的独立 Gamma 抽样, 不能单独证明抽样器生成 Dirichlet 分布, 也不能估计其矩。

例题 34.4 (计数证据与序列证据). 取 $\alpha = (1, 1, 1)$ 、 $n = (2, 1, 1)$ 。求后验、下一次预测、该计数向量的边际概率, 以及一条指定顺序为 $(1, 1, 2, 3)$ 的序列边际概率。

例题 34.4 解答

读题翻译 同一组观测先做 Dirichlet 共轭更新并求下一类预测; 再分别计算“只给计数向量”的边际证据和“给定一条具体顺序”的序列边际, 二者只差序列排列数。

已知与合法条件 $\alpha = (1, 1, 1)$ 、 $n = (2, 1, 1)$, 样本总数 $N = 4$, 计数向量的多项系数为 $4!/(2!1!1!) = 12$ 。

为什么想到这个方法 后验参数等于先验参数加计数, 单步预测取后验参数占总浓度之比; 指定序列证据是 Beta 函数比值, 计数证据还须乘多项组合系数。

方法选择 先求后验与预测, 再计算 $B(\alpha)$ 和 $B(\alpha + n)$; 最后分别保留或加入组合系数, 比较两种证据。

推导/计算 后验为 $\text{Dir}(3, 2, 2)$, 预测为 $(3/7, 2/7, 2/7)$ 。计算

$$B(1, 1, 1) = \frac{1}{2}, \quad B(3, 2, 2) = \frac{\Gamma(3)\Gamma(2)\Gamma(2)}{\Gamma(7)} = \frac{1}{360}.$$

计数组合系数为 $4!/(2!1!1!) = 12$, 所以

$$p(n | \alpha) = 12 \frac{1/360}{1/2} = \frac{1}{15}.$$

指定有序序列没有组合系数, 其边际概率为

$$\frac{B(3, 2, 2)}{B(1, 1, 1)} = \frac{1}{180}.$$

独立核验 预测分量和为 $(3 + 2 + 2)/7 = 1$; 十二条具有相同计数的序列概率相加正好得到 $12(1/180) = 1/15$, 与计数证据一致。

结论 后验为 $\text{Dir}(3, 2, 2)$, 下一次预测为 $(3/7, 2/7, 2/7)$; 计数向量边际证据为 $1/15$, 指定顺序 $(1, 1, 2, 3)$ 的序列边际为 $1/180$, 二者相差组合系数 12。

本章共 10 道练习。每道题干后立即给出同号解析; 长解析可自然跨页, 续页标题保留题号。

【原书练习整理】

练习 34.1. 设 $\Theta \sim \text{Dir}(\alpha)$ 。从归一化积分或一般矩公式推导 $\mathbb{E}(\Theta_i) = \alpha_i/\alpha_0$, 不得只引用结论; 同时指出交换求导或积分所需的参数条件。

练习 34.1 解析

在所有 $\alpha_j > 0$ 时, 取 $\mathbf{r} = \mathbf{e}_i$ 代入式 (34.12):

$$\mathbb{E}\Theta_i = \frac{B(\alpha_1, \dots, \alpha_i + 1, \dots, \alpha_K)}{B(\alpha)}.$$

利用 $\Gamma(\alpha_i + 1) = \alpha_i \Gamma(\alpha_i)$ 和 $\Gamma(\alpha_0 + 1) = \alpha_0 \Gamma(\alpha_0)$, 比值化为

$$\frac{B(\alpha + \mathbf{e}_i)}{B(\alpha)} = \frac{\Gamma(\alpha_i + 1)}{\Gamma(\alpha_i)} \frac{\Gamma(\alpha_0)}{\Gamma(\alpha_0 + 1)} = \frac{\alpha_i}{\alpha_0}.$$

若直接从积分计算, 把 $\theta_i \prod_j \theta_j^{\alpha_j - 1}$ 合并为新 Dirichlet 核即可得到同一比值。参数严格为正保证原密度与提高一个指数后的密度都可积; 若用参数求导法, 还要在正参数的紧子区域上给出可积控制函数。

练习 34.2. 四次独立类别观测取三类, $\theta = (1/2, 1/3, 1/6)$, 计数为 $(2, 1, 1)$ 。求该计数向量的概率和指定序列 $(1, 1, 2, 3)$ 的概率, 并解释二者的倍数关系。

练习 34.2 解析

组合系数是

$$\frac{4!}{2!1!1!} = 12.$$

指定序列的概率为

$$\left(\frac{1}{2}\right)^2 \frac{1}{3} \frac{1}{6} = \frac{1}{72}.$$

计数向量概率为 $12/72 = 1/6$ 。倍数 12 正是具有两个类别 1、一个类别 2 和一个类别 3 的不同序列数。

练习 34.3. 从二维 Gamma 积分完成 Beta-Gamma 变量变换证明, 并计算 $B(2, 3)$ 。随后核验 Beta(2, 3) 的均值 $2/5$ 与方差 $1/25$ 。

练习 34.3 解析

令 $x = st$ 、 $y = s(1 - t)$, 取值域为 $s > 0$ 、 $0 < t < 1$, Jacobian 为 s 。于是

$$\Gamma(a)\Gamma(b) = \int_0^\infty s^{a+b-1} e^{-s} ds \int_0^1 t^{a-1} (1-t)^{b-1} dt = \Gamma(a+b)B(a, b).$$

对 $a = 2, b = 3$, $B(2, 3) = 1!2!/4! = 1/12$ 。Beta 矩公式给出

$$\mathbb{E}\Theta = \frac{2}{2+3} = \frac{2}{5}, \quad \text{Var}(\Theta) = \frac{2 \cdot 3}{(2+3)^2(2+3+1)} = \frac{1}{25}.$$

练习 34.4. 设 G_i 独立且 $G_i \sim \text{Gamma}(\alpha_i, b)$ 。写出 $(G_1, \dots, G_K) \mapsto (S, \Theta_1, \dots, \Theta_{K-1})$ 的取值域和 Jacobian, 并证明 S 与 Θ 独立。若各分量 rate 不同, 指出原证明在哪一步不再分离。

练习 34.4 解析

设 $K \geq 2$ 、 $\alpha_i > 0$ 、 $b > 0$, 且 $G_1, \dots, G_K$ 相互独立并满足 $G_i \sim \text{Gamma}(\alpha_i, b)$ 。记 $\alpha_0 = \sum_i \alpha_i$, 其完整联合密度为

$$f_G(g) = \frac{b^{\alpha_0}}{\prod_{i=1}^K \Gamma(\alpha_i)} \left(\prod_{i=1}^K g_i^{\alpha_i-1} \right) e^{-b \sum_i g_i} \mathbf{1}_{(0, \infty)^K}(g).$$

令 $S = \sum_i G_i$ 、 $\Theta_i = G_i/S$ 。从 $(s, \theta_1, \dots, \theta_{K-1})$ 到 $(g_1, \dots, g_K)$ 的变换为 $g_i = s\theta_i$, 其中 $s > 0$ 、 $\theta_i > 0$ 且 $\sum_{i < K} \theta_i < 1$, 并置 $\theta_K = 1 - \sum_{i < K} \theta_i$; Jacobian 绝对值为 s^{K-1} 。共同 rate b 使指数项变为

$$\exp\left(-b \sum_i s\theta_i\right) = e^{-bs},$$

而幂次与 Jacobian 合并为 $s^{\alpha_0-1} \prod_i \theta_i^{\alpha_i-1}$ 。所以变换后的联合密度逐因子分解为

$$\underbrace{\frac{b^{\alpha_0}}{\Gamma(\alpha_0)} s^{\alpha_0-1} e^{-bs}}_{\text{Gamma}(\alpha_0, b) \text{ 密度}} \underbrace{\frac{\Gamma(\alpha_0)}{\prod_i \Gamma(\alpha_i)} \prod_{i=1}^K \theta_i^{\alpha_i-1}}_{\text{Dir}(\alpha) \text{ 密度}}.$$

两因子分别只依赖 s 与 θ , 且各自积分为 1, 故 $S \sim \text{Gamma}(\alpha_0, b)$ 、 $\Theta \sim \text{Dir}(\alpha)$, 并且二者独立。

若 rate 为 b_i , 指数项成为

$$\exp\left(-s \sum_i b_i \theta_i\right),$$

同时含 s 和 θ , 不再能按上述方式分离。归一化比例一般也不再服从参数仅为 α 的 Dirichlet 分布。

练习 34.5. 对 $\Theta \sim \text{Dir}(2, 3, 5)$, 计算均值向量、三个方差和三种不同分量协方差; 核验协方差矩阵每行元素之和为 0。

练习 34.5 解析

$\alpha_0 = 10$, 所以

$$\mathbb{E}\Theta = \left(\frac{1}{5}, \frac{3}{10}, \frac{1}{2}\right).$$

三个方差为

$$\text{Var}(\Theta_1) = \frac{4}{275}, \quad \text{Var}(\Theta_2) = \frac{21}{1100}, \quad \text{Var}(\Theta_3) = \frac{1}{44}.$$

三个协方差为

$$\text{Cov}(\Theta_1, \Theta_2) = -\frac{3}{550}, \quad \text{Cov}(\Theta_1, \Theta_3) = -\frac{1}{110}, \quad \text{Cov}(\Theta_2, \Theta_3) = -\frac{3}{220}.$$

第一行之和为 $4/275 - 3/550 - 1/110 = 0$; 第二行之和为 $-3/550 + 21/1100 - 3/220 = 0$; 第三行之和为 $-1/110 - 3/220 + 1/44 = 0$ 。这是 $\sum_i \Theta_i = 1$ 导致 $\text{Cov}(\Theta_i, \sum_j \Theta_j) = 0$ 的矩阵表现。

练习 34.6. 仍取 $\text{Dir}(2, 3, 5)$ 。求 Θ_1 的边缘分布；给定 $\Theta_1 = 1/4$ 时，求归一化剩余比例的条件分布，以及 $\mathbb{E}(\Theta_2 | \Theta_1 = 1/4)$ 和 $\mathbb{E}(\Theta_3 | \Theta_1 = 1/4)$ 。解释为什么“给定其余全部分量后 Θ_1 仍为 Beta”是错误说法。

练习 34.6 解析

由聚合性质，

$$\Theta_1 \sim \text{Beta}(2, 8).$$

给定 $\Theta_1 = 1/4$ 后，

$$\left(\frac{\Theta_2}{3/4}, \frac{\Theta_3}{3/4}\right) \sim \text{Dir}(3, 5).$$

因此

$$\mathbb{E}(\Theta_2 | \Theta_1 = 1/4) = \frac{3}{4} \frac{3}{8} = \frac{9}{32}, \quad \mathbb{E}(\Theta_3 | \Theta_1 = 1/4) = \frac{3}{4} \frac{5}{8} = \frac{15}{32}.$$

若给定其余全部 $K-1$ 个分量，则 $\Theta_1 = 1 - \sum_{j \neq 1} \Theta_j$ 已经确定，条件分布退化为点质量；Beta 结论针对单分量边缘，或针对“固定一个分量后归一化剩余比例”的条件分布。

练习 34.7. 利用 $\psi(n) = H_{n-1} - \gamma$ ，求 $\text{Dir}(2, 3, 5)$ 下 $\mathbb{E} \log \Theta_1$ 与 $\mathbb{E} \log \Theta_3$ 。用 Jensen 不等式比较 $\mathbb{E} \log \Theta_1$ 和 $\log \mathbb{E} \Theta_1$ 。

练习 34.7 解析

对 $\alpha_0 = 10$,

$$\mathbb{E} \log \Theta_1 = \psi(2) - \psi(10) = 1 - H_9,$$

$$\mathbb{E} \log \Theta_3 = \psi(5) - \psi(10) = H_4 - H_9.$$

由于 Θ_1 非退化且 $\log$ 严格凹，

$$\mathbb{E} \log \Theta_1 < \log \mathbb{E} \Theta_1 = \log \frac{1}{5}.$$

这也说明用均值取对数替代期望对数会系统性偏大。

练习 34.8. 先验为 $\text{Dir}(1, 1, 1)$ ，观测计数为 $(2, 1, 1)$ 。求后验、预测、计数向量边际概率和一条固定顺序序列的边际概率；指出组合系数在哪个答案中出现。

练习 34.8 解析

后验更新与预测为

$$\alpha^{\text{post}} = (1, 1, 1) + (2, 1, 1) = (3, 2, 2), \quad p_{\text{pred}} = \left(\frac{3}{7}, \frac{2}{7}, \frac{2}{7}\right).$$

由 $B(1, 1, 1) = 1/2$ 、 $B(3, 2, 2) = 1/360$ ，固定顺序序列的边际概率为

$$\frac{B(3, 2, 2)}{B(1, 1, 1)} = \frac{1}{180}.$$

练习 34.8 解析 (续)

计数向量还要乘组合系数:

$$p(\mathbf{n}) = \frac{4!}{2!1!1!} \frac{B(3, 2, 2)}{B(1, 1, 1)} = 12 \cdot \frac{1}{180} = \frac{1}{15}.$$

组合系数只出现在计数向量答案中。

练习 34.9. 先验参数为 $(2, 3, 5)$, 当前计数为 $(4, 1, 0)$ 。求未来依次出现类别 1、类别 2 的概率, 以及未来两次中两个类别各出现一次而不计顺序的概率。说明为何不能把当前单步预测的两个分量直接相乘。

练习 34.9 解析

当前后验参数是 $(6, 4, 5)$, 总和为 15。指定顺序 1 后 2 的概率为

$$\frac{6}{15} \frac{4}{16} = \frac{1}{10}.$$

反序 2 后 1 的概率是 $\frac{4}{15} \frac{6}{16} = 1/10$, 所以

$$P(\{1, 2\} \text{各一次}) = \frac{6}{15} \frac{4}{16} + \frac{4}{15} \frac{6}{16} = \frac{1}{5}.$$

不能直接把当前预测分量 $6/15$ 与 $4/15$ 相乘, 因为第一次未来观测后总质量由 15 变为 16, 对应类别的分子也可能更新。

练习 34.10. 后验参数为 $\alpha^{\text{post}} = (1/2, 3, 3/2)$ 。求后验均值; 判断式 (34.23) 能否使用, 并描述靠近 $\theta_1 = 0$ 的密度行为。再比较 $\text{Dir}(2, 3, 5)$ 与 $\text{Dir}(20, 30, 50)$ 的均值和方差, 说明“伪计数”“众数修正”“浓度”三种解释的边界。

练习 34.10 解析

$\alpha_0^{\text{post}} = 5$, 后验均值为

$$\left(\frac{1}{10}, \frac{3}{5}, \frac{3}{10}\right).$$

因为 $\alpha_1^{\text{post}} = 1/2 \leq 1$, 内点条件不成立, 式 (34.23) 不能使用。密度含因子 $\theta_1^{-1/2}$, 在保持其他分量为正并令 $\theta_1 \downarrow 0$ 时趋于无穷; 峰值位于边界意义下。

$\text{Dir}(2, 3, 5)$ 与 $\text{Dir}(20, 30, 50)$ 均值同为 $(1/5, 3/10, 1/2)$, 但后者总浓度从 10 增至 100, 方差按 $1/(\alpha_0 + 1)$ 型因子显著缩小。更新和预测中的先验质量是 α_i ; 内点众数的指数修正是 $\alpha_i - 1$; 总浓度是 α_0 。这三种解释作用于不同公式。

$$\text{Var}(\Theta_i) = \frac{\mu_i(1 - \mu_i)}{\alpha_0 + 1}, \quad \frac{\text{Var}_{(20,30,50)}(\Theta_i)}{\text{Var}_{(2,3,5)}(\Theta_i)} = \frac{11}{101}.$$

读前自检: 本章结论与下一步。 Dirichlet 章末把单纯形先验、类别计数与共轭预测串成 $\alpha \rightarrow \alpha + n$; 请核对后验参数仍严格为正, 并对全部类别求和和预测式 $(\alpha_i + n_i)/(\alpha_0 + N)$, 确认等于 1。

本章结论与下一步

核心结论：Dirichlet 是单纯形上的分布；形状向量控制中心与浓度，类别计数产生加法式后验更新。

关键依据：同率独立 Gamma 变量经总量—比例变换分解出 Gamma 与 Dirichlet 密度，Jacobian 为 s^{K-1} ；多元 Beta 比值给出矩与证据。

可执行自检：闭式算法累计计数，计算 $\alpha^{\text{post}} = \alpha + n$ ，再输出后验预测。

适用边界：适用于有限类别与严格正形状参数；序列概率和计数概率的组合系数不能混用，MAP 还需内点条件。

下一步：下一章把两组 Dirichlet 积分应用到 LDA，形成折叠联合与留一 Gibbs 条件。

1. 能否分别写出类别序列与计数向量的概率，定位组合系数，并用 Beta-Gamma 变量变换的区域和 Jacobian 得到多元归一化常数？
2. 能否说明 Dirichlet 密度的参考测度、可正规化条件和边界行为，再由一般矩公式核验均值、方差、协方差及行和为零？
3. 能否区分 Beta 边缘、归一化剩余比例条件分布和退化条件分布，并由 $\log B(\alpha)$ 求导得到期望对数而不以均值对数替代？
4. 能否逐行推导后验与两种证据，正确处理组合系数，并执行算法 34.1 的空样本、非法类别、 $K = 1$ 和对数域分支？
5. 能否按 Pólya 更新计算多步预测，并判断 MAP 内点条件，分别解释 α_i 、 $\alpha_i - 1$ 和 α_0 ？

第 35 章 潜在狄利克雷分配

读前自检：本章地图：潜在狄利克雷分配。 潜在狄利克雷分配章地图把“词袋语料 → LDA 生成模型 → 折叠 Gibbs/变分推断 → 留出评价”作为主线；请为其中首条箭头补出必要条件，并检查终点仍落在本章声明的输出域。

读前自检：本章可检验学习目标。 潜在狄利克雷分配学习目标固定核验“把语料、文档、主题和单词写成维数明确的随机变量，并从概率图读出完整联合分布”；请实际完成“把语料、文档、主题和单词写成维数明确的随机变量，并从概率图读出完整联合分布”，并用“中间结果逐项包含首目标“把语料、文档、主题和单词写成维数明确的随机变量，并从概率图读出完整联合分布”声明的对象、条件与结论”判定通过或失败。

读前自检：最短先修。 LDA 最短先修要求能归一化 Dirichlet- 类别模型并区分 KL、Jensen 与 Gibbs 条件更新；请对 K 维正参数 α 写出 $E\theta_k = \alpha_k/\alpha_0$ ，核对各主题权重和为 1。

读前自检：先修自检。 潜在狄利克雷分配先修自检固定核验“能否把 $p(a, b, c) = p(a)p(b | a)p(c | b)$ 画成有向图，并从图中说明 $c \perp a | b$ ”；请把 $p(a, b, c) = p(a)p(b | a)p(c | b)$ 画成有向图，并从图中说明 $c \perp a | b$ 并写出中间结果，再按“ $p(a, b, c) = p(a)p(b | a)p(c | b)$ 的计算或证明结果满足首项所列等式、定义域或判断”明确判为通过或失败。

读前自检：依赖路线。 潜在狄利克雷分配把“所引章节的 Dirichlet- 多项共轭与所引章节的 Gibbs 坐标更新 → 本章两条推断路线”接到“有限类别与独热编码 → 文档、主题和单词变量”；请用 → 补全这一步的等式或判据，再检查两端维数、支持或对象类型。

本章地图

核心问题：怎样从概率图完整推导 LDA 联合分布，并合法消元或构造变分近似？

可检验学习目标：

- 把语料、文档、主题和单词写成维数明确的随机变量，并从概率图读出完整联合分布；
- 解释文档 - 主题分布与主题 - 词分布的两层混合，以及词袋交换性所允许和不允许的结论；
- 由 Dirichlet- 多项积分逐步推出折叠联合分布、留一计数和 Gibbs 满条件分布；
- 从 KL-ELBO 恒等式推出平均场坐标更新、主题 - 词参数更新和超参数 Newton 更新；
- 按严格输入输出契约复现文本生成、折叠 Gibbs、通用变分 EM、局部变分推断和完整变分 EM；
- 用留出似然、困惑度、稳定性和资源复杂度评价主题模型，而不把训练目标误当成泛化能力。

最短先修：本章直接使用离散随机变量与条件独立、Bayes 公式、KL 散度、Jensen 不等式、Dirichlet- 多项共轭、Gibbs 抽样、EM 算法和 Newton 法。尤其需要熟悉第 34 章的结论：Dirichlet 先验与类别计数相乘后，后验参数按分量加上计数；这一通用共轭结论在本章只作局部调用，不重复证明。读者还应能区分概率向量、计数向量和独热向量。

依赖路线：第 34 章的 Dirichlet- 多项共轭与第 33 章的 Gibbs 坐标更新 → 本章两条推断路线；有限类别与独热编码 → 文档、主题和单词变量；Dirichlet- 多项共轭 → 积分消去 θ, ϕ → 折叠 Gibbs；KL 散

度与 Jensen 不等式 → ELBO → 平均场坐标更新；EM 与 Newton 法 → 全局主题参数和超参数学习；留出预测 → 困惑度与模型比较。图 35.1 只画这些直接依赖，不把诊断性远缘关系冒充前置课程。

完成标准与返回：先掌握第 34 章的多元 Beta 积分和第 33 章的坐标 Gibbs，再进入生成过程。




图 35.1 本章从共享的文档-主题-单词条件结构分出两个模型目标：完整 Bayes LDA 由折叠 Gibbs 推断，点参数 LDA 变体由平均场变分 EM 估计；箭头表示学习依赖，不表示两个后验相同

数据方向桥：LDA 语料仍按列放文档

若把词元压缩成计数矩阵，本章采用 $X_{\text{wd}} \in \mathbb{N}_0^{V \times M}$ ：词表项在行，文档在列。与全书默认行样本表示的关系是

$$X_{\text{doc,row}} = X_{\text{wd}}^T \in \mathbb{N}_0^{M \times V}.$$

例如 $V = 1000, M = 200$ 时，两种维数为 1000×200 与 200×1000 。LDA 内部的 θ_m 仍对应一篇文档， φ_k 仍对应一个主题；矩阵转置不交换这两个概率对象的角色。

读前自检：本章符号表。 潜在狄利克雷分配符号表规定 M, V, K, N_m, I 的类型或范围；请把 M, V, K 代入紧随其后的定义关系，逐项核对输入形状、输出形状与取值域。

本章符号表

符号	对象与读法	维数/范围	角色
M, V, K	文档数、词表大小、主题数	正整数	三个基本规模参数
N_m, I	第 m 篇长度、总词元数	$I = \sum_m N_m$	计算复杂度的样本规模
w_{mn}	第 m 篇第 n 个词元	$\{1, \dots, V\}$	观测变量
z_{mn}	词元的主题指派	$\{1, \dots, K\}$	离散隐变量
θ_m	文档-主题概率向量	Δ^{K-1}	文档级隐变量
φ_k	主题-词概率向量	Δ^{V-1}	主题级参数或隐变量
α	文档主题先验	$\mathbb{R}_{>0}^K$	Dirichlet 超参数
β	主题词先验	$\mathbb{R}_{>0}^V$	Dirichlet 超参数

n_{mk}, n_{kv}	文档 - 主题、主题 - 词计数	非负整数	折叠推断充分统计量
γ_m	$q(\theta_m)$ 参数	$\mathbb{R}_{>0}^K$	局部变分参数
η_{mn}	$q(z_{mn})$ 参数	Δ^{K-1}	主题责任度
ψ, ψ'	digamma、trigamma	标量函数	Dirichlet 对数矩与 Newton 步

为使低维数值例的式面更紧凑，下文在等号右侧直接列出全部坐标时采用如下显式排版约定： $\alpha, \beta, \theta, \varphi, \eta, \gamma$ 表示向量，而带下标的 α_k, β_v 等表示分量；括号中的完整数列按符号表给出的维数解释为对应向量。该约定不改变对象的维数、归一化约束或推导含义。

读前自检：潜在狄利克雷分配。 LDA 把文档表示成主题混合 θ_m ，再给每个词位置分配主题 z_{mn} 并生成 w_{mn} ；请沿“文档 - 主题混合 - 位置主题 - 单词”写出一项条件概率，核对“分配”指位置级主题指派。

读前自检：LDA 生成过程与概率图。 LDA 生成过程先采样 $\varphi_k \sim \text{Dir}(\beta)$ 和 $\theta_m \sim \text{Dir}(\alpha)$ ，再采样 z_{mn}, w_{mn} ；请按箭头顺序写出联合分布的四类因子并核对板内索引。

读前自检：LDA 文档—主题—词模型。 LDA 文档 - 主题 - 词模型满足 $P(w_{mn} = v \mid \theta_m, \varphi) = \sum_k \theta_{mk} \varphi_{kv}$ ；请对 v 求和，核对主题混合与主题词分布均归一时得到 1。

35.1 文档—主题—单词关系

问题提出。 一个文档通常不只谈一个主题，一个主题也不会只使用一个词。若直接给每篇文档估计一个 V 维词频向量，短文档会非常稀疏，文档之间也无法共享统计强度。LDA 在二者之间加入 K 个潜在主题：每篇文档先混合主题，每个词位置再选择主题，最后由所选主题产生单词。于是

文档 $\longrightarrow$ 主题混合 $\longrightarrow$ 逐位置主题 $\longrightarrow$ 单词。

两层 Dirichlet 先验分别平滑文档 - 主题分布和主题 - 词分布。学习任务不是为文档贴唯一标签，而是从只观察到的词序列反推主题词义、文档主题比例和逐词主题指派。

记号

“潜在”指 z_{mn} 和 θ_m 未被直接观察；“狄利克雷”指概率向量的先验；“分配”指每个词位置的主题指派。LDA 不是线性判别分析，也不等于把文档硬聚成一个主题。

读前自检：潜在狄利克雷分配模型。 LDA 给定 M 篇文档、 K 个主题和 V 词表，要求 $\theta_m \in \Delta^{K-1}$ 、 $\varphi_k \in \Delta^{V-1}$ ；请核对两向量维数与归一化，并标出 z_{mn} 和 w_{mn} 的取值集合。

定义 35.1 (潜在狄利克雷分配模型). 给定词表 $\mathcal{W} = \{1, \dots, V\}$ 、主题数 K 和文档数 M 。对每个主题 k , 取 $\varphi_k \sim \text{Dir}(\beta)$; 对每篇文档 m , 取 $\theta_m \sim \text{Dir}(\alpha)$ 。对文档 m 的每个位置 n , 依次生成

$$z_{mn} \mid \theta_m \sim \text{Cat}(\theta_m), \quad w_{mn} \mid z_{mn} = k, \varphi \sim \text{Cat}(\varphi_k).$$

所有 $\alpha_k > 0$ 、 $\beta_v > 0$ 。本章明确区分两个相关但目标不同的模型:

1. **完整 Bayes LDA**: $\varphi_k \sim \text{Dir}(\beta)$, 折叠 Gibbs 积分消去 θ, φ ;
2. **点参数 LDA 变体**: $\varphi_k \in \Delta^{V-1}$ 是待估参数, 不对 φ_k 放置 Dirichlet 先验, 变分 EM 最大化该参数模型的 ELBO。

两者共享条件似然 $p(w_{mn} \mid z_{mn}, \varphi)$ 和文档先验 $\theta_m \sim \text{Dir}(\alpha)$, 但不是同一个后验, 也不能把 β 平滑项临时加入点参数变体后仍声称优化同一目标。

读题翻译 首次阅读固定走“完整 Bayes 模型 $\rightarrow$ 积分消去 $\theta, \varphi \rightarrow$ 折叠 Gibbs 满条件 $\rightarrow$ 减一算一抽一加”这一条完整路线。第 35.4 节的变分 EM 是对点参数变体的进阶对照: 它优化 ELBO, 不是对前一条完整 Bayes 后验换一种算法。

读前自检: 模型定义。 LDA 模型定义区分对 θ, φ 积分的完整 Bayes 模型与点参数变体; 请写出后验 $p(z, \theta, \varphi \mid w, \alpha, \beta)$ 的分子, 核对折叠 Gibbs 与点参数变分 EM 针对的未知对象不同。

读前自检: LDA 的文本生成算法。 LDA 文本生成算法以 $M, K, V, N_m, \alpha, \beta$ 为输入; 请先采样一列 φ_k 和一篇文档的 θ_m , 再采样一个 z_{mn}, w_{mn} , 核对概率向量归一并在全部计划对象生成后停止。

读前自检: 概率图模型。 LDA 概率图在给定 θ_m 与全部 φ_k 时, 使同一文档各位置条件独立; 请写出 $P(z_{mn}, w_{mn} \mid \theta_m, \varphi)$, 核对跨位置共享 θ_m 仍会产生边缘相关。

读前自检: 随机变量序列的可交换性。 LDA 文档内词位置在积分掉共享 θ_m 后可交换但一般不独立; 请置换两个位置并比较条件联合乘积, 核对乘积因子次序改变而数值不变。

读前自检: 概率公式。 LDA 完整联合分布由主题词先验、文档主题先验、主题指派和发词因子相乘; 请对一个位置写出 $\theta_{m,z_{mn}} \varphi_{z_{mn}, w_{mn}}$, 核对所有索引落在 M, K, V 声明范围。

35.2 LDA 生成过程与概率图

对完整 Bayes LDA, 联合分布分解为

$$p(w, z, \theta, \varphi \mid \alpha, \beta) \quad (35.1)$$

$$= \prod_{k=1}^K p(\varphi_k \mid \beta) \prod_{m=1}^M \left[p(\theta_m \mid \alpha) \prod_{n=1}^{N_m} p(z_{mn} \mid \theta_m) p(w_{mn} \mid z_{mn}, \varphi) \right].$$

点参数变体则以 φ 为给定参数，其联合分布为

$$p_{\text{par}}(\mathbf{w}, \mathbf{z}, \boldsymbol{\theta} \mid \boldsymbol{\alpha}, \boldsymbol{\varphi}) = \prod_{m=1}^M \left[p(\boldsymbol{\theta}_m \mid \boldsymbol{\alpha}) \prod_{n=1}^{N_m} p(z_{mn} \mid \boldsymbol{\theta}_m) p(w_{mn} \mid z_{mn}, \boldsymbol{\varphi}) \right]. \quad (35.2)$$

板块图中， N_m 板块嵌在 M 板块内，表示每篇文档的每个词位置都重复生成； K 板块表示主题词向量重复 K 次。图 35.2 用统一符号展示这一生成依赖。




图 35.2 完整 Bayes LDA 盘式图把超参数、潜变量和观测变量分开：每篇文档共享一个主题比例，每个词位拥有一个主题指派，所有文档共享带 Dirichlet 先验的主题词分布；盘框标明重复次数，箭头只表示条件依赖方向

学习策略。已知 $\mathbf{w}$ 后，目标是后验

$$p(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\varphi} \mid \mathbf{w}, \boldsymbol{\alpha}, \boldsymbol{\beta}).$$

对 $\mathbf{z}$ 求和并对两组概率向量积分会产生指数规模耦合，通常不能精确计算。折叠 Gibbs 在完整 Bayes 模型中积分消去共轭概率向量，再对 $\mathbf{z}$ 抽样；变分 EM 在式 (35.2) 的点参数变体中，以可计算的平均场分布近似 $p_{\text{par}}(\boldsymbol{\theta}, \mathbf{z} \mid \mathbf{w}, \boldsymbol{\alpha}, \boldsymbol{\varphi})$ 并交替更新局部变分参数与全局点参数。前者提供完整 Bayes 后验的相关样本，后者提供另一个明确参数模型的不确定性局部近似。

命题 35.1 (条件独立生成蕴含文档内交换性) 在给定 $\boldsymbol{\theta}_m$ 和 $\boldsymbol{\varphi}$ 时，文档 m 各词位置独立同分布，且

$$p(w_{mn} = v \mid \boldsymbol{\theta}_m, \boldsymbol{\varphi}) = \sum_{k=1}^K \theta_{mk} \varphi_{kv}.$$

因此任意置换词位置不改变条件联合概率；积分消去 $\boldsymbol{\theta}_m$ 后，词位置仍交换，但一般不再边缘独立。

读前自检：证明：条件独立生成蕴含文档内交换性。 LDA 文档内词元在给定 $\boldsymbol{\theta}_m$ 时的联合概率为 $\prod_n \sum_k \theta_{mk} \varphi_{k, w_{mn}}$ ；请置换位置指标核对乘积不变，再指出边缘化后各位置仍因共享 $\boldsymbol{\theta}_m$ 而不独立。

证明. 对任意位置置换 π , 条件联合概率是

$$\prod_{n=1}^{N_m} \sum_k \theta_{mk} \varphi_{k, w_{mn}},$$

乘法交换律使其等于置换后的乘积。再对 $p(\theta_m | \alpha)$ 积分不会破坏置换不变性。但两个位置共享同一个随机 θ_m ; 边缘化后它们通过该共同原因相关, 所以不能由交换性推出独立性。□

生成算法. 图 35.3 以三条泳道展示完整 Bayes LDA 的四步祖先采样; $n = 1, \dots, N_m$ 嵌套在每个 m 内, 侧注只用于区分点参数变体。




图 35.3 完整 Bayes LDA 的三层祖先采样流程; 点参数变体仅在侧注中区分。

读图检查. 沿 $\beta \rightarrow \varphi_k$ 、 $\alpha \rightarrow \theta_m$ 、 $\theta_m \rightarrow z_{mn}$ 、 $z_{mn} \rightarrow w_{mn}$ 与 $\varphi_k \rightarrow w_{mn}$, 核对式 (35.1) 的主题词先验、文档主题先验、主题指派和发词四类因子; 再区分完整 Bayes 中随机的 φ_k 与点参数变体中每个 φ_k 为待估参数, 二者不是同一后验。

读前自检: LDA 文本生成 (祖先采样): 执行契约。 LDA 文本生成 (祖先采样) 输入 “文档/主题/词表规模、文档长度、严格正 Dirichlet 参数及可复现随机生成器状态”, 条件 “ M, K, V 为正整数, $N_m \in \mathbb{N}_0$, 先验向量维数相容且有限严格为正, 随机接口已登记”; 请执行 “概率向量完整通过单纯形检查后才原子追加”, 以 “完成 $K + M + 2I$ 个计划随机对象、空语料有限循环完成或首次失败时停止” 判停。

读前自检: LDA 文本生成 (祖先采样)。 LDA 文本生成 (祖先采样) 输入 “文档/主题/词表规模、文档长度、严格正 Dirichlet 参数及可复现随机生成器状态”, 条件 “ M, K, V 为正整数, $N_m \in \mathbb{N}_0$, 先验向量维数相容且有限严格为正, 随机接口已登记”; 请做一轮 “概率向量完整通过单纯形检查后才原子追加”, 以 “完成 $K + M + 2I$ 个计划随机对象、空语料有限循环完成或首次失败时停止” 核对停止证书。

算法 35.1: LDA 文本生成 (祖先采样)

输入: M, K, V ; 长度 $N_1, \dots, N_M$; 严格正的 α, β ; 随机数生成器状态
输出: 最后合法生成前缀; $k_{\text{done}}, m_{\text{done}}, i_{\text{done}}, q_{\text{done}}$; **status** 与最终诊断

- 1 置 $k_{\text{done}} = m_{\text{done}} = i_{\text{done}} = q_{\text{done}} = 0$ 并初始化空输出; 若维数、长度、先验或随机接口非法, 则返回空前缀、**invalid_input** 及字段诊断
- 2 对 $k \leftarrow 1$ 至 K 执行
 - 3 调用随机源抽取临时 φ_k 并增加 q_{done} ; 调用失败时返回最后合法前缀、**random_source_failure** 及主题 k 诊断
 - 4 若向量非有限、非负性或归一化失败, 则返回前缀、**numerical_failure** 及主题概率诊断; 否则原子追加并令 $k_{\text{done}} \leftarrow k$
- 5 结束
- 6 对 $m \leftarrow 1$ 至 M 执行
 - 7 调用随机源抽取临时 θ_m 并增加 q_{done} ; 调用失败时返回前缀、**random_source_failure** 及文档 m 诊断
 - 8 若向量检查失败, 则返回前缀、**numerical_failure** 及文档概率诊断; 否则原子追加并令 $m_{\text{done}} \leftarrow m$
 - 9 对 $n \leftarrow 1$ 至 N_m 执行
 - 10 依次抽临时 z_{mn} 和 w_{mn} , 每次调用增加 q_{done} ; 任一随机调用失败则返回前缀、**random_source_failure** 及 (m, n) 阶段诊断
 - 11 若索引越界或类别概率检查失败, 则返回前缀、**numerical_failure** 及词位诊断; 否则原子追加 (z_{mn}, w_{mn}) 并增加 i_{done}
 - 12 结束
- 13 结束
- 14 返回完整样本、实际计数、**completed** 及概率误差/生成器末状态最终诊断

初始化与更新顺序。初始化随机数生成器及空输出容器, 先按主题编号抽取全部 φ_k , 再按文档编号抽取 θ_m , 最后按词位顺序先抽 z_{mn} 、后抽 w_{mn} 。**停止条件**是所有有限循环正常完成;**异常与退化**包括非法维数、非正先验、非有限概率及随机数生成失败, 空文档是合法退化输入。**正确性依据**是式 (35.1) 的祖先分解。若保存全部输出, **空间复杂度**为 $O(KV + MK + I)$; **复杂度假设**是 Dirichlet 抽样与类别线性扫描都按相应向量长度计费, 此时生成时间为 $O(KV + MK + I(K + V))$ 。若先以 $O(KV + MK)$ 时间为每个 φ_k 和 θ_m 建立别名表, 使每次类别抽样为 $O(1)$, 则总生成时间可降为 $O(KV + MK + I)$ 。

阅读目标: 积分消去文档 – 主题和主题 – 词分布, 只保留计数。

对象: 主题指派 z 、词元 w 、Dirichlet 超参数 α, β 及计数 n_{mk}, n_{kv} 。

合法条件: $\alpha_k, \beta_v > 0$; 删去当前词元后的计数用上标 $-i$; 采用多元 Beta 函数。

第一步: 先按文档和主题分组联合分布, 并分别应用 Dirichlet– 多项积分。

推导目标

从式 (35.1) 积分消去 θ 和 φ , 得到只依赖计数的 $p(w, z | \alpha, \beta)$; 随后用“加入一个词元前后”的比值推出 Gibbs 满条件分布。

推导准备

记 $\alpha_0 = \sum_k \alpha_k$ 、 $\beta_0 = \sum_v \beta_v$; $n_{mk} = \sum_n \mathbf{1}\{z_{mn} = k\}$, $n_{kv} = \sum_{m,n} \mathbf{1}\{z_{mn} = k, w_{mn} = v\}$, $n_{m\cdot} = \sum_k n_{mk}$, $n_{k\cdot} = \sum_v n_{kv}$; 并记 $\mathbf{n}_m = (n_{m1}, \dots, n_{mK})$ 、 $\mathbf{n}_k = (n_{k1}, \dots, n_{kV})$ 。上标 $-i$ 表示删去当前词元 $i = (m, n)$ 后的计数。多元 Beta 函数记为 $B(\mathbf{a}) = \prod_j \Gamma(a_j) / \Gamma(\sum_j a_j)$ 。

推导第 1 步：按主题收集单词似然。

$$p(\mathbf{w} | \mathbf{z}, \boldsymbol{\varphi}) = \prod_{k=1}^K \prod_{v=1}^V \varphi_{kv}^{n_{kv}}.$$

由定义 35.1 中的 $\beta_v > 0$ ，每个主题的先验密度与有序词元似然的乘积为

$$\frac{1}{B(\boldsymbol{\beta})} \prod_{v=1}^V \varphi_{kv}^{\beta_v-1} \prod_{v=1}^V \varphi_{kv}^{n_{kv}} = \frac{1}{B(\boldsymbol{\beta})} \prod_{v=1}^V \varphi_{kv}^{n_{kv}+\beta_v-1}.$$

在 Δ_{V-1} 上逐项积分，并使用定理 34.3 背后的多元 Beta 恒等式，得到

$$\int_{\Delta_{V-1}} \frac{1}{B(\boldsymbol{\beta})} \prod_{v=1}^V \varphi_{kv}^{n_{kv}+\beta_v-1} d\boldsymbol{\varphi}_k = \frac{B(\mathbf{n}_k + \boldsymbol{\beta})}{B(\boldsymbol{\beta})}.$$

这里 $\mathbf{w}, \mathbf{z}$ 表示按位置编号的词元与主题指派，故似然是逐位置概率的乘积，没有计数向量概率中的多项组合系数。对 $k = 1, \dots, K$ 相乘得到

$$p(\mathbf{w} | \mathbf{z}, \boldsymbol{\beta}) = \prod_{k=1}^K \frac{B(\mathbf{n}_k + \boldsymbol{\beta})}{B(\boldsymbol{\beta})}. \quad (35.3)$$

推导第 2 步：按文档收集主题指派。把上一行中的主题索引 k 与词索引 v 分别换成文档索引 m 与主题索引 k ，并由 $\alpha_k > 0$ ，对每篇文档逐项写出

$$\int_{\Delta_{K-1}} \frac{1}{B(\boldsymbol{\alpha})} \prod_{k=1}^K \theta_{mk}^{n_{mk}+\alpha_k-1} d\boldsymbol{\theta}_m = \frac{B(\mathbf{n}_m + \boldsymbol{\alpha})}{B(\boldsymbol{\alpha})}.$$

这仍是有序主题指派的逐位置似然积分；没有额外的多项组合系数。对 $m = 1, \dots, M$ 相乘，积分消去 $\boldsymbol{\theta}_m$ ：

$$p(\mathbf{z} | \boldsymbol{\alpha}) = \prod_{m=1}^M \frac{B(\mathbf{n}_m + \boldsymbol{\alpha})}{B(\boldsymbol{\alpha})}. \quad (35.4)$$

定理 35.1 (LDA 的折叠联合分布) 在定义 35.1 的条件下，

$$p(\mathbf{w}, \mathbf{z} | \boldsymbol{\alpha}, \boldsymbol{\beta}) = \prod_{k=1}^K \frac{B(\mathbf{n}_k + \boldsymbol{\beta})}{B(\boldsymbol{\beta})} \prod_{m=1}^M \frac{B(\mathbf{n}_m + \boldsymbol{\alpha})}{B(\boldsymbol{\alpha})}. \quad (35.5)$$

该式保留了与 $\mathbf{z}$ 有关的全部归一化常数。

读前自检：证明：LDA 的折叠联合分布。 LDA 折叠联合分布的被积函数非负，且主题参数与文档参数两组积分变量互不重叠；请分别写出逐主题、逐文档的多元 Beta 比值并相乘，核对 $\alpha_k, \beta_v > 0$ 保证积分有限且无需多项组合系数。

证明。从式 (35.1) 出发，被积函数非负，Tonelli 定理允许改变积分次序。上面的逐主题计算给出式 (35.3)，逐文档计算给出式 (35.4)。两组积分变量互不重叠，故两式相乘即得 (35.5)。所有 α_k, β_v

严格为正，确保每个多元 Beta 积分有限；由于对象是有序词元与指派的联合概率，整个推导中都不出现多项组合系数。□

推论 35.1 (文档内主题指派的交换性) 固定观测词和其他文档后，若同时置换文档 m 的词位置及相应主题指派，式 (35.5) 不变。

读前自检：证明：文档内主题指派的交换性。 LDA 折叠联合分布只通过 n_{mk} 与 n_{kv} 依赖位置数据；请同步置换词元和主题指派，核对两组计数及 Beta 比值不变，再只置换词元构造 n_{kv} 可能改变的对照。

证明. 折叠联合分布只通过 n_{mk} 和 n_{kv} 依赖位置数据；同步置换不改变任一计数，故每个 Beta 函数比值不变。若只置换词而不随之置换指派， n_{kv} 可能改变，结论不成立。□

读前自检：LDA 折叠 Gibbs 抽样。 LDA 折叠 Gibbs 对词元 $i = (m, n)$ 、观测词 v 采用留一计数；请对每个主题计算 $(n_{mk}^{-i} + \alpha_k)(n_{kv}^{-i} + \beta_v)/(n_{k\cdot}^{-i} + \beta_0)$ ，再对 k 归一化，并核对得到合法满条件概率。

读前自检：折叠抽样的留一计数思想。 折叠抽样更新词元 i 前必须先从文档 – 主题和主题 – 词计数表减去其旧主题；请执行一次“减一”，核对两张表总计数各减少 1，再用留一计数计算候选权重。

读前自检：LDA 折叠 Gibbs 条件更新。 LDA 折叠 Gibbs 满条件由文档主题计数因子与主题词计数因子相乘；请为全部 k 算未归一化权重并除以权重和，核对概率非负且总和为 1。

读前自检：主题分布与主题词分布的后验汇总。 折叠 Gibbs 样本的后验汇总用 $\hat{\theta}_{mk} = (n_{mk} + \alpha_k)/(N_m + \alpha_0)$ 和 $\hat{\varphi}_{kv} = (n_{kv} + \beta_v)/(n_{k\cdot} + \beta_0)$ ；请逐行求和核对为 1。

读前自检：折叠 Gibbs 扫描流程。 折叠 Gibbs 扫描以当前主题指派和一致计数表为状态；请对一个词元完成“减 – 算 – 抽 – 加”，核对两张计数表与新指派一致，整轮提交后按扫描预算停止并保留链诊断。

读前自检：主题指派与计数表。 主题指派 z_i 与计数 $n_{mk}, n_{kv}, n_{k\cdot}$ 必须同步；请改变一个词元的主题，逐项更新受影响的旧、新主题计数，核对文档总数和主题总数守恒。

35.3 折叠 Gibbs 推断

命题 35.2 (折叠 Gibbs 满条件分布) 设当前词元 $i = (m, n)$ 的观测词为 v 。删去其旧主题后的满条件概率满足

$$p(z_i = k \mid \mathbf{z}_{-i}, \mathbf{w}, \boldsymbol{\alpha}, \boldsymbol{\beta}) \propto \frac{n_{kv}^{-i} + \beta_v}{n_{k\cdot}^{-i} + \beta_0} \frac{n_{mk}^{-i} + \alpha_k}{n_{m\cdot}^{-i} + \alpha_0}. \quad (35.6)$$

右端对 $k = 1, \dots, K$ 归一化后才是概率。

读前自检：证明：折叠 Gibbs 满条件分布。 折叠 Gibbs 比较候选主题 k 时只保留主题 - 词与文档 - 主题计数因子；请用 $\Gamma(x+1)/\Gamma(x) = x$ 分别约去两个 Beta 函数比值，核对所得两项相乘即为未归一化满条件权重。


证明. 在式 (35.5) 中，除主题 k 的词计数因子和文档 m 的主题计数因子外，其余因子在比较候选 k 时相消。使用 $\Gamma(x+1)/\Gamma(x) = x$ ，把“加入当前词元”后的 Beta 函数除以留一 Beta 函数，分别得到

$$\frac{n_{kv}^{-i} + \beta_v}{n_{k\cdot}^{-i} + \beta_0}, \quad \frac{n_{mk}^{-i} + \alpha_k}{n_{m\cdot}^{-i} + \alpha_0}.$$

两项相乘即为未归一化权重。第二项分母虽对 k 相同，保留它能显示完整的后验预测来源。 □

推导第 3 步：用留一状态的 Beta 函数比值形成满条件。 命题 35.2 把折叠联合分布中所有与候选主题无关的因子约去，再对 K 个正权重统一归一化；这一“先留一、后作比”的顺序也是实现计数守恒的依据。

图 35.4 把一次更新需要读写的两张计数表并列画出：先从旧主题的文档 - 主题计数和主题 - 词计数各减一，再计算所有候选权重，抽取新主题后再各加一。



上标 $-i$ 始终保留到抽样完成，防止当前词位对自身重复计数。

图 35.4 折叠 Gibbs 更新先临时移除当前词位，再把文档 - 主题偏好与主题 - 单词证据相乘形成满条件分布，最后抽取新主题并恢复计数；上标负 i 防止当前词位对自身产生重复计数

样本之后可用后验均值平滑估计

$$\hat{\theta}_{mk} = \frac{n_{mk} + \alpha_k}{n_{m\cdot} + \alpha_0}, \quad \hat{\phi}_{kv} = \frac{n_{kv} + \beta_v}{n_{k\cdot} + \beta_0}. \quad (35.7)$$

这些是给定某个保留样本的后验均值；更稳健的做法是对多个保留样本的预测量或计数平滑估计取平均，而不是只报告最后一次扫描。

实现提示

实现折叠 Gibbs 抽样时，输入应同时包括 $\boldsymbol{w}$ 、 $\boldsymbol{\alpha}$ 、 $\boldsymbol{\beta}$ 与 K ，避免把模型参数与数据割裂。燃烧期结束后还要继续留样，可按预先规定或诊断选择间隔，并报告有效样本量、链间差异和随机种子。燃烧期不是算法完成的同义词。

读前自检：LDA 变分 EM 局部—全局更新。 LDA 变分 EM 在局部 $q_m(z_m, \theta_m)$ 与全局点参数 φ, α 间交替；请完成一次局部责任度归一化，再用期望计数更新一行 φ_k ，核对 ELBO 不下降后提交。

读前自检：平均场变分推断。 平均场变分族把隐变量分解为若干 $q_j(h_j)$ ；请固定其余因子并计算 $q_j^*(h_j) \propto \exp(E_{-j} \log p(w, h))$ ，核对归一化常数有限。

读前自检：LDA 变分 EM 算法。 LDA 变分 EM 以语料、 K 、正 α 与列随机 φ 为输入；请完成一篇文档的局部坐标迭代和一次全局期望计数更新，只在 ELBO/归一化门禁通过时提交，按双容差或预算停止。

读前自检：通用变分 EM 坐标上升。 通用变分 EM 坐标上升固定其余 q_{-j} 时更新 q_j ，再固定 q 更新模型参数；请执行一个坐标最优更新，核对归一化且 ELBO 不降后再进入 M 步。

读前自检：LDA 变分更新推导。 LDA 变分更新从 $\log p(w, h)$ 中保留含当前因子的项并对其余变量取期望；请指数化并归一化一次，核对得到的责任度非负且和为 1。

读前自检：LDA 的变分参数估计算法。 LDA 变分参数估计维护局部责任度/Dirichlet 参数与全局主题词分布；请用局部期望计数更新一个 φ_{kv} 并归一化，核对 ELBO 不降，按外层容差或预算停止。

35.4 变分 EM 推断

定理 35.2 (KL-ELBO 恒等式) 设 $0 < p(\boldsymbol{w}) < \infty$ ，联合密度与 q 相对于同一支配测度可测， $q \ll p(\boldsymbol{h} \mid \boldsymbol{w})$ ，并且

$$\mathbb{E}_q |\log p(\boldsymbol{w}, \boldsymbol{h})| < \infty, \quad \mathbb{E}_q |\log q(\boldsymbol{h})| < \infty.$$

这些条件排除了未定义的 $\infty - \infty$ 。则

$$\log p(\boldsymbol{w}) = \mathcal{L}(q) + \text{KL}(q(\boldsymbol{h}) \parallel p(\boldsymbol{h} \mid \boldsymbol{w})), \quad (35.8)$$

其中 $\boldsymbol{h}$ 汇总隐变量，且

$$\mathcal{L}(q) = \mathbb{E}_q \log p(\boldsymbol{w}, \boldsymbol{h}) - \mathbb{E}_q \log q(\boldsymbol{h}).$$

因此 $\mathcal{L}(q) \leq \log p(\boldsymbol{w})$ ，等号当且仅当 q 等于精确后验（几乎处处）。

读前自检：证明：KL-ELBO 恒等式。 KL-ELBO 恒等式假定 $0 < p(\mathbf{w}) < \infty$ 、 q 对后验绝对连续且相关项绝对可积；请把 $\log p(\mathbf{h} | \mathbf{w}) = \log p(\mathbf{w}, \mathbf{h}) - \log p(\mathbf{w})$ 代入 KL，核对 $\text{KL}(q \| p) = \log p(\mathbf{w}) - \mathcal{L}(q)$ 。

证明。 由 $0 < p(\mathbf{w}) < \infty$ 与绝对连续性，Bayes 等式在 q 几乎处处成立： $\log p(\mathbf{h} | \mathbf{w}) = \log p(\mathbf{w}, \mathbf{h}) - \log p(\mathbf{w})$ 。上述绝对可积条件允许分别积分并整理，不会出现 $\infty - \infty$ ：

$$\begin{aligned}\text{KL}(q \| p) &= \mathbb{E}_q \log q(\mathbf{h}) - \mathbb{E}_q \log p(\mathbf{h} | \mathbf{w}) \\ &= \log p(\mathbf{w}) - \mathcal{L}(q).\end{aligned}$$

KL 非负给出下界与等号条件。 □

图 35.5 显示：受限族 $\mathcal{Q}$ 中最优 q^* 通常仍与真实后验有正 KL 距离，故“E 步后 ELBO 等于证据”一般错误。




图 35.5 观测对数证据等于 ELBO 与变分分布到真实后验的 KL 散度之和；平均场坐标更新可使 ELBO 逐步不降，但非凸目标下有限运行通常只得到坐标稳定点或局部驻点，多启动比较也不构成全局最优证明

以下变分推导只针对式 (35.2) 的点参数变体； β 不属于该变体的 ELBO。为使该模型的对数项、坐标命题与评价口径使用同一支持，先冻结训练活动词表 $\mathcal{V}_{\text{tr}}$ ：每个 $v \in \mathcal{V}_{\text{tr}}$ 在训练语料中至少出现一次，测试时的词表外项要么映射到一个已在训练中出现的显式 UNK，要么返回 `invalid_input(support_failure, v)`。本点参数模型的可行域规定

$$\varphi_{kv} > 0 \quad (k = 1, \dots, K, v \in \mathcal{V}_{\text{tr}}), \quad \sum_{v \in \mathcal{V}_{\text{tr}}} \varphi_{kv} = 1.$$

这是模型支持的明示限制，不是在实现中偷偷加入 β 平滑。对固定 φ 的单文档，采用平均场族

$$q(\theta_m, \mathbf{z}_m | \gamma_m, \eta_m) = \text{Dir}(\theta_m | \gamma_m) \prod_{n=1}^{N_m} \text{Cat}(z_{mn} | \eta_{mn}). \quad (35.9)$$

图 35.6 强调：近似族主动切断了后验中 θ_m 与各 z_{mn} 的依赖，这换来可计算性，也造成近似误差。




图 35.6 固定主题-词参数 φ 时，平均场近似把单文档后验中耦合的 θ_m 与 z_{mn} 替换为两个变分因子族；被切断的是近似后验中的直接依赖，固定参数仍通过词似然进入责任度更新

读前自检：平均场坐标最优形式。 平均场坐标最优形式以“设 A 关于支配测度 μ_j 几乎处处为实值且可测”为约束；请把 $q_j^*(h_j)$ 展开一次并检查其类型或边界，并确认展开后的量满足定义中的域、维数或符号限制。

命题 35.3 (平均场坐标最优形式) 固定其他变分因子，令 $A(h_j) = \mathbb{E}_{q_{-j}} \log p(\mathbf{w}, \mathbf{h})$ 。设 A 关于支配测度 μ_j 几乎处处为实值且可测，并且

$$0 < Z_j = \int e^{A(h_j)} \mu_j(dh_j) < \infty.$$

再假定

$$\int e^{A(h_j)} |A(h_j)| \mu_j(dh_j) < \infty.$$

则该坐标的正规化最优解存在并满足

$$q_j^*(h_j) = \frac{e^{A(h_j)}}{Z_j}, \quad \log q_j^*(h_j) = A(h_j) - \log Z_j, \quad (35.10)$$

并在 μ_j 零测集意义下唯一。

读前自检：证明：平均场坐标最优形式。 平均场坐标更新只比较 $q_j \ll q_j^*$ 且熵项、 $A(h_j)$ 项可积的密度；请将坐标目标改写为 $\log Z_j - \text{KL}(q_j \| q_j^*)$ ，核对 $q_j = q_j^*$ 几乎处处时唯一取到最大值。

证明. 把 ELBO 中与 q_j 有关的部分记为

$$\mathcal{F}(q_j) = \int q_j(h_j) A(h_j) \mu_j(dh_j) - \int q_j(h_j) \log q_j(h_j) \mu_j(dh_j),$$

并只比较满足 $q_j \ll q_j^*$ 、 $\int q_j |A| d\mu_j < \infty$ 且 $\int q_j |\log q_j| d\mu_j < \infty$ 的概率密度。新增的加权可积条件给出

$$\int q_j^* |A| d\mu_j = Z_j^{-1} \int e^A |A| d\mu_j < \infty, \quad \int q_j^* |\log q_j^*| d\mu_j < \infty,$$

所以 q_j^* 本身属于比较类, $\mathcal{F}(q_j^*)$ 不是 $\infty - \infty$ 。由 $\log q_j^* = A - \log Z_j$, 逐项代入可得

$$\mathcal{F}(q_j^*) - \mathcal{F}(q_j) = \int q_j \log \frac{q_j}{q_j^*} d\mu_j = \text{KL}(q_j \| q_j^*) \geq 0.$$

因此 q_j^* 达到最大值; 等号当且仅当 $q_j = q_j^*$ 几乎处处, 故最优解唯一。若 $Z_j = 0$ 或 $Z_j = \infty$, 则此正规化坐标更新不存在; 即使 $0 < Z_j < \infty$, 若 $\int e^A |A| d\mu_j = \infty$, 上述两项分开定义的 ELBO 坐标目标仍可能出现未定义的 $\infty - \infty$, 也不能只写 “ $\propto e^A$ ” 掩盖该缺口。□

将命题 35.3 用于 LDA 之前, 必须先核验当前观察词满足 $w_{mn} \in \mathcal{V}_{\text{tr}}$ 且 $\varphi_{k,w_{mn}} > 0$ 对每个 k 成立。否则 $\log \varphi_{k,w_{mn}} = -\infty$, 函数 A 不再满足命题中 “几乎处处为实值” 的假设; 本章当前版本不能继续套用该命题, 而应返回 `invalid_input(support_failure, m, n, w_{mn})`。在上述严格正支持下, 局部更新为

$$\eta_{mnk} \propto \varphi_{k,w_{mn}} \exp \left\{ \psi(\gamma_{mk}) - \psi \left(\sum_{\ell=1}^K \gamma_{m\ell} \right) \right\}, \quad (35.11)$$

$$\gamma_{mk} = \alpha_k + \sum_{n=1}^{N_m} \eta_{mnk}. \quad (35.12)$$

每次计算 η_{mn} 后必须对 k 归一化; 在对数域使用 `log-sum-exp` 可避免小概率下溢。式 (35.11) 和 (35.12) 交替至局部 ELBO 增量足够小。

固定全部局部变分参数, 点参数变体的主题-词参数 $\mathbf{M}$ 步是归一化期望计数:

$$\varphi_{kv} = \frac{\sum_{m=1}^M \sum_{n=1}^{N_m} \eta_{mnk} \mathbf{1}\{w_{mn} = v\}}{\sum_{v'=1}^V \sum_{m=1}^M \sum_{n=1}^{N_m} \eta_{mnk} \mathbf{1}\{w_{mn} = v'\}}. \quad (35.13)$$

记式 (35.13) 的分子为 $C_{kv} = \sum_{m,n} \eta_{mnk} \mathbf{1}\{w_{mn} = v\}$ 。严格正的 $\boldsymbol{\varphi}$ 与有限严格正的 $\boldsymbol{\gamma}_m$ 使式 (35.11) 归一化后有 $\eta_{mnk} > 0$ 。又因每个 $v \in \mathcal{V}_{\text{tr}}$ 至少出现一次, 故 $C_{kv} > 0$ 且 $C_{k\cdot} = \sum_v C_{kv} > 0$, 从而 $\mathbf{M}$ 步仍给出 $\varphi_{kv} = C_{kv}/C_{k\cdot} > 0$ 。这条推导证明严格正支持是不变量; 若浮点计算形成零或非有限的 C_{kv} , 那是数值支持塌缩, 候选不得提交。

勘误与核验

原书对应公式给出的只是期望计数和, 还不是主题-词概率。式 (35.13) 进一步除以该主题全部词的期望计数总和。本章选定的点参数变体不对 $\boldsymbol{\varphi}$ 置先验, 故式中不得临时加入 β_v 或 $\beta_v - 1$ 。若要采用后验均值或 MAP 平滑, 必须另行定义含 $\boldsymbol{\varphi}_k \sim \text{Dir}(\boldsymbol{\beta})$ 的目标, 并同步重写 ELBO、 $\mathbf{M}$ 步和评价口径。当某主题的期望总计数为零时, 式 (35.13) 无定义; 当活动词表中的某个

C_{kv} 被数值计算成零时, 后续责任度和困惑度会遇到 $\log 0$ 。本章算法分别把这两类候选记为 $\text{numerical_failure}(\text{empty_topic}, k)$ 与 $\text{numerical_failure}(\text{support_collapse}, k, v)$, 不进入后续 Newton 步, 也不静默沿用旧参数或临时加平滑常数。

对 α , 令 $\gamma_{m0} = \sum_k \gamma_{mk}$, $\alpha_0 = \sum_k \alpha_k$, ELBO 梯度与 Hessian 为

$$g_k(\alpha) = M\{\psi(\alpha_0) - \psi(\alpha_k)\} + \sum_{m=1}^M \{\psi(\gamma_{mk}) - \psi(\gamma_{m0})\}, \quad (35.14)$$

$$H_{k\ell}(\alpha) = M\{\psi'(\alpha_0) - \mathbf{1}(k = \ell)\psi'(\alpha_k)\}. \quad (35.15)$$

Newton 候选为

$$\alpha^{\text{new}} = \alpha^{\text{old}} - H(\alpha^{\text{old}})^{-1} g(\alpha^{\text{old}}). \quad (35.16)$$

实际实现必须阻尼或线搜索, 保证所有分量仍严格为正且 ELBO 不下降。

命题 35.4 (受限变分 EM 的单调性边界) 若每个 E 步和 M 步都在各自可行域内不降低同一个 ELBO, 则 ELBO 序列单调不减; 若其上有界, 则 ELBO 数值收敛。该结论不保证参数达到全局最优, 也不保证真实证据在受限平均场 E 步后等于 ELBO。

读前自检：证明：受限变分 EM 的单调性边界。 受限变分 EM 的单调性只在每个局部或参数子步不降低同一 ELBO 时成立; 请比较第 t 轮前后 ELBO, 构造一次近似子步下降的反例, 并说明此时必须拒绝候选或显式报告下降。

证明. 记第 t 轮参数为 $(q^{(t)}, \Theta^{(t)})$ 。坐标 E 步给出

$$\mathcal{L}(q^{(t+1)}, \Theta^{(t)}) \geq \mathcal{L}(q^{(t)}, \Theta^{(t)}),$$

M 步给出

$$\mathcal{L}(q^{(t+1)}, \Theta^{(t+1)}) \geq \mathcal{L}(q^{(t+1)}, \Theta^{(t)}).$$

合并即得单调性; 单调有界实数列收敛。由于 Q 通常不含精确后验, 式 (35.8) 中的 KL 间隙可能严格为正; 非凸性又允许不同初始化到达不同驻点。□

适用条件与局限

有些表述把受限平均场 E 步写成 $\log p(\mathbf{w} | \Theta^{(t-1)}) = \mathcal{L}(q^{(t)}, \Theta^{(t-1)})$ 。一般只能写 “ $\geq$ ”; 只有 $q^{(t)}$ 恰为精确后验时才取等号。因此本章把可审计结论限定为 ELBO 逐块单调, 不夸大成每一步都精确最大化真实证据。坐标更新达到数值稳定时, 也只能报告坐标稳定点或局部驻点; 多启动用于比较可行局部解, 不能证明找到了变分族上的全局最优。

读前自检：LDA 两类推断路线总结。 LDA 两类推断中, 折叠 Gibbs 输出相关主题指派样本, 变分 EM 输出确定性近似参数; 请对照一个词元的条件更新与一个局部责任度更新, 核对两者的状态、输出和诊断不同。

读前自检：LDA 变分 EM 超参数与评估。 LDA 变分 EM 的 K, α, β 及多启动预算必须在留出评价前冻结；请比较两个候选的留出困惑度与 ELBO 稳定性，核对不能用训练 ELBO 单独选择主题数。

35.5 超参数、实现与评估

几何解释。 θ_m 位于主题单纯形，表示文档是 K 个主题的凸组合； φ_k 位于词汇单纯形，表示主题是 V 个词的概率组合。模型把高维文档词频投影到低维主题单纯形，再映回词汇单纯形。若同时置换主题标签以及 θ, φ 相应坐标，观测分布不变，因此主题标签不可识别；比较两次运行需先做主题匹配。

概率解释。 给定 θ_m, φ 时，各词位置条件独立；边缘化共享的 θ_m 后，同文档词元相关。交换性只保证对位置作同步置换后联合概率不变，不表示词元边缘独立。Dirichlet 先验可理解为平滑伪计数：小 α_0 偏好少数主题占优，大 α_0 把文档主题混合拉向均值； β 对主题词分布起同样作用。

优化解释。 折叠 Gibbs 不是直接最大化一个确定性目标，而是构造以后验为平稳分布的马尔可夫链；变分 EM 则在受限分布族和模型参数之间坐标上升 ELBO。前者误差来自有限链长、相关样本和混合；后者误差来自近似族、局部最优和有限迭代。二者的“收敛”不可混用。

图形辅助。 图 35.7 把点参数 LDA 的局部 VI 成功门与语料级 VEM 提交门分开；局部预算或失败不拥有通往 M 步的边。




图 35.7 点参数 LDA 两层变分 EM: 仅 completed/converged 形成 LocalOK_m, 全部 m 到齐后才执行 $C \rightarrow \varphi \rightarrow$ 受保护 Newton; 可行的 budget_stop 保留原 status, 作为未收敛候选进入 $\mathcal{S}_{\text{acc}}$, 其余非成功状态止于记录。

读图检查。先沿 (a) 逐文档确认只有 completed/converged 形成 LocalOK_m ，局部预算或失败不进 C/M 步；再沿 (b) 核对全部 LocalOK_m 到齐后方可进入 C 、 φ 与受保护 Newton。外层 budget_stop 只有在该启动仍 feasible 时才以“预算候选/未收敛”进入 S_{acc} ，其余失败终点只留记录。

图 35.8 把完整 Bayes 折叠 Gibbs 与无 β 先验的点参数变分 EM 按模型目标、局部/全局变量、核心更新、输出与适用性、风险与诊断逐项并列。

比较维度	折叠 Gibbs (完整 Bayes LDA)	平均场变分 EM (点参数 LDA)
模型目标	完整 Bayes LDA: $\theta_m \sim \text{Dir}(\alpha)$, $\varphi_k \sim \text{Dir}(\beta)$; 折叠二者, 抽样 $p(z w, \alpha, \beta)$ 。	点参数 LDA: 无 β 先验。 φ_k 为待估参数; 最大化 同一点参数模型的 ELBO。
局部/全局 变量	局部链状态: z_i ; 共享计数: n_{mk}, n_{kv}, n_k ; θ, φ 已折叠。	局部 E 步固定当前 φ : (γ_m, η_m) ; 全局: (φ, α) 。
核心更新	留一计数满条件: $p(z_i = k \cdot) \propto \frac{n_{kv}^{-i} + \beta_v}{n_k^{-i} + \beta_0} (n_{mk}^{-i} + \alpha_k)$; 执行“减-算-抽-加”。	局部 $\eta_m \leftrightarrow \gamma_m$; 全部文档成功后 $C_{kv} = \sum_{m,n} \eta_{mnk} \mathbf{1}\{w_{mn} = v\}$; $\varphi_{kv} = C_{kv}/C_k$; α 用受保护 Newton, 候选须在正域且 ELBO 不下降。
输出、优势 与适用性	输出相关后验样本; 保留后验不确定性 与多峰信息。稀疏计数实现自然; 适于需要不确定性或多峰信息时。	输出 $(\varphi, \alpha, \{q_m\})$ 点参数/近似; 确定且易批量化; 适于大语料、 批量处理或预算敏感情形。
风险与诊断	烧入不等于收敛; 检查混合、自 相关/ESS、 多链主题匹配后的一致性; 单链样本轨迹不能充当收敛证书。	近似族与局部最优; 检查多启动、局 部未收敛、 空主题、线搜索与数值失败。同一点 参数模型的 可行块更新使 ELBO 逐块非降; ELBO 不等于真实证据。
公平比较: 冻结同一训练/验证/测试切分、词表与预处理、 K、计算预算和评价口径; 同时登记模型差异与推断差异。		

图 35.8 完整 Bayes 折叠 Gibbs 与无 β 先验的点参数变分 EM: 二者模型目标、状态、更新、输出和诊断均不同, 公平比较须同时登记模型与推断差异。

读图检查。先确认左列积分消去 θ, φ 并以 z 和计数为链状态, 右列只在局部 E 步固定当前 φ , 再由全局期望计数与受保护 Newton 分别更新 φ, α ; 最后只在相同训练/验证/测试切分、词表与预处理、主题数、计算预算和评价口径下比较, 并同时登记模型差异与推断差异。

小型数值例子。设 $K = 2$, 当前词 v 的留一计数为

$$(n_{1v}^{-i}, n_{2v}^{-i}) = (3, 1), \quad (n_{1\cdot}^{-i}, n_{2\cdot}^{-i}) = (8, 6), \quad (n_{m1}^{-i}, n_{m2}^{-i}) = (2, 4),$$

并取对称 $\alpha = (1, 1)$ 、每词 $\beta_v = 1$ 、 $V = 5$ 。式 (35.6) 给出未归一化权重

$$r_1 = \frac{4}{13} \frac{3}{8} = \frac{3}{26}, \quad r_2 = \frac{2}{11} \frac{5}{8} = \frac{5}{44}.$$

归一化后 $p(z_i = 1) = 66/131$ 、 $p(z_i = 2) = 65/131$ 。两个局部因子接近，说明不能只看“当前词更像哪个主题”，还要同时看文档主题计数。

对一次变分坐标更新，若 $\gamma = (3, 2)$ 且该词在两主题下概率为 $(0.6, 0.2)$ ，则

$$\psi(3) - \psi(5) = -\frac{7}{12}, \quad \psi(2) - \psi(5) = -\frac{13}{12}.$$

未归一化责任度约为 $(0.3348, 0.0677)$ ，归一化为 $(0.832, 0.168)$ 。

伪代码。主线只保留两条推断算法：完整 Bayes 折叠 Gibbs 与点参数 LDA 变分 EM；算法 35.1 仅用于说明生成方向。通用变分 EM 和单文档局部更新改作稳健实现细节条带，避免把模型路线、通用模板和子程序误读为五个并列选择。

输入与输出。生成算法输入维数、长度、先验和随机数，输出完整模拟语料；Gibbs 输入语料、 K, α, β 及扫描计划，输出保留样本、后验均值和诊断；通用变分 EM 输入模型、数据、可行族和两个块优化器，输出 q 与模型参数；局部变分推断输入一篇文档、固定全局参数和容差，输出 γ_m, η_m 及局部 ELBO；完整变分 EM 输入语料和初始化，输出全局参数、全部局部参数和 ELBO 轨迹。

参数含义。 K 控制表示维度而非已知真主题数； α 控制文档主题稀疏与均值； β 只属于完整 Bayes/Gibbs 模型并控制主题词先验，点参数变分 EM 不使用它； T_B 是燃烧扫描数， T_S 是留样扫描数， L 是抽样间隔； $\epsilon_{\text{loc}}, \epsilon_{\text{out}}$ 分别是局部和外层 ELBO 相对增量阈值； $T_{\text{loc}}, T_{\text{out}}$ 是硬迭代上限； R_{chain} 是独立 Gibbs 链数， R_{start} 是变分随机启动数， J_{ls} 是每次 Newton 更新的最大回溯候选数。

实现提示

Gibbs 可按固定种子均匀指派主题并一次性建立两张计数表；必须核验表的行列和与 $\mathbf{z}$ 一致。变分 EM 可用多次随机单纯形初始化、确定性分块初始化或外部可复现实验初始化；每篇文档取 $\eta_{mnk} = 1/K$ 、 $\gamma_{mk} = \alpha_k + N_m/K$ 是合法起点。空文档不更新主题责任度，只保留先验 $\gamma_m = \alpha$ 。

循环变量与更新顺序。Gibbs 按扫描 t 、文档 m 、位置 n 、候选主题 k 循环，严格执行“减旧计数 – 算 K 个权重 – 归一化 – 抽新主题 – 加新计数”。局部变分按迭代 s ，先更新所有 η_{mn} ，再汇总更新 γ_m 。外层变分 EM 按轮次 r ，先对所有文档完成局部 E 步，再汇总期望计数更新 φ ，最后以受保护 Newton 步更新 α 。

判断、停止、返回与异常。任何非法词索引、非正超参数、非有限概率、计数不守恒或归一化失败都使过程立即停止并指出位置。Gibbs 在完成预设燃烧与留样计划后停止；若达到预算仍未满足诊断条件，应说明当前样本尚不足以支持稳定推断。变分循环同时检查 ELBO 不下降、相对增量和硬上限；若 Newton 候选越过正域则回溯。结果应同时给出实际迭代数、目标轨迹和初始化方式。

正确性与收敛条件。Gibbs 更新由命题 35.2 保证；在有限状态、不可约、非周期等条件下链以目标后验为平稳分布，但有限样本仍有 Monte Carlo 误差。变分更新由命题 35.3 与 35.4 保证同一个点参数模型 ELBO 逐块非降。零概率锁死、主题空置、坏初始化、过严/过松容差、数值下溢或 Newton 越界都可能导致数值失败或预算停止；这些状态都不得写成数学收敛。

算法 35.2: LDA 折叠 Gibbs 抽样

输入: 语料 w ; 主题数 K ; 严格正 α, β ; 初始指派 $z^{(0)}$; 扫描数 T

输出: 最后合法指派/计数与完整扫描链; $t_{\text{done}}, i_{\text{done}}, q_{\text{done}}$; **status** 与最终诊断

- 1 若语料、 K, T 、先验、初始指派或随机接口非法, 则返回空结果、计数 0、**invalid_input** 及字段诊断
- 2 由 $z^{(0)}$ 建立并核对计数, 置 $t_{\text{done}} = i_{\text{done}} = q_{\text{done}} = 0$; 重建不变量失败则返回初始指派、**numerical_failure** 及初始化诊断
- 3 若 $T = 0$, 则返回初始指派/计数、空扫描链、**completed** 及零预算诊断
- 4 **对** 扫描 $t \leftarrow 1$ **至** T **执行**
- 5 **对** i 依预定词元次序遍历, 且 $i = (m, n), v = w_i$ **执行**
- 6 保存旧指派和三项计数, 再在临时事务中减一; 若将产生负计数则回滚并返回
 numerical_failure 及 (t, i) 计数诊断
- 7 计算并归一化 K 个条件概率; 非有限、负值或总和正时回滚并返回最后合法状态、
 numerical_failure 及条件诊断
- 8 调用随机源并增加 q_{done} ; 调用失败或主题索引非法时回滚, 分别返回 **random_source_failure**
 或 **numerical_failure** 及抽样诊断
- 9 原子提交新指派及三项加一并增加 i_{done}
- 10 **结束**
- 11 原子追加 $z^{(t)} \leftarrow z$ 并令 $t_{\text{done}} \leftarrow t$
- 12 **结束**
- 13 返回最后合法指派/计数、完整链、实际计数、**completed** 及计数不变量最终诊断

训练时间复杂度与预测时间复杂度。令 $I = \sum_m N_m$ 。稠密实现的一次 Gibbs 扫描计算 K 个候选, 时间为 $O(IK)$; R_{chain} 条独立链的总训练时间为 $O(R_{\text{chain}}(T_B + LT_S)IK)$ 。一次局部变分全语料扫描为 $O(IK)$, 一次 M 步汇总亦为 $O(IK + KV)$ 。若每轮 Newton 最多试 J_{ls} 个回溯候选, 并利用式 (35.15) “对角矩阵加秩一矩阵” 的结构在线性时间内求解, 则 R_{start} 次启动的总时间为

$$O(R_{\text{start}} T_{\text{out}} [T_{\text{loc}} IK + IK + KV + J_{\text{ls}} K]).$$

若每个 Newton 候选改用普通稠密线性求解, 则最后一项改为 $J_{\text{ls}} K^3$ 。因此不能把多启动或回溯候选数藏进常数。新文档折入固定主题模型需 $O(T_{\text{loc}} N_m K)$, 逐词预测另需 $O(N_m K)$ 。

空间复杂度与复杂度假设。Gibbs 当前链的计数与指派工作内存为 $O(KV + MK + I)$; 若把 T_S 个完整 z 样本全部驻留内存, 还须加 $O(T_S I)$, 而逐样本流式落盘或在线汇总可保持前一工作内存界。批量变分若把全部责任度作为驻留输出需 $O(IK + KV + MK)$; 只有在 η 逐文档流式落盘或不保留时, E 步工作内存才可降到 $O(KV + MK + K \max_m N_m)$ 。上述界把固定精度加法、digamma 和一次类别抽样视为 $O(1)$; 稀疏词表、别名采样和并行同步会改变常数或参数化界, 不能无条件宣称更低复杂度。

LDA 折叠 Gibbs 抽样: 五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新, 并指出何时提交。

数学停止。写出能直接核验的停止证书; 预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

算法执行契约：五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

算法实现说明：通用变分 EM 模板：每轮在临时对象上依次完成 E 块与 M 块，复算同一 ELBO 及一阶残差；只有可行性、单调门和有限性全通过才原子提交。双证书满足报 `converged`，预算耗尽报 `budget_stop`，接口或单调门失败回滚并报 `numerical_failure`。完整 C1-C14 契约

算法执行契约：五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

算法实现说明：单文档局部子程序：空文档返回 $\gamma_m = \alpha$ ；非空文档在对数域同步更新式 (35.11) 与 (35.12)，整篇候选通过 ELBO 与参数双门后才提交。词表支持失败报 `invalid_input`，预算耗尽报 `budget_stop`，数值或单调门失败回滚。完整 C1-C14 契约

读前自检：点参数 LDA 变分 EM（多启动）：执行契约。 点参数 LDA 变分 EM（多启动）输入“训练语料及活动词表、主题数 K 、严格正初始 α, φ 、局部/外层双预算和容差、可复现启动表及 Newton 回溯预算”，条件“语料词索引和维数合法，活动词表每项至少出现一次， $K, R_{\text{start}} \geq 1$ ，初值在整个活动词表上严格正归一，全部预算为非负整数且容差/并列规则冻结”；请执行“完整局部推断、临时主题矩阵、临时 α 和新 ELBO 全部通过归一化/单调门禁后，才原子提交一次外层轮”，以“每启动满足外层 ELBO/参数双证书、外层预算耗尽或首次启动内失败”判停。

点参数 LDA 变分 EM（多启动）：五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。写出能直接核验的停止证书；预算耗尽不等同于收敛。

输出。列出返回对象、实际计数、中心状态和用于复核的诊断。

读前自检：点参数 LDA 变分 EM（多启动）：执行契约。

算法 35.3: 点参数 LDA 变分 EM (多启动)

输入: 语料 $\mathcal{D}$; K ; 严格正初始 α, φ ; $\varepsilon_{\text{loc}}, \varepsilon_{\text{out}}, T_{\text{loc}}, T_{\text{out}}$; R_{start} 个可复现启动; Newton 回溯上限 J_{ls}
输出: 各启动最后合法状态与最佳参数; $S_{\text{done}}, r_{\text{done}}, m_{\text{done}}, k_{\text{done}}, j_{\text{done}}$; **status** 与诊断

- 1 冻结训练活动词表并核验其中每个词至少出现一次; 再核验词索引、维数、 α 正性、 φ 在整个活动词表上的严格正性、容差、预算与启动表。支持失败返回空结果、计数 0、**invalid_input** 及 **support_failure** 位置诊断, 其余输入失败返回字段诊断
- 2 清空 **record**[1: R_{start}] 并置 $s_{\text{done}} = r_{\text{done}} = m_{\text{done}} = k_{\text{done}} = j_{\text{done}} = 0$
- 3 **对** 标记启动循环 **start_loop**: $s \leftarrow 1$ **至** R_{start} **执行**
- 4 置局部 **startup_ok** $\leftarrow$ **true** 并初始化该启动临时状态; 置 **record**[s].**feasible** $\leftarrow$ **false**、**record**[s].**status** $\leftarrow$ **invalid_input**
- 5 若启动随机源失败, 置失败状态 **random_source_failure** 和 **startup_ok** $\leftarrow$ **false**
- 6 若启动状态合法则计算基线 ELBO; 非有限时置失败状态 **numerical_failure** 和 **startup_ok** $\leftarrow$ **false**
- 7 **若** **startup_ok** = **true** **则**
- 8 **对** 标记外层循环 **outer_loop**: $r \leftarrow 1$ **至** T_{out} **执行**
- 9 **对** 标记文档循环 **document_loop**: $m \leftarrow 1$ **至** M **执行**
- 10 按式 (35.11)–(35.12) 及局部实现条带执行单文档更新并增加 m_{done} ; 保存局部状态与诊断
- 11 若局部未收敛, 设置相应 **budget_stop** 或 **numerical_failure**, 令 **startup_ok** $\leftarrow$ **false** 并 **break** **document_loop**
- 12 **结束**
- 13 若 **startup_ok** = **false**, 则 **break** **outer_loop**; 不得执行 M 步
- 14 汇总临时 C_{kv}^+
- 15 **对** 标记主题循环 **topic_loop**: $k \leftarrow 1$ **至** K **执行**
- 16 若该行任一 C_{kv}^+ 非有限, 记录 (s, r, k, v) 与 **numerical_failure**(**nonfinite_count**), 令 **startup_ok** $\leftarrow$ **false** 并 **break** **topic_loop**
- 17 计算 C_k^+ ; 若 $C_k^+ \leq 0$, 记录 (s, r, k) 与 **numerical_failure**(**empty_topic**), 令 **startup_ok** $\leftarrow$ **false** 并 **break** **topic_loop**
- 18 若该行任一 $C_{kv}^+ \leq 0$, 记录 (s, r, k, v) 与 **numerical_failure**(**support_collapse**), 令 **startup_ok** $\leftarrow$ **false** 并 **break** **topic_loop**
- 19 对每个 v 在临时行形成严格正 $\varphi_{kv}^+ = C_{kv}^+ / C_k^+$, 核验整行正性与归一化后增加 k_{done}
- 20 **结束**
- 21 若 **startup_ok** = **false**, 则 **break** **outer_loop**
- 22 在至多 J_{ls} 个候选内形成严格正 α^+ 并逐次增加 j_{done} ; 若无合格步, 置 **line_search_failed** 与 **startup_ok** = **false** 并 **break** **outer_loop**
- 23 用完整临时候选计算 ELBO; 若非有限或异常下降, 置 **numerical_failure** 与 **startup_ok** = **false** 并 **break** **outer_loop**
- 24 原子提交 $(\alpha, \varphi, \gamma, \eta, \text{ELBO})$ 整轮候选并增加 r_{done}
- 25 若外层双证书满足, 置启动状态 **converged** 并 **break** **outer_loop**
- 26 **结束**
- 27 若 **startup_ok** = **true** 且未收敛, 置启动状态 **budget_stop**
- 28 **结束**
- 29 原子写入 **record**[s].**feasible** $\leftarrow$ **startup_ok**、**record**[s].**status**、最后合法参数、最终 ELBO、计数和诊断, 并增加 s_{done}
- 30 **若** **startup_ok** = **false** **则**
- 31 在此唯一位置 **continue** **start_loop**
- 32 **结束**
- 33 **结束**
- 34 令 $S_{\text{acc}} = \{s : \text{record}[s].\text{feasible} = \text{true}, \text{record}[s].\text{status} \in \{\text{converged}, \text{budget_stop}\}\}$; 跨启动阶段只读 **record**, 在评价口径相同的 S_{acc} 中按记录的最终 ELBO 和冻结并列规则选择
- 35 若 $S_{\text{acc}} = \emptyset$, 按全部 **record**[s].**status** 的确定性优先级返回 **random_source_failure**、**line_search_failed**、**budget_stop** 或 **numerical_failure** 及全部失败位置
- 36 返回最佳最后合法参数、所选启动规范状态、实际计数和跨启动最终诊断

算法实现说明：核心五步是逐文档局部 E 步、汇总期望计数、归一化 M 步、ELBO 验收、在同一评价口径内选择多启动；36 行故障树属于稳健实现细节 完整 C1–C14 契约

适用条件。LDA 适合无监督探索中长文本集合、词袋近似尚可、主题可由共现词解释且主题数可通过验证选择的场景。短文本、强顺序语义、动态主题、监督预测或词义高度上下文化时，需要聚合文本、序列主题模型、动态/监督扩展或上下文表示；不能只调 K 掩盖模型错配。

局限性。主题标签置换不可识别；似然非凸导致局部最优；Gibbs 可能混合缓慢，平均场常低估后验相关与方差；固定 K 、词袋假设和单一词义限制表达；高频停用词、极稀有词和语料漂移会扭曲主题。主题“可解释”仍需人工和稳定性检验，不能由困惑度单独保证。

常见错误

Gibbs 计算前未删当前词元；把 n_{mk} 和 n_{kv} 方向写反；遗漏 β ；把完整 Bayes Gibbs 与点参数变分 EM 写成同一个后验；把未归一化期望计数当 φ ；在 η 更新中漏掉 digamma 或归一化；把 ELBO 当真实对数证据；Newton 步产生非正 α 仍继续；用训练词同时推断文档主题并评价同一词的预测概率；只跑一条链或一次初始化便宣布稳定。

读前自检：易混淆概念对比：稳健实现说明：多启动与受保护 Newton。 围绕稳健实现说明：多启动与受保护 Newton，先采用条件“对比表首个数据行是“ θ_m 与 φ_k | 前者是文档在主题上的分布，维数 K | 后者是主题在词表上的分布，维数 V ”，再按列复述“ θ_m 与 φ_k | 前者是文档在主题上的分布，维数 K | 后者是主题在词表上的分布，维数 V ”中的对象、假设与结论；最后验证各列均对应首行对象“ θ_m 与 φ_k ”，且未与表中下一行互换。

易混淆概念对比

对象	第一项	第二项
θ_m 与 φ_k	前者是文档在主题上的分布，维数 K	后者是主题在词表上的分布，维数 V
α 与 β	前者平滑文档 – 主题计数	后者平滑主题 – 词计数
η_{mn} 与 φ_k	前者是某词元属于主题的变分责任度	后者是给定主题生成词的模型概率
折叠与非折叠	折叠法积分消去共轭概率向量	非折叠法显式抽样或近似它们
Gibbs 与变分	前者输出相关后验样本并需链诊断	后者输出确定性近似并需 ELBO 与多启动诊断
困惑度与解释性	困惑度衡量留出预测	解释性关注语义连贯、稳定与人工可读性

评估时，把训练集之外的词元记为 $\mathcal{H}$ ，用训练部分或文档已观察部分推断 $\hat{\theta}_m$ ，再计算

$$\text{perplexity}(\mathcal{H}) = \exp \left\{ -\frac{1}{|\mathcal{H}|} \sum_{(m,n) \in \mathcal{H}} \log \sum_{k=1}^K \hat{\theta}_{mk} \hat{\varphi}_{k,w_{mn}} \right\}. \quad (35.17)$$

必须固定切分、词表和未知词处理；文档完成式评价不能让留出词参与 $\hat{\theta}_m$ 的推断。对每个留出词还须在取对数前核验 $w_{mn} \in \mathcal{V}_{\text{tr}}$ （或已经映射到训练中出现过的 UNK）以及 $\sum_k \hat{\theta}_{mk} \hat{\varphi}_{k,w_{mn}} > 0$ ；

任一条件失败就返回 `invalid_input(support_failure, m, n, wmn)`, 困惑度记为未定义, 不能把 $\log 0$ 送入浮点计算。

公平比较原则。 比较两条路线时, 应使用同一训练/验证/测试切分, 并只在训练数据上确定词表与预处理规则; 固定 K 、初始化原则和计算预算。Gibbs 法报告链间一致性、自相关或有效样本量, 变分法报告 ELBO 轨迹与不同初值的离散程度; 两者使用同一困惑度、主题稳定性和语义连贯度口径。还必须把“完整 Bayes LDA”和“点参数 LDA 变体”登记为不同模型配置; 否则二者结果差异同时包含模型目标与推断方法变化, 不能归因于推断算法。若词表、遮罩、预算或主题匹配规则不同, 同样不能作单因素归因。

35.6 例题与练习

贯穿例：文档—词项矩阵小例

本章角色：把同一非负整数词项计数矩阵展开为有序词元, 并为主题比例与主题词分布加入 Dirichlet 随机层。

沿用词为行、文档为列的计数矩阵

$$\mathbf{X} = \begin{bmatrix} 2 & 0 & 1 \\ 1 & 2 & 0 \\ 0 & 1 & 3 \end{bmatrix}.$$

矩阵元素均为非负整数, 三列总数分别为 3, 3, 4 且没有空文档, 因而既符合上一站的词项计数约定, 也能合法展开为 LDA 的有序观测词元。本章不把它只写成 $\mathbf{WH}$, 而是分别用 θ_m 与 φ_k 生成主题指派和单词; 矩阵总计数等于词元数 $I = 10$ 。上一站见第 4 册第 6 章的 PLSA 概率分解。

例题 35.1 (一次折叠 Gibbs 更新). 取本章小型例子的计数与超参数。求两个候选主题的满条件概率, 并说明旧主题计数何时删除、何时恢复。

例题 35.1 解答

读题翻译 更新当前词元主题前, 先从“文档—主题”和“主题—词”两张计数表删除它的旧贡献; 用删除后的计数比较两个候选主题, 归一化抽样后再把词元加入新主题。

已知与合法条件 本章小例的删除后计数与正超参数已固定; 两个候选未归一化质量为有限正数, 因此归一化分母严格为正。

为什么想到这个方法 折叠 Gibbs 单点更新必须遵循“减旧计数—算 K 个满条件质量—归一化抽样—加新计数”, 且两个计数因子都使用排除当前词元的同一状态。

方法选择 先删除旧主题贡献, 按式 (35.6) 分别算 r_1, r_2 , 除以 $r_1 + r_2$ 得到概率; 抽样后只把新主题对应的两项计数各加一。

推导/计算 删去当前词元后得

$$r_1 = \frac{3}{26}, \quad r_2 = \frac{5}{44}, \quad r_1 + r_2 = \frac{131}{572}.$$

归一化后

$$\Pr(z_i = 1 | \mathbf{z}_{-i}, \mathbf{w}) = \frac{r_1}{r_1 + r_2} = \frac{66}{131}, \quad \Pr(z_i = 2 | \mathbf{z}_{-i}, \mathbf{w}) = \frac{65}{131}.$$

必须在计算前从旧主题对应的两张表各减一；抽到新主题后再加一。

独立核验 $66/131 + 65/131 = 1$ ；若把抽得的新主题再删去并把旧主题加回，两张计数表都精确恢复到更新前状态，说明“减 - 算 - 抽 - 加”保持词元总数守恒。

结论 本次两个候选主题的满条件概率为 $(66/131, 65/131)$ 。旧主题贡献必须在计算前从两张计数表各删除一次，抽样后再向新主题对应的两张表各加一；漏删、重复删或漏加都会改变目标 Gibbs 核。

例题 35.2 (一次平均场责任度更新). 给定 $K = 2$ 、 $\gamma = (3, 2)$ 以及 $(\varphi_{1v}, \varphi_{2v}) = (0.6, 0.2)$ ，计算 η_n 。

例题 35.2 解答

读题翻译 对当前词元分别计算两个主题的平均场未归一化责任度：文档主题项由 digamma 差给出，主题词项由 φ_{kv} 给出；最后统一归一化。

已知与合法条件 $K = 2$ 、 $\gamma = (3, 2)$ ，总参数为 5； $(\varphi_{1v}, \varphi_{2v}) = (0.6, 0.2)$ 均严格为正，两个候选权重有共同的正归一化分母。

为什么想到这个方法 坐标更新使用 $u_k = \exp\{\psi(\gamma_k) - \psi(\sum_j \gamma_j) + \log \varphi_{kv}\} = \varphi_{kv} e^{\psi(\gamma_k) - \psi(5)}$ ，再令 $\eta_{nk} = u_k / \sum_j u_j$ 。

方法选择 先利用整数 digamma 恒等式求两个差值，形成 u_1, u_2 ，再归一化并用权重比独立核对责任度比。

推导/计算 整数 digamma 差给出

$$\psi(3) - \psi(5) = -\frac{7}{12}, \quad \psi(2) - \psi(5) = -\frac{13}{12},$$

故未归一化权重和责任度依次为

$$\mathbf{u} = (0.6e^{-7/12}, 0.2e^{-13/12}) \approx (0.3348, 0.0677), \quad \eta_n = \frac{\mathbf{u}}{u_1 + u_2} \approx (0.832, 0.168).$$

独立核验 两个主题词概率都严格为正，且 $u_1/u_2 = 3e^{1/2} \approx 4.946$ 与 $0.832/0.168$ 在舍入误差内一致；同时 $0.832 + 0.168 = 1$ 。

结论 当前词元的平均场责任度约为 $\eta_n = (0.832, 0.168)$ 。统一归一化和 $\varphi_{kv} > 0$ 是该对数形式坐标更新的定义条件，不是事后的显示修正。

例题 35.3 (留出困惑度). 两个留出词的预测概率分别为 0.25 和 0.5。求每词困惑度；若错误地把概率改成训练后重估得到的 0.5 和 0.8，说明为什么数值虽更小却不可比较。

例题 35.3 解答

读题翻译 用训练完成后冻结的模型评估两个留出词：先平均它们的负对数预测概率，再指数化为每词困惑度；使用留出词重估后的概率属于信息泄漏，不能与冻结协议横向比较。

已知与合法条件 合法留出预测概率为 0.25, 0.5，均严格为正，留出词数为 $N = 2$ ；另一组 0.5, 0.8 来自看过留出词后的重估模型。

为什么想到这个方法 固定模型的每词困惑度为 $\exp\{-N^{-1} \sum_{i=1}^N \log p(w_i)\}$ ；所有候选数值必须来自同一训练/冻结/评估协议。

方法选择 将两个合法概率代入平均负对数似然并化成几何平均的倒数；再单独计算泄漏数值，只用于说明协议改变而非性能提升。

推导/计算

$$\text{perplexity} = \exp\left\{-\frac{1}{2}(\log 0.25 + \log 0.5)\right\} = \frac{1}{\sqrt{0.125}} = 2\sqrt{2} \approx 2.828.$$

若让留出词参与重估，则表面数值变成

$$\text{perplexity}_{\text{leak}} = \exp\left\{-\frac{1}{2}(\log 0.5 + \log 0.8)\right\} = \frac{1}{\sqrt{0.4}} \approx 1.581.$$

独立核验 合法值也可由预测概率几何平均复算： $\text{perplexity} = 1/\sqrt{0.25 \cdot 0.5} = 2\sqrt{2}$ ；两个概率均严格为正，因此没有支持失败。

结论 冻结模型的合法留出困惑度为 $2\sqrt{2} \approx 2.828$ 。重估后得到的 $1/\sqrt{0.4} \approx 1.581$ 使用了留出信息，与前者不是同一评估协议，不能据此宣称困惑度改善。

本章共 16 道练习。每道题干后立即给出同号解析；长解析可自然跨页，续页标题保留题号。

【原书练习整理】

练习 35.1. 对第四册潜在语义分析章使用的固定小语料建立 $K = 2$ 的 LDA 分析方案：给出词表、生成变量、一次可复现初始化、至少一次推断更新以及文档主题和主题关键词的输出格式。若不实际运行随机程序，哪些结论只能写成“计算方案”而不能虚构成数值结果？

练习 35.1 解析

沿用第四册固定的词袋矩阵，按下列顺序编码词表：(book, dads, dummies, estate, guide, investing, market, real, rich, stock, value)。九篇文档依次为 $T1 = (\text{guide, investing, market, stock})$, $T2 = (\text{dummies, investing})$, $T3 = (\text{book, investing, market, stock})$, $T4 = (\text{book, investing, value})$, $T5 = (\text{investing, value})$, $T6 = (\text{dads, guide, investing, market, stock})$, $T7 = (\text{guide, investing, market, stock})$, $T8 = (\text{book, investing, market, stock})$, $T9 = (\text{book, investing, value})$ 。

练习 35.1 解析 (续)

rich, rich), $T7 = (\text{estate}, \text{investing}, \text{real})$, $T8 = (\text{dummies}, \text{investing}, \text{stock})$, $T9 = (\text{dads}, \text{estate}, \text{investing}, \text{real}, \text{rich})$, 共 31 个词元。

取 $K = 2$, $\alpha = (1, 1)$, $\beta = \mathbf{1}_{11}$; 每篇文档内部按上述词表顺序展开词元, 并令 $z_{mn}^{(0)} = 1$ 当且仅当 $m+n$ 为偶数, 否则令其为 2。这给出不依赖随机数的可复现初始化。以 $T1$ 首词 guide 为一次手算更新: 删去它后, $(n_{11}^{-i}, n_{12}^{-i}) = (1, 2)$, $(n_{1, \text{guide}}^{-i}, n_{2, \text{guide}}^{-i}) = (1, 0)$, $(n_{1\cdot}^{-i}, n_{2\cdot}^{-i}) = (14, 16)$, 故两个未归一化权重为

$$r_1 = \frac{1+1}{3+2} \frac{1+1}{14+11} = \frac{4}{125}, \quad r_2 = \frac{2+1}{3+2} \frac{0+1}{16+11} = \frac{1}{45}.$$

归一化链为

$$r_1 + r_2 = \frac{61}{1125}, \quad \Pr(z_i = 1 | -) = \frac{36}{61}, \quad \Pr(z_i = 2 | -) = \frac{25}{61}.$$

这一步核验的是“减-算”; 实际“抽-加”还须记录伪随机生成器、实现版本与种子, 不能把未执行的随机抽样写成既成结果。

最终输出应固定为两张表: $T_m | \hat{\theta}_{m1}, \hat{\theta}_{m2}$, 以及 $k |$ 按 $\hat{\varphi}_{kv}$ 降序排列的词与概率; 另附迭代数、留样规则、种子和诊断量。其中每个留样状态的归一化估计量是

$$\hat{\theta}_{mk} = \frac{n_{mk} + \alpha_k}{N_m + \alpha_0}, \quad \hat{\varphi}_{kv} = \frac{n_{kv} + \beta_v}{n_{k\cdot} + \beta_0},$$

多次留样时再对这些估计量作样本平均。变分方案也须记录初始 φ , 按算法 35.3 完成局部更新和一次归一化期望计数 M 步。若没有实际运行程序, 只能报告上述数据编码、公式、手算条件更新、输出表结构和验收条件; 不能声称某词最终属于某主题、某文档比例为何值, 也不能虚构困惑度或收敛轮数。

练习 35.2. 分别指出折叠 Gibbs 与变分 EM 中 Dirichlet 分布出现的位置, 并解释共轭性、平滑和期望对数各自为何重要。

练习 35.2 解析

Gibbs 中 $\theta_m \sim \text{Dir}(\alpha)$, $\varphi_k \sim \text{Dir}(\beta)$ 与类别似然共轭, 使二者可积分消去, 留下 Beta 函数比值和式 (35.6); α, β 又以伪计数平滑零计数。

$$\int p(\theta_m | \alpha) \prod_k \theta_{mk}^{n_{mk}} d\theta_m = \frac{B(n_m + \alpha)}{B(\alpha)}, \quad \int p(\varphi_k | \beta) \prod_v \varphi_{kv}^{n_{kv}} d\varphi_k = \frac{B(n_k + \beta)}{B(\beta)}.$$

变分法中 $q(\theta_m) = \text{Dir}(\gamma_m)$, 其

$$\mathbb{E}_q \log \theta_{mk} = \psi(\gamma_{mk}) - \psi(\gamma_{m0}), \quad \eta_{mnk} \propto \varphi_{k, w_{mn}} \exp\{\mathbb{E}_q \log \theta_{mk}\},$$

进入责任度更新; 模型先验仍通过

$$\gamma_{mk} = \alpha_k + \sum_n \eta_{mnk}, \quad \sum_k \eta_{mnk} = 1$$

提供平滑。因此共轭性保证解析族闭合, 平滑避免零概率, 期望对数则是平均场坐标更新的自然参数, 三者作用不同。

练习 35.3. 以 $I, K, V, M, T_G, T_E, T_M$ 为规模参数, 给出稠密折叠 Gibbs 和批量变分 EM 的训练时间、预测时间与空间复杂度, 并说明每个界的实现假设。

练习 35.3 解析

令 T_G 为 Gibbs 总扫描数, 则稠密候选计算是 $O(T_G IK)$ 。更完整地,

$$\text{Gibbs 训练} = O(T_G IK), \quad \text{新文档折入} = O(T_E N_m K), \quad \text{工作空间} = O(KV + MK + I).$$

若 T_S 个完整指派样本全部驻留内存, 还须加 $O(T_S I)$, 流式落盘或在线汇总则不加。令变分 EM 外层为 T_M 、每个 E 步平均 T_E 轮, 则训练为

$$\text{变分训练} = O(T_M T_E IK + T_M KV), \quad \text{新文档推断} = O(T_E N_m K).$$

批量保存责任度与流式处理的空间界分别为

$$O(IK + KV + MK), \quad O(K \max_m N_m + KV + MK).$$

这里还假设每个外层轮次只做固定上限个 Newton 候选, 并利用 Hessian 的对角加秩一结构以 $O(K)$ 求解; 若用普通稠密求解, 训练界另加 $O(T_M K^3)$ 。这些界假设稠密遍历 K 个主题、固定精度特殊函数和 $O(1)$ 数组访问; 稀疏/并行实现需另列同步与索引成本。

练习 35.4. 证明精确块更新下变分 EM 的 ELBO 单调不减; 说明为什么这自动证明真实证据在每个受限 E 步后等于 ELBO, 也不保证参数收敛到全局最优。

练习 35.4 解析

固定模型参数的精确块 E 更新不会降低 ELBO; 固定新 q 的精确块 M 更新也不会降低 ELBO, 故

$$\mathcal{L}(q^t, \Theta^t) \leq \mathcal{L}(q^{t+1}, \Theta^t) \leq \mathcal{L}(q^{t+1}, \Theta^{t+1}).$$

ELBO 有上界时其数值收敛。由式 (35.8),

$$\log p(\mathbf{w} | \Theta) = \mathcal{L}(q, \Theta) + \text{KL}(q(\mathbf{h}) \| p(\mathbf{h} | \mathbf{w}, \Theta)),$$

ELBO 等于真实证据还要求 KL 间隙为零; 受限平均场通常不满足。非凸目标、标签置换和边界驻点又说明 ELBO 值收敛不等于参数唯一, 更不等于全局最优。

练习 35.5. 写出 $M = 3, K = 4, V = 10$ 时 $\theta, \varphi, \mathbf{z}, \mathbf{w}$ 的维数与取值域, 并把式 (35.1) 按板块逐项核对。

练习 35.5 解析

$$\theta = (\theta_{mk}) \in (\Delta^3)^3 \quad (3 \times 4), \quad \varphi = (\varphi_{kv}) \in (\Delta^9)^4 \quad (4 \times 10).$$

两组离散变量按文档长度形成锯齿形序列:

$$\mathbf{z}_{mn} \in \{1, 2, 3, 4\}, \quad \mathbf{w}_{mn} \in \{1, \dots, 10\}, \quad n = 1, \dots, N_m.$$

练习 35.5 解析 (续)

式 (35.1) 逐板块展开为

$$\prod_{k=1}^4 p(\varphi_k | \beta) \prod_{m=1}^3 p(\theta_m | \alpha) \prod_{m=1}^3 \prod_{n=1}^{N_m} p(z_{mn} | \theta_m) p(w_{mn} | z_{mn}, \varphi).$$

因此有 4 个主题先验因子、3 个文档先验因子和 $\sum_m N_m$ 对“主题指派 $\times$ 单词发射”因子，恰与三个板块重复次数一致。

练习 35.6. 从概率图判断： w_{mn} 在给定哪些变量时与其他词位置条件独立？边缘化 θ_m 后，同文档两个词是否仍独立？给出理由。

练习 35.6 解析

给定 z_{mn} 和全部 φ 时， w_{mn} 与其他位置的词和主题条件独立；若不显式给 z_{mn} ，给定 θ_m, φ 后积分该位置主题，词位置仍条件独立。

$$p(w_m | z_m, \varphi) = \prod_{n=1}^{N_m} \varphi_{z_{mn}, w_{mn}}, \quad p(w_m | \theta_m, \varphi) = \prod_{n=1}^{N_m} \sum_k \theta_{mk} \varphi_{k, w_{mn}}.$$

边缘化共享的 θ_m 后，同文档位置通常相关，因为观察一个词会改变对 θ_m 的后验，从而改变另一词的预测分布。

$$p(w_{m1}, w_{m2} | \varphi, \alpha) = \int \prod_{j=1}^2 \left(\sum_k \theta_{mk} \varphi_{k, w_{mj}} \right) p(\theta_m | \alpha) d\theta_m \neq \prod_{j=1}^2 p(w_{mj} | \varphi, \alpha)$$

一般成立，右侧不等是共享随机混合比例造成的。

练习 35.7. 证明给定 θ_m, φ 时词序列交换；再构造一个共享随机主题比例的二词例子，说明交换不等于边缘独立。

练习 35.7 解析

给定参数时联合概率是同一组位置因子的乘积，置换不改变乘积。

$$p(w_{m1:N_m} | \theta_m, \varphi) = \prod_{n=1}^{N_m} \sum_k \theta_{mk} \varphi_{k, w_{mn}} = p(w_{m, \pi(1): \pi(N_m)} | \theta_m, \varphi)$$

对任意置换 π 都成立。反例取随机 $\Theta \sim \text{Beta}(1, 1)$ ，给定 Θ 后两个二元词独立且成功概率为 Θ 。

$$\Pr(W_1 = 1) = \Pr(W_2 = 1) = \mathbb{E}\Theta = \frac{1}{2}, \quad \Pr(W_1 = W_2 = 1) = \mathbb{E}\Theta^2 = \frac{1}{3} \neq \frac{1}{4}.$$

所以两词边缘不独立；但联合式对两位置对称，故仍交换。

练习 35.8. 从两个 Dirichlet 积分完整推出式 (35.5), 写清每个 Beta 函数的向量维数和积分变量。

练习 35.8 解析

对每个主题 k , 在 V 分量概率向量上积分得

$$\int_{\Delta^{V-1}} \frac{1}{B(\beta)} \prod_v \varphi_{kv}^{n_{kv} + \beta_v - 1} d\varphi_k = \frac{B(n_k + \beta)}{B(\beta)}.$$

对每篇文档 m , 在 K 分量概率向量上积分得

$$\int_{\Delta^{K-1}} \frac{1}{B(\alpha)} \prod_k \theta_{mk}^{n_{mk} + \alpha_k - 1} d\theta_m = \frac{B(n_m + \alpha)}{B(\alpha)}.$$

分别对 K 个主题和 M 篇文档相乘即得式 (35.5)。

练习 35.9. 对当前词元 $i = (m, n)$, 用 Gamma 函数比值从折叠联合分布推出式 (35.6); 解释上标 $-i$ 为何必须同时作用于两类计数。

练习 35.9 解析

候选 k 相对留一状态只把 n_{kv}^{-i} 与 n_{mk}^{-i} 各加 1。Beta 函数比值用 $\Gamma(x+1)/\Gamma(x) = x$ 化为

$$r_k = \frac{n_{kv}^{-i} + \beta_v}{n_{k\cdot}^{-i} + \beta_0} \frac{n_{mk}^{-i} + \alpha_k}{n_{m\cdot}^{-i} + \alpha_0}.$$

满条件概率还须在主题上归一化:

$$\Pr(z_i = k \mid \mathbf{z}_{-i}, \mathbf{w}) = \frac{r_k}{\sum_{\ell=1}^K r_\ell}.$$

若只从一张表删旧词元, 两张表不再描述同一个 $\mathbf{z}_{-i}$, 所得比值就不是任何一致联合分布的满条件概率。

练习 35.10. 取 $K = 2, V = 3$, $\alpha = (1, 1)$, $\beta = (1, 1, 1)$, 留一计数 $(n_{1v}, n_{2v}) = (2, 1)$, $(n_{1\cdot}, n_{2\cdot}) = (5, 4)$, $(n_{m1}, n_{m2}) = (1, 3)$ 。计算一次主题更新的归一化概率。

练习 35.10 解析

两个权重为

$$r_1 = \frac{2+1}{5+3} \frac{1+1}{1+3+2} = \frac{1}{8}, \quad r_2 = \frac{1+1}{4+3} \frac{3+1}{1+3+2} = \frac{4}{21}.$$

归一化链为

$$r_1 + r_2 = \frac{53}{168}, \quad p(z_i = 1 \mid -) = \frac{21}{53}, \quad p(z_i = 2 \mid -) = \frac{32}{53}.$$

练习 35.11. 给定 $\alpha = (2, 1)$ 、 $\beta = (1, 1, 1)$ ，某文档主题计数 $(3, 2)$ ，两个主题的词计数行分别为 $(4, 1, 0)$ 和 $(1, 2, 2)$ 。计算平滑后的 $\hat{\theta}_m$ 与两行 $\hat{\phi}$ ，核验各行和为 1。

练习 35.11 解析

文档后验伪计数为 $(5, 3)$ ，故

$$\hat{\theta}_m = \frac{(3, 2) + (2, 1)}{3 + 2 + 2 + 1} = \left(\frac{5}{8}, \frac{3}{8}\right).$$

第一主题词伪计数为 $(5, 2, 1)$ ，第二主题为 $(2, 3, 3)$ ，所以

$$\hat{\phi}_1 = (5/8, 1/4, 1/8), \quad \hat{\phi}_2 = (1/4, 3/8, 3/8).$$

归一化核验为

$$\sum_k \hat{\theta}_{mk} = 1, \quad \sum_v \hat{\phi}_{1v} = 1, \quad \sum_v \hat{\phi}_{2v} = 1.$$

练习 35.12. 从 KL 定义证明式 (35.8)，并分别说明 $\mathcal{Q}$ 包含精确后验和不包含精确后验时最优 KL 间隙。

练习 35.12 解析

把 $\log p(h | w) = \log p(w, h) - \log p(w)$ 代入 $\text{KL}(q \| p) = \mathbb{E}_q \log q - \mathbb{E}_q \log p(h | w)$ ，得到

$$\begin{aligned} \text{KL}(q(h) \| p(h | w)) &= \mathbb{E}_q \log q(h) - \mathbb{E}_q \log p(w, h) + \log p(w) \\ &= \log p(w) - \mathcal{L}(q), \end{aligned}$$

即

$$\log p(w) = \mathcal{L}(q) + \text{KL}(q(h) \| p(h | w)).$$

若 $\mathcal{Q}$ 含精确后验，最优 q 可使 KL 为 0，ELBO 达到证据；对任一可行 $q \neq p(h | w)$ ，KL 严格为正。若 $\mathcal{Q}$ 中的最小值实际取到且精确后验不属于 $\mathcal{Q}$ ，则最优间隙严格为正；若只有下确界，则该下确界也可能为 0 而不取到。

练习 35.13. 利用拉格朗日乘子推出式 (35.11)，必须写出 $\sum_k \eta_{mnk} = 1$ 约束和归一化常数。再按本章点参数模型的支持契约，分别判断“某主题对观察词概率为零”“留出词不在训练活动词表”“某主题期望总计数为零”三类输入应在何处停止。

练习 35.13 解析

与 η_{mn} 有关的目标为

$$\sum_k \eta_{mnk} \{\log \varphi_{k, w_{mn}} + \psi(\gamma_{mk}) - \psi(\gamma_{m0})\} - \sum_k \eta_{mnk} \log \eta_{mnk} + \lambda (\sum_k \eta_{mnk} - 1).$$

记 $a_k = \log \varphi_{k, w_{mn}} + \psi(\gamma_{mk}) - \psi(\gamma_{m0})$ ，求偏导得

$$\frac{\partial}{\partial \eta_{mnk}} = a_k - \log \eta_{mnk} - 1 + \lambda = 0, \quad \eta_{mnk} = e^{\lambda-1} e^{a_k}.$$

练习 35.13 解析 (续)

由 $\sum_k \eta_{mnk} = 1$ 确定归一化常数:

$$u_k = e^{a_k}, \quad Z_{mn} = \sum_{\ell=1}^K u_{\ell}, \quad \eta_{mnk} = \frac{u_k}{Z_{mn}},$$

即式 (35.11)。

边界核验。三类测试不能进入同一条浮点归一化链: **(1)** 若某个 $\varphi_{k,w_{mn}} = 0$, 在局部更新取对数之前返回

`invalid_input(support_failure).`

(2) 若留出词不属于 $\mathcal{V}_{tr}$ 且未映射到已训练 UNK, 在困惑度取对数之前返回同一 `support_failure`, 困惑度未定义。**(3)** 若某主题 $C_{k\cdot} = 0$, 在 M 步除法之前返回

`numerical_failure(empty_topic).`

此外, 若 $C_{k\cdot} > 0$ 但某个活动词的 $C_{kv} = 0$, 则命名为

`numerical_failure(support_collapse).`

四条分支都保留上一合法状态, 不把 $\log 0$ 或 $0/0$ 送入数值计算。

练习 35.14. 取 $\alpha = (1, 1)$, 三词责任度为 $(0.8, 0.2)$ 、 $(0.3, 0.7)$ 、 $(0.6, 0.4)$ 。完成一次 γ 更新; 若下一轮责任度不变, 说明停止判断还应检查什么。

练习 35.14 解析

责任度列和为 $(1.7, 1.3)$, 故

$$\gamma = \alpha + \sum_{n=1}^3 \eta_n = (1, 1) + (1.7, 1.3) = (2.7, 2.3).$$

下一轮责任度不变意味着坐标固定, 但停止还须核验

$$\frac{|\mathcal{L}^{(t+1)} - \mathcal{L}^{(t)}|}{1 + |\mathcal{L}^{(t)}|} < \varepsilon, \quad \min_k \gamma_k > 0, \quad \max_n \left| \sum_k \eta_{nk} - 1 \right| < \varepsilon_{\text{norm}},$$

并要求局部 ELBO 有限, 以排除下溢造成的伪不变。

练习 35.15. 某主题对三个词的期望计数依次为 2.5, 1, 0.5。求无先验的 φ_k 更新, 说明原计数为何不是概率; 再说明 Newton 更新 α 时如何保护正性。

练习 35.15 解析

总计数为 4, 所以

$$\varphi_k = \frac{(2.5, 1, 0.5)}{2.5 + 1 + 0.5} = (0.625, 0.25, 0.125), \quad \sum_v \varphi_{kv} = 1.$$

练习 35.15 解析 (续)

原计数向量和为 4 而非 1, 不能作为类别概率。Newton 候选先解

$$H(\alpha)\Delta = g(\alpha), \quad \alpha^+ = \alpha - \rho\Delta, \quad \rho \in \{1, \frac{1}{2}, \frac{1}{4}, \dots\},$$

再回溯到

$$\min_k \alpha_k^+ > 0, \quad \mathcal{L}(\alpha^+) \geq \mathcal{L}(\alpha).$$

若步长低于下限仍失败, 则保留旧值并返回诊断。

练习 35.16. 为同一语料设计 Gibbs 与变分 EM 的公平比较: 固定训练/验证/测试切分、 K 、词表和预算, 列出至少四项诊断与两个评价指标, 并说明文档完成式困惑度如何避免信息泄漏。

练习 35.16 解析

先冻结同一分层切分、词表、未知词规则、 K 与总计算预算:

$$(\mathcal{D}_{\text{tr}}, \mathcal{D}_{\text{va}}, \mathcal{D}_{\text{te}}, \mathcal{V}, K, B)_{\text{Gibbs}} = (\mathcal{D}_{\text{tr}}, \mathcal{D}_{\text{va}}, \mathcal{D}_{\text{te}}, \mathcal{V}, K, B)_{\text{VI}}.$$

Gibbs 至少报告链间主题匹配后的计数稳定性、有效样本量/自相关、留样数和随机种子; 变分至少报告 ELBO 轨迹、不同初始化的离散程度、局部未收敛文档数和边界/空主题。共同指标可用文档完成式留出困惑度与主题稳定/语义连贯度, 并同时报告运行时间和最大工作存储量。文档完成时只用文档的观察部分推断

$$\hat{\theta}_m = \text{Infer}(\mathbf{w}_m^{\text{obs}}; \hat{\varphi}), \quad \ell_m^{\text{hold}} = \sum_{v \in \mathbf{w}_m^{\text{hold}}} \log \sum_k \hat{\theta}_{mk} \hat{\varphi}_{kv},$$

再以

$$\text{PPL} = \exp \left\{ - \frac{\sum_m \ell_m^{\text{hold}}}{\sum_m |\mathbf{w}_m^{\text{hold}}|} \right\}$$

评价被遮住的词; 若遮住词参与 E 步, 就发生信息泄漏。

读前自检: 本章结论与下一步。 潜在狄利克雷分配章末由“LDA 以文档主题向量与主题词向量形成两层混合生成模型, 词袋交换性不等于词元独立”落到“折叠 Gibbs 执行“减—算—抽—加”, 变分 EM 在局部责任度与全局参数之间交替”; 请把前者产出和后者输入逐项对齐, 固定核对前者末项的输出类型能否作为后者首项的输入类型。

本章结论与下一步

核心结论: LDA 以文档主题向量与主题词向量形成两层混合生成模型, 词袋交换性不等于词元独立。

关键依据: 两组严格正 Dirichlet 先验经多元 Beta 积分得到折叠联合; ELBO 恒等式和 KL 差给出可归一化坐标最优。

可执行自检: 折叠 Gibbs 执行“减—算—抽—加”, 变分 EM 在局部责任度与全局参数之间交替。

适用边界: 适用于计数语料与明确词表; 燃烧期不是收敛证明, ELBO 不等于真实证据, 困惑度也不等于解释性。

下一步: 进入第 36 章: PageRank 算法; 第 37 章统一比较矩阵分解、概率主题模型与采样推断。

1. **概念**：能否区分 θ/φ 、 α/β 、 η/φ ，并解释交换性不等于独立？不能则回看定义 35.1 和节 35.5。
2. **推导**：能否不跳步推出折叠联合、留一比值、KL-ELBO 恒等式和两条平均场更新？不能则回看节 35.3、35.4 的正式结果。
3. **算法**：能否写出 Gibbs “减 – 算 – 抽 – 加” 顺序，以及变分 EM 内外循环、停止条件和异常分支？不能则回看算法 35.2–35.3。
4. **应用与复现**：能否为新语料冻结切分、词表和预处理，选择 K ，设计多启动/多链，并在相同初始化预算下用无泄漏困惑度、稳定性和诊断公平比较？不能则回看节 35.5。
5. **诊断**：能否区分链未混合、局部 ELBO 未收敛、空主题与评价泄漏，并为每类问题给出对应证据？不能则回看节 35.5 的诊断要求；五类均能独立完成，才算掌握本章，只会调用现成主题模型而不能解释计数、ELBO 和评价切分，不视为通过。

第 36 章 PageRank 算法

读前自检：本章地图：算法。 PageRank 算法地图给出“网页图 → 列随机游走 → 悬挂修复与阻尼 → 稀疏幂法”；请写成一条带方向的依赖链，再用终点的输出说明它怎样回答本章核心问题，并核对路线“网页图 → 列随机游走 → 悬挂修复与阻尼 → 稀疏幂法”的前一产出能够直接作为后一输入。

读前自检：本章可检验学习目标。 PageRank 算法学习目标固定核验“采用列随机约定，把网页有向图、出度和随机游走写成维数明确的转移矩阵”；请实际完成“采用列随机约定，把网页有向图、出度和随机游走写成维数明确的转移矩阵”，并用“中间结果逐项包含首目标“采用列随机约定，把网页有向图、出度和随机游走写成维数明确的转移矩阵”声明的对象、条件与结论”判定通过或失败。

读前自检：最短先修。 PageRank 先修采用列随机约定；请给结点 j 的三条出链各写 $1/3$ 到矩阵第 j 列，核对该列和为 1，并说明分布按 $\boldsymbol{p}^{(t+1)} = M\boldsymbol{p}^{(t)}$ 推进。

读前自检：先修自检。 PageRank 算法先修自检固定核验“若 j 有三条出链，能否在矩阵第 j 列写出三个 $1/3$ ，并核验列和为 1”；请在 j 有三条出链条件下，实际在矩阵第 j 列写出三个 $1/3$ ，并核验列和为 1 并写出中间结果，再按“中间结果直接回答首项“若 j 有三条出链，能否在矩阵第 j 列写出三个 $1/3$ ，并核验列和为 1”并给出通过或失败”明确判为通过或失败。

读前自检：依赖路线。 PageRank 算法把“第 30 章（第 5 册第 1 章）的行随机链及该等式 → 第 36 章（第 5 册第 7 章）的列随机网页游走”接到“有向图与出度 → 列随机游走”；请用 → 补全这一步的等式或判据，再检查两端维数、支持或对象类型。

本章地图

核心问题：怎样把链接方向写成概率算子，并在悬挂、可约或周期图上得到可计算的唯一排序？

可检验学习目标：

- 采用列随机约定，把网页有向图、出度和随机游走写成维数明确的转移矩阵；
- 区分基本 PageRank 与一般 PageRank，识别周期、可约和悬挂结点造成的不同故障；
- 严格执行“先修复悬挂列，再构造阻尼矩阵”，并始终保持 $0 \leq d < 1$ ；
- 从入链贡献、平稳分布、压缩映射和线性方程四个角度理解 PageRank；
- 用稀疏幂法计算排序，给出可核验的停止误差界、异常情形和时间空间复杂度；
- 能复算本章四个代表性例题，并独立完成存在性、收敛性和复杂度证明。

最短先修：本章直接使用有向图、矩阵乘法、概率向量、一阶马尔可夫链、特征值与特征向量、诱导 1 范数、几何级数和线性方程组。必须先固定矩阵方向：本章所有概率分布均为列向量， M_{ij} 表示“从结点 j 转到结点 i ”的概率，故随机矩阵按列归一化。与第 30 章（第 5 册第 1 章）的行随机约定桥接时，为避免与本章邻接矩阵 A 混淆，把该章的行随机转移矩阵在此记作 P ；于是 $P_{ji} = \Pr(X_{t+1} = i \mid X_t = j)$ 且 $\boldsymbol{p}_{t+1} = \boldsymbol{p}_t P$ ，并令

$$M = P^T, \quad \boldsymbol{p}^{(t)} = \boldsymbol{p}_t^T.$$

于是 $p^{(t+1)} = Mp^{(t)}$ 与 $\rho_{t+1} = \rho_t P$ 完全等价, 平稳方程 $p_\star = Mp_\star$ 也等价于 $\rho_\star = \rho_\star P$; 这正是式 (30.6)。因此转换约定时必须同时转置矩阵和概率向量, 不能只转置某一个公式。

依赖路线: 第 30 章 (第 5 册第 1 章) 的行随机链及式 (30.6) → 第 36 章 (第 5 册第 7 章) 的列随机网页游走; 有向图与出度 → 列随机游走; 随机游走 → 平稳分布 → 基本 PageRank; 悬挂列修复与随机跳转 → 正的阻尼矩阵 → 唯一一般 PageRank; 主特征向量与压缩映射 → 幂法和误差证书; 稀疏矩阵 - 向量乘法 → 大图实现。图 36.1 给出这些直接依赖。

完成标准与返回: 先复习第 30 章 (第 5 册第 1 章) 的平稳分布及式 (30.6), 再固定本章列随机方向。




图 36.1 PageRank 的知识依赖: 随机游走、平稳分布与幂法共同支撑图排序

方向桥: 行随机链与列随机 PageRank

第 30 章用行向量 $\rho_t \in \mathbb{R}^{1 \times n}$ 和行随机矩阵; 本章在桥接处把该行随机核记作 P , 以区别本章的网页邻接矩阵 A 。本章用列向量 $p^{(t)} \in \mathbb{R}^{n \times 1}$ 和列随机矩阵 M 。二者必须成对转置:

$$M = P^T, \quad p^{(t)} = \rho_t^T, \quad p^{(t+1)} = Mp^{(t)}.$$

例如 $n = 4$ 时, P, M 均为 4×4 , 但概率向量分别为 1×4 和 4×1 。只转置矩阵或只转置向量都会破坏乘法方向。

读前自检: 本章符号表。 PageRank 算法符号表规定 $\mathcal{V}, \mathcal{E}$ 、 $|\mathcal{V}| = n, |\mathcal{E}| = m$ 的类型或范围; 请把 $\mathcal{V}, \mathcal{E}$ 代入紧随其后的定义关系, 逐项核对输入形状、输出形状与取值域。

本章符号表

符号	对象与读法	维数/范围	角色
$\mathcal{V}, \mathcal{E}$	结点集、有向边集	$ \mathcal{V} = n, \mathcal{E} = m$	网页图
A	邻接矩阵, $A_{ij} > 0$ 表示 $j \rightarrow i$	$\mathbb{R}_{\geq 0}^{n \times n}$	边权存储
c_j	结点 j 的加权出度	$c_j = \sum_i A_{ij}$	列归一化分母

D	悬挂结点集合	$\{j : c_j = 0\}$	需要先修复的零列
M	未修复的沿链矩阵	$M_{ij} = A_{ij}/c_j (c_j > 0)$	非悬挂列转移
$\boldsymbol{v}$	个性化跳转分布	$\boldsymbol{v} \geq 0, \mathbf{1}^\top \boldsymbol{v} = 1$	悬挂修复与随机跳转
S	悬挂修复后的沿链矩阵	非负列随机	基础转移算子
d	阻尼因子	$0 \leq d < 1$	沿链转移概率
G	一般 PageRank 转移矩阵	$G = dS + (1-d)\boldsymbol{v}\mathbf{1}^\top$	列随机; $\boldsymbol{v} > 0$ 时严格正
$\boldsymbol{r}^{(t)}$	第 t 步排名向量	Δ^{n-1}	幂迭代状态
$\varepsilon, T_{\max}$	目标 1 范数误差、迭代上限	正数、正整数	停止与失败保护
$\rho(B), \ B\ _1$	谱半径、诱导 1 范数	非负实数	收敛与复杂度分析

下文的 $\mathbf{1}$ 均为维数由上下文确定的全一列向量, $\Delta^{n-1} = \{\boldsymbol{x} \geq 0 : \mathbf{1}^\top \boldsymbol{x} = 1\}$ 。

读前自检：PageRank 的随机游走思想。 PageRank 随机游走以列随机网页矩阵 M 和概率列向量 $\boldsymbol{p}^{(t)}$ 为状态；请完成一次 $\boldsymbol{p}^{(t+1)} = M\boldsymbol{p}^{(t)}$ ，核对非负且分量和仍为 1。

读前自检：PageRank 阻尼排序算法。 阻尼 PageRank 使用悬挂修复矩阵 S 、 $0 \leq d < 1$ 和跳转分布 $\boldsymbol{v}$ ；请计算一轮 $dS\boldsymbol{p} + (1-d)\boldsymbol{v}$ ，核对结果仍在概率单纯形。

读前自检：PageRank 固定点定义。 PageRank 固定点 $\boldsymbol{r} = dS\boldsymbol{r} + (1-d)\boldsymbol{v}$ 要求 $\boldsymbol{r} \in \Delta^{n-1}$ ；请把候选 $\boldsymbol{r}$ 回代两边，核对残差与分量和。

读前自检：链接权重按出度分配。 网页 j 的出权和 $c_j = \sum_i A_{ij} > 0$ 时令 $M_{ij} = A_{ij}/c_j$ ；请归一化一列并核对来源页的全部排名质量恰按出链权重分完。

读前自检：有向图和随机游走模型。 有向图约定 $A_{ij} > 0$ 表示 $j \rightarrow i$ ，非悬挂列按 c_j 归一为 $M_{:j}$ ；请把一条边放到正确行列，再核对随机游走从 j 转到 i 的概率为 M_{ij} 。

读前自检：有向图上的随机游走例。 有向图随机游走例强调箭头 $j \rightarrow i$ 写入第 j 列第 i 行；请沿图中一个来源结点分配其整列出链概率，再推进一次 $M\boldsymbol{p}$ ，核对输出是结点概率分布而非内容相关度。

36.1 网页图与随机游走

问题提出。 网页的重要性不能只由入链条数决定：一个被许多低质量页面引用的网页，未必比一个被少数高质量页面引用的网页更重要。PageRank 把链接解释为“重要性投票”，但每个来源网页的票又要由它自己的重要性加权。这个循环定义自然变成随机游走的平稳方程。算法的输出是结点上的概率分布，不是网页内容的相关性分数；主题相关检索仍需另一个模型。

图 36.2 取结点顺序 (i, j, h) 和四条单位权边 $i \rightarrow j, j \rightarrow i, j \rightarrow h, h \rightarrow i$ ，故 $(c_i, c_j, c_h) = (1, 2, 1)$ 且没有悬挂结点。

读图。 先按箭头写邻接矩阵 A ，再用 c_j 逐列归一得到 M ，最后转置为行随机矩阵 $P = M^\top$ ；两种推进分别为 $\boldsymbol{p}^{(t+1)} = M\boldsymbol{p}^{(t)}$ 与 $\rho_{t+1} = \rho_t P$ 。




图 36.2 列随机约定下的网页有向图，并给出与行随机马尔可夫链约定的显式转置桥。

读前自检：网页随机游走矩阵。 网页随机游走矩阵对非悬挂列取 $M_{ij} = A_{ij}/c_j$ ；请计算 $\mathbf{1}^T M$ ，核对应等于 $\mathbf{1}^T$ ，并说明悬挂列为何尚需修复。

定义 36.1 (网页随机游走矩阵). 给定加权有向图，约定 $A_{ij} \geq 0$ 是边 $j \rightarrow i$ 的权重， $c_j = \sum_{i=1}^n A_{ij}$ 。对 $c_j > 0$ 定义

$$M_{ij} = \frac{A_{ij}}{c_j};$$

对 $c_j = 0$ 暂令 $M_{ij} = 0$ 。若所有 $c_j > 0$ ，则 $M \geq 0$ 且 $\mathbf{1}^T M = \mathbf{1}^T$ ，称 M 为列随机矩阵。在状态 j 时，游走者以 M_{ij} 的概率转到 i 。

模型。 若 $p^{(t)} \in \Delta^{n-1}$ 是时刻 t 的状态分布，则

$$p^{(t+1)} = Mp^{(t)}, \quad p_i^{(t+1)} = \sum_{j:j \rightarrow i} \frac{A_{ij}}{c_j} p_j^{(t)}. \quad (36.1)$$

右式显示入链贡献由来源结点的出度摊薄。无出链结点对应零列，概率一旦进入便无法按该式继续分配；因此“零列仍是随机矩阵的一列”是错误说法。

学习策略。 PageRank 没有带标签损失函数，也不从特征拟合监督参数。它把图结构转换成马尔可夫算子，再以平稳分布作为全局排序。建模阶段确定边方向、边权、悬挂修复分布 $\mathbf{v}$ 和阻尼 d ；计算阶段求固定点；验证阶段检查概率守恒、固定点残差和排序稳定性。

学习算法。 基本模型直接反复乘 M ，但只有在结构条件成立时才从任意初值收敛。一般模型先把每个悬挂零列替换为 $\mathbf{v}$ ，再加入概率 $1-d$ 的随机跳转；最终用稀疏矩阵-向量乘法实现幂迭代。这里的“先修复、后混合”是定义的一部分，不能在已经含零列的 M 上直接写 $G = dM + (1-d)\mathbf{v}\mathbf{1}^T$ 并声称 G 列随机。

读前自检：PageRank 的基本定义。 基本 PageRank 只在 M 列随机时定义为 $M\mathbf{r} = \mathbf{r}$ 的概率向量；请从一个归一候选做一次 $M\mathbf{r}$ ，核对固定点残差为 0。

读前自检：基本 PageRank 固定点。 基本 PageRank 固定点要求 $r \geq 0$ 、 $\mathbf{1}^\top r = 1$ 与 $Mr = r$ ；请逐项检查候选，指出只满足特征方程但未归一时还不能作为排名分布。

36.2 基本 PageRank

定义 36.2 (基本 PageRank). 设 M 是网页图的列随机转移矩阵。满足

$$Mr = r, \quad r \in \Delta^{n-1} \quad (36.2)$$

的概率向量称为该随机游走的平稳分布。若它唯一，就把其第 i 个分量 r_i 称为结点 i 的基本 PageRank 值。

命题 36.1 (列随机矩阵保持概率单纯形) 若 $P \geq 0$ 且 $\mathbf{1}^\top P = \mathbf{1}^\top$ ，则 $P\Delta^{n-1} \subseteq \Delta^{n-1}$ ；并且对任意自然数 k ， P^k 仍为列随机矩阵。

读前自检：证明：列随机矩阵保持概率单纯形。 列随机矩阵 P 满足 $P \geq 0$ 与 $\mathbf{1}^\top P = \mathbf{1}^\top$ ；请对 $x \in \Delta^{n-1}$ 核对 Px 非负且分量和为 1，再归纳到 P^k 。

证明. 对 $x \in \Delta^{n-1}$ ，非负性给出 $Px \geq 0$ ，而 $\mathbf{1}^\top Px = \mathbf{1}^\top x = 1$ 。再由 $\mathbf{1}^\top P^k = (\mathbf{1}^\top P)P^{k-1} = \mathbf{1}^\top P^{k-1}$ 归纳得到 P^k 的列和为 1；矩阵乘积的非负性给出其元素非负。□

定理 36.1 (有限不可约非周期链的基本 PageRank) 若有限状态马尔可夫链的列随机转移矩阵 M 不可约且非周期，则存在唯一 $r \in \Delta^{n-1}$ 满足 $Mr = r$ ，且对任意 $r^{(0)} \in \Delta^{n-1}$ 都有 $M^t r^{(0)} \rightarrow r$ 。

进阶证明（首次阅读可跳过）。 正文主线只使用“有限、不可约、非周期 $\Rightarrow$ 唯一平稳分布且幂迭代收敛”的结论；下面用本原矩阵给出完整证明。

读前自检：证明：有限不可约非周期链的基本。 有限不可约非周期列随机矩阵 M 有唯一平稳概率向量 r ；请把 $M^t x$ 按剩余类分解，核对各子序列都趋于 r ，从而整序列收敛。

证明. 有限、不可约且非周期蕴含 M 是本原矩阵：存在正整数 q 使 M^q 的所有元素严格为正。令 $\delta = \min_{i,j} (M^q)_{ij} > 0$ 、 $\alpha = n\delta \in (0, 1]$ ，并记 $U = \mathbf{1}\mathbf{1}^\top/n$ 。若 $\alpha < 1$ ，可写 $M^q = \alpha U + (1 - \alpha)Q$ ，其中 Q 非负列随机；若 $\alpha = 1$ 则 $M^q = U$ 。对概率向量 x, y ，有 $U(x - y) = 0$ ，故

$$\|M^q x - M^q y\|_1 \leq (1 - \alpha)\|x - y\|_1.$$

于是 M^q 在完备的概率单纯形上是严格压缩，存在唯一不动点 r ，且 $M^{qk} x \rightarrow r$ 。又因 Mr 也是 M^q 的不动点，唯一性给出 $Mr = r$ 。对 $0 \leq s < q$ ， $M^{qk+s} x = M^s(M^{qk} x) \rightarrow M^s r = r$ ，从而整个序列收敛。任一 M 的平稳分布也是 M^q 的不动点，故平稳分布唯一。□

这一定理同时包含“唯一平稳分布”和“从任意初始分布收敛”两个结论。不可约但周期为 2 的链仍可有唯一平稳分布，却可能在两个状态间振荡；可约链则可能有多个闭类和多个平稳分布。图 36.3 在本章列向量、列随机约定下并列展示周期振荡与悬挂零列两类故障及其不同修复顺序。




图 36.3 基本 PageRank 的两类结构性故障：周期 2 链可有唯一平稳分布却从给定初值振荡；悬挂零列不是列随机核并会丢失质量，须先回填再阻尼。

读图检查。左栏先核对 $M_p e_1 = e_2$ 、 $M_p e_2 = e_1$ ，再区分“唯一平稳分布 $(1/2, 1/2)^\top$ 存在”与“从 e_1 逐步收敛”（后者不成立）；右栏核对 M_d 第 2 列和为 0 且 $M_d e_2 = 0$ ，故它不是列随机概率核并丢失质量，最后复述一般 PageRank 必须先以 v 回填悬挂列得到 S ，再由 S 构造阻尼 G 。

阅读目标：从入链贡献式构造随机跳转固定点，并得到可计算残差界。

对象：列随机链接矩阵、悬挂列、随机跳转分布 v 与阻尼系数 $0 < \alpha < 1$ 。

合法条件：修复后的 S 非负列随机， $\mathbf{1}^\top v = 1$ 。

第一步：先把 $x = Sx$ 的第 i 个分量写成所有入链结点贡献之和，再修复悬挂列。

推导目标

从列随机固定点逐行推出入链贡献式，再把悬挂修复和随机跳转合成为一般 PageRank 方程；最后推出可计算的线性方程与 1 范数误差证书。

推导准备

准备三个事实： A_{ij}/c_j 是从 j 到 i 的转移概率； $\mathbf{1}^\top x = 1$ 可把常向量项写成秩一矩阵作用；非负列随机矩阵满足 $\|S\|_1 = 1$ 。

推导第 1 步：展开固定点的第 i 个分量。由式 (36.2) 和定义 36.1，

$$r_i = \sum_{j=1}^n M_{ij} r_j = \sum_{j:j \rightarrow i} \frac{A_{ij}}{c_j} r_j. \quad (36.3)$$

读前自检：基本的入链平衡。 基本 PageRank 的入链平衡为 $r_i = \sum_{j:j \rightarrow i} A_{ij} r_j / c_j$ ；请对结点 i 逐入链累加，核对每个来源 j 只贡献其排名质量的出链份额。


命题 36.2 (基本 PageRank 的入链平衡) 在无悬挂结点的非加权图中，式 (36.3) 化为 $r_i = \sum_{j:j \rightarrow i} r_j / c_j$ 。每个来源 j 把自身质量 r_j 等分给 c_j 条出链，而结点 i 累加全部入链贡献。

读前自检：证明：基本的入链平衡。 非加权图中 $A_{ij} \in \{0, 1\}$ ；请把基本固定点第 i 分量展开，核对仅入链来源保留且每项为 r_j / c_j ，从而得到入链平衡式。

证明。 非加权图有 $A_{ij} \in \{0, 1\}$ 。固定 i ，矩阵乘法只保留满足 $A_{ij} = 1$ 的列 j ，每个保留项为 $(1/c_j)r_j$ ，逐项相加即得结论。 $\square$

图 36.4 在“基本 PageRank、无悬挂且此处 $S = M$ ”的作用域内，把来源列的分摊与目标行的累加画成连续因果链，并在图内同时封住一般 PageRank 的符号边界。

基本 PageRank 入链贡献（无悬挂；此处 $S = M$ ）



一般 PageRank 边界（不可外推上方“正元素对应入链”）

先以 $S = M + \mathbf{v}\mathbf{a}^T$ 修复悬挂列；若 $c_j = 0$ ，即使没有 $j \rightarrow i$ ，也可有 $S_{ij} = v_i > 0$ 。
 随后 $G = dS + (1-d)\mathbf{v}\mathbf{1}^T$ ；因此上方入链解释只属于基本无悬挂的 $M(=S)$ ，不能套到修复后的 S/G 。

图 36.4 基本 PageRank（无悬挂）的入链贡献及一般 PageRank 的适用边界。

读图检查。 沿每个来源 j 到目标 i 核对 $M_{ij}r_j^{(t)}$ 来自第 j 列，非加权时分母 $\deg^+(j)$ 属于来源 j ；再复述边界：上方只适用于基本无悬挂的 $M(=S)$ ，一般 PageRank 先用 $S = M + \mathbf{v}\mathbf{a}^T$ 修复悬挂列，再构造 $G = dS + (1-d)\mathbf{v}\mathbf{1}^T$ ，故修复后的 S/G 正元素不必对应原图中的入链。

读前自检：PageRank 的一般定义。 一般 PageRank 先用 $S = M + \mathbf{v}\mathbf{a}^T$ 修复悬挂列，再取 $G = dS + (1-d)\mathbf{v}\mathbf{1}^T$ ；请核对 S, G 均列随机并写出 $G\mathbf{r} = \mathbf{r}$ 。

36.3 一般 PageRank 与阻尼

先定义悬挂指示向量 $\mathbf{a}$: $a_j = 1$ 当且仅当 $c_j = 0$ 。以概率向量 $\mathbf{v} \in \Delta^{n-1}$ 填补每个悬挂列, 得到

$$S = M + \mathbf{v}\mathbf{a}^\top, \quad S_{:j} = \begin{cases} M_{:j}, & c_j > 0, \\ \mathbf{v}, & c_j = 0. \end{cases} \quad (36.4)$$

此时 S 才是列随机矩阵。

推导第 2 步: 在修复后的沿链矩阵上加入随机跳转。 对 $0 \leq d < 1$ 定义

$$G = dS + (1-d)\mathbf{v}\mathbf{1}^\top. \quad (36.5)$$

当输入是概率向量 $\mathbf{x}$ 时, $G\mathbf{x} = dS\mathbf{x} + (1-d)\mathbf{v}$; 即以概率 d 沿修复后的链接行走, 以概率 $1-d$ 按 $\mathbf{v}$ 跳转。对尚未按分量和归一化的任意向量, 必须使用完整线性式 $G\mathbf{x} = dS\mathbf{x} + (1-d)\mathbf{v}(\mathbf{1}^\top \mathbf{x})$, 不能漏掉最后的尺度因子。

读前自检: 一般矩阵与向量。 一般 PageRank 向量满足 $\mathbf{r} = dS\mathbf{r} + (1-d)\mathbf{v}$; 请标出 $S \in \mathbb{R}^{n \times n}$ 与各向量的形状, 核对两项同为 n 维概率质量。

定义 36.3 (一般 PageRank 矩阵与向量). 给定式 (36.4) 的 S 、概率向量 $\mathbf{v} \in \Delta^{n-1}$ 和 $0 \leq d < 1$, 称式 (36.5) 的 G 为一般 PageRank 转移矩阵。若概率向量 $\mathbf{r}$ 满足

$$\mathbf{r} = G\mathbf{r} = dS\mathbf{r} + (1-d)\mathbf{v}, \quad \mathbf{r} \in \Delta^{n-1} \quad (36.6)$$

则称 $\mathbf{r}$ 为一般 PageRank 向量。其存在性与解集大小由下节定理 36.2 建立。

命题 36.3 (阻尼矩阵的随机性与正性) 按上述次序先修复悬挂列再构造 G , 则对任意概率向量 $\mathbf{v}$, G 都是非负列随机矩阵; 若额外有 $\mathbf{v} > 0$, 则 $G_{ij} \geq (1-d)v_i > 0$, 因而 G 严格正。

读前自检: 证明: 阻尼矩阵的随机性与正性。 阻尼矩阵 $G = dS + (1-d)\mathbf{v}\mathbf{1}^\top$ 中 S 列随机、 $0 \leq d < 1$; 请计算列和并在 $v_i > 0$ 时核对 $G_{ij} \geq (1-d)v_i > 0$ 。

证明. S 和 $\mathbf{v}\mathbf{1}^\top$ 都非负且每列和为 1, 其凸组合 G 仍非负且每列和为 $d + (1-d) = 1$ 。又因 $S_{ij} \geq 0$ 与 $1-d > 0$, 当 $v_i > 0$ 时给定严格正下界成立; $v_i = 0$ 时不保证该行所有元素为正, 但不影响列随机性。□

图 36.5 把悬挂修复与随机跳转分成两个有顺序的操作。




图 36.5 一般 PageRank 先修复悬挂列，再混合沿链转移与随机跳转

36.4 平稳分布与主特征向量

定义 36.4 (平稳排名与主特征向量). 对列随机矩阵 P , 概率向量 $\mathbf{r}$ 若满足 $P\mathbf{r} = \mathbf{r}$, 就称为平稳排名。它是特征值 1 的右特征向量; “排名” 还要求用 $\mathbf{1}^T \mathbf{r} = 1$ 固定尺度, 不能把任意倍数当作概率分布。

定理 36.2 (一般 PageRank 的唯一性与几何收敛) 设 S 非负列随机, $\mathbf{v} \geq 0$ 且 $\mathbf{1}^T \mathbf{v} = 1$, $0 \leq d < 1$ 。映射 $T(\mathbf{x}) = dS\mathbf{x} + (1-d)\mathbf{v}$ 在 Δ^{n-1} 上有唯一不动点 $\mathbf{r}$, 且对任意初始概率向量

$$\|\mathbf{r}^{(t)} - \mathbf{r}\|_1 \leq d^t \|\mathbf{r}^{(0)} - \mathbf{r}\|_1. \quad (36.7)$$

读前自检: 证明: 一般的唯一性与几何收敛。 一般 PageRank 映射 $T(\mathbf{x}) = dS\mathbf{x} + (1-d)\mathbf{v}$ 在 ℓ_1 上满足 $\|T(\mathbf{x}) - T(\mathbf{y})\|_1 \leq d\|\mathbf{x} - \mathbf{y}\|_1$; 请迭代此界, 核对 $d < 1$ 给唯一固定点与几何收敛。

证明. 命题 36.1 说明 T 把概率单纯形映回自身。对任意 $\mathbf{x}, \mathbf{y} \in \Delta^{n-1}$,

$$\|T(\mathbf{x}) - T(\mathbf{y})\|_1 = d\|S(\mathbf{x} - \mathbf{y})\|_1 \leq d\|S\|_1 \|\mathbf{x} - \mathbf{y}\|_1 = d\|\mathbf{x} - \mathbf{y}\|_1.$$

当 $d < 1$ 时这是严格压缩; 完备性与压缩映射定理给出唯一不动点。对上式反复应用 t 次即得式 (36.7)。□

几何解释。 概率向量位于 Δ^{n-1} 。沿链映射 S 可在单纯形内剪切或旋转质量, 随机跳转则把每个点向 $\mathbf{v}$ 拉回; 二者组合后, 任意两条轨迹的 1 范数距离至多缩成 d 倍。图 36.6 中的唯一交点就是平稳排名。

概率解释。 一般随机游走每一步先掷一枚独立硬币: 以概率 d 沿链接 (悬挂时按 $\mathbf{v}$ 离开), 以概率 $1-d$ 重新按 $\mathbf{v}$ 选择结点。当 $\mathbf{v} > 0$ 时, 随机跳转为任意两点之间提供正概率路径, 并额外保证 G 严格正; 若 $\mathbf{v}$ 允许零分量, 压缩性仍给出唯一固定点和几何收敛, 但不能再声称 G 严格正或所有结点都可由跳转直接到达。 r_i 是稳态下访问 i 的长期频率, 不是 “用户必然喜欢 i ” 的概率。

优化解释。 PageRank 通常不写成经验风险最小化; 它是线性固定点问题。可把计算理解为最小化固定点残差 $\|\mathbf{x} - T(\mathbf{x})\|_1$, 但幂迭代直接利用压缩结构, 比对这个非光滑目标调用通用优化器更自然。




图 36.6 阻尼 PageRank 在概率单纯形上的压缩迭代与唯一平稳点

推导第 3 步：把固定点改写成线性方程并给出证书。由式 (36.6) 移项得

$$(I - dS)r = (1 - d)v, \quad r = (1 - d)(I - dS)^{-1}v. \quad (36.8)$$

读前自检：代数表示与迭代残差证书。 PageRank 迭代令 $\delta_t = \|r^{(t+1)} - r^{(t)}\|_1$ ；请代入收缩因子 $d < 1$ ，核对 $\|r^{(t+1)} - r\|_1 \leq \delta_t / (1 - d)$ ，并用该上界判断是否达到目标误差。

命题 36.4 (代数表示与迭代残差证书) 在 $0 \leq d < 1$ 时， $I - dS$ 可逆，且

$$r = (1 - d) \sum_{k=0}^{\infty} d^k S^k v. \quad (36.9)$$

若 $r^{(t+1)} = T(r^{(t)})$ 且 $\delta_t = \|r^{(t+1)} - r^{(t)}\|_1$ ，则

$$\|r^{(t+1)} - r\|_1 \leq \frac{d}{1-d} \delta_t \leq \frac{1}{1-d} \delta_t. \quad (36.10)$$

读前自检：证明：代数表示与迭代残差证书。 PageRank 相邻差满足 $\delta_{t+j} \leq d^j \delta_t$ ；请对 $j \geq 0$ 求几何级数，核对从第 $t+1$ 步到极限的尾和不超过 $\delta_t / (1 - d)$ 。

证明。列随机性给出 $\rho(S) \leq \|S\|_1 = 1$ ，故 $\rho(dS) < 1$ 。Neumann 级数 $\sum_{k \geq 0} (dS)^k$ 绝对收敛并等于 $(I - dS)^{-1}$ ，从而得到式 (36.9)。再由压缩性，后续步长满足 $\delta_{t+j} \leq d^j \delta_t$ 。极限存在且为 r ，于是

$$\|r^{(t+1)} - r\|_1 \leq \sum_{j=1}^{\infty} \delta_{t+j} \leq \sum_{j=1}^{\infty} d^j \delta_t = \frac{d}{1-d} \delta_t.$$

最后一个较松界由 $d \leq 1$ 得到。 □

图形辅助。图 36.3、图 36.5 与图 36.8 构成本章“故障诊断 - 修复与阻尼 - 误差证书”三张主图。入链分解、单纯形几何和数值轨迹只作为相应推导、定理与小型例子的就近辅助，不再与三张主图连续堆叠。

小型数值例子。取三结点图 $1 \rightarrow 2, 3, 2 \rightarrow 3$, 结点 3 悬挂, $\boldsymbol{v} = (1/3, 1/3, 1/3)^\top$ 、 $d = 0.8$ 。先修复悬挂列得

$$S = \begin{bmatrix} 0 & 0 & 1/3 \\ 1/2 & 0 & 1/3 \\ 1/2 & 1 & 1/3 \end{bmatrix}, \quad G = \begin{bmatrix} 1/15 & 1/15 & 1/3 \\ 7/15 & 1/15 & 1/3 \\ 7/15 & 13/15 & 1/3 \end{bmatrix}.$$

从均匀分布出发, 第一步为 $\boldsymbol{r}^{(1)} = (7/45, 13/45, 5/9)^\top$; 精确固定点为 $\boldsymbol{r} = (25/123, 35/123, 21/41)^\top \approx (0.2033, 0.2846, 0.5122)^\top$ 。图 36.7 左侧展示从均匀初值得到的 $t = 0, \dots, 8$ 有限轨迹, 其中 $t = 6$ 只是展示截断、不是停止判定; 右侧给出精确固定点 (显示六位小数) 及排序 $3 > 2 > 1$ 。




图 36.7 PageRank 的有限迭代轨迹与精确固定点 (显示六位小数): $t = 6$ 仅为展示截断且残差非零; 固定点排序为 $3 > 2 > 1$ 。

读图检查。核对 $\|G\boldsymbol{r}^{(6)} - \boldsymbol{r}^{(6)}\|_1 = 4.474947 \times 10^{-4} > 0$, 所以 $t = 6$ 不是停止判定; 再比较 $\boldsymbol{r}_* = (25/123, 35/123, 21/41)^\top$ 与图中六位小数, 验证精确固定点的排序为 $3 > 2 > 1$ 。

读前自检: PageRank 迭代算法。 PageRank 迭代以修复矩阵 S 、跳转分布 $\boldsymbol{v}$ 、 $0 \leq d < 1$ 、初始排名和预算为输入; 请完成一轮 $\boldsymbol{r}^+ = dS\boldsymbol{r} + (1-d)\boldsymbol{v}$, 核对概率守恒后提交, 并按后验误差界或预算停止。

读前自检: PageRank 的计算。 PageRank 计算先汇总悬挂质量 $h_t = \sum_{j \in D} r_j^{(t)}$; 请把非悬挂边散射项、 $dh_t\boldsymbol{v}$ 与 $(1-d)\boldsymbol{v}$ 相加, 核对新向量分量和为 1。

读前自检: 迭代算法。 PageRank 迭代算法维护排名向量、相邻差 δ_t 和误差上界; 请形成一轮候选并在非负/质量门通过后提交, 核对 $\delta_t/(1-d) \leq \varepsilon$ 时可停止。

读前自检: 代数算法。 PageRank 代数算法解 $(I - dS)\boldsymbol{r} = (1-d)\boldsymbol{v}$; 请把解回代线性方程, 核对同时满足固定点式与概率归一化, 并与幂迭代目标一致。

读前自检：幂法。 PageRank 幂法从 $r^{(0)} \in \Delta^{n-1}$ 反复应用 G ；请做一次 $Gr^{(t)}$ 并计算 ℓ_1 相邻差，核对候选仍归一且收缩因子不超过 d 。

读前自检：一般 PageRank 的幂法计算。 一般 PageRank 稀疏幂法不显式形成 G ，而是沿非悬挂边散射并补悬挂/跳转质量；请完成一次等价更新，核对与 $dSr + (1-d)v$ 逐分量一致。

36.5 幂法计算

一般 PageRank 的幂迭代就是

$$r^{(t+1)} = Gr^{(t)} = dSr^{(t)} + (1-d)v. \quad (36.11)$$

实际实现不显式形成稠密的 G 。令 $h_t = \sum_{j \in D} r_j^{(t)}$ ，只对非悬挂边做稀疏乘法，便有

$$r_i^{(t+1)} = d \sum_{\substack{j \in D \\ j \rightarrow i}} \frac{A_{ij}}{c_j} r_j^{(t)} + (1-d + dh_t)v_i. \quad (36.12)$$

图 36.8 给出输入检查、悬挂汇总、稀疏乘法、残差计算和停止判断的顺序。




图 36.8 PageRank 稀疏幂法依次执行输入检查、悬挂质量回填、稀疏乘法与阻尼更新，并以 $\delta_t = \|r^{(t+1)} - r^{(t)}\|_1 \leq (1-d)\varepsilon$ 作为 ℓ_1 误差证书；不满足时继续迭代或按预算停止。

算法伪代码。 算法 36.1 只处理已经核验为无悬挂、不可约、非周期的基本链；算法 36.2 处理任意有向图，并在每次稀疏乘法中等价地完成悬挂修复。二者都采用列向量和确定性更新，并明确说明停止原因。

输入与输出。基本算法输入稀疏列随机矩阵、初始概率向量、容差和上限, 输出基本 PageRank、残差轨迹和迭代次数; 一般算法输入稀疏边表、 $\boldsymbol{v}, d, \varepsilon, T_{\max}$ 和可选初值, 输出一一般 PageRank、误差上界、轨迹与悬挂集合。

参数含义。 d 是沿修复链接行走的概率, 必须满足 $0 \leq d < 1$; 基本算法中的 ε 只是相邻差与固定点残差的数值阈值; 一般阻尼算法中的 ε 才是由压缩证书保证的目标 1 范数误差。 $T_{\max}$ 是硬上限; $\boldsymbol{v}$ 同时定义悬挂结点的离开分布和随机跳转分布, 使模型语义一致。

初始化。两种算法都要求 $\boldsymbol{r}^{(0)} \in \Delta^{n-1}$ 。缺省取 $\boldsymbol{v}$; 若用户给定非负但仅有微小浮点和误差的向量, 可核验后归一化一次; 负分量、零总和或非有限值必须报错, 不能静默修补。

循环变量与更新顺序。迭代变量为 $t = 0, 1, \dots, T_{\max} - 1$ 。基本算法先做 $\boldsymbol{M}\boldsymbol{r}^{(t)}$ 再核验; 一般算法依次汇总悬挂质量、沿非悬挂边散射、加入 $(1 - d + d\boldsymbol{h}_t)\boldsymbol{v}$ 、核验概率守恒、计算 δ_t , 不得颠倒悬挂修复与阻尼混合。

判断、停止、返回与异常。基本算法以相邻差和固定点残差均不超过 ε 作为数值停止条件; 该出口只报告 `numerical_failure`, 因为没有已知压缩因子或谱隙时, 两个小残差不能直接换算成真解的距离。一般算法以 $B_t = \delta_t / (1 - d) \leq \varepsilon$ 给出式 (36.10) 的保守误差证书, 只有该出口报告 `converged`。若出现非法索引、负边权、非正规规模、非有限数或严重质量漂移, 则停止并指出位置; 达到迭代上限仍未满足停止准则时, 保留最后一个合法向量并说明原因。

正确性依据与收敛条件。基本算法的正确性和从任意初值收敛由定理 36.1 保证, 但定理只给渐近结论, 未给当前残差到真解距离的可计算常数; 一般算法的唯一性、几何收敛和停止证书由定理 36.2 及命题 36.4 保证。若基本链没有不可约、非周期证书, 则该算法不适用; 一般算法的唯一性与压缩收敛只需 $\boldsymbol{v} \in \Delta^{n-1}$ 、 $0 \leq d < 1$ 和输入图有限; 严格正 $\boldsymbol{v}$ 只用于额外推出 $\boldsymbol{G} > \mathbf{0}$ 与全支撑可达。

离线构建与查询复杂度。PageRank 没有监督训练; 离线排名构建中, 基本算法每步一次稀疏乘法, T 步为 $O(T(n + m))$; 一般算法预处理出度 $O(n + m)$, 每步悬挂汇总、稀疏散射和跳转均为 $O(n + m)$, 总计 $O(n + m + T(n + m))$ 。若显式使用稠密 $\boldsymbol{G}$ 则为 $O(Tn^2)$ 。排名查询中, 物化全部结果后读取一个结点为 $O(1)$, 输出完整向量为 $O(n)$; 改变图、 d 或 $\boldsymbol{v}$ 必须重新计算。

空间复杂度与复杂度假设。邻接表或压缩稀疏列存储占 $O(n + m)$, 出度、悬挂标志、当前向量和下一向量占 $O(n)$, 故工作内存为 $O(n + m)$; 显式形成 $\boldsymbol{G}$ 会升为 $O(n^2)$ 。这些界假设边索引和一次浮点加乘为 $O(1)$ 、单机可存下稀疏图, 且不计分布式通信、外存扫描和排序展示成本。若还要全排序, 另需 $O(n \log n)$ 时间或选择算法的相应代价。

算法 36.1 的实现要点。初值必须是合法概率向量; 每轮依次进行稀疏乘法、概率检查和双残差判断。定理 36.1 要求有限、不可约和非周期; 周期链、可约链或悬挂列不满足本算法前提。稀疏离线构建为 $O(T(n + m))$, 单个排名查询为 $O(1)$, 工作空间为 $O(n + m)$ 。

基本的稀疏幂迭代：五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新, 并指出何时提交。

算法 36.1: 基本 PageRank 的稀疏幂迭代

输入: 非负稀疏矩阵 $M \in \mathbb{R}^{n \times n}$; 不可约、非周期条件; $r^{(0)} \in \Delta^{n-1}$; $\varepsilon > 0, T_{\max} \in \mathbb{N}_0$

输出: 最后合法 $\hat{r}$ 、残差轨迹; $t_{\text{done}}, m_{\text{done}}$; **status** 与最终诊断

- 1 置 $r \leftarrow r^{(0)}, t_{\text{done}} = m_{\text{done}} = 0$; 若矩阵、证书、初值、预算或容差非法, 则返回初始占位、**invalid_input** 及字段诊断; 若 $T_{\max} = 0$, 返回 r 、**budget_stop** 及零预算诊断
- 2 当 $t_{\text{done}} < T_{\max}$ **执行**
- 3 计算临时 $y = Mr$ 并增加 m_{done} ; 非有限、显著为负或质量漂移超限时, 返回最后合法 r 、**numerical_failure** 及首个乘法诊断
- 4 仅对舍入级质量漂移归一化 y , 计算 $\delta_t \leftarrow \|y - r\|_1$; 计算 $q_t = \|My - y\|_1$ 并增加 m_{done} ; 非有限则返回 r 、**numerical_failure** 及固定点复检诊断
- 5 原子提交 $r \leftarrow y$ 、轨迹 (δ_t, q_t) 并增加 t_{done} ; 若双残差均不超过 ε , 返回 r 、实际计数、**numerical_failure** 及“数值稳定但无真解距离证书”诊断
- 6 **结束**
- 7 返回最后合法 r 、轨迹、实际计数、**budget_stop** 及“达到上限、未满足双证书”最终诊断

数学停止。 写出能直接核验的停止证书; 预算耗尽不等同于收敛。

输出。 列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 36.2 的实现要点。 更新顺序严格对应式 (36.12)。空边图、全悬挂图和 $d = 0$ 是合法退化情形, 均给出 v ; 压缩定理要求 $v \in \Delta^{n-1}$ 和 $0 \leq d < 1$ 。稀疏离线排名为 $O(n + m + T(n + m))$, 物化后的单点查询为 $O(1)$, 空间为 $O(n + m)$ 。

读前自检: 带悬挂修复的一般稀疏幂法: 执行契约。 带悬挂修复的一般稀疏幂法输入“结点/加权边表、跳转分布 v 、阻尼 d 、初始排名、目标误差、质量容差和迭代预算”, 条件“ $n \geq 1, T_{\max} \in \mathbb{N}_0, 0 \leq d < 1$ ”; 请执行“完整边扫描、质量/非负性/差分检查通过后才原子提交 y 、误差上界和轨迹”, 以“显式满足 $B_t = \delta_t / (1 - d) \leq \varepsilon$ 、 $T_{\max}$ 轮耗尽或首次失败时停止”判停。

带悬挂修复的一般稀疏幂法: 五步阅读

输入。 写出数据对象、固定参数与必须成立的条件。

初始化。 标明主状态、计数器和第一个合法状态。

核心更新。 只手算一次从旧状态到候选状态的更新, 并指出何时提交。

数学停止。 写出能直接核验的停止证书; 预算耗尽不等同于收敛。

输出。 列出返回对象、实际计数、中心状态和用于复核的诊断。

算法 36.2: 带悬挂修复的一般 PageRank 稀疏幂法

输入: 结点数 n 与加权边表 $\mathcal{E}$; $\mathbf{v} \in \Delta^{n-1}$; $0 \leq d < 1$; $\mathbf{r}^{(0)} \in \Delta^{n-1}$; 目标误差 $\varepsilon > 0$; 上限 $T_{\max} \in \mathbb{N}_0$; 质量容差 τ_{mass}

输出: 最后合法 $\mathbf{r}$ 、误差轨迹与 D ; $t_{\text{done}}, e_{\text{done}}, p_{\text{done}}$; **status** 及最终诊断

- 1 置 $t_{\text{done}} = e_{\text{done}} = p_{\text{done}} = 0$; 若 $n, T_{\max}, d$ 、容差、 $\mathbf{v}, \mathbf{r}^{(0)}$ 非法, 则返回初始占位、**invalid_input** 及字段诊断
- 2 逐边核验索引/权重并增加 p_{done} , 非法时返回已检前缀、**invalid_input** 及边诊断; 计算出度, 非有限或为负时返回 **numerical_failure** 及出度诊断
- 3 构造悬挂集合 $D \leftarrow \{j : c_j = 0\}$
- 4 令 $\mathbf{r} \leftarrow \mathbf{r}^{(0)}$; 若 $T_{\max} = 0$, 返回 $\mathbf{r}, D$ 、**budget_stop** 及零预算/预处理最终诊断
- 5 **当** $t_{\text{done}} < T_{\max}$ **执行**
- 6 $\mathbf{h} \leftarrow \sum_{j \in D} \mathbf{r}_j$; 异常时返回最后合法 $\mathbf{r}$ 、**numerical_failure** 及悬挂质量诊断
- 7 $\mathbf{y} \leftarrow (1 - d + d\mathbf{h})\mathbf{v}$
- 8 **对** 每条非悬挂边 $j \rightarrow i$ 依固定存储顺序遍历 **执行**
- 9 $\mathbf{q} \leftarrow d(A_{ij}/c_j)\mathbf{r}_j$ 并增加 e_{done} ; 异常时返回 $\mathbf{r}$ 、**numerical_failure** 及边贡献诊断; 否则累加到临时 $\mathbf{y}_i$
- 10 **结束**
- 11 若 $\mathbf{y}$ 含非有限值或严重负分量, 则返回 $\mathbf{r}$ 、**numerical_failure** 及分量诊断
- 12 $\mathbf{s}_t \leftarrow \mathbf{1}^T \mathbf{y}$
- 13 若质量漂移超限, 返回 $\mathbf{r}$ 、**numerical_failure** 及质量诊断
- 14 仅对舍入级漂移令 $\mathbf{y} \leftarrow \mathbf{y}/s_t$
- 15 $\delta_t \leftarrow \|\mathbf{y} - \mathbf{r}\|_1$; 非有限时返回 $\mathbf{r}$ 、**numerical_failure** 及差分诊断
- 16 $B_t \leftarrow \delta_t/(1 - d)$
- 17 原子提交 $\mathbf{r} \leftarrow \mathbf{y}$ 、轨迹 (δ_t, B_t) 并增加 t_{done} ; **若** $B_t \leq \varepsilon$ **则**
- 18 返回 $\mathbf{r}, B_t, D$ 、实际计数、**converged** 及证书 $\|\mathbf{r} - \mathbf{r}_\star\|_1 \leq B_t \leq \varepsilon$ 诊断
- 19 **结束**
- 20 **结束**
- 21 返回最后合法 $\mathbf{r}$ 、误差轨迹、 D 、实际计数、**budget_stop** 及“达到上限、证书未满足”最终诊断

算法实现说明: 核心四步是修复悬挂列、形成随机转移、执行幂迭代、以残差停止; 规范化、预算与数值失败属于稳健实现细节 完整 C1–C14 契约

代数法可直接解式 (36.8), 但显式求逆既不必要也会破坏稀疏性; 稠密求解通常需 $O(n^3)$ 时间与 $O(n^2)$ 空间。实际若采用线性求解器, 应解方程而不是形成逆矩阵, 并报告线性残差与停止原因。

适用条件。PageRank 适合“有向关系可解释为重要性传递”的网页、引用、关注或推荐候选图。需要冻结结点/边版本、边权语义、去重规则、 $\mathbf{v}, d$ 和停止容差。若任务是查询相关性、因果效应或时间顺序预测, PageRank 只能作为结构特征, 不能替代专门模型。

局限性。分数受链接操纵、重复页、边权和个性化分布影响; 单一静态图不建模时间与内容; d 越接近 1 越强调链接却越慢收敛, 也越放大图结构偏差。PageRank 给出相对稳态权重, 不提供公平性、可信度或语义质量保证。

常见错误

把行随机矩阵与列向量混用; 把边 $i \rightarrow j$ 写入 M_{ij} 而未说明约定; 遗漏出度分母; 直接在零列矩阵上构造 G ; 取 $d = 1$ 却仍引用压缩保证; 每步按 $\|\cdot\|_\infty$ 归一化后又把向量当概率; 只看相邻差而不报告固定点残差; 显式存储稠密 G 并声称复杂度仍是 $O(m)$ 。

易混淆概念对比

对象	第一项	第二项
列随机与行随机	列和为 1, 列向量左乘 P	行和为 1, 行向量右乘 P
基本与一般	依赖不可约、非周期且无悬挂的原链	修复悬挂并以 $d < 1$ 跳转, 任意有限图均有唯一解
PageRank		
平稳与收敛	$P\mathbf{r} = \mathbf{r}$ 是静态方程	$P^t \mathbf{r}^{(0)} \rightarrow \mathbf{r}$ 还需动力学条件
悬挂与无入链	悬挂结点没有出边, 对应零列	无入链结点没有来自图的贡献, 但仍可由跳转获得质量
幂法与代数法	反复稀疏乘法, 适合大图	解 $(I - dS)\mathbf{r} = (1 - d)\mathbf{v}$, 适合小型核验
阻尼与停止容差	d 定义模型及收敛率	ε 只定义计算精度, 不应改变模型

36.6 例题、排序计算与练习

贯穿例：四节点小图

本章角色：复用第 30 章（第 5 册第 1 章）的加权有向小图；同时转置矩阵与概率向量后计算列随机 PageRank。

下例的 M 就是第 30 章（第 5 册第 1 章）贯穿例中 A^T , 且 $\mathbf{r}^{(0)} = \rho_0^T$ 。由于 A 非负且行随机, M 非负且列随机, 满足第 36 章（第 5 册第 7 章）的链接转移矩阵假设。在未加阻尼的基本核 M 下, 两个章节的推进满足 $\mathbf{r}^{(t)} = \rho_t^T$, 其平稳向量也互为转置, 因而可在不更换图数据的前提下检验行/列桥接。加入阻尼与正概率个性化向量后, PageRank 核仍为合法的列随机矩阵并继续复用同一链接数据, 但推进序列与平稳解一般都会改变。上一站见第 30 章（第 5 册第 1 章）的行随机马尔可夫链表示。

例题 36.1 (四结点基本 PageRank 复算). 给定列随机矩阵

$$M = \begin{bmatrix} 0 & 1/2 & 1 & 0 \\ 1/3 & 0 & 0 & 1/2 \\ 1/3 & 0 & 0 & 1/2 \\ 1/3 & 1/2 & 0 & 0 \end{bmatrix}, \quad \mathbf{r}^{(0)} = \frac{1}{4} \mathbf{1}.$$

复算第一步, 并核验极限 $\mathbf{r} = (1/3, 2/9, 2/9, 2/9)^T$ 。

例题 36.1 解答

读题翻译 按列随机约定执行 $\mathbf{r}^{(1)} = M\mathbf{r}^{(0)}$, 再把给定候选极限代回 $M\mathbf{r} = \mathbf{r}$; 分量大小直接给出结点排序。

已知与合法条件 M 是 4×4 非负列随机矩阵, $\mathbf{r}^{(0)} = \mathbf{1}/4$ 是四维概率列向量; 候选极限 $(1/3, 2/9, 2/9, 2/9)^T$ 也非负且分量和为 1。

为什么想到这个方法 列随机链接矩阵左乘概率列向量时保持总质量; 先做一次矩阵乘法, 再用固定点方程与不可约、非周期条件核验长期结论。

方法选择 逐行计算 $M\mathbf{r}^{(0)}$ 并检查分量和；随后计算 $M\mathbf{r}$ ，确认候选为概率固定点并调用基本收敛定理。

推导/计算 直接相乘得到

$$\mathbf{r}^{(1)} = M\mathbf{r}^{(0)} = \left(\frac{3}{8}, \frac{5}{24}, \frac{5}{24}, \frac{5}{24}\right)^T, \quad \mathbf{1}^T \mathbf{r}^{(1)} = 1.$$

独立核验 第一轮分量和为 1；候选极限也非负且分量和为 1，并且

$$M \begin{bmatrix} 1/3 \\ 2/9 \\ 2/9 \\ 2/9 \end{bmatrix} = \begin{bmatrix} 1/3 \\ 2/9 \\ 2/9 \\ 2/9 \end{bmatrix}.$$

该图对应链满足不可约、非周期条件，故定理 36.1 保证从给定初值收敛到此唯一向量。这个论证不要求 M 可对角化；即便改用 Jordan 标准形，次特征值对应的多项式因子也会被模小于 1 的幂压过。

结论 第一轮为 $(3/8, 5/24, 5/24, 5/24)^T$ ；从给定初值收敛到唯一概率向量 $(1/3, 2/9, 2/9, 2/9)^T$ ，因此最终排序为 $A > B = C = D$ 。

例题 36.2 (删除一条边后的概率质量流失). 从例 36.1 的图删除结点 C 指向 A 的唯一出边，于是第 C 列变为零。说明为何未经修复的迭代会丢失概率质量，并判断长期结果能否称为 PageRank 概率分布。

例题 36.2 解答

读题翻译 删除结点 C 的唯一出边后，第 C 列变成零列；要判断迭代是否合法，先检查一次乘法后的总质量，再分析反复流入 C 的质量如何永久丢失。

已知与合法条件 修改后的矩阵非负，但第 C 列和为 0，其余三列和为 1；初始向量是概率向量，且原图其余结点都存在到达 C 的路径。

为什么想到这个方法 对含悬挂零列的未修复链接矩阵，用列和恒等式 $\mathbf{1}^T M\mathbf{x} = \sum_j c_j x_j$ 直接诊断质量守恒；若所有状态可把质量送入零列，反复迭代将继续泄漏。

方法选择 先对任意非负向量推导一步总质量 $S' = S - x_C$ ，再从总质量 $S_0 = 1$ 的均匀初值复算前三步；最后结合到达零列的路径说明长期极限不能是概率分布。

推导/计算 删除边后第 C 列和为 0，其余列和为 1。因此对任意非负向量 $\mathbf{x}$,

$$\mathbf{1}^T M\mathbf{x} = \mathbf{1}^T \mathbf{x} - x_C;$$

特别地，输入为概率向量时右端才可写成 $1 - x_C$ 。

独立核验 记 $S_t = \mathbf{1}^T \mathbf{r}^{(t)}$ 。只要 C 仍有正质量, 递推 $S_{t+1} = S_t - r_C^{(t)}$ 就使下一步总质量严格减小。由均匀初值逐轮复算,

$$\mathbf{1}^T \mathbf{r}^{(0)} = 1, \quad \mathbf{1}^T \mathbf{r}^{(1)} = \frac{3}{4}, \quad \mathbf{1}^T \mathbf{r}^{(2)} = \frac{13}{24}, \quad \mathbf{1}^T \mathbf{r}^{(3)} = \frac{19}{48}.$$

其中依次减去的 C 分量为 $1/4, 5/24, 7/48$, 确有 $1 - 1/4 = 3/4$ 、 $3/4 - 5/24 = 13/24$ 及 $13/24 - 7/48 = 19/48$ 。又因其余状态都可到达 C , 流入零列的质量会持续丢失。

结论 未修复的迭代不保持概率总质量, 并最终趋向零向量; 零向量不是概率分布, 因此该长期结果不能称为 PageRank。必须先用合法概率列修复悬挂结点, 再进行排序迭代。

例题 36.3 (四结点阻尼 PageRank). 取 $d = 0.8$ 、 $\nu = 1/4$ 及

$$S = \begin{bmatrix} 0 & 1/2 & 0 & 0 \\ 1/3 & 0 & 0 & 1/2 \\ 1/3 & 0 & 1 & 1/2 \\ 1/3 & 1/2 & 0 & 0 \end{bmatrix}.$$

由线性方程求一般 PageRank, 并给出排序。

例题 36.3 解答

读题翻译 由给定列随机矩阵、阻尼系数和均匀传送分布, 解四个结点的 PageRank 固定点, 并按所得概率排序。

已知与合法条件 $d = 0.8$ 、 $\nu = 1/4$, 故传送项为 $(1-d)\nu = 0.051$; 结点顺序为 A, B, C, D 。

为什么想到这个方法 阻尼 PageRank 满足 $\mathbf{r} = dS\mathbf{r} + (1-d)\nu$; 将此固定点方程逐分量展开, 可利用对称的流入关系降元。

方法选择 先写出四个分量方程并由 B, D 的方程导出相等关系, 再求各分量, 最后核验概率、残差与唯一性。

推导/计算

$$\begin{aligned} r_A &= \frac{2}{5}r_B + \frac{1}{20}, & r_B &= \frac{4}{15}r_A + \frac{2}{5}r_D + \frac{1}{20}, \\ r_C &= \frac{4}{15}r_A + \frac{4}{5}r_C + \frac{2}{5}r_D + \frac{1}{20}, & r_D &= \frac{4}{15}r_A + \frac{2}{5}r_B + \frac{1}{20}. \end{aligned}$$

比较 B, D 两式得 $r_B - r_D = \frac{2}{5}(r_D - r_B)$, 从而 $r_B = r_D$ 。代入 $r_A = \frac{2}{5}r_B + \frac{1}{20}$ 及 B 式, 得到

$$\frac{37}{75}r_B = \frac{19}{300}, \quad r_B = r_D = \frac{19}{148}, \quad r_A = \frac{15}{148}.$$

代入 C 式得 $r_C = \frac{95}{148}$, 于是

$$\mathbf{r} = \frac{1}{148}(15, 19, 95, 19)^T.$$

独立核验 四个分量均正, 且 $15 + 19 + 95 + 19 = 148$, 所以 $\mathbf{1}^T \mathbf{r} = 1$; 直接代入四个分量方程 (等价地) 有

$$\|\mathbf{r} - 0.8S\mathbf{r} - 0.05\mathbf{1}\|_1 = 0.$$

又 $\|0.8S\|_1 = 0.8 < 1$, 故 $I - 0.8S$ 可逆; 配合正传送项, 固定点唯一且为正。

结论 $\mathbf{r} = (15, 19, 95, 19)^T / 148$, 排序为 $C > B = D > A$ 。

例题 36.4 (三结点幂法与概率归一化). 取 $d = 0.85$ 、 $\nu = 1/3$ 及

$$S = \begin{bmatrix} 0 & 0 & 1 \\ 1/2 & 0 & 0 \\ 1/2 & 1 & 0 \end{bmatrix}.$$

求平稳概率向量, 并解释为什么幂法中按最大分量归一化得到的特征向量还需按分量和归一化。

例题 36.4 解答

读题翻译 以三结点阻尼迭代求平稳概率, 并说明按最大分量归一化的特征向量为何还必须转成分量和为 1 的概率向量。

已知与合法条件 $d = 0.85 = 17/20$ 、 $\nu = 1/3$, 传送项为 $0.05\mathbf{1}$, 初始向量为 $\mathbf{r}^{(0)} = \mathbf{1}/3$ 。

为什么想到这个方法 先按 $\mathbf{r}^{(t+1)} = 0.85S\mathbf{r}^{(t)} + 0.05\mathbf{1}$ 复算迭代, 再将平稳方程逐分量求解, 并区分尺度归一化与概率归一化。

方法选择 保留前两次迭代作为复算记录, 解三条固定点分量方程; 最后从最大分量归一化的向量精确恢复概率向量。

推导/计算 从 $\mathbf{r}^{(0)} = \mathbf{1}/3$ 开始, 前两轮为

t	$r_1^{(t)}$	$r_2^{(t)}$	$r_3^{(t)}$	$\mathbf{1}^T \mathbf{r}^{(t)}$
0	1/3	1/3	1/3	1
1	1/3	23/120	19/40	1
2	363/800	23/120	851/2400	1

$$r_1 = \frac{17}{20}r_3 + \frac{1}{20},$$

$$r_2 = \frac{17}{40}r_1 + \frac{1}{20},$$

$$r_3 = \frac{17}{40}r_1 + \frac{17}{20}r_2 + \frac{1}{20}$$

$$\mathbf{r} = \frac{1}{1769}(686, 380, 703)^T$$

若幂法将同方向的特征向量按最大分量缩放, 则精确地有

$$\mathbf{z} = (686/703, 380/703, 1)^T, \quad \mathbf{1}^T \mathbf{z} = \frac{1769}{703}, \quad \frac{\mathbf{z}}{\mathbf{1}^T \mathbf{z}} = \frac{1}{1769} (686, 380, 703)^T.$$

最大分量归一化只固定尺度, 不保证分量和为 1; 概率解释需要上述 L^1 归一化。

独立核验 $686 + 380 + 703 = 1769$ 且三分量为正; 将精确解代回三条分量方程, 或等价地代回 $(I - 0.85S)\mathbf{r} = 0.05\mathbf{1}$, 残差为零。

结论 平稳概率向量为 $(686, 380, 703)^T/1769$, 排序为 $3 > 1 > 2$; 最大分量归一化后的向量还须按分量和归一化。

本章共 10 道练习。每道题干后立即给出同号解析; 长解析可自然跨页, 续页标题保留题号。

【原书练习整理】

练习 36.1. 设 A 为非负列随机矩阵。证明对每个自然数 k , A^k 仍为列随机矩阵。

练习 36.1 解析

对 $k \geq 1$, 矩阵乘积的每个元素满足

$$(A^k)_{ij} = \sum_{i_1, \dots, i_{k-1}} a_{ii_1} a_{i_1 i_2} \cdots a_{i_{k-1} j} \geq 0.$$

由列随机性 $\mathbf{1}^T A = \mathbf{1}^T$ 归纳得到

$$\mathbf{1}^T A^k = (\mathbf{1}^T A) A^{k-1} = \mathbf{1}^T A^{k-1} = \cdots = \mathbf{1}^T.$$

因此 A^k 非负且每列和为 1, 仍为列随机矩阵; $k = 0$ 时 $A^0 = I$ 也满足结论。

练习 36.2. 对例 36.1, 把初值分别改为 $(1, 0, 0, 0)^T$ 和 $(0, 1/2, 1/2, 0)^T$ 。说明为何两条迭代仍收敛到同一基本 PageRank, 并给出可核验的方法而非只报告小数。

练习 36.2 解析

两初值均非负且分量和为 1。第一步可精确复算为

$$M(1, 0, 0, 0)^T = \left(0, \frac{1}{3}, \frac{1}{3}, \frac{1}{3}\right)^T,$$

$$M\left(0, \frac{1}{2}, \frac{1}{2}, 0\right)^T = \left(\frac{3}{4}, 0, 0, \frac{1}{4}\right)^T.$$

练习 36.2 解析 (续)

从矩阵的有向图可核验任意状态可达任意状态, 且存在长度互素的闭游走, 故链不可约且非周期。定理 36.1 于是对每个初值给出同一唯一极限。精确核验不必依赖小数; 候选极限满足

$$\mathbf{r}_\star = \left(\frac{1}{3}, \frac{2}{9}, \frac{2}{9}, \frac{2}{9}\right)^\top, \quad M\mathbf{r}_\star = \mathbf{r}_\star, \quad \mathbf{1}^\top \mathbf{r}_\star = 1.$$

练习 36.3. 证明按本章一般定义构造的 PageRank 马尔可夫链具有平稳分布, 并说明在 $\nu > 0$ 、 $0 \leq d < 1$ 下为什么它唯一。

练习 36.3 解析

先按式 (36.4) 得到列随机 S , 再令

$$G = dS + (1-d)\nu\mathbf{1}^\top, \quad \mathbf{1}^\top G = \mathbf{1}^\top, \quad G \geq 0.$$

命题 36.3 说明 G 是严格正的列随机矩阵, 故它把紧凸的概率单纯形连续映回自身, 至少有一个不动点。更强地, 对任意概率向量 $\mathbf{x}, \mathbf{y}$,

$$\|G\mathbf{x} - G\mathbf{y}\|_1 = d\|S(\mathbf{x} - \mathbf{y})\|_1 \leq d\|\mathbf{x} - \mathbf{y}\|_1.$$

$d < 1$ 使其成为压缩, 故不动点存在且唯一, 并由任意初值迭代到达。

$$\|\mathbf{r}^{(t)} - \mathbf{r}_\star\|_1 \leq d^t \|\mathbf{r}^{(0)} - \mathbf{r}_\star\|_1 \longrightarrow 0.$$

练习 36.4. 证明非负列随机矩阵 P 的谱半径为 1, 也就是说特征值的最大模为 1。

练习 36.4 解析

列随机性给出 $\|P\|_1 = \max_j \sum_i |P_{ij}| = 1$, 所以

$$\rho(P) \leq \|P\|_1 = 1.$$

另一方面

$$\mathbf{1}^\top P = \mathbf{1}^\top \iff P^\top \mathbf{1} = \mathbf{1}$$

说明 1 是 $P^\top$ 的特征值; P 与 $P^\top$ 有相同特征多项式, 故 1 也是 P 的特征值。

$$1 \in \sigma(P) \implies \rho(P) \geq 1 \implies \rho(P) = 1.$$

练习 36.5. 证明式 (36.4) 所得 S 列随机, 并给出一个全悬挂图的 S 和一般 PageRank。

练习 36.5 解析

若 $c_j > 0$, S 第 j 列就是 M 第 j 列, 列和为 1; 若 $c_j = 0$, 该列被替换为 ν 。统一写成

$$\sum_i S_{ij} = \begin{cases} \sum_i M_{ij} = 1, & c_j > 0, \\ \sum_i \nu_i = 1, & c_j = 0, \end{cases} \quad S_{ij} \geq 0.$$

练习 36.5 解析 (续)

故 S 列随机。全悬挂图有 $M = 0$ 、 $\mathbf{a} = \mathbf{1}$ ，所以

$$S = M + \mathbf{v}\mathbf{a}^\top = \mathbf{v}\mathbf{1}^\top,$$

$$G = dS + (1-d)\mathbf{v}\mathbf{1}^\top = \mathbf{v}\mathbf{1}^\top, \quad G\mathbf{v} = \mathbf{v}.$$

压缩性给出唯一 PageRank 为 $\mathbf{v}$ 。

练习 36.6. 从 $M\mathbf{r} = \mathbf{r}$ 推出非加权图的入链贡献式，并解释同一起来源网页增加一条出链时，它给原有每个目标的直接贡献如何变化。

练习 36.6 解析

固定点第 i 行是

$$r_i = (M\mathbf{r})_i = \sum_j M_{ij}r_j.$$

非加权且无悬挂时， $M_{ij} = c_j^{-1}\mathbf{1}\{j \rightarrow i\}$ ，故

$$r_i = \sum_{j:j \rightarrow i} \frac{r_j}{c_j}.$$

若来源 j 的出度由 c_j 增为 $c_j + 1$ 且暂时固定 r_j ，则每条原有目标的直接贡献变化为

$$\frac{r_j}{c_j} \mapsto \frac{r_j}{c_j + 1}, \quad \Delta = -\frac{r_j}{c_j(c_j + 1)} < 0.$$

全局平稳解还会通过其他结点继续联动。

练习 36.7. 若一次一般 PageRank 迭代的相邻差为 2×10^{-7} 、 $d = 0.9$ ，用式 (36.10) 给出返回向量到真解的保守 1 范数误差上界。

练习 36.7 解析

令 $\delta_t = \|\mathbf{r}^{(t+1)} - \mathbf{r}^{(t)}\|_1 = 2 \times 10^{-7}$ 。较松而直接的证书为

$$\|\mathbf{r}^{(t+1)} - \mathbf{r}\|_1 \leq \frac{\delta_t}{1-d} = \frac{2 \times 10^{-7}}{1-0.9} = 2 \times 10^{-6}.$$

若使用命题中的较紧界，则

$$\|\mathbf{r}^{(t+1)} - \mathbf{r}\|_1 \leq \frac{d\delta_t}{1-d} = \frac{0.9(2 \times 10^{-7})}{0.1} = 1.8 \times 10^{-6}.$$

两者都必须连同 d 和采用的残差定义一起报告。

练习 36.8. 对 n 个结点、 m 条边、 T 次迭代，分别给出稀疏隐式算法、显式稠密 G 和稠密代数法的时间空间复杂度，并写出所用实现假设。

练习 36.8 解析

若输入已是去重后的加权边表，稀疏隐式法的预处理、总时间和工作存储量分别为

$$\begin{aligned} T_{\text{pre}} &= O(n + m), \\ T_{\text{total}} &= O(n + m) + T O(n + m) = O((T + 1)(n + m)), \\ S_{\text{work}} &= O(n + m). \end{aligned}$$

三种主体比较为

实现	时间	空间
稀疏隐式幂法	$O((T + 1)(n + m))$	$O(n + m)$
显式稠密 G	$O(Tn^2)$	$O(n^2)$
稠密线性方程	$O(n^3)$	$O(n^2)$

若原始边表还需排序聚合重复边，构图另需 $O(m \log m)$ ；期望常数时间哈希则为期望 $O(m)$ 。若最终要输出全部结点的有序名次，还需 $O(n \log n)$ 排序；只取前 k 名可用大小为 k 的堆在 $O(n \log k)$ 时间、 $O(k)$ 附加空间完成。这些界假设稀疏图驻留内存、一次边访问和浮点运算为 $O(1)$ ，且不计分布式通信；报告必须给出 n, m, T, k 以及边去重实现，若 $m = \Theta(n^2)$ ，稀疏界自然退化到稠密量级。

$$m = \Theta(n^2) \implies O(T(n + m)) = O(Tn^2).$$

练习 36.9. 固定 S, d ，令 $r(v)$ 和 $r(w)$ 分别是两个个性化分布的 PageRank。证明 $\|r(v) - r(w)\|_1 \leq \|v - w\|_1$ 。

练习 36.9 解析

由 Neumann 表示，

$$r(v) - r(w) = (1 - d) \sum_{k=0}^{\infty} d^k S^k (v - w).$$

利用 $\|S^k\|_1 = 1$ 和三角不等式，

$$\|r(v) - r(w)\|_1 \leq (1 - d) \sum_{k=0}^{\infty} d^k \|v - w\|_1 = \|v - w\|_1.$$

所以个性化输入的 1 范数扰动不会被放大。

练习 36.10. 设计一次 PageRank 对比实验：说明图的构造规则、预处理、参数、初始化、停止准则、残差和复杂度；比较两个 d 时指出哪些条件必须保持不变。

练习 36.10 解析

固定结点集合、边集、去重/自环规则、边权和悬挂处理，得到同一个列随机 S ；再固定 v 与初值。对每个候选 d 执行

$$r^{(t+1)} = d S r^{(t)} + (1 - d) v, \quad \mathbf{1}^T r^{(t+1)} = 1.$$

练习 36.10 解析 (续)

定义相邻差、固定点残差与误差证书

$$\delta_t = \|r^{(t+1)} - r^{(t)}\|_1, \quad \eta_t = \|r^{(t)} - dSr^{(t)} - (1-d)v\|_1, \quad B_t = \frac{d\delta_t}{1-d}.$$

停止规则预先固定为 $B_t \leq \varepsilon$ 或 $t = T_{\max}$; 后者必须报告为达到迭代上限且尚未满足收敛准则。结果同时报告迭代数、 δ_t, η_t, B_t 、质量守恒误差与

$$T_{\text{run}} = O(T(n+m)), \quad S_{\text{run}} = O(n+m).$$

比较两个 d 时必须保持图、边权、 v 、初值、 ε 和误差口径不变; 不能用相同迭代次数替代相同误差标准。

读前自检：本章结论与下一步。 PageRank 算法章末把“本章采用列随机约定”收束为“稀疏幂法汇总悬挂质量并沿边散射贡献，避免显式形成稠密 Google 矩阵”；请将 $M = P^T$ 的左端按定义展开一层并与右端对齐，再核对“等号两端有定义且化为同一量”且该结果能直接进入章末所述方法。

本章结论与下一步

核心结论：本章采用列随机约定； $M = P^T$ 与概率向量转置把它精确接到第 30 章的行随机链。

关键依据：先修复悬挂列，再加入 $0 \leq d < 1$ 的跳转；1 范数压缩给出唯一固定点、几何收敛与误差界。

可执行自检：稀疏幂法汇总悬挂质量并沿边散射贡献，避免显式形成稠密 Google 矩阵。

适用边界：适合关系图上的稳态结构排序；它不等于查询相关性、内容质量、因果影响或公平性。

下一步：进入第 37 章：无监督学习方法总结，把图排序与聚类、矩阵分解、主题模型和 MCMC 放入统一任务—模型—评价框架。

1. 我能从边 $j \rightarrow i$ 正确写出第 j 列并核验概率守恒，区分可约、周期和悬挂问题，再写出先修复零列的 S 与 G 。
2. 我能完整证明一般 PageRank 唯一并给出 d^t 误差界，再由相邻差生成 1 范数误差证书。
3. 我能解释稀疏更新为何是 $O(n+m)$ 而显式 G 是 $O(n^2)$ ，并指出实现中需保留的概率和诊断。
4. 我能复算四个例题的精确或指定精度结果，并同时报告概率和与固定点残差。
5. 我能说明图结构排序与内容质量、因果影响和公平性不是同一结论，并给出适用边界。

第 37 章 无监督学习方法总结

读前自检：本章地图：无监督学习方法总结。 无监督学习方法总结章地图沿“任务语义 → 表示与训练准则 → 求解器 → 无泄漏选择与评价”推进；请标出该路线第一次改变对象类型的位置，并核对前一步产出正是后一步输入。

读前自检：本章可检验学习目标。 无监督学习方法总结学习目标固定核验“从任务、表示、准则和推断四个层次区分聚类、降维、话题分析与图排序”；请实际完成“从任务、表示、准则和推断四个层次区分聚类、降维、话题分析与图排序”，并用“中间结果逐项包含首目标“从任务、表示、准则和推断四个层次区分聚类、降维、话题分析与图排序”声明的对象、条件与结论”判定通过或失败。

读前自检：最短先修。 无监督方法总结的先修要求区分 PLSA 的点参数似然与 LDA 的随机隐变量后验；请写出 PLSA 的 $P(w | d) = \sum_z P(w | z)P(z | d)$ 和 LDA 的 $p(z, \theta, \phi | w, \alpha, \beta)$ ，核对前者是点参数似然、后者包含随机主题混合与主题词分布。

读前自检：先修自检。 无监督学习方法总结先修自检固定核验“对 $X \in \mathbb{R}^{M \times N}$ ，能否解释行、列及秩 K 各自代表什么”；请对 $X \in \mathbb{R}^{M \times N}$ ，实际解释行、列及秩 K 各自代表什么并写出中间结果，再按“ $X \in \mathbb{R}^{M \times N}$ 的计算或证明结果满足首项所列等式、定义域或判断”明确判为通过或失败。

读前自检：依赖路线。 无监督学习方法总结把“第 4 册的聚类与矩阵分解”接到“任务语义与数据结构 → 候选表示”；请用 → 补全这一步的等式或判据，再检查两端维数、支持或对象类型。

本章地图

核心问题：怎样比较聚类、降维、主题模型、采样与图排序，而不混淆任务、模型和算法？

可检验学习目标：

- 从任务、表示、准则和推断四个层次区分聚类、降维、话题分析与图排序；
- 用统一的词 - 文档矩阵记号比较 LSA、NMF、PLSA 与 LDA，并核验每个因子的维数与约束；
- 推出高斯观测与平方损失、泊松计数与广义 KL 散度、PLSA 联合似然与 KL 准则的对应关系；
- 严格分开训练目标、验证指标、独立测试、稳定性、解释性和计算预算；
- 按无泄漏协议选择方法、超参数和停止规则，并为失败与未收敛状态保留证据；
- 能为新场景给出可复现的方法选择方案，而不是只报出一个方法名称。

最短先修：本章直接使用聚类、奇异值分解、主成分分析、潜在语义分析、PLSA、MCMC、LDA 和 PageRank。还需熟悉概率质量函数、极大似然、KL 散度、交叉验证、矩阵范数与条件独立。若不能写出薄 SVD 的维数，先回看 SVD；若不能区分似然和后验，先回看概率推断；若不能说明马尔可夫链平稳分布与迭代收敛的差别，先回看马尔可夫链与 PageRank。

依赖路线：第 4 册的聚类与矩阵分解，加上第 5 册第 3、6、7 章的 MCMC、LDA 与 PageRank → 本章的统一比较；任务语义与数据结构 → 候选表示；表示与概率假设 → 训练目标；训练目标与求解器条件 → 可计算模型；独立验证与诊断 → 方法选择；锁定测试与成本记录 → 可复核结论。图 37.1 给出本章的依赖主线。

完成标准与返回：先按需要回看前七章的定义域和保证，再用本章表格统一比较。




图 37.1 无监督学习方法总结的知识依赖：任务与数据结构共同约束表示、推断和模型选择

数据方向桥：总结章统一采用列对象

本章比较矩阵分解与主题模型时，把 N 个 M 维文档向量按列组成 $X_{\text{col}} \in \mathbb{R}^{M \times N}$ 。它与全书默认行样本表示满足

$$X_{\text{row}} = X_{\text{col}}^T \in \mathbb{R}^{N \times M}.$$

例如 $M = 1000, N = 200$ 时，本章为 1000×200 ，默认接口为 200×1000 。比较 LSA、NMF、PLSA 和 LDA 时统一沿用列文档；若接入普通学习器，先显式转置并重新核对每个因子维数。

读前自检：本章符号表。 无监督学习方法总结符号表规定 $X = [x_{ij}]$ 、 $\mathbb{R}^{M \times N}$ 的类型或范围；请把 $X = [x_{ij}]$ 代入紧随其后的定义关系，逐项核对输入形状、输出形状与取值域。

本章符号表

符号	对象与读法	维数/范围	作用
$X = [x_{ij}]$	词 - 文档或特征 - 样本矩阵	$\mathbb{R}^{M \times N}$	观测数据；计数、NMF 与话题场景另要求非负
W, H	左因子、右因子	$M \times K, K \times N$	低秩表示
U_K, Σ_K, V_K	截断 SVD 因子	$M \times K, K \times K, N \times K$	正交低秩坐标
z, θ_j, φ_k	主题指标、文档主题分布、主题词分布	$z \in \{1, \dots, K\}, \theta_j \in \Delta^{K-1}, \varphi_k \in \Delta^{M-1}$	概率话题表示
$\mathcal{M}, \lambda$	候选方法集合、超参数配置	有限集合	选择空间
$J_{\text{fit}}, Q_{\text{val}}$	训练目标、验证指标	任务相关实数	拟合与选择

$\hat{R}_{\text{test}}$	锁定测试集平均损失	非负或可积实数	最终性能估计
$\mathcal{G} = (\mathcal{V}, \mathcal{E})$	有向图	结点集与边集	图排序输入
$B, C_{\text{in}}, C_{\text{out}}, T_{\text{max}}$	候选配置数、内层折数、外层折数、迭代上限	正整数	K 只留给秩、簇数或主题数
$R_{\text{start}}, R_{\text{chain}}, R_{\text{bootstrap}}$	多启动、独立链、重采样次数	非负整数; 适用项为正	完整实验预算

本章统一把样本放在列中。图结点集用 $\mathcal{V}$, SVD 右奇异向量矩阵用 $\mathbf{V}_K$, 二者不可混写。

读前自检：无监督学习方法总结。 无监督学习只说明没有监督标签，不决定输出；请对同一矩阵分别指定聚类标签、低维坐标与概率密度三种任务，核对每种任务的输出域和训练准则不同。

读前自检：无监督学习方法的关系和特点。 无监督方法关系表按任务、主要输出、表示、训练准则和求解器五列组织；请对照聚类与 PCA 两行，核对类别划分不能与正交低维得分互换。

读前自检：各种方法之间的关系。 聚类、矩阵分解、话题模型与 PageRank 之间可共享求解器却不共享任务语义；请固定对照 NMF 与 PLSA 在同一非负矩阵上的表示，核对前者因子不自动归一、后者参数必须位于单纯形。

37.1 聚类、降维、主题模型与采样的联系

问题提出。“没有标签”只描述观测条件，并不规定输出。聚类要输出组或软成员度；降维要输出低维坐标或子空间；话题模型要输出词与文档的潜在结构；PageRank 要输出图上的平稳权重；MCMC 则是从目标分布构造相关样本的推断引擎，并非一种数据任务。若只按名称选方法，就会把任务、模型、目标和求解器混为一谈。

图 37.2 只总结本讲义中的代表性主路线和特定模型/求解方案的条件性复用；这些边都不是方法族与引擎之间的必要或充分关系，共享引擎也不意味着方法等价。





图 37.2 方法族—计算引擎教学映射：实线为本讲义代表性主路线，虚线为特定模型/方案的条件性复用；这些边均非必要或充分关系，共享引擎也不使方法等价。

读图检查。先看四条近似竖直实线对应的代表性主路线；再看话题分析到 SVD、EM 的两条短虚线，分别把它们理解为 LSA、PLSA 等特定方案中的条件性复用，而不是关系强弱；最后确认任一边都不构成必要或充分条件，复用同一引擎也不使两个方法等价。

图 37.3 把“任务 – 表示 – 推断”三轴仅作为粗粒度定位投影： (T, R, I) 不能唯一确定方法，完整可核验规格仍须写成 $\mathcal{U} = (\mathcal{X}, \mathcal{T}, \mathcal{R}, \mathcal{J}, \mathcal{A}, \mathcal{E}, \mathcal{B})$ 。图中的方法行都是限定条件下的代表示例，而非方法与三轴选项的唯一绑定。

任务—表示—推断三轴定位投影 (T,R,I)

粗粒度投影只供快速定位，不能唯一确定方法；
完整可核验规格为 $\mathcal{U} = (\mathcal{X}, \mathcal{T}, \mathcal{R}, \mathcal{J}, \mathcal{A}, \mathcal{E}, \mathcal{B})$ ；三轴不是其替代。



五行都是限定条件下的代表性投影，并非唯一绑定；
线型、端点标记、方法标签与条件文字共同识别路径，不编码数学强弱。



图 37.3 任务—表示—推断三轴定位投影：五行是限定条件下的代表示例；低秩表示按准则、潜变量表示按推断形成分叉，说明 (T,R,I) 并非唯一绑定，也不能替代完整规格 $\mathcal{U} = (\mathcal{X}, \mathcal{T}, \mathcal{R}, \mathcal{J}, \mathcal{A}, \mathcal{E}, \mathcal{B})$ 。

读图检查。先按任务、表示、推断读取五行代表示例；再沿两处分叉核对“同一低秩 R 可接平方损失或计数似然 J ”以及“同一潜变量 R 可接 VI 或 Gibbs 推断 I ”；最后把候选补回 $\mathcal{U} = (\mathcal{X}, \mathcal{T}, \mathcal{R}, \mathcal{J}, \mathcal{A}, \mathcal{E}, \mathcal{B})$ 七项规格，确认三轴投影既非唯一绑定，也不是完整规格的替代。

任务	主要输出	典型表示	训练准则	常见求解器
聚类	簇、树或成员度	中心、划分、混合分布	类内距离或似然	凝聚、交替更新、EM
降维	子空间与低维坐标	正交子空间或低秩因子	方差、重构误差	特征分解、SVD
话题分析	主题词与文档主题	矩阵因子或潜变量模型	重构损失、似然、ELBO	SVD、交替优化、EM、VI、Gibbs
图排序	结点稳态权重	马尔可夫算子	固定点方程与残差	幂法、线性方程求解

读前自检：本讲义的无监督学习工作框架。 无监督学习规格 $\mathfrak{U} = (\mathcal{X}, \mathcal{T}, \mathcal{R}, J, \mathcal{A}, \mathcal{E}, \mathcal{B})$ 分别编码观测、任务、表示、准则、算法、评价和预算；请为一个聚类任务逐项填入对象，核对七项类型匹配。

定义 37.1 (本讲义的无监督学习工作框架)。这是本讲义为阅读、复现和比较方法采用的工作性约定，不是学界统一定义。一个可核验的无监督学习规格记为

$$\mathfrak{U} = (\mathcal{X}, \mathcal{T}, \mathcal{R}, J, \mathcal{A}, \mathcal{E}, \mathcal{B}).$$

其中 $\mathcal{X}$ 是观测空间， $\mathcal{T}$ 是任务与输出语义， $\mathcal{R}$ 是表示族， J 是训练准则， $\mathcal{A}$ 是求解或推断过程， $\mathcal{E}$ 是独立评价协议， $\mathcal{B}$ 是时间、内存和失败预算。只有七项共同确定，方法比较才有明确对象。

模型。 设 $\mathbf{x}_j \in \mathbb{R}^M$ 是第 j 个观测列。低秩模型写成 $\mathbf{X} \approx \mathbf{W}\mathbf{H}$ ；概率潜变量模型写成 $p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\eta})$ 或 $p(\mathbf{X}, \mathbf{Z}, \boldsymbol{\eta})$ 。两种写法可共享乘积结构，却不因此拥有相同语义：约束、归一化、噪声分布和先验会改变可识别性与输出解释。

学习策略。 训练阶段只在开发数据上最小化 J_{fit} 或最大化相应下界/似然；选择阶段用预先声明的 Q_{val} 比较配置；测试阶段只对锁定模型做一次 $\hat{R}_{\text{test}}$ 评估。稳定性、解释性和成本是并列证据，不能藏进一个未说明权重的总分。不同量纲或不同概率口径的目标值不得直接横向排序。

学习算法。 本章不发明替代各方法的“万能迭代”。算法 37.1 是方法选择与评价协议：它调用候选方法已有的合法求解器，记录每次拟合状态，再在开发集内部完成选择。EM 只保证其观测似然不降并通常到达驻点；变分坐标更新只保证所选变分族内的 ELBO 不降并可能停在局部解；Gibbs 抽样的结论必须分层：有限不可约链或一般状态的正常 Harris 返链在可积条件下给出时间平均；非周期性另用于固定时刻边缘分布收敛；CLT 与批均值还需额外矩和混合条件。它不提供全局优化保证。

读前自检：话题模型之间的关系和特点。 话题模型比较在词 - 文档矩阵 $\mathbf{X} \in \mathbb{R}_{\geq 0}^{M \times N}$ 与秩 K 下进行；请对照 LSA、NMF、PLSA、LDA 的因子符号，核对哪些允许负值、哪些列归一、哪些含随机先验。

37.2 矩阵分解与概率模型比较

令 $\mathbf{X} \in \mathbb{R}_{\geq 0}^{M \times N}$ 按“词 $\times$ 文档”排列，目标秩为 $K \leq \min(M, N)$ 。四类话题表示的边界如下。


方法	共同乘积写法	关键约束或概率口径	训练/推断
LSA	$\mathbf{W} = \mathbf{U}_K, \mathbf{H} = \boldsymbol{\Sigma}_K \mathbf{V}_K^T$	$\mathbf{W}^T \mathbf{W} = \mathbf{I}_K, \mathbf{H} \mathbf{H}^T = \boldsymbol{\Sigma}_K^2$	截断 SVD 给平方损失的最优秩不超过 K 近似
NMF	$\mathbf{X} \approx \mathbf{W}\mathbf{H}$	$\mathbf{W}, \mathbf{H} \geq 0$ ；损失须另行声明	交替非负优化，通常只保证驻点性质

方法	共同乘积写法	关键约束或概率口径	训练/推断
PLSA	$P = WH$	$W_{ik} = p(w_i z_k),$ $H_{kj} = p(d_j z_k);$ $\sum_i W_{ik} = 1, \sum_{k,j} H_{kj} = 1$	联合 token 似然的 EM
LDA 模型族	$p(w, z, \theta, \varphi)$ 或 $p_{\text{par}}(w, z, \theta \varphi)$	完整 Bayes 版对 θ_j, φ_k 置先验; 点参数版只对 θ_j 置先验	完整 Bayes 版用 Gibbs; 本书点参数版用变分 EM


LSA 的文档系数是 H 的列；这些列一般不正交。PCA 则从已经中心化的样本矩阵寻找方差最大的正交方向，不能与未中心化文本矩阵的 LSA 等同。

图 37.4 展示低秩乘积、损失、约束和概率解释之间的桥梁。其中下层的条件高斯因子图表示：固定全局因子和第 n 个文档系数后生成观测文档；它是一种条件高斯表示，不是给所有因子都配置先验的完整贝叶斯模型。

上层：共同低秩外形与不同语义



下层：条件高斯因子图



H 的第 n 列对应下层 h_n ；损失、约束、归一化和先验改变统计含义，不能把 LSA、NMF 误画成同一概率模型。

图 37.4 矩阵分解与概率模型的桥梁： $X \approx WH$ 只是共同外形；损失、约束和概率口径决定语义，下层以 $W, h_n \rightarrow x_n$ 给出条件高斯分支。

读图检查。先看上层 $X \approx WH$ 的共同低秩外形；再比较 LSA、NMF 与概率因子模型框中的损失、约束和概率口径，并确认虚线只表示“共同乘积外形下进入概率建模分支”，不编码关系强弱；最后沿下层 $W, h_n \rightarrow x_n$ 的两条有向边核对条件高斯公式，确认代数乘积共享不等于模型语义相同，条件高斯分支也不等于完整贝叶斯模型。

阅读目标：从三种观测假设分别推出损失，避免把相同的 WH 误当作相同模型。

对象： $W \in \mathbb{R}^{M \times K}$ 、 $H \in \mathbb{R}^{K \times N}$ 与 $\Lambda = WH \in \mathbb{R}^{M \times N}$ 。

合法条件：高斯模型需 $\sigma^2 > 0$ ；泊松计数非负且正计数处 $\lambda_{ij} > 0$ ；PLSA 概率矩阵需归一化。

第一步：先为每种观测机制写联合对数似然，再删除与 W, H 无关的常数。

推导目标

在统一乘积 $\Lambda = WH$ 下, 分别从高斯连续观测、泊松计数和 PLSA 联合多项分布推出对应目标, 说明“相同乘积”为什么仍可能是不同模型。

推导准备

设 $W \in \mathbb{R}^{M \times K}$ 、 $H \in \mathbb{R}^{K \times N}$, 故 $\Lambda \in \mathbb{R}^{M \times N}$ 。高斯情形要求 $\sigma^2 > 0$; 泊松情形要求 $n_{ij} \in \mathbb{Z}_{\geq 0}$ 、 $\lambda_{ij} \geq 0$ 且 $n_{ij} > 0$ 时 $\lambda_{ij} > 0$; PLSA 联合口径要求 $p_{ij} \geq 0$ 且 $\sum_{i,j} p_{ij} = 1$ 。

推导第 1 步: 高斯观测给出平方重构。 若在给定 W, H 后各元素独立且 $X_{ij} \sim \mathcal{N}(\lambda_{ij}, \sigma^2)$, 则

$$-\log p(X | W, H) = \frac{MN}{2} \log(2\pi\sigma^2) + \frac{1}{2\sigma^2} \sum_{i,j} (x_{ij} - \lambda_{ij})^2.$$

固定 σ^2 时, 最大化似然等价于最小化 $\|X - WH\|_F^2$ 。这可作为实值权重的工作模型; TF-IDF 不是计数, 不能据此改用泊松似然。

推导第 2 步: 泊松计数给出广义 KL。 若 $N_{ij} \sim \text{Poisson}(\lambda_{ij})$ 相互独立, 则

$$-\log p(N | \Lambda) = \sum_{i,j} \{\lambda_{ij} - n_{ij} \log \lambda_{ij} + \log(n_{ij}!)\}.$$

定义

$$D_{\text{gKL}}(N \| \Lambda) = \sum_{i,j} \left[n_{ij} \log \frac{n_{ij}}{\lambda_{ij}} - n_{ij} + \lambda_{ij} \right],$$

采用扩展实数约定: 对任意 $\lambda \geq 0$ 令 $0 \log(0/\lambda) := 0$, 特别地 $0 \log 0 := 0$; 若 $n > 0, \lambda = 0$, 则 $-n \log \lambda = +\infty$ 且 $n \log(n/\lambda) = +\infty$ 。因此 $n = 0, \lambda = 0$ 时泊松负对数似然与广义 KL 的该格贡献都为 0, $n = 0, \lambda > 0$ 时都贡献 λ , 而 $n > 0$ 时必须取 $\lambda > 0$ 才能得到有限值。两式之差只含观测计数, 因此在同一扩展实数可行域上有相同极小点。

命题 37.1 (泊松负对数似然与广义 KL 等价) 在上述计数、正值和有限性条件下, 关于 Λ 最小化泊松负对数似然, 等价于最小化 $D_{\text{gKL}}(N \| \Lambda)$ 。

读前自检: 证明: 泊松负对数似然与广义 KL 等价。 Poisson 均值 $\lambda_{ij} = (WH)_{ij}$ 时, 负对数似然单项为 $\lambda_{ij} - x_{ij} \log \lambda_{ij}$ 加只依赖 x_{ij} 的常数; 请与广义 KL 单项相减, 核对差与 W, H 无关。

证明. 逐元素相减得到

$$\{-\log p(n_{ij} | \lambda_{ij})\} - \{n_{ij} \log(n_{ij}/\lambda_{ij}) - n_{ij} + \lambda_{ij}\} = \log(n_{ij}!) - n_{ij} \log n_{ij} + n_{ij},$$

其中 $n_{ij} = 0$ 时按 $0 \log 0 = 0$ 解释; 这同时覆盖 $\lambda_{ij} = 0$ 的零-零分支。右端不含 λ_{ij} , 对所有可行 Λ 都是同一常数; 因此两个目标的大小只差常数, 极小点集合相同。若正计数位置取 $\lambda_{ij} = 0$, 两目标都为正无穷, 该点不属于有限目标域, 结论仍与定义域一致。□

推导第 3 步：PLSA 联合 token 似然给出联合 KL。 令总 token 数 $N_{\text{tok}} = \sum_{i,j} n_{ij} > 0$, $\hat{p}_{ij} = n_{ij}/N_{\text{tok}}$, 并采用

$$p_{ij} = p(d_j) \sum_{k=1}^K p(w_i | z_k) p(z_k | d_j) = (\mathbf{W}\mathbf{H})_{ij}.$$

多项分布对数似然除去组合常数后为 $N_{\text{tok}} \sum_{i,j} \hat{p}_{ij} \log p_{ij}$, 而

$$D_{\text{KL}}(\hat{\mathbf{P}} \parallel \mathbf{P}) = \sum_{i,j} \hat{p}_{ij} \log \hat{p}_{ij} - \sum_{i,j} \hat{p}_{ij} \log p_{ij}.$$

第一项与模型无关, 故最大化联合 token 似然等价于最小化联合 KL。这里采用联合概率口径; 没有同时要求 $\mathbf{H}$ 每列和为 1。

命题 37.2 (附加约束不会改进同一损失的无约束下界) 设 $\emptyset \neq \mathcal{F}_c \subseteq \mathcal{F}$, 且损失 $\mathcal{J} : \mathcal{F} \rightarrow \mathbb{R} \cup \{+\infty\}$ 满足 $-\infty < \inf_{\mathcal{F}} \mathcal{J} < +\infty$ 。则

$$\inf_{(\mathbf{W}, \mathbf{H}) \in \mathcal{F}_c} \mathcal{J} \geq \inf_{(\mathbf{W}, \mathbf{H}) \in \mathcal{F}} \mathcal{J}.$$

读前自检：证明：附加约束不会改进同一损失的无约束下界。 附加约束不会改进同一损失的无约束下界所用的明确前提是“右端是 $\mathcal{J}$ 在更大集合 $\mathcal{F}$ 上的共同下界”；完成补出 $\mathcal{J}(\mathbf{W}, \mathbf{H}) \geq \inf_{\mathcal{F}} \mathcal{J}$ 到下一关系的一步不等式或求导后, 核对不等号方向与取等条件同时成立。

证明。 右端是 $\mathcal{J}$ 在更大集合 $\mathcal{F}$ 上的共同下界, 所以对每个 $(\mathbf{W}, \mathbf{H}) \in \mathcal{F}_c$ 都有 $\mathcal{J}(\mathbf{W}, \mathbf{H}) \geq \inf_{\mathcal{F}} \mathcal{J}$ 。再对左侧所有可行点取下确界, 保持该不等式。□

该命题只允许在同一损失、同一数据和可嵌套可行域下比较。平方损失、广义 KL、联合对数似然与 ELBO 不能只看数值大小来决定优劣。若用 Bregman 散度, 零点唯一性还要求生成函数在相应定义域严格凸; 仅有凸性不足以推出唯一零点。

例题 37.1 (两候选、两折的完整选择轮次)。这是用于复算协议的确定性教学输入。预先声明“两个验证折都成功才可选, 并在可选者中最小化平均损失”。候选 A 在两折的验证损失为 0.42, 0.46, 成本为 8, 9 分钟; 候选 B 第一折损失为 0.35、成本 12 分钟, 第二折数值失败。执行选择、重拟合与一次锁定测试协议; 测试损失规定为 0.47。

例题 37.1 解答

读题翻译 按“两折都数值成功才可选、再比较平均验证损失”的规则, 在 A 和 B 中完成选择、重拟合与一次锁定测试。

已知与合法条件 A 在两折的损失、成本为 (0.42, 8)、(0.46, 9); B 第一折为 (0.35, 12), 第二折数值失败; 锁定测试损失预先规定为 0.47。

为什么想到这个方法 先用所有折的成功指标确定可选集合, 只在该集合内汇总验证损失; 测试集必须与选择步骤隔离。

方法选择 计算两候选的成功向量与可选集合, 汇总唯一合格候选 A 的损失和成本, 随后在完整开发集重拟合并只报告一次测试结果。

推导/计算

$$a_A = (1, 1), \quad a_B = (1, 0), \quad \mathcal{B}_{\text{ok}} = \{b : \prod_{c=1}^2 a_{bc} = 1\} = \{A\}.$$

因此 B 的聚合指标未定义, 且其唯一成功折不能与完整两折的候选竞争。 A 的汇总为

$$\bar{L}_A = \frac{0.42 + 0.46}{2} = 0.44, \quad \bar{C}_A = \frac{8 + 9}{2} = 8.5 \text{ 分钟}.$$

独立核验 $\prod_c a_{Ac} = 1$ 而 $\prod_c a_{Bc} = 0$; A 的损失和、成本和分别为 0.88 和 17, 除以两折复得 0.44 和 8.5 分钟。

结论 选择 A , 在全部开发数据上重拟合并后, 只解封一次锁定测试并报告 $L_{\text{test}} = 0.47$; 该结果不反馈到候选、超参数或预处理。

几何解释。LSA 用 K 维正交子空间逼近数据, 允许因子坐标有正有负; NMF 把每个文档放在 W 列向量张成的非负锥中, 部分表示更易解释却缩小可行域; 聚类把数据压到有限原型或树结构; PCA 必须先中心化, 再以正交投影最大化方差或最小化重构误差。

概率解释。PLSA 对固定参数做极大似然, 没有文档主题分布的生成先验; 完整 Bayes LDA 为文档主题分布和主题词分布都配置狄利克雷先验, 并可用 Gibbs 推断; 第 35 章 (第 5 册第 6 章) 的点参数 LDA 变体只给文档主题分布配置先验, 把主题词分布作为点参数并用变分 EM 估计。两种口径不能写成同一个后验。MCMC 样本相关, 有限运行不要求也通常无法给出“已经收敛到后验”的数学证书。评价后验期望时应执行预先声明的有限诊断/停止协议: 至少报告独立链数 R_{chain} 、每链预热与留样预算、参数级有效样本量 (ESS)、 $\hat{R}$ 及 Monte Carlo 标准误; 诊断未达阈值时保留运行记录并标记证据不足, 不能把目标函数下降或 converged 标签当作链收敛证明。

优化解释。SVD 在平方损失的秩不超过 K 问题中给出全局解; NMF、PLSA 和多数变分目标非凸, 初始化会改变局部结果。EM 的观测似然不降、VI 的 ELBO 不降都是各自更新条件下的单调性, 不代表达到全局最优。Gibbs 是马尔可夫链后验推断, 不是以目标函数单调下降定义的优化算法。

图形辅助。图 37.4 说明矩阵与概率视角的共享部分; 后续图 37.5–37.7 分别承担验证、评价和方法选择, 每幅图都对应一个可执行检查, 而非装饰性分类。

小型数值例子。取

$$N = \begin{bmatrix} 3 & 0 \\ 1 & 2 \end{bmatrix}, \quad \Lambda = \begin{bmatrix} 2 & 1 \\ 2 & 1 \end{bmatrix}.$$

按零计数约定逐格计算,


$$D_{\text{gKL}}(N \parallel \Lambda) = 3 \log(3/2) + \log 2 \approx 1.9095.$$

四个单元的常数项抵消后可核验命题 37.1。若把 N 替换成 TF-IDF 权重, 则泊松计数语义消失, 即使公式仍能算出一个数, 也不能称为计数似然。

37.3 模型选择与评价

把数据单元先定义清楚：独立单元可能是样本、文档、用户、时间块或整张图，而不一定是矩阵元素。在这些单元上划分训练集、验证集和锁定测试集。所有方法、秩 K 、簇数、先验、初始化次数与停止容差只能由训练/验证信息决定；测试标签或测试 token 不能反馈到选择过程。

本章明确区分图 37.5 中的两个并列、无泄漏且估计对象不同的完整协议。协议 A 由算法 37.1 实现：只在开发数据 D 上选择并冻结候选，随后重训，锁定测试集 T 只开封一次。协议 B 是嵌套交叉验证：对每个外层折 c ，都须在 D_{-c} 上重新执行 C_{in} 折候选选择与重训，再仅用 D_c 作外层评价，最终汇总 C_{out} 个损失；它不是算法 37.1 的隐藏外循环。任何用锁定测试或外层评价结果回调候选、超参数或停止规则的做法都属于信息泄漏。



任何来自锁定测试或外层评估的这类回流都属于信息泄漏。

图 37.5 两种并列的无泄漏评价协议：协议 A 对应算法 37.1，冻结开发集候选后只开封测试集一次；协议 B（嵌套交叉验证）在每个外层折 c 内重做 C_{in} 折选择，再汇总 C_{out} 个外层损失。虚线回箭头与 X 表示任何评估结果回调选择或停止规则都属于泄漏。

读图检查。先复述协议 A 中“开发集选择并冻结候选、完整 D 重训、 T 只开封一次”的方向；再复述协议 B 中“每个 c 都在 D_{-c} 内重做 C_{in} 折选择、只用 D_c 评价、汇总 C_{out} ”的方向；最后沿两条橙色虚线回箭头从最终评价指回选择节点，说明为何箭头在 X 处被阻断，以及这种反馈为何构成泄漏。

读前自检：独立测试均值对已锁定模型条件无偏。 模型 $\hat{f}$ 由开发数据锁定，独立测试基本单元 Z_S 条件 iid；请写测试均值 $S^{-1} \sum_S L(Z_S, \hat{f})$ 的条件期望，核对应等于 $R(\hat{f})$ 。

命题 37.3 (独立测试均值对已锁定模型条件无偏) 设 $\mathcal{D}_{\text{dev}}$ 包含训练与验证信息, $\hat{f}$ 是其可测函数; 测试样本 $Z_1, \dots, Z_m$ 在给定 $\mathcal{D}_{\text{dev}}$ 后仍独立同分布于目标分布 P , 且 $\ell(\hat{f}, Z)$ 可积, 并定义 $R(\hat{f}) := \mathbb{E}_{Z \sim P}[\ell(\hat{f}, Z)]$ 。则

$$\mathbb{E}[\hat{R}_{\text{test}} \mid \mathcal{D}_{\text{dev}}] = R(\hat{f}), \quad \hat{R}_{\text{test}} = \frac{1}{m} \sum_{s=1}^m \ell(\hat{f}, Z_s).$$

读前自检：证明：独立测试均值对已锁定模型条件无偏。 给定开发数据后 $\hat{f}$ 固定, 测试单元与其独立且损失可积; 请把条件期望移入有限和, 核对每项期望均为同一 $R(\hat{f})$, 故测试均值条件无偏。

证明. 给定 $\mathcal{D}_{\text{dev}}$ 后, $\hat{f}$ 固定, 而每个 Z_s 仍服从 P 。可积性允许交换有限求和与条件期望, 因此

$$\mathbb{E}[\hat{R}_{\text{test}} \mid \mathcal{D}_{\text{dev}}] = \frac{1}{m} \sum_{s=1}^m \mathbb{E}_{Z \sim P}[\ell(\hat{f}, Z)] = R(\hat{f}).$$

在通常的非退化情况下, 若测试结果参与候选选择, $\hat{f}$ 不再只由 $\mathcal{D}_{\text{dev}}$ 决定, 上述条件独立结构被破坏; 但若给定 $\mathcal{D}_{\text{dev}}$ 后选择索引几乎处处固定, 或所有可能选中索引对应同一预测器, 则可测性可保留。□

读前自检：这一定理不能按行看起来像样本自动套用。 若基本单元在给定开发数据后确为 iid, 直接应用命题。独立测试均值定理要求基本评价单元条件 iid, 不能仅因表格按行排列就套用; 请用同一图的相关结点行作反例, 指出独立性失败, 并改用图专用重采样或设计型分析。

关键结论

这一定理不能按“行看起来像样本”自动套用。 若基本单元在给定开发数据后确为 iid, 直接应用命题。若只是交换但有共同用户、文档、时间块或抽样不放回结构, 应把整个组作为切分单元, 并按相应有限总体或簇抽样估计量分析。若结点、边来自同一张图, 训练边与测试边通常共享端点且相互依赖; 随机拆边并不产生 iid 测试样本。此时应按独立图、图快照、时间块或预先定义的结点群切分, 并把风险定义为“新图”“未来快照”或“新群组”上的目标; 若只有一张相依图, 则命题 37.3 不提供无偏保证, 必须报告依赖假设并采用图专用重采样或设计型分析。

数据结构	合法切分单元	可声称的评价结论
iid 观测	单个观测	满足命题条件时, 锁定测试均值条件无偏
组内相关/交换	用户、文档、家庭、会话或整组序列	组间独立时按组评价; 不能把组内元素当独立样本扩大样本量
时间依赖	不交叠时间块, 训练早于测试	估计未来时间块风险; 需说明漂移与间隔策略
图结点/边	独立图、图快照或预定义结点群	只对声明的图单位泛化; 单图随机拆边不自动继承 iid 无偏性

无监督评价至少保留以下证据:

- **拟合与任务效用**：重构误差、留出对数似然、文档完成困惑度、检索或下游效用；
- **稳定性**：重采样后簇、子空间、主题或排序的一致性，并处理标签置换或因子旋转；
- **解释性**：主题词一致性、原型可读性、负载稀疏性，连同人工规则和盲评协议；
- **计算证据**：运行时间、最大工作存储量、迭代数、失败率，以及所有候选共用的固定执行环境说明；
- **专用诊断**：PageRank 报告固定点残差和扰动稳定性；MCMC 报告 R_{chain} 、逐链预算、ESS、 $\hat{R}$ 、自相关和 Monte Carlo 标准误，并以“诊断通过/证据不足”而非有限步 converged 表述。

话题模型的文档完成式评价应在每篇测试文档内部再分“已观察 token”和“待评分 token”：只用前者推断该文档的主题比例，再对后者计算预测概率，不能用待评分 token 反向推断后再评分。

图 37.6 把拟合、预登记任务效用、稳定性、可解释性和计算代价五个互补维度并列展示；各卡的点、区间、分布或资源微图只提示报告形态，不是可复算数值结果，也不定义单一总分。




图 37.6 五个互补评价维度须联合报告：拟合、预登记任务效用、稳定性、可解释性与计算代价各保留方向、单位及不确定性或资源口径；微图仅提示概念形态，不是可复算结果，也不合成无依据总分。

读图检查。先逐卡核对五个指标的方向和单位；再读取 SE、95%CI、IQR、CI 所表达的不确定性或分布角色，以及时间/内存资源微图；最终把五类证据联合报告，并确认不得合成无依据的单一总分。

读前自检：无监督学习方法。无监督方法选择协议先按输出语义筛选候选，再在开发集内比较，锁定配置后只解封一次测试集；请把聚类、PCA、PLSA、PageRank 各匹配到其输出，核对测试结果未反馈到候选或预算。

37.4 方法选择地图

选择顺序应从输出语义开始，而不是从算法熟悉度开始：需要离散分组时先考虑聚类；需要线性压缩时比较 PCA、SVD/LSA 与 NMF；需要词与文档的概率生成结构时比较 PLSA 与 LDA；需要图上的稳态重要性时使用 PageRank；需要难积分后验的期望时才考虑 MCMC。图 37.7 给出

完整决策路径：唯一虚线只允许验证阶段回修候选族；一旦锁定选择，最终测试与报告都不得回流到候选或验证过程。




图 37.7 方法选择地图：首要任务先按输出语义与必要约束形成聚类、降维、话题或图排序候选族，再由验证协议、计算预算和失败模式筛选后锁定选择。唯一虚线只允许验证阶段回修候选族；最终测试与报告不回流。

读图检查。先看输出语义与必要约束；再看聚类、降维、话题、图排序四族如何进入验证协议、计算预算和失败模式筛选；最终沿实线锁定选择，并确认只允许验证阶段以虚线回修候选族，最终测试或报告绝不回流。

方法	核心模型	可声称的求解性质	主要警戒线
层次聚类	树状合并	有限次合并终止	距离与链接规则决定结果
k 均值	中心与硬划分	目标单调不增，通常到局部解	尺度、异常值、非球形簇
高斯混合	概率混合	EM 似然不降，通常到驻点	协方差退化与初始化
PCA/LSA	正交低秩子空间	秩不超过 K 的相应平方损失有 SVD 全局解	PCA 需中心化；LSA 语义不同
NMF	非负低秩因子	交替优化通常只到驻点	尺度/置换不唯一、局部解
PLSA/LDA	潜在主题模型	EM、VI 或 Gibbs 各有不同保证	似然、ELBO 与链诊断不可混用
PageRank	图上马尔可夫链	阻尼模型有唯一固定点和幂法收敛	悬挂修复、列随机方向、图偏差

算法伪代码。算法 37.1 只实现协议 A：任务定义、开发集内 C_{in} 折选择、一次锁定测试和多指标评价。协议 B 的 C_{out} 个外层折必须各自完整重跑内层选择，不能把算法 A 的一次开发集选择误称为嵌套交叉验证。算法不替代候选方法的内部求解器，而是规定一致的比较方式。

输入与输出。输入包括带独立单元标识的数据、任务规格、有限候选配置、拆分方案、主指标与约束指标、初始化规则和计算预算；输出包括锁定模型、一次测试结果，以及稳定性、解释性和成本比较。

参数含义。 K 可表示秩、簇数或主题数，但每个候选必须写明含义； C_{in} 是开发集内验证折数， C_{out} 只用于协议 B 的外层折数， B 是有限候选数， T_{max} 是内部迭代硬上限；主指标方向、容许退化阈值和资源上限必须在查看测试结果前确定。

初始化。先确定独立单元、预处理和拆分规则；再只用训练折拟合预处理参数。随机方法使用预先声明的 R_{start} 个初始化、 R_{chain} 条链和 $R_{bootstrap}$ 次重采样计划。任何由完整数据计算的词表、中心、均值或缩放都可能造成泄漏。

参数更新与更新顺序。候选循环依次遍历配置，内层循环依次遍历 C_{in} 个验证折；每次先拟合训练折，再在验证折计算主指标、稳定性和成本。候选选定后在整个开发集重拟合一次，最后才解封测试集；测试结果不再触发参数更新。

判断条件、停止条件与返回。内部求解器满足其预先声明的数值/诊断停止协议且检查通过时，该次拟合才进入比较。对优化或固定点方法，记录其规范状态与证书；对 MCMC 有限运行，不要求 converged，而是核验预登记的链数、预算、ESS 与 $\hat{R}$ 门槛。达到 T_{max} 、目标值不是有限实数、出现空簇或奇异协方差、MCMC 诊断证据不足或预算超限时，记录具体原因。有限候选和有限折全部处理完毕后流程结束；若所有候选都不满足预先声明的要求，则停止选择且不查看测试集。

正确性依据、收敛条件与不适用情形。数据隔离保证命题 37.3 的条件结构；有限枚举保证协议本身终止。候选内部保证仍分别依赖 SVD、EM、VI、MCMC 或幂法的条件，协议不把预算终止改写成数学收敛，也不为 MCMC 有限运行生成 converged 证书。命题 37.3 只在其条件 iid 前提成立时提供无偏结论；依赖图、时间序列或组内相关数据必须改用前述结构化切分与相应估计对象。无法定义切分单元、评价指标与任务语义时，该协议不适用应先修订实验设计。

训练时间复杂度与预测时间复杂度。设第 b 个配置在第 c 折的一次初始化拟合、一条链、一次重采样重拟合/对齐和常规评价代价分别为 $F_{bc}^{start}, F_{bc}^{chain}, F_{bc}^{boot}, E_{bc}$ 。不适用的项取零，则该折完整代价必须展开为

$$F_{bc} = R_{start,bc} F_{bc}^{start} + R_{chain,bc} F_{bc}^{chain} + R_{bootstrap,bc} F_{bc}^{boot},$$

选择总时间为 $O(\sum_{b=1}^B \sum_{c=1}^{C_{in}} (F_{bc} + E_{bc}))$ ，另加一次开发集重拟合。主题稳定性的 F_{bc}^{boot} 须包含主题匹配/最佳置换代价；不得把多启动、多链、重采样或匹配藏进常数。预测时间复杂度依锁定方法参数化报告：线性投影常为 $O(MK)$ 每列，最近中心分配为 $O(MK)$ ，PageRank 物化后单结点查询为 $O(1)$ ；不得给所有方法写同一个预测界。

空间复杂度与复杂度假设。串行复用中间存储时，峰值空间由数据和最大单次模型决定；并行执行会乘以并发数。复杂度假设包括稀疏/稠密存储、候选与折数有限、一次标量运算常数成本、不计外存和网络通信；比较时固定执行环境，并报告并行任务数、运行时间与最大工作存储量。

协议 A：开发集选择与一次锁定测试：五步阅读

输入。写出数据对象、固定参数与必须成立的条件。

初始化。标明主状态、计数器和第一个合法状态。

核心更新。只手算一次从旧状态到候选状态的更新，并指出何时提交。

数学停止。写出能直接核验的停止证书；预算耗尽不等同于收敛。

算法 37.1: 协议 A: 开发集选择与一次锁定测试

输入: 数据与独立单元 ID; 任务规格 $\mathbf{u}$; 有限候选 $\{(\mathcal{M}_b, \lambda_b)\}_{b=1}^B$; 开发/测试拆分; C_{in} 折生成规则; 指标方向; $R_{start}, R_{chain}, R_{bootstrap}$ 及种子表; T_{max} 与资源预算

输出: 最后合法折记录与锁定结果; $b_{done}, e_{done}, f_{done}$; **status** 与最终诊断

- 1 置 $b_{done} = e_{done} = f_{done} = 0$; 核验独立单元、候选/折、指标/约束/并列规则、种子表与预算并封存测试集; 失败则返回空记录、**invalid_input** 及字段诊断
- 2 对 $b \leftarrow 1$ 至 B 执行
 - 3 对 $c \leftarrow 1$ 至 C_{in} 执行
 - 4 若全局评价预算不足以启动本折, 则返回最后合法记录、**budget_stop** 及 (b, c) 预算诊断, 且不选择部分枚举结果
 - 5 读取预登记种子并执行训练折专属预处理与候选拟合; 种子/随机源失败时返回记录、**random_source_failure** 及 (b, c) 阶段诊断
 - 6 若候选为 MCMC, 则执行全部预登记链与预算, 记录 ESS、 $\hat{R}$ 、自相关和 Monte Carlo 标准误; 诊断未通过时原子记录 $valid[b, c] = false$ 与“有限运行证据不足”, 增加 e_{done} 并继续, 不得要求或伪造 **converged**
 - 7 若候选不是 MCMC 且内部停止状态不满足其预登记接纳规则, 或任一候选发生数值失败, 则原子记录 $valid[b, c] = false$ 及内部状态, 增加 e_{done} 并继续; 不得用失败折评价
 - 8 在对应验证折计算预声明指标、约束与稳定性; 非有限或对齐失败则原子记录不合格和诊断; 否则原子提交完整成功记录并增加 f_{done}, e_{done}
 - 9 **结束**
- 10 令 $b_{done} \leftarrow b$; 若任一折不合格, 则候选 b 记为不可选且不得汇总成功折; 否则以共同分母 C_{in} 汇总指标、离散度、稳定性和成本; 若候选 b 违反预声明硬约束, 则记为不可选;
- 11 **结束**
- 12 若汇总非有限, 则返回折记录、**numerical_failure** 及候选汇总诊断; 若无合格候选, 则返回无配置、**completed** 及“测试集未访问”最终诊断
- 13 按预声明排序与决胜规则选出 $(\hat{\mathcal{M}}, \hat{\lambda})$; 用整个开发集重拟合一次并增加 f_{done} ; 失败则保留选择/折记录, 返回 **numerical_failure** 及重拟合诊断
- 14 仅此时访问测试集一次; 评价非有限则返回锁定模型、**numerical_failure** 及测试阶段诊断; 否则返回全部结果、实际计数、**completed** 及“测试访问次数 1”最终诊断

输出。 列出返回对象、实际计数、中心状态和用于复核的诊断。

适用条件。 数据划分必须尊重用户、时间、文档或图快照等独立结构; 候选集与指标须有限且预先声明; 每种方法应说明停止原因和数值诊断。小数据可用协议 B 的 $C_{out} \times C_{in}$ 嵌套重采样, 大型数据可用协议 A 保留独立开发/测试划分, 但隔离原则不变。

局限性。 没有标签时, 内部指标可能偏爱错误几何; 稳定不代表有用, 易解释也不代表预测概率校准; 同一语料上的困惑度与人工主题质量可能排序相反。嵌套验证降低选择偏差, 却增加计算成本, 也不能修复数据分布漂移、测量偏差或错误任务定义。

常见错误。 在完整数据上中心化后再划分; 用测试集选 K ; 把训练重构误差当泛化能力; 把 EM 似然不降写成全局最优; 把 ELBO 与真实对数证据混写; 把 Gibbs 样本数当有效样本量; 把 TF-IDF 代入泊松模型; 声称 LSA 的文档列正交; 同时要求 PLSA 联合归一化与右因子每列归一化; 只报最好一次随机初始化而不报失败率。

易混淆概念对比

下列概念对最易在报告中混淆; 比较时必须区分它们的角色、证据口径和收敛含义。

任务与求解器: 聚类、降维、话题、排序规定输出; SVD、EM、VI、MCMC、幂法规定计算路线。

训练目标与验证指标: 前者用于拟合参数; 后者用于在独立数据上选择配置。

验证集与测试集: 验证集可反复参与选择; 锁定测试集只做一次最终评估。

似然与 ELBO: 似然是模型对观测的概率; ELBO 是给定变分族的下界。

优化收敛与链收敛：前者指目标或梯度达到驻点条件；后者在马尔可夫链条件下讨论分布或遍历均值收敛。

重构稳定与语义稳定：前者指数值误差相近；后者要求因子经置换或旋转对齐后含义一致。

37.5 全书综合自检

例题 37.2 (对象、目标与求解器分层). 某语料项目说“用 Gibbs 做无监督学习”。把这句话改写成可执行的任务规格。

例题 37.2 解答

读题翻译 “用 Gibbs 做无监督学习”只说了推断引擎；要把它补成可执行规格，必须声明数据、模型、后验目标、更新规则、运行预算和评价输出。

已知与合法条件 语料、分词与词表必须先固定；以 K 主题 LDA 为模型，超参数 α, β 、随机种子和资源预算均在运行前登记。

为什么想到这个方法 把口号拆成“数据—模型—目标—更新—预算—输出”六项，并逐项写出能够复算或核验的对象。

方法选择 先声明语料预处理与 LDA 潜变量，再写目标后验和塌缩 z_{dn} 满条件；随后固定扫描顺序、初始化、链数、预热与保留样本数，最后规定主题输出、留出似然、稳定性、ESS 和 MCSE。

推导/计算 任务写成“估计文档主题分布并计算后验主题期望”。生成模型为

$$\varphi_k \sim \text{Dir}(\beta), \quad \theta_d \sim \text{Dir}(\alpha), \quad z_{dn} | \theta_d \sim \text{Cat}(\theta_d), \quad w_{dn} | z_{dn} = k \sim \text{Cat}(\varphi_k).$$

塌缩掉 θ, φ 后，逐词元扫描并按

$$p(z_{dn} = k | z_{-dn}, w) \propto (n_{dk}^{-dn} + \alpha_k) \frac{n_{kw}^{-dn} + \beta_w}{n_k^{-dn} + \beta_0}$$

更新主题指派。运行规格需登记初始化、扫描顺序、种子、链数、预热长度、保留样本数与内存预算。若链只保存 $z^{(s)}$ ，文档主题比例采用 Rao-Blackwell 化估计

$$\hat{\theta}_{dk}^{(s)} = \frac{n_{dk}^{(s)} + \alpha_k}{N_d + \alpha_0}, \quad \hat{E}[\theta_{dk} | w_d] = \frac{1}{S} \sum_{s=1}^S \hat{\theta}_{dk}^{(s)}.$$

最终同时报告主题词、文档主题比例、文档完成式留出对数似然、主题稳定性以及链的 ESS 与 MCSE。

独立核验 把求解器替换为合法的变分推断后，语料、LDA 模型、后验目标和留出评价口径均可保持不变；这说明 Gibbs 只是求解器。并且 $\hat{\theta}_{dk}^{(s)}$ 只使用保留的塌缩链计数即可复算，分量非负且对 k 求和为 1。

结论 可执行规格必须同时声明数据预处理、LDA 模型、目标后验、塌缩 Gibbs 更新与扫描顺序、初始化和采样预算, 以及主题输出、留出评价、ESS 与 MCSE; 不能只写“用 Gibbs 做无监督学习”。

例题 37.3 (LSA 因子维数纠错). 设 $X \in \mathbb{R}^{6 \times 4}$ 、 $K = 2$ 。写出截断 SVD 因子的维数, 并判断“两个文档系数列必正交”是否成立。

例题 37.3 解答

读题翻译 对 $X \in \mathbb{R}^{6 \times 4}$ 取秩 2 截断 SVD, 写出 LSA 因子的维数, 并判断文档系数列是否正交。

已知与合法条件 $K = 2$, 截断 SVD 写为 $X \approx U_2 \Sigma_2 V_2^T$, 其中右奇异向量列满足 $V_2^T V_2 = I_2$ 。

为什么想到这个方法 先由原矩阵的行、列数确定截断 SVD 各因子的形状, 再将文档列内积写成矩阵条目, 避免把行正交误作列正交。

方法选择 标注 U_2, Σ_2, V_2, H 的维数, 建立文档列内积公式, 并用 HH^T 解释实际成立的正交关系。

推导/计算

$$U_2 \in \mathbb{R}^{6 \times 2}, \quad \Sigma_2 \in \mathbb{R}^{2 \times 2}, \quad V_2 \in \mathbb{R}^{4 \times 2}, \quad H := \Sigma_2 V_2^T \in \mathbb{R}^{2 \times 4}.$$

所以

$$X \approx U_2 H, \quad (6 \times 2)(2 \times 4) = 6 \times 4.$$

虽然 $V_2^T V_2 = I_2$, 但 $V_2 V_2^T$ 一般不等于 I_4 。若 h_j 、 h_ℓ 是 H 的两列文档系数, 则

$$h_j^T h_\ell = e_j^T V_2 \Sigma_2^2 V_2^T e_\ell,$$

其一般不为零, 故文档列不必正交。

独立核验 重构乘积为 $(6 \times 2)(2 \times 2)(2 \times 4) = 6 \times 4$, 且

$$HH^T = \Sigma_2 V_2^T V_2 \Sigma_2 = \Sigma_2^2.$$

这说明 H 的两行正交 (行范数由奇异值给出), 而不是四个文档列正交。

结论 U_2, Σ_2, V_2, H 的维数依次为 $6 \times 2, 2 \times 2, 4 \times 2, 2 \times 4$; LSA 文档系数列一般不正交。

例题 37.4 (锁定测试的条件无偏). 说明为什么比较 20 个秩后选出测试误差最小者通常会破坏命题 37.3 的条件, 并指出仍保留该条件的退化边界。

例题 37.4 解答

读题翻译 说明在测试集上比较 20 个秩并取最小测试误差时，为什么这种做法通常破坏锁定测试命题的条件无偏前提，并辨认不破坏可测性的退化边界。

已知与合法条件 条件在 $\mathcal{D}_{\text{dev}}$ 上，固定的 $f_1, \dots, f_{20}$ 各自满足 $\mathbb{E}[\hat{R}_K | \mathcal{D}_{\text{dev}}] = R(f_K)$ ；测试集独立且在选择前未打开。

为什么想到这个方法 条件无偏要求被评模型在给定开发数据后固定；若模型索引由测试误差决定，就要比较“固定候选的期望”与“测试最小值”的条件期望。

方法选择 先检验测试选择后的 $\hat{K}$ 是否仍只由开发数据决定，再写出条件不等式链，最后给出不泄漏测试集的正确流程。

推导/计算

$$\hat{K} \in \arg \min_{1 \leq K \leq 20} \hat{R}_{\text{test}}(f_K).$$

并列规则预先固定。测试 $\arg \min$ 通常使选中的预测器依赖 $\mathcal{D}_{\text{test}}$ ；除非给定 $\mathcal{D}_{\text{dev}}$ 后 $\hat{K}$ 几乎处处固定，或所有可能选中的索引对应同一预测器，否则 $f_{\hat{K}}$ 不是 $\mathcal{D}_{\text{dev}}$ -可测的固定候选，命题前提失效。给定 $\mathcal{D}_{\text{dev}}$ 时，

$$\mathbb{E}\left[\min_K \hat{R}_K | \mathcal{D}_{\text{dev}}\right] \leq \min_K R(f_K) \leq \mathbb{E}[R(f_{\hat{K}}) | \mathcal{D}_{\text{dev}}].$$

其中第一步利用每个固定 f_K 的条件无偏性，第二步因为 $R(f_{\hat{K}})$ 只能取 20 个风险之一。左侧等号当且仅当存在固定的总体风险最小索引 $K_{\star} \in \arg \min_K R(f_K)$ ，使给定 $\mathcal{D}_{\text{dev}}$ 后 $\hat{R}_{K_{\star}} = \min_K \hat{R}_K$ 几乎处处成立；右侧等号当且仅当

$$\mathbb{P}(\hat{K} \in \arg \min_K R(f_K) | \mathcal{D}_{\text{dev}}) = 1.$$


最小测试报告一般或典型地偏乐观；上述取等边界表明不能把它表述为无例外的严格不等式。

独立核验 若索引 K 在开发阶段预先锁定，则 f_K 对 $\mathcal{D}_{\text{dev}}$ 可测，命题的条件无偏结论适用；一般的非退化情况下， $\hat{K}$ 读取测试误差会失去该前提。若 $\hat{K}$ 给定 $\mathcal{D}_{\text{dev}}$ 后几乎处处固定，或所有可能选中索引对应同一预测器，则该可测性仍可保留，这与上文可取等的退化边界一致。


结论 应在开发集内部选择秩，锁定并重拟合后，对未打开的测试集只评估一次；不要以最小测试误差作为模型选择依据。

图 37.8 把全书方法放回“问题定义 – 建模 – 计算 – 证据 – 边界”主闭环；下层监督与无监督任务共享线性代数、优化、概率、推断四类可复用计算引擎，隔离验证后的结论只能单向进入可复现报告，报告不回流。

(a) 问题到边界的五站主闭环



(b) 任务路线共享引擎与单向报告出口



实线接入：监督任务；虚线接入：无监督任务；池内四类引擎均可复用；双线报告框：单向终点。

图 37.8 全书统计学习闭环分为两层：(a) 问题定义、建模、计算、证据与边界构成五站主闭环，边界暴露或证据失败时返回问题定义；(b) 监督与无监督任务都进入包含线性代数、优化、概率、推断的共享可复用计算引擎池，再共同进入隔离验证并单向到达无回流的可复现报告。

读图检查。 先看上层五站主闭环及边界暴露/证据失败后返回问题定义的反馈；再看下层监督与无监督两路如何共同进入共享引擎池并汇入隔离验证；最终确认只有隔离验证后的结论能单向进入可复现报告，报告没有回流。

本章共 10 道练习。每道题干后立即给出同号解析；长解析可自然跨页，续页标题保留题号。

练习 37.1. 把“聚类、PCA、LDA、MCMC、PageRank、EM、SVD”分成任务、模型和求解器三类；对兼具两种角色的名称说明具体语境。

练习 37.1 解析

聚类是输出分组的任务族；PCA 是服务于降维任务的正交线性表示模型；LDA 是概率话题模型；PageRank 是以图稳态权重为目标的排序模型。MCMC 是后验期望估计的采样推断器，EM 是潜变量模型的迭代优化框架。SVD 既是代数分解对象，也是 PCA/LSA 中的计算工具。可用对象映射区分三类角色：

任务： $\mathcal{D} \mapsto \mathcal{Y}$ ， 模型： $\theta \mapsto p_{\theta}(\mathcal{D})$ 或 f_{θ} ， 求解器： $(\theta^{(t)}, \mathcal{D}) \mapsto \theta^{(t+1)}$ 。

例如

PageRank 模型： $\mathbf{r} = G\mathbf{r}$ ， 幂法： $\mathbf{r}^{(t+1)} = G\mathbf{r}^{(t)}$ ； LDA 模型 $\neq$ Gibbs 求解器。

练习 37.1 解析 (续)

因此“任务、模型、求解器”是角色分类而非互斥名称分类，必须同时说明输出量与计算目标。

练习 37.2. 对 $\mathbf{X} \in \mathbb{R}^{M \times N}$ 、秩 K 写出 LSA 的 $\mathbf{W}, \mathbf{H}$ 维数与两个正确正交关系，并纠正“文档列两两正交”。

练习 37.2 解析

薄截断 SVD 及维数为

$$\mathbf{X}_{M \times N} \approx \mathbf{U}_{K, M \times K} \mathbf{\Sigma}_{K, K \times K} \mathbf{V}_{K, N \times K}^T.$$

取 $\mathbf{W} = \mathbf{U}_K$ 、 $\mathbf{H} = \mathbf{\Sigma}_K \mathbf{V}_K^T$ ，则

$$\mathbf{W}^T \mathbf{W} = \mathbf{I}_K, \quad \mathbf{H} \mathbf{H}^T = \mathbf{\Sigma}_K \mathbf{V}_K^T \mathbf{V}_K \mathbf{\Sigma}_K = \mathbf{\Sigma}_K^2.$$

维数链为 $(M \times K)(K \times K)(K \times N) = M \times N$ ，与 $\mathbf{X}$ 一致；这也复核了转置必须落在 $\mathbf{V}_K$ 上。文档列是 $\mathbf{H}$ 的 N 列，数量可超过维数 K ，一般不两两正交。

练习 37.3. 比较 SVD、PCA 与 LSA：分别写明输入预处理、优化对象、输出解释和共同的线性代数工具。

练习 37.3 解析

SVD 对任意实矩阵给出

$$\mathbf{X} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T, \quad \mathbf{X}_K \in \arg \min_{\text{rank}(\mathbf{Y}) \leq K} \|\mathbf{X} - \mathbf{Y}\|_F^2.$$

PCA 先中心化 $\mathbf{X}_c = \mathbf{X} - \bar{\mathbf{x}} \mathbf{1}^T$ ，再求

$$\max_{\mathbf{U}^T \mathbf{U} = \mathbf{I}_K} \|\mathbf{U}^T \mathbf{X}_c\|_F^2 \iff \min_{\mathbf{U}^T \mathbf{U} = \mathbf{I}_K} \|\mathbf{X}_c - \mathbf{U} \mathbf{U}^T \mathbf{X}_c\|_F^2.$$

LSA 通常直接对词-文档权重矩阵 $\mathbf{X}$ 作截断 SVD，并把 $\mathbf{\Sigma}_K \mathbf{V}_K^T$ 解释为潜在语义坐标。三者共享奇异向量计算，但数据预处理和输出语义不同，不能互换名称。

练习 37.4. 从高斯与泊松观测模型分别推出平方损失和广义 KL；说明哪一种可用于原始计数，以及为什么 TF-IDF 不应解释为泊松计数。

练习 37.4 解析

记 $\lambda_{ij} = (\mathbf{W} \mathbf{H})_{ij}$ 。独立同方差高斯模型给出

$$p(\mathbf{X} | \mathbf{W}, \mathbf{H}) = \prod_{i,j} (2\pi\sigma^2)^{-1/2} \exp \left[-\frac{(x_{ij} - \lambda_{ij})^2}{2\sigma^2} \right],$$

练习 37.4 解析 (续)

逐项取负对数即得常数加 $\|X - WH\|_F^2/(2\sigma^2)$ 。独立泊松模型则有 $p(N | \Lambda) = \prod_{i,j} e^{-\lambda_{ij}} \lambda_{ij}^{n_{ij}} / n_{ij}!$, 故

$$-\log p = \sum_{i,j} \{\lambda_{ij} - n_{ij} \log \lambda_{ij} + \log(n_{ij}!)\}.$$

逐格采用扩展实数定义: $n = 0, \lambda = 0$ 时, 以 $0 \log 0 = 0$ 和 $0 \log(0/0) = 0$ 约定, 两项目标都贡献 0; $n = 0, \lambda > 0$ 时, 两者都贡献 λ ; $n > 0, \lambda = 0$ 时, 两者都为 $+\infty$; 只有 $n > 0, \lambda > 0$ 时才按通常对数代数相减。因而在全部分支上, 它与 $D_{\text{gKL}}(N \| \Lambda)$ 之差都是 $\sum_{i,j} \{\log(n_{ij}!) - n_{ij} \log n_{ij} + n_{ij}\}$, 只依赖观测。正计数处必须有 $\lambda_{ij} > 0$ 才能得到有限目标。原始非负整数频数适合检验泊松口径; TF-IDF 经过归一化和逆文档频率变换, 不是事件计数, 所以可用平方损失工作模型, 却不能声称泊松生成语义。

练习 37.5. 判断并修正三句话: “EM 收敛到全局最优” “VI 收敛到真实后验” “Gibbs 收敛到全局最优参数”。

练习 37.5 解析

EM 在精确 E/M 更新且似然有限时满足似然单调性

$$\ell(\theta^{(t+1)}; \mathbf{x}) \geq \ell(\theta^{(t)}; \mathbf{x}).$$

这条不等式本身既不保证参数序列收敛, 也不排除非唯一 M 步在等似然集合内移动。若进一步假设更新在极限点附近单值连续、M 步解局部唯一且参数迭代确实收敛到 θ^* , 才有

$$\theta^{(t)} \rightarrow \theta^* \implies \|\theta^{(t+1)} - \theta^{(t)}\| \rightarrow 0.$$

相邻参数差趋零至多是停止诊断; 在通常可微与内部点等正则条件下, 极限点可为驻点或局部解, 并不自动是全局最优。VI 在给定变分族与合法坐标更新下满足

$$\log p(\mathbf{x}) = \mathcal{L}(q, \theta) + D_{\text{KL}}(q(z) \| p(z | \mathbf{x}, \theta)), \quad \mathcal{L}^{(t+1)} \geq \mathcal{L}^{(t)},$$

所得是该族内近似后验, 不自动等于真实后验。有限状态 Gibbs 链不可约时, 目标后验唯一且可积函数的时间平均收敛; 非周期性另保证固定时刻边缘分布收敛。一般状态链相应要求正常 Harris 返与可积性才能得到时间平均, 再加非周期性才谈总变差或边缘收敛; CLT、有限渐近方差和批均值一致性还需额外矩与混合条件。它不是寻找“全局最优参数”的单调优化。

$$\hat{f}_n = \frac{1}{n} \sum_{t=1}^n f(X_t) \longrightarrow E_{\pi} f \quad \text{依赖链条件, 而非“全局最优参数”}.$$

练习 37.6. 采用本章 PLSA 联合概率口径, 写出 W, H 的归一化约束; 再说明 LDA 比 PLSA 多出的随机变量与先验。

练习 37.6 解析

联合口径取 $w_{ik} = p(w_i | z_k)$, 所以每列满足 $\sum_i w_{ik} = 1$; $H_{kj} = p(d_j)p(z_k | d_j)$, 故 $H \geq 0$ 且 $\sum_{k,j} H_{kj} = 1$, 但单列和是 $p(d_j)$ 而非统一为 1。完整 Bayes LDA 把每篇文档的主题比例

练习 37.6 解析 (续)

θ_j 和每个主题的词分布 φ_k 都视为随机变量, 分别配置狄利克雷先验, 再对主题指派与参数后验作推断; 第 35 章 (第 5 册第 6 章) 的点参数变体保留 θ_j 先验, 却把 φ_k 作为待估单纯形参数。

$$W_{ik} \geq 0, \quad \sum_i W_{ik} = 1; \quad H_{kj} \geq 0, \quad \sum_{k,j} H_{kj} = 1, \quad \sum_k H_{kj} = p(d_j).$$

$$p(w_i, d_j) = \sum_k W_{ik} H_{kj}, \quad \sum_{i,j} p(w_i, d_j) = 1.$$

完整 Bayes LDA 额外引入

$$\theta_j \sim \text{Dir}(\alpha), \quad \varphi_k \sim \text{Dir}(\beta), \quad z_{jn} | \theta_j \sim \text{Cat}(\theta_j).$$

点参数变体则用

$$\theta_j \sim \text{Dir}(\alpha), \quad \varphi_k \in \Delta^{V-1} \text{ 为参数,}$$

其 ELBO 和 M 步不含 β 。

练习 37.7. 数据由两个细长弯曲簇和少量异常点构成。设计至少三种聚类候选、验证指标、稳定性检查和失败诊断。

练习 37.7 解析

候选可含 k 均值、不同链接规则的层次聚类和能表达非凸连通结构的图聚类; 先对特征尺度和异常值处理方案作开发集内选择。评价同时报告内部紧致/分离指标、重采样后经标签匹配的簇一致性、异常点扰动敏感度和运行成本。 k 均值的非球形失配、层次链接的链化、图聚类对邻接参数敏感都应列为失败诊断。

$$\hat{b} = \arg \max_{b \in \mathcal{B}_{\text{ok}}} \{\overline{\text{sil}}_b : \text{stab}_b \geq s_0, C_b \leq C_{\max}\},$$

$$\text{stab}_b = \frac{2}{R(R-1)} \sum_{r < s} \text{ARI}(\hat{z}_b^{(r)}, \hat{z}_b^{(s)}), \quad \text{fail}_b = R^{-1} \sum_r \mathbf{1}\{\text{拟合 } r \text{ 失败}\}.$$

若全部候选违反稳定性、失败率或预算约束, 则停止选择并报告“无合格候选”。

练习 37.8. 分别为 PageRank 与 MCMC 列出模型方程、数值停止或诊断量, 并解释为何两者都出现马尔可夫链却不能共用同一收敛报告。

练习 37.8 解析

PageRank 求列随机阻尼矩阵的固定点 $\mathbf{r} = G\mathbf{r}$, 用相邻迭代差、固定点残差、概率守恒和严格误差上界停止。

$$\mathbf{r}^{(t+1)} = G\mathbf{r}^{(t)}, \quad \eta_t = \|\mathbf{r}^{(t)} - G\mathbf{r}^{(t)}\|_1, \quad B_t = \frac{d}{1-d} \|\mathbf{r}^{(t)} - \mathbf{r}^{(t-1)}\|_1.$$

MCMC 构造转移核 K 满足 $\pi K = \pi$, 以目标后验 π 为平稳分布, 并用

$$\hat{I}_n = \frac{1}{n} \sum_{t=1}^n f(X_t), \quad \widehat{\text{MCSE}}_{\text{BM}} = \sqrt{\hat{\sigma}_{\text{BM}}^2/n}$$

练习 37.8 解析 (续)

估计 $\mathbb{E}_{\pi}[f(X)]$ 及其数值不确定性；有限链不可约或一般状态链正常 Harris 返且 $f \in L^1(\pi)$ 时，才有相应时间平均结论；非周期性另用于固定时刻边缘或总变差收敛；CLT、MCSE 和批均值还需额外矩与混合条件。有限运行必须报告独立链数 R_{chain} 、逐链预热/留样预算、 $\hat{R}$ 、自相关、ESS 和 MCSE；这些只是诊断，不能替代上述条件，也不应汇总成 converged 证书。前者是确定固定点数值迭代，后者是相关随机样本推断；共享马尔可夫术语不意味着共享停止阈值或证明。

练习 37.9. 某研究者在测试集上选择主题数、停词表和随机种子，再报告同一测试集困惑度。指出全部泄漏路径并重写嵌套验证流程。

练习 37.9 解析

主题数、停词表和随机种子都由测试困惑度选择，形成三条测试到模型的反馈路径；随后再报同一数值会产生选择偏差。应先封存测试文档，在开发集内执行 C_{in} 折选择：每个内层训练折拟合词表与模型，在内层验证折选择全部配置；锁定后在完整开发集重拟合，最后按文档完成协议对测试文档评分一次，并同时报告稳定性、失败率和成本。

$$\hat{\lambda} = \arg \min_{\lambda=(K, \mathcal{V}, s)} \widehat{\text{PPL}}_{\text{val}}(\lambda), \quad \lambda \text{ 仅由开发集内层折决定.}$$

$$\hat{f} = \text{Refit}(\mathcal{D}_{\text{dev}}, \hat{\lambda}), \quad \hat{R}_{\text{test}} = m^{-1} \sum_{i=1}^m \ell(\hat{f}, Z_i) \quad \text{只计算一次.}$$

练习 37.10. 为“从百万篇新闻中提取可解释主题，并支持新文档快速表示”给出完整方案：说明任务、数据划分、候选模型、训练或推断、指标、诊断与计算成本。

练习 37.10 解析

任务定义为学习主题词分布并为新文档产生低维表示。按时间或来源划分开发/测试文档，候选设为 NMF、PLSA 和 LDA 及有限 K ；训练分别使用声明的损失与求解器。开发集内以文档完成对数似然或重构效用选配置，并联合主题稳定性、人工可读性、失败率、单文档推断时间和最大工作存储量。若词-文档矩阵含 $\text{nnz}(X)$ 个非零元，则稀疏截断 LSA 每次矩阵-向量/块乘的主成本为 $O(\text{nnz}(X)K)$ 。对平方 Frobenius 损失的标准稀疏 NMF 乘法更新，一轮还要形成或应用 $K \times K$ Gram 矩阵，故训练主成本为 $O(\text{nnz}(X)K + (M + N)K^2)$ ， I 轮再乘 I ；其他散度、坐标更新或稠密实现必须另报。训练期保存两因子需 $O((M + N)K)$ ，只部署主题词字典时可为 $O(MK)$ 。对含 $\text{nnz}(x)$ 个非零词的新文档，LSA 投影为 $O(\text{nnz}(x)K)$ ；若预先保存 $W^T W$ ，NMF 的每轮非负系数更新为 $O(\text{nnz}(x)K + K^2)$ 。报告必须同时给出文档数 N 、词表大小 M 、秩/主题数 K 、训练轮数 I 和新文档轮数 I_{doc} ；PLSA/LDA 则按各自推断器另列。最终方案还应给出确定的词表、模型参数、变换规则、一次测试结果，以及新文档超出词表时的处理方式。

$$\hat{\lambda} = \arg \min_{\lambda \in \Lambda_{\text{ok}}} \left\{ \bar{L}_{\text{val}}(\lambda) : \text{stab}(\lambda) \geq s_0, \text{fail}(\lambda) \leq f_0, C(\lambda) \leq C_{\text{max}} \right\}.$$

练习 37.10 解析 (续)

主要稀疏复杂度为

$$\begin{aligned} T_{\text{NMF}} &= O(I[\text{nnz}(X)K + (M + N)K^2]), & S_{\text{train}} &= O((M + N)K), \\ T_{\text{LSA,new}} &= O(\text{nnz}(x)K), & T_{\text{NMF,new}} &= O(I_{\text{doc}}[\text{nnz}(x)K + K^2]). \end{aligned}$$

读前自检：本章结论与下一步。 无监督学习方法总结以任务、表示、准则、算法、评价和预算组成工作规格；请按“开发集内比较每个候选的各验证折 – 重拟合锁定配置 – 仅一次解封测试集”标出测试集首次可访问位置，核对候选选择和预算调整均未读取测试结果。

本章结论与下一步

核心结论：本讲义用任务、表示、准则、算法、评价与预算组成工作性无监督学习规格，而非给出学界统一定义。

关键依据：高斯观测对应平方重构，泊松计数对应扩展实数广义 KL，PLSA 联合 token 似然对应联合 KL；每个对应都有定义域。

可执行自检：选择协议在开发集内完成全部候选与折比较，重拟合锁定配置后只解封一次测试集。

适用边界：共享低秩乘积或马尔可夫术语不意味着共享语义与保证；EM、VI、Gibbs、SVD 和幂法必须各用自己的条件。

下一步：回看全书时按“任务—表示—准则—求解—评价”五列核对；任一列缺失就返回相应章节补齐。

1. 我能把任务、模型、训练准则和求解器分开；否则回看定义 37.1。
2. 我能写出 LSA、NMF、PLSA 因子的维数和约束，并逐行推出高斯、泊松与联合多项式目标；否则回看节 37.2 和推导第 1–3 步。
3. 我不会把 EM、VI 和 Gibbs 的保证混写；否则回看本章优化与概率解释。
4. 我能设计训练/验证/测试隔离和文档完成评价，并为聚类、话题、PageRank 和 MCMC 选择各自诊断；否则回看图 37.5 与评价面板。
5. 我能按算法 37.1 说明停止原因、计算成本与一次锁定测试结果。

全书回看建议

回看全书时可按“任务与数据结构—模型表示—学习或推断目标—求解器—诊断与评价”五列重整每一种方法。若某列无法明确填写，应返回相应章节核对定义域、维数、随机性、停止条件和失效模式；只有五列闭合且测试协议冻结，模型比较才具有可重复含义。

算法阅读与执行契约 C1-C14

每个算法标题都是可点击的契约入口；它与算法框中的专用输入、输出和正文复杂度段共同构成完整接口：C1 输入，C2 输出，C3 前置条件，C4 初始化，C5 循环变量，C6 更新次序，C7 有限性与定义域检查，C8 失败分支，C9 数学停止证书，C10 预算上限，C11 返回状态，C12 实际完成轮数，C13 最终诊断，C14 复杂度假设。变量必须先初始化后使用并按行更新；非有限、越域、零分母或线搜索失败不得冒充成功。只有正文给出的残差、KKT、固定点、有限穷举或相对于冻结候选类的证书满足时才返回 converged；有限闭式计算、扫描、排序或动态规划按定义结束时返回 completed。参数或目标变化阈值达到但没有数学证书时返回 numerical_failure，并在诊断中写明“数值平台”；验证耐心、连续无更新保护轮数或其他显式预算耗尽时返回 budget_stop，并在诊断中区分预算种类。输入、数值、线搜索和随机源失败分别返回 invalid_input、numerical_failure、line_search_failed 和 random_source_failure。无可行路径属于有限动态规划的完成结果，无正弱边只有在候选类已冻结且边缘已完整核验时才构成相对证书；两者的具体结果都写入诊断，不新增状态枚举。输出还须携带实际轮数和最终诊断；时间、空间口径以相邻复杂度段声明的数据表示、单步成本和多启动／多链／搜索次数为准。

统一返回状态字典（首次出现的中英映射）

状态码	中文释义	触发口径
converged	收敛	残差、KKT、固定点、单调性或有限穷举证书达到正文阈值。
completed	有限过程完成	有限闭式计算、扫描或排序按定义完成。
budget_stop	预算停止	迭代、时间、评估、验证耐心或连续无更新保护预算耗尽，尚无收敛证书。
invalid_input	输入非法	维数、定义域、归一化或必要前置条件不成立。
numerical_failure	数值失败	溢出、非有限值、分解失败，或达到数值平台但没有数学停止证书；具体原因写入诊断。
line_search_failed	线搜索失败	合法试探步中没有找到满足接受条件的步长。
random_source_failure	随机源失败	所需随机数流不可用或不满足算法声明。

主题索引

如何使用主题索引

主题索引优先列规范名称；缩写和近义名通过“见”或“另见”指向主条目。电子阅读时可点击页码跳转，并用[目录](#)返回学习主线。

- AdaBoost, 336
- AdaBoost 是前向分步加法算法的特例, 343
- AdaBoost 最终分类器的训练误差, 341
- AdaBoost 的计算例题, 349
- AdaBoost 算法, 339
- AdaBoost 算法的解释, 340
- AdaBoost 算法的训练误差分析, 341
- Baum–Welch 模型参数估计公式, 398
- Baum–Welch 算法, 386, 398, 399
- BFGS 算法, 121
- BFGS (Broyden–Fletcher–Goldfarb–Shanno) 算法, 121
- Broyden 类算法, 122
- C4.5 生成算法, 250
- C4.5 的算法步骤, 251
- CART, 243
- CART 剪枝, 256
- CART 最弱环节剪枝算法, 257
- CART 生成, 254
- CART 生成算法, 255
- CART 算法, 254
- DFP 算法, 121
- DFP (Davidon–Fletcher–Powell) 算法, 121
- Dirichlet 分布, *see* 狄利克雷分布
- EM 对数似然值与参数估计序列的收敛性, 366
- EM 算法, 359, 361, 364, 552
- EM 算法似然函数序列的单调性, 366
- EM 算法及其推广, 361
- EM 算法在无监督学习中的应用, 376
- EM 算法在高斯混合模型学习中的应用, 367
- EM 算法的一次迭代可由 F 函数的极大-极大算法实现, 372
- EM 算法的导出, 362
- EM 算法的引入, 361
- EM 算法的推广, 371
- EM 算法的收敛性, 366
- Frobenius 范数, 486
- F 函数, 370
- F 函数与观测数据对数似然的等价关系, 371
- F 函数极大值与观测数据对数似然极大值的关系, 372
- F 函数的极大-极大算法, 371
- Gamma 函数与 Gamma 分布, 66
- GEM 算法, 359, 372
- Gibbs 坐标核的目标保持, 672
- Gibbs 抽样, 666
- Gibbs 抽样的满条件分解, 668
- Gibbs 抽样的满条件提议, 672
- Hammersley–Clifford 定理, 415
- Hessian 矩阵, 39
- ID3 的递归过程, 250
- ID3 算法, 250
- Jacobian 矩阵, 40
- Jensen 不等式, 104
- KKT 条件, 100
- KL 散度的定义, 85
- KL 散度的定义和狄利克雷分布的性质, 85
- KL 散度 (相对熵), 85
- k 值的选择, 207
- k 均值聚类, 471
- k 均值聚类, 465
- k 均值聚类算法, 474
- k 近邻模型, 211
- k 近邻法, 207
- k 近邻法, 206
- k 近邻法的实现: kd 树, 213
- k 近邻法算法, 211
- k 近邻算法, 211
- LDA, *see* 潜在狄利克雷分配
- LDA 两类推断路线总结, 730
- LDA 变分 EM 局部—全局更新, 725
- LDA 变分 EM 算法, 725
- LDA 变分 EM 超参数与评估, 730
- LDA 变分更新推导, 725
- LDA 折叠 Gibbs 抽样, 723
- LDA 折叠 Gibbs 条件更新, 723
- LDA 文档—主题—词模型, 717
- LDA 生成过程与概率图, 717
- LDA 的变分参数估计算法, 725
- LDA 的文本生成算法, 718
- LDA 的混合主题思想, 717
- MCMC, *see* 马尔可夫链蒙特卡罗法
- MCMC 基本思想, 636
- MCMC 的提议—接受—留驻步骤, 636
- MCMC 的目标保持与可达性, 636
- Metropolis–Hastings 拒绝自环, 639
- Metropolis–Hastings 接受率, 639
- Metropolis–Hastings 核可逆性, 639
- Metropolis–Hastings 算法, 655
- Metropolis–Hastings 转移核, 639
- Monte Carlo 标准误, 655
- Novikoff 定理, 193
- PageRank, 749
- PageRank 固定点定义, 751

PageRank 的一般定义, 756
 PageRank 的基本定义, 753
 PageRank 的计算, 760
 PageRank 的随机游走思想, 751
 PageRank 迭代算法, 760
 PageRank 阻尼排序算法, 751
 PLSA 共现模型, 556
 PLSA 参数估计的 EM 算法, 558
 PLSA 模型性质, 557
 PLSA 生成模型, 556
 PLSA 的基本思想, 555
 PLSA 算法, 558

 Q 函数, 362
 Q 函数单调上升的广义 EM, 373

 Slater 条件, 106
 SMO 两变量未剪辑解, 321
 SMO 变量的选择方法, 321
 SMO 算法, 321
 SMO 算法的完整流程, 321

 TF-IDF, 530

 Viterbi 最优路径递推, 400
 Viterbi 算法, 386, 401, 412

 一些概率与期望值的计算, 393
 一元高斯分布, 65
 一致弱学习条件下的指数误差界, 342
 一般 PageRank 的幂法计算, 760
 一般条件随机场, 417
 上标、下标与转置记号, 6
 不可约性, 584
 不可约正常返链, 586
 两个变量二次规划的求解方法, 321
 严格凸函数, 100
 主成分个数, 513
 主成分分析, 509, 510
 主成分分析算法, 521
 主题分布与主题词分布的后验汇总, 723
 主题指派与计数表, 723
 主题模型, 715
 二次型, 23
 二次型的梯度, 40
 二类 AdaBoost 的训练误差界, 341
 二项分布, 65
 二项逻辑斯谛回归模型, 270
 二项逻辑斯谛回归的条件概率分布, 270
 互信息, 87
 互补松弛条件, 101
 交叉熵, 85
 交叉验证, 158
 从给定分布抽样, 611
 代数算法, 760
 以平稳链估计目标期望, 636
 优化问题的基本形式, 98
 伯努利分布, 65
 似然函数, 67
 低秩近似, 486
 信息增益, 88, 243, 246
 信息增益比, 88, 247
 信息增益比的定义, 247
 信息增益的定义, 246
 信息增益的算法, 246

信息论, 81
 信息量, 82

 偏导数, 38
 先验、似然与后验, 69
 全概率公式, 50
 全直径阈值类, 468
 共轭先验, 69, 690, 699
 决策树, 243, 244
 决策树与 if-then 规则, 245
 决策树与条件概率分布, 245
 决策树剪枝, 253
 决策树学习, 245
 决策树模型, 244
 决策树模型与学习, 244
 决策树的生成, 250
 几何解释, 498
 几何间隔, 311
 凸优化, 98
 凸函数, 100
 凸函数的一阶条件, 104
 凸函数的二阶条件, 104
 凸集, 100
 函数间隔, 311
 函数间隔和几何间隔, 311
 分块条件极大化的广义 EM, 374
 分类决策树的结构定义, 245
 分类决策规则, 208
 分类问题, 171
 判别方法, 434
 前 k 个主成分对原变量的贡献率, 514
 前 q 个主成分具有最大方差, 513
 前向 - 后向算法, 412, 422
 前向 - 后向递推, 391
 前向分步算法, 336, 342
 前向分步算法与 AdaBoost, 343
 前向概率, 391
 前向算法, 386, 392
 动态规划与递推, 391
 协方差与协方差矩阵, 51
 协方差矩阵, 509
 协方差矩阵特征对刻画总体主成分, 512
 单分量 Metropolis-Hastings 算法, 639
 单分量 Metropolis-Hastings 算法, 655
 单纯形, 552, 695
 单词 - 文本矩阵, 530
 单词向量空间, 532
 单词向量空间与话题向量空间, 532
 原始问题, 105
 原始问题和对偶问题的关系, 106
 原问题, 105
 参数、变量、样本、特征与标签, 6
 双向目标 - 提议流, 639
 可行域, 99
 可逆马尔可夫链, 589, 638
 各种方法之间的关系, 775
 合页损失函数, 317
 吉布斯抽样, *see* Gibbs 抽样
 后向概率, 393
 后向算法, 393
 后验概率最大化的含义, 228
 向量内积, 20
 向量及其分量, 20
 向量夹角, 20

- 向量空间的基和维数, 22
- 向量空间的子空间, 22
- 向量范数, 20
- 命题、量词与常用数学逻辑, 6
- 回归问题, 174
- 回归问题的提升树算法, 344
- 因子分解、势函数与归一化, 415
- 团与最大团, 415
- 固定参数时 F 函数极大化的唯一分布, 371
- 坐标下降, 123
- 基、坐标与维数, 21
- 基于 F 函数的交替极大化, 372
- 基尼指数, 89, 255
- 基本 PageRank 固定点, 753
- 基本分类, 142
- 基本想法, 511
- 基本方法, 227
- 基础机器学习方法, 785
- 多元函数, 38
- 多元函数极值的必要条件, 39
- 多元微积分与矩阵微分, 32
- 多元泰勒展开, 40
- 多元链式法则, 40
- 多元高斯分布, 65
- 多项分布, 65, 691, 692
- 多项分布定义, 691
- 多项逻辑斯蒂回归, 268, 277
- 大数定律与样本均值, 51
- 夹角余弦, 468
- 奇异值与奇异值分解的预备知识, 23
- 奇异值分解, 486, 487
- 奇异值分解与矩阵近似, 495
- 奇异值分解基本定理, 488
- 奇异值分解的主要性质, 490
- 奇异值分解的定义与性质, 487
- 奇异值分解的矩阵因子形式, 487
- 奇异值分解的计算, 493
- 子空间的正交补, 22
- 学习与分类算法, 230
- 学习的对偶算法, 314
- 学习策略, 436
- 学习算法, 397, 438
- 定义与定理, 487
- 定义和导出, 511
- 定理 C.1, 106
- 定理 C.2, 106
- 定理 C.3, 100
- 定理 D.1, 22
- 对偶函数, 105
- 对偶问题, 105
- 对数似然, 67
- 对数几率, 268
- 对数函数的梯度, 40
- 对称矩阵, 23
- 对称矩阵的谱分解, 23
- 局部最优与全局最优, 99
- 层次聚类, 465, 470
- 常用核函数, 319
- 常用矩阵微分公式及分量解释, 40
- 幂法, 749, 760
- 幂法与最大模特征方向, 23
- 平均与最大距离阈值类, 468
- 平均场变分推断, 725
- 平均距离阈值类, 468
- 平方损失下的乘法更新规则, 540
- 平稳分布, 582
- 平稳分布的固定点定义, 582
- 平稳分布的流量解释, 582
- 序列最小最优化, 309
- 序列最小最优化算法, 321
- 序列标注问题, 417
- 弗罗贝尼乌斯范数, 495
- 弱对偶, 106
- 强对偶, 106
- 总体、样本、参数与统计量, 67
- 总体主成分分析, 511
- 总体主成分定义, 511
- 总体主成分的主要性质, 513
- 感知机, 185, 186
- 感知机学习策略, 188
- 感知机学习策略的损失函数, 188
- 感知机学习算法, 190
- 感知机学习算法原始形式, 190
- 感知机学习算法对偶形式, 194
- 感知机学习算法的原始形式, 190
- 感知机学习算法的对偶形式, 194
- 感知机学习算法的收敛性, 193
- 感知机定义, 186
- 感知机模型, 186
- 截断 SVD
 - 潜在维数选择, 532
- 截断 SVD 的低秩最优性, 496
- 截断奇异值分解, 486, 492
- 批均值, 655
- 折叠 Gibbs 扫描流程, 723
- 折叠抽样的留一计数思想, 723
- 抽样计算, 678
- 抽稀, 655
- 拉格朗日乘法, 105
- 拉格朗日函数, 105
- 拉格朗日对偶, 98
- 拉格朗日对偶性, 105
- 拒绝自环, 655
- 拟牛顿法, 121, 291, 421
- 拟牛顿法的思路, 121
- 指数函数与对数函数的微分, 40
- 指数族分布, 71
- 指示函数, 6
- 按技巧分类, 144
- 按模型分类, 143
- 按算法分类, 144
- 接受 - 拒绝抽样, 612
- 接受 - 拒绝法, 612
- 接受 - 拒绝抽样, 612
- 接受概率, 655
- 接受率的成对流推导, 641
- 推论 C.1, 106
- 提升方法, 336, 337
- 提升方法 AdaBoost 算法, 338
- 提升方法的基本思路, 337, 338
- 提升树, 336, 344
- 提升树模型, 344
- 提升树算法, 344
- 搜索 kd 树, 216
- 支持向量, 316
- 支持向量机, 309, 310
- 改进的迭代尺度法, 287, 295, 421

- 改进的迭代尺度算法 IIS, 295
改进迭代尺度, 412
散度损失下的乘法更新规则, 540
数值优化, 117
数学期望, 51
数学期望估计, 607
数学语言、符号约定与学习路线, 2
数据矩阵的奇异值分解算法, 518
数据集的线性可分性, 186
数据集线性可分性定义, 186
文档—单词矩阵与词袋表示, 531
方向导数, 38
方差, 51
方差最大化, 509
方差贡献率, 514
无监督学习, 450, 773
无监督学习基本原理, 451
无监督学习方法, 453, 785
无监督学习方法总结, 775
无监督学习方法的关系和特点, 775
无监督学习概论, 451
无监督学习的基本问题, 452
映射与函数, 6
最大后验估计, 69
最大熵与改进迭代尺度法的优化基础, 124
最大熵原理, 287, 288
最大熵模型, 287, 288
最大熵模型学习的 BFGS 算法, 291
最大熵模型的学习, 292
最大熵模型的定义, 292
最大间隔分离超平面的存在唯一性, 313
最小二乘回归树生成算法, 254
有向图上的随机游走例, 751
有向图和随机游走模型, 751
有效样本量, 655
有限状态链的唯一平稳分布, 586
期望值的计算, 420
朴素贝叶斯法, 226, 227
朴素贝叶斯法的参数估计, 230
朴素贝叶斯法的学习与分类, 227
朴素贝叶斯算法, 228
机器学习三要素, 453
条件分布, 56
条件期望, 51
条件概率, 49
条件熵, 83, 287
条件独立, 57, 226
条件随机场, 412, 414
条件随机场模型学习的 BFGS 算法, 421
条件随机场模型学习的改进的迭代尺度法, 421
条件随机场的参数化形式, 418
条件随机场的学习算法, 420
条件随机场的定义, 417
条件随机场的定义与形式, 417
条件随机场的概率计算问题, 422
条件随机场的矩阵形式, 419
条件随机场的简化形式, 418
条件随机场的预测算法, 424
条件随机场预测的 Viterbi 算法, 424
极大似然, 268
极大似然估计, 67, 230, 290
构造 kd 树, 213
构造平衡 kd 树, 213
标准化变量的总体主成分分析, 513
标注问题, 173
标量、向量与矩阵记号, 6
标量对向量求导, 40
树的剪枝算法, 253
样本主成分分析, 515
样本主成分的定义和性质, 516
样本主成分的方差最大化刻画, 516
样本空间与随机事件, 48
核函数, 309
核函数的定义, 319
核技巧, 318
梯度, 38
梯度下降与步长, 117
梯度下降法, 118, 119
梯度提升, 336, 346
梯度提升算法, 347
概率公式, 718
概率公理与基本运算, 49
概率分布与分布函数, 55
概率图模型, 718
概率图模型与条件独立, 414
概率无向图模型, 412, 414
概率无向图模型的因子分解, 415
概率无向图模型的马尔可夫性质, 414
概率潜在语义分析, 552, 554
概率潜在语义分析模型, 554
概率潜在语义索引, 552
概率计算, 420
概率计算算法, 391
概率论基础, 48
模型, 145, 211, 438, 471
模型参数估计, 273
模型学习的最优化算法, 290
模型定义, 414, 718
模型评估, 151
模型评估与模型选择, 154
模型选择, 434, 773
正交与标准正交组, 21
正交投影, 22
正则化, 156
正则化与交叉验证, 155
正定核, 319
正定核的充要条件, 319
正定核的等价定义, 320
正定矩阵与半正定矩阵, 23
正常返, 585
求和、连乘与索引记号, 6
泛化能力, 151, 160
泛化误差, 160
泛化误差上界, 160
泛化误差上界: 有限二类分类假设空间, 160
满条件分布, 671
满条件分布的逐坐标更新原理, 668
满足经验约束的最大熵条件模型, 292
潜在主题, 552
潜在主题、混合分布与文档表示, 553
潜在狄利克雷分配, 715, 717
潜在结构, 450
潜在语义分析, 530, 532
潜在语义分析数值例子, 544
潜在语义分析模型, 535
潜在语义分析算法, 533
潜在语义因子模型
 模型定义, 532

潜在语义索引, 530

点到超平面的距离, 22

熵, 82

燃烧期, 636

牛顿法, 121, 128

牛顿法和拟牛顿法, 121

特征值与特征向量, 23

特征选择, 246

特征选择问题, 246

状态转移矩阵, 389, 580

狄利克雷—多项建模入口, 691

狄利克雷分布, 69, 690

定义, 695

狄利克雷分布定义, 695

狄利克雷分布的矩与条件性质, 695

生成式学习, 450

生成方法, 434

生成模型与判别模型, 162

用 kd 树的 k 近邻搜索, 216

由对偶解恢复硬间隔原始解, 315

由软间隔对偶解恢复原始解, 317

监督学习任务与应用, 170

监督学习应用, 171

监督学习方法, 398

监督学习方法总结, 434, 435

目标函数, 99

直接计算法, 391

相似度或距离, 467

相关矩阵的特征值分解算法, 519

相关系数, 468

矩阵乘法的分量形式, 20

矩阵分解, 773

矩阵及其分量, 20

矩阵奇异值分解算法, 533

矩阵的基本子空间, 22

矩阵的外积展开式, 499

矩阵的最优近似, 496

矩阵的秩, 21

矩阵的行空间和列空间, 22

矩阵的迹, 23

矩阵的零空间, 22

离散状态马尔可夫链, 580

秩—零度定理, 22

积分自相关时间, 655

积分计算, 607

等式约束与不等式约束, 99

策略, 152, 472

算法, 153, 474

算法特性, 473

类与类之间的距离, 469

类别分布, 692

类或簇, 467

系统扫描, 655

系统扫描 Gibbs 算法, 672

紧奇异值分解, 486, 491

紧奇异值分解与截断奇异值分解, 491

线性代数基础, 14

线性函数的梯度, 40

线性可分支持向量机, 311

线性可分支持向量机与硬间隔最大化, 310

线性可分支持向量机学习算法, 315

线性可分支持向量机学习算法——最大间隔法, 312

线性可分支持向量机的规范定义, 312

线性支持向量机, 316

线性支持向量机与软间隔最大化, 316

线性支持向量机原始最优化问题, 318

线性支持向量机学习算法, 317

线性支持向量机的定义, 316

线性方程组与解空间, 21

线性相关与线性无关, 21

线性组合与张成, 21

线性链条件随机场, 418

线性链条件随机场的参数化形式, 418

线搜索, 118

细致平衡, 638

细致平衡方程, 638

统计学习, 142

统计学习及监督学习概论, 142

统计学习方法, 1

统计学习方法三要素, 145

统计学习的分类, 142

统计学习的基本框架, 135

统计推断, 64

联合分布, 56

联合熵, 83

聚合聚类算法, 470

聚类, 465

聚类方法, 466

聚类的基本概念, 466

自相关, 655

舍弃主成分具有最小信息损失, 514

蒙特卡罗估计, 607

蒙特卡罗法, 607

行列式, 20

表示学习, 450

观测序列概率的前向算法, 392

观测序列概率的后向算法, 393

观测序列的生成, 390

观测序列的生成过程, 390

训练误差与测试误差, 154

话题向量空间, 533

话题模型, 773

话题模型之间的关系和特点, 778

贝叶斯估计, 231

贝叶斯公式, 50

超平面及其法向量表示, 21

距离, 465

距离与度量, 20

距离度量, 207

软间隔学习的对偶算法, 316

软间隔支持向量, 317

边缘似然, 71

边缘分布, 56

过拟合与模型选择, 155

近似算法, 401

近邻连通阈值类, 468

连接, 465

连续状态马尔可夫链, 581

迭代算法, 760

迭代算法的停止条件与收敛判据, 119

适用问题, 439

逆变换抽样, 611

通用变分 EM 坐标上升, 725

逻辑斯谛分布, 270

逻辑斯谛分布的分布函数与密度函数, 270

- 逻辑斯谛回归, 268
- 逻辑斯谛回归与最大熵模型, 269
- 逻辑斯谛回归模型, 270
- 遍历均值, 636
- 遍历定理, 586
- 重构误差, 509
- 重要性抽样, 616
- 链接权重按出度分配, 751
- 间隔最大化, 309, 312
- 闵可夫斯基距离, 467
- 阻尼随机游走, 756
- 随机变量, 55
- 随机变量序列的可交换性, 718
- 随机变量的独立性, 57
- 随机扫描, 655
- 随机抽样, 607
- 随机游走, 592, 749
- 随机过程, 388
- 隐变量, 359
- 隐变量与不完全数据, 71
- 隐马尔可夫模型, 386, 388
- 隐马尔可夫模型的 3 个基本问题, 391
- 隐马尔可夫模型的基本概念, 388
- 隐马尔可夫模型的定义, 389
- 集合、元素与集合运算, 6
- 非周期性, 584
- 非线性支持向量分类机, 320
- 非线性支持向量机与核函数, 318
- 非线性支持向量机学习算法, 320
- 非线性支持向量机的定义, 320
- 非负矩阵分解, 530, 535
- 非负矩阵分解的形式化, 535
- 非负矩阵分解的迭代算法, 540
- 非负矩阵分解算法, 535, 540
- 预测算法, 400
- 马哈拉诺比斯距离, 467
- 马尔可夫性质, 388, 578
- 马尔可夫性质与时齐转移, 578
- 马尔可夫链, 388, 578
- 马尔可夫链的性质, 584
- 马尔可夫链的随机过程表述, 578
- 马尔可夫链蒙特卡罗法, 634
- 马尔可夫链蒙特卡罗法与统计学习, 645
- 马尔可夫链蒙特卡罗目标期望, 636
- 高斯混合模型, 359, 367
- 高斯混合模型参数估计的 EM 算法, 368, 369